

# Optimización y Análisis de Redes

---

Diapositivas de la  
Asignatura

Grado en Matemáticas

## AUTORES

- Víctor Aceña Gil
- Antonio Alonso Ayuso

2026-2027



# Índice de diapositivas

---

- Tema 1: Introducción a la investigación operativa
- Tema 2: Optimización no lineal y métodos numéricos

# Tema 1: Introducción a la investigación operativa

## Optimización y Análisis de Redes

Víctor Aceña Gil - Antonio Alonso Ayuso

2026-06-15

# Introducción a la investigación operativa

## Raíces históricas

La **investigación operativa (IO)** o *Operations Research* nace formalmente durante la Segunda Guerra Mundial:

- ▶ **Problemas complejos:** Logística, despliegue de radares, escolta de convoyes y asignación de recursos limitados.
- ▶ **Enfoque interdisciplinar:** Grupos de científicos (matemáticos, físicos, ingenieros) colaborando para aplicar el método científico a operaciones militares.
- ▶ **Postguerra:** Aplicación exitosa al crecimiento industrial, el comercio y la gestión pública.

# Definición de investigación operativa

## Operational Research Society

La Investigación Operativa es la **aplicación del método científico** a los **problemas complejos** producidos en la dirección y gestión de grandes sistemas de personas, máquinas, materiales y dinero, en la industria, comercio, administración y defensa.

- Consiste en construir un **modelo científico** del sistema (incluyendo azar y riesgo) para predecir y **comparar los resultados** de diferentes decisiones estratégicas.

# Herramientas de la investigación operativa

La IO abarca múltiples metodologías cuantitativas:

- ▶ **Optimización matemática** (Lineal, Entera, No Lineal) ← *Foco del bloque I*
- ▶ **Teoría de grafos y redes** ← *Foco del bloque II*
- ▶ Sistemas dinámicos y teoría de control
- ▶ Modelos estocásticos y teoría de colas
- ▶ Simulación de eventos discretos
- ▶ Teoría de juegos y teoría de la decisión

## El concepto de modelo



# ¿Qué es un modelo?

Un **modelo** es una representación simplificada de la realidad diseñada para estructurar, analizar y predecir el comportamiento de un sistema real.

## Tipos de modelos

- ▶ **Modelos concretos (físicos):** Representaciones físicas a escala (ej. túnel de viento, maqueta de un edificio).
- ▶ **Modelos abstractos (matemáticos):** Relaciones y ecuaciones cuantitativas que definen la lógica interna del sistema. Son la herramienta central en ciencias de la decisión.

# Ciclo de vida del modelado

El proceso de modelización matemática es iterativo:

1. **Formulación:** Traducir la realidad a variables y ecuaciones.
2. **Resolución:** Aplicar algoritmos para hallar el óptimo.
3. **Validación:** Contrastar con datos reales y analizar sensibilidad.
4. **Implementación:** Toma de decisiones informada.

# Modelos de optimización

# Formulación general

Un modelo de programación matemática consta de:

$$\begin{array}{ll}\min_{x \in \mathbb{R}^n} & f(x) \\ \text{sujeto a} & g_i(x) \leq 0, \quad i = 1, \dots, m \\ & h_j(x) = 0, \quad j = 1, \dots, p\end{array}$$

- ▶ **Variables de decisión ( $x$ ):** Las incógnitas que podemos controlar.
- ▶ **Función objetivo ( $f$ ):** La función real a maximizar o minimizar.
- ▶ **Restricciones ( $g_i, h_j$ ):** Límites físicos, económicos o lógicos que restringen las variables.

# Clasificación de modelos de optimización

Atendiendo al tipo de ecuaciones y funciones:

- ▶ **Optimización lineal (LP):** Función objetivo y restricciones estrictamente lineales.
- ▶ **Optimización no lineal (NLP):** Objetivo o alguna restricción presentan curvatura no lineal.
- ▶ **Optimización estocástica:** Incluye parámetros probabilísticos y aleatorios.

# Clasificación según el tipo de variables

- ▶ **Optimización continua:** Las variables de decisión pueden tomar cualquier valor real dentro de un intervalo:

$$x_i \geq 0, \quad x_i \in \mathbb{R}$$

- ▶ **Optimización entera:** Las variables deben ser valores enteros (ej. número de camiones a comprar):

$$x_i \in \mathbb{Z}$$

- ▶ **Optimización binaria:** Decisiones lógicas sí/no ( $x_i \in \{0, 1\}$ ).
- ▶ **Entera mixta (MIP):** Combina variables continuas y enteras.

## Optimización no lineal y en redes

# Bloque I: optimización no lineal (NLP)

Se estudian problemas continuos donde la curvatura juega un papel crítico:

- ▶ **Diferenciabilidad:** Uso del gradiente y la matriz Hessiana para el análisis de curvatura local.
- ▶ **Convexidad:** Si el problema es convexo, se garantiza la globalidad de los óptimos.
- ▶ **Algoritmos:**
  - ▶ *Búsqueda 1D:* Bisección, Newton, Sección Áurea.
  - ▶ *Multivariantes:* Máximo Descenso, Newton, BFGS.
  - ▶ *Con restricciones:* Condiciones de Karush-Kuhn-Tucker (KKT).



## Bloque II: optimización en redes

Modelado y resolución eficiente de problemas estructurados sobre grafos:

- ▶ **Matriz de incidencia:**  
Totalmente unimodular  
(garantiza soluciones enteras en relajación lineal).
- ▶ **Algoritmos especializados:**  
Símplex de redes, Dijkstra, Kruskal, algoritmos de flujo máximo.

### Problemas clave

- ▶ Caminos mínimos.
- ▶ Flujo máximo.
- ▶ Emparejamientos.
- ▶ Rutas de reparto (TSP).

# Tema 2: optimización no lineal y métodos numéricos

Optimización y Análisis de Redes

Víctor Aceña Gil - Antonio Alonso Ayuso

2026-06-16

## Introducción y formulación

## ¿De qué trata este tema?

La optimización no lineal (NLP) aborda problemas reales donde las relaciones matemáticas no se comportan de forma proporcional o lineal.

- ▶ **Economías de escala:** El coste unitario disminuye con el volumen de producción, rompiendo la proporcionalidad directa.
- ▶ **Elasticidad de la demanda:** La cantidad demandada es sensible al precio de venta, por lo que la función de ingresos ( $I = P \cdot Q$ ) es inherentemente cuadrática.
- ▶ **Riesgo financiero:** La volatilidad de una cartera se modela mediante la covarianza conjunta (forma cuadrática acoplada).
- ▶ **Ajuste de modelos:** La estimación de parámetros en ciencia de datos suele penalizar errores cuadráticamente (mínimos cuadrados), generando funciones objetivo no lineales.

## ¿Qué aprenderás en este tema?

- ▶ **Formulación matemática:** Plantear modelos no lineales con restricciones generales.
- ▶ **Análisis local de curvatura:** Utilizar el gradiente y la matriz hessiana para caracterizar geométricamente las funciones.
- ▶ **Condiciones de optimalidad:** Aplicar las condiciones diferenciales necesarias y suficientes para identificar máximos, mínimos y puntos de silla.
- ▶ **Algoritmos de búsqueda 1D:** Programar y analizar la convergencia de solvers de una variable sin y con derivadas.
- ▶ **Algoritmos multivariantes:** Implementar y comparar los principales métodos de búsqueda local sin restricciones (coordenadas cíclicas, máximo descenso, Newton y Cuasi-Newton BFGS).

# Formulación matemática general

Un **problema de optimización no lineal (PNL)** general se define matemáticamente sobre un espacio vectorial  $\mathbb{R}^n$  como:

$$\begin{array}{ll}\min_{x \in \mathbb{R}^n} & f(x) \\ \text{sujeto a} & g_i(x) \leq 0, \quad i = 1, \dots, m \\ & h_j(x) = 0, \quad j = 1, \dots, p\end{array}$$

Donde:

- ▶  $f(x)$  es la **función objetivo**.
- ▶  $g_i(x)$  representa las restricciones de **desigualdad**.
- ▶  $h_j(x)$  representa las restricciones de **igualdad**.
- ▶ Al menos una de estas funciones es no lineal.

# Geometría de la optimización: lineal vs no lineal

La no linealidad altera profundamente la geometría del espacio de búsqueda:

## ► Programación lineal (LP):

- Conjunto factible: Siempre un poliedro convexo.
- Óptimo: Se localiza necesariamente en un **vértice** (punto extremo).
- Algoritmos: El Símplex explora únicamente un número finito de vértices.

## ► Programación no lineal (NLP):

- Conjunto factible: Las restricciones no lineales curvan las fronteras.
- Óptimo: Puede hallarse en el **interior** o en cualquier punto de la **frontera**.
- Múltiples óptimos locales: Los solvers locales pueden quedar atrapados en soluciones subóptimas.

# Casos particulares de la optimización no lineal

Clasificamos los problemas en familias según sus propiedades:

- ▶ **Programación cuadrática (QP):** Objetivo cuadrático y restricciones afines (lineales):

$$\min_x \quad \frac{1}{2}x^T Qx - b^T x \quad \text{sujeto a} \quad Ax \leq d$$

- ▶ **Programación convexa:** Objetivo y restricciones de desigualdad convexas, e igualdades afines. ¡Todo mínimo local es global!
- ▶ **Programación separable:** Las funciones se pueden descomponer en sumas de una variable:  $f(x) = \sum f_j(x_j)$ .
- ▶ **Programación geométrica:** Modelada con posinomios, transformable en convexa mediante el cambio  $y_j = \ln(x_j)$ .
- ▶ **Programación fraccionaria:** Objetivo como cociente de dos funciones.



## El monopolio de Cournot (1838)

- **Precio de venta:**  $P(Q) = 10 - Q$  (elasticidad).
- **Coste total:**  $C(Q) = 1 + 3Q$  (lineal).
- **Modelo de maximización:**

$$\max_{Q,P} B(Q, P) = P \cdot Q - 3Q - 1$$

$$\text{sujeto a } Q \leq 10 - P, \quad 0 \leq P \leq 8, \quad 0 \leq Q \leq 9$$

- **Reducción:** Sustituyendo la demanda activa ( $P = 10 - Q$ ):


$$\max_Q B(Q) = -Q^2 + 7Q - 1 \quad \text{sujeto a } 2 \leq Q \leq 9$$

- **Óptimo analítico:**

$$B'(Q) = -2Q + 7 = 0 \implies Q^* = 3.5 \in [2, 9].$$

# Monopolio de Cournot: análisis geométrico

El punto óptimo  $(3.5, 6.5)$  se sitúa en la frontera y no coincide con ningún vértice de la región factible polimórfica:



## Selección de cartera de valores (Markowitz, 1952)

Inversión de capital  $C$  en  $n$  activos para maximizar rendimiento neto del riesgo:

$$\begin{aligned} \max_{x \in \mathbb{R}^n} \quad & \sum_{i=1}^n \mu_i x_i - \beta \sum_{i=1}^n \sum_{j=1}^n \sigma_{ij} x_i x_j \\ \text{sujeto a} \quad & \sum_{i=1}^n x_i \leq C \\ & x_i \geq 0, \quad i = 1, \dots, n \end{aligned}$$

Donde:

- ▶  $\mu_i$ : Rendimiento esperado del activo  $i$ .
- ▶  $\sigma_{ij}$ : Covarianza del rendimiento (riesgo cuadrático acoplado).
- ▶  $\beta > 0$ : Coeficiente de aversión al riesgo.
- ▶ Es un problema **cuadrático convexo (QP)**.

## Óptimos y análisis diferencial

# Óptimos locales, globales y puntos de silla

Sea  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  definida sobre un conjunto factible  $\mathcal{X} \subseteq \mathbb{R}^n$ :

- ▶ **Mínimo global:**  $x^*$  es el óptimo absoluto si:

$$f(x) \geq f(x^*) \quad \forall x \in \mathcal{X}$$


- ▶ **Mínimo local:**  $x^*$  es el mejor en su entorno local si existe un radio  $\epsilon > 0$  tal que:

$$f(x) \geq f(x^*) \quad \forall x \in \mathcal{X} \quad \text{con} \quad \|x - x^*\| \leq \epsilon$$

- ▶ **Estricto:** Si la desigualdad se cumple de forma estricta ( $>$ ) para todo  $x \neq x^*$ .
- ▶ **Punto de silla:** Punto crítico que no es ni mínimo ni máximo local.

# Tipos de óptimos de un vistazo

Diferencia fundamental con LP: múltiples óptimos locales mediocres frente al mínimo global único:



# Herramientas de análisis diferencial

Asumiendo funciones con derivadas segundas continuas (de clase  $\mathcal{C}^2$ ):

- **Vector gradiente:** Vector columna de derivadas de primer orden (pendiente):

$$\nabla f(x) = \left( \frac{\partial f(x)}{\partial x_1}, \frac{\partial f(x)}{\partial x_2}, \dots, \frac{\partial f(x)}{\partial x_n} \right)^T$$

- **Matriz hessiana:** Matriz simétrica de segundas derivadas parciales (curvatura):

$$[\nabla^2 f(x)]_{ij} = \frac{\partial^2 f(x)}{\partial x_i \partial x_j}$$

# Desarrollo de Taylor multivariante

Aproximación cuadrática local de  $f(x)$  alrededor de un punto de referencia  $\bar{x}$ :

$$f(x) = f(\bar{x}) + \nabla f(\bar{x})^T (x - \bar{x}) + \frac{1}{2} (x - \bar{x})^T \nabla^2 f(\bar{x}) (x - \bar{x}) + o(\|x - \bar{x}\|^2)$$

Donde:

- ▶ El término lineal  $\nabla f(\bar{x})^T (x - \bar{x})$  define el plano tangente.
- ▶ El término cuadrático  $\frac{1}{2} (x - \bar{x})^T \nabla^2 f(\bar{x}) (x - \bar{x})$  define la parábola de ajuste.
- ▶ Si la función  $f(x)$  es cuadrática, la aproximación es exacta en todo el dominio.



# Clasificación de la curvatura y matrices

Clasificación de  $H = \nabla^2 f(x)$  según la forma cuadrática  $z^T H z$ :

- ▶ **Definida positiva** ( $H \succ 0$ ):  $z^T H z > 0 \quad \forall z \neq 0$ . Menores principales  $> 0$ . Autovalores  $> 0$ . (Curva en cuenco).
- ▶ **Semidefinida positiva** ( $H \succeq 0$ ):  $z^T H z \geq 0 \quad \forall z$ . Autovalores  $\geq 0$ .
- ▶ **Definida negativa** ( $H \prec 0$ ):  $z^T H z < 0 \quad \forall z \neq 0$ . Menores alternan signo ( $M_1 < 0, M_2 > 0$ ). Autovalores  $< 0$ . (Cúpula).
- ▶ **Semidefinida negativa** ( $H \preceq 0$ ):  $z^T H z \leq 0 \quad \forall z$ . Autovalores  $\leq 0$ .
- ▶ **Indefinida**: Autovalores positivos y negativos. (Punto de silla).

# Condiciones de optimalidad en optimización libre

Caracterización diferencial de extremos locales sin restricciones:

- **Condición necesaria de primer orden (FONC):** Si  $x^*$  es un mínimo local, entonces el gradiente se anula:

$$\nabla f(x^*) = 0$$

(El punto  $x^*$  es un **punto crítico** o estacionario).

- **Condición necesaria de segundo orden (SONC):** Si  $x^*$  es un mínimo local:

$$\nabla^2 f(x^*) \succeq 0$$

- **Condición suficiente de segundo orden (SOSC):** Si se cumple simultáneamente que:

$$\nabla f(x^*) = 0 \quad \text{y} \quad \nabla^2 f(x^*) \succ 0$$

Entonces  $x^*$  es un **mínimo local estricto**.

## Métodos de búsqueda unidimensional

# Métodos de búsqueda unidimensional

Consiste en minimizar una función real de una variable  $f : \mathbb{R} \rightarrow \mathbb{R}$  en un intervalo acotado  $[a, b]$ .

- Caso de prueba para trazas numéricas:


$$f(x) = \frac{1}{4}x^4 - \frac{13}{3}x^3 + 27x^2 - 72x + 1$$

definida en el intervalo  $[1, 4]$ .

- Mínimo global analítico situado exactamente en  $x^* = 3.0$ .


# Función de prueba unidimensional

Representación gráfica de la función de prueba en el intervalo  $[1, 4]$ :




# Métodos sin derivadas: búsqueda uniforme

- ▶ Subdivide el intervalo  $[a, b]$  en  $n$  subintervalos iguales mediante una rejilla.
- ▶ Poco eficiente debido a que no aprovecha la información de las evaluaciones previas.



# Búsqueda dicotómica: insuficiencia de un solo punto

Evaluar un único punto medio es insuficiente porque dos funciones unimodales diferentes pueden tener idéntico valor en el centro teniendo sus mínimos en lados opuestos:



# Métodos sin derivadas: búsqueda dicotómica

- Calcula dos puntos simétricos separados por una pequeña perturbación  $\delta$ :

$$\lambda_k = \frac{a_k + b_k}{2} - \delta \quad \mu_k = \frac{a_k + b_k}{2} + \delta$$

- Compara los valores de la función en ambos puntos para descartar una porción del intervalo en cada iteración:
  - Si  $f(\lambda_k) < f(\mu_k) \implies$  el mínimo no está en  $[\mu_k, b_k]$ , nuevo intervalo  $[a_k, \mu_k]$ .
  - Si  $f(\lambda_k) > f(\mu_k) \implies$  el mínimo no está en  $[a_k, \lambda_k]$ , nuevo intervalo  $[\lambda_k, b_k]$ .



## Búsqueda dicotómica: paso a paso numérico (paso 1)

Minimizamos  $f(x)$  en  $[1, 4]$  con  $\delta = 0.02$  y tolerancia  $\epsilon = 0.15$ :

► **Paso 1:** Intervalo inicial  $[a_0, b_0] = [1, 4]$ . Punto medio  $c = 2.5$ .

► Planteamos y sustituimos:

$$\lambda_0 = \frac{a_0 + b_0}{2} - \delta = \frac{1 + 4}{2} - 0.02 = 2.48$$

$$\mu_0 = \frac{a_0 + b_0}{2} + \delta = \frac{1 + 4}{2} + 0.02 = 2.52$$

► Calculamos evaluaciones:

$$f(2.48) \approx -68.397 \quad f(2.52) \approx -68.490$$

► Como  $f(\lambda_0) > f(\mu_0) \implies$  descartamos  $[a_0, \lambda_0]$ . Nuevo intervalo:  $[2.48, 4]$ .

## Búsqueda dicotómica: paso a paso numérico (paso 2)

► **Paso 2:**  $[a_1, b_1] = [2.48, 4]$ . Punto medio  $c_1 = 3.24$ .

► Planteamos y sustituimos:

$$\lambda_1 = \frac{a_1 + b_1}{2} - \delta = 3.22$$

$$\mu_1 = \frac{a_1 + b_1}{2} + \delta = 3.26$$

► Calculamos evaluaciones:

$$f(3.22) \approx -68.730 \quad f(3.26) \approx -68.683$$

► Como  $f(\lambda_1) < f(\mu_1) \implies$  descartamos  $[\mu_1, b_1]$ . Nuevo intervalo:  $[2.48, 3.26]$ .

## Búsqueda dicotómica: paso a paso numérico (paso 3 y siguientes)

► **Paso 3:**  $[a_2, b_2] = [2.48, 3.26]$ . Punto medio  $c_2 = 2.87$ .

► Planteamos y sustituimos:

$$\lambda_2 = 2.85 \quad \mu_2 = 2.89$$

► Calculamos evaluaciones:


$$f(2.85) \approx -68.711 \quad f(2.89) \approx -68.724$$

► Como  $f(\lambda_2) > f(\mu_2) \implies$  descartamos  $[a_2, \lambda_2]$ . Nuevo intervalo final:  $[2.85, 3.26]$ .

► **Fin de la búsqueda:** El intervalo final es  $[2.85, 3.26]$  con amplitud 0.41. Para alcanzar la tolerancia  $\epsilon = 0.15$  se requerirían iteraciones adicionales.

# Búsqueda dicotómica: visualización del método

El proceso divide iterativamente el intervalo de búsqueda prácticamente a la mitad, convergiendo con rapidez hacia el óptimo mediante evaluaciones pareadas:



## Métodos sin derivadas: sección áurea

- ▶ Optimiza la búsqueda dicotómica al reutilizar uno de los puntos evaluados en el paso anterior, reduciendo el coste computacional.
- ▶ La amplitud del intervalo se reduce de forma constante por la razón áurea:

$$I_k = \frac{b_k - a_k}{\alpha} \quad \text{con} \quad \alpha = \frac{1 + \sqrt{5}}{2} \approx 1.61803$$

- ▶ Los puntos se localizan simétricamente en el intervalo:

$$\lambda_k = b_k - I_k \quad \mu_k = a_k + I_k$$

## Sección áurea: paso a paso numérico (paso 1)

Minimizamos  $f(x)$  en  $[1, 4]$  con tolerancia  $\epsilon = 0.15$ :

► **Paso 1:** Intervalo inicial  $[a_0, b_0] = [1, 4]$ .

► Amplitud teórica:

$$I_1 = \frac{b_0 - a_0}{\alpha} = \frac{4 - 1}{1.61803} \approx 1.8541$$

► Sustituimos y calculamos puntos:

$$\lambda_0 = b_0 - I_1 = 4 - 1.8541 = 2.1459 \implies f(2.1459) \approx -66.692$$

$$\mu_0 = a_0 + I_1 = 1 + 1.8541 = 2.8541 \implies f(2.8541) \approx -68.714$$

► Como  $f(\lambda_0) > f(\mu_0) \implies$  descartamos  $[a_0, \lambda_0]$ . Nuevo intervalo:  $[2.1459, 4]$ .

## Sección áurea: paso a paso numérico (paso 2)

- ▶ **Paso 2:**  $[a_1, b_1] = [2.1459, 4]$ . Amplitud  $I_2 = 1.8541/1.61803 = 1.1459$ .

- ▶ Reutilizamos el punto interior evaluado:

$$\lambda_1 = \mu_0 = 2.8541 \implies f(2.8541) \approx -68.714$$

- ▶ Sustituimos y calculamos el nuevo punto:

$$\mu_1 = a_1 + I_2 = 2.1459 + 1.1459 = 3.2918 \implies f(3.2918) \approx -68.654$$

- ▶ Como  $f(\lambda_1) < f(\mu_1) \implies$  descartamos  $[\mu_1, b_1]$ . Nuevo intervalo:  $[2.1459, 3.2918]$ .

## Sección áurea: paso a paso numérico (pasos siguientes)

► **Paso 3:**  $[a_2, b_2] = [2.1459, 3.2918]$ . Amplitud  $I_3 = 0.7082$ .

► Reutilizamos:

$$\mu_2 = \lambda_1 = 2.8541 \implies f(2.8541) \approx -68.714$$

► Calculamos el nuevo punto:

$$\lambda_2 = b_2 - I_3 = 3.2918 - 0.7082 = 2.5836 \implies f(2.5836) \approx -68.601$$


► Como  $f(\lambda_2) > f(\mu_2) \implies$  descartamos  $[a_2, \lambda_2]$ . Nuevo intervalo:  $[2.5836, 3.2918]$ .

► **Convergencia:** El proceso continúa de forma análoga. En el **paso 7**, la amplitud de búsqueda se reduce a  $0.1033 \leq 0.15$  (tolerancia alcanzada), con el óptimo localizado en el intervalo final  $[2.91, 3.01]$ .



# Sección áurea: visualización del método

La amplitud del intervalo se contrae de forma secuencial manteniendo la proporción de la sección áurea, reutilizando las evaluaciones previas de forma simétrica:



## Métodos sin derivadas: Fibonacci

- ▶ Fija de antemano el número total de evaluaciones de función  $N$  para maximizar la reducción del intervalo final.
- ▶ Utiliza los términos de la serie de Fibonacci para definir los coeficientes de reducción:

$$F_0 = 1, F_1 = 1, F_2 = 2, F_3 = 3, F_4 = 5, F_5 = 8, F_6 = 13, F_7 = 21,$$

- ▶ La amplitud del paso en cada iteración  $k$  se calcula mediante:

$$I_k = \frac{F_{N-k}}{F_{N-k+2}}(b_{k-1} - a_{k-1})$$

## Fibonacci: paso a paso numérico (paso 1)

Minimizamos  $f(x)$  en  $[1, 4]$  mediante Fibonacci para un total de  $N = 6$  evaluaciones ( $F_7 = 21$ ):

► **Paso 1:**  $[a_0, b_0] = [1, 4]$ .

► Amplitud teórica del paso:

$$I_1 = \frac{F_6}{F_7}(b_0 - a_0) = \frac{13}{21}(4 - 1) = \frac{39}{21} \approx 1.8571$$

► Sustituimos y calculamos:

$$\lambda_0 = b_0 - I_1 = 4 - 1.8571 = 2.1429 \implies f(2.1429) \approx -66.673$$

$$\mu_0 = a_0 + I_1 = 1 + 1.8571 = 2.8571 \implies f(2.8571) \approx -68.715$$

► Como  $f(\lambda_0) > f(\mu_0) \implies$  nuevo intervalo:  $[2.1429, 4]$ .

## Fibonacci: paso a paso numérico (paso 2 y siguientes)

- ▶ **Paso 2:**  $[a_1, b_1] = [2.1429, 4]$ . Paso

$$I_2 = \frac{F_5}{F_7}(b_0 - a_0) = \frac{8}{21} \cdot 3 = 1.1429.$$

- ▶ Reutilizamos el punto interior evaluado:

$$\lambda_1 = \mu_0 = 2.8571 \implies f(2.8571) \approx -68.715$$

- ▶ Sustituimos y calculamos el nuevo punto:

$$\mu_1 = a_1 + I_2 = 2.1429 + 1.1429 = 3.2857 \implies f(3.2857) \approx -68.657$$

- ▶ Como  $f(\mu_1) > f(\lambda_1) \implies$  descartamos  $[\mu_1, b_1]$ . Nuevo intervalo final:  $[2.1429, 3.2857]$ .

- ▶ **Pasos siguientes:** El algoritmo continúa de forma análoga reduciendo los coeficientes de Fibonacci hasta agotar las  $N = 6$  evaluaciones de la función planificadas, estrechando el intervalo en torno a  $x^* = 3.0$ .

## Métodos con derivadas: bisección (Bolzano)

- ▶ Busca el cero de la primera derivada ( $f'(x) = 0$ ) en un intervalo  $[a, b]$  donde el signo de la derivada en los extremos sea opuesto ( $f'(a) \cdot f'(b) < 0$ ).
- ▶ En cada paso, evalúa el punto medio del intervalo:

$$c_k = \frac{a_k + b_k}{2}$$

- ▶ Reduce el intervalo a la mitad analizando el signo de  $f'(c_k)$ :
  - ▶ Si  $f'(c_k) < 0 \implies$  nuevo intervalo  $[c_k, b_k]$ .
  - ▶ Si  $f'(c_k) > 0 \implies$  nuevo intervalo  $[a_k, c_k]$ .

## Bisección: paso a paso numérico (paso 1)

Minimizamos  $f(x)$  con  $f'(x) = x^3 - 13x^2 + 54x - 72$  en  $[1, 4]$ ,  $\epsilon = 0.15$ :

► **Paso 1:**  $[a_0, b_0] = [1, 4]$ .

► Punto medio teórico:

$$c_0 = \frac{a_0 + b_0}{2} = \frac{1 + 4}{2} = 2.5$$

► Sustituimos y calculamos la derivada:

$$f'(2.5) = (2.5)^3 - 13(2.5)^2 + 54(2.5) - 72 = -2.625 < 0$$

► Descartamos la mitad izquierda  $\implies$  nuevo intervalo  $[2.5, 4]$ .

## Bisección: paso a paso numérico (paso 2)

► **Paso 2:**  $[a_1, b_1] = [2.5, 4]$ . Punto medio  $c_1 = 3.25$ .

► Sustituimos y calculamos la derivada:

$$f'(3.25) = (3.25)^3 - 13(3.25)^2 + 54(3.25) - 72 = 0.5156 > 0$$

► Como  $f'(c_1) > 0 \implies$  descartamos la mitad derecha. Nuevo intervalo:  $[2.5, 3.25]$ .

## Bisección: paso a paso numérico (paso 3 y siguientes)

► **Paso 3:**  $[a_2, b_2] = [2.5, 3.25]$ . Punto medio  $c_2 = 2.875$ .

► Sustituimos y calculamos la derivada:

$$f'(2.875) = (2.875)^3 - 13(2.875)^2 + 54(2.875) - 72 = -0.4433 < 0$$


► Como  $f'(c_2) < 0 \implies$  descartamos la mitad izquierda. Nuevo intervalo:  $[2.875, 3.25]$ .

► **Convergencia:** En el **paso 5**, el intervalo es  $[2.9531, 3.0469]$  con una amplitud de  $0.0938 \leq 0.15$ , alcanzando la tolerancia.



# Bisección: visualización del método

El método se basa en el teorema de Bolzano, acotando sucesivamente el valor donde la derivada se anula dividiendo a la mitad la amplitud en cada iteración:



# Métodos con derivadas: método de Newton 1D

- ▶ Aproxima la función objetivo mediante su polinomio de Taylor cuadrático alrededor del punto de búsqueda actual  $x_k$ .
- ▶ El siguiente punto iterado se obtiene saltando directamente al vértice de la parábola aproximada (donde la derivada aproximada se anula):

$$x_{k+1} = x_k - \frac{f'(x_k)}{f''(x_k)}$$

- ▶ Requiere que la función sea de clase  $\mathcal{C}^2$  y que  $f''(x_k) \neq 0$ .

## Newton 1D: paso a paso numérico (paso 1)

Minimizamos la misma función partiendo de  $x_0 = 1.0$ :

► **Paso 1:** Partimos de  $x_0 = 1.0$ .

► Ecuaciones teóricas y derivadas ( $f''(x) = 3x^2 - 26x + 54$ ):

$$f'(x_0) = f'(1.0) = 1^3 - 13(1)^2 + 54(1) - 72 = -30.0$$

$$f''(x_0) = f''(1.0) = 3(1)^2 - 26(1) + 54 = 31.0$$

► Sustituimos en la regla de Newton:

$$x_1 = x_0 - \frac{f'(x_0)}{f''(x_0)} = 1.0 - \frac{-30.0}{31.0} \approx 1.9677$$

## Newton 1D: paso a paso numérico (paso 2)

► **Paso 2:** Partimos del punto anterior  $x_1 = 1.9677$ .

► Calculamos primera y segunda derivada:

$$f'(1.9677) \approx -8.459 \quad f''(1.9677) \approx 14.450$$

► Sustituimos en la regla de Newton:

$$x_2 = x_1 - \frac{f'(x_1)}{f''(x_1)} = 1.9677 - \frac{-8.459}{14.450} \approx 2.5529$$

## Newton 1D: paso a paso numérico (pasos 3-5)

► **Paso 3:** Partimos de  $x_2 = 2.5529$ .

► Calculamos derivadas:  $f'(2.5529) \approx -2.235$ ,  
 $f''(2.5529) \approx 7.177$ .

► Actualización:  $x_3 = 2.5529 - \frac{-2.235}{7.177} \approx 2.8637$ .


► **Paso 4:**  $x_3 = 2.8637 \implies x_4 = 2.8637 - \frac{-0.485}{4.146} \approx 2.9808$ .

► **Paso 5:**

$x_4 = 2.9808 \implies x_5 = 2.9808 - \frac{-0.059}{3.154} \approx 2.9995 \approx 3.0$ .

# Newton 1D: visualización del método

El algoritmo aproxima de manera local mediante parábolas sucesivas y converge muy rápido si el punto inicial  $x_0$  está próximo al óptimo:



# Método de la secante

- ▶ Evita el cálculo de la segunda derivada del método de Newton.
- ▶ Aproxima la curvatura mediante la diferencia de gradientes en los últimos dos pasos:

$$x_{k+1} = x_k - f'(x_k) \frac{x_k - x_{k-1}}{f'(x_k) - f'(x_{k-1})}$$

- ▶ Características:
  - ▶ Convergencia superlineal con orden  $\approx 1.618$ .
  - ▶ Exige disponer de dos puntos iniciales  $x_0$  y  $x_{-1}$ .

# Métodos multivariantes



# Métodos multivariantes de optimización sin restricciones

Buscan minimizar  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  mediante la sucesión iterativa:

$$x_{k+1} = x_k + \alpha_k d_k$$

Donde:

- **Dirección de búsqueda ( $d_k$ ):** Debe ser de descenso (formar un ángulo obtuso con el gradiente):

$$\nabla f(x_k)^T d_k < 0$$

- **Tamaño de paso ( $\alpha_k$ ):** Determina el avance óptimo a lo largo de la dirección. Se calcula resolviendo el problema unidimensional:

$$\alpha_k = \arg \min_{\alpha > 0} f(x_k + \alpha d_k)$$

# Método de coordenadas cíclicas

- ▶ Es un método de optimización multivariante de búsqueda directa (no requiere derivadas).
- ▶ Avanza de forma iterativa minimizando respecto a una sola variable de decisión a la vez de forma cíclica (direcciones de búsqueda ortogonales  $d_k = e_i$ ):

$$x_{k+1} = x_k + \alpha_k e_i$$

- ▶ El tamaño de paso exacto  $\alpha_k$  se calcula mediante una búsqueda lineal unidimensional exacta en la dirección  $e_i$ .

## Coordenadas cíclicas: paso a paso numérico (paso 1)

Minimizamos  $f(x, y) = 8x^2 + 3xy + 7y^2 - 25x + 31y - 29$  desde  $x_0 = (0, 0)^T$ :

► **Paso 1:** Optimizamos respecto a  $x$  fijando  $y = y_0 = 0$ :

► Sustituimos en la ecuación teórica:

$$f(x, 0) = 8x^2 + 3x(0) + 7(0)^2 - 25x + 31(0) - 29 = 8x^2 - 25x - 29$$

► Derivamos respecto a  $x$  e igualamos a cero:

$$\frac{df(x, 0)}{dx} = 16x - 25 = 0 \implies x = \frac{25}{16} = 1.5625$$

► El punto resultante es  $x_1 = (1.5625, 0)^T$ .

## Coordenadas cíclicas: paso a paso numérico (paso 2)

► **Paso 2:** Optimizamos respecto a  $y$  fijando  $x = 1.5625$ :

► Sustituimos en la ecuación:

$$f(1.5625, y) = 7y^2 + 35.6875y - 48.531$$

► Derivamos respecto a  $y$  e igualamos a cero:

$$\frac{\partial f(1.5625, y)}{\partial y} = 14y + 35.6875 = 0 \implies y_2 \approx -2.5491$$

► El punto resultante es  $x_2 = (1.5625, -2.5491)^T$ .

## Coordenadas cíclicas: paso a paso numérico (paso 3)

► **Paso 3:** Optimizamos respecto a  $x$  fijando  $y = -2.5491$ :

► Sustituimos en la ecuación:

$$f(x, -2.5491) = 8x^2 - 32.647x - 62.533$$

► Derivamos respecto a  $x$  e igualamos a cero:


$$\frac{\partial f(x, -2.5491)}{\partial x} = 16x - 32.647 = 0 \implies x_3 \approx 2.0405$$

► El punto resultante es  $x_3 = (2.0405, -2.5491)^T$ .

## Coordenadas cíclicas: variables desacopladas


Avanza minimizando respecto a una sola variable a la vez. Si las variables están desacopladas (Hessiana diagonal), localiza el mínimo en exactamente  $n = 2$  pasos ortogonales exactos:

Descenso por Coordenadas:  $f(x, y) = (x - 2)^2 + (y - 1)^2$



## Coordenadas cíclicas: variables acopladas

Si las variables están acopladas (término bilineal  $3xy$ ), la trayectoria dibuja un patrón de “escalera”, haciendo lenta la convergencia:



# Método del máximo descenso

- Dirección de búsqueda: opuesta al gradiente local ( $d_k = -\nabla f(x_k)$ ).
- Teorema de la ortogonalidad: Si el tamaño de paso se calcula mediante búsqueda de línea exacta, las direcciones consecutivas son ortogonales:

$$d_k^T d_{k+1} = 0$$

- Demostración: Definiendo  $\phi(\alpha) = f(x_k + \alpha d_k)$ , su derivada en el óptimo  $\alpha_k$  debe ser nula:

$$\phi'(\alpha_k) = \nabla f(x_k + \alpha_k d_k)^T d_k = 0 \implies \nabla f(x_{k+1})^T d_k = 0$$

Dado que las direcciones son proporcionales a los gradientes, se cumple:

$$d_{k+1}^T d_k = 0$$



## Máximo descenso: paso a paso numérico (paso 1)

Caso cuadrático acoplado  $f(x, y)$  desde  $x_0 = (0, 0)^T$ :

► **Paso 1:** Calculamos el gradiente y la dirección de descenso:

► Gradiente teórico:

$$\nabla f(x, y) = \begin{pmatrix} 16x + 3y - 25 \\ 3x + 14y + 31 \end{pmatrix}$$

► Sustituimos  $x_0 = (0, 0)^T$ :

$$\nabla f(x_0) = \begin{pmatrix} 16(0) + 3(0) - 25 \\ 3(0) + 14(0) + 31 \end{pmatrix} = \begin{pmatrix} -25 \\ 31 \end{pmatrix}$$

► Dirección de búsqueda ( $d_0 = -\nabla f(x_0)$ ):

$$d_0 = \begin{pmatrix} 25 \\ -31 \end{pmatrix}$$

## Máximo descenso: paso a paso numérico (paso 2)

- **Paso 2:** Búsqueda lineal exacta en la dirección

$$d_0 = (25, -31)^T:$$

- Sustituimos la trayectoria  $x(\alpha) = x_0 + \alpha d_0 = (25\alpha, -31\alpha)^T$ :

$$\phi(\alpha) = f(25\alpha, -31\alpha) = 9402\alpha^2 - 1586\alpha - 29$$

- Derivamos e igualamos a cero:

$$\phi'(\alpha) = 18804\alpha - 1586 = 0 \implies \alpha_0 = \frac{1586}{18804} \approx 0.0843$$

## Máximo descenso: paso a paso numérico (pasos 3-4)

- **Paso 3:** Actualizamos el punto con la longitud de paso óptima  $\alpha_0 \approx 0.0843$ :

$$x_1 = x_0 + \alpha_0 d_0 = \begin{pmatrix} 0 \\ 0 \end{pmatrix} + 0.0843 \begin{pmatrix} 25 \\ -31 \end{pmatrix} \approx \begin{pmatrix} 2.109 \\ -2.615 \end{pmatrix}$$

- **Paso 4:** Verificamos la ortogonalidad teórica en el nuevo punto:

- Evaluamos el gradiente en  $x_1$ :


$$\nabla f(x_1) \approx \begin{pmatrix} 0.8925 \\ 0.7225 \end{pmatrix}$$

- El producto escalar es nulo (ortogonales):

$$d_0^T \nabla f(x_1) = 25(0.8925) - 31(0.7225) \approx 0$$

# Máximo descenso: visualización del método

La ortogonalidad obligada entre direcciones consecutivas debido a la búsqueda lineal exacta provoca un patrón de “zigzag” muy ineficiente en funciones con valles estrechos (elipses alargadas):



# Método de Newton multivariante

Aproxima la función objetivo mediante una parábola multivariante en el punto actual  $x_k$ :

$$x_{k+1} = x_k - [\nabla^2 f(x_k)]^{-1} \nabla f(x_k)$$

- ▶ **Ventaja:** Convergencia cuadrática local de orden 2. Localiza el mínimo en 1 iteración para funciones cuadráticas.
- ▶ **Limitaciones:**
  - ▶ Coste computacional de resolver el sistema lineal es alto ( $O(n^3)$ ).
  - ▶ Exige que la Hessiana sea definida positiva ( $H \succ 0$ ).
  - ▶ Convergencia estrictamente local (puede divergir si se empieza lejos).

## Newton multivariante: paso a paso numérico (pasos 1-2)

Minimizamos  $f(x, y) = 8x^2 + 3xy + 7y^2 - 25x + 31y - 29$  desde  $x_0 = (0, 0)^T$ :

► **Paso 1:** Calculamos el gradiente y la Hessiana en el punto actual:

► Expresiones teóricas:

$$\nabla f(x, y) = \begin{pmatrix} 16x + 3y - 25 \\ 3x + 14y + 31 \end{pmatrix} \Rightarrow \nabla f(x_0) = \begin{pmatrix} -25 \\ 31 \end{pmatrix}$$

$$H = \nabla^2 f(x, y) = \begin{pmatrix} 16 & 3 \\ 3 & 14 \end{pmatrix} \quad (\text{constante})$$

► **Paso 2:** Calculamos la inversa de la Hessiana  $H^{-1}$  (determinante  $|H| = 16 \cdot 14 - 3^2 = 215$ ):

$$H^{-1} = \frac{1}{215} \begin{pmatrix} 14 & -3 \\ -3 & 16 \end{pmatrix}$$

## Newton multivariante: paso a paso numérico (paso 3)

- **Paso 3:** Aplicamos la actualización iterativa del método de Newton:

$$x_1 = x_0 - H^{-1} \nabla f(x_0)$$

$$x_1 = \begin{pmatrix} 0 \\ 0 \end{pmatrix} - \frac{1}{215} \begin{pmatrix} 14 & -3 \\ -3 & 16 \end{pmatrix} \begin{pmatrix} -25 \\ 31 \end{pmatrix}$$

$$x_1 = -\frac{1}{215} \begin{pmatrix} 14(-25) - 3(31) \\ -3(-25) + 16(31) \end{pmatrix} = -\frac{1}{215} \begin{pmatrix} -443 \\ 571 \end{pmatrix} = \begin{pmatrix} 443/215 \\ -571/215 \end{pmatrix}$$

$$x_1 \approx \begin{pmatrix} 2.0605 \\ -2.6558 \end{pmatrix}$$

- **Conclusión:** Dado que la función  $f(x, y)$  es cuadrática, la aproximación local es exacta y el método de Newton converge al mínimo global en **exactamente una iteración**.

# Método cuasi-Newton: BFGS

Resuelven los inconvenientes del método de Newton estimando la inversa de la Hessiana  $H_k \approx [\nabla^2 f(x_k)]^{-1}$  usando solo gradientes:

- Fuerzan la **ecuación de la secante**:

$$H_{k+1}y_k = s_k$$

donde  $s_k = x_{k+1} - x_k$  y  $y_k = \nabla f(x_{k+1}) - \nabla f(x_k)$ .

- Mantiene la matriz definida positiva en cada paso (si cumple condiciones de Wolfe).
- Costo de  $O(n^2)$  por iteración y convergencia superlineal.