

Tema 2: optimización no lineal y métodos numéricos

Optimización y Análisis de Redes

Víctor Aceña Gil - Antonio Alonso Ayuso

2026-06-16

Introducción y formulación

¿De qué trata este tema?

La optimización no lineal (NLP) aborda problemas reales donde las relaciones matemáticas no se comportan de forma proporcional o lineal.

- ▶ **Economías de escala:** El coste unitario disminuye con el volumen de producción, rompiendo la proporcionalidad directa.
- ▶ **Elasticidad de la demanda:** La cantidad demandada es sensible al precio de venta, por lo que la función de ingresos ($I = P \cdot Q$) es inherentemente cuadrática.
- ▶ **Riesgo financiero:** La volatilidad de una cartera se modela mediante la covarianza conjunta (forma cuadrática acoplada).
- ▶ **Ajuste de modelos:** La estimación de parámetros en ciencia de datos suele penalizar errores cuadráticamente (mínimos cuadrados), generando funciones objetivo no lineales.

¿Qué aprenderás en este tema?

- ▶ **Formulación matemática:** Plantear modelos no lineales con restricciones generales.
- ▶ **Análisis local de curvatura:** Utilizar el gradiente y la matriz hessiana para caracterizar geométricamente las funciones.
- ▶ **Condiciones de optimalidad:** Aplicar las condiciones diferenciales necesarias y suficientes para identificar máximos, mínimos y puntos de silla.
- ▶ **Algoritmos de búsqueda 1D:** Programar y analizar la convergencia de solvers de una variable sin y con derivadas.
- ▶ **Algoritmos multivariantes:** Implementar y comparar los principales métodos de búsqueda local sin restricciones (coordenadas cíclicas, máximo descenso, Newton y Cuasi-Newton BFGS).

Formulación matemática general

Un **problema de optimización no lineal (PNL)** general se define matemáticamente sobre un espacio vectorial $\mathbb{R}^n$ como:

$$\begin{array}{ll}\min_{x \in \mathbb{R}^n} & f(x) \\ \text{sujeto a} & g_i(x) \leq 0, \quad i = 1, \dots, m \\ & h_j(x) = 0, \quad j = 1, \dots, p\end{array}$$

Donde:

- ▶ $f(x)$ es la **función objetivo**.
- ▶ $g_i(x)$ representa las restricciones de **desigualdad**.
- ▶ $h_j(x)$ representa las restricciones de **igualdad**.
- ▶ Al menos una de estas funciones es no lineal.

Geometría de la optimización: lineal vs no lineal

La no linealidad altera profundamente la geometría del espacio de búsqueda:

► Programación lineal (LP):

- Conjunto factible: Siempre un poliedro convexo.
- Óptimo: Se localiza necesariamente en un **vértice** (punto extremo).
- Algoritmos: El Símplex explora únicamente un número finito de vértices.

► Programación no lineal (NLP):

- Conjunto factible: Las restricciones no lineales curvan las fronteras.
- Óptimo: Puede hallarse en el **interior** o en cualquier punto de la **frontera**.
- Múltiples óptimos locales: Los solvers locales pueden quedar atrapados en soluciones subóptimas.

Casos particulares de la optimización no lineal

Clasificamos los problemas en familias según sus propiedades:

- ▶ **Programación cuadrática (QP):** Objetivo cuadrático y restricciones afines (lineales):

$$\min_x \quad \frac{1}{2}x^T Qx - b^T x \quad \text{sujeto a} \quad Ax \leq d$$

- ▶ **Programación convexa:** Objetivo y restricciones de desigualdad convexas, e igualdades afines. ¡Todo mínimo local es global!
- ▶ **Programación separable:** Las funciones se pueden descomponer en sumas de una variable: $f(x) = \sum f_j(x_j)$.
- ▶ **Programación geométrica:** Modelada con posinomios, transformable en convexa mediante el cambio $y_j = \ln(x_j)$.
- ▶ **Programación fraccionaria:** Objetivo como cociente de dos funciones.

El monopolio de Cournot (1838)

- **Precio de venta:** $P(Q) = 10 - Q$ (elasticidad).
- **Coste total:** $C(Q) = 1 + 3Q$ (lineal).
- **Modelo de maximización:**

$$\max_{Q,P} B(Q, P) = P \cdot Q - 3Q - 1$$

$$\text{sujeto a } Q \leq 10 - P, \quad 0 \leq P \leq 8, \quad 0 \leq Q \leq 9$$

- **Reducción:** Sustituyendo la demanda activa ($P = 10 - Q$):


$$\max_Q B(Q) = -Q^2 + 7Q - 1 \quad \text{sujeto a } 2 \leq Q \leq 9$$

- **Óptimo analítico:**

$$B'(Q) = -2Q + 7 = 0 \implies Q^* = 3.5 \in [2, 9].$$

Monopolio de Cournot: análisis geométrico

El punto óptimo $(3.5, 6.5)$ se sitúa en la frontera y no coincide con ningún vértice de la región factible polimórfica:



Selección de cartera de valores (Markowitz, 1952)

Inversión de capital C en n activos para maximizar rendimiento neto del riesgo:

$$\begin{aligned} \max_{x \in \mathbb{R}^n} \quad & \sum_{i=1}^n \mu_i x_i - \beta \sum_{i=1}^n \sum_{j=1}^n \sigma_{ij} x_i x_j \\ \text{sujeto a} \quad & \sum_{i=1}^n x_i \leq C \\ & x_i \geq 0, \quad i = 1, \dots, n \end{aligned}$$

Donde:

- ▶ μ_i : Rendimiento esperado del activo i .
- ▶ σ_{ij} : Covarianza del rendimiento (riesgo cuadrático acoplado).
- ▶ $\beta > 0$: Coeficiente de aversión al riesgo.
- ▶ Es un problema **cuadrático convexo (QP)**.

Óptimos y análisis diferencial

Óptimos locales, globales y puntos de silla

Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ definida sobre un conjunto factible $\mathcal{X} \subseteq \mathbb{R}^n$:

► **Mínimo global:** x^* es el óptimo absoluto si:

$$f(x) \geq f(x^*) \quad \forall x \in \mathcal{X}$$

► **Mínimo local:** x^* es el mejor en su entorno local si existe un radio $\epsilon > 0$ tal que:


$$f(x) \geq f(x^*) \quad \forall x \in \mathcal{X} \quad \text{con} \quad \|x - x^*\| \leq \epsilon$$

► **Estricto:** Si la desigualdad se cumple de forma estricta ($>$) para todo $x \neq x^*$.

► **Punto de silla:** Punto crítico que no es ni mínimo ni máximo local.

Tipos de óptimos de un vistazo

Diferencia fundamental con LP: múltiples óptimos locales mediocres frente al mínimo global único:



Herramientas de análisis diferencial

Asumiendo funciones con derivadas segundas continuas (de clase $\mathcal{C}^2$):

- **Vector gradiente:** Vector columna de derivadas de primer orden (pendiente):

$$\nabla f(x) = \left(\frac{\partial f(x)}{\partial x_1}, \frac{\partial f(x)}{\partial x_2}, \dots, \frac{\partial f(x)}{\partial x_n} \right)^T$$

- **Matriz hessiana:** Matriz simétrica de segundas derivadas parciales (curvatura):

$$[\nabla^2 f(x)]_{ij} = \frac{\partial^2 f(x)}{\partial x_i \partial x_j}$$

Desarrollo de Taylor multivariante

Aproximación cuadrática local de $f(x)$ alrededor de un punto de referencia $\bar{x}$:

$$f(x) = f(\bar{x}) + \nabla f(\bar{x})^T (x - \bar{x}) + \frac{1}{2} (x - \bar{x})^T \nabla^2 f(\bar{x}) (x - \bar{x}) + o(\|x - \bar{x}\|^2)$$

Donde:

- ▶ El término lineal $\nabla f(\bar{x})^T (x - \bar{x})$ define el plano tangente.
- ▶ El término cuadrático $\frac{1}{2} (x - \bar{x})^T \nabla^2 f(\bar{x}) (x - \bar{x})$ define la parábola de ajuste.
- ▶ Si la función $f(x)$ es cuadrática, la aproximación es exacta en todo el dominio.


Clasificación de la curvatura y matrices

Clasificación de $H = \nabla^2 f(x)$ según la forma cuadrática $z^T H z$:


- ▶ **Definida positiva** ($H \succ 0$): $z^T H z > 0 \quad \forall z \neq 0$. Menores principales > 0 . Autovalores > 0 . (Curva en cuenco).
- ▶ **Semidefinida positiva** ($H \succeq 0$): $z^T H z \geq 0 \quad \forall z$. Autovalores ≥ 0 .
- ▶ **Definida negativa** ($H \prec 0$): $z^T H z < 0 \quad \forall z \neq 0$. Menores alternan signo ($M_1 < 0, M_2 > 0$). Autovalores < 0 . (Cúpula).
- ▶ **Semidefinida negativa** ($H \preceq 0$): $z^T H z \leq 0 \quad \forall z$. Autovalores ≤ 0 .
- ▶ **Indefinida**: Autovalores positivos y negativos. (Punto de silla).

Geometría de la curvatura: Definida positiva

Mínimo Circular ($H \succ 0$)




Mínimo Elíptico ($H \succ 0$)




Geometría de la curvatura: Indefinida

Punto de Silla (Indefinida)

Superficie 3D (Punto de Silla)



Curvas de Nivel (Hessiana Indefinida)



Condiciones de optimalidad en optimización libre

Caracterización diferencial de extremos locales sin restricciones:

- ▶ **Condición necesaria de primer orden (FONC):** Si x^* es un mínimo local, entonces el gradiente se anula:

$$\nabla f(x^*) = 0$$

(El punto x^* es un **punto crítico** o estacionario).

- ▶ **Condición necesaria de segundo orden (SONC):** Si x^* es un mínimo local:

$$\nabla^2 f(x^*) \succeq 0$$

- ▶ **Condición suficiente de segundo orden (SOSC):** Si se cumple simultáneamente que:

$$\nabla f(x^*) = 0 \quad \text{y} \quad \nabla^2 f(x^*) \succ 0$$

Entonces x^* es un **mínimo local estricto**.

Métodos de búsqueda unidimensional

Métodos de búsqueda unidimensional

Consiste en minimizar una función real de una variable $f : \mathbb{R} \rightarrow \mathbb{R}$ en un intervalo acotado $[a, b]$.

- ▶ Caso de prueba para trazas numéricas:


$$f(x) = \frac{1}{4}x^4 - \frac{13}{3}x^3 + 27x^2 - 72x + 1$$

definida en el intervalo $[1, 4]$.

- ▶ Mínimo global analítico situado exactamente en $x^* = 3.0$.


Función de prueba unidimensional

Representación gráfica de la función de prueba en el intervalo $[1, 4]$:



Métodos sin derivadas: búsqueda uniforme


- ▶ Subdivide el intervalo $[a, b]$ en n subintervalos iguales mediante una rejilla.
- ▶ Poco eficiente debido a que no aprovecha la información de las evaluaciones previas.



Búsqueda dicotómica: insuficiencia de un solo punto

Evaluar un único punto medio es insuficiente porque dos funciones unimodales diferentes pueden tener idéntico valor en el centro teniendo sus mínimos en lados opuestos:

**Un solo punto medio c no es suficiente para decidir el descarte
(ambas funciones tienen idéntico valor $f(c)$)**



Métodos sin derivadas: búsqueda dicotómica

- Calcula dos puntos simétricos separados por una pequeña perturbación δ :

$$\lambda_k = \frac{a_k + b_k}{2} - \delta \quad \mu_k = \frac{a_k + b_k}{2} + \delta$$

- Compara los valores de la función en ambos puntos para descartar una porción del intervalo en cada iteración:
 - Si $f(\lambda_k) < f(\mu_k) \implies$ el mínimo no está en $[\mu_k, b_k]$, nuevo intervalo $[a_k, \mu_k]$.
 - Si $f(\lambda_k) > f(\mu_k) \implies$ el mínimo no está en $[a_k, \lambda_k]$, nuevo intervalo $[\lambda_k, b_k]$.

Búsqueda dicotómica: paso a paso numérico (paso 1)

Minimizamos $f(x)$ en $[1, 4]$ con $\delta = 0.02$ y tolerancia $\epsilon = 0.15$:

► **Paso 1:** Intervalo inicial $[a_0, b_0] = [1, 4]$. Punto medio $c = 2.5$.

► Planteamos y sustituimos:

$$\lambda_0 = \frac{a_0 + b_0}{2} - \delta = \frac{1 + 4}{2} - 0.02 = 2.48$$

$$\mu_0 = \frac{a_0 + b_0}{2} + \delta = \frac{1 + 4}{2} + 0.02 = 2.52$$

► Calculamos evaluaciones:

$$f(2.48) \approx -68.1386 \quad f(2.52) \approx -68.2437$$

► Como $f(\lambda_0) > f(\mu_0) \implies$ descartamos $[a_0, \lambda_0]$. Nuevo intervalo: $[2.48, 4]$.

Búsqueda dicotómica: paso a paso numérico (paso 2)

► **Paso 2:** $[a_1, b_1] = [2.48, 4]$. Punto medio $c_1 = 3.24$.

► Planteamos y sustituimos:

$$\lambda_1 = \frac{a_1 + b_1}{2} - \delta = 3.22$$

$$\mu_1 = \frac{a_1 + b_1}{2} + \delta = 3.26$$

► Calculamos evaluaciones:

$$f(3.22) \approx -68.6910 \quad f(3.26) \approx -68.6709$$

► Como $f(\lambda_1) < f(\mu_1) \implies$ descartamos $[\mu_1, b_1]$. Nuevo intervalo: $[2.48, 3.26]$.

Búsqueda dicotómica: paso a paso numérico (paso 3 y siguientes)

► **Paso 3:** $[a_2, b_2] = [2.48, 3.26]$. Punto medio $c_2 = 2.87$.

► Planteamos y sustituimos:

$$\lambda_2 = 2.85 \quad \mu_2 = 2.89$$

► Calculamos evaluaciones:


$$f(2.85) \approx -68.7116 \quad f(2.89) \approx -68.7300$$

► Como $f(\lambda_2) > f(\mu_2) \implies$ descartamos $[a_2, \lambda_2]$. Nuevo intervalo final: $[2.85, 3.26]$.

► **Fin de la búsqueda:** El intervalo final es $[2.85, 3.26]$ con amplitud 0.41. Para alcanzar la tolerancia $\epsilon = 0.15$ se requerirían iteraciones adicionales.

Búsqueda dicotómica: visualización del método

El proceso divide iterativamente el intervalo de búsqueda prácticamente a la mitad, convergiendo con rapidez hacia el óptimo mediante evaluaciones pareadas:



Métodos sin derivadas: sección áurea

- ▶ Optimiza la búsqueda dicotómica al reutilizar uno de los puntos evaluados en el paso anterior, reduciendo el coste computacional.
- ▶ La amplitud del intervalo se reduce de forma constante por la razón áurea:

$$I_k = \frac{b_k - a_k}{\alpha} \quad \text{con} \quad \alpha = \frac{1 + \sqrt{5}}{2} \approx 1.61803$$

- ▶ Los puntos se localizan simétricamente en el intervalo:

$$\lambda_k = b_k - I_k \quad \mu_k = a_k + I_k$$

Sección áurea: deducción del ratio α (1)

- ▶ Queremos que la razón entre las amplitudes de iteraciones sucesivas sea constante:

$$I_k = \alpha I_{k+1} \quad I_{k+1} = \alpha I_{k+2} \implies I_k = \alpha^2 I_{k+2}$$

- ▶ Para poder reutilizar uno de los puntos internos del paso anterior, la suma de las amplitudes sucesivas debe satisfacer la relación de partición geométrica:

$$I_k = I_{k+1} + I_{k+2}$$

Sección áurea: deducción del ratio α (2)

- Sustituyendo las proporciones constantes de la escala en la partición geométrica:

$$\alpha^2 I_{k+2} = \alpha I_{k+2} + I_{k+2} \implies \alpha^2 - \alpha - 1 = 0$$

- Resolviendo esta ecuación cuadrática, la única raíz física posible ($\alpha > 1$) es la **razón áurea**:

$$\alpha = \frac{1 + \sqrt{5}}{2} \approx 1.618033988$$

Sección áurea: paso a paso numérico (paso 1)

Minimizamos $f(x)$ en $[1, 4]$ con tolerancia $\epsilon = 0.15$:

► **Paso 1:** Intervalo inicial $[a_0, b_0] = [1, 4]$.

► Amplitud teórica:

$$I_1 = \frac{b_0 - a_0}{\alpha} = \frac{4 - 1}{1.61803} \approx 1.8541$$

► Sustituimos y calculamos puntos:

$$\lambda_0 = b_0 - I_1 = 4 - 1.8541 = 2.1459 \implies f(2.1459) \approx -66.692$$

$$\mu_0 = a_0 + I_1 = 1 + 1.8541 = 2.8541 \implies f(2.8541) \approx -68.714$$

► Como $f(\lambda_0) > f(\mu_0) \implies$ descartamos $[a_0, \lambda_0]$. Nuevo intervalo: $[2.1459, 4]$.

Sección áurea: paso a paso numérico (paso 2)

- ▶ **Paso 2:** $[a_1, b_1] = [2.1459, 4]$. Amplitud $I_2 = 1.8541/1.61803 = 1.1459$.

- ▶ Reutilizamos el punto interior evaluado:

$$\lambda_1 = \mu_0 = 2.8541 \implies f(2.8541) \approx -68.714$$

- ▶ Sustituimos y calculamos el nuevo punto:

$$\mu_1 = a_1 + I_2 = 2.1459 + 1.1459 = 3.2918 \implies f(3.2918) \approx -68.654$$

- ▶ Como $f(\lambda_1) < f(\mu_1) \implies$ descartamos $[\mu_1, b_1]$. Nuevo intervalo: $[2.1459, 3.2918]$.

Sección áurea: paso a paso numérico (pasos siguientes)

► **Paso 3:** $[a_2, b_2] = [2.1459, 3.2918]$. Amplitud $I_3 = 0.7082$.

► Reutilizamos:

$$\mu_2 = \lambda_1 = 2.8541 \implies f(2.8541) \approx -68.714$$

► Calculamos el nuevo punto:


$$\lambda_2 = b_2 - I_3 = 3.2918 - 0.7082 = 2.5836 \implies f(2.5836) \approx -68.386$$

► Como $f(\lambda_2) > f(\mu_2) \implies$ descartamos $[a_2, \lambda_2]$. Nuevo intervalo: $[2.5836, 3.2918]$.

► **Convergencia:** El proceso continúa de forma análoga. En el **paso 7**, la amplitud de búsqueda se reduce a $0.1033 \leq 0.15$ (tolerancia alcanzada), con el óptimo localizado en el intervalo final $[2.91, 3.01]$.

Sección áurea: visualización del método

La amplitud del intervalo se contrae de forma secuencial manteniendo la proporción de la sección áurea, reutilizando las evaluaciones previas de forma simétrica:



Métodos sin derivadas: Fibonacci

- ▶ Fija de antemano el número total de evaluaciones de función N para maximizar la reducción del intervalo final.
- ▶ Utiliza los términos de la serie de Fibonacci para definir los coeficientes de reducción:

$$F_0 = 1, F_1 = 1, F_2 = 2, F_3 = 3, F_4 = 5, F_5 = 8, F_6 = 13, F_7 = 21,$$

- ▶ La amplitud del paso en cada iteración k se calcula mediante:

$$I_k = \frac{F_{N-k}}{F_{N-k+2}}(b_{k-1} - a_{k-1})$$

Fibonacci: relación de amplitudes e intervalos (1)

- ▶ Se fija de antemano el número total de evaluaciones N .
- ▶ En la última iteración ($N - 1$), queremos que los puntos coincidan prácticamente en el centro para poder descartar la mitad del espacio restante:

$$I_{N-1} \approx 2I_N$$

- ▶ Siguiendo la regla de adición para la reutilización de puntos, las amplitudes de intervalos sucesivos se van acumulando:

$$I_{N-2} = I_{N-1} + I_N \approx 3I_N$$

$$I_{N-3} = I_{N-2} + I_{N-1} \approx 5I_N$$

Fibonacci: relación de amplitudes e intervalos (2)

- ▶ En general, las amplitudes sucesivas en la iteración k se relacionan mediante los términos de Fibonacci:

$$I_k = F_{N-k+1} I_N$$

- ▶ Esto nos permite deducir el paso en cada iteración en función del intervalo actual de incertidumbre:

$$I_{k+1} = \frac{F_{N-k}}{F_{N-k+1}} (b_k - a_k)$$

Fibonacci: paso a paso numérico (paso 1)

Minimizamos $f(x)$ en $[1, 4]$ mediante Fibonacci para un total de $N = 6$ evaluaciones ($F_7 = 21$):

► **Paso 1:** $[a_0, b_0] = [1, 4]$.

► Amplitud teórica del paso:

$$I_1 = \frac{F_6}{F_7}(b_0 - a_0) = \frac{13}{21}(4 - 1) = \frac{39}{21} \approx 1.8571$$

► Sustituimos y calculamos:

$$\lambda_0 = b_0 - I_1 = 4 - 1.8571 = 2.1429 \implies f(2.1429) \approx -66.673$$

$$\mu_0 = a_0 + I_1 = 1 + 1.8571 = 2.8571 \implies f(2.8571) \approx -68.715$$

► Como $f(\lambda_0) > f(\mu_0) \implies$ nuevo intervalo: $[2.1429, 4]$.

Fibonacci: paso a paso numérico (paso 2 y siguientes)

- **Paso 2:** $[a_1, b_1] = [2.1429, 4]$. Paso
 $I_2 = \frac{F_5}{F_7}(b_0 - a_0) = \frac{8}{21} \cdot 3 = 1.1429$.

- Reutilizamos el punto interior evaluado:

$$\lambda_1 = \mu_0 = 2.8571 \implies f(2.8571) \approx -68.715$$

- Sustituimos y calculamos el nuevo punto:

$$\mu_1 = a_1 + I_2 = 2.1429 + 1.1429 = 3.2857 \implies f(3.2857) \approx -68.657$$

- Como $f(\mu_1) > f(\lambda_1) \implies$ descartamos $[\mu_1, b_1]$. Nuevo intervalo final: $[2.1429, 3.2857]$.

- **Pasos siguientes:** El algoritmo continúa de forma análoga reduciendo los coeficientes de Fibonacci hasta agotar las $N = 6$ evaluaciones de la función planificadas, estrechando el intervalo en torno a $x^* = 3.0$.

Métodos con derivadas: bisección (Bolzano)

- ▶ Busca el cero de la primera derivada ($f'(x) = 0$) en un intervalo $[a, b]$ donde el signo de la derivada en los extremos sea opuesto ($f'(a) \cdot f'(b) < 0$).
- ▶ En cada paso, evalúa el punto medio del intervalo:

$$c_k = \frac{a_k + b_k}{2}$$

- ▶ Reduce el intervalo a la mitad analizando el signo de $f'(c_k)$:
 - ▶ Si $f'(c_k) < 0 \implies$ nuevo intervalo $[c_k, b_k]$.
 - ▶ Si $f'(c_k) > 0 \implies$ nuevo intervalo $[a_k, c_k]$.

Bisección: paso a paso numérico (paso 1)

Minimizamos $f(x)$ con $f'(x) = x^3 - 13x^2 + 54x - 72$ en $[1, 4]$, $\epsilon = 0.15$:

► **Paso 1:** $[a_0, b_0] = [1, 4]$.

► Punto medio teórico:

$$c_0 = \frac{a_0 + b_0}{2} = \frac{1 + 4}{2} = 2.5$$

► Sustituimos y calculamos la derivada:

$$f'(2.5) = (2.5)^3 - 13(2.5)^2 + 54(2.5) - 72 = -2.625 < 0$$

► Descartamos la mitad izquierda $\implies$ nuevo intervalo $[2.5, 4]$.

Bisección: paso a paso numérico (paso 2)

► **Paso 2:** $[a_1, b_1] = [2.5, 4]$. Punto medio $c_1 = 3.25$.

► Sustituimos y calculamos la derivada:

$$f'(3.25) = (3.25)^3 - 13(3.25)^2 + 54(3.25) - 72 = 0.5156 > 0$$

► Como $f'(c_1) > 0 \implies$ descartamos la mitad derecha. Nuevo intervalo: $[2.5, 3.25]$.

Bisección: paso a paso numérico (paso 3 y siguientes)

► **Paso 3:** $[a_2, b_2] = [2.5, 3.25]$. Punto medio $c_2 = 2.875$.

► Sustituimos y calculamos la derivada:


$$f'(2.875) = (2.875)^3 - 13(2.875)^2 + 54(2.875) - 72 = -0.4395 < 0$$

► Como $f'(c_2) < 0 \implies$ descartamos la mitad izquierda. Nuevo intervalo: $[2.875, 3.25]$.

► **Convergencia:** En el **paso 5**, el intervalo es $[2.9531, 3.0469]$ con una amplitud de $0.0938 \leq 0.15$, alcanzando la tolerancia.

Bisección: visualización del método

El método se basa en el teorema de Bolzano, acotando sucesivamente el valor donde la derivada se anula dividiendo a la mitad la amplitud en cada iteración:



Métodos con derivadas: método de Newton 1D

- ▶ Aproxima la función objetivo mediante su polinomio de Taylor cuadrático alrededor del punto de búsqueda actual x_k .
- ▶ El siguiente punto iterado se obtiene saltando directamente al vértice de la parábola aproximada (donde la derivada aproximada se anula):

$$x_{k+1} = x_k - \frac{f'(x_k)}{f''(x_k)}$$

- ▶ Requiere que la función sea de clase $\mathcal{C}^2$ y que $f''(x_k) \neq 0$.

Newton 1D: deducción de la fórmula

- El desarrollo de Taylor de segundo orden en x_k es:

$$q(x) = f(x_k) + f'(x_k)(x - x_k) + \frac{1}{2}f''(x_k)(x - x_k)^2$$

- Para hallar el vértice de la aproximación parabólica, igualamos su derivada a cero:

$$q'(x) = f'(x_k) + f''(x_k)(x - x_k) = 0$$

- Despejando x , obtenemos el punto iterado x_{k+1} :

$$x - x_k = -\frac{f'(x_k)}{f''(x_k)} \implies x_{k+1} = x_k - \frac{f'(x_k)}{f''(x_k)}$$

Newton 1D: paso a paso numérico (paso 1)

Minimizamos la misma función partiendo de $x_0 = 1.0$:

► **Paso 1:** Partimos de $x_0 = 1.0$.

► Ecuaciones teóricas y derivadas ($f''(x) = 3x^2 - 26x + 54$):

$$f'(x_0) = f'(1.0) = 1^3 - 13(1)^2 + 54(1) - 72 = -30.0$$

$$f''(x_0) = f''(1.0) = 3(1)^2 - 26(1) + 54 = 31.0$$

► Sustituimos en la regla de Newton:

$$x_1 = x_0 - \frac{f'(x_0)}{f''(x_0)} = 1.0 - \frac{-30.0}{31.0} \approx 1.9677$$

Newton 1D: paso a paso numérico (paso 2)

► **Paso 2:** Partimos del punto anterior $x_1 = 1.9677$.

► Calculamos primera y segunda derivada:

$$f'(1.9677) \approx -8.4589 \quad f''(1.9677) \approx 14.4547$$

► Sustituimos en la regla de Newton:

$$x_2 = x_1 - \frac{f'(x_1)}{f''(x_1)} = 1.9677 - \frac{-8.4589}{14.4547} \approx 2.5529$$

Newton 1D: paso a paso numérico (pasos 3-5)

► **Paso 3:** Partimos de $x_2 = 2.5529$.

► Calculamos derivadas: $f'(2.5529) \approx -2.2300$,
 $f''(2.5529) \approx 7.1760$.

► Actualización: $x_3 = 2.5529 - \frac{-2.2300}{7.1760} \approx 2.8637$.


► **Paso 4:** $x_3 = 2.8637 \implies x_4 = 2.8637 - \frac{-0.485}{4.146} \approx 2.9808$.

► **Paso 5:**

$$x_4 = 2.9808 \implies x_5 = 2.9808 - \frac{-0.059}{3.154} \approx 2.9995 \approx 3.0.$$

Newton 1D: visualización del método

El algoritmo aproxima de manera local mediante parábolas sucesivas y converge muy rápido si el punto inicial x_0 está próximo al óptimo:



Método de la secante

- ▶ Evita el cálculo de la segunda derivada del método de Newton.
- ▶ Aproxima la curvatura mediante la diferencia de gradientes en los últimos dos pasos:

$$x_{k+1} = x_k - f'(x_k) \frac{x_k - x_{k-1}}{f'(x_k) - f'(x_{k-1})}$$

- ▶ Características:
 - ▶ Convergencia superlineal con orden ≈ 1.618 .
 - ▶ Exige disponer de dos puntos iniciales x_0 y x_{-1} .

Secante: paso a paso numérico (pasos 1-2)

Minimizamos $f(x)$ en $[1, 4]$ partiendo de $x_{-1} = 1.0$ y $x_0 = 1.5$:

► **Paso 1:** $x_{-1} = 1.0$, $x_0 = 1.5$.

► Evaluamos derivadas:

$$f'(1.0) = -30.0 \quad f'(1.5) = -16.875.$$

► Sustituimos en la regla:

$$x_1 = 1.5 - (-16.875) \cdot \frac{1.5 - 1.0}{-16.875 - (-30.0)} \approx 2.1429$$

► **Paso 2:** $x_0 = 1.5$, $x_1 = 2.1429$.

► Derivada nueva: $f'(2.1429) \approx -6.1399$.

► Actualización:

$$x_2 = 2.1429 - (-6.1399) \cdot \frac{2.1429 - 1.5}{-6.1399 - (-16.875)} \approx 2.5106$$

Secante: paso a paso numérico (pasos siguientes)

- ▶ **Paso 3:** $x_1 = 2.1429$, $x_2 = 2.5106$.
 - ▶ Actualización: $x_3 \approx 2.7707$.
- ▶ **Paso 4:** $x_2 = 2.5106$, $x_3 = 2.7707$.
 - ▶ Actualización: $x_4 \approx 2.9157$.
- ▶ **Paso 5:** $x_3 = 2.7707$, $x_4 = 2.9157$.
 - ▶ Actualización: $x_5 \approx 2.9807$ (llegando a $x_7 \approx 2.9999 \approx 3.0$ en iteraciones posteriores sin calcular segundas derivadas).

Métodos multivariantes

Métodos multivariantes de optimización sin restricciones

Buscan minimizar $f : \mathbb{R}^n \rightarrow \mathbb{R}$ mediante la sucesión iterativa:

$$x_{k+1} = x_k + \alpha_k d_k$$

Donde:

- **Dirección de búsqueda (d_k):** Debe ser de descenso (formar un ángulo obtuso con el gradiente):

$$\nabla f(x_k)^T d_k < 0$$

- **Tamaño de paso (α_k):** Determina el avance óptimo a lo largo de la dirección. Se calcula resolviendo el problema unidimensional:


$$\alpha_k = \arg \min_{\alpha > 0} f(x_k + \alpha d_k)$$

Funciones multivariantes de prueba (1)

► Función de distancia circular (desacoplada):

$$f(x, y) = (x - 2)^2 + (y - 1)^2$$

- Presenta un paraboloide circular de revolución simétrico con curvas de nivel circulares concéntricas y mínimo global en $x^* = (2, 1)^T$.




Funciones multivariantes de prueba (2)

► Función cuadrática mal acondicionada (acoplada):

$$f(x, y) = 8x^2 + 3xy + 7y^2 - 25x + 31y - 29$$

- Presenta un paraboloide elíptico alargado con curvas de nivel elípticas y mínimo global en $x^* \approx (2.060, -2.656)^T$.



Método de coordenadas cíclicas

- ▶ Es un método de optimización multivariante de búsqueda directa (no requiere derivadas).
- ▶ Avanza de forma iterativa minimizando respecto a una sola variable de decisión a la vez de forma cíclica (direcciones de búsqueda ortogonales $d_k = e_i$):

$$x_{k+1} = x_k + \alpha_k e_i$$

- ▶ El tamaño de paso exacto α_k se calcula mediante una búsqueda lineal unidimensional exacta en la dirección e_i .

Coordenadas cíclicas: paso a paso numérico (paso 1)

Minimizamos $f(x, y) = 8x^2 + 3xy + 7y^2 - 25x + 31y - 29$ desde $x_0 = (0, 0)^T$:

► **Paso 1:** Optimizamos respecto a x fijando $y = y_0 = 0$:

► Sustituimos en la ecuación teórica:

$$f(x, 0) = 8x^2 + 3x(0) + 7(0)^2 - 25x + 31(0) - 29 = 8x^2 - 25x - 29$$

► Derivamos respecto a x e igualamos a cero:

$$\frac{df(x, 0)}{dx} = 16x - 25 = 0 \implies x = \frac{25}{16} = 1.5625$$

► El punto resultante es $x_1 = (1.5625, 0)^T$.

Coordenadas cíclicas: paso a paso numérico (paso 2)

► **Paso 2:** Optimizamos respecto a y fijando $x = 1.5625$:

► Sustituimos en la ecuación:

$$f(1.5625, y) = 7y^2 + 35.6875y - 48.531$$

► Derivamos respecto a y e igualamos a cero:

$$\frac{\partial f(1.5625, y)}{\partial y} = 14y + 35.6875 = 0 \implies y_2 \approx -2.5491$$

► El punto resultante es $x_2 = (1.5625, -2.5491)^T$.

Coordenadas cíclicas: paso a paso numérico (paso 3)

► **Paso 3:** Optimizamos respecto a x fijando $y = -2.5491$:

► Sustituimos en la ecuación:

$$f(x, -2.5491) = 8x^2 - 32.647x - 62.533$$

► Derivamos respecto a x e igualamos a cero:


$$\frac{\partial f(x, -2.5491)}{\partial x} = 16x - 32.647 = 0 \implies x_3 \approx 2.0405$$

► El punto resultante es $x_3 = (2.0405, -2.5491)^T$.

Coordenadas cíclicas: variables desacopladas


Avanza minimizando respecto a una sola variable a la vez. Si las variables están desacopladas (Hessiana diagonal), localiza el mínimo en exactamente $n = 2$ pasos ortogonales exactos:

Descenso por Coordenadas: $f(x, y) = (x - 2)^2 + (y - 1)^2$



Coordenadas cíclicas: variables acopladas

Si las variables están acopladas (término bilineal $3xy$), la trayectoria dibuja un patrón de “escalera”, haciendo lenta la convergencia:



Método del máximo descenso

- Dirección de búsqueda: opuesta al gradiente local ($d_k = -\nabla f(x_k)$). :: {.callout-important title="Ortogonalidad"} Si el tamaño de paso se calcula mediante búsqueda de línea exacta, las direcciones de búsqueda consecutivas son siempre ortogonales:

$$d_k^T d_{k+1} = 0$$

:::

- **Consecuencia geométrica:** El método avanza generando un patrón en “zig-zag” característico con ángulos de 90° entre iteraciones sucesivas.

Máximo descenso: paso a paso numérico (paso 1)

Caso cuadrático acoplado $f(x, y)$ desde $x_0 = (0, 0)^T$:

► **Paso 1:** Calculamos el gradiente y la dirección de descenso:

► Gradiente teórico:

$$\nabla f(x, y) = \begin{pmatrix} 16x + 3y - 25 \\ 3x + 14y + 31 \end{pmatrix}$$

► Sustituimos $x_0 = (0, 0)^T$:

$$\nabla f(x_0) = \begin{pmatrix} 16(0) + 3(0) - 25 \\ 3(0) + 14(0) + 31 \end{pmatrix} = \begin{pmatrix} -25 \\ 31 \end{pmatrix}$$

► Dirección de búsqueda ($d_0 = -\nabla f(x_0)$):

$$d_0 = \begin{pmatrix} 25 \\ -31 \end{pmatrix}$$

Máximo descenso: paso a paso numérico (paso 2)

- **Paso 2:** Búsqueda lineal exacta en la dirección

$$d_0 = (25, -31)^T:$$

- Sustituimos la trayectoria $x(\alpha) = x_0 + \alpha d_0 = (25\alpha, -31\alpha)^T$:

$$\phi(\alpha) = f(25\alpha, -31\alpha) = 9402\alpha^2 - 1586\alpha - 29$$

- Derivamos e igualamos a cero:

$$\phi'(\alpha) = 18804\alpha - 1586 = 0 \implies \alpha_0 = \frac{1586}{18804} \approx 0.0843$$

Máximo descenso: paso a paso numérico (pasos 3-4)

- **Paso 3:** Actualizamos el punto con la longitud de paso óptima $\alpha_0 \approx 0.0843$:

$$x_1 = x_0 + \alpha_0 d_0 = \begin{pmatrix} 0 \\ 0 \end{pmatrix} + 0.0843 \begin{pmatrix} 25 \\ -31 \end{pmatrix} \approx \begin{pmatrix} 2.109 \\ -2.615 \end{pmatrix}$$

- **Paso 4:** Verificamos la ortogonalidad teórica en el nuevo punto:

- Evaluamos el gradiente en x_1 :


$$\nabla f(x_1) \approx \begin{pmatrix} 0.8925 \\ 0.7225 \end{pmatrix}$$

- El producto escalar es nulo (ortogonales):

$$d_0^T \nabla f(x_1) = 25(0.8925) - 31(0.7225) \approx 0$$

Máximo descenso: visualización del método

La ortogonalidad obligada entre direcciones consecutivas debido a la búsqueda lineal exacta provoca un patrón de “zigzag” muy ineficiente en funciones con valles estrechos (elipses alargadas):



Método de Newton multivariante

Aproxima la función objetivo mediante una parábola multivariante en el punto actual x_k :

$$x_{k+1} = x_k - [\nabla^2 f(x_k)]^{-1} \nabla f(x_k)$$

- ▶ **Ventaja:** Convergencia cuadrática local de orden 2. Localiza el mínimo en 1 iteración para funciones cuadráticas.
- ▶ **Limitaciones:**
 - ▶ Coste computacional de resolver el sistema lineal es alto ($O(n^3)$).
 - ▶ Exige que la Hessiana sea definida positiva ($H \succ 0$).
 - ▶ Convergencia estrictamente local (puede divergir si se empieza lejos).

Newton multivariante: paso a paso numérico (pasos 1-2)

Minimizamos $f(x, y) = 8x^2 + 3xy + 7y^2 - 25x + 31y - 29$ desde $x_0 = (0, 0)^T$:

► **Paso 1:** Calculamos el gradiente y la Hessiana en el punto actual:

► Expresiones teóricas:

$$\nabla f(x, y) = \begin{pmatrix} 16x + 3y - 25 \\ 3x + 14y + 31 \end{pmatrix} \Rightarrow \nabla f(x_0) = \begin{pmatrix} -25 \\ 31 \end{pmatrix}$$

$$H = \nabla^2 f(x, y) = \begin{pmatrix} 16 & 3 \\ 3 & 14 \end{pmatrix} \quad (\text{constante})$$

► **Paso 2:** Calculamos la inversa de la Hessiana H^{-1} (determinante $|H| = 16 \cdot 14 - 3^2 = 215$):

$$H^{-1} = \frac{1}{215} \begin{pmatrix} 14 & -3 \\ -3 & 16 \end{pmatrix}$$

Newton multivariante: paso a paso numérico (paso 3)

- **Paso 3:** Aplicamos la actualización iterativa del método de Newton:

$$x_1 = x_0 - H^{-1} \nabla f(x_0)$$

$$x_1 = \begin{pmatrix} 0 \\ 0 \end{pmatrix} - \frac{1}{215} \begin{pmatrix} 14 & -3 \\ -3 & 16 \end{pmatrix} \begin{pmatrix} -25 \\ 31 \end{pmatrix}$$

$$x_1 = -\frac{1}{215} \begin{pmatrix} 14(-25) - 3(31) \\ -3(-25) + 16(31) \end{pmatrix} = -\frac{1}{215} \begin{pmatrix} -443 \\ 571 \end{pmatrix} = \begin{pmatrix} 443/215 \\ -571/215 \end{pmatrix}$$

$$x_1 \approx \begin{pmatrix} 2.0605 \\ -2.6558 \end{pmatrix}$$

- **Conclusión:** Dado que la función $f(x, y)$ es cuadrática, la aproximación local es exacta y el método de Newton converge al mínimo global en **exactamente una iteración**.

Método cuasi-Newton: BFGS

Resuelven los inconvenientes del método de Newton estimando la inversa de la Hessiana $H_k \approx [\nabla^2 f(x_k)]^{-1}$ usando solo gradientes:

- Fuerzan la **ecuación de la secante**:

$$H_{k+1}y_k = s_k$$

donde $s_k = x_{k+1} - x_k$ y $y_k = \nabla f(x_{k+1}) - \nabla f(x_k)$.

- Mantiene la matriz definida positiva en cada paso (si cumple condiciones de Wolfe).
- Costo de $O(n^2)$ por iteración y convergencia superlineal.