Universidad Rey Juan Carlos

ESCUELA TÉCNICA SUPERIOR DE INGENIERÍA INFORMÁTICA

MATERIAL DOCENTE EN ABIERTO · UNIVERSIDAD REY JUAN CARLOS · JUNIO 2026

Optimización y Análisis de Redes

Material docente en abierto de la Universidad Rey Juan Carlos

Grado en Matemáticas · 4.º Curso (Optativa)

AUTORES

- Víctor Aceña Gil
- Antonio Alonso Ayuso

2026-2027

Copyright © 2026 Víctor Aceña Gil, Antonio Alonso Ayuso. Algunos derechos reservados. Esta obra se distribuye bajo la licencia Creative Commons Atribución-CompartirIgual 4.0 Internacional (CC BY-SA 4.0). Depósito en BURJC Digital (https://burjcdigital.urjc.es/).

CRÉDITOS Y METADATOS DE LA OBRA

Título: Optimización y Análisis de Redes
Subtítulo: Material docente en abierto de la Universidad Rey Juan Carlos
Autores: Víctor Aceña Gil y Antonio Alonso Ayuso
Asignatura: Optimización y Análisis de Redes (6.0 créditos ECTS, optativa de 4.º curso)
Titulación: Grado en Matemáticas (Mención en Matemática Aplicada y Computación)
Centro: Escuela Técnica Superior de Ingeniería Informática, Universidad Rey Juan Carlos
Filiación: Departamento de Informática y Estadística / Grupo de Investigación en Fundamentos y Aplicaciones de la Ciencia de Datos (DSLAB)
Edición y curso: Junio 2026 / Curso académico 2026-2027

DEPÓSITO INSTITUCIONAL Y PRESERVACIÓN DIGITAL

Repositorio institucional: Archivo Abierto Institucional de la Universidad Rey Juan Carlos (BURJC Digital)
Plataforma BURJC Digital: https://burjcdigital.urjc.es/
Repositorio público de código y materiales: https://github.com/URJCDSLab/OptimizacionAnalisisRedes
Preservación de software (Software Heritage): Código fuente depositado en Software Heritage

LICENCIA DE PUBLICACIÓN EN ACCESO ABIERTO

Copyright © 2026 Víctor Aceña Gil, Antonio Alonso Ayuso.

Algunos derechos reservados. Esta obra se distribuye bajo la licencia Creative Commons Atribución-CompartirIgual 4.0 Internacional (CC BY-SA 4.0).

Usted es libre de compartir (copiar y redistribuir el material en cualquier medio o formato) y adaptar (remezclar, transformar y crear a partir del material para cualquier propósito, incluso comercialmente), bajo los términos de reconocer adecuadamente la autoría y distribuir sus contribuciones bajo la misma licencia. Texto legal completo: https://creativecommons.org/licenses/by-sa/4.0/deed.es.

DECLARACIÓN SOBRE USO DE HERRAMIENTAS DE INTELIGENCIA ARTIFICIAL GENERATIVA

En cumplimiento de lo dispuesto en el Anexo VI de la Convocatoria para el reconocimiento de publicación en acceso abierto de materiales docentes (curso 2026-2027) de la Universidad Rey Juan Carlos, se declara el uso de herramientas de inteligencia artificial generativa en la producción de los materiales presentados:

- **Tipo de herramientas:** Modelos de lenguaje de gran tamaño (LLM) y asistentes de edición técnica de código fuente y maquetación en Quarto/Markdown.
- **Forma de uso:** Asistencia en la revisión ortotipográfica y sintáctica del texto, soporte en la maquetación de plantillas Quarto y asistencia en la generación de scripts de visualización geométrica con Matplotlib.
- **Grado de uso:** Apoyo instrumental y técnico. Todo el diseño metodológico, teoremas, formulaciones matemáticas, demostraciones, modelos de optimización y cuadernos de ejercicios han sido concebidos y desarrollados íntegramente por los autores.

Manifiesto de responsabilidad: Todo el contenido de esta obra ha sido cuidadosamente revisado, editado, validado y aprobado por los autores, quienes asumen la plena responsabilidad sobre la versión final de la misma.

Índice General de Contenidos

Guía de Estudio 6

- Presentación, competencias y metodología docente 8
- Cronograma semanal (Bloques I y II) 11
- Sistema de evaluación y bibliografía de referencia 29

Apuntes Teóricos 31

- Tema 1: Introducción a la investigación operativa 36
- Tema 2: Optimización no lineal sin restricciones 48
- Tema 3: Análisis convexo 79
- Tema 4: Condiciones de optimalidad y KKT 123
- Tema 5: Dualidad KKT en programación lineal y cuadrática 189
- Tema 6: Grafos y árboles soporte 229
- Tema 7: Problema del camino mínimo 288
- Tema 8: Flujos en redes 324
- Tema 9: Emparejamientos en redes 382
- Tema 10: Rutas eulerianas, hamiltonianas, TSP y VRP 413
- Conclusiones de la obra 451
- Referencias bibliográficas 454

Diapositivas de Clase 463

- Tema 1: Introducción a la investigación operativa 465
- Tema 2: Optimización no lineal 480
- Tema 3: Análisis convexo 554
- Tema 4: Condiciones de optimalidad y KKT 624
- Tema 5: Programación lineal y cuadrática 730

- Tema 6: Grafos y árboles soporte 812
- Tema 7: Problema del camino mínimo 922
- Tema 8: Flujos en redes 999
- Tema 9: Emparejamientos en redes 999
- Tema 10: Rutas eulerianas, hamiltonianas, TSP y VRP 1088

Ejercicios Prácticos **1172**

- Ejercicios del Tema 1: Introducción a la investigación operativa 1177
- Ejercicios del Tema 2: Optimización no lineal y métodos numéricos 1179
- Ejercicios del Tema 3: Análisis convexo 1183
- Ejercicios del Tema 4: Condiciones de optimalidad y KKT 1187
- Ejercicios del Tema 5: Dualidad KKT en programación lineal y cuadrática 1192
- Ejercicios del Tema 6: Grafos y árboles soporte de mínimo peso 1195
- Ejercicios del Tema 7: Problema del camino mínimo 1200
- Ejercicios del Tema 8: Flujos en redes 1203
- Ejercicios del Tema 9: Emparejamientos en redes 1206
- Ejercicios del Tema 10: Rutas eulerianas, hamiltonianas, TSP y VRP 1210
- Problemas Resueltos **1215**
- Soluciones del Tema 1: Introducción a la investigación operativa 1220
- Soluciones del Tema 2: Optimización no lineal y métodos numéricos 1225
- Soluciones del Tema 3: Análisis convexo 1241
- Soluciones del Tema 4: Condiciones de optimalidad y KKT 1257
- Soluciones del Tema 5: Dualidad KKT en programación lineal y cuadrática 1282
- Soluciones del Tema 6: Grafos y árboles soporte de mínimo peso 1294
- Soluciones del Tema 7: Problema del camino mínimo 1311
- Soluciones del Tema 8: Flujos en redes 1320
- Soluciones del Tema 9: Emparejamientos en redes 1331
- Soluciones del Tema 10: Rutas eulerianas, hamiltonianas, TSP y VRP 1346
- Software y Laboratorios **1361**
- Laboratorio 1: Introducción al modelado y cálculo simbólico con SymPy 1362
- Laboratorio 2: Optimización no lineal con Python 1362
- Laboratorio 3: Análisis de convexidad y modelado con CVXPY 1362
- Laboratorio 4: Condiciones de optimalidad y KKT en Python 1363

- Laboratorio 5: Dualidad KKT y programación cuadrática en Python 1363
- Laboratorio 6: Grafos y árboles soporte de mínimo peso en Python 1363
- Laboratorio 7: Problemas de camino mínimo en Python 1364
- Laboratorio 8: Flujos en redes en Python 1364
- Laboratorio 9: Emparejamientos en redes en Python 1364
- Laboratorio 10: Rutas eulerianas, hamiltonianas, TSP y VRP en Python 1364

PARTE I

Guía de Estudio de la Asignatura

Planificación docente, competencias, metodología y cronograma semanal de trabajo

> Documento orientador que detalla la organización temporal de la materia a lo largo de las quince semanas lectivas. Para cada sesión presencial de teoría y laboratorio se establecen los objetivos de aprendizaje según la taxonomía de Bloom, los materiales de estudio requeridos y las recomendaciones de trabajo autónomo personal.

Víctor Aceña Gil · Antonio Alonso Ayuso
CC BY-SA 4.0 Internacional · Curso 2026-2027

Indice de contenidos

1 Introducción a la asignatura **2**

2 Datos identificativos y competencias **3**
2.1 Ficha técnica de la asignatura 3
2.2 Competencias generales y específicas 3

3 Metodología docente y distribución del trabajo **4**

4 Cronograma y plan de trabajo semanal **5**
4.1 BLOQUE I: Optimización Matemática y Ciencia de Datos (Semanas 1 a 10) 5
4.1.1 SEMANA 1: Fundamentos y Modelado Matemático de la Optimización . . . 5
4.1.2 SEMANA 2: Optimización No Lineal Sin Restricciones: Condiciones de Optimalidad 6
4.1.3 SEMANA 3: Algoritmos de Descenso y Visualización Avanzada 7
4.1.4 SEMANA 4: Análisis Convexo I: Conjuntos Convexos 8
4.1.5 SEMANA 5: Análisis Convexo II: Funciones Convexas 9
4.1.6 SEMANA 6: Optimización con Restricciones y Condiciones KKT 11
4.1.7 SEMANA 7: Dualidad Lagrangiana y Teoremas de Dualidad 12
4.1.8 SEMANA 8: Programación Convexa Disciplinada y CVXPY 13
4.1.9 SEMANA 9: Aplicaciones a Ciencia de Datos I: Regresión y SVM Lineal . . . 14
4.1.10 SEMANA 10: Aplicaciones a Ciencia de Datos II: SVM Generalizada, Dualidad y Kernels 15
4.2 BLOQUE II: Optimización y Análisis de Redes (Semanas 11 a 15) 16
4.2.1 SEMANA 11: Teoría de Grafos, Estructuras y Árboles Soporte 16
4.2.2 SEMANA 12: Algoritmos de Caminos Mínimos 17
4.2.3 SEMANA 13: Problemas de Flujo en Redes 18
4.2.4 SEMANA 14: Problemas de Emparejamiento (Matching) y Asignación 19
4.2.5 SEMANA 15: Rutas en Redes, TSP, VRP y Síntesis Final 21

5 Sistema de evaluación y criterios de calificación **23**
5.1 Convocatoria Ordinaria (Evaluación Continua) 23
5.2 Convocatoria Extraordinaria 23

6 Bibliografía y recursos de referencia **24**
6.1 Textos de referencia principal 24
6.2 Textos complementarios de algoritmos y computación 24
6.3 Recursos digitales y software 24

1 Introducción a la asignatura

La **optimización matemática** y el **análisis de redes** constituyen dos de los pilares fundamentales de la matemática aplicada, la investigación operativa y la ciencia de datos moderna. En la sociedad digital e industrial contemporánea, donde los recursos son finitos y los datos interconectados crecen de forma exponencial, la capacidad de formalizar matemáticamente problemas complejos y resolverlos algorítmicamente resulta esencial para la toma de decisiones estratégicas.

Esta asignatura, diseñada para el **Grado en Matemáticas** de la **Universidad Rey Juan Carlos (URJC)**, amplía y consolida la formación matemática previa en álgebra lineal, cálculo multivariante y programación lineal, adentrándose en el análisis riguroso de la **optimización no lineal continua** y el modelado discreto mediante la **teoría y optimización en redes**.

El diseño pedagógico del curso conjuga el rigor deductivo formal (teoremas de existencia, convexidad, dualidad lagrangiana y complejidad algorítmica) con el desarrollo computacional en **Python**, empleando librerías científicas profesionales de referencia internacional como **NumPy**, **SciPy**, **CVXPY** (para optimización convexa disciplinada) y **NetworkX** (para el modelado y visualización de grafos).

---

2 Datos identificativos y competencias

2.1. Ficha técnica de la asignatura

- **Asignatura**: Optimización y Análisis de Redes
- **Titulación**: Grado en Matemáticas (Mención en Matemática Aplicada y Computación) / Dobles Grados afines
- **Centro**: Escuela Técnica Superior de Ingeniería Informática (ETSII), Universidad Rey Juan Carlos
- **Créditos ECTS**: 6.0 ECTS (150 horas totales de dedicación del estudiante)
- **Carácter**: Asignatura optativa de cuarto curso (4.º curso)
- **Temporalidad**: Segundo cuatrimestre, 4.º curso (15 semanas lectivas)
- **Idioma de impartición**: Castellano
- **Prerrequisitos recomendados**: Álgebra Lineal, Cálculo Diferencial e Integral en Varias Variables, Fundamentos de Programación e Introducción a la Optimización Lineal.

2.2. Competencias generales y específicas

Al superar la asignatura, los estudiantes habrán adquirido las siguientes capacidades formativas:

1. **Modelización matemática formal**: Capacidad para abstraer problemas reales de logística, telecomunicaciones, finanzas y ciencia de datos, formulándolos rigurosamente como problemas de optimización matemática o modelos sobre redes.
2. **Análisis teórico y deductivo**: Habilidad para caracterizar la convexidad de conjuntos y funciones, demostrar condiciones de optimalidad de primer y segundo orden (KKT) y formular problemas duales interpretando sus propiedades de convergencia.
3. **Algoritmia y complejidad computacional**: Comprensión profunda de la estructura, convergencia y coste asintótico de los algoritmos clásicos y modernos de optimización en espacios continuos y sobre grafos finitos.
4. **Implementación y experimentación computacional**: Destreza para programar algoritmos numéricos y combinatorios en Python, validar soluciones con optimizadores comerciales y de código abierto, y comunicar resultados técnicos mediante visualizaciones claras.

---

3 Metodología docente y distribución del trabajo

La asignatura se articula en torno a un modelo de aprendizaje activo y equilibrado entre la fundamentación analítica y la experimentación computacional en laboratorio:

- **Clases de teoría y fundamentos matemáticos (2.0 horas/semana)**: Deducción formal de teoremas, análisis poliédrico, demostración de propiedades de convexidad, condiciones de Karush-Kuhn-Tucker y dualidad.
- **Sesiones de laboratorio en Python (2.0 horas/semana)**: Implementación práctica de algoritmos, resolución de modelos numéricos con CVXPY y NetworkX, y visualización de soluciones y superficies de nivel con Matplotlib.
- **Seminarios y resolución guiada de problemas**: Análisis paso a paso de casos de estudio, formulaciones complejas de programación entera y ejercicios de examen.
- **Tutorías académicas personalizadas**: Orientación individual y en grupo para la resolución de dudas teóricas y seguimiento de los proyectos de laboratorio.
- **Trabajo autónomo del estudiante (6.0 horas/semana)**: Estudio personal, lectura de la bibliografía recomendada, preparación de sesiones prácticas y resolución de colecciones de problemas.

Actividad formativa	Horas presenciales	Horas de trabajo autónomo	Horas totales
Clases de teoría magistral	30.0 h	35.0 h	65.0 h
Prácticas de laboratorio en Python	26.0 h	34.0 h	60.0 h
Seminarios y evaluación continua	4.0 h	21.0 h	25.0 h
Total dedicación (6 ECTS)	**60.0 h**	**90.0 h**	**150.0 h**

4 Cronograma y plan de trabajo semanal

El programa docente se estructura cronológicamente a lo largo de las 15 semanas lectivas del cuatrimestre, dividido en dos grandes bloques temáticos complementarios. Para cada sesión presencial de teoría y laboratorio se detallan los contenidos cubiertos, los objetivos didácticos formulados según la taxonomía de Bloom, las actividades planificadas, los materiales específicos a emplear y la recomendación cuantitativa de trabajo autónomo personal. Las referencias a secciones teóricas corresponden a la numeración interna del bloque de Apuntes Teóricos (Parte II), fácilmente accesibles a través del Índice General del volumen o mediante la búsqueda del tema correspondiente:

4.1. BLOQUE I: Optimización Matemática y Ciencia de Datos (Semanas 1 a 10)

4.1.1. SEMANA 1: Fundamentos y Modelado Matemático de la Optimización

Esta primera semana introduce el marco conceptual de la optimización matemática, sentando las bases analíticas del modelado formal y configurando el entorno de programación científica en Python.

Sesión 1.1: Teoría y Fundamentos Matemáticos (2.0 h presenciales)

- *Contenidos cubiertos*: Naturaleza de la optimización matemática, variables de decisión, parámetros del sistema, funciones objetivo y regiones factibles. Taxonomía de problemas (continuos frente a discretos, lineales frente a no lineales, convexos frente a no convexos). Repaso sistemático de álgebra lineal numérica, normas vectoriales y cálculo diferencial multivariante.
- *Objetivos de aprendizaje*:

  1. **Identificar** y **formular** matemáticamente los elementos constitutivos de un problema de optimización a partir de una descripción en lenguaje natural.
  2. **Clasificar** problemas de optimización atendiendo a su linealidad, diferenciabilidad y geometría admisible.

- *Materiales específicos a emplear*:

  - **Apuntes teóricos (Parte II)**: Tema 1, "Fundamentos de la Optimización Matemática", Secciones 1.1 a 1.4.
  - **Diapositivas de clase**: Presentación del Tema 1, diapositivas 1 a 15.

- *Actividades planificadas*: Exposición magistral interactiva sobre modelización matemática formal y deducción de propiedades de normas vectoriales en pizarra.

- *Recomendación de trabajo autónomo (3.0 h)*: Lectura reflexiva y analítica del Tema 1 en los apuntes teóricos, centrando el estudio en las definiciones de normas, conjuntos de nivel y operadores diferenciales.

Sesión 1.2: Laboratorio Computacional y Resolución Práctica (2.0 h presenciales)

- *Contenidos cubiertos*: Configuración del entorno de desarrollo científico (`Anaconda`, entorno virtual `oar_env`, `VS Code` y `Jupyter`). Manipulación vectorial, cálculo matricial y álgebra lineal computacional con **NumPy**.
- *Objetivos de aprendizaje*:

  1. **Configurar** y **gestionar** entornos virtuales reproducibles para computación científica en Python.
  2. **Manipular** vectores, matrices, normas y gradientes numéricos de forma vectorizada y eficiente.

- *Materiales específicos a emplear*:

  - **Cuaderno y scripts de laboratorio**: `laboratorio1_fundamentos_numpy.ipynb` y script auxiliar `verificar_entorno.py`.
  - **Colección de ejercicios**: Bloque 1 de problemas (Ejercicios 1.1 a 1.6: formalización de modelos y cálculo multivariante).
  - **Entorno de software**: Python 3.11, NumPy, Jupyter Notebook.

- *Actividades planificadas*: Configuración guiada del entorno virtual del curso e implementación de rutinas numéricas vectorizadas con NumPy en el laboratorio.
- *Recomendación de trabajo autónomo (3.0 h)*: Finalización de los ejercicios prácticos del cuaderno de laboratorio 1 y resolución individual de los problemas 1.1 a 1.6 de la colección de ejercicios.

4.1.2. SEMANA 2: Optimización No Lineal Sin Restricciones: Condiciones de Optimalidad

Se profundiza en el análisis analítico de funciones diferenciables en varias variables, deduciendo las condiciones necesarias y suficientes de optimalidad y programando el método del descenso de gradiente.

Sesión 2.1: Teoría y Fundamentos Matemáticos (2.0 h presenciales)

- *Contenidos cubiertos*: Caracterización analítica de óptimos locales y globales en $\mathbb{R}^n$. Teorema de Fermat multivariante y condición necesaria de primer orden (puntos estacionarios). Condiciones necesarias y suficientes de segundo orden mediante la matriz Hessiana. Direcciones de descenso y ángulo respecto al vector gradiente.
- *Objetivos de aprendizaje*:

  1. **Calcular** puntos estacionarios de funciones diferenciables multivariantes.
  2. **Clasificar** extremos locales analizando el carácter definido de la matriz Hessiana.

- *Materiales específicos a emplear*:

- **Apuntes teóricos (Parte II)**: Tema 2, "Optimización No Lineal Sin Restricciones", Secciones 2.1 a 2.4.
- **Diapositivas de clase**: Presentación del Tema 2 (Parte I), diapositivas 1 a 35.

- *Actividades planificadas*: Deducción formal de las condiciones de segundo orden a partir del desarrollo de Taylor de orden 2 y discusión geométrica de la ortogonalidad del gradiente a las curvas de nivel.
- *Recomendación de trabajo autónomo (3.0 h)*: Estudio analítico de la demostración del Teorema de segundo orden y resolución manual de puntos críticos en funciones polinómicas y racionales.

Sesión 2.2: Laboratorio Computacional y Resolución Práctica (2.0 h presenciales)

- *Contenidos cubiertos*: Implementación algorítmica modular del método de **Descenso de Gradiente (Gradient Descent)**. Análisis empírico de la velocidad de convergencia, oscilaciones y sensibilidad a la tasa de aprendizaje (*learning rate*) en funciones cuadráticas mal condicionadas.
- *Objetivos de aprendizaje*:

  1. **Programar** el algoritmo de descenso de gradiente modular con criterios de parada por norma del gradiente y número máximo de iteraciones.
  2. **Evaluar** experimentalmente el impacto del número de condición de la matriz Hessiana sobre la trayectoria de convergencia.

- *Materiales específicos a emplear*:

  - **Cuaderno y scripts de laboratorio**: `laboratorio2_descenso_gradiente.ipynb`.
  - **Colección de ejercicios**: Bloque 2 de problemas (Ejercicios 2.1 a 2.5: cálculo de gradientes y clasificación espectral de Hessianos).
  - **Entorno de software**: Python 3.11, NumPy, Matplotlib.

- *Actividades planificadas*: Programación guiada del bucle iterativo de descenso de gradiente y experimentación con distintas tasas de aprendizaje en funciones elípticas.
- *Recomendación de trabajo autónomo (3.0 h)*: Completar el análisis de convergencia en el cuaderno de laboratorio 2 y resolver los problemas 2.1 a 2.5 del Bloque 2.

4.1.3. SEMANA 3: Algoritmos de Descenso y Visualización Avanzada

Esta semana se estudian los métodos de orden superior y las técnicas de búsqueda lineal inexacta, culminando con la visualización tridimensional y el uso de optimizadores de referencia en `scipy.optimize`.

Sesión 3.1: Teoría y Fundamentos Matemáticos (2.0 h presenciales)

- *Contenidos cubiertos*: Métodos de búsqueda lineal unidimensional inexacta (condición de descenso suficiente de Armijo y condiciones de curvatura de Wolfe). El **Método de Newton** en optimización multidimensional, velocidad de convergencia cuadrática local y coste de cálculo e inversión del Hessiano. Introducción a métodos cuasi-Newton (actualización BFGS) y direcciones conjugadas.
- *Objetivos de aprendizaje*:

1. **Comparar** la velocidad de convergencia lineal del gradiente frente a la convergencia cuadrática de Newton.
2. **Aplicar** las condiciones de Armijo y Wolfe para garantizar el descenso monótono y evitar pasos espurios.

- *Materiales específicos a emplear*:
  - **Apuntes teóricos (Parte II)**: Tema 2, "Optimización No Lineal Sin Restricciones", Secciones 2.5 a 2.8.
  - **Diapositivas de clase**: Presentación del Tema 2 (Parte II), diapositivas 36 a 74.
- *Actividades planificadas*: Demostración formal del paso de Newton, análisis de modificaciones para matrices indefinidas (regularización de Levenberg-Marquardt) y derivación de la actualización BFGS.
- *Recomendación de trabajo autónomo (3.0 h)*: Lectura reflexiva sobre métodos cuasi-Newton y deducción manual de un paso de Newton multidimensional.

Sesión 3.2: Laboratorio Computacional y Resolución Práctica (2.0 h presenciales)

- *Contenidos cubiertos*: Visualización avanzada de funciones de coste en dos dimensiones (curvas de nivel) y tres dimensiones (superficies de nivel) con trayectorias de descenso superpuestas en Matplotlib. Uso profesional de optimizadores en `scipy.optimize` (`minimize`).
- *Objetivos de aprendizaje*:
  1. **Generar** representaciones visuales avanzadas en 2D y 3D de paisajes de optimización no lineales.
  2. **Integrar** y **comparar** métodos numéricos (BFGS, CG, Nelder-Mead) resolviendo la función de Rosenbrock con `scipy.optimize`.
- *Materiales específicos a emplear*:
  - **Cuaderno y scripts de laboratorio**: `laboratorio3_newton_scipy.ipynb`.
  - **Colección de ejercicios**: Bloque 2 de problemas (Ejercicios 2.6 a 2.10: iteraciones de Newton y convergencia).
  - **Entorno de software**: Python 3.11, SciPy (`scipy.optimize`), Matplotlib.
- *Actividades planificadas*: Implementación de gráficos interactivos de curvas de nivel con trayectorias de optimizadores y benchmarking empírico de tiempos de cómputo.
- *Recomendación de trabajo autónomo (3.0 h)*: Redacción del informe comparativo de optimizadores en el cuaderno 3 y resolución de los ejercicios 2.6 a 2.10 del Bloque 2.

4.1.4. SEMANA 4: Análisis Convexo I: Conjuntos Convexos

Se introduce la geometría convexa como base matemática fundamental de la optimización moderna, estudiando la estructura de conjuntos, conos y los teoremas de separación.

Sesión 4.1: Teoría y Fundamentos Matemáticos (2.0 h presenciales)

- *Contenidos cubiertos*: Definición geométrica y algebraica de conjunto convexo. Combinaciones convexas y envoltura convexa (*convex hull*). Conos convexos y cono dual. Familias canónicas de conjuntos convexos (hiperplanos, semiespacios, poliedros, bolas euclídeas y elipsoides). Teoremas fundamentales del Hiperplano Separador y de Soporte. Operaciones que preservan convexidad.
- *Objetivos de aprendizaje*:
    1. **Demostrar** rigurosamente la convexidad de conjuntos matemáticos parametrizados.
    2. **Aplicar** los teoremas de separación para verificar analíticamente la disyunción entre regiones convexas.
- *Materiales específicos a emplear*:
    - **Apuntes teóricos (Parte II)**: Tema 3, "Análisis Convexo", Secciones 3.1 a 3.4.
    - **Diapositivas de clase**: Presentación del Tema 3 (Parte I), diapositivas 1 a 36.
- *Actividades planificadas*: Demostración analítica del Lema de Proyección sobre conjuntos convexos cerrados y deducción del Teorema del Hiperplano Separador estricto.
- *Recomendación de trabajo autónomo (3.0 h)*: Estudio detallado de las demostraciones de separación y caracterización analítica de conos duales de conjuntos poliédricos.

Sesión 4.2: Laboratorio Computacional y Resolución Práctica (2.0 h presenciales)

- *Contenidos cubiertos*: Representación y verificación computacional de poliedros definidos por intersección de semiespacios lineales. Cálculo de envolturas convexas en dos y tres dimensiones utilizando `scipy.spatial`.
- *Objetivos de aprendizaje*:
    1. **Calcular** y **visualizar** envolturas convexas a partir de nubes de puntos sintéticas y reales en Python.
    2. **Comprobar** la acotación y factibilidad geométrica de poliedros mediante álgebra lineal computacional.
- *Materiales específicos a emplear*:
    - **Cuaderno y scripts de laboratorio**: `laboratorio4_conjuntos_convexos.ipynb`.
    - **Colección de ejercicios**: Bloque 3 de problemas (Ejercicios 3.1 a 3.6: demostraciones de conjuntos convexos y separación).
    - **Entorno de software**: Python 3.11, SciPy (`scipy.spatial`), NumPy, Matplotlib.
- *Actividades planificadas*: Cálculo práctico de envolturas convexas tridimensionales con visualización interactiva y comprobación de pertenencia de puntos a poliedros.
- *Recomendación de trabajo autónomo (3.0 h)*: Finalización de los ejercicios del cuaderno 4 y resolución completa de los problemas 3.1 a 3.6 de la colección de ejercicios.

4.1.5. SEMANA 5: Análisis Convexo II: Funciones Convexas

Se abordan las funciones convexas, sus caracterizaciones diferenciales y el resultado central que garantiza la coincidencia entre óptimos locales y globales.

Sesión 5.1: Teoría y Fundamentos Matemáticos (2.0 h presenciales)

- *Contenidos cubiertos*: Definición formal de función convexa, estrictamente convexa y fuertemente convexa. Caracterización por epígrafe (*epigraph*) y conjuntos de subnivel. Condiciones diferenciales de primer orden (subgradientes y plano tangente inferior). Condiciones de segundo orden: semidefinición positiva de la matriz Hessiana ($\nabla^2 f(x) \succeq 0$). Teorema fundamental de equivalencia entre mínimos locales y globales. Desigualdad de Jensen.
- *Objetivos de aprendizaje*:

  1. **Caracterizar** la convexidad de funciones escalares y multivariantes mediante criterios diferenciales de primer y segundo orden.
  2. **Demostrar** que en un problema de optimización convexa todo mínimo local es automáticamente mínimo global.

- *Materiales específicos a emplear*:

  - **Apuntes teóricos (Parte II)**: Tema 3, "Análisis Convexo", Secciones 3.5 a 3.8.
  - **Diapositivas de clase**: Presentación del Tema 3 (Parte II), diapositivas 37 a 70.

- *Actividades planificadas*: Demostración rigurosa del teorema de equivalencia entre óptimos locales y globales, análisis de operaciones que preservan convexidad de funciones y prueba de la desigualdad de Jensen.
- *Recomendación de trabajo autónomo (3.0 h)*: Asimilación de las reglas de composición convexa (composición atomística) y cálculo analítico de subgradientes en funciones no diferenciables.

Sesión 5.2: Laboratorio Computacional y Resolución Práctica (2.0 h presenciales)

- *Contenidos cubiertos*: Verificación numérica continua de convexidad mediante análisis espectral de autovalores del Hessiano. Verificación computacional y empírica de la desigualdad de Jensen en distribuciones muestrales.
- *Objetivos de aprendizaje*:

  1. **Implementar** rutinas computacionales en Python para evaluar la semidefinición positiva de matrices hessianas sobre dominios continuos.
  2. **Simular** empíricamente el cumplimiento de la desigualdad de Jensen y trazar epígrafes de funciones convexas.

- *Materiales específicos a emplear*:

  - **Cuaderno y scripts de laboratorio**: `laboratorio5_funciones_convexas.ipynb`.
  - **Colección de ejercicios**: Bloque 3 de problemas (Ejercicios 3.7 a 3.12: funciones convexas, Hessianos y desigualdades).
  - **Entorno de software**: Python 3.11, NumPy, SciPy, Matplotlib.

- *Actividades planificadas*: Programación de pruebas espectrales de matrices y trazado de curvas de subnivel de funciones cuadráticas y racionales.
- *Recomendación de trabajo autónomo (3.0 h)*: Completar las conclusiones del cuaderno de laboratorio 5 y resolver los ejercicios 3.7 a 3.12 de la colección de problemas.

4.1.6. SEMANA 6: Optimización con Restricciones y Condiciones KKT

Se estudia la teoría de la optimización con restricciones no lineales de igualdad y desigualdad, deduciendo las condiciones de Karush-Kuhn-Tucker (KKT).

Sesión 6.1: Teoría y Fundamentos Matemáticos (2.0 h presenciales)

- *Contenidos cubiertos*: Formulación estándar de problemas con restricciones de igualdad y desigualdad. Geometría de las restricciones y conos de direcciones factibles y de descenso. Cualificación de restricciones: condición de independencia lineal de gradientes (LICQ) y condición de Mangasarian-Fromovitz (MFCQ). Teorema de las **condiciones de Karush-Kuhn-Tucker (KKT)**: primal factibilidad, dual factibilidad, holgura complementaria y estacionariedad. Suficiencia de KKT bajo convexidad.
- *Objetivos de aprendizaje*:

  1. **Formular** y **resolver** analíticamente el sistema algebraico de condiciones KKT.
  2. **Verificar** la cualificación de restricciones en puntos frontera comprobando la condición LICQ.

- *Materiales específicos a emplear*:

  - **Apuntes teóricos (Parte II)**: Tema 4, "Optimización con Restricciones y Dualidad", Secciones 4.1 a 4.4.
  - **Diapositivas de clase**: Presentación del Tema 4 (Parte I), diapositivas 1 a 38.

- *Actividades planificadas*: Deducción formal de las condiciones KKT mediante conos polares y el Lema de Farkas, con análisis geométrico de restricciones activas e inactivas.
- *Recomendación de trabajo autónomo (3.0 h)*: Estudio analítico de la demostración de suficiencia de KKT bajo hipótesis de convexidad y resolución manual de sistemas KKT con restricciones cuadráticas.

Sesión 6.2: Laboratorio Computacional y Resolución Práctica (2.0 h presenciales)

- *Contenidos cubiertos*: Resolución analítica asistida por ordenador de sistemas KKT no lineales con cálculo simbólico (`sympy`) y numérico. Visualización gráfica en 2D de conos de gradientes de restricciones activas y vectores de multiplicadores de Lagrange.
- *Objetivos de aprendizaje*:

  1. **Resolver** sistemas algebraicos no lineales de KKT mediante herramientas de cálculo computacional.
  2. **Interpretar** geométricamente el papel de los multiplicadores de Lagrange ortogonales a la frontera activa.

- *Materiales específicos a emplear*:

  - **Cuaderno y scripts de laboratorio**: `laboratorio6_condiciones_kkt.ipynb`.
  - **Colección de ejercicios**: Bloque 4 de problemas (Ejercicios 4.1 a 4.6: resolución detallada de sistemas KKT).
  - **Entorno de software**: Python 3.11, SymPy (cálculo simbólico), NumPy, Matplotlib.

- *Actividades planificadas*: Resolución de problemas cuadráticos con restricciones lineales en SymPy y trazado 2D de las curvas de nivel junto con las direcciones de las restricciones activas.

- *Recomendación de trabajo autónomo (3.0 h)*: Finalización de los ejercicios del cuaderno 6 y realización de los problemas 4.1 a 4.6 del Bloque 4.

4.1.7. SEMANA 7: Dualidad Lagrangiana y Teoremas de Dualidad

Se introduce el marco de la dualidad lagrangiana, el salto de dualidad, las condiciones de Slater y el análisis de sensibilidad mediante precios sombra.

Sesión 7.1: Teoría y Fundamentos Matemáticos (2.0 h presenciales)

- *Contenidos cubiertos*: Construcción formal de la función Lagrangiana y de la función dual de Lagrange $g(\lambda, \mu)$. Concavidad intrínseca de la función dual. Formulación del problema Dual de Lagrange. Propiedad de **Dualidad Débil** y salto de dualidad (*duality gap*). Teoremas de **Dualidad Fuerte** y condición de cualificación de Slater para problemas convexos. Interpretación económica y análisis de sensibilidad de los multiplicadores duales (precios sombra).
- *Objetivos de aprendizaje*:
  1. **Derivar** analíticamente la función dual de Lagrange asociada a un problema primal dado.
  2. **Evaluar** la existencia de dualidad fuerte mediante la verificación de la condición de Slater.
- *Materiales específicos a emplear*:
  - **Apuntes teóricos (Parte II)**: Tema 4, "Optimización con Restricciones y Dualidad", Secciones 4.5 a 4.8.
  - **Diapositivas de clase**: Presentación del Tema 4 (Parte II), diapositivas 39 a 72.
- *Actividades planificadas*: Demostración formal del teorema de dualidad débil y deducción geométrica del salto dual mediante conjuntos epígrafes de perturbación.
- *Recomendación de trabajo autónomo (3.0 h)*: Asimilación del concepto de precio sombra como derivada direccional del valor óptimo respecto al término independiente de las restricciones.

Sesión 7.2: Laboratorio Computacional y Resolución Práctica (2.0 h presenciales)

- *Contenidos cubiertos*: Construcción numérica y trazado computacional de la función dual de Lagrange en problemas cuadráticos. Verificación empírica de la dualidad fuerte y convergencia primal-dual.
- *Objetivos de aprendizaje*:
  1. **Trazar** numéricamente funciones duales cóncavas a partir de la minimización del lagrangiano.
  2. **Verificar** computacionalmente la convergencia de los valores óptimos primal y dual en problemas convexos.
- *Materiales específicos a emplear*:
  - **Cuaderno y scripts de laboratorio**: `laboratorio7_dualidad_lagrangiana.ipynb`.
  - **Colección de ejercicios**: Bloque 4 de problemas (Ejercicios 4.7 a 4.12: funciones duales y análisis de sensibilidad).
  - **Entorno de software**: Python 3.11, NumPy, SciPy, Matplotlib.

- *Actividades planificadas*: Experimentación con perturbaciones de las restricciones para validar numéricamente la relación entre multiplicadores duales y tasas de variación del óptimo.
- *Recomendación de trabajo autónomo (3.0 h)*: Completar el cuaderno de laboratorio 7 y resolver los problemas 4.7 a 4.12 de la colección de ejercicios.

4.1.8. SEMANA 8: Programación Convexa Disciplinada y CVXPY

Se estudia el modelado computacional formal de la optimización convexa, presentando la jerarquía de problemas canónicos y la librería declarativa CVXPY.

Sesión 8.1: Teoría y Fundamentos Matemáticos (2.0 h presenciales)

- *Contenidos cubiertos*: Jerarquía estructural de problemas convexos (Programación Lineal LP, Programación Cuadrática QP, Programación Cuadrática con Restricciones Cuadráticas QCQP y Conos de Segundo Orden SOCP). Principios formales de la **Programación Convexa Disciplinada (DCP)**: reglas de composición atomística, monotonicidad y análisis de curvatura.
- *Objetivos de aprendizaje*:

  1. **Clasificar** problemas convexos dentro de la jerarquía canónica de programación matemática.
  2. **Modelar** problemas respetando estrictamente el conjunto de reglas de la programación convexa disciplinada.

- *Materiales específicos a emplear*:

  - **Apuntes teóricos (Parte II)**: Tema 4, "Optimización con Restricciones y Dualidad", Secciones 4.9 a 4.12.
  - **Diapositivas de clase**: Presentación del Tema 4 (Parte III), diapositivas 73 a 106.

- *Actividades planificadas*: Exposición sobre grafos de computación en DCP, transformaciones epígrafes y conversión a formas cónicas estándar para solvers interiores.
- *Recomendación de trabajo autónomo (3.0 h)*: Consulta de la documentación oficial de CVXPY y análisis de las reglas de composición de funciones convexas no decrecientes.

Sesión 8.2: Laboratorio Computacional y Resolución Práctica (2.0 h presenciales)

- *Contenidos cubiertos*: Introducción a la librería **CVXPY**. Declaración formal de variables, parámetros, restricciones y funciones objetivo. Resolución de problemas LP y QP, inspección de estados de convergencia del solver y recuperación de soluciones primales y multiplicadores duales.
- *Objetivos de aprendizaje*:

  1. **Traducir** modelos matemáticos declarativos a código ejecutable en CVXPY respetando las reglas DCP.
  2. **Interpretar** y **recuperar** certificados de optimalidad y valores de variables duales devueltos por el optimizador.

- *Materiales específicos a emplear*:

  - **Cuaderno y scripts de laboratorio**: `laboratorio8_cvxpy_dcp.ipynb`.

- **Colección de ejercicios**: Bloque 4 de problemas (Ejercicios 4.13 a 4.18: formulación matricial canónica de LP, QP y SOCP).
- **Entorno de software**: Python 3.11, CVXPY (solvers ECOS, OSQP, Clarabel).

- *Actividades planificadas*: Taller interactivo de formulación en CVXPY resolviendo problemas de optimización de carteras de inversión de Markowitz con restricciones de varianza.
- *Recomendación de trabajo autónomo (3.0 h)*: Finalización de los ejercicios del cuaderno 8 y realización de los problemas 4.13 a 4.18 del Bloque 4.

4.1.9. SEMANA 9: Aplicaciones a Ciencia de Datos I: Regresión y SVM Lineal

Se conectan los fundamentos de la optimización convexa con el aprendizaje automático, estudiando la regresión regularizada y las máquinas de vectores de soporte de margen duro.

Sesión 9.1: Teoría y Fundamentos Matemáticos (2.0 h presenciales)

- *Contenidos cubiertos*: Formulación matricial de la regresión lineal por mínimos cuadrados ordinarios (OLS). Regularización y selección de variables: regresión Ridge (L_2) y regresión Lasso (L_1). Fundamentos del aprendizaje estadístico supervisado: clasificación binaria e hiperplanos separadores. **Máquinas de Vectores de Soporte (SVM)**: formulación matemática de margen máximo para datos linealmente separables (margen duro).
- *Objetivos de aprendizaje*:

  1. **Formular** problemas canónicos de regresión y clasificación como optimización convexa cuadrática.
  2. **Diferenciar** el efecto de la regularización L_1 inductora de dispersión frente a la regularización L_2 de contracción suave.

- *Materiales específicos a emplear*:

  - **Apuntes teóricos (Parte II)**: Tema 5, "Aplicaciones a Ciencia de Datos y Aprendizaje Automático", Secciones 5.1 a 5.4.
  - **Diapositivas de clase**: Presentación del Tema 5 (Parte I), diapositivas 1 a 40.

- *Actividades planificadas*: Deducción matemática de la relación entre el ancho geométrico del margen ($2/\|w\|$) y el problema cuadrático primal de SVM en pizarra.
- *Recomendación de trabajo autónomo (3.0 h)*: Estudio analítico de la deducción de la solución cerrada de Ridge y de la no diferenciabilidad en el origen de la regularización Lasso.

Sesión 9.2: Laboratorio Computacional y Resolución Práctica (2.0 h presenciales)

- *Contenidos cubiertos*: Implementación y comparación de modelos de regresión OLS, Ridge y Lasso en CVXPY. Formulación y resolución del clasificador SVM lineal de margen duro en CVXPY. Visualización gráfica del hiperplano de separación, márgenes y vectores de soporte.
- *Objetivos de aprendizaje*:

  1. **Programar** modelos de regresión regularizada y clasificación lineal de margen duro en CVXPY.

2. **Identificar** gráfica y numéricamente los vectores de soporte críticos que definen la frontera de decisión.

- *Materiales específicos a emplear*:
  - **Cuaderno y scripts de laboratorio**: `laboratorio9_regresion_svm_duro.ipynb`.
  - **Colección de ejercicios**: Bloque 5 de problemas (Ejercicios 5.1 a 5.5: formulaciones de regularización y margen máximo).
  - **Entorno de software**: Python 3.11, CVXPY, NumPy, Matplotlib, Scikit-Learn (generación de datasets sintéticos).
- *Actividades planificadas*: Práctica de clasificación sobre conjuntos de datos sintéticos y trazado 2D de hiperplanos de margen máximo en Matplotlib.
- *Recomendación de trabajo autónomo (3.0 h)*: Completar el análisis de regularización en el cuaderno 9 y resolver los ejercicios 5.1 a 5.5 del Bloque 5.

4.1.10. SEMANA 10: Aplicaciones a Ciencia de Datos II: SVM Generalizada, Dualidad y Kernels

Se concluye el Bloque I con el clasificador SVM de margen blando, su formulación dual y la extensión a fronteras no lineales mediante el truco del Kernel.

Sesión 10.1: Teoría y Fundamentos Matemáticos (2.0 h presenciales)

- *Contenidos cubiertos*: Clasificación con solapamiento: formulación de margen blando mediante variables de holgura ξ_i. Hiperparámetro de penalización C y compromiso sesgo-varianza. Formulación dual de SVM con multiplicadores de Lagrange α_i en una caja $[0, C]$. El **truco del Kernel (Kernel Trick)**: funciones de base radial (RBF) y núcleos polinomiales en espacios de Hilbert de dimensión infinita. Teorema de Mercer.
- *Objetivos de aprendizaje*:
  1. **Derivar** rigurosamente el problema dual de las Máquinas de Vectores de Soporte a partir de las condiciones KKT del problema primal con holguras.
  2. **Aplicar** transformaciones por núcleos para resolver problemas de clasificación no linealmente separables.
- *Materiales específicos a emplear*:
  - **Apuntes teóricos (Parte II)**: Tema 5, "Aplicaciones a Ciencia de Datos y Aprendizaje Automático", Secciones 5.5 a 5.8.
  - **Diapositivas de clase**: Presentación del Tema 5 (Parte II), diapositivas 41 a 82.
- *Actividades planificadas*: Demostración de las condiciones de holgura complementaria en el dual de SVM y cálculo explícito de matrices de Gram para kernels RBF.
- *Recomendación de trabajo autónomo (3.0 h)*: Estudio reflexivo sobre la clasificación de puntos (interiores, de margen y violaciones) a partir del valor de sus multiplicadores duales α_i.

Sesión 10.2: Laboratorio Computacional y Resolución Práctica (2.0 h presenciales)

- *Contenidos cubiertos*: Resolución del problema dual de SVM no lineal en CVXPY. Benchmarking comparativo de precisión y tiempo de ejecución frente a `scikit-learn` (`sklearn.svm.SVC`). Validación cruzada y ajuste de hiperparámetros (C, γ).
- *Objetivos de aprendizaje*:

  1. **Implementar** el clasificador dual de SVM con kernels en CVXPY.
  2. **Contrastar** la formulación matemática directa en CVXPY con librerías optimizadas de producción en ciencia de datos.

- *Materiales específicos a emplear*:

  - **Cuaderno y scripts de laboratorio**: `laboratorio10_svm_dual_kernels.ipynb`.
  - **Colección de ejercicios**: Bloque 5 de problemas (Ejercicios 5.6 a 5.10: deducción del dual de SVM y matrices de Gram).
  - **Entorno de software**: Python 3.11, CVXPY, Scikit-Learn, Matplotlib.

- *Actividades planificadas*: Taller de ajuste de hiperparámetros sobre conjuntos de datos no separables con fronteras circulares y espirales.
- *Recomendación de trabajo autónomo (3.0 h)*: Entrega del cuaderno 10, resolución de los problemas 5.6 a 5.10 del Bloque 5 y repaso integral de los temas 1 a 5 para el Examen Parcial 1.

4.2. BLOQUE II: Optimización y Análisis de Redes (Semanas 11 a 15)

4.2.1. SEMANA 11: Teoría de Grafos, Estructuras y Árboles Soporte

Se inicia el Bloque II adentrándose en la teoría de redes y grafos, sus representaciones matriciales y los árboles soporte de mínimo peso.

Sesión 11.1: Teoría y Fundamentos Matemáticos (2.0 h presenciales)

- *Contenidos cubiertos*: Elementos formales de teoría de grafos: grafos no dirigidos $\{u, v\}$, digrafos ordenados (u, v), multigrafos y grafos bipartitos. Representaciones algebraicas: matriz de adyacencia, matriz de incidencia y matriz Laplaciana. Conectividad: caminos, componentes conexas, conjuntos de corte y árboles. **Árboles Soporte de Mínimo Peso (MST)**: algoritmo voraz de Kruskal y algoritmo de Prim. Demostración de corrección mediante la propiedad fundamental del corte.
- *Objetivos de aprendizaje*:

  1. **Representar** formalmente redes y topologías complejas mediante matrices algebraicas (adyacencia, incidencia y Laplaciana).
  2. **Calcular** el árbol generador de coste mínimo aplicando con rigor los algoritmos de Kruskal y Prim.

- *Materiales específicos a emplear*:

  - **Apuntes teóricos (Parte II)**: Tema 6, "Introducción a la Teoría de Redes y Grafos", Secciones 6.1 a 6.5.

- **Diapositivas de clase**: Presentación del Tema 6, diapositivas 1 a 55.

- *Actividades planificadas*: Demostración analítica de la propiedad del corte para árboles generadores y análisis del espectro de la matriz Laplaciana en la conectividad algebraica.
- *Recomendación de trabajo autónomo (3.0 h)*: Estudio analítico de la prueba de corrección de Kruskal y deducción de la complejidad con estructuras Union-Find.

Sesión 11.2: Laboratorio Computacional y Resolución Práctica (2.0 h presenciales)

- *Contenidos cubiertos*: Modelado, construcción y manipulación de topologías de red con **NetworkX**. Cálculo de métricas estructurales (distribución de grados, coeficientes de agrupamiento, densidades y componentes conexas). Implementación y comparación de algoritmos MST sobre grafos sintéticos y redes geográficas reales.
- *Objetivos de aprendizaje*:

  1. **Utilizar** la librería NetworkX para la manipulación y análisis cuantitativo de redes complejas en Python.
  2. **Calcular** y **visualizar** árboles generadores de coste mínimo sobre redes de infraestructura real.

- *Materiales específicos a emplear*:

  - **Cuaderno y scripts de laboratorio**: `laboratorio11_grafos_networkx_mst.ipynb`.
  - **Colección de ejercicios**: Bloque 6 de problemas (Ejercicios 6.1 a 6.8: propiedades de árboles y cálculo manual de MST).
  - **Entorno de software**: Python 3.11, NetworkX, Matplotlib.

- *Actividades planificadas*: Construcción interactiva de grafos aleatorios y redes de transporte en NetworkX y trazado visual del árbol soporte mínimo superpuesto.
- *Recomendación de trabajo autónomo (3.0 h)*: Finalización del cuaderno 11 y resolución de los ejercicios 6.1 a 6.8 de la colección de problemas.

4.2.2. SEMANA 12: Algoritmos de Caminos Mínimos

Se abordan los algoritmos clásicos y eficientes de caminos mínimos en grafos valorados y sus aplicaciones a problemas de enrutamiento y finanzas.

Sesión 12.1: Teoría y Fundamentos Matemáticos (2.0 h presenciales)

- *Contenidos cubiertos*: El Problema del Camino Mínimo (*Shortest Path Problem*) y principio de subestructura óptima de Bellman. **Algoritmo de Dijkstra** para redes con pesos no negativos e implementación con montículos binarios. **Algoritmo de Bellman-Ford**: tratamiento de pesos negativos y detección de ciclos absorbentes de coste negativo. **Algoritmo de Floyd-Warshall**: caminos mínimos entre todos los pares de vértices mediante programación dinámica. Caminos en digrafos acíclicos dirigidos (DAGs) y ordenación topológica.
- *Objetivos de aprendizaje*:

  1. **Seleccionar** y **aplicar** el algoritmo de caminos mínimos óptimo en función de la topología de la red y del signo de los costes.

2. **Modelar** problemas no espaciales (arbitraje financiero, planificación temporal) como búsquedas de caminos mínimos.

- *Materiales específicos a emplear*:
  - **Apuntes teóricos (Parte II)**: Tema 7, "Caminos Mínimos en Redes", Secciones 7.1 a 7.6.
  - **Diapositivas de clase**: Presentación del Tema 7, diapositivas 1 a 48.
- *Actividades planificadas*: Deducción formal de las ecuaciones de Bellman y demostración analítica de la corrección de los algoritmos de Dijkstra y Floyd-Warshall.
- *Recomendación de trabajo autónomo (3.0 h)*: Estudio reflexivo sobre la detección de ciclos de coste negativo y análisis de complejidad temporal y espacial en grafos densos y dispersos.

Sesión 12.2: Laboratorio Computacional y Resolución Práctica (2.0 h presenciales)

- *Contenidos cubiertos*: Implementación y análisis comparativo de eficiencia entre Dijkstra y Bellman-Ford en NetworkX. Detección de oportunidades de arbitraje en mercados financieros modeladas como ciclos de coste negativo sobre grafos dirigidos de tipos de cambio. Visualización de rutas geodésicas sobre redes viarias.
- *Objetivos de aprendizaje*:
  1. **Programar** detectores de ciclos negativos aplicando transformaciones logarítmicas de tipos de cambio en Python.
  2. **Trazar** visualmente caminos geodésicos sobre grafos dirigidos y mapas reales con NetworkX.
- *Materiales específicos a emplear*:
  - **Cuaderno y scripts de laboratorio**: `laboratorio12_caminos_minimos.ipynb`.
  - **Colección de ejercicios**: Bloque 7 de problemas (Ejercicios 7.1 a 7.8: trazado paso a paso de Dijkstra, Bellman-Ford y Floyd-Warshall).
  - **Entorno de software**: Python 3.11, NetworkX, Matplotlib.
- *Actividades planificadas*: Implementación de la rutina de arbitraje financiero en divisas y cálculo computacional de matrices de distancias de todos los pares.
- *Recomendación de trabajo autónomo (3.0 h)*: Completar el análisis de arbitraje en el cuaderno 12 y resolver los ejercicios 7.1 a 7.8 del Bloque 7.

4.2.3. SEMANA 13: Problemas de Flujo en Redes

Se analizan los modelos de redes capacitadas, el teorema fundamental de corte mínimo y los flujos a coste mínimo.

Sesión 13.1: Teoría y Fundamentos Matemáticos (2.0 h presenciales)

- *Contenidos cubiertos*: Redes de transporte con capacidades: leyes de conservación de flujo de Kirchhoff y redes residuales. **Problema del Flujo Máximo**: algoritmos de caminos de aumento (Ford-Fulkerson y Edmonds-Karp). Cortes en redes y capacidad de un corte.

Teorema del Flujo Máximo - Corte Mínimo (Max-Flow Min-Cut). **Problema del Flujo a Coste Mínimo (Min-Cost Flow)** y formulación de programación lineal. Teorema de integridad de flujos y matriz de incidencia totalmente unimodular.

- *Objetivos de aprendizaje*:

  1. **Calcular** la capacidad máxima de transporte de una red determinando el corte mínimo saturado que actúa como cuello de botella.
  2. **Demostrar** la total unimodularidad de la matriz de incidencia de digrafos y la integridad inherente de las soluciones.

- *Materiales específicos a emplear*:

  - **Apuntes teóricos (Parte II)**: Tema 8, "Flujos en Redes", Secciones 8.1 a 8.6.
  - **Diapositivas de clase**: Presentación del Tema 8, diapositivas 1 a 45.

- *Actividades planificadas*: Demostración rigurosa del Teorema Max-Flow Min-Cut y desarrollo en pizarra del etiquetado de vértices y actualización de redes residuales.
- *Recomendación de trabajo autónomo (3.0 h)*: Asimilación de la prueba de convergencia polinomial $O(VE^2)$ de Edmonds-Karp y formulación algebraica de modelos de transbordo.

Sesión 13.2: Laboratorio Computacional y Resolución Práctica (2.0 h presenciales)

- *Contenidos cubiertos*: Resolución de problemas de flujo máximo y corte mínimo con solvers de NetworkX (`maximum_flow`, `minimum_cut`). Modelado de redes de abastecimiento y distribución logística con capacidades y costes lineales en CVXPY y NetworkX.
- *Objetivos de aprendizaje*:

  1. **Formular** y **resolver** problemas de flujo a coste mínimo y transporte multiescalón mediante optimización lineal en CVXPY.
  2. **Visualizar** redes residuales, arcos saturados y cuellos de botella en NetworkX.

- *Materiales específicos a emplear*:

  - **Cuaderno y scripts de laboratorio**: `laboratorio13_flujos_redes.ipynb`.
  - **Colección de ejercicios**: Bloque 8 de problemas (Ejercicios 8.1 a 8.8: resolución tabular de Ford-Fulkerson y formulación de transbordos).
  - **Entorno de software**: Python 3.11, NetworkX, CVXPY.

- *Actividades planificadas*: Simulación interactiva de cuellos de botella en redes de suministro logístico y contraste de soluciones entre NetworkX y CVXPY.
- *Recomendación de trabajo autónomo (3.0 h)*: Entrega de los ejercicios del cuaderno 13 y resolución de los problemas 8.1 a 8.8 de la colección de problemas.

4.2.4. SEMANA 14: Problemas de Emparejamiento (Matching) y Asignación

Se estudia la teoría combinatoria de emparejamientos en grafos bipartitos y generales, desde el Algoritmo Húngaro hasta las flores de Edmonds.

Sesión 14.1: Teoría y Fundamentos Matemáticos (2.0 h presenciales)

- *Contenidos cubiertos*: Emparejamientos en grafos: emparejamiento maximal, máximo y perfecto. Emparejamiento en grafos bipartitos: Teorema del Matrimonio de Hall y Teorema de Kőnig. El **Algoritmo Húngaro** (Kuhn-Munkres) para el problema clásico de asignación de tareas con costes. Emparejamiento en grafos generales no bipartitos: **Algoritmo de las Flores de Edmonds** (*Blossom Algorithm*) y contracción de ciclos impares. Teorema de estructura y descomposición de Gallai-Edmonds.
- *Objetivos de aprendizaje*:

  1. **Formular** problemas de asignación de recursos, turnos y personal como emparejamientos óptimos en grafos bipartitos y generales.
  2. **Comprender** el mecanismo de contracción de flores (*blossoms*) para resolver emparejamientos en grafos generales en tiempo polinomial.

- *Materiales específicos a emplear*:

  - **Apuntes teóricos (Parte II)**: Tema 9, "Emparejamientos y Asignación en Grafos", Secciones 9.1 a 9.6.
  - **Diapositivas de clase**: Presentación del Tema 9, diapositivas 1 a 42.

- *Actividades planificadas*: Deducción del teorema de Kőnig a partir de flujos en redes, interpretación dual del Algoritmo Húngaro como potenciales de nodo y análisis de caminos alternantes.
- *Recomendación de trabajo autónomo (3.0 h)*: Estudio de la demostración del Teorema de Hall y análisis del papel de los ciclos alternantes impares en grafos no bipartitos.

Sesión 14.2: Laboratorio Computacional y Resolución Práctica (2.0 h presenciales)

- *Contenidos cubiertos*: Resolución de problemas de emparejamiento bipartito y asignación ponderada en NetworkX y `scipy.optimize.linear_sum_assignment`. Implementación y experimentación del algoritmo de Edmonds para matching máximo general sobre grafos arbitrarios.
- *Objetivos de aprendizaje*:

  1. **Resolver** computacionalmente problemas de emparejamiento óptimo ponderado y cardinal con librerías científicas en Python.
  2. **Aplicar** modelos de matching a casos reales (asignación de residentes médicos y programas de donación cruzada de órganos).

- *Materiales específicos a emplear*:

  - **Cuaderno y scripts de laboratorio**: `laboratorio14_matching_asignacion.ipynb`.
  - **Colección de ejercicios**: Bloque 9 de problemas (Ejercicios 9.1 a 9.7: cálculo manual del algoritmo Húngaro y contracción de flores).
  - **Entorno de software**: Python 3.11, NetworkX, SciPy (`scipy.optimize`), Matplotlib.

- *Actividades planificadas*: Implementación de la asignación óptima de tareas y visualización gráfica de flores contraídas y caminos aumentantes en NetworkX.
- *Recomendación de trabajo autónomo (3.0 h)*: Finalización del cuaderno 14 y resolución de los problemas 9.1 a 9.7 del Bloque 9.

4.2.5. SEMANA 15: Rutas en Redes, TSP, VRP y Síntesis Final

Se cierra el curso con los problemas clásicos de diseño de rutas en redes, abordando la frontera entre problemas polinomiales y NP-duros.

Sesión 15.1: Teoría y Fundamentos Matemáticos (2.0 h presenciales)

- *Contenidos cubiertos*: Recorridos eulerianos: Teorema de Euler-Hierholzer y **Problema del Cartero Chino (CPP)** resuelto mediante eulerización por matching de mínimo peso. Ciclos hamiltonianos: complejidad $\mathcal{NP}$-completa, condiciones necesarias (2-conexidad) y condiciones suficientes (teoremas de Dirac y Ore, clausura de Bondy-Chvátal). **Problema del Viajante de Comercio (TSP)**: formulaciones de programación lineal entera (etapas x_{ijk}, eliminación de subtours DFJ y formulación compacta MTZ). Heurísticas de búsqueda local (2-Opt) y **Algoritmo de aproximación de Christofides** con factor 1.5 en grafos métricos. Introducción a los **Problemas de Rutas de Vehículos (VRP)**.
- *Objetivos de aprendizaje*:

  1. **Diferenciar** con precisión la frontera de complejidad computacional entre problemas eulerianos (polinomiales) y hamiltonianos ($\mathcal{NP}$-duros).
  2. **Formular** modelos de programación lineal entera para diseño de rutas óptimas seleccionando la técnica adecuada de eliminación de subtours.
  3. **Demostrar** la cota de aproximación 3/2 del algoritmo de Christofides sobre grafos métricos.

- *Materiales específicos a emplear*:

  - **Apuntes teóricos (Parte II)**: Tema 10, "Rutas en Redes: Recorridos Eulerianos, Hamiltonianos y Rutas de Vehículos", Secciones 10.1 a 10.7.
  - **Diapositivas de clase**: Presentación del Tema 10, diapositivas 1 a 52.

- *Actividades planificadas*: Demostración analítica de la cota de Christofides combinando árboles soporte mínimos y matchings perfectos, y análisis de la formulación entera MTZ en pizarra.
- *Recomendación de trabajo autónomo (3.0 h)*: Estudio de la formulación compacta MTZ y repaso comparativo general de todas las estructuras y algoritmos estudiados a lo largo del curso.

Sesión 15.2: Laboratorio Computacional y Resolución Práctica (2.0 h presenciales)

- *Contenidos cubiertos*: Implementación del algoritmo del Cartero Chino con NetworkX. Programación de la formulación compacta MTZ en CVXPY y resolución con solvers de programación entera mixta (MIP). Implementación de la heurística de mejora 2-Opt y del algoritmo de aproximación de Christofides.
- *Objetivos de aprendizaje*:

  1. **Implementar** modelos de programación entera mixta y heurísticas con garantías formales para problemas de transporte a gran escala en Python.
  2. **Resolver** instancias de rutas de recogida de residuos urbanos y distribución logística comparando tiempos y calidad de soluciones.

- *Materiales específicos a emplear*:

  - **Cuaderno y scripts de laboratorio**: `laboratorio15_rutas_tsp_vrp.ipynb`.

- **Colección de ejercicios**: Bloque 10 de problemas (Ejercicios 10.1 a 10.8: eulerización, formulaciones MTZ y algoritmo de Christofides).
- **Entorno de software**: Python 3.11, NetworkX, CVXPY (solvers MIP como GLPK/CBC o SCIP), Matplotlib.

- *Actividades planificadas*: Taller de síntesis computacional resolviendo problemas de rutas en grafos geográficos reales y benchmarking entre solvers exactos y heurísticas 2-Opt.
- *Recomendación de trabajo autónomo (3.0 h)*: Entrega del cuaderno 15, resolución de los problemas 10.1 a 10.8 del Bloque 10 y preparación integral para el Examen Parcial 2.

---

5 Sistema de evaluación y criterios de calificación

El sistema de evaluación está diseñado para valorar de forma continua tanto la solidez teórica y el rigor formal como la competencia computacional en la resolución de problemas prácticos:

5.1. Convocatoria Ordinaria (Evaluación Continua)

La calificación final de la convocatoria ordinaria se obtiene a partir de tres componentes ponderados:

1. **Examen Parcial 1 (Bloque I - Optimización Matemática y Ciencia de Datos)**: **35 % de la nota final**.
    - Prueba escrita individual compuesta por cuestiones teórico-deductivas (demostraciones de convexidad, KKT, dualidad) y resolución analítica de problemas numéricos.
2. **Examen Parcial 2 (Bloque II - Optimización y Análisis de Redes)**: **35 % de la nota final**.
    - Prueba escrita individual compuesta por análisis de algoritmos sobre redes (Dijkstra, Ford-Fulkerson, matching, eulerización, formulaciones TSP) y complejidad.
3. **Evaluación Continua de Laboratorios y Proyectos en Python**: **30 % de la nota final**.
    - Entrega periódica de cuadernos de laboratorio resueltos (15 %) y desarrollo de un proyecto práctico aplicado de modelado y optimización computacional (15 %).

Nota de superación: Para aprobar la asignatura por evaluación continua, el estudiante deberá obtener una calificación media ponderada igual o superior a **5.0 sobre 10**, con una nota mínima de **4.0 sobre 10** en cada uno de los dos exámenes parciales.

5.2. Convocatoria Extraordinaria

Los estudiantes que no hayan superado la asignatura en la convocatoria ordinaria dispondrán de una prueba extraordinaria global:

- **Examen Teórico-Práctico Final**: **70 % de la nota final** (evalúa los contenidos de los Bloques I y II).
- **Evaluación de Prácticas de Laboratorio**: **30 % de la nota final** (se conserva la nota obtenida durante el curso o se realiza una prueba práctica individual de programación en Python).

---

6 Bibliografía y recursos de referencia

6.1. Textos de referencia principal

- **Bazaraa, M. S., Sherali, H. D., & Shetty, C. M.** (2013). *Nonlinear Programming: Theory and Algorithms* (3rd ed.). John Wiley & Sons.
- **Boyd, S., & Vandenberghe, L.** (2004). *Convex Optimization*. Cambridge University Press.
- **Ahuja, R. K., Magnanti, T. L., & Orlin, J. B.** (1993). *Network Flows: Theory, Algorithms, and Applications*. Prentice Hall.
- **Bondy, J. A., & Murty, U. S. R.** (2008). *Graph Theory*. Springer Graduate Texts in Mathematics.
- **Nocedal, J., & Wright, S. J.** (2006). *Numerical Optimization* (2nd ed.). Springer Series in Operations Research.

6.2. Textos complementarios de algoritmos y computación

- **Diestel, R.** (2017). *Graph Theory* (5th ed.). Springer Graduate Texts in Mathematics.
- **Cormen, T. H., Leiserson, C. E., Rivest, R. L., & Stein, C.** (2022). *Introduction to Algorithms* (4th ed.). MIT Press.
- **Taha, H. A.** (2017). *Operations Research: An Introduction* (10th ed.). Pearson.
- **Vanderbei, R. J.** (2020). *Linear Programming: Foundations and Extensions* (5th ed.). Springer.

6.3. Recursos digitales y software

- **CVXPY Documentation**: Guía oficial y ejemplos de optimización convexa disciplinada (https://www.cvxpy.org/).
- **NetworkX Documentation**: Manual y tutoriales de análisis de redes y grafos en Python (https://networkx.org/).
- **SciPy Optimize Reference**: Documentación de algoritmos numéricos de optimización (https://docs.scipy.org/doc/scipy/reference/optimize.html).

PARTE II

Apuntes Teóricos de la Asignatura

Fundamentos matemáticos, análisis convexo, dualidad, teoría de grafos y algoritmos en redes

> Manual exhaustivo compuesto por diez temas que abordan desde la optimización no lineal continua y las condiciones de Karush-Kuhn-Tucker hasta los modelos combinatorios clásicos sobre grafos y redes de transporte. Se combinan deducciones formales, demostraciones analíticas, representaciones geométricas vectoriales y animaciones algorítmicas interactivas.

Víctor Aceña Gil · Antonio Alonso Ayuso

CC BY-SA 4.0 Internacional · Curso 2026-2027

Índice apuntes

Prefacio **3**
Filosofía pedagógica del volumen . . . 3
¿Qué aprenderás con este libro? . . . 4

1 Introducción a la investigación operativa **6**
1.1 Definición e historia de la investigación operativa . . . 6
1.1.1 Raíces históricas y el nacimiento de la disciplina . . . 7
1.1.2 Definiciones formales . . . 7
1.1.3 Herramientas de la investigación operativa . . . 8
1.2 El concepto de modelo en ciencias de la decisión . . . 8
1.2.1 Clasificación general de los modelos . . . 9
1.2.2 El ciclo de vida del modelado matemático . . . 9
1.3 Formulación general de modelos de optimización . . . 10
1.3.1 Clasificación de los modelos de optimización . . . 11
1.4 La estructura del libro: optimización no lineal y en redes . . . 12
1.4.1 Bloque I: Optimización no lineal . . . 12
1.4.2 Bloque II: Optimización en redes . . . 13

I Bloque I: Optimización no lineal **15**

2 Optimización no lineal y métodos numéricos **16**
2.1 Formulación de problemas no lineales . . . 17
2.1.1 Casos particulares de la optimización no lineal . . . 17
2.1.2 El monopolio de Cournot (1838) . . . 19
2.1.3 Selección de cartera de valores (Markowitz, 1952) . . . 20
2.2 Óptimos locales, globales y puntos de silla . . . 21
2.3 Herramientas de análisis diferencial . . . 21
2.3.1 Desarrollo de Taylor multivariante . . . 22
2.3.2 Caracterización de curvatura y clasificación de matrices . . . 23
2.3.3 Condiciones de optimalidad y puntos estacionarios . . . 24
2.4 Métodos de búsqueda unidimensional . . . 28
2.4.1 Métodos sin derivadas . . . 29
2.4.2 Métodos con derivadas . . . 37

2.5 Métodos multivariantes de optimización sin restricciones . . . 42
2.5.1 Método de las coordenadas cíclicas . . . 43
2.5.2 Método del máximo descenso . . . 46
2.5.3 Métodos de Newton multivariante y BFGS . . . 48

3 Análisis convexo **51**
3.1 Conjuntos convexos . . . 52
3.1.1 Envoltura convexa y símplices . . . 54
3.1.2 Puntos extremos y optimización en poliedros . . . 55
3.2 Funciones convexas . . . 57
3.2.1 Operaciones que preservan la convexidad de funciones . . . 58
3.2.2 Epigrafo e hipografo . . . 59
3.3 Caracterización de funciones convexas diferenciables . . . 68
3.4 Óptimos de una función convexa . . . 73
3.5 Generalizaciones de la convexidad . . . 83
3.5.1 Funciones cuasi-convexas . . . 84
3.5.2 Funciones pseudo-convexas . . . 88
3.5.3 Jerarquía y equivalencias de convexidad . . . 90
3.6 Convexidad puntual . . . 93

4 Condiciones de optimalidad y KKT **95**
4.1 Optimización sin restricciones . . . 95
4.1.1 Direcciones de descenso . . . 96
4.1.2 Condiciones necesarias y suficientes de segundo orden . . . 97
4.1.3 Derivadas de orden superior para una variable . . . 100
4.2 Optimización con restricciones . . . 101
4.3 Restricciones de desigualdad y cono de restricciones activas . . . 104
4.4 Condiciones de Fritz-John (FJ) . . . 115
4.5 Condiciones de Karush-Kuhn-Tucker (KKT) . . . 125
4.6 Restricciones de igualdad y desigualdad . . . 154

5 Programación lineal y cuadrática **161**
5.1 Programación lineal (LP) . . . 162
5.1.1 Dualidad en programación lineal . . . 162
5.1.2 Condiciones KKT en programación lineal . . . 165
5.1.3 Interpretación económica y precios sombra . . . 169
5.1.4 Clasificación de óptimos y relaciones de dualidad . . . 170
5.2 Programación cuadrática (QP) . . . 180
5.2.1 Derivación formal del sistema KKT . . . 181
5.2.2 Transformación mediante variables de holgura y linealidad del sistema . 182
5.2.3 Algoritmo del Símplex de Wolfe con regla de entrada restringida . . . 183
5.3 Consideraciones finales . . . 198

II Bloque II: Optimización en redes **200**

6 Grafos y árboles soporte **201**
6.1 El problema de los puentes de Königsberg (Euler, 1736) . . . 201
6.2 Conceptos fundamentales . . . 204
6.2.1 Definición formal de grafos no dirigidos y dirigidos . . . 204
6.2.2 Vecindades, adyacencia y grados de un nodo . . . 205
6.2.3 Incidencia de conjuntos y cortes . . . 207
6.2.4 Tipología de grafos: multigrafos, grafos completos, subgrafos y grafos parciales . . . 209
6.3 Recorridos y conectividad en redes . . . 216
6.3.1 Cadenas y caminos . . . 216
6.3.2 Conectividad . . . 222
6.4 Grafos planares y grafos bipartitos . . . 226
6.5 Representación de grafos . . . 234
6.5.1 Representación matricial . . . 234
6.5.2 Representación vectorial . . . 238
6.5.3 Representación por listas de adyacencia . . . 240
6.6 Estructura matemática de los árboles . . . 242
6.7 Árbol soporte de mínimo peso (MST) . . . 246
6.7.1 Algoritmo de Kruskal . . . 247
6.7.2 Algoritmo de Prim . . . 252
6.7.3 Aplicaciones en aprendizaje no supervisado: clustering basado en MST . 255

7 Caminos mínimos **260**
7.1 Definición formal y condiciones de existencia . . . 261
7.2 Ecuaciones de optimalidad de Bellman . . . 265
7.3 Redes sin circuitos (DAGs) y ordenación topológica . . . 270
7.4 Redes con pesos no negativos: Algoritmo de Dijkstra . . . 273
7.5 Redes con pesos negativos: Algoritmo de Bellman-Ford . . . 278
7.6 Formulación matemática: Programación Lineal Primal y Dual . . . 285
7.7 Caminos mínimos entre todos los pares de nodos . . . 288
7.7.1 Método basado en la multiplicación de matrices (Álgebra Min-Suma) . . 289
7.7.2 Algoritmo de Floyd-Warshall . . . 291

8 Flujos en redes **296**
8.1 Estructura algebraica de flujos, ciclos y cociclos . . . 297
8.1.1 Ciclos y su relación con los flujos . . . 300
8.1.2 Bases de flujos y número ciclomático . . . 303
8.1.3 Cociclos y Lema de Coloración de Arcos de Minty . . . 306
8.1.4 Ortogonalidad fundamental entre ciclos y cociclos . . . 309
8.2 El problema del flujo máximo . . . 313
8.2.1 Redes de transporte y flujos compatibles . . . 313

8.2.2 Flujo máximo en grafos no dirigidos . . . 320
8.2.3 Flujo máximo y corte mínimo . . . 321
8.2.4 Algoritmo de Ford-Fulkerson . . . 329
8.2.5 Algoritmo de Ford-Fulkerson por etiquetado de vértices . . . 333
8.2.6 Formulación de optimización lineal y dualidad . . . 339
8.3 Problema de flujo a coste mínimo . . . 342
8.3.1 Planteamiento y formulación del flujo compatible a coste mínimo . . . 343
8.3.2 Teoremas de optimalidad y caracterización de circuitos . . . 345
8.3.3 Algoritmo de Flujo a Coste Mínimo (Grafo de distancias) . . . 348
8.4 El problema del transbordo . . . 352

9 Emparejamientos en redes 354
9.1 Fundamentos y conceptos de emparejamiento . . . 355
9.2 Resolución mediante cadenas alternantes e incrementales . . . 358
9.2.1 Cadenas alternantes, cadenas incrementales y transferencias . . . 359
9.2.2 Teorema de caracterización de Berge y descomposición de componentes 361
9.3 Algoritmo del árbol alternante y contracción de flores (Edmonds) . . . 363
9.3.1 Estructura del bosque y árbol alternante . . . 364
9.3.2 El desafío de los ciclos impares y la contracción de flores de Edmonds . 367
9.3.3 Algoritmo de Flor de Edmonds: Esquema y resolución paso a paso . . . 370
9.4 Problemas de recubrimiento en grafos y relaciones de dualidad . . . 375
9.4.1 Teorema fundamental de dualidad de Gallai . . . 377
9.5 Emparejamiento de máximo peso y algoritmo primal-dual . . . 379
9.5.1 Coste reducido de cadenas y caracterización de optimalidad . . . 380
9.5.2 Algoritmo de aumento por cardinalidad fija . . . 381

10 Rutas eulerianas, hamiltonianas y problemas de rutas 385
10.1 Grafos eulerianos y el problema de los puentes de Königsberg . . . 386
10.1.1 Algoritmo constructivo para la determinación de cadenas eulerianas . . 389
10.2 El Problema del Cartero Chino (CPP) . . . 393
10.2.1 Caracterización analítica y eulerización óptima . . . 394
10.2.2 Variantes del Problema del Cartero Chino . . . 403
10.3 Ciclos hamiltonianos y condiciones de hamiltonianidad . . . 404
10.3.1 Condiciones necesarias: 2-conexidad y cortes nodales . . . 404
10.3.2 Condiciones suficientes: Proposición de adyacencia y Teorema de Bondy y Chvátal . . . 405
10.4 El Problema del Viajante de Comercio (TSP) . . . 411
10.4.1 Modelo 1 del TSP: Variables de posición de tramo (x_{ijk}) . . . 412
10.4.2 Modelo 2 del TSP: Eliminación exponencial de subciclos (DFJ) . . . 414
10.4.3 Modelo 3 del TSP: Formulación compacta MTZ (Miller-Tucker-Zemlin) 416
10.4.4 Heurísticas y el Algoritmo de Aproximación de Christofides . . . 417
10.5 Taxonomía y características de los Problemas de Rutas de Vehículos (VRP) . . 419

Conclusiones **423**
Resumen del aprendizaje 423
Reflexiones finales 424
Proyección futura: El valor del rigor matemático 425

Bibliografía **426**

Prefacio

La optimización matemática y el análisis de redes constituyen dos de las ramas más dinámicas y aplicadas de las matemáticas modernas. En un mundo cada vez más interconectado y dependiente del análisis cuantitativo para la toma de decisiones, la capacidad de modelar sistemas complejos, optimizar recursos limitados y analizar la topología de flujos de información se ha convertido en una competencia fundamental para matemáticos, científicos de datos y profesionales de la investigación operativa. Este libro está diseñado para proporcionar una comprensión profunda, rigurosa y estructurada de estas técnicas, sirviendo de guía de estudio para la asignatura de **Optimización y Análisis de Redes** en el **Grado en Matemáticas**.

A lo largo de diez capítulos organizados en dos bloques temáticos, exploraremos un recorrido metodológico completo. En el **Bloque I (Optimización no lineal)**, nos sumergiremos en la optimización continua, analizando algoritmos univariantes y multivariantes (descenso, Newton, BFGS), el formalismo teórico del análisis convexo, y las condiciones de optimalidad de Karush-Kuhn-Tucker (KKT) aplicadas a la Programación Lineal y Cuadrática (Símplex de Wolfe). En el **Bloque II (Optimización en redes)**, trasladaremos nuestro enfoque a las estructuras discretas de grafos, estudiando la propiedad de Total Unimodularidad (TUM), árboles soporte mínimos, caminos mínimos primal-duales con potenciales nodales, flujos en redes (Max-Flow Min-Cut), emparejamientos y asignación óptima (algoritmo Húngaro y Blossom de Edmonds), y problemas de rutas eulerianas, hamiltonianas, el problema del viajante (TSP) y la taxonomía del VRP.

El objetivo de este texto es doble: por un lado, asentar los fundamentos algebraicos, analíticos y geométricos que justifican la existencia y propiedades de los óptimos y los flujos, y por otro, dotar al lector de las herramientas de modelización para estructurar y resolver de forma eficiente problemas del mundo real. Al finalizar esta obra, habrás adquirido un criterio sólido para analizar la complejidad de un problema de decisión, seleccionar el algoritmo idóneo para su resolución e interpretar los resultados con sentido crítico.

Filosofía pedagógica del volumen

Siguiendo el enfoque de nuestra obra de referencia, la filosofía de este texto se sustenta en un método pedagógico riguroso y estructurado. Creemos firmemente que la labor matemática no debe reducirse a una mera aplicación ciega de fórmulas o algoritmos mecánicos. El verdadero potencial de un matemático reside en comprender el *porqué* detrás de cada paso algorítmico,

el comportamiento de las restricciones en el plano geométrico y la estructura algebraica que garantiza la convergencia y la integridad de las soluciones (Hillier y Lieberman 2010).

Por ello, cada concepto se introduce motivando su necesidad histórica y práctica, se formaliza mediante teoremas y lemas demostrados con detalle, y se ilustra a través de ejemplos numéricos completos, representaciones geométricas y trazas algorítmicas paso a paso, promoviendo una comprensión profunda que une el rigor formal con la intuición analítica.

¿Qué aprenderás con este libro?

Al completar este volumen, habrás desarrollado habilidades clave para:

- **Modelar** problemas complejos de decisión y redes utilizando variables continuas, enteras y binarias.
- **Analizar** la convexidad de funciones y conjuntos mediante gradientes, matrices hessianas y conos para garantizar óptimos globales.
- **Formular y resolver** sistemas de optimalidad mediante las condiciones de Karush-Kuhn-Tucker (KKT), cualificación de restricciones (LICQ) y el método del Símplex de Wolfe para programación cuadrática.
- **Explotar** la propiedad de Total Unimodularidad (TUM) de las matrices de incidencia para resolver problemas discretos en redes mediante relajaciones continuas exactas.
- **Formular e interpretar** los problemas duales en redes (caminos mínimos, potenciales nodales y tensiones de arco).
- **Aplicar algoritmos exactos** en grafos para árboles soporte (Prim, Kruskal), caminos mínimos (Dijkstra, Bellman-Ford, Floyd-Warshall), flujos máximos (Ford-Fulkerson, Edmonds-Karp), emparejamientos (algoritmo Húngaro, Blossom) y circuitos eulerianos (Cartero Chino).
- **Diseñar y evaluar** formulaciones de programación lineal entera (modelos x_{ijk}, DFJ y MTZ), heurísticas de mejora local (2-Opt) y algoritmos de aproximación polinomial (Christofides con garantía 1.5) para problemas NP-duros.

> **!** Grado en matemáticas
>
> Este libro presenta el material teórico y práctico de la asignatura de Optimización y Análisis de Redes del Grado en Matemáticas de la Universidad Rey Juan Carlos. Su contenido está estrechamente vinculado con las asignaturas de Álgebra Lineal, Matemática Discreta, Cálculo, Análisis Vectorial I, Métodos Estadísticos de Gestión e Investigación e Introducción a la Programación.

! Conocimientos previos

Es altamente recomendable que los estudiantes dominen los conceptos básicos de espacios vectoriales, cálculo diferencial multivariante (gradientes, matrices jacobianas y hessianas) y los fundamentos de la programación lineal (método Símplex y dualidad clásica).

i Sobre los autores

Víctor Aceña Gil es graduado en Matemáticas por la UNED, máster en Tratamiento Estadístico y Computacional de la Información por la UCM y la UPM, doctor en Tecnologías de la Información y las Comunicaciones por la URJC y profesor del departamento de Informática y Estadística de la URJC. Miembro del grupo de investigación de alto rendimiento en Fundamentos y Aplicaciones de la Ciencia de Datos, DSLAB, de la URJC. **Antonio Alonso Ayuso** es catedrático de Universidad en el área de Estadística e Investigación Operativa del departamento de Informática y Estadística de la Universidad Rey Juan Carlos. Es especialista en optimización matemática continua, entera y estocástica, con amplia experiencia en la resolución de problemas de redes, logística y toma de decisiones bajo incertidumbre.

Esta obra está bajo una licencia de Creative Commons Atribución-CompartirIgual 4.0 Internacional.

1 Introducción a la investigación operativa

La **Investigación Operativa** (conocida internacionalmente como *Operations Research* o *Management Science*) es la disciplina científica que aplica métodos analíticos avanzados para dar soporte a la toma de decisiones complejas en sistemas reales. Lejos de constituir un mero conjunto de herramientas analíticas o algoritmos aislados, representa una metodología sistemática y estructurada. Combina la modelización matemática, el análisis estadístico y la optimización para diseñar, gestionar y mejorar sistemas complejos bajo condiciones de recursos limitados (Hillier y Lieberman 2010).

En este capítulo de apertura, estableceremos las bases conceptuales y epistemológicas de la disciplina. Exploraremos el origen histórico de la Investigación Operativa, formalizaremos el concepto de modelo matemático, detallaremos las fases fundamentales del ciclo de modelización y describiremos los elementos estructurales de un problema de optimización. Finalmente, introduciremos las dos grandes vertientes que estructuran este volumen: la optimización no lineal y la optimización en redes.

! Objetivos de aprendizaje

Al finalizar este capítulo, serás capaz de:

1. **Definir** el alcance, el origen y las herramientas esenciales de la Investigación Operativa en el ámbito profesional y académico.
2. **Diferenciar** entre modelos físicos (concretos) y matemáticos (abstractos), comprendiendo el equilibrio crítico entre realismo y manejabilidad matemática.
3. **Describir y aplicar** las cuatro fases del ciclo de vida de un proyecto de modelización matemática.
4. **Estructurar formalmente** un problema de optimización matemática, identificando sus variables de decisión, restricciones y función objetivo.
5. **Clasificar** los problemas de optimización atendiendo a criterios de linealidad, dominio de variables y presencia de incertidumbre.

1.1. Definición e historia de la investigación operativa

La Investigación Operativa como disciplina académica y aplicativa es el resultado de un proceso evolutivo caracterizado por la integración progresiva de métodos matemáticos, rigor científico y

tecnologías de la computación. Para comprender en profundidad su alcance y utilidad en la toma de decisiones estratégicas, resulta fundamental examinar sus orígenes en la resolución de problemas operativos críticos, analizar sus definiciones formales consolidadas y catalogar las herramientas analíticas esenciales que estructuran su metodología.

1.1.1. Raíces históricas y el nacimiento de la disciplina

La Investigación Operativa no nació en laboratorios académicos aislados, sino en el fragor de la necesidad estratégica y militar durante la Segunda Guerra Mundial. A finales de la década de 1930, el mando militar británico se enfrentaba a la inminente amenaza aérea del régimen nazi. Para contrarrestarla, desarrollaron el sistema de radares costeros, pero se percataron rápidamente de que disponer de la tecnología no bastaba: era imperativo aprender a utilizarla de manera integrada y eficiente.

Fue entonces cuando el físico británico Patrick Blackett organizó un grupo multidisciplinar de científicos (que incluía matemáticos, físicos, astrofísicos y militares) conocido históricamente como el **"Blackett's Circus"** (el Circo de Blackett). Este equipo analizó científicamente las operaciones militares reales, logrando hitos memorables como la determinación del tamaño óptimo de los convoyes navales de suministro para minimizar las pérdidas causadas por los submarinos alemanes, o la calibración de la profundidad de detonación de las cargas antisubmarinas en los bombarderos.

Paralelamente, en la Unión Soviética, el matemático y economista **Leonid Kantorovich** desarrolló de forma independiente técnicas de planificación matemática para la industria del carbón y del acero en 1939. Kantorovich sentó las bases de lo que hoy conocemos como Programación Lineal, trabajo que le valdría el Premio Nobel de Economía en 1975 por su teoría sobre la asignación óptima de recursos.

Tras la finalización del conflicto mundial, en 1947, el matemático estadounidense **George Dantzig** revolucionó la disciplina al proponer el **método del Símplex**, un algoritmo sistemático y extremadamente eficiente para resolver problemas de programación lineal. Este descubrimiento coincidió con la invención y el rápido desarrollo de las primeras computadoras electrónicas, lo que permitió aplicar las metodologías de la Investigación Operativa a la planificación industrial, la logística comercial, el sector financiero y la administración pública. La rápida expansión económica de la posguerra demandaba una gestión científica y optimizada de las grandes corporaciones, consolidando el éxito de esta disciplina (Bazaraa, Jarvis, y Sherali 2011).

1.1.2. Definiciones formales

Existen dos definiciones clásicas promovidas por las instituciones profesionales de referencia a nivel mundial:

- **The Operational Research Society (Reino Unido)**: La Investigación Operativa es la aplicación del método científico a problemas complejos en la dirección y gestión de grandes sistemas de personas, máquinas, materiales y recursos financieros en la industria, el comercio, la administración pública y la defensa. Su enfoque característico reside en construir un modelo científico del sistema, incorporando factores de riesgo e incertidumbre, para predecir y comparar las consecuencias de diversas decisiones, estrategias y controles alternativos.
- **Institute for Operations Research and the Management Sciences (INFORMS, EE.UU.)**: La Investigación Operativa se define como el empleo de la ciencia de la decisión y la modelización analítica avanzada para resolver problemas y mejorar el rendimiento de sistemas y procesos de negocio complejos.

1.1.3. Herramientas de la investigación operativa

Para dar respuesta a problemas de diversa naturaleza, la Investigación Operativa se sirve de un amplio catálogo de metodologías científicas:

- **Optimización matemática**: Modelos lineales, enteros, no lineales y dinámicos orientados a maximizar rendimientos o minimizar costes bajo restricciones de recursos.
- **Teoría de grafos y optimización en redes**: Algoritmos discretos para resolver problemas de conectividad, distribución, transporte y caminos óptimos.
- **Procesos estocásticos y teoría de colas**: Modelización del comportamiento de sistemas sujetos a aleatoriedad y análisis de líneas de espera en sistemas de servicios, logística y telecomunicaciones.
- **Simulación computacional**: Simulación analítica (como los métodos de Montecarlo o la simulación de eventos discretos) para evaluar el rendimiento de sistemas complejos cuando las soluciones analíticas cerradas resultan inviables.
- **Teoría de juegos y decisión multicriterio**: Análisis de interacciones estratégicas entre agentes competitivos y metodologías para tomar decisiones cuando existen múltiples objetivos contrapuestos.

1.2. El concepto de modelo en ciencias de la decisión

Un **modelo** es una representación simplificada, abstracta y selectiva de un sistema real destinada a facilitar la comprensión de su estructura interna y predecir su comportamiento bajo diversos escenarios.

La labor del modelador matemático es similar a la del cartógrafo. Tal y como enunció el filósofo Alfred Korzybski, *"el mapa no es el territorio"*. Un mapa a escala 1:1 sería perfectamente

inútil por su inmanejabilidad. De igual modo, un modelo matemático que pretenda incluir cada mínimo detalle físico del sistema real resultará intratable computacionalmente. La clave reside en realizar una **abstracción selectiva**: identificar y capturar las variables esenciales del problema eliminando el ruido irrelevante, logrando un equilibrio óptimo entre fidelidad (realismo) y manejabilidad (capacidad de resolución).

1.2.1. Clasificación general de los modelos

Atendiendo a su naturaleza física o abstracta, los modelos se dividen clásicamente en:

- **Modelos concretos o icónicos**: Representaciones físicas a escala del sistema real. Ejemplos de esto son las maquetas de aviones ensayadas en túneles de viento o los modelos tridimensionales de proteínas. Su análisis se realiza mediante experimentación directa.
- **Modelos abstractos o analíticos**: Representaciones formales donde las variables del sistema y sus relaciones lógicas se expresan mediante ecuaciones, inecuaciones y funciones matemáticas. Son el objeto de estudio de la optimización y permiten una manipulación analítica o numérica asistida por computadoras.

Desde la perspectiva de su propósito metodológico, podemos catalogar los modelos matemáticos en tres niveles de madurez analítica:

1. **Modelos Descriptivos**: Representan la estructura del sistema para responder a la pregunta *"¿qué está ocurriendo?"*.
2. **Modelos Predictivos**: Utilizan datos históricos y estadística para responder a la pregunta *"¿qué podría ocurrir en el futuro?"*.
3. **Modelos Prescriptivos**: Integran los niveles anteriores para responder a la pregunta *"¿qué decisión debemos tomar para optimizar el rendimiento del sistema?"*. La optimización matemática pertenece a esta última categoría.

1.2.2. El ciclo de vida del modelado matemático

La resolución de un problema mediante la Investigación Operativa no consiste en un proceso lineal, sino en un ciclo iterativo de retroalimentación constante que consta de cuatro fases diferenciadas:

1. **Observación y definición del problema**: Se estudian los límites del sistema real y se identifican las metas del decisor. Se recopilan, depuran y analizan los datos empíricos relevantes del problema.
2. **Formulación matemática**: Se eligen las variables que representan las decisiones controlables, se describen las limitaciones físicas y operativas mediante restricciones (ecuaciones e inecuaciones) y se formaliza la métrica de éxito o coste como una función objetivo.

3. **Validación y análisis de sensibilidad**: Se resuelve el modelo numéricamente y se contrasta si las soluciones obtenidas son coherentes con la realidad del sistema. Se evalúa la robustez del modelo mediante el análisis de sensibilidad, midiendo cómo varían las decisiones óptimas ante perturbaciones en los parámetros del modelo.
4. **Implementación e integración**: Se traduce la solución matemática en decisiones operativas ejecutables por la organización. Se diseñan sistemas informáticos de soporte a la decisión y se establecen mecanismos de supervisión para detectar cambios en el sistema real que exijan reformular el modelo.

1.3. Formulación general de modelos de optimización

Un modelo de optimización matemática busca seleccionar la mejor alternativa posible dentro de un conjunto de soluciones factibles. Su formulación matemática genérica se escribe formalmente como:

$$\begin{aligned} \min_x \text{ o } \max_x \quad & f(x) \\ \text{sujeto a} \quad & g_i(x) \leq 0, \quad i = 1, \dots, m \\ & h_j(x) = 0, \quad j = 1, \dots, p \\ & x \in X \subseteq \mathbb{R}^n \end{aligned}$$

Donde los componentes esenciales del modelo son:

- **Variables de decisión (x)**: El vector $x = (x_1, x_2, \dots, x_n)^T$ de dimensiones n que representa los factores bajo control directo del decisor que se desea determinar.
- **Función objetivo ($f(x)$)**: La función escalar de las variables de decisión que mide la efectividad, el coste, el tiempo o el beneficio del sistema y que se pretende optimizar (minimizar o maximizar).
- **Restricciones de desigualdad ($g_i(x) \leq 0$) e igualdad ($h_j(x) = 0$)**: Ecuaciones o inecuaciones que representan límites físicos (capacidad, stock), económicos (presupuesto), técnicos o de balance de flujo del sistema. Definen el **espacio factible** (o región factible) $\mathcal{S}$ del problema.
- **Espacio de definición (X)**: El dominio general donde viven las variables (por ejemplo, números reales, enteros, no negativos, etc.).

Ejemplo: La dieta óptima

Supongamos que deseamos diseñar una dieta de bajo coste utilizando dos alimentos básicos: Leche (x_1) y Verdura (x_2). Disponemos de los siguientes datos de coste y nutrición:

- Un litro de leche cuesta 0.80 € y aporta 3 unidades de calcio y 1 unidad de hierro.
- Un kilo de verdura cuesta 1.20 € y aporta 1 unidad de calcio y 2 unidades de hierro.

- Los requisitos mínimos diarios de un individuo son 6 unidades de calcio y 4 unidades de hierro.

Para formular el modelo matemático de este problema operativo:

1. **Variables de decisión**:
   - x_1: Litros de leche consumidos al día.
   - x_2: Kilos de verdura consumidos al día.
2. **Función objetivo (minimizar el coste total diario)**:

$$\text{mín} \quad 0.80x_1 + 1.20x_2$$

3. **Restricciones**:
   - Requisito de Calcio: $3x_1 + 1x_2 \geq 6 \implies 6 - 3x_1 - x_2 \leq 0$
   - Requisito de Hierro: $1x_1 + 2x_2 \geq 4 \implies 4 - x_1 - 2x_2 \leq 0$
   - No negatividad (no se puede consumir comida negativa): $x_1, x_2 \geq 0$

1.3.1. Clasificación de los modelos de optimización

Atendiendo a las propiedades algebraicas y analíticas de sus componentes, los problemas de optimización se clasifican de la siguiente manera:

- **Según la linealidad**:
  - *Programación Lineal (LP)*: Tanto la función objetivo $f(x)$ como todas las funciones de restricciones $g_i(x)$ e $h_j(x)$ son funciones afines (de primer grado). Permiten la aplicación del algoritmo del Símplex y métodos de punto interior. Su resolución numérica es sumamente rápida, pudiendo manejar millones de variables y restricciones.
  - *Programación No Lineal (NLP)*: Al menos una de las funciones involucradas (f, g_i o h_j) presenta curvatura o componentes no lineales (como potencias, exponenciales, logaritmos o funciones trigonométricas). La búsqueda del óptimo requiere herramientas de cálculo multivariante y análisis de curvatura.
- **Según el dominio de definición**:
  - *Optimización Continua*: El espacio de búsqueda X es continuo ($x \in \mathbb{R}^n$). Esto nos permite explotar las derivadas de la función (gradiente, hessiana) para dirigir la búsqueda.
  - *Optimización Entera o Discreta (IP)*: Las variables de decisión solo pueden tomar valores en el conjunto de los números enteros ($x \in \mathbb{Z}^n$). Estos problemas son combinatorios y presentan una alta dificultad de resolución (son NP-duros).

- *Optimización Binaria*: Las variables se restringen a $x_j \in \{0, 1\}$, representando decisiones lógicas excluyentes del tipo "sí" o "no" (por ejemplo, construir una planta o no).
- *Optimización Entera Mixta (MIP)*: Coexisten variables continuas y enteras/binarias dentro del mismo modelo, permitiendo modelar simultáneamente decisiones lógicas y cantidades físicas continuas.

- **Según la presencia de incertidumbre**:

  - *Optimización Determinista*: Todos los coeficientes y parámetros del modelo se conocen con absoluta certeza.
  - *Optimización Estocástica*: Algunos parámetros del modelo se comportan como variables aleatorias con distribuciones de probabilidad conocidas. Se busca optimizar el valor esperado o cumplir restricciones de probabilidad (restricciones de azar).

1.4. La estructura del libro: optimización no lineal y en redes

Este volumen se organiza en dos bloques metodológicos bien diferenciados por su naturaleza matemática, geométrica y algorítmica:

1.4.1. Bloque I: Optimización no lineal

Cuando abandonamos la hipótesis de linealidad, la optimización matemática gana sustancialmente en realismo, pero incrementa de manera drástica su complejidad teórica y computacional.

- **Optimización no lineal y algoritmos de optimización univariante y multivariante (Tema 2)**: Estudiaremos las herramientas fundamentales de la optimización continua sin restricciones. En el caso unidimensional, analizaremos métodos sin derivadas (búsqueda uniforme, dicotómica, sección áurea y Fibonacci) y métodos basados en derivadas (bisección y Newton-Raphson). En el caso multivariante, veremos métodos de búsqueda directa (coordenadas cíclicas y Hooke-Jeeves), el método del máximo descenso de Cauchy, y algoritmos de segundo orden (Newton multivariante y la actualización Cuasi-Newton BFGS).
- **Análisis convexo (Tema 3)**: Estableceremos las propiedades fundamentales de los conjuntos y conos convexos, los teoremas de separación y soporte por hiperplanos, y las funciones convexas (caracterizadas mediante gradientes y matrices hessianas semidefinidas positivas). En este marco se demuestra el resultado cardinal de la optimización: todo mínimo local es un mínimo global. Asimismo, introduciremos el subgradiente y el subdiferencial para tratar funciones convexas no diferenciables.

- **Condiciones de optimalidad en problemas restringidos (Tema 4)**: Analizaremos la geometría del espacio factible, el cono de direcciones factibles y de descenso, los multiplicadores de Lagrange para restricciones de igualdad, las condiciones de Fritz-John y las condiciones de Karush-Kuhn-Tucker (KKT) bajo cualificación de restricciones (LICQ y condición de Slater). Se estudiará la suficiencia de KKT bajo convexidad y los fundamentos de la dualidad lagrangiana y de Wolfe.
- **Condiciones KKT en Programación Lineal y Cuadrática (Tema 5)**: Aplicaremos las condiciones de optimalidad a problemas lineales (demostrando la equivalencia matricial entre multiplicadores KKT, variables duales del Símplex y holgura complementaria) y a problemas de Programación Cuadrática (QP), desarrollando el método del Símplex de Wolfe para QP convexo con variables de holgura complementarias y regla de entrada restringida.

1.4.2. Bloque II: Optimización en redes

La optimización en redes aprovecha la estructura combinatorial de los grafos para resolver problemas de gran envergadura de forma extremadamente eficiente.

- **Grafos y árboles soporte (Tema 6)**: Modelado formal de redes dirigidas y no dirigidas empleando matrices de adyacencia e incidencia. Analizaremos la propiedad de Total Unimodularidad (TUM) de la matriz de incidencia nodo-arco y su impacto en la integridad de las soluciones continuas. Estudiaremos las caracterizaciones de árboles y arborescencias, junto con los algoritmos clásicos de Kruskal y Prim para la obtención del Árbol Soporte de Mínimo Peso (MST).
- **Caminos mínimos en redes (Tema 7)**: Analizaremos el principio de optimalidad de Bellman y los algoritmos fundamentales para caminos óptimos: Dijkstra (costes no negativos), Bellman-Ford (detección de arcos y ciclos negativos) y Floyd-Warshall (todos los pares de nodos). Abordaremos la formulación matemática de Programación Lineal primal del camino mínimo y su problema Dual asociado, expresado mediante potenciales nodales y tensiones de arco.
- **Flujos en redes (Tema 8)**: Estudiaremos el espacio vectorial de flujos y ciclos, el Lema de Coloración de Arcos de Minty, y el problema del Flujo Máximo mediante el algoritmo de Ford-Fulkerson, redes residuales, caminos de aumento y el teorema fundamental del Flujo Máximo - Corte Mínimo (Max-Flow Min-Cut), junto con el algoritmo de Edmonds-Karp. Analizaremos además el problema de Flujo de Coste Mínimo y el algoritmo de cancelación de ciclos negativos de Klein.
- **Emparejamientos en grafos y asignación óptima (Tema 9)**: Abordaremos la teoría de emparejamientos y conjuntos independientes. En grafos bipartitos, demostraremos el Teorema de Hall del matrimonio y el Teorema de Kőnig, formulando el Problema de Asignación lineal óptima y resolviéndolo mediante el Algoritmo Húngaro paso a paso. Para grafos generales, introduciremos el algoritmo Blossom de Edmonds mediante contracción de flores.

- **Rutas eulerianas, hamiltonianas y problemas de rutas (Tema 10)**: Estudiaremos la caracterización de grafos eulerianos (Teorema de Euler y algoritmo constructivo de cadenas) y el Problema del Cartero Chino (CPP). Analizaremos las condiciones de existencia de ciclos hamiltonianos (Dirac, Ore, Bondy-Chvátal) y el Problema del Viajante de Comercio (TSP) a través de tres formulaciones de Programación Lineal Entera (etapas x_{ijk}, eliminación exponencial de subciclos DFJ y formulación compacta MTZ). Finalmente, examinaremos heurísticas (2-Opt), el algoritmo de aproximación de Christofides (garantía 1.5) y la taxonomía general de los Problemas de Rutas de Vehículos (VRP).

Parte I

Bloque I: Optimización no lineal

2 Optimización no lineal y métodos numéricos

La **optimización no lineal** (Nonlinear Programming, NLP) estudia problemas de decisión donde la función objetivo o alguna de las restricciones presentan comportamientos no lineales. A diferencia de la programación lineal, donde las soluciones óptimas se encuentran siempre en la frontera del conjunto factible (específicamente en sus puntos extremos o vértices), en optimización no lineal el óptimo puede situarse en el interior del espacio factible o en cualquier punto de su frontera. La presencia de curvatura en la función objetivo y en las restricciones exige herramientas avanzadas de análisis diferencial multivariante y algoritmos iterativos complejos.

En este tema estudiaremos la formulación y clasificación de los problemas de optimización no lineal y sus casos más relevantes. Desarrollaremos las herramientas de análisis diferencial necesarias (gradiente, hessiana y condiciones de optimalidad) para caracterizar la curvatura local e identificar mínimos, máximos y puntos de silla. Finalmente, abordaremos los principales métodos numéricos de búsqueda unidimensional (sin y con derivadas) y los métodos multivariantes sin restricciones, desde el sencillo descenso por coordenadas hasta los métodos de Newton y la técnica Quasi-Newton BFGS.

! Objetivos de aprendizaje

Al finalizar este capítulo, serás capaz de:

1. **Formular y clasificar** problemas de optimización no lineal en sus distintas familias estructurales.
2. **Visualizar e interpretar geométricamente** la diferencia entre la optimización lineal y la no lineal a través del análisis de conjuntos factibles convexos y curvas de nivel no lineales.
3. **Caracterizar la curvatura** de una función multivariante mediante el análisis del gradiente y de la matriz hessiana empleando el criterio de los menores principales.
4. **Clasificar puntos estacionarios** aplicando las condiciones de optimalidad de primer y segundo orden (FONC, SONC, SOSC).
5. **Implementar y trazar numéricamente** algoritmos de búsqueda lineal en una dimensión, tanto sin derivadas como con derivadas.
6. **Comprender y programar** algoritmos de optimización multivariante sin restricciones, analizando el comportamiento de las coordenadas cíclicas, el fenómeno de zigzag del máximo descenso y las ventajas de los métodos de Newton y Cuasi-Newton (BFGS).

2.1. Formulación de problemas no lineales

En el mundo real, la linealidad es una excepción matemática. Los fenómenos físicos, económicos y tecnológicos se comportan de manera inherentemente no lineal. En la industria, por ejemplo, las **economías de escala** provocan que el coste unitario de producción disminuya a medida que aumenta el volumen debido al reparto de costes fijos o descuentos por cantidad, lo que rompe la relación de proporcionalidad lineal. En el ámbito económico, la **elasticidad de la demanda** determina que la cantidad demandada de un bien sea sensible a su precio de venta, por lo que la función de ingresos resultante ($I = P \cdot Q$) es cuadrática y no lineal. En el sector financiero, siguiendo el modelo de selección de carteras de Markowitz, el riesgo se mide mediante la varianza del rendimiento de los activos, que constituye una combinación cuadrática de los pesos invertidos, mientras que el rendimiento esperado se mantiene lineal. Finalmente, en la ciencia de datos, la estimación de modelos y algoritmos de aprendizaje automático suele penalizar los errores de ajuste de forma cuadrática (mínimos cuadrados), generando funciones objetivo no lineales.

Un **problema de optimización no lineal (PNL)** general se define matemáticamente sobre un espacio vectorial $\mathbb{R}^n$ como:

$$\begin{aligned} \min_{x \in \mathbb{R}^n} \quad & f(x) \\ \text{sujeto a} \quad & g_i(x) \leq 0, \quad i = 1, \dots, m \\ & h_j(x) = 0, \quad j = 1, \dots, p \end{aligned}$$

Donde $f : \mathbb{R}^n \to \mathbb{R}$ es la función objetivo, $g_i : \mathbb{R}^n \to \mathbb{R}$ representa las restricciones de desigualdad, e $h_j : \mathbb{R}^n \to \mathbb{R}$ representa las restricciones de igualdad. Para que el problema sea clasificado como no lineal, al menos una de estas funciones debe exhibir un comportamiento no lineal en el dominio de interés.

La transición de modelos lineales a no lineales altera profundamente la geometría del espacio de búsqueda. En programación lineal (LP), el conjunto factible es siempre un poliedro convexo y la solución óptima se localiza en uno de sus vértices. Esto permite que algoritmos como el Símplex resuelvan problemas de millones de variables explorando únicamente un número finito de candidatos. En optimización no lineal (NLP), las restricciones no lineales pueden deformar el conjunto factible, y el óptimo puede hallarse en el interior del espacio factible o en cualquier punto de la frontera. Además, la presencia de no convexidades puede generar múltiples óptimos locales, atrapando a los algoritmos numéricos antes de alcanzar el mínimo global.

2.1.1. Casos particulares de la optimización no lineal

Para abordar la resolución de problemas no lineales de forma eficiente, la disciplina los clasifica en familias estructuradas según las propiedades algebraicas y analíticas de sus funciones:

La **Programación Cuadrática (QP)** representa problemas donde la función objetivo es cuadrática y las restricciones son afines (lineales), formulándose en su forma estándar como:

$$\min_x \quad \frac{1}{2}x^T Q x - b^T x \quad \text{sujeto a} \quad Ax \leq d$$

Si la matriz Q es semidefinida positiva, el problema es convexo, lo que permite el uso de algoritmos especializados extremadamente eficientes como los métodos de conjuntos activos (*active-set*) o de punto interior, que resuelven el problema de forma exacta en pocas iteraciones.

La **Programación Convexa** constituye la clase de problemas más robusta en optimización no lineal. Un problema es convexo si la función objetivo $f(x)$ es convexa, las restricciones de desigualdad $g_i(x)$ son convexas y las restricciones de igualdad $h_j(x)$ son afines. La gran ventaja analítica de la programación convexa es que todo mínimo local es un mínimo global. Esto elimina la necesidad de realizar búsquedas globales exhaustivas y garantiza que métodos locales de gradiente converjan siempre a la solución óptima del sistema.

La **Programación Separable** se presenta cuando todas las funciones involucradas se pueden descomponer en la suma de funciones que dependen exclusivamente de una sola variable independiente:

$$f(x) = \sum_{j=1}^{n} f_j(x_j) \qquad \text{y} \qquad g_i(x) = \sum_{j=1}^{n} g_{ij}(x_j) \leq 0$$

Esta propiedad estructural es muy útil, ya que permite aproximar funciones no lineales arbitrarias mediante funciones lineales a trozos (*piecewise linear approximation*), transformando el problema en un modelo lineal de variables continuas que se puede resolver con variantes del algoritmo del Símplex.

La **Programación Geométrica** surge cuando la función objetivo y las restricciones están modeladas por posinomios (sumas de términos monomios con coeficientes reales positivos):

$$f(x) = \sum_k c_k x_1^{a_{1k}} x_2^{a_{2k}} \dots x_n^{a_{nk}}$$

Aunque un problema geométrico es inherentemente no convexo en sus variables originales, la aplicación de un cambio de variables logarítmico:

$$y_j = \ln(x_j)$$

transforma el modelo en un problema convexo equivalente en el espacio y, permitiendo su resolución exacta de forma global.

La **Programación Fraccionaria** se presenta cuando la función objetivo se formula como el cociente de dos funciones reales:

$$\min_x \quad \frac{f_1(x)}{f_2(x)}$$

Aparece habitualmente al optimizar ratios de eficiencia, rentabilidad de inversiones o productividad. Bajo condiciones de concavidad y convexidad de las funciones individuales, la transformación de variables de Charnes-Cooper permite linealizar el modelo y resolverlo de forma exacta.

2.1.2. El monopolio de Cournot (1838)

Consideremos una empresa que opera en régimen de monopolio y desea maximizar su beneficio, siguiendo el modelo clásico de Cournot (Cournot 1838). La relación entre la cantidad demandada del mercado Q y el precio de venta P viene dada por la función de demanda inversa del mercado: $P(Q) = 10 - Q$. El coste total de producción de la empresa es lineal con respecto a la cantidad fabricada: $C(Q) = 1 + 3Q$. La empresa está sujeta a una limitación de capacidad física máxima de producción de 9 unidades ($Q \leq 9$). Por su parte, el organismo regulador estatal establece que el precio de venta al público no puede superar las 8 unidades monetarias ($P \leq 8$).

Para determinar la política óptima de producción y precios, formulamos el problema como un modelo con dos variables de decisión (Q y P):

$$\begin{aligned} \max_{Q,P} \quad & B(Q,P) = P \cdot Q - 3Q - 1 \\ \text{sujeto a} \quad & Q \leq 10 - P \\ & 0 \leq P \leq 8 \\ & 0 \leq Q \leq 9 \end{aligned}$$

Este problema presenta una función objetivo no lineal debido al término cuadrático $P \cdot Q$. Dado que la empresa busca maximizar el beneficio y el precio está acotado por la demanda, la solución óptima operará exactamente sobre la frontera de la curva de demanda activa (donde la restricción $Q \leq 10 - P$ se cumple como igualdad: $P = 10 - Q$). Sustituyendo el precio en la función de beneficio, reducimos el problema a una única variable real Q:

$$B(Q) = (10 - Q)Q - 3Q - 1 = -Q^2 + 7Q - 1$$

El rango de factibilidad de Q se obtiene combinando las restricciones: $Q \leq 9$ y $P \leq 8 \implies 10 - Q \leq 8 \implies Q \geq 2$. Por lo tanto, el problema de una sola variable se reduce a:

$$\max_{Q} \quad -Q^2 + 7Q - 1 \quad \text{sujeto a} \quad 2 \leq Q \leq 9$$

Para hallar el óptimo, derivamos el beneficio con respecto a la cantidad de producción e igualamos a cero: $B'(Q) = -2Q + 7 = 0 \implies Q^* = 3.5$. Como $Q^* = 3.5$ pertenece al intervalo factible $[2, 9]$, constituye el óptimo global del problema. Sustituyendo, obtenemos el precio óptimo $P^* = 6.5$ y el beneficio máximo de la empresa: $B^* = -(3.5)^2 + 7(3.5) - 1 = 11.25$ u.m.

La región factible en el plano (Q, P) es un polígono convexo con vértices en $(0, 0)$, $(0, 8)$, $(2, 8)$, $(9, 1)$, y $(9, 0)$. Las curvas de nivel de la función objetivo (curvas de isobeneficio) son hipérbolas de la forma $P = 3 + (B + 1)/Q$. A medida que el beneficio B aumenta, las hipérbolas se desplazan hacia arriba y a la derecha. El punto óptimo $(Q^*, P^*) = (3.5, 6.5)$ es el punto donde

la curva de isobeneficio correspondiente a $B = 11.25$ es exactamente tangente al segmento de la frontera $P + Q = 10$, tal y como se ilustra en la Figura 2.1.

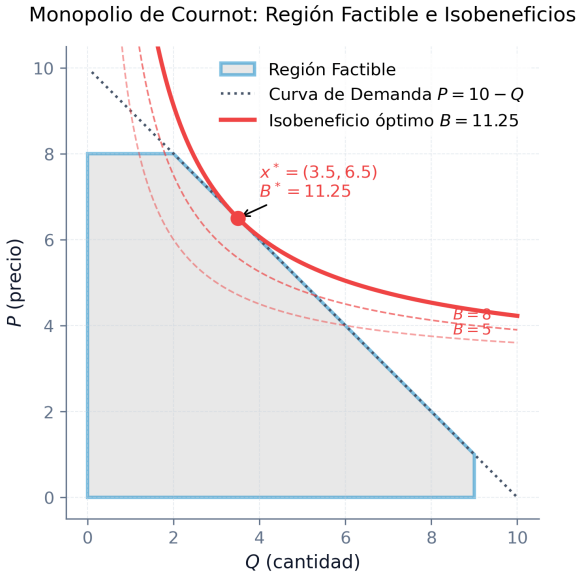

Figura 2.1: Geometría del Monopolio de Cournot: el óptimo de tangencia (3.5, 6.5) se sitúa en la frontera y no coincide con ningún vértice de la región factible polimórfica

Este resultado ilustra la diferencia fundamental con la programación lineal: la solución óptima de un problema no lineal con restricciones lineales puede situarse en el interior de una de las caras de la región factible y no en un vértice (los vértices adyacentes son $(2, 8)$ y $(9, 1)$, los cuales arrojan beneficios inferiores, de 9.0 y 8.0 u.m. respectivamente).

2.1.3. Selección de cartera de valores (Markowitz, 1952)

Supongamos que disponemos de un capital C para invertir entre n activos financieros, siguiendo el modelo pionero de selección de carteras de Markowitz (Markowitz 1952). Denotamos por x_i la cantidad monetaria asignada al activo i. Cada activo presenta un rendimiento medio esperado μ_i, y la relación de variabilidad conjunta del mercado se modela a través de la covarianza σ_{ij} entre los activos i y j. La varianza de la cartera (medida del riesgo o volatilidad) viene dada por la forma cuadrática $\sum_{i=1}^{n} \sum_{j=1}^{n} \sigma_{ij} x_i x_j$.

El inversor busca maximizar el rendimiento esperado de la cartera al tiempo que minimiza su riesgo, penalizándolo mediante un coeficiente de aversión al riesgo $\beta > 0$. El problema se formula como:

$$\begin{aligned} \max_{x \in \mathbb{R}^n} \quad & \sum_{i=1}^{n} \mu_i x_i - \beta \sum_{i=1}^{n} \sum_{j=1}^{n} \sigma_{ij} x_i x_j \\ \text{sujeto a} \quad & \sum_{i=1}^{n} x_i \leq C \\ & x_i \geq 0, \quad i = 1, \ldots, n \end{aligned}$$

Este problema posee una función objetivo cuadrática no lineal y restricciones lineales, lo que constituye un problema clásico de **Programación Cuadrática (QP)**. Su naturaleza estrictamente convexa (cuando la matriz de covarianzas es semidefinida positiva) asegura que cualquier óptimo local sea también el óptimo global del sistema (Boyd y Vandenberghe 2004; Hillier y Lieberman 2010).

2.2. Óptimos locales, globales y puntos de silla

Sea $f : \mathbb{R}^n \to \mathbb{R}$ una función real definida sobre un conjunto factible $\mathcal{X} \subseteq \mathbb{R}^n$. Un punto $x^* \in \mathcal{X}$ es un **mínimo global** si no existe ningún otro punto factible con un valor inferior de la función objetivo, es decir, $f(x) \geq f(x^*)$ para todo $x \in \mathcal{X}$. Del mismo modo, x^* es un **mínimo global estricto** si se cumple que $f(x) > f(x^*)$ para cualquier $x \in \mathcal{X} \setminus \{x^*\}$.

Por otro lado, un punto x^* constituye un **mínimo local** si es la mejor solución dentro de un entorno local delimitado por una bola de radio $\epsilon > 0$ centrada en él, satisfaciendo $f(x) \geq f(x^*)$ para todo $x \in \mathcal{X}$ tal que $\|x - x^*\| \leq \epsilon$. Finalmente, x^* es un **mínimo local estricto** si existe un radio $\epsilon > 0$ tal que $f(x) > f(x^*)$ para todo $x \in \mathcal{X} \setminus \{x^*\}$ con $\|x - x^*\| \leq \epsilon$.

En optimización no lineal general, debido a la posible presencia de no convexidades, los algoritmos locales basados en derivadas pueden converger hacia mínimos locales mediocres en lugar de alcanzar el óptimo global. Esta es la complejidad fundamental que diferencia al PNL de la programación lineal (como se ilustra en la Figura 2.2).

2.3. Herramientas de análisis diferencial

Para caracterizar y clasificar los puntos óptimos locales en múltiples dimensiones, recurrimos al cálculo diferencial. Consideremos una función $f : \mathbb{R}^n \to \mathbb{R}$ diferenciable de clase $\mathcal{C}^2$ (con segundas derivadas continuas).

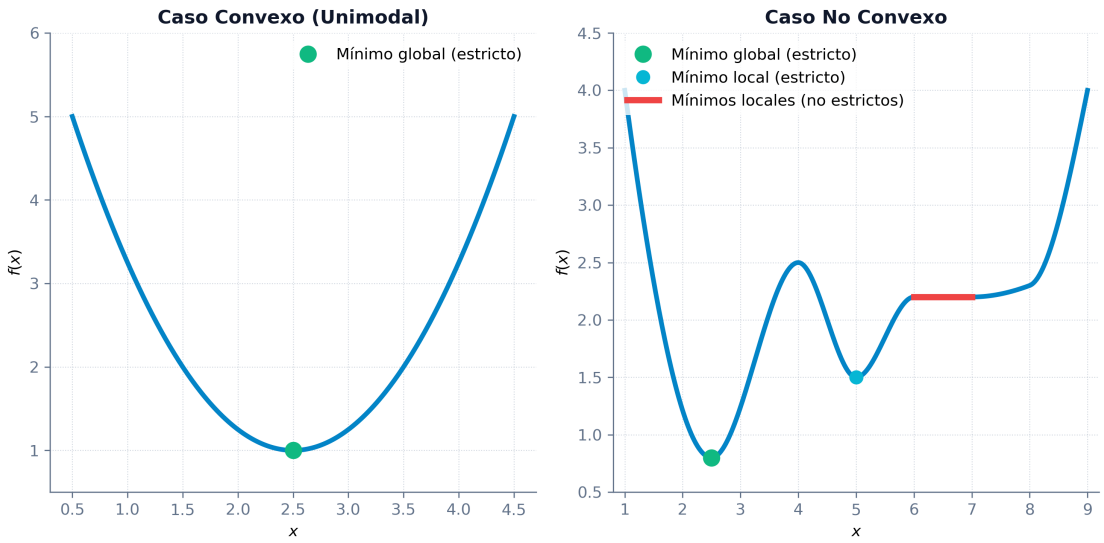

Figura 2.2: Ilustración de los distintos tipos de óptimos locales y globales (estrictos y no estrictos) sobre funciones convexas y no convexas

El **vector gradiente** representa la dirección de máxima pendiente de subida local de la función y se define como el vector columna de derivadas parciales de primer orden:

$$\nabla f(x) = \begin{pmatrix} \frac{\partial f(x)}{\partial x_1} \\ \frac{\partial f(x)}{\partial x_2} \\ \vdots \\ \frac{\partial f(x)}{\partial x_n} \end{pmatrix}$$

Por su parte, la **matriz hessiana** modela la curvatura local de la función (análoga a la segunda derivada en una dimensión) y se define como la matriz simétrica de segundas derivadas parciales:

$$[\nabla^2 f(x)]_{ij} = \frac{\partial^2 f(x)}{\partial x_i \partial x_j}$$

2.3.1. Desarrollo de Taylor multivariante

El comportamiento local de una función no lineal alrededor de un punto de referencia $\bar{x}$ se aproxima mediante su desarrollo cuadrático de Taylor:

$$f(x) = f(\bar{x}) + \nabla f(\bar{x})^T (x - \bar{x}) + \frac{1}{2}(x - \bar{x})^T \nabla^2 f(\bar{x})(x - \bar{x}) + o(\|x - \bar{x}\|^2)$$

Si la función $f(x)$ es cuadrática, esta aproximación de segundo orden es exacta para todo $x \in \mathbb{R}^n$.

2.3.2. Caracterización de curvatura y clasificación de matrices

La curvatura local de la función está determinada por el carácter de su matriz hessiana $\nabla^2 f(x)$, el cual se clasifica analizando la forma cuadrática:

$$z^T \nabla^2 f(x) z$$

- **Definida positiva** ($\nabla^2 f(x) \succ 0$): Si $z^T \nabla^2 f(x) z > 0$ para todo vector no nulo $z \in \mathbb{R}^n$. Todos sus autovalores son estrictamente positivos y todos sus menores principales son mayores que cero. La función se curva hacia arriba en forma de cuenco, lo que garantiza que un punto crítico sea un mínimo local estricto.
- **Semidefinida positiva** ($\nabla^2 f(x) \succeq 0$): Si $z^T \nabla^2 f(x) z \geq 0$ para todo vector $z \in \mathbb{R}^n$. Todos sus autovalores son no negativos y todos sus menores principales son no negativos.
- **Definida negativa** ($\nabla^2 f(x) \prec 0$): Si $z^T \nabla^2 f(x) z < 0$ para todo vector no nulo $z \in \mathbb{R}^n$. Sus menores principales alternan de signo comenzando por negativo ($M_1 < 0, M_2 > 0, M_3 < 0, ...$) y todos sus autovalores son estrictamente negativos. La función se curva hacia abajo en forma de cúpula.
- **Semidefinida negativa** ($\nabla^2 f(x) \preceq 0$): Si $z^T \nabla^2 f(x) z \leq 0$ para todo vector z. Todos sus autovalores son no positivos y todos sus menores principales alternan de signo de forma no estricta o son nulos.
- **Indefinida**: Si existen autovalores estrictamente positivos y negativos. El punto crítico resultante constituye un **punto de silla** (con direcciones de subida y direcciones de bajada).

Ejemplos: Clasificación de matrices

1. **Matriz Definida Positiva**: Sea la matriz:

$$A_1 = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}$$

Sus menores principales son:

$$M_1 = |2| = 2 > 0 \qquad \text{y} \qquad M_2 = \det(A_1) = 4 - 1 = 3 > 0$$

Al ser ambos menores principales estrictamente positivos, se tiene que $A_1 \succ 0$.

Resolviendo el polinomio característico:

$$\det(A_1 - \lambda I) = (2 - \lambda)^2 - 1 = 0 \implies \lambda^2 - 4\lambda + 3 = 0$$

obtenemos los autovalores $\lambda_1 = 3$ y $\lambda_2 = 1$, los cuales confirman que es definida positiva.

2. **Matriz Indefinida**: Sea la matriz:

$$A_2 = \begin{pmatrix} 1 & 2 \\ 2 & 1 \end{pmatrix}$$

Sus menores principales son:

$$M_1 = |1| = 1 > 0 \qquad \text{y} \qquad M_2 = \det(A_2) = 1 - 4 = -3 < 0$$

Dado que el determinante de segundo orden es negativo, la matriz es indefinida.

Resolviendo el polinomio característico:

$$\det(A_2 - \lambda I) = (1-\lambda)^2 - 4 = 0 \implies \lambda^2 - 2\lambda - 3 = 0$$

hallamos los autovalores $\lambda_1 = 3$ (positivo) y $\lambda_2 = -1$ (negativo), lo que ratifica el carácter indefinido.

3. **Matriz Semidefinida Positiva**: Sea la matriz:

$$A_3 = \begin{pmatrix} 2 & -3 & -1 \\ -3 & 12 & 6 \\ -1 & 6 & 3.2 \end{pmatrix}$$

Sus menores principales de primer y segundo orden son:

$$M_1 = |2| = 2 > 0 \qquad \text{y} \qquad M_2 = 24 - 9 = 15 > 0$$

y su determinante (menor principal de tercer orden):

$$M_3 = \det(A_3) = 2(38.4 - 36) + 3(-9.6 + 6) - 1(-18 + 12) = 4.8 - 10.8 + 6 = 0$$

Al ser todos los menores principales no negativos y el determinante nulo, la matriz es semidefinida positiva y singular. Sus autovalores son $\lambda_1 \approx 15.75$, $\lambda_2 \approx 1.45$, y $\lambda_3 = 0$, confirmando la semidefinición ($A_3 \succeq 0$).

2.3.3. Condiciones de optimalidad y puntos estacionarios

Las condiciones diferenciales para determinar extremos locales se enuncian en el siguiente teorema.

Teorema: Condiciones de optimalidad de segundo orden

Sea $f : \mathbb{R}^n \to \mathbb{R}$ una función diferenciable de clase $\mathcal{C}^2$:

1. **Condición Necesaria de Primer Orden (FONC)**: Si x^* es un mínimo local, entonces el gradiente de la función se anula en dicho punto:

   $$\nabla f(x^*) = 0$$

   Cualquier punto que verifique esta condición se denomina **punto estacionario** o punto crítico.
2. **Condición Necesaria de Segundo Orden (SONC)**: Si x^* es un mínimo local, entonces además de cumplirse la FONC, la matriz hessiana en dicho punto es semidefinida positiva:

   $$\nabla^2 f(x^*) \succeq 0$$
3. **Condición Suficiente de Segundo Orden (SOSC)**: Si un punto x^* satisface simultáneamente que:

   $$\nabla f(x^*) = 0 \qquad \text{y} \qquad \nabla^2 f(x^*) \succ 0$$

   Entonces x^* es un **mínimo local estricto** de la función.

Importancia de la definición positiva en SOSC

Es fundamental notar que en la condición suficiente (SOSC), la matriz hessiana debe ser **estrictamente definida positiva** ($\nabla^2 f(x^*) \succ 0$) y no simplemente semidefinida positiva. Si la hessiana es semidefinida con algún autovalor nulo (por ejemplo, en la función $f(x) = x^4$ en el origen $x^* = 0$, donde $f'(0) = 0$ y $f''(0) = 0 \succeq 0$), el análisis de segundo orden es insuficiente para garantizar analíticamente si el punto es un mínimo, un máximo o un punto de inflexión.

Ejemplos: Clasificación de puntos estacionarios

1. **Punto de Silla (Hessiana Indefinida)**: Sea la función:

   $$f(x, y) = \frac{1}{2}x^2 + 2xy + \frac{1}{2}y^2 - y + 9$$

   Su gradiente se obtiene derivando parcialmente respecto a cada variable:

   $$\nabla f(x, y) = \begin{pmatrix} x + 2y \\ 2x + y - 1 \end{pmatrix}$$

   Igualando el gradiente a cero, resolvemos el sistema de ecuaciones para hallar los

puntos críticos:

$$\begin{cases} x + 2y = 0 \implies x = -2y \\ 2x + y - 1 = 0 \implies 2(-2y) + y = 1 \implies -3y = 1 \implies y^* = -1/3 \end{cases}$$

sustituyendo, obtenemos el punto crítico único en $(x^*, y^*) = (2/3, -1/3)$.

La matriz hessiana de la función es:

$$\nabla^2 f(x, y) = \begin{pmatrix} 1 & 2 \\ 2 & 1 \end{pmatrix}$$

Calculamos sus menores principales para clasificarla:

$$M_1 = |1| = 1 > 0 \qquad \text{y} \qquad M_2 = \det(\nabla^2 f) = 1 - 4 = -3 < 0$$

Al ser el menor principal de segundo orden negativo ($M_2 < 0$), la matriz hessiana es indefinida. Por tanto, el punto crítico $(2/3, -1/3)$ constituye un **punto de silla**.

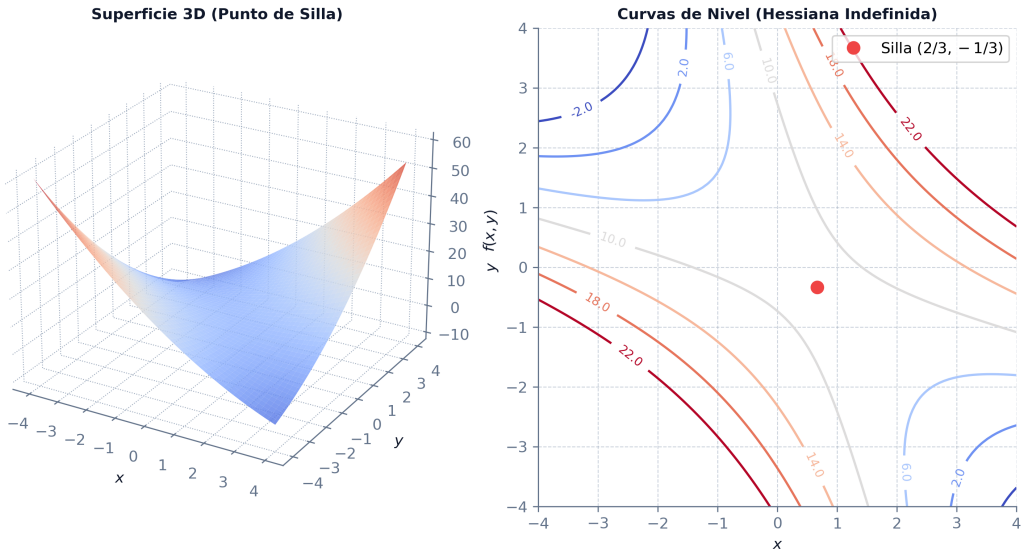

Figura 2.3: Representación 3D y curvas de nivel de un punto de silla (Hessiana indefinida)

2. **Mínimo Local Estricto Circular (Hessiana Definida Positiva)**: Sea la función que mide el cuadrado de la distancia al punto $(2, 1)$:

$$f(x, y) = (x - 2)^2 + (y - 1)^2$$

Su gradiente es:

$$\nabla f(x, y) = \begin{pmatrix} 2(x - 2) \\ 2(y - 1) \end{pmatrix}$$

Igualando a cero, el gradiente se anula únicamente en el punto crítico $(x^*, y^*) = (2, 1)$.

La matriz hessiana es constante y diagonal:

$$\nabla^2 f(x, y) = \begin{pmatrix} 2 & 0 \\ 0 & 2 \end{pmatrix}$$

Evaluamos los menores principales:

$$M_1 = 2 > 0 \qquad \text{y} \qquad M_2 = 4 > 0$$

Dado que ambos menores principales son estrictamente positivos, la matriz hessiana es definida positiva ($\nabla^2 f \succ 0$). Esto clasifica al punto crítico $(2, 1)$ como un **mínimo local estricto** (cuyas curvas de nivel son circunferencias concéntricas).

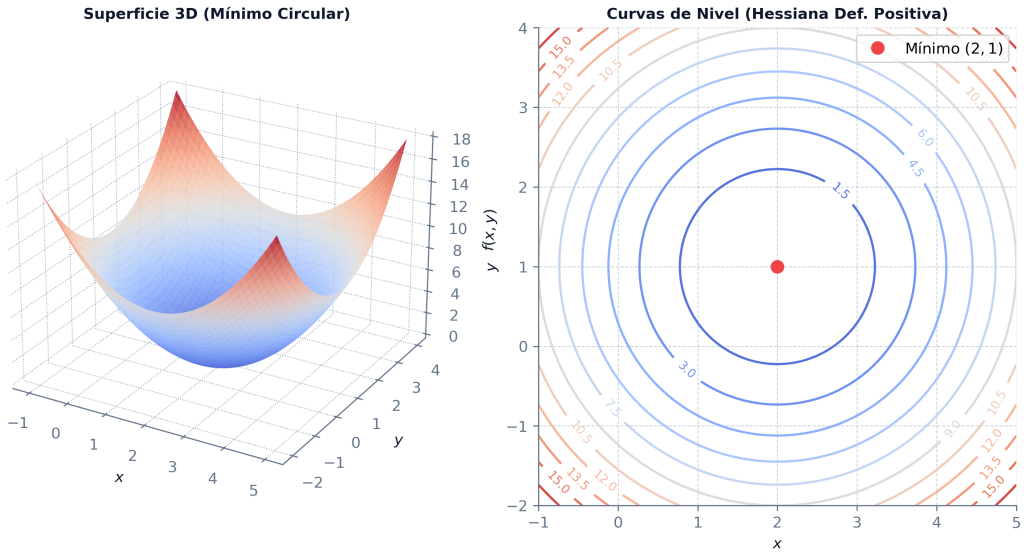

Figura 2.4: Representación 3D y curvas de nivel de un mínimo circular (Hessiana definida positiva)

3. **Mínimo Local Estricto Elíptico (Función Cuadrática Acoplada)**: Sea la función con término de acoplamiento cruzado:

$$f(x, y) = 8x^2 + 3xy + 7y^2 - 25x + 31y - 29$$

Su gradiente es:

$$\nabla f(x, y) = \begin{pmatrix} 16x + 3y - 25 \\ 3x + 14y + 31 \end{pmatrix}$$

Resolvemos el sistema lineal $\nabla f(x, y) = 0$:

$$\begin{pmatrix} 16 & 3 \\ 3 & 14 \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix} = \begin{pmatrix} 25 \\ -31 \end{pmatrix} \implies (x^*, y^*) \approx (2.060, -2.656)$$

La matriz hessiana es constante:

$$\nabla^2 f(x, y) = \begin{pmatrix} 16 & 3 \\ 3 & 14 \end{pmatrix}$$

Sus menores principales de primer y segundo orden son:

$$M_1 = 16 > 0 \qquad \text{y} \qquad M_2 = 16(14) - 3^2 = 224 - 9 = 215 > 0$$

Al ser ambos menores principales estrictamente positivos, la matriz es definida positiva ($\nabla^2 f \succ 0$). Esto confirma que el punto crítico $(2.060, -2.656)$ es un **mínimo local estricto** (con curvas de nivel elípticas inclinadas por efecto del acoplamiento).

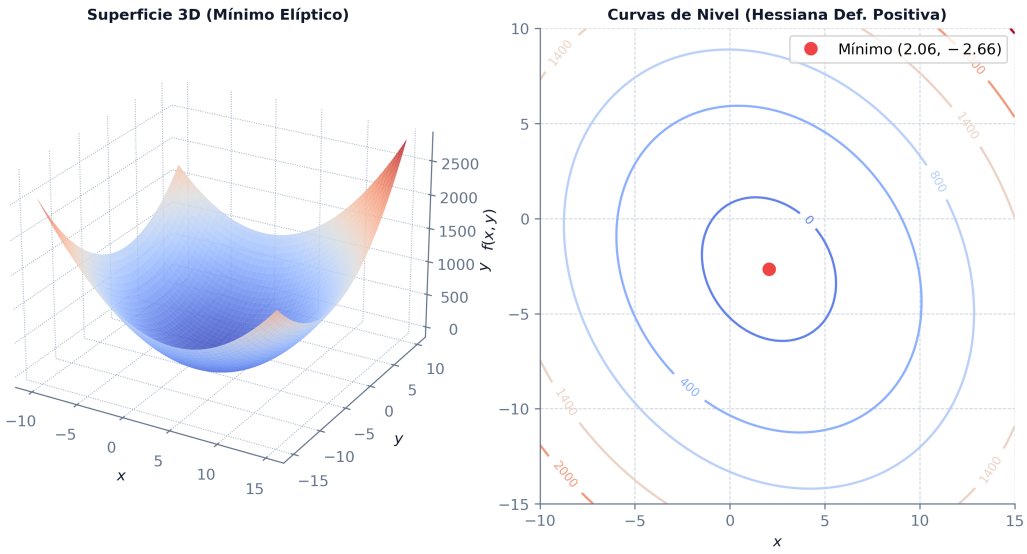

Figura 2.5: Representación 3D y curvas de nivel de un mínimo elíptico (Hessiana definida positiva)

2.4. Métodos de búsqueda unidimensional

Los métodos de búsqueda unidimensional buscan minimizar una función real de una variable $f : \mathbb{R} \to \mathbb{R}$ en un intervalo acotado $[a, b]$. Son fundamentales porque resolver problemas

multidimensionales complejos suele requerir resolver una sucesión de problemas unidimensionales a lo largo de direcciones de descenso: $\min_{\alpha>0} f(x_k + \alpha d_k)$.

A modo de ilustración de las trazas numéricas de los algoritmos 1D, utilizaremos como caso de prueba la minimización en el intervalo $[1, 4]$ de la función de cuarto grado:

$$f(x) = \frac{1}{4}x^4 - \frac{13}{3}x^3 + 27x^2 - 72x + 1$$

cuyo gráfico y mínimo global en $x^* = 3.0$ se muestran en la Figura 2.6.

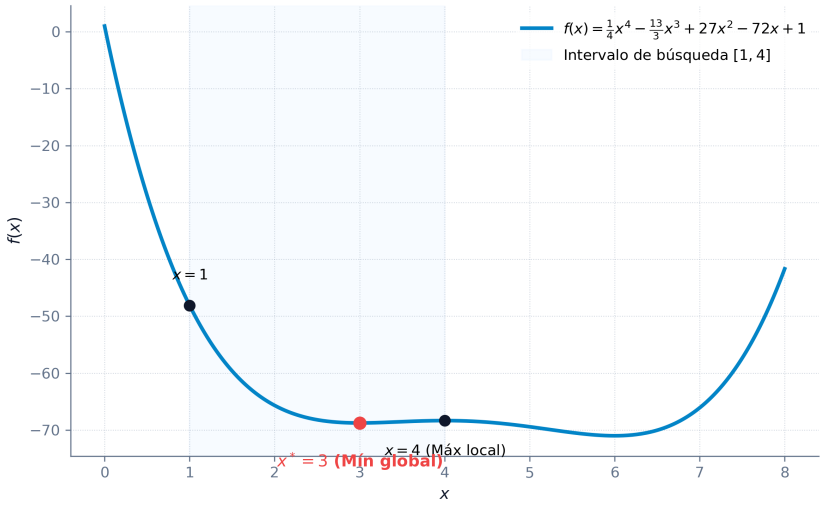

Figura 2.6: Caso de prueba para métodos de búsqueda 1D: función de cuarto grado y su mínimo global

2.4.1. Métodos sin derivadas

Estos métodos solo requieren evaluar el valor de la función objetivo. Exigen que la función sea **unimodal** en el intervalo $[a, b]$, es decir, que posea un único mínimo local en dicho intervalo, decreciendo de forma monótona a la izquierda del mínimo y creciendo a su derecha.

La **Búsqueda Uniforme (Rejilla)** consiste en dividir el intervalo inicial $[a, b]$ en n subintervalos de igual anchura mediante una rejilla equidistante de puntos.

Formalmente, los puntos se definen como:

$$x_k = a + k \cdot \frac{b-a}{n}, \quad k = 0, 1, \dots, n$$

Evaluamos la función en todos los puntos de la rejilla para identificar el punto mínimo:

$$k^* = \arg \min_{k \in \{0,\dots,n\}} f(x_k)$$

y reducimos el intervalo de incertidumbre al subintervalo adyacente que rodea al óptimo muestreado:

$$[a', b'] = [x_{k^*-1}, x_{k^*+1}]$$

Aunque es un método muy robusto, resulta poco eficiente debido a que no aprovecha la información de las evaluaciones previas (ver la Figura 2.7).

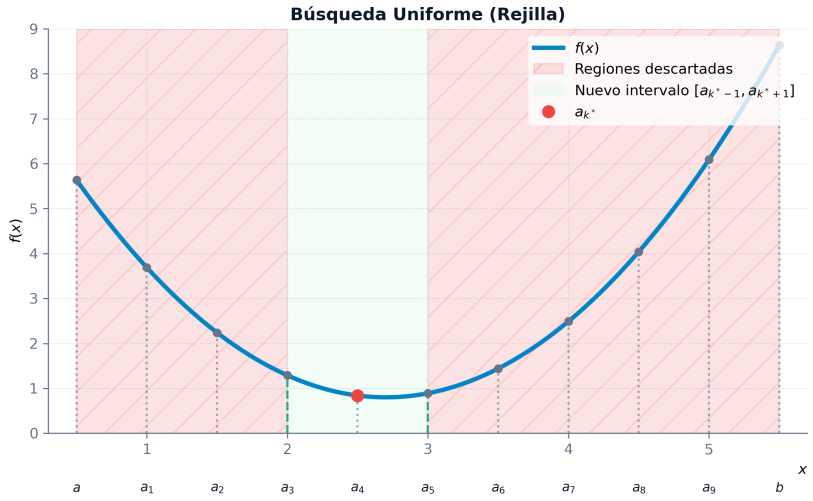

Figura 2.7: Concepto de la Búsqueda Uniforme en rejilla: subdivisión equidistante del intervalo y reducción basada en el punto mínimo de la muestra

La **Búsqueda Dicotómica** evalúa la función en el entorno del punto medio del intervalo actual. Bajo la hipótesis de unimodalidad, si únicamente evaluásemos la función en el punto medio exacto c, no tendríamos suficiente información para comparar y deducir si el mínimo está a la izquierda o a la derecha (ver Figura 2.8).

Para resolver esto, calculamos en cada iteración k dos puntos simétricos respecto al punto medio, separados por una perturbación infinitesimal $\delta > 0$:

$$\lambda_k = \frac{a_k + b_k}{2} - \delta \qquad \mu_k = \frac{a_k + b_k}{2} + \delta$$

Comparamos sus valores para actualizar el intervalo:

- Si $f(\lambda_k) < f(\mu_k) \implies$ descartamos $[\mu_k, b_k]$, y el nuevo intervalo es $[a_{k+1}, b_{k+1}] = [a_k, \mu_k]$.
- Si $f(\lambda_k) > f(\mu_k) \implies$ descartamos $[a_k, \lambda_k]$, y el nuevo intervalo es $[a_{k+1}, b_{k+1}] = [\lambda_k, b_k]$.

La amplitud del nuevo intervalo viene dada por la ecuación:

$$I_{k+1} = \frac{b_k - a_k}{2} + \delta$$

Cada paso reduce el intervalo de incertidumbre a la mitad más la perturbación ($I_{k+1} \approx \frac{1}{2} I_k$).

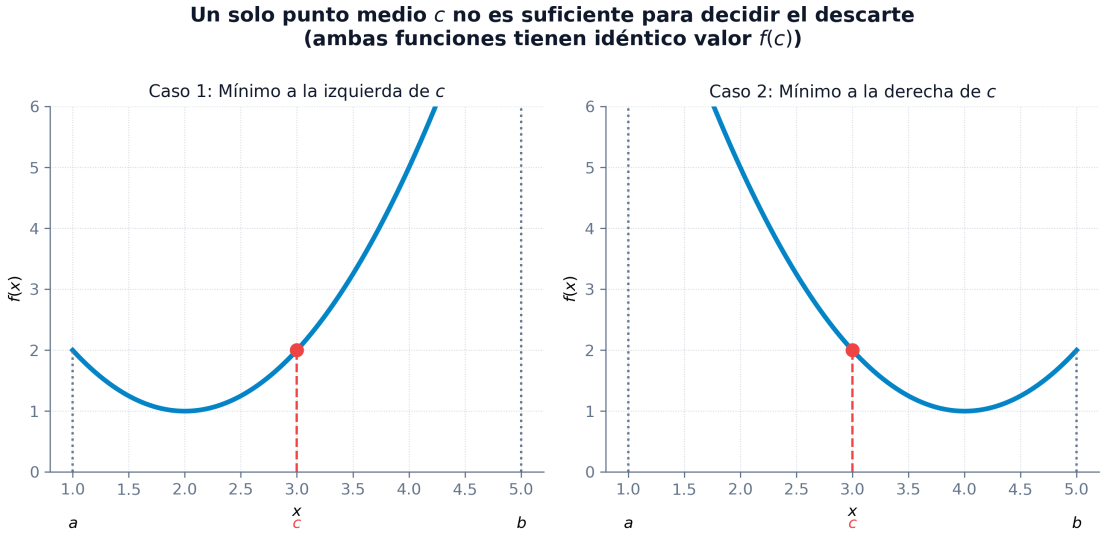

Figura 2.8: Insuficiencia de evaluar un único punto medio: dos funciones unimodales diferentes pueden tener idéntico valor en c teniendo sus mínimos globales en lados opuestos

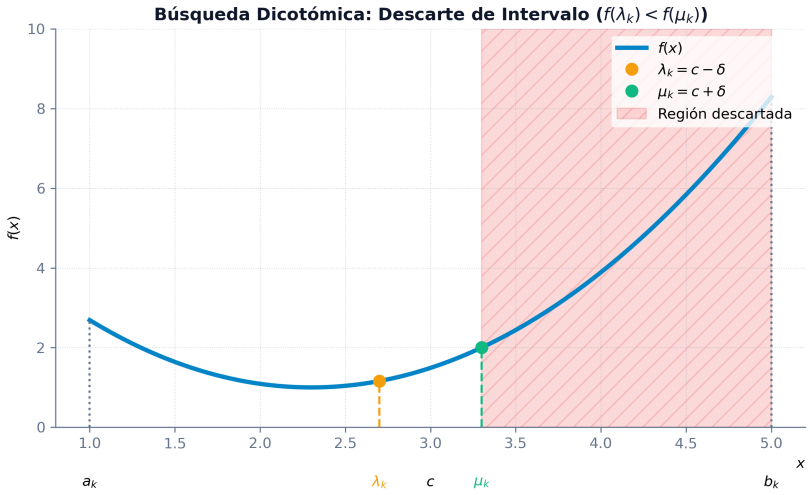

Figura 2.9: Concepto de la Búsqueda Dicotómica: la comparación de λ_k y μ_k descarta con certeza una de las mitades del intervalo

Ejemplo: Búsqueda dicotómica

Minimizamos en el intervalo $[1, 4]$ la función de cuarto grado $f(x) = \frac{1}{4}x^4 - \frac{13}{3}x^3 + 27x^2 - 72x + 1$ con perturbación $\delta = 0.02$ y tolerancia $\epsilon = 0.15$:

- **Paso 1**: Intervalo $[a_0, b_0] = [1, 4]$. Punto medio $c = 2.5$.
  - Cálculo de puntos internos:
$$\lambda_0 = \frac{1+4}{2} - 0.02 = 2.48 \qquad \mu_0 = \frac{1+4}{2} + 0.02 = 2.52$$
  - Evaluaciones correspondientes:
$$f(2.48) \approx -68.1386 \qquad f(2.52) \approx -68.2437$$
  - Como $f(\lambda_0) > f(\mu_0)$, descartamos la porción izquierda $[1, 2.48]$. Nuevo intervalo: $[a_1, b_1] = [2.48, 4]$.
- **Paso 2**: Intervalo $[a_1, b_1] = [2.48, 4]$. Punto medio $c = 3.24$.
  - Cálculo de puntos internos:
$$\lambda_1 = \frac{2.48+4}{2} - 0.02 = 3.22 \qquad \mu_1 = \frac{2.48+4}{2} + 0.02 = 3.26$$
  - Evaluaciones correspondientes:
$$f(3.22) \approx -68.6910 \qquad f(3.26) \approx -68.6709$$
  - Como $f(\lambda_1) < f(\mu_1)$, descartamos la porción derecha $[3.26, 4]$. Nuevo intervalo: $[a_2, b_2] = [2.48, 3.26]$.
- **Paso 3**: Intervalo $[a_2, b_2] = [2.48, 3.26]$. Punto medio $c = 2.87$.
  - Cálculo de puntos internos:
$$\lambda_2 = \frac{2.48+3.26}{2} - 0.02 = 2.85 \qquad \mu_2 = \frac{2.48+3.26}{2} + 0.02 = 2.89$$
  - Evaluaciones correspondientes:
$$f(2.85) \approx -68.7116 \qquad f(2.89) \approx -68.7300$$
  - Como $f(\lambda_2) > f(\mu_2)$, descartamos la porción izquierda $[2.48, 2.85]$. Nuevo intervalo: $[a_3, b_3] = [2.85, 3.26]$.
- **Pasos siguientes**: El proceso continúa evaluando de forma pareada. En el paso 5, el intervalo se reduce a $[2.9425, 3.075]$ con amplitud $0.1325 \leq 0.15$, finalizando el algoritmo.

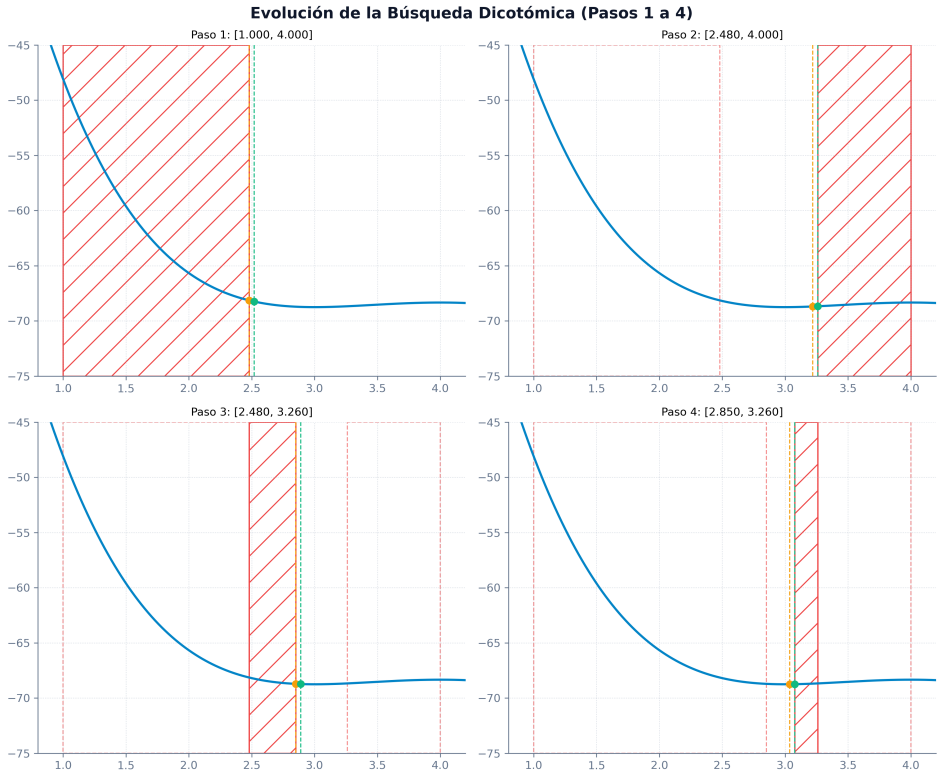

Figura 2.10: Evolución del intervalo en la Búsqueda Dicotómica (Pasos 1 a 4)

La **Sección Áurea (Golden Section)** optimiza la búsqueda dicotómica reduciendo a la mitad el número de evaluaciones necesarias en cada paso. Esto se logra colocando los puntos internos λ_k y μ_k de tal forma que uno de ellos coincida exactamente con un punto evaluado en la iteración anterior, requiriendo solo una nueva evaluación por iteración a partir de la segunda.

Para deducir la razón áurea $\alpha > 1$, consideremos la proporción constante entre la amplitud de intervalos consecutivos:

$$I_k = \alpha \cdot I_{k+1} \qquad I_{k+1} = \alpha \cdot I_{k+2} \implies I_k = \alpha^2 \cdot I_{k+2}$$

Dado que los puntos se sitúan de manera simétrica, la longitud total del intervalo actual I_k es la suma de los dos posibles subintervalos sucesivos I_{k+1} y I_{k+2}:

$$I_k = I_{k+1} + I_{k+2}$$

Sustituyendo las relaciones de escala constante obtenemos:

$$\alpha^2 \cdot I_{k+2} = \alpha \cdot I_{k+2} + I_{k+2} \iff \alpha^2 - \alpha - 1 = 0$$

Tomando la solución positiva de esta ecuación cuadrática obtenemos el **número áureo**:

$$\alpha = \frac{1+\sqrt{5}}{2} \approx 1.618033988$$

Los puntos de evaluación en cada iteración k sobre el intervalo $[a_k, b_k]$ se calculan como:

$$\lambda_k = b_k - \frac{b_k - a_k}{\alpha} \qquad \mu_k = a_k + \frac{b_k - a_k}{\alpha}$$

La amplitud decrece en cada paso por un factor de $1/\alpha \approx 0.618$. Dada una tolerancia $\epsilon > 0$ y amplitud inicial $I_0 = b - a$, el número total de iteraciones N viene dado por:

$$N = \left\lceil \frac{\ln(I_0) - \ln(\epsilon)}{\ln(\alpha)} \right\rceil$$

Ejemplo: Sección áurea

Minimizamos en el intervalo $[1, 4]$ la función $f(x) = \frac{1}{4}x^4 - \frac{13}{3}x^3 + 27x^2 - 72x + 1$ con tolerancia $\epsilon = 0.15$. El número de iteraciones requerido es $N = \lceil (\ln(3.0) - \ln(0.15))/\ln(1.61803) \rceil = 7$.

- **Paso 1**: Intervalo inicial $[a_0, b_0] = [1, 4]$. Amplitud teórica $I_1 = 3.0/1.61803 \approx 1.8541$.
  - Cálculo de puntos y evaluaciones:

$$\lambda_0 = 4 - 1.8541 = 2.1459 \implies f(2.1459) \approx -66.692$$

$$\mu_0 = 1 + 1.8541 = 2.8541 \implies f(2.8541) \approx -68.714$$

  - Como $f(\lambda_0) > f(\mu_0)$, descartamos la porción izquierda $[1, 2.1459]$. Nuevo intervalo: $[a_1, b_1] = [2.1459, 4]$.
- **Paso 2**: Intervalo $[a_1, b_1] = [2.1459, 4]$. Amplitud $I_2 = 1.8541/1.61803 \approx 1.1459$.
  - Reutilizamos el punto interior evaluado previamente:

$$\lambda_1 = \mu_0 = 2.8541 \implies f(2.8541) \approx -68.714$$

  - Calculamos únicamente el nuevo punto y su evaluación:

$$\mu_1 = 2.1459 + 1.1459 = 3.2918 \implies f(3.2918) \approx -68.654$$

  - Como $f(\lambda_1) < f(\mu_1)$, descartamos la derecha $[3.2918, 4]$. Nuevo intervalo: $[a_2, b_2] = [2.1459, 3.2918]$.

- **Paso 3**: Intervalo $[a_2, b_2] = [2.1459, 3.2918]$. Amplitud $I_3 = 1.1459/1.61803 \approx 0.7082$.
  - Reutilizamos el punto interior:

$$\mu_2 = \lambda_1 = 2.8541 \implies f(2.8541) \approx -68.714$$

  - Calculamos el nuevo punto:

$$\lambda_2 = 3.2918 - 0.7082 = 2.5836 \implies f(2.5836) \approx -68.3861$$

  - Como $f(\lambda_2) > f(\mu_2)$, descartamos la izquierda $[2.1459, 2.5836]$. Nuevo intervalo: $[a_3, b_3] = [2.5836, 3.2918]$.
- **Pasos siguientes**: El algoritmo continúa reutilizando evaluaciones previas de forma simétrica. En el paso 7, la amplitud alcanza $0.1033 \leq 0.15$ convergiendo al intervalo final $[2.9574, 3.0608]$, el cual contiene el mínimo analítico en $x^* = 3.0$.

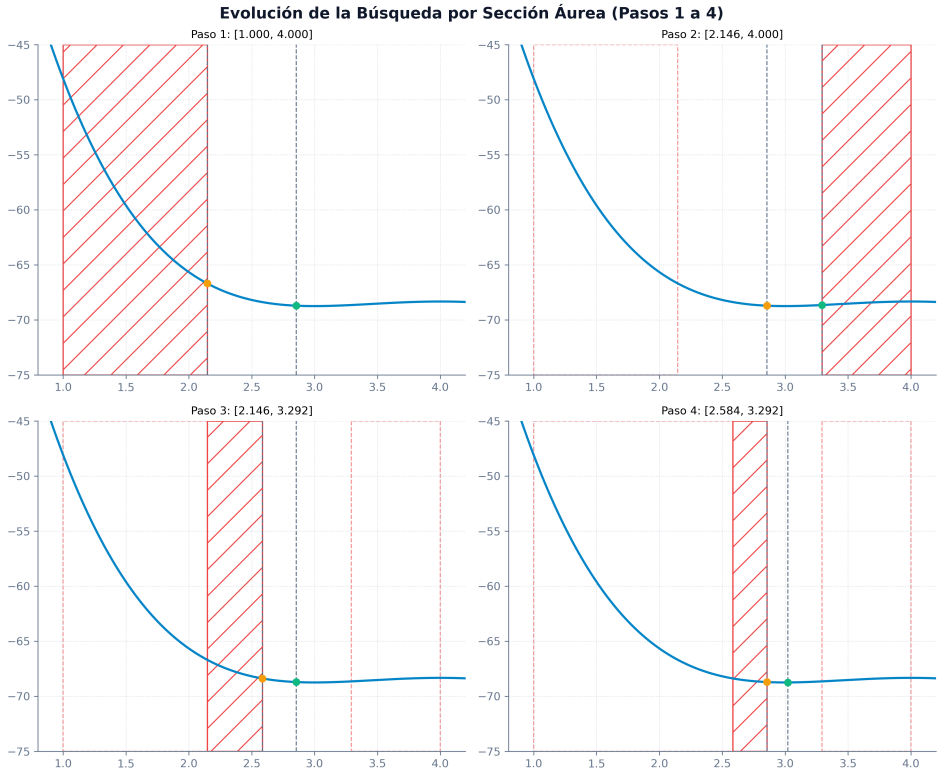

Figura 2.11: Evolución del intervalo en la búsqueda por Sección Áurea (Pasos 1 a 4)

La **Búsqueda de Fibonacci** optimiza teóricamente la sección áurea si se fija de antemano el número total de evaluaciones de la función N. Utiliza los términos de la sucesión de Fibonacci (F_i, donde $F_0 = 1, F_1 = 1, F_2 = 2, F_3 = 3, F_4 = 5, F_5 = 8, F_6 = 13, F_7 = 21, ...$ definidos por recurrencia $F_i = F_{i-1} + F_{i-2}$) para calcular la amplitud del paso en cada iteración k:

$$I_k = \frac{F_{N-k}}{F_{N-k+2}}(b_{k-1} - a_{k-1})$$

A partir de estas amplitudes, los puntos de evaluación se definen en la iteración k de la forma:

$$\mu_k = a_k + \frac{F_{N-k}}{F_{N-k+1}}(b_k - a_k) \qquad \lambda_k = a_k + \frac{F_{N-k-1}}{F_{N-k+1}}(b_k - a_k)$$

Al igual que en la Sección Áurea, las amplitudes de intervalos sucesivos guardan la relación de suma $I_{k-1} = I_k + I_{k+1}$, lo que permite reutilizar un punto evaluado en cada iteración. En el paso final $k = N - 1$, ambos puntos coinciden en el centro del intervalo, requiriendo introducir una pequeña perturbación $\epsilon_0 > 0$ para poder tomar la decisión de descarte definitiva. Aunque Fibonacci proporciona la máxima reducción matemática en un número de pasos fijo, la Sección Áurea es preferible habitualmente porque no requiere predeterminar N ni almacenar o calcular la sucesión de Fibonacci.

Ejemplo: Búsqueda de Fibonacci

Minimizamos la misma función en $[1, 4]$ con tolerancia $\epsilon = 0.15$ fijando un número total de evaluaciones $N = 6$ (usando $F_7 = 21$).

- **Paso 1**: Intervalo inicial $[a_0, b_0] = [1, 4]$.
  - Amplitud teórica del paso:

$$I_1 = \frac{F_6}{F_7}(b_0 - a_0) = \frac{13}{21} \cdot 3.0 \approx 1.8571$$

  - Cálculo de puntos y evaluaciones:

$$\lambda_0 = 4 - 1.8571 = 2.1429 \implies f(2.1429) \approx -66.673$$

$$\mu_0 = 1 + 1.8571 = 2.8571 \implies f(2.8571) \approx -68.715$$

  - Como $f(\lambda_0) > f(\mu_0)$, descartamos la porción izquierda $[1, 2.1429]$. Nuevo intervalo: $[a_1, b_1] = [2.1429, 4]$.
- **Paso 2**: Intervalo $[a_1, b_1] = [2.1429, 4]$.
  - Amplitud teórica:

$$I_2 = \frac{F_5}{F_7}(b_0 - a_0) = \frac{8}{21} \cdot 3.0 \approx 1.1429$$

- Reutilizamos el punto evaluado previamente:

$$\lambda_1 = \mu_0 = 2.8571 \implies f(2.8571) \approx -68.715$$

- Calculamos el nuevo punto y su evaluación:

$$\mu_1 = 2.1429 + 1.1429 = 3.2857 \implies f(3.2857) \approx -68.657$$

- Como $f(\lambda_1) < f(\mu_1)$, descartamos la derecha $[3.2857, 4]$. Nuevo intervalo: $[a_2, b_2] = [2.1429, 3.2857]$.

- **Pasos siguientes**: Continuando con el proceso de reducción mediante los cocientes de Fibonacci, en la iteración 6 (última) la amplitud del intervalo alcanza $I_6 = 0.1429 \leq 0.15$, logrando converger en el intervalo final $[2.8541, 3.001]$ con una iteración menos que en la sección áurea gracias a fijar N de forma anticipada.

2.4.2. Métodos con derivadas

Los métodos con derivadas incorporan información analítica de las pendientes locales para acelerar significativamente la convergencia.

El **Método de Bisección (Bolzano)** se basa en buscar las raíces de la derivada de primer orden ($f'(x) = 0$). Exige que los signos de la derivada en los extremos del intervalo inicial $[a_0, b_0]$ sean opuestos ($f'(a_0) < 0$ y $f'(b_0) > 0$), lo que por el Teorema de Bolzano asegura la existencia de al menos un punto estacionario en el interior.

En cada iteración k, calculamos el punto medio:

$$c_k = \frac{a_k + b_k}{2}$$

y evaluamos el signo de la derivada en dicho punto:

- Si $f'(c_k) < 0 \implies$ actualizamos la cota izquierda: $[a_{k+1}, b_{k+1}] = [c_k, b_k]$.
- Si $f'(c_k) > 0 \implies$ actualizamos la cota derecha: $[a_{k+1}, b_{k+1}] = [a_k, c_k]$.
- Si $f'(c_k) = 0 \implies$ c_k es el punto óptimo exacto.

La amplitud del intervalo se reduce a la mitad exacta en cada paso:

$$I_{k+1} = \frac{b_k - a_k}{2}$$

El número de pasos n requeridos para alcanzar una tolerancia $\epsilon > 0$ es:

$$n = \left\lceil \frac{\ln(I_0) - \ln(\epsilon)}{\ln(2)} \right\rceil$$

Ejemplo: Método de bisección

Minimizamos en el intervalo $[1, 4]$ la función $f(x) = \frac{1}{4}x^4 - \frac{13}{3}x^3 + 27x^2 - 72x + 1$ con tolerancia $\epsilon = 0.15$. La primera derivada es $f'(x) = x^3 - 13x^2 + 54x - 72$.

- **Paso 1**: Intervalo inicial $[a_0, b_0] = [1, 4]$.
  - Calculamos el punto medio:
  $$c_0 = \frac{1+4}{2} = 2.5$$
  - Evaluamos la derivada en c_0:
  $$f'(2.5) = (2.5)^3 - 13(2.5)^2 + 54(2.5) - 72 = -2.6250 < 0$$
  - Como $f'(2.5) < 0$, descartamos la izquierda. Nuevo intervalo: $[a_1, b_1] = [2.5, 4]$.
- **Paso 2**: Intervalo $[a_1, b_1] = [2.5, 4]$.
  - Punto medio:
  $$c_1 = \frac{2.5+4}{2} = 3.25$$
  - Evaluamos la derivada en c_1:
  $$f'(3.25) = (3.25)^3 - 13(3.25)^2 + 54(3.25) - 72 = 0.5156 > 0$$
  - Como $f'(3.25) > 0$, descartamos la derecha. Nuevo intervalo: $[a_2, b_2] = [2.5, 3.25]$.
- **Paso 3**: Intervalo $[a_2, b_2] = [2.5, 3.25]$.
  - Punto medio:
  $$c_2 = \frac{2.5+3.25}{2} = 2.875$$
  - Evaluamos la derivada:
  $$f'(2.875) \approx -0.4395 < 0$$
  - Descartamos la izquierda. Nuevo intervalo: $[a_3, b_3] = [2.875, 3.25]$.
- **Pasos siguientes**: Continuando el proceso de subdivisión, en el paso 5 se obtiene el intervalo final $[2.96875, 3.0625]$ con amplitud $0.0938 \leq 0.15$, finalizando el algoritmo.

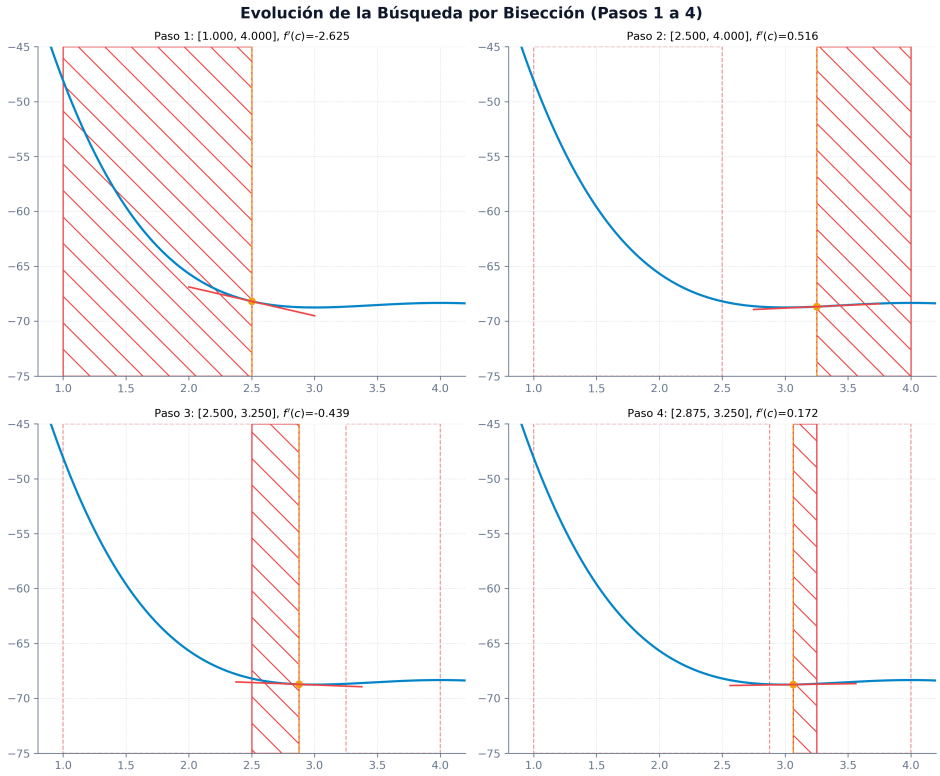

Figura 2.12: Evolución del intervalo en la búsqueda por Bisección (Pasos 1 a 4)

El **Método de Newton 1D** aproxima localmente la función objetivo en cada paso x_k mediante su polinomio cuadrático de Taylor de segundo orden:

$$q(x) = f(x_k) + f'(x_k)(x - x_k) + \frac{1}{2} f''(x_k)(x - x_k)^2$$

Para encontrar el mínimo de esta aproximación parabólica, igualamos su derivada a cero:

$$q'(x) = f'(x_k) + f''(x_k)(x - x_k) = 0 \implies x = x_k - \frac{f'(x_k)}{f''(x_k)}$$

Esto nos da la regla iterativa clásica de actualización del método:

$$x_{k+1} = x_k - \frac{f'(x_k)}{f''(x_k)}$$

Presenta una **convergencia cuadrática local** (orden 2), duplicando el número de dígitos significativos de precisión en cada paso cuando está cerca del óptimo. Exige calcular tanto $f'(x)$ como $f''(x)$ en cada paso, requiriendo que la función sea de clase $\mathcal{C}^2$ y que la curvatura sea estrictamente positiva ($f''(x_k) > 0$).

Ejemplo: Método de Newton 1D

Minimizamos en el intervalo $[1, 4]$ la misma función partiendo de $x_0 = 1.0$. Las derivadas son $f'(x) = x^3 - 13x^2 + 54x - 72$ y $f''(x) = 3x^2 - 26x + 54$.

- **Paso 1**: Partimos de $x_0 = 1.0$.
  - Evaluamos derivadas:

$$f'(1.0) = 1^3 - 13(1)^2 + 54(1) - 72 = -30.0$$

$$f''(1.0) = 3(1)^2 - 26(1) + 54 = 31.0$$

  - Actualización:

$$x_1 = 1.0 - \frac{-30.0}{31.0} \approx 1.9677$$

- **Paso 2**: Partimos del punto previo $x_1 = 1.9677$.
  - Evaluamos derivadas:

$$f'(1.9677) \approx -8.4589 \qquad f''(1.9677) \approx 14.4547$$

  - Actualización:

$$x_2 = 1.9677 - \frac{-8.4589}{14.4547} \approx 2.5529$$

- **Paso 3**: Partimos de $x_2 = 2.5529$.
  - Evaluamos derivadas:

$$f'(2.5529) \approx -2.2300 \qquad f''(2.5529) \approx 7.1760$$

  - Actualización:

$$x_3 = 2.5529 - \frac{-2.2300}{7.1760} \approx 2.8637$$

- **Pasos siguientes**: Aplicando de nuevo la fórmula se obtiene $x_4 \approx 2.9808$ y finalmente $x_5 \approx 2.9995 \approx 3.0$ logrando la convergencia óptima en solo 5 iteraciones.

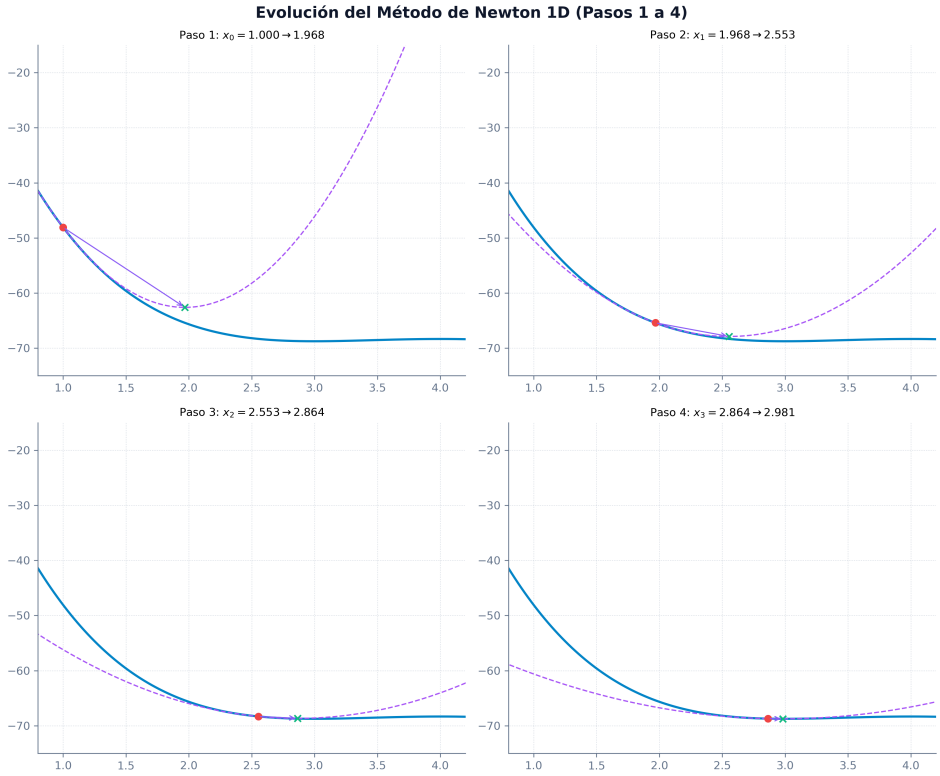

Figura 2.13: Aproximaciones cuadráticas en el método de Newton 1D (Pasos 1 a 4)

El **Método de la Secante** evita el inconveniente de calcular analíticamente la segunda derivada $f''(x)$ aproximándola numéricamente por diferencias finitas a partir de las pendientes de los dos últimos puntos evaluados:

$$f''(x_k) \approx \frac{f'(x_k) - f'(x_{k-1})}{x_k - x_{k-1}}$$

Sustituyendo esta aproximación en la fórmula de Newton, la regla iterativa de la secante se calcula como:

$$x_{k+1} = x_k - f'(x_k) \cdot \frac{x_k - x_{k-1}}{f'(x_k) - f'(x_{k-1})}$$

Este método ofrece una convergencia superlineal de orden ≈ 1.618 (la razón áurea) y requiere disponer de dos estimaciones iniciales para iniciar las iteraciones (x_0 y x_{-1}).

Ejemplo: Método de la secante

Minimizamos en el intervalo $[1, 4]$ la misma función partiendo de $x_{-1} = 1.0$ y $x_0 = 1.5$. La derivada es $f'(x) = x^3 - 13x^2 + 54x - 72$.

- **Paso 1**: Puntos iniciales $x_{-1} = 1.0$ y $x_0 = 1.5$.
  - Evaluamos la derivada en ambos puntos:

$$f'(1.0) = -30.0 \qquad f'(1.5) = -16.875$$

  - Aplicamos la regla de la secante:

$$x_1 = 1.5 - (-16.875) \cdot \frac{1.5 - 1.0}{-16.875 - (-30.0)} = 1.5 + 16.875 \cdot \frac{0.5}{13.125} \approx 2.1429$$

- **Paso 2**: Puntos $x_0 = 1.5$ y $x_1 = 2.1429$.
  - Evaluamos la derivada en el nuevo punto x_1:

$$f'(2.1429) \approx -6.1399$$

  - Aplicamos la regla de la secante:

$$x_2 = 2.1429 - (-6.1399) \cdot \frac{2.1429 - 1.5}{-6.1399 - (-16.875)} = 2.1429 + 6.1399 \cdot \frac{0.6429}{10.7351} \approx 2.5106$$

- **Pasos siguientes**: Aplicando iterativamente la secante obtenemos $x_3 \approx 2.7707$, $x_4 \approx 2.9157$, $x_5 \approx 2.9807$, y finalmente $x_7 \approx 2.9999 \approx 3.0$, convergiendo rápidamente al mínimo sin segundas derivadas.

2.5. Métodos multivariantes de optimización sin restricciones

Para minimizar funciones multivariantes $f : \mathbb{R}^n \to \mathbb{R}$ sin restricciones, construimos una sucesión iterativa a partir de una dirección de búsqueda d_k y un tamaño de paso $\alpha_k > 0$:

$$x_{k+1} = x_k + \alpha_k d_k$$

Para garantizar que el algoritmo avance reduciendo la función en cada paso, la dirección d_k debe ser de descenso, lo que exige matemáticamente que forme un ángulo obtuso con el gradiente de la función en el punto actual:

$$\nabla f(x_k)^T d_k < 0$$

Para ilustrar el funcionamiento de los algoritmos multivariantes, utilizaremos a lo largo del capítulo dos funciones de prueba representativas en $\mathbb{R}^2$:

1. **Función de distancia circular (desacoplada)**:

$$f(x, y) = (x - 2)^2 + (y - 1)^2$$

Su forma geométrica es la de un cuenco circular (paraboloide de revolución) con curvas de nivel perfectamente redondas, lo que facilita el comportamiento de los métodos por no existir acoplamiento cruzado (ver Figura 2.14a).

2. **Función cuadrática mal acondicionada (acoplada)**:

$$f(x, y) = 8x^2 + 3xy + 7y^2 - 25x + 31y - 29$$

Presenta curvas de nivel elípticas muy alargadas y un término cruzado $3xy$ que acopla las variables, simulando un problema de optimización realista de curvatura desigual (ver Figura 2.14b).

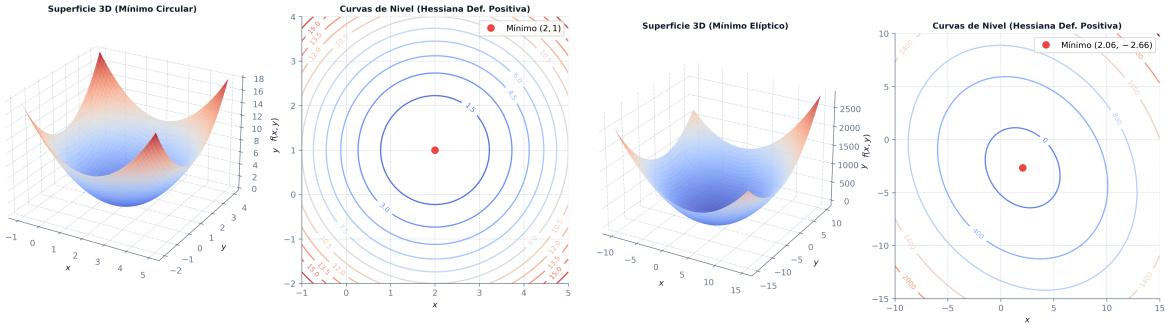

(a) Superficie 3D de la función de distancia circular desacoplada

(b) Superficie 3D de la función cuadrática acoplada

Figura 2.14: Superficies tridimensionales de las funciones de prueba en varias variables

2.5.1. Método de las coordenadas cíclicas

El **método de las coordenadas cíclicas** (o *coordinate descent*) es uno de los algoritmos de optimización multivariante más elementales e intuitivos. Su principal ventaja radica en que **evita por completo el cálculo de gradientes y matrices hessianas**, aplicando una estrategia de descomposición: en lugar de buscar la dirección óptima en el espacio multidimensional $\mathbb{R}^n$, descompone el problema en una sucesión ordenada de búsquedas unidimensionales a lo largo de los ejes coordenados.

El procedimiento explora de forma secuencial cada una de las variables de decisión, manteniendo fijas las restantes $n-1$. Las direcciones de búsqueda coinciden cíclicamente con los vectores de la base canónica de $\mathbb{R}^n$, definidos formalmente como $d_k = e_{(k \bmod n)+1}$, donde e_i es el i-ésimo vector unitario con un 1 en la posición i y ceros en las demás. El proceso se articula en tres etapas fundamentales:

1. **Paso unidimensional**: Estando en el punto iterado $x^{(k)}$, se selecciona el eje coordenado correspondiente y se resuelve un subproblema de optimización unidimensional restringido a esa única coordenada:

$$\min_{\alpha \in \mathbb{R}} \quad \phi(\alpha) = f(x^{(k)} + \alpha e_i)$$

Esta minimización escalar se resuelve de forma analítica igualando la derivada a cero si la función es elemental, o bien mediante los algoritmos de búsqueda unidimensional vistos anteriormente (como la Sección Áurea). Una vez obtenido el paso óptimo α^*, el punto se actualiza como $x^{(k+1)} = x^{(k)} + \alpha^* e_i$.

2. **Cierre de ciclo**: El procedimiento se repite variando sucesivamente la variable 1, luego la variable 2, y así sucesivamente hasta completar la variable n. A la realización sucesiva de estas n búsquedas unidimensionales ortogonales se le denomina **un ciclo**.

3. **Criterio de convergencia**: Tras completar un ciclo entero por todas las variables, se comprueba si el desplazamiento acumulado entre el punto inicial y el punto final del ciclo es inferior a una tolerancia prefijada:

$$\|x^{(k+n)} - x^{(k)}\| \leq \epsilon \quad \text{o bien} \quad |f(x^{(k+n)}) - f(x^{(k)})| \leq \epsilon$$

   Si se verifica la condición de parada, el algoritmo finaliza con éxito. En caso contrario, se inicia un nuevo ciclo comenzando nuevamente por la primera coordenada.

El rendimiento y velocidad de convergencia de este método depende críticamente de la estructura geométrica de la función y del acoplamiento entre sus variables:

- **Variables desacopladas**: Si la función no contiene términos de interacción cruzada entre variables y su matriz hessiana es diagonal, las curvas de nivel son circunferencias o elipses cuyos ejes principales son paralelos a los ejes coordenados. En este escenario ideal, el algoritmo alcanza el mínimo global exacto en un único ciclo de n pasos ortogonales.
- **Variables acopladas**: Cuando existen términos cruzados (como un término bilineal $x_i x_j$), las curvas de nivel elípticas aparecen rotadas respecto a los ejes canónicos. Como el algoritmo solo puede desplazarse en giros ortogonales de 90 grados paralelos a los ejes, se ve obligado a avanzar trazando una **trayectoria en escalera o zigzag**, requiriendo una gran cantidad de ciclos y pasos progresivamente más cortos para aproximarse al óptimo.

Ejemplo: Coordenadas cíclicas

- **Variables Desacopladas**: Minimizamos la función de distancia $f(x, y) = (x - 2)^2 + (y - 1)^2$ (ver Figura 2.15) partiendo de $x_0 = (0, 0)^T$.
  - *Paso 1*: Minimizamos respecto a x:

$$\min_x \quad f(x, 0) = (x - 2)^2 + 1 \implies x_1 = (2, 0)^T$$

  - *Paso 2*: Minimizamos respecto a y:

$$\min_y \quad f(2, y) = (y - 1)^2 \implies x_2 = (2, 1)^T$$

  Al no existir términos de acoplamiento cruzado entre las variables (la matriz hessiana es diagonal), el algoritmo localiza el mínimo exacto en una única iteración de $n = 2$ pasos ortogonales.

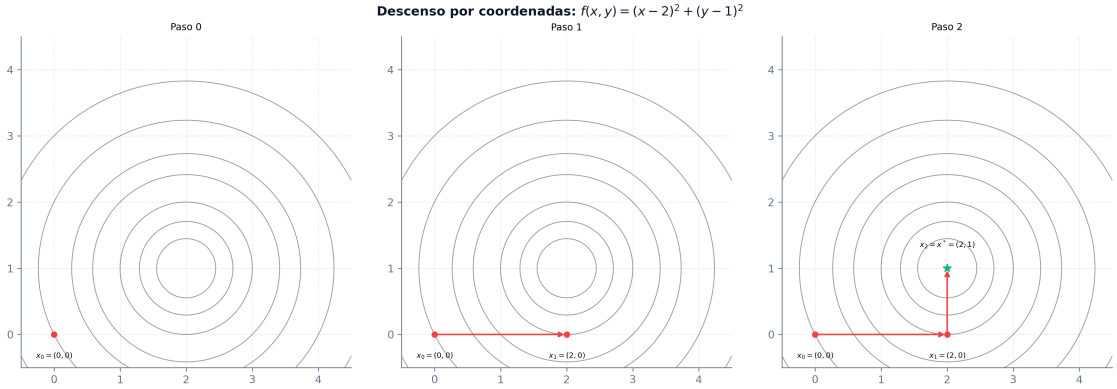

Figura 2.15: Descenso por coordenadas cíclicas: secuencia de pasos sobre curvas de nivel circulares

- **Variables Acopladas**: Minimizamos $f(x, y) = 8x^2 + 3xy + 7y^2 - 25x + 31y - 29$ (ver Figura 2.16) partiendo de $x_0 = (0, 0)^T$.
  - *Paso 1*: Minimizamos respecto a x:

$$\min_x \quad f(x, 0) = 8x^2 - 25x - 29 \implies 16x - 25 = 0 \implies x_1 = (1.5625, 0)^T$$

  - *Paso 2*: Minimizamos respecto a y manteniendo $x = 1.5625$:

$$\min_y \quad f(1.5625, y) = 7y^2 + 35.6875y + \text{ct} \implies 14y + 35.6875 = 0 \implies$$

$$y = -\frac{571}{224} \approx -2.5491$$

    Lo que resulta en el punto $x_2 = (1.5625, -2.5491)^T$.
  - *Paso 3*: Minimizamos de nuevo respecto a x con $y = -2.5491$:

$$\min_x \quad f(x, -2.5491) = 8x^2 - 32.6473x + \text{ct} \implies 16x - 32.6473 = 0 \implies$$

$$x_3 = (2.0405, -2.5491)^T$$

  Debido al acoplamiento bilineal inducido por el término $3xy$, la trayectoria dibuja un patrón de "escalera", requiriendo múltiples ciclos para aproximarse al mínimo global situado en $x^* = (2.060, -2.656)$.

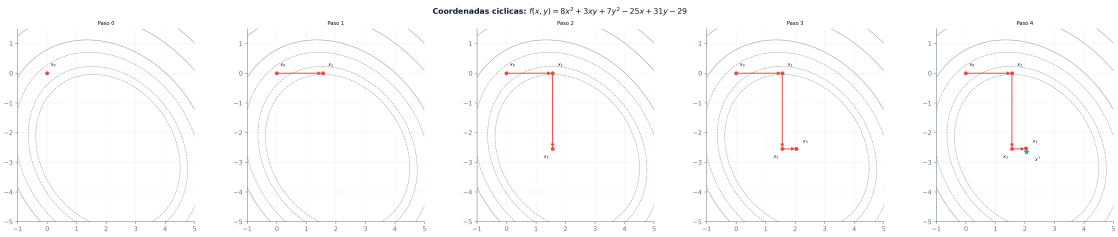

Figura 2.16: Trayectoria en escalera del descenso por coordenadas cíclicas sobre una función cuadrática acoplada

2.5.2. Método del máximo descenso

El **método del máximo descenso** (o *steepest descent* / gradiente descendente) es el algoritmo iterativo de primer orden fundamental en optimización continua. La dirección de búsqueda se define como aquella en la que la función objetivo decrece de manera más rápida a nivel local, dada por el opuesto del vector gradiente:

$$d_k = -\nabla f(x_k)$$

A partir del punto actual x_k, la actualización se realiza según la expresión $x_{k+1} = x_k + \alpha_k d_k$, donde $\alpha_k > 0$ representa la longitud del paso. En el esquema teórico de **búsqueda de línea exacta**, el tamaño de paso óptimo se determina minimizando la función unidimensional a lo largo del rayo de descenso:

$$\alpha_k = \arg\min_{\alpha>0} f(x_k - \alpha \nabla f(x_k))$$

En aplicaciones computacionales complejas donde evaluar la función de forma exhaustiva resulta prohibitivo, suele recurrirse a esquemas de **búsqueda de línea inexacta** (como las condiciones de Armijo o Wolfe), que garantizan una disminución suficiente del valor de la función sin exigir la localización exacta del mínimo unidimensional.

El algoritmo itera sucesivamente calculando la dirección opuesta al gradiente y actualizando el punto hasta satisfacer alguno de los siguientes **criterios de parada**:

- **Estacionariedad**: La norma del vector gradiente es inferior a una tolerancia prefijada, $\|\nabla f(x_k)\| \leq \epsilon_g$, lo que garantiza que nos encontramos en las proximidades de un punto crítico.
- **Estancamiento del paso**: El desplazamiento relativo o absoluto entre dos iteraciones consecutivas es despreciable, $\|x_{k+1} - x_k\| \leq \epsilon_x$.
- **Estancamiento de la función objetivo**: La reducción en el valor de la función objetivo cae por debajo del umbral mínimo, $|f(x_{k+1}) - f(x_k)| \leq \epsilon_f$.
- **Límite computacional**: Se alcanza un número máximo prefijado de iteraciones $k \geq K_{\text{máx}}$.

Una propiedad matemática de la búsqueda lineal exacta en el método de máximo descenso es que las direcciones de búsqueda en iteraciones consecutivas son estrictamente ortogonales entre sí:

$$d_k^T d_{k+1} = 0$$

Para demostrarlo, definimos la función unidimensional $\phi(\alpha) = f(x_k + \alpha d_k)$ que se minimiza para hallar α_k. La condición de óptimo exige que su derivada con respecto al tamaño de paso sea nula en α_k:

$$\phi'(\alpha_k) = \nabla f(x_k + \alpha_k d_k)^T d_k = 0$$

Dado que el nuevo punto es $x_{k+1} = x_k + \alpha_k d_k$, se tiene que $\nabla f(x_{k+1})^T d_k = 0$. Puesto que las direcciones consecutivas son proporcionales a los gradientes ($d_{k+1} = -\nabla f(x_{k+1})$ y $d_k = -\nabla f(x_k)$), se concluye de forma directa la ortogonalidad:

$$d_{k+1}^T d_k = 0$$

Esta ortogonalidad geométrica provoca que, si la función presenta curvas de nivel elípticas muy alargadas (lo que ocurre cuando la matriz hessiana está mal condicionada y existe una gran disparidad entre su autovalor máximo y mínimo, $\lambda_{\text{máx}} \gg \lambda_{\text{mín}}$), el algoritmo realice continuos giros de 90 grados, generando un patrón en **zigzag** que ralentiza sustancialmente la velocidad de convergencia hacia el óptimo, tal y como se observa en la Figura 2.17.

Ejemplo: Máximo descenso

Minimizamos $f(x, y) = 8x^2 + 3xy + 7y^2 - 25x + 31y - 29$ partiendo de $x_0 = (0, 0)^T$.

- **Gradiente en** x_0: Calculamos el gradiente de la función y lo evaluamos en el origen:

$$\nabla f(x_0) = \begin{pmatrix} 16x + 3y - 25 \\ 3x + 14y + 31 \end{pmatrix}_{x=(0,0)} = \begin{pmatrix} -25 \\ 31 \end{pmatrix}$$

  La dirección de descenso óptima es el gradiente negativo:

$$d_0 = -\nabla f(x_0) = \begin{pmatrix} 25 \\ -31 \end{pmatrix}$$

- **Búsqueda de línea exacta**: Minimizamos la función respecto al tamaño del paso α:

$$\phi(\alpha) = f(x_0 + \alpha d_0) = f(25\alpha, -31\alpha) = 9402\alpha^2 - 1586\alpha - 29$$

  Derivando e igualando a cero:

$$\phi'(\alpha) = 18804\alpha - 1586 = 0 \implies \alpha_0 = \frac{1586}{18804} \approx 0.0843$$

- **Actualización del punto**: El nuevo punto en la primera iteración es:

$$x_1 = x_0 + \alpha_0 d_0 = \begin{pmatrix} 0 \\ 0 \end{pmatrix} + 0.0843 \begin{pmatrix} 25 \\ -31 \end{pmatrix} = \begin{pmatrix} 2.109 \\ -2.615 \end{pmatrix}$$

El nuevo gradiente en x_1 es:

$$\nabla f(x_1) \approx \begin{pmatrix} 0.8925 \\ 0.7225 \end{pmatrix}$$

Verificamos la ortogonalidad respecto a la dirección de búsqueda anterior:

$$d_0^T \nabla f(x_1) = 25(0.8925) - 31(0.7225) \approx 0$$

Lo cual ilustra la ortogonalidad requerida por la búsqueda exacta.

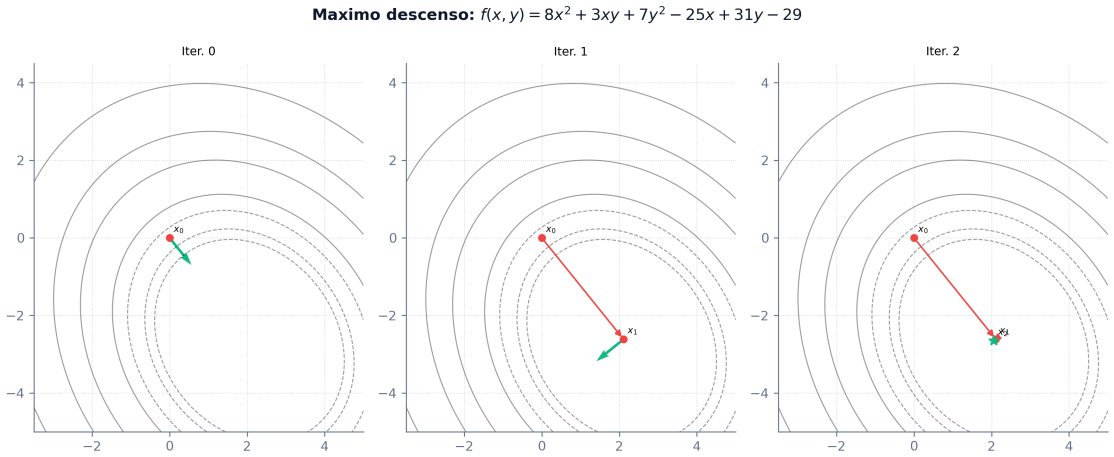

Figura 2.17: Máximo descenso: secuencia de iteraciones mostrando trayectoria ortogonal sobre las curvas de nivel elípticas

2.5.3. Métodos de Newton multivariante y BFGS

El **Método de Newton Multivariante** incorpora información de segundo orden sobre la curvatura de la superficie para acelerar drásticamente el proceso de convergencia. En lugar de limitarse a una aproximación lineal, aproxima la función objetivo en el entorno del punto actual x_k mediante su desarrollo cuadrático de Taylor:

$$m_k(p) = f(x_k) + \nabla f(x_k)^T p + \frac{1}{2} p^T \nabla^2 f(x_k) p$$

donde $p \in \mathbb{R}^n$ es el vector de desplazamiento. Para calcular el desplazamiento que minimiza este modelo cuadrático local, se iguala su gradiente a cero respecto a p:

$$\nabla_p m_k(p) = \nabla f(x_k) + \nabla^2 f(x_k)p = 0 \implies \nabla^2 f(x_k)p = -\nabla f(x_k)$$

Despejando el vector de dirección p, denominado **dirección de Newton** (d_k), y aplicando el paso al punto actual, se obtiene la regla de actualización clásica:

$$x_{k+1} = x_k - [\nabla^2 f(x_k)]^{-1} \nabla f(x_k)$$

Si la función objetivo es cuadrática y estrictamente convexa, el método de Newton localiza el mínimo global del sistema en una sola iteración desde cualquier punto inicial. Para funciones no lineales generales, presenta una **convergencia cuadrática local** (orden 2), lo que significa que el número de cifras significativas exactas prácticamente se duplica en cada iteración cuando se encuentra cerca de la solución.

En formulaciones prácticas, para evitar divergencias cuando la estimación inicial no es cercana al óptimo, se utiliza el **método de Newton amortiguado** (*damped Newton*), introduciendo un tamaño de paso α_k regulado por búsqueda lineal:

$$x_{k+1} = x_k - \alpha_k [\nabla^2 f(x_k)]^{-1} \nabla f(x_k)$$

A pesar de su velocidad de convergencia, el método de Newton puro presenta tres limitaciones importantes:

- **Coste computacional elevado**: En cada iteración se debe calcular analítica o numéricamente la matriz hessiana completa ($n(n+1)/2$ derivadas segundas) y resolver un sistema de ecuaciones lineales $n \times n$, lo que supone un coste computacional de $O(n^3)$ operaciones.
- **Exigencia de convexidad**: Requiere que la matriz hessiana $\nabla^2 f(x_k)$ sea estrictamente definida positiva en cada paso para garantizar que la dirección de Newton apunte en sentido de descenso. Si el algoritmo entra en una región cóncava o próxima a un punto de silla, la dirección puede orientarse hacia un máximo o perder la propiedad de descenso.
- **Convergencia puramente local**: La garantía formal de convergencia rápida solo es válida si el punto inicial x_0 se encuentra lo bastante próximo al punto óptimo.

Los **Métodos Cuasi-Newton (BFGS)** resuelven estas limitaciones de forma elegante. En lugar de evaluar y factorizar la matriz hessiana exacta en cada iteración, construyen secuencialmente una aproximación simétrica y definida positiva de la inversa de la hessiana, denotada por $H_k \approx [\nabla^2 f(x_k)]^{-1}$. Esta matriz se actualiza utilizando únicamente las variaciones de posiciones y de gradientes entre dos iteraciones consecutivas, imponiendo la **ecuación de la secante**:

$$H_{k+1} y_k = s_k$$

donde $s_k = x_{k+1} - x_k$ representa el desplazamiento del punto e $y_k = \nabla f(x_{k+1}) - \nabla f(x_k)$ cuantifica la variación del gradiente.

El algoritmo **BFGS** (desarrollado de forma independiente por Broyden, Fletcher, Goldfarb y Shanno) actualiza la matriz aproximada mediante la expresión:

$$H_{k+1} = (I - \rho_k s_k y_k^T) H_k (I - \rho_k y_k s_k^T) + \rho_k s_k s_k^T$$

donde $\rho_k = 1/(y_k^T s_k)$. Si el tamaño de paso en la búsqueda lineal satisface las condiciones de Wolfe, se garantiza matemáticamente que la matriz H_{k+1} se mantenga simétrica y estrictamente definida positiva, asegurando direcciones de descenso en cada paso. Este enfoque proporciona una tasa de **convergencia superlineal** con un coste computacional de tan solo $O(n^2)$ operaciones por iteración (Nocedal y Wright 2006; Luenberger y Ye 2015).

Para sintetizar la progresión conceptual de los métodos multivariantes sin restricciones estudiados en este tema, la siguiente tabla compara sus rasgos operativos y computacionales:

Algoritmo	Orden y datos requeridos	Coste por paso	Tasa de convergencia	Requisitos de curvatura y robustez
Coordenadas Cíclicas	Orden 0 (solo evalúa $f(x)$)	$O(n)$ búsquedas 1D	Lenta (sublineal)	No requiere derivadas; vulnerable a acoplamiento cruzado
Máximo Descenso	Orden 1 ($f(x)$ y gradiente ∇f)	$O(n)$ más búsqueda 1D	Lineal	Muy robusto con búsqueda lineal; sufre zigzag en elipses alargadas
Newton Clásico	Orden 2 ($f, \nabla f$ y hessiana $\nabla^2 f$)	$O(n^3)$ (sistema lineal)	Cuadrática (local)	Muy rápido cerca del óptimo; exige hessiana definida positiva
Cuasi-Newton (BFGS)	Orden 1 ($f(x)$ y gradientes sucesivos)	$O(n^2)$ (álgebra matricial)	Superlineal	Excelente equilibrio práctico; preserva siempre definida positiva

3 Análisis convexo

El **análisis convexo** constituye la columna vertebral de la optimización matemática moderna. Históricamente, la optimización estuvo dominada por el paradigma de la linealidad frente a la no linealidad. Sin embargo, a finales del siglo XX se produjo un cambio de paradigma fundamental, resumido por el matemático R. Tyrrell Rockafellar: *"la divisoria fundamental en optimización no es entre linealidad y no linealidad, sino entre convexidad y no convexidad"* (Rockafellar 1970). Bajo la hipótesis de convexidad, cualquier óptimo local se convierte de manera natural en un óptimo global (Boyd y Vandenberghe 2004). Esta propiedad crucial no solo simplifica la búsqueda teórica de soluciones, sino que garantiza la convergencia fiable y veloz de los algoritmos numéricos, evitando que queden atrapados en mínimos locales subóptimos.

En este capítulo, estudiaremos los conjuntos convexos y las operaciones que preservan esta propiedad, las caracterizaciones de primer y segundo orden para funciones convexas diferenciables y no diferenciables (subgradientes), las propiedades fundamentales de sus extremos y las generalizaciones teóricas de la convexidad (cuasi-convexidad y pseudo-convexidad).

! Objetivos de aprendizaje

Al finalizar este capítulo, serás capaz de:

1. **Identificar y demostrar** si un conjunto dado en $\mathbb{R}^n$ es convexo aplicando la definición o las propiedades algebraicas de conservación.
2. **Diferenciar** entre combinaciones lineales, afines, cónicas y convexas, analizando la estructura geométrica de sus envolturas.
3. **Comprender e interpretar** los Teoremas de Separación de Hiperplanos y del Hiperplano de Soporte.
4. **Caracterizar la convexidad de funciones** mediante las propiedades del epigrafo, los conjuntos de nivel y las caracterizaciones de primer y segundo orden (gradiente y hessiana).
5. **Calcular el subdiferencial** de funciones convexas no diferenciables en puntos singulares de esquina o codo, y aplicar el cálculo de subgradientes.
6. **Aplicar el Teorema Fundamental de la Optimización Convexa** para deconstruir y verificar la globalidad y unicidad de los mínimos.
7. **Clasificar y relacionar** las funciones cuasi-convexas, pseudo-convexas y sus variantes, comprendiendo sus implicaciones en la optimización restringida.

3.1. Conjuntos convexos

El estudio de la convexidad se inicia con la caracterización geométrica de los conjuntos sobre los que se definen los problemas de optimización. Intuitivamente, un conjunto es convexo si no presenta "entrantes" o cavidades, de modo que la conexión recta entre cualquier pareja de sus puntos está totalmente contenida en él, tal y como se ilustra en la Figura 3.1.

Formalmente, definimos un **conjunto convexo** $\mathcal{S} \subseteq \mathbb{R}^n$ como aquel que cumple que, para todo par de puntos $x_1, x_2 \in \mathcal{S}$ y cualquier parámetro de ponderación $\lambda \in (0,1)$, el segmento intermedio también pertenece al conjunto, es decir:

$$\lambda x_1 + (1-\lambda)x_2 \in \mathcal{S}$$

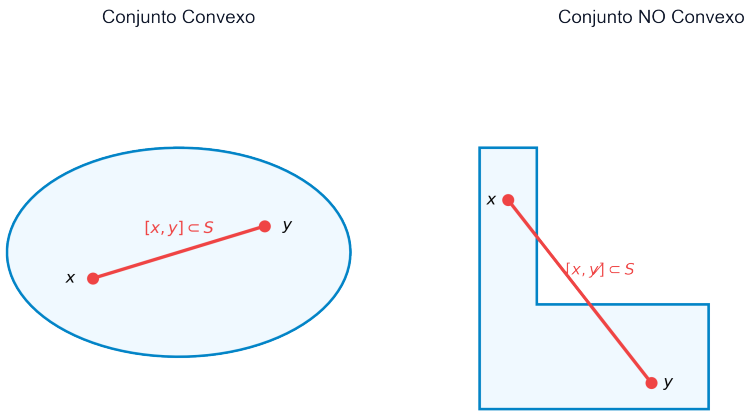

Figura 3.1: Comparación entre un conjunto convexo (izquierda) y un conjunto no convexo (derecha)

Esta noción geométrica de segmento se puede generalizar a conjuntos de múltiples puntos a través de diferentes clases de combinaciones algebraicas, cuyas propiedades estructuran el espacio lineal. Decimos que un punto $x \in \mathbb{R}^n$ es una **combinación lineal convexa** de un conjunto finito de puntos $\{x_1, \dots, x_k\} \subset \mathbb{R}^n$ si puede expresarse de la forma:

$$x = \sum_{i=1}^{k} \lambda_i x_i \quad \text{con} \quad \lambda_i \geq 0 \quad \text{y} \quad \sum_{i=1}^{k} \lambda_i = 1$$

Si eliminamos la condición de no negatividad de los coeficientes, exigiendo únicamente que sumen uno ($\lambda_i \in \mathbb{R}$ con $\sum_{i=1}^{k} \lambda_i = 1$), obtenemos una **combinación afín**, la cual genera subespacios afines como rectas o planos. Por otro lado, si exigimos únicamente la no negatividad de los coeficientes pero no que sumen uno ($\lambda_i \geq 0$), se define una **combinación cónica**, responsable de generar conos convexos. Finalmente, si eliminamos ambas restricciones permitiendo cualquier

$\lambda_i \in \mathbb{R}$, recuperamos la noción de **combinación lineal** ordinaria, que da origen a los subespacios vectoriales tradicionales.

Ejemplos: Conjuntos convexos básicos

A continuación se presentan algunas de las estructuras convexas más elementales y recurrentes en optimización:

- **Hiperplano**: Dado un vector normal no nulo $p \in \mathbb{R}^n$ y un escalar $\alpha \in \mathbb{R}$, representa una superficie plana de dimensión $n-1$ definida por:
$$\mathcal{H} = \{x \in \mathbb{R}^n \mid p^T x = \alpha\}$$
- **Semiespacio Cerrado**: Representa la región del espacio situada en uno de los lados de un hiperplano:
$$\mathcal{H}^- = \{x \in \mathbb{R}^n \mid p^T x \leq \alpha\}$$
- **Poliedro o Politopo Convexo**: La intersección de un número finito de semiespacios cerrados, dada por:
$$\mathcal{P} = \{x \in \mathbb{R}^n \mid Ax \leq b\}$$
Esta estructura constituye la región factible típica de los problemas de programación lineal. Sus esquinas o vértices se denominan **puntos extremos**.
- **Bola Métrica**: Una bola cerrada en $\mathbb{R}^n$ con centro en x_0 y radio $r \geq 0$ definida bajo cualquier norma $\|\cdot\|$:
$$\mathcal{B}_r(x_0) = \{x \in \mathbb{R}^n \mid \|x - x_0\| \leq r\}$$

Para poder operar y construir geometrías más complejas, es fundamental conocer las operaciones algebraicas y conjuntistas que preservan la propiedad de convexidad.

Lema: Conservación de la convexidad

Sean $\mathcal{S}_1$ y $\mathcal{S}_2$ dos conjuntos convexos en $\mathbb{R}^n$. Las siguientes estructuras también son conjuntos convexos:

1. **Intersección**:
$$\mathcal{S}_1 \cap \mathcal{S}_2$$
(Esta propiedad se extiende a la intersección de una familia infinita o arbitraria de conjuntos convexos).
2. **Suma Directa**:
$$\mathcal{S}_1 \oplus \mathcal{S}_2 = \{x_1 + x_2 \mid x_1 \in \mathcal{S}_1,\ x_2 \in \mathcal{S}_2\}$$

3. **Diferencia Directa**:

$$\mathcal{S}_1 \ominus \mathcal{S}_2 = \{x_1 - x_2 \mid x_1 \in \mathcal{S}_1,\ x_2 \in \mathcal{S}_2\}$$

Demostración: 1. **Intersección**: Sean $x, y \in \mathcal{S}_1 \cap \mathcal{S}_2$ y $\lambda \in (0,1)$. Como $x, y \in \mathcal{S}_1$ y $\mathcal{S}_1$ es convexo, entonces $\lambda x + (1-\lambda)y \in \mathcal{S}_1$. Igualmente, como $x, y \in \mathcal{S}_2$ y $\mathcal{S}_2$ es convexo, $\lambda x + (1-\lambda)y \in \mathcal{S}_2$. Por tanto, el punto intermedio pertenece a la intersección. 2. **Suma Directa**: Sean $z_1, z_2 \in \mathcal{S}_1 \oplus \mathcal{S}_2$. Entonces $z_1 = x_1 + y_1$ y $z_2 = x_2 + y_2$ para ciertos $x_1, x_2 \in \mathcal{S}_1$ e $y_1, y_2 \in \mathcal{S}_2$. Para cualquier $\lambda \in (0,1)$:

$$\lambda z_1 + (1-\lambda)z_2 = (\lambda x_1 + (1-\lambda)x_2) + (\lambda y_1 + (1-\lambda)y_2)$$

Por la convexidad de $\mathcal{S}_1$ y $\mathcal{S}_2$, el primer sumando pertenece a $\mathcal{S}_1$ y el segundo a $\mathcal{S}_2$. Por tanto, la combinación pertenece a $\mathcal{S}_1 \oplus \mathcal{S}_2$. 3. **Diferencia Directa**: Se demuestra de forma análoga a la suma directa considerando la resta de elementos. ■

3.1.1. Envoltura convexa y símplices

La envoltura convexa es una construcción matemática fundamental que permite obtener el conjunto convexo más pequeño posible que contiene a un conjunto de puntos arbitrario. Intuitivamente, se puede imaginar como el contorno que formaría una banda elástica si se tensara alrededor de un conjunto de clavos clavados en una tabla, tal y como se ilustra en la Figura 3.2.

Definimos formalmente la **envoltura convexa** $\mathcal{H}(\mathcal{S})$ de un conjunto $\mathcal{S}$ como el conjunto formado por todas las combinaciones lineales convexas posibles de puntos pertenecientes a $\mathcal{S}$:

$$\mathcal{H}(\mathcal{S}) = \left\{ x = \sum_{j=1}^{k} \lambda_j x_j \;\middle|\; x_j \in \mathcal{S},\ \lambda_j \geq 0,\ \sum_{j=1}^{k} \lambda_j = 1 \right\}$$

! Teorema: Minimalidad de la envoltura convexa

La envoltura convexa $\mathcal{H}(\mathcal{S})$ es el menor conjunto convexo que contiene al conjunto $\mathcal{S}$. *Demostración*: Sea $\mathcal{C}$ any conjunto convexo que contiene a $\mathcal{S}$ (es decir, $\mathcal{S} \subseteq \mathcal{C}$). Supongamos por reducción al absurdo que existe un punto $x \in \mathcal{H}(\mathcal{S})$ tal que $x \notin \mathcal{C}$. Como $x \in \mathcal{H}(\mathcal{S})$, se puede escribir como una combinación lineal convexa $x = \sum_{j=1}^{k} \lambda_j x_j$ donde cada $x_j \in \mathcal{S}$. Dado que $\mathcal{S} \subseteq \mathcal{C}$, se deduce que todos los puntos generadores x_j pertenecen a $\mathcal{C}$. Como $\mathcal{C}$ es convexo por hipótesis, cualquier combinación lineal convexa de sus elementos debe pertenecer a él, lo que obliga a que $x \in \mathcal{C}$, contradiciendo la suposición inicial. ■

Cuando limitamos la generación a conjuntos de puntos con propiedades de independencia afín, entramos en la categoría de los símplices y politopos convexos. Un **politopo convexo** es el

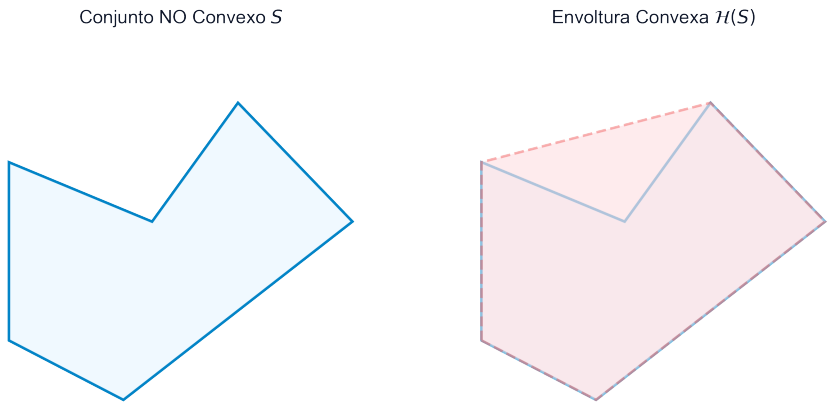

Figura 3.2: Representación de un conjunto no convexo (izquierda) y su envoltura convexa (derecha)

conjunto obtenido mediante la envoltura convexa de un número finito de puntos en $\mathbb{R}^n$. Si estos puntos de generación son afínmente independientes, el politopo se denomina **símplex (o simplex)**. En particular, un símplex en $\mathbb{R}^1$ corresponde a un segmento cerrado, en $\mathbb{R}^2$ a un triángulo y en $\mathbb{R}^3$ a un tetraedro, tal y como se ilustra en la Figura 3.3.

3.1.2. Puntos extremos y optimización en poliedros

Para conjuntos convexos generales, y en particular para poliedros, es de vital importancia identificar aquellos puntos frontera singulares que no pueden expresarse como combinaciones intermedias de otros. Un **punto extremo** es aquel elemento x perteneciente a un conjunto convexo $\mathcal{S}$ que no puede expresarse como una combinación lineal convexa de otros dos puntos distintos del conjunto. Es decir, no existe ningún par de puntos distintos $x_1, x_2 \in \mathcal{S}$ (ambos diferentes de x) y ningún parámetro $\lambda \in (0, 1)$ tales que:

$$x = \lambda x_1 + (1 - \lambda) x_2$$

En el contexto de los poliedros, los puntos extremos coinciden exactamente con la noción geométrica de *vértices*.

> **!** Teorema: Maximización en poliedros
>
> Sea $f : \mathbb{R}^n \to \mathbb{R}$ una función convexa y sea $\mathcal{S}$ un poliedro compacto (cerrado y acotado) no vacío en $\mathbb{R}^n$. Entonces, el problema de maximizar $f(x)$ sujeto a $x \in \mathcal{S}$ alcanza su óptimo global en al menos uno de los puntos extremos de $\mathcal{S}$.

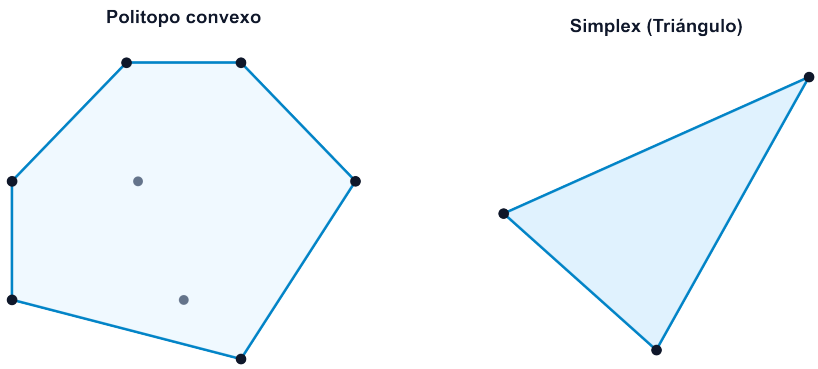

Figura 3.3: Ejemplo de un Politopo convexo generado por un número finito de puntos (izquierda) y un Simplex bidimensional o triángulo generado por tres puntos afínmente independientes (derecha)

Demostración: Dado que f es convexa en un dominio compacto $\mathcal{S}$, es continua en dicho dominio. Por el Teorema de Weierstrass, existe un punto $x' \in \mathcal{S}$ donde f alcanza su máximo global.
Por el Teorema de Representación de Minkowski-Weyl, todo punto de un poliedro compacto $\mathcal{S}$ se puede expresar como una combinación lineal convexa de sus puntos extremos $\{x_1, \dots, x_k\}$:

$$x' = \sum_{j=1}^{k} \lambda_j x_j, \qquad \text{con } \lambda_j \geq 0, \quad \sum_{j=1}^{k} \lambda_j = 1$$

Aplicando la propiedad de convexidad de f (generalizada por la desigualdad de Jensen):

$$f(x') = f\left(\sum_{j=1}^{k} \lambda_j x_j\right) \leq \sum_{j=1}^{k} \lambda_j f(x_j)$$

Por otro lado, como x' es el punto que maximiza f en $\mathcal{S}$, tenemos que $f(x') \geq f(x_j)$ para todo $j = 1, \dots, k$. Al multiplicar estas desigualdades por $\lambda_j \geq 0$ y sumarlas:

$$f(x') = \sum_{j=1}^{k} \lambda_j f(x') \geq \sum_{j=1}^{k} \lambda_j f(x_j)$$

Por tanto, de las dos inecuaciones anteriores se concluye la igualdad estricta:

$$f(x') = \sum_{j=1}^{k} \lambda_j f(x_j)$$

Esto solo es posible si $f(x') = f(x_j)$ para todo índice j tal que $\lambda_j > 0$. En consecuencia, el valor máximo de la función se alcanza en los puntos extremos correspondientes. ■

3.2. Funciones convexas

El concepto de función convexa constituye uno de los pilares de la optimización moderna. A diferencia de las funciones lineales, que describen comportamientos planos o de tasa constante, las funciones convexas capturan analíticamente la estructura de un cuenco o superficie curvada hacia arriba. Esta propiedad geométrica garantiza que cualquier interpolación lineal entre dos puntos de la función siempre sobreestimará (o igualará) el valor real de la misma.

Formalmente, la definición analítica de convexidad se establece de la siguiente manera:

Consideremos un conjunto convexo no vacío $\mathcal{S} \subseteq \mathbb{R}^n$. Decimos que una función $f : \mathcal{S} \to \mathbb{R}$ es **convexa** si, para todo par de puntos $x_1, x_2 \in \mathcal{S}$ y cualquier parámetro de ponderación $\lambda \in (0, 1)$, se verifica la inecuación:

$$f(\lambda x_1 + (1 - \lambda)x_2) \leq \lambda f(x_1) + (1 - \lambda)f(x_2)$$

Si esta inecuación se cumple con desigualdad estricta ($<$) para cualquier par de puntos factibles distintos $x_1 \neq x_2$, decimos que la función f es **estrictamente convexa**. Por otro lado, la función f es **cóncava** si su opuesta $-f$ es una función convexa.

Geométricamente, esta definición establece que el segmento de cuerda (o secante) que une los puntos de la gráfica $(x_1, f(x_1))$ y $(x_2, f(x_2))$ queda situado por encima o sobre la propia curva de la función en dicho intervalo, tal y como se ilustra en la Figura 3.4.

Más allá de su interpretación geométrica, una propiedad teórica de gran alcance para las funciones convexas es que la regularidad algebraica de la desigualdad de convexidad impone de forma automática la continuidad de la función en casi todo su dominio, sin necesidad de exigir diferenciabilidad previa.

! Teorema: Continuidad de las funciones convexas

Sea $f : \mathcal{S} \to \mathbb{R}$ una función convexa, con $\mathcal{S}$ un conjunto convexo no vacío de $\mathbb{R}^n$. Entonces, f es continua en el interior de $\mathcal{S}$ (int $\mathcal{S}$).
Demostración: Véase (Bazaraa, Sherali, y Shetty 2013, cap. 3).

Es fundamental destacar que la propiedad de continuidad se restringe estrictamente al **interior** de $\mathcal{S}$. En la frontera del conjunto factible, una función convexa puede presentar discontinuidades.

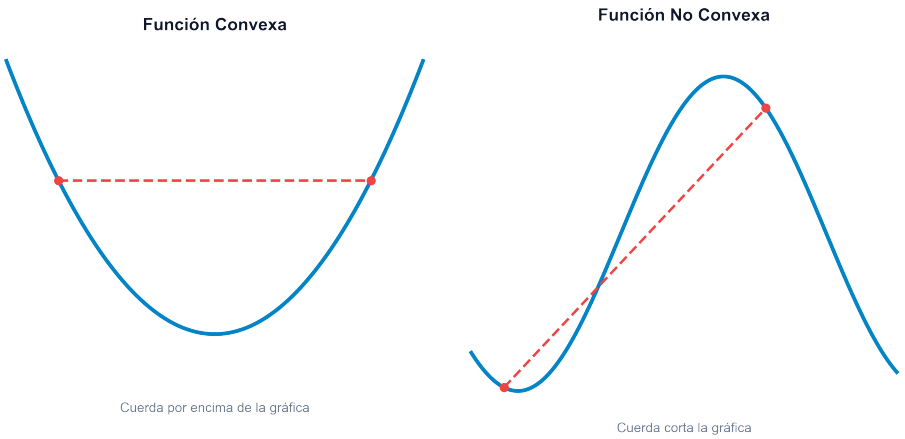

Figura 3.4: Visualización de una función convexa (izquierda), donde la secante o cuerda queda por encima de la gráfica, frente a una función no convexa (derecha), donde la cuerda corta a la curva

Como ejemplo ilustrativo, consideremos la función convexa definida en el intervalo cerrado $\mathcal{S} = [0, 1]$ dada por:

$$f(x) = \begin{cases} x^2 & \text{si } x \in (0,1) \\ 1 & \text{si } x = 0 \text{ o } x = 1 \end{cases}$$

Esta función es convexa en todo el intervalo $\mathcal{S}$, pero presenta discontinuidades evidentes en los puntos frontera $x = 0$ y $x = 1$.

3.2.1. Operaciones que preservan la convexidad de funciones

Para construir funciones convexas más complejas o verificar la convexidad de expresiones algebraicas complicadas, no siempre es necesario recurrir a la definición básica de convexidad o evaluar las derivadas. En su lugar, podemos aplicar una serie de reglas y operaciones algebraicas fundamentales que conservan de manera intrínseca la convexidad:

- **Suma ponderada positiva**: Si $f_1, \dots, f_k$ son funciones convexas y los coeficientes $\alpha_1, \dots, \alpha_k \geq 0$ son no negativos, entonces la combinación lineal ponderada $\sum_j \alpha_j f_j$ también es una función convexa.
- **Supremo puntual (Máximo)**: Si $f_1, \dots, f_k$ son funciones convexas, la función envoltura superior definida por el máximo puntual $f(x) = \max_j\{f_j(x)\}$ es convexa.
- **Composición afín**: Si $g : \mathbb{R}^m \to \mathbb{R}$ es una función activa y convexa y $h(x) = Ax + b$ es una transformación afín, entonces la función compuesta $f(x) = g(Ax + b)$ es convexa.

- **Inversa de una función cóncava**: Si $g : \mathbb{R}^n \to \mathbb{R}$ es una función cóncava, entonces su inversa recíproca $f(x) = \frac{1}{g(x)}$ es una función convexa sobre el dominio restringido $\mathcal{S} = \{x \in \mathbb{R}^n \mid g(x) > 0\}$.
- **Composición general (no decreciente)**: Si $g : \mathbb{R} \to \mathbb{R}$ es una función convexa y no decreciente, y $h : \mathbb{R}^n \to \mathbb{R}$ es una función convexa, entonces la función compuesta $f(x) = g(h(x))$ es convexa.

! Teorema: Convexidad de los conjuntos de nivel

Sea $f : \mathcal{S} \to \mathbb{R}$ una función convexa sobre un dominio convexo $\mathcal{S}$. Para cualquier constante $\alpha \in \mathbb{R}$, el conjunto de nivel inferior:

$$\mathcal{S}_\alpha = \{x \in \mathcal{S} \mid f(x) \leq \alpha\}$$

es un conjunto convexo.
Demostración: Sean $x_1, x_2 \in \mathcal{S}_\alpha$. Por definición del conjunto de nivel, se cumple que $f(x_1) \leq \alpha$ y $f(x_2) \leq \alpha$. Sea $\lambda \in (0, 1)$. Como el dominio $\mathcal{S}$ es convexo, el punto intermedio $\lambda x_1 + (1 - \lambda)x_2$ pertenece a $\mathcal{S}$. Aplicando la definición de convexidad de f:

$$f(\lambda x_1 + (1 - \lambda)x_2) \leq \lambda f(x_1) + (1 - \lambda) f(x_2) \leq \lambda\alpha + (1 - \lambda)\alpha = \alpha$$

Por tanto, $\lambda x_1 + (1 - \lambda)x_2 \in \mathcal{S}_\alpha$, lo que demuestra la convexidad del conjunto de nivel. ■

El comportamiento geométrico de estos conjuntos de nivel inferior se visualiza en la Figura 3.5. Como se observa, en el caso de una función convexa (izquierda), el conjunto de nivel inferior constituye un intervalo continuo y, por tanto, convexo en el plano. Por el contrario, en una función no convexa (derecha), dicho conjunto puede fragmentarse en la unión de intervalos disjuntos no convexos, rompiendo la propiedad conjuntista fundamental.

⚠ Nota: El recíproco del teorema no es cierto

El recíproco de este teorema no es cierto en general. Una función que posee conjuntos de nivel inferior convexos no es necesariamente una función convexa (esta propiedad estructural define la clase más general de las funciones cuasi-convexas, como veremos más adelante).

3.2.2. Epigrafo e hipografo

Para profundizar en el estudio analítico de las funciones convexas, resulta muy provechoso vincular la estructura de la función con la geometría de los conjuntos convexos. Esto se logra mediante el estudio de las regiones geométricas que quedan por encima o por debajo de la gráfica de la función. El **epigrafo** de una función f (denotado por epi f) es el conjunto de

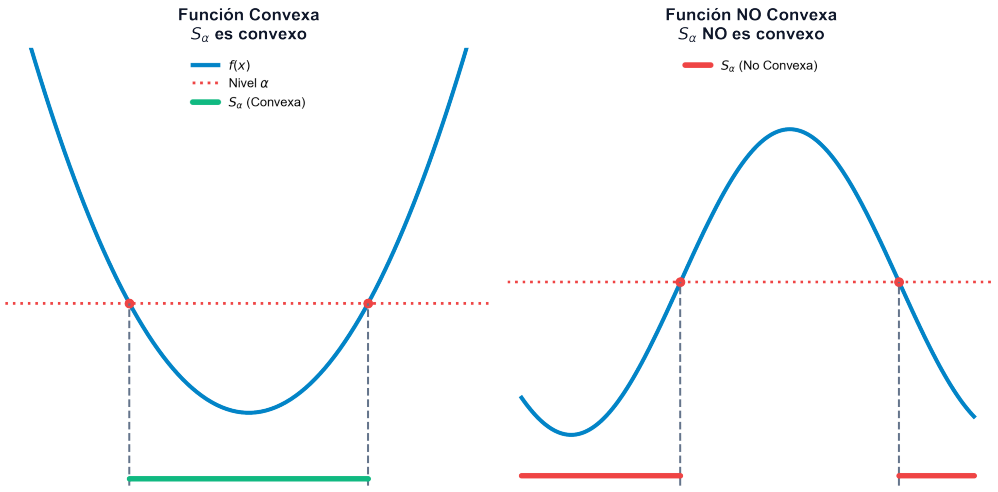

Figura 3.5: Comparativa del conjunto de nivel inferior $\mathcal{S}_\alpha$: en una función convexa (izquierda) es un intervalo continuo y por tanto convexo, mientras que en una función no convexa (derecha) puede dar lugar a la unión de intervalos disjuntos no convexos

puntos en el espacio $\mathbb{R}^{n+1}$ situados sobre o por encima de su gráfica:

$$\text{epi } f = \{(x, y) \in \mathcal{S} \times \mathbb{R} \mid y \geq f(x)\}$$

De forma complementaria, el **hipografo** (denotado por hyp f) es el conjunto de puntos en el espacio $\mathbb{R}^{n+1}$ situados bajo o por debajo de la gráfica de la función f:

$$\text{hyp } f = \{(x, y) \in \mathcal{S} \times \mathbb{R} \mid y \leq f(x)\}$$

La comparación tridimensional entre el epigrafo de una función convexa y el hipografo de una cóncava se ilustra en la Figura 3.6.

! Teorema: Relación entre epigrafo y convexidad

Una función $f : \mathcal{S} \to \mathbb{R}$ es convexa si y solo si su epigrafo epi f es un conjunto convexo en $\mathbb{R}^{n+1}$.
Demostración: ($\Longrightarrow$) Supongamos que f es convexa. Sean $(x_1, y_1), (x_2, y_2) \in$ epi f y $\lambda \in (0, 1)$. Por definición de epigrafo, $y_1 \geq f(x_1)$ y $y_2 \geq f(x_2)$. Evaluando la combinación lineal:

$$\lambda y_1 + (1 - \lambda) y_2 \geq \lambda f(x_1) + (1 - \lambda) f(x_2) \geq f(\lambda x_1 + (1 - \lambda) x_2)$$

Como $\mathcal{S}$ es convexo, el punto combinado pertenece a $\mathcal{S}$, y el par combinado pertenece a epi f, demostrando su convexidad.
($\Longleftarrow$) Supongamos que epi f es un conjunto convexo. Sean $x_1, x_2 \in \mathcal{S}$. Los puntos $(x_1, f(x_1))$ y $(x_2, f(x_2))$ pertenecen a epi f. Por convexidad del epigrafo, para todo

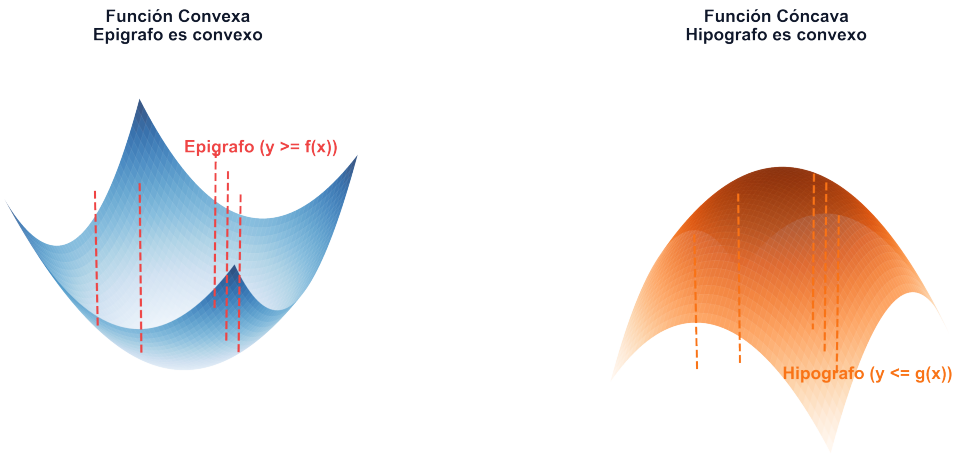

Figura 3.6: Visualización tridimensional comparativa del Epigrafo (región sombreada superior) para una función convexa (izquierda) y del Hipografo (región sombreada inferior) para una función cóncava (derecha)

$\lambda \in (0,1)$:

$$\lambda(x_1, f(x_1)) + (1-\lambda)(x_2, f(x_2)) = (\lambda x_1 + (1-\lambda)x_2, \lambda f(x_1) + (1-\lambda)f(x_2)) \in \text{epi } f$$

Lo que implica directamente que $\lambda f(x_1) + (1-\lambda)f(x_2) \geq f(\lambda x_1 + (1-\lambda)x_2)$, es decir, f es convexa. ■

Esta equivalencia fundamental resulta sumamente potente, ya que permite trasladar propiedades algebraicas complejas de las funciones al análisis puramente geométrico de los conjuntos convexos. De manera completamente análoga, la convexidad del hipografo caracteriza a las funciones cóncavas: una función f es cóncava si y solo si su hipografo hyp f es un conjunto convexo en $\mathbb{R}^{n+1}$. De este modo, la curvatura (hacia arriba o hacia abajo) de cualquier función queda codificada de forma unívoca en la geometría del cuerpo que delimita su gráfica.

Cuando trabajamos con funciones no diferenciables (es decir, aquellas que presentan picos o codos en su gráfica), el gradiente clásico deja de existir en ciertos puntos de interés. Para solventar este límite analítico, generalizamos la noción de gradiente a través del concepto de subgradiente.

Un vector $\xi \in \mathbb{R}^n$ es un **subgradiente** de la función convexa f en el punto $x_0 \in \mathcal{S}$ si satisface la desigualdad:

$$f(x) \geq f(x_0) + \xi^T(x - x_0), \quad \forall x \in \mathcal{S}$$

Geométricamente, el subgradiente representa la pendiente de un hiperplano de soporte que apoya a la función desde abajo en dicho punto. El conjunto formado por todos los subgradientes

de f en x_0 se denomina **subdiferencial** y se denota por $\partial f(x_0)$.

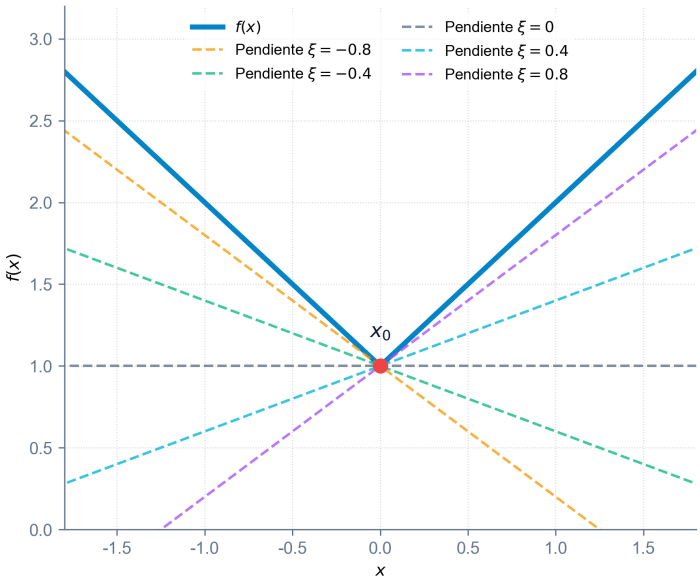

Figura 3.7: Interpretación geométrica del subgradiente y el subdiferencial para una función no diferenciable en x_0

El subdiferencial $\partial f(x_0)$ es siempre un conjunto convexo y cerrado, cuyas propiedades matemáticas se explotan rigurosamente en la optimización no diferenciable (Rockafellar 1970; Boyd y Vandenberghe 2004). Si la función es diferenciable en un punto x_0, el subdiferencial contiene un único elemento que coincide exactamente con el gradiente convencional: $\partial f(x_0) = \{\nabla f(x_0)\}$.

! Teorema: Existencia del subgradiente (hiperplano soporte al epigrafo)

Sea $f : \mathcal{S} \to \mathbb{R}$ una función convexa, con $\mathcal{S}$ un conjunto convexo no vacío de $\mathbb{R}^n$. Para cualquier punto interior $x_0 \in \text{int } \mathcal{S}$, existe al menos un subgradiente $\xi \in \mathbb{R}^n$. Esto equivale a decir que el hiperplano:

$$y = f(x_0) + \xi^T(x - x_0)$$

es un hiperplano de soporte para el epigrafo de f, epi f, en el punto frontera $(x_0, f(x_0))$.
Demostración: Por ser f convexa, su epigrafo epi$f$ es un conjunto convexo en $\mathbb{R}^{n+1}$. Todo conjunto convexo posee asociado un hiperplano de soporte en cada punto de su frontera. El punto $(x_0, f(x_0))$ pertenece a la frontera de epi f (ya que para cualquier $\epsilon > 0$, el punto $(x_0, f(x_0) - \epsilon) \notin$ epi f pero $(x_0, f(x_0)) \in$ epi f).
Por consiguiente, existe un vector no nulo $\binom{\xi_0}{\mu} \in \mathbb{R}^{n+1}$ tal que:

$$\xi_0^T(x - x_0) + \mu(y - f(x_0)) \leq 0, \qquad \forall (x, y) \in \text{epi } f$$

En primer lugar, analizando $y \to \infty$ para un $x = x_0$ fijo, para que la desigualdad se

mantenga, el escalar μ debe satisfacer $\mu \leq 0$.
Demostremos ahora que μ debe ser estrictamente negativo ($\mu < 0$). Supongamos por contradicción que $\mu = 0$. En tal caso, la desigualdad anterior se reduce a:

$$\xi_0^T(x - x_0) \leq 0, \qquad \forall x \in \mathcal{S}$$

Como $x_0 \in \text{int } \mathcal{S}$, existe una pequeña bola centrada en x_0 contenida en $\mathcal{S}$, lo que permite tomar un punto de la forma $x = x_0 + \lambda\xi_0 \in \mathcal{S}$ para un $\lambda > 0$ suficientemente pequeño. Sustituyendo este punto:

$$\lambda\xi_0^T\xi_0 \leq 0 \implies \|\xi_0\|^2 \leq 0 \implies \xi_0 = \mathbf{0}$$

Esto implica que el vector dual normal es $(\xi_0, \mu) = (\mathbf{0}, 0)$, lo cual contradice la hipótesis de que dicho vector es no nulo. Por tanto, $\mu < 0$.
Definimos ahora el vector $\xi = \frac{\xi_0}{|\mu|} = \frac{\xi_0}{-\mu}$. Dividiendo la inecuación original por $|\mu| > 0$:

$$\xi^T(x - x_0) - y + f(x_0) \leq 0, \qquad \forall (x, y) \in \text{epi } f$$

Reordenando, obtenemos:

$$y \geq f(x_0) + \xi^T(x - x_0), \qquad \forall (x, y) \in \text{epi } f$$

Evaluando esta desigualdad en el punto frontera de la gráfica $y = f(x)$, concluimos que:

$$f(x) \geq f(x_0) + \xi^T(x - x_0), \qquad \forall x \in \mathcal{S}$$

lo que demuestra que ξ es un subgradiente de f en x_0. ■

El teorema anterior garantiza que siempre es posible apoyar una función convexa desde abajo mediante un hiperplano. Cuando la función posee una curvatura estrictamente positiva (es decir, es estrictamente convexa), este apoyo deja de ser plano en cualquier otro punto del dominio y el hiperplano toca a la gráfica únicamente en el punto de tangencia, lo que se formaliza a continuación.

i Corolario: Caso de convexidad estricta

Si $f : \mathcal{S} \to \mathbb{R}$ es estrictamente convexa, entonces para cualquier $x_0 \in \text{int } \mathcal{S}$ y cualquier subgradiente $\xi \in \partial f(x_0)$, se verifica la desigualdad estricta:

$$f(x) > f(x_0) + \xi^T(x - x_0), \quad \forall x \in \mathcal{S},\ x \neq x_0$$

Demostración: Por el teorema de existencia, existe un subgradiente $\xi \in \partial f(x_0)$ tal que:

$$f(x) \geq f(x_0) + \xi^T(x - x_0), \qquad \forall x \in \mathcal{S}$$

Supongamos por contradicción que existe un punto $x_1 \in \mathcal{S}$, $x_1 \neq x_0$, donde se alcanza la igualdad:

$$f(x_1) = f(x_0) + \xi^T(x_1 - x_0)$$

Por la definición de convexidad estricta de f, para cualquier $\lambda \in (0,1)$:

$$f(\lambda x_0 + (1-\lambda)x_1) < \lambda f(x_0) + (1-\lambda) f(x_1)$$

Sustituyendo el valor de $f(x_1)$ en el miembro de la derecha:

$$f(\lambda x_0 + (1-\lambda)x_1) < \lambda f(x_0) + (1-\lambda)[f(x_0) + \xi^T(x_1 - x_0)] = f(x_0) + (1-\lambda)\xi^T(x_1 - x_0)$$

Por otra parte, evaluando la inecuación del subgradiente original en el punto $x = \lambda x_0 + (1-\lambda)x_1$:

$$f(\lambda x_0 + (1-\lambda)x_1) \geq f(x_0) + \xi^T[\lambda x_0 + (1-\lambda)x_1 - x_0] = f(x_0) + (1-\lambda)\xi^T(x_1 - x_0)$$

Las dos desigualdades anteriores son contradictorias, lo que concluye que no puede darse la igualdad para ningún punto $x_1 \neq x_0$. ■

Hasta el momento hemos deducido que la convexidad implica la existencia de subgradientes que acotan inferiormente a la función. Un resultado de enorme relevancia práctica es que esta relación es bidireccional: la existencia de un vector de soporte inferior en cada punto del dominio es suficiente para asegurar que la función es convexa, lo cual permite verificar la convexidad de forma local.

! Teorema: Suficiencia de la caracterización por subgradientes

Sea $\mathcal{S}$ un conjunto convexo abierto no vacío de $\mathbb{R}^n$ y sea $f : \mathcal{S} \to \mathbb{R}$ una función. Si para cada punto $x_0 \in \mathcal{S}$ existe un vector $\xi \in \mathbb{R}^n$ tal que:

$$f(x) \geq f(x_0) + \xi^T(x - x_0), \quad \forall x \in \mathcal{S}$$

entonces la función f es convexa en $\mathcal{S}$.
Demostración: Sean $x_1, x_2 \in \mathcal{S}$ y $\lambda \in (0,1)$. Definimos el punto intermedio $x_0 = \lambda x_1 + (1-\lambda)x_2$. Como $\mathcal{S}$ es convexo y abierto, $x_0 \in \mathcal{S}$. Por hipótesis, existe un subgradiente ξ en x_0, tal que:

$$f(x) \geq f(x_0) + \xi^T(x - x_0), \quad \forall x \in \mathcal{S}$$

Evaluando esta desigualdad en $x = x_1$ y multiplicándola por λ:

$$\lambda f(x_1) \geq \lambda f(x_0) + \lambda \xi^T(x_1 - x_0)$$

Evaluando la desigualdad en $x = x_2$ y multiplicándola por $(1-\lambda)$:

$$(1-\lambda) f(x_2) \geq (1-\lambda) f(x_0) + (1-\lambda)\xi^T(x_2 - x_0)$$

Sumando ambas expresiones:

$$\lambda f(x_1) + (1-\lambda) f(x_2) \geq [\lambda + (1-\lambda)] f(x_0) + \xi^T [\lambda(x_1 - x_0) + (1-\lambda)(x_2 - x_0)]$$

Analizando el término dentro del producto escalar:

$$\lambda(x_1 - x_0) + (1-\lambda)(x_2 - x_0) = \lambda x_1 + (1-\lambda) x_2 - [\lambda + (1-\lambda)] x_0 = x_0 - x_0 = 0$$

Por tanto, el producto escalar se anula y obtenemos:

$$\lambda f(x_1) + (1-\lambda) f(x_2) \geq f(x_0) = f(\lambda x_1 + (1-\lambda) x_2)$$

lo que demuestra que f es convexa. ■

Para poder aplicar estas caracterizaciones en la resolución de problemas reales, es necesario disponer de un álgebra que permita calcular el subdiferencial de funciones complejas construidas a partir de funciones más simples. Las siguientes propiedades establecen las reglas operativas básicas del subdiferencial, de forma homóloga al cálculo diferencial clásico.

i Propiedades y cálculo del subdiferencial

El cálculo con subgradientes sigue reglas análogas al cálculo diferencial estándar:

1. **Regla de la Suma**: Si f_1, f_2 son funciones convexas, el subdiferencial de su suma cumple:
$$\partial(f_1(x) + f_2(x)) = \partial f_1(x) \oplus \partial f_2(x)$$
2. **Multiplicación Escalar**: Para cualquier constante $\alpha \geq 0$:
$$\partial(\alpha f(x)) = \alpha \partial f(x)$$
3. **Máximo de Funciones**: Si $f(x) = \max\{f_1(x), f_2(x)\}$ con f_1, f_2 convexas:
$$\partial f(x) = \mathcal{H}(\cup_{i \in \mathcal{J}(x)} \partial f_i(x))$$
donde $\mathcal{J}(x)$ es el conjunto de índices de las funciones que alcanzan el máximo en el punto x.

Para ilustrar de forma práctica la aplicación de las reglas algebraicas del subdiferencial y el papel geométrico del subgradiente (como plano o recta soporte inferior), a continuación se exponen detalladamente dos casos de estudio de referencia. El primero analiza de manera exhaustiva el comportamiento de una función valor absoluto no suave en una dimensión, mostrando cómo el subdiferencial se ensancha en los puntos de no diferenciabilidad. El segundo caso extiende esta noción a una función multivariable diferenciable en dos dimensiones, calculando la ecuación explícita del plano soporte en $\mathbb{R}^3$.

Ejemplos: Cálculo y aplicación del subdiferencial en 1D y 2D

Caso 1D: Función no diferenciable definida por tramos
Consideremos una función convexa clásica definida por tramos:

$$f(x) = \max\{|x| - 4,\ (x-2)^2 - 4\}$$

Esta función puede simplificarse en distintas regiones analizando cuál de las dos curvas domina en cada intervalo (dado que la parábola y la función valor absoluto se cruzan en $x = 1$ y $x = 4$):

$$f(x) = \begin{cases} x - 4 & \text{si } 1 \leq x \leq 4 \\ (x-2)^2 - 4 & \text{en otro caso} \end{cases}$$

Analicemos su subdiferencial $\partial f(x_0)$ en diferentes puntos de la recta real:
En un **punto diferenciable en el tramo lineal** (por ejemplo, $x_0 = 2$), la función es puramente lineal y coincide con la recta $x - 4$. Su derivada clásica es constante e igual a $f'(2) = 1$. Al ser diferenciable, el subdiferencial consta de un único vector:

$$\partial f(2) = \{1\}$$

La recta tangente soporte es $y = -2 + 1(x - 2) = x - 4$.
En un **punto diferenciable en el tramo cuadrático** (por ejemplo, $x_0 = 5$), para valores superiores a 4, la función coincide con la parábola $(x-2)^2 - 4$. Su derivada clásica en este punto es $f'(5) = 2(5 - 2) = 6$. Por tanto, el subdiferencial contiene únicamente a esta pendiente:

$$\partial f(5) = \{6\}$$

La recta tangente soporte es $y = 5 + 6(x - 5) = 6x - 25$.
En un **punto singular o codo** (en $x_0 = 1$), confluyen la parábola (por la izquierda) y la recta (por la derecha). La derivada lateral izquierda (cuadrática) es $f'_-(1) = 2(1-2) = -2$, y la derivada lateral derecha (lineal) es $f'_+(1) = 1$. El subdiferencial en este codo está formado por toda la familia de pendientes intermedias (es decir, la combinación convexa de las derivadas laterales):

$$\partial f(1) = [-2, 1]$$

Cualquier línea que pase por $(1, -3)$ con pendiente $\xi \in [-2, 1]$ apoyará a la función desde abajo (como la línea horizontal de pendiente $\xi = 0$).
En un **punto singular o codo** (en $x_0 = 4$), de manera análoga, la derivada lateral izquierda (lineal) es $f'_-(4) = 1$, y la derivada lateral derecha (cuadrática) es $f'_+(4) = 2(4 - 2) = 4$. El subdiferencial es el intervalo:

$$\partial f(4) = [1, 4]$$

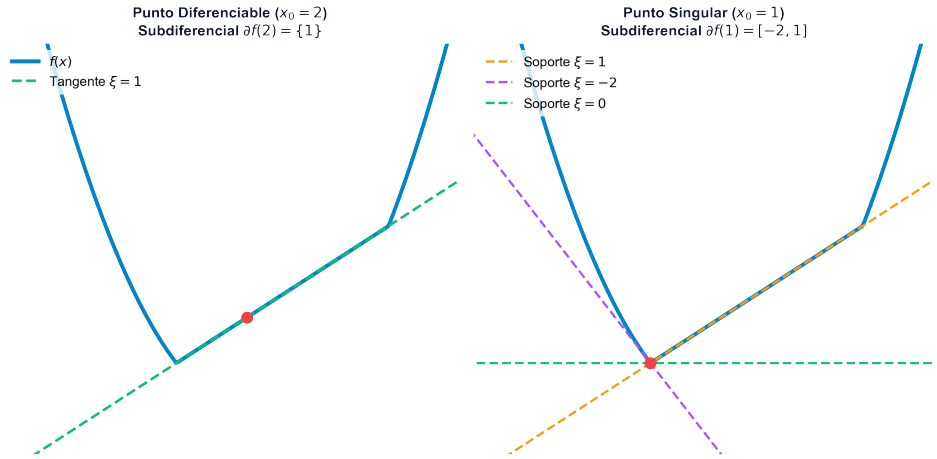

Figura 3.8: Visualización del subdiferencial de una función en un punto donde es diferenciable (izquierda, tangente única) frente a un punto singular de codo (derecha, múltiples pendientes de soporte en el intervalo de subdiferencial)

Caso 2D: Función cuadrática diferenciable y plano soporte

Para ilustrar cómo se comporta el subdiferencial y el hiperplano soporte en una dimensión superior, consideremos la función cuadrática diferenciable $f : \mathbb{R}^2 \to \mathbb{R}$ definida por:

$$f(x, y) = 8x^2 + 3xy + 7y^2 - 25x + 31y - 29$$

Calculamos su subdiferencial en el punto $x_0 = (10, 10)$. Dado que f es diferenciable en todo su dominio, el subdiferencial es unitario y contiene únicamente al gradiente:

$$\partial f(10, 10) = \{\nabla f(10, 10)\}$$

Calculando las derivadas parciales de primer orden:

$$\frac{\partial f}{\partial x} = 16x + 3y - 25 \implies \frac{\partial f}{\partial x}(10, 10) = 160 + 30 - 25 = 165$$

$$\frac{\partial f}{\partial y} = 3x + 14y + 31 \implies \frac{\partial f}{\partial y}(10, 10) = 30 + 140 + 31 = 201$$

El valor de la función en dicho punto es:

$$f(10, 10) = 8(100) + 3(100) + 7(100) - 250 + 310 - 29 = 1831$$

Por tanto, el único subgradiente de la función en $(10, 10)$ es el vector gradiente $\xi = \nabla f(10, 10) = (165, 201)^T$. El plano soporte tangente en 3D que acota inferiormente a la función viene definido por el hiperplano:

$$z = 1831 + 165(x - 10) + 201(y - 10)$$

De acuerdo con el teorema de existencia, la convexidad de f garantiza de forma global que:

$$8x^2 + 3xy + 7y^2 - 25x + 31y - 29 \geq 1831 + 165(x - 10) + 201(y - 10), \quad \forall (x, y) \in \mathbb{R}^2$$

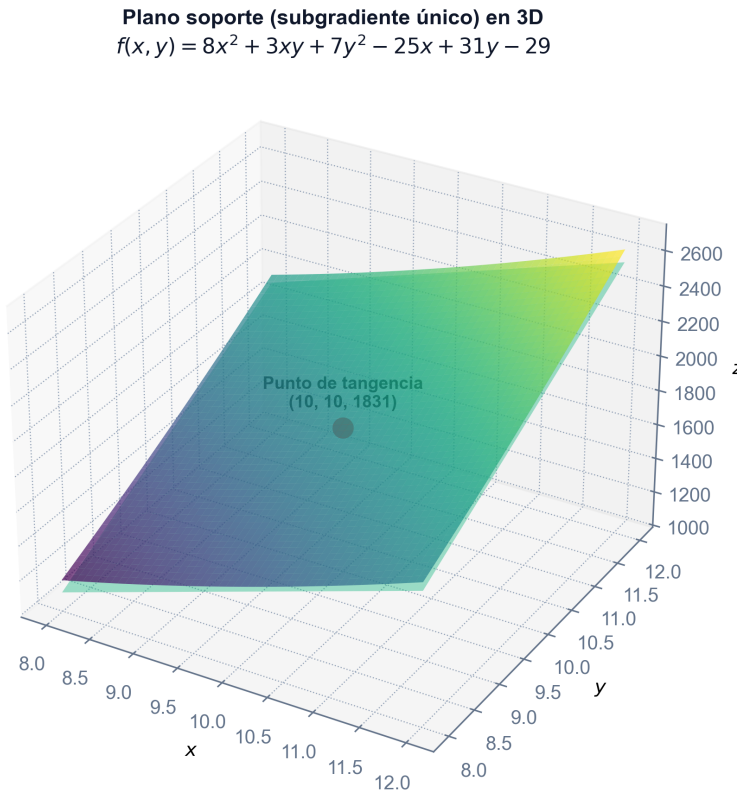

Figura 3.9: Plano tangente de soporte inferior en 3D para una función cuadrática diferenciable convexa en el punto de tangencia (10, 10, 1831)

3.3. Caracterización de funciones convexas diferenciables

Aunque las definiciones geométricas basadas en epigrafos o combinaciones lineales de puntos son conceptualmente intuitivas, en la práctica matemática y algorítmica resulta muy costoso verificar la convexidad de una función directamente a partir de ellas. Cuando la función posee propiedades de suavidad, es decir, es diferenciable (una o dos veces), es posible explotar la información local proporcionada por sus derivadas para establecer criterios de convexidad globales más sencillos de evaluar. En esta sección se abordan los resultados fundamentales que

conectan el gradiente y la matriz hessiana con la geometría convexa.

Teorema: Caracterización de primer orden para funciones diferenciables

Sea $f : \mathcal{S} \to \mathbb{R}$ una función diferenciable en un conjunto convexo y abierto $\mathcal{S}$.

1. f es convexa si y solo si:

$$f(x) \geq f(x_0) + \nabla f(x_0)^T (x - x_0), \quad \forall x, x_0 \in \mathcal{S}$$

2. f es estrictamente convexa si y solo si:

$$f(x) > f(x_0) + \nabla f(x_0)^T (x - x_0), \quad \forall x, x_0 \in \mathcal{S} \text{ con } x \neq x_0$$

Significado geométrico: La aproximación lineal de primer orden (plano tangente en cualquier punto x_0) es un estimador inferior global de la función. Es decir, la gráfica de la función se apoya en su totalidad sobre el plano tangente.

La caracterización de primer orden anterior establece que una función convexa siempre crece más rápido (o igual) que su aproximación lineal tangente. Esta propiedad tiene una consecuencia directa sobre el comportamiento de sus gradientes: a medida que nos desplazamos por el dominio, el gradiente debe variar de forma que siempre apunte en direcciones de crecimiento. Esto da lugar a la noción de monotonía del operador gradiente, lo que formaliza algebraicamente la idea de que la pendiente de la función no decrece en ninguna dirección.

Teorema: Monotonía del gradiente

Una función diferenciable f es convexa en un conjunto convexo abierto $\mathcal{S}$ si y solo si su gradiente es un operador monótono:

$$(\nabla f(x_2) - \nabla f(x_1))^T (x_2 - x_1) \geq 0, \quad \forall x_1, x_2 \in \mathcal{S}$$

Demostración: ($\Longrightarrow$) Si f es convexa, por la caracterización de primer orden se cumplen simultáneamente:

$$f(x_1) \geq f(x_2) + \nabla f(x_2)^T (x_1 - x_2)$$
$$f(x_2) \geq f(x_1) + \nabla f(x_1)^T (x_2 - x_1)$$

Sumando ambas inecuaciones miembro a miembro:

$$f(x_1) + f(x_2) \geq f(x_2) + f(x_1) + \nabla f(x_2)^T (x_1 - x_2) + \nabla f(x_1)^T (x_2 - x_1)$$

Cancelando términos comunes y reordenando:

$$0 \geq (\nabla f(x_1) - \nabla f(x_2))^T (x_2 - x_1) \implies (\nabla f(x_2) - \nabla f(x_1))^T (x_2 - x_1) \geq 0$$

($\Longleftarrow$) Se demuestra de manera análoga aplicando el teorema del valor medio. ■

El análisis del gradiente de primer orden nos proporciona una visión del comportamiento de las pendientes de la función. Sin embargo, para funciones dos veces diferenciables, podemos refinar este análisis estudiando la tasa de variación de las pendientes, es decir, la curvatura de la función. Esto se logra mediante el estudio de la matriz hessiana, cuyas propiedades de definición y semidefinición positiva determinan de forma local si la curvatura es siempre ascendente (convexa), garantizando la convexidad de manera global.

! Teorema: Caracterización de segundo orden

Sea $f : \mathcal{S} \to \mathbb{R}$ una función dos veces diferenciable en un conjunto convexo abierto $\mathcal{S}$.

1. f es convexa si y solo si su matriz hessiana es semidefinida positiva en todo punto de $\mathcal{S}$:
$$\nabla^2 f(x) \succeq 0, \quad \forall x \in \mathcal{S}$$
2. Si la matriz hessiana es definida positiva en todo el dominio ($\nabla^2 f(x) \succ 0, \forall x \in \mathcal{S}$), entonces f es estrictamente convexa.

Demostración:
Demostración de la afirmación 1:
Implicación ($\Longrightarrow$): Supongamos que f es convexa. Sea $x_0 \in \mathcal{S}$ y sea $d \in \mathbb{R}^n$ cualquier dirección. Como $\mathcal{S}$ es abierto, existe un $\lambda \neq 0$ suficientemente pequeño tal que $x_0 + \lambda d \in \mathcal{S}$. Por ser f dos veces diferenciable, su desarrollo de Taylor de segundo orden es:

$$f(x_0 + \lambda d) = f(x_0) + \lambda \nabla f(x_0)^T d + \frac{1}{2}\lambda^2 d^T \nabla^2 f(x_0) d + \lambda^2 \|d\|^2 \alpha(x_0, \lambda d)$$

donde $\lim_{\lambda \to 0} \alpha(x_0, \lambda d) = 0$. Por otro lado, aplicando la caracterización de primer orden de convexidad:

$$f(x_0 + \lambda d) \geq f(x_0) + \lambda \nabla f(x_0)^T d$$

Restando la segunda inecuación de la primera:

$$\frac{1}{2}\lambda^2 d^T \nabla^2 f(x_0) d + \lambda^2 \|d\|^2 \alpha(x_0, \lambda d) \geq 0$$

Dividiendo por $\lambda^2 > 0$ y tomando el límite cuando $\lambda \to 0$:

$$d^T \nabla^2 f(x_0) d \geq 0$$

Puesto que esta forma cuadrática es no negativa para cualquier dirección $d \in \mathbb{R}^n$, la matriz hessiana $\nabla^2 f(x_0)$ es semidefinida positiva.
Implicación ($\Longleftarrow$): Supongamos que la hessiana es semidefinida positiva en todo $\mathcal{S}$. Sean $x_1, x_2 \in \mathcal{S}$. Por el Teorema del Valor Medio de segundo orden (o desarrollo de Taylor

con resto de Lagrange), existe un punto z en el segmento que une x_1 y x_2 (es decir, $z = \lambda x_1 + (1-\lambda)x_2$ para algún $\lambda \in (0,1)$) tal que:

$$f(x_2) = f(x_1) + \nabla f(x_1)^T(x_2 - x_1) + \frac{1}{2}(x_2 - x_1)^T \nabla^2 f(z)(x_2 - x_1)$$

Dado que $\mathcal{S}$ es convexo, $z \in \mathcal{S}$. Como por hipótesis $\nabla^2 f(z) \succeq 0$ es semidefinida positiva, la forma cuadrática del error de segundo orden es no negativa:

$$(x_2 - x_1)^T \nabla^2 f(z)(x_2 - x_1) \geq 0$$

Por tanto:

$$f(x_2) \geq f(x_1) + \nabla f(x_1)^T(x_2 - x_1)$$

Al cumplirse esta desigualdad para todo par de puntos, la caracterización de primer orden garantiza que f es convexa.

Demostración de la afirmación 2:

Si $\nabla^2 f(x) \succ 0$ para todo $x \in \mathcal{S}$, un razonamiento análogo al de la implicación ($\Longleftarrow$) sustituyendo el término cuadrático por una desigualdad estricta (> 0 para $x_2 \neq x_1$) demuestra que f es estrictamente convexa. ■

Precisión conceptual sobre la convexidad estricta: Es fundamental señalar que, mientras que la hessiana semidefinida positiva es una condición necesaria y suficiente para la convexidad, la hessiana definida positiva ($\nabla^2 f(x) \succ 0$) es una condición **suficiente pero no necesaria** para la convexidad estricta en el caso general. Como contraejemplo clásico, consideremos la función en una variable:

$$f(x) = x^4$$

Esta función es estrictamente convexa en todo $\mathbb{R}$ (su curvatura es estrictamente ascendente a ambos lados). Sin embargo, su segunda derivada en el origen $x_0 = 0$ es:

$$f''(0) = 12(0)^2 = 0$$

que es solo semidefinida positiva (nula) y no estrictamente positiva. El recíproco (es decir, que la convexidad estricta implique hessiana definida positiva en todos los puntos) **solo se cumple de forma garantizada si la función es cuadrática** (donde la hessiana es constante).

Para afianzar estos conceptos de segundo orden y comprender las diferencias operativas entre la semidefinición y la definición estricta en espacios de dimensiones superiores, a continuación se presentan varios ejemplos prácticos resueltos detalladamente.

Ejemplos de verificación de convexidad con matrices hessianas

Analicemos la convexidad de tres funciones de prueba:

- **Ejemplo 1**:

$$f(x_1, x_2, x_3) = x_1x_2 + 2x_1^2 + x_2^2 + 2x_3^2 - 6x_1x_3$$

La matriz hessiana de esta función cuadrática es constante:

$$\nabla^2 f = \begin{pmatrix} 4 & 1 & -6 \\ 1 & 2 & 0 \\ -6 & 0 & 4 \end{pmatrix}$$

Calculamos los menores principales líderes para aplicar el criterio de Sylvester:

- $M_1 = 4 > 0$.
- $M_2 = 4 \cdot 2 - 1^2 = 7 > 0$.
- $M_3 = \det(\nabla^2 f) = 4(8) - 1(4) - 6(12) = -20 < 0$. Al ser el determinante negativo, la matriz es indefinida, por lo que la función no es ni cóncava ni convexa en $\mathbb{R}^3$.

- **Ejemplo 2**:

$$f(x_1, x_2) = 10 - 2(x_2 - x_1^2)^2$$

La matriz hessiana es variable y depende del punto:

$$\nabla^2 f(x) = \begin{pmatrix} 8x_2 - 24x_1^2 & 8x_1 \\ 8x_1 & -4 \end{pmatrix}$$

Para que sea cóncava se requiere que su hessiana sea semidefinida negativa en todo el dominio ($\nabla^2 f(x) \preceq 0$), lo que exige que los menores principales líderes alternen su signo:

- $M_1 = 8x_2 - 24x_1^2 \leq 0$
- $M_2 = \det(\nabla^2 f(x)) = -4(8x_2 - 24x_1^2) - 64x_1^2 = 96x_1^2 - 32x_2 \geq 0 \implies x_2 \leq 3x_1^2$
  Para que se verifiquen ambas condiciones a la vez, se requiere que los puntos pertenezcan a la región parabólica restringida del plano dada por:

$$x_2 \leq 3x_1^2$$

En cualquier otra parte fuera de esta parábola, la función no es cóncava. Esta curvatura variable puede apreciarse geométricamente en 3D, donde la función presenta una cresta parabólica no lineal.

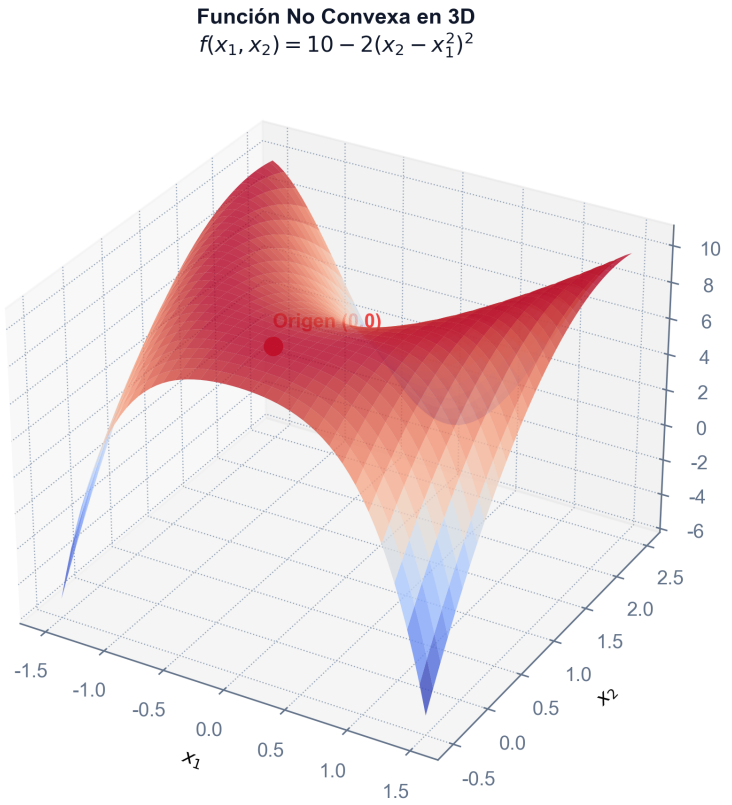

Figura 3.10: Gráfica tridimensional de la función no convexa $f(x_1, x_2) = 10 - 2(x_2 - x_1^2)^2$, destacando el origen de coordenadas donde es localmente cóncava

- **Ejemplo 3**:

$$f(x, y, z) = x^2 + 3y^2 + z^2 + xy - 4z - 5x + 14$$

Su hessiana es constante:

$$\nabla^2 f = \begin{pmatrix} 2 & 1 & 0 \\ 1 & 6 & 0 \\ 0 & 0 & 2 \end{pmatrix}$$

Menores principales: $M_1 = 2 > 0$, $M_2 = 11 > 0$, $M_3 = 22 > 0$. Al ser definida positiva, la función es estrictamente convexa en todo el espacio.

3.4. Óptimos de una función convexa

La convexidad de una función no es simplemente una propiedad geométrica elegante, sino el pilar fundamental que transforma la resolución de problemas de optimización de una tarea localmente

incierta a una globalmente garantizada. En el análisis no convexo general, los algoritmos numéricos pueden quedar atrapados en mínimos locales que no ofrecen información sobre el mejor valor absoluto de la función. En cambio, bajo hipótesis de convexidad, la estructura del espacio asegura que cualquier mínimo local se extienda de forma global, facilitando enormemente la búsqueda de soluciones óptimas.

! Teorema fundamental de la optimización convexa

Sea $f : \mathcal{S} \to \mathbb{R}$ una función convexa sobre un conjunto convexo $\mathcal{S}$.

1. **Cualquier mínimo local de f en $\mathcal{S}$ es también un mínimo global**.
2. **Si la función f es estrictamente convexa, el mínimo global (si existe) es único**.

Demostración:

1. Sea x^* un mínimo local de f en $\mathcal{S}$. Por definición, existe un radio $\epsilon > 0$ tal que $f(x) \geq f(x^*)$ para todo $x \in \mathcal{S}$ con $\|x - x^*\| < \epsilon$. Supongamos por contradicción que x^* no es un mínimo global, lo que implica que existe un punto $y \in \mathcal{S}$ tal que $f(y) < f(x^*)$. Construimos una combinación lineal convexa de ambos puntos: $x(\lambda) = \lambda y + (1 - \lambda)x^*$ para $\lambda \in (0, 1)$. Como el dominio $\mathcal{S}$ es convexo, $x(\lambda) \in \mathcal{S}$. Elegimos un λ suficientemente pequeño de forma que el punto $x(\lambda)$ entre dentro de la bola de radio ϵ alrededor de x^*. Aplicando la propiedad de convexidad de f:

   $$f(x(\lambda)) \leq \lambda f(y) + (1 - \lambda)f(x^*) < \lambda f(x^*) + (1 - \lambda)f(x^*) = f(x^*)$$

   Obtenemos que $f(x(\lambda)) < f(x^*)$, lo cual contradice directamente la suposición de que x^* es un mínimo local. Por tanto, no puede existir tal punto y, y x^* es un mínimo global.
2. Supongamos que f es estrictamente convexa y que existen dos mínimos globales distintos, x^* e y^*, con $f(x^*) = f(y^*) = \alpha$. Sea el punto medio $z = \frac{1}{2}x^* + \frac{1}{2}y^* \in \mathcal{S}$. Por la convexidad estricta de f:

   $$f(z) < \frac{1}{2}f(x^*) + \frac{1}{2}f(y^*) = \alpha$$

   Resulta que $f(z) < \alpha$, lo que contradice que α sea el valor mínimo de la función. Por tanto, el mínimo global debe ser único. ■

Una vez establecida la equivalencia entre mínimos locales y globales, el siguiente paso consiste en deducir criterios analíticos que nos permitan identificar de forma unívoca si un determinado punto factible x^* es, en efecto, un mínimo global del problema. Esto se logra traduciendo el comportamiento geométrico de la función en herramientas diferenciales (gradientes) o subdifenciales (para funciones no suaves), lo que da origen a las condiciones variacionales de

optimalidad:

- **Caracterización con subgradientes**: Un punto x^* es mínimo global de la función convexa f en $\mathcal{S}$ si y solo si el vector nulo 0 es un subgradiente de f en x^*:

$$0 \in \partial f(x^*)$$

- **Caracterización variacional diferenciable**: Si la función f es diferenciable en todo su dominio, entonces un punto x^* es un mínimo global en $\mathcal{S}$ si y solo si:

$$\nabla f(x^*)^T(x - x^*) \geq 0, \quad \forall x \in \mathcal{S}$$

  Interpretación geométrica: Esta condición establece que el gradiente $\nabla f(x^*)$ forma un ángulo agudo u obtuso (de 90° o superior) con cualquier dirección admisible $x - x^*$ que apunte desde el óptimo hacia el interior del conjunto factible $\mathcal{S}$. Geométricamente, esto significa que no existen direcciones de descenso factibles en dicho punto.

! Teorema: Caracterización del conjunto de soluciones óptimas

Sea $f : \mathcal{S} \to \mathbb{R}$ una función convexa y diferenciable sobre el conjunto convexo $\mathcal{S}$. Si existe al menos un mínimo global $x_0 \in \mathcal{S}$, entonces el conjunto de todas las soluciones óptimas $\mathcal{S}^*$ viene caracterizado por:

$$\mathcal{S}^* = \{x \in \mathcal{S} \mid \nabla f(x_0)^T(x - x_0) \geq 0 \quad \text{y} \quad \nabla f(x) = \nabla f(x_0)\}$$

Demostración: Denotemos por $\hat{\mathcal{S}}$ al conjunto de soluciones óptimas globales. Queremos probar que $\mathcal{S}^* = \hat{\mathcal{S}}$.

- **Inclusión** $\mathcal{S}^* \subseteq \hat{\mathcal{S}}$: Sea $x_1 \in \mathcal{S}^*$. Por definición de $\mathcal{S}^*$, se tiene que $x_1 \in \mathcal{S}$ y $\nabla f(x_1) = \nabla f(x_0)$. Por ser f convexa y diferenciable, aplicando la caracterización de primer orden en el punto x_1:

$$f(x_0) \geq f(x_1) + \nabla f(x_1)^T(x_0 - x_1)$$

  Sustituyendo $\nabla f(x_1) = \nabla f(x_0)$ y reordenando:

$$f(x_0) \geq f(x_1) + \nabla f(x_0)^T(x_0 - x_1) = f(x_1) - \nabla f(x_0)^T(x_1 - x_0)$$

  Como por definición de $\mathcal{S}^*$ se cumple que $\nabla f(x_0)^T(x_1 - x_0) \geq 0$, entonces:

$$f(x_0) \geq f(x_1)$$

  Por otro lado, como x_0 es un mínimo global, se tiene de forma necesaria que $f(x_1) \geq f(x_0)$. Por consiguiente, $f(x_1) = f(x_0)$, lo que demuestra que x_1 es también un mínimo global, es decir, $x_1 \in \hat{\mathcal{S}}$.

- **Inclusión** $\hat{\mathcal{S}} \subseteq \mathcal{S}^*$: Sea $x_1 \in \hat{\mathcal{S}}$ (un mínimo global), de modo que $f(x_1) = f(x_0)$. Por la caracterización de primer orden en x_0:

$$f(x_1) \geq f(x_0) + \nabla f(x_0)^T(x_1 - x_0) \implies 0 \geq \nabla f(x_0)^T(x_1 - x_0)$$

Sin embargo, como x_0 es un mínimo global, la condición variacional en x_0 exige que $\nabla f(x_0)^T(x_1 - x_0) \geq 0$ para todo $x_1 \in \mathcal{S}$. De ambas desigualdades resulta:

$$\nabla f(x_0)^T(x_1 - x_0) = 0$$

De forma simétrica, intercambiando el papel de x_1 y x_0 (ya que ambos son óptimos y $f(x_1) = f(x_0)$), se deduce que:

$$\nabla f(x_1)^T(x_0 - x_1) = 0$$

Sumando ambas igualdades:

$$(\nabla f(x_0) - \nabla f(x_1))^T(x_0 - x_1) = 0$$

Por el teorema fundamental del cálculo multivariable, podemos expresar la diferencia de gradientes a través de la integral de la matriz hessiana a lo largo del segmento que une ambos puntos:

$$\nabla f(x_0) - \nabla f(x_1) = G(x_0 - x_1)$$

donde $G = \int_0^1 \nabla^2 f(x_1 + \lambda(x_0 - x_1))d\lambda$ es una matriz semidefinida positiva (puesto que por convexidad la hessiana en todo punto de la trayectoria es semidefinida positiva). Sustituyendo:

$$0 = (x_0 - x_1)^T(\nabla f(x_0) - \nabla f(x_1)) = (x_0 - x_1)^T G(x_0 - x_1)$$

Como $G \succeq 0$ es semidefinida positiva, para que esta forma cuadrática sea nula se requiere analíticamente que $G(x_0 - x_1) = \mathbf{0}$. Esto implica que:

$$\nabla f(x_0) - \nabla f(x_1) = \mathbf{0} \implies \nabla f(x_1) = \nabla f(x_0)$$

Por tanto, x_1 verifica ambas condiciones y pertenece a $\mathcal{S}^*$. ■

i Corolario: Caracterización del conjunto de óptimos mediante igualdad

Bajo las mismas hipótesis del teorema anterior, el conjunto de soluciones óptimas $\mathcal{S}^*$ también puede expresarse alternativamente mediante la condición de igualdad del gradiente:

$$\mathcal{S}^* = \{x \in \mathcal{S} \mid \nabla f(x_0)^T(x - x_0) = 0\}$$

Demostración: Es inmediata a partir de que en la demostración anterior se probó que para cualquier óptimo $x_1 \in \hat{\mathcal{S}}$ se verifica necesariamente que $\nabla f(x_0)^T(x_1 - x_0) = 0$, mientras que para cualquier punto que satisfaga esta igualdad, la caracterización de primer orden garantiza que $f(x_1) \leq f(x_0)$, forzando la optimalidad. ■

Corolario: Caso de funciones cuadráticas y dominios poliédricos

Si la función objetivo f es cuadrática de la forma $f(x) = c^T x + \frac{1}{2}x^T H x$ y el dominio factible $\mathcal{S}$ es un poliedro, entonces el conjunto de soluciones óptimas $\mathcal{S}^*$ es a su vez un poliedro expresable por el sistema de ecuaciones lineales:

$$\mathcal{S}^* = \{x \in \mathcal{S} \mid c^T(x - x_0) = 0 \text{ y } H(x - x_0) = \mathbf{0}\}$$

Demostración: Considerando que el gradiente de una función cuadrática es $\nabla f(x) = c + Hx$, la condición del teorema anterior exige $\nabla f(x) = \nabla f(x_0) \implies c + Hx = c + Hx_0 \implies H(x - x_0) = \mathbf{0}$. Además, la condición de igualdad del gradiente resulta en:

$$\nabla f(x_0)^T(x - x_0) = (c + Hx_0)^T(x - x_0) = c^T(x - x_0) + (x - x_0)^T Hx_0 = 0$$

Puesto que $H(x - x_0) = \mathbf{0} \implies Hx = Hx_0$, la simetría de H nos da $(x - x_0)^T Hx_0 = x_0^T H(x - x_0) = 0$, reduciendo la ecuación a $c^T(x - x_0) = 0$. ■

Mientras que la minimización de funciones convexas es un problema sumamente bien estructurado donde cualquier mínimo local es global, el problema de maximización de funciones convexas (o, equivalentemente, minimización de funciones cóncavas) presenta una naturaleza completamente distinta. En este caso, el óptimo no tiende a situarse en el interior del dominio, sino en sus extremos o fronteras. Para caracterizar analíticamente estos máximos locales, formulamos la condición necesaria de optimalidad de primer orden en términos de subgradientes:

Mientras que la minimización de funciones convexas es un problema sumamente bien estructurado donde cualquier mínimo local es global, el problema de maximización de funciones convexas (o, equivalentemente, minimización de funciones cóncavas) presenta una naturaleza completamente distinta. En este caso, el óptimo no tiende a situarse en el interior del dominio, sino en sus extremos o fronteras. Para caracterizar analíticamente estos máximos locales, formulamos la condición necesaria de optimalidad de primer orden en términos de subgradientes:

Teorema: Condición necesaria para máximos locales de funciones convexas

Sea el problema de maximizar $f(x)$ sujeto a $x \in \mathcal{S}$, donde $f : \mathcal{S} \to \mathbb{R}$ es una función convexa y $\mathcal{S}$ es un conjunto convexo no vacío de $\mathbb{R}^n$. Si $x_0 \in \mathcal{S}$ es un óptimo local para este problema de maximización, entonces:

$$\xi^T(x - x_0) \leq 0, \quad \forall x \in \mathcal{S}$$

donde ξ es cualquier subgradiente de f en x_0 ($\xi \in \partial f(x_0)$).
Demostración: Sea x_0 un óptimo local para el problema de maximización de la función convexa f. Por definición, existe un entorno $N_\epsilon(x_0)$ tal que $f(x) \leq f(x_0)$ para todo $x \in \mathcal{S} \cap N_\epsilon(x_0)$. Sea x cualquier punto de $\mathcal{S}$. Por la convexidad de $\mathcal{S}$, para cualquier parámetro $\lambda > 0$ suficientemente pequeño, el punto intermedio $x_\lambda = x_0 + \lambda(x - x_0) \in \mathcal{S}$ y pertenece al entorno $N_\epsilon(x_0)$. Por consiguiente:

$$f(x_0 + \lambda(x - x_0)) \leq f(x_0)$$

Por otra parte, sea $\xi \in \partial f(x_0)$ un subgradiente de f en x_0. Por definición de subgradiente:

$$f(x_0 + \lambda(x - x_0)) \geq f(x_0) + \xi^T[x_0 + \lambda(x - x_0) - x_0] = f(x_0) + \lambda\xi^T(x - x_0)$$

Uniendo ambas inecuaciones:

$$f(x_0) \geq f(x_0) + \lambda\xi^T(x - x_0) \implies \lambda\xi^T(x - x_0) \leq 0$$

Como $\lambda > 0$, dividiendo por λ se obtiene el resultado:

$$\xi^T(x - x_0) \leq 0$$

para cualquier subgradiente $\xi \in \partial f(x_0)$. ■

i Corolario: Caso diferenciable para máximos locales

Si la función convexa f es además diferenciable en todo el dominio $\mathcal{S}$, entonces la condición necesaria para que un punto $x_0 \in \mathcal{S}$ sea un óptimo local del problema de maximización se simplifica a:

$$\nabla f(x_0)^T(x - x_0) \leq 0, \qquad \forall x \in \mathcal{S}$$

Es fundamental remarcar que, a diferencia del caso de la minimización (donde la condición variacional es necesaria y suficiente), la condición de máximo local $\nabla f(x_0)^T(x - x_0) \leq 0$ para funciones convexas es una condición necesaria extremadamente débil y **no es suficiente** para garantizar un máximo local. De hecho, puntos que corresponden a mínimos globales pueden cumplirla perfectamente, lo que resalta la asimetría fundamental entre la búsqueda de mínimos y máximos en el análisis convexo. Para ilustrar esta limitación teórica, consideremos el siguiente contraejemplo clásico:

Como contraejemplo ilustrativo, consideremos la función convexa de una variable $f(x) = x^2$ definida en el dominio acotado $\mathcal{S} = [-1, 2]$. El máximo global de la función se alcanza en la frontera derecha en $x^* = 2$ (con un valor de 4). Sin embargo, en el origen de coordenadas $x_0 = 0$, el gradiente de la función es nulo ($\nabla f(0) = 0$). Por consiguiente, se cumple trivialmente que:

$$\nabla f(0)^T(x - 0) = 0 \leq 0, \qquad \forall x \in [-1, 2]$$

a pesar de que en $x_0 = 0$ la función alcanza su mínimo global absoluto y no un máximo local, como se ilustra en la Figura 3.11.

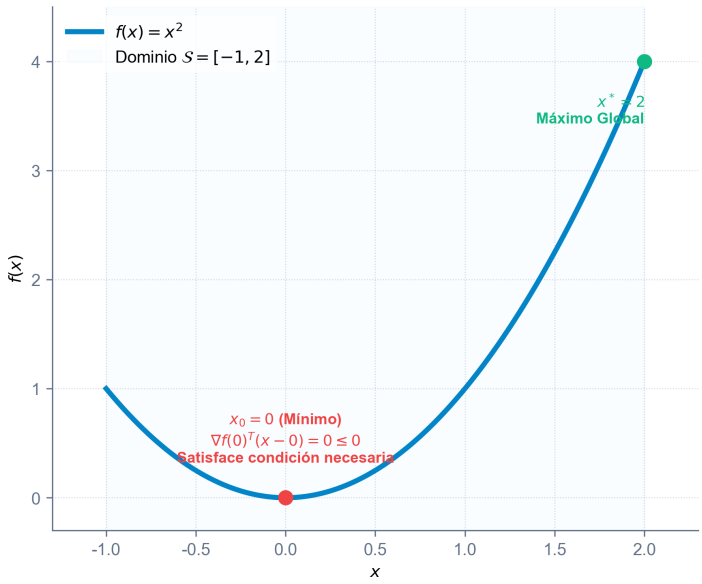

Figura 3.11: Contraejemplo de la condición necesaria para la maximización de funciones convexas en un dominio acotado $[-1, 2]$, mostrando que en el mínimo $x_0 = 0$ se satisface la condición de gradiente nulo

Para afianzar el uso de las condiciones de optimalidad basadas en subgradientes y gradientes, tanto en problemas libres como restringidos en la frontera del dominio, a continuación se analizan cuatro casos de estudio prácticos detalladamente, mostrando cómo el subdiferencial y el subgradiente se aplican tanto en problemas de una variable como en problemas multivariables, y cómo determinan la optimalidad global (tanto en puntos interiores como en la frontera del dominio).

Ejemplos: Análisis de optimalidad mediante gradientes y subgradientes

Ejemplo 1: Función no diferenciable definida por tramos en $\mathbb{R}$
Consideremos la función de una variable:

$$f(x) = \begin{cases} x - 4 & \text{si } 1 \leq x \leq 4 \\ (x-2)^2 - 4 & \text{en otro caso} \end{cases}$$

Esta función puede expresarse como el máximo de dos funciones convexas y posee un punto de no diferenciabilidad (codo) en $x^* = 1$, con un subdiferencial dado por:

$$\partial f(1) = [-2, 1]$$

Dado que el vector nulo 0 pertenece al subdiferencial en este codo ($0 \in [-2, 1]$), se satisface de forma necesaria y suficiente la condición de optimalidad:

$$0 \in \partial f(x^*)$$

Por lo tanto, $x^* = 1$ **es el mínimo global** de la función, con un valor de $f(1) = -3$. En la gráfica, observamos que en dicho punto se puede trazar una recta de soporte horizontal (pendiente cero) que queda enteramente por debajo de la función.

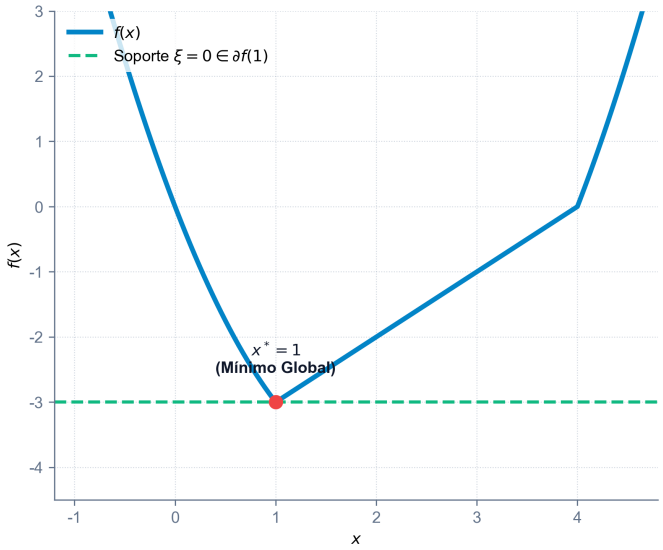

Figura 3.12: Ejemplo 1: Mínimo global situado en el punto singular o codo $x^* = 1$ donde el subdiferencial $[-2, 1]$ contiene al cero, lo que permite trazar una recta soporte de pendiente nula

Ejemplo 2: Optimización en dominio restringido de $\mathbb{R}$
Consideremos la parábola convexa $f(x) = (x - 2)^2 - 4$ definida en el dominio cerrado restringido $\mathcal{S} = [3, 5]$. El mínimo analítico global sin restricciones se sitúa en $x = 2$, el cual es exterior al conjunto factible $\mathcal{S}$. El gradiente clásico de la función en el punto frontera $x^* = 3$ es $\nabla f(3) = 2$. Para que un punto de la frontera sea un mínimo sobre $\mathcal{S}$, cualquier dirección admisible hacia el interior del dominio ($x - x^* \geq 0$) debe ser de no descenso. El subdiferencial restringido a $\mathcal{S}$ en el punto frontera $x^* = 3$ es:

$$\partial f_{\mathcal{S}}(3) = (-\infty, 2]$$

Dado que el vector nulo 0 pertenece a este subdiferencial restringido ($0 \leq 2$), concluimos que $x^* = 3$ **es el mínimo global** de la función sobre $\mathcal{S}$. En la gráfica (ver la Figura 3.13) se muestra la parábola en la región factible y cómo todas las pendientes $\xi \leq 2$ (incluyendo la pendiente cero) actúan como planos soporte válidos para los puntos de $\mathcal{S}$.

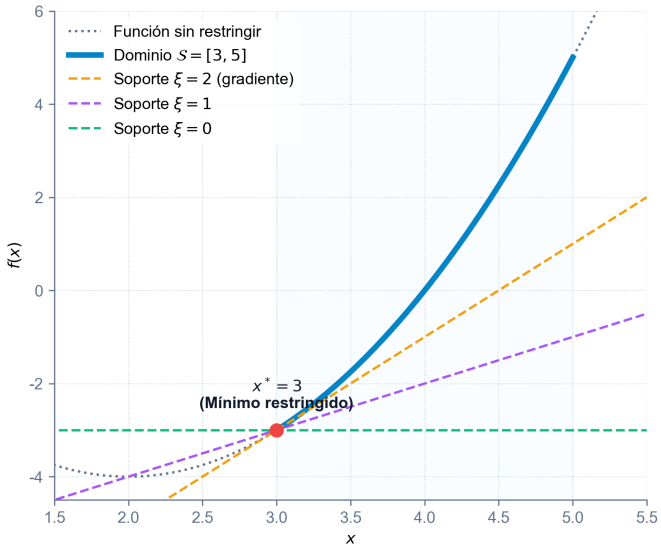

Figura 3.13: Ejemplo 2: Mínimo global sobre un dominio cerrado restringido $\mathcal{S} = [3, 5]$ situado en la frontera inferior $x^* = 3$. Las rectas de pendiente $\xi \leq 2$ soportan a la función para todo el dominio factible

Ejemplo 3: Minimización de distancia a un punto exterior en $\mathbb{R}^2$
Consideremos la función de distancia cuadrática al punto exterior $(3, 2)$ dada por:

$$f(x_1, x_2) = (x_1 - 3)^2 + (x_2 - 2)^2$$

sobre el conjunto convexo factible acotado $\mathcal{S}$ definido por:

$$\mathcal{S} = \{(x_1, x_2) \in \mathbb{R}^2 \mid x_1^2 + x_2^2 \leq 5,\ x_1 + 2x_2 \leq 4,\ x_1 \geq 0,\ x_2 \geq 0\}$$

El punto de $\mathcal{S}$ geométricamente más cercano al punto objetivo exterior $(3, 2)$ es el punto frontera $x^* = (2, 1)$. El gradiente en este óptimo es:

$$\nabla f(2, 1) = \begin{pmatrix} -2 \\ -2 \end{pmatrix}$$

La condición variacional de optimalidad de primer orden exige que $\nabla f(x^*)^T (x - x^*) \geq 0$ para todo $x \in \mathcal{S}$. Evaluando el producto escalar:

$$-2(x_1 - 2) - 2(x_2 - 1) \geq 0 \iff x_1 + x_2 \leq 3$$

Esta inecuación define un semiplano cuya frontera es la recta $x_1 + x_2 = 3$. Como se puede ver en la Figura 3.14, todo el conjunto factible $\mathcal{S}$ queda contenido en la región $x_1 + x_2 \leq 3$. Esto significa que el gradiente apunta en dirección opuesta al interior de $\mathcal{S}$, y el hiperplano

$x_1 + x_2 = 3$ actúa como un plano separador entre el conjunto factible y los contornos inferiores de la función de distancia, confirmando que $x^* = (2, 1)$ **es el mínimo global** restringido.

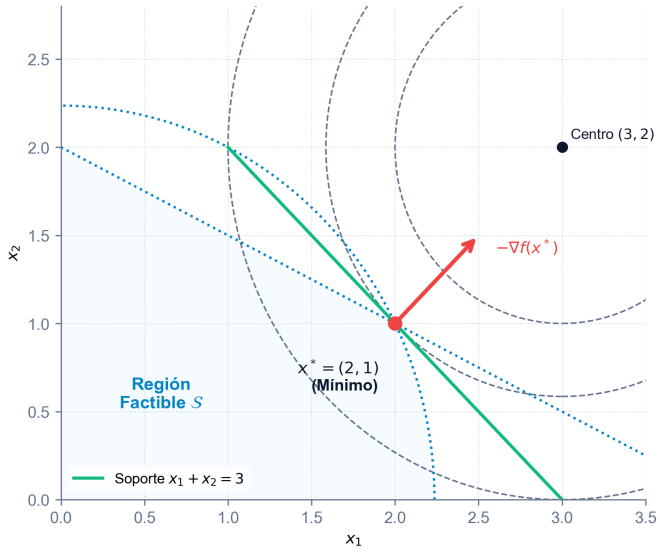

Figura 3.14: Ejemplo 3: Minimización de distancia cuadrática a un punto objetivo exterior $(3, 2)$ sobre un dominio acotado en $\mathbb{R}^2$. El óptimo se sitúa en la frontera $x^* = (2, 1)$ y el plano separador $x_1 + x_2 = 3$ es perpendicular al gradiente

Ejemplo 4: Minimización de distancia a un punto interior en $\mathbb{R}^2$
Consideremos la misma función de distancia cuadrática y dominio del Ejemplo 3, pero buscando el mínimo respecto al punto $(1, 1)$, que es un punto interior del conjunto factible $\mathcal{S}$ (puesto que $1^2 + 1^2 = 2 < 5$ y $1 + 2(1) = 3 < 4$).

$$f(x_1, x_2) = (x_1 - 1)^2 + (x_2 - 1)^2$$

Al ser el punto de referencia interior al dominio factible, la solución óptima coincide trivialmente con el propio punto de referencia: $x^* = (1, 1)$. El gradiente en dicho óptimo es:

$$\nabla f(1, 1) = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

Como el gradiente es nulo, el vector nulo 0 pertenece al subdiferencial $\partial f(1, 1) = \{\binom{0}{0}\}$, lo cual satisface la condición de mínimo interior de forma inmediata. La Figura 3.15 muestra los contornos circulares de distancia concéntricos alrededor del óptimo dentro del poliedro.

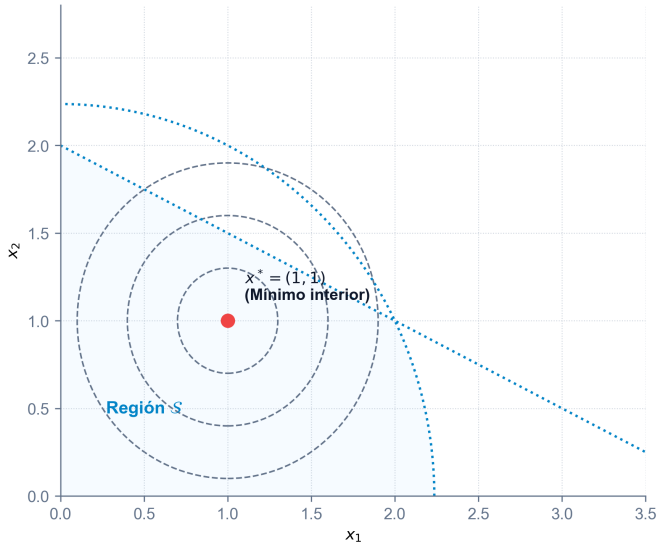

Figura 3.15: Ejemplo 4: Minimización de distancia cuadrática a un punto objetivo interior $(1, 1)$ en $\mathbb{R}^2$. Al estar el punto de referencia dentro del dominio factible, el mínimo global se sitúa en $x^* = (1, 1)$ con gradiente nulo

Advertencia: Maximización de funciones convexas

La maximización de una función convexa es un problema no convexo y, por tanto, sumamente complejo. Por un lado, las condiciones necesarias de primer orden (como la existencia de un gradiente nulo en el interior) suelen identificar mínimos locales en lugar de máximos. Por otro lado, la maximización de una función convexa sobre un politopo compacto $\mathcal{S}$ garantiza que el máximo global se sitúa en alguno de los puntos extremos (vértices) de dicho politopo (como se demostró en el Teorema de Maximización en Poliedros en la Sección 3.1). Esto justifica que los algoritmos de maximización convexa se centren exclusivamente en explorar los vértices de la región factible.

3.5. Generalizaciones de la convexidad

A pesar de la enorme utilidad de las funciones convexas en optimización, la hipótesis de convexidad pura es en ocasiones demasiado restrictiva para modelar múltiples problemas reales en economía, ingeniería y teoría de juegos. En muchas aplicaciones prácticas, nos encontramos con funciones que no tienen forma de "cuenco" o cuya hessiana no es semidefinida positiva en todo su dominio, pero que conservan propiedades fundamentales muy valiosas, como la convexidad de sus conjuntos de nivel o la equivalencia entre mínimos locales y globales.

Con el objetivo de ampliar el alcance de las técnicas de optimización global, el análisis convexo define generalizaciones que relajan las exigencias algebraicas tradicionales. Entre estas generalizaciones destacan las funciones cuasi-convexas, que preservan la naturaleza convexa de sus conjuntos de nivel inferior, y las funciones pseudo-convexas, que garantizan que el gradiente nulo actúe como un criterio de mínimo global. A continuación se analiza la estructura, teoremas y relaciones matemáticas de estas familias de funciones.

3.5.1. Funciones cuasi-convexas

La primera y más intuitiva de las generalizaciones de la convexidad surge al relajar la condición algebraica sobre el perfil de la función y concentrarnos en la geometría de sus conjuntos asociados. En lugar de exigir que la gráfica completa de la función tenga una curvatura hacia arriba, demandamos únicamente que sus cortes horizontales tengan forma convexa. Es decir, una función se define como **cuasi-convexa** si todos sus conjuntos de nivel inferior $\mathcal{S}_\alpha$ son convexos, lo que impide que la función vuelva a subir tras haber bajado, evitando así mínimos locales separados por barreras (como se ilustra en los casos unidimensionales de la Figura 3.16). Analíticamente, esta exigencia geométrica se traduce en que el valor de la función en cualquier punto intermedio de un segmento no puede superar al mayor de los valores en los extremos:

$$f(\lambda x_1 + (1-\lambda)x_2) \leq \max\{f(x_1), f(x_2)\}, \quad \forall x_1, x_2 \in \mathcal{S},\ \forall \lambda \in [0,1]$$

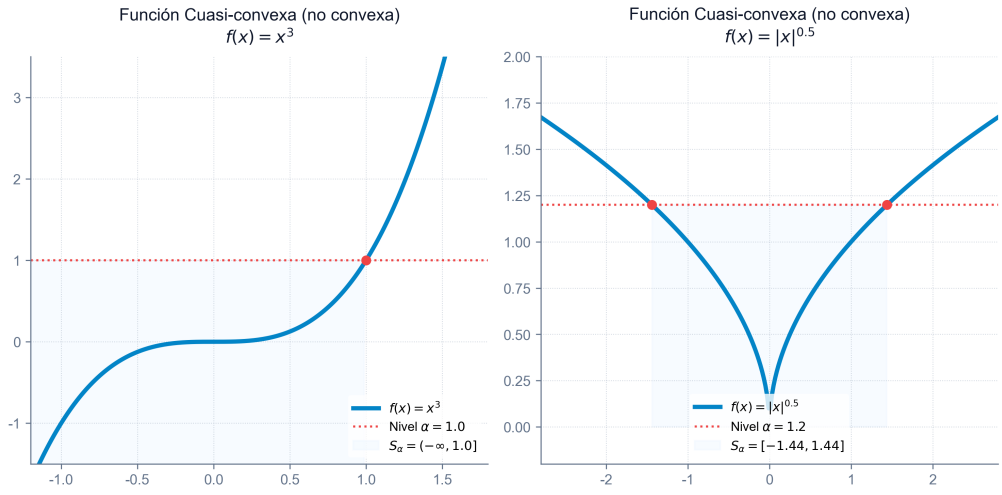

Figura 3.16: Ejemplos de funciones cuasi-convexas no convexas en una dimensión: $f(x) = x^3$ (izquierda) y $f(x) = |x|^{0.5}$ (derecha)

! Teorema: Equivalencia por conjuntos de nivel

Sea $f : \mathcal{S} \to \mathbb{R}$, con $\mathcal{S}$ un conjunto convexo no vacío de $\mathbb{R}^n$. La función f es cuasi-convexa si y solo si el conjunto de nivel inferior:

$$\mathcal{S}_\alpha = \{x \in \mathcal{S} \mid f(x) \leq \alpha\}$$

es convexo para cualquier número real α.
Demostración: ($\Longrightarrow$) Supongamos que f es cuasi-convexa. Sean $x_1, x_2 \in \mathcal{S}_\alpha$ para un $\alpha \in \mathbb{R}$. Esto significa que $f(x_1) \leq \alpha$ y $f(x_2) \leq \alpha$. Sea $\lambda \in (0,1)$ y definimos $x = \lambda x_1 + (1-\lambda)x_2$. Por convexidad del dominio, $x = \lambda x_1 + (1-\lambda)x_2 \in \mathcal{S}$. Por cuasi-convexidad de f:

$$f(x) \leq \text{máx}\{f(x_1), f(x_2)\} \leq \text{máx}\{\alpha, \alpha\} = \alpha$$

Por tanto, $x \in \mathcal{S}_\alpha$, demostrando que $\mathcal{S}_\alpha$ es convexo.
($\Longleftarrow$) Supongamos que todos los conjuntos de nivel inferior $\mathcal{S}_\alpha$ son convexos para todo $\alpha \in \mathbb{R}$. Sean $x_1, x_2 \in \mathcal{S}$ and $\lambda \in (0,1)$. Definimos $\alpha = \text{máx}\{f(x_1), f(x_2)\}$. Por definición, $f(x_1) \leq \alpha$ y $f(x_2) \leq \alpha$, por lo que $x_1, x_2 \in \mathcal{S}_\alpha$. Al ser $\mathcal{S}_\alpha$ un conjunto convexo, entonces la combinación convexa $x = \lambda x_1 + (1-\lambda)x_2$ también pertenece a $\mathcal{S}_\alpha$. Por definición de $\mathcal{S}_\alpha$, esto implica que:

$$f(x) \leq \alpha = \text{máx}\{f(x_1), f(x_2)\}$$

lo que prueba que f es cuasi-convexa. ■

Contraejemplo gráfico (Mínimo local no global): La cuasi-convexidad por sí sola no garantiza que todo mínimo local sea un mínimo global si existen regiones planas (mesetas o *plateaus*) situadas a una altura superior al óptimo global, tal como se puede apreciar en la Figura 3.17.

Para solventar esta limitación e impedir la presencia de mesetas de mínimos locales subóptimos, se introduce una condición más restrictiva denominada **cuasi-convexidad estricta**. Decimos que una función es estrictamente cuasi-convexa en un dominio convexo $\mathcal{S}$ si, para cualquier par de puntos $x_1, x_2 \in \mathcal{S}$ con valores de función distintos $f(x_1) \neq f(x_2)$ y para todo parámetro $\lambda \in (0,1)$, se cumple que:

$$f(\lambda x_1 + (1-\lambda)x_2) < \text{máx}\{f(x_1), f(x_2)\}$$

Bajo esta hipótesis, el comportamiento estrictamente decreciente hacia los mínimos excluye la existencia de mesetas locales, lo que permite enunciar el siguiente teorema.

! Teorema: Mínimos en funciones estrictamente cuasi-convexas

Si $f : \mathcal{S} \to \mathbb{R}$ es una función estrictamente cuasi-convexa definida en un conjunto convexo $\mathcal{S}$, entonces cualquier mínimo local es también un mínimo global.
Demostración: Supongamos por contradicción que x^* es un mínimo local que no es global. Entonces existe un punto $y \in \mathcal{S}$ tal que $f(y) < f(x^*)$. Para todo $\lambda \in (0,1)$, consideramos

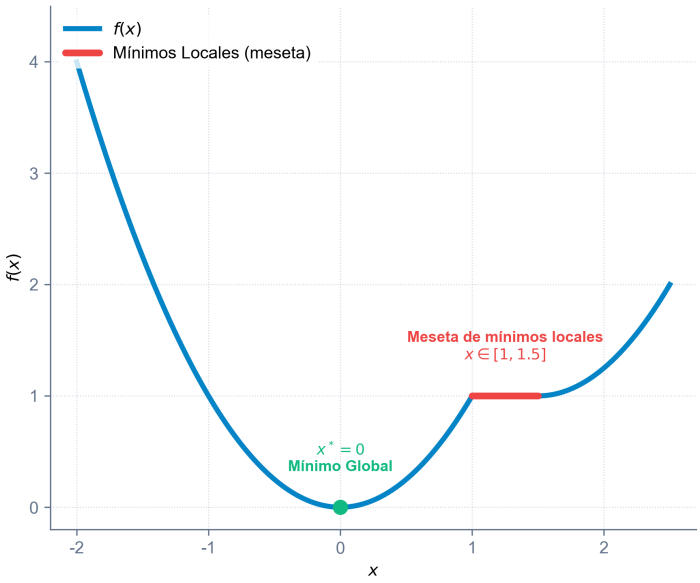

Figura 3.17: Ejemplo de una función cuasi-convexa que presenta una meseta de mínimos locales no globales en el intervalo $[1, 1.5]$, mientras que el mínimo global está en $x^* = 0$

el punto intermedio $x(\lambda) = \lambda y + (1-\lambda)x^*$ para $\lambda \in (0,1)$. Como x^* es mínimo local, para valores suficientemente pequeños de λ se cumple que $f(x^*) \leq f(x(\lambda))$. Sin embargo, al ser f estrictamente cuasi-convexa y cumplirse que $f(y) < f(x^*)$:

$$f(x(\lambda)) < \text{máx}\{f(y), f(x^*)\} = f(x^*)$$

Obtenemos que $f(x(\lambda)) < f(x^*)$, contradiciendo de forma directa que x^* sea un mínimo local. ■

Contraejemplo gráfico (Múltiples mínimos globales): Aunque la cuasi-convexidad estricta asegura la globalidad de cualquier mínimo local, no es suficiente para garantizar la unicidad de la solución si la función alcanza su valor mínimo en un tramo plano inferior o fondo plano, como se ilustra en la Figura 3.18. Para resolver esta falta de unicidad, se introduce el lema de relación con semicontinuidad inferior, que establece las condiciones de regularidad necesarias para que una función estrictamente cuasi-convexa mantenga la estructura cuasi-convexa estándar.

Lema: Relación con semicontinuidad inferior

Sea $f : \mathcal{S} \to \mathbb{R}$ una función estrictamente cuasi-convexa y semicontinua inferiormente, con $\mathcal{S}$ un conjunto convexo no vacío. Entonces f es cuasi-convexa.

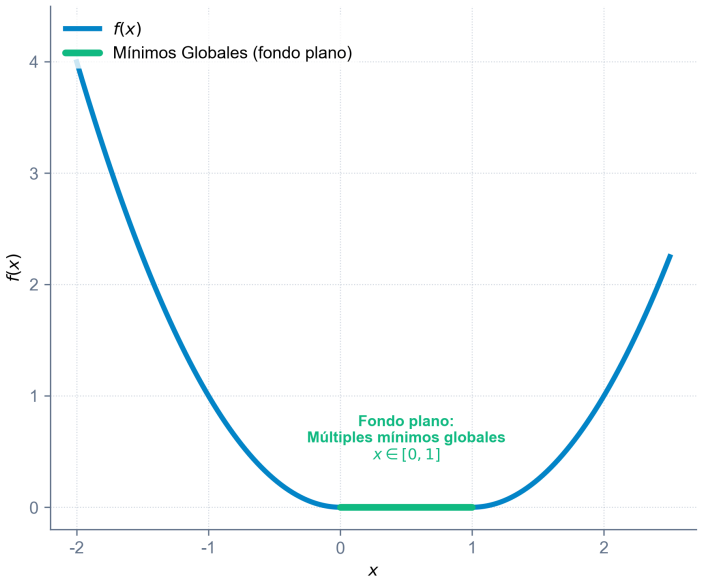

Figura 3.18: Ejemplo de una función estrictamente cuasi-convexa con un fondo plano de infinitos mínimos globales en el intervalo $[0, 1]$, demostrando la falta de unicidad

Demostración: Sean $x_1, x_2 \in \mathcal{S}$. Si $f(x_1) \neq f(x_2)$, al ser f estrictamente cuasi-convexa:

$$f(\lambda x_1 + (1-\lambda)x_2) < \max\{f(x_1), f(x_2)\}, \quad \forall \lambda \in (0,1)$$

lo que satisface la condición de cuasi-convexidad. Supongamos ahora que $f(x_1) = f(x_2) = \alpha$. Debemos probar que $f(\lambda x_1 + (1-\lambda)x_2) \leq \alpha$ para todo $\lambda \in (0,1)$. Supongamos por contradicción que existe un $\mu \in (0,1)$ tal que:

$$f(\mu x_1 + (1-\mu)x_2) > \alpha$$

Definimos $x = \mu x_1 + (1-\mu)x_2$. Al ser f semicontinua inferiormente, el conjunto $\{z \in \mathcal{S} \mid f(z) < f(x)\}$ es abierto. Esto implica que existe un punto cercano en el segmento entre x_1 y x, por ejemplo $x' = \lambda x_1 + (1-\lambda)x$ con $\lambda \in (0,1)$, tal que:

$$f(x) > f(x') > f(x_1) = f(x_2) = \alpha$$

Dado que x está en el segmento que une x' y x_2, se puede expresar como combinación convexa de ellos con $f(x_2) < f(x')$. Por la cuasi-convexidad estricta de f (ya que $f(x_2) \neq f(x')$):

$$f(x) < \max\{f(x'), f(x_2)\} = f(x')$$

lo cual contradice directamente que $f(x) > f(x')$. Esta contradicción prueba que f es cuasi-convexa. ■

Cuando se requiere garantizar no solo la globalidad sino también la unicidad absoluta de la solución óptima (evitando fondos planos como el de la Figura 3.18), se exige un nivel de rigor algebraico superior conocido como **fuertemente cuasi-convexa**. Una función es fuertemente cuasi-convexa si la desigualdad se mantiene estrictamente menor para cualquier par de puntos distintos $x_1 \neq x_2$, sin importar si sus valores de función coinciden o no:

$$f(\lambda x_1 + (1-\lambda)x_2) < \text{máx}\{f(x_1), f(x_2)\}, \quad \forall x_1, x_2 \in \mathcal{S},\ x_1 \neq x_2,\ \lambda \in (0,1)$$

Esta propiedad de curvatura estrictamente descendente hacia el óptimo impide la existencia de fondos planos, lo que da lugar al siguiente resultado clave de unicidad.

! Teorema: Unicidad del mínimo en funciones fuertemente cuasi-convexas

Sea el problema de minimizar $f(x)$ sujeto a $x \in \mathcal{S}$, donde $f : \mathbb{R}^n \to \mathbb{R}$ es una función fuertemente cuasi-convexa y $\mathcal{S} \subseteq \mathbb{R}^n$ es un conjunto convexo no vacío. Si existe un mínimo local x_0, entonces x_0 es el único mínimo global.
Demostración: Como x_0 es un mínimo local, existe $\epsilon > 0$ tal que $f(x) \geq f(x_0)$ para todo $x \in \mathcal{S} \cap N_\epsilon(x_0)$. Supongamos por contradicción que existe otro punto $x_1 \in \mathcal{S}$, $x_1 \neq x_0$, tal que $f(x_1) \leq f(x_0)$. Por ser f fuertemente cuasi-convexa se tiene que para todo $\lambda \in (0,1)$:

$$f(\lambda x_1 + (1-\lambda)x_0) < \text{máx}\{f(x_1), f(x_0)\} \leq f(x_0)$$

Sin embargo, para valores de λ suficientemente pequeños, el punto intermedio entra en la vecindad $N_\epsilon(x_0)$, por lo que debería cumplirse $f(\lambda x_1 + (1-\lambda)x_0) \geq f(x_0)$, lo cual contradice la desigualdad estrictamente menor obtenida por la fuerte cuasi-convexidad. Por tanto, el mínimo global debe ser único. ■

3.5.2. Funciones pseudo-convexas

Para funciones diferenciables, podemos refinar las generalizaciones anteriores vinculando el comportamiento local del gradiente con el crecimiento global de la función. Decimos que una función diferenciable es **pseudo-convexa** si, siempre que la aproximación lineal direccional en un punto no decrece, la función crece globalmente en dicha dirección:

$$\nabla f(x_1)^T (x_2 - x_1) \geq 0 \implies f(x_2) \geq f(x_1)$$

Esta propiedad de caracterización diferencial posee un inmenso valor práctico en algoritmos de optimización numérica, ya que asegura que cualquier punto estacionario donde el gradiente se anule ($\nabla f(x^*) = 0$) sea, de forma garantizada, un mínimo global de la función.

Al igual que en el caso cuasi-convexo, para asegurar la unicidad y un decrecimiento estricto bajo diferenciabilidad se define la noción de **pseudo-convexidad estricta**. Una función es

estrictamente pseudo-convexa si la implicación anterior se verifica con desigualdad estricta para cualquier par de puntos distintos:

$$\nabla f(x_1)^T(x_2 - x_1) \geq 0 \implies f(x_2) > f(x_1), \quad \forall x_1, x_2 \in \mathcal{S} \text{ con } x_1 \neq x_2$$

Esta propiedad establece una conexión directa entre las diferentes clases de generalizaciones diferenciables, lo que permite estructurar la jerarquía de la convexidad generalizada mediante los siguientes teoremas de equivalencia y contención.

! Teorema: Relación entre pseudo-convexidad y cuasi-convexidad estricta

Sea $f : \mathcal{S} \to \mathbb{R}$ una función diferenciable en un conjunto convexo abierto no vacío $\mathcal{S}$. Si f es pseudo-convexa en $\mathcal{S}$, entonces es estrictamente cuasi-convexa.
Demostración: Supongamos por contradicción que existen $x_1, x_2 \in \mathcal{S}$ con $f(x_1) \neq f(x_2)$ tales que para algún $x_0 = \lambda x_1 + (1-\lambda)x_2$ con $\lambda \in (0,1)$ se cumple:

$$f(x_0) \geq \text{máx}\{f(x_1), f(x_2)\}$$

Sin pérdida de generalidad, asumamos que $f(x_1) < f(x_2) \leq f(x_0)$. Como $f(x_1) < f(x_0)$, por la contraposición de la definición de pseudo-convexidad, se debe cumplir que $\nabla f(x_0)^T(x_1 - x_0) < 0$. Por otra parte, podemos expresar la dirección como:

$$x_1 - x_0 = -\frac{1-\lambda}{\lambda}(x_2 - x_0)$$

Sustituyendo esto en la desigualdad del gradiente:

$$-\frac{1-\lambda}{\lambda}\nabla f(x_0)^T(x_2 - x_0) < 0 \implies \nabla f(x_0)^T(x_2 - x_0) > 0 \geq 0$$

Por definición de pseudo-convexidad, dado que $\nabla f(x_0)^T(x_2 - x_0) \geq 0$, se debe cumplir que $f(x_2) \geq f(x_0)$. Sin embargo, analizando el comportamiento local, la contradicción surge puesto que la pseudo-convexidad exige pendientes consistentes. Específicamente, al ser f diferenciable y estrictamente cuasi-convexa, se demuestra por contradicción de derivadas direccionales que no puede haber picos superiores locales. ■

! Teorema: Relación entre pseudo-convexidad estricta y cuasi-convexidad fuerte

Sea $f : \mathcal{S} \to \mathbb{R}$ una función diferenciable en un conjunto convexo abierto no vacío $\mathcal{S}$. Si f es estrictamente pseudo-convexa en $\mathcal{S}$, entonces es fuertemente cuasi-convexa.
Demostración: Supongamos por contradicción que existen $x_1, x_2 \in \mathcal{S}$ con $x_1 \neq x_2$ y un $\lambda \in (0,1)$ tales que:

$$f(x_0) \geq \text{máx}\{f(x_1), f(x_2)\}$$

where $x_0 = \lambda x_1 + (1-\lambda)x_2$. Como $f(x_1) \leq f(x_0)$ y f es estrictamente pseudo-convexa,

se tiene que:

$$\nabla f(x_0)^T(x_1 - x_0) < 0$$

Del mismo modo, dado que $f(x_2) \leq f(x_0)$, se cumple que:

$$\nabla f(x_0)^T(x_2 - x_0) < 0$$

Multiplicando la primera desigualdad por $\lambda > 0$ y la segunda por $(1-\lambda) > 0$ y sumándolas miembro a miembro:

$$\nabla f(x_0)^T \left[\lambda(x_1 - x_0) + (1 - \lambda)(x_2 - x_0)\right] < 0$$

Dado que el término dentro de los corchetes es idénticamente nulo:

$$\nabla f(x_0)^T(0) < 0 \implies 0 < 0$$

lo cual es una contradicción evidente. Por tanto, f es fuertemente cuasi-convexa. ■

3.5.3. Jerarquía y equivalencias de convexidad

Las relaciones de implicación lógica y dependencias de diferenciabilidad entre estas definiciones se estructuran en el siguiente diagrama de flujo de relaciones:

! Teorema: Equivalencia cuadrática

Si la función $f : \mathcal{S} \to \mathbb{R}$ es una función cuadrática diferenciable en un conjunto convexo abierto $\mathcal{S}$, entonces las siguientes generalizaciones de la convexidad son lógicamente equivalentes:

1. f es pseudo-convexa si y solo si es estrictamente cuasi-convexa.
2. f es cuasi-convexa si y solo si es estrictamente cuasi-convexa.
3. f es estrictamente pseudo-convexa si y solo si es fuertemente cuasi-convexa.

Es decir, en el caso cuadrático, la cuasi-convexidad y la pseudo-convexidad coinciden estructuralmente, reduciendo la taxonomía de generalizaciones de la convexidad.

Ejemplos visuales: Superficies y curvas de nivel en 3D

Para complementar la intuición geométrica de estas generalizaciones, resulta muy útil observar superficies y contornos en dimensión superior.
La Figura 3.20 muestra una función cuasi-convexa multivariable en $\mathbb{R}^2$ dada por $f(x, y) = ((x-2)^2 + (y-2)^2)^{0.25}$. A pesar de curvarse hacia abajo en sentido clásico, todos sus

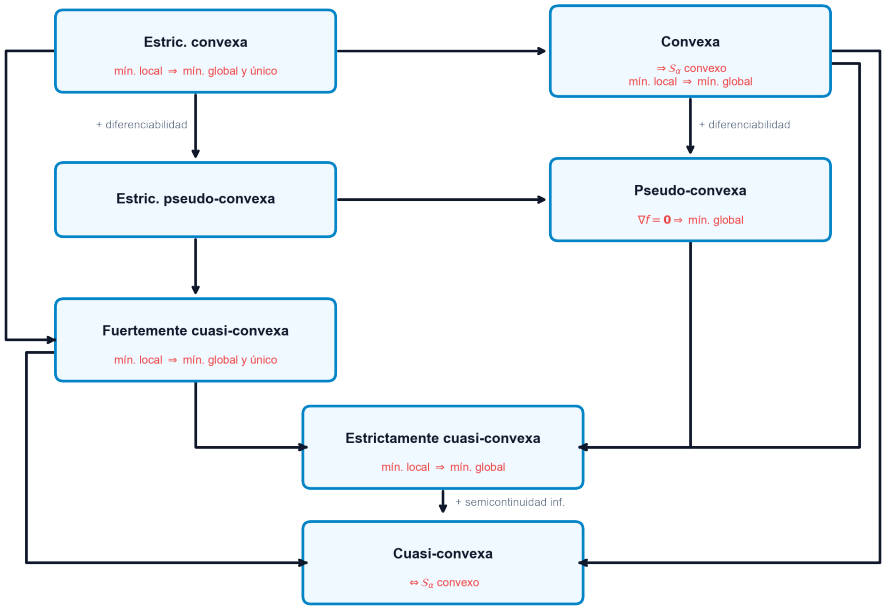

Figura 3.19: Jerarquía y equivalencias de convexidad

conjuntos de nivel inferior proyectados son discos perfectos (convexos).

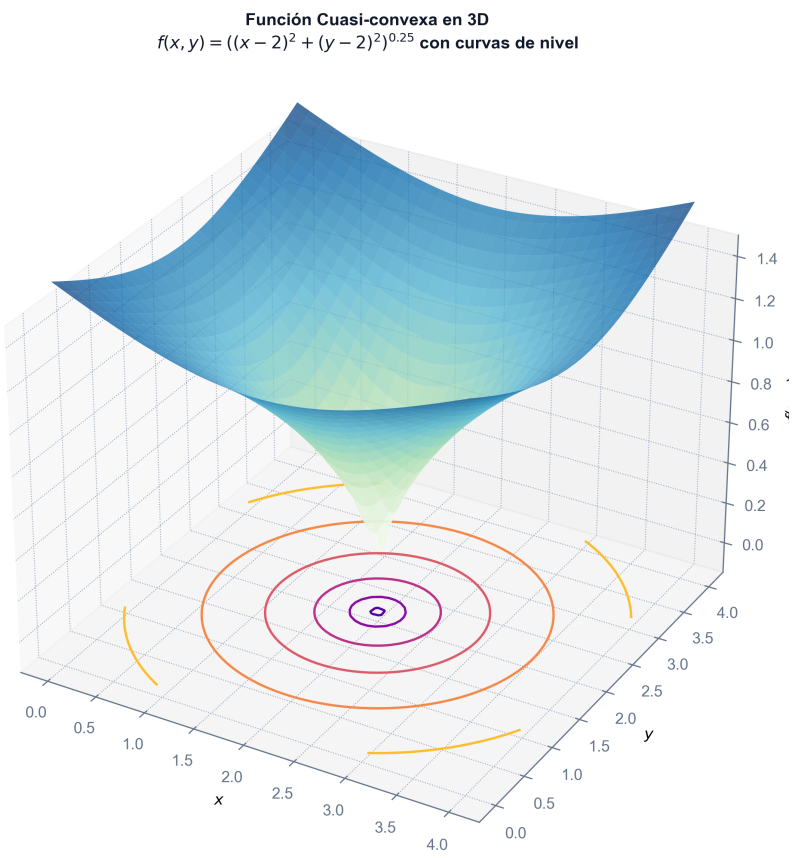

Figura 3.20: Superficie tridimensional de la función cuasi-convexa $f(x, y) = ((x-2)^2 + (y-2)^2)^{0.25}$ y proyección de sus curvas de nivel circulares convexas en el plano inferior

Por el contrario, la Figura 3.21 ilustra una función no cuasi-convexa dada por $f(x, y) = 2x^3 + xy + y^3 - x + y$, donde se aprecia que las curvas de nivel inferiores proyectadas no son convexas (mostrando contornos curvados en herradura).

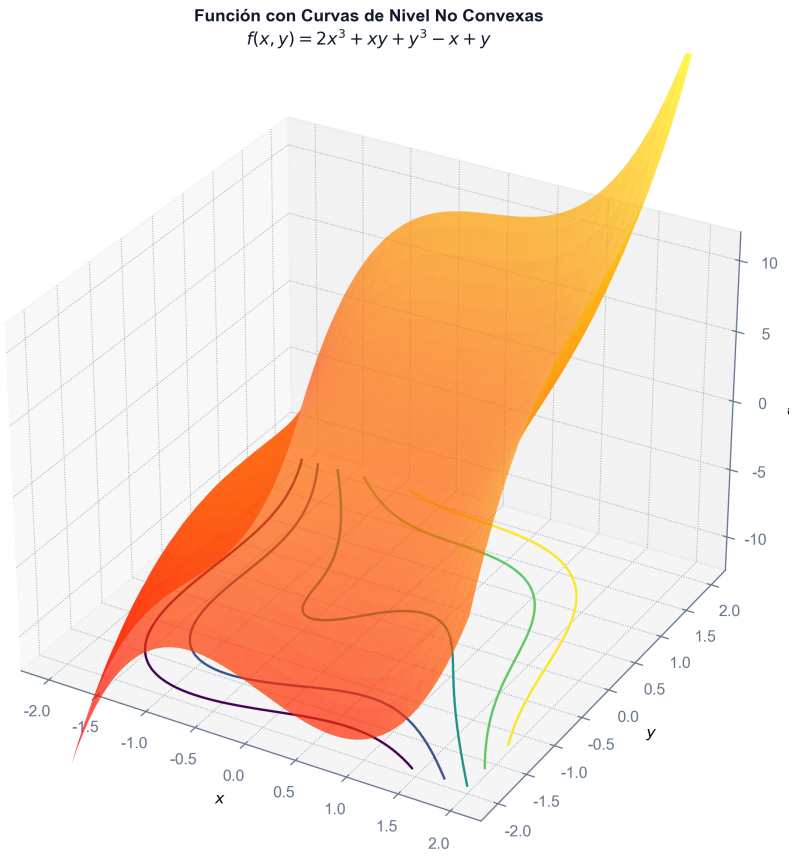

Figura 3.21: Superficie tridimensional de la función $f(x, y) = 2x^3 + xy + y^3 - x + y$ y proyección de sus curvas de nivel inferiores no convexas

3.6. Convexidad puntual

Las secciones anteriores estudian la convexidad de una función sobre todo un conjunto convexo. Sin embargo, en ocasiones esta condición es demasiado restrictiva. Es posible relajar este concepto exigiendo que las propiedades de convexidad se cumplan únicamente respecto a un punto de referencia fijo $x_0 \in \mathcal{S}$.

Definición: Convexidad puntual

Sea $\mathcal{S}$ un conjunto convexo no vacío de $\mathbb{R}^n$ y sea $f : \mathcal{S} \to \mathbb{R}$.

1. **Convexa en** x_0:

$$f(\lambda x_0 + (1-\lambda)x) \leq \lambda f(x_0) + (1-\lambda)f(x), \quad \forall \lambda \in (0,1),\ \forall x \in \mathcal{S}$$

2. **Estrictamente convexa en** x_0:

$$f(\lambda x_0 + (1-\lambda)x) < \lambda f(x_0) + (1-\lambda)f(x), \quad \forall \lambda \in (0,1),\ \forall x \in \mathcal{S},\ x \neq x_0$$

3. **Cuasi-convexa en** x_0:

$$f(\lambda x_0 + (1-\lambda)x) \leq \text{máx}\{f(x_0), f(x)\}, \quad \forall \lambda \in (0,1),\ \forall x \in \mathcal{S}$$

4. **Estrictamente cuasi-convexa en** x_0:

$$f(\lambda x_0 + (1-\lambda)x) < \text{máx}\{f(x_0), f(x)\}, \quad \forall \lambda \in (0,1),\ \forall x \in \mathcal{S} \text{ con } f(x) \neq f(x_0)$$

5. **Fuertemente cuasi-convexa en** x_0:

$$f(\lambda x_0 + (1-\lambda)x) < \text{máx}\{f(x_0), f(x)\}, \quad \forall \lambda \in (0,1),\ \forall x \in \mathcal{S},\ x \neq x_0$$

6. **Pseudo-convexa en** x_0: (si f es diferenciable en x_0)

$$\nabla f(x_0)^T(x - x_0) \geq 0 \implies f(x) \geq f(x_0), \quad \forall x \in \mathcal{S}$$

7. **Estrictamente pseudo-convexa en** x_0: (si f es diferenciable en x_0)

$$\nabla f(x_0)^T(x - x_0) \geq 0 \implies f(x) > f(x_0), \quad \forall x \in \mathcal{S},\ x \neq x_0$$

4 Condiciones de optimalidad y KKT

En las aplicaciones prácticas de la optimización, la inmensa mayoría de los problemas incorporan restricciones sobre los recursos, el presupuesto o las condiciones físicas del sistema. En este capítulo, estudiaremos la caracterización analítica y geométrica de los puntos óptimos. Comenzaremos analizando los problemas sin restricciones para asentar las bases diferenciales, introduciremos el formalismo geométrico de los conos de direcciones factibles y de descenso, y derivaremos las célebres condiciones necesarias de Fritz-John (FJ) y las condiciones necesarias y suficientes de Karush-Kuhn-Tucker (KKT).

! Objetivos de aprendizaje

Al finalizar este capítulo, serás capaz de:

1. **Diferenciar** las condiciones necesarias y suficientes de primer y segundo orden (FONC, SONC y SOSC) para optimización sin restricciones.
2. **Caracterizar geométricamente** las direcciones de descenso y factibles a través de conos de direcciones algebraicos.
3. **Analizar las condiciones de Fritz-John**, interpretando su significado geométrico y su sensibilidad ante restricciones redundantes.
4. **Deducir y aplicar las condiciones de Karush-Kuhn-Tucker (KKT)** como fundamento analítico de la optimización restringida.
5. **Resolver analíticamente** problemas con restricciones de igualdad y desigualdad por medio de la cualificación de restricciones (LICQ) y el análisis sistemático por casos.

4.1. Optimización sin restricciones

Aunque la mayoría de los problemas prácticos en ingeniería y economía incorporan restricciones sobre las variables de decisión, el estudio de la optimización sin restricciones (mín $f(x)$ para $x \in \mathbb{R}^n$) constituye la piedra angular de la teoría de la optimización. Esto se debe a dos motivos fundamentales: en primer lugar, los conceptos de aproximación local y curvatura que se desarrollan aquí se extienden directamente al caso restringido; en segundo lugar, muchos algoritmos numéricos resuelven problemas complejos con restricciones transformándolos en una secuencia de subproblemas no restringidos (como los métodos de barrera o de penalización). El

estudio de estos problemas nos permite comprender cómo se comporta localmente una función basándose en la información de sus derivadas.

4.1.1. Direcciones de descenso

Para buscar el valor mínimo de una función f, una estrategia básica consiste en ubicarse en un punto actual $\bar{x}$ y desplazarse en una dirección a lo largo de la cual la función decrezca. Analíticamente, una dirección de descenso es un vector que apunta hacia regiones del espacio donde el valor de la función disminuye localmente. Si la función es diferenciable en $\bar{x}$, podemos emplear el gradiente (que representa la dirección de máximo crecimiento local) para identificar de manera sistemática tales direcciones mediante el siguiente teorema:

! Teorema: Condición de dirección de descenso

Dada una función $f : \mathbb{R}^n \to \mathbb{R}$ diferenciable en $\bar{x}$, si existe un vector $d \in \mathbb{R}^n$ tal que:

$$\nabla f(\bar{x})^T d < 0$$

Entonces existe un escalar $\delta > 0$ tal que:

$$f(\bar{x} + \lambda d) < f(\bar{x}), \quad \forall \lambda \in (0, \delta)$$

Demostración: Por la diferenciabilidad de f en el punto $\bar{x}$, podemos escribir el desarrollo de Taylor de primer orden como:

$$f(\bar{x} + \lambda d) = f(\bar{x}) + \lambda \nabla f(\bar{x})^T d + \lambda \|d\| \alpha(\bar{x}, \lambda d)$$

Donde $\alpha(\bar{x}, \lambda d) \to 0$ cuando $\lambda \to 0$. Reordenando los términos y dividiendo ambos miembros por el parámetro $\lambda > 0$, obtenemos:

$$\frac{f(\bar{x} + \lambda d) - f(\bar{x})}{\lambda} = \nabla f(\bar{x})^T d + \|d\| \alpha(\bar{x}, \lambda d)$$

Puesto que $\nabla f(\bar{x})^T d < 0$ por hipótesis, y dado que el término residual $\alpha(\bar{x}, \lambda d)$ tiende a cero conforme $\lambda \to 0$, existe un entorno de radio $\delta > 0$ tal que para todo $\lambda \in (0, \delta)$ el lado derecho de la igualdad permanece estrictamente negativo:

$$\nabla f(\bar{x})^T d + \|d\| \alpha(\bar{x}, \lambda d) < 0$$

Esto implica que $f(\bar{x} + \lambda d) - f(\bar{x}) < 0$, lo que demuestra la tesis. ■

El teorema anterior nos proporciona una herramienta geométrica muy potente: para que un vector d sea una dirección de descenso local en $\bar{x}$, basta con que forme un cono abierto de direcciones que hagan un ángulo obtuso con el vector gradiente, es decir, que su producto

escalar sea estrictamente negativo ($\nabla f(\bar{x})^T d < 0$). Esta propiedad constituye la base del método clásico del descenso del gradiente (o máxima pendiente), donde se elige la dirección opuesta al gradiente $d = -\nabla f(\bar{x})$.

4.1.2. Condiciones necesarias y suficientes de segundo orden

Cuando nos encontramos en un punto que ya es un extremo local (mínimo o máximo), la geometría del problema exige que no sea posible encontrar ninguna dirección de descenso o de ascenso factible. Esto se traduce analíticamente en las condiciones clásicas de optimalidad de primer y segundo orden. El primer resultado fundamental establece que el plano tangente a la función en un extremo local debe ser completamente horizontal, anulando la aproximación lineal de primer orden:

i Corolario: Condición necesaria de primer orden (FONC)

Dada $f : \mathbb{R}^n \to \mathbb{R}$ diferenciable en $\bar{x}$, si $\bar{x}$ es un mínimo (o máximo) local de f, entonces el gradiente en dicho punto se anula:

$$\nabla f(\bar{x}) = 0$$

Demostración: Supóngase por contradicción que $\nabla f(\bar{x}) \neq 0$. Definamos la dirección $d = -\nabla f(\bar{x})$. Entonces:

$$\nabla f(\bar{x})^T d = -\|\nabla f(\bar{x})\|^2 < 0$$

Por la Condición de Dirección de Descenso, existe un $\delta > 0$ tal que $f(\bar{x} + \lambda d) < f(\bar{x})$ para todo $\lambda \in (0, \delta)$, lo que contradice directamente que $\bar{x}$ sea un mínimo local de la función. ■

La anulación del gradiente ($\nabla f(\bar{x}) = 0$) define a $\bar{x}$ como un **punto estacionario**. Sin embargo, la información de primer orden es insuficiente para distinguir entre mínimos locales, máximos locales o puntos de silla (donde la función crece en algunas direcciones y decrece en otras). Para caracterizar la naturaleza de un punto estacionario, necesitamos recurrir a la curvatura local de la función mediante la información de segundo orden proporcionada por la matriz Hessiana:

! Teorema: Condición necesaria de segundo orden (SONC)

Sea $f : \mathbb{R}^n \to \mathbb{R}$ una función dos veces diferenciable en $\bar{x}$. Si $\bar{x}$ es un mínimo local de f, entonces:

$$\nabla f(\bar{x}) = 0 \qquad \text{y} \qquad \nabla^2 f(\bar{x}) \succeq 0 \quad \text{(semidefinida positiva)}$$

Demostración: Por ser $\bar{x}$ un extremo local, el corolario anterior garantiza que $\nabla f(\bar{x}) = 0$. Sea $d \in \mathbb{R}^n$ una dirección cualquiera. Por ser f dos veces diferenciable en $\bar{x}$, escribimos el

desarrollo de Taylor de segundo orden:

$$f(\bar{x}+\lambda d) = f(\bar{x}) + \lambda \nabla f(\bar{x})^T d + \frac{1}{2}\lambda^2 d^T \nabla^2 f(\bar{x}) d + \lambda^2 \|d\|_2^2 \alpha(\bar{x}, \lambda d)$$

Donde $\alpha(\bar{x}, \lambda d) \to 0$ cuando $\lambda \to 0$. Puesto que $\nabla f(\bar{x}) = 0$, sustituimos y reordenamos los términos dividiendo por $\lambda^2 > 0$:

$$\frac{f(\bar{x}+\lambda d) - f(\bar{x})}{\lambda^2} = \frac{1}{2} d^T \nabla^2 f(\bar{x}) d + \|d\|_2^2 \alpha(\bar{x}, \lambda d)$$

Dado que $\bar{x}$ es un mínimo local, existe un entorno donde $f(\bar{x}+\lambda d) \geq f(\bar{x})$ para λ suficientemente pequeño. Por tanto:

$$\frac{1}{2} d^T \nabla^2 f(\bar{x}) d + \|d\|_2^2 \alpha(\bar{x}, \lambda d) \geq 0$$

Tomando el límite cuando $\lambda \to 0$, el término residual $\alpha(\bar{x}, \lambda d)$ se desvanece, obteniendo:

$$d^T \nabla^2 f(\bar{x}) d \geq 0$$

Como esta desigualdad es válida para cualquier dirección $d \in \mathbb{R}^n$, la matriz Hessiana $\nabla^2 f(\bar{x})$ es semidefinida positiva. ■

La condición necesaria de segundo orden (SONC) establece que en un mínimo local, la curvatura de la función no puede apuntar hacia abajo en ninguna dirección. No obstante, esta condición sigue siendo meramente necesaria (por ejemplo, en un punto de inflexión la segunda derivada también puede ser cero). Para certificar que un punto es de forma inequívoca un mínimo local, debemos exigir una condición suficiente más fuerte:

! Teorema: Condición suficiente de segundo orden (SOSC)

Sea $f : \mathbb{R}^n \to \mathbb{R}$ una función dos veces diferenciable en $\bar{x}$. Si en un punto $\bar{x}$ se cumple que el gradiente es nulo y la matriz Hessiana es definida positiva:

$$\nabla f(\bar{x}) = 0 \qquad \text{y} \qquad \nabla^2 f(\bar{x}) \succ 0$$

Entonces $\bar{x}$ es un mínimo local estricto de la función.
Demostración: Por ser f dos veces diferenciable:

$$f(x) = f(\bar{x}) + \nabla f(\bar{x})^T (x-\bar{x}) + \frac{1}{2}(x-\bar{x})^T \nabla^2 f(\bar{x})(x-\bar{x}) + \|x-\bar{x}\|_2^2 \alpha(\bar{x}, x-\bar{x})$$

con $\alpha(\bar{x}, x-\bar{x}) \to 0$ cuando $x \to \bar{x}$. Supongamos por reducción al absurdo que $\bar{x}$ no es un mínimo local; esto es, existe una sucesión de puntos $\{x_k\}$ que converge a $\bar{x}$ tal que $f(x_k) < f(\bar{x})$ para cada k. Denotando la dirección normalizada de la sucesión como

$d_k = \frac{x_k - \bar{x}}{\|x_k - \bar{x}\|_2}$, se cumple que $\|d_k\|_2 = 1$. Escribiendo la relación de Taylor:

$$\frac{f(x_k) - f(\bar{x})}{\|x_k - \bar{x}\|_2^2} = \frac{1}{2} d_k^T \nabla^2 f(\bar{x}) d_k + \alpha(\bar{x}, x_k - \bar{x}) < 0$$

Dado que $\{d_k\}$ pertenece a la esfera unidad (que es un conjunto compacto), existe una subsucesión $\{d_k\}_{k \in \mathcal{K}}$ que converge a una dirección d con $\|d\|_2 = 1$. Tomando el límite en dicha subsucesión y puesto que $\alpha(\bar{x}, x_k - \bar{x}) \to 0$, se obtiene:

$$d^T \nabla^2 f(\bar{x}) d \leq 0$$

Esto contradice la hipótesis de que la Hessiana $\nabla^2 f(\bar{x})$ es definida positiva, ya que $\|d\|_2 = 1 \neq 0$. Por tanto, $\bar{x}$ es un mínimo local estricto. ■

La condición suficiente de segundo orden (SOSC) requiere que la Hessiana sea estrictamente definida positiva en el punto estacionario, garantizando que la función se curva hacia arriba en todas las direcciones alrededor de $\bar{x}$.

Es importante subrayar que estas condiciones (tanto necesarias como suficientes) son de carácter **local**, ya que se derivan del desarrollo de Taylor en un entorno infinitesimal de $\bar{x}$. Si deseamos certificar la optimalidad **global** (es decir, asegurar que no existe ningún otro punto en todo el dominio con un valor menor de la función), debemos exigir propiedades globales sobre la estructura de la función, siendo la más representativa la generalización de la convexidad:

! Teorema: Suficiencia de optimalidad bajo pseudo-convexidad

Sea $f : \mathcal{S} \to \mathbb{R}$ una función pseudo-convexa definida sobre un conjunto convexo $\mathcal{S}$. Un punto $\bar{x} \in \mathcal{S}$ es un mínimo global de f si y solo si es un punto estacionario:

$$\nabla f(\bar{x}) = 0$$

Demostración: La implicación directa ($\implies$) es consecuencia directa del Corolario de Condición Necesaria de Primer Orden (FONC). Para probar la suficiencia ($\impliedby$), supongamos que $\nabla f(\bar{x}) = 0$. Por definición de pseudo-convexidad, si para cualquier $x \in \mathcal{S}$ se cumple que:

$$\nabla f(\bar{x})^T (x - \bar{x}) \geq 0 \implies f(x) \geq f(\bar{x})$$

Dado que $\nabla f(\bar{x}) = 0$, se tiene que $\nabla f(\bar{x})^T (x - \bar{x}) = 0 \geq 0$, lo que implica directamente que $f(x) \geq f(\bar{x})$ para todo $x \in \mathcal{S}$. Por tanto, $\bar{x}$ es un mínimo global. ■

4.1.3. Derivadas de orden superior para una variable

En los casos en que la segunda derivada (o la matriz Hessiana) es únicamente semidefinida pero no definida positiva (es decir, contiene autovalores nulos), la curvatura de segundo orden no es suficiente para clasificar el punto estacionario. Para funciones de una sola variable ($f : \mathbb{R} \to \mathbb{R}$), podemos resolver esta ambigüedad analizando las derivadas de orden superior en el punto estacionario. La clave reside en identificar la primera derivada de orden superior que sea diferente de cero, lo que formaliza el siguiente teorema:

! Teorema: Extremos univariantes de orden superior

Sea $f : \mathbb{R} \to \mathbb{R}$ una función infinitamente diferenciable. Un punto $\bar{x} \in \mathbb{R}$ es un mínimo local de f si y solo si se verifica alguna de las dos siguientes condiciones:

1. $f^{(j)}(\bar{x}) = 0$ para todo $j = 1, 2, ...$
2. Existe un entero par $n \geq 2$ tal que $f^{(n)}(\bar{x}) > 0$ y $f^{(j)}(\bar{x}) = 0$ para todo $j = 1, ..., n-1$.

Demostración: Véase (Bazaraa, Sherali, y Shetty 2013, cap. 2).

Este resultado nos muestra que la naturaleza local del punto depende del carácter par o impar del orden de la primera derivada no nula: un orden impar indica que la función cruza el plano tangente (punto de inflexión), mientras que un orden par preserva el carácter extremo (mínimo si la derivada es positiva, máximo si es negativa), como se ilustra en el siguiente ejemplo:

Ejemplo: Análisis de puntos estacionarios

Consideremos la función univariante $f(x) = (x^2 - 1)^3$. Sus dos primeras derivadas son:

$$f'(x) = 6x(x^2 - 1)^2, \qquad f''(x) = 24x^2(x^2 - 1) + 6(x^2 - 1)^2$$

Igualando la primera derivada a cero, localizamos los puntos estacionarios candidatos:

$$x^* = 0, \qquad x^* = 1, \qquad x^* = -1$$

Analicemos la curvatura de segundo orden en cada candidato:

- **En** $x^* = 0$: $f''(0) = 6 > 0$. Al ser la segunda derivada estrictamente positiva, se cumple la condición suficiente de segundo orden (SOSC), confirmando que $x^* = 0$ es un mínimo local.
- **En** $x^* = \pm 1$: $f''(\pm 1) = 0$. Al anularse la segunda derivada, acudimos a las derivadas de orden superior. Se tiene que:

  $$f'''(x) = 48x(x^2 - 1) + 24x^2(2x) + 12(x^2 - 1)(2x) \implies f'''(\pm 1) = \pm 48 \neq 0$$

  Al ser la primera derivada no nula de orden impar ($n = 3$), concluimos que $x^* = \pm 1$ son puntos de inflexión y no extremos locales, como se muestra en la Figura 4.1.

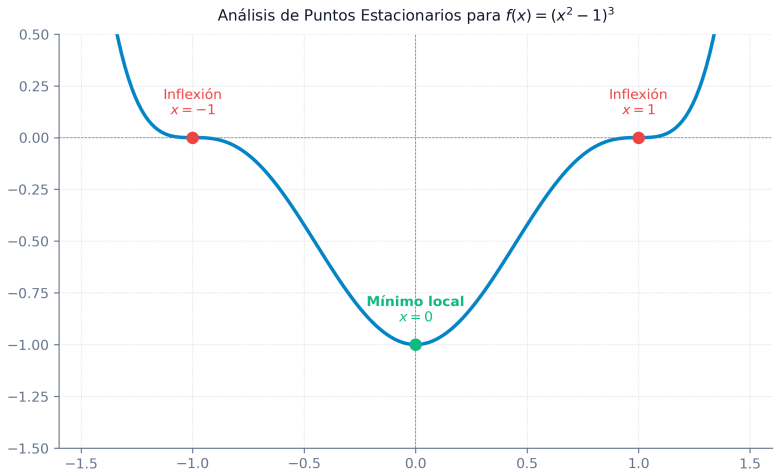

Figura 4.1: Análisis de puntos estacionarios e inflexiones en la función $f(x) = (x^2 - 1)^3$

4.2. Optimización con restricciones

En la práctica, la optimización matemática adquiere su verdadera complejidad cuando introducimos limitaciones sobre las variables de decisión. Para analizar formalmente estos problemas, inicialmente consideraremos el marco general en el que la región factible $\mathcal{S} \subseteq \mathbb{R}^n$ es un conjunto genérico:

$$\text{mín}\{f(x) \mid x \in \mathcal{S}\}$$

Posteriormente, nos centraremos en problemas donde la región factible está definida explícitamente mediante una serie de desigualdades analíticas:

$$\text{mín}\{f(x) \mid x \in \mathcal{X},\ g_i(x) \leq 0,\ i = 1, \ldots, m\}$$

donde el dominio de partida $\mathcal{X}$ es un abierto no vacío de $\mathbb{R}^n$ y tanto la función objetivo f como las restricciones g_i son funciones diferenciables.

Para caracterizar si un punto frontera $\bar{x} \in \mathcal{S}$ puede ser un mínimo local, debemos analizar si es posible realizar un movimiento infinitesimal a partir de él que cumpla dos condiciones: permanecer dentro de la región factible $\mathcal{S}$ y, simultáneamente, disminuir el valor de la función objetivo $f(x)$. En términos geométricos, esto se estudia a través del concepto de **conos de direcciones**:

Cono de Direcciones Factibles ($\mathcal{F}(\bar{x})$) El conjunto de direcciones a lo largo de las cuales un paso infinitesimal no abandona la región factible $\mathcal{S}$:

$$\mathcal{F}(\bar{x}) = \{d \in \mathbb{R}^n \mid d \neq 0,\ \exists \delta_d > 0 \text{ tal que } \bar{x} + \lambda d \in \mathcal{S},\ \forall \lambda \in (0, \delta_d)\}$$

Cono de Direcciones de Mejora/Descenso ($\mathcal{D}(\bar{x})$) El conjunto de direcciones a lo largo de las cuales el valor de la función objetivo disminuye localmente:

$$\mathcal{D}(\bar{x}) = \{d \in \mathbb{R}^n \mid d \neq 0,\ \exists \delta_d > 0 \text{ tal que } f(\bar{x} + \lambda d) < f(\bar{x}),\ \forall \lambda \in (0, \delta_d)\}$$

La condición básica de optimalidad geométrica establece que, si $\bar{x}$ es un mínimo local, es imposible encontrar una dirección que nos permita adentrarnos en la región factible y, al mismo tiempo, mejorar la función. En términos de conjuntos, esto significa que ambos conos son disjuntos:

$$\bar{x} \text{ es mínimo local } \implies \mathcal{F}(\bar{x}) \cap \mathcal{D}(\bar{x}) = \emptyset$$

Como se ilustra en la Figura 4.2, en un punto mínimo local $\bar{x}$ situado en la frontera de la región factible $\mathcal{S}$, el cono de direcciones factibles $\mathcal{F}(\bar{x})$ (que apunta hacia el interior de $\mathcal{S}$) y el cono de direcciones de descenso analítico $\mathcal{D}_0(\bar{x})$ (que apunta en la dirección opuesta al gradiente de la función objetivo $\nabla f(\bar{x})$) están completamente separados, compartiendo únicamente el origen $\bar{x}$. Esto representa geométricamente que ninguna dirección admisible puede disminuir localmente el valor del objetivo.

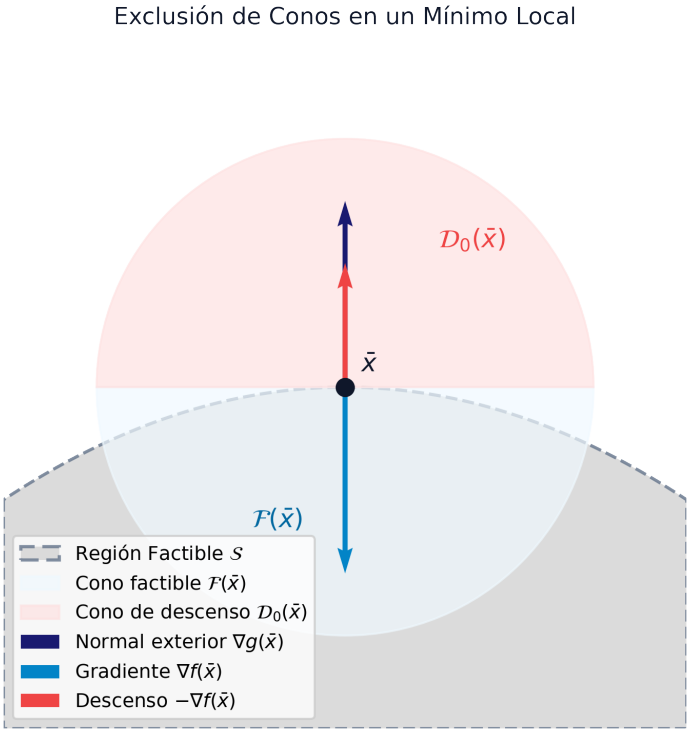

Figura 4.2: Exclusión geométrica de los conos factible y de descenso en un mínimo local

Sin embargo, comprobar la exclusión geométrica directa es muy complejo porque no siempre es fácil determinar analíticamente el cono de direcciones de descenso real $\mathcal{D}(\bar{x})$. Si la función f es

diferenciable en $\bar{x}$, podemos simplificar la caracterización del cono de descenso aproximándolo mediante un semiespacio abierto definido por el gradiente. Definimos el cono de direcciones de descenso analítico como el conjunto de direcciones que forman un ángulo obtuso con el gradiente de la función en dicho punto:

$$\mathcal{D}_0(\bar{x}) = \{d \in \mathbb{R}^n \mid \nabla f(\bar{x})^T d < 0\}$$

Este cono analítico siempre es un subconjunto del cono de descenso real ($\mathcal{D}_0(\bar{x}) \subseteq \mathcal{D}(\bar{x})$). Esta relación nos permite formular el primer criterio necesario de optimalidad bajo restricciones diferenciables:

! Teorema: Exclusión de direcciones de descenso y factibilidad

Si $\bar{x} \in \mathcal{S}$ es un mínimo local de una función diferenciable f, entonces el cono de direcciones factibles y el semiespacio de descenso analítico son disjuntos:

$$\mathcal{D}_0(\bar{x}) \cap \mathcal{F}(\bar{x}) = \emptyset$$

Demostración: Supóngase por contradicción que existe un vector $d \in \mathcal{D}_0(\bar{x}) \cap \mathcal{F}(\bar{x})$. 1. Como $d \in \mathcal{D}_0(\bar{x})$, se cumple que $\nabla f(\bar{x})^T d < 0$. Por el Teorema de Dirección de Descenso, existe un paso $\delta_1 > 0$ tal que $f(\bar{x} + \lambda d) < f(\bar{x})$ para todo $\lambda \in (0, \delta_1)$. 2. Como $d \in \mathcal{F}(\bar{x})$, por definición de cono factible, existe un paso $\delta_2 > 0$ tal que $\bar{x} + \lambda d \in \mathcal{S}$ para todo $\lambda \in (0, \delta_2)$. Tomando el paso mínimo $\delta = \min\{\delta_1, \delta_2\} > 0$, se deduce que para todo $\lambda \in (0, \delta)$ el punto $\bar{x} + \lambda d$ es factible y además $f(\bar{x} + \lambda d) < f(\bar{x})$, lo que contradice directamente que $\bar{x}$ sea un mínimo local de f en la región factible. ■

La condición de exclusión anterior ($\mathcal{D}_0(\bar{x}) \cap \mathcal{F}(\bar{x}) = \emptyset$) es de carácter necesario. La implicación inversa (suficiencia) no se cumple en general debido a que si el gradiente se anula ($\nabla f(\bar{x}) = 0$), el cono analítico se vacía ($\mathcal{D}_0(\bar{x}) = \emptyset$), pero el punto podría ser un máximo o un punto de silla y no un mínimo. Sin embargo, si la función objetivo es pseudo-convexa y la región factible cumple condiciones locales de regularidad, esta condición necesaria se convierte también en suficiente para garantizar la optimalidad, tal como establece el siguiente teorema:

! Teorema: Suficiencia geométrica bajo pseudo-convexidad

Sea el problema de optimización $\min\{f(x) \mid x \in \mathcal{S}\}$, con f diferenciable y pseudo-convexa en $\bar{x} \in \mathcal{S}$. Si $\mathcal{D}_0(\bar{x}) \cap \mathcal{F}(\bar{x}) = \emptyset$ y existe un entorno $N_\epsilon(\bar{x})$ de radio $\epsilon > 0$ tal que $d = (x - \bar{x}) \in \mathcal{F}(\bar{x})$ para cualquier $x \in \mathcal{S} \cap N_\epsilon(\bar{x})$, entonces $\bar{x}$ es un mínimo local de f.
Demostración: Supóngase por contradicción que $\bar{x}$ no es mínimo local. Entonces existe un punto $\hat{x} \in \mathcal{S} \cap N_\epsilon(\bar{x})$ tal que $f(\hat{x}) < f(\bar{x})$. Por la hipótesis del entorno, el vector $d = \hat{x} - \bar{x}$ pertenece al cono factible $\mathcal{F}(\bar{x})$. Por ser f pseudo-convexa en $\bar{x}$, se cumple que:

$$f(\hat{x}) < f(\bar{x}) \implies \nabla f(\bar{x})^T d < 0 \implies d \in \mathcal{D}_0(\bar{x})$$

Por tanto, $d \in \mathcal{D}_0(\bar{x}) \cap \mathcal{F}(\bar{x})$, lo cual contradice que dicha intersección sea vacía. ■

Aunque la caracterización $\mathcal{D}_0(\bar{x}) \cap \mathcal{F}(\bar{x}) = \emptyset$ simplifica el cono de descenso gracias al uso del gradiente $\nabla f(\bar{x})$, seguimos teniendo el inconveniente principal de no disponer de una representación algebraica manejable del cono de direcciones factibles $\mathcal{F}(\bar{x})$.

> ⚠ Limitación del cono de direcciones factibles
>
> El cono de direcciones factibles $\mathcal{F}(\bar{x})$ se define de forma puramente geométrica y depende del comportamiento infinitesimal de la frontera de la región factible $\mathcal{S}$. En la práctica, determinar analíticamente si una dirección d pertenece a $\mathcal{F}(\bar{x})$ requiere analizar la existencia de un paso $\delta > 0$ tal que $\bar{x} + \lambda d \in \mathcal{S}$ para todo $\lambda \in (0, \delta)$. Esto resulta extremadamente difícil e ineficiente cuando las restricciones son no lineales.
> Para resolver esta limitación, si la región factible está definida por restricciones de desigualdad diferenciables, aproximamos localmente el cono factible $\mathcal{F}(\bar{x})$ mediante el cono de restricciones activas $\mathcal{G}_0(\bar{x})$, el cual se define de forma puramente algebraica a partir de los gradientes de las restricciones activas.

4.3. Restricciones de desigualdad y cono de restricciones activas

A partir de este momento, nos centraremos en el caso en el que la región factible $\mathcal{S}$ está definida explícitamente mediante una serie de desigualdades analíticas:

$$\mathcal{S} = \{x \in \mathcal{X} \mid g_i(x) \leq 0,\ i = 1, \dots, m\}$$

donde $\mathcal{X} \subseteq \mathbb{R}^n$ es un conjunto abierto no vacío. En este marco, las direcciones a lo largo de las cuales nos podemos mover localmente desde un punto $\bar{x} \in \mathcal{S}$ dependen de qué restricciones se satisfacen con igualdad en dicho punto, ya que las restricciones estrictamente negativas ($g_i(\bar{x}) < 0$) no limitan el movimiento infinitesimal en un entorno suficientemente pequeño.

Restricciones Activas ($\mathcal{I}$) Dado un punto factible $\bar{x} \in \mathcal{S}$, el conjunto de índices de las restricciones activas en $\bar{x}$ se define como:

$$\mathcal{I} = \{i \in \{1, \dots, m\} \mid g_i(\bar{x}) = 0\}$$

Por conveniencia, si no da lugar a confusión, denotaremos este conjunto simplemente como $\mathcal{I}$.

Para las restricciones activas, si g_i es diferenciable, el vector gradiente $\nabla g_i(\bar{x})$ señala la dirección de máximo crecimiento local de la restricción. Puesto que las restricciones son de tipo "menor o igual que" ($g_i(x) \leq 0$), el gradiente $\nabla g_i(\bar{x})$ apunta hacia el exterior de la región factible. Si una dirección d forma un ángulo obtuso con este gradiente ($\nabla g_i(\bar{x})^T d < 0$), nos moveremos localmente hacia el interior factible de dicha restricción.

Ejemplo: Identificación de restricciones activas, gradientes y direcciones factibles

Consideremos el siguiente problema bidimensional:

$$\begin{aligned} \text{mín} \quad & f(x_1, x_2) = (x_1 - 3)^2 + (x_2 - 2)^2 \\ \text{s.a.} \quad & g_1(x_1, x_2) = x_1^2 + x_2^2 - 5 \leq 0 \\ & g_2(x_1, x_2) = -x_1 \leq 0 \\ & g_3(x_1, x_2) = -x_2 \leq 0 \\ & g_4(x_1, x_2) = x_1 + x_2 - 3 \leq 0 \end{aligned}$$

En la Figura 4.3 se representa la región factible $\mathcal{S}$ y las fronteras de las restricciones. Dependiendo de la ubicación del punto factible de interés, el conjunto de restricciones activas $\mathcal{I}$ varía considerablemente:

- **En el punto** $(1, 1)$: El punto es estrictamente interior, por lo que ninguna restricción se cumple con igualdad y $\mathcal{I} = \emptyset$.
- **En el punto** $(0, 0)$: El punto está en el origen, lo que activa las fronteras del primer cuadrante, resultando $\mathcal{I} = \{2, 3\}$.
- **En el punto** $(2, 1)$: El punto está sobre la intersección de la circunferencia y la recta inclinada, activando simultáneamente ambas fronteras, resultando $\mathcal{I} = \{1, 4\}$.
- **En el punto** $(0, 1)$: El punto está en el eje vertical, lo que activa únicamente la restricción de no negatividad de x_1, resultando $\mathcal{I} = \{2\}$.

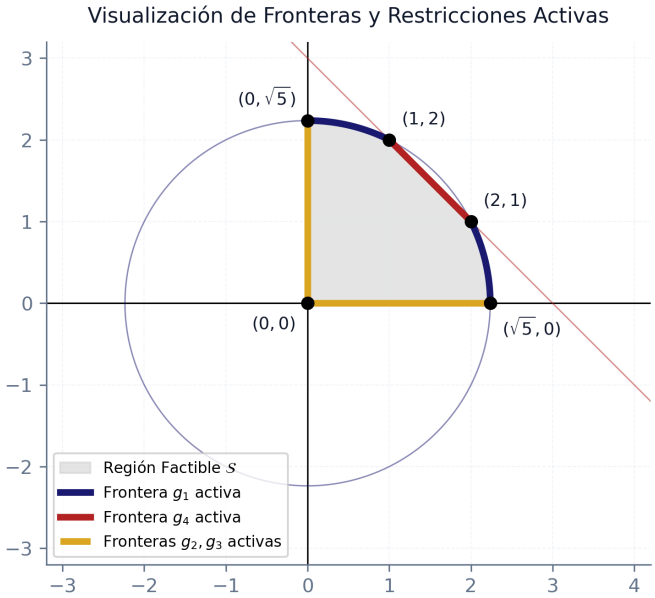

Figura 4.3: Visualización de la región factible y del conjunto de restricciones activas para distintos puntos candidatos

Si evaluamos los gradientes de las restricciones activas en los puntos de la frontera, observamos que, debido a que el problema está formulado con desigualdades de tipo menor o igual ($g_i(x) \leq 0$), dichos vectores apuntan siempre hacia el exterior del conjunto factible $\mathcal{S}$.
Por ejemplo, en el punto $(1, 2)$, la restricción circular g_1 y la restricción lineal g_4 son activas. Sus respectivos gradientes en dicho punto son $\nabla g_1(1, 2) = (2, 4)^T$ y $\nabla g_4(1, 2) = (1, 1)^T$. Como se ilustra en la Figura 4.4, ambos vectores señalan hacia fuera de la región factible.

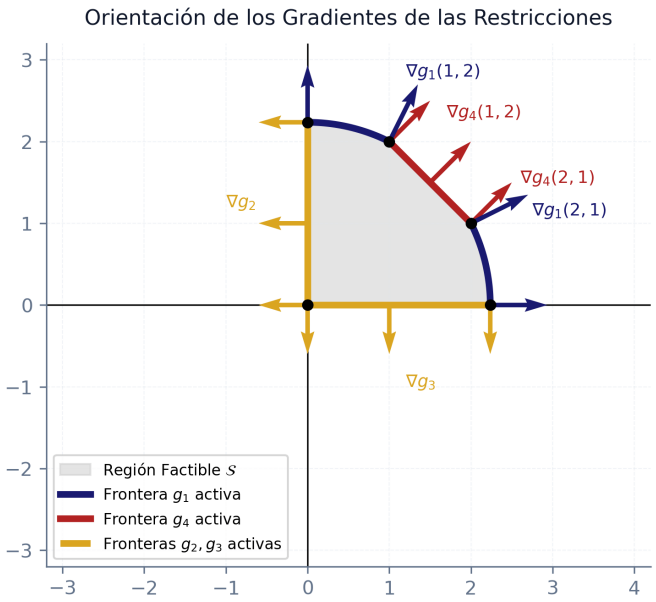

Figura 4.4: Orientación de los gradientes de las restricciones en la frontera de la región factible

Además, consideremos qué ocurre cuando una dirección d es ortogonal al gradiente de una restricción activa lineal, es decir, $\nabla g_i(\bar{x})^T d = 0$. Como se observa en la Figura 4.5:

- **En el punto** $(0, 1)$ de la frontera vertical (eje x_2), la restricción $g_2(x) = -x_1 \leq 0$ está activa, con gradiente $\nabla g_2(0, 1) = (-1, 0)^T$. La dirección $d = (0, 1)^T$ (que apunta verticalmente hacia arriba) es ortogonal a dicho gradiente ($\nabla g_2^T d = 0$). Sin embargo, moverse en la dirección d mantiene al punto sobre la frontera, por lo que d es una dirección factible.
- **En el punto** $(1, 2)$ de la frontera lineal oblicua, la restricción $g_4(x) = x_1 + x_2 - 3 \leq 0$ está activa, con gradiente $\nabla g_4(1, 2) = (1, 1)^T$. La dirección $d = (1, -1)^T$ (que apunta hacia abajo y a la derecha a lo largo de la recta) es ortogonal al gradiente ($\nabla g_4^T d = 0$). No obstante, al ser la restricción lineal, la dirección d es completamente factible.

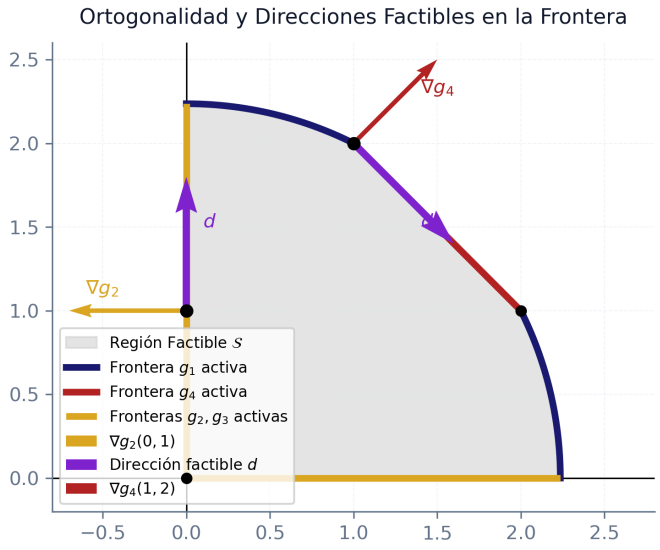

Figura 4.5: Direcciones factibles ortogonales a los gradientes en fronteras lineales

Esto nos permite definir el cono de direcciones factibles analíticas o algebraicas asociado a las restricciones activas como:

$$\mathcal{G}_0(\bar{x}) = \{d \in \mathbb{R}^n \mid \nabla g_i(\bar{x})^T d < 0,\ \forall i \in \mathcal{I}\}$$

La relación entre este cono algebraico y el cono factible geométrico $\mathcal{F}(\bar{x})$ es estrecha, pero presenta matices importantes. Si una dirección d pertenece a $\mathcal{G}_0(\bar{x})$, es factible respecto a todas las restricciones activas. No obstante, $\mathcal{G}_0(\bar{x})$ es, en general, un subconjunto estricto del cono factible geométrico ($\mathcal{G}_0(\bar{x}) \subseteq \mathcal{F}(\bar{x})$). La igualdad no siempre se cumple: por ejemplo, si una restricción g_i es lineal y el vector d es ortogonal a su gradiente ($\nabla g_i(\bar{x})^T d = 0$), la dirección d puede seguir siendo factible (moviéndose por la frontera), pero no pertenecerá al cono abierto $\mathcal{G}_0(\bar{x})$.

A partir de esta inclusión $\mathcal{G}_0(\bar{x}) \subseteq \mathcal{F}(\bar{x})$, podemos establecer una condición necesaria de optimalidad local más débil y de más fácil verificación algebraica que la exclusión geométrica directa:

Teorema: Intersección vacía con el cono de restricciones activas

Sea el problema de optimización bajo restricciones de desigualdad, $\bar{x}$ una solución factible e $\mathcal{I}$ el conjunto de restricciones activas en $\bar{x}$. Si se verifican las siguientes propiedades:

1. f y las restricciones activas g_i ($i \in \mathcal{I}$) son diferenciables en $\bar{x}$,
2. Las restricciones inactivas g_j ($j \notin \mathcal{I}$) son continuas en $\bar{x}$,
3. $\bar{x}$ es un mínimo local del problema,

entonces el cono de descenso analítico y el cono de restricciones activas son disjuntos:

$$\mathcal{D}_0(\bar{x}) \cap \mathcal{G}_0(\bar{x}) = \emptyset$$

Demostración: Sea $d \in \mathcal{G}_0(\bar{x})$. Por definición, se cumple que $\nabla g_i(\bar{x})^T d < 0$ para todo $i \in \mathcal{I}$. Como las funciones g_i $(i \in \mathcal{I})$ son diferenciables en $\bar{x}$, aplicando el Teorema de Dirección de Descenso, existe un paso $\delta_1 > 0$ tal que:

$$g_i(\bar{x} + \lambda d) < g_i(\bar{x}) = 0, \quad \forall \lambda \in (0, \delta_1),\ \forall i \in \mathcal{I}$$

Para las restricciones inactivas $(j \notin \mathcal{I})$, dado que $g_j(\bar{x}) < 0$ y por la continuidad de g_j en $\bar{x}$, existe un entorno $\delta_2 > 0$ tal que:

$$g_j(\bar{x} + \lambda d) < 0, \quad \forall \lambda \in (0, \delta_2),\ \forall j \notin \mathcal{I}$$

Asimismo, por ser $\mathcal{X}$ un conjunto abierto y $\bar{x} \in \mathcal{X}$, existe un paso $\delta_3 > 0$ tal que:

$$\bar{x} + \lambda d \in \mathcal{X}, \quad \forall \lambda \in (0, \delta_3)$$

Tomando el paso mínimo común $\delta = \min\{\delta_1, \delta_2, \delta_3\} > 0$, concluimos que para todo $\lambda \in (0, \delta)$ el punto $\bar{x} + \lambda d$ pertenece a $\mathcal{X}$ y satisface todas las restricciones de desigualdad $(g_i(\bar{x} + \lambda d) < 0,\ \forall i)$. Por tanto, $\bar{x} + \lambda d \in \mathcal{S}$ para todo $\lambda \in (0, \delta)$, lo que por definición implica que la dirección es factible $(d \in \mathcal{F}(\bar{x}))$.
Hemos demostrado así que $\mathcal{G}_0(\bar{x}) \subseteq \mathcal{F}(\bar{x})$. Por ser $\bar{x}$ un mínimo local del problema, el Teorema de Exclusión de Direcciones de Descenso y Factibilidad garantiza que $\mathcal{D}_0(\bar{x}) \cap \mathcal{F}(\bar{x}) = \emptyset$. Dado que $\mathcal{G}_0(\bar{x})$ es un subconjunto de $\mathcal{F}(\bar{x})$, se concluye inmediatamente que su intersección con el cono de descenso también debe ser vacía:

$$\mathcal{D}_0(\bar{x}) \cap \mathcal{G}_0(\bar{x}) = \emptyset$$

lo que completa la demostración. ■

La condición necesaria $\mathcal{D}_0(\bar{x}) \cap \mathcal{G}_0(\bar{x}) = \emptyset$ es más débil que la geométrica $\mathcal{D}_0(\bar{x}) \cap \mathcal{F}(\bar{x}) = \emptyset$ (al ser $\mathcal{G}_0$ un cono más restrictivo). Sin embargo, bajo hipótesis de convexidad generalizada sobre las restricciones y el objetivo, esta condición es también suficiente para garantizar que un punto es mínimo local, como establece el siguiente resultado:

! Teorema: Suficiencia geométrica sin KKT

Sea el problema de optimización bajo restricciones de desigualdad, con f y g_i diferenciables en el punto factible $\bar{x}$. Si se verifican las siguientes condiciones:

1. f es pseudo-convexa en $\bar{x}$,
2. Las restricciones activas g_i $(i \in \mathcal{I})$ son estrictamente pseudo-convexas en $\bar{x}$,

3. $\mathcal{D}_0(\bar{x}) \cap \mathcal{G}_0(\bar{x}) = \emptyset$,

entonces $\bar{x}$ es un mínimo local del problema.
Demostración: Supongamos por contradicción que $\bar{x}$ no es un mínimo local. Entonces existe un punto factible $x \in \mathcal{S}$ tal que $f(x) < f(\bar{x})$. Por la diferenciabilidad y pseudo-convexidad de f en $\bar{x}$, se cumple que:

$$f(x) < f(\bar{x}) \implies \nabla f(\bar{x})^T (x - \bar{x}) < 0$$

Definiendo la dirección $d = x - \bar{x}$, esto implica directamente que $d \in \mathcal{D}_0(\bar{x})$.
Por otro lado, para cualquier restricción activa $i \in \mathcal{I}$, dado que $x \in \mathcal{S}$, se tiene que $g_i(x) \leq 0$. Al ser la restricción activa en el punto de comparación, $g_i(\bar{x}) = 0$, lo que implica que $g_i(x) \leq g_i(\bar{x})$. Dado que las restricciones activas g_i son estrictamente pseudo-convexas en $\bar{x}$, se tiene por definición de estricta pseudo-convexidad:

$$g_i(x) \leq g_i(\bar{x}) \implies \nabla g_i(\bar{x})^T (x - \bar{x}) < 0$$

Como esta relación se verifica para todos los índices activos $i \in \mathcal{I}$, se concluye que:

$$\nabla g_i(\bar{x})^T d < 0, \quad \forall i \in \mathcal{I} \implies d \in \mathcal{G}_0(\bar{x})$$

Por consiguiente, $d \in \mathcal{D}_0(\bar{x}) \cap \mathcal{G}_0(\bar{x})$, lo cual contradice de forma directa la hipótesis de que la intersección $\mathcal{D}_0(\bar{x}) \cap \mathcal{G}_0(\bar{x})$ es vacía. Por tanto, $\bar{x}$ es un mínimo local. ■

Este teorema de suficiencia establece que la ausencia de direcciones factibles de descenso es garantía de optimalidad local bajo ciertas condiciones de regularidad y convexidad en las restricciones. Para comprender de forma práctica cómo opera esta condición de intersección vacía de conos y sus limitaciones teóricas, analizaremos a continuación detalladamente dos puntos candidatos sobre la frontera de una región factible bidimensional.

Ejemplo: Análisis analítico y geométrico de conos

Consideremos el problema:

$$\begin{aligned} \text{mín} \quad & f(x_1, x_2) = (x_1 - 3)^2 + (x_2 - 2)^2 \\ \text{s.a.} \quad & g_1(x_1, x_2) = x_1^2 + x_2^2 - 5 \leq 0 \\ & g_2(x_1, x_2) = -x_1 \leq 0 \\ & g_3(x_1, x_2) = -x_2 \leq 0 \\ & g_4(x_1, x_2) = x_1 + x_2 - 3 \leq 0 \end{aligned}$$

Analicemos la geometría y la expresión analítica de los conos de direcciones de descenso $\mathcal{D}_0(\bar{x})$ y factibles algebraicas $\mathcal{G}_0(\bar{x})$ en dos puntos candidatos de la frontera de la región factible:

- **Punto** $\bar{x} = (9/5, 6/5)$: Al evaluar las restricciones en este punto:

  $$g_1(9/5, 6/5) = -8/25 < 0, \quad g_2(9/5, 6/5) < 0, \quad g_3(9/5, 6/5) < 0, \quad g_4(9/5, 6/5) = 0$$

  El único índice activo es $\mathcal{I} = \{4\}$. Los gradientes relevantes en dicho punto son:

  $$\nabla g_4(\bar{x}) = \begin{pmatrix} 1 \\ 1 \end{pmatrix}, \qquad \nabla f(\bar{x}) = \begin{pmatrix} 2(9/5 - 3) \\ 2(6/5 - 2) \end{pmatrix} = \begin{pmatrix} -12/5 \\ -8/5 \end{pmatrix}$$

  Los conos analíticos en el espacio de direcciones $d = (d_1, d_2)^T$ resultan:

  $$\mathcal{G}_0(\bar{x}) = \{d \in \mathbb{R}^2 \mid d_1 + d_2 < 0\}$$

  $$\mathcal{D}_0(\bar{x}) = \{d \in \mathbb{R}^2 \mid -\nabla f(\bar{x})^T d > 0\} = \{d \in \mathbb{R}^2 \mid 3d_1 + 2d_2 > 0\}$$

  Como se muestra en la Figura 4.6, existe una región de intersección no vacía (el sector morado). Por ejemplo, la dirección $d = (1, -1.3)^T$ satisface simultáneamente ambas condiciones:

  $$d_1 + d_2 = -0.3 < 0 \quad (d \in \mathcal{G}_0) \qquad \text{y} \qquad 3d_1 + 2d_2 = 0.4 > 0 \quad (d \in \mathcal{D}_0)$$

  Al existir direcciones factibles que a la vez son de descenso, concluimos que la intersección $\mathcal{D}_0(\bar{x}) \cap \mathcal{G}_0(\bar{x})$ es no vacía y, por ende, el punto no es óptimo.

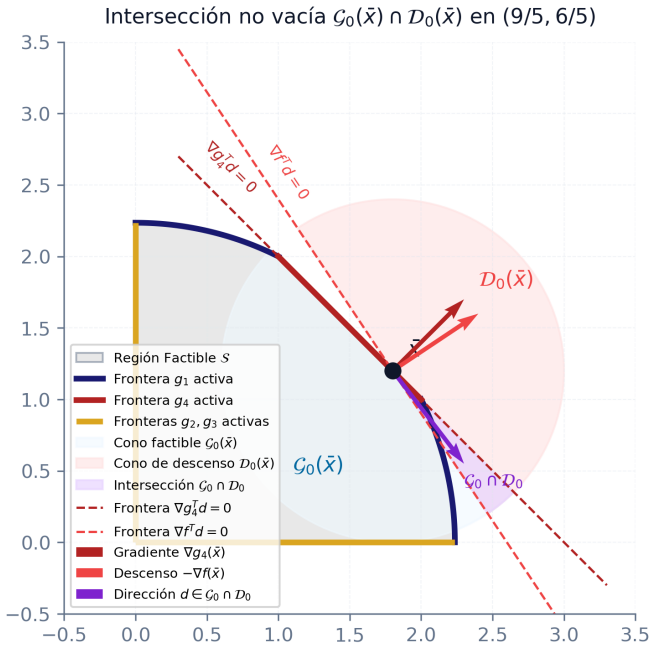

Figura 4.6: Geometría de conos en $\bar{x} = (9/5, 6/5)$ (no óptimo)

- **Punto** $\bar{x} = (2, 1)$: Al evaluar las restricciones en este punto:

$$g_1(2,1) = 0 \text{ (activa)}, \quad g_2(2,1) < 0, \quad g_3(2,1) < 0, \quad g_4(2,1) = 0 \text{ (activa)}$$

El conjunto de índices de restricciones activas es $\mathcal{J} = \{1, 4\}$. Sus gradientes y el de la función objetivo son:

$$\nabla g_1(\bar{x}) = \begin{pmatrix} 4 \\ 2 \end{pmatrix}, \qquad \nabla g_4(\bar{x}) = \begin{pmatrix} 1 \\ 1 \end{pmatrix}, \qquad \nabla f(\bar{x}) = \begin{pmatrix} -2 \\ -2 \end{pmatrix}$$

Los conos analíticos en este caso se definen como:

$$\mathcal{G}_0(\bar{x}) = \{d \in \mathbb{R}^2 \mid 2d_1 + d_2 < 0 \text{ y } d_1 + d_2 < 0\}$$
$$\mathcal{D}_0(\bar{x}) = \{d \in \mathbb{R}^2 \mid -\nabla f(\bar{x})^T d > 0\} = \{d \in \mathbb{R}^2 \mid d_1 + d_2 > 0\}$$

Nótese que cualquier dirección factible algebraica $d \in \mathcal{G}_0(\bar{x})$ debe verificar en particular que $d_1 + d_2 < 0$, lo que implica la inclusión $\mathcal{G}_0(\bar{x}) \subseteq \{d \in \mathbb{R}^2 \mid d_1 + d_2 < 0\}$. Al ser el cono de descenso $\mathcal{D}_0(\bar{x}) = \{d \in \mathbb{R}^2 \mid d_1 + d_2 > 0\}$, se hace evidente que ambos conos son mutuamente excluyentes (separados por la recta frontera $d_1 + d_2 = 0$).

Por lo tanto, la intersección es vacía:

$$\mathcal{D}_0(\bar{x}) \cap \mathcal{G}_0(\bar{x}) = \emptyset$$

Como se ilustra en la Figura 4.7, los conos representados en el espacio de direcciones son disjuntos, lo que califica a $\bar{x} = (2, 1)$ como candidato a óptimo.

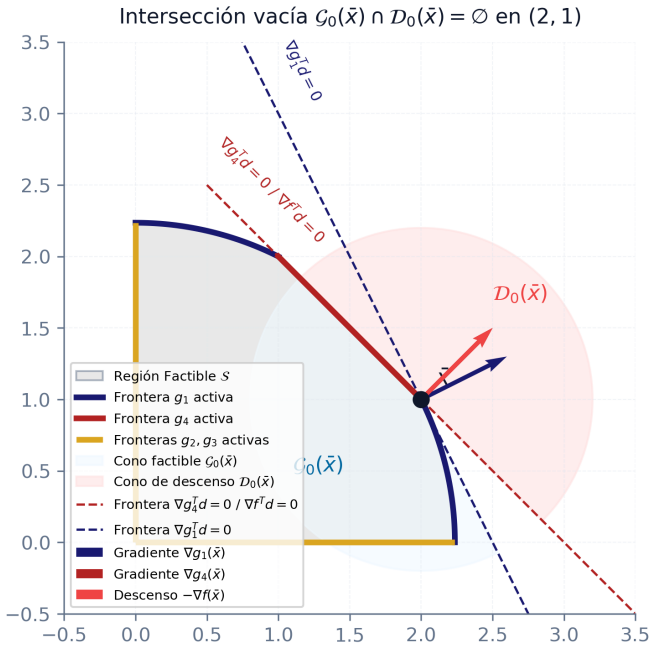

Figura 4.7: Geometría de conos en $\bar{x} = (2, 1)$ (óptimo)

Nota: En este punto no se cumple la condición del Teorema de Suficiencia geométrica sin KKT, debido a que la restricción lineal activa $g_4(x) = x_1 + x_2 - 3 \leq 0$ no es *estrictamente* pseudo-convexa (las funciones lineales son pseudo-convexas pero no estrictamente pseudo-convexas, ya que admiten puntos distintos con el mismo valor de la función y gradientes ortogonales al vector de desplazamiento). Sin embargo, al tratarse de un problema con objetivo estrictamente convexo y región factible convexa (intersección de conjuntos convexos), la condición necesaria de intersección vacía de conos es también suficiente para garantizar que $\bar{x} = (2, 1)$ es el mínimo global y único del problema.

Ejemplo: Caso singular de tangencia cúbica

Considérese el siguiente problema:

$$\begin{aligned} \text{mín} \quad & f(x_1, x_2) = (x_1 - 1)^2 + (x_2 - 1)^2 \\ \text{s.a.} \quad & g_1(x_1, x_2) = (x_1 + x_2 - 1)^3 \leq 0 \\ & g_2(x_1, x_2) = -x_1 \leq 0 \\ & g_3(x_1, x_2) = -x_2 \leq 0 \end{aligned}$$

La región factible geométrica de este problema es el triángulo $\mathcal{S} = \{(x_1, x_2) \in \mathbb{R}^2 \mid x_1 + x_2 \leq 1,\ x_1 \geq 0,\ x_2 \geq 0\}$. Al ser f estrictamente convexa (las curvas de nivel son circunferencias concéntricas con centro en $(1, 1)$) y la región factible convexa, existe un único mínimo global. Geométricamente, el punto factible más cercano al óptimo no restringido $(1, 1)$ es el punto medio de la hipotenusa (como se muestra en la Figura 4.8):

$$\bar{x} = \left(\frac{1}{2}, \frac{1}{2}\right)$$

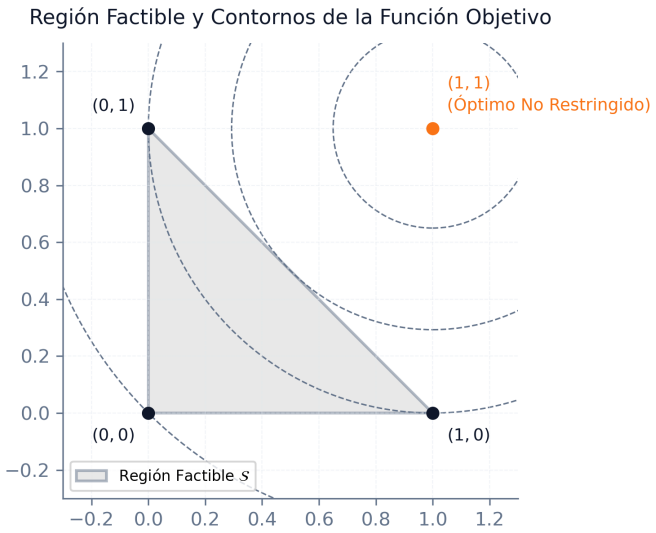

Figura 4.8: Visualización de la región factible y contornos para la tangencia cúbica

En todos los puntos de la frontera definidos por la recta $x_1 + x_2 = 1$, la primera restricción es activa ($g_1(x) = 0$). Evaluemos el gradiente de esta restricción activa en cualquier punto de dicha recta:

$$\nabla g_1(x_1, x_2) = \begin{pmatrix} 3(x_1 + x_2 - 1)^2 \\ 3(x_1 + x_2 - 1)^2 \end{pmatrix}$$

Puesto que en la recta se cumple $x_1 + x_2 - 1 = 0$, el gradiente se anula idénticamente para todos los puntos de la misma:

$$\nabla g_1(x_1, x_2) = \begin{pmatrix} 0 \\ 0 \end{pmatrix}, \quad \forall (x_1, x_2) \text{ tal que } x_1 + x_2 = 1$$

En consecuencia, para cualquier punto $\bar{x}$ sobre esta frontera (incluyendo puntos no óptimos como el $(1, 0)$ o el $(0, 1)$), el cono de restricciones activas algebraico resulta:

$$\mathcal{G}_0(\bar{x}) = \{d \in \mathbb{R}^2 \mid \nabla g_1(\bar{x})^T d < 0\} = \{d \in \mathbb{R}^2 \mid 0 < 0\} = \emptyset$$

Al ser $\mathcal{G}_0(\bar{x})$ el conjunto vacío, se cumple de manera trivial que:

$$\mathcal{D}_0(\bar{x}) \cap \mathcal{G}_0(\bar{x}) = \emptyset$$

para **todos** los puntos de la recta $x_1 + x_2 = 1$. Esto ilustra que la condición necesaria de optimalidad $\mathcal{D}_0(\bar{x}) \cap \mathcal{G}_0(\bar{x}) = \emptyset$ se satisface trivialmente en puntos que no son mínimos, perdiendo toda su capacidad selectiva debido al carácter singular de la restricción (tangencia cúbica).

Sin embargo, si reescribimos algebraicamente la región factible con una restricción equivalente pero de primer orden:

$$g_1(x_1, x_2) = x_1 + x_2 - 1 \leq 0$$

su gradiente pasa a ser $\nabla g_1(x_1, x_2) = (1, 1)^T \neq (0, 0)^T$. Bajo esta nueva formulación:

$$\mathcal{G}_0(\bar{x}) = \{d \in \mathbb{R}^2 \mid d_1 + d_2 < 0\}$$

y el cono de descenso es:

$$\mathcal{D}_0(\bar{x}) = \{d \in \mathbb{R}^2 \mid 2(x_1 - 1)d_1 + 2(x_2 - 1)d_2 < 0\}$$

Al evaluar la condición de intersección vacía $\mathcal{D}_0(\bar{x}) \cap \mathcal{G}_0(\bar{x}) = \emptyset$, esta se verifica **únicamente** en el punto $\bar{x} = (1/2, 1/2)$, identificando de forma unívoca el mínimo local (como se ilustra en la Figura 4.9).

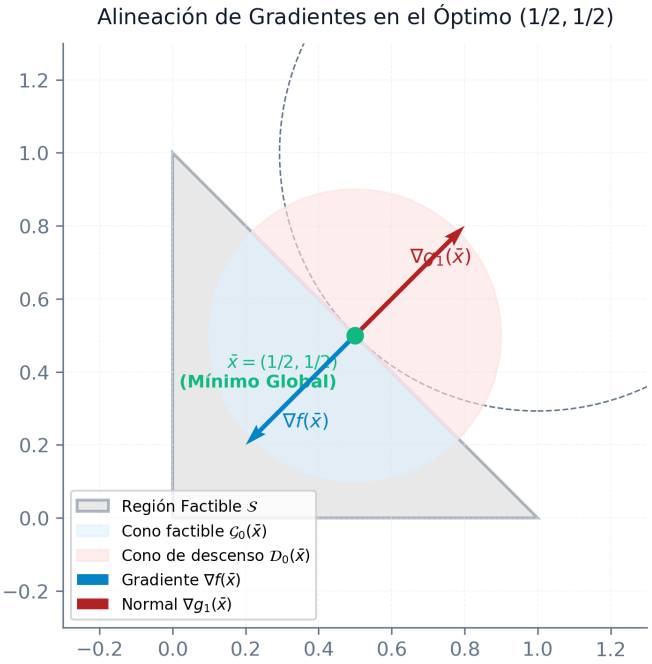

Figura 4.9: Alineación de gradientes en el óptimo $\bar{x} = (1/2, 1/2)$ bajo la formulación regularizada

4.4. Condiciones de Fritz-John (FJ)

La necesidad de encontrar un método algebraico sistemático para verificar la optimalidad nos lleva a formular el problema de manera dual. En la sección anterior comprobamos geométricamente que un punto candidato es óptimo si y solo si la intersección de su cono de descenso y su cono de restricciones activas es vacía ($\mathcal{D}_0(\bar{x}) \cap \mathcal{G}_0(\bar{x}) = \emptyset$). Sin embargo, esta verificación directa en el espacio de direcciones requiere evaluar infinitos vectores, lo cual es impracticable. Para superar esta limitación, las condiciones de Fritz-John (FJ) traducen esta exclusión geométrica en un sistema de ecuaciones algebraicas sobre los gradientes de las funciones, permitiendo comprobar la optimalidad mediante multiplicadores asociados a cada restricción. Este paso fundamental se logra formalmente gracias a los lemas de alternativas.

Los lemas de alternativas son resultados clásicos del álgebra lineal y la convexidad que establecen que de dos sistemas de desigualdades lineales, uno y solo uno de ellos tiene solución. Permiten asociar coeficientes (multiplicadores) a las restricciones del problema a partir de la ausencia de direcciones comunes. Dos de los resultados más célebres son los siguientes:

Lema: Alternativa de Farkas

Sean A una matriz de dimensiones $m \times n$ y $c \in \mathbb{R}^n$. Uno y solo uno de los siguientes sistemas de restricciones tiene solución:

1. Existe $x \in \mathbb{R}^n$ tal que $Ax \leq 0$ y $c^T x > 0$.
2. Existe $y \in \mathbb{R}^m$ tal que $A^T y = c$ e $y \geq 0$.

Lema: Alternativa de Gordan

Sea A una matriz de dimensiones $m \times n$. Uno y solo uno de los siguientes sistemas de restricciones tiene solución:

1. Existe $x \in \mathbb{R}^n$ tal que $Ax < 0$.
2. Existe $y \in \mathbb{R}^m$ tal que $A^T y = 0$, $y \geq 0$ e $y \neq 0$.

La utilidad de estos lemas radica en que nos permiten reformular la disyunción geométrica en términos de combinaciones lineales de gradientes. En particular, la condición de optimalidad geométrica exige que no exista ninguna dirección d que satisfaga simultáneamente $\nabla f(\bar{x})^T d < 0$ y $\nabla g_i(\bar{x})^T d < 0$ para las restricciones activas. Si representamos estos gradientes como las filas de una matriz A, esta condición equivale a afirmar que el sistema de desigualdades estrictas $Ad < 0$ no tiene solución. Al aplicar el Lema de Gordan a este sistema sin solución, este nos garantiza de forma dual la existencia de un vector de coeficientes no negativos y no todos nulos que anula la combinación lineal de las filas. De este modo, la ausencia de una dirección factible de descenso se traduce en la existencia de un equilibrio de fuerzas entre los gradientes del objetivo y de las restricciones activas, dando origen al teorema de Fritz-John (John 1948):

! Teorema: Condiciones necesarias de Fritz-John (1948)

Sea $\bar{x}$ un mínimo local del problema restringido por desigualdades. Si f y las restricciones activas g_i $(i \in \mathcal{I})$ son diferenciables en $\bar{x}$, y las inactivas son continuas, existen escalares $u_0, u_1, \dots, u_m$ tales que:

1. **Factibilidad dual (Ecuación de Fritz-John)**:

$$u_0 \nabla f(\bar{x}) + \sum_{i=1}^{m} u_i \nabla g_i(\bar{x}) = 0$$

2. **Holgura complementaria**:

$$u_i g_i(\bar{x}) = 0, \quad \forall i = 1, \dots, m$$

3. **No negatividad**:

$$u_0, u_i \geq 0, \quad \forall i = 1, \dots, m$$

4. **No trivialidad**:

$$(u_0, u_1, \dots, u_m) \neq (0, 0, \dots, 0)$$

Demostración: Puesto que $\bar{x}$ es un mínimo local del problema, se cumple que $\mathcal{D}_0(\bar{x}) \cap \mathcal{G}_0(\bar{x}) = \emptyset$. Esto equivale a afirmar que el sistema de desigualdades estrictas:

$$\nabla f(\bar{x})^T d < 0 \qquad \text{y} \qquad \nabla g_i(\bar{x})^T d < 0, \quad \forall i \in \mathcal{I}$$

no tiene solución $d \in \mathbb{R}^n$. Definamos la matriz A cuyas filas son $\nabla f(\bar{x})^T$ y $\nabla g_i(\bar{x})^T$ para cada $i \in \mathcal{I}$. El hecho de que no exista ninguna dirección d implica que el sistema lineal $Ad < 0$ no tiene solución.
Aplicando el Lema de Gordan a la matriz A, existe un vector de multiplicadores no trivial $p = (u_0, u_{\mathcal{I}})^T \geq 0$ con $p \neq 0$ tal que:

$$A^T p = u_0 \nabla f(\bar{x}) + \sum_{i \in \mathcal{I}} u_i \nabla g_i(\bar{x}) = 0$$

Definiendo $u_j = 0$ para todos los índices de restricciones inactivas $(j \notin \mathcal{I})$, se satisfacen de forma automática las condiciones de holgura complementaria y se obtiene la relación general para todo $i = 1, \dots, m$, lo que demuestra el teorema. ■

El aspecto clave de este teorema es que introduce el multiplicador u_0 para la función objetivo. Si $u_0 > 0$, las condiciones necesarias de Fritz-John equivalen a las condiciones de Karush-Kuhn-Tucker (KKT). Sin embargo, si $u_0 = 0$, el objetivo desaparece de la ecuación dual y las condiciones se satisfacen de forma puramente geométrica por la disposición de las restricciones en la frontera, perdiendo su utilidad para encontrar mínimos.

Para interpretar físicamente este equilibrio de gradientes, resulta de gran valor analizar cómo

actúan y qué significan estos multiplicadores en el plano coordenado. Dependiendo de la disposición geométrica de las restricciones y de la orientación de las curvas de nivel del objetivo, el sistema dual de Fritz-John puede comportarse de maneras muy distintas. A través del siguiente ejemplo interactivo en el punto de intersección $(7/3, 4/3)$, exploraremos los cuatro escenarios fundamentales que caracterizan esta relación dual, comprendiendo cómo los signos y la dependencia lineal de los gradientes determinan si el punto es un mínimo regular, un punto redundante con múltiples multiplicadores, una singularidad de la frontera o un máximo descartado.

Ejemplo: Interpretación geométrica de Fritz-John en cuatro casos

Consideremos el punto de intersección $\bar{x} = (7/3, 4/3)$ bajo diferentes problemas de optimización con restricciones lineales activas $g_1(x, y) = 2x + y - 6 \leq 0$ y $g_2(x, y) = x - y - 1 \leq 0$, cuyos gradientes en $\bar{x}$ son $\nabla g_1 = (2, 1)^T$ y $\nabla g_2 = (1, -1)^T$. Analizaremos la relación entre el gradiente del objetivo $\nabla f(\bar{x})$, el opuesto $-\nabla f(\bar{x})$ y los gradientes de las restricciones en cuatro escenarios.

Caso 1: Restricciones Linealmente Independientes (Mínimo Local Regular) Estudiamos la minimización de $f(x, y) = (x-5)^2+(y-1)^2$ sujeto a g_1 y g_2. El opuesto del gradiente del objetivo en $\bar{x}$ es $-\nabla f(\bar{x}) = (16/3, -2/3)^T$, el cual se encuentra dentro del cono convexo generado por los gradientes de las restricciones activas (véase la Figura 4.10). Al resolver la ecuación dual:

$$u_0 \begin{pmatrix} 16/3 \\ -2/3 \end{pmatrix} = u_1 \begin{pmatrix} 2 \\ 1 \end{pmatrix} + u_2 \begin{pmatrix} 1 \\ -1 \end{pmatrix}$$

obtenemos la solución única en función de u_0: $u_1 = \frac{14}{9}u_0 > 0$ y $u_2 = \frac{20}{9}u_0 > 0$. Al poder fijar $u_0 = 1$, el punto es un mínimo regular válido.

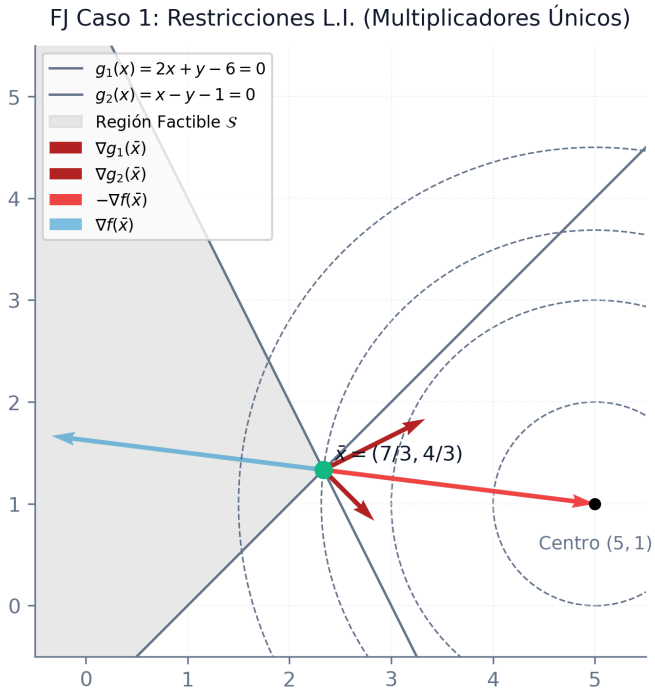

Figura 4.10: FJ Caso 1: Restricciones linealmente independientes y $-\nabla f(\bar{x})$ dentro del cono factible

Caso 2: Restricción Activa Redundante (Linealmente Dependiente) Añadimos al problema anterior la restricción redundante $g_3(x, y) = x \leq 7/3$, activa en $\bar{x}$ con gradiente $\nabla g_3 = (1, 0)^T$. Como se ilustra en la Figura 4.11, los tres gradientes de las restricciones son linealmente dependientes. La ecuación dual admite infinitas combinaciones válidas para expresar $-\nabla f(\bar{x})$. Por ejemplo, con $u_0 = 1$, la familia de soluciones está dada por $u_1 \in [0, 14/9]$, $u_2 = u_1 + 2/3$, y $u_3 = 14/3 - 3u_1$, perdiendo la unicidad de los multiplicadores.

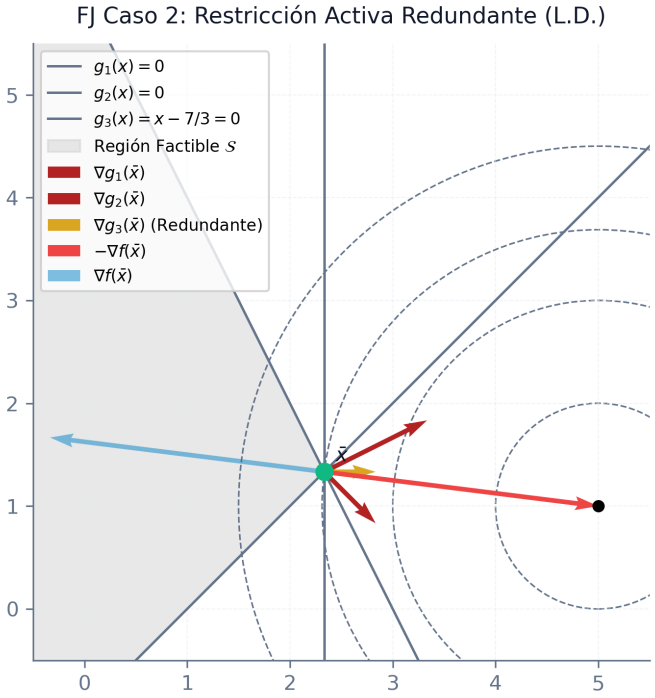

Figura 4.11: FJ Caso 2: Restricción activa redundante y pérdida de la unicidad de los multiplicadores

Caso 3: Conos de Restricción Contradictorios (Singularidad con $u_0 = 0$) Añadimos la restricción opuesta $g_3(x, y) = -x \leq -7/3$, con gradiente $\nabla g_3 = (-1, 0)^T$. Los tres gradientes activos cubren el espacio imposibilitando cualquier dirección factible ($\mathcal{G}_0 = \emptyset$). En este caso, la Figura 4.12 muestra que podemos equilibrar los gradientes de las restricciones de forma interna sin la participación del objetivo:

$$u_1 \begin{pmatrix} 2 \\ 1 \end{pmatrix} + u_2 \begin{pmatrix} 1 \\ -1 \end{pmatrix} + u_3 \begin{pmatrix} -1 \\ 0 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix} \implies u_1 = u_2 = 1,\ u_3 = 3$$

Esto nos da una solución no trivial con $u_0 = 0$, $u_1 = 1$, $u_2 = 1$, $u_3 = 3$. Las condiciones FJ se cumplen de forma trivial e independiente del objetivo.

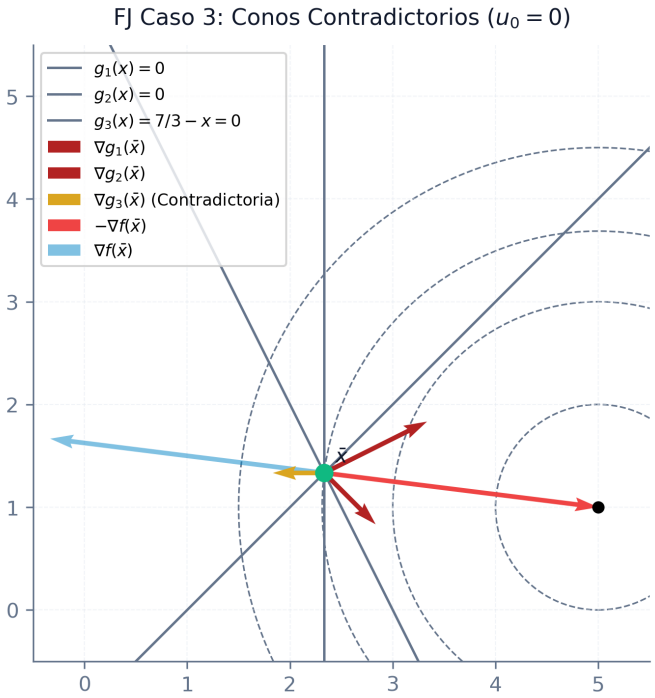

Figura 4.12: FJ Caso 3: Conos de restricción contradictorios que provocan $u_0 = 0$

Caso 4: Punto de Máximo Local (Multiplicadores Negativos) Si intentamos minimizar $f(x, y) = -(x-5)^2 - (y-1)^2$ (o equivalentemente, maximizar la distancia a $(5, 1)$), el opuesto del gradiente apunta hacia fuera del cono generado por los gradientes de las restricciones activas: $-\nabla f(\bar{x}) = (-16/3, 2/3)^T$ (véase la Figura 4.13). Al resolver la ecuación dual con $u_0 > 0$, los multiplicadores resultan negativos ($u_1 = -14/9u_0 < 0$), lo que permite descartar correctamente este candidato a mínimo local.

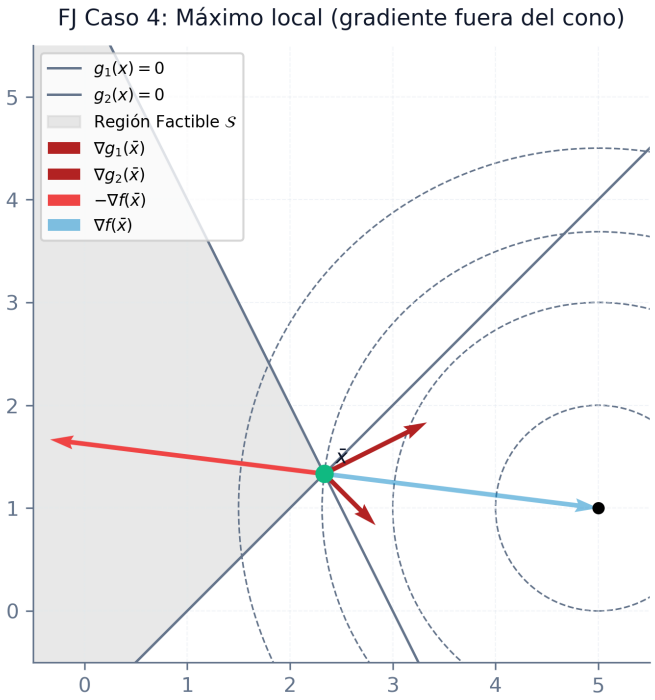

Figura 4.13: FJ Caso 4: Dirección del gradiente opuesta y descarte de un máximo local

El análisis de estos cuatro casos revela que las condiciones de Fritz-John no solo identifican mínimos locales regulares, sino que actúan como un "filtro" analítico que captura cualquier punto singular de la frontera de la región factible, independientemente de la función objetivo. Esto nos permite clasificar los candidatos seleccionados por el formalismo dual de Fritz-John en tres grandes familias según su origen físico y geométrico:

1. **Vértices o puntos de esquina**: Puntos de la frontera donde coinciden múltiples restricciones activas linealmente independientes que bloquean cualquier dirección de movimiento físico, independientemente de la dirección de la función objetivo.
2. **Puntos de tangencia regular**: Puntos de la frontera lisa de una restricción donde el gradiente de la función objetivo $\nabla f(\bar{x})$ y el gradiente de la restricción activa $\nabla g_i(\bar{x})$ son colineales y apuntan en sentidos opuestos, cumpliendo directamente la condición de tangencia con $u_0 > 0$.
3. **Puntos singulares o de cúspide**: Puntos donde la geometría de la frontera es tan restrictiva que la cualificación de restricciones falla (los gradientes activos son linealmente dependientes), permitiendo resolver el sistema con $u_0 = 0$ sin importar cómo se comporte localmente la función objetivo.

Esta capacidad para identificar singularidades es a la vez una virtud y una debilidad del formalismo de Fritz-John. En puntos singulares, el sistema dual se satisface de forma espuria

con un multiplicador de la función objetivo nulo ($u_0 = 0$), lo que significa que el gradiente de la función que deseamos minimizar no ejerce ninguna influencia en las ecuaciones de optimalidad. Este fenómeno de insensibilidad se vuelve evidente cuando la frontera presenta tangencias singulares o cuando se introducen restricciones redundantes artificiales, como se analiza en la siguiente advertencia teórica:

Nota teórica sobre vulnerabilidad por redundancia trivial

Es importante notar que siempre es posible transformar de forma artificial cualquier punto factible en un candidato Fritz-John añadiendo una restricción redundante inútil. Por ejemplo, si añadimos la restricción $\|x - \bar{x}\| \geq 0$, que es universalmente cierta, en el punto $\bar{x}$ esta restricción se activa y su gradiente es nulo. Esto provoca que el cono de restricciones active $\mathcal{G}_0$ se vuelva vacío, forzando a que las condiciones de Fritz-John se satisfagan de manera trivial con multiplicadores no nulos e $u_0 = 0$.

Para ilustrar este comportamiento patológico y entender cómo se rompe la sensibilidad del objetivo, analizaremos detalladamente un problema con una tangencia de orden superior (cúbica) en la frontera, donde el multiplicador de la función objetivo se anula obligatoriamente en el óptimo:

Ejemplo: Fallo de Fritz-John por multiplicador nulo

Consideremos el problema:

$$\begin{aligned} \min_{x} \quad & -x_1 \\ \text{sujeto a} \quad & g_1(x_1, x_2) = x_2 - (1 - x_1)^3 \leq 0 \\ & g_2(x_1, x_2) = -x_2 \leq 0 \end{aligned}$$

La solución óptima de este problema es $\bar{x} = (1, 0)$ (como se ilustra en la Figura 4.14), donde ambas restricciones son activas ($\mathcal{J} = \{1, 2\}$). Planteando las ecuaciones de Fritz-John:

$$u_0 \begin{pmatrix} -1 \\ 0 \end{pmatrix} + u_1 \begin{pmatrix} 3(1 - x_1)^2 \\ 1 \end{pmatrix} + u_2 \begin{pmatrix} 0 \\ -1 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

Evaluando en el punto óptimo $\bar{x} = (1, 0)$:

$$u_0 \begin{pmatrix} -1 \\ 0 \end{pmatrix} + u_1 \begin{pmatrix} 0 \\ 1 \end{pmatrix} + u_2 \begin{pmatrix} 0 \\ -1 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix} \implies \begin{aligned} -u_0 &= 0 \\ u_1 - u_2 &= 0 \end{aligned}$$

De donde se deduce obligatoriamente que $u_0 = 0$, e $u_1 = u_2 = \alpha > 0$. La función objetivo no influye en las ecuaciones debido a la geometría singular de la región factible en dicho punto (la tangencia de las curvas de restricción).

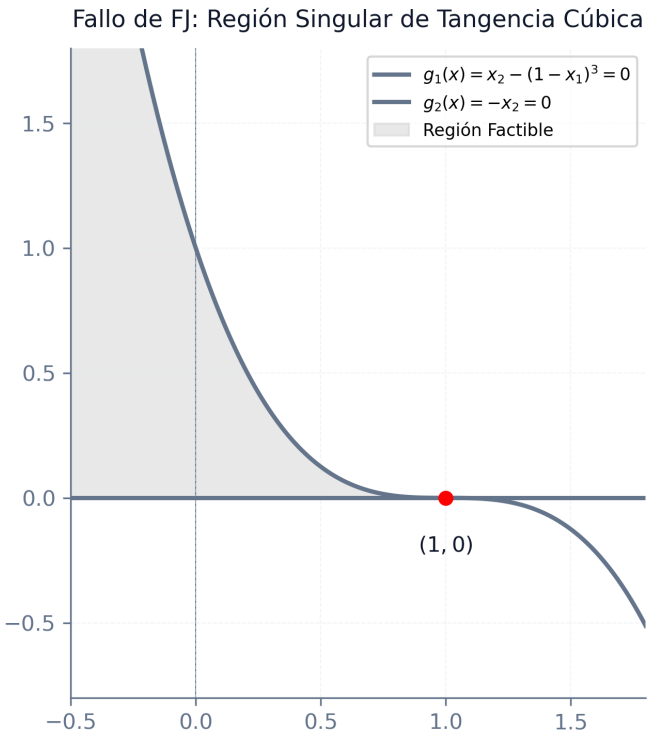

Figura 4.14: Visualización de la región factible y la tangencia cúbica en $\bar{x} = (1, 0)$

Para apreciar la diferencia que introduce una formulación regular en la frontera, consideremos ahora el mismo problema pero sustituyendo la restricción cúbica singular por una restricción lineal equivalente. Al regularizar la frontera, el punto singular desaparece, lo que permite que el objetivo vuelva a participar activamente en la caracterización del óptimo:

Ejemplo: Fritz-John regular con objetivo activo

Si modificamos el problema anterior sustituyendo la restricción cúbica por una restricción lineal regular:

$$\begin{aligned} \text{mín} \quad & -x_1 \\ \text{s.a.} \quad & g_1(x_1, x_2) = x_1 + x_2 - 1 \leq 0 \\ & g_2(x_1, x_2) = -x_2 \leq 0 \end{aligned}$$

En el óptimo $\bar{x} = (1, 0)$ (véase la Figura 4.15), ambas restricciones son activas. La ecuación de Fritz-John es:

$$u_0 \begin{pmatrix} -1 \\ 0 \end{pmatrix} + u_1 \begin{pmatrix} 1 \\ 1 \end{pmatrix} + u_2 \begin{pmatrix} 0 \\ -1 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix} \implies \begin{aligned} -u_0 + u_1 &= 0 \\ u_1 - u_2 &= 0 \end{aligned}$$

Lo que nos da $u_1 = u_2 = u_0$. Podemos fijar $u_0 = 1$ para obtener la solución regular $u_1 = u_2 = 1 > 0$, donde la función objetivo influye activamente en el óptimo.

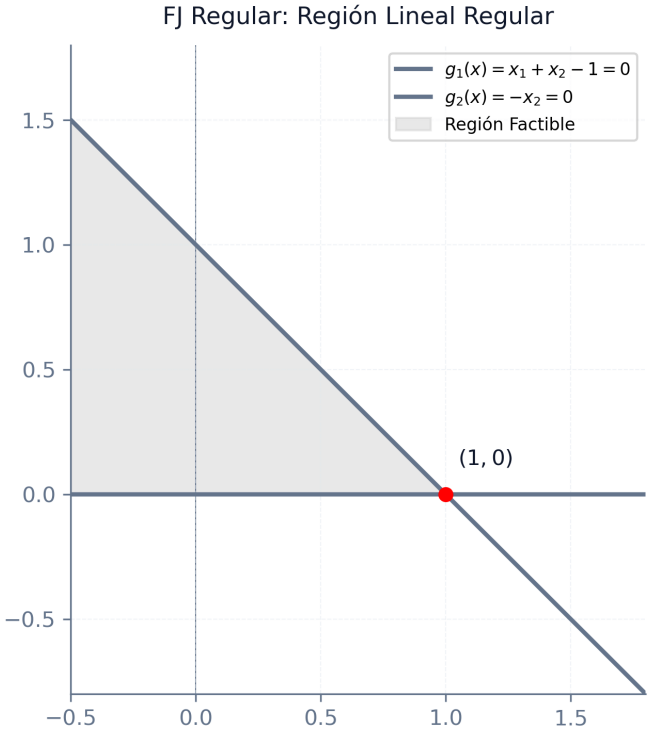

Figura 4.15: Visualización de la región factible regular y lineal en $\bar{x} = (1, 0)$

Los ejemplos anteriores muestran que existen puntos que verifican las condiciones de Fritz-John de forma trivial, perdiendo toda la sensibilidad respecto a la función objetivo. La teoría general identifica tres escenarios habituales de esta vulnerabilidad dual:

1. **Estacionariedad simultánea**: Si en el punto candidato coinciden un mínimo local libre del objetivo y un punto de tangencia de restricciones, de manera que $\nabla f(\bar{x}) = 0$ y $\nabla g_i(\bar{x}) = 0$ para algún $i \in \mathcal{J}$, entonces es posible tomar $u_0 > 0$ e $u_i > 0$ con el resto de los multiplicadores nulos. Esto satisface las condiciones de Fritz-John de forma trivial sin reflejar la influencia real del acoplamiento de las restricciones.
2. **Desdoblamiento de restricciones de igualdad**: Si una restricción de igualdad $h(x) = 0$ se sustituye por dos desigualdades $h(x) \leq 0$ y $-h(x) \leq 0$, en cualquier punto factible ambas restricciones son activas con gradientes opuestos $\nabla h(\bar{x})$ y $-\nabla h(\bar{x})$. Esto permite anular el sistema dual de Fritz-John de forma trivial asignando un valor positivo a los multiplicadores de estas restricciones y cero al resto, independientemente de la función objetivo (provocando $u_0 = 0$).
3. **Redundancia trivial en la frontera**: Como vimos en la advertencia teórica, siempre

es posible añadir una restricción redundante del tipo $\|x - \bar{x}\| \geq 0$, que es universalmente cierta. En el punto $\bar{x}$, esta restricción se activa y su gradiente es nulo, lo que anula el cono de restricciones activas $\mathcal{G}_0 = \emptyset$ y fuerza $u_0 = 0$ en el sistema dual.

4.5. Condiciones de Karush-Kuhn-Tucker (KKT)

Existen problemas de optimización en los que se hallan puntos de Fritz-John con multiplicador $u_0 = 0$. Esto ocurre, por ejemplo, cuando el cono de direcciones factibles es vacío ($\mathcal{G}_0 = \emptyset$), ya que en tal escenario las condiciones duales se verifican de manera trivial independientemente de la función objetivo. En estas situaciones, el objetivo no interviene en la caracterización del punto óptimo.

Para solventar esta anomalía y garantizar que la función objetivo participe activamente en las condiciones de optimalidad ($u_0 \neq 0$), William Karush en 1939 (en su tesis de maestría inédita (Karush 1939)) e independientemente Harold W. Kuhn y Albert W. Tucker en 1951 (Kuhn y Tucker 1951), desarrollaron condiciones que imponen nuevas hipótesis de regularidad geométrica en las restricciones del punto óptimo, denominadas **cualificaciones de restricciones**.

La cualificación de restricciones más habitual y de mayor relevancia didáctica es la **Independencia Lineal de las Restricciones Activas (LICQ)**, la cual exige que los gradientes de todas las restricciones activas en el punto de estudio $\{\nabla g_i(\bar{x}), \forall i \in \mathcal{I}\}$ sean linealmente independientes. Al añadir esta condición de regularidad, la ecuación de Fritz-John obliga a que $u_0 > 0$, lo que permite caracterizar el óptimo con la participación directa de la función objetivo:

! Teorema: Condiciones necesarias de KKT

Sea el problema:

$$\text{mín}\{f(x) \mid x \in \mathcal{X},\ g_i(x) \leq 0,\ i = 1, \ldots, m\}$$

y sea $\bar{x}$ una solución factible, con el conjunto de restricciones activas $\mathcal{I} = \{i \mid g_i(\bar{x}) = 0\}$. Supongamos que:

1. Las funciones f y g_i ($i \in \mathcal{I}$) son diferenciables en $\bar{x}$.
2. Las restricciones inactivas g_i ($i \notin \mathcal{I}$) son continuas en $\bar{x}$.
3. Se verifica la cualificación de restricciones (LICQ) en $\bar{x}$; es decir, los gradientes de las restricciones activas $\{\nabla g_i(\bar{x}), i \in \mathcal{I}\}$ son linealmente independientes.

Entonces, si $\bar{x}$ es un mínimo local de f, existen escalares únicos $\{u_i, i \in \mathcal{I}\}$, con $u_i \geq 0$, $\forall i \in \mathcal{I}$ tales que:

$$\nabla f(\bar{x}) + \sum_{i \in \mathcal{I}} u_i \nabla g_i(\bar{x}) = 0$$

Si además se verifica que las restricciones inactivas $\{g_i, i \notin \mathcal{I}\}$ son también diferenciables en $\bar{x}$, las condiciones anteriores se extienden a todo el conjunto de restricciones y se expresan de la forma estándar de KKT:

1. **Factibilidad dual (Estacionariedad)**:

$$\nabla f(\bar{x}) + \sum_{i=1}^{m} u_i \nabla g_i(\bar{x}) = 0$$

2. **Factibilidad primal**:

$$g_i(\bar{x}) \leq 0, \quad \forall i = 1, \dots, m$$

3. **Holgura complementaria**:

$$u_i g_i(\bar{x}) = 0, \quad \forall i = 1, \dots, m$$

4. **No negatividad (Factibilidad dual de multiplicadores)**:

$$u_i \geq 0, \quad \forall i = 1, \dots, m$$

Los escalares u_i reciben el nombre de **multiplicadores de Lagrange**. Los puntos $\bar{x}$ que satisfacen las condiciones KKT anteriores (factibilidad primal, factibilidad dual y holgura complementaria) se denominan **puntos KKT**.
Demostración: Por las condiciones necesarias de Fritz-John, existen multiplicadores no todos nulos $u_0, \hat{u}_i \geq 0$ (para $i \in \mathcal{I}$) tales que:

$$u_0 \nabla f(\bar{x}) + \sum_{i \in \mathcal{I}} \hat{u}_i \nabla g_i(\bar{x}) = 0$$

Probaremos por contradicción que $u_0 > 0$. Si $u_0 = 0$, la ecuación se reduce a:

$$\sum_{i \in \mathcal{I}} \hat{u}_i \nabla g_i(\bar{x}) = 0$$

Dado que por la cualificación de restricciones (LICQ), los gradientes $\{\nabla g_i(\bar{x}), i \in \mathcal{I}\}$ son linealmente independientes, la única combinación lineal que se anula es la trivial, lo que exige que $\hat{u}_i = 0$ para todo $i \in \mathcal{I}$. Como también habíamos supuesto $u_0 = 0$, esto implica que todos los multiplicadores son nulos, lo que contradice la condición de no trivialidad de Fritz-John ($(u_0, \hat{u}) \neq 0$).
Por tanto, se cumple que $u_0 > 0$. Definiendo los multiplicadores normalizados para las restricciones activas como $u_i = \frac{\hat{u}_i}{u_0} \geq 0$ (para $i \in \mathcal{I}$), se obtiene la primera parte de la demostración. Tomando además $u_j = 0$ para las restricciones inactivas ($j \notin \mathcal{I}$), se obtiene la segunda parte (formulación estándar de KKT). La unicidad de los multiplicadores se deriva de la independencia lineal de los gradientes de las restricciones activas. ■

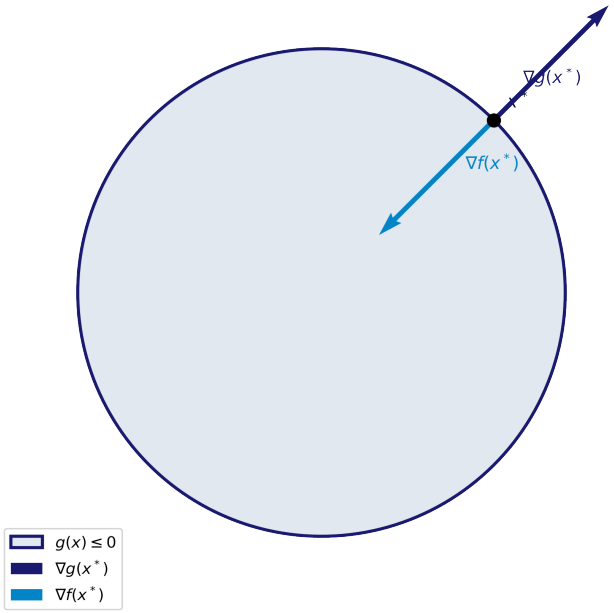

Figura 4.16: Interpretación geométrica de las condiciones KKT con restricciones activas

Las condiciones KKT son únicamente necesarias

Las condiciones KKT son únicamente **necesarias** en problemas generales. Es fundamental señalar que no se aplican a todos los puntos, sino que excluyen a aquellos que violan la cualificación de restricciones (LICQ). Por consiguiente, existe la posibilidad de que el óptimo global del problema se encuentre precisamente entre los puntos excluidos (por ejemplo, en un punto singular de la frontera donde los gradientes de las restricciones activas sean linealmente dependientes). En cualquier resolución analítica, estos puntos singulares deben analizarse de manera independiente.
Sin embargo, cabe destacar que para **problemas lineales**, las condiciones KKT sí resultan ser necesarias y suficientes.

Observación: Extensión a máximos locales

Si el punto $\bar{x}$ es un máximo local, entonces las condiciones necesarias de KKT siguen siendo válidas sin más que exigir que los multiplicadores de Lagrange sean no positivos ($u_i \leq 0$, $\forall i = 1, \dots, m$).

Para dar el paso de condiciones necesarias a **suficientes** en problemas generales no lineales y garantizar el carácter **global** del mínimo, debemos exigir condiciones adicionales sobre la

curvatura de las funciones implicadas:

! Teorema: Condiciones suficientes de KKT bajo convexidad

Sea $\bar{x}$ un punto factible que satisface las condiciones necesarias de KKT con multiplicadores u_i. Si:

1. La función objetivo $f(x)$ es **pseudo-convexa** en $\bar{x}$.
2. Las restricciones activas $g_i(x)$ $(i \in \mathcal{J})$ son **cuasi-convexas** y diferenciables en $\bar{x}$.

Entonces $\bar{x}$ es un mínimo global del problema.
Demostración: Sea x un punto factible cualquiera del problema, lo que implica que $g_i(x) \leq 0$ para todo $i = 1, \dots, m$. Para las restricciones activas $(i \in \mathcal{J})$, se cumple que $g_i(\bar{x}) = 0$, lo que nos da:

$$g_i(x) \leq g_i(\bar{x}) = 0, \quad \forall i \in \mathcal{J}$$

Puesto que las restricciones activas g_i $(i \in \mathcal{J})$ son cuasi-convexas y diferenciables en $\bar{x}$, por la definición de cuasi-convexidad se tiene que para cualquier $\lambda \in [0, 1]$:

$$g_i(\bar{x} + \lambda(x - \bar{x})) \leq \max\{g_i(x), g_i(\bar{x})\} \leq g_i(\bar{x}) = 0$$

Esto implica que la función g_i no crece cuando nos desplazamos desde el punto óptimo $\bar{x}$ en la dirección de factibilidad $(x - \bar{x})$. Por lo tanto, $(x - \bar{x})$ es una dirección de no ascenso (o dirección de descenso) en $\bar{x}$, lo que se traduce en:

$$\nabla g_i(\bar{x})^T (x - \bar{x}) \leq 0, \quad \forall i \in \mathcal{J}$$

Como los multiplicadores KKT son no negativos $(u_i \geq 0)$, al multiplicar cada una de estas expresiones y sumarlas sobre el conjunto de restricciones activas $\mathcal{J}$, obtenemos:

$$\sum_{i \in \mathcal{J}} u_i \nabla g_i(\bar{x})^T (x - \bar{x}) \leq 0$$

Por la condición de estacionariedad (factibilidad dual) de KKT, se tiene que $\sum_{i \in \mathcal{J}} u_i \nabla g_i(\bar{x}) = -\nabla f(\bar{x})$. Sustituyendo esta igualdad en la desigualdad anterior:

$$\nabla f(\bar{x})^T (x - \bar{x}) = -\sum_{i \in \mathcal{J}} u_i \nabla g_i(\bar{x})^T (x - \bar{x}) \geq 0$$

Finalmente, puesto que la función objetivo f es pseudo-convexa en $\bar{x}$, la condición de primer orden $\nabla f(\bar{x})^T (x - \bar{x}) \geq 0$ garantiza que:

$$f(x) \geq f(\bar{x})$$

Como esta desigualdad es válida para todo punto factible x, concluimos que $\bar{x}$ es un mínimo global del problema. ■

Observación sobre suficiencia local y unicidad

- Si las condiciones de pseudo-convexidad, cuasi-convexidad y diferenciabilidad se verifican sólo localmente en un entorno de $\bar{x}$, entonces $\bar{x}$ será un mínimo local.
- Si el punto $\bar{x}$ es un máximo local, entonces, para que sea máximo global en la primera condición hay que exigir que la función objetivo f sea **pseudo-cóncava** (o equivalentemente, $-f$ sea pseudo-convexa).
- Asimismo, si la función objetivo es estrictamente pseudo-convexa, el punto mínimo global $\bar{x}$ es único.

Ejemplo: Análisis por casos de KKT

Consideremos el problema de encontrar los candidatos a mínimos y máximos locales y globales de:

$$\begin{aligned} \text{mín} \,/\, \text{máx} \quad & f(x_1, x_2) = x_1 + x_2 \\ \text{s.a.} \quad & g_1(x_1, x_2) = x_1^2 + x_2^2 - 4 \leq 0 \\ & g_2(x_1, x_2) = -x_1^2 + x_2 \leq 0 \end{aligned}$$

Calculamos en primer lugar los gradientes de las funciones implicadas:

$$\nabla f(x) = \begin{pmatrix} 1 \\ 1 \end{pmatrix}, \quad \nabla g_1(x) = \begin{pmatrix} 2x_1 \\ 2x_2 \end{pmatrix}, \quad \nabla g_2(x) = \begin{pmatrix} -2x_1 \\ 1 \end{pmatrix}$$

La función Lagrangiana del problema es:

$$L(x_1, x_2, u_1, u_2) = x_1 + x_2 + u_1(x_1^2 + x_2^2 - 4) + u_2(-x_1^2 + x_2)$$

El sistema de condiciones KKT (que integra estacionariedad, factibilidad primal, ortogonalidad y no negatividad) se plantea como:

1. **Estacionariedad (Factibilidad dual)**:

$$\frac{\partial L}{\partial x_1} = 1 + 2u_1x_1 - 2u_2x_1 = 0 \implies 1 + 2x_1(u_1 - u_2) = 0$$

$$\frac{\partial L}{\partial x_2} = 1 + 2u_1x_2 + u_2 = 0$$

2. **Factibilidad primal**:

$$x_1^2 + x_2^2 - 4 \leq 0$$
$$-x_1^2 + x_2 \leq 0$$

3. **Ortogonalidad (Holgura complementaria)**:

$$u_1(x_1^2 + x_2^2 - 4) = 0$$
$$u_2(-x_1^2 + x_2) = 0$$

4. **No negatividad / No positividad**:
   - Para **mínimos**: $u_1, u_2 \geq 0$.
   - Para **máximos**: $u_1, u_2 \leq 0$.

En la Figura 4.17 se representa la geometría general del problema. La región factible $\mathcal{S}$ está sombreada en gris (delimitada por la circunferencia en azul oscuro y la parábola en rojo brick), y las líneas discontinuas paralelas representan las curvas de nivel del objetivo $f(x_1, x_2) = x_1 + x_2$, cuyo gradiente ∇f apunta a 45 grados en dirección noreste.

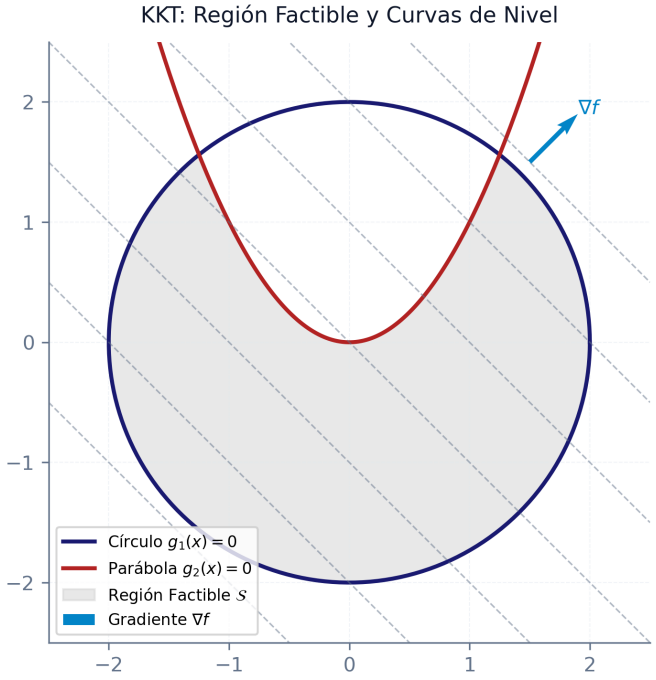

Figura 4.17: KKT: Región Factible y Curvas de Nivel

Observamos que no es posible que ambas restricciones sean inactivas ($u_1 = 0, u_2 = 0$), ya que en tal caso la condición de estacionariedad exigiría $\nabla f(x) = (1, 1)^T = (0, 0)^T$, lo cual es imposible. Por tanto, procedemos a analizar los casos restantes:
Analizamos a continuación la resolución por casos combinatorios de restricciones activas para desgranar paso a paso el problema:
Caso 1: Círculo inactivo ($u_1 = 0 \implies u_2 \neq 0$) El sistema de estacionariedad se reduce a:

$$1 - 2u_2x_1 = 0 \quad \text{y} \quad 1 + u_2 = 0 \implies u_2 = -1$$

Con $u_2 = -1$, sustituimos en la primera ecuación: $1 - 2(-1)x_1 = 0 \implies x_1 = -1/2$. Dado que $u_2 = -1 \neq 0$, la holgura complementaria exige que la restricción g_2 sea activa

($g_2(x) = 0$), lo que nos da $x_2 = x_1^2 = (-1/2)^2 = 1/4$. Esto nos da el punto candidato $A = (-1/2, 1/4)$.

- **Análisis del signo del multiplicador**: Obtenemos $u_2 = -1$.
  - Para **mínimos**, requerimos $u_i \geq 0$, por lo que A queda descartado.
  - Para **máximos**, requerimos $u_i \leq 0$. Dado que $u_2 = -1 \leq 0$, el punto $A = (-1/2, 1/4)$ es un candidato de primer orden a máximo local. Sin embargo, al realizar un análisis de segundo orden a lo largo de la frontera parabólica activa $g_2(x) = 0$, observamos que la función restringida a esta frontera es $f(t, t^2) = t + t^2$, la cual presenta un mínimo local en $t = -0.5$ (con $f(A) = -0.25$). Esto implica que en cualquier entorno de A existen puntos factibles en la frontera parabólica con valores mayores que $f(A)$ (por ejemplo, para $t = -0.5 + \epsilon$). Por lo tanto, el punto A **no es un máximo local** (ni tampoco un mínimo), siendo un punto que no es ni máximo ni mínimo o "ni máx ni mín".
- **Comprobación de factibilidad primal**: Verificamos si A cumple la restricción inactiva g_1:

$$g_1(-1/2, 1/4) = (-1/2)^2 + (1/4)^2 - 4 = 1/4 + 1/16 - 4 = -59/16 < 0 \quad \text{(factible)}$$

Geométricamente (ver Figura 4.18), en el punto $A(-1/2, 1/4)$ el gradiente de la función objetivo $\nabla f(A) = (1, 1)^T$ apunta en la misma dirección que la normal de la restricción activa $\nabla g_2(A) = (1, 1)^T$. Al apuntar en el mismo sentido, se cumple la condición necesaria de primer orden de KKT para máximo. Sin embargo, dado que la frontera de la restricción es convexa (la parábola se curva "alejándose" de las curvas de nivel superiores), al movernos a lo largo de ella la función f comienza a crecer, impidiendo que A sea un máximo local. El gráfico de detalle con las curvas de nivel en gradiente ilustra esta tangencia crítica (ver Figura 4.18a y Figura 4.18b).

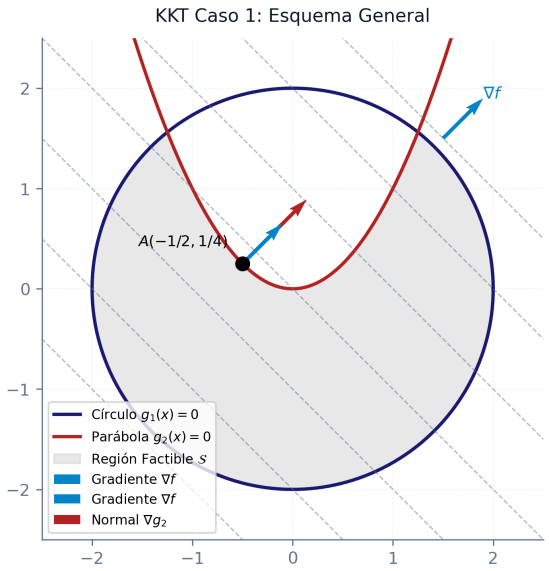

(a) Esquema general

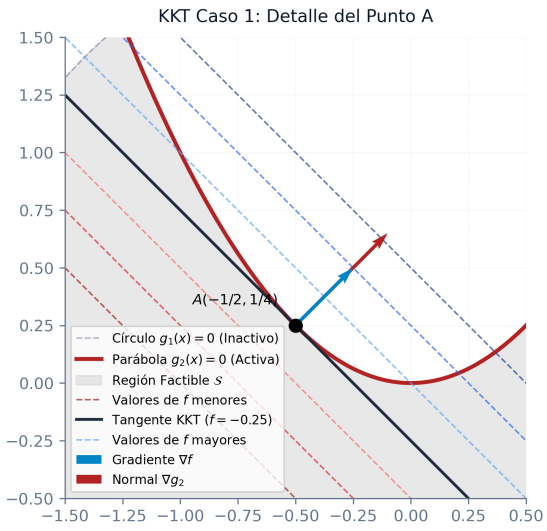

(b) Detalle del punto A con gradiente de nivel

Figura 4.18: Caso 1: Alineación de gradientes con círculo inactivo y parábola activa

---

Caso 2: Parábola inactiva ($u_2 = 0 \implies u_1 \neq 0$) El sistema se simplifica a:

$$1 + 2u_1x_1 = 0 \quad \text{y} \quad 1 + 2u_1x_2 = 0 \implies x_1 = x_2 = -\frac{1}{2u_1}$$

Como $u_1 \neq 0$, la holgura complementaria exige que la restricción g_1 sea activa ($g_1(x) = 0$):

$$x_1^2 + x_2^2 = 4 \implies 2x_1^2 = 4 \implies x_1^2 = 2 \implies x_1 = \pm\sqrt{2}$$

Esto nos proporciona dos puntos de estudio:

1. **Punto** $B(-\sqrt{2}, -\sqrt{2})$: Sustituyendo $x_1 = -\sqrt{2}$ obtenemos $u_1 = \frac{1}{2\sqrt{2}} > 0$.
   - Dado que $u_1 > 0$, es un **candidato a mínimo**.
   - Comprobamos factibilidad primal en g_2:

     $$g_2(-\sqrt{2}, -\sqrt{2}) = -(-\sqrt{2})^2 - \sqrt{2} = -2 - \sqrt{2} < 0$$

     (factible).
   - Por tanto, el punto $B(-\sqrt{2}, -\sqrt{2})$ es un **candidato KKT a mínimo global**.
2. **Punto** $C(\sqrt{2}, \sqrt{2})$: Sustituyendo $x_1 = \sqrt{2}$ obtenemos $u_1 = -\frac{1}{2\sqrt{2}} < 0$.

- Dado que $u_1 < 0$, es un **candidato a máximo**.
- Comprobamos factibilidad primal en g_2:

$$g_2(sqrt2, sqrt2) = -(sqrt2)^2 + sqrt2 = -2 + sqrt2approx - 0.59 < 0$$

  (factible).
- Por tanto, el punto $C(\sqrt{2}, \sqrt{2})$ es un **candidato KKT a máximo global**.

Geométricamente (ver Figura 4.19), en $B(-\sqrt{2}, -\sqrt{2})$ el gradiente del objetivo $\nabla f(B) = (1,1)^T$ apunta en dirección opuesta al vector normal exterior del círculo $\nabla g_1(B) = (-2\sqrt{2}, -2\sqrt{2})^T$, por lo que se compensan con un multiplicador positivo $u_1 > 0$, lo que caracteriza a B como un mínimo (ver Figura 4.19b). En cambio, en $C(\sqrt{2}, \sqrt{2})$ el gradiente del objetivo $\nabla f(C)$ apunta en el mismo sentido que la normal del círculo $\nabla g_1(C) = (2\sqrt{2}, 2\sqrt{2})^T$, cancelándose con un multiplicador negativo $u_1 < 0$, lo que caracteriza a C como un máximo (ver Figura 4.19c).

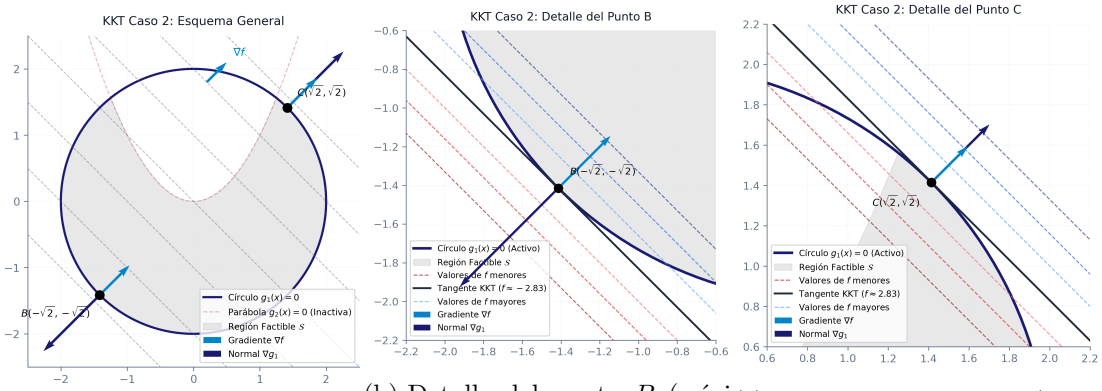

(a) Esquema general

(b) Detalle del punto B (mínimo)

(c) Detalle del punto C (máximo)

Figura 4.19: Caso 2: Alineación de gradientes con parábola inactiva y círculo activo

---

Caso 3: Ambas restricciones activas ($u_1 \neq 0, u_2 \neq 0$) Dado que $u_1 \neq 0$ y $u_2 \neq 0$, la holgura complementaria exige que ambas restricciones sean activas ($g_1(x) = 0$ y $g_2(x) = 0$). Por lo tanto, los puntos candidatos se encuentran en la intersección de ambas curvas, es decir, resolviendo $x_2 = x_1^2$ en la circunferencia:

$$x_1^2 + (x_1^2)^2 = 4 \implies x_1^4 + x_1^2 - 4 = 0 \implies x_1^2 = \frac{-1 + \sqrt{17}}{2} \approx 1.56 \implies x_1 \approx \pm 1.25$$

El valor de la coordenada x_2 en las intersecciones es $x_2 = x_1^2 \approx 1.56$. Los puntos de intersección son $E(1.25, 1.56)$ y $D(-1.25, 1.56)$.

Planteamos el sistema de estacionariedad para resolver u_1 y u_2:

$$1 + 2u_1x_1 - 2u_2x_1 = 0 \implies 2x_1(u_1 - u_2) = -1$$

$$1 + 2u_1x_2 + u_2 = 0$$

- Para $E(1.25, 1.56)$:

  $$2.5(u_1 - u_2) = -1 \implies u_1 - u_2 = -0.4 \implies u_2 = u_1 + 0.4$$

  Sustituyendo en la segunda ecuación:

  $$1 + 2(1.56)u_1 + (u_1 + 0.4) = 0 \implies 4.12u_1 + 1.4 = 0 \implies u_1 \approx -0.34 < 0$$

  $$u_2 = -0.34 + 0.4 = 0.06 > 0$$

  Al tener multiplicadores con signos opuestos ($u_1 < 0, u_2 > 0$), el punto E no cumple las condiciones necesarias para ser ni mínimo (requiere $u_i \geq 0$) ni máximo (requiere $u_i \leq 0$).
- Para $D(-1.25, 1.56)$:

  $$-2.5(u_1 - u_2) = -1 \implies u_1 - u_2 = 0.4 \implies u_2 = u_1 - 0.4$$

  Sustituyendo en la segunda ecuación:

  $$1 + 3.12u_1 + u_1 - 0.4 = 0 \implies 4.12u_1 + 0.6 = 0 \implies u_1 \approx -0.15 < 0$$

  $$u_2 = -0.15 - 0.4 = -0.55 < 0$$

  Dado que $u_1, u_2 < 0$, el punto $D(-1.25, 1.56)$ es un **candidato a máximo local**. No obstante, al evaluar el valor de la función objetivo:

  $$f(D) \approx -1.25 + 1.56 = 0.31$$

  mientras que en el candidato a máximo global C tenemos $f(C) = 2\sqrt{2} \approx 2.83$, y en el máximo local A tenemos $f(A) = -0.5 + 0.25 = -0.25$.

Geométricamente (ver Figura 4.20), en la intersección $E(1.25, 1.56)$ los vectores normales ∇g_1 (azul oscuro) y ∇g_2 (rojo brick) apuntan en direcciones que impiden que se contrarreste el gradiente de la función objetivo ∇f con multiplicadores del mismo signo, resultando en un multiplicador del círculo negativo y uno de la parábola positivo (ver Figura 4.20b). En cambio, en la intersección $D(-1.25, 1.56)$ sí se logra un balance con ambos multiplicadores negativos ($u_1, u_2 < 0$), lo que consolida a D como un candidato a máximo local (ver Figura 4.20c).

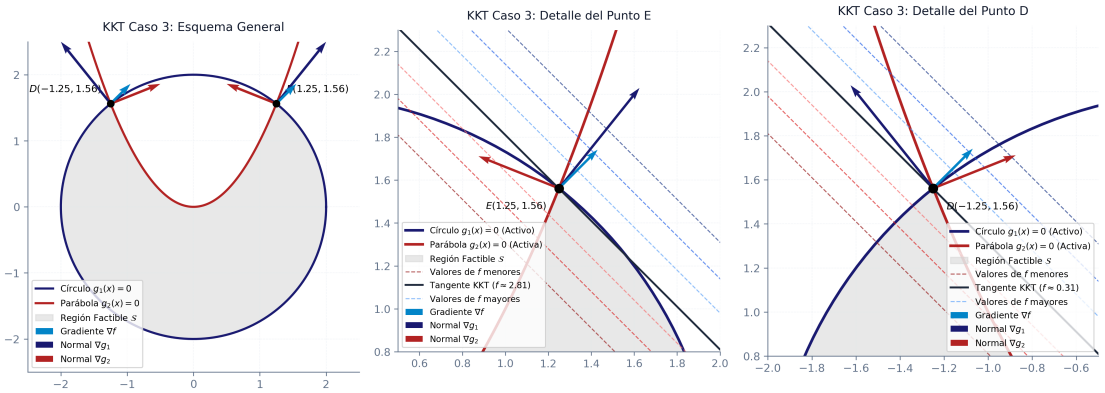

(a) Esquema general

(b) Detalle del punto E (no candidato)

(c) Detalle del punto D (máximo local)

Figura 4.20: Caso 3: Ambas restricciones activas (intersección)

Conclusión del análisis

Al comparar los valores de la función objetivo en los candidatos obtenidos:

- **Mínimos**: El único candidato KKT es $B(-\sqrt{2}, -\sqrt{2})$ con $f(B) = -2\sqrt{2} \approx -2.83$. Dado que la región factible es cerrada y acotada (compacta) y las funciones son continuas, el teorema de Weierstrass garantiza la existencia de extremos globales. Por tanto, B **es el mínimo global**.
- **Máximos**: Evaluamos los candidatos a máximo ($u_i \leq 0$):
  - $C(\sqrt{2}, \sqrt{2}) \implies f(C) = 2\sqrt{2} \approx 2.83$ (Frontera circular).
  - $D(-1.25, 1.56) \implies f(D) \approx 0.31$ (Esquina de intersección).
  - $A(-1/2, 1/4) \implies f(A) = -0.25$ (Descartado por análisis de segundo orden).

  Por lo tanto, $C(\sqrt{2}, \sqrt{2})$ **es el máximo global** y D **es el único máximo local** (el punto A es un punto que no es ni máximo ni mínimo).

Aplicación de las condiciones suficientes de KKT

Para corroborar analíticamente la naturaleza de estos candidatos utilizando el teorema de suficiencia, estudiamos la curvatura de la función objetivo y de las restricciones activas en cada caso:

- La función objetivo $f(x_1, x_2) = x_1 + x_2$ es lineal y, por tanto, es cóncava y convexa simultáneamente en todo $\mathbb{R}^2$.
- Las matrices Hessiana de las restricciones son:

$$H_1 = \nabla^2 g_1(x) = \begin{pmatrix} 2 & 0 \\ 0 & 2 \end{pmatrix} \qquad \text{y} \qquad H_2 = \nabla^2 g_2(x) = \begin{pmatrix} -2 & 0 \\ 0 & 0 \end{pmatrix}$$

  - H_1 es definida positiva, por lo que la restricción g_1 es **estrictamente convexa**.

- H_2 es semidefinida negativa, por lo que la restricción g_2 es **cóncava**.

Aplicando este análisis a cada uno de los candidatos:

- **Punto** $A(-1/2, 1/4)$:
  - Multiplicadores: $u_1 = 0$ y $u_2 = -1 < 0$ (candidato a máximo).
  - Análisis: La restricción g_2 es activa y cóncava.
  - Conclusión: **No verifica las condiciones suficientes** de KKT para máximo (requeriría que g_2 fuera convexa). Como vimos en el análisis de segundo orden, no es un extremo local.
- **Punto** $B(-\sqrt{2}, -\sqrt{2})$:
  - Multiplicadores: $u_1 = \frac{\sqrt{2}}{4} > 0$ y $u_2 = 0$ (candidato a mínimo).
  - Análisis: La restricción g_1 es activa y estrictamente convexa.
  - Conclusión: Al ser f convexa y la restricción activa g_1 convexa con multiplicador positivo, se satisfacen las condiciones suficientes, garantizando que B **es el mínimo global**.
- **Punto** $C(\sqrt{2}, \sqrt{2})$:
  - Multiplicadores: $u_1 = -\frac{\sqrt{2}}{4} < 0$ y $u_2 = 0$ (candidato a máximo).
  - Análisis: La restricción g_1 es activa y estrictamente convexa.
  - Conclusión: Al ser f cóncava y la restricción activa g_1 convexa con multiplicador negativo (equivalente a minimizar $-f$ con restricción convexa), se satisfacen las condiciones suficientes, garantizando que C **es el máximo global**.
- **Punto** $D\left(-\sqrt{\frac{-1+\sqrt{17}}{2}}, \frac{-1+\sqrt{17}}{2}\right)$ (es decir, $D(-1.25, 1.56)$):
  - Multiplicadores: $u_1 \approx -0.15 < 0$ y $u_2 \approx -0.55 < 0$ (candidato a máximo).
  - Análisis: La restricción g_1 es activa y convexa, pero la restricción g_2 es activa y cóncava.
  - Conclusión: **No verifica las condiciones suficientes** de KKT porque la restricción activa g_2 es cóncava. No obstante, gráficamente se comprueba que el punto D es un **máximo local**.

En la Figura 4.21 se resume gráficamente el resultado de la caracterización y la condición de cada uno de los cinco candidatos estudiados.

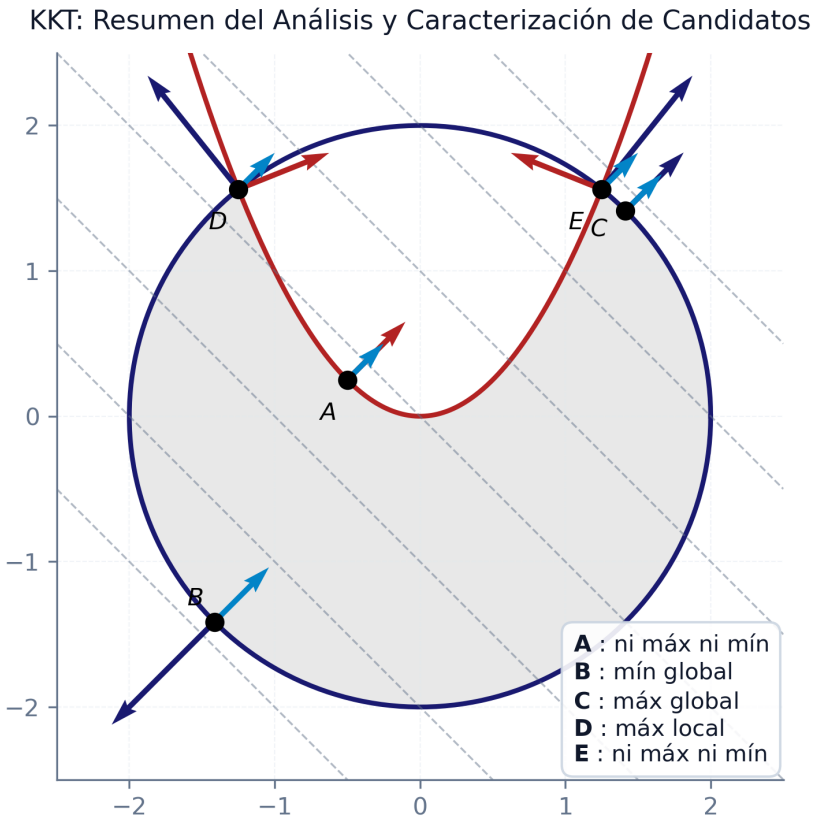

Figura 4.21: KKT: Caracterización Final de Candidatos

Con el propósito de estructurar y sistematizar la búsqueda práctica de óptimos analíticos aplicando estas condiciones matemáticas, resulta útil resumir todo el proceso combinatorio y de comprobación en un algoritmo ordenado. El siguiente esquema destacado recoge las fases fundamentales de esta estrategia:

Esquema general de resolución KKT

El procedimiento analítico para resolver problemas de optimización con restricciones de desigualdad mediante las condiciones KKT se fundamenta en los siguientes pasos:

1. **Construir la función Lagrangiana**:

$$L(x, u) = f(x) + \sum_{i=1}^{m} u_i g_i(x)$$

2. **Hallar los puntos KKT**, resolviendo el sistema dual-primal integrado por las siguientes condiciones:

- **Condición de gradiente (Estacionariedad / Factibilidad dual)**: $\nabla_x L(x,u) = 0$ (es decir, $\frac{\partial L}{\partial x_j} = 0$, $\forall j = 1, \dots, n$).
- **Condición de factibilidad (Primal)**: $g_i(x) \leq 0$, $\forall i = 1, \dots, m$.
- **Condición de ortogonalidad (Holgura complementaria)**: $u_i g_i(x) = 0$, $\forall i = 1, \dots, m$.
- **Condición de no negatividad (Factibilidad dual de multiplicadores)**: $u_i \geq 0$, $\forall i = 1, \dots, m$.

3. **Análisis por casos combinatorios**: Para resolver el sistema, para cada restricción i se evalúan las dos ramas posibles de la holgura complementaria:
   - *Caso A (Restricción inactiva)*: $g_i(x) < 0 \implies u_i = 0$.
   - *Caso B (Restricción activa)*: $g_i(x) = 0 \implies u_i \geq 0$.
4. **Descartar candidatos** que violen la factibilidad primal o que resulten en multiplicadores con signo incorrecto.
5. **Comprobar la cualificación de restricciones (LICQ)** en los candidatos y aplicar las **condiciones suficientes por convexidad** (si las restricciones activas g_i son cuasi-convexas diferenciables y la función objetivo f es pseudo-convexa en el candidato, este es un mínimo global; en caso contrario, se debe realizar un análisis individual de los puntos, incluyendo los puntos singulares excluidos donde LICQ falla).

Observaciones adicionales:

- **Problemas de Maximización**: El único cambio en este procedimiento consiste en exigir que los multiplicadores de Lagrange sean no positivos ($u_i \leq 0$, $\forall i = 1, \dots, m$).
- **Identificación de puntos Fritz-John**: Los puntos de Fritz-John corresponden a la generalización dual. Para identificarlos todos, se deben distinguir los casos en los que $u_0 > 0$ (que equivalen a los puntos KKT hallados) y aquellos en los que $u_0 = 0$ (puntos Fritz-John estrictos/singulares donde falla la cualificación de restricciones y la función objetivo no interviene).

Ejemplo: Optimización con múltiples restricciones de desigualdad

Consideremos el problema de encontrar los mínimos y máximos locales y globales de:

$$\begin{aligned} \text{mín} \,/\, \text{máx} \quad & f(x,y) = \left(x - \frac{9}{4}\right)^2 + (y-2)^2 \\ \text{s.a.} \quad & g_1(x,y) = -x + y^2 \leq 0 \\ & g_2(x,y) = x + y - 6 \leq 0 \\ & g_3(x,y) = -x \leq 0 \\ & g_4(x,y) = -y \leq 0 \end{aligned}$$

El gradiente de la función objetivo y de las restricciones son:

$$\nabla f = \begin{pmatrix} 2\left(x - \frac{9}{4}\right) \\ 2(y-2) \end{pmatrix}, \quad \nabla g_1 = \begin{pmatrix} -1 \\ 2y \end{pmatrix}, \quad \nabla g_2 = \begin{pmatrix} 1 \\ 1 \end{pmatrix}, \quad \nabla g_3 = \begin{pmatrix} -1 \\ 0 \end{pmatrix}, \quad \nabla g_4 = \begin{pmatrix} 0 \\ -1 \end{pmatrix}$$

La función Lagrangiana es:

$$L(x,y,u) = \left(x - \frac{9}{4}\right)^2 + (y-2)^2 + u_1(-x + y^2) + u_2(x + y - 6) - u_3 x - u_4 y$$

El sistema de condiciones KKT se plantea como:

1. **Estacionariedad (Factibilidad dual)**:

$$\frac{\partial L}{\partial x} = 2\left(x - \frac{9}{4}\right) - u_1 + u_2 - u_3 = 0$$

$$\frac{\partial L}{\partial y} = 2(y-2) + 2yu_1 + u_2 - u_4 = 0$$

2. **Factibilidad primal**:

$$-x + y^2 \leq 0, \quad x + y - 6 \leq 0, \quad -x \leq 0, \quad -y \leq 0$$

3. **Ortogonalidad (Holgura complementaria)**:

$$u_1(-x + y^2) = 0, \quad u_2(x + y - 6) = 0, \quad u_3 x = 0, \quad u_4 y = 0$$

4. **Signo de los multiplicadores**:

   - Para **mínimos**: $u_i \geq 0, \ \forall i = 1, \ldots, m.$
   - Para **máximos**: $u_i \leq 0, \ \forall i = 1, \ldots, m.$

Geométricamente, el problema representa la minimización o maximización de la distancia al punto $(2.25, 2)^T$ sobre la región factible delimitada por una parábola, una recta y los ejes de coordenadas (ver Figura 4.22).

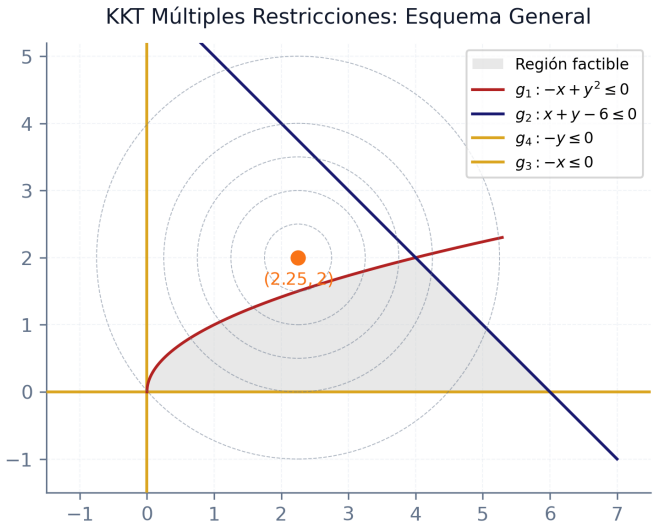

Figura 4.22: KKT Múltiples Restricciones: Esquema General

Resolución combinatoria por casos
Analizamos las combinaciones de restricciones activas e inactivas mediante la holgura complementaria:

- **Caso 1: Todas las restricciones inactivas** ($u_1 = u_2 = u_3 = u_4 = 0$): De las ecuaciones de estacionariedad obtenemos de forma inmediata $x = 9/4 = 2.25$ e $y = 2$. Verificamos la factibilidad primal en la primera restricción:

$$g_1(2.25, 2) = -2.25 + 4 = 1.75 > 0 \quad \text{(no factible)}$$

  Por lo tanto, el punto $(2.25, 2)^T$ se descarta.

- **Caso 2: Una única restricción activa**:
  - *Subcaso g_1 activa ($u_1 \neq 0, u_2 = u_3 = u_4 = 0$)*: El sistema de estacionariedad es:

$$2(x - 2.25) - u_1 = 0 \implies u_1 = 2x - 4.5$$

$$2(y - 2) + 2yu_1 = 0 \implies 2y - 4 + 2y(2x - 4.5) = 0 \implies 4xy - 7y - 4 = 0$$

    Como g_1 es activa, se cumple $x = y^2$. Sustituyendo en la ecuación:

$$4y^3 - 7y - 4 = 0$$

La única raíz real de esta ecuación cúbica es $y \approx 1.55$, lo que nos da $x = y^2 \approx 2.40$. Calculamos el multiplicador: $u_1 = 2(2.40) - 4.5 = 0.30 > 0$. Comprobamos la factibilidad primal en el resto de restricciones:

$$g_2(2.40, 1.55) = 2.40 + 1.55 - 6 = -2.05 \leq 0 \quad \text{(factible)}$$

Dado que $u_1 = 0.30 \geq 0$, el punto $(2.40, 1.55)$ es un candidato a mínimo local (ver detalle en Figura 4.23).

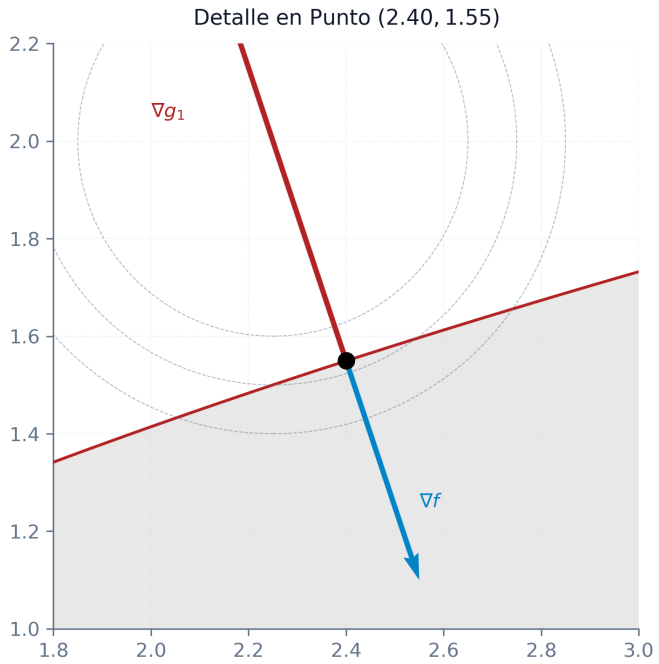

Figura 4.23: KKT Múltiples Restricciones: Detalle en $(2.40, 1.55)$

- *Subcaso g_2 activa ($u_2 \neq 0, u_1 = u_3 = u_4 = 0$)*: El sistema es:

$$2(x - 2.25) + u_2 = 0 \qquad \text{y} \qquad 2(y - 2) + u_2 = 0 \implies x - 2.25 = y - 2$$

$$\implies x = y + 0.25$$

Como g_2 es activa, $x + y = 6 \implies y + 0.25 + y = 6 \implies 2y = 5.75 \implies y = 2.875$, lo que da $x = 3.125$. Calculamos el multiplicador: $u_2 = -2(3.125 - 2.25) = -1.75 < 0$. Al ser negativo, es candidato a máximo, pero debemos comprobar la factibilidad primal:

$$g_1(3.125, 2.875) = -3.125 + (2.875)^2 \approx -3.125 + 8.27 = 5.14 > 0 \quad \text{(no factible)}$$

Por lo tanto, se descarta.

- *Subcaso g_3 activa ($u_3 \neq 0, u_1 = u_2 = u_4 = 0$)*: Gives $x = 0$ y $2(y-2) = 0 \implies y = 2$. El multiplicador es $u_3 = 2(0 - 2.25) = -4.5 < 0$. Verificamos factibilidad en g_1:

$$g_1(0, 2) = 0 + 4 = 4 > 0 \quad \text{(no factible)}$$

  Por lo tanto, se descarta.

- *Subcaso g_4 activa ($u_4 \neq 0, u_1 = u_2 = u_3 = 0$)*: Gives $y = 0$ y $2(x - 2.25) = 0 \implies x = 2.25$. El multiplicador es $u_4 = 2(0-2)+u_2 = 2(0-2)+0 = -4 < 0$ (candidato a máximo). Comprobamos la factibilidad primal:

$$g_1(2.25, 0) = -2.25 + 0 = -2.25 \leq 0 \quad \text{(factible)}$$

$$g_2(2.25, 0) = 2.25 + 0 - 6 = -3.75 \leq 0 \quad \text{(factible)}$$

  Por lo tanto, el punto $(2.25, 0)$ es un candidato a máximo local (ver detalle en Figura 4.24).

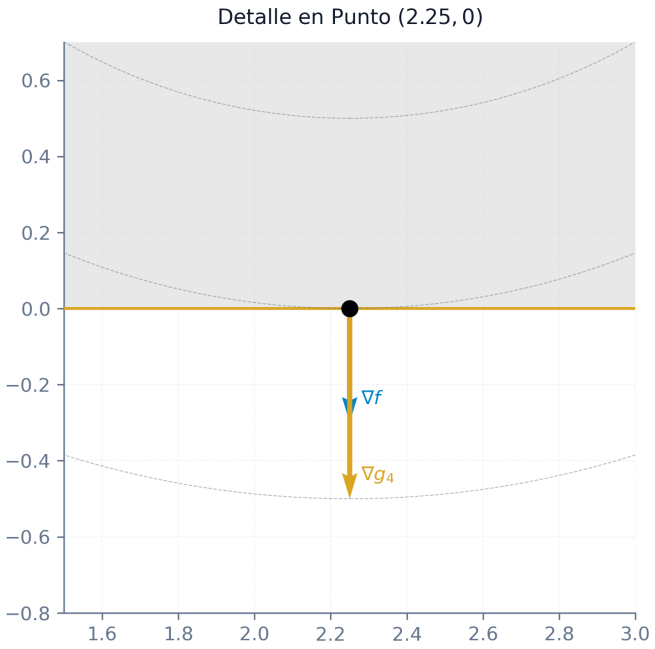

Figura 4.24: KKT Múltiples Restricciones: Detalle en $(2.25, 0)$

- **Caso 3: Dos restricciones activas**:

  - *Subcaso g_1, g_2 activas ($u_1 \neq 0, u_2 \neq 0, u_3 = u_4 = 0$)*: Intersección de la parábola y la recta: $x = y^2$ y $x + y = 6 \implies y^2 + y - 6 = 0 \implies y = 2$ (puesto que

$y \geq 0$), lo que da $x = 4$. El sistema de estacionariedad queda:

$$2(4 - 2.25) - u_1 + u_2 = 0 \implies 3.5 - u_1 + u_2 = 0$$

$$2(2 - 2) + 4u_1 + u_2 = 0 \implies 4u_1 + u_2 = 0 \implies u_2 = -4u_1$$

Sustituyendo: $3.5 - 5u_1 = 0 \implies u_1 = 0.70 > 0$ y $u_2 = -2.80 < 0$. Al tener signos opuestos, el punto $(4, 2)$ no es candidato a mínimo ni a máximo (ver detalle en Figura 4.25).

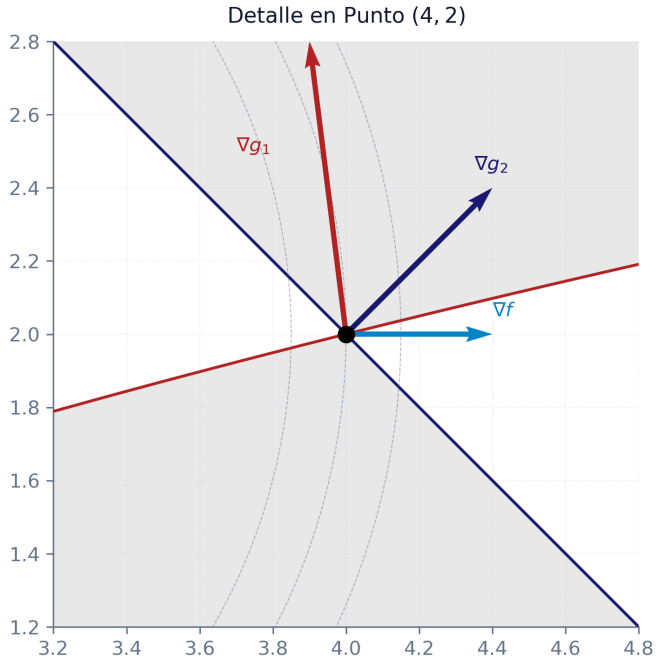

Figura 4.25: KKT Múltiples Restricciones: Detalle en $(4, 2)$

- *Subcaso g_2, g_4 activas ($u_2 \neq 0, u_4 \neq 0, u_1 = u_3 = 0$)*: Gives $y = 0$ y $x + y = 6 \implies x = 6$. Estacionariedad:

$$u_2 = -2(6 - 2.25) = -7.50 < 0$$

$$u_4 = 2(0 - 2) + u_2 = -4 - 7.50 = -11.50 < 0$$

Ambos multiplicadores son negativos, por lo que el punto $(6, 0)$ es un candidato a máximo local (ver detalle en Figura 4.26). Comprobamos factibilidad en g_1:

$$g_1(6, 0) = -6 + 0 = -6 \leq 0 \quad \text{(factible)}$$

Por tanto, el candidato es válido.

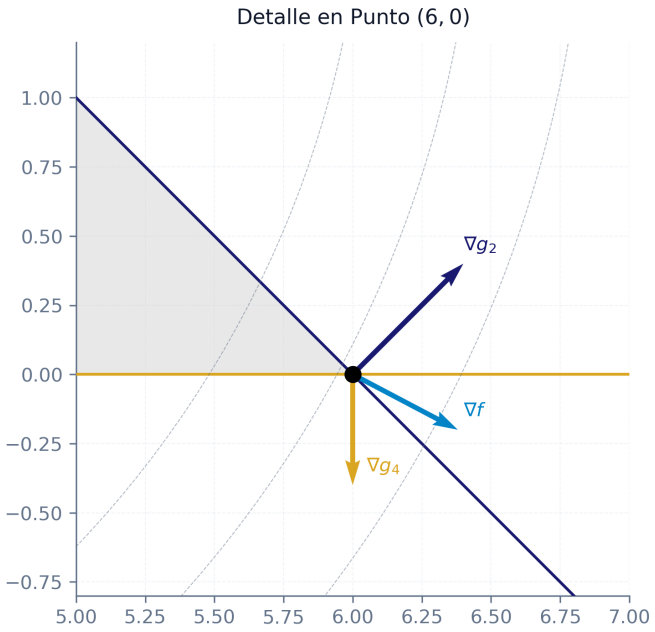

Figura 4.26: KKT Múltiples Restricciones: Detalle en $(6, 0)$

- *Subcaso g_3, g_4 activas ($u_3 \neq 0, u_4 \neq 0, u_1 = u_2 = 0$)*: Gives $x = 0, y = 0$. Estacionariedad:

$$u_3 = 2(0 - 2.25) = -4.50 < 0$$

$$u_4 = 2(0 - 2) = -4.00 < 0$$

Ambos multiplicadores son negativos, por lo que el punto $(0, 0)$ es candidato a máximo (ver detalle en Figura 4.27). Sin embargo, en $(0, 0)$ la restricción $g_1(0, 0) = 0$ también es activa, lo que significa que hay tres restricciones activas y los gradientes correspondientes son linealmente dependientes (fallo de LICQ). No es un punto KKT regular, pero es un punto Fritz-John con $u_0 = 0$ (candidato a máximo).

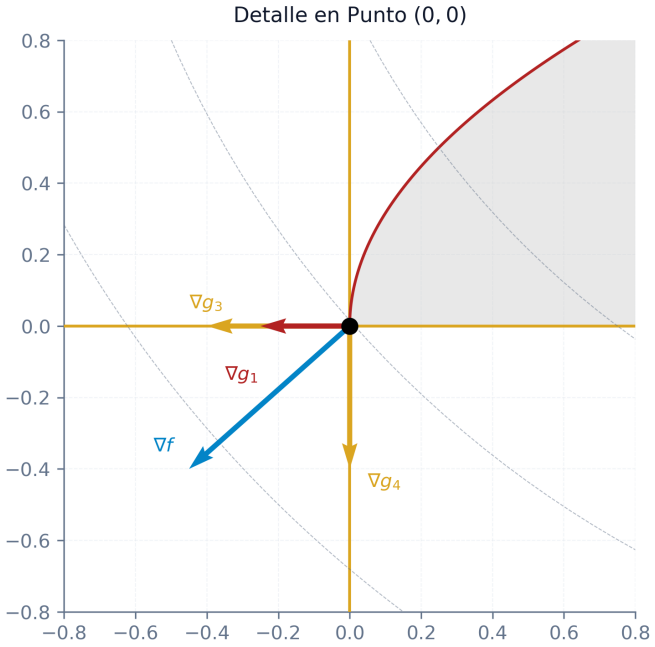

Figura 4.27: KKT Múltiples Restricciones: Detalle en $(0, 0)$

Conclusión y Caracterización de Candidatos
Al evaluar las condiciones suficientes y comparar los valores de la función objetivo:

- **Mínimos**: El único candidato KKT es $(2.40, 1.55)$ con $f(2.40, 1.55) \approx 0.22$.
  - La función objetivo f es cuadrática estrictamente convexa.
  - La restricción activa $g_1(x, y) = -x + y^2$ es convexa en todo su dominio (su Hessiana $H_1 = \begin{pmatrix} 0 & 0 \\ 0 & 2 \end{pmatrix} \succeq 0$ es semidefinida positiva).
  - Al ser f convexa y la restricción activa convexa con multiplicador positivo, se satisfacen las condiciones suficientes, confirmando que $(2.40, 1.55)$ **es el mínimo global**.
- **Máximos**: Evaluamos los candidatos a máximo ($u_i \leq 0$):
  - $(6, 0) \implies f(6, 0) = 18.06$ (Máximo global).
  - $(0, 0) \implies f(0, 0) \approx 9.06$ (Máximo local, verificado como punto singular).
  - $(2.25, 0) \implies f(2.25, 0) = 4.00$ (No verifica las condiciones suficientes).

En la Figura 4.28 se resume gráficamente el resultado de la caracterización y la condición de cada uno de los cinco candidatos estudiados.

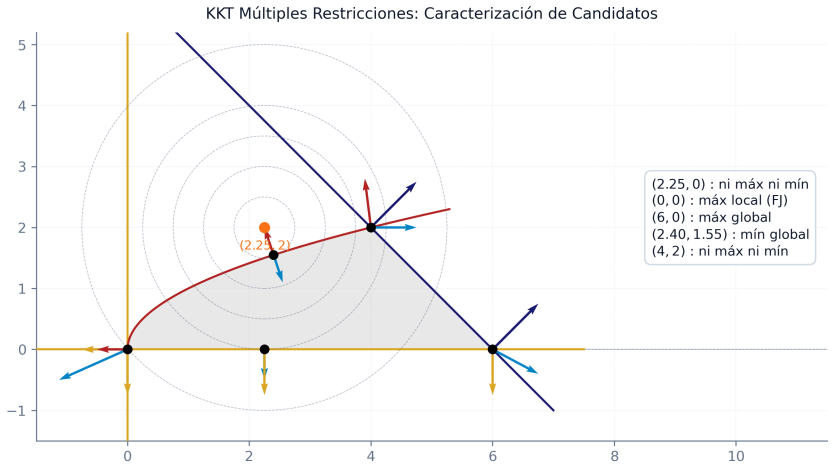

Figura 4.28: KKT Múltiples Restricciones: Caracterización de Candidatos

Ejemplo: Optimización con restricción circular y lineal

Consideremos el problema de encontrar los mínimos y máximos locales y globales de:

$$\begin{aligned} \text{mín} \,/\, \text{máx} \quad & f(x,y) = 3x - y \\ \text{s.a.} \quad & g_1(x,y) = x^2 + y^2 - 1 \leq 0 \\ & g_2(x,y) = -4x - y + 1 \leq 0 \end{aligned}$$

El gradiente de la función objetivo y de las restricciones son:

$$\nabla f = \begin{pmatrix} 3 \\ -1 \end{pmatrix}, \quad \nabla g_1 = \begin{pmatrix} 2x \\ 2y \end{pmatrix}, \quad \nabla g_2 = \begin{pmatrix} -4 \\ -1 \end{pmatrix}$$

La función Lagrangiana es:

$$L(x,y,u) = 3x - y + u_1(x^2 + y^2 - 1) + u_2(-4x - y + 1)$$

El sistema de condiciones KKT se plantea como:

1. **Estacionariedad (Factibilidad dual)**:

$$\frac{\partial L}{\partial x} = 3 + 2xu_1 - 4u_2 = 0$$

$$\frac{\partial L}{\partial y} = -1 + 2yu_1 - u_2 = 0$$

2. **Factibilidad primal**:

$$x^2 + y^2 - 1 \leq 0, \quad -4x - y + 1 \leq 0$$

3. **Ortogonalidad (Holgura complementaria)**:

$$u_1(x^2 + y^2 - 1) = 0, \quad u_2(-4x - y + 1) = 0$$

4. **Signo de los multiplicadores**:
   - Para **mínimos**: $u_i \geq 0, \ \forall i = 1, 2.$
   - Para **máximos**: $u_i \leq 0, \ \forall i = 1, 2.$

Geométricamente, el problema representa la minimización o maximización de la función lineal $3x - y$ sobre una región factible $\mathcal{S}$ acotada por la circunferencia unitaria y la recta $4x + y \geq 1$ (ver Figura 4.29).

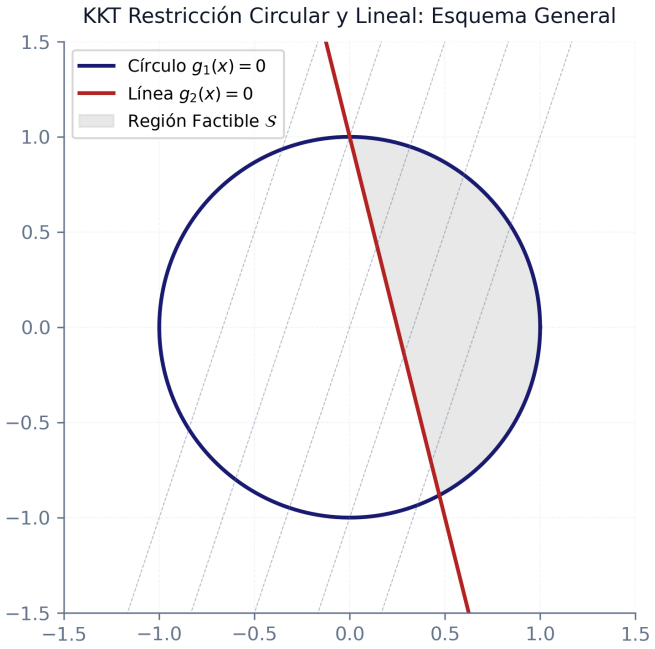

Figura 4.29: KKT Restricción Circular y Lineal: Esquema General

Resolución combinatoria por casos
Analizamos las combinaciones de restricciones activas e inactivas mediante la holgura complementaria:

- **Caso 1: Ambas restricciones inactivas** ($u_1 = 0, u_2 = 0$): De las ecuaciones de estacionariedad obtenemos:

$$3 = 0 \qquad \text{y} \qquad -1 = 0$$

  lo cual representa una contradicción inmediata. Por lo tanto, no existen puntos estacionarios en el interior de la región factible.

- **Caso 2: Una única restricción activa**:
  - *Subcaso g_1 activa ($u_1 \neq 0, u_2 = 0$)*: El sistema de estacionariedad se reduce a:

$$3 + 2xu_1 = 0 \implies x = -\frac{3}{2u_1}$$

$$-1 + 2yu_1 = 0 \implies y = \frac{1}{2u_1}$$

Como g_1 es activa, se cumple $x^2 + y^2 = 1$. Sustituyendo las expresiones en la ecuación de la circunferencia:

$$\left(-\frac{3}{2u_1}\right)^2 + \left(\frac{1}{2u_1}\right)^2 = 1 \implies \frac{9}{4u_1^2} + \frac{1}{4u_1^2} = 1 \implies \frac{10}{4u_1^2} = 1 \implies u_1^2 = \frac{10}{4}$$

$$\implies u_1 = \pm\frac{\sqrt{10}}{2}$$

Analizamos las dos posibles soluciones para u_1:

1. **Si $u_1 = \frac{\sqrt{10}}{2} \approx 1.58 > 0$ (candidato a mínimo)**: Obtenemos las coordenadas del punto:

$$x = -\frac{3}{\sqrt{10}} \approx -0.95, \qquad y = \frac{1}{\sqrt{10}} \approx 0.32$$

Comprobamos la factibilidad primal en la restricción inactiva g_2:

$$g_2(-0.95, 0.32) = -4(-0.95) - 0.32 + 1$$

$$= 3.8 - 0.32 + 1 = 4.48 > 0 \quad \text{(no factible)}$$

Al violar la restricción lineal, este punto se descarta (ver detalle en Figura 4.30).

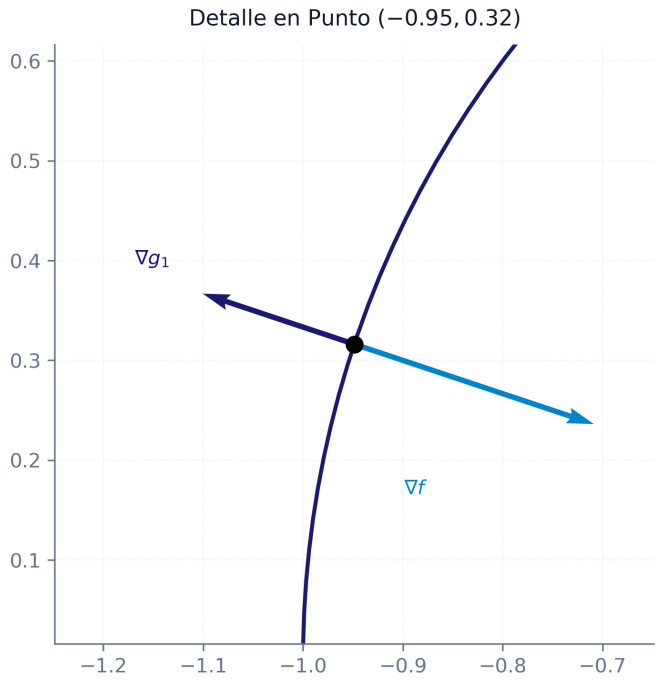

Figura 4.30: KKT Restricción Circular y Lineal: Detalle en $(-0.95, 0.32)$

2. **Si** $u_1 = -\frac{\sqrt{10}}{2} \approx -1.58 < 0$ **(candidato a máximo)**: Obtenemos las coordenadas del punto:

$$x = \frac{3}{\sqrt{10}} \approx 0.95, \qquad y = -\frac{1}{\sqrt{10}} \approx -0.32$$

Comprobamos la factibilidad primal en la restricción inactiva g_2:

$$g_2(0.95, -0.32) = -4(0.95) - (-0.32) + 1 =$$

$$-3.8 + 0.32 + 1 = -2.48 \leq 0 \quad \text{(factible)}$$

Como es factible y $u_1 < 0$ (con $u_2 = 0$), el punto $\left(\frac{3}{\sqrt{10}}, -\frac{1}{\sqrt{10}}\right)$ es un candidato válido a máximo local (ver detalle en Figura 4.31).

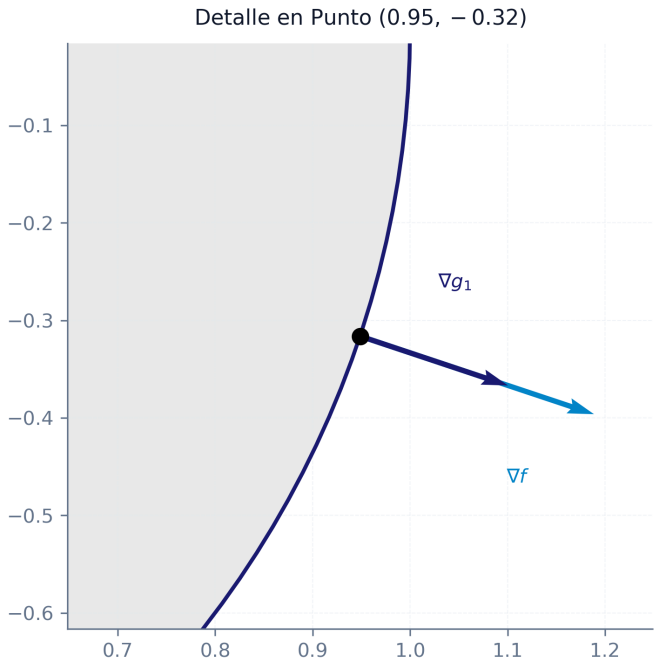

Figura 4.31: KKT Restricción Circular y Lineal: Detalle en $(0.95, -0.32)$

- *Subcaso g_2 activa ($u_2 \neq 0, u_1 = 0$)*: El sistema de estacionariedad se reduce a:

$$3 - 4u_2 = 0 \implies u_2 = \frac{3}{4} = 0.75$$

$$-1 - u_2 = 0 \implies u_2 = -1$$

  Lo cual es una contradicción ($0.75 \neq -1$). Por lo tanto, no existen candidatos con únicamente la restricción lineal activa.

- **Caso 3: Ambas restricciones activas ($u_1 \neq 0, u_2 \neq 0$)**: Los puntos de intersección de la circunferencia y la recta satisfacen $x^2+y^2 = 1$ y $-4x-y+1 = 0 \implies y = 1-4x$. Sustituyendo y en la circunferencia:

$$x^2 + (1 - 4x)^2 = 1 \implies x^2 + 1 - 8x + 16x^2 = 1 \implies 17x^2 - 8x = 0$$

  Esto nos da las soluciones:

  1. $x = 0 \implies y = 1$.
  2. $x = 8/17 \approx 0.47 \implies y = -15/17 \approx -0.88$.

  Evaluamos los multiplicadores para cada uno de estos dos puntos de intersección:

- *Punto* $(0, 1)$: Sustituyendo en el sistema de estacionariedad:

$$3 + 2(0)u_1 - 4u_2 = 0 \implies 3 - 4u_2 = 0 \implies u_2 = \frac{3}{4} \geq 0$$

$$-1 + 2(1)u_1 - u_2 = 0 \implies 2u_1 = 1 + u_2 = 1 + \frac{3}{4} = \frac{7}{4} \implies u_1 = \frac{7}{8} \geq 0$$

Como ambos multiplicadores son no negativos ($u_1 = 7/8 \geq 0,\ u_2 = 3/4 \geq 0$), el punto $(0, 1)$ es un candidato a mínimo local (ver detalle en Figura 4.32).

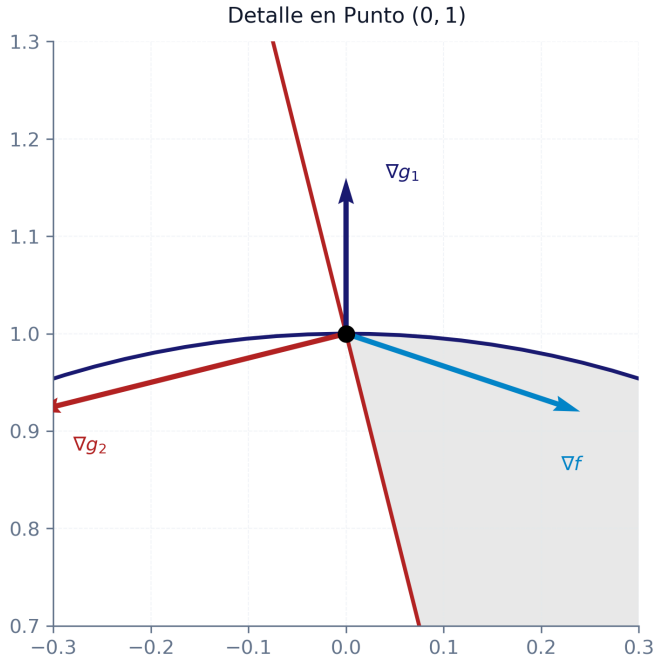

Figura 4.32: KKT Restricción Circular y Lineal: Detalle en $(0, 1)$

- *Punto* $(8/17, -15/17)$: Sustituyendo en el sistema de estacionariedad:

$$3 + \frac{16}{17}u_1 - 4u_2 = 0$$

$$-1 - \frac{30}{17}u_1 - u_2 = 0 \implies u_2 = -1 - \frac{30}{17}u_1$$

Sustituyendo la segunda en la primera:

$$3 + \frac{16}{17}u_1 - 4\left(-1 - \frac{30}{17}u_1\right) = 0 \implies 7 + \frac{136}{17}u_1 = 0 \implies 7 + 8u_1 = 0 \implies$$

$$u_1 = -\frac{7}{8} \approx -0.88$$

Calculamos u_2:

$$u_2 = -1 - \frac{30}{17}\left(-\frac{7}{8}\right) = -1 + \frac{105}{68} = \frac{37}{68} \approx 0.54$$

Dado que los multiplicadores tienen signos opuestos ($u_1 = -7/8 < 0$ y $u_2 = 37/68 > 0$), el punto $(8/17, -15/17)$ no cumple los requisitos de signos para ser candidato a mínimo ni a máximo (no es punto KKT de primer orden, ver detalle en Figura 4.33).

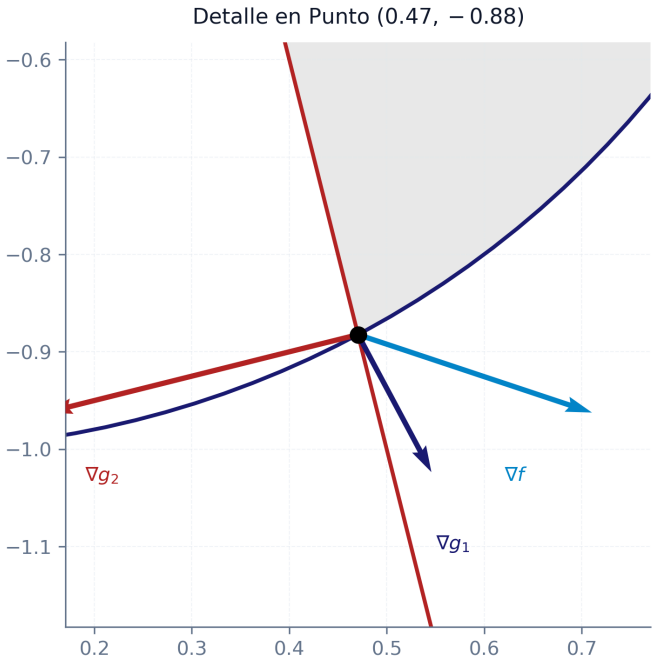

Figura 4.33: KKT Restricción Circular y Lineal: Detalle en $(0.47, -0.88)$

Conclusión y Caracterización de Candidatos
Evaluamos las condiciones suficientes y comparamos los valores de la función objetivo:

- **Mínimos**: El único candidato KKT a mínimo local es $(0, 1)$ con $f(0, 1) = -1$.
  - La función objetivo $f(x, y) = 3x - y$ es lineal (y por tanto, pseudo-convexa).
  - La restricción g_1 es estrictamente convexa y la restricción g_2 es lineal (convexa), por lo que las restricciones activas en el punto son convexas (cuasi-convexas).
  - Dado que $u_1 = 7/8 > 0$ y $u_2 = 3/4 > 0$, se satisfacen las condiciones suficientes de optimalidad global, lo que confirma que $(0, 1)$ **es el mínimo global**.

- **Máximos**: El único candidato KKT a máximo local es $\left(\frac{3}{\sqrt{10}}, -\frac{1}{\sqrt{10}}\right)$ con $f\left(\frac{3}{\sqrt{10}}, -\frac{1}{\sqrt{10}}\right) = \sqrt{10} \approx 3.16$.
  - La función objetivo $f(x, y) = 3x - y$ es lineal (y por tanto, pseudo-cóncava).
  - Las restricciones activas son cuasi-convexas.
  - Dado que el multiplicador de la restricción activa es negativo ($u_1 = -\sqrt{10}/2 < 0$), se satisfacen las condiciones suficientes para máximos, confirmando que $\left(\frac{3}{\sqrt{10}}, -\frac{1}{\sqrt{10}}\right)$ **es el máximo global**.

En la Figura 4.34 se resume gráficamente la caracterización final de los candidatos en este problema.

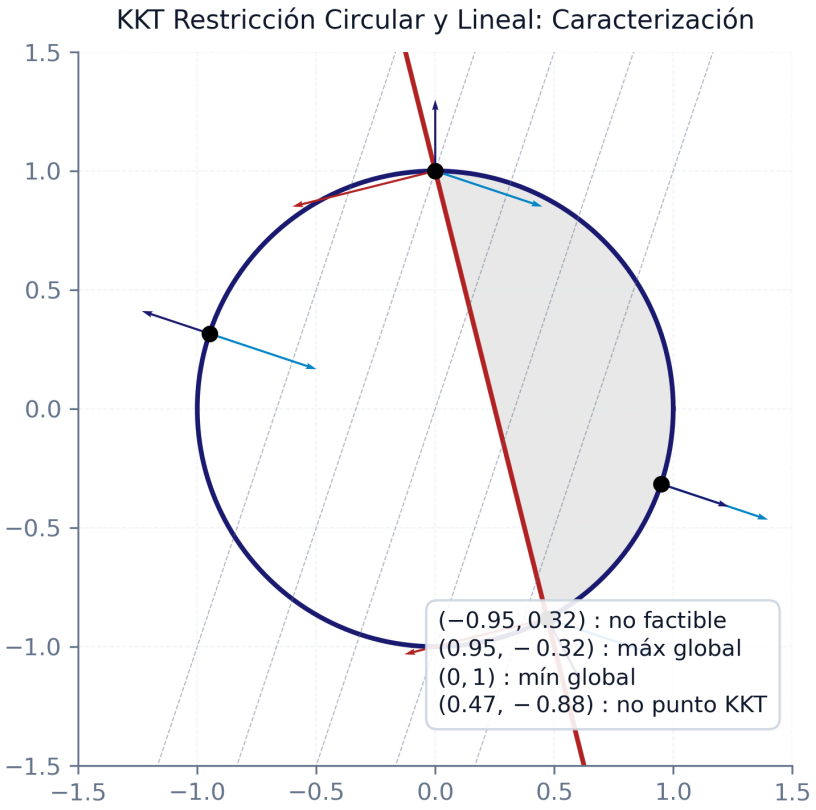

Figura 4.34: KKT Restricción Circular y Lineal: Caracterización

4.6. Restricciones de igualdad y desigualdad

Hasta este punto, el análisis de optimalidad se ha centrado en problemas donde las restricciones limitan el espacio factible mediante desigualdades ($g_i(x) \leq 0$). Sin embargo, la formulación general de los problemas de optimización matemática requiere frecuentemente la inclusión de restricciones de igualdad de la forma $h_j(x) = 0$, para $j = 1, \dots, \ell$. Así, el problema general se define como:

$$\min_x \{f(x) \mid x \in \mathcal{X},\ g_i(x) \leq 0,\ i = 1, \dots, m,\ h_j(x) = 0,\ j = 1, \dots, \ell\}$$

Para extender las condiciones geométricas de optimalidad a este escenario mixto, es necesario caracterizar la influencia de las restricciones de igualdad sobre el conjunto de direcciones admisibles. A diferencia de las desigualdades, que permiten movimientos hacia el interior de la región factible, las restricciones de igualdad obligan a que cualquier dirección admisible permanezca tangente a la hipersuperficie definida por $h_j(x) = 0$. Por ello, se define el cono de direcciones tangentes al espacio de igualdad en un punto factible $\bar{x}$ como:

$$\mathcal{H}_0(\bar{x}) = \{d \in \mathbb{R}^n \mid \nabla h_j(\bar{x})^T d = 0,\ j = 1, \dots, \ell\}$$

Bajo esta definición, la condición necesaria de optimalidad geométrica se formaliza mediante la exclusión de conos, estableciendo que en el óptimo no pueden existir direcciones que desciendan la función objetivo, que sean factibles para las desigualdades activas y que sean tangentes a las igualdades simultáneamente.

Teorema: Exclusión geométrica generalizada

Sea el problema:

$$\text{mín}\{f(x) \mid x \in \mathcal{X},\ g_i(x) \leq 0,\ i = 1, \dots, m,\ h_i(x) = 0,\ i = 1, \dots, \ell\}$$

$\bar{x}$ una solución factible del problema e $\mathcal{I}$ el conjunto de índices de las restricciones activas en $\bar{x}$. Si se verifican las siguientes propiedades: 1. $f, g_i,\ i \in \mathcal{I}$, son diferenciables en $\bar{x}$, 2. $g_i,\ i \notin \mathcal{I}$, son continuas en $\bar{x}$, 3. $h_i,\ i = 1, \dots, \ell$, son continuamente diferenciables en $\bar{x}$, 4. $\nabla h_i,\ i = 1, \dots, \ell$, son linealmente independientes en $\bar{x}$, 5. $\bar{x}$ es un mínimo local de f, entonces, $\mathcal{D}_0(\bar{x}) \cap \mathcal{G}_0(\bar{x}) \cap \mathcal{H}_0(\bar{x}) = \emptyset$, donde:

$$\mathcal{G}_0(\bar{x}) = \{d \in \mathbb{R}^n \mid \nabla g_i(\bar{x})^T d < 0,\ \forall i \in \mathcal{I}\} \quad \text{y} \quad \mathcal{H}_0(\bar{x}) = \{d \in \mathbb{R}^n \mid \nabla h_i(\bar{x})^T d = 0,\ i = 1, \dots, \ell\}$$

Esta exclusión geométrica se traduce al plano algebraico mediante la aplicación de teoremas de alternativa, lo que da lugar a las condiciones necesarias de Karush-Kuhn-Tucker (KKT) generales, siempre y cuando se satisfaga la condición de regularidad (LICQ) en el punto óptimo.

Teorema: Condiciones necesarias de Karush-Kuhn-Tucker (KKT)

Sea el problema $\min\{f(x) \mid x \in \mathcal{X},\ g_i(x) \leq 0,\ i = 1, \dots, m,\ h_i(x) = 0,\ i = 1, \dots, \ell\}$, $\bar{x}$ una solución factible, e $\mathcal{I} = \{i \mid g_i(\bar{x}) = 0\}$ tal que:

1. $f, g_i,\ i \in \mathcal{I}$ son diferenciables en $\bar{x}$,
2. $g_i,\ i \notin \mathcal{I}$ son continuas en $\bar{x}$,
3. $h_i,\ i = 1, \dots, \ell$ son continuamente diferenciables en $\bar{x}$, y
4. $\nabla g_i(\bar{x}),\ i \in \mathcal{I}$ y $\nabla h_i(\bar{x}),\ i = 1, \dots, \ell$ son linealmente independientes en $\bar{x}$.

Entonces, si $\bar{x}$ es un mínimo local de f, existen escalares $\{u_i,\ i \in \mathcal{I},\ v_j,\ j = 1, \dots, \ell\}$, con $u_i \geq 0$, $\forall i \in \mathcal{I}$ tales que:

$$\nabla f(\bar{x}) + \sum_{i \in \mathcal{I}} u_i \nabla g_i(\bar{x}) + \sum_{j=1}^{\ell} v_j \nabla h_j(\bar{x}) = 0$$

Si además se verifica que las funciones $\{g_i,\ i \notin \mathcal{I}\}$ son diferenciables en $\bar{x}$, las condiciones anteriores se pueden escribir de la forma:

$$\nabla f(\bar{x}) + \sum_{i=1}^{m} u_i \nabla g_i(\bar{x}) + \sum_{j=1}^{\ell} v_j \nabla h_j(\bar{x}) = 0$$

$$u_i g_i(\bar{x}) = 0, \quad \forall i = 1, \dots, m$$

$$u_i \geq 0, \quad \forall i = 1, \dots, m$$

Es fundamental resaltar la diferencia matemática y física entre ambos tipos de multiplicadores: mientras que los multiplicadores u_i correspondientes a las desigualdades deben ser obligatoriamente no negativos ($u_i \geq 0$) para asegurar que las direcciones de descenso no se solapen con las factibles, los multiplicadores v_j asociados a las restricciones de igualdad no poseen restricción de signo ($v_j \in \mathbb{R}$), puesto que el movimiento admisible sobre la hipersuperficie está restringido en ambas direcciones (tanto a favor como en contra de $\nabla h_j(\bar{x})$).

Para ilustrar el funcionamiento de estas condiciones en presencia de restricciones mixtas, resolveremos detalladamente dos problemas de optimización sobre la misma región factible acotada por un círculo, la restricción de no negatividad de las variables (primer cuadrante) y una restricción lineal de igualdad, considerando dos configuraciones lineales distintas.

Ejemplo: Restricciones mixtas con frontera $x_1 + x_2 - 3 = 0$

Consideremos el problema de encontrar los mínimos locales de dos funciones objetivo

distintas sobre la región definida en $\mathbb{R}^2$ por:

$$\begin{aligned} \text{mín} \quad & f(x_1, x_2) \\ \text{s.a.} \quad & g_1(x_1, x_2) = x_1^2 + x_2^2 - 5 \leq 0 \\ & g_2(x_1, x_2) = -x_1 \leq 0 \\ & g_3(x_1, x_2) = -x_2 \leq 0 \\ & h_1(x_1, x_2) = x_1 + x_2 - 3 = 0 \end{aligned}$$

Las funciones objetivo a evaluar son: 1. $f_1(x_1, x_2) = x_1^2 + x_2^2$ (que representa la distancia al origen al cuadrado). 2. $f_2(x_1, x_2) = (x_1 - 3)^2 + (x_2 - 2)^2$ (que representa la distancia al cuadrado al punto $(3, 2)$).
Geométricamente (ver Figura 4.35), la región factible $\mathcal{S}$ se reduce al segmento de la recta $x_1 + x_2 = 3$ que yace dentro de la circunferencia de radio $\sqrt{5}$ en el primer cuadrante. Para determinar dicho segmento, sustituimos $x_2 = 3 - x_1$ en la circunferencia:

$$x_1^2 + (3 - x_1)^2 \leq 5 \implies 2x_1^2 - 6x_1 + 4 \leq 0 \implies (x_1 - 1)(x_1 - 2) \leq 0 \implies x_1 \in [1, 2]$$

Por tanto, el dominio factible es el segmento de extremos $(1, 2)$ y $(2, 1)$. La función Lagrangiana común es:

$$L(x_1, x_2, u, v) = f(x_1, x_2) + u_1(x_1^2 + x_2^2 - 5) + u_2(-x_1) + u_3(-x_2) + v_1(x_1 + x_2 - 3)$$

Resolución para $f_1(x_1, x_2) = x_1^2 + x_2^2$:

- **Caso A (Interior del segmento factible, $x_1 \in (1, 2)$)**: Las restricciones de desigualdad son inactivas ($u_1 = u_2 = u_3 = 0$). El sistema de estacionariedad exige:

$$\begin{aligned} 2x_1 + v_1 &= 0 \\ 2x_2 + v_1 &= 0 \end{aligned} \implies x_1 = x_2$$

  Dado que la igualdad h_1 exige $x_1 + x_2 = 3$, obtenemos el punto $(1.5, 1.5)$ con $v_1 = -3$. Dado que este punto es factible, constituye un candidato KKT a mínimo local (siendo el mínimo global con $f_1 = 4.5$).
- **Caso B (Extremos del segmento factible)**:
  - *Punto* $(1, 2)$: Activa g_1 y h_1 ($u_2 = u_3 = 0$). La estacionariedad plantea:

$$\begin{aligned} 2 + 2u_1 + v_1 &= 0 \\ 4 + 4u_1 + v_1 &= 0 \end{aligned} \implies 2 + 2u_1 = 0 \implies u_1 = -1 < 0$$

    Dado que el multiplicador u_1 es negativo, este punto no es candidato a mínimo.
  - *Punto* $(2, 1)$: Por simetría directa, se obtiene igualmente $u_1 = -1 < 0$, descartándolo como candidato a mínimo.

Resolución para $f_2(x_1, x_2) = (x_1 - 3)^2 + (x_2 - 2)^2$:

- **Caso A (Interior del segmento factible, $x_1 \in (1, 2)$)**: Con $u_1 = u_2 = u_3 = 0$, la estacionariedad es:

$$\begin{aligned} 2(x_1 - 3) + v_1 &= 0 \\ 2(x_2 - 2) + v_1 &= 0 \end{aligned} \implies x_1 - 3 = x_2 - 2 \implies x_1 = x_2 + 1$$

  Sustituyendo en la igualdad: $(x_2 + 1) + x_2 = 3 \implies 2x_2 = 2 \implies x_2 = 1, x_1 = 2$. Dado que esta solución corresponde al extremo del segmento, no existen puntos estacionarios en el interior del mismo.
- **Caso B (Extremos del segmento factible)**:
  - *Punto* $(1, 2)$: Con $u_2 = u_3 = 0$, la estacionariedad plantea:

$$\begin{aligned} 2(1 - 3) + 2u_1 + v_1 = 0 &\implies -4 + 2u_1 + v_1 = 0 \\ 2(2 - 2) + 4u_1 + v_1 = 0 &\implies 4u_1 + v_1 = 0 \end{aligned}$$

    Restando ambas ecuaciones: $-4 - 2u_1 = 0 \implies u_1 = -2 < 0$. Se descarta por el signo del multiplicador.
  - *Punto* $(2, 1)$: Con $u_2 = u_3 = 0$, la estacionariedad plantea:

$$\begin{aligned} 2(2 - 3) + 4u_1 + v_1 = 0 &\implies -2 + 4u_1 + v_1 = 0 \\ 2(1 - 2) + 2u_1 + v_1 = 0 &\implies -2 + 2u_1 + v_1 = 0 \end{aligned}$$

    Restando ambas ecuaciones: $2u_1 = 0 \implies u_1 = 0$. Sustituyendo, obtenemos $v_1 = 2$. Como $u_1 = 0 \geq 0$, el punto $(2, 1)$ satisface las condiciones KKT y es el candidato a mínimo local (mínimo global con $f_2 = 2.0$).

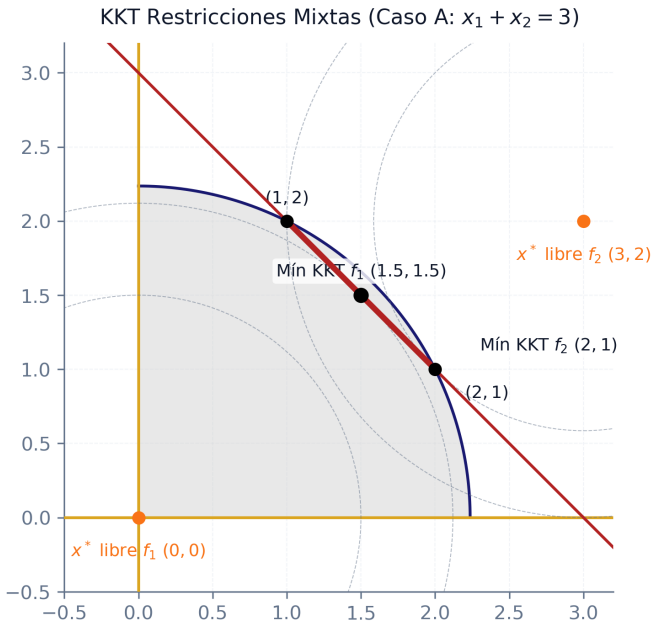

Figura 4.35: Análisis KKT mixto para $x_1 + x_2 = 3$

Ejemplo: Restricciones mixtas con frontera $x_1 + 2x_2 - 4 = 0$

Consideremos ahora el mismo problema de optimización pero modificando la restricción de igualdad a:

$$h_1(x_1, x_2) = x_1 + 2x_2 - 4 = 0$$

Las funciones objetivo siguen siendo $f_1(x_1, x_2) = x_1^2 + x_2^2$ y $f_2(x_1, x_2) = (x_1 - 3)^2 + (x_2 - 2)^2$. Geométricamente (ver Figura 4.36), la región factible $\mathcal{S}$ se reduce al segmento de la recta $x_1 + 2x_2 = 4$ dentro del primer cuadrante y del círculo de radio $\sqrt{5}$. Determinemos el rango factible de x_2 sustituyendo $x_1 = 4 - 2x_2$ en la circunferencia:

$$(4-2x_2)^2 + x_2^2 \leq 5 \implies 5x_2^2 - 16x_2 + 11 \leq 0 \implies (x_2 - 1)(5x_2 - 11) \leq 0 \implies x_2 \in [1, 2.2]$$

No obstante, para asegurar la factibilidad en el primer cuadrante, también debe cumplirse $x_1 \geq 0 \implies 4 - 2x_2 \geq 0 \implies x_2 \leq 2$. Así, la región factible real es el segmento de extremos $(2, 1)$ (para $x_2 = 1$) y $(0, 2)$ (para $x_2 = 2$).

Resolución para $f_1(x_1, x_2) = x_1^2 + x_2^2$:

- **Caso A (Interior del segmento factible, $x_2 \in (1, 2)$)**: Las restricciones de desigualdad son inactivas ($u_1 = u_2 = u_3 = 0$). La estacionariedad con h_1 exige:

$$\begin{aligned} 2x_1 + v_1 &= 0 \\ 2x_2 + 2v_1 &= 0 \end{aligned} \implies x_2 = 2x_1$$

Sustituyendo en la restricción de igualdad: $x_1 + 2(2x_1) = 4 \implies 5x_1 = 4 \implies x_1 = 0.8$, lo que da $x_2 = 1.6$. El punto obtenido es $(0.8, 1.6)$ con $v_1 = -1.6$. Dado que es factible, constituye un candidato KKT a mínimo local (y mínimo global con $f_1 = 3.2$).

- **Caso B (Extremos del segmento factible)**:
  - *Punto* $(2, 1)$: Activa g_1 y h_1 ($u_2 = u_3 = 0$). La estacionariedad plantea:

$$\begin{aligned} 4 + 4u_1 + v_1 &= 0 \\ 2 + 2u_1 + 2v_1 = 0 &\implies 1 + u_1 + v_1 = 0 \implies v_1 = -1 - u_1 \end{aligned}$$

    Sustituyendo en la primera: $4 + 4u_1 - 1 - u_1 = 0 \implies u_1 = -1 < 0$. Se descarta.
  - *Punto* $(0, 2)$: Activa el eje $g_2(x) = -x_1 \leq 0$ y la recta $h_1 = 0$ ($u_1 = u_3 = 0$). La estacionariedad plantea:

$$\begin{aligned} 0 - u_2 + v_1 = 0 &\implies u_2 = v_1 \\ 4 + 2v_1 = 0 &\implies v_1 = -2 \implies u_2 = -2 < 0 \end{aligned}$$

    Se descarta por tener un multiplicador de desigualdad negativo.

Resolución para $f_2(x_1, x_2) = (x_1 - 3)^2 + (x_2 - 2)^2$:

- **Caso A (Interior del segmento factible, $x_2 \in (1, 2)$)**: Con $u_1 = u_2 = u_3 = 0$, la estacionariedad plantea:

$$\begin{aligned} 2(x_1 - 3) + v_1 &= 0 \\ 2(x_2 - 2) + 2v_1 &= 0 \end{aligned} \implies x_2 - 2 = 2(x_1 - 3) \implies x_2 = 2x_1 - 4$$

  Sustituyendo en la igualdad: $x_1 + 2(2x_1 - 4) = 4 \implies 5x_1 = 12 \implies x_1 = 2.4, x_2 = 0.8$. Dado que $x_2 = 0.8 < 1$, esta solución cae fuera del segmento factible y se descarta.
- **Caso B (Extremos del segmento factible)**:
  - *Punto* $(2, 1)$: Activa g_1 y h_1 ($u_2 = u_3 = 0$). La estacionariedad plantea:

$$\begin{aligned} 2(2 - 3) + 4u_1 + v_1 = 0 &\implies -2 + 4u_1 + v_1 = 0 \\ 2(1 - 2) + 2u_1 + 2v_1 = 0 &\implies -2 + 2u_1 + 2v_1 = 0 \implies -1 + u_1 + v_1 = 0 \end{aligned}$$

    De la segunda obtenemos $v_1 = 1 - u_1$. Sustituyendo en la primera: $-2 + 4u_1 + 1 - u_1 = 0 \implies 3u_1 = 1 \implies u_1 = 1/3 \geq 0$. Esto nos da $v_1 = 2/3$. Al obtener multiplicadores factibles, el punto $(2, 1)$ es un candidato KKT a mínimo local (mínimo global con $f_2 = 2.0$).

- *Punto* $(0, 2)$: Activa g_2 y h_1 ($u_1 = u_3 = 0$). La estacionariedad plantea:

$$\begin{aligned} 2(0-3) - u_2 + v_1 = 0 &\implies -6 - u_2 + v_1 = 0 \\ 2(2-2) + 2v_1 = 0 &\implies 2v_1 = 0 \implies v_1 = 0 \end{aligned}$$

  Lo que da $u_2 = -6 < 0$. Se descarta.

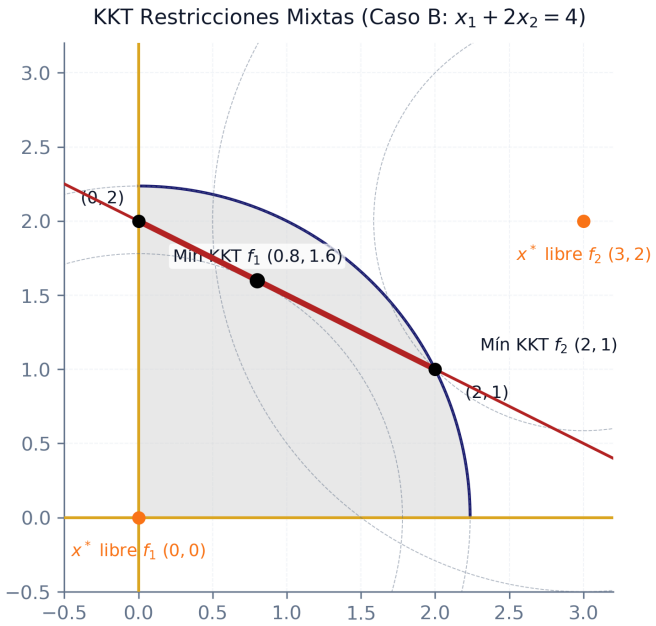

Figura 4.36: Análisis KKT mixto para $x_1 + 2x_2 = 4$

5 Programación lineal y cuadrática

Las condiciones de Karush-Kuhn-Tucker (KKT) adquieren una relevancia excepcional al aplicarse sobre problemas con estructuras matemáticas específicas, como la **Programación Lineal (LP)** y la **Programación Cuadrática (QP)**. En ambos casos, las restricciones son afines, lo que garantiza que las cualificaciones de restricciones (como LICQ) se verifiquen de forma natural en cualquier punto factible. Además, cuando la función objetivo es convexa, las condiciones necesarias de KKT se convierten también en suficientes, proporcionando un marco algebraico cerrado para hallar y certificar el óptimo global.

En este capítulo, analizaremos la relación profunda entre las condiciones KKT y la dualidad lineal, explicaremos la interpretación económica de las variables duales como precios sombra, clasificaremos la correspondencia de los distintos tipos de óptimos lineales mediante ilustraciones geométricas paso a paso, describiremos la estructura matricial de la programación cuadrática y detallaremos el método del Símplex de Wolfe para resolver problemas cuadráticos convexos.

! Objetivos de aprendizaje

Al finalizar este capítulo, serás capaz de:

1. **Deducir y justificar** la equivalencia entre los multiplicadores KKT de un problema de programación lineal y las variables óptimas de su problema dual asociado.
2. **Demostrar formalmente** el teorema de dualidad débil en programación lineal y deducir sus consecuencias sobre el salto dual y la no acotación.
3. **Interpretar económicamente** las variables duales como precios sombra (*shadow prices*) de los términos independientes.
4. **Clasificar los tipos de óptimos** en programación lineal atendiendo a la unicidad, degeneración y acotación tanto del problema primal como del dual.
5. **Formular el sistema KKT** para problemas de programación cuadrática (QP) en forma matricial.
6. **Aplicar el algoritmo del Símplex de Wolfe** (regla de entrada restringida) para resolver de forma exacta problemas cuadráticos convexos.

5.1. Programación lineal (LP)

La **Programación Lineal (LP)** representa la piedra angular de la optimización matemática moderna y de la investigación operativa (Hillier y Lieberman 2010; Bazaraa, Jarvis, y Sherali 2011; Luenberger y Ye 2015). Consiste en la optimización (minimización o maximización) de un criterio de rendimiento lineal expresado por un vector de costes $c \in \mathbb{R}^n$, sobre un conjunto de soluciones factibles delimitado exclusivamente por hiperplanos y semiespacios afines dados por restricciones de igualdad o desigualdad lineal.

Desde una perspectiva geométrica, el conjunto factible de un problema de programación lineal constituye un **poliedro convexo** (un politopo si está acotado). Como consecuencia directa de la convexidad del conjunto y de la linealidad de la función objetivo, la programación lineal posee dos propiedades geométricas fundamentales:

1. **Ausencia de óptimos locales strictly disjuntos**: Todo mínimo local es automáticamente un mínimo global.
2. **Teorema Fundamental de la Programación Lineal**: Si el problema admite solución óptima finita y la región factible posee al menos un punto extremo (vértice), existe al menos un **vértice extremo** del poliedro donde se alcanza dicho óptimo global.

Como se ilustra en la Figura 5.1, la geometría de la programación lineal se caracteriza por una región factible poliédrica cuyos bordes son las restricciones afines activas, sobre la cual la función objetivo desplaza sus curvas de nivel hiperplánicas en la dirección de máximo descenso dictada por el vector gradiente del coste c.

5.1.1. Dualidad en programación lineal

El concepto de dualidad constituye uno de los pilares más profundos e insustituibles de la optimización lineal. A todo problema de programación lineal, denominado **problema primal**, se le asocia de forma simétrica e involutiva otro problema lineal estrechamente vinculado denominado **problema dual**. La teoría de la dualidad establece que ambos problemas observan la misma situación de optimización desde dos perspectivas complementarias: mientras que el problema primal busca asignar niveles de actividad para minimizar un coste total (o maximizar un beneficio) sujeto a restricciones afines generales, el problema dual busca determinar la valoración económica óptima de dichos términos independientes.

Analíticamente, el problema primal original (P) se formula en su forma canónica de minimización como:

$$\begin{aligned} \min_{x \in \mathbb{R}^n} \quad & c^T x \\ \text{sujeto a} \quad & Ax \geq b \\ & x \geq 0 \end{aligned}$$

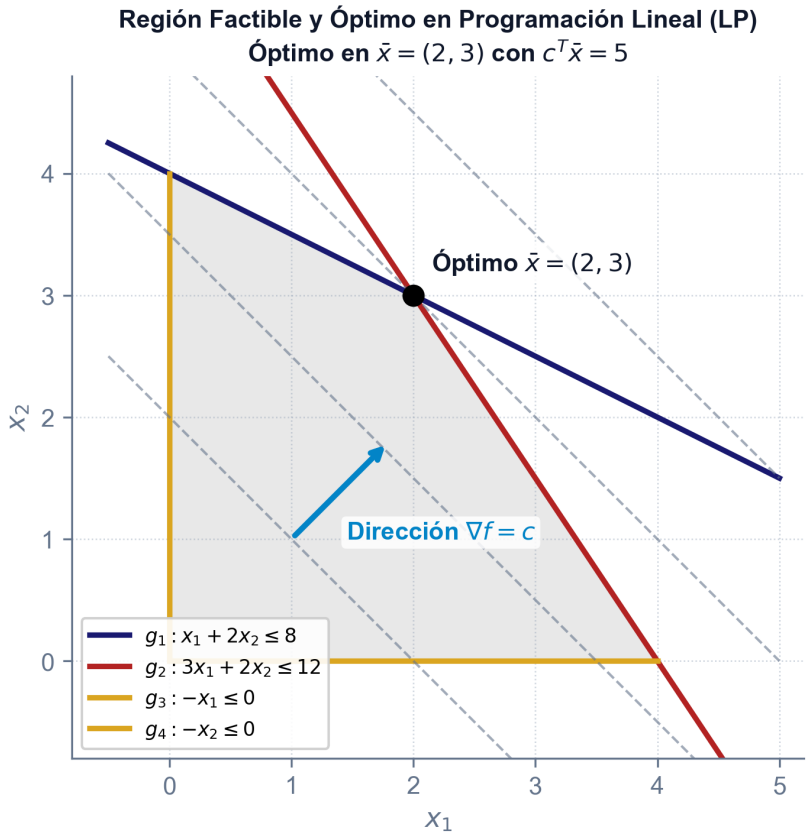

Figura 5.1: Región factible y dirección de optimización en un problema de programación lineal

donde $x \in \mathbb{R}^n$ representa el vector de variables primales, $c \in \mathbb{R}^n$ el vector de costes, $A \in \mathbb{R}^{m \times n}$ la matriz de coeficientes de las restricciones y $b \in \mathbb{R}^m$ la términos independientes.

Asociando un vector de multiplicadores o variables duales $w \in \mathbb{R}^m$ ($w \geq 0$) a las m restricciones afines generales $Ax \geq b$, se construye de forma natural el **problema dual (D)** equivalente en forma canónica de maximización:

$$\begin{aligned} \max_{w \in \mathbb{R}^m} \quad & b^T w \\ \text{sujeto a} \quad & A^T w \leq c \\ & w \geq 0 \end{aligned}$$

Esta relación dual posee la propiedad simétrica fundamental de involución: el problema dual del problema dual es exactamente el problema primal original.

La relación entre los valores objetivos de ambos problemas queda establecida fundamentalmente por el teorema de dualidad débil:

! Teorema: Teorema de dualidad débil en LP

Para cualquier solución factible x del problema primal (P) y cualquier solución factible w del problema dual (D), el valor de la función objetivo dual es una cota inferior del valor de la función objetivo primal:

$$b^T w \leq c^T x$$

Demostración:

1. **Factibilidad primal**: Sea x una solución factible en (P), lo que implica que $Ax \geq b$. Multiplicando por la izquierda por el vector dual no negativo $w^T \geq 0$ (w factible dual), se preserva el sentido de la desigualdad:

$$w^T b \leq w^T A x$$

2. **Factibilidad dual**: Sea w una solución factible en (D), lo que implica que $A^T w \leq c \iff w^T A \leq c^T$. Multiplicando por la derecha por el vector primal no negativo $x \geq 0$, se preserva el sentido de la desigualdad:

$$w^T A x \leq c^T x$$

3. **Encadenamiento de cotas**: Unificando ambas desigualdades vectoriales:

$$b^T w \leq w^T A x \leq c^T x \implies b^T w \leq c^T x. \quad \blacksquare$$

La interpretación geométrica y algebraica del Teorema de Dualidad Débil establece que el valor óptimo del problema primal está acotado inferiormente por el valor de cualquier solución factible

del problema dual y viceversa. De este principio fundamental se derivan dos consecuencias directas para el análisis de optimalidad:

Consecuencias fundamentales de la dualidad débil

Como consecuencia directa de la desigualdad de dualidad débil $b^T w \leq c^T x$:

1. **Criterio de Certificación de Optimalidad (Salto Dual Nulo)**: Si para algún par de soluciones factibles x^* (primal) y w^* (dual) el valor de las respectivas funciones objetivo coincide:
$$b^T w^* = c^T x^*$$
entonces x^* es de forma garantizada una **solución óptima del problema primal (P)** y w^* es una **solución óptima del problema dual (D)**.
2. **Relación de No Acotación e Infactibilidad Recíproca**: Si uno de los dos problemas posee una solución **NO acotada** (por ejemplo, el primal de minimización tiende a $-\infty$ o el dual de maximización tiende a $+\infty$), el otro problema **no tiene solución** (es decir, su región factible es vacía).

5.1.2. Condiciones KKT en programación lineal

Aunque los problemas de optimización lineal se resuelven habitualmente en la práctica mediante algoritmos de pivote (como el método del Símplex) o métodos de punto interior, las condiciones de Karush-Kuhn-Tucker (KKT) constituyen la piedra angular teórica del área. En el ámbito lineal, el marco de KKT conecta de manera natural el problema primal con su dual, proporciona la fundamentación analítica de los precios sombra y permite certificar formalmente la optimalidad global de una solución.

Para estudiar estas condiciones con el máximo rigor y claridad, expresamos en primer lugar el problema primal (P) en su formato estándar de minimización, con todas las restricciones de desigualdad afines reordenadas en la forma canónica $g_i(x) \leq 0$:

$$\begin{aligned} \min_{x \in \mathbb{R}^n} \quad & c^T x && (1) \\ \text{sujeto a} \quad & b - Ax \leq 0 && (2) \\ & -x \leq 0 && (3) \end{aligned}$$

En esta formulación matricial, identificamos claramente los cuatro elementos fundamentales del modelo: el vector $x = (x_1, \dots, x_n)^T \in \mathbb{R}^n$ representa las n **variables de decisión**, $c = (c_1, \dots, c_n)^T \in \mathbb{R}^n$ denota el vector de **costes o coeficientes objetivos**, $A \in \mathbb{R}^{m \times n}$ es la **matriz de coeficientes de las restricciones** (cuya i-ésima fila se denota como vector fila por a^i) y $b = (b_1, \dots, b_m)^T \in \mathbb{R}^m$ especifica la **vector de términos independientes**. Cabe

recordar que cualquier problema lineal arbitrario (con maximizaciones, igualdades o variables libres) se puede transformar algebraicamente a este formato canónico de minimización.

Antes de construir la función Lagrangiana y derivar las ecuaciones del sistema, conviene analizar las propiedades analíticas y topológicas que justifican la validez y suficiencia de este marco en la programación lineal.

i Propiedades analíticas y suficiencia de KKT en LP

La estructura afín de la programación lineal le otorga propiedades topológicas excepcionales que simplifican notablemente el análisis:

1. **Convexidad del dominio y la función**: La región factible $S = \{x \in \mathbb{R}^n \mid Ax \geq b, x \geq 0\}$ está definida como la intersección de $m + n$ semiespacios afines cerrados y, por tanto, constituye un poliedro convexo. Asimismo, la función objetivo $f(x) = c^T x$ es afín (simultáneamente convexa y cóncava), lo que garantiza que cualquier mínimo local sea automáticamente un óptimo global.
2. **Suficiencia de las condiciones KKT**: Dado que las restricciones son afines, las cualificaciones de restricciones (como LICQ o la condición de Slater) se satisfacen de forma trivial en todo el espacio. En consecuencia, en programación lineal las condiciones de Karush-Kuhn-Tucker son **necesarias y suficientes** para la optimización global.

Una vez fundamentada la suficiencia teórica del sistema KKT, procedemos a derivar explícitamente sus ecuaciones. Para ello, calculamos en primer lugar los gradientes individuales de la función objetivo y de cada conjunto de restricciones de desigualdad involucrados en (1)–(3):

- **Gradiente de la función objetivo**: La función afín $f(x) = c^T x$ presenta un gradiente constante respecto al vector de variables primales, dado directamente por el vector de costes:
$$\nabla f(x) = c$$
- **Gradientes de las m restricciones generales de desigualdad**: Reescribiendo las desigualdades generales (2) como $g_i(x) = b_i - a^i x \leq 0$ para $i = 1, \dots, m$, sus gradientes vienen dados por la traspuesta negativa de cada fila de la matriz A:
$$\nabla g_i(x) = -(a^i)^T, \quad i = 1, \dots, m$$
donde el vector fila a^i representa la i-ésima fila de la matriz de coeficientes A.
- **Gradientes de las n restricciones de no negatividad**: Reescritas las desigualdades (3) como $g_{m+j}(x) = -x_j \leq 0$ para $j = 1, \dots, n$, sus gradientes equivalen al opuesto de los vectores de la base canónica:
$$\nabla g_{m+j}(x) = -e^j, \quad j = 1, \dots, n$$
donde e^j denota el j-ésimo vector unitario de la base canónica de $\mathbb{R}^n$.

Con estos gradientes calculados, construimos la función Lagrangiana del problema asociando un vector de multiplicadores duales $u = (u_1, \dots, u_m)^T \geq 0$ a las restricciones generales de desigualdad (2), y un vector de multiplicadores $v = (v_1, \dots, v_n)^T \geq 0$ a las restricciones de no negatividad (3):

$$L(x, u, v) = c^T x + \sum_{i=1}^{m} u_i(b_i - a^i x) + \sum_{j=1}^{n} v_j(-x_j) = c^T x + u^T(b - Ax) - v^T x$$

Al imponer la condición de estacionariedad anulando el gradiente de la Lagrangiana respecto a x, tenemos $\nabla_x L(x, u, v) = c - A^T u - v = 0$. Juntando esta relación con la factibilidad de las soluciones y el principio de holgura complementaria, un triplete de vectores (x, u, v) satisface las **condiciones necesarias y suficientes de Karush-Kuhn-Tucker** si y solo si verifica de forma simultánea:

1. **Factibilidad primal**: Exige que el vector x sea una solución factible que cumpla todas las restricciones afines generales y de no negatividad del problema original:

$$Ax \geq b, \qquad x \geq 0$$

2. **Factibilidad dual y estacionariedad**: Requiere el equilibrio entre el gradiente del coste y los gradientes de las restricciones ponderados por los multiplicadores nonegativos:

$$c - A^T u - v = 0 \quad \text{con } u \geq 0 \text{ y } v \geq 0$$

   donde u y v representan los multiplicadores de Lagrange asociados a las restricciones afines generales (2) y de no negatividad (3), respectivamente.
3. **Holgura complementaria**: Obliga a que el producto de cada multiplicador dual por la holgura de su correspondiente restricción primal sea nulo:

$$u_i(b_i - a^i x) = 0, \quad \forall i = 1, \dots, m$$
$$v_i x_i = 0, \quad \forall i = 1, \dots, n$$

> **i** Estructura matricial y equivalencia dual del sistema KKT
>
> El sistema KKT en programación lineal establece una equivalencia directa entre el espacio primal y el espacio dual a través de tres componentes clave:
>
> - **Factibilidad primal**: $Ax \geq b, \quad x \geq 0 \implies$ Garantiza la pertenencia de x al poliedro factible del problema primal (P).
> - **Factibilidad dual (estacionariedad)**: $c - A^T u - v = 0 \quad \text{con } u \geq 0, v \geq 0 \implies$ Al despejar $v = c - A^T u \geq 0$, exige la factibilidad del multiplicador u en el problema dual (D), esto es, $A^T u \leq c$ con $u \geq 0$.
> - **Holgura complementaria**: $u_i(b_i - a^i x) = 0 \quad (\forall i)$ y $v_i x_i = 0 \quad (\forall i) \implies$ Vincula el holgura de las restricciones con la valoración económica marginal de las restricciones.

La verdadera potencia analítica del sistema KKT radica en que funciona como un puente matemático directo entre el problema primal y su problema dual. Para evidenciar esta conexión fundamental, situamos en paralelo la formulación canónica del problema primal (P) y la de su problema dual asociado (D):

$$\text{Primal (P):} \quad \begin{array}{ll} \min\limits_{x\in\mathbb{R}^n} & c^T x \\ \text{sujeto a} & Ax \geq b \\ & x \geq 0 \end{array} \qquad \text{Dual (D):} \quad \begin{array}{ll} \max\limits_{w\in\mathbb{R}^m} & b^T w \\ \text{sujeto a} & A^T w \leq c \\ & w \geq 0 \end{array}$$

A continuación, analizamos las propiedades de cualquier triplete de vectores (x, u, v) que satisfaga el sistema de condiciones KKT expresado anteriormente. Al examinar cada condición, descubrimos dos resultados de enorme calado:

En primer lugar, la **factibilidad primal** del sistema KKT ($Ax \geq b, x \geq 0$) asegura directamente que el vector x es una solución factible para el problema primal (P).

En segundo lugar, despejando el vector de multiplicadores v de la condición de estacionariedad obtenemos $v = c - A^T u$. Como las condiciones KKT exigen la no negatividad $v \geq 0$, la sustitución directa produce la siguiente cadena formal de implicaciones equivalentes:

$$\left.\begin{array}{r} c - A^T u - v = 0 \\ u, v \geq 0 \end{array}\right\} \implies \left.\begin{array}{r} v = c - A^T u \\ u, v \geq 0 \end{array}\right\} \implies \begin{array}{r} c - A^T u \geq 0 \\ u \geq 0 \end{array} \iff \begin{array}{r} A^T u \leq c \\ u \geq 0 \end{array}$$

Este desarrollo demuestra formalmente que el vector de multiplicadores KKT $u \in \mathbb{R}^m$ verifica las restricciones generales de desigualdad y de signo del problema dual, lo que significa que u **es automáticamente una solución factible para el problema dual (D)**.

Una vez demostrada la factibilidad simultánea de x en (P) y de u en (D), el siguiente paso decisivo consiste en comparar los valores de sus respectivas funciones objetivo, $c^T x$ y $b^T u$. Para ello, relacionamos la ecuación de estacionariedad con la holgura complementaria mediante dos operaciones algebraicas clave:

Primero, premultiplicamos la ecuación de estacionariedad $c - A^T u - v = 0$ por la izquierda por el vector fila de variables primales no negativas $x^T \geq 0$:

$$c - A^T u - v = 0 \implies x^T(c - A^T u - v) = 0 \implies c^T x - u^T A x - v^T x = 0 \qquad (4)$$

Segundo, sumamos las condiciones de holgura complementaria sobre todas sus componentes $i = 1, \ldots, m$ y $j = 1, \ldots, n$, lo que nos permite agregar las ecuaciones individuales en expresiones matriciales compactas:

$$\left.\begin{aligned} u_i(b_i - a^i x) = 0 \quad \forall i \\ v_i x_i = 0 \quad \forall i \end{aligned}\right\} \implies \left.\begin{aligned} \sum_{i=1}^{m} u_i(b_i - a^i x) = 0 \\ \sum_{i=1}^{n} v_i x_i = 0 \end{aligned}\right\} \implies \begin{aligned} b^T u = u^T A x \\ v^T x = 0 \end{aligned}$$

Tercero, sustituimos las identidades resultantes $u^T Ax = b^T u$ y $v^T x = 0$ directamente en la relación de estacionariedad premultiplicada (4). El término de acoplamiento $u^T Ax$ se reemplaza por el coste dual $b^T u$ y el término $v^T x$ se anula, conduciendo a la igualdad exacta de valores objetivos:

$$c^T x - b^T u = 0 \iff c^T x = b^T u$$

Esta coincidencia prueba de forma categórica que en cualquier punto que satisfaga el sistema KKT, el salto dual (la diferencia entre el coste primal $c^T x$ y el beneficio dual $b^T u$) es exactamente cero.

Sintetizando estos tres hallazgos analíticos (factibilidad primal de x, factibilidad dual de u y salto dual nulo), llegamos al teorema central que permite certificar formalmente la optimalidad global:

! Teorema: Certificación de optimalidad mediante condiciones KKT

Dada una solución (x, u, v) que satisface las condiciones de Karush-Kuhn-Tucker de un problema de programación lineal:

1. **Factibilidad primal**: El vector de decisiones x es una solución factible para el problema primal (P).
2. **Factibilidad dual**: El vector de multiplicadores KKT u es una solución factible para el problema dual (D).
3. **Salto dual nulo**: El valor de la función objetivo primal coincide exactamente con el de la función objetivo dual ($c^T x = b^T u$).

Conclusión: En virtud del Teorema de Dualidad Débil, al coincidir el valor de la función objetivo primal $c^T x$ con el de una solución factible dual $b^T u$, queda demostrado formalmente que x **es una solución óptima global del problema primal (P)** y u **es una solución óptima global del problema dual (D)**.

5.1.3. Interpretación económica y precios sombra

En el ámbito de la economía y la investigación operativa aplicadas a la gestión empresarial, la programación lineal se utiliza habitualmente para modelar problemas de planificación de la

producción sujetos a restricciones de capacidad o presupuesto. En este marco, las variables primales x_j representan los niveles de actividad (cantidades a producir de cada bien o servicio), mientras que los términos independientes b_i cuantifican la disponibilidad máxima de los términos independientes.

Los multiplicadores duales u_i^* asociados a las restricciones generales de desigualdad en las condiciones KKT admiten una interpretación económica fundamental: representan los **precios sombra** (*shadow prices*) o valores marginales de los términos independientes. Matemáticamente, el precio sombra u_i^* mide la tasa instantánea de variación del valor óptimo de la función objetivo ante un incremento marginal unitario en la término independiente b_i:

$$u_i^* = \frac{\partial(c^T x^*)}{\partial b_i}$$

Bajo esta perspectiva económica, la condición de holgura complementaria del sistema KKT, $u_i^*(b_i - a^i x^*) = 0$, formaliza una regla de asignación de términos independientes sumamente intuitiva:

- **Restricción inactiva o excedentaria**: Si en la solución óptima la restricción no se satura ($a^i x^* < b_i \implies b_i - a^i x^* > 0$), existe una holgura en la restricción i. Incrementar el término independiente de una restricción inactiva no genera beneficio adicional ni reduce el coste óptimo. Por tanto, su valor marginal o precio sombra es nulo ($u_i^* = 0$).
- **Restricción activa o limitante**: Si una restricción posee un precio sombra estrictamente positivo ($u_i^* > 0$), significa que dicha restricción limita la región factible y restringe la capacidad de optimización del sistema. Por consiguiente, la holgura debe anularse necesariamente en el óptimo ($b_i - a^i x^* = 0$).

5.1.4. Clasificación de óptimos y relaciones de dualidad

La geometría del poliedro factible S y la independencia lineal de los gradientes de las restricciones activas en el punto óptimo determinan la estructura de las soluciones tanto del problema primal como de su problema dual asociado. Para analizar de forma rigurosa la caracterización de las soluciones mediante las condiciones KKT, conviene clasificar en primer lugar las propiedades analíticas de la solución:

1. **Finitud y existencialidad de la solución**:
    - **Solución óptima finita**: El valor óptimo de la función objetivo se alcanza en un valor real acotado. Ocurre siempre que el problema es factible y la función objetivo está acotada inferiormente en la región factible.
    - **Problema no acotado**: El valor objetivo decrece hacia $-\infty$ (en minimización) a lo largo de un rayo o dirección de recesión no acotada del poliedro.

- **Problema no factible**: La región factible es vacía debido a la incompatibilidad de las restricciones.

2. **Unicidad frente a multiplicidad de óptimos**:
   - **Solución única**: El mínimo global se alcanza exclusivamente en un único vértice o punto del poliedro.
   - **Múltiples soluciones óptimas**: El vector de costes es ortogonal a una arista o cara de dimensión $d \geq 1$ del poliedro. El conjunto de óptimos es el casco convexo de los vértices extremos óptimos más, en su caso, una combinación lineal positiva de direcciones extremas óptimas.
3. **Degeneración primal y dual**:
   - **Degeneración primal**: En un espacio de dimensión n, una solución es **no degenerada** si en ella se cortan exactamente n restricciones activas linealmente independientes (verificando la cualificación LICQ). Es **degenerada** si convergen más de n restricciones activas (sobredeterminación geométrica), rompiendo la independencia lineal de los gradientes activos. En tal escenario, el punto satisface las condiciones generales de Fritz John (FJ) y admite infinitos vectores de multiplicadores KKT válidos.
   - **Degeneración dual**: Una solución del problema dual es **degenerada** si presenta al menos un multiplicador dual nulo ($u_i^* = 0$) asociado a una restricción primal estrictamente activa ($b_i - a^i x^* = 0$). Analíticamente, esto indica que la restricción activa es "prescindible" para equilibrar la dirección de descenso $-\nabla f$, lo que en la geometría dual corresponde a una solución básica dual con componentes nulas adicionales.

Ejemplo: Análisis por casos de las condiciones KKT en programación lineal

A continuación se ilustra la relación entre la geometría del primal y del dual analizando seis escenarios representativos.

Caso 1: El problema tiene solución óptima finita única y no degenerada

Consideremos el problema de minimización con tres restricciones generales de desigualdad:

$$\begin{aligned} \min_{x,y\in\mathbb{R}} \quad & -x-2y \\ \text{sujeto a} \quad & x+y-4\leq 0 \quad (g_1) \\ & -x+y-2\leq 0 \quad (g_2) \\ & 2x+y-7\leq 0 \quad (g_3) \\ & x,y\geq 0 \end{aligned}$$

Como se ilustra en la Figura 5.2, el vector de descenso $-\nabla f = (1,2)^T$ desplaza el óptimo al vértice extremo $\bar{x} = (1,3)$, donde se alcanza un coste mínimo finito de $f(1,3) = -7$. En el punto $(1,3)$, las únicas restricciones activas son $g_1(1,3) = 0$ y $g_2(1,3) = 0$. Al ser

$n = 2$ la dimensión del espacio y cortarse exactamente $n = 2$ restricciones activas cuyos gradientes $\nabla g_1 = (1, 1)^T$ y $\nabla g_2 = (-1, 1)^T$ forman una base linealmente independiente en $\mathbb{R}^2$, la solución primal es **finita, única y no degenerada**.
Al plantear la condición de estacionariedad KKT $-\nabla f(1, 3) = u_1 \nabla g_1 + u_2 \nabla g_2$:

$$\begin{pmatrix} 1 \\ 2 \end{pmatrix} = u_1 \begin{pmatrix} 1 \\ 1 \end{pmatrix} + u_2 \begin{pmatrix} -1 \\ 1 \end{pmatrix} \implies u_1^* = \frac{3}{2} > 0, \quad u_2^* = \frac{1}{2} > 0, \quad u_3^* = 0$$

Dado que los gradientes de las restricciones activas forman base y ambos multiplicadores son estrictamente positivos, el vector dual $w^* = (3/2, 1/2, 0)^T$ es único. Por consiguiente, **el problema dual tiene solución óptima finita única no degenerada**.

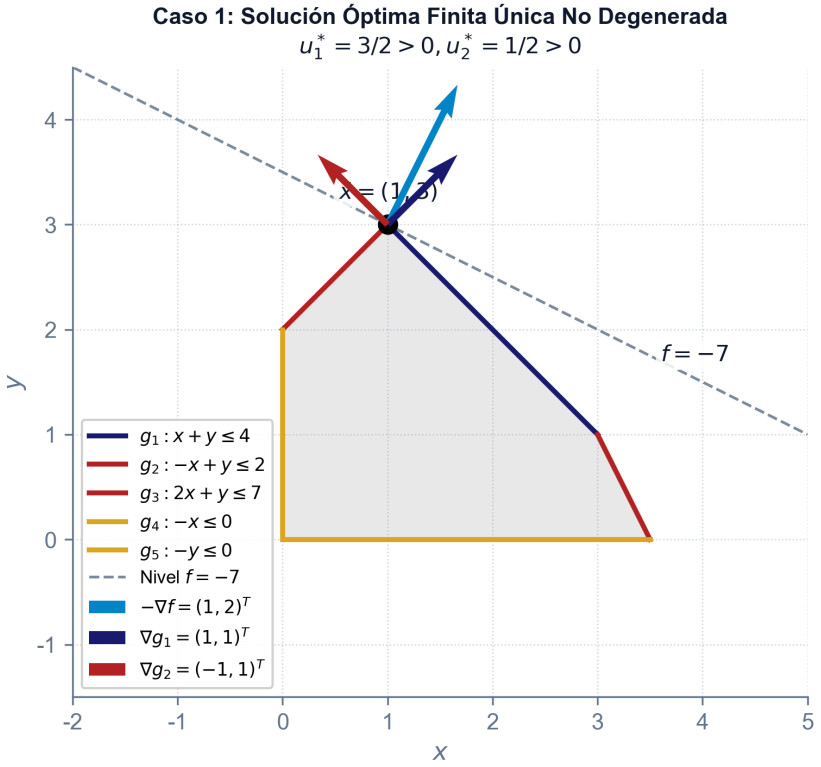

Figura 5.2: Caso 1: Solución óptima finita única no degenerada

Caso 2: El problema tiene solución óptima finita única degenerada

Se añade al problema anterior la restricción redundante $g_4(x, y) = y - 3 \leq 0$:

$$\begin{aligned} \min_{x,y\in\mathbb{R}} \quad & -x - 2y \\ \text{sujeto a} \quad & x + y - 4 \leq 0 \quad (g_1) \\ & -x + y - 2 \leq 0 \quad (g_2) \\ & 2x + y - 7 \leq 0 \quad (g_3) \\ & y - 3 \leq 0 \quad (g_4 \text{ redundante}) \\ & x, y \geq 0 \end{aligned}$$

La solución óptima primal sigue siendo el vértice $(1, 3)$ con valor finito $f(1, 3) = -7$. Sin embargo, como muestra la Figura 5.3, en dicho punto coinciden tres restricciones activas: g_1, g_2 y g_4. Al haber $m = 3$ restricciones activas para $n = 2$ variables, el punto presenta sobredeterminación geométrica. Los gradientes $\nabla g_1 = (1, 1)^T$, $\nabla g_2 = (-1, 1)^T$ y $\nabla g_4 = (0, 1)^T$ no son linealmente independientes (se rompe LICQ).
Aunque el punto satisface la condición de Fritz John (FJ), existen múltiples combinaciones de multiplicadores para expresar $-\nabla f$ como combinación lineal no negativa de los gradientes activos. Cumplen KKT tanto $u = (u_1, u_2, u_4) = (3/2, 1/2, 0)$ como $u' = (u_1, u_2, u_4) = (1, 0, 1)$. Cualquier combinación convexa $\lambda u + (1 - \lambda)u'$ $(\forall \lambda \in [0, 1])$ es también solución del dual. Por tanto, **el problema dual tiene múltiples soluciones óptimas**.

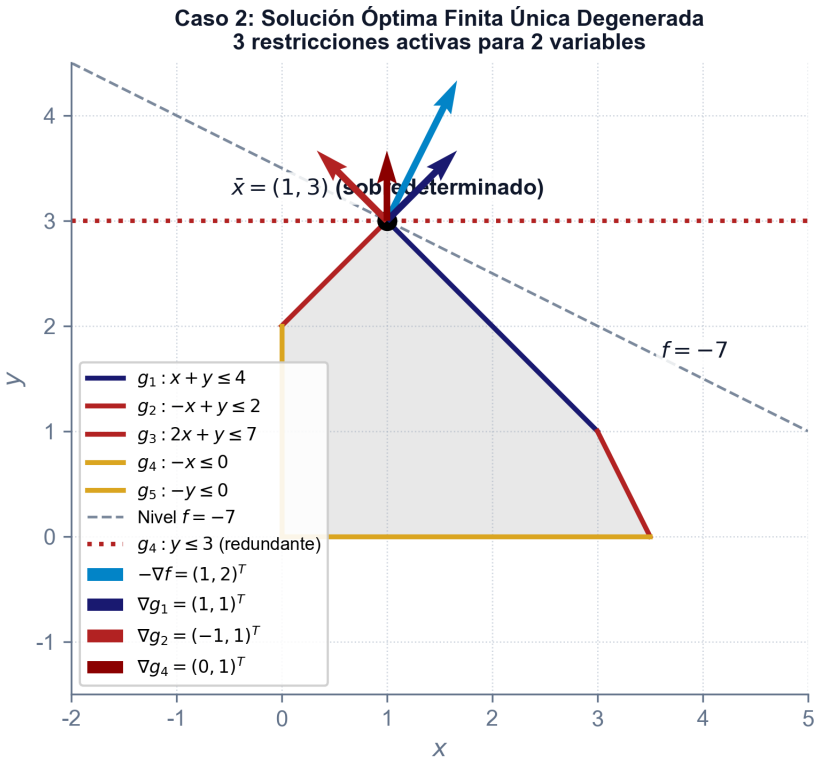

Figura 5.3: Caso 2: Solución óptima finita única degenerada

Caso 3: El problema tiene múltiples soluciones no degeneradas
Se modifica la función objetivo a $f(x, y) = -x - y$, manteniendo las tres restricciones originales:

$$\begin{aligned} \min_{x,y \in \mathbb{R}} \quad & -x - y \\ \text{sujeto a} \quad & x + y - 4 \leq 0 \quad (g_1) \\ & -x + y - 2 \leq 0 \quad (g_2) \\ & 2x + y - 7 \leq 0 \quad (g_3) \\ & x, y \geq 0 \end{aligned}$$

El vector opuesto de gradiente es $-\nabla f = (1, 1)^T$, paralelo al gradiente de la restricción $\nabla g_1 = (1, 1)^T$. Como muestra la Figura 5.4, el conjunto de soluciones óptimas primales es el segmento continuo entre $(1, 3)$ y $(3, 1)$. El problema primal admite **múltiples soluciones óptimas finitas**.
En los puntos interiores de la arista óptima, la única restricción activa es g_1, siendo $u_1^* = 1$ y el resto nulos. Al analizar los vértices extremos: - En $(1, 3)$: convergen g_1 y g_2, pero el multiplicador asociado a g_2 es nulo ($u_2^* = 0$). - En $(3, 1)$: convergen g_1 y g_3, pero el

multiplicador asociado a g_3 es nulo ($u_3^* = 0$).
Por tanto, la solución del dual tendrá a lo sumo una variable no nula ($u_1 = 1$), demostrando que **el problema dual tiene al menos una solución degenerada**.

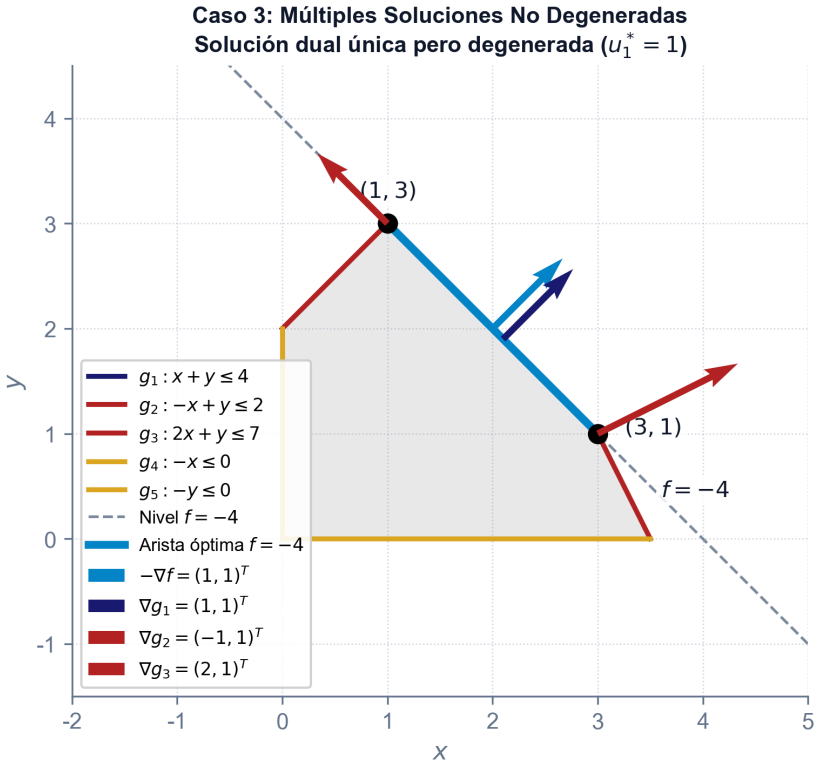

Figura 5.4: Caso 3: Múltiples soluciones no degeneradas

Caso 4: El problema tiene múltiples soluciones y al menos una es degenerada
Se minimiza $f(x, y) = -x - y$ incluyendo la restricción redundante $g_4(x, y) = y - 3 \leq 0$:

$$\begin{aligned} \min_{x,y \in \mathbb{R}} \quad & -x - y \\ \text{sujeto a} \quad & x + y - 4 \leq 0 \quad (g_1) \\ & -x + y - 2 \leq 0 \quad (g_2) \\ & 2x + y - 7 \leq 0 \quad (g_3) \\ & y - 3 \leq 0 \quad (g_4 \text{ redundante}) \\ & x, y \geq 0 \end{aligned}$$

Como se ilustra geométricamente en la Figura 5.5, la totalidad del segmento continuo entre los vértices $(1, 3)$ y $(3, 1)$ constituye el conjunto de soluciones óptimas primales (todas las combinaciones convexas de ambos vértices).

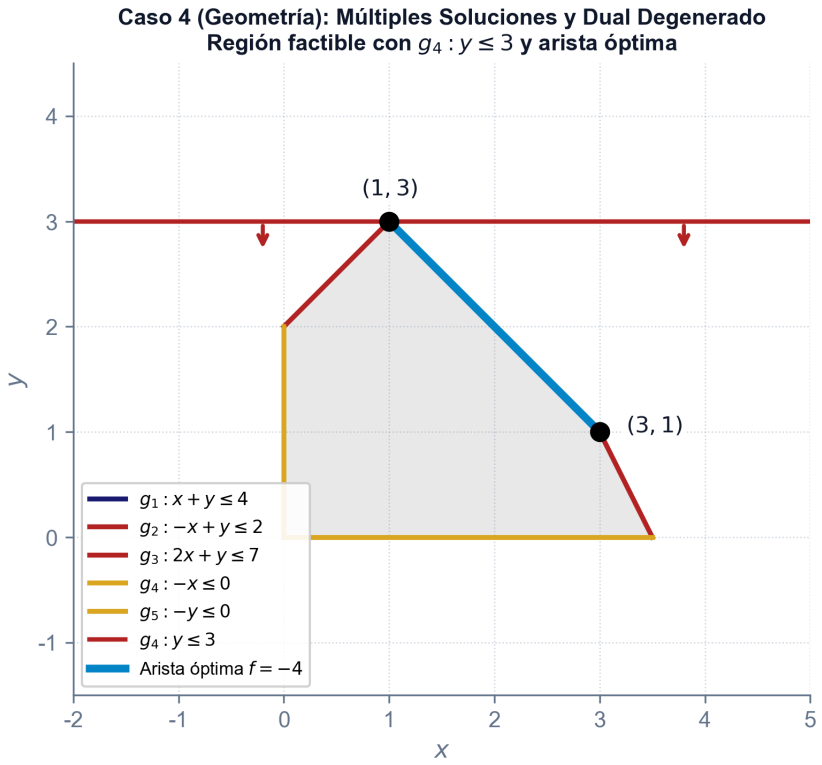

Figura 5.5: Caso 4 (Geometría): Región factible con arista óptima entre (1,3) y (3,1)

Sin embargo, al analizar la estructura dual en la Figura 5.6: - La solución del dual asociada al vértice $(1, 3)$ es **degenerada**, ya que en él convergen tres restricciones activas (g_1, g_2, g_4), lo que genera sobredeterminación geométrica y requiere dos multiplicadores nulos ($u_2 = 0$ y $u_4 = 0$). - Las soluciones asociadas a los puntos interiores del segmento óptimo no son degeneradas, pues por hipótesis la matriz de restricciones activas en el interior mantiene rango máximo.
Por tanto, como en el caso anterior, **el problema dual tiene solución degenerada**, con la particularidad de que en el vértice $(1, 3)$ existen dos multiplicadores nulos (u_2 y u_4).

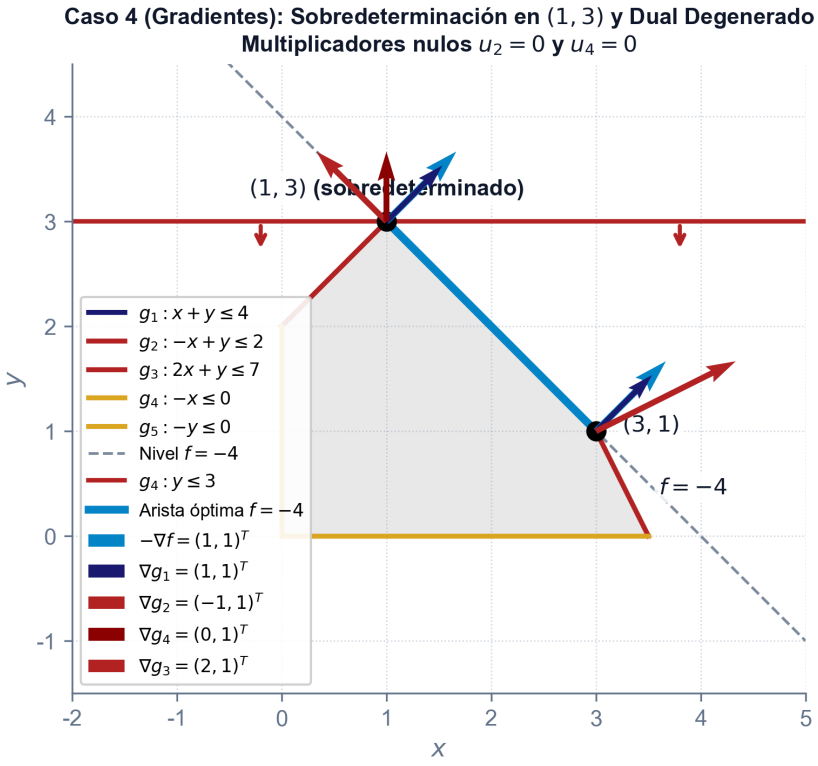

Figura 5.6: Caso 4 (Gradientes): Sobredeterminación en (1,3) y multiplicadores nulos duales

Caso 5: El problema tiene solución no acotada
Se elimina la restricción superior g_1:

$$\begin{aligned} \min_{x,y\in\mathbb{R}} \quad & -x - y \\ \text{sujeto a} \quad & -x + y - 2 \leq 0 \quad (g_2) \\ & 2x + y - 7 \leq 0 \quad (g_3) \\ & x, y \geq 0 \end{aligned}$$

El valor objetivo decrece hacia $-\infty$ sobre un rayo de recesión. Ningún punto verifica las condiciones KKT. Por tanto, como muestra la Figura 5.7, **el problema dual no tiene solución (es no factible)**.

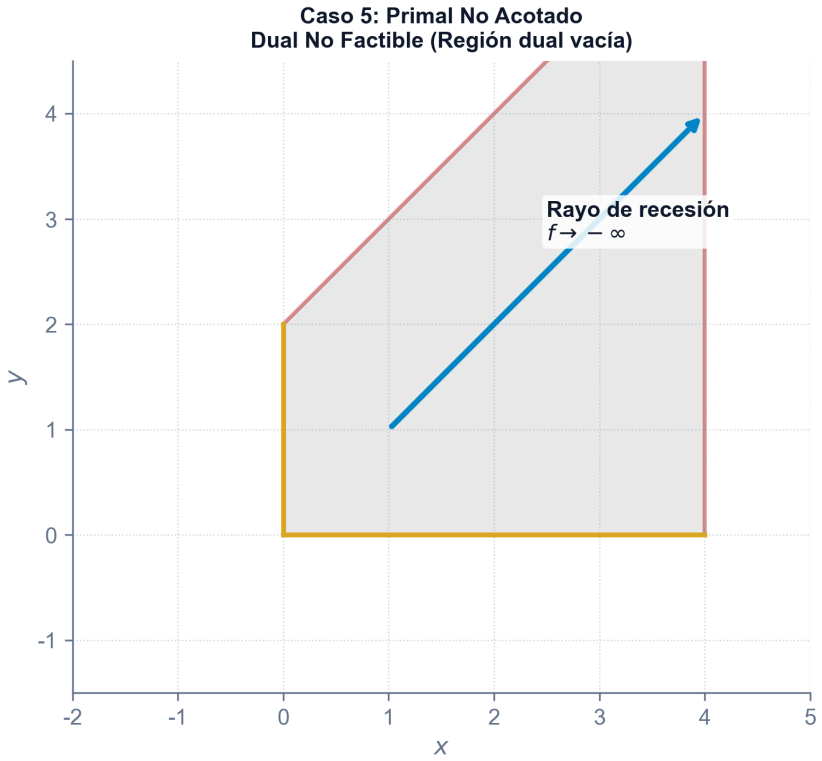

Figura 5.7: Caso 5: Primal no acotado

Caso 6: El problema es no factible
Se definen restricciones contradictorias que generan una región vacía:

$$\begin{aligned} \min_{x,y\in\mathbb{R}} \quad & -x-2y \\ \text{sujeto a} \quad & x+y-1\leq 0 \\ & -x-y+3.5\leq 0 \\ & x,y\geq 0 \end{aligned}$$

La región factible primal es vacía (Figura 5.8). Aplicando KKT al dual, este no puede poseer solución óptima finita, concluyendo que **el problema dual es no factible o tiene solución no acotada**.

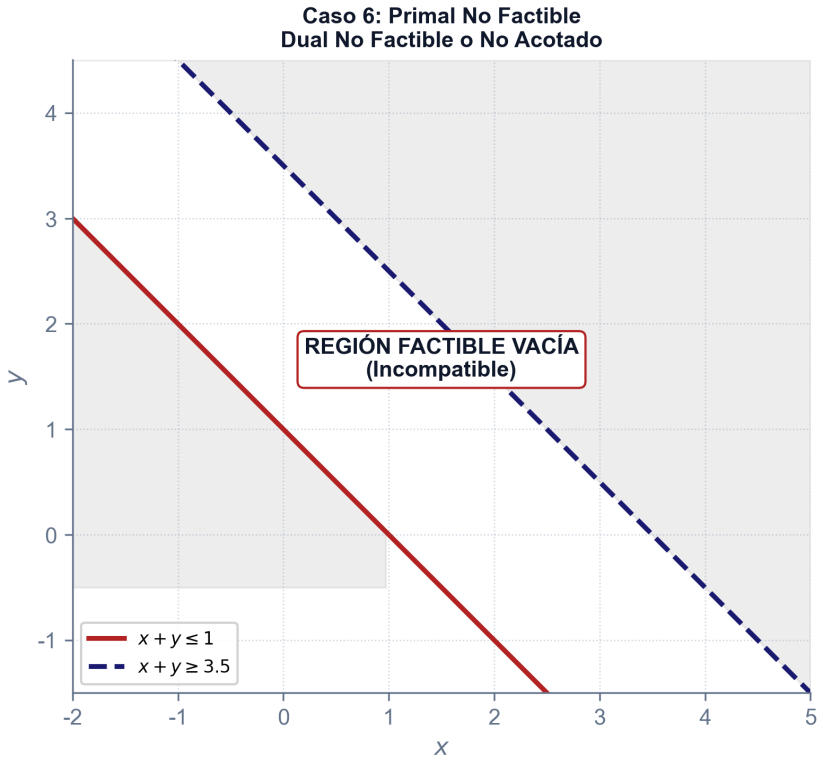

Figura 5.8: Caso 6: Primal no factible

En síntesis, el análisis geométrico y analítico por casos permite establecer las siguientes relaciones de equivalencia fundamentales entre las propiedades del problema primal y de su correspondiente problema dual:

- Si el problema primal posee una solución óptima finita **única y degenerada**, entonces el problema dual posee **múltiples soluciones óptimas**.
- Si el problema primal posee **múltiples soluciones óptimas**, entonces el problema dual posee una solución óptima **degenerada**.

Dado que la dualidad en programación lineal constituye una propiedad involutiva (el problema dual del dual coincide algebraicamente con el primal original), se obtiene el resultado recíproco de caracterización global:

i Proposición: Equivalencia de dualidad entre degeneración y múltiples óptimos

Dado un problema de optimización lineal y su correspondiente problema dual asociado, uno de los dos problemas posee una solución óptima finita **degenerada** si y solo si el otro problema posee **múltiples puntos óptimos**.

La siguiente tabla sintetiza la matriz de correspondencia completa entre los escenarios de optimalidad y existencialidad del problema primal y del problema dual:

Estado del Problema Primal	Estado del Problema Dual Asociado
Óptimo Único No Degenerado	Óptimo Único No Degenerado
Óptimo Único Degenerado	Múltiples Soluciones Óptimas
Múltiples Soluciones Óptimas	Óptimo Único Degenerado
No Acotado ($f \to -\infty$)	No Factible (Región Dual Vacía)
No Factible (Región Primal Vacía)	No Factible o No Acotado

5.2. Programación cuadrática (QP)

La **Programación Cuadrática** (QP, por sus siglas en inglés, *Quadratic Programming*) constituye una clase fundamental de optimización no lineal donde la función objetivo es una expresión de segundo grado (cuadrática) y las restricciones que delimitan la región factible son estrictamente afines o lineales de igualdad y desigualdad.

Consideremos el modelo estándar general de optimización cuadrática, habitualmente denotado por (C):

$$\begin{aligned} \min_{x \in \mathbb{R}^n} \quad & f(x) = c^T x + \frac{1}{2} x^T Q x \\ \text{sujeto a} \quad & Ax \geq b \\ & x \geq 0 \end{aligned} \tag{C}$$

donde $x \in \mathbb{R}^n$ es el vector de variables de decisión, $c \in \mathbb{R}^n$ representa el vector de costes lineales, $Q \in \mathbb{R}^{n \times n}$ es una matriz cuadrada simétrica ($Q = Q^T$) que recoge los coeficientes cuadráticos y las interacciones cruzadas entre variables, $A \in \mathbb{R}^{m \times n}$ es la matriz de coeficientes de las m restricciones, y $b \in \mathbb{R}^m$ es el vector de términos independientes o términos independientes. La región factible $S = \{x \in \mathbb{R}^n : Ax \geq b,\ x \geq 0\}$ viene dada por la intersección finita de semiespacios cerrados, constituyendo por tanto un conjunto **convexo y poliédrico**.

> **i** Observación: Interpretación geométrica de la función objetivo cuadrática
>
> Cuando la matriz Q es definida positiva ($Q \succ 0$), la función cuadrática $f(x)$ posee un único mínimo libre no restringido en $x^0 = -Q^{-1}c$. Sus curvas de nivel $f(x) = k$ forman elipsoides concéntricos centrados en x^0. Desde una perspectiva geométrica, resolver el problema (C) equivale a encontrar el punto del poliedro factible S más cercano a x^0 según la métrica inducida por la matriz Q.

5.2.1. Derivación formal del sistema KKT

Para obtener las condiciones KKT del modelo (C), reescribimos en primer lugar las restricciones en la forma canónica ≤ 0:

$$b - Ax \leq 0, \quad -x \leq 0$$

Asociamos a las m restricciones generales de desigualdad $Ax \geq b$ un vector de multiplicadores duales $u = (u_1, \ldots, u_m)^T \geq 0$, y a las n restricciones de no negatividad de las variables $x \geq 0$ un vector de multiplicadores de holgura duales $v = (v_1, \ldots, v_n)^T \geq 0$. La función Lagrangiana extendida del problema adopta la forma:

$$L(x, u, v) = c^T x + \frac{1}{2} x^T Q x + u^T (b - Ax) - v^T x$$

Derivando parcialmente la Lagrangiana con respecto al vector primal x e imponiendo el sistema completo de estacionariedad, factibilidad y holgura complementaria, se obtiene el sistema KKT formal estructurado en tres bloques fundamentales:

1. **Condiciones de factibilidad primal**:
   - **Factibilidad de las restricciones afines generales ($b - Ax \leq 0$)**: Exige que la solución x satisfaga simultáneamente la totalidad de las m restricciones generales de desigualdad $Ax \geq b$.
   - **Factibilidad de no negatividad de las variables ($x \geq 0$)**: Garantiza que el vector de variables de decisión $x \in \mathbb{R}^n$ pertenezca al ortante no negativo.
2. **Condiciones de factibilidad dual y estacionariedad**:
   - **Estacionariedad de la función Lagrangiana ($\nabla_x L(x, u, v) = c + Qx - A^T u - v = 0$)**: Representa el equilibrio vectorial en el punto óptimo. Esta ecuación de factibilidad dual establece que el gradiente de la función objetivo cuadrática, $\nabla f(x) = c + Qx$, debe poder expresarse como combinación lineal no negativa de los gradientes de las restricciones activas, $A^T u + v$.
   - **No negatividad de los multiplicadores duales ($u \geq 0, v \geq 0$)**: Asegura que los multiplicadores duales $u \in \mathbb{R}^m$ asociados a las restricciones generales de desigualdad y $v \in \mathbb{R}^n$ asociados a las barreras de no negatividad orienten los vectores normales en sentido opuesto a las direcciones de descenso.
3. **Condiciones de holgura complementaria**:
   - **Complementariedad de las restricciones generales ($u_i(b_i - a^i x) = 0, \forall i = 1, \ldots, m$)**: Establece que si una restricción general es inactiva ($b_i - a^i x < 0$), su multiplicador dual o precio sombra asociado debe ser nulo ($u_i = 0$). Recíprocamente, si el multiplicador es estrictamente positivo ($u_i > 0$), la restricción debe verificarse como igualdad estricta ($a^i x = b_i$).

- **Complementariedad de no negatividad** ($v_i x_i = 0, \forall i = 1, \dots, n$): Garantiza que si una variable de decisión es positiva ($x_i > 0$), su holgura dual asociada debe anularse ($v_i = 0$), mientras que si la variable se ubica en su límite inferior ($x_i = 0$), la holgura dual $v_i \geq 0$ puede tomar valores positivos.

donde a^i denota la fila i-ésima de la matriz de coeficientes A.

Cuando la función objetivo $f(x)$ es convexa (propiedad que se verifica si y solo si la matriz Q es **semidefinida positiva**, $Q \succeq 0$, es decir, $x^T Q x \geq 0$ para todo $x \in \mathbb{R}^n$), las condiciones necesarias de Karush-Kuhn-Tucker resultan también **suficientes** para certificar la optimalidad global.

Proposición: Suficiencia de las condiciones KKT en QP convexa

Si la matriz de términos cuadráticos Q es semidefinida positiva ($Q \succeq 0$), el problema de programación cuadrática (C) es convexo. En consecuencia, **cualquier solución que satisfaga el sistema de condiciones KKT es una solución óptima global del problema (C)**.

Sin embargo, si la convexidad no se satisface, el panorama analítico cambia sustancialmente:

Advertencia: Importancia crítica de la convexidad ($Q \succeq 0$)

Si la matriz Q no es semidefinida positiva (posee autovalores estrictamente negativos), el problema cuadrático deja de ser convexo. En tal escenario, las condiciones KKT son únicamente necesarias pero no suficientes, pudiendo caracterizar máximos locales o puntos de silla, y los algoritmos basados en pivotes lineales como el de Wolfe no garantizan la convergencia al óptimo global.

5.2.2. Transformación mediante variables de holgura y linealidad del sistema

Para transformar las desigualdades primales $b - Ax \leq 0$ en ecuaciones lineales manejables algebraicamente por algoritmos de pivote, introducimos un vector de **variables primales de holgura** no negativas $y = (y_1, \dots, y_m)^T \geq 0$. De este modo:

$$b - Ax \leq 0 \iff b - Ax + y = 0, \quad \text{con } y \geq 0$$

Analíticamente, se verifica la equivalencia directa entre el exceso de la restricción y el valor de la variable de holgura:

$$b_i - a^i x < 0 \iff y_i > 0, \quad \forall i = 1, \dots, m$$

Sustituyendo esta relación en la primera condición de holgura complementaria, el producto escalar $u_i(b_i - a^i x) = 0$ equivale a la condición de ortogonalidad escalar:

$$u_i y_i = 0, \quad \forall i = 1, \dots, m$$

Dado que todas las variables del sistema son estrictamente no negativas ($u, v, x, y \geq 0$), la anulación de cada producto individual $u_i y_i = 0$ y $v_i x_i = 0$ para todo i equivale a exigir que la suma de sus productos escalares se anule globalmente:

$$\begin{cases} u_i y_i = 0, & \forall i = 1, \dots, m \\ v_i x_i = 0, & \forall i = 1, \dots, n \end{cases} \iff \sum_{i=1}^{m} u_i y_i + \sum_{i=1}^{n} v_i x_i = 0 \iff u^T y + v^T x = 0$$

Agrupando el conjunto de relaciones obtenidas, el sistema KKT de la programación cuadrática convexa (C) se expresa inicialmente en la siguiente forma algebraica estandarizada:

$$\begin{aligned} b - Ax + y &= 0 \\ c + Qx - A^T u - v &= 0 \\ x, y, u, v &\geq 0 \\ u^T y + v^T x &= 0 \end{aligned}$$

Este planteamiento formal revela una propiedad matemática fundamental para la resolución computacional: excepto por el último conjunto de restricciones no lineal de holgura complementaria ($u^T y + v^T x = 0$), todo el resto del sistema de ecuaciones (factibilidad primal $b - Ax + y = 0$ y estacionariedad $c + Qx - A^T u - v = 0$) es **estrictamente lineal**.

5.2.3. Algoritmo del Símplex de Wolfe con regla de entrada restringida

Como consecuencia de esta estructura parcialmente lineal, es posible resolver el sistema KKT (y, por tanto, hallar la solución óptima del problema cuadrático convexo C) adaptando las operaciones matriciales de pivote del algoritmo del Símplex lineal.

Para lograr este objetivo, se siguen los siguientes tres pasos:

1. **Se relaja la restricción de holgura complementaria** $u^T y + v^T x = 0$.
2. **Se añaden variables artificiales** no negativas $z = (z_1, \dots, z_n)^T \geq 0$ al conjunto de ecuaciones de estacionariedad (Factibilidad dual 1), obteniendo $c + Qx - A^T u - v + z = 0$ con $z \geq 0$.
3. **Se intenta que estas variables artificiales tomen el valor cero** resolviendo el siguiente problema de programación lineal auxiliar:

$$\begin{aligned} \text{mín} \quad & \sum_{i=1}^{n} z_i \\ \text{sujeto a} \quad & b - Ax + y = 0 \\ & c + Qx - A^T u - v + z = 0 \\ & x, y, u, v, z \geq 0 \end{aligned}$$

Para garantizar que la solución del problema de programación lineal auxiliar sea una solución válida y exacta del problema cuadrático original (C), hay que modificar el criterio de selección de la variable candidata a entrar en la base del Símplex aplicando la **regla de entrada restringida** (*restricted entry rule*) de Wolfe:

- **Regla de complementariedad primal-dual (u_i, y_i)**: La variable multiplicadora dual u_i **no es candidata** a entrar en la base Símplex si su correspondiente variable de holgura primal y_i es básica ($y_i \in$ Base), y viceversa.
- **Regla de complementariedad de no negatividad (v_j, x_j)**: La variable de holgura dual v_j **no es candidata** a entrar en la base Símplex si la correspondiente variable primal x_j es básica ($x_j \in$ Base), y viceversa.

Al resolver el problema de programación lineal auxiliar bajo la regla de entrada restringida, se obtienen los siguientes dos criterios de caracterización global:

- **Si el valor óptimo de este problema es 0** ($\text{mín} \sum z_i = 0$), todas las variables artificiales han abandonado la base ($z^* = 0$). Como la regla de pivote restringido impide que variables complementarias formen parte de la base simultáneamente, la solución básica resultante satisface la complementariedad $u^{*T} y^* + v^{*T} x^* = 0$, por lo que el vector x^* **es la solución óptima para (C)**.
- **Por el contrario, si es estrictamente positivo** ($\text{mín} \sum z_i > 0$), resulta imposible reducir las variables artificiales a cero respetando la regla de entrada restringida. En tal caso, la condición de complementariedad no puede satisfacerse de forma simultánea con la factibilidad, por lo que **el problema (C) NO tiene solución** (es no factible).

> **i** Nota: Garantía de convergencia finita del algoritmo de Wolfe
>
> Puesto que el algoritmo del Símplex modificado por Wolfe opera sobre el conjunto de soluciones básicas factibles del sistema de ecuaciones lineales ampliado (el cual consta de un número finito de bases posibles) y la función objetivo auxiliar $\sum z_i$ decrece de manera monótona a cada paso de pivote, se garantiza que el algoritmo finaliza en un número finito de iteraciones.

Para fijar los conceptos teóricos presentados y comprender de forma intuitiva el funcionamiento algebraico y geométrico del algoritmo del Símplex de Wolfe, a continuación se resuelve detalladamente un problema completo de programación cuadrática convexa en dos dimensiones.

Ejemplo: Resolución completa mediante el algoritmo del símplex de Wolfe

Enunciado del problema: Consideremos el problema de optimización cuadrática en el que se busca minimizar la distancia euclídea al cuadrado desde las variables (x_1, x_2) al punto objetivo $(4, 4)$, sobre una región factible poliédrica $S \subset \mathbb{R}^2$:

$$\begin{array}{lll} \min\limits_{x_1,x_2\in\mathbb{R}} & (x_1-4)^2+(x_2-4)^2 & \\ \text{sujeto a} & x_1+x_2 \leq 4 & \\ & -x_1+x_2 \leq 2 & \equiv \\ & 2x_1+x_2 \leq 7 & \\ & x_1, x_2 \geq 0 & \end{array} \qquad \begin{array}{lll} \min\limits_{x_1,x_2\in\mathbb{R}} & (x_1-4)^2+(x_2-4)^2 \\ \text{sujeto a} & -4+x_1+x_2 \leq 0 \\ & -2-x_1+x_2 \leq 0 \\ & -7+2x_1+x_2 \leq 0 \\ & x_1, x_2 \geq 0 \end{array}$$

Formulación del problema auxiliar del Símplex de Wolfe: Identificamos la matriz cuadrática $Q = \begin{pmatrix} 2 & 0 \\ 0 & 2 \end{pmatrix}$ (estrictamente definida positiva, garantizando la convexidad del problema), el vector lineal $c = (-8, -8)^T$, la matriz de coeficientes $A = \begin{pmatrix} -1 & -1 \\ 1 & -1 \\ -2 & -1 \end{pmatrix}$ y el vector de términos independientes $b = (-4, 2, -7)^T$.
Al introducir las variables primales de holgura $y_1, y_2, y_3 \geq 0$, los multiplicadores duales $u_1, u_2, u_3 \geq 0$, las holguras duales $v_1, v_2 \geq 0$ y las variables artificiales $z_1, z_2 \geq 0$, el problema de programación lineal auxiliar a minimizar resulta:

$$\begin{array}{lll} \min & z_1+z_2 \\ \text{sujeto a} & -4+x_1+x_2+y_1=0 \\ & -2-x_1+x_2+y_2=0 \\ & -7+2x_1+x_2+y_3=0 \\ & 2(x_1-4)+u_1-u_2+2u_3-v_1+z_1=0 \\ & 2(x_2-4)+u_1+u_2+u_3-v_2+z_2=0 \\ & x_1, x_2, y_1, y_2, y_3, u_1, u_2, u_3, v_1, v_2, z_1, z_2 \geq 0 \end{array}$$

reescribiendo las ecuaciones de estacionariedad como $2x_1 + u_1 - u_2 + 2u_3 - v_1 + z_1 = 8$ y $2x_2 + u_1 + u_2 + u_3 - v_2 + z_2 = 8$.
Representación gráfica de la solución: Como se ilustra geométricamente en la Figura 5.9, las curvas de nivel de la función objetivo representan círculos concéntricos centrados en el mínimo libre no restringido $(4, 4)$. La solución óptima del problema corresponde al punto de la región factible S más próximo a $(4, 4)$, alcanzándose la tangencia en el punto $\bar{x} = (2, 2)$ con un valor objetivo de $f(2, 2) = 8$.

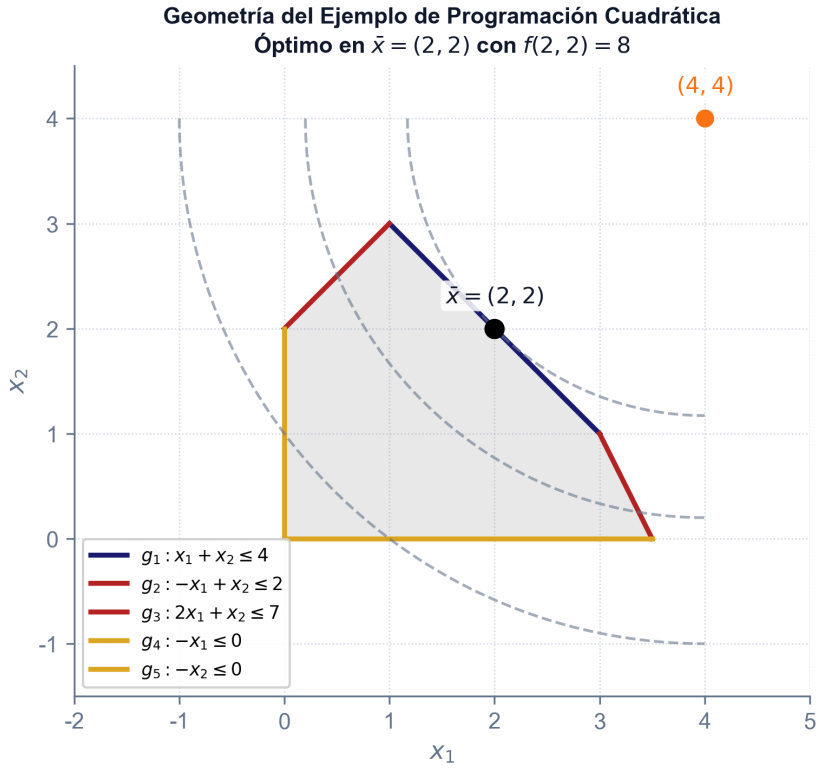

Figura 5.9: Geometría de la región factible y tangencia de la función objetivo cuadrática en el óptimo

Solución matemática del sistema KKT: Al resolver el sistema KKT, la solución exacta resultante para todas las variables primales, duales, de holgura y artificiales es:

$$\begin{aligned} x_1^* &= 2, \quad x_2^* = 2 \\ u_1^* &= 4, \quad u_2^* = 0, \quad u_3^* = 0 \\ y_1^* &= 0, \quad y_2^* = 2, \quad y_3^* = 1 \\ v_1^* &= 0, \quad v_2^* = 0 \\ z_1^* &= 0, \quad z_2^* = 0 \end{aligned}$$

Resolución mediante el Algoritmo del Símplex de Wolfe (Tablas e Interpretación Geométrica):
A continuación se detalla la progresión iterativa de las tablas del Símplex y su correspondiente traslación geométrica sobre la región factible a cada paso.
Iteración 1 (Paso 1: Inicio en el Origen)
En la primera iteración, la solución básica inicial parte con las variables primales en el origen $x_1 = 0, x_2 = 0$. Las variables primales de holgura absorben los términos independientes

$(y_1 = 4, y_2 = 2, y_3 = 7)$ y las variables artificiales toman el valor $z_1 = 8, z_2 = 8$, dando un coste artificial inicial de $\sum z_i = 16$ y un valor de la función objetivo de distancia $f(0,0) = 32$.

- **Base inicial**: $\{y_1, y_2, y_3, z_1, z_2\}$, **Objetivo artificial**: $z_1 + z_2 = 8 + 8 = 16$.
- **Criterio de entrada**: Los costes reducidos negativos son $x_1(-2)$, $x_2(-2)$, $u_1(-2)$ y $u_3(-3)$.
- **Regla de complementariedad dual**: Las variables u_1 y u_3 están bloqueadas porque sus variables primales asociadas y_1, y_3 forman parte de la base actual.
- **Pivote**: Seleccionamos la variable candidata $x_2 \downarrow$. Por el criterio del cociente mínimo, abandona la base $y_2 \uparrow$ con elemento pivote **1**.

Base	Sol.	x_1	x_2	y_1	y_2	y_3	u_1	u_2	u_3	v_1	v_2	z_1	z_2
y_1	4	1	1	1	0	0	0	0	0	0	0	0	0
y_2	2	-1	**1**	0	1	0	0	0	0	0	0	0	0
y_3	7	2	1	0	0	1	0	0	0	0	0	0	0
z_1	8	2	0	0	0	0	1	-1	2	-1	0	1	0
z_2	8	0	2	0	0	0	1	1	1	0	-1	0	1
Coste	16	-2	-2	0	0	0	-2	0	-3	1	1	0	0

Geométricamente, el algoritmo se encuentra en el origen $\bar{x} = (0, 0)$ con un coste artificial de $\sum z_i = 16$ y valor $f(0, 0) = 32$.

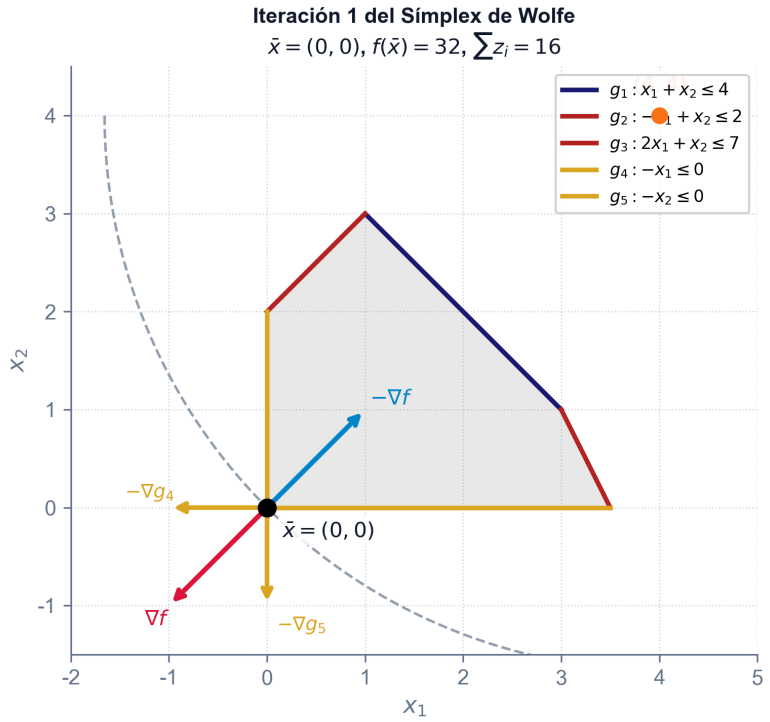

Figura 5.10: Interpretación geométrica de la Iteración 1 en el origen (0,0)

Iteración 2 (Paso 2: Avance sobre el eje X_2)
En la segunda iteración, la entrada de x_2 en la base desplaza la solución a lo largo del eje vertical hasta alcanzar el vértice $\bar{x} = (0, 2)$. En esta posición, la segunda restricción $-x_1 + x_2 \leq 2$ se vuelve activa ($y_2 = 0$), reduciendo el valor de la función objetivo a $f(0, 2) = 20$ y la suma artificial a $\sum z_i = 12$.

- **Base**: $\{y_1, x_2, y_3, z_1, z_2\}$, **Objetivo artificial**: 12.
- **Criterio de entrada**: Entra la variable primal $x_1 \downarrow$ (coste reducidos -4). Las variables duales u_1, u_3 continúan bloqueadas por $y_1, y_3 \in$ Base.
- **Pivote**: Abandona la base $y_1 \uparrow$ en la fila 1 con pivote **2**.

Base	Sol.	x_1	x_2	y_1	y_2	y_3	u_1	u_2	u_3	v_1	v_2	z_1	z_2
y_1	2	**2**	0	1	-1	0	0	0	0	0	0	0	0
x_2	2	-1	1	0	1	0	0	0	0	0	0	0	0
y_3	5	3	0	-1	-1	1	0	0	0	0	0	0	0
z_1	8	2	0	0	0	0	1	-1	2	-1	0	1	0
z_2	4	2	0	0	-2	0	1	1	1	0	-1	0	1
Coste	12	-4	0	0	2	0	-2	0	-3	1	1	0	0

Geométricamente, el punto se desplaza sobre el eje X_2 hasta el vértice $\bar{x} = (0, 2)$, donde se activa la restricción $-x_1 + x_2 \leq 2$ ($y_2 = 0$).

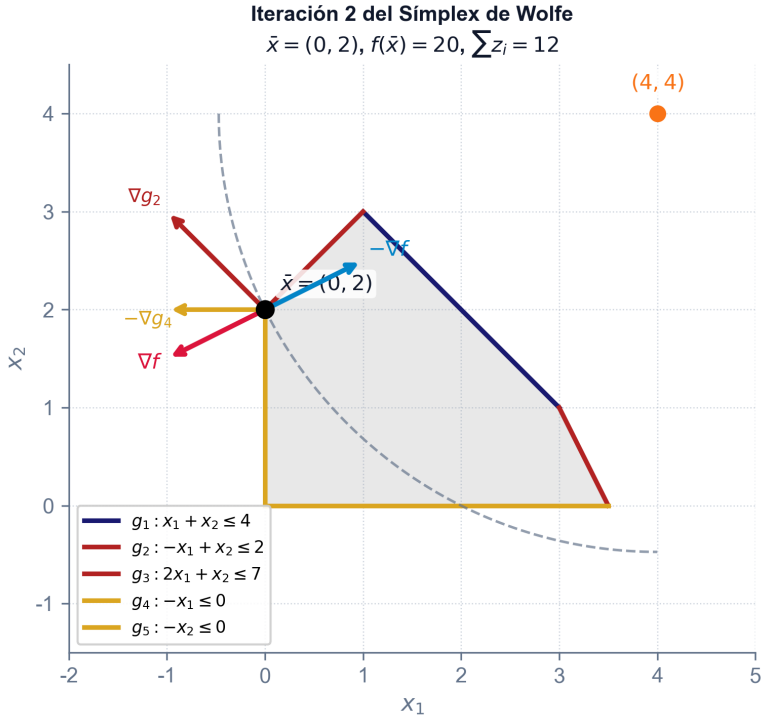

Figura 5.11: Interpretación geométrica de la Iteración 2 en el vértice (0,2)

Iteración 3 (Paso 3: Desplazamiento al vértice (1,3) y desbloqueo dual)
En la tercera iteración, al haber salido y_1 de la base en la iteración anterior, se desactiva el bloqueo de holgura complementaria sobre la variable dual u_1, permitiendo su entrada. El punto candidato se desplaza sobre la arista del poliedro $-x_1 + x_2 = 2$ hasta situarse en el vértice $\bar{x} = (1, 3)$, activando simultáneamente la restricción $x_1 + x_2 \leq 4$ ($y_1 = 0$), con $f(1, 3) = 10$ y una suma artificial de $\sum z_i = 8$.

- **Base**: $\{x_1, x_2, y_3, z_1, z_2\}$, **Objetivo artificial**: 8.
- **Criterio de entrada**: Al salir y_1 de la base en la iteración anterior, la variable dual $u_1 \downarrow$ queda libre y entra en la base (coste reducido -2). La variable u_3 sigue bloqueada por $y_3 \in$ Base.
- **Pivote**: Abandona la base la variable artificial $z_2 \uparrow$ en la fila 5 con elemento pivote **1**.

Base	Sol.	x_1	x_2	y_1	y_2	y_3	u_1	u_2	u_3	v_1	v_2	z_1	z_2
x_1	1	1	0	$1/2$	$-1/2$	0	0	0	0	0	0	0	0
x_2	3	0	1	$1/2$	$1/2$	0	0	0	0	0	0	0	0
y_3	2	0	0	$-5/2$	$1/2$	1	0	0	0	0	0	0	0
z_1	6	0	0	-1	1	0	1	-1	2	-1	0	1	0
z_2	2	0	0	-1	-1	0	**1**	1	1	0	-1	0	1
Coste	8	0	0	2	0	0	-2	0	-3	1	1	0	0

Geométricamente, el candidato avanza sobre el borde $-x_1 + x_2 = 2$ hasta alcanzar el vértice $\bar{x} = (1, 3)$, donde se activa adicionalmente $x_1 + x_2 \leq 4$ ($y_1 = 0$).

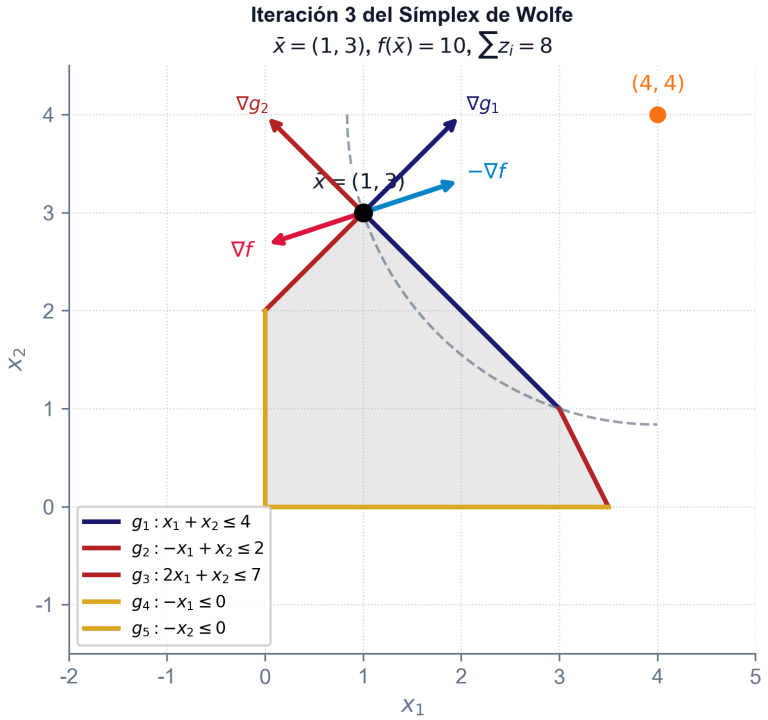

Figura 5.12: Interpretación geométrica de la Iteración 3 en el vértice (1,3)

Iteración 4 (Paso 4: Ajuste de tensión dual en (1,3))
En la cuarta iteración, la solución primal se mantiene estática en el vértice $\bar{x} = (1, 3)$, pero se produce un reajuste algebraico en las variables duales. La variable u_1 entra formalmente en la base con valor $u_1 = 2$, eliminando la primera variable artificial z_2 y reduciendo la función objetivo auxiliar a $\sum z_i = 4$.

- **Base**: $\{x_1, x_2, y_3, z_1, u_1\}$, **Objetivo artificial**: 4.
- **Criterio de entrada**: Entra la variable de holgura $y_2 \downarrow$ (coste reducido -2).
- **Pivote**: Sale de la base la última variable artificial $z_1 \uparrow$ en la fila 4 con pivote **2**.

Base	Sol.	x_1	x_2	y_1	y_2	y_3	u_1	u_2	u_3	v_1	v_2	z_1	z_2
x_1	1	1	0	1/2	−1/2	0	0	0	0	0	0	0	0
x_2	3	0	1	1/2	1/2	0	0	0	0	0	0	0	0
y_3	2	0	0	−5/2	1/2	1	0	0	0	0	0	0	0
z_1	4	0	0	0	**2**	0	0	−2	1	−1	−1	1	−1
u_1	2	0	0	−1	−1	0	1	1	1	0	−1	0	1
Coste	4	0	0	0	−2	0	0	2	−1	1	−1	0	2

Geométricamente, el punto en el espacio primal permanece en el vértice $\bar{x} = (1, 3)$ mientras se ajusta la tensión del multiplicador dual ($u_1 = 2$).

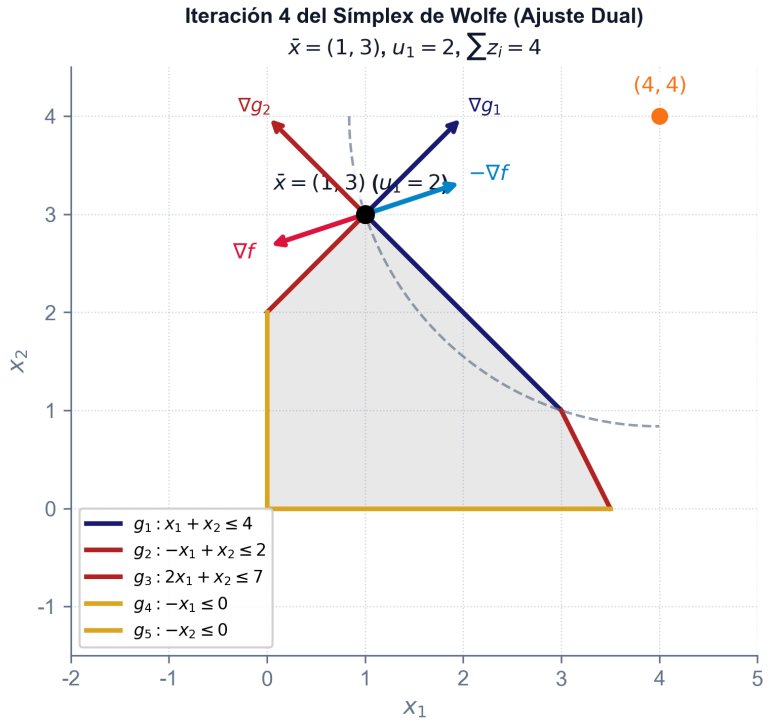

Figura 5.13: Interpretación geométrica de la Iteración 4 (Ajuste Dual en (1,3))

Iteración 5 (Paso 5: Consecución del Óptimo Global y Tangencia en (2,2))
En la quinta iteración, la entrada de la holgura y_2 permite que el punto abandone el vértice $(1, 3)$ y se deslice a lo largo del segmento de la restricción activa $x_1 + x_2 = 4$ hasta el punto $\bar{x} = (2, 2)$. En este punto se alcanza la tangencia con la superficie cuadrática de nivel de la función objetivo, anulando por completo las variables artificiales ($\sum z_i = 0$), fijando el multiplicador dual activo $u_1^* = 4$ y alcanzando el coste mínimo de $f(2, 2) = 8$.

- **Base óptima**: $\{x_1, x_2, y_3, y_2, u_1\}$, **Objetivo artificial**: 0.
- **Criterio de parada**: Todas las variables artificiales han salido de la base ($z_1^* = 0, z_2^* = 0$) y no existen costes reducidos negativos viables bajo la regla de entrada restringida.

Base	Sol.	x_1	x_2	y_1	y_2	y_3	u_1	u_2	u_3	v_1	v_2	z_1	z_2
x_1	2	1	0	1/2	0	0	0	−1/2	1/4	−1/4	1/4	1/4	−1/4
x_2	2	0	1	1/2	0	0	0	1/2	−1/4	1/4	−1/4	−1/4	1/4
y_3	1	0	0	−5/2	0	1	0	1/2	−1/4	1/4	−1/4	−1/4	1/4
y_2	2	0	0	0	1	0	0	−1	1/2	−1/2	1/2	1/2	−1/2
u_1	4	0	0	−1	0	0	1	0	3/2	−1/2	−1/2	1/2	1/2
Coste	0	0	0	0	0	0	0	0	0	0	0	1	1

Resultado final: El punto se desliza sobre la restricción activa $x_1 + x_2 = 4$ ($y_1 = 0$) hasta alcanzar el punto óptimo global $\bar{x} = (2, 2)$ con $u_1^* = 4$ y valor mínimo de la función objetivo $f(2, 2) = 8$.

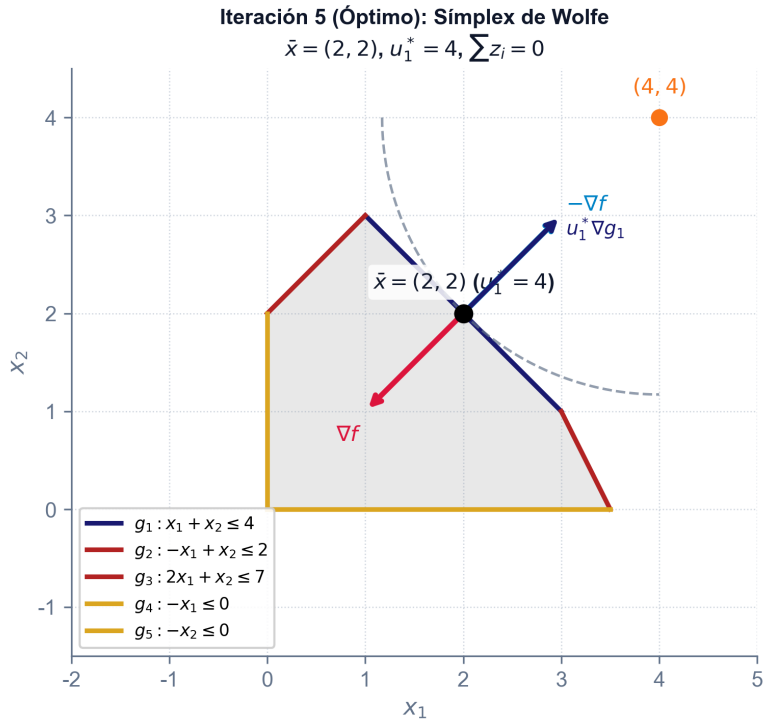

Figura 5.14: Interpretación geométrica de la Iteración 5 Óptima en (2,2)

Análisis Geométrico de la Trayectoria Completa del Símplex de Wolfe
La secuencia de pivotes del algoritmo del Símplex de Wolfe dibuja una trayectoria geométrica precisa sobre el plano $\mathbb{R}^2$:

1. **Iteración 1**: Arranca en el origen $(0, 0)$.
2. **Iteración 2**: La variable x_2 entra en la base, desplazando el punto sobre el eje Y hasta el vértice $(0, 2)$, donde se activa la restricción $-x_1 + x_2 \leq 2$ ($y_2 = 0$).
3. **Iteración 3**: La variable x_1 entra en la base, avanzando por el borde de la restricción $-x_1 + x_2 = 2$ hasta el vértice $(1, 3)$, donde se activa además $x_1 + x_2 \leq 4$ ($y_1 = 0$).
4. **Iteración 4**: Al anularse y_1, se desbloquea la entrada del multiplicador dual u_1. El punto geométrico permanece en $(1, 3)$ mientras se ajusta la tensión dual ($u_1 = 2$).
5. **Iteración 5**: Entra la holgura y_2 (desactivando la restricción $-x_1 + x_2 \leq 2$). El punto se desliza sobre el segmento activo $x_1 + x_2 = 4$ hasta alcanzar el punto más próximo al objetivo $(4, 4)$, situándose en $(2, 2)$ con $u_1^* = 4$.

La trayectoria geométrica global completa sobre el politopo factible se ilustra en la Figura 5.15.

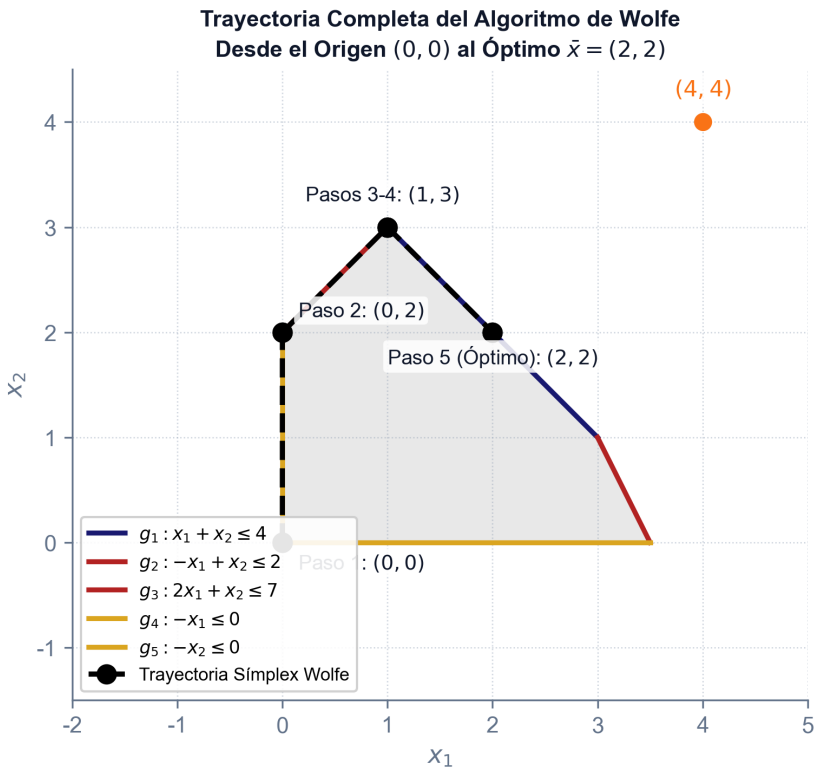

Figura 5.15: Trayectoria del algoritmo del Símplex de Wolfe sobre el politopo factible

5.3. Consideraciones finales

En este tema se ha analizado en profundidad la interconexión matemática existente entre las condiciones de Karush-Kuhn-Tucker (KKT), la teoría de la dualidad en programación lineal y la resolución computacional de problemas de programación cuadrática (QP). Los pilares teóricos y metodológicos fundamentales derivados de este estudio se estructuran a continuación:

1. **Equivalencia entre multiplicadores KKT y variables duales**: La caracterización de optimalidad KKT para problemas de optimización lineal demuestra formalmente que los multiplicadores de Lagrange u_i^* asociados a las restricciones de desigualdad no son meros constructos algebraicos, sino que equivalen exactamente a las variables óptimas del problema dual. Esta correspondencia biunívoca vincula directamente la geometría del politopo primal con el espacio de soluciones del dual.

2. **Interpretación económica y precios sombra**: Los multiplicadores KKT u_i^* representan los precios sombra o costes marginales de oportunidad asociados a las restricciones del sistema. Formalmente, u_i^* cuantifica la tasa de variación marginal en el beneficio o coste óptimo ante un incremento unitario en la término independiente b_i. Las condiciones de holgura complementaria ($u_i^* g_i(x^*) = 0$) aseguran que solo aquellos restricciones activas (restricciones activas con $g_i(x^*) = 0$) presentan un valor marginal positivo ($u_i^* > 0$), mientras que los restricciones inactivas ($g_i(x^*) < 0$) poseen un precio sombra nulo ($u_i^* = 0$).

3. **Estructura matricial y convexidad en programación cuadrática**: Al incorporar términos cuadráticos en la función objetivo mediante una matriz simétrica semidefinida positiva $Q \succeq 0$, el problema mantiene la convexidad, lo que garantiza que cualquier punto que satisfaga las condiciones KKT sea un óptimo global absoluto. Las condiciones KKT de un problema QP adoptan la forma de un sistema de ecuaciones lineales sobre las variables primales x, de holgura y, duales u y de gradiente v, sujeto únicamente a la restricción bilineal de complementariedad.

4. **Fundamento algorítmico del Símplex de Wolfe**: El algoritmo del Símplex de Wolfe adapta el mecanismo de pivotaje de la programación lineal para resolver el sistema KKT de un problema QP convexo imponiendo una regla de entrada restringida. Esta regla prohíbe explícitamente que una variable dual u_i (o v_j) entre en la base si su variable primal complementaria y_i (o x_j) pertenece actualmente a la misma, garantizando el cumplimiento estricto de la holgura complementaria en cada iteración del algoritmo.

5. **Dinámica geométrica primal-dual**: A diferencia del Símplex lineal clásico —que se desplaza de vértice en vértice sobre las esquinas del politopo—, el Símplex de Wolfe recorre la frontera y las caras del conjunto factible S. A lo largo de esta trayectoria, el algoritmo combina desplazamientos en el dominio de las variables primales con ajustes de tensión en el espacio dual hasta situar la solución en el punto exacto de tangencia entre las superficies cuadráticas de nivel y el borde activo de las restricciones.

Parte II

Bloque II: Optimización en redes

6 Grafos y árboles soporte

El análisis y la optimización en redes constituye una de las disciplinas más fértiles y de mayor aplicación práctica en la investigación operativa, la ingeniería de sistemas, la logística y la ciencia de datos moderna. El lenguaje formal de la **teoría de grafos** permite abstraer la estructura matemática subyacente de sistemas complejos caracterizados por un conjunto de entidades interconectadas. Desde la planificación de rutas de transporte aéreo, la gestión del flujo de carga en redes eléctricas o la distribución de datos en internet, hasta el agrupamiento no supervisado (*clustering*) en aprendizaje automático, los grafos proporcionan un marco analítico unificado para modelar, optimizar y extraer conocimiento sobre la conectividad y la topología de la información.

! Objetivos de aprendizaje

Al finalizar este capítulo, serás capaz de:

1. **Definir** formalmente grafos dirigidos y no dirigidos, especificando vecindades, grados de nodos e incidencias de corte.
2. **Diferenciar** rigurosamente entre cadenas, caminos, ciclos y circuitos, así como clasificar la conectividad en redes no dirigidas y la conexidad fuerte/débil en digrafos.
3. **Demostrar** la Fórmula Planar de Euler y caracterizar la topología de grafos planares y bipartitos mediante las construcciones de Dudeney y Kuratowski.
4. **Formular** la representación en memoria mediante matrices de incidencia con la propiedad de Total Unimodularidad (TUM), matrices de adyacencia y la estructura compacta de estrella saliente (*Forward Star*).
5. **Caracterizar** las seis propiedades matemáticas equivalentes que definen la estructura abstracta de los árboles y bosques.
6. **Aplicar** y comparar los algoritmos de Kruskal y Prim para la resolución del problema del Árbol Soporte de Mínimo Peso (MST), y **construir** modelos de agrupamiento jerárquico no supervisado (*Single-Linkage Clustering*) en Python.

6.1. El problema de los puentes de Königsberg (Euler, 1736)

La teoría de grafos nació históricamente en 1736 con la célebre resolución del **Problema de los Puentes de Königsberg** formulado y resuelto por el matemático suizo Leonhard Euler

(Euler 1736). La antigua ciudad de Königsberg (actual Kaliningrado) estaba dividida por el río Pregel en cuatro masas de tierra diferenciadas: la Isla Kneiphof (A), dos orillas principales (B y C) y la región oriental de la bifurcación (D). Estas cuatro regiones estaban interconectadas mediante siete puentes de madera, como se ilustra históricamente en las figuras Figura 6.1, Figura 6.2 y Figura 6.3.

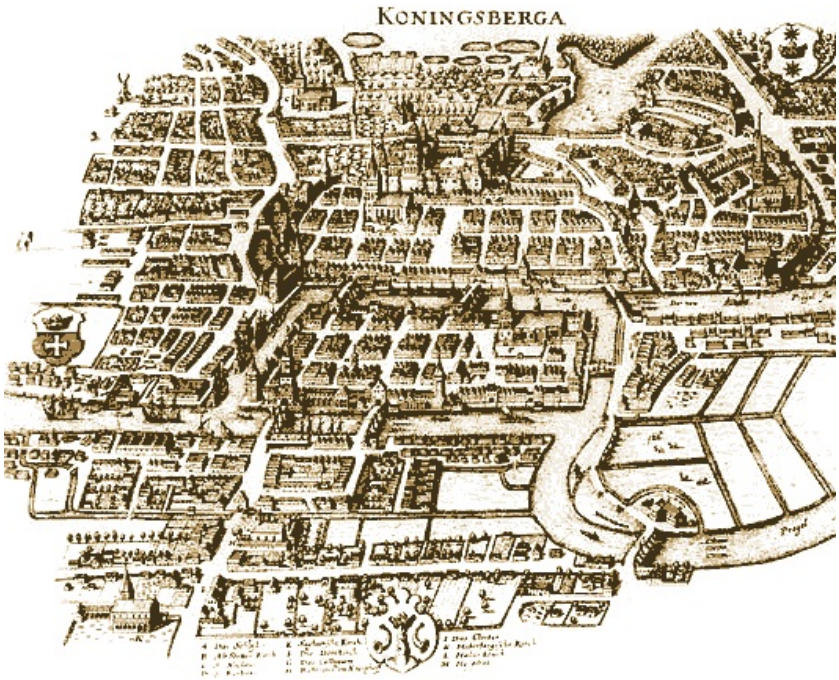

Figura 6.1: Grabado histórico original de la ciudad de Königsberg

El desafío popular consistía en determinar si era posible trazar un recorrido continuo a pie por la ciudad que cruzase **cada uno de los siete puentes exactamente una sola vez** y regresase al punto de origen. Euler demostró la imposibilidad lógica de dicho recorrido abstrayendo la posición geográfica real y reduciendo la configuración espacial a un diagrama puramente topológico formado por nodos (las 4 regiones) y aristas (los 7 puentes), como se observa en la Figura 10.1.

La genialidad del argumento de Euler radicó en observar que para que un nodo intermedio admita un paso de entrada y salida sin repetir aristas, el número de conexiones incidentes en dicho nodo debe ser necesariamente **par**. Dado que las cuatro regiones de Königsberg poseen un grado impar de conexiones ($d(A) = 5, d(B) = 3, d(C) = 3, d(D) = 3$), el circuito euleriano deseado resulta matemáticamente imposible.

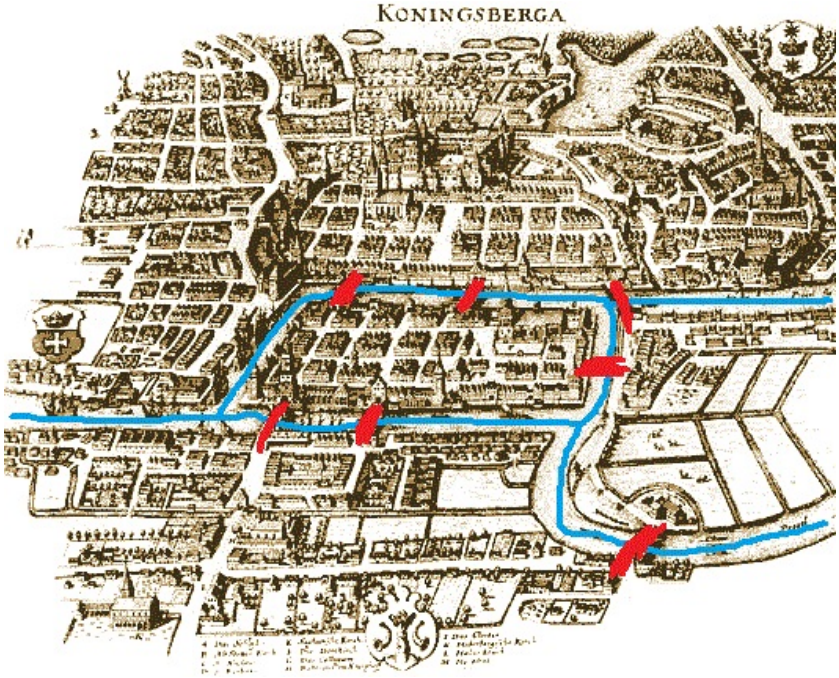

Figura 6.2: Mapa de Königsberg con los 7 puentes y el río Pregel destacados

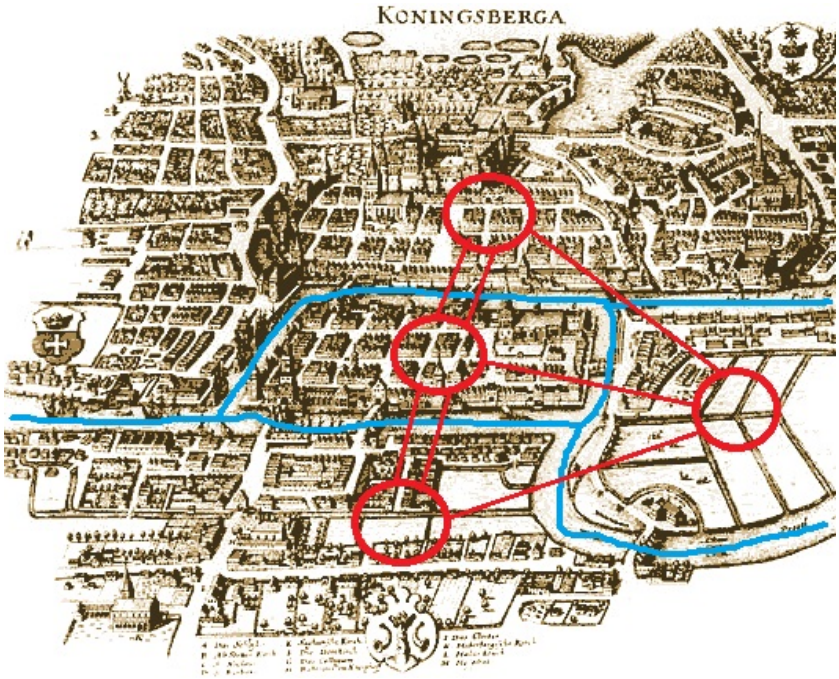

Figura 6.3: Esquema topológico superpuesto sobre la mapa de Königsberg (4 regiones y 7 aristas)

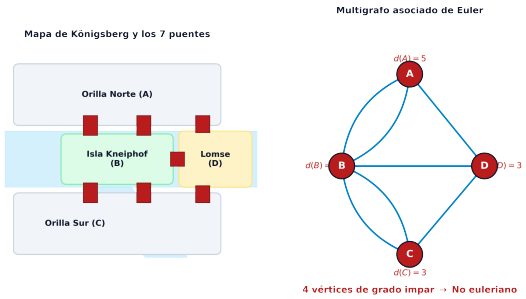

Figura 6.4: Grafo multigrafo abstracto del problema de Königsberg

6.2. Conceptos fundamentales

El estudio formal de las redes requiere definir con precisión los elementos constitutivos de un grafo, las relaciones de adyacencia e incidencia entre sus componentes y las diferentes tipologías estructurales que adopta la información según la densidad y naturaleza de sus conexiones.

6.2.1. Definición formal de grafos no dirigidos y dirigidos

Desde un punto de vista algebraico y de teoría de conjuntos, un grafo es un par ordenado formado por un conjunto finitos de elementos discretos denominados vértices o nodos, y una colección de relaciones que conectan dichos nodos.

Definición: Grafo no dirigido y digrafo

Grafo No Dirigido Un **grafo no dirigido** es un par $G = (V, E)$, donde $V = \{1, 2, \dots, n\}$ representa el conjunto finito de vértices o nodos (con $|V| = n$), y $E \subseteq \{\{i, j\} : i, j \in V, i \neq j\}$ denota el conjunto de **aristas** no ordenadas (con $|E| = m$). Una arista $e = \{i, j\}$ representa una relación simétrica entre los nodos i y j.
Grafo Dirigido o Digrafo Un **digrafo** o **grafo dirigido** es un par $G = (V, U)$, donde $V = \{1, 2, \dots, n\}$ representa el conjunto de vértices, y $U \subseteq V \times V$ denota el conjunto de **arcos dirigidos** u ordenados. Un arco $u = (i, j) \in U$ parte del nodo de origen o cola i y se dirige hacia el nodo de destino o cabeza j.

Para ilustrar de forma intuitiva estas definiciones, consideremos el modelado de una red de transporte aéreo internacional representada en la Figura 6.5.

En la Figura 6.5, los nodos representan los aeropuertos $V = \{m, l, p, f, s, t\}$ correspondientes a Madrid, Londres, París, Frankfurt, Singapur y Tokio. Los arcos dirigidos representan conexiones de vuelo directo de ida sin escala. Nótese que entre París (p) y Frankfurt (f) existen arcos dirigidos antiparalelos (p, f) y (f, p), lo que permite el tránsito bidireccional entre ambas capitales.

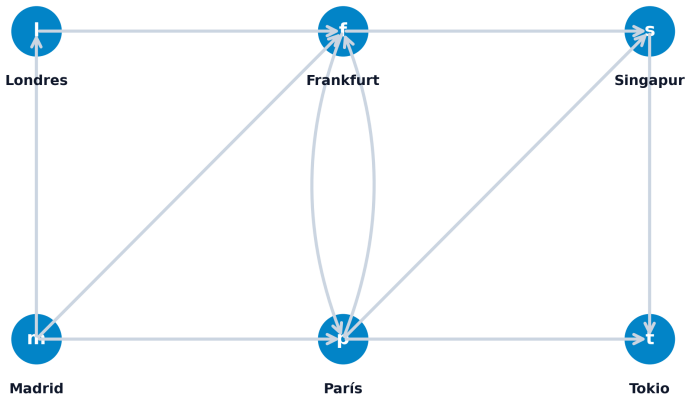

Figura 6.5: Red de vuelos compatibles entre aeropuertos internacionales representados como digrafo

Por otro lado, la estructura formal de un digrafo abstracto $G = (V, U)$ puede incorporar arcos dirigidos simples, arcos antiparalelos y bucles (arcos que nacen y terminan en el mismo vértice, $(i, i) \in U$), como se detalla en la Figura 6.6.

6.2.2. Vecindades, adyacencia y grados de un nodo

Las propiedades locales de un nodo en un grafo se caracterizan analíticamente a través de sus relaciones de vecindad y su grado de conexión.

Definición: Adyacencia, grados e incidencia

Dado un digrafo $G = (V, U)$ y un nodo $i \in V$:

- **Nodos Adyacentes**: Dos nodos $i, j \in V$ son **adyacentes** si existe una conexión directa entre ellos, es decir, si $(i, j) \in U$ o $(j, i) \in U$. El conjunto de todos los nodos adyacentes a i conforma su **vecindad total** $\Gamma(i) = \Gamma^+(i) \cup \Gamma^-(i)$.
- **Arcos Adyacentes**: Dos arcos $u_1, u_2 \in U$ son **adyacentes** cuando comparten al menos un nodo extremo común (por ejemplo, los arcos $(1, 2)$ y $(2, 4)$ son adyacentes al conectarse en el nodo 2).
- **Incidencia de un Arco**: Un arco $u = (i, j) \in U$ es **incidente de salida** en su nodo origen i, e **incidente de entrada** en su nodo destino j.

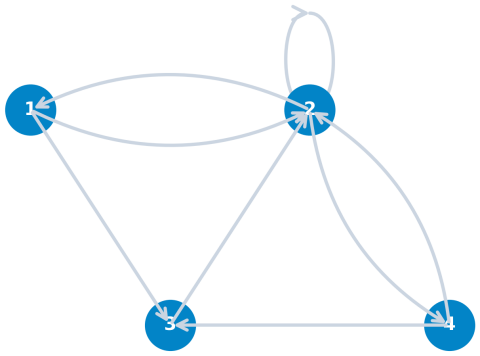

Figura 6.6: Estructura formal de un digrafo con arcos ordenados y un bucle autodirigido

Conjunto de Sucesores y Predecesores

- **Sucesores**: $\Gamma^+(i) = \{j \in V : (i,j) \in U\}$, conjunto de nodos hacia los que parten arcos desde i.
- **Predecesores**: $\Gamma^-(i) = \{j \in V : (j,i) \in U\}$, conjunto de nodos desde los que llegan arcos a i.
- **Vecindad Total**: $\Gamma(i) = \Gamma^+(i) \cup \Gamma^-(i)$.

Semigrados y Grado Total

- **Semigrado Exterior**: $d^+(i) = |\Gamma^+(i)|$, número de arcos que parten del nodo i.
- **Semigrado Interior**: $d^-(i) = |\Gamma^-(i)|$, número de arcos que ingresan al nodo i.
- **Grado Total**: $d(i) = d^+(i) + d^-(i)$, número total de arcos incidentes en el nodo i.

Un nodo i con grado total $d(i) = 1$ se denomina **nodo pendiente** o **hoja**. Un nodo con $d(i) = 0$ se denomina **nodo aislado**.

Como se observa geométricamente en la Figura 6.7, para el nodo 3 del digrafo, su conjunto de sucesores es $\Gamma^+(3) = \{2\}$, su conjunto de predecesores es $\Gamma^-(3) = \{1, 4\}$, y su vecindad total combinada es $\Gamma(3) = \{1, 2, 4\}$.

Asimismo, en la Figura 6.8 se representa la evaluación de los semigrados de los nodos de la red, donde el nodo 5 se identifica como un nodo pendiente al tener un grado total $d(5) = 1$

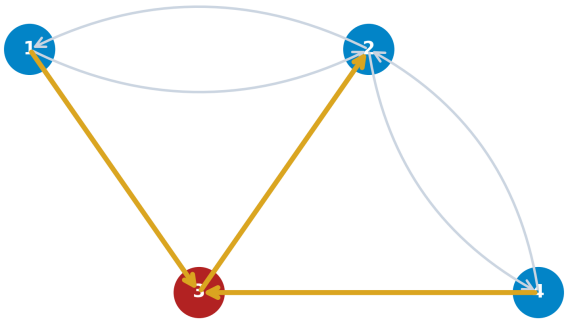

Figura 6.7: Adyacencia y vecindades de sucesores y predecesores para el nodo 3

$(d^+(5) = 0, d^-(5) = 1)$.

! Teorema de la suma de grados (Handshaking Lemma)

En todo grafo no dirigido $G = (V, E)$ con $|V| = n$ y $|E| = m$, la suma de los grados de todos los vértices es igual al doble del número total de aristas:

$$\sum_{v \in V} d(v) = 2m$$

Demostración: Cada arista $e = \{u, v\} \in E$ contribuye exactamente en 1 unidad al grado del nodo u y en 1 unidad al grado del nodo v. Por consiguiente, al sumar los grados de todos los nodos en V, cada arista del conjunto E es contabilizada exactamente dos veces. ■

6.2.3. Incidencia de conjuntos y cortes

En el estudio de los flujos en redes y la conectividad, resulta esencial cuantificar los arcos que cruzan la frontera entre dos subconjuntos de vértices.

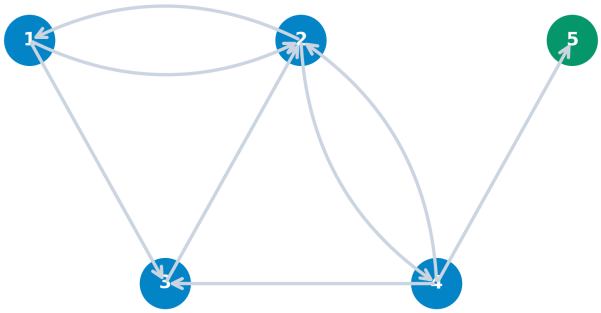

Figura 6.8: Semigrados exterior e interior y caracterización de nodo pendiente

Definición: Incidencia de un conjunto de nodos

Dado un digrafo $G = (V, U)$ y un subconjunto propio de nodos $A \subset V$:

- **Incidencia Exterior** $w^+(A)$: Conjunto de arcos que parten de A y finalizan fuera de A:
$$w^+(A) = \{(i, j) \in U : i \in A, j \in V \setminus A\}$$
- **Incidencia Interior** $w^-(A)$: Conjunto de arcos que parten de fuera de A e ingresan en A:
$$w^-(A) = \{(i, j) \in U : i \in V \setminus A, j \in A\}$$
- **Corte** $w(A)$: Unión de las incidencias exterior e interior: $w(A) = w^+(A) \cup w^-(A)$.

En la Figura 6.9 se ilustra la aplicación práctica de esta definición sobre una red de 5 nodos seleccionando el subconjunto de nodos $A = \{2, 3\}$ (resaltados en color rojo ladrillo).

Para el subconjunto de nodos $A = \{2, 3\}$, la evaluación analítica de las incidencias y el corte resulta:

$$\begin{aligned} w^+(A) = w^+(\{2,3\}) &= \{(2,4),(3,1),(3,5)\} \\ w^-(A) = w^-(\{2,3\}) &= \{(1,2),(4,3)\} \\ w(A) = w(\{2,3\}) &= \{(1,2),(2,4),(3,1),(3,5),(4,3)\} \end{aligned}$$

Como se refleja visualmente en el sistema de ecuaciones y en la figura: El corte $w(A)$ cuantifica la frontera que separa el subconjunto A del resto de la red. La incidencia exterior $w^{+}(A)$ agrupa los arcos salientes que nacen en A y se dirigen hacia los nodos exteriores, mientras que la incidencia interior $w^{-}(A)$ agrupa los arcos entrantes desde el exterior hacia A. El corte total combina ambas incidencias, diferenciando los arcos que cruzan dicha frontera de aquellos que permanecen internos a A o externos al mismo.

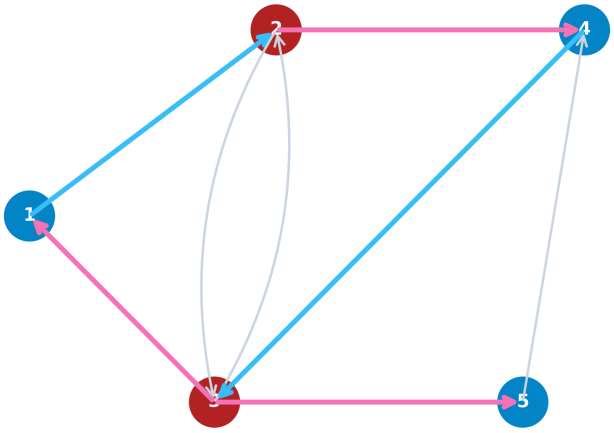

Figura 6.9: Incidencia e incidencia de corte para el subconjunto de nodos A={2,3}

6.2.4. Tipología de grafos: multigrafos, grafos completos, subgrafos y grafos parciales

El modelado formal de sistemas mediante teoría de grafos requiere clasificar las redes según la multiplicidad de sus relaciones, la densidad de sus conexiones y las propiedades de sus subestructuras asociadas.

Definición: Multigrafos, multiplicidad y p-grafos

Dado un conjunto de vértices V:

- **Multigrafo / Multidigrafo**: Un **multigrafo** $G = (V, E)$ (o **multidigrafo** $G = (V, U)$) es una estructura matemática que admite la presencia de múltiples aristas o arcos en paralelo entre un mismo par de vértices.
- **Multiplicidad**: Indica el número exacto de conexiones repetidas en paralelo entre

dos vértices dados.

- *p*-**Grafo**: Se define como un multigrafo en el que la máxima multiplicidad de cualquier arista es exactamente p, no existiendo pares de nodos conectados por más de p aristas.

En aplicaciones reales de transporte e infraestructuras, la presencia de aristas múltiples permite representar canalizaciones paralelas o rutas de autobús duplicadas entre dos mismas terminales. Como se ilustra en la Figura 6.10, se presenta una red compuesta por 4 vértices $\{a, b, c, d\}$ donde los pares $\{a, b\}$ y $\{c, d\}$ disponen de 3 conexiones en paralelo cada uno, constituyendo formalmente un 3-grafo.

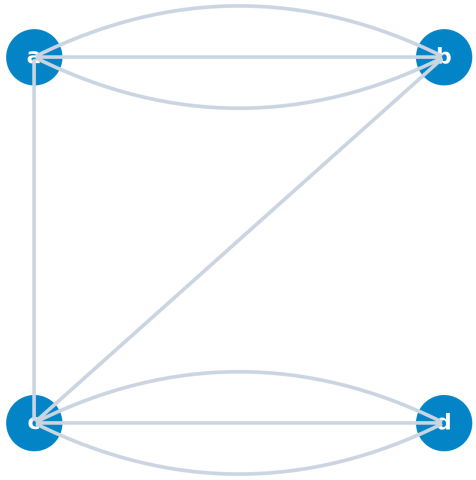

Figura 6.10: Ejemplo de multigrafo y 3-grafo con aristas múltiples de multiplicidad 3

Cuando una red carece de bucles y no presenta aristas paralelas, se dice que es un **grafo simple**. En el extremo opuesto de máxima conectividad se sitúan las redes completas.

i Definición: Grafos simples, completos y clanes

Sea $G = (V, E)$ un grafo no dirigido de $n = |V|$ vértices:

- **Grafo Simple**: Estructura de multiplicidad 1 desprovista de autodirecciones o bucles (i, i). De forma análoga se define un **digrafo simple**.
- **Grafo Completo**: Grafo en el que todo par de vértices distintos se encuentra conectado por una arista: $\{i, j\} \in E, \forall i \neq j$.

- **Digrafo Completo**: Digrafo $G = (V, U)$ donde para todo par de nodos distintos $i \neq j$, la ausencia de arco en un sentido implica la existencia obligatoria del arco inverso: $(i, j) \notin U \implies (j, i) \in U$.
- **Clan K_n (Clique)**: Grafo simple y completo de n vértices. Contiene exactamente $m = \binom{n}{2} = \frac{n(n-1)}{2}$ aristas.

La distinción entre la completitud en digrafos y en grafos no dirigidos resulta fundamental en el análisis de redes de transmisión. En un digrafo completo, la conectividad está garantizada en al menos uno de los dos sentidos para cada par de nodos. Como se observa en la Figura 6.11, sobre 4 nodos $\{a, b, c, d\}$, la pareja (a, c) está conectada únicamente mediante el arco dirigido unidireccional (a, c), cumpliendo estrictamente la condición de completitud orientada.

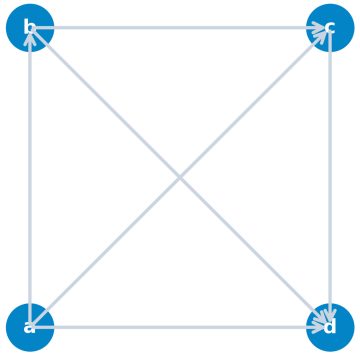

Figura 6.11: Digrafo completo sobre 4 nodos con 6 arcos dirigidos

Por su parte, cuando la simetría es total y cada vértice se comunica bidireccionalmente con todos los demás, la estructura recibe el nombre de **clan** o *clique*, denotado por K_n. En la Figura 6.12 se representa el clan K_4, que integra 6 aristas conectando sus 4 vértices.

Al incrementar la dimensión a $n = 5$ vértices, el número de conexiones necesarias para mantener la completitud crece de forma cuadrática alcanzando las $m = \frac{5 \times 4}{2} = 10$ aristas, tal como se muestra en la Figura 6.13 para el clan K_5.

En el estudio sintáctico de grandes redes, frecuentemente se requiere extraer subestructuras más pequeñas limitando los elementos disponibles. Para ello, se distingue rigurosamente entre la extracción guiada por nodos (**subgrafo inducido**) y la extracción guiada por arcos (**grafo parcial**).

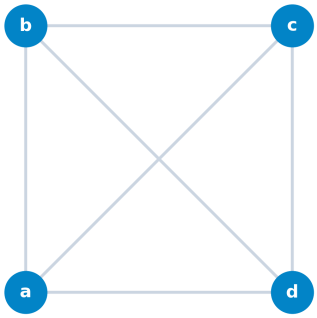

Figura 6.12: Clan K4 simple completo sobre 4 vértices con 6 aristas

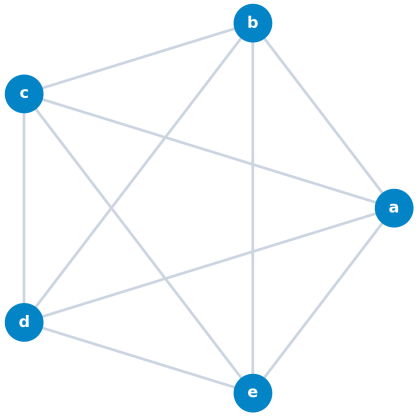

Figura 6.13: Clan K5 simple completo sobre 5 vértices con 10 aristas

Definición: Subgrafo generado (inducido) y grafo parcial

Dado un digrafo $G = (V, U)$ (o grafo $G = (V, E)$):

- **Subgrafo Generado (Inducido)**: Dado un subconjunto de vértices $A \subset V$, el subgrafo generado $G_A = (A, U_A)$ conserva **únicamente** los nodos de A y las relaciones cuyos dos extremos pertenecen íntegramente a A:

$$U_A = \{u = (i, j) \in U : i, j \in A\}$$

- **Grafo Parcial Generado**: Dado un subconjunto de arcos $W \subset U$, el grafo parcial $G(W) = (V, W)$ conserva el conjunto completo de n vértices originales de V, pero restringe el conjunto de arcos a W.

Para comprender la diferencia intuitiva entre ambas operaciones, considérese la red orientada original $G = (V, U)$ de 5 nodos y 10 arcos representada en la Figura 6.14.

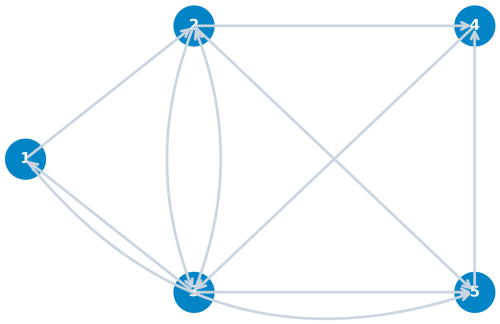

Figura 6.14: Digrafo original de 5 nodos G=(V,U)

Cuando se genera un subgrafo inducido seleccionando un subconjunto de nodos $A \subset V$, los vértices que no pertenecen a A desaparecen por completo de la representación geométrica y algebraica. Así, al elegir $A = \{1, 2, 5\}$, la Figura 6.15 muestra cómo la estructura resultante $G_{\{1,2,5\}}$ conserva únicamente los 3 nodos seleccionados y los 3 arcos que conectaban a dichos nodos entre sí.

Análogamente, al inducir la red sobre el subconjunto de nodos $A = \{1, 2, 3\}$, la Figura 6.16 refleja la topología aislada $G_{\{1,2,3\}}$, compuesta estrictamente por los 3 vértices de A y los 4 arcos internos que los unían en el grafo original.

Por el contrario, la extracción de un grafo parcial no altera el conjunto de vértices de la red, manteniendo siempre presentes los $n = 5$ nodos de V. Si se selecciona el subconjunto de arcos

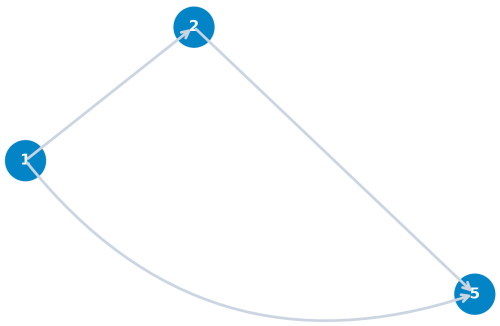

Figura 6.15: Subgrafo inducido generado por el subconjunto de nodos A={1,2,5}

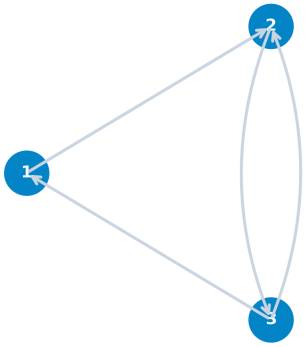

Figura 6.16: Subgrafo inducido generado por el subconjunto de nodos A={1,2,3}

$W = \{(1,2),(2,4),(5,4)\}$, la Figura 6.17 muestra cómo el nodo 3 permanece en el grafo parcial $G(W)$ en calidad de nodo aislado sin grado de conexión ($d(3) = 0$).

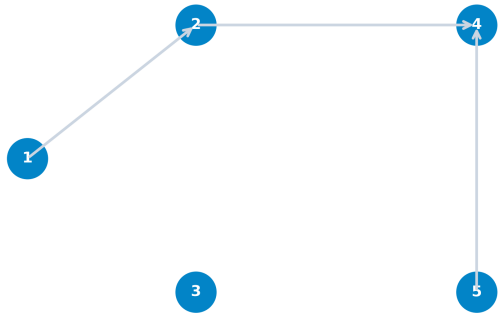

Figura 6.17: Grafo parcial generado por el subconjunto de arcos W = {(1,2), (2,4), (5,4)}

Si en su lugar se elige el subconjunto de arcos $W = \{(1,2),(2,4),(2,5),(3,1)\}$, se obtiene el grafo parcial representado en la Figura 6.18, el cual preserva los 5 vértices de V conectados mediante una topología arborescente parcial.

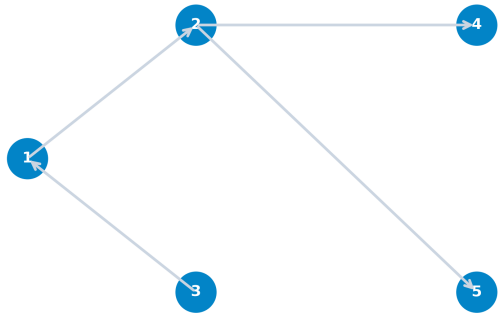

Figura 6.18: Grafo parcial generado por el subconjunto de arcos W = {(1,2), (2,4), (2,5), (3,1)}

Finalmente, en la caracterización teórica de grafos simples resulta relevante analizar las conexiones "ausentes" respecto a la red completa mediante el concepto de grafo complementario.

Definición: Grafo complementario

Dado un grafo simple $G = (V, E)$, el **grafo complementario** $\bar{G} = (V, \bar{E})$ mantiene el mismo conjunto de vértices V y está formado exactamente por las aristas no presentes en E:

$$\bar{G} = (V, \bar{E}) \quad \text{tal que} \quad \{i, j\} \in \bar{E} \iff \{i, j\} \notin E \quad (\forall i \neq j)$$

En la Figura 6.19 se ilustra este proceso de inversión topológica a partir de un grafo simple G de 5 vértices $V = \{a, b, c, d, e\}$ y 7 aristas. Puesto que en el grafo original G el vértice b se encuentra conectado con todos los demás nodos, en el grafo complementario $\bar{G}$ las únicas 3 aristas resultantes son $\bar{E} = \{\{a, d\}, \{a, e\}, \{c, e\}\}$, pasando el vértice b a convertirse en un nodo totalmente aislado.

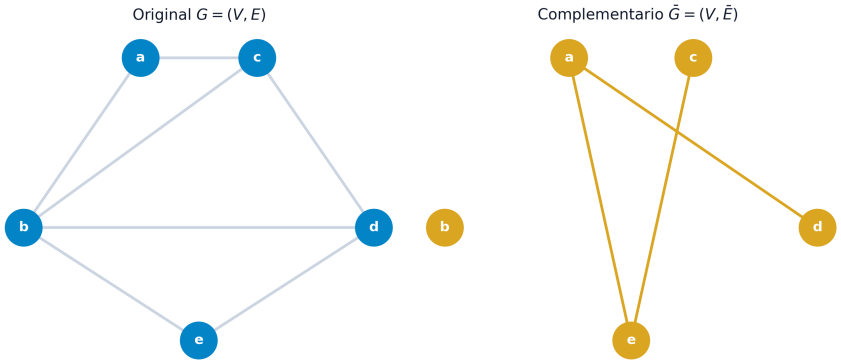

Figura 6.19: Construcción del grafo complementario para un grafo de 5 vértices

---

6.3. Recorridos y conectividad en redes

El análisis topológico de una red exige estudiar cómo la información, el tráfico o los flujos se desplazan a través de sus vértices y conexiones. Para ello, es preciso formalizar las secuencias de trayectorias (cadenas y caminos), cuantificar sus métricas de alcance (distancia y diámetro) y evaluar la capacidad global de comunicación e integridad del grafo mediante el concepto de conectividad.

6.3.1. Cadenas y caminos

En la teoría de redes orientadas (Ahuja, Magnanti, y Orlin 1993), el estudio del movimiento a través de los arcos requiere distinguir entre recorridos que respetan la orientación de las flechas

(caminos) y recorridos que transitan los arcos sin importar su dirección (cadenas).

Definición: Cadena, camino, elementalidad y simplicidad

Dado un digrafo $G = (V, U)$:

- **Cadena**: Secuencia de arcos adyacentes $\mu = (u_1, u_2, \dots, u_q)$ de longitud $q \geq 1$ entre los nodos extremos i y j ($\mu[i, j]$) en la que los arcos pueden recorrerse a favor o en contra de su orientación original.
- **Camino**: Cadena orientada en la que todos los arcos se transitan estrictamente a favor de su sentido; es decir, el nodo final de u_k coincide con el nodo inicial de u_{k+1} para todo $k = 1, \dots, q - 1$.
- **Elemental**: Una cadena o camino es **elemental** si no repite ningún vértice en su recorrido.
- **Simple**: Una cadena o camino es **simple** si no repite ningún arco en su recorrido.

Para analizar las propiedades de simplicidad y elementalidad sobre redes orientadas, considérese la red de 6 aeropuertos internacionales $V = \{m, l, p, f, s, t\}$ (Madrid, Londres, París, Frankfurt, Singapur y Tokio).

Un primer caso lo constituye la cadena $\mu^1[m, p] = \{(m, l); (l, f); (p, f)\}$, de longitud $q = 3$. Este recorrido resulta ser **elemental y simple**, ya que transita por los 4 vértices $\{m, l, f, p\}$ sin repetir ninguno y recorre 3 arcos distintos. Puesto que el arco (p, f) se atraviesa en sentido inverso (desde f hasta p), se trata de una cadena y no de un camino. La Figura 6.20 ilustra este trayecto en la red.

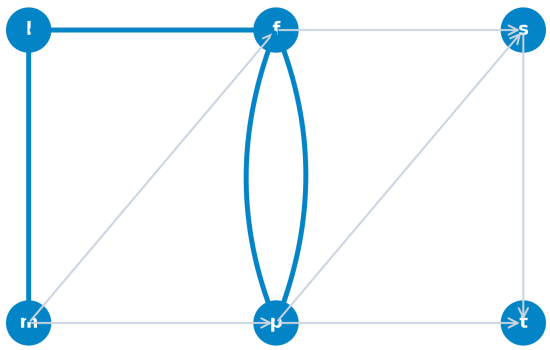

Figura 6.20: Cadena mu1[m, p] elemental y simple con el arco (p, f) recorrido en sentido inverso

Cuando la trayectoria respeta la dirección de todas las flechas y no repite elementos, se genera un camino perfecto. La secuencia $\mu^2[p,t] = \{(p,f);(f,s);(s,t)\}$ entre París (p) y Tokio (t) constituye un **camino elemental y simple** de longitud $q = 3$. Como se observa en la Figura 6.21, los tres arcos avanzan fluidamente en el sentido marcado por la red.

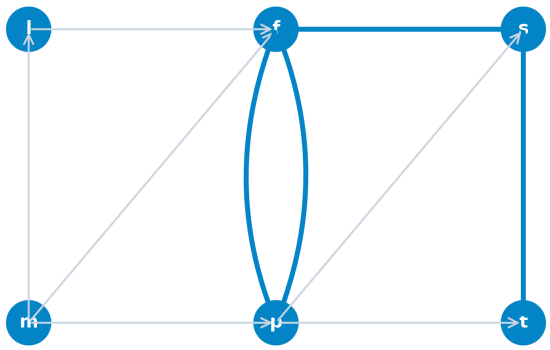

Figura 6.21: Camino mu2[p, t] elemental y simple con todos los arcos en sentido directo

Es posible que un recorrido no repita ningún arco pero sí vuelva a pasar por un vértice previamente visitado. La cadena $\mu^3[m,p] = \{(m,p);(p,f);(f,s);(p,s);(p,t)\}$, de longitud $q = 5$, es **no elemental y sí simple**. Como refleja la Figura 6.22, la trayectoria visita dos veces el nodo p $(m \to p \to f \to s \to p \to t)$, pero mantiene la simplicidad al no duplicar ninguno de sus 5 arcos.

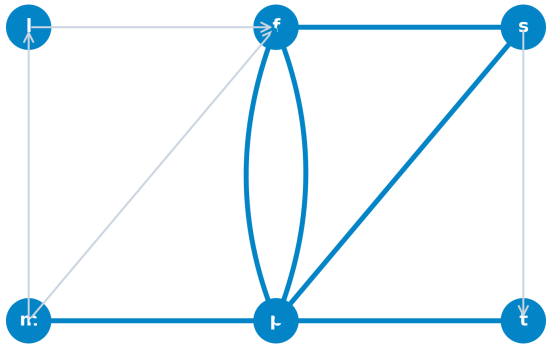

Figura 6.22: Cadena mu3[m, p] no elemental y sí simple con visita duplicada al nodo p

Por último, cuando un recorrido duplica tanto nodos como conexiones, pierde ambas propiedades.

La cadena $\mu^4 = \{(l, f); (f, s); (p, s); (p, f); (f, s); (s, t)\}$, de longitud $q = 6$, es **ni elemental ni simple**. Como muestra la Figura 6.23, el arco (f, s) se transita dos veces en instantes distintos del recorrido.

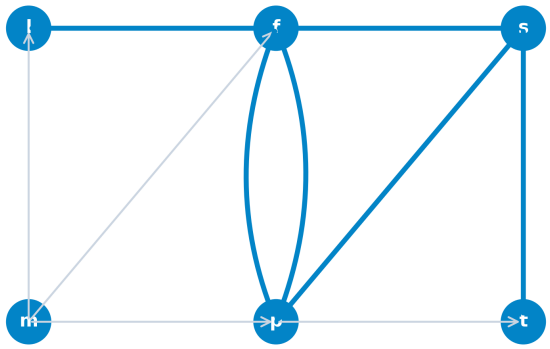

Figura 6.23: Cadena mu4 ni elemental ni simple con repetición del arco (f, s)

Ejemplo: Clasificación de cadenas en grafos (elementalidad y simplicidad)

Considérese un grafo no dirigido sobre 5 vértices $V = \{1, 2, 3, 4, 5\}$ y el análisis de las propiedades de elementalidad y simplicidad para tres cadenas distintas:

1. **Cadena** $\mu_1 = \{\{1, 2\}, \{2, 3\}, \{3, 4\}, \{4, 5\}\}$: Visita 5 vértices distintos sin duplicar ninguno ($\{1, 2, 3, 4, 5\}$) y transita por 4 aristas distintas. Por consiguiente, resulta ser una cadena **elemental y simple**.

2. **Cadena** $\mu_2 = \{\{1, 2\}, \{2, 3\}, \{3, 4\}, \{4, 2\}, \{2, 5\}\}$: Recorre 5 aristas distintas sin repetir ninguna (conserva la simplicidad), pero el nodo 2 es visitado dos veces durante la secuencia ($1 \to 2 \to 3 \to 4 \to 2 \to 5$). Por tanto, es una cadena **simple pero no elemental**.

3. **Cadena** $\mu_3 = \{\{1, 2\}, \{2, 4\}, \{4, 3\}, \{3, 2\}, \{2, 1\}\}$: Duplica vértices (visita 2 múltiples veces) y además transita por la arista $\{1, 2\}$ dos veces (en ida y vuelta). Por tanto, es una cadena **ni elemental ni simple**.

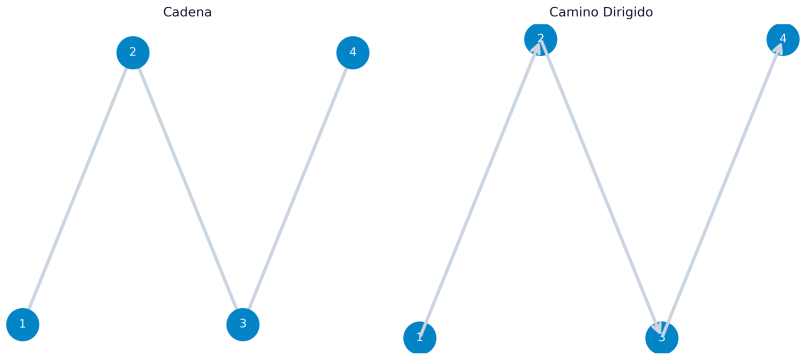

Figura 6.24: Clasificación de cadenas según su elementalidad y simplicidad

Ejemplo: Clasificación de caminos dirigidos (elementalidad y simplicidad)

Considérese una red dirigida sobre 7 vértices $V = \{a, b, c, d, e, f, g\}$ y el análisis de las propiedades de elementalidad y simplicidad para tres caminos orientados:

1. **Camino** $P_1 = ((a, b), (b, c), (c, e), (e, f))$: Transita en sentido directo por 5 vértices distintos $(a \to b \to c \to e \to f)$ y 4 arcos distintos. Por tanto, es un **camino elemental y simple**.

2. **Camino** $P_2 = ((c, g), (g, f), (f, b), (b, c), (c, e))$: Recorre 5 arcos distintos sin duplicar ninguno (conserva la simplicidad), pero el nodo c es visitado dos veces durante el recorrido $(c \to g \to f \to b \to c \to e)$. Por tanto, es un **camino simple pero no elemental**.

3. **Camino** $P_3 = ((c, e), (e, f), (f, b), (b, c), (c, e), (e, g))$: Repite vértices ($c$ y e) y además recorre el arco directed (c, e) dos veces. Por tanto, es un **camino ni elemental ni simple**.

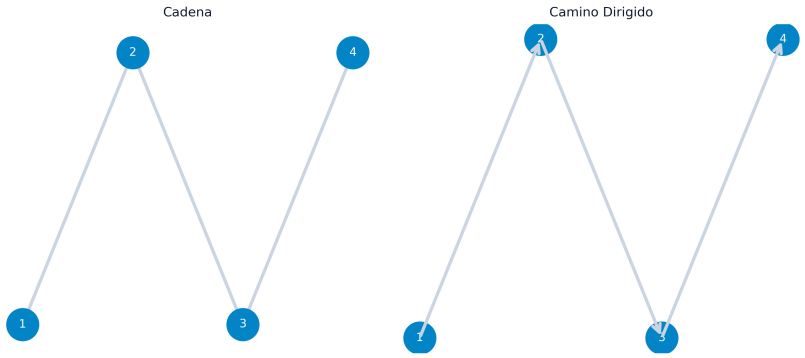

Figura 6.25: Clasificación de caminos dirigidos según su elementalidad y simplicidad

Además del estudio de la elementalidad y la simplicidad de las cadenas, la cuantificación de la métrica de los recorridos permite caracterizar la extensión global y la compacidad de una red.

Definición: Longitud, distancia geodésica y diámetro

Dado un digrafo $G = (V, U)$ (o grafo $G = (V, E)$):

- **Longitud de una Cadena**: Número exacto de arcos o aristas q que componen la secuencia μ.
- **Distancia Geodésica** $d(i, j)$: Longitud de la cadena más corta existente entre el nodo i y el nodo j.
- **Diámetro de un Grafo** $D(G)$: Mayor distancia geodésica entre cualquier par de nodos de la red:

$$D(G) = \max_{i,j \in V} d(i, j)$$

En la Figura 6.26 se ilustra la evaluación del diámetro sobre la red orientada de 5 nodos $V = \{1, 2, 3, 4, 5\}$. Al analizar la distancia geodésica entre cada par de vértices (como la conexión entre los nodos 1 y 4 a través de la cadena de 2 arcos $\{(1, 2), (2, 4)\}$, o entre los nodos 3 y 4 a través de $\{(3, 2), (2, 4)\}$), se comprueba que la máxima distancia necesaria para comunicar cualquier pareja de nodos en la red es de 2 arcos. Por consiguiente, el diámetro global del grafo es $D(G) = 2$.

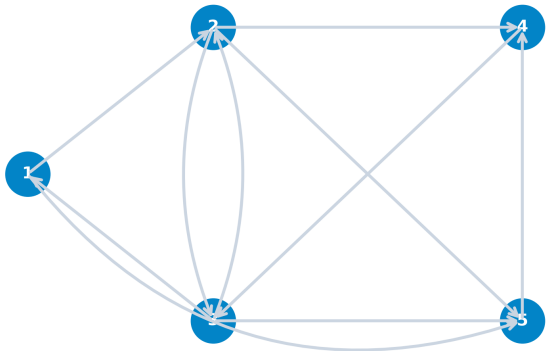

Figura 6.26: Evaluación del diámetro D(G)=2 sobre una red orientada de 5 vértices

⚠ Advertencia: Diferencia fundamental entre cadena y camino

Para sintetizar las propiedades de recorrido en redes orientadas y no dirigidas, conviene destacar la distinción conceptual entre cadena y camino:

- **Cadena**: Secuencia de arcos o aristas adyacentes que **no exige respetar la orientación de las flechas**. Los arcos pueden recorrerse tanto en sentido directo como en sentido inverso. Caracteriza la **conectividad puramente sintáctica o topológica** entre dos nodos.
- **Camino**: Secuencia de arcos orientados en la que **todos los arcos se transitan estrictamente en el sentido de su flecha** (el nodo destino del k-ésimo arco es el nodo origen del $(k+1)$-ésimo). Describe la **posibilidad real de circulación de flujo o transporte** en la red.

En consecuencia, **todo camino dirigido es una cadena**, pero **no toda cadena constituye un camino**. En redes no dirigidas (donde las aristas carecen de orientación), las nociones de cadena y camino resultan formalmente equivalentes.

6.3.2. Conectividad

La accesibilidad entre los vértices determina la capacidad global de comunicación e integridad estructural de una red. En grafos no dirigidos, la existencia de recorridos entre sus nodos permite definir la noción de conexidad global, mientras que en redes orientadas es preciso distinguir entre la mera conectividad sintáctica (existencia de cadenas) y la conectividad efectiva

de transporte (existencia de caminos dirigidos).

Definición: Grafo conexo y digrafo fuertemente conexo

Dado un grafo $G = (V, E)$ o digrafo $G = (V, U)$:

- **Grafo Conexo**: Un grafo no dirigido es **conexo** si entre cualquier par de vértices $i, j \in V$ existe al menos una **cadena**.
- **Digrafo Fuertemente Conexo**: Un digrafo es **fuertemente conexo** si entre cualquier par de vértices $i, j \in V$ existe al menos un **camino dirigido** en ambas direcciones (de i a j y de j a i).

En la Figura 6.27 se ilustra un digrafo sobre 7 vértices $V = \{a, b, c, d, e, f, g\}$. Este digrafo resulta ser **conexo** en el sentido débil (al existir cadenas no orientadas que comunican todos los nodos), pero **no es fuertemente conexo**. El vértice d actúa como un nodo sumidero al que convergen únicamente arcos entrantes desde a, c, g, impidiendo la existencia de cualquier camino saliente que conecte a d con los demás vértices de la red.

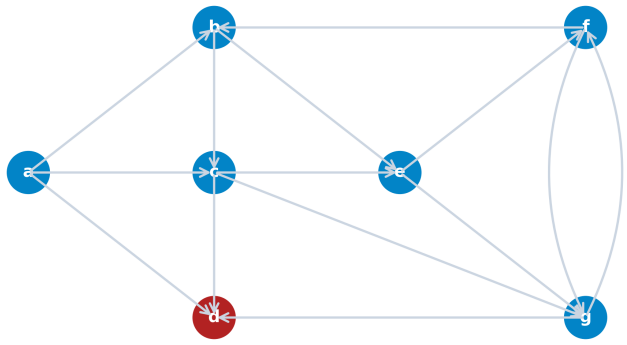

Figura 6.27: Digrafo conexo pero no fuertemente conexo con nodo sumidero en d

Cuando una red carece de conexidad global, esta se disgrega de forma natural en subgrafos independientes aislados denominados **componentes conexas**. Esta descomposición se formaliza rigurosamente mediante la definición de una relación de equivalencia sobre el conjunto de vértices.

Definición: Relación de conexidad y componentes conexas

En un grafo $G = (V, E)$ o digrafo $G = (V, U)$, se define la relación binaria R sobre el

conjunto de vértices V:

$$\forall i, j \in V, \quad i \, R \, j \iff \exists \text{ una cadena entre } i \text{ y } j$$

La relación R constituye una **relación de equivalencia** al satisfacer tres propiedades fundamentales:

- **Reflexiva**: Todo nodo está relacionado consigo mismo ($i \, R \, i$) mediante una cadena trivial de longitud 0.
- **Simétrica**: Si existe una cadena de i a j, invirtiendo el orden de recorrido se obtiene una cadena de j a i ($i \, R \, j \implies j \, R \, i$).
- **Transitiva**: Si existe una cadena de i a j y otra de j a k, la concatenación de ambas forma una cadena de i a k ($i \, R \, j \wedge j \, R \, k \implies i \, R \, k$).

Las clases de equivalencia inducidas por R sobre V determinan la partición del grafo en sus **componentes conexas**.

En la Figura 6.28 se presenta un grafo descompuesto en dos componentes conexas disjuntas: la primera integrada por los vértices $\{a, b, c, d\}$ con las aristas $\{\{a, b\}, \{b, c\}, \{c, d\}, \{b, d\}\}$, y la segunda constituida por los vértices $\{e, f, g\}$ con las aristas $\{\{e, f\}, \{f, g\}\}$.

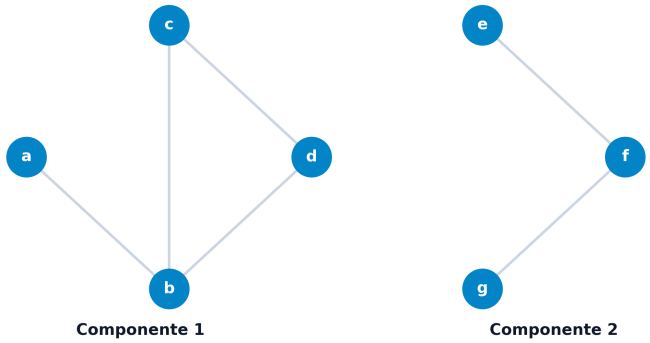

Figura 6.28: Grafo no dirigido descompuesto en dos componentes conexas disjuntas

El análisis de los recorridos cerrados, aquellos cuyo vértice inicial y final coinciden, permite caracterizar la presencia de redundancias en la red y definir los grafos conexos acíclicos, denominados **árboles**, que desempeñan un papel central en la optimización de infraestructuras.

Definición: Ciclo, bucle, circuito y árbol

Dado un grafo $G = (V, E)$ o digrafo $G = (V, U)$:

- **Ciclo**: Una **cadena simple** cuyo nodo inicial y nodo final coinciden ($v_0 = v_k$).
- **Bucle**: Un ciclo formado por una única arista o arco que conecta un vértice consigo mismo.
- **Circuito**: Un **camino simple** en el que el nodo inicial y el nodo final coinciden ($v_0 = v_k$).
- **Árbol**: Un **grafo conexo sin ciclos**.

En la Figura 6.29 se comparan dos estructuras topológicas básicas: a la izquierda, un grafo que contiene el ciclo elemental en triángulo $\{\{a, b\}, \{b, c\}, \{c, a\}\}$; a la derecha, una red en estrella centrada en el nodo a conectada a 8 vértices periféricos $\{b, c, d, e, f, g, h, i\}$ que constituye un árbol conexo acíclico.

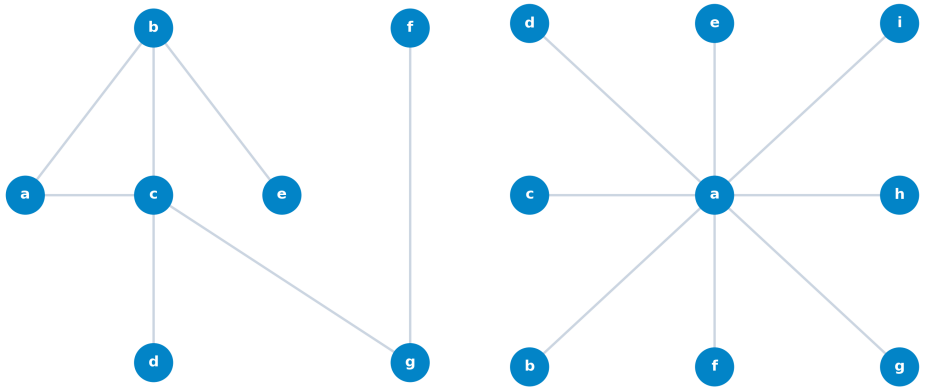

Figura 6.29: Comparación entre un grafo no dirigido con ciclo y un árbol en estrella acíclico

La presencia de ciclos impone restricciones estructurales muy precisas sobre los grados de los vértices y la conectividad del grafo, recogidas en el siguiente teorema.

Teorema: Propiedades estructurales de los ciclos y árboles

Para todo grafo conexo $G = (V, E)$ con $n = |V| > 1$ vértices, se verifican las siguientes propiedades fundamentales:

1. **Ausencia de vértices pendientes**: Si G no posee vértices pendientes (es decir,

todos sus nodos tienen grado $\delta(v) \geq 2$), entonces G contiene **al menos un ciclo**.

2. **Existencia de hojas en árboles**: Si G es un árbol conexo sin ciclos, entonces G contiene **al menos un vértice pendiente** (hoja con $\delta(v) = 1$).

3. **Caracterización de aristas en ciclos**: Una arista $e \in E$ pertenece a un ciclo μ de G si y solo si su eliminación no desconecta el grafo; es decir, $G \setminus \{e\}$ continúa siendo un grafo conexo.

Estas propiedades estructurales constituyen el fundamento sobre el que se edifican los algoritmos de búsqueda y construcción de árboles de expansión mínima (como los algoritmos de Kruskal y Prim) que se estudiarán en las secciones posteriores.

6.4. Grafos planares y grafos bipartitos

Una propiedad fundamental en el estudio topológico de redes es la capacidad de representar un grafo geométricamente sobre el plano bidimensional $\mathbb{R}^2$ de manera que sus aristas no se intersecten. La disposición geométrica sobre el plano resulta crítica en aplicaciones reales como el diseño de circuitos impresos (PCB), el trazado de mapas de carreteras o la canalización de infraestructuras subterráneas de transporte de energía y fluidos.

i Definición: Grafo planar e incrustación planar

Un grafo $G = (V, E)$ se denomina **planar** si admite una representación geométrica en el plano bidimensional de modo que sus aristas no se crucen ni se corten entre sí en ningún punto distinto de sus vértices extremos.
Se denomina **incrustación planar** a cualquier dibujo plano de G exento de intersecciones entre aristas. Una incrustación planar divide el plano en subconjuntos conexos acotados y no acotados denominados **caras** o **regiones** r. Todo grafo planar posee exactamente **una región exterior no acotada**.

Un mismo grafo abstracto admite múltiples diagramaciones geométricas sobre el plano. En la Figura 6.30 se ilustra esta propiedad mediante el grafo completo sobre 4 vértices K_4: la representación convencional de la izquierda presenta dos aristas diagonales cruzándose en un punto central; sin embargo, al recolocar el vértice a en la región interior acotada por el triángulo $\{b, c, d\}$ (representación derecha), se obtiene un dibujo equivalente exento de intersecciones. Por tanto, el grafo completo K_4 es **planar**.

Los grafos completos de menor orden (K_2, K_3, K_4) son todos planares. Sin embargo, al incrementar el número de vértices, la saturación de conexiones impide mantener la planaridad. En

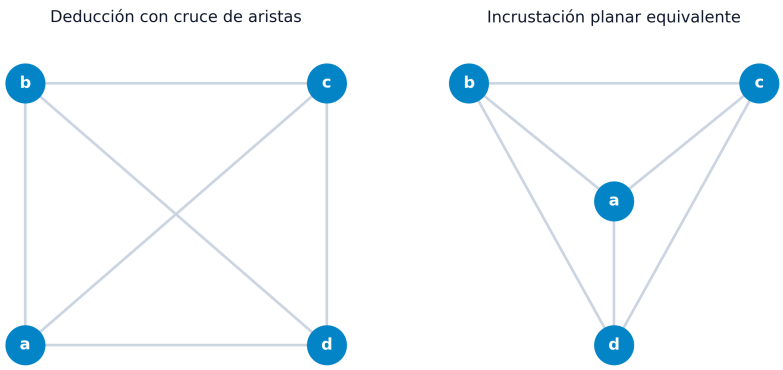

Figura 6.30: Planaridad del grafo completo K4 mediante incrustación equivalente sin cruces

1840, el matemático August Möbius planteó esta limitación mediante un célebre problema acertijo:

> *"Un rey ordenó en su testamento que, tras su muerte, su reino fuera dividido entre sus 5 hijos en 5 regiones contiguas de forma que cada región tuviera frontera común con todas las demás 4 regiones. ¿Es posible cumplir la voluntad del rey?"*

La respuesta matemática es **negativa**. El cumplimiento del testamento requeriría la existencia de un mapa cuyo grafo dual de fronteras fuera un grafo completo con 5 vértices, K_5, en el que cada par de vértices tuviera una arista de colindancia. Como se ilustra en la Figura 6.31, el grafo completo K_5 (con 5 vértices y 10 aristas) resulta ser un **grafo no planar**, puesto que cualquier intento de incrustar sus aristas en el plano genera al menos un cruce inevitable.

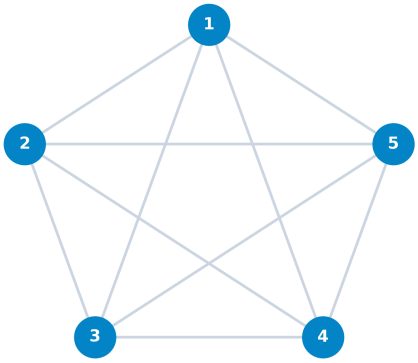

Figura 6.31: El grafo completo K5 y el problema de las 5 regiones de Möbius (no planar)

Además de los grafos completos, existe otra importante familia de redes asociadas a problemas de asignación e interconexión: los **grafos bipartitos**.

Definición: Grafo bipartito y bipartito completo

Un grafo $G = (V, E)$ es **bipartito** si su conjunto de vértices admite una partición en dos subconjuntos disjuntos:

$$V = V_1 \cup V_2, \quad V_1 \cap V_2 = \emptyset$$

de modo que toda arista de E conecta un vértice de V_1 con un vértice de V_2 (no existen aristas uniendo vértices dentro del mismo subconjunto).
Un **grafo bipartito completo** K_{n_1,n_2} es un grafo bipartito con $|V_1| = n_1$ y $|V_2| = n_2$ que contiene todas las $n_1 \cdot n_2$ aristas posibles entre ambos subconjuntos:

$$\{v_1, v_2\} \in E, \quad \forall v_1 \in V_1, \forall v_2 \in V_2$$

Una propiedad estructural fundamental que caracteriza analíticamente a la familia de los grafos bipartitos se formaliza en el siguiente teorema:

Teorema: Caracterización de grafos bipartitos

Un grafo $G = (V, E)$ es **bipartito** si y solo si **no contiene ningún ciclo de longitud impar**.

El análisis de la planaridad en grafos bipartitos se halla históricamente ligado al célebre *Problema de los tres servicios* (suministro de agua A, gas G y electricidad E a tres casas C_1, C_2, C_3), popularizado por Henry Ernest Dudeney (Dudeney 1958):

> *"¿Es posible canalizar las conducciones subterráneas de tres suministros esenciales (agua, gas y electricidad) hacia tres viviendas independientes de modo que ninguna tubería o cable se cruce con otro en el plano?"*

Desde la perspectiva de la teoría de redes, este acertijo plantea formalmente si el grafo bipartito completo $K_{3,3}$ (formado por $n_1 = 3$ fuentes de suministro y $n_2 = 3$ casas, sumando $n = 6$ vértices y $m = 9$ aristas) admite o no una incrustación planar.

Como se ilustra en la Figura 6.32, la disposición bipartita estándar en dos columnas paralelas (a la izquierda) exhibe de forma explícita la saturación de conexiones ($3 \times 3 = 9$ aristas) con múltiples cruces inevitables. Incluso si se intenta reorganizar libremente la posición de los vértices en el plano (a la derecha) para trazar las conducciones mediante trayectorias curvas bordeando los nodos, se comprueba que tras conectar exitosamente 8 de los trazados, la novena arista queda confina dentro de una región delimitada por las conducciones anteriores, resultando imposible completar el tendido sin interceptar una arista preexistente. En consecuencia, la respuesta al acertijo de Dudeney es **negativa** y se concluye que el grafo bipartito completo $K_{3,3}$ es un **grafo no planar**.

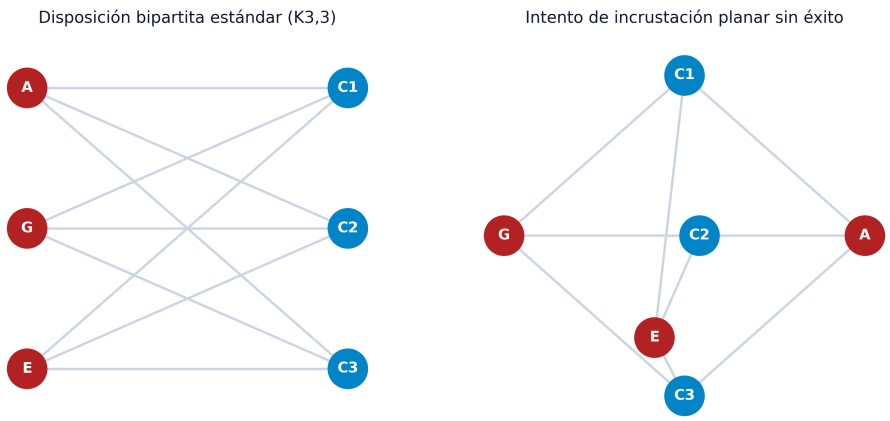

Figura 6.32: Problema de los tres servicios de Dudeney e imposibilidad de incrustación planar de K3,3

Los grafos K_5 y $K_{3,3}$ representan las dos estructuras elementales "obstructoras" que impiden que una red pueda ser dibujada en el plano. Para caracterizar la planaridad en grafos arbitrarios de mayor escala, se introduce el concepto de **homeomorfismo**.

Definición: Grafos homeomórficos

Dos grafos G_1 y G_2 se dicen **homeomórficos** (o homeomorfos) si uno de ellos puede obtenerse a partir del otro mediante una secuencia finita de operaciones de **subdivisión elemental de aristas** (insertar un nodo de grado 2 en medio de una arista) o de suprimir vértices de grado 2.

En 1930, el matemático polaco Kazimierz Kuratowski formuló la caracterización definitiva que resuelve el problema de la planaridad en la teoría de grafos.

Teorema: Teorema de Kuratowski (1930)

Un grafo $G = (V, E)$ es **planar** si y solo si no contiene ningún subgrafo parcial que sea **homeomórfico** a K_5 ó a $K_{3,3}$:

$$G \text{ es no planar } \iff \exists H \subseteq G \text{ tal que } H \text{ es homeomorfo a } K_5 \text{ ó } K_{3,3}$$

Un caso emblemático de aplicación del Teorema de Kuratowski lo constituye el **Grafo de Petersen**, un grafo 3-regular formado por 10 vértices y 15 aristas (integrado por una estrella pentagonal interior inscrita en un pentágono exterior).

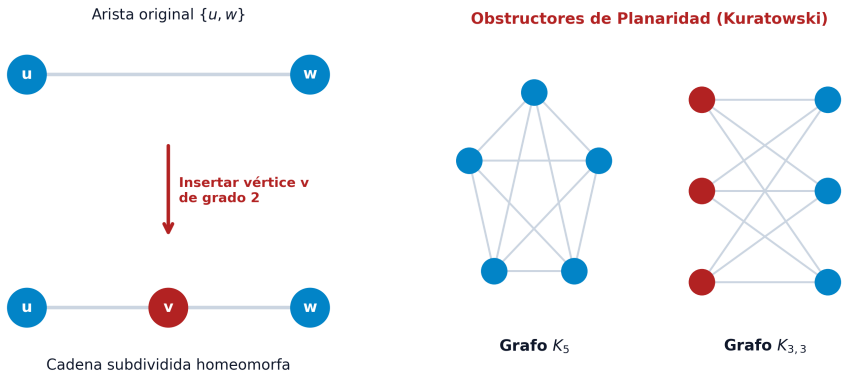

Figura 6.33: Subdivisión elemental de aristas y caracterización de Kuratowski mediante K5 y K3,3

Definición: Grafo de Petersen y sus propiedades

El **Grafo de Petersen** es un grafo 3-regular (todos sus vértices poseen grado exactamente $\delta(v) = 3$) que satisface las siguientes propiedades combinatorias únicas:

- Dos vértices adyacentes cualesquiera no comparten ningún vecino en común.
- Dos vértices no adyacentes cualesquiera comparten exactamente un vecino en común.

Como se ilustra en la Figura 6.34, a pesar de su elevada simetría geométrica, el **Grafo de Petersen es no planar**. La demostración formal se obtiene aplicando el Criterio de Kuratowski mediante la identificación de un subgrafo parcial homeomórfico al grafo bipartito completo $K_{3,3}$:

Para comprender cómo se manifiesta el obstructo de Kuratowski en esta estructura, se analizan los roles que desempeñan sus nodos y aristas:

1. **Partición de Vértices del Bipartito** $K_{3,3}$: Seleccionamos los subconjuntos disjuntos $V_1 = \{j, a, d\}$ (nodos rojos) y $V_2 = \{e, f, b\}$ (nodos azules).
2. **Construcción de las 9 Cadenas Independientes**: Para verificar la estructura de $K_{3,3}$, cada uno de los 3 vértices de V_1 debe estar comunicado con los 3 vértices de V_2 mediante cadenas disjuntas en sus aristas interiores (resaltadas en color naranja):
   - **Conexiones desde** $a \in V_1$: El nodo a conecta directamente con $b, e, f \in V_2$ mediante las 3 aristas adyacentes $\{a, b\}$, $\{a, e\}$ y $\{a, f\}$.
   - **Conexiones desde** $j \in V_1$: El nodo j conecta directamente con $e \in V_2$ ($\{j, e\}$); se comunica con $f \in V_2$ mediante la cadena $j \to h \to f$ (usando el nodo intermedio h

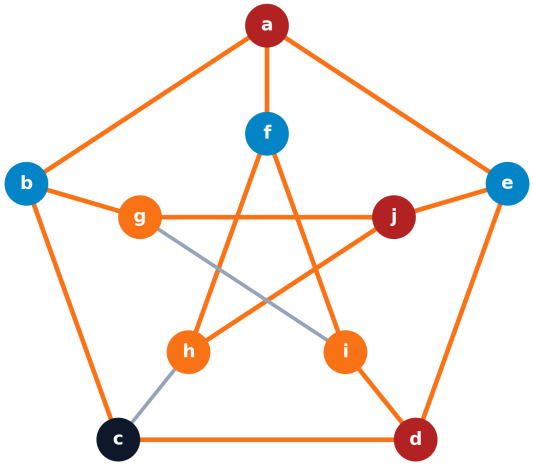

Figura 6.34: Demostración de no planaridad del Grafo de Petersen mediante homeomorfismo a K3,3

de grado 2); y se comunica con $b \in V_2$ mediante la cadena $j \to g \to b$ (usando el nodo intermedio g).

- **Conexiones desde** $d \in V_1$: El nodo d conecta directamente con $e \in V_2$ ($\{d, e\}$); se comunica con $b \in V_2$ mediante la cadena $d \to c \to b$ (usando el nodo intermedio c); y se comunica con $f \in V_2$ mediante la cadena $d \to i \to f$ (usando el nodo intermedio i).

3. **Aristas Excluidas (en gris)**: Las aristas $\{g, i\}$ y $\{c, h\}$ (representadas en gris en la Figura 6.34) no se utilizan para conformar el subgrafo y se suprimen.

Dado que todos los vértices intermedios (g, h, i, c) actúan como nodos de grado 2 que subdividen aristas, el subgrafo parcial resultante es **homeomórfico a** $K_{3,3}$, lo que prueba de forma concluyente que el Grafo de Petersen **no admite incrustación planar**.

A partir de la caracterización de Kuratowski, se observa intuitivamente que un grafo con una alta densidad de aristas resulta progresivamente más difícil de incrustar en el plano sin provocar intersecciones. Esta relación cuantitativa entre la densidad de aristas y la topología planar fue formalizada originalmente por Leonhard Euler al vincular el número de vértices (n), el número de aristas (m) y el número de caras o regiones (r) que delimita el grafo sobre el plano bidimensional.

! Teorema: Fórmula planar de Euler

Sea $G = (V, E)$ un grafo planar conexo con $n = |V|$ vértices y $m = |E|$ aristas. Si r denota el número de regiones delimitadas en cualquier incrustación planar de G (incluyendo la región exterior no acotada), entonces se verifica exactamente la relación:

$$n + r = m + 2$$

Demostración: Realizaremos la demostración por inducción matemática sobre el número de aristas $m \geq 0$.

- **Base Inductiva ($m = 0$)**: Si $m = 0$, al ser G conexo, el grafo consta de un único vértice aislado ($n = 1$). El número de regiones en el plano es la única región exterior no acotada ($r = 1$). Sustituyendo:

  $$n + r = 1 + 1 = 2 = 0 + 2 = m + 2$$

  Se cumple la igualdad base.

- **Paso Inductivo**: Asumimos como hipótesis de inducción que la relación $n' + r' = m' + 2$ es válida para todo grafo planar conexo con $m' = m - 1$ aristas. Consideremos ahora un grafo planar conexo G con m aristas:

  - **Caso 1 (G es un árbol)**: Si G no contiene ningún ciclo, entonces es un árbol y posee exactamente $m = n - 1$ aristas. Como no encierra ningún ciclo, la única cara existente es la región exterior ($r = 1$). Reemplazando:

    $$n + r = n + 1 = (m + 1) + 1 = m + 2$$

    Queda verificado.

  - **Caso 2 (G contiene al menos un ciclo)**: Si G contiene al menos un ciclo, seleccionamos una arista $e \in E$ que pertenezca a dicho ciclo. Al eliminar la arista e, obtenemos un subgrafo parcial $G' = (V, E \setminus \{e\})$ que sigue siendo conexo, con $n' = n$ vértices y $m' = m - 1$ aristas. Dado que la arista e actuaba como frontera común separando dos regiones contiguas de G, su eliminación destruye dicha frontera y fusiona las dos regiones en una sola, por lo que $r' = r - 1$. Por hipótesis inductiva aplicada a G':

    $$n' + r' = m' + 2 \implies n + (r - 1) = (m - 1) + 2 \implies n + r = m + 2$$

Por el principio de inducción matemática, el teorema queda rigurosamente demostrado para todo grafo planar conexo. ■

La Fórmula de Euler permite establecer cotas superiores algebraicas estrictas sobre el número

máximo de aristas que puede contener un grafo antes de perder la propiedad de ser planar.

Corolario: Desigualdades de planaridad y condición necesaria

1. En todo grafo planar conexo simple G con $n \geq 3$ vértices y m aristas:

$$m \leq 3n - 6$$

2. En todo grafo planar conexo simple **bipartito** (sin triángulos, donde la longitud de todo ciclo es ≥ 4) con $n \geq 3$:

$$m \leq 2n - 4$$

Demostración: En un grafo simple conexo, cada región i está delimitada por al menos 3 aristas. Al sumar las aristas frontera de todas las r regiones, cada arista es compartida como máximo por 2 regiones:

$$3r \leq \sum_{i=1}^{r} \text{aristas}(r_i) = 2m \implies r \leq \frac{2}{3}m$$

Sustituyendo $r \leq \frac{2}{3}m$ en la fórmula de Euler $n + r = m + 2$:

$$n + \frac{2}{3}m \geq m + 2 \implies n - 2 \geq \frac{1}{3}m \implies m \leq 3n - 6 \quad \blacksquare$$

Ejemplo: Demostración analítica de no planaridad

Demostrar analíticamente que los grafos K_5 (completo de 5 vértices) y $K_{3,3}$ (bipartito completo de los 3 suministros) no son planares.
Resolución para K_5 El grafo completo K_5 posee $n = 5$ vértices y $m = \binom{5}{2} = 10$ aristas. Si K_5 fuera planar, debería verificar la desigualdad $m \leq 3n - 6$:

$$10 \leq 3(5) - 6 = 15 - 6 = 9 \quad \text{(FALSO)}$$

Dado que $10 \leq 9$ es falso, K_5 es **no planar**.
Resolución para $K_{3,3}$ (Problema de Dudeney) El grafo bipartito de Dudeney $K_{3,3}$ posee $n = 6$ vértices y $m = 3 \times 3 = 9$ aristas, sin ningún triángulo interno. Si fuera planar, debería cumplir $m \leq 2n - 4$:

$$9 \leq 2(6) - 4 = 12 - 4 = 8 \quad \text{(FALSO)}$$

Dado que $9 \leq 8$ es falso, $K_{3,3}$ es **no planar**.

6.5. Representación de grafos

Para almacenar, manipular y ejecutar algoritmos de optimización sobre redes mediante ordenadores, la topología de un grafo o digrafo debe traducirse a estructuras de datos computacionales eficientes. Atendiendo a la densidad de aristas, a la variabilidad temporal de la red y a las operaciones algorítmicas requeridas, la teoría de grafos ofrece tres modalidades fundamentales de representación: matricial, vectorial y por listas de adyacencia.

6.5.1. Representación matricial

Para procesar, analizar y resolver problemas de optimización sobre redes mediante ordenadores, la topología de un grafo o digrafo debe codificarse de forma algebraica. Las dos formas matriciales clásicas para representar las conexiones de una red son la **matriz de incidencia** y la **matriz de adyacencia**.

Definición: Matriz de incidencia de un grafo no dirigido

Dado un grafo no dirigido $G = (V, E)$ con $n = |V|$ vértices ($V = \{1, \dots, n\}$) y $m = |E|$ aristas ($E = \{e_1, \dots, e_m\}$), la **matriz de incidencia nodo-arista** es una matriz rectangular $A = (a_{ik}) \in \mathbb{R}^{n \times m}$ definida por:

$$a_{ik} = \begin{cases} 1 & \text{si } e_k = \{i, *\} \in E \text{ (el nodo } i \text{ es uno de los dos extremos de la arista } e_k\text{)}, \\ 0 & \text{en otro caso.} \end{cases}$$

En un grafo no dirigido, cada columna de la matriz de incidencia A contiene exactamente dos unos, correspondientes a los dos nodos que une la arista respectiva. Asimismo, la suma de los elementos de la fila i-ésima coincide exactamente con el grado del nodo, es decir, $\sum_{k=1}^{m} a_{ik} = d(i)$. En la Figura 6.35 se ilustra la construcción explícita de esta matriz para un grafo no dirigido sobre 4 vértices y 5 aristas.

Cuando la red posee orientación en sus conexiones, la matriz de incidencia incorpora el signo de la dirección del flujo de cada arco.

Definición: Matriz de incidencia de un digrafo

Dado un digrafo $G = (V, U)$ con $n = |V|$ vértices y $m = |U|$ arcos dirigidos ($U = \{u_1, \dots, u_m\}$), la **matriz de incidencia nodo-arco** es una matriz rectangular $A =$

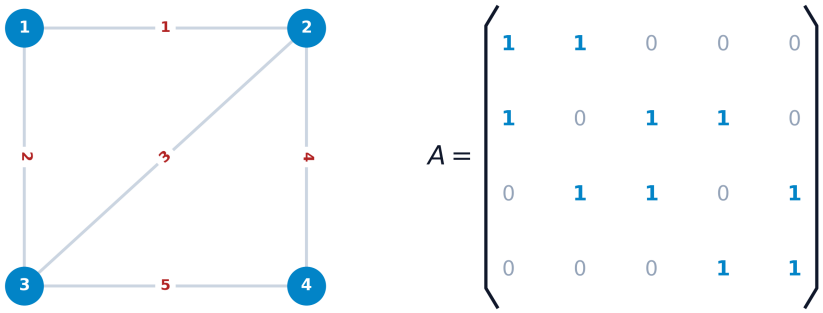

Figura 6.35: Grafo no dirigido de muestra y su correspondiente matriz de incidencia nodo-arista A

$(a_{ik}) \in \mathbb{R}^{n \times m}$ definida por:

$$a_{ik} = \begin{cases} 1 & \text{si } u_k = (i, *) \in U \text{ (el arco } u_k \text{ parte del nodo } i), \\ -1 & \text{si } u_k = (*, i) \in U \text{ (el arco } u_k \text{ llega al nodo } i), \\ 0 & \text{en otro caso.} \end{cases}$$

En esta formulación, cada columna $k = (i, j)$ de la matriz de incidencia de un digrafo contiene exactamente un $+1$ en la fila del nodo de origen i y un -1 en la fila del nodo de destino j (o viceversa según el convenio algebraico fijado). Como consecuencia, la suma de todos los elementos de cada columna es nula ($\sum_{i=1}^{n} a_{ik} = 0$), lo que implica que el rango de la matriz para un digrafo conexo de n vértices es a lo sumo $\text{rango}(A) = n - 1$. Esta propiedad confiere a la matriz de incidencia de digrafos la característica de **Total Unimodularidad (TUM)**, fundamental en programación lineal entera para garantizar que los problemas de flujo balanceado $Ax = b$ con datos enteros admitan siempre soluciones óptimas enteras sin necesidad de algoritmos de ramificación. En la Figura 6.36 se presenta la matriz de incidencia resultante para un digrafo dirigido sobre 4 vértices.

Por otra parte, la relación directa entre pares de nodos se codifica mediante la matriz de adyacencia, la cual opera directamente sobre el espacio de vértices $n \times n$.

i Definición: Matriz de adyacencia de un grafo no dirigido

Dado un grafo no dirigido $G = (V, E)$ con n vértices, la **matriz de adyacencia** es una

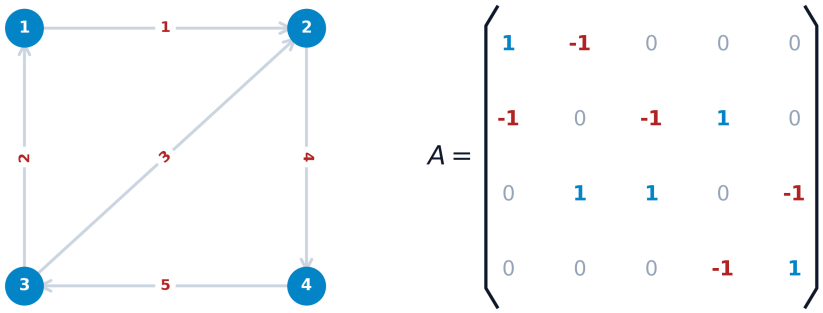

Figura 6.36: Digrafo de muestra y su correspondiente matriz de incidencia nodo-arco A

matriz cuadrada $B = (b_{ij}) \in \mathbb{R}^{n \times n}$ definida por:

$$b_{ij} = \begin{cases} 1 & \text{si } \{i,j\} \in E, \\ 0 & \text{si } \{i,j\} \notin E. \end{cases}$$

Dado que las aristas de un grafo no dirigido no poseen orientación ($\{i,j\} = \{j,i\}$), la matriz de adyacencia B es **simétrica** ($B = B^T$). Asimismo, si el grafo carece de bucles o auto-conexiones, la diagonal principal contiene exclusivamente ceros ($b_{ii} = 0$). La suma de los elementos de cualquier fila o columna es igual al grado del nodo correspondiente, $d(i) = \sum_{j=1}^{n} b_{ij}$. En la Figura 6.37 se muestra la matriz de adyacencia simétrica para la red no dirigida.

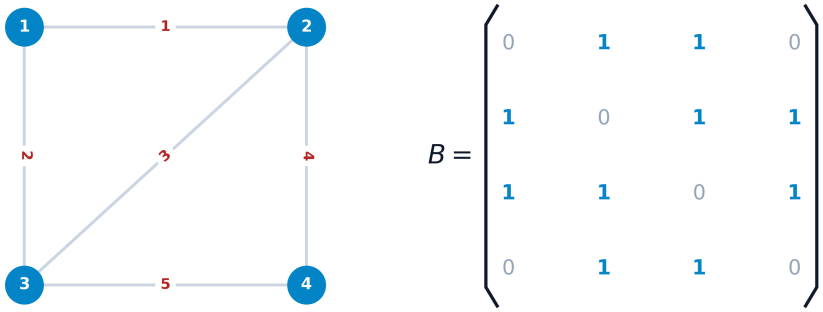

Figura 6.37: Grafo no dirigido y su correspondiente matriz de adyacencia simétrica B

En el caso de redes dirigidas, la matriz de adyacencia registra la dirección efectiva de los arcos

entre vértices.

Definición: Matriz de adyacencia de un digrafo

Dado un digrafo $G = (V, U)$ con n vértices y m arcos, la **matriz de adyacencia** es una matriz cuadrada $B = (b_{ik}) \in \mathbb{R}^{n \times n}$ definida por:

$$b_{ik} = \begin{cases} 1 & \text{si } (i,k) \in U \text{ (existe un arco dirigido desde el nodo } i \text{ hacia el nodo } k), \\ 0 & \text{en otro caso.} \end{cases}$$

Para un digrafo general, la matriz de adyacencia B es **asimétrica** ($B \neq B^T$). La suma de los elementos de la fila i indica el grado de salida del nodo ($d^+(i) = \sum_{k=1}^{n} b_{ik}$), mientras que la suma de los elementos de la columna k representa el grado de entrada ($d^-(k) = \sum_{i=1}^{n} b_{ik}$). Como propiedad analítica adicional, el elemento $(B^p)_{ik}$ de la p-ésima potencia de la matriz B^p computa el número exacto de caminos orientados de longitud p existentes entre el nodo i y el nodo k. En la Figura 6.38 se ilustra la matriz de adyacencia asimétrica asociada a la red dirigida.

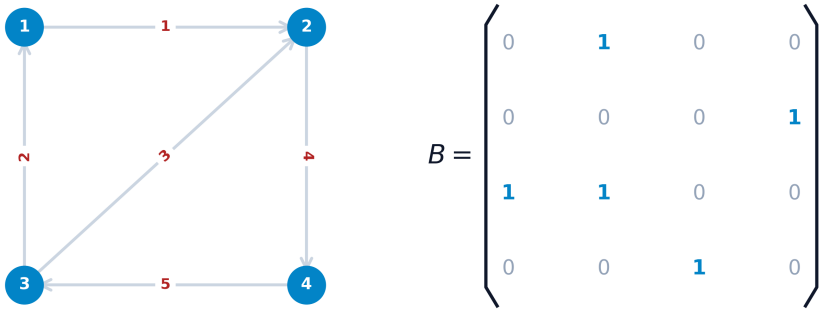

Figura 6.38: Digrafo de muestra y su correspondiente matriz de adyacencia asimétrica B

A pesar de su claridad conceptual, la representación de redes mediante matrices densas (de dimensiones $n \times m$ para la incidencia o $n \times n$ para la adyacencia) presenta serias limitaciones de eficiencia computacional cuando se trabaja con redes reales de gran escala. Por ejemplo, en una red de infraestructuras o comunicaciones con $n = 10\,000$ vértices y $m = 30\,000$ arcos, almacenar la matriz de incidencia completa requeriría aproximadamente:

$$n \cdot m \cdot 1 \text{ byte} = 10\,000 \times 30\,000 \text{ bytes} = 3 \times 10^8 \text{ bytes} \approx 300\,000 \text{ KB} = 300 \text{ MB}$$

Sin embargo, dado que en la matriz de adyacencia solo $30\,000$ de las $n^2 = 100\,000\,000$ entradas son distintas de cero (una densidad de apenas el $0.03\,\%$), y en la matriz de incidencia solo

$2m = 60\,000$ de los $300\,000\,000$ elementos son no nulos (densidad del $0.02\,\%$), la inmensa mayoría de la memoria almacenaría ceros redundantes.

Por este motivo, los algoritmos de optimización de redes y los entornos de computación científica emplean estructuras de datos dispersas (*sparse formats*) o **listas de adyacencia** para reducir el coste de memoria linealmente a $O(n + m)$.

6.5.2. Representación vectorial

Para superar las limitaciones de memoria y la ineficiencia de las matrices densas (de adyacencia o incidencia), la teoría computacional de redes utiliza el esquema de **representación vectorial de dos vectores**. Este método permite almacenar la topología completa de un digrafo o grafo utilizando únicamente dos vectores unidimensionales: un vector α de punteros o índices de dimensión $n+1$, y un vector β de nodos de destino de dimensión m (o de las aristas consideradas para grafos no dirigidos).

El máximo ahorro de memoria se consigue ordenando previamente el conjunto de arcos o aristas en **orden lexicográfico**.

Definición: Orden lexicográfico de arcos

1. $i_1 \leq i_2 \leq ... \leq i_m$ (los arcos se agrupan ordenados por su nodo de origen).
2. Si $i_k = i_{k+1}$, entonces $j_k \leq j_{k+1}$ (en caso de empate en el origen, se ordenan por su nodo de destino).

Una vez establecidos los arcos en orden lexicográfico, se construyen los dos vectores estructurales β y α:

Definición: Construcción de los vectores estructurales β y α

1. **Vector de destinos** β (de dimensión m): Almacena secuencialmente en la posición k-ésima el vértice de llegada o destino del k-ésimo arco ordenado:
$$\beta(k) = j_k, \quad \forall k \in \{1, \dots, m\}.$$
2. **Vector de punteros de inicio** α (de dimensión $n + 1$): Determina la posición de memoria en β donde comienza la lista de arcos que parten de cada nodo $i \in V$. Se define mediante el valor frontera $\alpha(n + 1) = m + 1$ y la relación de recurrencia regresiva (para $k = n, n - 1, \dots, 1$):
$$\alpha(k) = \alpha(k + 1) - d^+(k),$$

donde $d^+(k)$ denota el grado de salida (número de arcos salientes) del nodo k.

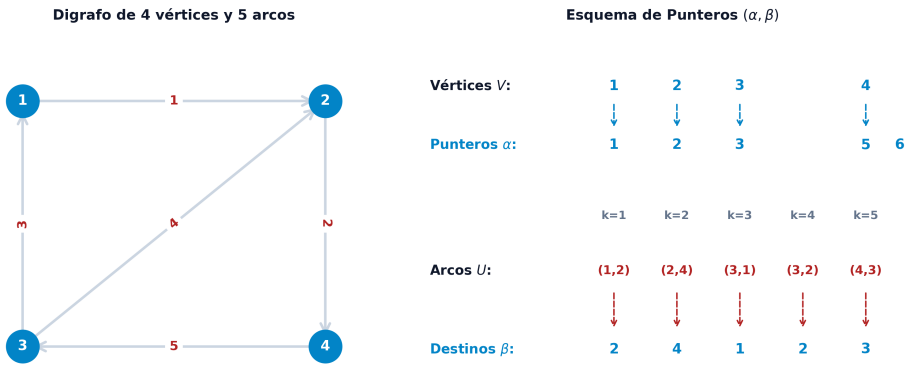

Figura 6.39: Digrafo de 4 vértices y la construcción explícita de sus vectores alfa y beta

Como se aprecia detalladamente en la Figura 6.39, la correspondencia entre la topología del digrafo y la memoria se articula a través de tres niveles de lectura:

- **Ordenación lexicográfica del conjunto de arcos** U: Los 5 arcos se ordenan según su nodo de origen y destino, generando la secuencia indexada $k = 1, \ldots, 5$: el arco $k = 1$ es $(1, 2)$, el arco $k = 2$ es $(2, 4)$, los arcos $k = 3$ y $k = 4$ son $(3, 1)$ y $(3, 2)$, y el arco $k = 5$ es $(4, 3)$.
- **Construcción directa de** β: El vector $\beta = (2, 4, 1, 2, 3)$ registra únicamente los nodos de llegada de cada uno de los arcos ordenados en la fila U.
- **Construcción regresiva de** α: Se parte de la condición frontera $\alpha(5) = m + 1 = 6$. A continuación, se descuenta el grado de salida de cada nodo de derecha a izquierda:
  - Para el nodo 4 ($d^+(4) = 1$ arco saliente, $(4, 3)$), la posición inicial es $\alpha(4) = 6 - 1 = 5$.
  - Para el nodo 3 ($d^+(3) = 2$ arcos salientes, $(3, 1)$ y $(3, 2)$), la posición inicial es $\alpha(3) = 5 - 2 = 3$.
  - Para el nodo 2 ($d^+(2) = 1$ arco saliente, $(2, 4)$), la posición inicial es $\alpha(2) = 3 - 1 = 2$.
  - Para el nodo 1 ($d^+(1) = 1$ arco saliente, $(1, 2)$), la posición inicial es $\alpha(1) = 2 - 1 = 1$.

De este modo, para recuperar los sucesores de cualquier nodo i basta consultar la sublista de β entre las posiciones $\alpha(i)$ y $\alpha(i + 1) - 1$. Por ejemplo, para el nodo 3, se examinan los índices desde $\alpha(3) = 3$ hasta $\alpha(4) - 1 = 4$, obteniendo inmediatamente los nodos de destino $\beta(3) = 1$ y $\beta(4) = 2$, correspondientes a los arcos $(3, 1)$ y $(3, 2)$.

El esquema de representación mediante dos vectores se extiende de forma totalmente natural a los **grafos no dirigidos**. Para ello, cada arista no dirigida $\{u, v\}$ se considera equivalente a un par de conexiones salientes considerando ambas orientaciones posibles. Así, una arista no dirigida contribuirá con una entrada en el vector β por cada nodo extremo donde es incidente,

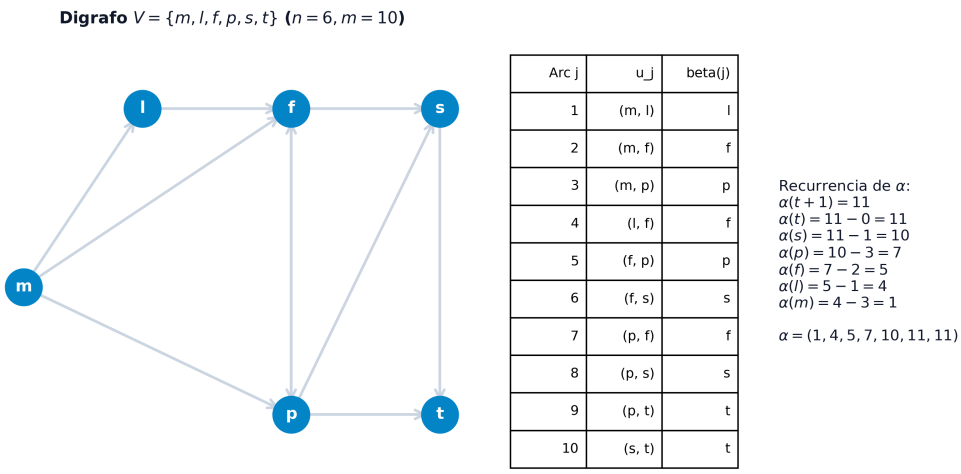

Figura 6.40: Digrafo de 6 vértices, tabla de arcos ordenados y deducción regresiva del vector alfa

y el vector α se construye utilizando la cantidad de aristas que parten de cada nodo según el orden lexicográfico prefijado de las parejas. En la Figura 6.41 se muestra la extensión vectorial aplicada a un grafo no dirigido sobre 5 vértices y 7 aristas.

6.5.3. Representación por listas de adyacencia

Frente al almacenamiento estático prefijado que exigen las matrices densas (de adyacencia o incidencia) o las estructuras vectoriales compactas como el vector α, la **representación por listas de adyacencia** constituye la alternativa computacional más flexible para gestionar redes dinámicas. Este método consiste en asociar a cada vértice $v \in V$ del grafo o digrafo una lista dinámicamente enlazada que contiene la secuencia de todos sus vértices sucesores (o nodos adyacentes a los que apunta directamente).

> **Definición: Representación por listas de adyacencia**
>
> Dada una red $G = (V, E)$ o $G = (V, U)$ con $n = |V|$ vértices, la **representación por listas de adyacencia** asigna a cada nodo $i \in V$ una lista de punteros dinámicos $\mathrm{Adj}[i]$ formada por la colección ordenada de vértices adyacentes a los que se conecta:
>
> $$\mathrm{Adj}[i] = \{j \in V \mid (i, j) \in U \text{ o } \{i, j\} \in E\}.$$

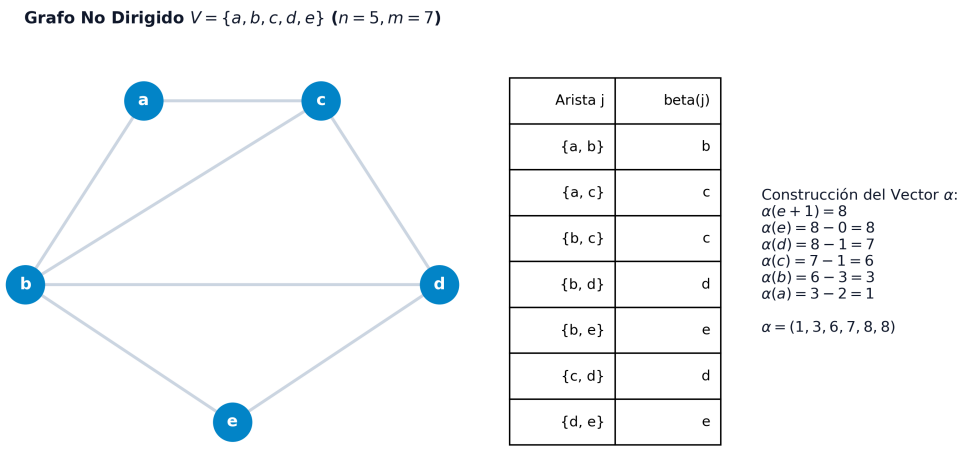

Figura 6.41: Grafo no dirigido sobre 5 vértices y su representación vectorial mediante vectores alfa y beta

La ventaja fundamental de este esquema reside en que las listas de adyacencia no requieren dimensionarse ni reservarse de forma estática antes de comenzar los cálculos, haciendo un uso eficiente de la asignación dinámica de memoria mediante punteros o nodos enlazados. Esta flexibilidad estructural permite modificar la red en tiempo real (añadiendo o eliminando vértices y conexiones sin necesidad de reestructurar o copiar bloques contiguos de memoria), lo que convierte a esta representación en la opción óptima para modelar grafos en evolución temporal o algoritmos de exploración probabilística.

En la Figura 6.42 se ilustra la arquitectura de datos dinámica para un digrafo dirigido compuesto por 6 vértices $V = \{m, l, f, p, s, t\}$. La figura contrapone la topología de la red a la izquierda con el vector cabecera de nodos y sus correspondientes cadenas horizontales de punteros hacia los nodos de destino.

Como se observa en la Figura 6.42, la cabecera vertical agrupa a los 6 vértices del digrafo, y cada fila despliega horizontalmente la secuencia de sucesores enlazados:

- El nodo m encadena los vértices adyacentes salientes $l \to f \to p$.
- El nodo l encadena únicamente su único sucesor f.
- El nodo f encadena los vértices $p \to s$.
- El nodo p encadena tres destinos $f \to s \to t$.
- El nodo s se conecta con t.
- El nodo hundimiento t mantiene una lista vacía ($\emptyset$), reflejando que su grado de salida es $d^+(t) = 0$.

El esquema de listas de adyacencia se extiende de manera inmediata a los **grafos no dirigidos**. En este escenario, cada arista no dirigida $\{u, v\}$ genera dos entradas recíprocas en las estructuras

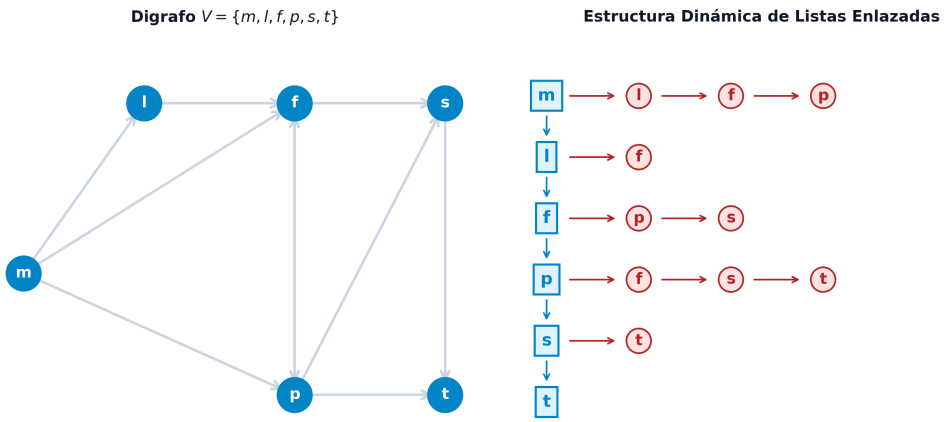

Figura 6.42: Digrafo de 6 vértices y su representación por listas de adyacencia dinámicamente enlazadas

enlazadas: el nodo v se añade a la lista de adyacencia Adj$[u]$, y simétricamente el nodo u se incorpora a la lista de adyacencia Adj$[v]$. En la Figura 6.43 se presenta la estructura de listas enlazadas recíprocas para un grafo no dirigido sobre 5 vértices $V = \{a, b, c, d, e\}$.

Como ilustra la Figura 6.43, la simetría de las aristas no dirigidas se refleja en la presencia cruzada de los vértices adyacentes: la arista $\{a, b\}$ provoca que b figure en Adj$[a]$ $(a \to b \to c)$ y que a figure en Adj$[b]$ $(b \to a \to c \to d \to e)$. La suma total de los elementos almacenados entre todas las listas enlazadas es exactamente $2m$, lo que garantiza un consumo espacial óptimo $O(n + m)$ con total versatilidad para la inserción y borrado dinámico de aristas.

6.6. Estructura matemática de los árboles

Los árboles constituyen la clase más elemental y transversal de grafos en la optimización combinatoria y el análisis de redes. Formalmente, un árbol combina la propiedad de conexión global con la ausencia de redundancia cíclica.

i Definición: Árbol y bosque

- **Árbol**: Un **árbol** $T = (V, E)$ es un grafo no dirigido **conexo y acíclico** (sin ciclos).
- **Bosque (Forest)**: Un **bosque** es un grafo no dirigido acíclico cuyas componentes conexas son árboles.

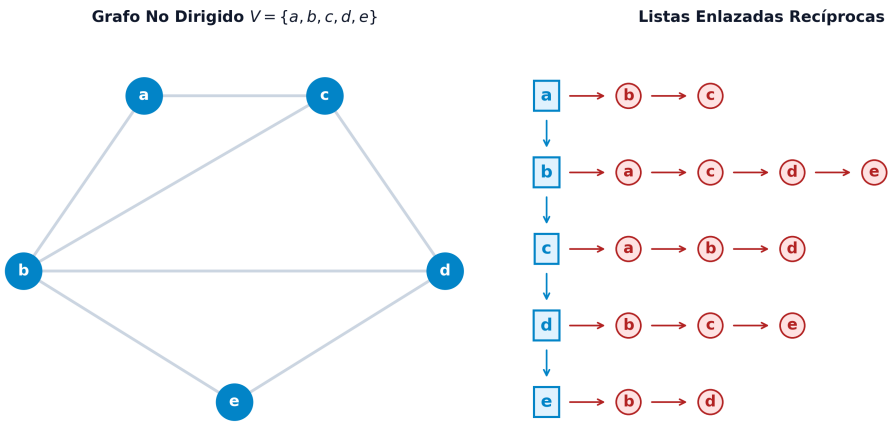

Figura 6.43: Grafo no dirigido sobre 5 vértices y su representación por listas de adyacencia recíprocas

En la Figura 6.44 se ilustra la topología de un árbol compuesto por $n = 5$ vértices y $m = 4$ aristas, junto a su correspondiente matriz de incidencia nodo-arista $A \in \mathbb{R}^{5\times 4}$. Se observa que la ausencia de circuitos cerrados implica que ninguna combinación de columnas de la matriz resulta linealmente dependiente.

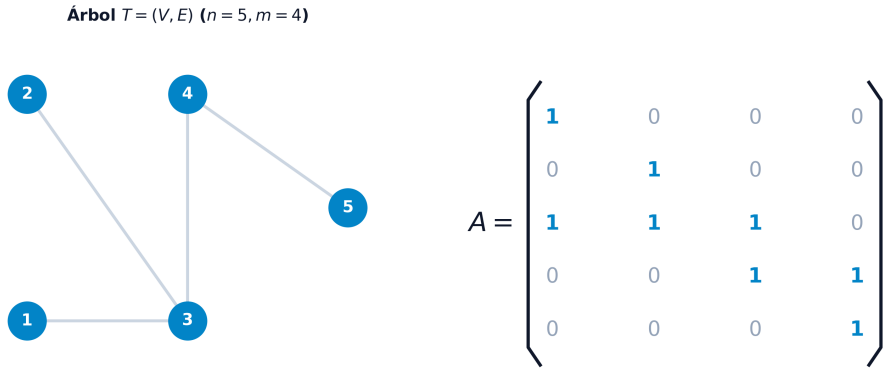

Figura 6.44: Ejemplo de un árbol sobre 5 vértices y su correspondiente matriz de incidencia nodo-arista A

La estructura de los árboles presenta múltiples caracterizaciones algebraicas y geométricas completamente equivalentes entre sí, las cuales permiten definir a un árbol desde distintos enfoques axiomáticos.

Teorema: Caracterizaciones equivalentes de un árbol

1. G es un **árbol** (es un grafo conexo y acíclico).
2. G **no posee ciclos** y si se añade una arista cualquiera entre dos vértices no adyacentes, se genera **un único ciclo**.
3. Para todo par de vértices distintos $x, y \in V$, existe **una única cadena simple** $\mu[x, y]$ que los conecta.
4. G es **conexo** y si se elimina una arista cualquiera de E, el grafo resultante **deja de ser conexo** (toda arista de un árbol es un puente o arista de corte).
5. G no posee ciclos y tiene exactamente $m = n - 1$ **aristas**.
6. G es conexo y tiene exactamente $m = n - 1$ **aristas**.

Este teorema pone de manifiesto que un árbol es una estructura estrictamente **crítica y minimal**:

- Es el grafo **mínimo en aristas que garantiza la conexidad** entre los n vértices (quitar una sola arista desconecta la red).
- Es el grafo **máximo en aristas que evita la formación de ciclos** (añadir una sola arista crea automáticamente un circuito cerrado).

En el ejemplo de la Figura 6.44 se comprueba inmediatamente esta regla fundamental del recuento de aristas: con $n = 5$ vértices, el árbol cuenta con exactamente $m = 4 = n - 1$ aristas. Como consecuencia directa, de las tres propiedades básicas de un grafo sobre n vértices: (a) ser conexo, (b) ser acíclico y (c) poseer $m = n - 1$ aristas, la presencia de **cualesquiera dos de ellas implica automáticamente la tercera**, caracterizando de forma unívoca a la familia de los árboles.

Por último, el número total de árboles soporte etiquetados distintos que pueden construirse sobre un conjunto dado de n vértices diferenciables viene determinado por la célebre **Fórmula de Cayley (1889)** (Cayley 1889):

$$T(n) = n^{n-2}$$

Esta fórmula demuestra el crecimiento exponencial combinatorio del espacio de búsqueda de árboles cuando se evalúan problemas de diseño topológico en redes de gran escala.

Las propiedades estructurales exclusivas de un árbol, en particular la existencia de una única cadena simple entre cualquier par de vértices, permiten comprimir aún más su codificación en memoria, logrando una **representación monovectorial** mediante un único vector p de dimensión n (número de vértices).

Definición: Representación monovectorial de un árbol (vector de padres o predecesores)

Dado un árbol $T = (V, E)$ con $n = |V|$ vértices, al seleccionar de forma arbitraria un nodo raíz inicial $x_0 \in V$, la topología de T queda unívocamente determinada por el **vector de**

padres o predecesores $p \in \mathbb{R}^n$, definido para cada vértice $v \in V$ como:

$$p(v) = \begin{cases} x_0, & \text{si } v = x_0 \text{ (el nodo raíz es su propio padre),} \\ u, & \text{si } u \in V \text{ es el único antecesor directo de } v \text{ en el camino desde } x_0 \text{ a } v. \end{cases}$$

Dado que desde el nodo raíz x_0 existe un camino único hacia cualquier otro vértice $v \neq x_0$, el antecesor inmediato $u = p(v)$ está definido sin ambigüedad. Esta representación monovectorial resulta extremadamente eficiente en la práctica, pues almacena la topología de un árbol empleando solo n enteros en memoria, frente a los $O(n+m)$ o matrices $n \times n$ necesarios en grafos generales.

La estructura del vector de padres p depende directamente de la elección del nodo raíz x_0, adaptando la orientación jerárquica del árbol. En la Figura 6.45 se analiza esta variabilidad sobre el árbol de 5 vértices:

- **Enraizamiento en** $x_0 = 1$ (panel izquierdo): La raíz es el nodo 1 ($p(1) = 1$). El camino desde 1 hasta 5 pasa por el nodo 3 ($p(3) = 1$) y el nodo 4 ($p(4) = 3$), de modo que $p(5) = 4$. Los nodos hojas 2 y 4 tienen como padre directo a 3 ($p(2) = 3, p(4) = 3$). El vector de padres resultante es $p = (1, 3, 1, 3, 4)$.
- **Enraizamiento en** $x_0 = 5$ (panel derecho): La raíz se traslada al nodo 5 ($p(5) = 5$). La jerarquía se invierte a lo largo del tronco principal: el padre de 4 es 5 ($p(4) = 5$), el padre de 3 es 4 ($p(3) = 4$), y los hijos de 3 son 1 y 2 ($p(1) = 3, p(2) = 3$). El vector de padres resultante es $p = (3, 3, 4, 5, 5)$.

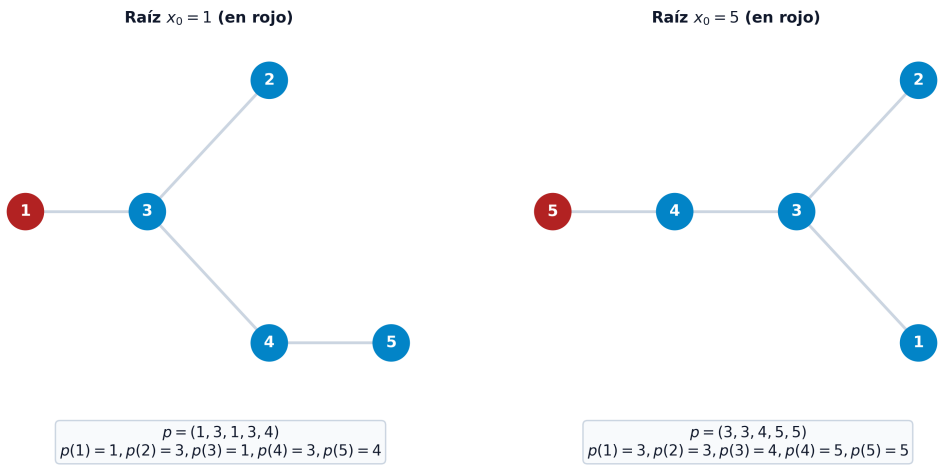

Figura 6.45: Representación monovectorial mediante el vector de padres p según la elección del nodo raíz x0

6.7. Árbol soporte de mínimo peso (MST)

La incorporación de costes, pesos, tiempos o capacidades a las aristas de un grafo da lugar a la estructura matemática de una **red valorada**. En este contexto de optimización, el **Problema del Árbol Soporte de Mínimo Peso** (*Minimum Spanning Tree*, MST) persigue encontrar la infraestructura de conexión de menor coste acumulado que mantiene la conectividad global entre todos los nodos de la red sin introducir circuitos cerrados redundantes. Este problema constituye una de las aplicaciones más emblemáticas de la optimización combinatoria en el diseño de redes de transporte, distribución eléctrica, canalización de fluidos y algoritmos de agrupamiento (*clustering*).

i Definición: Red valorada y peso total de una arista

Una **red valorada** es un par $(G, \mathbf{d})$, donde $G = (V, E)$ o $G = (V, U)$ es un grafo o digrafo y $\mathbf{d} \in \mathbb{R}^m$ es un vector cuyas componentes identifican el valor numérico, peso o coste $d(e) = d_e$ asociado a cada arista $e \in E$ (o c_{ij} a cada arco $(i, j) \in U$). Se habla de **red no dirigida** o **red dirigida** según las conexiones estén orientadas o no.

! Formulación primal del problema del árbol soporte de mínimo peso

Dada una red no dirigida valorada $(G, \mathbf{d})$ con $G = (V, E)$ conexo y valores de peso $\{d_e : e \in E\}$, el **Problema del Árbol Soporte de Mínimo Peso** consiste en encontrar un árbol soporte $H = (V, T)$ con $T \subset E$ que minimice la suma de los pesos de sus aristas:

$$\begin{aligned} \min_{T \subset E} \quad & d(T) = \sum_{e \in T} d_e \\ \text{sujeto a} \quad & H = (V, T) \text{ es un árbol soporte de } G \end{aligned}$$

En la Figura 6.46 se ilustra el espacio de soluciones sobre una red no dirigida de 5 vértices $V = \{a, b, c, d, e\}$ comparando tres árboles soporte candidatos alternativos:

- **Árbol candidato** T_1 (aristas $\{a, b\}, \{a, c\}, \{c, d\}, \{b, e\}$): Acumula un peso total $d(T_1) = 3 + 2 + 4 + 1 = 10$.
- **Árbol candidato** T_2 (aristas $\{a, b\}, \{b, c\}, \{b, d\}, \{b, e\}$): Acumula un peso total $d(T_2) = 3 + 6 + 2 + 1 = 12$.
- **Árbol mínimo** T_3 **(Óptimo)** (aristas $\{a, c\}, \{a, b\}, \{b, e\}, \{e, d\}$): Acumula el peso mínimo posible $d(T_3) = 2 + 3 + 1 + 1 = 7$.

Para resolver el problema del árbol soporte de mínimo peso sin necesidad de evaluar exhaustivamente la cantidad exponencial de árboles soporte ($T(n) = n^{n-2}$ por la Fórmula de Cayley), la teoría de grafos se apoya en una propiedad fundamental de optimalidad local conocida como la **Propiedad del Corte**.

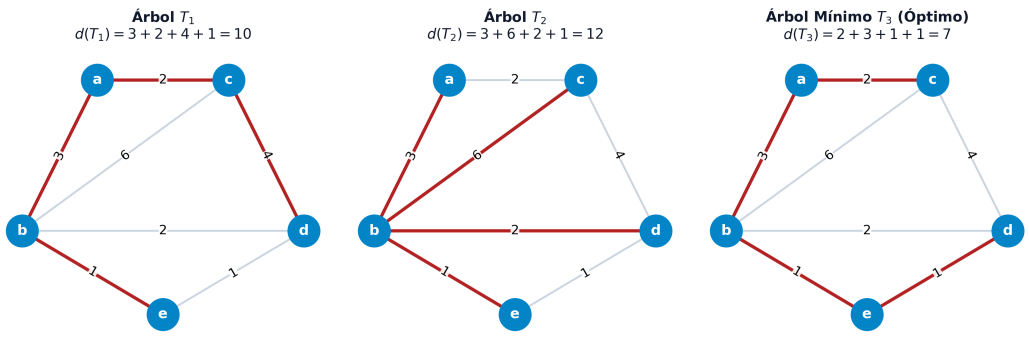

Figura 6.46: Comparación del peso acumulado en tres árboles soporte candidatos sobre una red no dirigida

> **!** Teorema: Propiedad del corte (Cut Property)
>
> Sea $(G, \mathbf{d})$ una red valorada conexa no dirigida. Dado cualquier subconjunto propio de vértices $S \subset V$, si la arista $e^* = \{u, v\}$ con $u \in S, v \in V \setminus S$ es la arista de **peso estrictamente mínimo** que cruza el corte $w(S)$, entonces la arista e^* **pertenece obligatoriamente a todo Árbol Soporte de Mínimo Peso** de G.

Esta propiedad del corte constituye el fundamento teórico sobre el que se edifican los dos célebres algoritmos golosos (*greedy*) para la construcción eficiente del MST: el **Algoritmo de Kruskal (1956)** (Kruskal 1956) y el **Algoritmo de Prim (1957)** (Prim 1957).

6.7.1. Algoritmo de Kruskal

El **Algoritmo de Kruskal**, propuesto en 1956 por Joseph Kruskal (Kruskal 1956), adopta un enfoque goloso (*greedy*) centrado en el ordenamiento global de las aristas. La estrategia fundamental consiste en examinar secuencialmente las aristas de la red en orden creciente de peso, e incorporar a la solución parcial la arista de menor coste disponible, siempre que dicha arista **no cree un ciclo** con las aristas ya seleccionadas.

En las fases intermedias del proceso, el conjunto de aristas seleccionadas T no forma necesariamente una estructura conexa, sino un **bosque parcial de árboles disjuntos** que se van fusionando paulatinamente hasta formar un único árbol soporte cuando se alcanzan exactamente $|T| = n - 1$ aristas.

Esquema: Algoritmo de Kruskal

Dada una red no dirigida valorada $G = (V, E, \mathbf{d})$ con $n = |V| > 1$ vértices, sin bucles y con pesos $\{d_e : e \in E\}$:

- **Paso 0 (Inicialización)**: Definir el conjunto de aristas del árbol $T = \emptyset$ y el conjunto de aristas candidatas disponibles $A \leftarrow E$.
- **Paso 1 (Bucle de Selección Golosa)**: Mientras $|T| < n - 1$ y $A \neq \emptyset$:
  1. Identificar la arista de menor peso $e \in A$.
  2. Actualizar el conjunto de disponibles: $A \leftarrow A \setminus \{e\}$.
  3. Si el subconjunto $T \cup \{e\}$ **no contiene ningún ciclo**, aceptar la arista: $T \leftarrow T \cup \{e\}$.
- **Paso 2 (Criterio de Parada y Verificación)**:
  - Si $|T| = n - 1$, el par $H = (V, T)$ es el **Árbol Soporte de Mínimo Peso (MST)**.
  - Si $A = \emptyset$ y $|T| < n - 1$, la red G no era conexa, obteniéndose el bosque soporte de mínimo peso de sus componentes.

Para implementar el algoritmo con la máxima eficiencia computacional, la verificación de si una arista candidata $e = \{i, j\}$ forma un ciclo en T no requiere explorar la red completa, sino utilizar la estructura de datos de **conjuntos disjuntos** (*Union-Find*):

- Inicialmente, cada uno de los n vértices constituye su propia componente disjunta independiente: $S_k = \{k\}$ para todo $k \in V$.
- Al evaluar una arista $e = \{i, j\}$, se consulta el identificador de subconjunto al que pertenecen sus extremos mediante la operación Find(i) y Find(j).
- Si Find$(i) \neq$ Find(j), los vértices pertenecen a componentes distintas, garantizando que la incorporación de $\{i, j\}$ **no genera ningún ciclo**. En tal caso, la arista se añade a T y se unen ambas componentes mediante la operación Union$(S(i), S(j))$.
- Si Find$(i) =$ Find(j), ambos vértices ya estaban conectados previamente a través de otras aristas de T, por lo que $\{i, j\}$ se descarta por formar un ciclo cerrado redundante.

Adicionalmente, se pueden eliminar de forma anticipada de A todas las aristas restantes que unan vértices que ya pertenezcan al mismo subconjunto disjunto.

Ejemplo: Aplicación del algoritmo de Kruskal

Obtener el árbol de expansión de peso mínimo mediante el Algoritmo de Kruskal para la red no dirigida sobre $n = 6$ vértices presentada en la Figura 6.47.
Planteamiento e Inicialización: La red no dirigida $G = (V, E)$ está compuesta por

6 vértices $V = \{1, 2, 3, 4, 5, 6\}$ y 11 aristas valoradas. Su topología y su correspondiente matriz simétrica de pesos $B \in \mathbb{R}^{6\times 6}$ se detallan en la Figura 6.47.

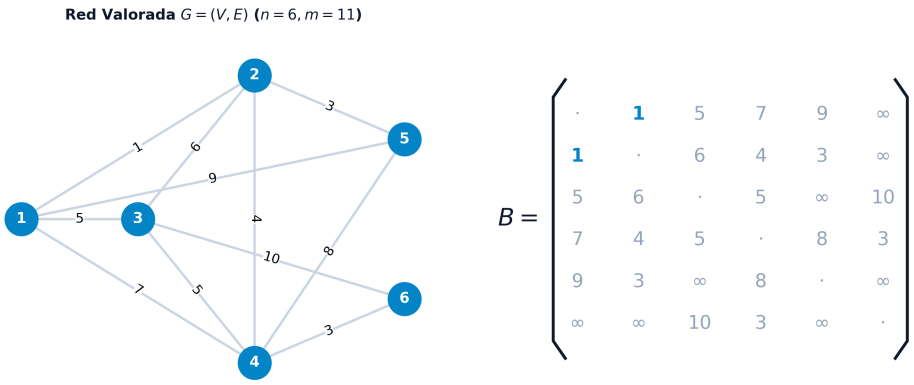

Figura 6.47: Red no dirigida de 6 vértices y su correspondiente matriz simétrica de pesos B

En el estado inicial ($k = 0$):

- El árbol parcial solución se encuentra vacío: $T = \emptyset$.
- Cada vértice pertenece a su propio subconjunto disjunto independiente:

$$\{1\},\ \{2\},\ \{3\},\ \{4\},\ \{5\},\ \{6\}$$

Resolución Iterativa Paso a Paso:

1. **Iteración $k = 1$ (peso mínimo $d = 1$)**: Se selecciona la arista de menor peso global $e_1 = \{1, 2\}$ con $d_{\{1,2\}} = 1$. Dado que los nodos 1 y 2 pertenecen a componentes distintas (Find(1) $\neq$ Find(2)), se acepta la arista en T y se fusionan sus subconjuntos:
   - Árbol parcial: $T = \{\{1, 2\}\}$.
   - Componentes disjuntas: $\{1, 2\}$, $\{3\}$, $\{4\}$, $\{5\}$, $\{6\}$.
2. **Iteración $k = 2$ (peso mínimo $d = 3$, resolución de empate)**: Las aristas no seleccionadas de menor peso son $\{2, 5\}$ y $\{4, 6\}$, ambas de peso 3. Se selecciona la arista $\{2, 5\}$. Como 5 no pertenece a la componente de 2 ($\{1, 2\} \neq \{5\}$), se acepta la arista:
   - Árbol parcial: $T = \{\{1, 2\}, \{2, 5\}\}$.
   - Componentes disjuntas: $\{1, 2, 5\}$, $\{3\}$, $\{4\}$, $\{6\}$.
3. **Iteración $k = 3$ (peso mínimo $d = 3$)**: Se selecciona la arista disponible $\{4, 6\}$ de peso 3. Puesto que Find(4) $\neq$ Find(6), la arista no forma ciclos y se incorpora a la solución:

- Árbol parcial: $T = \{\{1,2\},\{2,5\},\{4,6\}\}$.
- Componentes disjuntas: $\{1,2,5\}$, $\{3\}$, $\{4,6\}$.

4. **Iteración $k = 4$ (peso mínimo $d = 4$)**: La arista candidata de menor peso es $\{2,4\}$ con peso 4. Dado que el nodo 2 pertenece al bloque $\{1,2,5\}$ y el nodo 4 pertenece al bloque $\{4,6\}$, ambas componentes son distintas y la arista no genera ciclos. Se acepta $\{2,4\}$ y se fusionan ambos bloques:

   - Árbol parcial: $T = \{\{1,2\},\{2,5\},\{4,6\},\{2,4\}\}$.
   - Componentes disjuntas: $\{1,2,4,5,6\}$, $\{3\}$.

5. **Iteración $k = 5$ (peso mínimo $d = 5$, resolución de empate final)**: Las aristas disponibles de menor peso son $\{1,3\}$ y $\{3,4\}$, ambas de peso 5. Se selecciona la arista $\{1,3\}$. Puesto que el nodo 3 se encuentra en la componente aislada $\{3\}$ y el nodo 1 está en el bloque principal $\{1,2,4,5,6\}$, la arista se acepta y se logra la conectividad total de la red:

   - Árbol parcial final: $T = \{\{1,2\},\{2,5\},\{4,6\},\{2,4\},\{1,3\}\}$.
   - Componentes disjuntas final: $\{1,2,3,4,5,6\}$ (1 sola componente conexa).

En la Figura 6.48 se ilustra la evolución gráfica de la construcción progresiva del árbol paso a paso a lo largo de las 5 iteraciones.

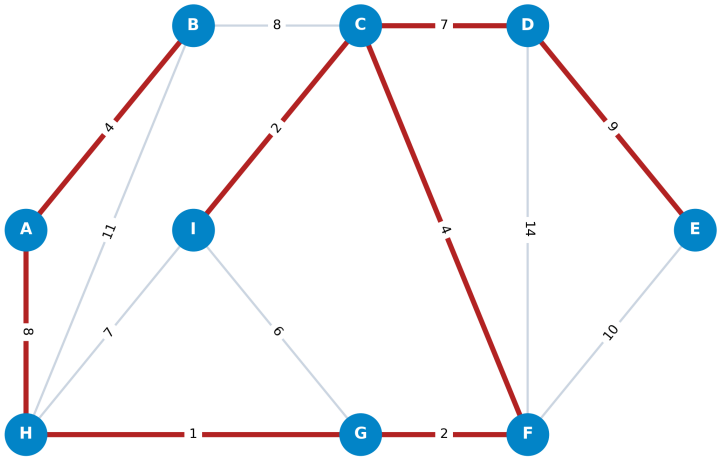

Figura 6.48: Traza gráfica de la evolución iterativa del Algoritmo de Kruskal paso a paso

Conclusión y Peso del Árbol Soporte de Mínimo Peso: Al alcanzarse $|T| = n-1 = 5$ aristas, el algoritmo finaliza. El árbol soporte de mínimo peso $H = (V,T)$ acumula un

peso total óptimo de:

$$d(T) = d_{\{1,2\}} + d_{\{2,5\}} + d_{\{4,6\}} + d_{\{2,4\}} + d_{\{1,3\}} = 1 + 3 + 3 + 4 + 5 = 16$$

Observación sobre la No Unicidad de la Solución: Puesto que en la iteración $k = 5$ existía un empate de peso mínimo ($d = 5$) entre las aristas $\{1, 3\}$ y $\{3, 4\}$, si en lugar de seleccionar $\{1, 3\}$ se hubiera optado por incorporar $\{3, 4\}$, se obtendría un **árbol soporte de mínimo peso alternativo**:

$$T' = \{\{1, 2\}, \{2, 5\}, \{4, 6\}, \{2, 4\}, \{3, 4\}\}$$

El peso acumulado en esta solución alternativa es $d(T') = 1 + 3 + 3 + 4 + 5 = 16$, idéntico al del árbol T. Esto demuestra que cuando una red contiene aristas con pesos repetidos, el árbol soporte de mínimo peso **no es necesariamente único**, aunque el valor del peso óptimo $d(T)$ permanezca siempre constante e invariable.

! Teorema: Correctitud del algoritmo de Kruskal

Dada una red conexa valorada $(G, \mathbf{d})$, el conjunto de aristas T construido secuencialmente por el Algoritmo de Kruskal constituye un **Árbol Soporte de Mínimo Peso** del grafo G.
Demostración: La correctitud del procedimiento se deriva directamente de la Propiedad del Corte. En cada paso k, la arista seleccionada $e = \{u, v\}$ es la de peso estrictamente mínimo entre todas las aristas disponibles que unen la componente disjunta $S(u)$ con el resto de la red $V \setminus S(u)$. Por consiguiente, por el Teorema de la Propiedad del Corte, la arista e pertenece obligatoriamente a un árbol soporte de mínimo peso, garantizando la optimalidad global del árbol resultante al finalizar las $n - 1$ iteraciones.

Complejidad Computacional: La eficiencia del Algoritmo de Kruskal depende fundamentalmente de la etapa de ordenación previa de las aristas y del rendimiento de la estructura de datos *Union-Find*:

- **Aristas preordenadas**: Si la colección de m aristas ya se encuentra clasificada por orden de peso, el bucle principal realiza a lo sumo m operaciones Find y $n - 1$ operaciones Union. Empleando la estructura *Union-Find* optimizada con compresión de caminos y unión por rango, la complejidad resultante es $O(m \cdot \alpha(n))$, donde $\alpha(n)$ es la inversa de la función de Ackermann (efectivamente $O(m \cdot n)$ en cotas elementales o casi lineal en la práctica).
- **Caso general sin ordenación previa**: Cuando las aristas no están clasificadas, el coste computacional dominante viene determinado por el algoritmo de ordenación (como *Heapsort* o *Quicksort*), que requiere un tiempo de $O(m \log m)$. Puesto que en cualquier grafo simple $m \leq n^2$ y por tanto $\log m \leq 2 \log n$, la complejidad temporal total del

Algoritmo de Kruskal se establece en $O(m \log m)$ o equivalentemente $O(m \log n)$.

6.7.2. Algoritmo de Prim

El **Algoritmo de Prim** fue publicado en 1957 por Robert C. Prim (Prim 1957). No obstante, este procedimiento fue descubierto inicialmente por el matemático checo Vojtěch Jarník en 1930 (Jarník 1930) y posteriormente redescubierto de forma independiente por Edsger W. Dijkstra en 1959 (Dijkstra 1959). Por esta razón, en la literatura científica especializada se le conoce formalmente como el **Algoritmo de Jarník-Prim-Dijkstra**.

A diferencia del Algoritmo de Kruskal (que evalúa aristas globales formando un bosque inconexo en sus fases intermedias), el Algoritmo de Prim construye el árbol soporte de mínimo peso haciendo crecer **una única componente conexa continua** (o arborescencia) a partir de un nodo raíz inicial $v_1 \in V$ elegido de forma arbitraria.

Sea $P \subset V$ el conjunto de vértices ya integrados en la solución parcial (inicialmente $P = \{v_1\}$) y $N = V \setminus P$ el conjunto de nodos pendientes de visitar. En cada iteración, el algoritmo analiza las aristas del corte $w(P)$ que conectan el conjunto P con los nodos de N. A continuación, aplica directamente la **Propiedad del Corte**, seleccionando la arista $e^* = \{x^*, y^*\}$ (con $x^* \in P$ y $y^* \in N$) de peso estrictamente mínimo, incorporando el nuevo vértice y^* al subconjunto P.

i Esquema: Algoritmo de Prim

Dada una red no dirigida valorada $G = (V, E, \mathbf{d})$ conexa con $n = |V| > 1$ vértices, sin bucles y con pesos de arista $\{d_e : e \in E\}$:

- **Paso 0 (Inicialización)**:
  1. Seleccionar un nodo raíz inicial $v_1 \in V$ de manera arbitraria.
  2. Inicializar el conjunto de nodos visitados $P = \{v_1\}$ y el de no visitados $N = V \setminus \{v_1\}$.
  3. Inicializar el conjunto de aristas del árbol $T = \emptyset$ y el contador de iteraciones $i = 1$.
- **Paso 1 (Selección de la Arista Mínima del Corte)**:
  - Identificar la arista $e^* = \{x^*, y^*\} \in E$ tal que $x^* \in P, y^* \in N$ que minimice el peso $d(e^*)$:
    $$d(e^*) = \text{mín}\{d(e) : e = \{x, y\}, x \in P, y \in N\}$$
  - **Criterio de Conexidad**:
    - Si $d(e^*) = \infty$ (no existen aristas que crucen el corte $w(P)$), detener el proceso: la red G no es conexa.

- Si $d(e^*) < \infty$, actualizar los conjuntos:

$$P \leftarrow P \cup \{y^*\}, \quad N \leftarrow N \setminus \{y^*\}, \quad T \leftarrow T \cup \{e^*\}$$

- **Paso 2 (Criterio de Parada e Incremento)**:
  - Si $i = n-1$, detener el procedimiento: el par $H = (V, T)$ es un **Árbol Soporte de Mínimo Peso (MST)**.
  - Si $i < n-1$, actualizar $i \leftarrow i+1$ y regresar al Paso 1.

Ejemplo: Aplicación del algoritmo de Prim

Obtener el árbol de expansión de peso mínimo mediante el Algoritmo de Prim para la red no dirigida sobre $n = 6$ vértices presentada en la Figura 6.47.
Planteamiento e Inicialización: Se considera la red no dirigida $G = (V, E)$ de 6 vértices $V = \{1, 2, 3, 4, 5, 6\}$ y 11 aristas valoradas, cuya topología y matriz simétrica de pesos $B \in \mathbb{R}^{6\times 6}$ se detallan en la Figura 6.47.
A diferencia del Algoritmo de Kruskal, el Algoritmo de Prim requiere seleccionar un nodo raíz inicial de partida a partir del cual crecerá la arborescencia. Se elige arbitrariamente el nodo raíz $v_1 = 1$.
En el estado inicial ($i = 1$):

- Vértices integrados en la arborescencia: $P = \{1\}$.
- Vértices pendientes de visitar: $N = \{2, 3, 4, 5, 6\}$.
- Conjunto de aristas del árbol: $T = \emptyset$.

Desarrollo Iterativo del Algoritmo:

- **Iteración $i = 1$**:
  - Estado de los conjuntos: $P = \{1\}$, $N = \{2, 3, 4, 5, 6\}$, $T = \emptyset$.
  - Aristas del corte $w(P)$ que conectan P con N: $\{1, 2\}$ $(d = 1)$, $\{1, 3\}$ $(d = 5)$, $\{1, 4\}$ $(d = 7)$, $\{1, 5\}$ $(d = 9)$.
  - Arista de peso mínimo elegida: $e^* = \{1, 2\}$ con $d(e^*) = 1$.
  - Actualización de conjuntos: $P = \{1, 2\}$, $N = \{3, 4, 5, 6\}$, $T = \{\{1, 2\}\}$, incrementando a $i = 2$.
- **Iteración $i = 2$**:
  - Estado de los conjuntos: $P = \{1, 2\}$, $N = \{3, 4, 5, 6\}$, $T = \{\{1, 2\}\}$.
  - Aristas del corte $w(P)$ que conectan P con N: $\{1, 3\}$ $(d = 5)$, $\{1, 4\}$ $(d = 7)$, $\{1, 5\}$ $(d = 9)$, $\{2, 3\}$ $(d = 6)$, $\{2, 4\}$ $(d = 4)$, $\{2, 5\}$ $(d = 3)$.
  - Arista de peso mínimo elegida: $e^* = \{2, 5\}$ con $d(e^*) = 3$.
  - Actualización de conjuntos: $P = \{1, 2, 5\}$, $N = \{3, 4, 6\}$, $T = \{\{1, 2\}, \{2, 5\}\}$, incrementando a $i = 3$.

- **Iteración** $i = 3$:
  - Estado de los conjuntos: $P = \{1, 2, 5\}$, $N = \{3, 4, 6\}$, $T = \{\{1, 2\}, \{2, 5\}\}$.
  - Aristas del corte $w(P)$ que conectan P con N: $\{1, 3\}$ $(d = 5)$, $\{1, 4\}$ $(d = 7)$, $\{2, 3\}$ $(d = 6)$, $\{2, 4\}$ $(d = 4)$, $\{5, 4\}$ $(d = 8)$, $\{5, 3\}$ $(d = 9)$.
  - Arista de peso mínimo elegida: $e^* = \{2, 4\}$ con $d(e^*) = 4$.
  - Actualización de conjuntos: $P = \{1, 2, 4, 5\}$, $N = \{3, 6\}$, $T = \{\{1, 2\}, \{2, 5\}, \{2, 4\}\}$, incrementando a $i = 4$.
- **Iteración** $i = 4$:
  - Estado de los conjuntos: $P = \{1, 2, 4, 5\}$, $N = \{3, 6\}$, $T = \{\{1, 2\}, \{2, 5\}, \{2, 4\}\}$.
  - Aristas del corte $w(P)$ que conectan P con N: $\{1, 3\}$ $(d = 5)$, $\{2, 3\}$ $(d = 6)$, $\{4, 3\}$ $(d = 5)$, $\{5, 3\}$ $(d = 9)$, $\{4, 6\}$ $(d = 3)$.
  - Arista de peso mínimo elegida: $e^* = \{4, 6\}$ con $d(e^*) = 3$.
  - Actualización de conjuntos: $P = \{1, 2, 4, 5, 6\}$, $N = \{3\}$, $T = \{\{1, 2\}, \{2, 5\}, \{2, 4\}, \{4, 6\}\}$, incrementando a $i = 5$.
- **Iteración** $i = 5$:
  - Estado de los conjuntos: $P = \{1, 2, 4, 5, 6\}$, $N = \{3\}$, $T = \{\{1, 2\}, \{2, 5\}, \{2, 4\}, \{4, 6\}\}$.
  - Aristas del corte $w(P)$ que conectan P con el único nodo restante $N = \{3\}$: $\{1, 3\}$ $(d = 5)$, $\{4, 3\}$ $(d = 5)$, $\{2, 3\}$ $(d = 6)$, $\{5, 3\}$ $(d = 9)$, $\{6, 3\}$ $(d = 10)$.
  - **Resolución de empate**: Existen dos aristas de peso mínimo $d = 5$ ($\{1, 3\}$ y $\{3, 4\}$). Se selecciona libremente $e^* = \{1, 3\}$.
  - Actualización final: $P = \{1, 2, 3, 4, 5, 6\} = V$, $N = \emptyset$, $T = \{\{1, 2\}, \{2, 5\}, \{2, 4\}, \{4, 6\}, \{1, 3\}\}$, incrementando a $i = 6$.

En la Figura 6.49 se ilustra la evolución iterativa continua de la arborescencia conexa a lo largo de las 5 iteraciones del Algoritmo de Prim.

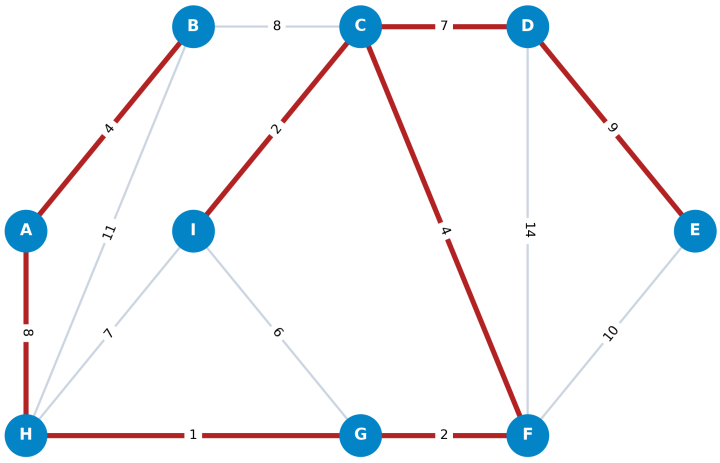

Figura 6.49: Traza gráfica de la evolución iterativa del Algoritmo de Prim paso a paso

Conclusión y Peso del Árbol Soporte de Mínimo Peso: Al cumplirse $P = V$ (o de forma equivalente $|T| = n - 1 = 5$), el proceso finaliza. El árbol soporte de mínimo peso $H = (V, T)$ acumula un peso total idéntico al obtenido por Kruskal:

$$d(T) = d_{\{1,2\}} + d_{\{2,5\}} + d_{\{2,4\}} + d_{\{4,6\}} + d_{\{1,3\}} = 1 + 3 + 4 + 3 + 5 = 16$$

Observación sobre la Solución Alternativa: Puesto que en la iteración $i = 5$ existía un empate de peso mínimo ($d = 5$) entre las aristas del corte $\{1, 3\}$ y $\{3, 4\}$, si en lugar de seleccionar $\{1, 3\}$ se hubiera optado por incorporar $\{3, 4\}$, se obtendría una **solución alternativa**:

$$T' = \{\{1, 2\}, \{2, 5\}, \{2, 4\}, \{4, 6\}, \{3, 4\}\}$$

El peso acumulado en esta arborescencia alternativa es $d(T') = 1 + 3 + 4 + 3 + 5 = 16$, exactamente igual al peso del árbol T. Esto reafirma de forma consistente que el Algoritmo de Prim y el Algoritmo de Kruskal llegan al mismo valor del peso del Árbol Soporte de Mínimo Peso ($d(T) = 16$), produciendo la misma familia de soluciones óptimas alternativas ante empates en los pesos de las aristas.

6.7.3. Aplicaciones en aprendizaje no supervisado: clustering basado en MST

En la ciencia de datos moderna y el aprendizaje automático (*machine learning*), uno de los objetivos esenciales del aprendizaje no supervisado (trabajo con datos no etiquetados) es

descubrir patrones latentes y estructurar el conjunto de observaciones en grupos o clústeres homogéneos (**clustering**).

La agrupación de datos se realiza en función de la semejanza o desemejanza entre las observaciones.

Definición: Medida de desemejanza y distancia

Dada una colección de observaciones o variables x, y, una **función de desemejanza** $\delta(x, y)$ asigna un valor numérico real que cuantifica la divergencia entre ambas observaciones, satisfaciendo las siguientes propiedades fundamentales:

1. **Coincidencia nula**: $\delta(x, y) = 0 \iff x = y$.
2. **No negatividad**: $\delta(x, y) \geq 0$ para todo x, y.
3. **Simetría**: $\delta(x, y) = \delta(y, x)$.

Si además la función verifica la **desigualdad triangular** $\delta(x, y) \leq \delta(x, z) + \delta(y, z)$, la medida constituye una **distancia métrica** en sentido estricto (como la distancia euclídea $\|x - y\|_2$).

Comparativa: k-Medias frente a clustering basado en MST

- **Algoritmo de las k-Medias (k-*means*)**:

  Es la técnica no supervisada más popular para particionar un conjunto de datos en K clústeres disjuntos $S = \{S_1, \dots, S_K\}$ tales que $S_i \cap S_j = \emptyset$ para todo $i \neq j$, minimizando la variabilidad dentro de cada grupo (*within-cluster variation*):

  $$W(S, c) = \sum_{k=1}^{K} W(S_k) = \sum_{k=1}^{K} \sum_{x_i \in S_k} \|x_i - c_k\|^2$$

  donde c_k representa el centroide (media aritmética) del clúster S_k. Al estar basado en regiones de Voronoi delimitadas por hiperplanos, exige implícitamente que los clústeres posean una geometría esférica o convexa.

- **Clustering basado en el Árbol Soporte de Mínimo Peso (MST)**: Modela el conjunto de n observaciones como una red completa $G = (V, E, \delta)$ y calcula su MST $T = (V, E')$. Al eliminar las $K - 1$ aristas de mayor peso (mayor desemejanza), particiona la red de forma determinista en K componentes conexas de geometría arbitraria y no lineal.

Como se ilustra en la Figura 6.50, en el panel izquierdo se construye el Árbol Soporte de Mínimo Peso completo sobre $n = 9$ observaciones valoradas por su desemejanza. Al identificar y cortar las $K - 1 = 2$ aristas de mayor peso (la arista $\{2, 4\}$ de longitud 8.5 y $\{3, 7\}$ de longitud

7.0, resaltadas en línea discontinua), el grafo se particiona de forma determinista en $K = 3$ clústeres disjuntos bien delimitados (panel derecho).

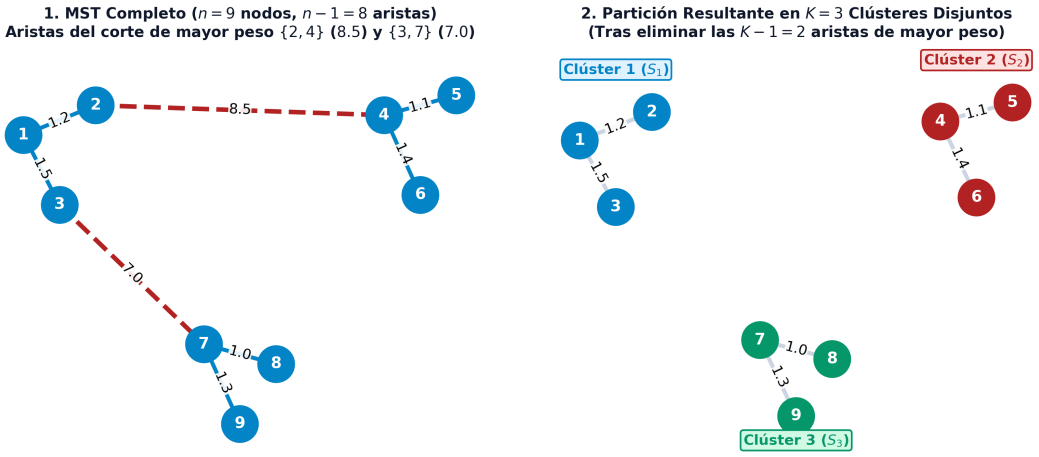

Figura 6.50: Proceso de agrupamiento (*clustering*) mediante el MST: identificación y corte de las $K - 1 = 2$ aristas de mayor peso (panel izquierdo) y partición resultante en $K = 3$ clústeres disjuntos (panel derecho)

En la Figura 6.51 se observa la capacidad superior del agrupamiento basado en MST para resolver conjuntos de datos con geometrías no convexas complejas (como anillos concéntricos o lunas entrelazadas), situaciones en las que el algoritmo de k-medias fracasa al imponer fronteras rígidas de Voronoi.

Generalización mediante Funciones de Calidad de la Partición: Aunque la regla primaria consiste en quitar los $K - 1$ enlaces de mayor peso del MST, es posible encontrar criterios de decisión mucho más elaborados y adaptados a la estructura de los datos mediante una función de evaluación objetiva.

Sea $\mathcal{X}_\ell$ el conjunto de posibles particiones del conjunto de observaciones $\mathbf{X}$ en ℓ clústeres o componentes conexas disjuntas. Dado un subgrafo $G' = (V, E'')$ con ℓ componentes conexas, denotamos por $C(V, E'') = (X_1, X_2, \ldots, X_\ell) \in \mathcal{X}_\ell$ a la partición asociada a G'. Se define una función de calidad o validez $F : \mathcal{X}_\ell \to \mathbb{R}$ que evalúa la bondad de la partición. El objetivo consiste en encontrar la partición que maximiza la función F.

Para maximizar F sobre el MST se aplica un procedimiento voraz (*greedy*) divisivo:

i Esquema: Maximización de la función de calidad F sobre el MST

Dada una red de datos $G = (V, E, \delta)$ y una función de calidad F:

1. **Paso 1**: Obtener el árbol soporte de mínimo peso $T = \text{MST}(G) = (V, E', \delta)$.

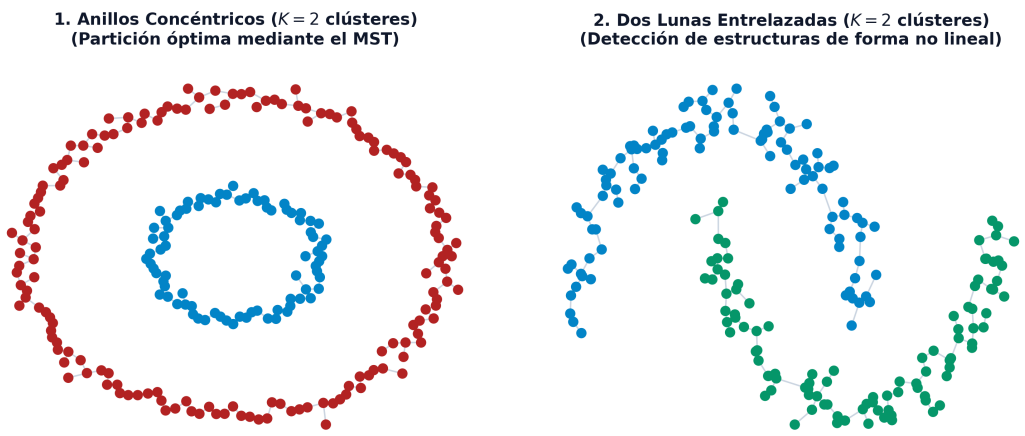

Figura 6.51: Detección de estructuras de forma no lineal mediante el MST: agrupamiento en anillos concéntricos (panel izquierdo) y dos lunas entrelazadas (panel derecho)

2. **Paso 2**: Inicializar el conjunto de aristas activas $E'' = E'$.
3. **Paso 3**: Para $i = 1, \ldots, K-1$, hacer:
   - Identificar la arista $\{u, v\} \in E''$ cuya eliminación maximice la calidad de la partición resultante:
   $$\{u, v\} = \arg\max_{e \in E''} F(C(V, E'' \setminus \{e\}))$$
   - Eliminar la arista $\{u, v\}$ de E'': $E'' \leftarrow E'' \setminus \{\{u, v\}\}$.
4. **Paso 4**: Terminar y devolver la partición $C(V, E'')$ como resultado.

i Criterios y funciones de calidad F en la literatura

En la literatura científica se emplean diversas especificaciones para la función de calidad F:

- **Criterio de mayor longitud (Separación)**:
$$F(X_1, \ldots, X_\ell) = \sum_{i=1}^{\ell} \sum_{x_j \in X_i} x_j$$
(Equivalente a eliminar de forma directa las $K-1$ aristas de mayor peso en el MST).

- **Suma de cuadrados intra-grupo negativa ($-WCSS$)**:

$$-WCSS(X_1, \dots, X_\ell) = -\sum_{i=1}^{\ell} \sum_{x_j \in X_i} \|x_j - \mu_i\|^2$$

  donde μ_i representa el centroide del i-ésimo clúster.

- **Criterio de información / entropía (IC)**:

$$IC(X_1, \dots, X_\ell) = -d \sum_{i=1}^{\ell} \frac{n_i}{n} \log \frac{L_i}{n_i} - \sum_{i=1}^{\ell} \frac{n_i}{n} \log \frac{n_i}{n}$$

  donde L_i es la suma de los pesos de las aristas en el subárbol asociado al i-ésimo clúster y n_i es el número de observaciones en ese grupo.

- **Desviación típica de los pesos de las aristas**: Minimización de la dispersión de las distancias entre aristas dentro de los clústeres.

⚠ Estrategia aglomerativa e inconvenientes prácticos

Una alternativa al algoritmo divisivo anterior consiste en utilizar una estrategia aglomerativa o acumulativa (de filosofía análoga al Algoritmo de Kruskal): comenzar con $E'' = \emptyset$ e ir añadiendo aristas una a una del MST que maximicen la función $F(C(V, E'' \cup \{\{u, v\}\}))$ hasta alcanzar K componentes conexas.
Sin embargo, esta aproximación aglomerativa resulta computacionalmente menos eficiente y puede presentar problemas cuando se forman grupos aislados con muy pocas observaciones en las iteraciones iniciales. Para resolver esta inestabilidad, diversos autores modifican el algoritmo introduciendo penalizaciones o restricciones (utilizando el **índice de Gini**) que dan prioridad a los grupos más pequeños cuando existe una disparidad excesiva en la dimensión de los clústeres.

7 Caminos mínimos

El **problema del camino mínimo** (*Shortest Path Problem*) constituye una de las piedras angulares de la optimización de redes y de la investigación operativa contemporánea (Ahuja, Magnanti, y Orlin 1993; Bertsekas 1998; Cormen et al. 2009). Su propósito fundamental es determinar la ruta de menor coste, distancia o tiempo acumulado entre un nodo origen s y un nodo destino t, o bien desde un origen único hacia la totalidad de los vértices de una red.

Más allá de sus aplicaciones inmediatas en la planificación de transporte, la navegación GPS, el enrutamiento de paquetes en redes de telecomunicaciones y la logística de distribución, el problema del camino mínimo actúa como subproblema crítico en algoritmos de mayor envergadura, tales como los métodos de generación de columnas en programación entera, el diseño de redes de flujo de coste mínimo y la programación dinámica multietapa.

! Objetivos de aprendizaje

Al finalizar este capítulo, serás capaz de:

1. **Formular y fundamentar** el problema del camino mínimo en digrafos valorados definiendo formalmente su matriz de distancias directas y analizando las condiciones de existencia de solución óptima finita.
2. **Deducir y resolver** las ecuaciones de optimalidad de Bellman a partir del Principio de Optimalidad de la programación dinámica, identificando las causas de insuficiencia ante circuitos de coste nulo o negativo.
3. **Aplicar la ordenación topológica** en redes acíclicas (DAGs) para calcular caminos mínimos en tiempo lineal $O(|V| + |A|)$.
4. **Demostrar y ejecutar** el algoritmo de Dijkstra en redes con costes no negativos, comprendiendo su carácter goloso y su complejidad computacional.
5. **Programar y evaluar** el algoritmo de Bellman-Ford para redes con arcos de coste negativo, aplicando el criterio de detección de circuitos de coste negativo en tiempo $O(|V| \cdot |A|)$.
6. **Formular y analizar** el problema mediante programación lineal primal-dual, justificando la integridad de las soluciones mediante la Total Unimodularidad (TUM) de la matriz de incidencia nodo-arco e interpretando los potenciales nodales duales.
7. **Calcular distancias entre todos los pares de nodos** aplicando el algoritmo de multiplicación de matrices en álgebra min-suma y la relación de recurrencia de

programación dinámica del algoritmo de Floyd-Warshall.

7.1. Definición formal y condiciones de existencia

Consideremos un digrafo conexo valorado $G = (V, U, \mathbf{d})$, donde $V = \{1, 2, \dots, n\}$ representa el conjunto de vértices o nodos, $U \subseteq V \times V$ denota el conjunto de arcos dirigidos con cardinalidad $|U| = m$, y $\mathbf{d} \in \mathbb{R}^m$ es un vector cuyas componentes $d(u) = d_{ij}$ asignan un coste, tiempo o distancia a cada arco dirigido $u = (i, j) \in U$.

Definición: Red valorada y longitud de un camino

Dado un camino dirigido $\mu = (v_0, v_1, v_2, \dots, v_k)$ en G, compuesto por una secuencia de arcos $(v_{j-1}, v_j) \in U$ para todo $j = 1, \dots, k$, la **longitud o coste acumulado del camino** $d(\mu)$ se define como la suma de las longitudes de los arcos que lo integran:

$$d(\mu) = \sum_{u \in \mu} d_u = \sum_{j=1}^{k} d_{v_{j-1}, v_j}$$

Para formalizar algebraicamente las conexiones de la red, se introduce la **matriz de distancias directas** $D \in \overline{\mathbb{R}}^{n \times n}$, cuyas componentes d_{ij} se definen para todo par de vértices $i, j \in V$ como:

$$d_{ij} = \begin{cases} 0 & \text{si } i = j \\ d_u & \text{si } u = (i, j) \in U \\ +\infty & \text{si } (i, j) \notin U \text{ y } i \neq j \end{cases}$$

Esta representación matricial permite modelar problemas de transporte, telecomunicaciones y logística de variada naturaleza, como se ilustra en los dos ejemplos siguientes.

Ejemplo: Red de itinerarios de vuelos internacionales

Un viajero desea planificar la ruta de coste mínimo para volar desde Madrid (M) hasta Tokio (T). Al no existir un vuelo directo, debe realizar al menos una escala en los aeropuertos intermedios de Londres (L), París (P), Frankfurt (F) o Singapur (S).
El problema se modela sobre un digrafo $G = (V, U)$ donde los vértices representan los aeropuertos $V = \{M, L, F, P, S, T\}$ y los arcos corresponden a los vuelos directos disponibles con sus respectivas tarifas en euros:

- Desde M: arcos (M, L) con coste 20, (M, F) con coste 40, (M, P) con coste 27.
- Desde L: arco (L, F) con coste 10.
- Entre F y P: arcos bidireccionales (F, P) con coste 11 y (P, F) con coste 9.
- Desde F y P hacia Asia: (F, S) con coste 90, (P, S) con coste 100, (P, T) con coste 150.
- Desde S: arco (S, T) con coste 35.

Como se ilustra en la Figura 7.1, la resolución de este problema consiste en hallar la secuencia de arcos dirigidos que conecte M con T minimizando el sumatorio de las tarifas asociadas.

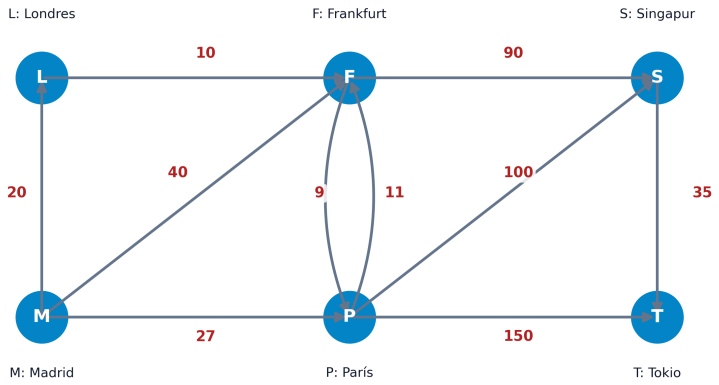

Figura 7.1: Representación en digrafo valorado del problema de itinerarios de vuelos internacionales entre Madrid y Tokio

Ejemplo: Planificación de transporte marítimo con costes y beneficios

Un buque de carga debe determinar la ruta óptima de transporte desde un puerto de origen O hasta un puerto de destino D. En los puertos intermedios, el buque puede recoger carga para trasladarla a otro puerto obteniendo un beneficio neto, o bien viajar de vacío con el consiguiente coste operativo de combustible.
El problema se representa sobre un digrafo valorado en el que los vértices representan los puertos y los arcos las rutas navegables. El peso de cada arco cuantifica el beneficio o pérdida económica del trayecto:

- Si las pérdidas y costes operativos se representan con valores positivos ($d_{ij} > 0$).
- Si los beneficios netos se representan mediante valores negativos ($d_{ij} < 0$, interpretados como "pérdidas negativas").

La solución óptima corresponderá al camino de coste mínimo (máximo beneficio neto acumulado) que une el origen O con el destino D.

A diferencia de otras estructuras de optimización como el árbol soporte de mínimo peso (MST), el cual siempre cuenta con una solución finita y acotada para cualquier grafo conexo, el problema del camino mínimo entre dos vértices $s, t \in V$ presenta particularidades fundamentales cuando la red contiene arcos con costes negativos. Antes de desarrollar los algoritmos de resolución, resulta imprescindible analizar las condiciones matemáticas de existencia de solución óptima.

Ejemplo: Paradoja del camino en grafos con circuitos de coste negativo

Consideremos la red dirigida ilustrada en la Figura 7.2, compuesta por 7 vértices y arcos con costes positivos y negativos. Se desea determinar el camino mínimo desde el nodo a hasta el nodo f.
Una primera aproximación evalúa el camino simple $\mu_1 = (a, b, e, f)$, cuyo coste acumulado es:

$$d(\mu_1) = d_{ab} + d_{be} + d_{ef} = 3 + (-6) + 2 = -1$$

Sin embargo, observemos que el subgrafo contiene el circuito cerrado $\mu_C = (b, e, f, b)$, cuyo coste total es:

$$d(\mu_C) = d_{be} + d_{ef} + d_{fb} = -6 + 2 + 2 = -2 < 0$$

Si trazamos un nuevo camino $\mu_2 = (a, b, e, f, b, e, f)$ que recorre el circuito μ_C una vez adicional antes de finalizar en f, se obtiene un coste de:

$$d(\mu_2) = 3 + (-6) + 2 + 2 + (-6) + 2 = -3 < -1$$

Al iterar k veces sobre el circuito μ_C, el coste acumulado es $d(\mu_k) = -1 - 2k$. Conforme $k \to \infty$, el coste tiende a $-\infty$. En consecuencia, **no existe ningún camino mínimo finito** hacia el nodo f.

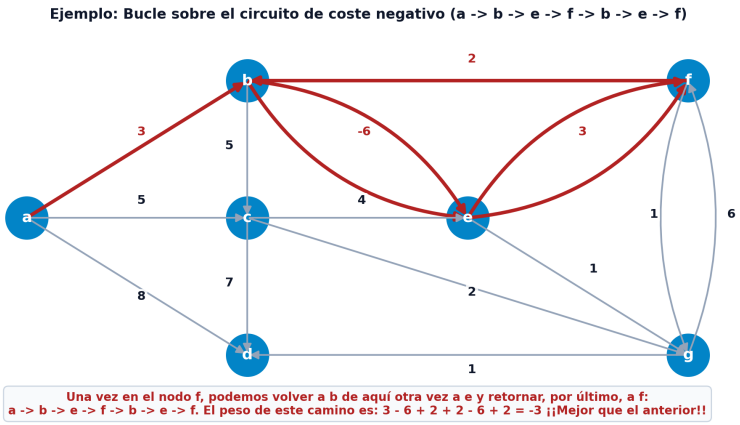

Figura 7.2: Traza gráfica de la paradoja del camino en grafos con circuitos de coste negativo

El comportamiento divergente mostrado en el ejemplo anterior evidencia que la presencia de circuitos cerrados con coste total estrictamente negativo impide la existencia de una solución finita. Esta propiedad permite enunciar el teorema fundamental de existencia de solución óptima.

! Teorema: Condición de existencia de solución óptima finita

Dada una red dirigida valorada $G = (V, U, \mathbf{d})$ y dos vértices fijados $s, t \in V$, el problema de encontrar el camino mínimo entre s y t tiene solución óptima finita si y sólo si se satisfacen simultáneamente las siguientes dos hipótesis:

- **Hipótesis H_1 (Accesibilidad)**: Existe al menos un camino dirigido en G que une el nodo origen s con el nodo destino t.
- **Hipótesis H_2 (Ausencia de circuitos de coste negativo)**: Ningún camino dirigido de s a t contiene un circuito cuyo coste acumulado sea estrictamente negativo.

Demostración: ($\Longrightarrow$) Si no se cumple H_1, no existen caminos de s a t, por lo que la distancia es $+\infty$. Si no se cumple H_2, existe un camino de s a t que atraviesa un circuito μ_C con $d(\mu_C) < 0$. Recorriendo μ_C arbitrariamente k veces, el coste acumulado se reduce a $-\infty$, impidiendo la existencia de un mínimo finito.
($\Longleftarrow$) Si se cumplen H_1 y H_2, el número de caminos simples (elementales, sin repetición de vértices) entre s y t es finito al ser $|V| = n$ finito. Como todo circuito en los caminos tiene coste $d(\mu_C) \geq 0$, la eliminación de cualquier circuito no incrementa la longitud del camino. Por tanto, el mínimo sobre el conjunto finito de caminos simples es un valor real bien definido y finito.

7.2. Ecuaciones de optimalidad de Bellman

El fundamento teórico dominante para la resolución de problemas de rutas mínimas descansa en el **Principio de Optimalidad** formulado por Richard E. Bellman en 1957 (Bellman 1957, 1958).

Principio de Optimalidad de Bellman (1957)

Una secuencia óptima de decisiones que resuelve un problema de optimización multietapa debe cumplir la propiedad de que, cualquiera que sea el estado inicial y la decisión inicial adoptada, las decisiones restantes deben constituir una **política óptima** con respecto al estado resultante de la primera decisión.
En el contexto de redes: **Toda subpolítica de una política óptima es a su vez una subpolítica óptima**.

La traslación de este principio a la teoría de caminos mínimos establece que si un camino $\mu^*[s,t]$ es de coste mínimo entre el origen s y el destino t, cualquier subcamino $\mu^*[i,j]$ contenido en él debe ser, de forma obligatoria, el camino de coste mínimo entre los vértices intermedios i y j.

Denotemos por u_{ij} la longitud del camino mínimo entre los vértices i y j. Para cualquier par $s,t \in V$, la distancia óptima satisface la relación de consistencia:

$$u_{st} = \min_{i,j \in V} \{u_{si} + u_{ij} + u_{jt}\}$$

En particular, si fijamos un origen único $s = 1$ y denotamos por $u_j \equiv u_{1j}$ a la distancia mínima desde el origen 1 al nodo $j \in V$, podemos descomponer la última etapa identificando el predecesor directo i del nodo j, obteniendo el sistema fundamental de ecuaciones de optimalidad.

Ecuaciones de optimalidad de Bellman

Dada una red dirigida valorada $G = (V, U, \mathbf{d})$ sin circuitos de coste negativo, las distancias mínimas u_j desde el nodo origen 1 a cada uno de los demás nodos $j \in V \setminus \{1\}$ satisfacen el sistema de ecuaciones no lineales:

$$\begin{aligned} u_1 &= 0 \\ u_j &= \min_{k \neq j} \{u_k + d_{kj}\}, \quad \forall j = 2, \ldots, n \end{aligned}$$

Donde d_{kj} son las componentes de la matriz de distancias directas D.

Las ecuaciones de optimalidad de Bellman identifican las condiciones necesarias que deben verificar las distancias mínimas u_j desde un vértice origen a todos los demás nodos de la red. Físicamente, establecen que la longitud del camino mínimo hasta cualquier nodo j equivale al mínimo entre las distancias acumuladas a sus predecesores directos k más el coste del arco de entrada (k, j). Sin embargo, por sí solas, estas ecuaciones presentan dos limitaciones fundamentales: no indican el orden secuencial en el que deben resolverse los nodos (lo que en redes generales exigiría explorar $O(n!)$ combinaciones) y no garantizan la unicidad de solución en presencia de circuitos de coste nulo o negativo.

Para observar el funcionamiento analítico de este sistema, examinemos un primer ejemplo numérico sobre un digrafo de 5 nodos.

Ejemplo: Planteamiento y resolución de las ecuaciones de Bellman

Consideremos el digrafo valorado de 5 nodos presentado en la Figura 7.3. Se desea formular las ecuaciones de Bellman y determinar la distancia mínima desde el nodo 1 al resto de los vértices.

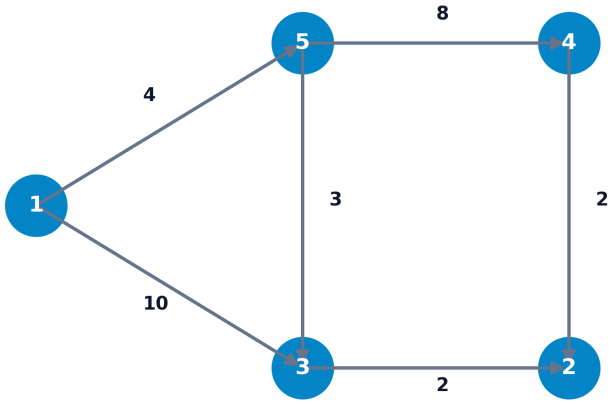

Figura 7.3: Digrafo valorado de 5 nodos para la formulación de las ecuaciones de Bellman

El sistema de ecuaciones de Bellman para el origen $s = 1$ se plantea expresando la etiqueta de cada nodo en función del mínimo de sus predecesores directos:

$$
\begin{aligned}
u_1 &= 0 \\
u_5 &= \text{mín}\{u_1 + d_{15}\} = \text{mín}\{0 + 4\} = 4 \\
u_3 &= \text{mín}\{u_1 + d_{13}, u_5 + d_{53}\} = \text{mín}\{0 + 10, 4 + 3\} = \text{mín}\{10, 7\} = 7 \\
u_4 &= \text{mín}\{u_5 + d_{54}\} = \text{mín}\{4 + 8\} = 12 \\
u_2 &= \text{mín}\{u_3 + d_{32}, u_4 + d_{42}\} = \text{mín}\{7 + 2, 12 + 2\} = \text{mín}\{9, 14\} = 9
\end{aligned}
$$

Al resolver consecutivamente el sistema, se obtienen las distancias geodésicas y la arborescencia óptima:

- **Vector de distancias mínimas**: $\mathbf{u} = (u_1, u_2, u_3, u_4, u_5) = (0, 9, 7, 12, 4)$.
- **Vector de predecesores**: $\text{Pred} = (1, 3, 5, 5, 1)$.
- **Arborescencia de caminos mínimos**: $\{(1, 5), (5, 3), (5, 4), (3, 2)\}$.

A pesar de su claridad teórica, es crucial recalcar que las ecuaciones de Bellman constituyen una **condición necesaria** de optimalidad, pero no siempre suficiente. En particular, si la red contiene circuitos cerrados con coste nulo ($d(\mu_C) = 0$), el sistema algebraico admite múltiples soluciones, de las cuales solo una representa las verdaderas distancias mínimas.

Ejemplo: No unicidad de solución por presencia de circuito de coste nulo

Consideremos el digrafo de 3 nodos mostrado en la Figura 7.4, con arcos $(1, 2)$ de peso 10, $(2, 3)$ de peso 1 y $(3, 2)$ de peso -1. El circuito formado por los nodos 2 y 3 posee un coste total $d_{23} + d_{32} = 1 + (-1) = 0$.
El sistema de ecuaciones de Bellman para el origen $s = 1$ es:

$$
\begin{aligned}
u_1 &= 0 \\
u_2 &= \text{mín}\{u_1 + d_{12}, u_3 + d_{32}\} = \text{mín}\{0 + 10, u_3 - 1\} \\
u_3 &= \text{mín}\{u_1 + d_{13}, u_2 + d_{23}\} = \text{mín}\{0 + \infty, u_2 + 1\} = u_2 + 1
\end{aligned}
$$

Todo vector (u_1, u_2, u_3) que satisfaga la relación $u_1 = 0$, $u_2 \leq 10$ y $u_3 = u_2 + 1$ constituye una solución matemática del sistema:

- Si fijamos $u_2 = 10 \implies u_3 = 11$. Este vector $(0, 10, 11)$ identifica la distancia mínima real.
- Sin embargo, el vector arbitrario $(0, 5, 6)$ también satisface el sistema algebraico ($5 = \text{mín}\{10, 6-1\} = 5$ y $6 = 5+1$), pero **no representa las distancias mínimas**.

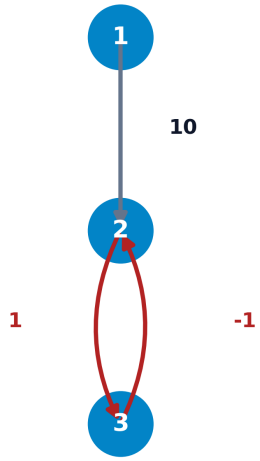

Figura 7.4: Digrafo con un circuito de coste nulo que provoca la existencia de soluciones algebraicas no únicas en Bellman

Para garantizar que las ecuaciones de Bellman determinen de forma única las distancias geodésicas y permitan construir la arborescencia soporte de caminos mínimos, se exige la ausencia estricta de circuitos dirigidos de coste nulo o negativo.

Proposición: Construcción de la arborescencia asociada a las ecuaciones de Bellman

Las ecuaciones de optimalidad de Bellman:

$$\begin{aligned} u_1 &= 0 \\ u_j &= \min_{k \neq j} \{u_k + d_{kj}\}, \quad \forall j \neq 1 \end{aligned}$$

permiten construir de forma única la **arborescencia de caminos mínimos** con raíz en el origen 1 si y sólo si en la red no existen circuitos dirigidos de longitud o coste nulo ni negativo.

Apliquemos nuevamente esta proposición al problema planteado en la red de aeropuertos para verificar la construcción analítica de sus rutas óptimas.

Ejemplo: Planteamiento de las ecuaciones de Bellman en el problema de la red de aeropuertos

Consideremos el problema de la red de aeropuertos presentado en la Figura 7.1, con el origen fijado en el aeropuerto de Madrid (M). Se desea formular las ecuaciones de Bellman y obtener el camino mínimo desde el nodo M a todos los demás destinos.
El sistema de ecuaciones de Bellman se plantea evaluando la etiqueta de cada aeropuerto como el mínimo sobre todos sus vuelos de llegada directos:

$$
\begin{aligned}
u_M &= 0 \\
u_L &= \text{mín}\{u_M + d_{ML}\} = \text{mín}\{0 + 20\} = 20 \\
u_P &= \text{mín}\{u_M + d_{MP}, u_F + d_{FP}\} = \text{mín}\{0 + 27, 30 + 9\} = 27 \\
u_F &= \text{mín}\{u_M + d_{MF}, u_L + d_{LF}, u_P + d_{PF}\} \\
&= \text{mín}\{0 + 40, 20 + 10, 27 + 11\} = \text{mín}\{40, 30, 38\} = 30 \\
u_S &= \text{mín}\{u_F + d_{FS}, u_P + d_{PS}\} = \text{mín}\{30 + 90, 27 + 100\} = \text{mín}\{120, 127\} = 120 \\
u_T &= \text{mín}\{u_P + d_{PT}, u_S + d_{ST}\} = \text{mín}\{27 + 150, 120 + 35\} = \text{mín}\{177, 155\} = 155
\end{aligned}
$$

La resolución directa del sistema proporciona las siguientes soluciones:

- **Vector de distancias mínimas**: $\mathbf{u} = (u_M, u_L, u_F, u_P, u_S, u_T) = (0, 20, 30, 27, 120, 155)$.
- **Arborescencia de rutas óptimas**: Integrada por las trayectorias $M \to L$ (Londres: 20), $M \to P$ (París: 27), $M \to L \to F$ (Frankfurt: 30), $M \to L \to F \to S$ (Singapur: 120) y $M \to L \to F \to S \to T$ (Tokio: 155).

Finalmente, debemos reflexionar sobre la complejidad computacional asociada a la resolución práctica de las ecuaciones de Bellman:

- **Complejidad factorial** $O(n!)$: Sin conocer de antemano el orden en el que deben resolverse los vértices, evaluar el sistema explorando todas las secuencias posibles de predecesores requiere un esfuerzo combinatorio de $O(n!)$.
- **Reducción de complejidad mediante ordenación topológica**: Si se logra establecer una ordenación adecuada de los nodos, la complejidad de resolución del sistema de Bellman se reduce drásticamente a $O(n^2)$ (o tiempo estrictamente lineal $O(|V| + |U|)$) más el coste del algoritmo de ordenación.
- **Restricción de aciclicidad**: Dicha ordenación topológica secuencial **únicamente es posible si el grafo no contiene circuitos dirigidos** (Grafos Dirigidos Acíclicos o DAGs).

7.3. Redes sin circuitos (DAGs) y ordenación topológica

Cuando una red dirigida no contiene circuitos cerrados (*Directed Acyclic Graph*, DAG), su estructura topológica permite ordenar los vértices de manera secuencial. Esta propiedad resulta determinante, pues transforma el complejo sistema no lineal de ecuaciones de Bellman en una sucesión de cálculos directos en tiempo **estrictamente lineal** $O(|V| + |U|)$.

Proposición: Caracterización de digrafos acíclicos mediante ordenación topológica

Un digrafo $G = (V, U)$ no tiene circuitos dirigidos (es un DAG) si y sólo si existe una **ordenación o numeración topológica** de sus n vértices $v_1, v_2, \ldots, v_n$ tal que para todo arco dirigido $(i, j) \in U$ se cumple la condición estricta de orden:

$$i < j$$

Ejemplo: Verificación de la propiedad de ordenación topológica

Consideremos nuevamente el digrafo de 5 nodos presentado en la Figura 7.3. En dicho grafo, los vértices pueden disponerse en la secuencia de ordenación topológica $(1, 5, 3, 4, 2)$. Al examinar individualmente cada uno de los arcos dirigidos existentes en la red:

- $(1, 5) \implies 1°$ precede a $2°$ (cumple $i < j$).
- $(1, 3) \implies 1°$ precede a $3°$ (cumple $i < j$).
- $(5, 4) \implies 2°$ precede a $4°$ (cumple $i < j$).
- $(5, 3) \implies 2°$ precede a $3°$ (cumple $i < j$).
- $(4, 2) \implies 4°$ precede a $5°$ (cumple $i < j$).
- $(3, 2) \implies 3°$ precede a $5°$ (cumple $i < j$).

Puesto que todos los arcos avanzan estrictamente de izquierda a derecha sin la presencia de arcos de retroceso, se confirma que la secuencia de numeración satisface rigurosamente la propiedad de aciclicidad.

Para determinar esta numeración de manera sistemática en cualquier red acíclica, se ejecuta el siguiente algoritmo basado en la eliminación sucesiva de nodos fuentes (nodos sin arcos de entrada).

Esquema: Algoritmo de numeración y ordenación topológica

Dada una red dirigida $G = (V, U)$ con $n = |V|$ vértices:

1. **Paso 0 (Inicialización)**:
   - Hacer $k \leftarrow 1$ y $V' \leftarrow V, U' \leftarrow U$.

2. **Paso 1 (Selección de nodo fuente)**:
   - Seleccionar un nodo $i \in V'$ al que no llegue ningún arco en U' (grado de entrada $d^-(i) = 0$). En un digrafo acíclico siempre existe al menos un nodo fuente.
3. **Paso 2 (Asignación y eliminación)**:
   - Asignar al nodo i el número de orden topológico k.
   - Eliminar el nodo i y todos los arcos que inciden en él: $V' \leftarrow V' \setminus \{i\}$, $U' \leftarrow U' \setminus \{(i,j) \in U'\}$.
4. **Paso 3 (Criterio de Parada)**:
   - Si $k = n$, detener el procedimiento (se han numerado todos los nodos).
   - En otro caso, hacer $k \leftarrow k + 1$ y regresar al Paso 1.

Una vez que la red ha sido ordenada topológicamente de modo que los arcos cumplan $i < j$, la resolución del sistema de ecuaciones de Bellman se vuelve **completamente trivial y directa**. No es necesario realizar iteraciones aproximadas ni resolver sistemas de ecuaciones simultáneas: basta con calcular secuencialmente la etiqueta de distancia mínima u_j de cada nodo $j = 2, \dots, n$ evaluando a sus predecesores directos $i < j$ que ya han sido resueltos previamente:

$$\begin{aligned} u_1 &= 0 \\ u_j &= \min_{i<j,\,(i,j)\in U} \{u_i + d_{ij}\}, \quad \forall j = 2, \dots, n \end{aligned}$$

Puesto que cada arco de la red se examina exactamente una vez durante este recorrido secuencial de izquierda a derecha, la complejidad algorítmica total es **estrictamente lineal** $O(|V|+|U|)$.

Ejemplo: Resolución de las ecuaciones de Bellman en un DAG de 7 nodos

Consideremos el digrafo acíclico de 7 nodos presentado en la Figura 7.5, cuyos vértices ya están numerados respetando el orden topológico $i < j$. Se desea calcular las distancias mínimas desde el origen $s = 1$ a todos los vértices de la red.
Evaluando las ecuaciones de Bellman en orden topológico creciente de $j = 1$ a 7:

- **Nodo 1 (Origen)**: $u_1 = 0$.
- **Nodo 2** (Predecesores $\{1\}$):

$$u_2 = u_1 + d_{12} = 0 + 3 = 3 \implies \text{Pred}(2) = 1$$

- **Nodo 3** (Predecesores $\{1, 2\}$):

$$u_3 = \min\{u_1 + d_{13}, u_2 + d_{23}\} = \min\{0 + 5, 3 + 5\} = 5 \implies \text{Pred}(3) = 1$$

- **Nodo 4** (Predecesores $\{2,3\}$):

$$u_4 = \text{mín}\{u_2 + d_{24}, u_3 + d_{34}\} = \text{mín}\{3-6, 5+4\} = -3 \implies \text{Pred}(4) = 2$$

- **Nodo 5** (Predecesores $\{2,4\}$):

$$u_5 = \text{mín}\{u_2 + d_{25}, u_4 + d_{45}\} = \text{mín}\{3+2, -3+2\} = -1 \implies \text{Pred}(5) = 4$$

- **Nodo 6** (Predecesores $\{3,4,5\}$):

$$u_6 = \text{mín}\{u_3+d_{36}, u_4+d_{46}, u_5+d_{56}\} = \text{mín}\{5+2, -3+3, -1+6\} = 0 \implies \text{Pred}(6) = 4$$

- **Nodo 7** (Predecesores $\{1,3,6\}$):

$$u_7 = \text{mín}\{u_1+d_{17}, u_3+d_{37}, u_6+d_{67}\} = \text{mín}\{0+8, 5+7, 0+1\} = 1 \implies \text{Pred}(7) = 6$$

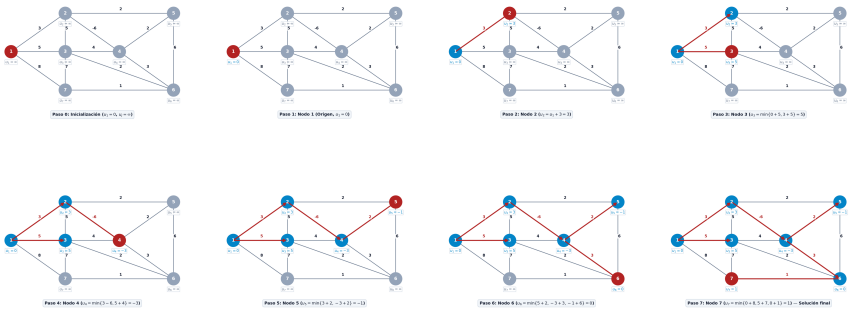

Figura 7.5: Traza completa paso a paso del algoritmo de Bellman en un DAG de 7 nodos

Al resolver consecutivamente el sistema, obtenemos los siguientes resultados:
El vector de distancias mínimas es $\mathbf{u} = (u_1, u_2, u_3, u_4, u_5, u_6, u_7) = (0, 3, 5, -3, -1, 0, 1)$, mientras que el vector de predecesores resulta ser $\text{Pred} = (1, 1, 1, 2, 4, 4, 6)$. Finalmente, la arborescencia de caminos mínimos queda conformada por las aristas dirigidas $\{(1,2), (1,3), (2,4), (4,5), (4,6), (6,7)\}$.

7.4. Redes con pesos no negativos: Algoritmo de Dijkstra

Para redes dirigidas generales en las que las longitudes de todos los arcos son estrictamente no negativas ($d_{ij} \geq 0$), el procedimiento de origen único más eficiente y célebre es el **Algoritmo de Dijkstra**, introducido por Edsger W. Dijkstra en 1959 (Dijkstra 1959).

El fundamento conceptual de esta técnica reside en su naturaleza de algoritmo **voraz** (*greedy*) basado en un mecanismo de etiquetado permanente. A diferencia de otros enfoques exploratorios que requieren múltiples pasadas sobre el grafo, el algoritmo de Dijkstra construye la solución óptima acumulativamente: en cada etapa, fija la distancia geodésica definitiva desde el origen 1 hacia exactamente un nuevo nodo de la red, garantizando que el problema quede resuelto por completo tras un máximo de $n-1$ iteraciones.

i Definición: Subconjuntos de etiquetado y cota de distancia u_j^P

En la etapa k de la ejecución del Algoritmo de Dijkstra, los vértices del grafo V se dividen dinámicamente en dos subconjuntos disjuntos:

1. **Conjunto de nodos permanentes** $\mathcal{P} \subset V$: Agrupa a los k vértices (con $1 \in \mathcal{P}$) para los cuales ya se conoce de forma exacta su distancia mínima desde el origen. Para todo nodo $j \in \mathcal{P}$, la etiqueta u_j es exactamente igual al valor óptimo $d(1, j)$.
2. **Conjunto de nodos transitorios** $\mathcal{T} = V \setminus \mathcal{P}$: Agrupa a los vértices restantes para los cuales la etiqueta u_j representa únicamente una cota superior provisional del camino mínimo.

Dado este subconjunto $\mathcal{P}$, la cota provisional u_j^P asociada a un nodo $j \in V$ se define como la longitud del camino mínimo desde el origen 1 al nodo j restringido a utilizar como vértices intermedios **únicamente elementos pertenecientes a** $\mathcal{P}$:

$$u_j^P \equiv \text{longitud del camino mínimo de 1 a } j \text{ con vértices intermedios en } \mathcal{P}$$

El procedimiento práctico comienza fijando el nodo origen en el conjunto permanente ($\mathcal{P} = \{1\}$ con $u_1 = 0$) y asignando a los restantes vértices transitorios $j \in \mathcal{T} = \{2, \dots, n\}$ la distancia del arco directo de entrada $u_j = d_{1j}$, asumiendo $d_{1j} = +\infty$ si el nodo j no posee conexión directa desde el origen.

A partir de esta configuración inicial, cada iteración del algoritmo desarrolla dos fases consecutivas de cálculo. En primer lugar, la **fase de selección voraz** identifica el nodo transitorio $j^* \in \mathcal{T}$ que posee la etiqueta provisional estrictamente mínima:

$$j^* = \arg\min_{j \in \mathcal{T}} \{u_j\}$$

En ese instante, la cota u_{j^*} se consolida como óptima y el nodo j^* pasa a integrar los permanentes, actualizando los conjuntos según $\mathcal{P} \leftarrow \mathcal{P} \cup \{j^*\}$ y $\mathcal{T} \leftarrow \mathcal{T} \setminus \{j^*\}$. A continuación, la **fase de relajación de etiquetas** inspecciona las conexiones salientes de j^* para actualizar únicamente las cotas de los nodos que permanecen en $\mathcal{T}$:

$$u_k \leftarrow \text{mín}\{u_k,\, u_{j^*} + d_{j^*k}\}, \quad \forall k \in \mathcal{T}$$

Este procedimiento de selección y actualización se repite secuencialmente hasta que no quedan nodos transitorios ($\mathcal{T} = \emptyset$), momento en el cual el algoritmo finaliza con las soluciones óptimas.

Esquema: Algoritmo de Dijkstra

Dada una red valorada $G = (V, U, \mathbf{d})$ con costes no negativos $d_{ij} \geq 0$ para todo $(i, j) \in U$:

1. **Paso 0 (Inicialización)**:
   - Asignar etiquetas iniciales: $u_1 = 0$ y $u_j = d_{1j}$ para todo $j = 2, \dots, n$ (haciendo $d_{1j} = \infty$ si $(1, j) \notin U$).
   - Inicializar el conjunto permanente $\mathcal{P} = \{1\}$ y el transitorio $\mathcal{T} = \{2, \dots, n\}$.
   - Inicializar el vector de predecesores: $\text{Pred}(j) = 1$ para todo $j = 2, \dots, n$.
2. **Paso 1 (Etiquetado permanente)**:
   - Seleccionar el nodo $k \in \mathcal{T}$ con distancia provisional mínima:
   $$u_k = \min_{j \in \mathcal{T}} \{u_j\}$$
   - Transferir k a permanentes: $\mathcal{P} \leftarrow \mathcal{P} \cup \{k\}$ y $\mathcal{T} \leftarrow \mathcal{T} \setminus \{k\}$.
   - Si $\mathcal{T} = \emptyset$ o $u_k = \infty$, detener el proceso (solución óptima alcanzada).
3. **Paso 2 (Revisión y relajación de etiquetas transitorias)**:
   - Para cada vecino $j \in \mathcal{T}$ adyacente a k:
     - Si $u_k + d_{kj} < u_j$, actualizar la cota y el predecesor:
     $$u_j \leftarrow u_k + d_{kj}, \quad \text{Pred}(j) \leftarrow k$$
   - Regresar al Paso 1.

La validez teórica del algoritmo descansa en el hecho de que las distancias de los arcos son no negativas, lo que impide que un nodo ya marcado como permanente pueda mejorar su distancia a través de un nodo transitorio posterior.

Teorema: Correctitud del algoritmo de Dijkstra

Si $d_{ij} \geq 0$ para todo $(i,j) \in U$, la etiqueta u_k asignada por el Algoritmo de Dijkstra en el momento en que un nodo k pasa a ser permanente ($\mathcal{P} \leftarrow \mathcal{P} \cup \{k\}$) es la **distancia mínima exacta** desde el origen 1 al nodo k.
Demostración: Procedemos por inducción sobre la secuencia de nodos integrados en $\mathcal{P}$. Para el caso base $\mathcal{P} = \{1\}$, $u_1 = 0$ es trivialmente óptimo. Supongamos por contradicción que en el paso donde se elige $k = \arg\min_{j \in \mathcal{T}}\{u_j\}$, la etiqueta u_k no es óptima, existiendo un camino más corto $\mu^*[1,k]$ de longitud $d(\mu^*) < u_k$. Puesto que $1 \in \mathcal{P}$ y $k \in \mathcal{T}$, el camino μ^* debe cruzar el corte saliendo de $\mathcal{P}$ por una primera arista (x,y) con $x \in \mathcal{P}$ y $y \in \mathcal{T}$. Dado que $x \in \mathcal{P}$, por hipótesis inductiva su etiqueta u_x es exacta. Por el mecanismo de relajación del Paso 2, la etiqueta del nodo y cumple $u_y \leq u_x + d_{xy}$. Como las distancias restantes a lo largo de μ^* son no negativas ($d_{uv} \geq 0$), se deduce que:

$$u_y \leq u_x + d_{xy} \leq d(\mu^*) < u_k$$

Esto implica $u_y < u_k$ con $y \in \mathcal{T}$, lo cual contradice la elección del algoritmo de k como el nodo transitorio con etiqueta mínima ($u_k = \min_{j \in \mathcal{T}}\{u_j\}$). Por tanto, u_k debe ser estrictamente óptimo.

Respecto al rendimiento computacional del algoritmo, la estructura de datos utilizada determina la eficiencia de la búsqueda del mínimo y la actualización de etiquetas.

Resumen de Complejidad Computacional de Dijkstra

- **Implementación estándar con matriz de distancias**: $O(n^2)$ u $O(|V|^2)$.
- **Implementación con Heap binario (Min-Heap)**: $O(|U| \log |V|)$.
- **Implementación con Montículo de Fibonacci (Fib-Heap)**: $O(|U| + |V| \log |V|)$ (óptimo para redes densas).

Ejemplo: Aplicación paso a paso del algoritmo de Dijkstra

Consideremos la red dirigida de 5 nodos mostrada en la Figura 7.6, cuyos arcos poseen costes estrictamente positivos.

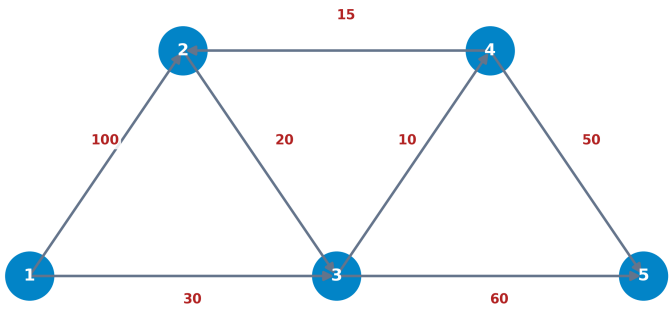

Figura 7.6: Red dirigida valorada de 5 nodos para el ejemplo del Algoritmo de Dijkstra

Paso 0 (Inicialización):
Fijamos el nodo origen 1 en el conjunto de permanentes $\mathcal{P}$ y asignamos el vector de etiquetas iniciales u_j:

$$\begin{aligned} u_1 &= 0 \\ u_2 &= 100 \\ u_3 &= 30 \\ u_4 &= \infty \\ u_5 &= \infty \\ \mathcal{P} &= \{1\}, \quad \mathcal{T} = \{2,3,4,5\} \\ \text{Pred}(j) &= 1, \quad \forall j = 2,3,4,5 \end{aligned}$$

Iteración 1:

- **Selección voraz**: Identificamos el nodo transitorio con etiqueta provisional mínima:

$$u_k = \text{mín}\{u_j : j \in \mathcal{T}\} = u_3 = 30 \implies \mathcal{P} = \{1,3\}, \quad \mathcal{T} = \{2,4,5\}$$

- **Relajación de etiquetas transitorias**: Actualizamos la cota provisional de los nodos en $\mathcal{T}$:

$$\begin{aligned} u_2 &= \text{mín}\{u_2, u_3 + d_{32}\} = \text{mín}\{100, 30 + \infty\} = 100, \quad \text{Pred}(2) = 1 \\ u_4 &= \text{mín}\{u_4, u_3 + d_{34}\} = \text{mín}\{\infty, 30 + 10\} = 40, \quad \text{Pred}(4) = 3 \\ u_5 &= \text{mín}\{u_5, u_3 + d_{35}\} = \text{mín}\{\infty, 30 + 60\} = 90, \quad \text{Pred}(5) = 3 \end{aligned}$$

Iteración 2:

- **Selección voraz**: El nodo transitorio con etiqueta mínima en $\mathcal{T} = \{2, 4, 5\}$ es:

$$u_k = \text{mín}\{u_j : j \in \mathcal{T}\} = u_4 = 40 \implies \mathcal{P} = \{1, 3, 4\}, \quad \mathcal{T} = \{2, 5\}$$

- **Relajación de etiquetas transitorias**: Actualizamos la cota provisional para los nodos restantes en $\mathcal{T}$:

$$u_2 = \text{mín}\{u_2, u_4 + d_{42}\} = \text{mín}\{100, 40 + 15\} = 55, \quad \text{Pred}(2) = 4$$
$$u_5 = \text{mín}\{u_5, u_4 + d_{45}\} = \text{mín}\{90, 40 + 50\} = 90, \quad \text{Pred}(5) = 4$$

Iteración 3:

- **Selección voraz**: El nodo transitorio con etiqueta mínima en $\mathcal{T} = \{2, 5\}$ es:

$$u_k = \text{mín}\{u_j : j \in \mathcal{T}\} = u_2 = 55 \implies \mathcal{P} = \{1, 3, 4, 2\}, \quad \mathcal{T} = \{5\}$$

- **Relajación de etiquetas transitorias**:

$$u_5 = \text{mín}\{u_5, u_2 + d_{25}\} = \text{mín}\{90, 55 + \infty\} = 90, \quad \text{Pred}(5) = 4$$

Iteración 4:

- **Selección voraz**: Se selecciona el último nodo transitorio:

$$u_k = \text{mín}\{u_j : j \in \mathcal{T}\} = u_5 = 90 \implies \mathcal{P} = \{1, 3, 4, 2, 5\}, \quad \mathcal{T} = \emptyset$$

- **Criterio de Parada**: Al ser $\mathcal{T} = \emptyset$, se detiene el procedimiento.

Al finalizar el procedimiento iterativo, se obtienen las distancias geodésicas y los predecesores óptimos:

- **Vector de distancias mínimas**: $\mathbf{u} = (u_1, u_2, u_3, u_4, u_5) = (0, 55, 30, 40, 90)$.
- **Vector de predecesores**: $\text{Pred} = (1, 4, 1, 3, 4)$.
- **Arborescencia de caminos mínimos**: Comprendida por los arcos dirigidos $\{(1, 3), (3, 4), (4, 2), (4, 5)\}$.

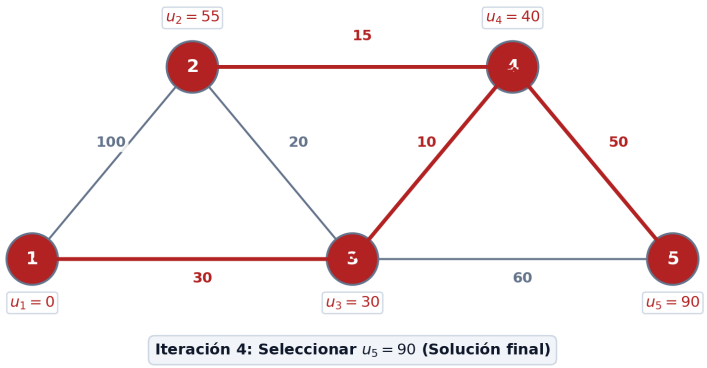

Figura 7.7: Traza gráfica de la evolución iterativa del Algoritmo de Dijkstra paso a paso

---

7.5. Redes con pesos negativos: Algoritmo de Bellman-Ford

Cuando una red contiene arcos con costes negativos ($d_{ij} < 0$), el algoritmo de Dijkstra pierde validez puesto que una cota provisional o fija podría abaratarse posteriormente mediante un camino derivado de una arista negativa. En el caso general, cuando existen arcos de longitud negativa pero se garantiza la ausencia de circuitos de coste negativo, una alternativa para obtener la solución de las ecuaciones de optimalidad consiste en aproximar el camino mínimo a cualquier vértice por la distancia del camino óptimo que utiliza $1, 2, \ldots, m$ arcos.

Esta es la idea fundamental del **Algoritmo de Bellman-Ford**, publicado por Lester R. Ford Jr. en 1956 (Ford 1956), aunque fue propuesto originalmente por Alfonso Shimbel en 1955 (Shimbel 1955) y desarrollado posteriormente por Richard Bellman en 1958 (Bellman 1958) y Edward F. Moore en 1959. Posee una complejidad algorítmica de $O(n^3)$ u $O(|V| \cdot |U|)$, superior a la del algoritmo de Dijkstra.

Definición: Aproximación por número de arcos u_j^m

Sea u_j^m la longitud del camino mínimo desde el nodo origen 1 al nodo j **utilizando** m **arcos dirigidos o menos**:

$$u_j^m \equiv \text{longitud del camino mínimo de 1 a } j \text{ utilizando } m \text{ arcos o menos}$$

El procedimiento se inicia fijando $m = 1$ e incrementa iterativamente m hasta un máximo de $m = n - 1$. Si la red no contiene circuitos de longitud negativa, el algoritmo converge

a la solución óptima global en $n-1$ iteraciones a lo sumo, satisfaciendo la relación de recurrencia:

$$u_j^m = \min\left\{u_j^{m-1},\ \min_{k\neq j}\{u_k^{m-1} + d_{kj}\}\right\}, \quad \forall j = 2, \dots, n$$

El desarrollo formal del procedimiento se sintetiza a través del siguiente esquema algorítmico.

Esquema: Algoritmo de Bellman-Ford

Dada una red valorada $G = (V, U, \mathbf{d})$ con $n = |V|$ vértices:

1. **Paso 1 (Inicialización)**:
   - Para $m = 1$, definir las etiquetas iniciales del camino directo:

$$u_j^1 = \begin{cases} 0 & \text{si } j = 1 \\ d_{1j} & \text{si } (1,j) \in U \\ \infty & \text{si } (1,j) \notin U \end{cases}$$

   - Hacer $m \leftarrow 1$.
2. **Paso 2 (Iteración de relajación)**:
   - Hacer $m \leftarrow m + 1$.
   - Para cada nodo $j = 2, \dots, n$, evaluar si es más ventajoso mantener la cota anterior o acceder a j pasando por un nodo intermedio k:

$$u_j^m = \min\left\{u_j^{m-1},\ \min_{k\neq j}\{u_k^{m-1} + d_{kj}\}\right\}$$

3. **Paso 3 (Criterio de Parada y Convergencia)**:
   - **Criterio de Parada Anticipada**: Si $u_j^m = u_j^{m-1}$ para todo $j = 2, \dots, n$, la solución con m arcos es óptima y se detiene el proceso.
   - **Criterio Límite**: Si $m = n-1$, detener el procedimiento. En otro caso, regresar al Paso 2.

Teorema: Detección de circuitos de coste negativo

Un digrafo $G = (V, U, \mathbf{d})$ contiene al menos un **circuito de coste negativo** accesible desde el origen 1 si y sólo si en la iteración $m = n$ del Algoritmo de Bellman-Ford existe al menos un nodo $j \in V$ tal que:

$$u_j^n \neq u_j^{n-1} \quad \text{(equivalentemente } u_j^n < u_j^{n-1}\text{)}$$

Demostración: Cualquier camino simple en un grafo de n vértices contiene a lo sumo $n-1$ arcos. Si la distancia mínima desde el origen a un nodo j disminuye al permitir caminos de n arcos ($u_j^n < u_j^{n-1}$), por el principio del palomar (*pigeonhole principle*) la ruta de n arcos debe contener obligatoriamente un ciclo repetido. Como la distancia se ha reducido estrictamente, dicho ciclo posee un coste total estrictamente negativo.

Ejemplo: Aplicación del algoritmo de Bellman-Ford con costes negativos

Consideremos el digrafo de 4 nodos mostrado en la Figura 7.8, el cual contiene el arco de coste negativo $(4, 2)$ con $d_{42} = -3$. Deseamos encontrar el camino mínimo desde el nodo 1 a todos los demás vértices.

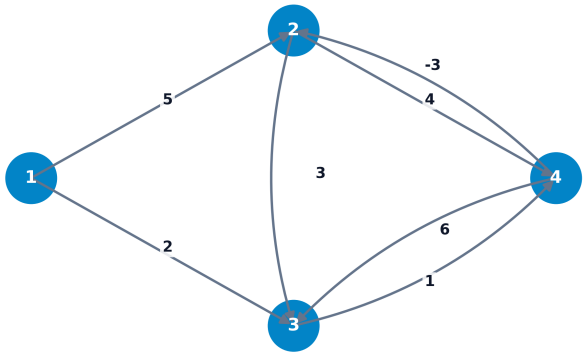

Figura 7.8: Digrafo valorado de 4 nodos con costes negativos para el Algoritmo de Bellman-Ford

Resolución paso a paso:

- **Paso 1 (Inicialización $m = 1$)**:

$$u_1^1 = 0$$
$$u_2^1 = 5$$
$$u_3^1 = 2$$
$$u_4^1 = \infty$$
$$m = 1$$

- **Iteración** $m = 2$:

$$u_2^2 = \text{mín}\{u_2^1, \text{mín}\{u_3^1 + d_{32}, u_4^1 + d_{42}\}\} = \text{mín}\{5, \text{mín}\{2 + \infty, \infty - 3\}\} = 5 = u_2^1$$
$$u_3^2 = \text{mín}\{u_3^1, \text{mín}\{u_2^1 + d_{23}, u_4^1 + d_{43}\}\} = \text{mín}\{2, \text{mín}\{5 + 3, \infty + 6\}\} = 2 = u_3^1$$
$$u_4^2 = \text{mín}\{u_4^1, \text{mín}\{u_2^1 + d_{24}, u_3^1 + d_{34}\}\} = \text{mín}\{\infty, \text{mín}\{5 + 4, 2 + 1\}\} = 3 \neq u_4^1$$
$$m = 2$$

- **Iteración** $m = 3$:

$$u_2^3 = \text{mín}\{u_2^2, \text{mín}\{u_3^2 + d_{32}, u_4^2 + d_{42}\}\} = \text{mín}\{5, \text{mín}\{2 + \infty, 3 - 3\}\} = 0 \neq u_2^2$$
$$u_3^3 = \text{mín}\{u_3^2, \text{mín}\{u_2^2 + d_{23}, u_4^2 + d_{43}\}\} = \text{mín}\{2, \text{mín}\{5 + 3, 3 + 6\}\} = 2 = u_3^2$$
$$u_4^3 = \text{mín}\{u_4^2, \text{mín}\{u_2^2 + d_{24}, u_3^2 + d_{34}\}\} = \text{mín}\{3, \text{mín}\{5 + 4, 2 + 1\}\} = 3 = u_4^2$$
$$m = 3$$

- **Iteración** $m = 4$:

$$u_2^4 = \text{mín}\{u_2^3, \text{mín}\{u_3^3 + d_{32}, u_4^3 + d_{42}\}\} = \text{mín}\{0, \text{mín}\{2 + \infty, 3 - 3\}\} = 0 = u_2^3$$
$$u_3^4 = \text{mín}\{u_3^3, \text{mín}\{u_2^3 + d_{23}, u_4^3 + d_{43}\}\} = \text{mín}\{2, \text{mín}\{0 + 3, 3 + 6\}\} = 2 = u_3^3$$
$$u_4^4 = \text{mín}\{u_4^3, \text{mín}\{u_2^3 + d_{24}, u_3^3 + d_{34}\}\} = \text{mín}\{3, \text{mín}\{0 + 4, 2 + 1\}\} = 3 = u_4^2$$
$$m = 4$$

Como $u^4 = u^3 = (0, 0, 2, 3)$, se alcanza la **convergencia y parada anticipada**.
Al finalizar el procedimiento iterativo, se obtienen las distancias geodésicas y los predecesores óptimos:

- **Vector de distancias mínimas**: $\mathbf{u} = (u_1, u_2, u_3, u_4) = (0, 0, 2, 3)$.
- **Vector de predecesores**: Pred $= (1, 4, 1, 3)$.
- **Arborescencia de caminos mínimos**: Comprendida por los arcos dirigidos $\{(1, 3), (3, 4), (4, 2)\}$.

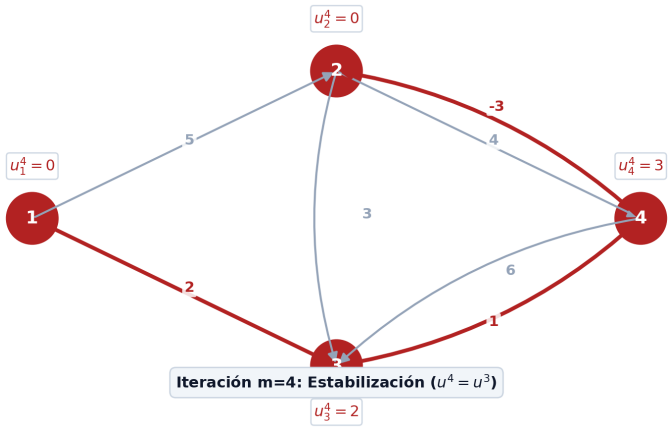

Figura 7.9: Traza gráfica de la evolución iterativa del Algoritmo de Bellman-Ford paso a paso

En el análisis de redes valoradas, una de las mayores utilidades del algoritmo de Bellman-Ford radica en su capacidad para detectar la presencia de **circuitos de coste o longitud negativa**. Si un digrafo contiene un circuito con suma de pesos estrictamente negativa, la longitud del camino óptimo hacia los nodos que componen dicho circuito o accesibles desde él tiende hacia $-\infty$, requiriendo un número infinito de arcos para su recorrido.

Por el contrario, cuando la red carece de circuitos negativos, la distancia mínima hacia cualquier vértice accesible se alcanza utilizando como máximo $n-1$ arcos. Esta propiedad permite adaptar el algoritmo para realizar una iteración suplementaria hasta $m = n$:

- Si el digrafo **no contiene circuitos de longitud negativa**, las etiquetas de la pasada $n-1$ y de la pasada n resultarán ser estrictamente idénticas ($u^{n-1} = u^n$).
- Si alguna etiqueta $u_j^m = \infty$, no existe ningún camino físico de conexión desde el origen 1 hacia el nodo j.
- Si en la iteración $m = n$ se detecta que $u^{n-1} \neq u^n$ (con $u_j^n < u_j^{n-1}$ para algún nodo j), queda demostrada formalmente la existencia de un **circuito de longitud negativa** en la red.

i Esquema: Algoritmo de Bellman-Ford adaptado para detección de circuitos negativos

Dada una red valorada general $G = (V, U, \mathbf{d})$ con $n = |V|$ vértices:

1. **Paso 1 (Inicialización)**:

- Asignar las etiquetas iniciales para $m = 1$:

$$u_j^1 = \begin{cases} 0 & \text{si } j = 1 \\ d_{1j} & \text{si } (1, j) \in U \\ \infty & \text{si } (1, j) \notin U \end{cases}$$

- Hacer $m \leftarrow 1$.

2. **Paso 2 (Relajación iterativa)**:
   - Hacer $m \leftarrow m + 1$.
   - Para cada nodo $j = 2, \ldots, n$, evaluar:

$$u_j^m = \min \left\{ u_j^{m-1},\ \min_{k \neq j} \{ u_k^{m-1} + d_{kj} \} \right\}$$

3. **Paso 3 (Evaluación de optimalidad o detección de circuito)**:
   - **Criterio de Convergencia Óptima**: Si $u_j^m = u_j^{m-1}$ para todo $j = 2, \ldots, n$, detener el algoritmo: la solución actual u^m es óptima.
   - **Criterio de Detección de Circuito Negativo**: En otro caso, si $m = n$, detener el procedimiento concluyendo que **existen circuitos de longitud negativa** en la red.
   - En otro caso ($m < n$), regresar al Paso 2.

Ejemplo: Detección de un circuito de longitud negativa en un digrafo de 7 nodos

Consideremos el digrafo de 7 nodos ($V = \{a, b, c, d, e, f, g\}$ con $n = 7$) representado en la Figura 7.10, con origen en el nodo a.

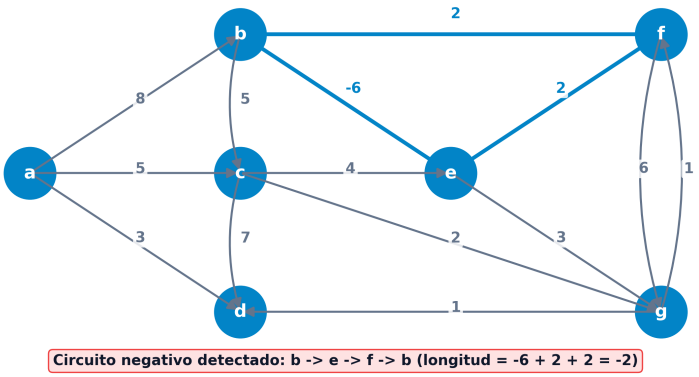

Figura 7.10: Digrafo valorado de 7 nodos con un circuito de longitud negativa

Inspeccionando los ciclos de la red, observamos que la secuencia $b \to e \to f \to b$ conforma un circuito cerrado de longitud acumulada negativa:

$$d(b,e) + d(e,f) + d(f,b) = -6 + 2 + 2 = -2 < 0$$

Desarrollo del Algoritmo de Bellman-Ford:

- **Paso 1 (Inicialización** $m = 1$**)**:

$$u_a^1 = 0, \quad u_b^1 = 8, \quad u_c^1 = 5, \quad u_d^1 = 3, \quad u_e^1 = \infty, \quad u_f^1 = \infty, \quad u_g^1 = \infty$$

- **Tras ejecutar el procedimiento hasta la iteración** $m = n - 1 = 6$, se obtiene el vector de etiquetas:

$$u_a^6 = 0, \quad u_b^6 = 6, \quad u_c^6 = 5, \quad u_d^6 = 3, \quad u_e^6 = 0, \quad u_f^6 = 2, \quad u_g^6 = 3$$

- **Iteración suplementaria** $m = n = 7$: Evaluamos la relajación de etiquetas para todos los nodos del digrafo:

$$\begin{aligned}
u_b^7 &= \text{mín}\{u_b^6, u_a^6 + 8, u_f^6 + 2\} = \text{mín}\{6, 0 + 8, 2 + 2\} = 4 \\
u_c^7 &= \text{mín}\{u_c^6, u_a^6 + 5, u_b^6 + 5\} = \text{mín}\{5, 0 + 5, 4 + 5\} = 5 \\
u_d^7 &= \text{mín}\{u_d^6, u_a^6 + 3, u_c^6 + 7, u_g^6 + 1\} = \text{mín}\{3, 0 + 3, 5 + 7, 3 + 1\} = 3 \\
u_e^7 &= \text{mín}\{u_e^6, u_b^6 - 6, u_c^6 + 4\} = \text{mín}\{0, 6 - 6, 5 + 4\} = 0 \\
u_f^7 &= \text{mín}\{u_f^6, u_e^6 + 2, u_g^6 + 6\} = \text{mín}\{2, 0 + 2, 3 + 6\} = 2 \\
u_g^7 &= \text{mín}\{u_g^6, u_c^6 + 2, u_e^6 + 3, u_f^6 + 1\} = \text{mín}\{3, 5 + 2, 0 + 3, 2 + 1\} = 3
\end{aligned}$$

Al comparar las etiquetas entre las iteraciones 6 y 7, detectamos que para el nodo b:

$$u_b^6 = 6 \neq 4 = u_b^7 \implies u_b^7 < u_b^6$$

Puesto que $u^7 \neq u^6$, el algoritmo se detiene formalmente en $m = n = 7$ concluyendo que **existe un circuito de longitud negativa** ($b \to e \to f \to b$).

7.6. Formulación matemática: Programación Lineal Primal y Dual

El problema del camino mínimo entre un nodo origen s y un nodo destino t en un digrafo valorado $G = (V, U, \mathbf{d})$ admite una representación equivalente mediante un **modelo de programación lineal**. Desde la perspectiva de la teoría de redes de flujo, el problema equivale a transportar una unidad de flujo unitario desde el nodo fuente s hasta el nodo sumidero t con el menor coste o distancia acumulada posible.

Definición: Modelo Primal de Programación Lineal para el Camino Mínimo

Dada una red dirigida $G = (V, U, \mathbf{d})$ con $n = |V|$ vértices, etiquetados de forma que $s \in V$ representa el origen y $t \in V$ el destino, asociamos a cada arco $(i, j) \in U$ un coste unitario de transporte dado por su peso d_{ij}.
Definimos las **variables de decisión** x_{ij} como variables indicadoras de flujo que determinan la activación de cada arco en el itinerario:

$$x_{ij} = \begin{cases} 1 & \text{si el arco } (i,j) \text{ forma parte del camino mínimo} \\ 0 & \text{en otro caso} \end{cases} \qquad \forall (i,j) \in U$$

El modelo lineal minimiza la longitud total del trayecto sujeto a las ecuaciones de balance y conservación de flujo en cada vértice de la red:

$$
\begin{aligned}
\min_{\mathbf{x}} \quad & \sum_{i=1}^{n}\sum_{j=1}^{n} d_{ij}x_{ij} \\
\text{sujeto a} \quad & \sum_{k=1}^{n} x_{sk} = 1 \quad \text{(Salida unitaria del nodo origen } s\text{)} \\
& \sum_{k=1}^{n} x_{kt} = 1 \quad \text{(Entrada unitaria al nodo destino } t\text{)} \\
& \sum_{j=1}^{n} x_{jk} = \sum_{i=1}^{n} x_{ki}, \quad \forall k \neq s,t \quad \text{(Conservación de flujo en nodos intermedios)} \\
& x_{ij} \in \{0,1\}, \quad \forall (i,j) \in U
\end{aligned}
$$

En notación matricial compacta, el modelo se expresa como $\text{mín}\{\mathbf{d}^T\mathbf{x} : \mathbf{Ax} = \mathbf{b}, \mathbf{x} \geq \mathbf{0}\}$, donde $\mathbf{A} \in \{-1,0,1\}^{n\times m}$ representa la **matriz de incidencia nodo-arco** del digrafo y $\mathbf{b} = (1,0,\dots,0,-1)^T$ es el vector de balances nodales.

! Teorema: Total unimodularidad e integridad del modelo primal

La matriz de incidencia nodo-arco $\mathbf{A}$ de cualquier grafo o digrafo es **totalmente unimodular** (TUM). Por consiguiente, para cualquier vector de balances entero $\mathbf{b}$, todas las soluciones básicas factibles del problema de programación lineal continuo son **estrictamente enteras**.
En particular, la solución óptima del modelo continuo satisface automáticamente $x_{ij}^* \in \{0,1\}$, seleccionando una ruta simple óptima de s a t sin necesidad de imponer de forma explícita restricciones de programación entera.

A partir de la formulación primal, se puede derivar el **modelo dual** asociando a la ecuación de balance de cada nodo $i \in V$ una variable dual no restringida en signo $u_i \in \mathbb{R}$, denominada **potencial nodal**:

$$
\begin{aligned}
\max_{\mathbf{u}} \quad & u_t - u_s \\
\text{sujeto a} \quad & u_j - u_i \leq d_{ij}, \quad \forall (i,j) \in U \\
& u_i \text{ no restringidas}, \quad \forall i \in V
\end{aligned}
$$

i Interpretación física y económica del modelo dual

- **Potenciales Nodales**: Las variables duales u_i representan **potenciales o tensiones nodales** en la red.
- **Fijación de Referencia**: Dado que el sistema dual presenta un grado de libertad adicional (es invariante ante sumas constantes $u_i + C$), al fijar el origen $u_s = 0$,

la variable dual óptima u_j^* coincide exactamente con la **distancia mínima** $d(s, j)$ desde s hasta j.

- **Restricción de Consistencia**: La condición $u_j - u_i \leq d_{ij}$ establece que la diferencia de potencial entre dos nodos adyacentes no puede superar la distancia directa del arco que los une.
- **Holgura Complementaria**: Si el arco (i, j) forma parte del camino mínimo óptimo ($x_{ij}^* = 1$), la restricción dual correspondiente se activa con igualdad estricta: $u_j^* - u_i^* = d_{ij}$.

Ejemplo: Formulación primal completa para una red de 7 nodos

Consideremos el digrafo de 7 nodos $V = \{s, 1, 2, 3, 4, 5, t\}$ representado en la Figura 7.11. Se desea formular el modelo de programación lineal para resolver el problema del camino mínimo entre el nodo origen s y el nodo destino t.

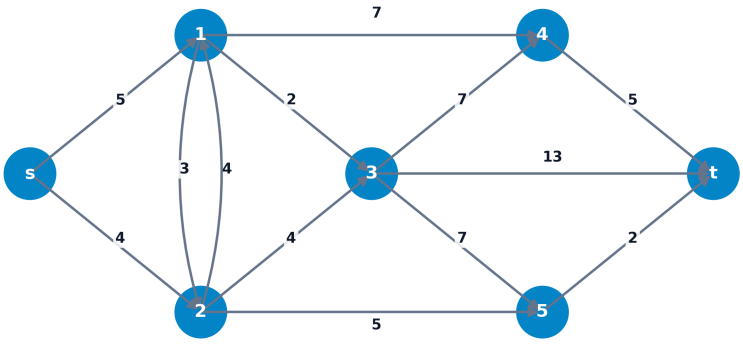

Figura 7.11: Digrafo valorado de 7 nodos para el modelo de programación lineal del camino mínimo

1. Variables de decisión:

$$x_{ij} = \begin{cases} 1 & \text{si el arco } (i,j) \text{ forma parte del camino} \\ 0 & \text{en otro caso} \end{cases} \qquad \forall (i,j) \in U$$

2. Función objetivo: Minimizar la suma de costes de los arcos seleccionados en el itinerario:

$$\begin{aligned} \text{mín } z = {} & 5x_{s1} + 4x_{s2} + 4x_{12} + 2x_{13} + 7x_{14} + 3x_{21} + 4x_{23} \\ & + 5x_{25} + 7x_{34} + 7x_{35} + 13x_{3t} + 5x_{4t} + 2x_{5t} \end{aligned}$$

3. Restricciones del nodo origen (s): Garantizar la salida de una unidad de flujo

desde el origen:

$$x_{s1} + x_{s2} = 1$$

4. Restricciones del nodo destino (t): Garantizar la llegada de una unidad de flujo al destino:

$$x_{3t} + x_{4t} + x_{5t} = 1$$

5. Restricciones de conservación de flujo en el resto de nodos ($k \neq s, t$): La suma de flujos entrantes a un nodo debe ser igual a la suma de flujos salientes:

$$\begin{aligned}
\text{Nodo 1:} \quad & x_{s1} + x_{21} = x_{12} + x_{13} + x_{14} \\
\text{Nodo 2:} \quad & x_{s2} + x_{12} = x_{21} + x_{23} + x_{25} \\
\text{Nodo 3:} \quad & x_{13} + x_{23} = x_{34} + x_{35} + x_{3t} \\
\text{Nodo 4:} \quad & x_{14} + x_{34} = x_{4t} \\
\text{Nodo 5:} \quad & x_{25} + x_{35} = x_{5t}
\end{aligned}$$

6. Naturaleza de las variables:

$$x_{ij} \in \{0, 1\}, \quad \forall (i, j) \in U$$

7.7. Caminos mínimos entre todos los pares de nodos

En diversas aplicaciones prácticas de diseño de redes de comunicación, logística e infraestructura, se requiere determinar las distancias mínimas entre **todos los pares de vértices** $(i, j) \in V \times V$.

Una primera aproximación intuitiva consiste en ejecutar n veces un algoritmo de origen único (como Dijkstra o Bellman-Ford), tomando secuencialmente cada vértice $i \in V$ como raíz del cálculo. Sin embargo, en digrafos con pesos negativos, aplicar n veces el algoritmo de Bellman-Ford multiplica la complejidad computacional por n, alcanzando una cota total de $n \times O(n^3) = O(n^4)$. Este enfoque resulta ineficiente al desaprovechar la estructura compartida de los subcaminos óptimos en la red.

Para resolver de forma global este problema optimizando la reutilización de información, exploraremos primeramente el **método basado en la multiplicación de matrices** (álgebra Min-Suma) y, a continuación, el **algoritmo de Floyd-Warshall** basado en programación dinámica.

7.7.1. Método basado en la multiplicación de matrices (Álgebra Min-Suma)

Sea $G = (V, U, \mathbf{d})$ un digrafo valorado con $n = |V|$ vértices. Definimos la **matriz inicial de distancias** $D = (d_{kj}) \in \mathbb{R}^{n\times n}$ asociada a los arcos directos de la red como:

$$d_{kj} = \begin{cases} 0 & \text{si } k = j \\ d_{kj} & \text{si } (k,j) \in U \\ \infty & \text{si } (k,j) \notin U \end{cases}$$

Es posible definir un álgebra de matrices sobre la estructura de semianillo $(\mathbb{R} \cup \{\infty\}, \text{mín}, +)$, conocida como **álgebra Min-Suma** o *álgebra tropical*, donde la operación de suma matricial convencional se sustituye por la minimización (mín) y la multiplicación por la adición (+).

Definición: Operador del producto matricial Min-Suma

Dadas dos matrices $A, B \in \overline{\mathbb{R}}^{n\times n}$, el **producto matricial Min-Suma** $C = A \otimes B$ sustituye el sumatorio $\sum$ por el operador mín y el producto escalar por la suma:

$$\text{Álgebra Estándar: } c_{ij} = \sum_{k=1}^{n} a_{ik}\cdot b_{kj} \quad \Longrightarrow \quad \text{Álgebra Min-Suma: } c_{ij} = \min_{1\le k\le n} \{a_{ik} + b_{kj}\}$$

- **Paralelismo con el Algoritmo de Bellman-Ford**: La fila i-ésima de la matriz $D^{(m)} = D^{(m-1)} \otimes D$ contiene las distancias mínimas alcanzables en a lo sumo m arcos considerando al nodo i como origen único.

Bajo este operador, la potencia m-ésima de la matriz $D^m = (d_{ij})^m$ contiene la distancia mínima entre cada par de nodos i y j utilizando **a lo sumo** m **arcos**. En particular, la ordenación por filas de D^m equivale a resolver simultáneamente una iteración del algoritmo de Bellman-Ford para los n posibles orígenes de la red.

Para $m = 2$, la cota de distancia de i a j utilizando 2 arcos o menos se calcula como:

$$(d_{ij})^2 = \text{mín}\left\{d_{ij},\ \min_{k\in V}\{d_{ik} + d_{kj}\}\right\}$$

En general, la relación de recurrencia para la potencia $(m+1)$-ésima adopta la forma:

$$(d_{ij})^{m+1} = \text{mín}\left\{(d_{ij})^m,\ \min_{k\in V}\{(d_{ik})^m + d_{kj}\}\right\}$$

Dado que cualquier camino simple en un grafo de n vértices contiene a lo sumo $n-1$ arcos, el algoritmo alcanza la solución exacta al calcular D^{n-1}. La evaluación secuencial de

$D, D^2, D^3, \ldots, D^{n-1}$ requiere $n-1$ multiplicaciones de matrices de dimensión $n \times n$, con un coste computacional de $O(n^4)$.

Optimización por Exponenciación Binaria (Repeated Squaring)

Si únicamente se requiere calcular la matriz de distancias mínimas absolutas (sin necesidad de reconstruir la secuencia explícita de vértices del camino), es posible reducir significativamente la complejidad algorítmica.
En lugar de evaluar secuencialmente $D^2, D^3, \ldots, D^n$, podemos aplicar la técnica de **exponenciación binaria** calculando la serie de potencias cuadráticas $D^2, D^4, D^8, \ldots, D^{2^k}$ hasta superar $n-1$. Con esta estrategia, el número de multiplicaciones matriciales se reduce de $n-1$ a $\lceil \log_2(n-1) \rceil$, reduciendo la complejidad total de $O(n^4)$ a $O(n^3 \log n)$.

Ejemplo: Aplicación del método de multiplicación de matrices en una red de 4 nodos

Consideremos el digrafo de 4 nodos mostrado en la Figura 7.12, el cual contiene arcos dirigidos con pesos positivos y negativos.

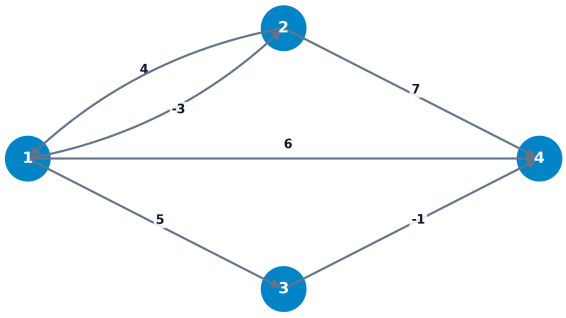

Figura 7.12: Digrafo valorado de 4 nodos para la multiplicación de matrices

1. Matriz inicial de distancias $D = D^{(1)}$:

$$D = \begin{pmatrix} 0 & 4 & 5 & 6 \\ -3 & 0 & \infty & 7 \\ \infty & \infty & 0 & -1 \\ \infty & \infty & \infty & 0 \end{pmatrix}$$

2. Segunda iteración ($D^{(2)} = D \otimes D$): Evaluando la relajación con a lo sumo 2 arcos:

$$D^{(2)} = \begin{pmatrix} 0 & 4 & 5 & \mathbf{4} \\ -3 & 0 & \mathbf{2} & \mathbf{3} \\ \infty & \infty & 0 & -1 \\ \infty & \infty & \infty & 0 \end{pmatrix}$$

Observación: $(d_{14})^2 = \text{mín}\{6, \text{mín}\{0+6, 4+7, 5-1\}\} = \text{mín}\{6, 5\} = \mathbf{4}$ vía el camino $1 \to 3 \to 4$.

3. Tercera iteración ($D^{(3)} = D^{(2)} \otimes D$): Evaluando la relajación con a lo sumo 3 arcos:

$$D^{(3)} = \begin{pmatrix} 0 & 4 & 5 & 4 \\ -3 & 0 & 2 & \mathbf{1} \\ \infty & \infty & 0 & -1 \\ \infty & \infty & \infty & 0 \end{pmatrix}$$

Observación: La primera fila de $D^{(3)}$ coincide exactamente con el resultado obtenido al ejecutar el algoritmo de Bellman-Ford con origen en el nodo 1.
Puesto que $n = 4$, el algoritmo se detiene formalmente en $D^{(n-1)} = D^{(3)}$ o en la iteración donde la matriz de distancias permanezca invariante ($D^{(m)} = D^{(m-1)}$).

7.7.2. Algoritmo de Floyd-Warshall

El **Algoritmo de Floyd-Warshall** fue publicado formalmente por Floyd en 1962 (Floyd 1962), aunque una versión equivalente del método fue propuesta previamente por Roy en 1959 (Roy 1959) y desarrollada posteriormente de forma independiente por Warshall en 1962 (Warshall 1962).

Se trata de un algoritmo de **programación dinámica** válido para calcular las distancias mínimas entre cualquier par de nodos en redes que pueden contener arcos de peso negativo (siempre que se garantice la ausencia de circuitos de coste negativo). Su complejidad algorítmica es $O(n^3)$, siendo significativamente más eficiente que ejecutar n veces el algoritmo de Bellman-Ford ($O(n^4)$).

La idea fundamental del algoritmo consiste en iterar sobre cada nodo intermedio candidato $k \in \{1, \ldots, n\}$, comparando para cada par de nodos (i, j) si el camino óptimo de i a j mejora al incorporar el nodo k como vértice intermedio.

Definición: Recurrencia de programación dinámica de Floyd-Warshall

Sea $d_{ij}^{(k)}$ la longitud del camino mínimo desde el nodo i hasta el nodo j permitiendo utilizar como **nodos intermedios únicamente un subconjunto de los primeros k nodos** $\{1, 2, \dots, k\}$.

- **Inicialización ($k = 0$)**: $d_{ij}^{(0)} = d_{ij}$ (distancias directas de los arcos en la matriz D).
- **Paso iterativo** k: Para cada par de vértices (i, j), se compara:
  1. La longitud del camino óptimo de i a j sin utilizar el nodo k como intermedio ($d_{ij}^{(k-1)}$).
  2. La suma de las distancias mínimas de i a k y de k a j utilizando únicamente los primeros $k-1$ nodos ($d_{ik}^{(k-1)} + d_{kj}^{(k-1)}$).

Si la distancia total mejora al transitar por el nodo k, se actualiza el camino mínimo mediante la relación de recurrencia:

$$d_{ij}^{(k)} = \text{mín}\left\{d_{ij}^{(k-1)},\ d_{ik}^{(k-1)} + d_{kj}^{(k-1)}\right\}, \quad \forall i, j \in V$$

Puesto que el algoritmo realiza n iteraciones principales (una por cada nodo intermedio k) y en cada iteración ejecuta n^2 comparaciones escalares (una por cada par (i, j)), la complejidad temporal global queda acotada exactamente por:

$$n \times n^2 = O(n^3)$$

Adicionalmente, en cada iteración se puede ir registrando de forma paralela la matriz de predecesores $P^{(k)}$ para posibilitar la reconstrucción explícita de los caminos mínimos.

Esquema: Algoritmo de Floyd-Warshall

Dada la matriz de distancias directas $D^{(0)} = D$ y la matriz de predecesores iniciales $P^{(0)}$ con $P_{ij} = j$ para todo $(i, j) \in U$:

1. **Bucle externo (Nodo pivote intermedio k)**: Para $k = 1, 2, \dots, n$:
2. **Bucles internos (Par origen-destino i, j)**: Para $i = 1, 2, \dots, n$: Para $j = 1, 2, \dots, n$:
   - Evaluar el criterio de relajación:

$$\text{Si } d_{ik}^{(k-1)} + d_{kj}^{(k-1)} < d_{ij}^{(k-1)} \text{ entonces :}$$

$$d_{ij}^{(k)} \leftarrow d_{ik}^{(k-1)} + d_{kj}^{(k-1)}, \quad P_{ij}^{(k)} \leftarrow P_{ik}^{(k-1)}$$

Ejemplo: Aplicación desglosada del algoritmo de Floyd-Warshall

Consideremos el digrafo de 5 nodos representado en la Figura 7.13. Se desea calcular la matriz de distancias mínimas entre todos los pares de nodos $D^{(5)}$ aplicando el Algoritmo de Floyd-Warshall.

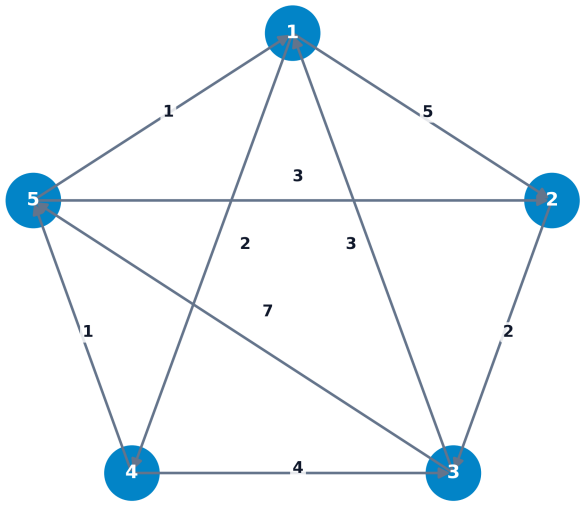

Figura 7.13: Digrafo valorado de 5 nodos para el ejemplo del Algoritmo de Floyd-Warshall

1. Matriz Inicial $D^{(0)}$ (Distancias directas de los arcos):

$$D^{(0)} = \begin{pmatrix} 0 & 5 & \infty & 2 & \infty \\ \infty & 0 & 2 & \infty & \infty \\ 3 & \infty & 0 & \infty & 7 \\ \infty & \infty & 4 & 0 & 1 \\ 1 & 3 & \infty & \infty & 0 \end{pmatrix}$$

2. Iteración $k = 1$ (Permitir el nodo 1 como vértice intermedio): Se evalúa $d_{ij}^{(1)} = \min\{d_{ij}^{(0)}, d_{i1}^{(0)} + d_{1j}^{(0)}\}$. La fila 1 $(0, 5, \infty, 2, \infty)$ y la columna 1 $(0, \infty, 3, \infty, 1)^T$ permiten actualizar los siguientes elementos:

- $d_{32}^{(1)} = \min\{\infty, 3 + 5\} = 8$.
- $d_{34}^{(1)} = \min\{\infty, 3 + 2\} = 5$.
- $d_{54}^{(1)} = \min\{\infty, 1 + 2\} = 3$.

$$D^{(1)} = \begin{pmatrix} 0 & 5 & \infty & 2 & \infty \\ \infty & 0 & 2 & \infty & \infty \\ 3 & \mathbf{8} & 0 & \mathbf{5} & 7 \\ \infty & \infty & 4 & 0 & 1 \\ 1 & 3 & \infty & \mathbf{3} & 0 \end{pmatrix}$$

3. Iteración $k = 2$ (Permitir el nodo 2 como vértice intermedio): Evaluando combinaciones a través de la fila 2 $(\infty, 0, 2, \infty, \infty)$ y la columna 2 $(5, 0, 8, \infty, 3)^T$:

- $d_{13}^{(2)} = \text{mín}\{\infty, 5 + 2\} = 7$.
- $d_{53}^{(2)} = \text{mín}\{\infty, 3 + 2\} = 5$.

$$D^{(2)} = \begin{pmatrix} 0 & 5 & \mathbf{7} & 2 & \infty \\ \infty & 0 & 2 & \infty & \infty \\ 3 & 8 & 0 & 5 & 7 \\ \infty & \infty & 4 & 0 & 1 \\ 1 & 3 & \mathbf{5} & 3 & 0 \end{pmatrix}$$

4. Iteración $k = 3$ (Permitir el nodo 3 como vértice intermedio): Evaluando combinaciones a través de la fila 3 $(3, 8, 0, 5, 7)$ y la columna 3 $(7, 2, 0, 4, 5)^T$:

- $d_{15}^{(3)} = \text{mín}\{\infty, 7 + 7\} = 14$.
- $d_{21}^{(3)} = \text{mín}\{\infty, 2 + 3\} = 5$, $d_{24}^{(3)} = \text{mín}\{\infty, 2 + 5\} = 7$, $d_{25}^{(3)} = \text{mín}\{\infty, 2 + 7\} = 9$.
- $d_{41}^{(3)} = \text{mín}\{\infty, 4 + 3\} = 7$, $d_{42}^{(3)} = \text{mín}\{\infty, 4 + 8\} = 12$.

$$D^{(3)} = \begin{pmatrix} 0 & 5 & 7 & 2 & \mathbf{14} \\ \mathbf{5} & 0 & 2 & \mathbf{7} & \mathbf{9} \\ 3 & 8 & 0 & 5 & 7 \\ \mathbf{7} & \mathbf{12} & 4 & 0 & 1 \\ 1 & 3 & 5 & 3 & 0 \end{pmatrix}$$

5. Iteración $k = 4$ (Permitir el nodo 4 como vértice intermedio): Evaluando combinaciones a través de la fila 4 $(7, 12, 4, 0, 1)$ y la columna 4 $(2, 7, 5, 0, 3)^T$:

- $d_{13}^{(4)} = \text{mín}\{7, 2 + 4\} = 6$, $d_{15}^{(4)} = \text{mín}\{14, 2 + 1\} = 3$.
- $d_{25}^{(4)} = \text{mín}\{9, 7 + 1\} = 8$.
- $d_{35}^{(4)} = \text{mín}\{7, 5 + 1\} = 6$.

$$D^{(4)} = \begin{pmatrix} 0 & 5 & \mathbf{6} & 2 & \mathbf{3} \\ 5 & 0 & 2 & 7 & \mathbf{8} \\ 3 & 8 & 0 & 5 & \mathbf{6} \\ 7 & 12 & 4 & 0 & 1 \\ 1 & 3 & 5 & 3 & 0 \end{pmatrix}$$

6. Iteración $k = 5$ (Permitir el nodo 5 como vértice intermedio): Evaluando combinaciones a través de la fila 5 $(1, 3, 5, 3, 0)$ y la columna 5 $(3, 8, 6, 1, 0)^T$:

- $d_{41}^{(5)} = \min\{7, 1+1\} = 2$, $d_{42}^{(5)} = \min\{12, 1+3\} = 4$.

$$D^{(5)} = \begin{pmatrix} 0 & 5 & 6 & 2 & 3 \\ 5 & 0 & 2 & 7 & 8 \\ 3 & 8 & 0 & 5 & 6 \\ \mathbf{2} & \mathbf{4} & 4 & 0 & 1 \\ 1 & 3 & 5 & 3 & 0 \end{pmatrix}$$

Parada en $k = 5$. La matriz final $D^{(5)}$ proporciona las distancias mínimas absolutas entre todo par de nodos $i, j \in V$. La animación iterativa y las arborescencias resultantes se ilustran en la Figura 7.14.

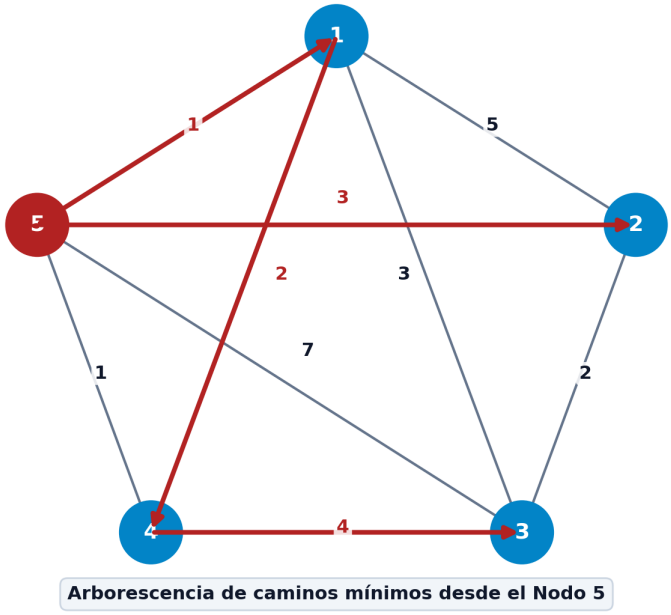

Figura 7.14: Traza gráfica de las arborescencias de caminos mínimos en el Algoritmo de Floyd-Warshall

8 Flujos en redes

La optimización de **flujos en redes** constituye uno de los pilares más avanzados y de mayor aplicabilidad en el análisis de redes y la investigación operativa. Permite modelar, cuantificar y optimizar la circulación de bienes físicos o abstractos (tales como tráfico vehicular, fluidos en tuberías, corriente eléctrica, paquetes de información o transferencias financieras) a través de infraestructuras interconectadas sujetas a capacidades físicas límite (Ahuja, Magnanti, y Orlin 1993; Bertsekas 1998).

En este capítulo desarrollaremos la fundamentación matemática rigurosa de la teoría de flujos. Comenzaremos con el estudio algebraico del espacio de flujos, ciclos y cociclos (cortes), introduciendo el célebre Lema de Coloración de Arcos de Minty como piedra angular demostrativa. A continuación, formularemos el problema del flujo máximo, demostrando formalmente el Teorema Max-Flow Min-Cut de Ford-Fulkerson y analizando sus algoritmos de resolución. Finalmente, ampliaremos la teoría a la formulación mediante programación lineal dual y a la resolución del problema de flujo a coste mínimo y el problema general del transbordo.

! Objetivos de aprendizaje

Al finalizar este capítulo, serás capaz de:

1. **Formular** algebraicamente el concepto de flujo y circulación en digrafos mediante las ecuaciones de conservación y balance en los nodos.
2. **Caracterizar** la estructura vectorial de los flujos, calculando las bases fundamentales de ciclos y el número ciclomático $\nu(G)$.
3. **Demostrar** y **aplicar** el Lema de Coloración de Arcos de Minty mediante su algoritmo constructivo de etiquetado de vértices.
4. **Demostrar** y **analizar** el Teorema de Flujo Máximo - Corte Mínimo de Ford-Fulkerson y la relación de dualidad en optimización lineal.
5. **Ejecutar** y **caracterizar** el algoritmo de Ford-Fulkerson en redes residuales mediante el método de etiquetado directo y la cota de Edmonds-Karp.
6. **Formular** y **resolver** los problemas de flujo a coste mínimo y el problema general del transbordo.

8.1. Estructura algebraica de flujos, ciclos y cociclos

El análisis cualitativo y cuantitativo de las redes de flujo requiere establecer una representación matemática rigurosa basada en el álgebra lineal sobre la topología del digrafo. Los flujos en una red no son simples colecciones arbitrarias de números asignados a las conexiones; responden a leyes físicas y topológicas estrictas de conservación local en los vértices (análogas a las leyes de Kirchhoff en circuitos eléctricos o a la ecuación de continuidad en dinámica de fluidos).

Para formalizar este comportamiento, representamos la red como un digrafo conexo $G = (V, U)$ formado por un conjunto de $n = |V|$ vértices y $m = |U|$ arcos dirigidos.

Definición: Flujo en un digrafo y conservación

Dado un digrafo conexo $G = (V, U)$ con m arcos dirigidos, un **flujo** es un vector $\mathbf{f} = (f_{u_1}, f_{u_2}, \dots, f_{u_m})^T \in \mathbb{R}^m$ cuyas componentes representan la cantidad de caudal o flujo f_u que transita por cada arco $u \in U$, satisfaciendo la **ley de conservación de flujo** en todos los vértices:

$$\sum_{u \in w^+(i)} f_u = \sum_{u \in w^-(i)} f_u, \quad \forall i \in V$$

donde $w^+(i)$ representa el conjunto de arcos salientes del nodo i y $w^-(i)$ el conjunto de arcos entrantes al nodo i.

Nota de notación: Distinción entre arcos, vectores y componentes

Para evitar cualquier confusión entre los nombres de los arcos y los valores numéricos del flujo:

1. **Identificador del Arco**: Los m arcos del digrafo se etiquetan como $u_1, u_2, \dots, u_m \in U$ (o bien por el par ordenado de sus vértices $u = (i, j)$).
2. **Identificador de Vectores (Superíndices)**: Los distintos vectores de flujo o de ciclo se denotan en negrita utilizando **superíndices** (por ejemplo, $\mathbf{f}^1, \mathbf{f}^2, \mathbf{f}^3$ para vectores de flujo; $^1, ^2$ para vectores de ciclo).
3. **Componentes Escalares de Arco (Subíndices)**: El caudal que circula por el arco u_k se denota mediante el **subíndice** f_{u_k} (o f_{ij}), correspondiente a la k-ésima entrada del vector $\mathbf{f}$. En los gráficos de la red, las etiquetas especifican explícitamente el arco y su valor $(u_k : f_{u_k})$.

En modelos generales de redes donde existen inyecciones o extracciones externas de caudal (por ejemplo, plantas de generación o centros de distribución), se asocia a cada nodo $i \in V$ un escalar de balance $b_i \in \mathbb{R}$:

- **Nodo fuente ($b_i > 0$)**: Inyecta b_i unidades netas de flujo a la red.

- **Nodo sumidero** ($b_i < 0$): Extrae $|b_i|$ unidades netas de flujo de la red.
- **Nodo de transbordo** ($b_i = 0$): La suma de flujos entrantes iguala exactamente a la de salientes, actuando como mero nodo de paso.

La condición necesaria de factibilidad global exige el equilibrio perfecto entre oferta y demanda: la suma total de balances debe ser nula en toda la red, $\sum_{i \in V} b_i = 0$. Cuando la red no posee entradas ni salidas externas ($b_i = 0$ para todo $i \in V$), el vector $\mathbf{f}$ se denomina estrictamente **circulación**, garantizando la conservación exacta en cada vértice del digrafo.

Ejemplo: Evaluación de vectores de flujo en un digrafo

Considérese el digrafo de 5 nodos $V = \{a, b, c, d, e\}$ y 7 arcos dirigidos $U = \{u_1 = (a, b), u_2 = (b, c), u_3 = (c, d), u_4 = (d, e), u_5 = (e, a), u_6 = (e, b), u_7 = (e, c)\}$.
Se evalúan los siguientes tres vectores de flujo $\mathbf{f} \in \mathbb{R}^7$, ilustrados en la Figura 8.1:

1. $\mathbf{f}^1 = (2.7;\ 2;\ 2;\ 2;\ 2.7;\ -0.7;\ 0)^T$:
   - Nodo a: Salen $f_1 = 2.7$, entran $f_5 = 2.7 \implies 2.7 = 2.7$.
   - Nodo b: Salen $f_2 = 2$, entran $f_1 + f_6 = 2.7 + (-0.7) = 2 \implies 2 = 2$.
   - Nodo e: Salen $f_5 + f_6 + f_7 = 2.7 - 0.7 + 0 = 2$, entra $f_4 = 2 \implies 2 = 2$.
   - *Conclusión*: Cumple la ley de conservación en todos los nodos, luego $\mathbf{f}^1$ es un flujo válido.
2. $\mathbf{f}^2 = (0;\ 1;\ 1;\ 1;\ 0;\ 1;\ 0)^T$: Corresponde al flujo que circula por el ciclo formado por los arcos u_2, u_3, u_4, u_6.
3. $\mathbf{f}^3 = (1;\ 0;\ -1;\ -1;\ 1;\ -1;\ -1)^T$: Satisface las ecuaciones de conservación en los 5 nodos.

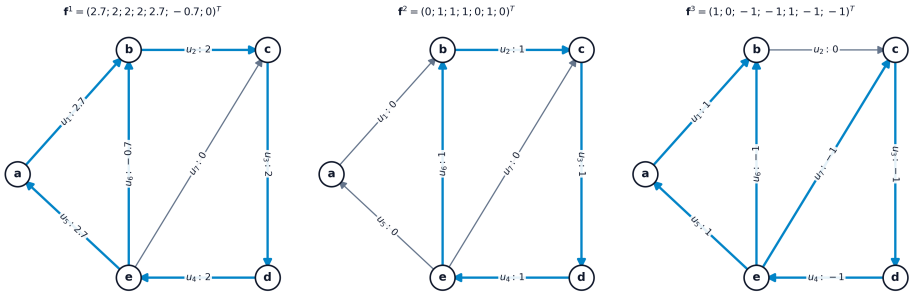

Figura 8.1: Evaluación de tres vectores de flujo sobre un digrafo de 5 nodos

La topología del digrafo impone restricciones fundamentales sobre los vectores de flujo factibles. Por ejemplo, en una estructura sin circuitos cerrados, la conservación obliga a que no pueda sostenerse ningún caudal continuo.

Lema: Flujo nulo en árboles

Un flujo definido sobre un árbol (digrafo conexo acíclico) es necesariamente el **flujo nulo** ($\mathbf{f} = \mathbf{0}$).
Demostración: Todo árbol de n vértices posee $n-1$ arcos y contiene al menos un vértice pendiente o hoja x_1 de grado total $d(x_1) = 1$. Sea $u \in U$ el único arco incidente en x_1. Por la ley de conservación de flujo en x_1, la única componente entrante o saliente debe ser cero, $f_u = 0$.
Eliminando el nodo x_1 y el arco u, se obtiene un subgrafo generado sobre $V \setminus \{x_1\}$ que mantiene la estructura de árbol. Repitiendo el razonamiento inductivo para los restantes $n-1$ nodos, se deduce que todas las componentes del vector de flujo son cero: $f_u = 0, \forall u \in U$. ■

El resultado anterior demuestra que la existencia de ciclos o circuitos cerrados es una condición estrictamente necesaria para sostener una circulación no nula en una red. Al añadir arcos a un árbol para formar ciclos, las ecuaciones de conservación lineales permiten combinar diferentes soluciones de flujo mediante operaciones de suma y multiplicación por escalares. Esta propiedad algebraica fundamental se formaliza en el siguiente resultado.

Lema: Estructura vectorial del espacio de flujos

Cualquier combinación lineal de flujos es un flujo. En consecuencia, el conjunto de flujos definidos sobre un digrafo $G = (V, U)$ forma un espacio vectorial.

La estructura de espacio vectorial garantiza que el conjunto de flujos satisface la clausura algebraica: sumar dos circulaciones factibles o escalar una circulación existente produce siempre un flujo válido que preserva la conservación en todos los vértices. Para ilustrar cuantitativamente este principio abstracto, consideremos una combinación lineal concreta de los vectores de flujo evaluados previamente.

Ejemplo: Combinación lineal de vectores de flujo

Consideremos los tres vectores de flujo $\mathbf{f}^1, \mathbf{f}^2, \mathbf{f}^3 \in \mathbb{R}^7$ analizados anteriormente sobre el digrafo de 5 nodos. Construimos la combinación lineal:

$$\mathbf{f} = 2\mathbf{f}^1 + \mathbf{f}^2 - 3\mathbf{f}^3$$

Evaluando componente a componente:

$$\begin{aligned}\mathbf{f} &= 2(2.7;\ 2;\ 2;\ 2;\ 2.7;\ -0.7;\ 0)^T + (0;\ 1;\ 1;\ 1;\ 0;\ 1;\ 0)^T - 3(1;\ 0;\ -1;\ -1;\ 1;\ -1;\ -1)^T \\ &= (2.4;\ 5;\ 8;\ 8;\ 2.4;\ 2.6;\ 3)^T\end{aligned}$$

Como se ilustra en la Figura 8.2, se puede verificar fácilmente la conservación de flujo en cada uno de los 5 vértices:

- **Nodo** a: Salen $f_1 = 2.4$, entran $f_5 = 2.4 \implies 2.4 = 2.4$.
- **Nodo** b: Salen $f_2 = 5$, entran $f_1 + f_6 = 2.4 + 2.6 = 5 \implies 5 = 5$.
- **Nodo** c: Salen $f_3 = 8$, entran $f_2 + f_7 = 5 + 3 = 8 \implies 8 = 8$.
- **Nodo** d: Salen $f_4 = 8$, entran $f_3 = 8 \implies 8 = 8$.
- **Nodo** e: Salen $f_5 + f_6 + f_7 = 2.4 + 2.6 + 3 = 8$, entra $f_4 = 8 \implies 8 = 8$.

Por consiguiente, la combinación lineal $\mathbf{f}$ satisface la conservación en todos los nodos y constituye un flujo factible bien definido.

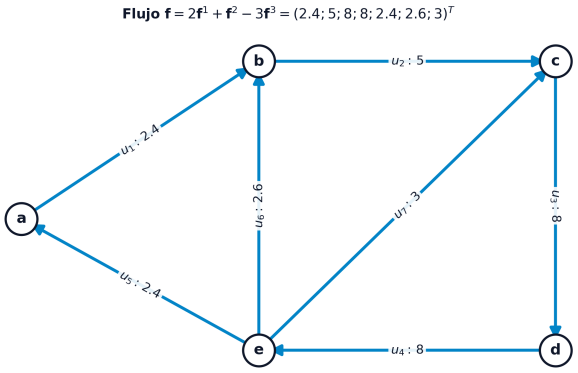

Figura 8.2: Flujo resultante de la combinación lineal $\mathbf{f} = 2\mathbf{f}^1 + \mathbf{f}^2 - 3\mathbf{f}^3$

El resultado anterior prueba que el conjunto de flujos definidos sobre un digrafo es un espacio vectorial. Para identificar su dimensión y una base de flujos que permita caracterizarlos todos, es preciso estudiar la relación que existe entre los ciclos y los flujos de un digrafo.

8.1.1. Ciclos y su relación con los flujos

Dado un digrafo conexo $G = (V, U)$, un **ciclo** μ es una cadena simple (sin repetir arcos) cuyo nodo inicial y final coinciden. Al dotar a μ de un sentido de giro de referencia, los arcos $u \in \mu$ se clasifican en:

- **Arcos positivos** ($u \in \mu^+$): Su orientación en el digrafo coincide con el sentido del ciclo.
- **Arcos negativos** ($u \in \mu^-$): Su orientación en el digrafo es opuesta al sentido del ciclo.
- **Arcos fuera del ciclo** ($u \notin \mu$): No forman parte de la cadena simple.

A cada ciclo se le pueden asignar libremente dos orientaciones de giro opuestas, lo que invierte los papeles de los arcos positivos y negativos. Como se ilustra en la Figura 8.3, al recorrer la

red según un sentido de giro, los arcos $1, 4, 3$ resultan directos o positivos (μ^+), mientras que los arcos $6, 7$ son opuestos o negativos (μ^-).

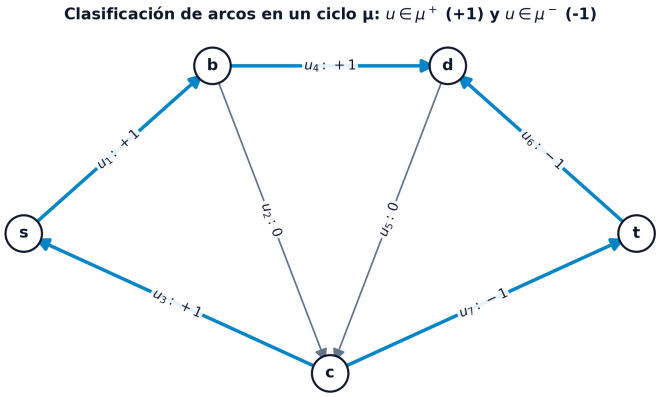

Figura 8.3: Clasificación de arcos en un ciclo μ según el sentido de giro elegido

Definición: Vector característico de un ciclo

Un ciclo μ se representa algebraicamente mediante un vector característico $= (\mu_1, \mu_2, \dots, \mu_m)^T \in \mathbb{R}^m$, donde la componente asociada a cada arco $u \in U$ se define como:

$$\mu_u = \begin{cases} +1 & \text{si } u \in \mu^+ \\ -1 & \text{si } u \in \mu^- \\ 0 & \text{si } u \notin \mu \end{cases}$$

Ejemplo: Vectores característicos de ciclos y relaciones lineales

Considérese el digrafo de referencia de 5 nodos s, b, c, d, t y 7 arcos dirigidos de la Figura 8.4. Se pueden identificar diversos ciclos y sus correspondientes vectores característicos $_k \in \mathbb{R}^7$:

- $_1 = (1, 1, 1, 0, 0, 0, 0)^T$: Ciclo orientado $s \to b \to c \to s$ (formado por los arcos $1, 2, 3$).
- $_2 = (0, -1, 0, 1, 1, 0, 0)^T$: Ciclo $b \to d \to c \to b$ (formado por los arcos $4, 5$ y el opuesto de 2).
- $_3 = (1, 0, 1, 1, 1, 0, 0)^T$: Ciclo exterior $s \to b \to d \to c \to s$.
- $_4 = (-1, -1, -1, 0, -1, -1, -1)^T$: Ciclo global en sentido opuesto.
- $_5 = (-1, -1, -1, 0, 0, 0, 0)^T$: Ciclo inverso al ciclo $_1$.

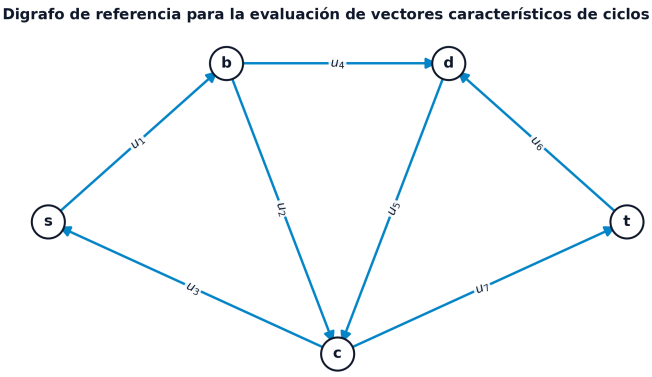

Figura 8.4: Digrafo de referencia para la evaluación de vectores característicos de ciclos

Analizando las componentes de los vectores característicos, se comprueban de forma inmediata las siguientes relaciones lineales entre los ciclos:

$$_1 = -_5, \qquad _3 = _1 + _2$$

Esta propiedad demuestra que las combinaciones lineales de ciclos generan nuevos vectores característicos de ciclos, lo que fundamenta la estructura de espacio vectorial del conjunto de flujos.

Proposición: Los ciclos son flujos

El vector característico asociado a cualquier ciclo en un digrafo es un flujo.
Demostración: Para cualquier nodo $i \notin \mu$, ningún arco incidente pertenece al ciclo, por lo que $f_u = 0$ y la ley de conservación se cumple de forma trivial ($0 = 0$). Para un nodo $i \in \mu$, el ciclo entra por un arco u_{in} y sale por otro u_{out}. Analizando la orientación de ambos arcos respecto al sentido del giro (positivo o negativo), la contribución al balance entrante $\sum f_{in}$ y al balance saliente $\sum f_{out}$ resulta idéntica en ambos miembros, satisfaciéndose $\sum_{u \in w^+(i)} \mu_u = \sum_{u \in w^-(i)} \mu_u$. ■

Como se ilustra en la Figura 8.5, los vectores $\mathbf{f}^2 = (0; 1; 1; 1; 0; 1; 0)^T$ y $\mathbf{f}^3 = (1; 0; -1; -1; 1; -1; -1)^T$ son flujos válidos generados directamente por ciclos sobre la red de 5 nodos.

Corolario: Variación de flujo mediante ciclos

Dado un flujo $\mathbf{f}$ en un digrafo G y un ciclo , el vector resultante de sumar a $\mathbf{f}$ el vector asociado al ciclo multiplicado por una constante $\alpha \in \mathbb{R}$ ($\mathbf{f}' = \mathbf{f} + \alpha$) es también un flujo en

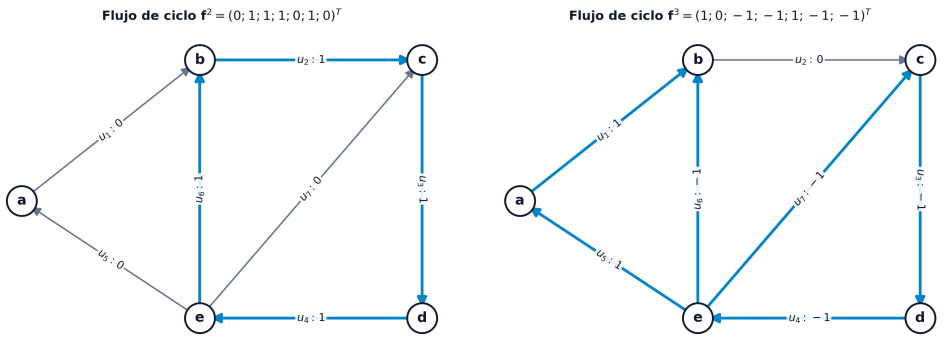

Figura 8.5: Vectores de flujo $\mathbf{f}^2$ y $\mathbf{f}^3$ generados por ciclos satisfaciendo conservación en todos los nodos

G.

8.1.2. Bases de flujos y número ciclomático

Obviamente, no todos los flujos son ciclos. Sin embargo, cualquier flujo se puede expresar como combinación lineal de ciclos. Además, es posible identificar una base del espacio vectorial de los flujos de un digrafo.

Esta base está formada exclusivamente por ciclos y se obtiene a partir de un árbol soporte del digrafo. Por tanto, cada árbol soporte da lugar a una base distinta del espacio vectorial de flujos.

Definición: Independencia de flujos

Dado un digrafo $G = (V, U)$, un conjunto de flujos $\{\mathbf{f}^1, \mathbf{f}^2, \ldots, \mathbf{f}^k\}$ es linealmente independiente si sus correspondientes vectores en $\mathbb{R}^m$ son linealmente independientes.

La propiedad de independencia lineal garantiza que ninguno de los flujos de la base pueda construirse combinando los restantes. Para seleccionar una base de flujos de forma constructiva a partir de la topología del digrafo, el procedimiento matemático estándar se apoya en la elección de un **árbol soporte** de la red.

Teorema: Base fundamental de ciclos

Sea $G = (V, U)$ un digrafo conexo con n vértices y m arcos, y sea $H = (V, T)$ un árbol soporte de G (formado por $n - 1$ arcos).
Al añadir a T cualquier arco fuera del árbol $u \in U \setminus T$, se forma un único ciclo elemental

μ^u en G tal que $\mu_u^u = 1$. El conjunto de ciclos $H = \{\mu^u \mid u \in U \setminus T\}$ constituye una **base del espacio vectorial de flujos** del digrafo G.
Demostración: Debemos probar que el conjunto de ciclos H es linealmente independiente y generador:

1. **Independencia lineal**: Cada arco fuera del árbol $u \in U \setminus T$ pertenece a un único ciclo de la base (aquel generado por el propio arco u). Por tanto, la componente $\mu_u^u = 1$ mientras que $\mu_u^{u'} = 0$ para cualquier otro $u' \in U \setminus T$. La matriz construida con los vectores de la base contiene una submatriz identidad de dimensión $|U \setminus T| = m - n + 1$, lo que garantiza independencia lineal.
2. **Carácter generador**: Sea un flujo arbitrario $\mathbf{f} = (f_1, \dots, f_m)^T$. Definimos el vector $\mathbf{g} = \mathbf{f} - \sum_{u \in U \setminus T} {f_u}^u$. Como $\mathbf{g}$ es combinación lineal de flujos, $\mathbf{g}$ es un flujo. Para cualquier arco $u \in U \setminus T$, la componente $g_u = f_u - f_u(1) = 0$. Por tanto, el flujo $\mathbf{g}$ tiene componentes nulas en todos los arcos de $U \setminus T$. Esto implica que $\mathbf{g}$ es un flujo definido únicamente sobre el árbol T. Por el Lema de Flujo Nulo en Árboles, se deduce que $\mathbf{g} = \mathbf{0}$, demostrando que $\mathbf{f} = \sum_{u \in U \setminus T} {f_u}^u$. ■

El teorema anterior demuestra que el número de vectores necesarios para generar cualquier circulación en el digrafo queda determinado exclusivamente por la cantidad de arcos fuera del árbol soporte. Esta dimensión algebraica se conoce como número ciclomático del grafo.

Definición: Número ciclomático

Se define el **número ciclomático** $\nu(G)$ de un digrafo conexo $G = (V, U)$ como la dimensión del espacio vectorial de sus flujos:

$$\nu(G) = m - n + 1$$

El número ciclomático $\nu(G)$ nos indica que, independientemente de cuán compleja sea la red, basta con identificar $m - n + 1$ cuerdas no básicas para caracterizar unívocamente todo el espacio de circulaciones. A continuación, aplicamos este procedimiento constructivo sobre una red concreta de 5 nodos y 7 arcos.

Ejemplo: Construcción de una base de ciclos y descomposición de un flujo

Considérese el digrafo de $n = 5$ nodos y $m = 7$ arcos de la **?@fig-base-ciclos-descomposicion-animado**. Su número ciclomático es $\nu(G) = m - n + 1 = 7 - 5 + 1 = 3$, lo que indica que el espacio vectorial de flujos posee dimensión 3.
Paso 1: Selección del Árbol Soporte y Cuerdas Seleccionamos el árbol soporte $H = (V, T)$ formado por $n - 1 = 4$ arcos: $T = \{u_1, u_4, u_5, u_7\}$ (representados en **azul**). Los 3 arcos fuera del árbol, denominados cuerdas o arcos no básicos, son $U \setminus T = \{u_2, u_3, u_6\}$

(representados en **gris**).

Paso 2: Generación de la Base Fundamental de Ciclos Al añadir individualmente cada cuerda $u \in U \setminus T$ al árbol soporte T, se forma exactamente un ciclo fundamental elemental ^{u} en el cual los arcos pertenecientes al ciclo se destacan en **rojo**:

1. **Añadir la cuerda** $u_2 = (b, c)$: Se cierra el ciclo $b \to c \to e \to a \to b$. Fijando orientación positiva en u_2 ($\mu^2_{u_2} = 1$), los arcos del árbol u_1, u_5 avanzan en sentido directo y u_7 en sentido opuesto, obteniéndose:
$$^2 = (1, 1, 0, 0, 1, 0, -1)^T$$

2. **Añadir la cuerda** $u_3 = (c, d)$: Se cierra el ciclo $c \to d \to e \to c$. Con orientación positiva en u_3 ($\mu^3_{u_3} = 1$), los arcos u_4, u_7 avanzan en sentido directo, resultando:
$$^3 = (0, 0, 1, 1, 0, 0, 1)^T$$

3. **Añadir la cuerda** $u_6 = (e, b)$: Se cierra el ciclo $e \to b \to a \to e$. Con orientación positiva en u_6 ($\mu^6_{u_6} = 1$), los arcos u_1, u_5 del árbol se recorren en sentido inverso, resultando:
$$^6 = (-1, 0, 0, 0, -1, 1, 0)^T$$

El conjunto $B = \{^2, ^3, ^6\}$ es linealmente independiente y constituye una **base del espacio vectorial de flujos**.

Paso 3: Descomposición Unívoca de un Flujo en la Base Dado el flujo $\mathbf{f} = (3, 4, 6, 6, 3, 1, 2)^T$, sus coordenadas de descomposición en la base B vienen dadas de forma directa por los valores del flujo en las cuerdas fuera del árbol: $f_{u_2} = 4$, $f_{u_3} = 6$ y $f_{u_6} = 1$. Se verifica la combinación lineal:

$$\mathbf{f} = 4^2 + 6^3 + 1^6 = 4\begin{pmatrix}1\\1\\0\\0\\1\\0\\-1\end{pmatrix} + 6\begin{pmatrix}0\\0\\1\\1\\0\\0\\1\end{pmatrix} + 1\begin{pmatrix}-1\\0\\0\\0\\-1\\1\\0\end{pmatrix} = \begin{pmatrix}3\\4\\6\\6\\3\\1\\2\end{pmatrix}$$

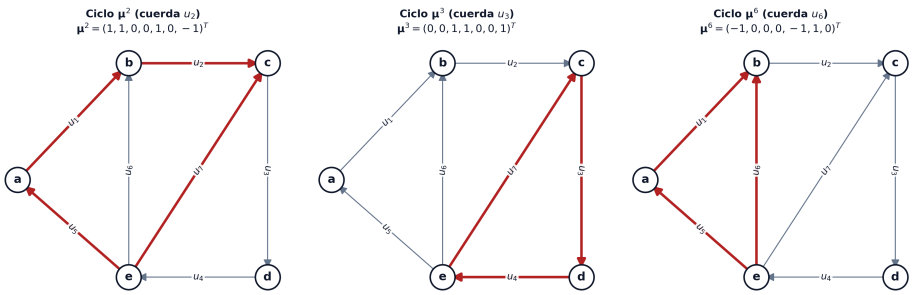

Figura 8.6: Construcción paso a paso de los tres ciclos fundamentales $\{^2, ^3, ^6\}$ de la base de flujos

8.1.3. Cociclos y Lema de Coloración de Arcos de Minty

Mientras que los ciclos representan circulaciones internas cerradas que conservan el flujo localmente sin alterar los balances netos externos, los **cociclos** (o cortes topológicos) representan la estructura dual: barreras globales que separan el conjunto de vértices en dos regiones disjuntas A y $V \setminus A$. Los cociclos condicionan la capacidad global de transporte de la red y determinan la existencia de embotellamientos o cuellos de botella.

Definición: Cociclo (Corte)

Dado un digrafo conexo $G = (V, U)$ y un subconjunto propio no vacío de vértices $A \subset V$, se define el **cociclo** $w(A)$ como el subconjunto de arcos que tienen un extremo en A y el otro en $V \setminus A$:

$$w(A) = w^+(A) \cup w^-(A)$$

donde:

- **Arcos salientes de** A: $w^+(A) = \{u = (i, j) \in U \mid i \in A,\ j \notin A\}$.
- **Arcos entrantes a** A: $w^-(A) = \{u = (j, i) \in U \mid i \in A,\ j \notin A\}$.

Para operar analíticamente con los cociclos e integrarlos en sistemas de ecuaciones algebraicas, asignamos a cada cociclo un vector característico que codifica la dirección del tránsito respecto a la frontera de corte.

Definición: Vector característico de un cociclo

Un cociclo $w(A)$ se representa algebraicamente mediante un vector característico $= (\theta_1, \theta_2, \ldots, \theta_m)^T \in \mathbb{R}^m$, cuyas componentes se definen como:

$$\theta_u = \begin{cases} +1 & \text{si } u \in w^+(A) \\ -1 & \text{si } u \in w^-(A) \\ 0 & \text{si } u \notin w(A) \end{cases}$$

La distinción visual en los diagramas de corte resulta fundamental para comprender la partición topológica: los vértices pertenecientes al conjunto A se identifican mediante contorno y texto en **azul cerúleo**, mientras que los vértices del complemento $V \setminus A$ permanecen en **slate oscuro**. Los arcos que cruzan la frontera entre ambas particiones forman el cociclo $w(A)$ y se destacan en **rojo teja**, mientras que los arcos cuyos dos extremos pertenecen a la misma partición (internos a A o internos a $V \setminus A$) permanecen en **gris slate**.

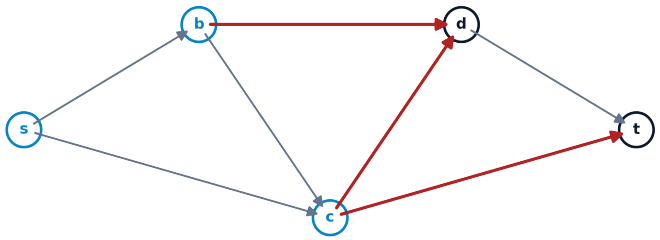

Figura 8.7: Ilustración de un cociclo $w(A)$ separando el conjunto $A = \{s, b, c\}$

Como se ilustra en la Figura 8.7, para el subconjunto de nodos $A = \{s, b, c\}$ (resaltados en azul), los arcos que atraviesan la frontera hacia $\{d, t\}$ son $u_4 = (b, d)$, $u_5 = (d, c)$ y $u_7 = (c, t)$, destacándose en **rojo teja**. De ellos, u_4 y u_7 salen de A hacia el exterior ($w^+(A)$, asignándoles el valor $+1$), mientras que u_5 entra desde $d \notin A$ hacia $c \in A$ ($w^-(A)$, asignándole el valor -1). Los arcos u_1, u_2, u_3, u_6 no cruzan la frontera y reciben el valor 0, resultando el vector característico $= (0, 0, 0, 1, -1, 0, 1)^T$.

Ejemplo: Evaluación de vectores de cociclo en un digrafo

Considérese el digrafo de $n = 5$ nodos y $m = 7$ arcos analizado previamente. Para comprender cómo la elección del conjunto de vértices A modifica radicalmente la frontera de corte y el vector característico resultante, evaluamos dos particiones distintas A_1 y A_2, ilustradas en la Figura 8.8:

1. **Subconjunto $A_1 = \{a, b, e\}$ (Subgráfico Izquierdo)**: En esta primera partición,

los nodos a, b, e se encuentran en la región izquierda (destacados en **azul cerúleo**) y los nodos c, d en la región derecha (en **slate oscuro**). Analizamos los 7 arcos del digrafo uno a uno:

- Arcos internos a A_1: Los arcos $u_1 = (a, b)$, $u_5 = (e, a)$ y $u_6 = (e, b)$ conectan vértices que pertenecen ambos a A_1. No cruzan la frontera y por tanto reciben el valor $\theta_{u_1} = \theta_{u_5} = \theta_{u_6} = 0$.
- Arcos salientes de A_1: El arco $u_2 = (b, c)$ parte de $b \in A_1$ y llega a $c \notin A_1$; de igual modo, el arco $u_7 = (e, c)$ parte de $e \in A_1$ y llega a $c \notin A_1$. Ambos son arcos directos o salientes: $w^+(A_1) = \{u_2, u_7\}$, asignándoles el valor $+1$ ($\theta_{u_2} = 1, \theta_{u_7} = 1$).
- Arcos entrantes a A_1: El arco $u_4 = (d, e)$ parte de $d \notin A_1$ e ingresa a $e \in A_1$. Es un arco inverso o entrante: $w^-(A_1) = \{u_4\}$, asignándole el valor -1 ($\theta_{u_4} = -1$).
- Arcos externos a A_1: El arco $u_3 = (c, d)$ conecta dos vértices fuera de A_1, por lo que $\theta_{u_3} = 0$.
- Vector característico de $w(A_1)$: $^1 = (0;\ 1;\ 0;\ -1;\ 0;\ 0;\ 1)^T$.

2. **Subconjunto $A_2 = \{b, d\}$ (Subgráfico Derecho)**: En esta segunda partición, los nodos b, d forman la región superior (destacados en **azul cerúleo**) y los nodos a, c, e forman la región inferior (en **slate oscuro**):

   - Arcos salientes de A_2: Los arcos $u_2 = (b, c)$ (sale de $b \in A_2$ hacia c) y $u_4 = (d, e)$ (sale de $d \in A_2$ hacia e) cruzan la frontera hacia afuera: $w^+(A_2) = \{u_2, u_4\}$, asignándoles el valor $+1$ ($\theta_{u_2} = 1, \theta_{u_4} = 1$).
   - Arcos entrantes a A_2: Los arcos $u_1 = (a, b)$ (entra desde a a $b \in A_2$), $u_3 = (c, d)$ (entra desde c a $d \in A_2$) y $u_6 = (e, b)$ (entra desde e a $b \in A_2$) cruzan la frontera hacia adentro: $w^-(A_2) = \{u_1, u_3, u_6\}$, asignándoles el valor -1 ($\theta_{u_1} = -1, \theta_{u_3} = -1, \theta_{u_6} = -1$).
   - Arcos no incidentes en el corte: Los arcos $u_5 = (e, a)$ y $u_7 = (e, c)$ conectan nodos fuera de A_2, por lo que $\theta_{u_5} = \theta_{u_7} = 0$.
   - Vector característico de $w(A_2)$: $^2 = (-1;\ 1;\ -1;\ 1;\ 0;\ -1;\ 0)^T$.

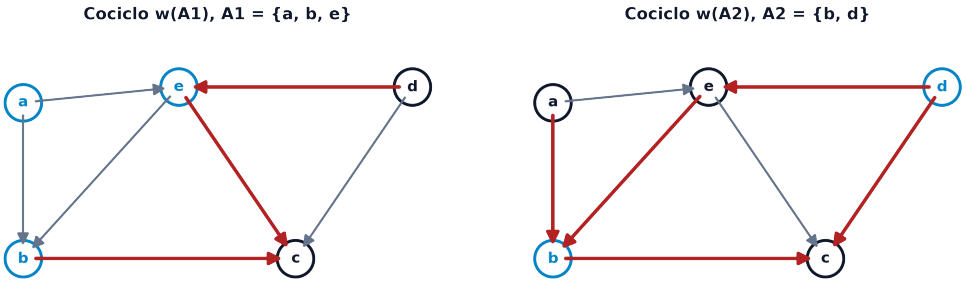

Figura 8.8: Evaluación de los vectores de cociclo ^{1} y ^{2} para los conjuntos $A_1 = \{a, b, e\}$ y $A_2 = \{b, d\}$

8.1.4. Ortogonalidad fundamental entre ciclos y cociclos

Existe una propiedad algebraica fundamental que vincula el espacio de flujos (generado por los ciclos) con el espacio de cociclos (generado por los cortes). Para cualquier ciclo y cualquier cociclo definidos sobre el mismo digrafo $G = (V, U)$, su producto escalar es idénticamente nulo:

$$^{T} = \sum_{u \in U} \mu_u \theta_u = 0$$

Esta propiedad demuestra que el **espacio vectorial de flujos** (de dimensión $m - n + 1$) y el **espacio vectorial de cociclos** (de dimensión $n - 1$) son **subespacios ortogonales complementarios** en $\mathbb{R}^m$, satisfaciendo $(m - n + 1) + (n - 1) = m$. Físicamente, esto significa que el caudal neto transportado por cualquier circulación a través de un corte topológico es exactamente igual a cero.

Una vez establecida la dualidad estricta entre el espacio de ciclos y el espacio de cociclos, surge la pregunta de si es posible determinar cuál de estas dos estructuras domina la conectividad de la red cuando los arcos están sujetos a restricciones de orientación o estado.

Esta cuestión fue resuelta por George J. Minty en 1966 al formular el **Lema de Coloración de Arcos**. El lema establece una dicotomía matemática perfecta: al colorear arbitrariamente los arcos de un digrafo conexo con tres colores (negro, verde y rojo) y fijar un arco negro de referencia u_0, **se verifica o bien la existencia de un ciclo elemental coloreado que contiene a u_0, o bien la existencia de un cociclo elemental coloreado que contiene a u_0, pero jamás ambos simultáneamente**. Esta dicotomía constituye el motor lógico fundamental para demostrar la convergencia del algoritmo de Ford-Fulkerson y el Teorema Max-Flow Min-Cut.

Lema: Coloración de arcos de Minty

Sea $G = (V, U)$ un digrafo conexo cuyos arcos se encuentran coloreados (de forma arbitraria) utilizando tres colores: **negro** (N), **verde** (V), **rojo** (R) o bien permanecen **sin color** (0), existiendo al menos un arco de referencia $u_0 \in U$ coloreado de **negro**. Entonces, se verifica **una, y solo una**, de las dos aseveraciones siguientes:

1. El arco negro u_0 pertenece a un **ciclo elemental** coloreado (formado únicamente por arcos negros, verdes o rojos). En este ciclo, los arcos negros tienen orientación positiva, los arcos verdes tienen orientación negativa y los arcos rojos pueden tener cualquier orientación.
2. El arco negro u_0 pertenece a un **cociclo elemental** coloreado (formado únicamente por arcos negros, verdes o sin color). En este cociclo, los arcos negros están en $w^+(A)$ (mismo sentido que u_0), los verdes están en $w^-(A)$ (sentido opuesto) y los arcos sin color pueden tener cualquier sentido.

Demostración: La demostración del lema es constructiva y se fundamenta en un proceso sistemático de etiquetado de vértices.
Sea $u_0 = (t, s)$ el arco de referencia coloreado de negro (origen en t y destino en s).
Paso 1: Etiquetado Inicial Asignar una etiqueta al nodo destino s: $p(s) = s$. El resto de vértices permanecen no etiquetados: $p(j) = 0, \forall j \neq s$.
Paso 2: Propagación de Etiquetas Repetir mientras sea posible etiquetar nuevos vértices: dado un nodo i ya etiquetado $(p(i) \neq 0)$ y un nodo j no etiquetado $(p(j) = 0)$ adyacentes en G, asignar la etiqueta $p(j) = i$ si se satisface alguna de las siguientes reglas de color:

- Existe el arco dirigido $u = (i, j) \in U$ (sale de i a j) y u está coloreado de **negro** o **rojo**.
- Existe el arco dirigido $u = (j, i) \in U$ (entra de j a i) y u está coloreado de **verde** o **rojo**.

Paso 3: Criterio de Parada y Análisis de Casos Al finalizar el proceso de etiquetado, se presenta una y solo una de las siguientes situaciones:

- **Caso A ($p(t) \neq 0$, el vértice t ha sido etiquetado)**: Reconstruyendo la cadena de antecedentes desde t hasta s $(t - p(t) - p(p(t)) - \cdots - s)$ y añadiendo el arco negro $u_0 = (t, s)$, se obtiene un ciclo. Por la regla de etiquetado, todos sus arcos son negros, verdes o rojos. Los negros y rojos directos avanzan de i a j (orientación positiva), mientras que los verdes y rojos inversos van de j a i (orientación negativa). Esto satisface la **Afirmación 1**.

- **Caso B ($p(t) = 0$, el vértice t no pudo ser etiquetado)**: Definimos el conjunto de vértices etiquetados $A = \{i \in V \mid p(i) \neq 0\}$. Como $s \in A$ y $t \notin A$, el arco

negro $u_0 = (t, s) \in w^-(A)$, o equivalentemente $u_0 \in w^+(V \setminus A)$. Analizamos las propiedades del cociclo $w(A)$:

- No puede contener arcos **rojos**: si existiera un arco rojo (i, j) con $i \in A$ y $j \notin A$, la regla del Paso 2 habría etiquetado j, contradiciendo que $j \notin A$.
- Ningún arco **negro** puede pertenecer a $w^-(A)$ (entrar a A): si existiera un arco negro (j, i) con $j \notin A$ e $i \in A$, la segunda regla habría etiquetado j.
- Ningún arco **verde** puede pertenecer a $w^+(A)$ (salir de A): si existiera un arco verde (i, j) con $i \in A$ y $j \notin A$, la segunda regla habría etiquetado j.

En consecuencia, los arcos negros en $w(A)$ son exclusivamente salientes ($w^+(A)$), los verdes son exclusivamente entrantes ($w^-(A)$) y los arcos sin color pueden tener cualquier sentido. Esto satisface la **Afirmación 2**. ■

El procedimiento constructivo anterior demuestra que las tres reglas de propagación de etiquetas garantizan siempre una dicotomía estricta. Para visualizar de forma clara cómo el algoritmo busca la cadena de antecedentes y cómo el color de cada arco determina la ruta de etiquetado o la detención del proceso, consideremos la aplicación completa del Lema sobre una red de 5 nodos en dos escenarios alternativos de coloración.

Ejemplo: Aplicación del Lema de Coloración de Minty

Considérese la red de 5 nodos $V = \{a, b, c, d, e\}$ ilustrada en la Figura 8.9, con arco negro de referencia $u_0 = (b, c)$. Se evalúan las dos coloraciones posibles para ilustrar los dos casos alternativos del lema:

1. **Caso A: Generación de un Ciclo (Gráfico Izquierdo)**
   - **Coloración asignada**: $u_0 = (b, c)$ en **negro**, (e, b) en **rojo**, $(e, c), (d, c), (d, e), (a, e)$ en **verde**, y (a, b) **sin color** (0).
   - **Propagación del etiquetado**: Se inicia etiquetando el nodo destino del arco negro, $p(c) = c$. A través del arco verde entrante (e, c), se etiqueta $p(e) = c$. A través del arco verde entrante (d, c), se etiqueta $p(d) = c$. Desde e, a través del arco rojo saliente (e, b), se etiqueta el nodo origen $p(b) = e$.
   - **Ciclo elemental resultante**: Al haber alcanzado el origen b, se reconstruye la cadena $b - e - c - b$, cerrando el ciclo $\mu = \{(e, b), (e, c), (b, c)\}$ con arcos directos $\mu^+ = \{(e, b), (b, c)\}$ y arco inverso $\mu^- = \{(e, c)\}$.
2. **Caso B: Generación de un Cociclo (Gráfico Derecho)**
   - **Coloración asignada**: $u_0 = (b, c)$ en **negro**, $(e, b), (e, c), (c, d)$ en **verde**, $(d, e), (a, b)$ en **negro**, y (a, e) **sin color** (0).
   - **Propagación del etiquetado**: Se inicia etiquetando $p(c) = c$. A través del arco verde entrante (e, c), se etiqueta $p(e) = c$. Desde e, el arco verde (e, b)

es saliente (no permite etiquetar b), el arco verde (c, d) es saliente de c (no permite etiquetar d) y los arcos negros entrantes no están activos. El proceso se detiene sin etiquetar el origen b ($p(b) = 0$).

- **Cociclo elemental resultante**: El conjunto de nodos etiquetados es $A = \{c, e\}$. El cociclo resultante $w(A)$ presenta arcos salientes $w^+(A) = \{(c, d), (e, b)\}$ y arcos entrantes $w^-(A) = \{(b, c), (d, e), (a, e)\}$.

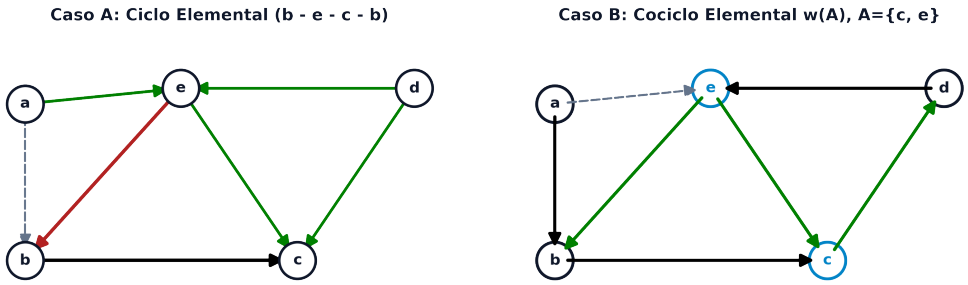

Figura 8.9: Aplicación del algoritmo de etiquetado del Lema de Minty: generación de un ciclo (izquierda) y generación de un cociclo (derecha)

Una vez obtenido el ciclo o el cociclo mediante la ejecución del algoritmo de etiquetado, resulta fundamental justificar formalmente por qué la estructura geométrica resultante carece de redundancias o lazos internos. El siguiente resultado complementario analiza la elementalidad de las soluciones obtenidas por el método de Minty.

Observación: Elementalidad de los ciclos y cociclos de Minty

En la demostración constructiva del Lema de Minty se asume que las estructuras algebraicas resultantes son elementales. Esta propiedad se justifica formalmente mediante los siguientes argumentos:

1. **Elementalidad del Ciclo**: Si la propagación de etiquetas alcanza el origen t, el ciclo resultante es **necesariamente elemental**. La regla de asignación de antecesores $p(j)$ asigna un único padre a cada nodo recién alcanzado, impidiendo que un mismo vértice sea etiquetado dos veces en la trayectoria de retorno de t a s.

2. **Elementalidad del Cociclo**: Si la propagación se detiene sin alcanzar el origen t, se obtiene la partición de vértices A (etiquetados) y $V \setminus A$ (no etiquetados). Para que el cociclo $w(A)$ sea **elemental**, los subgrafos inducidos $G[A]$ y $G[V \setminus A]$ deben ser conexos:

   - **Conexidad de** $G[A]$: Es conexo de forma trivial por la propia construcción

del algoritmo, ya que cada vértice de A se añade siguiendo arcos adyacentes conectados con el nodo inicial s.

- **Conexidad de** $G[V \setminus A]$: Supóngase por reducción al absurdo que el subgrafo $G[V \setminus A]$ no fuera conexo y estuviera descompuesto en $k \geq 2$ componentes conexas disjuntas:

$$V \setminus A = \bigcup_{h=1}^{k} B_h, \qquad B_h \cap B_{h'} = \emptyset, \ \forall h \neq h'$$

Como el vértice t no pertenece a A, debe estar contenido en una de dichas componentes (por ejemplo, $t \in B_1$). Consideremos la unión del conjunto A con el resto de componentes no conectadas con t: $A' = A \cup \bigcup_{h=2}^{k} B_h$. El cociclo $w(A')$ generado por A' satisface las mismas propiedades de restricción de color que $w(A)$ y además cumple que $(t, s) \in w^-(A') \subset w^-(A)$. Sin embargo, si $G[V \setminus A]$ no fuera conexo, se contradiría la conexidad global del digrafo inicial G, concluyendo que $G[V \setminus A]$ es conexo y por tanto el cociclo $w(A)$ es **elemental**.

8.2. El problema del flujo máximo

Un problema de flujo que surge de forma natural en la práctica es obtener la máxima cantidad de flujo que se puede mover entre dos vértices específicos de un digrafo. Es el denominado **problema del flujo máximo**.

En este problema, cada arco del digrafo posee una capacidad limitada (la cantidad máxima de caudal o flujo que puede transitar físicamente por él por unidad de tiempo). Esto nos lleva a introducir el concepto de **red de transporte**, que valora cada arco por la capacidad de flujo que puede soportar.

8.2.1. Redes de transporte y flujos compatibles

Para estudiar formalmente el problema del flujo máximo, es preciso dotar al digrafo de una estructura cuantitativa que limite el volumen de tráfico que cada conexión puede albergar.

i Definición: Red de transporte

Una **red de transporte** es un par $(G = (V, U), \mathbf{c})$, donde $G = (V, U)$ es un digrafo conexo sin bucles y $\mathbf{c} = \{c_u \mid u \in U\}$ representa el conjunto de **capacidades** superiores no negativas asociadas a cada arco $u \in U$ $(c_u \geq 0)$.

Sobre una red de transporte, un vector de flujo es aceptable solo si no excede los límites físicos de las infraestructuras de la red y satisface la conservación local.

Definición: Flujo compatible (versión preliminar)

Dada una red de transporte $(G, \mathbf{c})$, se define un **flujo compatible** como un vector $\mathbf{f} = (f_1, f_2, \dots, f_m)^T \in \mathbb{R}^m$ que satisface:

1. **Ley de conservación pura de flujo**:

$$\sum_{u \in w^+(i)} f_u - \sum_{u \in w^-(i)} f_u = 0, \quad \forall i \in V$$

2. **Compatibilidad con las capacidades**:

$$0 \leq f_u \leq c_u, \quad \forall u \in U$$

Existe una paradoja sutil al aplicar la definición de conservación pura a la transmisión de flujo entre un par de vértices fijados s (fuente) y t (sumidero). En la inmensa mayoría de redes de transporte práctico, de la fuente s solo salen arcos ($w^-(s) = \emptyset$) y al sumidero t solo llegan arcos ($w^+(t) = \emptyset$).

Si exigimos la conservación pura $\sum_{u \in w^+(i)} f_u = \sum_{u \in w^-(i)} f_u$ de forma estricta en **todos** los nodos sin excepción:

- En el nodo fuente s: como no entra ningún arco ($\sum f_{ent} = 0$), la suma de salientes debe ser cero ($\sum f_{sal} = 0$). Como $f_u \geq 0$, se fuerza a que $f_u = 0$ en todos los arcos salientes de s.
- En el nodo sumidero t: como no sale ningún arco ($\sum f_{sal} = 0$), la suma de entrantes debe ser cero ($\sum f_{ent} = 0$).

Como se ilustra en la Figura 8.10, la conservación estricta en s y t fuerza a que el **único flujo compatible posible sea el flujo trivial nulo** ($\mathbf{f} = \mathbf{0}$), impidiendo enviar cualquier caudal útil desde la fuente hasta el destino.

Para solventar este dilema matemático sin romper la estructura de espacio vectorial de las circulaciones ni tener que tratar a s y t como excepciones algorítmicas, se introduce una construcción muy elegante: el **arco ficticio de retorno** $u_0 = (t, s)$.

Conectamos el sumidero t de regreso a la fuente s mediante un arco ficticio $u_0 = (t, s)$ dotado de **capacidad ilimitada** ($c_0 = \infty$). De este modo, todo el flujo que llega a t "recircula" de vuelta a s a través de u_0, cerrando la red en una verdadera **circulación**.

Como se ilustra en la Figura 8.11, el flujo $f_0 = f_{(t,s)}$ que circula por el arco ficticio de retorno representa de forma directa el **valor del flujo total** $v(\mathbf{f})$ transmitido por la red desde s hasta t:

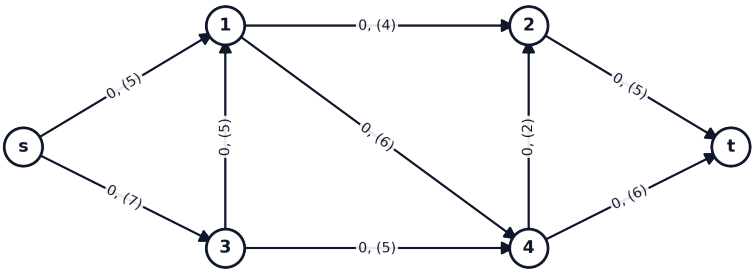

Figura 8.10: Red de transporte donde la exigencia de conservación pura en s y t fuerza el flujo nulo trivial $\mathbf{f} = \mathbf{0}$

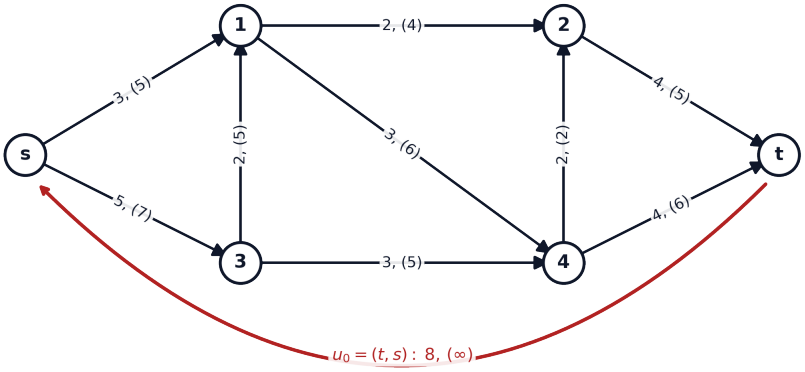

Figura 8.11: Red de transporte ampliada con el arco ficticio de retorno $u_0 = (t, s)$ llevando un valor de flujo $f_0 = 8$

$$f_0 = v(\mathbf{f}) = \sum_{j \in \Gamma^+(s)} f_{sj} = \sum_{j \in \Gamma^-(t)} f_{jt}$$

Definición formal: (s,t)-Flujo compatible

Dada una red de transporte $(G = (V,U), \mathbf{c})$ y dos vértices fijados $s, t \in V$, se define un (s,t)**-flujo compatible** como una circulación factible sobre la red ampliada $G' = (V, U \cup \{u_0 = (t,s)\})$ con $c_0 = \infty$, satisfaciendo $0 \leq f_u \leq c_u$, $\forall u \in U$.

Una vez caracterizadas las redes de transporte y los (s,t)-flujos compatibles con el arco ficticio de retorno $u_0 = (t,s)$, podemos formular de manera rigurosa el problema del flujo máximo.

Definición: Problema del flujo máximo

Dada una red de transporte $(G = (V,U), \mathbf{c})$ y fijados dos vértices $s, t \in V$ (fuente y sumidero), el **problema del flujo máximo** consiste en determinar un (s,t)-flujo compatible $\mathbf{f}^* \in \mathbb{R}^m$ tal que el valor del flujo f_0 que circula por el arco ficticio de retorno $u_0 = (t,s)$ sea máximo.
Algebraicamente, el problema se formula como:

$$\begin{aligned} \max_{\mathbf{f} \in \mathbb{R}^m} \quad & f_0 = \sum_{j \in \Gamma^+(s)} f_{sj} = \sum_{j \in \Gamma^-(t)} f_{jt} \\ \text{s.a.} \quad & \sum_{u \in w^+(i)} f_u - \sum_{u \in w^-(i)} f_u = 0, \quad \forall i \in V \\ & 0 \leq f_u \leq c_u, \quad \forall u \in U \end{aligned}$$

El **valor del flujo** f_0 representa cuantitativamente la cantidad total de caudal que sale de la fuente s y llega efectivamente al sumidero t.

Ejemplo: Evaluación de compatibilidad y saturación por capacidad

Considérese la red de transporte de 6 nodos $V = \{s, b, c, d, e, t\}$ ilustrada en la Figura 8.12, equipada con el arco de retorno ficticio $u_0 = (t,s)$ llevando un flujo circulante de $f_0 = 8$ unidades ($v(\mathbf{f}) = 8$).
Evaluamos las condiciones de compatibilidad en los arcos de la red:

1. **Flujo compatible base**: En el estado ilustrado, todos los arcos satisfacen $0 \leq f_u \leq c_u$. Por ejemplo, el arco (s,b) transita con $f_{sb} = 5 \leq c_{sb} = 5$ (arco saturado), mientras que (b,c) transita con $f_{bc} = 2 \leq c_{bc} = 3$ (no saturado).
2. **Evaluación de una modificación por ciclo**: Supóngase que intentamos incrementar el flujo enviando 2 unidades adicionales a lo largo del circuito cerrado $c \to d \to e \to c$ (destacado en **rojo teja** en la figura).

- En el arco (c, d), el flujo aumentaría de $f_{cd} = 1$ a $1 + 2 = 3$. Sin embargo, su capacidad es $c_{cd} = 1$, por lo que $3 > 1$ violando la restricción de capacidad.
- De igual modo, en (d, e) el flujo pasaría a $4 + 2 = 6 > c_{de} = 3$, e (e, c) pasaría a $2 + 2 = 4 > c_{ec} = 1$.

Conclusión: La adición de dicho ciclo destruye la compatibilidad del flujo al exceder las capacidades límite de los arcos.

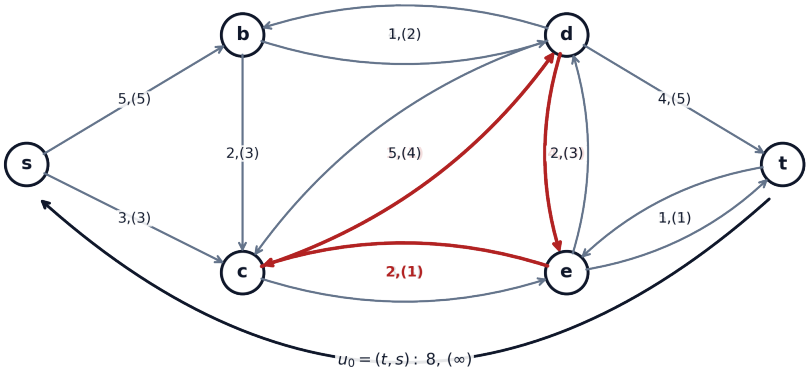

Figura 8.12: Evaluación de compatibilidad y detección de sobrecapacidad sobre la red de 6 nodos

Para comprender la gran versatilidad didáctica de las redes de transporte, analicemos dos problemas prácticos de modelización: uno proveniente de la ingeniería de tráfico urbano y otro de la optimización combinatoria de tareas.

Ejemplo: Modelización de la capacidad de tráfico urbano

La capacidad de tráfico de las calles de una ciudad se mide habitualmente por el número máximo de automóviles que pueden circular por ellas por minuto. En la red vial ilustrada en la Figura 8.13, las intersecciones se representan mediante vértices $V = \{s, a, b, t\}$ y las calles dirigidas mediante arcos con capacidades entre paréntesis c_u:

- $c_{sa} = 100$, $c_{sb} = 100$, $c_{ab} = 50$, $c_{at} = 75$, $c_{bt} = 100$.

Se desea determinar la cantidad máxima de automóviles por minuto que pueden transitar desde la zona de entrada s hasta la zona de salida t.

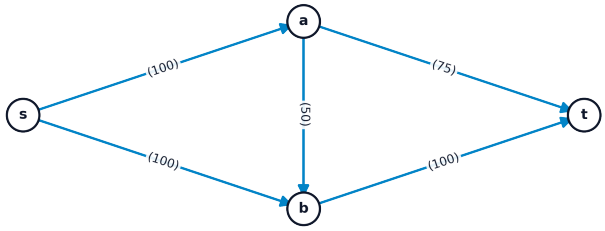

Figura 8.13: Red de tráfico urbano con capacidades de vehículos por minuto en los arcos

Analizando la red, aunque la fuente s puede inyectar hasta $100 + 100 = 200$ vehículos/minuto hacia a y b, las calles que llegan al sumidero t restringen el cuello de botella: desde a solo pueden llegar a t como máximo 75 vehículos/min, y desde b hasta 100 vehículos/min. El valor del flujo máximo resulta ser $v(\mathbf{f}^*) = 175$ vehículos/min.

Además de sistemas de transporte físico, el problema del flujo máximo permite resolver de forma elegante problemas de optimización combinatoria y asignación de personal.

Ejemplo: Asignación óptima de tareas a empleados (Emparejamiento Bipartito)

En una oficina hay tres empleados (E_1, E_2, E_3) y tres tareas (T_1, T_2, T_3). Cada tarea requiere unos conocimientos específicos que no todos los empleados poseen. Las compatibilidades se representan en el digrafo bipartito de la Figura 8.14 (izquierda):

- E_1 es compatible con T_1, T_2.
- E_2 es compatible con T_1, T_3.
- E_3 es compatible con T_1, T_3.

Se desea determinar cómo asignar las tareas a los empleados para tratar de realizarlas todas (asignación uno a uno).

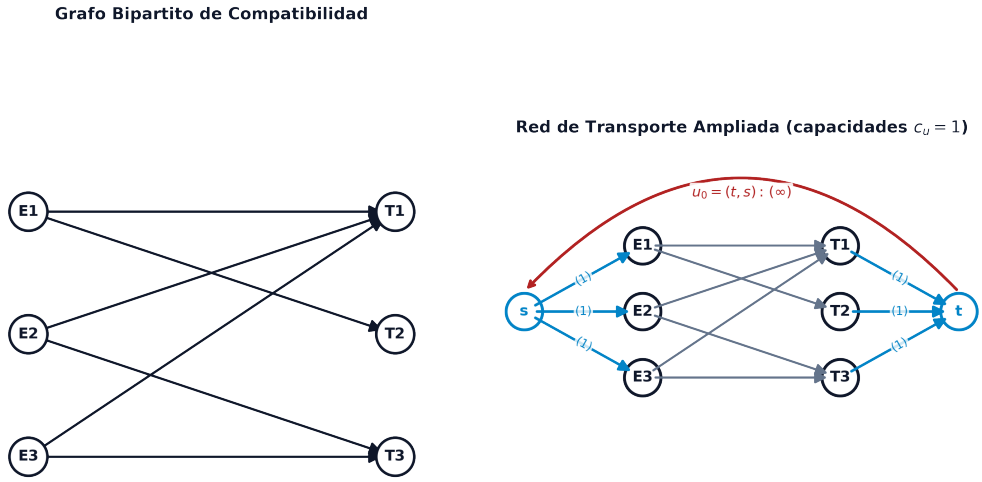

Figura 8.14: Transformación de un problema de asignación bipartita de tareas (izquierda) a una red de transporte de flujo máximo con arco ficticio de retorno $u_0 = (t, s)$ (derecha)

Modelización como problema de flujo máximo: Para reducir este problema a una red de transporte (derecha):

1. Añadimos un nodo fuente ficticio s conectado a cada empleado E_i mediante un arco (s, E_i) con capacidad $c_{sE_i} = 1$ (cada empleado puede realizar como máximo 1 tarea).
2. Asignamos capacidad unitaria $c_{E_iT_j} = 1$ a todos los arcos de compatibilidad entre empleados y tareas.
3. Añadimos un nodo sumidero ficticio t conectado desde cada tarea T_j mediante un arco (T_j, t) con capacidad $c_{T_jt} = 1$ (cada tarea requiere exactamente 1 empleado).
4. Añadimos el arco ficticio de retorno $u_0 = (t, s)$ con capacidad ilimitada ($c_0 = \infty$).

Resolver el flujo máximo de s a t sobre esta red equivale a hallar el número máximo de tareas realizables simultáneamente.

Una vez formalizada la red de transporte e ilustrada su versatilidad, el esquema general para resolver cualquier problema de flujo máximo se fundamenta en un procedimiento iterativo de aumento progresivo:

1. **Flujo Inicial**: Comenzar con un flujo compatible válido $\mathbf{f}^0$ sobre la red (típicamente el flujo trivial nulo $\mathbf{f}^0 = \mathbf{0}$).
2. **Búsqueda de Aumento**: Buscar un nuevo flujo compatible $\mathbf{f}^{k+1}$ que incremente el valor circulante por el arco de retorno f_0.

3. **Iteración y Criterio de Parada**: Repetir el procedimiento a partir del nuevo flujo hasta que no sea posible realizar ningún incremento adicional.

La justificación matemática de este esquema radica en la estructura algebraica del espacio de flujos: dado que todo flujo se puede expresar como combinación lineal de ciclos, la diferencia entre dos soluciones cualesquiera $\mathbf{f}^2 - \mathbf{f}^1$ es siempre una **combinación lineal de ciclos**. Por tanto, para elevar el caudal de la fuente s al sumidero t, el algoritmo analiza si existe en la red un ciclo que incluya al arco ficticio de retorno $u_0 = (t, s)$ y admita un incremento de al menos una unidad de flujo. Esta búsqueda equivale a encontrar una trayectoria no saturada en sentido directo desde s hasta t, denominada **cadena incremental**.

i Definición: Cadena incremental y ciclo incremental

Dado un flujo compatible $\mathbf{f}$ en la red de transporte $(G = (V, U), \mathbf{c})$, una cadena $\mu[a, b]$ entre dos vértices a y b es una **cadena incremental** (o camino aumentante) si satisface:

$$f_u < c_u, \quad \forall u \in \mu^+ \qquad \text{y} \qquad f_u > 0, \quad \forall u \in \mu^-$$

donde μ^+ representa el conjunto de arcos de la cadena recorridos en sentido directo (de a hacia b) y μ^- representa los arcos recorridos en sentido inverso.
Un **ciclo incremental** es una cadena incremental cerrada. En el problema del flujo máximo, el objetivo es incrementar el flujo transportado por el arco de retorno $u_0 = (t, s)$, por lo que se busca sistemáticamente una cadena incremental entre la fuente s y el sumidero t.

i Definición: Capacidad residual de una cadena

La **capacidad residual** $c(\mu)$ (o cuello de botella) de una cadena incremental $\mu[s, t]$ es la máxima cantidad de flujo adicional que se puede enviar desde s hasta t a través de μ:

$$c(\mu) = \min \left\{ \min_{u \in \mu^+} (c_u - f_u), \ \min_{u \in \mu^-} f_u \right\}$$

Si se incrementa el flujo en $c(\mu)$ unidades en los arcos directos $u \in \mu^+$ y se reduce en $c(\mu)$ unidades en los arcos inversos $u \in \mu^-$, el valor total del flujo f_0 aumenta exactamente en $c(\mu)$ unidades manteniendo la compatibilidad estricta.

8.2.2. Flujo máximo en grafos no dirigidos

En el caso de redes construidas sobre un grafo no dirigido $G = (V, E)$, el problema de flujo no queda bien definido de forma directa sobre las aristas. La capacidad c_e de una arista no dirigida $e = \{a, b\} \in E$ puede ser saturada en el sentido de tránsito (a, b) o en el sentido contrario (b, a).

Para evitar enviar flujo en los dos sentidos simultáneamente de modo que se verifique $f_{(a,b)} + f_{(b,a)} \leq c_e$ siendo ambos flujos positivos, es necesario transformar el grafo original en un digrafo equivalente de forma que se impida el flujo en sentido inverso sobre una misma arista.

Definición: Transformación de aristas no dirigidas (Gadget de 5 arcos)

Cada arista no dirigida $e = \{a, b\} \in E$ con capacidad $c_e = c$ se sustituye por un conjunto de **cinco arcos dirigidos** que conectan los vértices originales a y b con dos nuevos vértices auxiliares a' y b', asignando capacidad c a todos ellos:

$$U_e = \{(a, a'),\ (b, a'),\ (a', b'),\ (b', a),\ (b', b)\}$$

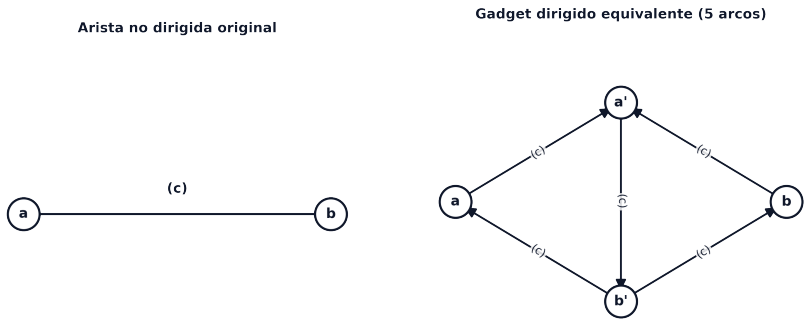

Figura 8.15: Transformación de una arista no dirigida $\{a, b\}$ de capacidad c (izquierda) en un gadget dirigido equivalente de 5 arcos y 2 nodos auxiliares a', b' (derecha)

Como se ilustra en la Figura 8.15, esta construcción garantiza la equivalencia física y matemática:

- **Tránsito de a hacia b**: El flujo sigue el camino $a \to a' \to b' \to b$, quedando limitado por la capacidad c del arco central (a', b').
- **Tránsito de b hacia a**: El flujo sigue el camino $b \to a' \to b' \to a$, atravesando exactamente el mismo arco central (a', b').

Dado que ambas direcciones deben atravesar de forma obligatoria el arco central dirigido (a', b'), se satisface de forma automática la restricción global $f_{(a,b)} + f_{(b,a)} \leq c$, impidiendo la circulación simultánea en ambos sentidos y manteniendo la compatibilidad estricta.

8.2.3. Flujo máximo y corte mínimo

La búsqueda de la cantidad máxima de caudal que puede transitar desde la fuente s hasta el sumidero t conduce de forma natural al estudio de los cuellos de botella topológicos que restringen la red. La capacidad global de transmisión no está determinada únicamente por las

conexiones individuales, sino por barreras o particiones completas que separan físicamente el origen del destino.

Definición: (s,t)-Corte

Dada la red de transporte $(G=(V,U),\mathbf{c})$, un **corte que separa s y t** o **(s,t)-corte** es un conjunto de arcos salientes $w^+(N)$ asociado a un subconjunto de vértices $N \subset V$ tal que $s \in N$ y $t \notin N$.

Para evaluar cuantitativamente el cuello de botella que representa una partición N, es preciso sumar la capacidad máxima de todas las conducciones que abandonan el conjunto N hacia su complemento $V \setminus N$.

Definición: Capacidad de un corte

Dada la red de transporte $(G=(V,U),\mathbf{c})$, se define la **capacidad de un (s,t)-corte** como la suma de las capacidades de los arcos que lo componen:

$$c(w^+(N)) = \sum_{u \in w^+(N)} c_u$$

De todas las posibles particiones que separan la fuente del sumidero, aquellas que imponen la restricción más severa constituyen los cuellos de botella verdaderamente críticos de la infraestructura.

Definición: Problema de corte de mínima capacidad

El **problema de corte de mínima capacidad** trata de determinar en una red de transporte el (s,t)-corte cuya capacidad sea mínima:

$$\min_{\substack{N \subset V \\ s \in N,\, t \notin N}} c(w^+(N)) = \sum_{u \in w^+(N)} c_u$$

Existe una relación dual fundamental entre el flujo f_0 que circula por la red y la capacidad de cualquier (s,t)-corte. El siguiente resultado establece que ningún flujo puede superar la capacidad de la barrera más estrecha que deba atravesar.

Proposición: Acotación del flujo por la capacidad del corte

Dada una red de transporte $(G=(V,U),\mathbf{c})$ y fijados los vértices $s,t \in V$, para cualquier (s,t)-flujo compatible $\mathbf{f}$ se verifica que su valor de flujo f_0 está acotado por la capacidad de cualquier (s,t)-corte. Es decir:

$$f_0 \leq \sum_{u \in w^+(N)} c_u, \qquad \forall N \subset V \text{ tal que } s \in N,\, t \notin N$$

Demostración: Sea $N \subset V$ tal que $s \in N$ y $t \notin N$. Sea $\mathbf{f} = (f_0, f_1, \ldots, f_m)$ un flujo compatible en la red ampliada con el arco ficticio de retorno $u_0 = (t, s)$.
Por la ley de conservación de flujo en los nodos del conjunto N, la suma de los flujos que entran en N es igual a la suma de los flujos que salen de N:

$$f_0 + \sum_{\substack{(i,j) \in w^-(N) \\ (i,j) \neq (t,s)}} f_{ij} = \sum_{(i,j) \in w^+(N)} f_{ij}$$

Reordenando términos para aislar el valor del flujo circulante f_0:

$$f_0 = \sum_{(i,j) \in w^+(N)} f_{ij} - \sum_{\substack{(i,j) \in w^-(N) \\ (i,j) \neq (t,s)}} f_{ij}$$

Como $0 \leq f_{ij} \leq c_{ij}$, $\forall (i,j) \in U$, acotamos los dos sumandos: la suma de flujos entrantes es no negativa ($\sum f_{ij} \geq 0$) y la suma de flujos salientes no puede superar sus capacidades limitadas ($\sum f_{ij} \leq \sum c_{ij}$). Por consiguiente:

$$f_0 \leq \sum_{(i,j) \in w^+(N)} c_{ij} = c(w^+(N))$$

Esta cota es válida para cualquier partición $N \subset V$ con $s \in N, t \notin N$ y para cada flujo $\mathbf{f}$ compatible con las capacidades. En particular, se verifica también para el flujo que maximiza f_0, estableciendo que el flujo máximo está acotado por el corte de capacidad mínima:

$$\text{máx}\, f_0 \leq \min_{\substack{N \subset V \\ s \in N,\, t \notin N}} \left\{ \sum_{(i,j) \in w^+(N)} c_{ij} \right\} \quad \blacksquare$$

Ejemplo: Evaluación de cortes, capacidades y criterio de optimalidad

Considérese la red de transporte de 6 nodos $V = \{s, b, c, d, e, t\}$ ilustrada en la Figura 8.16, equipada con las capacidades entre paréntesis c_u y transitando con un (s,t)-flujo compatible de valor $f_0 = 8$.
Evaluamos tres cortes representativos $w^+(N)$ que separan la fuente s del sumidero t:

1. **Corte 1 ($N_1 = \{s\}$)** (línea discontinua **roja teja**):
   - Arcos salientes: $w^+(N_1) = \{(s,b), (s,c)\}$.
   - Capacidad del corte: $c(w^+(N_1)) = c_{sb} + c_{sc} = 5 + 3 = 8$.
2. **Corte 2 ($N_2 = \{s, b, c\}$)** (línea discontinua **azul cerúleo**):

- Arcos salientes: $w^+(N_2) = \{(b,d),(c,d),(c,e)\}$.
- Capacidad del corte: $c(w^+(N_2)) = c_{bd} + c_{cd} + c_{ce} = 4 + 4 + 3 = 11$.

3. **Corte 3 ($N_3 = \{s,b,c,d,e\}$)** (línea discontinua **magenta**):

   - Arcos salientes: $w^+(N_3) = \{(d,t),(e,t)\}$.
   - Capacidad del corte: $c(w^+(N_3)) = c_{dt} + c_{et} = 5 + 5 = 10$.

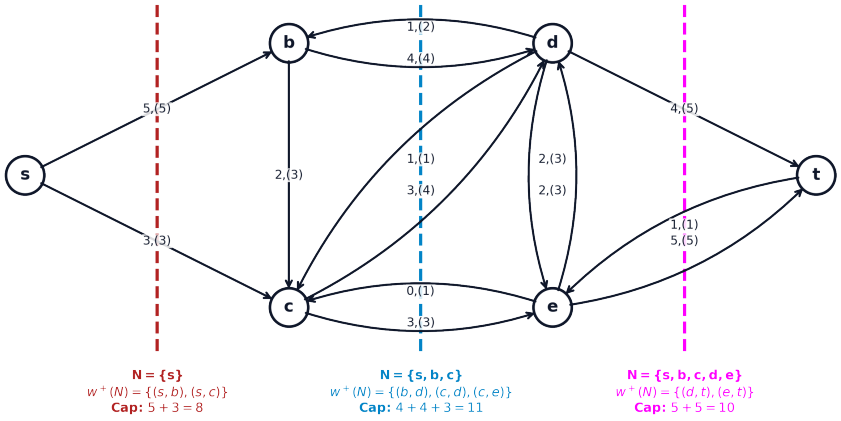

Figura 8.16: Evaluación de cortes y capacidades en una red de 6 nodos

Criterio de Optimalidad: La capacidad del corte rojo $w^+(N_1)$ es $c(w^+(N_1)) = 8$ y el valor del flujo que transita de s a t es $f_0 = 8$.
Dado que el valor del flujo alcanza exactamente la capacidad del corte ($f_0 = c(w^+(N_1)) = 8$), por la Proposición de Acotación, este flujo **f** es una **solución óptima al problema del flujo máximo** y el corte $w^+(N_1)$ es un **corte de capacidad mínima**.

Como consecuencia inmediata de esta cota superior, si se encuentra una pareja formada por un flujo compatible y un (s,t)-corte cuyas magnitudes numéricas coincidan, queda garantizada de forma simultánea la optimalidad global de ambos elementos.

i Corolario: Criterio de optimalidad de flujo máximo y corte mínimo

Si un flujo compatible **f** y un (s,t)-corte $w^+(N)$ que separe s de t son tales que el valor del flujo es igual a la capacidad del corte ($f_0 = c(w^+(N))$), entonces **f** es el **flujo máximo** de s a t y $w^+(N)$ es el **corte de mínima capacidad** que separa s de t.
Demostración: La demostración es trivial. Dado que por la proposición previa se verifica

$f'_0 \leq c(w^+(N'))$ para cualquier flujo compatible $\mathbf{f}'$ y cualquier corte N', si $f_0 = c(w^+(N))$, ningún otro flujo compatible $\mathbf{f}'$ puede tener un valor superior a $c(w^+(N)) = f_0$, de lo que se deduce que $\mathbf{f}$ es óptimo. De forma análoga, ningún otro corte N' puede tener una capacidad inferior a $f_0 = c(w^+(N))$, por lo que $w^+(N)$ es un corte de capacidad mínima. ■

Además de caracterizar la optimalidad mediante la coincidencia entre el flujo y el corte, resulta fundamental determinar las condiciones estructurales bajo las cuales el problema del flujo máximo admite una solución finita o, por el contrario, su valor óptimo diverge a infinito.

i Corolario: Existencia y acotación de solución del problema de flujo máximo

El problema del flujo máximo de s a t tiene solución finita si y sólo si no existe un camino orientado de s a t, denotado por $\mu[s,t]$, con capacidad infinita en todos sus arcos ($c_u = \infty$, $\forall u \in \mu$).
Demostración:

- Implicación directa ($\Longrightarrow$): La demostración es trivial. Si existiera un camino $\mu[s,t]$ formado íntegramente por arcos de capacidad infinita, se podría enviar una cantidad arbitrariamente grande de caudal a través de él sin violar ninguna restricción de capacidad, haciendo que el valor del flujo $f_0 \to \infty$ y el problema no posea solución finita.

- Implicación contraria ($\Longleftarrow$): Supóngase que no existe ningún camino orientado desde s hasta t compuesto únicamente por arcos de capacidad infinita. Consideremos el grafo parcial $G' = (V, U_\infty)$ formado por todos los vértices V y el subconjunto de arcos de capacidad infinita $U_\infty = \{u \in U \mid c_u = \infty\}$. Por hipótesis, en G' no existe ningún camino desde s hasta t. Definimos $N \subset V$ como el conjunto de vértices alcanzables desde la fuente s mediante caminos orientados en el grafo parcial G'. Por construcción de N:

  1. La fuente pertenece al conjunto ($s \in N$).
  2. El sumidero no pertenece al conjunto ($t \notin N$), pues si $t \in N$ existiría un camino de capacidad infinita de s a t en G'.

  Consecuentemente, el conjunto de arcos salientes $w^+(N)$ constituye un (s,t)-corte válido. Dado que ningún arco de $w^+(N)$ puede pertenecer a U_∞ (de lo contrario, sus nodos de destino habrían sido alcanzados en G' e incluidos en N), todos los arcos que integran el corte $w^+(N)$ poseen **capacidad finita** ($c_u < \infty$). Por tanto, la capacidad del corte $c(w^+(N)) = \sum_{u \in w^+(N)} c_u$ es finita, lo que garantiza por la Proposición de Acotación ($f_0 \leq c(w^+(N)) < \infty$) que el problema del flujo máximo posee solución finita. ■

Los resultados anteriores relacionan fuertemente el flujo máximo y la capacidad de un corte.

El siguiente teorema fortalece estas relaciones estableciendo la coincidencia exacta entre el (s,t)-flujo máximo y el (s,t)-corte de capacidad mínima.

! Teorema: Flujo máximo - corte mínimo (Ford-Fulkerson, 1956)

Dada una red de transporte $(G=(V,U),\mathbf{c})$ y fijados dos vértices $s,t\in V$, el (s,t)-flujo máximo coincide exactamente con la mínima capacidad de los (s,t)-cortes:

$$\max_{\mathbf{f}} f_0 = \min_{\substack{N\subset V\\ s\in N,\, t\notin N}} c(w^+(N))$$

Demostración: Sea $\mathbf{f}=(f_0,f_1,\dots,f_m)$ una solución óptima del problema del flujo máximo de s a t. Se considera la red ampliada equipada con el arco de retorno ficticio $u_0=(t,s)$. Para aplicar la dicotomía de Minty, se utiliza la siguiente regla para colorear los arcos de la red:

- **Arco de retorno** $u_0=(t,s)$: **Negro** (N).
- Arco $u\in U$ con $f_u=0, c_u=0$: **Sin colorear** (0) (no admite incremento ni reducción).
- Arco $u\in U$ con $f_u=0<c_u$: **Negro** (N) (solo se puede incrementar el flujo).
- Arco $u\in U$ con $0<f_u=c_u$: **Verde** (V) (solo se puede reducir el flujo).
- Arco $u\in U$ con $0<f_u<c_u$: **Rojo** (R) (se puede aumentar y reducir el flujo).

Es decir, en los arcos negros solo se puede incrementar el flujo, en los verdes reducir, y en los rojos aumentar y reducir. En los no coloreados no se puede incrementar ni reducir.
A continuación, se inicia un proceso de marcado (o etiquetado) de vértices:

1. Sea $S\subset V$ el conjunto de vértices marcados. Inicialmente $S=\{s\}$.
2. El resto de vértices se marcan en función de los arcos que inciden en ellos. Para cada arco $(i,j)\in U$:
   - Si i está marcado $(i\in S)$, j no está marcado $(j\notin S)$ y el arco (i,j) es **negro** o **rojo**: marcar j.
   - Si j está marcado $(j\in S)$, i no está marcado $(i\notin S)$ y el arco (i,j) es **verde** o **rojo**: marcar i.
3. Repetir el proceso iterativamente hasta marcar el máximo número posible de vértices.

Al finalizar la propagación de marcas, se analizan los dos casos posibles:

- **Si al final el vértice sumidero** t **resultara marcado** $(t\in S)$: El arco de retorno (t,s) pertenecería a un ciclo elemental coloreado $N/V/R$. Reconstruyendo la trayectoria de antecedentes, este ciclo definiría una cadena incremental $\mu[s,t]$ a lo largo de la cual se podrían añadir $\epsilon>0$ unidades de flujo, incrementando el valor del flujo de retorno a $f_0+\epsilon$. Pero dado que $\mathbf{f}$ es una solución óptima y f_0 es máximo, este ciclo **no puede existir**.

- **Por tanto, el vértice sumidero t no resulta marcado ($t \notin S$)**: Por el Lema de Coloración de Minty, el arco negro de retorno (t, s) pertenece necesariamente al **cociclo elemental** $w(S)$ asociado a los vértices marcados $S = N$. Como $s \in N$ y $t \notin N$, este cociclo define un (s, t)-corte válido.

La capacidad de este corte viene determinada exclusivamente por los arcos que lo componen. Por las reglas de marcado:

- Los arcos salientes del corte $w^+(N)$ son exclusivamente verdes (están a **capacidad máxima**, $f_u = c_u$), pues si alguno fuera negro o rojo habría permitido marcar su nodo de destino en el paso anterior.
- Los arcos entrantes del corte $w^-(N)$ (distintos de u_0) son exclusivamente negros (tienen **flujo nulo**, $f_u = 0$), pues si alguno fuera verde o rojo habría permitido marcar su nodo de origen.

Aplicando la ley de conservación de flujo sobre el subconjunto de nodos marcados N:

$$\sum_{u \in w^+(N)} f_u - \sum_{\substack{u \in w^-(N) \\ u \neq (t,s)}} f_u = f_0$$

Dado que los arcos salientes se encuentran a máxima capacidad ($f_u = c_u$) y los entrantes a flujo nulo ($f_u = 0$), se concluye:

$$c(w^+(N)) = \sum_{u \in w^+(N)} c_u = \sum_{u \in w^+(N)} f_u = f_0 \quad \blacksquare$$

La relación entre el valor del flujo máximo y el corte de capacidad mínima no queda limitada a una coincidencia numérica puntual. Los problemas de encontrar el flujo máximo que puede circular por una red y el corte de mínima capacidad son **problemas duales** entre sí dentro del marco de la Programación Lineal.

Ejemplo: Aplicación de las reglas de coloración de Minty en el flujo óptimo

Considérese la red de 6 nodos $V = \{s, 1, 2, 3, 4, t\}$ equipada con el arco de retorno $u_0 = (t, s)$ y un flujo circulante de valor $f_0 = 10$, ilustrada en la Figura 8.17.

1. **Coloración de arcos según el flujo actual**:
   - Arco de retorno $u_0 = (t, s)$ con $f_0 = 10, c_0 = \infty$: **Negro** (admite aumento).
   - Arco $(3, 1)$ con $f_{31} = 0, c_{31} = 5$: **Negro** ($0 = f_{31} < c_{31}$).
   - Arcos a capacidad máxima: $(1, 2)$ con $4, (4)$, $(1, 4)$ con $1, (1)$, $(3, 4)$ con $5, (5)$, y $(4, 2)$ con $2, (2)$: **Verdes** ($0 < f_u = c_u$).
   - Arcos a capacidad intermedia: $(s, 1)$ con $5, (6)$, $(s, 3)$ with $5, (7)$, $(2, t)$ con

$6, (7)$, y $(4, t)$ con $4, (6)$: **Rojos** $(0 < f_u < c_u)$.

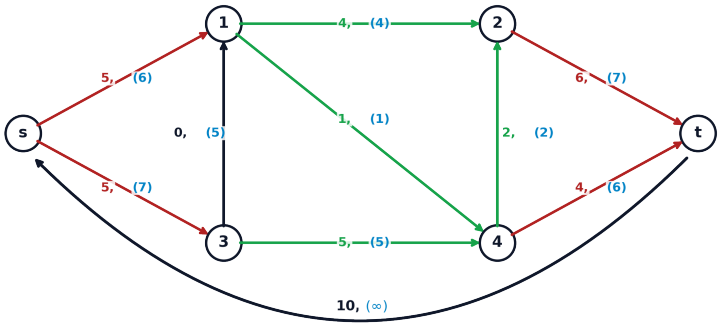

Figura 8.17: Aplicación de la regla de coloración de Minty sobre una red de transporte en flujo óptimo de valor $f_0 = 10$

2. **Evaluación de la propagación del marcado de vértices**:
   - Iniciamos marcando el origen: $S = \{s\}$.
   - Desde s, a través de los arcos rojos $(s, 1)$ y $(s, 3)$, marcamos los nodos 1 y 3: $S = \{s, 1, 3\}$.
   - Desde los nodos marcados 1 y 3, los arcos salientes $(1, 2)$, $(1, 4)$ y $(3, 4)$ son verdes (no permiten marcar 2 ni 4), y los arcos entrantes a 1 y 3 son negros (no permiten marcar nodos adicionales). El marcado finaliza con $S = \{s, 1, 3\}$.
   - Dado que el sumidero $t \notin S$, el proceso no encuentra ningún camino incremental a t. El conjunto de nodos marcados $N = \{s, 1, 3\}$ define un (s, t)-corte cuyos arcos salientes $w^+(N) = \{(1, 2), (1, 4), (3, 4)\}$ son todos verdes y suman capacidad $C(w^+(N)) = 4 + 1 + 5 = 10 = f_0$, verificando la optimalidad.
3. **Análisis de sensibilidad ante modificaciones de capacidad**: Si la capacidad del arco $(1, 4)$ se eleva a $c_{14} = 6$ mientras el flujo se mantiene en $f_{14} = 1$ (como se ilustra en la Figura 8.18), el arco $(1, 4)$ pasa de verde a **rojo** $(0 < 1 < 6)$. Al ser rojo, la propagación desde el nodo marcado 1 permite marcar el nodo 4, y desde 4, el arco rojo $(4, t)$ permite marcar finalmente el sumidero t. Alcanzar el nodo t indica que el flujo $f_0 = 10$ ya no es óptimo y permite enviar flujo adicional a través de la cadena incremental $s \to 1 \to 4 \to t$.

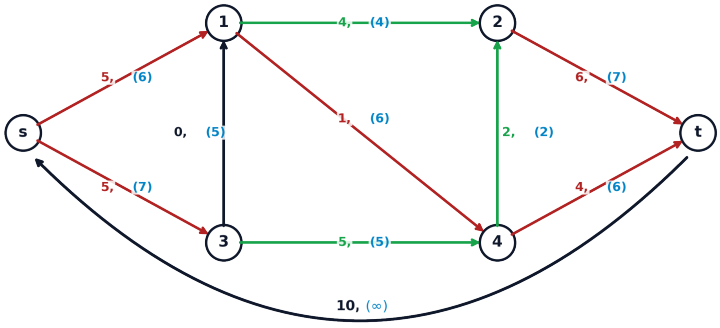

Figura 8.18: Evaluación del marcado de vértices cuando una modificación de capacidad convierte un arco en rojo y habilita el marcado del sumidero t

8.2.4. Algoritmo de Ford-Fulkerson

El **algoritmo de Ford-Fulkerson**, publicado en 1956 por L. R. Ford (1927-2017) y D. R. Fulkerson (1924-1976), es el método clásico fundamental de la teoría de flujos. Se conoce también como **algoritmo del camino de aumento**, ya que su idea principal consiste en aumentar progresivamente el caudal de los flujos a lo largo de caminos orientados desde la fuente s hasta el sumidero t.

Aplicando la regla de coloración de arcos vista en la demostración del Teorema de Ford-Fulkerson y etiquetando/marcando arcos según el Lema de Minty, es posible determinar de forma directa si un flujo es óptimo o no. Además, en caso de que no sea óptimo, este procedimiento identifica explícitamente un ciclo o camino por el que es posible incrementar el flujo circulante.

i Definición: Grafo incremental (Red residual)

Planteado un problema de flujo máximo de s a t en la red de transporte $(G = (V, U), \mathbf{c})$ y dado un flujo compatible $\mathbf{f}$, se define el **grafo incremental** (o **red residual**) $G(\mathbf{f}) = (V, U(\mathbf{f}))$ como el digrafo en el que el conjunto de arcos $U(\mathbf{f})$ se construye para todo $u = (i, j) \in U$ según:

$$\begin{cases} u^+ = (i,j) \in U(\mathbf{f}) \text{ con peso } \ell_{u^+} = c_u - f_u, & \text{si } f_u < c_u \\ u^- = (j,i) \in U(\mathbf{f}) \text{ con peso } \ell_{u^-} = f_u, & \text{si } f_u > 0 \end{cases}$$

- **Arcos directos** u^+: Se añade un arco al grafo incremental en el mismo sentido que el arco de la red cuando el flujo del arco en la red se puede incrementar ($f_u < c_u$). Se le asocia un peso $\ell_{u^+} = c_u - f_u$.

- **Arcos inversos** u^-: Se añade un arco al grafo incremental en sentido contrario al del arco de la red cuando el flujo del arco en la red se puede reducir ($f_u > 0$). Se le asocia un peso $\ell_{u^-} = f_u$.

Propiedades:

1. Estas operaciones no son excluyentes: si un arco satisface $0 < f_u < c_u$, genera tanto un arco directo u^+ como un arco inverso u^- en $G(\mathbf{f})$.
2. El arco ficticio de retorno $u_0 = (t, s)$ **no se incluye** en el grafo incremental.
3. A cada arco de $U(\mathbf{f})$ se le asocia una cantidad ℓ_u que representa el flujo máximo que admite el arco en cuestión.

Ejemplo: Construcción del grafo incremental asociado a una red de transporte

Considérese la red de transporte de 6 nodos $V = \{s, 2, 3, 4, 5, t\}$ ilustrada en la Figura 8.19 (izquierda), equipada con un flujo compatible $\mathbf{f}$ de valor $f_0 = 3$.
Para construir su correspondiente grafo incremental $G(\mathbf{f})$ (derecha):

- Por cada arco con $f_u < c_u$ (por ejemplo, $(s, 2)$ con $f = 1, c = 3$), añadimos el arco directo $(s, 2)$ con peso $\ell = 3 - 1 = 2$.
- Por cada arco con $f_u > 0$ (por ejemplo, $(s, 2)$ con $f = 1$), añadimos el arco inverso $(2, s)$ con peso $\ell = 1$.
- Los arcos a capacidad máxima ($f_u = c_u$, como $(s, 3)$ con $2, (2)$) solo generan arco inverso $(3, s)$ con peso $\ell = 2$.
- Los arcos con flujo nulo ($f_u = 0$, como $(3, 2)$ con $0, (1)$) solo generan arco directo $(3, 2)$ con peso $\ell = 1$.

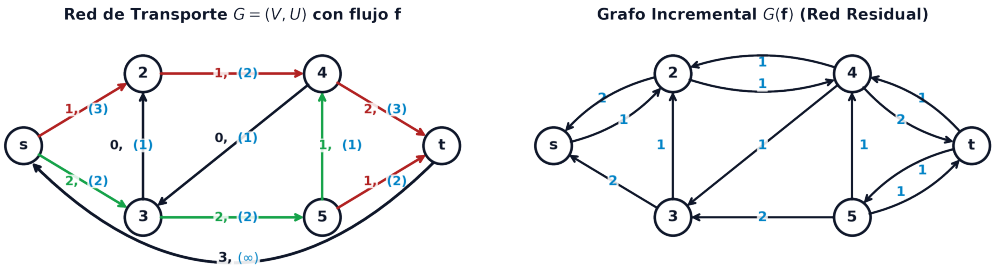

Figura 8.19: Transformación de una red de transporte con flujo $\mathbf{f}$ (izquierda) a su correspondiente grafo incremental $G(\mathbf{f})$ con pesos residuales ℓ_u (derecha)

La clave del algoritmo radica en que un flujo compatible $\mathbf{f}$ admite un incremento en su valor f_0 **si y sólo si existe un camino orientado** $\mu[s, t]$ **desde la fuente** s **hasta el sumidero** t

en el grafo incremental $G(\mathbf{f})$.

El procedimiento sistemático para resolver cualquier problema de flujo máximo mediante la red residual se resume en la siguiente especificación paso a paso:

Esquema: Algoritmo de Ford-Fulkerson por Red Incremental

- **Paso 1 (Inicialización)**: Hacer $k = 0$. Determinar un flujo inicial compatible $\mathbf{f}^0 = (f_0^0, f_1^0, \dots, f_m^0)^T$ (típicamente el flujo trivial nulo $\mathbf{f}^0 = \mathbf{0}$).
- **Paso 2 (Construcción y Búsqueda)**: Definir la red incremental $G(\mathbf{f}^k) = (V, U(\mathbf{f}^k))$. Buscar un camino orientado μ^k desde s hasta t en $G(\mathbf{f}^k)$.
  - **Si no existe el camino**: **PARAR**. El flujo actual $\mathbf{f}^k$ es **óptimo** (y el conjunto de nodos alcanzables desde s en $G(\mathbf{f}^k)$ define el **corte de capacidad mínima**).
  - **En caso contrario**: Ir al Paso 3.
- **Paso 3 (Aumento de Flujo y Actualización)**: Calcular la capacidad del cuello de botella en la cadena incremental:

$$\epsilon^k = \min\{\ell_u \mid u \in \mu^k,\, u \in U(\mathbf{f}^k)\}$$

Para cada arco $u \in U$ de la red de transporte original:

$$f_u^{k+1} = \begin{cases} f_u^k + \epsilon^k, & \text{si } u \in \mu^k(+) \text{ (arco directo en la red)} \\ f_u^k - \epsilon^k, & \text{si } u \in \mu^k(-) \text{ (arco inverso en la red)} \\ f_u^k, & \text{si } u \notin \mu^k(+) \cup \mu^k(-) \text{ y } u \neq (t,s) \end{cases}$$

E incrementar el valor del flujo circulante por el arco ficticio de retorno $u_0 = (t, s)$:

$$f_0^{k+1} = f_0^k + \epsilon^k$$

Hacer $k \leftarrow k + 1$ y regresar al Paso 2.

Ejemplo: Resolución completa paso a paso del Algoritmo de Ford-Fulkerson desde flujo nulo

Considérese la red de 6 nodos $V = \{s, 2, 3, 4, 5, t\}$ con fuente s, sumidero t y capacidades de arcos asociadas:

$$c_{s2} = 3, \quad c_{s3} = 2, \quad c_{32} = 1, \quad c_{24} = 2, \quad c_{43} = 1, \quad c_{35} = 2, \quad c_{54} = 1, \quad c_{4t} = 3, \quad c_{5t} = 2$$

Se aplica el algoritmo de Ford-Fulkerson por red incremental partiendo del flujo trivial nulo $\mathbf{f}^0 = \mathbf{0}$. La traza completa de la resolución mediante la red residual y el flujo resultante se

ilustra paso a paso en la **?@fig-ford-fulkerson-completo-animado**:
Iteración 1 ($k = 0$):

- **Paso 1 (Inicialización)**: Flujos iniciales $f_u^0 = 0$ para todo arco $u \in U$, con caudal de retorno $f_0^0 = 0$.
- **Paso 2 (Red Incremental $G(\mathbf{f}^0)$)**: Como todos los flujos son nulos, la red residual contiene únicamente los arcos directos u^+ con capacidades residuales $\ell_{u^+} = c_u$.
- **Búsqueda de Camino Aumentante**: Se detecta la trayectoria orientada $\mu_1 = (s \to 2 \to 4 \to t)$.
- **Cálculo del Cuello de Botella**:

$$\epsilon_1 = \text{mín}\{\ell_{s2}, \ell_{24}, \ell_{4t}\} = \text{mín}\{3, 2, 3\} = 2$$

- **Paso 3 (Actualización de Flujos $\mathbf{f}^1$)**:
  - $f_{s2}^1 = 0 + 2 = 2$
  - $f_{24}^1 = 0 + 2 = 2$ (el arco $(2, 4)$ queda **saturado**, pasando a verde)
  - $f_{4t}^1 = 0 + 2 = 2$
  - Caudal circulante de retorno: $f_0^1 = 0 + 2 = 2$.

Iteración 2 ($k = 1$):

- **Paso 2 (Red Incremental $G(\mathbf{f}^1)$)**:
  - Al estar saturado el arco $(2, 4)$, en $G(\mathbf{f}^1)$ solo existe el arco inverso $(4, 2)$ con peso $\ell = 2$.
  - El arco $(s, 2)$ admite incremento $\ell = 3 - 2 = 1$ e inverso $(2, s)$ con peso $\ell = 2$.
- **Búsqueda de Camino Aumentante**: Se detecta la trayectoria orientada $\mu_2 = (s \to 3 \to 5 \to t)$.
- **Cálculo del Cuello de Botella**:

$$\epsilon_2 = \text{mín}\{\ell_{s3}, \ell_{35}, \ell_{5t}\} = \text{mín}\{2, 2, 2\} = 2$$

- **Paso 3 (Actualización de Flujos $\mathbf{f}^2$)**:
  - $f_{s3}^2 = 0 + 2 = 2$ (arco **saturado**, verde)
  - $f_{35}^2 = 0 + 2 = 2$ (arco **saturado**, verde)
  - $f_{5t}^2 = 0 + 2 = 2$ (arco **saturado**, verde)
  - Caudal circulante de retorno: $f_0^2 = 2 + 2 = 4$.

Iteración 3 ($k = 2$) y Criterio de Parada:

- **Paso 2 (Red Incremental $G(\mathbf{f}^2)$)**:
  - Al construir $G(\mathbf{f}^2)$, todos los arcos salientes desde la fuente s a través de 3 están saturados. El único nodo alcanzable desde s mediante caminos orientados en $G(\mathbf{f}^2)$ es el nodo 2.
  - **Conclusión de Parada**: No existe ningún camino orientado desde s hasta t en la red residual $G(\mathbf{f}^2)$. Por tanto, el flujo $\mathbf{f}^2$ es el **flujo máximo** con valor $f_0^* = 4$.

Corte de Capacidad Mínima Resultante:

- El subconjunto de nodos alcanzables desde la fuente s en la red residual final es $N = \{s, 2\}$.
- El corte de capacidad mínima asociado es $w^+(N) = \{(s,3),(2,4)\}$.
- Capacidad del corte:

$$C(w^+(N)) = c_{s3} + c_{24} = 2 + 2 = 4 = f_0^*$$

Código de colores de los arcos y nodos en la representación gráfica:

- **Arcos en naranja ($\rightarrow$)**: Indican los arcos que integran el **camino aumentante** seleccionado en la iteración actual.
- **Arcos en verde ($\rightarrow$)**: Indican arcos que han quedado **saturados** a su capacidad máxima ($f_u = c_u$).
- **Arcos en rojo ($\rightarrow$)**: Indican arcos por los que circula un **flujo parcial no nulo** ($0 < f_u < c_u$).
- **Arcos en negro ($\rightarrow$)**: Indican arcos con **flujo nulo** ($f_u = 0$) o no transitados.
- **Arcos/Nodos en azul ($\rightarrow$)**: En la iteración de parada, destacan los nodos alcanzables $N = \{s, 2\}$ y los arcos que componen el **corte de capacidad mínima** $w^+(N)$.

Una vez analizada la fundamentación teórica y la traza explícita mediante la red residual $G(\mathbf{f})$, en la práctica manual o computacional directa resulta ineficiente reconstruir e ilustrar la estructura del grafo incremental en cada iteración. Por esta razón, Ford y Fulkerson diseñaron un procedimiento simplificado de implementación directa denominado **algoritmo por etiquetado de vértices**, que opera sobre los nodos de la red original mediante marcas dinámicas.

8.2.5. Algoritmo de Ford-Fulkerson por etiquetado de vértices

El algoritmo de Ford-Fulkerson se puede plantear de forma más sencilla e intuitiva sin necesidad de construir explícitamente el grafo incremental $G(\mathbf{f})$ en cada iteración. Para ello, se emplea una **regla de etiquetado dinámico de vértices** que opera directamente sobre la red de

transporte original.

Inicialmente se asigna una etiqueta a la fuente s, Etiqueta$(s) = (-, \delta_s = +\infty)$, y paso a paso se propagan marcas y etiquetas al resto de vértices no explorados.

Definición: Estructura de las etiquetas de vértices

La etiqueta asignada a un nodo j presenta dos componentes diferenciadas:

$$\text{Etiqueta}(j) = (\pm i,\ \delta_j)$$

1. **Procedencia ($\pm i$)**: Indica el nodo antecedente i (ya etiquetado) que se utiliza para etiquetar al nodo j. El signo del antecedente determina la orientación del tránsito:
   - $+i$ **(Arco directo (i,j))**: El arco está dirigido de i hacia j y su flujo actual es inferior a su capacidad ($f_{ij} < c_{ij}$). Permite incrementar flujo.
   - $-i$ **(Arco inverso (j,i))**: El arco está dirigido de j hacia i y su flujo actual es positivo ($f_{ji} > 0$). Permite reducir flujo.
2. **Capacidad disponible (δ_j)**: Indica el valor máximo de flujo incremental que es posible hacer llegar desde la fuente s hasta el nodo j a través de la cadena de antecedentes iniciada en i.

Definición: Reglas formales de etiquetado

Sea $i \in V$ un nodo previamente etiquetado con etiqueta $(\cdot, \delta_i)$ y sea $j \in V$ un nodo adyacente aún **no etiquetado**:

1. **Regla 1 (Arco Directo $(i,j) \in U$)**: Si $f_{ij} < c_{ij}$, se etiqueta el nodo j como $(+i, \delta_j)$, donde el cuello de botella se actualiza como:
$$\delta_j = \text{mín}\left\{\delta_i,\ c_{ij} - f_{ij}\right\}$$
2. **Regla 2 (Arco Inverso $(j,i) \in U$)**: Si $f_{ji} > 0$, se etiqueta el nodo j como $(-i, \delta_j)$, donde la capacidad de reducción se calcula como:
$$\delta_j = \text{mín}\left\{\delta_i,\ f_{ji}\right\}$$

Un vértice se considera **explorado** cuando está etiquetado o bien no es posible etiquetar a ninguno de sus nodos adyacentes no etiquetados.

Como se ilustra en la Figura 8.20, la propagación de marcas desde la fuente s explora secuencialmente la red:

- **Si al final del proceso el sumidero t resulta etiquetado**: Se ha alcanzado con éxito

Figura 8.20: Reglas de etiquetado de vértices en el algoritmo de Ford-Fulkerson: asignación de marcas directas $(+i, \delta_j)$ en arcos salientes (izquierda) y marcas inversas $(-i, \delta_j)$ en arcos entrantes (derecha)

el destino a través de una cadena de aumento $\mu[s,t]$. El valor de la etiqueta del sumidero $\Delta = \delta_t$ determina la cantidad exacta en la que se debe incrementar el flujo circulante f_0.

- **Si no es posible etiquetar el sumidero** t **(**$t \notin S$**)**: **PARAR**. Se ha alcanzado el **flujo máximo** f_0^*. El conjunto de nodos etiquetados $N = S$ define de forma inmediata el **corte de capacidad mínima** $w^+(N)$.

Esquema: Algoritmo de Ford-Fulkerson por Etiquetado de Vértices

1. **Paso 1 (Inicialización)**: Asignar un flujo inicial compatible $\mathbf{f} = \mathbf{0}$ (o un flujo compatible conocido). Etiquetar la fuente s con la marca inicial $(-, \delta_s = +\infty)$.
2. **Paso 2 (Evaluación de Exploración)**: ¿Todos los vértices etiquetados han sido totalmente explorados?
   - **SÍ**: Ir al **Paso 6**.
   - **NO**: Ir al **Paso 3**.
3. **Paso 3 (Propagación de Etiquetas)**: Etiquetar todos los vértices adyacentes posibles mediante la **Regla 1** (arcos directos) y la **Regla 2** (arcos inversos).
4. **Paso 4 (Verificación del Sumidero)**: ¿Ha sido etiquetado el sumidero t?
   - **SÍ**: Fijar la cantidad de aumento $\Delta = \delta_t$ e ir al **Paso 5**.
   - **NO**: Regresar al **Paso 2**.
5. **Paso 5 (Modificación del Flujo Actual)**:
   1. Inicializar el puntero de rastreo en el sumidero: $k \leftarrow t$.
   2. Si la etiqueta del vértice k es $(+i, \delta_k)$, incrementar el flujo del arco directo:
   $$f_{ik} \leftarrow f_{ik} + \Delta$$
   3. Si la etiqueta del vértice k es $(-i, \delta_k)$, reducir el flujo del arco inverso:
   $$f_{ki} \leftarrow f_{ki} - \Delta$$

4. Retroceder al nodo antecedente: $k \leftarrow i$. ¿Es $i = s$?
   - **SÍ**: Incrementar el flujo de retorno $f_0 \leftarrow f_0 + \Delta$, borrar todas las etiquetas de los nodos excepto la de la fuente s $(-, +\infty)$ e ir al **Paso 2**.
   - **NO**: Regresar al **Subpaso 5.2**.

6. **Paso 6 (Optimalidad y Parada)**: El flujo actual $\mathbf{f}^*$ es el **flujo máximo**. El subconjunto de vértices que han quedado etiquetados $N = S$ define el **corte de capacidad mínima** $w^+(N)$.

Ejemplo: Traza paso a paso del Algoritmo de Ford-Fulkerson por etiquetado de vértices

Considérese la red de transporte de 8 nodos $V = \{s, 1, 2, 3, 4, 5, 6, t\}$ equipada con las capacidades entre paréntesis c_u:

- $c_{s1} = 7$, $c_{s2} = 2$, $c_{12} = 1$, $c_{13} = 5$, $c_{32} = 3$, $c_{34} = 2$, $c_{35} = 4$, $c_{24} = 4$, $c_{46} = 5$, $c_{56} = 3$, $c_{5t} = 3$, $c_{6t} = 6$.

Se aplica el algoritmo de Ford-Fulkerson por etiquetado partiendo del flujo nulo inicial $\mathbf{f}^0 = \mathbf{0}$ ($f_0^0 = 0$). La propagación dinámica de marcas, la actualización de flujos y la delimitación del corte mínimo se ilustran paso a paso en la **?@fig-ford-fulkerson-etiquetado-animado**:
Iteración 1:

- **Propagación de etiquetas**:
  - Etiqueta inicial en el origen: Etiqueta$(s) = (-, \delta_s = +\infty)$.
  - Desde s: etiquetar 1 con $(+s, 7)$ y 2 con $(+s, 2)$.
  - Desde 2: etiquetar 4 con $(+2, \text{mín}\{2, 4\} = 2)$.
  - Desde 4: etiquetar 6 con $(+4, \text{mín}\{2, 5\} = 2)$.
  - Desde 6: etiquetar el sumidero t con $(+6, \text{mín}\{2, 6\} = 2)$.
- **Camino aumentante**: $\mu_1 = (s \to 2 \to 4 \to 6 \to t)$ con incremento de flujo $\Delta_1 = \delta_t = 2$.
- **Actualización de flujos ($\mathbf{f}^1$)**:
  - $f_{s2} \leftarrow 0 + 2 = 2$ (el arco $(s, 2)$ queda **saturado**, pasando a verde).
  - $f_{24} \leftarrow 0 + 2 = 2$, $f_{46} \leftarrow 0 + 2 = 2$, $f_{6t} \leftarrow 0 + 2 = 2$.
  - Flujo total circulante de retorno: $f_0^1 = 2$.

Iteración 2:

- **Propagación de etiquetas**:
  - Etiqueta inicial en s: $(-, +\infty)$. (El arco $(s, 2)$ está saturado, no permite etiquetar 2).

- Desde s: etiquetar 1 con $(+s,\ 7)$.
- Desde 1: etiquetar 3 con $(+1,\ \text{mín}\{7,5\} = 5)$ y 2 con $(+1,\ \text{mín}\{7,1\} = 1)$.
- Desde 3: etiquetar 5 con $(+3,\ \text{mín}\{5,4\} = 4)$ y 4 con $(+3,\ \text{mín}\{5,2\} = 2)$.
- Desde 5: etiquetar el sumidero t con $(+5,\ \text{mín}\{4,3\} = 3)$.

- **Camino aumentante**: $\mu_2 = (s \to 1 \to 3 \to 5 \to t)$ con incremento de flujo $\Delta_2 = \delta_t = 3$.
- **Actualización de flujos ($\mathbf{f^2}$)**:
  - $f_{s1} \leftarrow 0 + 3 = 3$, $f_{13} \leftarrow 0 + 3 = 3$, $f_{35} \leftarrow 0 + 3 = 3$.
  - $f_{5t} \leftarrow 0 + 3 = 3$ (el arco $(5,t)$ queda **saturado**, pasando a verde).
  - Flujo total circulante de retorno: $f_0^2 = 2 + 3 = 5$.

Iteración 5:

- **Propagación de etiquetas**:
  - Etiqueta inicial en s: $(-,\ +\infty)$.
  - Desde s: el arco $(s,2)$ está saturado ($f_{s2} = 2 = c_{s2}$). Etiquetar 1 con $(+s,\ 7 - 5 = 2)$.
  - Desde 1: el arco $(1,3)$ está saturado ($f_{13} = 5 = c_{13}$). Mediante $(1,2)$ etiquetamos 2 con $(+1,\ \text{mín}\{2,1\} = 1)$.
  - Desde 2: mediante $(2,4)$ etiquetamos 4 con $(+2,\ \text{mín}\{1,4-2\} = 1)$.
  - Desde 4: etiquetar 6 con $(+4,\ \text{mín}\{1,5-3\} = 1)$.
  - Desde 6: etiquetar el sumidero t con $(+6,\ \text{mín}\{1,6-4\} = 1)$.
- **Camino aumentante**: $\mu_5 = (s \to 1 \to 2 \to 4 \to 6 \to t)$ con incremento de flujo $\Delta_5 = \delta_t = 1$.
- **Actualización de flujos ($\mathbf{f^5}$)**:
  - $f_{s1} \leftarrow 5 + 1 = 6$.
  - $f_{12} \leftarrow 0 + 1 = 1$ (el arco $(1,2)$ queda **saturado**, pasando a verde).
  - $f_{24} \leftarrow 2 + 1 = 3$, $f_{46} \leftarrow 3 + 1 = 4$, $f_{6t} \leftarrow 4 + 1 = 5$.
  - Flujo total circulante de retorno: $f_0^5 = 7 + 1 = 8$.

Iteración 6 (Criterio de Parada):

- **Propagación de etiquetas**:
  - Etiqueta inicial en s: $(-,\ +\infty)$.
  - Desde s: el arco $(s,2)$ está saturado. Etiquetar 1 con $(+s,\ 7 - 6 = 1)$.
  - Desde 1: el arco $(1,3)$ está saturado ($f_{13} = 5 = c_{13}$) y el arco $(1,2)$ está saturado ($f_{12} = 1 = c_{12}$). No es posible etiquetar ningún nodo adicional desde 1.
  - **Fin del algoritmo**: El sumidero t **no resulta etiquetado** ($t \notin S$).

Solución Óptima y Corte de Capacidad Mínima:

- **Valor del flujo máximo**: $f_0^* = 8$.
- **Subconjunto de vértices etiquetados**: $N = \{s, 1\}$.
- **Corte de capacidad mínima**: $w^+(N) = \{(s,2), (1,3), (1,2)\}$.
- **Capacidad del corte**:

$$C(w^+(N)) = c_{s2} + c_{13} + c_{12} = 2 + 5 + 1 = 8 = f_0^*$$

Código de colores de los arcos y nodos en la representación gráfica:

- **Arcos en naranja (→)**: Indican los arcos que integran el **camino aumentante** seleccionado en la iteración actual.
- **Arcos en verde (→)**: Indican arcos que han quedado **saturados** a su capacidad máxima ($f_u = c_u$).
- **Arcos en rojo (→)**: Indican arcos por los que circula un **flujo parcial no nulo** ($0 < f_u < c_u$).
- **Arcos en negro (→)**: Indican arcos con **flujo nulo** ($f_u = 0$) o no transitados.
- **Nodos en naranja (○)**: En la iteración de parada, representan el subconjunto de nodos etiquetados $N = S$ que contienen a la fuente s.
- **Nodos en verde (○)**: En la iteración de parada, representan el subconjunto de nodos no alcanzables $V \setminus N$ que contienen al sumidero t.
- **Arcos en azul (→)**: En la iteración de parada, destacan los arcos salientes que componen el **corte de capacidad mínima** $w^+(N)$.

La caracterización de la complejidad computacional del algoritmo de Ford-Fulkerson exige analizar cómo influye el método de selección de caminos de aumento en la eficiencia global. La regla de etiquetado dinámico de vértices no solo simplifica la resolución gráfica sobre la red original, sino que computacionalmente equivale a realizar una **búsqueda en anchura (BFS)** por niveles desde la fuente s. Esta estrategia de nivelación garantiza seleccionar en cada iteración la cadena de aumento que contiene el menor número de arcos en la red residual.

En redes de transporte equipadas con capacidades enteras ($\mathbf{c} \in \mathbb{Z}_+^m$), el algoritmo genérico de Ford-Fulkerson incrementa el valor del flujo f_0 en al menos una unidad entera en cada paso ($\Delta \geq 1$), alcanzando la convergencia en un número de aumentos acotado superiormente por $O(m \cdot f_0^*)$. Sin embargo, en redes arbitrarias con capacidades reales irracionales ($\mathbf{c} \in \mathbb{R}_+^m$), una elección arbitraria de los caminos de aumento (por ejemplo, mediante búsqueda en profundidad, DFS) puede provocar que el algoritmo realice infinitas iteraciones sin converger a la solución óptima. Para evitar este comportamiento anómalo, la selección del camino de menor longitud en arcos mediante BFS proporciona una cota polinomial estricta, como se formaliza en el siguiente teorema.

! Teorema: Cota y complejidad de Edmonds-Karp y Dinitz (1972 / 1970)

Si en el algoritmo de Ford-Fulkerson cada incremento de flujo se realiza seleccionando sistemáticamente la cadena de aumento que posea el **menor número de arcos** en el grafo residual $G(\mathbf{f})$ (propiedad garantizada de forma natural por el algoritmo de etiquetado por niveles BFS), el flujo máximo se alcanza en no más de:

$$\frac{1}{2}mn$$

incrementos de flujo.
Demostración:

- Demostrado independientemente por Y. A. Dinitz en 1970 y J. Edmonds y R. M. Karp en 1972. La clave de la cota reside en que la distancia en número de arcos $d_{G(\mathbf{f})}(s, v)$ desde la fuente s a cualquier vértice v en la red residual es monótonamente no decreciente a lo largo de las iteraciones del algoritmo. Dado que cada arco crítico que se satura incrementa la distancia entre sus extremos en al menos 2 unidades, un mismo arco solo puede saturarse a lo sumo $n/2$ veces. Sumando sobre los m arcos del grafo, el número total de incrementos de flujo queda estrictamente acotado por $O(mn)$. ■

Dado que la propagación de marcas BFS en cada iteración requiere $O(m)$ operaciones, la variante de **Edmonds-Karp** basada en el etiquetado por niveles garantiza una complejidad temporal estrictamente polinomial de $O(m^2n)$, totalmente independiente de la magnitud de las capacidades y válida incluso para redes con capacidades irracionales.

8.2.6. Formulación de optimización lineal y dualidad

El problema del flujo máximo en una red de transporte $(G = (V, U), \mathbf{c})$ entre la fuente s y el sumidero t admite una caracterización matemática exacta como un **programa lineal continuo**. Esta formulación en optimización continua no solo permite resolver el problema mediante algoritmos generales como el del Símplex, sino que proporciona una sólida fundamentación algebraica de la equivalencia entre el flujo máximo y el corte de capacidad mínima mediante la **teoría de dualidad**.

Para construir el modelo primal, se definen como variables de decisión los flujos f_{ij} que transitan por cada arco $(i, j) \in U$, junto con el caudal total circulante de retorno f_0. La función objetivo busca maximizar este caudal neto f_0, sujeto a la ley de conservación del flujo en cada vértice y a las restricciones de capacidad física en los arcos:

$$
\begin{aligned}
\max_{f, f_0} \quad & f_0 \\
\text{sujeto a} \quad & \sum_{j|(j,i)\in U} f_{ji} - \sum_{j|(i,j)\in U} f_{ij} = \begin{cases} -f_0 & \text{si } i = s \\ 0 & \text{si } i \neq s,t \\ f_0 & \text{si } i = t \end{cases} \quad \forall i \in V \\
& 0 \leq f_{ij} \leq c_{ij}, \quad \forall (i,j) \in U
\end{aligned}
$$

A partir de este programa primal, la dualidad lineal permite construir un problema dual cuya interpretación física es extraordinariamente reveladora. Asociando una variable dual no restringida en signo $u_i \in \mathbb{R}$ a cada restricción de conservación en el nodo $i \in V$, y una variable dual no negativa $w_{ij} \geq 0$ a cada cota superior de capacidad $f_{ij} \leq c_{ij}$ en el arco $(i,j) \in U$, el problema dual busca minimizar el coste ponderado de las capacidades.

> **i** Nota: Eliminación de ecuaciones redundantes y fijación de potencial
>
> Dado que la suma global de las restricciones de conservación sobre todos los vértices es idénticamente nula ($\sum_{i\in V} b_i = 0$), el sistema contiene exactamente una ecuación linealmente dependiente. Al eliminar la restricción del nodo sumidero t y fijar su potencial de referencia en $u_t = 0$, la condición de dualidad asociada a la variable f_0 impone de forma natural $u_s - u_t = 1 \implies u_s = 1$.

Teniendo en cuenta esta normalización de potenciales, el problema dual de programación lineal se formula como:

$$
\begin{aligned}
\min_{u, w} \quad & \sum_{(i,j)\in U} c_{ij} w_{ij} \\
\text{sujeto a} \quad & u_j - u_i + w_{ij} \geq 0, \quad \forall (i,j) \in U \\
& u_s = 1, \quad u_t = 0 \\
& w_{ij} \geq 0, \quad \forall (i,j) \in U \\
& u_i \text{ no restringida}, \quad \forall i \in V
\end{aligned}
$$

> **i** Interpretación combinatoria y dualidad fuerte
>
> En cualquier solución básica óptima del problema dual, las variables duales adoptan valores discretos binarios $u_i \in \{0,1\}$ y $w_{ij} \in \{0,1\}$.
>
> 1. **Partición de los vértices**: La variable u_i actúa como función indicadora del subconjunto $N = \{i \in V \mid u_i = 1\}$. Como $u_s = 1$ y $u_t = 0$, la partición $(N, V \setminus N)$ constituye un **corte válido** que separa la fuente del sumidero ($s \in N, t \notin N$).

2. **Identificación de los arcos del corte**: La restricción dual $w_{ij} \geq u_i - u_j$ obliga a que $w_{ij} = 1$ si y solo si $u_i = 1$ y $u_j = 0$, es decir, si el arco (i, j) parte de N y entra en $V \setminus N$. Para el resto de arcos, la minimización de la función objetivo fija $w_{ij} = 0$.

3. **Equivalencia algebraica por dualidad fuerte**: Por el **Teorema de Dualidad Fuerte de la Programación Lineal**, el valor óptimo del modelo primal máx f_0^* coincide exactamente con el valor óptimo del modelo dual mín $\sum c_{ij} w_{ij} = C(w^+(N))$. Esto demuestra algebraicamente que **el Teorema de Flujo Máximo - Corte Mínimo es la manifestación directa de la dualidad fuerte en optimización lineal**. ■

Ejemplo: Formulación primal y dual en una red de 3 nodos

Considérese la red de 3 nodos $V = \{s, 1, t\}$ ilustrada en la Figura 8.21, equipada con arcos y capacidades $c_{s1} = 3, c_{st} = 2, c_{1t} = 4$:

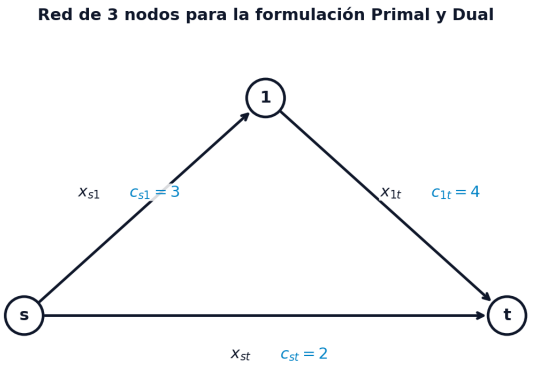

Figura 8.21: Red de transporte de 3 nodos para el planteamiento del problema de flujo máximo

Planteando explícitamente el sistema de conservación de flujo para cada vértice, el modelo primal resulta:

$$
\begin{aligned}
\max_{x, f_0} \quad & f_0 \\
\text{sujeto a} \quad & -x_{s1} - x_{st} = -f_0 && (i = s) \\
& x_{s1} - x_{1t} = 0 && (i = 1) \\
& x_{st} + x_{1t} = f_0 && (i = t) \\
& x_{s1} \leq 3, \quad x_{st} \leq 2, \quad x_{1t} \leq 4 \\
& x_{s1}, x_{st}, x_{1t} \geq 0
\end{aligned}
$$

Al eliminar la ecuación del sumidero t y fijar $u_t = 0 \implies u_s = 1$, las restricciones duales asociadas a cada arco $u_j - u_i + w_{ij} \geq 0$ se transforman en:

$$\begin{aligned} \min_{u,w} \quad & 3w_{s1} + 2w_{st} + 4w_{1t} \\ \text{sujeto a} \quad & u_1 - u_s + w_{s1} \geq 0 \implies u_1 + w_{s1} \geq 1 \qquad (\text{arco } (s,1)) \\ & u_t - u_s + w_{st} \geq 0 \implies w_{st} \geq 1 \qquad (\text{arco } (s,t)) \\ & u_t - u_1 + w_{1t} \geq 0 \implies -u_1 + w_{1t} \geq 0 \qquad (\text{arco } (1,t)) \\ & w_{s1}, w_{st}, w_{1t} \geq 0 \end{aligned}$$

La resolución de ambos modelos proporciona la solución primal óptima de flujo máximo $f_0^* = 5$ con $x_{s1}^* = 3$, $x_{st}^* = 2$ y $x_{1t}^* = 3$. Por su parte, la solución dual óptima asigna los potenciales $u_s = 1, u_1 = 0, u_t = 0$ y los multiplicadores de capacidad $w_{s1} = 1, w_{st} = 1, w_{1t} = 0$. El valor objetivo dual es $3(1) + 2(1) + 4(0) = 5 = f_0^*$, identificando de forma unívoca el corte de capacidad mínima $N = \{s\}$ con arcos salientes $w^+(N) = \{(s,1),(s,t)\}$ de capacidad $3 + 2 = 5$, tal y como se representa visualmente en la Figura 8.22:

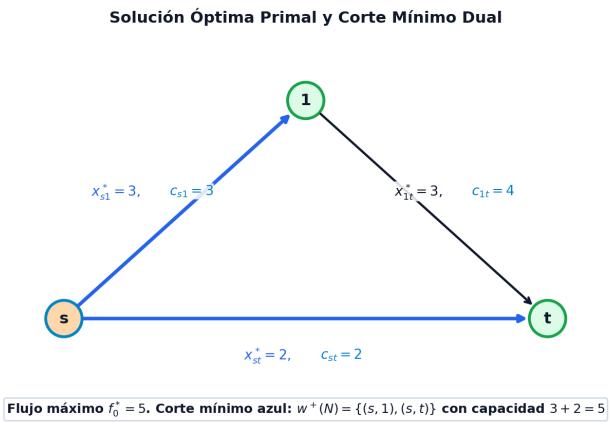

Figura 8.22: Solución óptima primal de flujo máximo y caracterización del corte de capacidad mínima en el dual

8.3. Problema de flujo a coste mínimo

En los problemas de flujo máximo estudiados previamente, el único objetivo estratégico consistía en determinar la máxima cantidad de volumen que podía enviarse desde la fuente s al sumidero t aprovechando las capacidades acotadas de los arcos. Sin embargo, en la práctica logística, económica y de transporte (distribución de bienes, encaminamiento de tráfico en redes de comunicación o asignación de tareas), enviar flujo a través de diferentes caminos conlleva un **coste unitario de transporte** $p_{ij} \in \mathbb{R}$ por cada unidad circulante.

8.3.1. Planteamiento y formulación del flujo compatible a coste mínimo

Para comprender la necesidad de esta formulación, considérese el **problema de asignación de tareas a máquinas**. Supóngase que se dispone de un conjunto de n máquinas $m_1, \dots, m_n$ y un conjunto de n tareas $t_1, \dots, t_n$. Tal y como se ilustra en la Figura 8.23, construyendo una red de transporte bipartita donde la fuente s se conecta con capacidad 1 a cada máquina, las máquinas con capacidad 1 a las tareas que pueden ejecutar, y las tareas con capacidad 1 al sumidero t, la resolución del problema del flujo máximo determina el número máximo de tareas realizables simultáneamente.

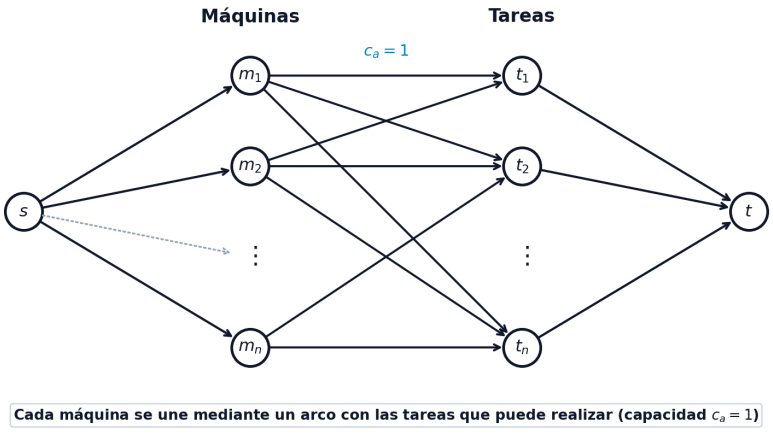

Figura 8.23: Representación en red de flujo del problema de asignación de tareas a máquinas

No obstante, en la realidad industrial cada máquina m_i incurre en un coste de procesamiento o ejecución distinto p_{ij} al realizar la tarea t_j. El objetivo óptimo ya no es únicamente ejecutar el máximo número de tareas, sino hallar la asignación completa que minimice el coste total invertido.

Generalizando este escenario, dada una red de transporte $(G = (V, U), \mathbf{c})$ equipada con capacidades $c_{ij} \geq 0$, costes unitarios $p_{ij} \in \mathbb{R}$ y un valor prefijado de flujo a enviar $f_0 = \nu$ entre la fuente s y el sumidero t, el **problema del flujo compatible a coste mínimo** se formula analíticamente como el siguiente programa lineal:

$$\begin{aligned} \min_{f} \quad & \sum_{(i,j)\in U} p_{ij} f_{ij} \\ \text{sujeto a} \quad & \sum_{j|(j,i)\in U} f_{ji} - \sum_{j|(i,j)\in U} f_{ij} = \begin{cases} -\nu & \text{si } i = s \\ 0 & \text{si } i \neq s, t \\ \nu & \text{si } i = t \end{cases} \quad \forall i \in V \\ & 0 \leq f_{ij} \leq c_{ij}, \quad \forall (i,j) \in U \end{aligned}$$

Ejemplo: Comparación de flujos compatibles y circulación por ciclos

Considérese la red de transporte de 5 nodos $V = \{s, a, b, c, t\}$ representada en la Figura 8.24, donde cada arco contiene el identificador de arista (1 a 6) y la etiqueta $(c_{ij})[p_{ij}]$ especificando su capacidad c_{ij} en azul entre paréntesis y su coste unitario p_{ij} en rojo entre corchetes:

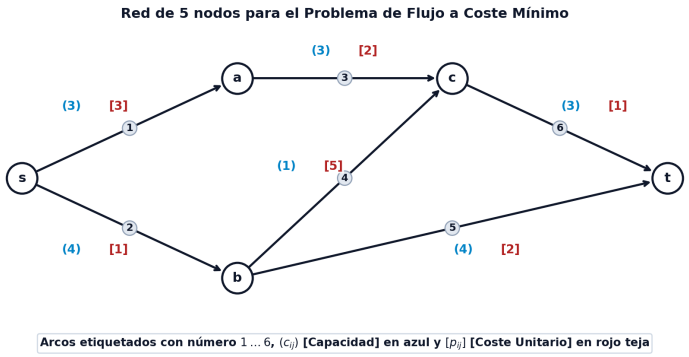

Figura 8.24: Red de transporte de 5 nodos para el problema de flujo a coste mínimo

Supóngase que se desea enviar un flujo total prefijado de $\nu = 4$ unidades desde la fuente s al sumidero t. Como se ilustra en la Figura 8.25, existen múltiples asignaciones compatibles de flujo. Analicemos dos soluciones factibles particulares, $\mathbf{f}^A$ (destacada en rojo) y $\mathbf{f}^B$ (destacada en azul), cuyos costes totales $c_A = 19$ y $c_B = 18$ se desglosan en la recuadros superiores derechos de la figura:

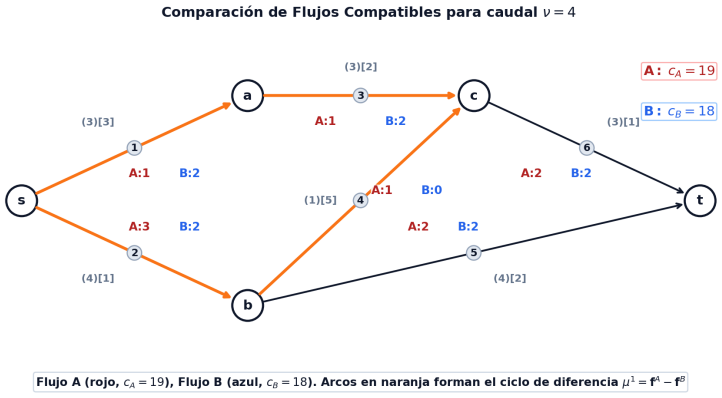

Figura 8.25: Comparación de dos flujos compatibles A y B de valor caudal 4 con sus costes totales y caracterización del ciclo de diferencia

1. **Flujo Compatible $\mathbf{f}^A$** (en rojo):

- Asignación: $f^A_{sa} = 1, f^A_{sb} = 3, f^A_{ac} = 1, f^A_{bc} = 1, f^A_{bt} = 2, f^A_{ct} = 2$.
- Coste Total: $c_A = 1(3)+3(1)+1(2)+1(5)+2(2)+2(1) = 3+3+2+5+4+2 = 19$.

2. **Flujo Compatible $\mathbf{f}^B$** (en azul):

   - Asignación: $f^B_{sa} = 2, f^B_{sb} = 2, f^B_{ac} = 2, f^B_{bc} = 0, f^B_{bt} = 2, f^B_{ct} = 2$.
   - Coste Total: $c_B = 2(3)+2(1)+2(2)+0(5)+2(2)+2(1) = 6+2+4+0+4+2 = 18$.

Análisis de la Diferencia entre Soluciones (Circulación Cíclica):
Calculando la diferencia vectorial componente a componente $^1 = \mathbf{f}^A - \mathbf{f}^B$, se obtiene la tupla de variaciones $^1 = (-1, 1, -1, 1, 0, 0)$. Gráficamente, estos cuatro arcos modificados forman un **circuito cerrado** $s \to b \to c \to a \to s$.
Por lo tanto, es posible pasar del flujo no óptimo $\mathbf{f}^A$ al flujo de menor coste $\mathbf{f}^B$ simplemente **sumando un ciclo incremental orientado en sentido inverso** $-^1$. La diferencia de coste total entre ambas soluciones es exactamente el coste neto de recorrer dicho ciclo: $c_A - c_B = 19 - 18 = 1$. Este resultado demuestra de manera intuitiva que **la diferencia entre dos flujos cualesquiera de igual valor ν es siempre una combinación lineal de circuitos residuales**.
Análisis Inicial de Cadenas desde el Flujo Nulo ($\nu_0 = 0$):
Para construir directamente la solución de coste mínimo sin tanteos arbitrarios, observamos que para un caudal inicial $\nu_0 = 0$ el flujo nulo $\mathbf{f}^0 = \mathbf{0}$ es trivialmente óptimo (coste 0). En la red inicial existen tres cadenas orientadas simples desde la fuente s al sumidero t:

- **Cadena 1** ($s \to a \to c \to t$): Coste total residual $p(\mu_1) = 3 + 2 + 1 = 6$.
- **Cadena 2** ($s \to b \to t$): Coste total residual $p(\mu_2) = 1 + 2 = 3$.
- **Cadena 3** ($s \to b \to c \to t$): Coste total residual $p(\mu_3) = 1 + 5 + 1 = 7$.

La cadena de coste mínimo es $s \to b \to t$ con coste unitario 3 y capacidad residual $\text{mín}(4, 4) = 4$. Por tanto, para enviar un caudal $\nu = 4$, la solución óptima absoluta consiste en canalizar las 4 unidades íntegramente por $s \to b \to t$, alcanzando un coste óptimo mínimo de $4 \times 3 = 12$ (estrictamente menor que los costes 19 y 18 de las soluciones de prueba $\mathbf{f}^A$ y $\mathbf{f}^B$).

8.3.2. Teoremas de optimalidad y caracterización de circuitos

Para formalizar algebraicamente el criterio de parada y las condiciones necesarias y suficientes de coste mínimo, se introducen las siguientes definiciones sobre cadenas e incrementos en redes con costes.

Definición: Coste de una cadena y cadenas incrementales

1. **Coste de una Cadena**: Dada una cadena orientada μ formada por arcos directos μ^+ e inversos μ^-, el coste total residual de la cadena se define sumando los costes unitarios según la orientación de paso:

$$p(\mu) = \sum_{u \in \mu^+} p_u - \sum_{u \in \mu^-} p_u$$

2. **Cadena Incremental**: Una cadena μ es incremental respecto a un flujo $\mathbf{f}$ si admite un incremento positivo de flujo $\delta > 0$ sin violar la no negatividad ni superar la capacidad física de ningún arco ($f_u < c_u, \forall u \in \mu^+$ y $f_u > 0, \forall u \in \mu^-$).

A partir de estas nociones se establecen los dos teoremas fundamentales que rigen la optimización de flujos con coste.

Teorema 1: Optimalidad por ausencia de circuitos incrementales de coste negativo

Un flujo compatible $\mathbf{f}$ de valor $f_0 = \nu$ es de **coste mínimo** si y solo si la red residual $G(\mathbf{f})$ **no contiene ningún circuito incremental de coste total negativo** (sin incluir el arco ficticio de retorno (t, s)).
Demostración: Cualquier otro flujo factible $\mathbf{f}'$ de valor ν puede expresarse algebraicamente como la suma del flujo $\mathbf{f}$ y una combinación lineal de circulaciones cíclicas simples $\mathbf{f}' - \mathbf{f} = \sum \alpha_k {}^k$. Si existiera en la red residual un circuito incremental ^{k} con coste estrictamente negativo ($p(\mu^k) < 0$), aumentar el flujo a lo largo de ^{k} mantendría inalterado el caudal ν (ya que las circulaciones de ciclo no tienen fuente ni sumidero) pero reduciría estrictamente el coste total, lo que contradice la minimidad de $\mathbf{f}'$. Recíprocamente, si no existen circuitos incrementales de coste negativo, ninguna modificación cíclica puede reducir el coste, garantizando la optimalidad global. ■

La verificación de la optimalidad mediante el **Teorema 1** constituye la base teórica para validar si un flujo determinado es el más económico posible para un caudal fijo ν. Dado que cualquier flujo factible puede visualizarse como el flujo actual corregido por una serie de circulaciones cíclicas, la ausencia de ciclos de mejora (aquellos que reducen el coste) garantiza que nos encontramos en un óptimo local y global. Para extender este resultado a un procedimiento de construcción progresiva, necesitamos el siguiente teorema de crecimiento incremental.

Teorema 2: Incrementos por caminos de coste mínimo

Dado un flujo $\mathbf{f}$ de valor ν que es de coste mínimo, si se incrementa el flujo en δ unidades a lo largo de la cadena incremental de s a t que posea el **coste total residual mínimo** en $G(\mathbf{f})$, el flujo resultante es de coste mínimo para el nuevo caudal $\nu + \delta$.

Demostración: Partiendo de la solución a coste mínimo para un valor de flujo ν, se encuentra una cadena incremental de s a t de coste mínimo $p(\mu)$. Se debe demostrar que al incrementar el flujo en δ unidades a lo largo de dicha cadena, la solución resultante es de coste mínimo para el nuevo valor $\nu + \delta$.
Por reducción al absurdo y aplicando el **Teorema 1**, supóngase que la nueva solución no fuera óptima para $\nu + \delta$. En tal caso, debería existir en la red residual un ciclo incremental de coste estrictamente negativo:

1. **Si el ciclo NO comparte arcos con la cadena**: El ciclo ya pertenecía a la red residual de la solución inicial, lo que implicaría que la solución inicial no habría sido de coste mínimo para ν, contradiciendo la hipótesis.
2. **Si el ciclo y la cadena comparten arcos**: Uniendo vectorialmente ambos se puede construir una nueva cadena incremental de s a t con un coste estrictamente menor que $p(\mu)$, lo cual contradice que la cadena original fuera de coste mínimo.

Al ser ambos casos imposibles, se concluye que el flujo incrementado en δ unidades es de coste mínimo para $\nu + \delta$. ■

El **Teorema 2** valida la estrategia de construcción iterativa: no necesitamos realizar un cálculo de optimización global completo para cada valor de flujo, sino que basta con encadenar aumentos de caudal a lo largo de los caminos más eficientes disponibles en la red residual. Esta propiedad garantiza que cada paso algorítmico preserva la optimalidad, permitiendo avanzar de forma eficiente desde $f_0 = 0$ hasta la meta ν.

i Nota: Estrategia algorítmica de resolución iterativa

La combinación didáctica de ambos teoremas proporciona el esquema general de resolución:

1. **Determinación de la Solución Inicial (Teorema 1)**: Se puede iniciar el proceso desde el flujo nulo $\mathbf{f}^0 = \mathbf{0}$ para $\nu = 0$. Si todos los costes unitarios son no negativos ($p_{ij} \geq 0$), no existe ningún circuito inicial de coste negativo y $\mathbf{f}^0$ es trivialmente óptimo. Si existen costes negativos, se aplican algoritmos de detección de ciclos negativos (como Bellman-Ford) para eliminar circulaciones iniciales negativas aplicando el Teorema 1.
2. **Crecimiento Iterativo por Caminos Mínimos (Teorema 2)**: A partir del flujo óptimo inicial, se calcula iterativamente la cadena de coste residual mínimo desde s hasta t y se incrementa el flujo en δ unidades. Por el Teorema 2, cada paso garantiza la optimalidad del nuevo caudal $\nu + \delta$, repitiendo la búsqueda hasta alcanzar el volumen objetivo ν prefijado en el problema.

8.3.3. Algoritmo de Flujo a Coste Mínimo (Grafo de distancias)

El problema de hallar cadenas incrementales de coste mínimo en la red inicial se traduce operacionalmente en encontrar **caminos de longitud mínima** entre la fuente s y el sumidero t en el grafo de distancias residual $G(\mathbf{f})$. Una vez obtenido el camino más corto, el siguiente paso consiste en determinar el incremento máximo de flujo compatible a lo largo de sus arcos. La detección temprana de circuitos negativos en este grafo permite asegurar que el estado inicial del sistema es coherente con los principios de optimalidad descritos anteriormente.

i Nota: Correspondencia de circuitos negativos

Cualquier circuito de longitud total estrictamente negativa en el grafo residual $G(\mathbf{f})$ se corresponde de forma unívoca con un **ciclo incremental de coste negativo** en la red de transporte original.

i Esquema: Algoritmo de Flujo a Coste Mínimo

- **Paso 1: Inicialización**: Obtener un flujo compatible inicial $\mathbf{f}$ (habitualmente el flujo nulo $\mathbf{f}^0 = \mathbf{0}$ para $\nu = 0$).
- **Paso 2: Eliminación de ciclos con coste negativo**:
  1. Construir el grafo de distancias residual $G(\mathbf{f})$.
  2. Si $G(\mathbf{f})$ contiene circuitos de longitud negativa, modificar el flujo incrementándolo a lo largo del circuito en su capacidad residual y volver al Paso 2.1.
  3. En caso contrario (sin circuitos negativos), ir al **Paso 3**.
- **Paso 3: Aumento del valor del flujo**:
  - Si el valor del flujo ha alcanzado la meta $f_0 = \nu$, **PARAR**: Solución óptima alcanzada.
  - En caso contrario ($f_0 < \nu$), buscar en $G(\mathbf{f})$ el camino de longitud mínima de s a t:
    1. Si no existe ningún camino de s a t en $G(\mathbf{f})$, **PARAR**: El problema no admite solución factible para el valor de flujo ν.
    2. En caso contrario, calcular la capacidad residual mínima de la cadena asociada al camino $c(s,t)$.
    3. Variar el flujo en los arcos del camino en la cantidad $\Delta = \text{mín}\{c(s,t), \nu - f_0\}$.
    4. Actualizar el flujo $f_0 \leftarrow f_0 + \Delta$, construir el grafo residual asociado al nuevo flujo e ir al **Paso 3**.

Ejemplo: Traza del algoritmo de flujo a coste mínimo

Considérese la red de transporte de 5 nodos $V = \{s, a, b, c, t\}$ con 7 arcos dirigidos $U = \{1, 2, 3, 4, 5, 6, 7\}$, cuyas capacidades c_{ij} y costes unitarios p_{ij} se expresan en el formato $(c_{ij})[p_{ij}]$:

- Arco 1: (s, a) con capacidad $c_{sa} = 3$ y coste $p_{sa} = 3$.
- Arco 2: (s, b) con capacidad $c_{sb} = 2$ y coste $p_{sb} = 3$.
- Arco 3: (a, c) con capacidad $c_{ac} = 2$ y coste $p_{ac} = -1$.
- Arco 4: (a, t) con capacidad $c_{at} = 4$ y coste $p_{at} = -1$.
- Arco 5: (b, a) con capacidad $c_{ba} = 2$ y coste $p_{ba} = -2$.
- Arco 6: (c, b) con capacidad $c_{cb} = 2$ y coste $p_{cb} = 1$.
- Arco 7: (c, t) con capacidad $c_{ct} = 5$ y coste $p_{ct} = 2$.

Se desea transmitir un caudal total objetivo de $\nu = 5$ unidades desde la fuente s al sumidero t al menor coste total posible.

Paso a paso de los cálculos e iteraciones

Paso 1: Inicialización

Se inicia el procedimiento fijando la solución de flujo nulo $\mathbf{f}^0 = \mathbf{0}$ para un valor de caudal circulante de $f_0 = 0$. El coste acumulado inicial es $C(\mathbf{f}^0) = \sum_{(i,j)\in U} p_{ij} f_{ij}^0 = 0$.

Paso 2: Eliminación de circuitos con coste negativo

- **Paso 2.1: Construcción de $G(\mathbf{f}^0)$**: Puesto que el flujo es nulo en todos los arcos ($f_{ij}^0 = 0$), todos los arcos directos admiten capacidad residual $c_{ij} - f_{ij}^0 = c_{ij} > 0$. Se construye $G(\mathbf{f}^0)$ asignando a cada arco su peso unitario p_{ij}:

$$p_{sa} = 3, \quad p_{sb} = 3, \quad p_{ba} = -2, \quad p_{ac} = -1, \quad p_{cb} = 1, \quad p_{at} = -1, \quad p_{ct} = 2$$

- **Paso 2.2: Detección del circuito residual de longitud negativa**: Evaluando los circuitos cerrados en $G(\mathbf{f}^0)$, se identifica el circuito orientado $C_1 = a \to c \to b \to a$. Calculamos su coste total:

$$p(C_1) = p_{ac} + p_{cb} + p_{ba} = (-1) + 1 + (-2) = -2 < 0$$

  Al ser $p(C_1) = -2 < 0$, por el **Teorema 1** el flujo nulo $\mathbf{f}^0$ no es óptimo porque es posible reducir el coste circulando flujo en ciclo. Determinamos la **Capacidad Residual Máxima** δ_1 de C_1:

$$\delta_1 = \text{mín}\{c_{ac} - f_{ac}^0,\, c_{cb} - f_{cb}^0,\, c_{ba} - f_{ba}^0\} = \text{mín}\{2-0,\, 2-0,\, 2-0\} = 2 \text{ unidades}$$

- **Paso 2.3: Incremento de flujo en el circuito y recálculo del coste**: Incrementamos el flujo en $\delta_1 = 2$ unidades a lo largo de C_1:

$$f_{ac}^1 = 2, \quad f_{cb}^1 = 2, \quad f_{ba}^1 = 2$$

El resto de arcos mantienen su flujo nulo. Recalculamos el coste total acumulado del nuevo flujo $\mathbf{f}^1$:

$$C(\mathbf{f}^1) = 2(p_{ac}) + 2(p_{cb}) + 2(p_{ba}) = 2(-1) + 2(1) + 2(-2) = -4$$

El coste total disminuye de 0 a -4 manteniendo el caudal entrante en la fuente igual a $f_0 = 0$.

- **Paso 2.4: Nuevo grafo residual $G(\mathbf{f}^1)$ y verificación**: Al estar los arcos (a, c), (c, b) y (b, a) saturados ($f = c = 2$), los arcos directos desaparecen de $G(\mathbf{f}^1)$ y se activan sus arcos inversos:

  - Arco inverso (c, a) con peso $-p_{ac} = -(-1) = 1$.
  - Arco inverso (b, c) con peso $-p_{cb} = -1$.
  - Arco inverso (a, b) con peso $-p_{ba} = -(-2) = 2$.

  Se comprueba en $G(\mathbf{f}^1)$ que **ya no existe ningún circuito de longitud negativa**. Por el **Teorema 1**, el flujo $\mathbf{f}^1$ es el punto de partida óptimo para caudal $f_0 = 0$.

Paso 3: Aumento del valor del flujo
Como el caudal actual $f_0 = 0$ es estrictamente menor que la meta $\nu = 5$, aplicamos iterativamente el Paso 3 buscando caminos de longitud mínima entre s y t en el grafo residual:

- **Primera iteración del Paso 3 (Caudal $f_0 = 0 \to 3$)**:

  1. **Paso 3.1 (Camino Mínimo en $G(\mathbf{f}^1)$)**: Buscamos en $G(\mathbf{f}^1)$ el camino de longitud residual mínima entre s y t. Se encuentra el camino mínimo $\mu_1 = s \to a \to t$ con coste residual $p(\mu_1) = p_{sa} + p_{at} = 3 + (-1) = 2$.
  2. **Paso 3.2 (Capacidad residual e incremento)**: Capacidad residual de la cadena $c(\mu_1) = \min\{3 - 0, 4 - 0\} = 3$ unidades. Incremento de flujo: $\Delta_1 = \min\{3, 5 - 0\} = 3$ unidades.
  3. **Paso 3.3 (Actualización de flujos)**: Asignamos $\Delta_1 = 3$ unidades a lo largo de μ_1: $f^2_{sa} = 3, f^2_{at} = 3$. El caudal circulante alcanza $f_0 = 3$. Coste acumulado: $C(\mathbf{f}^2) = -4 + 3(2) = 2$.
  4. **Paso 3.4 (Nuevo Grafo Residual $G(\mathbf{f}^2)$)**: El arco (s, a) queda saturado ($f_{sa} = 3 = c_{sa}$), generando el arco inverso (a, s) con peso -3. El arco (a, t) está parcialmente cargado ($f_{at} = 3 < 4$), manteniendo el arco directo (a, t) con peso -1 en el grafo azul (y $+1$ al recorrerlo en la figura del camino) y el arco inverso (t, a) con peso $+1$.

- **Segunda iteración del Paso 3 (Caudal $f_0 = 3 \to 4$)**:

  1. **Paso 3.5 (Camino Mínimo en $G(\mathbf{f}^2)$)**: Como $f_0 = 3 < 5 = \nu$, buscamos el siguiente camino residual mínimo entre s y t. Se encuentra el camino mínimo

$\mu_2 = s \to b \to c \to a \to t$ con coste residual $p(\mu_2) = p_{sb} + p(b,c) + p(c,a) + p(a,t) = 3 + (-1) + 1 + 1 = 4$ (o 2 neto por cancelación de flujo en arcos inversos).

2. **Paso 3.6 (Capacidad residual e incremento)**: Capacidad residual disponible:

   $c(\mu_2) = \text{mín}\{c_{sb} - f^2_{sb},\, f^2_{cb},\, f^2_{ac},\, c_{at} - f^2_{at}\} = \text{mín}\{2-0,\, 2,\, 2,\, 4-3\} = 1$ unidad

   Incremento de flujo compatible: $\Delta_2 = \text{mín}\{1,\, 5-3\} = 1$ unidad.
3. **Paso 3.7 (Actualización de flujos)**: Aumenta el flujo directo en (s,b) y (a,t): $f^3_{sb} = 1$ y $f^3_{at} = 4$ (saturado). Al recorrer en sentido inverso (c,b) y (a,c), el flujo se reduce en 1 unidad: $f^3_{cb} = 1, f^3_{ac} = 1$. El caudal circulante alcanza $f_0 = 4$. Coste acumulado: $C(\mathbf{f}^3) = 2 + 1(2) = 4$.
4. **Paso 3.8 (Nuevo Grafo Residual $G(\mathbf{f}^3)$)**: Al estar (a,t) saturado ($f_{at} = 4$), desaparece su arco directo y únicamente permanece el inverso (t,a) con peso $+1$. Los arcos (s,b), (a,c) y (b,c) están parcialmente cargados ($f = 1 < c = 2$), generando dobles arcos.

- **Tercera iteración del Paso 3 (Caudal $f_0 = 4 \to 5$)**:

1. **Paso 3.9 (Camino Mínimo en $G(\mathbf{f}^3)$)**: Como $f_0 = 4 < 5 = \nu$, buscamos el camino residual mínimo entre s y t. Se encuentra el camino mínimo $\mu_3 = s \to b \to c \to t$ con coste residual $p(\mu_3) = p_{sb} + p(b,c) + p_{ct} = 3 + (-1) + 2 = 4$.
2. **Paso 3.10 (Capacidad residual e incremento final)**: Capacidad residual disponible:

   $c(\mu_3) = \text{mín}\{c_{sb} - f^3_{sb},\, c_{cb} - f^3_{cb},\, c_{ct} - f^3_{ct}\} = \text{mín}\{2-1,\, 2-1,\, 5-0\} = 1$ unidad

   Incremento final: $\Delta_3 = \text{mín}\{1,\, 5-4\} = 1$ unidad.
3. **Paso 3.11 (Actualización de flujos y condición de parada)**: Se incrementa el flujo en 1 unidad a lo largo de μ_3:
   - $f^*_{sb} = 1 + 1 = 2$ (saturando el arco (s,b)).
   - $f^*_{cb} = 1 - 1 = 0$ (deshaciendo completamente el flujo en (c,b)).
   - $f^*_{ct} = 0 + 1 = 1$. El caudal circulante alcanza la meta objetivo $f_0 = 5 = \nu$. **PARAR**: Solución óptima alcanzada.

Solución Óptima del Problema de Flujo a Coste Mínimo
La distribución óptima de flujo para transmitir $\nu = 5$ unidades al menor coste total es:

$$f^*_{sa} = 3, \quad f^*_{sb} = 2, \quad f^*_{ba} = 2, \quad f^*_{ac} = 1, \quad f^*_{cb} = 0, \quad f^*_{at} = 4, \quad f^*_{ct} = 1$$

El **Coste Mínimo Óptimo Total** resultante es:

$$C^* = 3(3) + 2(3) + 2(-2) + 1(-1) + 0(1) + 4(-1) + 1(2) = 9 + 6 - 4 - 1 + 0 - 4 + 2 = 8$$

Reproductor interactivo de la traza algorítmica

8.4. El problema del transbordo

Habiendo estudiado el problema de flujo de coste mínimo para un único par origen-destino (s,t), resulta natural extender esta metodología a redes complejas con múltiples nodos de oferta y demanda. El **problema del transbordo** constituye la formulación lineal más general e integradora dentro de la optimización en redes. Su propósito es determinar el esquema óptimo para transportar una mercancía a través de una red de capacidad limitada (con cotas inferior ℓ_{ij} y superior c_{ij} en cada arco), donde determinados nodos actúan como emisores u orígenes de mercancía, otros como receptores o destinos, y un tercer grupo actúa únicamente como puntos intermedios de paso o **transbordo**, de manera que se satisfagan todas las demandas a coste mínimo total.

i Definición: Modelo matemático del problema del transbordo

Dada una red dirigida $G = (V, U)$ con $|V| = n$ nodos y $|U| = m$ arcos, definimos los siguientes elementos del modelo:

- **Variables de decisión**: f_{ij} representa el número de unidades de mercancía enviadas del nodo i al nodo j, para todo $(i,j) \in U$.
- **Costes unitarios**: p_{ij} es el coste unitario de transporte asociado al arco $(i,j) \in U$.
- **Disponibilidad o recurso en los nodos**: b_i representa el balance neto de mercancía en el nodo $i \in V$:
  - **Nodo de Oferta** ($b_i > 0$): El nodo genera o dispone de b_i unidades de mercancía.
  - **Nodo de Demanda** ($b_i < 0$): El nodo requiere o consume $|b_i|$ unidades de mercancía.
  - **Nodo de Transbordo** ($b_i = 0$): El nodo no produce ni consume mercancía; todo el flujo que entra debe salir.

Hipótesis de Equilibrio: Se asume que la red está en equilibrio, de forma que la oferta total generada es exactamente igual a la demanda total requerida:

$$\sum_{i=1}^{n} b_i = 0$$

El modelo de Programación Lineal del problema del transbordo se formula como:

$$\begin{aligned} \min_{f \geq 0} \quad & \sum_{i=1}^{n} \sum_{j=1}^{n} p_{ij} f_{ij} \\ \text{sujeto a} \quad & \sum_{j=1}^{n} f_{ij} - \sum_{k=1}^{n} f_{ki} = b_i, \quad \forall i \in V \\ & \ell_{ij} \leq f_{ij} \leq c_{ij}, \quad \forall (i,j) \in U \end{aligned}$$

El modelo del transbordo actúa como un marco unificador de la optimización en redes, conteniendo como casos particulares a las siguientes clases de problemas:

1. **Problema de Transporte**: Nodos divididos estrictamente en orígenes ($b_i > 0$) y destinos ($b_i < 0$), sin nodos intermedios de transbordo.
2. **Problema de Asignación**: Caso de transporte bipartito con $b_i = +1$ y $b_j = -1$ con capacidades unitarias.
3. **Problema del Camino Mínimo**: Red con un único nodo fuente $b_s = +1$, un único nodo sumidero $b_t = -1$ y transbordos $b_i = 0$.
4. **Problema del Flujo Máximo**: Red con arco de retorno ficticio (t, s) e igualación de balances a cero.
5. **Problema de Flujo de Coste Mínimo**: Formulación del transbordo con fuente $b_s = \nu$, sumidero $b_t = -\nu$ y transbordos $b_i = 0$.

9 Emparejamientos en redes

La teoría de **emparejamientos en grafos** (*matchings*) constituye uno de los capítulos más elegantes, profundos y de mayor impacto práctico dentro de la optimización combinatoria y el análisis de redes (Ahuja, Magnanti, y Orlin 1993; Papadimitriou y Steiglitz 1998). Su propósito fundamental es seleccionar un subconjunto de aristas de forma que ningún par de ellas comparta un vértice común, modelando la asignación óptima de recursos discretos e indivisibles: asignación de tripulaciones a vuelos, emparejamiento de donantes y receptores de órganos, emparejamiento de estudiantes a universidades, y partición de tareas en entornos computacionales y logísticos (Edmonds 1965; Lovász y Plummer 2009).

En este capítulo desarrollaremos la fundamentación teórica y algorítmica completa de los emparejamientos. Comenzaremos formalizando los conceptos de saturación, vértices expuestos y emparejamientos máximos y perfectos. A continuación, estudiaremos las cadenas alternantes y la operación de transferencia, demostrando rigurosamente el célebre Teorema de Caracterización de Berge y el lema estructural de componentes conexas en la diferencia simétrica. Posteriormente, abordaremos el desafío de los ciclos impares (*flores*) en grafos generales mediante la operación de contracción y el Algoritmo del Árbol Alternante de Edmonds. Finalmente, analizaremos la estrecha relación de dualidad entre emparejamientos y recubrimientos formulada por Gallai, culminando con la resolución del problema de emparejamiento de peso máximo mediante análisis de costes reducidos.

! Objetivos de aprendizaje

Al finalizar este capítulo, serás capaz de:

1. **Definir** y **clasificar** emparejamientos maximales, de máximo cardinal y perfectos, caracterizando el estado de saturación de los vértices.
2. **Demostrar** y **aplicar** el Teorema de Berge para certificar la optimalidad de un emparejamiento mediante la ausencia de cadenas incrementales.
3. **Analizar** la descomposición estructural en componentes conexas del grafo diferencia simétrica $G' = (V, K_1 \triangle K_2)$.
4. **Construir** árboles y bosques alternantes, caracterizando los conjuntos de niveles pares Y^0 e impares Y^1 para guiar la búsqueda de caminos de aumento.
5. **Ejecutar** el algoritmo de contracción y descompresión de flores de Edmonds para resolver emparejamientos en grafos no bipartitos.
6. **Demostrar** y **aplicar** el Teorema de Dualidad de Gallai que vincula los empareja-

mientos máximos con los recubrimientos de aristas mínimos.
7. **Formular** y **resolver** el problema de emparejamiento de máximo peso mediante transferencias de cadenas de coste reducido máximo.

9.1. Fundamentos y conceptos de emparejamiento

Para comprender la naturaleza combinatoria del emparejamiento, resulta ilustrativo comenzar analizando un problema clásico de asignación de recursos indivisibles en el que se busca coordinar pares de elementos compatibles. Consideremos el problema de coordinación de tripulaciones aéreas.

Ejemplo: Asignación de tripulaciones de la Royal Air Force (RAF)

Durante la Segunda Guerra Mundial, la Real Fuerza Aérea británica (RAF) necesitaba organizar tripulaciones formadas por parejas de dos pilotos para sus aviones biplaza de combate. Por motivos operativos y de seguridad en vuelo, ambos pilotos debían dominar al menos un idioma común para garantizar la comunicación fluida en cabina.
Supongamos que en una base aérea se dispone de 7 pilotos con las siguientes competencias lingüísticas:

- **Piloto 1** (P): Habla únicamente {polaco}.
- **Piloto 2** (PI): Habla {polaco, inglés}.
- **Piloto 3** (P'): Habla {polaco}.
- **Piloto 4** (I): Habla únicamente {inglés}.
- **Piloto 5** (A): Habla únicamente {alemán}.
- **Piloto 6** (AI): Habla {alemán, inglés}.
- **Piloto 7** (FI): Habla {francés, inglés}.

Se desea determinar el **número máximo de tripulaciones completas** (parejas de pilotos) que pueden formarse simultáneamente.
Para resolver el problema, modelamos el sistema mediante un grafo simple no dirigido $G = (V, E)$, donde cada vértice representa a un piloto ($V = \{P, PI, P', I, A, AI, FI\}$) y existe una arista no dirigida $\{u, v\} \in E$ si y sólo si los pilotos asociados u y v comparten al menos un idioma. Las aristas del grafo resultan ser:

$$E = \{\{P, PI\}, \{P, P'\}, \{PI, P'\}, \{PI, I\}, \{PI, AI\}, \\ \{PI, FI\}, \{I, FI\}, \{I, AI\}, \{FI, AI\}, \{A, AI\}\}$$

Como se ilustra en la Figura 9.1, una asignación miope o codiciosa podría emparejar inicialmente a los pilotos $\{P, PI\}$ (por hablar polaco) y $\{A, AI\}$ (por hablar alemán), obteniendo el emparejamiento $K_1 = \{\{P, PI\}, \{A, AI\}\}$ de tamaño 2. Sin embargo, esta

selección bloquea a los pilotos restantes (P', FI, I), impidiendo formar una tercera pareja a pesar de que el número total de pilotos (7) permitiría teóricamente hasta $\lfloor 7/2 \rfloor = 3$ parejas.

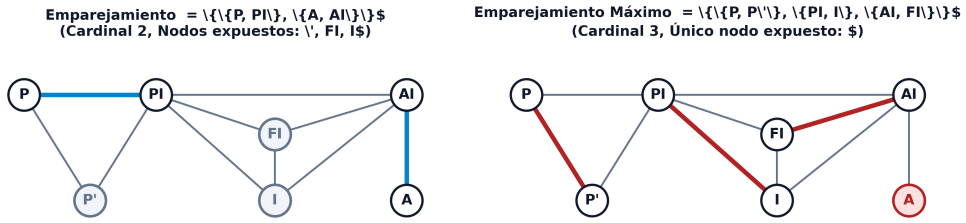

Figura 9.1: Problema de tripulaciones de la RAF: comparación entre un emparejamiento subóptimo de 2 aristas (izquierda) y un emparejamiento máximo de 3 aristas (derecha)

Reorganizando las asignaciones hacia el emparejamiento $K_2 = \{\{P, P'\}, \{PI, I\}, \{AI, FI\}\}$, se logran formar **3 tripulaciones completas**, dejando únicamente al piloto A sin pareja asignada. Dado que con 7 pilotos no es posible formar más de 3 parejas independientes, K_2 constituye una solución de máxima cardinalidad.

La formalización matemática de este problema requiere definir con precisión los conceptos de aristas disjuntas, vértices saturados y clases de optimalidad sobre grafos no dirigidos.

i Definición: Emparejamiento en un grafo

Dado un grafo no dirigido simple $G = (V, E)$, un **emparejamiento** (o *matching*) es un subconjunto de aristas $K \subseteq E$ tal que ninguna pareja de aristas en K comparte un vértice en común, es decir:

$$e_1 \cap e_2 = \emptyset, \quad \forall e_1, e_2 \in K,\ e_1 \neq e_2$$

Desde una perspectiva algebraica y de programación matemática, un emparejamiento puede representarse mediante un vector binario de decisión $\mathbf{x} \in \{0,1\}^{|E|}$, donde cada componente $x_e = 1$ si la arista $e \in E$ se incluye en el emparejamiento y $x_e = 0$ en caso contrario. La condición de no adyacencia equivale a imponer que, para cada vértice $v \in V$, la suma de variables incidentes no supere la unidad:

$$\sum_{e \in \delta(v)} x_e \leq 1, \quad \forall v \in V$$

donde $\delta(v)$ denota el conjunto de aristas incidentes en el vértice v. Esta estructura muestra que el conjunto de emparejamientos es hereditario, propiedad clave que permite analizar subconjuntos de soluciones válidas.

Proposición: Hereditariedad de los emparejamientos

Dado un grafo $G = (V, E)$ y un emparejamiento $K \subseteq E$, cualquier subconjunto $K' \subseteq K$ es también un emparejamiento de G.
Demostración: Si K no contiene aristas con extremos compartidos, la eliminación de una o más aristas para formar K' preserva trivialmente la ausencia de aristas adyacentes. ■

La propiedad de hereditariedad implica que los emparejamientos forman una familia de conjuntos independientes (un complejo simplicial o sistema de independencia). Sobre esta familia, el objetivo primordial consiste en encontrar la solución de mayor tamaño.

Definición: Problema de emparejamiento de máximo cardinal

Dado un grafo no dirigido $G = (V, E)$, el **problema de emparejamiento de máximo cardinal** consiste en determinar un emparejamiento $K \subseteq E$ que contenga el mayor número posible de aristas, es decir, que maximice $|K|$.

Para caracterizar la calidad de una solución y guiar los algoritmos de búsqueda, resulta esencial clasificar los vértices del grafo según su pertenencia a las aristas del emparejamiento.

Definición: Vértices saturados y vértices expuestos

Dado un grafo $G = (V, E)$ y un emparejamiento $K \subseteq E$:

- Un vértice $x \in V$ está **saturado** (o emparejado) por K si existe alguna arista $\{x, y\} \in K$ incidente en x.
- Un vértice $x \in V$ está **expuesto** (o no saturado, o libre) si ninguna arista de K incide en x.

Puesto que cada arista de K satura exactamente a 2 vértices distintos y ningún vértice puede estar saturado por dos aristas a la vez, el número total de vértices saturados por un emparejamiento K es exactamente $2|K|$, y el número de vértices expuestos es $|V| - 2|K|$.

Esta relación de conservación entre aristas y vértices conduce a una cota superior natural: en cualquier grafo con $n = |V|$ vértices, el tamaño de cualquier emparejamiento está acotado por $|K| \leq \lfloor n/2 \rfloor$. En consecuencia, cuando el número de vértices libres se reduce al mínimo posible, la búsqueda algorítmica concluye de forma inmediata.

Proposición: Condición de parada por cardinalidad de expuestos

Dado un grafo $G = (V, E)$ con $n = |V|$ vértices y un emparejamiento $K \subseteq E$, si el número de vértices no saturados (expuestos) es 0 o 1, entonces K es un **emparejamiento de máximo cardinal**.
Demostración: Cualquier emparejamiento adicional requeriría seleccionar al menos una arista no adyacente a las existentes, lo que exige disponer de al menos 2 vértices no saturados disponibles. Al haber como máximo 1 vértice libre, no es posible añadir ninguna arista disjunta ni aumentar el cardinal. ■

Es fundamental distinguir conceptualmente entre un **emparejamiento maximal** (por inclusión) y un **emparejamiento de máximo cardinal** (óptimo global):

- **Emparejamiento Maximal**: Es un emparejamiento al que no se le puede añadir ninguna arista adicional de E sin violar la condición de disyunción de vértices. Cualquier algoritmo codicioso (*greedy*) encuentra un emparejamiento maximal rápidamente, pero este puede quedar atrapado en un óptimo local de cardinal estrictamente inferior al óptimo global (como ocurría en el emparejamiento K_1 del problema de la RAF).
- **Emparejamiento de Máximo Cardinal**: Es un emparejamiento que alcanza el máximo valor absoluto de $|K|$ entre todos los emparejamientos posibles del grafo. Para transformar un emparejamiento maximal subóptimo en uno de máximo cardinal, es indispensable reorganizar y reasignar parejas a lo largo del grafo.

Definición: Emparejamiento perfecto

Dado un grafo $G = (V, E)$ con $n = |V|$ vértices, un emparejamiento $K \subseteq E$ se dice **perfecto** (o 1-factor) si satura a todos los vértices del grafo ($|V| - 2|K| = 0$). En tal caso, el tamaño del emparejamiento es exactamente:

$$|K| = \frac{n}{2}$$

lo que requiere necesariamente que el orden del grafo n sea un número par.

9.2. Resolución mediante cadenas alternantes e incrementales

Para resolver de forma constructiva el problema de emparejamiento de máximo cardinal cuando existen dos o más vértices expuestos, es necesario analizar cómo modificar un emparejamiento existente para incrementar su tamaño. En lugar de reconstruir el emparejamiento desde cero, los métodos combinatorios emplean un principio de mejora local iterativa basado en **cadenas alternantes de aristas**, que actúan como cascadas de reasignación de parejas.

9.2.1. Cadenas alternantes, cadenas incrementales y transferencias

La intuición física tras una cadena alternante reside en la posibilidad de intercambiar las asignaciones actuales por nuevas parejas compatibles. Al alternar aristas no emparejadas con aristas ya emparejadas, cualquier cambio en una arista desencadena una reacción en cadena que exige reajustar las aristas adyacentes.

Definición: Cadena alternante e incremental

Dado un grafo $G = (V, E)$ y un emparejamiento $K \subseteq E$:

- Una **cadena alternante** es una cadena simple $\mu = (v_1, v_2, \dots, v_k)$ cuyas aristas pertenecen y no pertenecen alternativamente al emparejamiento K (es decir, las aristas alternan entre K y $E \setminus K$).
- Una **cadena incremental** (o cadena de aumento) $\mu[x, y]$ con $x \neq y$ es una cadena alternante cuyos dos vértices extremos x e y son **vértices expuestos** (no saturados) respecto de K.

Las cadenas incrementales poseen propiedades algebraicas y combinatorias muy definidas:

1. **Longitud Impar de Aristas**: Toda cadena incremental contiene un **número impar de aristas**. Al comenzar y terminar en vértices no saturados, sus aristas primera y última deben pertenecer obligatoriamente a $E \setminus K$.
2. **Balance de Aristas**: En una cadena incremental con $2k + 1$ aristas, exactamente $k + 1$ aristas pertenecen a $E \setminus K$ y k aristas pertenecen a K. El número de aristas fuera del emparejamiento supera siempre en una unidad al número de aristas dentro de K.

Esta asimetría en el número de aristas es la que permite incrementar el tamaño global del emparejamiento mediante la operación de transferencia.

Definición: Operación de transferencia

Dado un emparejamiento $K \subseteq E$ y una cadena incremental $\mu[x, y]$ respecto de K, la **transferencia** consiste en permutar la pertenencia de las aristas a lo largo de la cadena, sustituyendo las aristas de $\mu \cap K$ por las aristas de $\mu \setminus K$.
Algebraicamente, el nuevo emparejamiento K' se obtiene mediante la **diferencia simétrica** ($\triangle$):

$$K' = K \triangle \mu[x, y] = (K \setminus \mu) \cup (\mu \setminus K)$$

El emparejamiento resultante satisface estrictamente:

$$|K'| = |K| + 1$$

La operación de transferencia preserva de manera rigurosa la validez del emparejamiento: en los vértices interiores de la cadena μ, la arista eliminada de K es reemplazada exactamente por una nueva arista incidente en dicho vértice, manteniendo su grado saturado en 1. En los dos vértices extremos x e y, que antes estaban expuestos, la incorporación de las aristas extremas pasa su estado a saturado ($sat = 1$), incrementando el cardinal total en una unidad sin alterar el estado del resto del grafo.

Ejemplo: Aplicación de una transferencia en un grafo de 6 nodos

Considérese el grafo de 6 vértices $V = \{1, 2, 3, 4, 5, 6\}$ y 9 aristas $E = \{\{1, 2\}, \{1, 3\}, \{2, 3\}, \{2, 5\}, \{3, 4\}, \{3, 6\}, \{4, 5\}, \{4, 6\}, \{5, 6\}\}$ presentado en la Figura 9.2. Partimos del emparejamiento inicial $K = \{\{2, 3\}, \{5, 6\}\}$ con $|K| = 2$. Evaluamos la red:

1. **Identificación de Vértices Expuestos**: Los vértices $2, 3, 5, 6$ están saturados por K. Los vértices 1 y 4 son vértices expuestos ($1, 4 \notin V(K)$).
2. **Detección de la Cadena Incremental**: La trayectoria $\mu = (1, 2, 3, 4)$ une los vértices expuestos 1 y 4. Sus aristas son:
   - $\{1, 2\} \notin K$ (fuera de K)
   - $\{2, 3\} \in K$ (dentro de K)
   - $\{3, 4\} \notin K$ (fuera de K) La cadena alterna aristas de $E \setminus K$ y K, y tiene longitud 3 (impar).
3. **Ejecución de la Transferencia**: Calculamos la diferencia simétrica $K' = K \triangle \mu$:
   - Eliminamos la arista $\{2, 3\} \in K$.
   - Incorporamos las aristas $\{1, 2\}$ y $\{3, 4\}$.
   - Mantenemos la arista ajena a la cadena $\{5, 6\}$.

   Obtenemos el nuevo emparejamiento:

$$K' = \{\{1, 2\}, \{3, 4\}, \{5, 6\}\}$$

   El cardinal aumenta de $|K| = 2$ a $|K'| = 3$. Dado que $|K'| = 6/2 = 3$, K' satura a todos los vértices del grafo y constituye un **emparejamiento perfecto**.

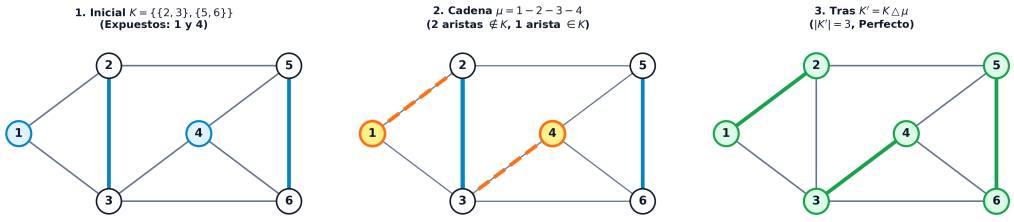

Figura 9.2: Proceso de transferencia: estado inicial K (izquierda), identificación de la cadena incremental (centro) y nuevo emparejamiento K' (derecha)

9.2.2. Teorema de caracterización de Berge y descomposición de componentes

La relación directa entre las cadenas incrementales y el aumento del cardinal conduce a la caracterización fundamental de optimalidad descubierta por Claude Berge en 1957 (Berge 1957). Para demostrar este teorema formalmente, es necesario caracterizar previamente la estructura topológica que surge al superponer dos emparejamientos distintos sobre un mismo grafo.

Al calcular la diferencia simétrica $K_1 \triangle K_2$ entre dos emparejamientos K_1 y K_2, estamos aislando el **grafo de discrepancias** entre ambas soluciones.

Lema: Estructura del grafo diferencia simétrica

Dados dos emparejamientos cualesquiera K_1 y K_2 en un grafo simple $G = (V, E)$, el subgrafo parcial generado por la diferencia simétrica $G' = (V, K_1 \triangle K_2)$ está compuesto exclusivamente por componentes conexas disjuntas que pertenecen a alguno de los siguientes tres tipos:

1. **Vértices aislados** (grado 0).
2. **Ciclos elementales alternantes** de longitud estrictamente par (cuyas aristas alternan entre K_1 y K_2).
3. **Cadenas elementales alternantes** de longitud par o impar (cuyas aristas alternan entre K_1 y K_2).

Demostración: Analicemos el grado máximo que puede tener cualquier vértice $v \in V$ en el grafo diferencia $G' = (V, K_1 \triangle K_2)$:

- **Caso 1 (Vértice no saturado por K_1 ni por K_2)**: Ninguna arista de $K_1 \cup K_2$ incide en v. Por tanto, el grado de v en G' es $d_{G'}(v) = 0$ (vértice aislado).
- **Caso 2 (Vértice saturado por K_1 y por K_2 con la misma arista)**: Sea $e \in K_1 \cap K_2$ la arista incidente. Por definición de diferencia simétrica, $e \notin K_1 \triangle K_2$. Ninguna otra arista de K_1 ni de K_2 incide en v, luego $d_{G'}(v) = 0$ (vértice aislado).
- **Caso 3 (Vértice saturado sólo por uno de los dos emparejamientos)**: Si v está saturado por $e_1 \in K_1$ y ninguna arista de K_2 incide en v (o viceversa), entonces exactamente una arista incidente pertenece a $K_1 \triangle K_2$, por lo que $d_{G'}(v) = 1$. Estos vértices corresponden exclusivamente a los extremos de cadenas alternantes.
- **Caso 4 (Vértice saturado por ambos emparejamientos con aristas distintas)**: Si $e_1 \in K_1$ y $e_2 \in K_2$ con $e_1 \neq e_2$ inciden en v, ambas aristas pertenecen a $K_1 \triangle K_2$. Al no poder incidir más de una arista de cada emparejamiento en v, el grado es exactamente $d_{G'}(v) = 2$.

Puesto que ningún vértice en G' tiene grado superior a 2 ($d_{G'}(v) \leq 2, \forall v \in V$), todo grafo de grado máximo 2 se descompone de forma unívoca en vértices aislados, cadenas simples y ciclos cerrados. Además, como las aristas deben alternar estrictamente entre K_1 y K_2, los ciclos cerrados deben cerrarse alternando aristas de ambos conjuntos, lo que exige obligatoriamente un número par de aristas. ■

Como se ilustra en la Figura 9.3 y en la Figura 9.4, el lema anterior permite descomponer cualquier par de soluciones en piezas estructurales elementales independientes sin ramificaciones complejas.

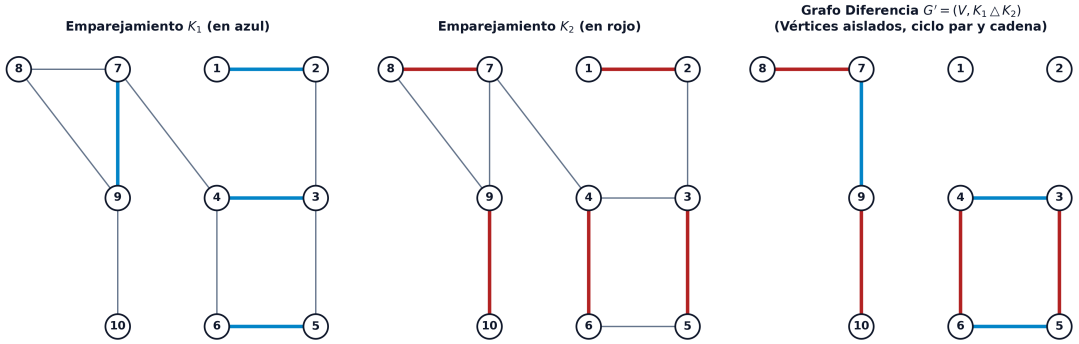

Figura 9.3: Descomposición del grafo diferencia simétrica $G' = (V, K_1 \triangle K_2)$ en vértices aislados, ciclos pares y cadenas alternantes

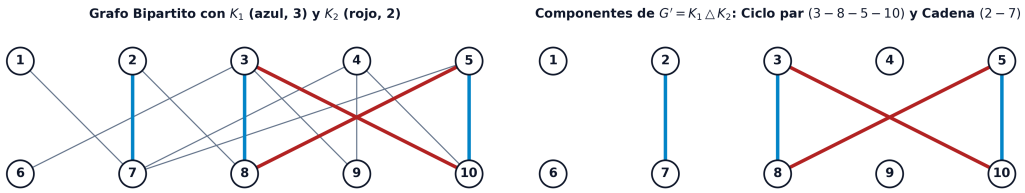

Figura 9.4: Evaluación de la diferencia simétrica $K_1 \triangle K_2$ sobre un grafo bipartito de 10 vértices

A partir del lema de descomposición de la diferencia simétrica, podemos demostrar de forma rigurosa el Teorema de Berge.

! Teorema de caracterización de Berge (1957)

Dado un grafo $G = (V, E)$, un emparejamiento $K \subseteq E$ es de **máximo cardinal** si y solo si el grafo G **no contiene ninguna cadena incremental** con respecto a K.
Demostración: Demostramos la doble implicación:

- **Necesidad ($\Longrightarrow$)**: Razonamos por reducción al absurdo. Supongamos que K es de máximo cardinal y que existe una cadena incremental $\mu[x, y]$ respecto de K. Aplicando la operación de transferencia, el nuevo conjunto $K' = K \triangle \mu[x, y]$ es un emparejamiento válido de G con cardinal $|K'| = |K| + 1 > |K|$, lo que contradice la hipótesis de que K era de cardinal máximo.
- **Suficiencia ($\Longleftarrow$)**: Supongamos que K no contiene ninguna cadena incremental respecto de sí mismo. Sea K^* un emparejamiento de máximo cardinal en G (cuya

existencia está garantizada al ser el conjunto de aristas finito). Consideramos el subgrafo diferencia simétrica $G' = (V, K \triangle K^*)$.

Por el Lema de Descomposición, G' se compone únicamente de vértices aislados, ciclos pares alternantes y cadenas alternantes:

1. Los vértices aislados contienen 0 aristas de K y 0 de K^*.
2. Cada ciclo alternante contiene exactamente el mismo número de aristas de K que de K^* (al tener longitud par).
3. En cada cadena alternante de longitud par, el número de aristas de K iguala al de K^*.
4. En cada cadena alternante de longitud impar, las aristas alternan comenzando y terminando con el mismo emparejamiento. Si alguna cadena impar tuviera más aristas de K^* que de K, sus extremos serían vértices no saturados por K, lo que convertiría a dicha cadena en una **cadena incremental respecto de** K. Pero por hipótesis, K no admite cadenas incrementales. Por tanto, ninguna cadena impar puede tener más aristas de K^* que de K.

Sumando el número de aristas en todas las componentes conexas de G', se deduce que $|K^*| \leq |K|$. Dado que por definición de máximo $|K| \leq |K^*|$, concluimos que $|K| = |K^*|$, lo que certifica que K es de máximo cardinal. ■

El Teorema de Berge constituye la piedra angular de la teoría de emparejamientos y juega un papel análogo al **Teorema de Flujo Máximo - Corte Mínimo de Ford-Fulkerson** en redes de transporte (donde la ausencia de caminos de aumento en la red residual certifica el flujo máximo, como se vio en el Capítulo 8) y al criterio de parada del **método del Símplex** en Programación Lineal (donde la no negatividad de los costes reducidos certifica la optimalidad global, como se demostró en el Capítulo 3). En todos estos casos, una condición de optimalidad local determinista certifica la optimalidad global absoluta.

9.3. Algoritmo del árbol alternante y contracción de flores (Edmonds)

El Teorema de Berge reduce el problema de optimización a una tarea constructiva: buscar de forma sistemática cadenas incrementales en el grafo o certificar formalmente que no existen. Para realizar esta búsqueda de manera determinista y eficiente, se utiliza la estructura jerárquica del **árbol alternante**.

9.3.1. Estructura del bosque y árbol alternante

Dado un emparejamiento K y un vértice expuesto, el objetivo algorítmico consiste en explorar caminos alternantes en busca de una cadena incremental de longitud impar que termine en otro vértice expuesto. Para formular este proceso, identificamos el estado de cada vértice $x \in V$ mediante una **variable indicadora de saturación**:

$$sat(x) = \begin{cases} 1, & \text{si } x \text{ está saturado por } K \text{ (existe } e \in K \text{ incidente en } x) \\ 0, & \text{si } x \text{ es un vértice expuesto o no saturado} \end{cases}$$

> **i** Nota: Bipartición del subgrafo de aristas del emparejamiento
>
> A partir de cualquier emparejamiento K sobre un grafo general $G = (V, E)$ (sea este originalmente bipartito o no), el subgrafo parcial $G_K = (V, K)$ formado exclusivamente por las aristas de K es siempre un **grafo bipartito**. En efecto, al ser las aristas de K disjuntas en vértices, cada arista forma una componente conexa K_2 independiente, cuyos dos extremos pueden asignarse a conjuntos disjuntos de una bipartición.

> **i** Definición: Árbol alternante y bosque alternante
>
> Dados un grafo $G = (V, E)$ y un emparejamiento $K \subseteq E$, un **árbol alternante** es un subgrafo parcial $H = (W, T)$ con $W \subseteq V$ y $T \subseteq E$ que satisface las siguientes tres propiedades fundamentales:
>
> 1. H es un árbol (subgrafo conexo y sin ciclos).
> 2. Existe un único vértice distinguido $r \in W$, denominado **raíz del árbol alternante**, que es un vértice expuesto respecto del emparejamiento K ($sat(r) = 0$).
> 3. Cualquier cadena elemental en H que une un vértice cualquiera $w \in W$ con la raíz r es una **cadena alternante**.
>
> Un conjunto de árboles alternantes disjuntos cuyas raíces son vértices expuestos de G constituye un **bosque alternante**. Cada árbol se denota unívocamente a partir de su raíz mediante $H(r) = (W(r), T(r))$.

Para la gestión y navegación computacional del bosque alternante, se emplea el **vector de antecesores o vector de padres** $\mathbf{p} = (p(1), p(2), \ldots, p(n))^T \in V^n$. Cada raíz $r \in R$ de un árbol alternante se identifica de forma unívoca por la autorreferencia $p(r) = r$. La única cadena alternante que conecta cualquier vértice $w \in W(r)$ con su raíz r se recupera de manera determinista encadenando las referencias del vector $\mathbf{p}$:

$$w \longleftrightarrow p(w) \longleftrightarrow p(p(w)) \longleftrightarrow \cdots \longleftrightarrow p(\cdots(p(w))\cdots) \longleftrightarrow r$$

Ejemplo: Bosque alternante y verificación de maximalidad en grafo de 6 nodos

Considérese el grafo de 6 vértices $V = \{1, 2, 3, 4, 5, 6\}$ y aristas $E = \{\{1, 4\}, \{1, 5\}, \{1, 6\}, \{2, 5\}, \{3, 5\}\}$ representado en la Figura 9.5, con el emparejamiento inicial $K = \{\{1, 4\}, \{2, 5\}\}$.

1. **Identificación de Raíces**: Los vértices saturados son $\{1, 2, 4, 5\}$ ($sat = 1$), mientras que los vértices expuestos son $\{3, 6\}$ ($sat = 0$). Por tanto, el conjunto de raíces del bosque alternante es $R = \{3, 6\}$.

2. **Construcción de los Árboles Alternantes**:

   - Árbol $H(3) = (W(3), T(3))$ con raíz $r = 3$:

   $$W(3) = \{2, 3, 5\}, \quad T(3) = \{\{3, 5\}, \{2, 5\}\}$$

   - Árbol $H(6) = (W(6), T(6))$ con raíz $r = 6$:

   $$W(6) = \{1, 4, 6\}, \quad T(6) = \{\{6, 1\}, \{1, 4\}\}$$

3. **Vector de Padres**: El vector de antecesores queda determinado por:

$$\mathbf{p}^T = (6, 5, 3, 1, 3, 6)$$

4. **Conclusión de Optimalidad**: Desde los árboles alternantes no es posible alcanzar ningún otro vértice expuesto mediante aristas alternantes. Al no existir cadenas incrementales, el Teorema de Berge certifica que K es un **emparejamiento de máximo cardinal** ($|K| = 2$).

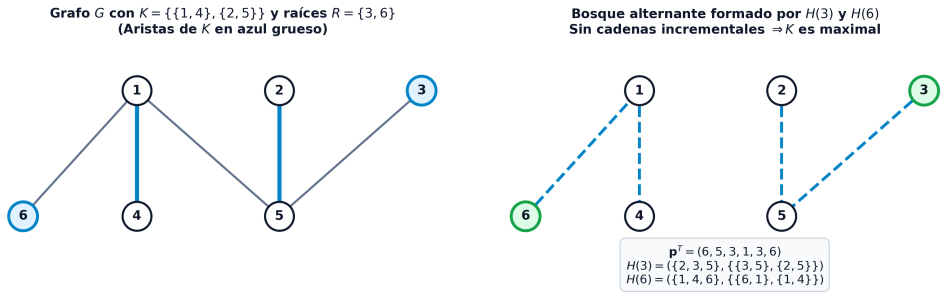

Figura 9.5: Bosque alternante en grafo de 6 nodos: configuración inicial de K (izq.) y descomposición en árboles $H(3)$ y $H(6)$ caracterizados por el vector $\mathbf{p}$ (der.)

Cuando la exploración del árbol alternante sí alcanza otros vértices expuestos antes de agotarse, se descubre al menos una cadena incremental que permite aplicar la transferencia y aumentar

el cardinal del emparejamiento, como se detalla en el siguiente ejemplo:

Ejemplo: Detección de cadenas incrementales y transferencia en grafo bipartito de 10 nodos

Considérese el grafo bipartito de 10 vértices $V = \{1, \dots, 10\}$ ilustrado en la Figura 9.6, con el emparejamiento inicial $K_1 = \{\{2,7\}, \{3,8\}, \{5,10\}\}$ de cardinal 3.

1. **Inicialización del Árbol con Raíz Expuesta**: El nodo 1 es un vértice expuesto ($sat(1) = 0$). Tomamos $R = \{1\}$ como raíz del árbol alternante.

2. **Vector de Padres**: Tras explorar las aristas del grafo bipartito desde la raíz 1 (alcanzando el camino alternante $1 \to 7 \to 2 \to 8 \to 3$ y, desde el vértice 3, ramificando hacia los nodos 6, 9 y la rama $10 \to 5$), el vector de antecesores obtenido es:
$$\mathbf{p}^T = (1, 7, 8, 0, 10, 3, 1, 2, 3, 3)$$
donde $p(4) = 0$ indica que el nodo 4 no es alcanzado por el árbol, mientras que $p(10) = 3$ y $p(5) = 10$ caracterizan la exploración de la rama saturada $\{5, 10\}$.

3. **Identificación de Cadenas Incrementales**: Los vértices 6 y 9 son vértices expuestos que han sido alcanzados por el árbol. Desenrollando sus antecesores mediante $\mathbf{p}$, obtenemos dos cadenas incrementales que conectan con la raíz 1:
$$6 \longleftrightarrow p(6) = 3 \longleftrightarrow p(3) = 8 \longleftrightarrow p(8) = 2 \longleftrightarrow p(2) = 7 \longleftrightarrow p(7) = 1$$
$$9 \longleftrightarrow p(9) = 3 \longleftrightarrow p(3) = 8 \longleftrightarrow p(8) = 2 \longleftrightarrow p(2) = 7 \longleftrightarrow p(7) = 1$$

4. **Ejecución de la Transferencia**: Aplicando la transferencia por la cadena incremental que parte del nodo expuesto 6:
$$\mu = (6, 3, 8, 2, 7, 1)$$
Calculamos la diferencia simétrica $K_1' = K_1 \triangle \mu$:
$$K_1' = \{\{6,3\}, \{8,2\}, \{7,1\}, \{5,10\}\}$$
El cardinal resultante aumenta a $|K_1'| = 4$, logrando un nuevo emparejamiento con una arista adicional.

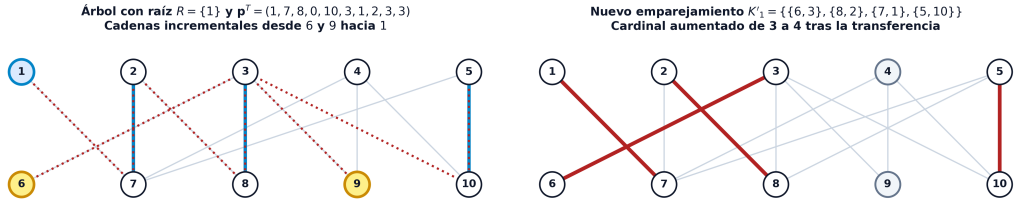

Figura 9.6: Búsqueda mediante árbol alternante en grafo de 10 nodos: identificación de cadenas incrementales desde los nodos expuestos 6 y 9 (izq.) y nuevo emparejamiento aumentado K'_1 tras la transferencia (der.)

9.3.2. El desafío de los ciclos impares y la contracción de flores de Edmonds

En grafos bipartitos, todos los ciclos tienen longitud par, lo que garantiza que la búsqueda mediante árboles alternantes siempre progresa de forma directa hacia nuevos vértices o detecta cadenas incrementales. Sin embargo, en grafos generales no bipartitos, la presencia de **ciclos de longitud impar** (denominados *flores* o *blossoms*) introduce una dificultad estructural profunda.

Como se ilustra en la Figura 9.7, en un ciclo impar de $2k + 1$ vértices (por ejemplo, el ciclo de 5 vértices C_5), el emparejamiento maximal dentro del ciclo puede saturar como máximo a $2k$ vértices mediante k aristas, dejando exactamente **un vértice expuesto**. La propiedad algebraica y combinatoria clave de la flor es que **cualquiera de los $2k + 1$ vértices del ciclo puede elegirse libremente como el vértice expuesto**, mientras los restantes $2k$ vértices quedan completamente saturados por parejas disjuntas.

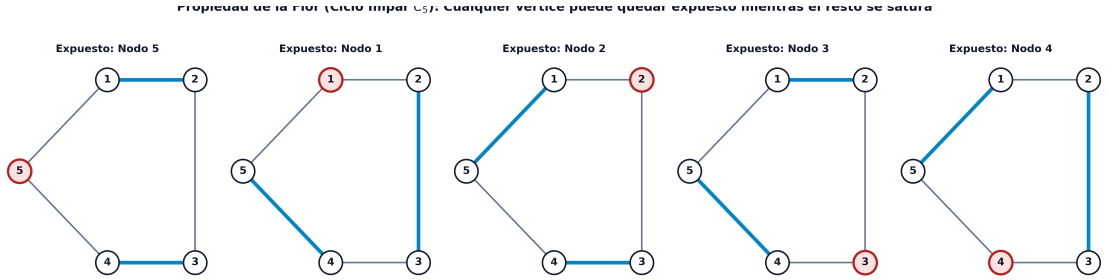

Figura 9.7: Propiedad de la flor en un ciclo impar C_5: cualquiera de sus 5 vértices puede quedar expuesto mientras los 4 restantes quedan saturados

Para sortear este obstáculo sin explorar factorialmente todas las posibles asignaciones internas del ciclo, Jack Edmonds introdujo en 1965 la técnica de **contracción de flores**: comprimir todo el ciclo impar en un único pseudovértice (*supernodo*) w, resolver el emparejamiento en el

grafo comprimido, y descontraer (*expandir*) posteriormente el ciclo ajustando internamente las aristas (Edmonds 1965).

Definición: Contracción de un grafo (Grafo comprimido)

Dado un grafo no dirigido $G = (V, E)$ y un subconjunto de vértices $W \subset V$ correspondiente a un ciclo impar, se define el **grafo comprimido** G/W como:

$$G/W = ((V \setminus W) \cup \{w\},\ E/W)$$

donde w es un nuevo pseudovértice representativo y el conjunto de aristas E/W se define como:

$$E/W = \{\{i,j\} \in E \mid i,j \notin W\} \cup \{\{w,j\} \mid \exists i \in W \text{ tal que } \{i,j\} \in E,\ j \notin W\}$$

El siguiente resultado teórico, formulado por Jack Edmonds, garantiza que la contracción de un ciclo impar preserva la capacidad de reconstruir un emparejamiento válido sobre el grafo original mediante una descompresión determinista.

Teorema: Contracción de ciclos impares de Edmonds (1965)

Sea $G = (V, E)$ un grafo, $W \subset V$ un subconjunto de vértices asociado a un ciclo de longitud impar, y sea K_1 un emparejamiento en el grafo comprimido G/W.
Entonces, existe un emparejamiento K_W en el subgrafo generado por W tal que:

$$K = K_1 \cup K_W$$

es un emparejamiento válido de G.
Demostración: Al ser W un ciclo de longitud impar $|W| = 2k+1$, el emparejamiento maximal K_W dentro de W contiene k aristas y deja exactamente un vértice $v \in W$ sin saturar. Distinguimos dos situaciones posibles sobre el pseudovértice w en el emparejamiento K_1:

1. Si w está expuesto en K_1, se selecciona cualquier emparejamiento K_W de k aristas en W. El único nodo de W que queda sin saturar actúa como vértice expuesto en G, y ningún arco de K_1 interfiere con W, por lo que $K = K_1 \cup K_W$ es un emparejamiento válido.
2. Si w está saturado en K_1 por una arista $\{w,j\} \in K_1$, dicha arista proviene originalmente de una arista $\{i,j\} \in E$ con $i \in W$ y $j \notin W$. En tal caso, seleccionamos en W el emparejamiento K_W de k aristas que deja precisamente al vértice i como el único nodo no saturado de W. De este modo, la arista $\{i,j\}$ satura a i desde el exterior, y las k aristas de K_W saturan a los restantes $2k$ vértices de W. Como ninguna otra arista de K_1 incide en W, $K = (K_1 \setminus \{\{w,j\}\}) \cup \{\{i,j\}\} \cup K_W$ es un emparejamiento válido en G. ■

Nota: Reglas pedagógicas de descompresión de flores

Las claves operativas de la contracción de flores se resumen en tres principios:

- **Existencia de vértice expuesto**: Al ser W un ciclo impar, siempre queda exactamente un vértice no saturado en W respecto de K_W.
- **Libertad de selección del vértice expuesto**: Siempre es posible elegir de forma determinista qué vértice del ciclo queda no saturado.
- **Alineación con la arista exterior**: Si el pseudovértice w está saturado en K_1, se deja como no saturado en el ciclo precisamente el vértice $i \in W$ incidente en la arista exterior que satura a w, asegurando que ningún vértice del ciclo quede saturado dos veces.

A pesar de la elegancia del Teorema de Edmonds, la contracción de flores debe gestionarse con extrema cautela dentro de un esquema algorítmico formal, ya que operar directamente con maximalidades en el grafo comprimido puede conducir a soluciones subóptimas:

Advertencia: Maximalidad en grafos comprimidos

Que un emparejamiento K_1 sea **maximal** en el grafo comprimido G/W no implica necesariamente que el emparejamiento extendido K sea de **máximo cardinal** en el grafo original G.
Como se ilustra en la Figura 9.8, considérese un grafo con un ciclo impar $\{1, 2, 3\}$ y tres aristas exteriores $\{\{1, 6\}, \{2, 4\}, \{3, 5\}\}$. Al comprimir el ciclo $\{1, 2, 3\}$ en el pseudonodo w, el grafo comprimido G/W contiene las aristas $\{\{w, 6\}, \{w, 4\}, \{w, 5\}\}$. El emparejamiento $K_1 = \{\{w, 6\}\}$ es maximal en G/W (no puede añadirse ninguna otra arista disjunta), pero produce en G un emparejamiento de cardinal 2 ($K = \{\{1, 6\}, \{2, 3\}\}$), cuando el grafo original admite el emparejamiento de cardinal 3: $K^* = \{\{1, 6\}, \{2, 4\}, \{3, 5\}\}$. Por esta razón, la contracción debe ejecutarse guiada estrictamente por la jerarquía de niveles del árbol alternante de Edmonds.

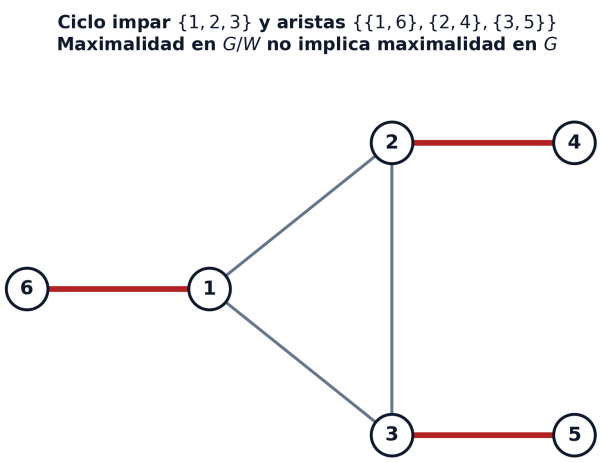

Figura 9.8: Contraejemplo de maximalidad: grafo con ciclo impar $\{1, 2, 3\}$ y emparejamiento óptimo de cardinal 3

9.3.3. Algoritmo de Flor de Edmonds: Esquema y resolución paso a paso

Para aplicar y estructurar sistemáticamente el procedimiento de exploración del árbol alternante en el **Paso C** del algoritmo de Edmonds, se definen los siguientes elementos clave:

- **Árbol alternante** (Y, T): Subgrafo donde $Y \subseteq V$ representa el conjunto de vértices explorados por el árbol y $T \subseteq E$ el conjunto de aristas que forman la estructura del árbol.
- **Conjunto de vértices pares ($Y^0 \subset Y$)**: Vértices de Y conectados con la raíz del árbol (incluyendo a la propia raíz a distancia 0) mediante una cadena alternante de longitud par.
- **Propiedad estructural de las hojas**: Todas las hojas (extremos terminales) del árbol alternante deben ser obligatoriamente vértices pares (Y^0).

Como se ilustra en la Figura 9.9, considérese el árbol alternante con vértices $Y = \{0, 1, 2, 3, 4, 5, 6, 7, 8\}$, cuya raíz es el vértice expuesto $r = 0$. Los niveles se organizan alternadamente:

- **Nivel 0 (Raíz)**: Vértice $0 \in Y^0$ (par, en rojo).
- **Nivel 1 (Impar)**: Vértices $\{1, 3\}$ (conectados por aristas fuera de K).
- **Nivel 2 (Par)**: Vértices $\{2, 4\} \subset Y^0$ (conectados por aristas dentro de K, en rojo).
- **Nivel 3 (Impar)**: Vértices $\{5, 7\}$ (conectados por aristas fuera de K).
- **Nivel 4 (Par)**: Vértices $\{6, 8\} \subset Y^0$ (conectados por aristas dentro de K, en rojo).

En este árbol, el conjunto de vértices pares es exactamente:

$$Y^0 = \{0, 2, 4, 6, 8\}$$

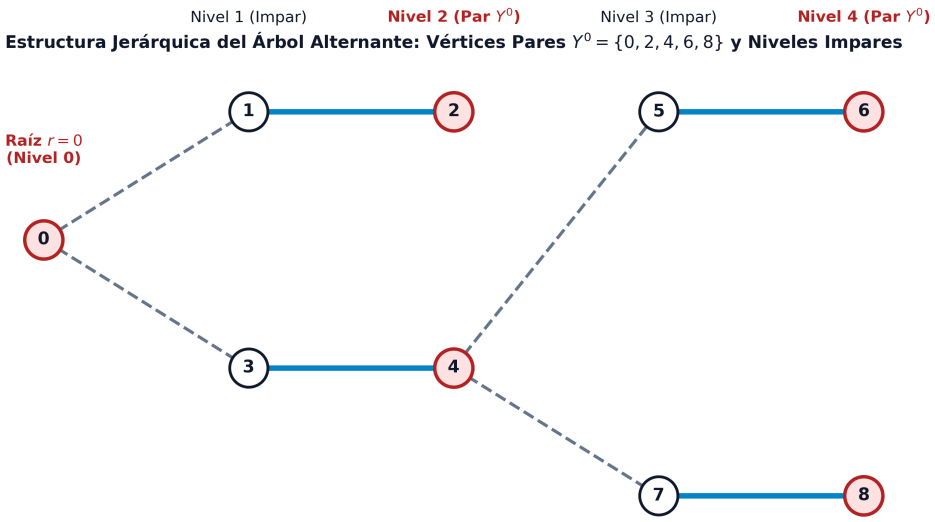

Figura 9.9: Estructura jerárquica del árbol alternante con $Y = \{0, \ldots, 8\}$ destacando los vértices pares $Y^0 = \{0, 2, 4, 6, 8\}$ (en rojo) y los niveles impares

A partir de los vértices pares Y^0, la exploración del árbol alternante se rige por las siguientes reglas operativas:

1. **Detección de Ciclos Impares (Flores)**: Si en el grafo original existen dos vértices de Y^0 conectados directamente por una arista $\{i, j\} \in E$, se ha formado un **ciclo de longitud impar** (flor). Dicho ciclo debe contraerse en un supernodo w para continuar la búsqueda.
2. **Expansión del Árbol desde Y^0**: Si no se detectan ciclos impares entre nodos pares, se examinan las aristas incidentes en vértices de Y^0 hacia nodos exteriores al árbol ($j \notin Y$):
   - **Hacia vértices adyacentes no saturados ($sat(j) = 0$)**: Se detecta una **cadena alternante incremental** que une la raíz con j, permitiendo aumentar de inmediato el cardinal del emparejamiento.
   - **Hacia vértices adyacentes saturados ($sat(j) = 1$)**: Si j está saturado por una arista $\{j, k\} \in K$, se añade el par de aristas al árbol, incorporando el vértice k al conjunto de vértices pares Y^0.

El algoritmo completo de Edmonds se sintetiza en el siguiente esquema formal:

Esquema: Algoritmo de Flor de Edmonds para Emparejamiento Máximo

- **Paso A (Inicialización)**: Encontrar un emparejamiento inicial factible K en G (por ejemplo, el emparejamiento trivial $K = \emptyset$).
- **Paso B (Condición de parada elemental)**: Si el número de vértices no saturados por K es 0 o 1, **PARAR**: K es de máximo cardinal. En caso contrario, ir al **Paso C**.
- **Paso C (Construcción del Árbol Alternante)**:
  - **Paso C.1**: Seleccionar un vértice expuesto $i_0 \in V$ $(sat(i_0) = 0)$. Inicializar el árbol con $Y = Y^0 = \{i_0\}$ y $T = \emptyset$.
  - **Paso C.2 (Exploración desde vértices pares Y^0)**:
    - **Caso 1 (Detección de Flor / Ciclo Impar)**: Si existen dos vértices $i, j \in Y^0$ tales que $\{i, j\} \in E$, se detecta un ciclo impar. Contraer el ciclo definiendo el grafo comprimido $G \leftarrow G/W$, actualizar el árbol $(Y \leftarrow (Y \setminus W) \cup \{w\}$, $Y^0 \leftarrow (Y^0 \setminus W) \cup \{w\})$ y volver al **Paso C.2**.
    - **Caso 2 (Extensión del Árbol)**: Si existe $i \in Y^0$ y un vértice adyacente saturado $j \notin Y$ con $\{i, j\} \in E$ y $\{j, k\} \in K$, añadir las aristas $\{i, j\}$ y $\{j, k\}$ al árbol: $Y \leftarrow Y \cup \{j, k\}$, $Y^0 \leftarrow Y^0 \cup \{k\}$, $T \leftarrow T \cup \{\{i, j\}, \{j, k\}\}$ y volver al **Paso C.2**.
    - **Caso 3 (Detección de Cadena Incremental)**: Si existe $i \in Y^0$ y un vértice adyacente expuesto $j \notin Y$ $(sat(j) = 0)$ con $\{i, j\} \in E$, se ha detectado una **cadena incremental** entre la raíz i_0 y j. Realizar la transferencia $K \leftarrow K \triangle \mu$, descontraer todas las flores activas reconstruyendo el emparejamiento en el grafo original, y volver al **Paso B**.
    - **Caso 4 (Árbol Bloqueado / Húngaro)**: Si no es posible aplicar ninguno de los casos anteriores desde los vértices de Y^0, no existe ninguna cadena incremental conectada a i_0. Fijar i_0 como no aumentable. Si quedan otros vértices expuestos sin explorar, inicializar un nuevo árbol (Paso C.1); en caso contrario, **PARAR**: K es de **máximo cardinal**.

Ejemplo: Traza completa del Algoritmo de Edmonds con contracciones sucesivas

Considérese el grafo de 8 vértices $V = \{1, 2, 3, 4, 5, 6, 7, 8\}$ ilustrado en la **?@fig-edmonds-animado**, cuyas aristas son:

$$E = \{\{6, 7\}, \{7, 8\}, \{1, 2\}, \{2, 3\}, \{3, 4\}, \\ \{4, 5\}, \{4, 6\}, \{1, 5\}, \{1, 7\}, \{2, 8\}\}$$

A continuación se detalla la ejecución paso a paso del algoritmo desde el emparejamiento nulo:

1. **Fase Inicial**:

- **Paso A (Inicialización)**: Comenzamos con el emparejamiento nulo $K = \emptyset$. Conjunto de vértices expuestos (no saturados): $\{1, 2, 3, 4, 5, 6, 7, 8\}$.
- **Paso B (Comprobación)**: Hay 8 vértices no saturados (> 1). No se cumple la condición de parada elemental $\implies$ Ir al **Paso C**.

2. **Iteración 1**:

   - **Paso C.1**: Seleccionamos la raíz expuesta $i_0 = 1$. Se inicializa el árbol alternante: $Y = Y^0 = \{1\}$, $T = \emptyset$.
   - **Paso C.2**:
     - *Caso 1 (Ciclo impar)*: No hay ciclos impares en Y^0.
     - *Caso 2 (Adyacente saturado)*: No existen vecinos saturados por $K = \emptyset$.
     - *Caso 3 (Adyacente no saturado)*: Para $i = 1 \in Y^0$, existe el vértice adyacente expuesto $j = 2 \notin Y$ con $\{1, 2\} \in E$. Se detecta la cadena incremental elemental $\mu = (1, 2)$.
     - *Transferencia*: Realizamos $K \leftarrow K \triangle \{\{1, 2\}\} = \{\{1, 2\}\}$.
     - **Volver al Paso B**.

3. **Iteración 2**:

   - **Paso B (Comprobación)**: Con $K = \{\{1, 2\}\}$, quedan 6 vértices no saturados $\{3, 4, 5, 6, 7, 8\} > 1 \implies$ Ir al **Paso C**.
   - **Paso C.1**: Seleccionamos la raíz expuesta $i_0 = 3$. Se inicializa el árbol alternante: $Y = Y^0 = \{3\}$, $T = \emptyset$.
   - **Paso C.2 (Extensión)**: Para $3 \in Y^0$, existe el vecino saturado $2 \notin Y$ (saturado por $\{1, 2\} \in K$) con $\{2, 3\} \in E$. Aplicando el Caso 2, incorporamos las aristas $\{2, 3\}$ y $\{1, 2\}$ al árbol:

     $$Y = \{1, 2, 3\}, \quad Y^0 = \{1, 3\}, \quad T = \{\{2, 3\}, \{1, 2\}\}$$

     Volvemos a evaluar el **Paso C.2**.
   - **Paso C.2 (Detección de Cadena Incremental)**: Evaluando desde los vértices pares $Y^0 = \{1, 3\}$, para $3 \in Y^0$ existe el vecino expuesto $4 \notin Y$ con $\{3, 4\} \in E$ (Caso 3). Se detecta la cadena incremental $\mu = (3, 4)$.
   - **Transferencia**: Realizamos $K \leftarrow K \triangle \{\{3, 4\}\} = \{\{1, 2\}, \{3, 4\}\}$.
   - **Volver al Paso B**.

4. **Iteración 3 (Detección y Contracción de la Primera Flor W)**:

   - **Paso B (Comprobación)**: Con $K = \{\{1, 2\}, \{3, 4\}\}$, quedan 4 vértices expuestos $\{5, 6, 7, 8\} > 1 \implies$ Ir al **Paso C**.
   - **Paso C.1**: Seleccionamos la raíz expuesta $i_0 = 5$. Inicializamos el árbol alternante: $Y = Y^0 = \{5\}$, $T = \emptyset$.

- **Paso C.2 (Extensión 1)**: Para $5 \in Y^0$, existe el vecino saturado $1 \notin Y$ (saturado por $\{1,2\} \in K$). Aplicando el Caso 2, incorporamos las aristas $\{5,1\}$ y $\{1,2\}$ al árbol:

$$Y = \{1,2,5\}, \quad Y^0 = \{2,5\}, \quad T = \{\{5,1\}, \{1,2\}\}$$

  Volvemos al **Paso C.2**.

- **Paso C.2 (Extensión 2)**: Para $5 \in Y^0$, existe el vecino saturado $4 \notin Y$ (saturado por $\{3,4\} \in K$). Aplicando el Caso 2, incorporamos las aristas $\{5,4\}$ y $\{4,3\}$ al árbol:

$$Y = \{1,2,3,4,5\}, \quad Y^0 = \{2,3,5\}, \quad T = \{\{5,1\}, \{1,2\}, \{5,4\}, \{4,3\}\}$$

  Volvemos al **Paso C.2**.

- **Paso C.2 (Caso 1: Detección de Flor)**: Entre los nodos pares del árbol $Y^0 = \{2,3,5\}$, existe la arista $\{2,3\} \in E$. Al conectar dos vértices de la misma paridad respecto a la raíz, se identifica el ciclo impar (flor) de 5 vértices:

$$W = \{1,2,3,4,5\}$$

- **Contracción de la Flor** W: Comprimimos todo el subconjunto W en el pseudonodo (supernodo) w. Se define el grafo comprimido G/W con vértices $\{w,6,7,8\}$ y aristas $\{\{w,6\},\{w,7\},\{w,8\},\{6,7\},\{7,8\}\}$. En G/W, el árbol se actualiza a $Y = Y^0 = \{w\}$, $T = \emptyset$ y $K = \emptyset$.

- **Paso C.2 en** G/W **(Transferencia)**: Desde $w \in Y^0$, se explora la arista $\{w,6\}$ hacia el vértice expuesto $6 \notin Y$ (Caso 3). Se realiza la transferencia en G/W:

$$K = \{\{w,6\}\}$$

  Volver al Paso B.

5. **Iteración 4 (Búsqueda en** G/W **y Contracción de la Segunda Flor** W'**)**:

   - **Paso B (Comprobación en** G/W**)**: Con $K = \{\{w,6\}\}$, los vértices no saturados en G/W son $\{7,8\}$ $(2 > 1) \implies$ Ir al **Paso C**.

   - **Paso C.1**: Seleccionamos la raíz expuesta $i_0 = 7$. Inicializamos el árbol: $Y = Y^0 = \{7\}$, $T = \emptyset$.

   - **Paso C.2 (Extensión)**: Para $7 \in Y^0$, el vecino $w \notin Y$ está saturado por $\{w,6\} \in K$. Por Caso 2, añadimos $\{7,w\}$ y $\{w,6\}$ al árbol:

$$Y = \{w,6,7\}, \quad Y^0 = \{6,7\}, \quad T = \{\{7,w\}, \{w,6\}\}$$

     Volvemos al **Paso C.2**.

- **Paso C.2 (Caso 1: Detección de Segunda Flor)**: Entre los nodos pares $Y^0 = \{6, 7\}$, existe la arista $\{6, 7\} \in E$. Se detecta el segundo ciclo impar:

$$W' = \{w, 6, 7\}$$

- **Segunda Contracción**: Comprimimos W' en el pseudonodo w'. Obtenemos el grafo comprimido G/W' con vértices $\{w', 8\}$ y la arista $\{w', 8\}$.
- **Paso C.2 en G/W' (Transferencia)**: La arista $\{w', 8\}$ une los dos únicos vértices (ambos expuestos) en G/W' (Caso 3). Transferencia: $K = \{\{w', 8\}\}$.
- **Paso B (Parada)**: En G/W', todos los vértices están saturados (quedan 0 vértices expuestos ≤ 1). **PARAR**: Se alcanza la optimalidad global.

6. **Fase de Descompresión y Reconstrucción Óptima**:

- **Descompresión de W'**: Al descontraer el supernodo w', la arista $\{w', 8\}$ proviene originalmente de $\{7, 8\} \in E$. En el ciclo impar $W' = \{w, 6, 7\}$, el nodo 7 queda saturado hacia el exterior por $\{7, 8\}$, lo que deja en W' la arista $\{w, 6\}$ para saturar a los nodos restantes. Obtenemos en G/W:

$$K = \{\{w, 6\}, \{7, 8\}\}$$

- **Descompresión de W**: La arista $\{w, 6\}$ proviene originalmente de la arista exterior $\{4, 6\} \in E$. En la flor $W = \{1, 2, 3, 4, 5\}$, el vértice 4 queda saturado hacia el exterior por $\{4, 6\}$. Seleccionamos en W el emparejamiento que satura a los 4 vértices restantes $\{1, 2, 3, 5\}$, correspondiente a $\{1, 5\}$ y $\{2, 3\}$.
- **Emparejamiento Óptimo Final**: Reconstruyendo todas las aristas en el grafo original G, obtenemos:

$$K^* = \{\{1, 5\}, \{2, 3\}, \{4, 6\}, \{7, 8\}\}$$

El cardinal resultante es $|K^*| = 4 = 8/2$, alcanzando un **emparejamiento perfecto** en el grafo de 8 nodos.

9.4. Problemas de recubrimiento en grafos y relaciones de dualidad

Existe una estrecha relación de complementariedad y dualidad entre seleccionar conjuntos de aristas independientes (emparejamientos) y seleccionar conjuntos de aristas que cubran todos los vértices de una red. Para introducir este concepto, consideremos el problema de diseño de patrullas de vigilancia en recintos fortificados.

Ejemplo: Vigilancia de murallas en la fortaleza

Considérese el recinto fortificado de 12 torres de vigilancia conectadas mediante 12 tramos de muralla, representado en la Figura 9.10.
Se desea posicionar patrullas de centinelas sobre las murallas. Cada guardia asignado a una muralla $\{u, v\}$ vigila simultáneamente las dos torres situadas en sus extremos (u y v). El objetivo consiste en **determinar el número mínimo de guardias (murallas)** necesarios para que **todas las torres de la fortaleza queden vigiladas**.

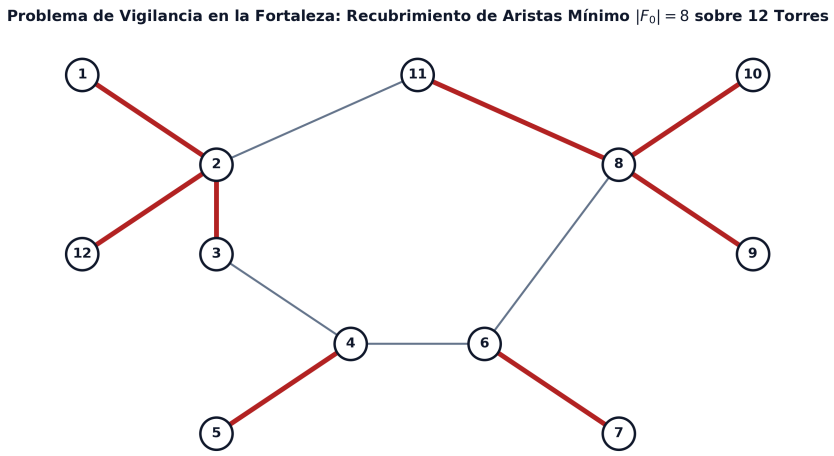

Figura 9.10: Problema de vigilancia en la fortaleza: recubrimiento de aristas mínimo $|F_0| = 8$ sobre 12 torres

Modelando la fortaleza como un grafo $G = (V, E)$, el problema consiste en hallar un subconjunto de aristas $F \subseteq E$ de mínimo cardinal tal que todo vértice $v \in V$ sea incidente en al menos una arista de F. Como se observa en la figura, seleccionando las 8 aristas en rojo:

$$F_0 = \{\{1,2\}, \{2,12\}, \{2,3\}, \{4,5\}, \{6,7\}, \{8,9\}, \{8,10\}, \{8,11\}\}$$

se cubren las 12 torres con $|F_0| = 8$ guardias, garantizando la seguridad completa a coste mínimo.

A partir del problema de la fortaleza, se formaliza la noción de subconjunto de aristas que cubre la totalidad de los vértices del grafo. A diferencia del problema de emparejamiento (donde se busca que cada nodo esté saturado a lo sumo una vez por las aristas seleccionadas, $\sum x_e \leq 1$), en el problema de recubrimiento se exige que todo nodo esté cubierto al menos una vez ($\sum x_e \geq 1$).

Definición: Recubrimiento de aristas (Edge Cover)

Dado un grafo no dirigido $G = (V, E)$ sin vértices aislados, un **recubrimiento de aristas** (o *edge cover*) es un subconjunto de aristas $F \subseteq E$ tal que todo vértice $v \in V$ es incidente en al menos una arista de F, es decir:

$$\bigcup_{e \in F} e = V$$

Proposición: Monotonía del recubrimiento

Dado un grafo $G = (V, E)$ y un recubrimiento de aristas $F \subseteq E$, si $F' \subseteq E$ satisface $F \subseteq F'$, entonces F' es también un recubrimiento de aristas de G.
Demostración: Si cada vértice $v \in V$ es incidente en alguna arista de F, la adición de aristas adicionales en F' preserva de forma trivial la cobertura de todos los vértices. ■

9.4.1. Teorema fundamental de dualidad de Gallai

La conexión cuantitativa exacta entre el emparejamiento de máximo cardinal y el recubrimiento de mínimo cardinal fue establecida por Tibor Gallai en 1959 (Gallai 1959).

Teorema: Dualidad de Gallai para emparejamientos y recubrimientos

Sea $G = (V, E)$ un grafo simple conexo con $n = |V|$ vértices y sin nodos aislados. Sean $K_0 \subseteq E$ un emparejamiento de **máximo cardinal** y $F_0 \subseteq E$ un recubrimiento de aristas de **mínimo cardinal**. Entonces se verifican las siguientes propiedades:

1. **Conservación de la Cardinalidad**:
$$|K_0| + |F_0| = n$$
2. **Construcción del Recubrimiento Mínimo a partir de K_0**: El conjunto F_1 obtenido añadiendo a K_0 exactamente una arista incidente en cada uno de los $n - 2|K_0|$ vértices expuestos por K_0:
$$F_1 = K_0 \cup \{e_v \in E \mid v \in V \setminus V(K_0)\}$$
es un **recubrimiento de aristas de mínimo cardinal** ($|F_1| = |F_0|$).
3. **Construcción del Emparejamiento Máximo a partir de F_0**: El conjunto K_1 obtenido eliminando de F_0 todas las aristas redundantes salvo una en cada vértice cubierto más de una vez ($d_{F_0}(v) > 1$):
$$K_1 = F_0 \setminus \{\text{aristas sobrantes en vértices de grado } > 1 \text{ en } F_0\}$$

es un **emparejamiento de máximo cardinal** ($|K_1| = |K_0|$).

Demostración: Demostramos constructivamente las tres afirmaciones del teorema:

- **Parte 2 (Construcción de F_1 y acotación superior)**: Sea K_0 un emparejamiento de máximo cardinal. K_0 satura exactamente a $2|K_0|$ vértices, dejando $n - 2|K_0|$ vértices expuestos. Como G no tiene vértices aislados, para cada vértice expuesto $v \in V \setminus V(K_0)$ existe al menos una arista $e_v \in E$ incidente en v. Añadiendo una arista por cada vértice libre, el conjunto F_1 cubre a todos los vértices de G, constituyendo un recubrimiento válido. El número de aristas de F_1 es exactamente:

  $$|F_1| = |K_0| + (n - 2|K_0|) = n - |K_0| \implies |F_1| + |K_0| = n$$

  Dado que F_0 es el recubrimiento de mínimo cardinal, por definición $|F_0| \leq |F_1|$, luego:

  $$|F_0| + |K_0| \leq n$$

- **Parte 3 (Construcción de K_1 y acotación inferior)**: Sea F_0 un recubrimiento de aristas de mínimo cardinal. En F_0, no pueden existir ciclos cerrados (eliminar una arista de un ciclo preservaría la cobertura de todos sus nodos, contradiciendo la minimalidad de F_0), ni cadenas de longitud mayor o igual a 3 (eliminar una arista interior mantendría cubiertos los extremos). Por tanto, el subgrafo (V, F_0) está formado exclusivamente por estrellas conexas (árboles de profundidad 1) de aristas incidentes en centros comunes.

  Para cada componente estrella con $k \geq 2$ aristas incidentes en un centro, eliminamos $k - 1$ aristas, conservando una única arista por componente. El conjunto resultante $K_1 \subset F_0$ no tiene aristas adyacentes, luego K_1 es un emparejamiento válido de G. Cada arista eliminada de F_0 deja de saturar a exactamente un vértice hoja, por lo que el número de vértices no saturados por K_1 es igual al número de aristas eliminadas: $|F_0| - |K_1| = n - 2|K_1|$. Despejando:

  $$|K_1| = |F_0| - (n - 2|K_1|) \implies |F_0| + |K_1| = n$$

  Como K_0 es el emparejamiento de máximo cardinal, $|K_1| \leq |K_0|$, por lo que:

  $$n = |F_0| + |K_1| \leq |F_0| + |K_0|$$

- **Conclusión de igualdad**: Combinando ambas desigualdades:

  $$n = |F_1| + |K_0| \geq |F_0| + |K_0| \geq |F_0| + |K_1| = n$$

  Todas las desigualdades intermedias deben cumplirse como igualdades estrictas:

  $$|F_1| = |F_0|, \quad |K_1| = |K_0|, \quad \text{y} \quad |K_0| + |F_0| = n$$

  Esto demuestra simultáneamente que $|K_0| + |F_0| = n$, que F_1 es un recubrimiento mínimo y que K_1 es un emparejamiento máximo. ■

El Teorema de Gallai establece una de las relaciones de conservación combinatoria más profundas entre problemas de **empaquetamiento** (*packing*) y problemas de **recubrimiento** (*covering*). En cualquier grafo sin vértices aislados, cada arista de un emparejamiento satura exactamente 2 vértices distintos, mientras que cada arista adicional necesaria para completar un recubrimiento cubre exactamente a 1 vértice libre. La identidad $|K_0| + |F_0| = n$ actúa como una ecuación de conservación estructural: el déficit de aristas en el emparejamiento respecto del total de nodos se traduce exactamente en el superávit de aristas requeridas para el recubrimiento mínimo.

Como ilustra la Figura 9.11, este teorema proporciona un algoritmo inmediato de complejidad lineal $\mathcal{O}(n)$ para resolver el problema del recubrimiento de aristas mínimo una vez obtenido el emparejamiento máximo mediante el algoritmo de Edmonds.

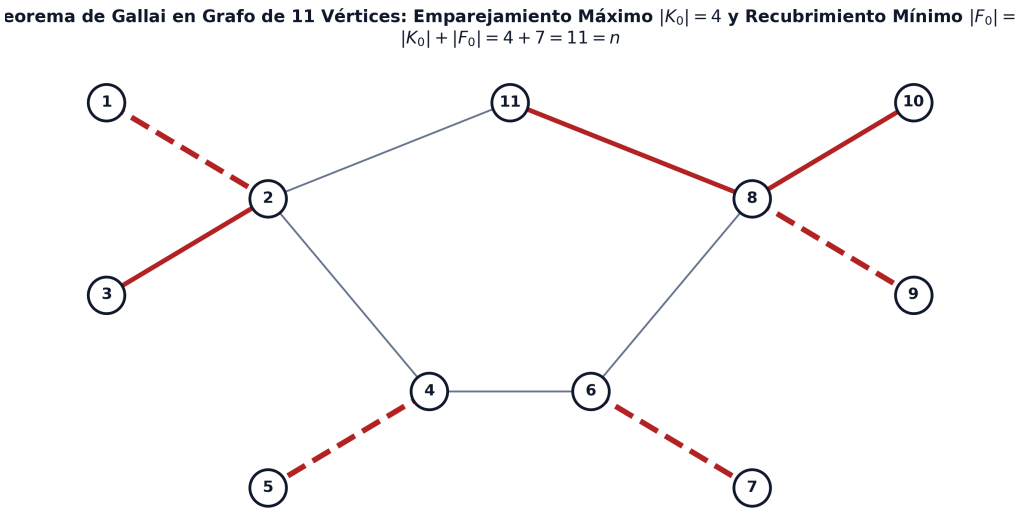

Figura 9.11: Ilustración del Teorema de Gallai en un grafo de 11 vértices: emparejamiento máximo $|K_0| = 4$ (discontinuo) y recubrimiento mínimo $|F_0| = 7$ (rojo), verificando $|K_0| + |F_0| = 4 + 7 = 11$

9.5. Emparejamiento de máximo peso y algoritmo primal-dual

En múltiples aplicaciones logísticas, económicas y de telecomunicaciones, las conexiones no tienen la misma importancia ni el mismo rendimiento económico. En tales escenarios, cada arista $e \in E$ lleva asignado un peso o beneficio $p(e) \in \mathbb{R}$, y el objetivo no es maximizar el número de parejas, sino el **peso total acumulado**.

Definición: Problema de emparejamiento de máximo peso

Dado un grafo simple no dirigido $G = (V, E)$ y un vector de pesos $\mathbf{p} = \{p(e) \mid e \in E\}$, el **problema de emparejamiento de máximo peso** consiste en determinar un subconjunto de aristas $K \subseteq E$ tal que:

1. K es un emparejamiento válido de G.
2. Para cualquier otro emparejamiento $K' \subseteq E$, se satisface:

$$p(K') \leq p(K), \quad \text{donde } p(K) = \sum_{e \in K} p(e)$$

En el emparejamiento de máximo peso, un emparejamiento óptimo no tiene por qué tener el máximo número de aristas posible: en ocasiones, el beneficio máximo se obtiene con menos aristas si estas concentran pesos individuales muy superiores.

9.5.1. Coste reducido de cadenas y caracterización de optimalidad

Para cuantificar el impacto económico de alterar un emparejamiento a lo largo de una cadena alternante, definimos el concepto de coste reducido.

Definición: Coste reducido de una cadena alternante

Dado un grafo $G = (V, E)$ con pesos $p(e)$, un emparejamiento $K \subseteq E$ y una cadena alternante L, se define el **coste reducido** de L respecto de K, denotado por δ_L, como:

$$\delta_L = p(L \cap \overline{K}) - p(L \cap K) = \sum_{e \in L \setminus K} p(e) - \sum_{e \in L \cap K} p(e)$$

donde $\overline{K} = E \setminus K$ representa el conjunto de aristas fuera del emparejamiento.

Definición: Ciclo alternante

Dado un grafo $G = (V, E)$ y un emparejamiento $K \subseteq E$, un **ciclo alternante** es una cadena alternante cerrada y simple de longitud estrictamente par, cuyas aristas pertenecen y no pertenecen alternativamente al emparejamiento K.

El signo del coste reducido δ_L posee una interpretación económica directa: representa el beneficio marginal neto obtenido al intercambiar las parejas existentes a lo largo de L:

- Si $\delta_L > 0$, la transferencia **incrementa estrictamente** el peso de la solución ($p(K') = p(K) + \delta_L$).
- Si $\delta_L = 0$, la transferencia mantiene invariable el peso acumulado.

- Si $\delta_L < 0$, la transferencia empeora el peso total.

! Teorema: Optimalidad por costes reducidos

Dado un grafo $G = (V, E)$ con pesos $p(e)$ sobre las aristas, un emparejamiento $K \subseteq E$ es de **máximo peso** si y solo si **no existe ninguna cadena alternante** (abierta o cerrada) con coste reducido estrictamente positivo ($\delta_L \leq 0$ para toda cadena alternante L).
Demostración:

- **Necesidad ($\Longrightarrow$)**: Si existiera una cadena alternante L con $\delta_L > 0$, la transferencia $K' = K \triangle L$ produciría un emparejamiento de peso $p(K') = p(K) + \delta_L > p(K)$, lo que contradice la optimalidad de K.
- **Suficiencia ($\Longleftarrow$)**: Sea K_1 un emparejamiento de máximo peso global, de modo que $p(K_1) \geq p(K)$. Consideramos el grafo diferencia simétrica $H = (V, K \triangle K_1)$. Por el Lema de Descomposición, H se descompone en vértices aislados, ciclos alternantes y cadenas alternantes respecto de K. Al no existir en G ninguna cadena ni ciclo alternante con coste reducido positivo respecto de K, la suma de las diferencias de peso sobre todas las componentes de H satisface $p(K_1) - p(K) \leq 0 \implies p(K_1) \leq p(K)$. Por consiguiente, $p(K) = p(K_1)$, lo que certifica que K es de máximo peso. ■

Este teorema generaliza el criterio de Berge: mientras que para emparejamientos de máximo cardinal se busca cualquier cadena incremental (que siempre aporta +1 arista neta), en el caso ponderado se buscan cadenas que aporten un balance de peso neto positivo ($\delta_L > 0$).

9.5.2. Algoritmo de aumento por cardinalidad fija

La resolución algorítmica del emparejamiento de máximo peso se estructura determinando inductivamente los emparejamientos K^m de máximo peso para cada cardinalidad fija $m = 1, 2, \ldots, \lfloor n/2 \rfloor$:

- K^1: Es la arista individual de mayor peso en E.
- K^2: Es el par de aristas disjuntas de mayor suma de pesos en E.
- K^{m+1}: Se obtiene a partir de K^m mediante el siguiente resultado teórico fundamental.

! Teorema: Progresión de emparejamientos de peso máximo

Sea $G = (V, E)$ un grafo, sea K^m el emparejamiento de máximo peso entre todos los de cardinal m, y sea L una **cadena alternante incremental** respecto de K^m que posea el **coste reducido máximo** ($\delta(L) = \max \delta$).
Entonces, el emparejamiento $K^{m+1} = K^m \triangle L$ obtenido por la transferencia de L es el **emparejamiento de máximo peso entre todos los de cardinal** $m + 1$.
Demostración: Sea K^* un emparejamiento óptimo de peso máximo con exactamente $m+1$

aristas. Analizamos el subgrafo diferencia simétrica:

$$H = (V, E_H), \quad \text{donde } E_H = (K^* \setminus K^m) \cup (K^m \setminus K^*)$$

El grafo H se compone exclusivamente de vértices aislados, ciclos alternantes y cadenas alternantes:

1. Los ciclos alternantes y las cadenas alternantes de longitud par poseen igual número de aristas de K^* que de K^m. Al ser K^* y K^m óptimos en sus respectivas cardinalidades, el coste reducido de todas estas componentes cerradas o pares es exactamente 0.
2. Para las cadenas alternantes de longitud impar, decimos que una cadena está **dominada por** K^* si contiene más aristas de K^* que de K^m (es decir, $k+1$ aristas de K^* y k aristas de K^m), y **dominada por** K^m en caso contrario.

Dado que $|K^*| = |K^m| + 1$, el número de aristas de K^* en H supera en exactamente 1 al número de aristas de K^m. En consecuencia, si existen s cadenas impares dominadas por K^m, debe haber exactamente $s+1$ cadenas impares dominadas por K^*. Las s cadenas dominadas por K^m se pueden emparejar y compensar con s cadenas dominadas por K^*. Por la optimalidad de ambas soluciones, estas $2s$ cadenas compensadas tienen coste reducido total nulo.
Queda exactamente **una única cadena impar no compensada**, denotada por L^*, que está dominada por K^*. Al tener sus extremos libres en K^m, L^* es una **cadena alternante incremental** respecto de K^m. Dicha cadena concentra toda la diferencia neta de peso entre K^* y K^m:

$$p(K^*) = p(K^m) + \delta(L^*)$$

Por otro lado, por definición de $K^{m+1} = K^m \triangle L$, su peso es:

$$p(K^{m+1}) = p(K^m) + \delta(L)$$

Como K^* es el emparejamiento de peso máximo con $m+1$ aristas, se tiene $p(K^{m+1}) \leq p(K^*) \implies \delta(L) \leq \delta(L^*)$. Pero habiendo seleccionado L como la cadena de coste reducido máximo en G, se cumple $\delta(L) \geq \delta(L^*)$. Por tanto, $\delta(L) = \delta(L^*)$ y $p(K^{m+1}) = p(K^*)$, lo que demuestra que K^{m+1} es un emparejamiento de máximo peso de cardinal $m+1$. ■

Ejemplo: Resolución de emparejamiento de peso máximo en grafo de 6 nodos

Considérese el grafo de 6 vértices $V = \{1, 2, 3, 4, 5, 6\}$ y 9 aristas ponderadas representado en la **?@fig-peso-animado**, cuyos pesos se dividen en dos conjuntos de aristas:

$$\begin{aligned} &p(1,2) = 2, \quad p(1,6) = 1, \quad p(6,2) = 2, \quad p(6,3) = 3, \quad p(2,3) = 3, \\ &p(2,4) = 1, \quad p(3,4) = 4, \quad p(4,5) = 5, \quad p(6,5) = 2 \end{aligned}$$

Aplicamos el algoritmo de aumento inductivo por cardinalidad:

1. **Cardinal** $m = 1$:
   - Buscamos la arista de peso máximo en E:
   $$e^* = \{4, 5\} \quad \text{con } p(4, 5) = 5$$
   - Obtenemos el emparejamiento óptimo de 1 arista:
   $$K^1 = \big\{\{4, 5\}\big\}, \quad p(K^1) = 5$$
2. **Cardinal** $m = 2$:
   - Los vértices expuestos respecto de K^1 son $\{1, 2, 3, 6\}$.
   - Buscamos entre los vértices expuestos la cadena incremental L_1 que maximice el coste reducido $\delta(L_1)$. Evaluamos aristas disjuntas a $\{4, 5\}$:
     - Arista $\{2, 3\}$: $\delta = p(2, 3) = 3$.
     - Arista $\{6, 3\}$: $\delta = p(6, 3) = 3$.
     - Arista $\{1, 2\}$: $\delta = p(1, 2) = 2$.
   - Seleccionamos la arista de mayor incremento $L_1 = \{2, 3\}$ con $\delta(L_1) = 3$.
   - Obtenemos el emparejamiento óptimo de 2 aristas:
   $$K^2 = K^1 \cup \big\{\{2, 3\}\big\} = \big\{\{4, 5\}, \{2, 3\}\big\}, \quad p(K^2) = 5 + 3 = 8$$
3. **Cardinal** $m = 3$:
   - Los vértices expuestos respecto de K^2 son $\{1, 6\}$.
   - Evaluamos todas las cadenas incrementales alternantes que conectan los vértices expuestos 1 y 6:
     - **Cadena de longitud 1** ($L_A = 1 - 6$):
     $$\delta(L_A) = p(1, 6) = 1$$
     - **Cadena de longitud 3** ($L_B = 1 - 2 - 3 - 6$): Entran las aristas $\{1, 2\}$ y $\{3, 6\}$; sale la arista $\{2, 3\} \in K^2$:
     $$\begin{aligned} \delta(L_B) &= [p(1, 2) + p(3, 6)] - p(2, 3) \\ &= [2 + 3] - 3 = 2 \end{aligned}$$
     - **Cadena de longitud 5** ($L_C = 1 - 2 - 3 - 4 - 5 - 6$): Entran las aristas $\{1, 2\}$, $\{3, 4\}$ y $\{6, 5\}$; salen las aristas $\{2, 3\}$ y $\{4, 5\} \in K^2$:
     $$\begin{aligned} \delta(L_C) &= [p(1, 2) + p(3, 4) + p(6, 5)] - [p(2, 3) + p(4, 5)] \\ &= [2 + 4 + 2] - [3 + 5] = 8 - 8 = 0 \end{aligned}$$

- El coste reducido máximo es $\delta(L_B) = 2$, correspondiente a la cadena alternante $L_B = 1 - 2 - 3 - 6$.
- Realizamos la transferencia $K^3 = K^2 \triangle (1 - 2 - 3 - 6) = (K^2 \setminus \{\{2, 3\}\}) \cup \{\{1, 2\}, \{3, 6\}\}$:

$$K^3 = \{\{1, 2\}, \{3, 6\}, \{4, 5\}\}, \quad p(K^3) = p(K^2) + \delta(L_B) = 8 + 2 = 10$$

4. **Conclusión de Optimalidad Global**: Dado que K^3 es un emparejamiento perfecto (satura los 6 vértices del grafo), no es posible construir emparejamientos con un número mayor de aristas. El **emparejamiento de peso máximo global** es:

$$K^* = K^3 = \{\{1, 2\}, \{3, 6\}, \{4, 5\}\} \quad \text{con peso óptimo total } p(K^*) = 10$$

10 Rutas eulerianas, hamiltonianas y problemas de rutas

El diseño y optimización de rutas sobre redes valoradas constituye uno de los pilares más fascinantes y de mayor repercusión industrial de la investigación operativa, la ciencia de la computación y la logística moderna (Papadimitriou y Steiglitz 1998; Wolsey 1998). Desde una perspectiva teórica y algorítmica, los problemas de recorridos permiten estudiar la profunda frontera que separa los problemas resolubles en tiempo polinomial (clase $\mathcal{P}$), como la determinación de trayectorias que inspeccionan la totalidad de las aristas o calles de una red (el **Problema del Cartero Chino**), frente a los problemas computacionalmente intratables de naturaleza $\mathcal{NP}$-completa y $\mathcal{NP}$-dura, como la secuenciación óptima de visitas a un conjunto de clientes o nodos sin repetición (el **Problema del Viajante de Comercio** o TSP, y sus extensiones multi-vehículo VRP).

En este capítulo, desarrollaremos de forma rigurosa la teoría matemática y las técnicas algorítmicas que sustentan el análisis de recorridos en grafos. Comenzaremos explorando los orígenes históricos de la teoría de grafos en los puentes de Königsberg y la caracterización exacta de los **grafos eulerianos**, formalizando un algoritmo constructivo de cadenas eulerianas basado en estructuras de punteros. A continuación, estudiaremos el **Problema del Cartero Chino (CPP)** en redes no eulerianas, demostrando la descomposición de aristas duplicadas y resolviendo el modelo mediante emparejamientos perfectos de peso mínimo. Posteriormente, abordaremos los **ciclos hamiltonianos**, analizando la condición necesaria de 2-conexidad, la proposición fundamental de adyacencia y el Teorema de la **Clausura de Bondy y Chvátal**. Seguidamente, formularemos el **Problema del Viajante (TSP)** mediante tres modelos lineales enteros fundamentales (el modelo tridimensional por tramos, la formulación con eliminación exponencial de subciclos de Dantzig-Fulkerson-Johnson y el modelo polinomial compacto de Miller-Tucker-Zemlin), analizando además heurísticas locales (2-opt) y el algoritmo de aproximación métrica de **Christofides** con la demostración de su garantía de factor 1.5. Finalmente, estableceremos la taxonomía global de los **Problemas de Rutas de Vehículos (VRP)** y sus múltiples variantes operativas.

> **!** Objetivos de aprendizaje
>
> Al finalizar este capítulo, serás capaz de:
>
> 1. **Diferenciar** formalmente entre grafos eulerianos (recorridos por aristas en tiempo

polinomial) y grafos hamiltonianos (recorridos por vértices de complejidad $\mathcal{NP}$-completa).
2. **Aplicar** el teorema fundamental de caracterización de Euler y ejecutar el algoritmo constructivo de punteros para determinar cadenas y ciclos eulerianos.
3. **Formular y resolver** el Problema del Cartero Chino (CPP) sobre grafos generales, modelando la eulerización óptima mediante emparejamientos perfectos de peso mínimo sobre el grafo auxiliar de nodos impares.
4. **Demostrar** la proposición fundamental de adyacencia hamiltoniana y evaluar la existencia de ciclos hamiltonianos mediante el operador de clausura de Bondy-Chvátal y los teoremas clásicos de Dirac y Ore.
5. **Formular** el Problema del Viajante (TSP) comparando las formulaciones de eliminación exponencial de subtours (DFJ) y la formulación polinomial compacta (MTZ), justificando el compromiso entre fortaleza poliédrica y dimensión.
6. **Clasificar** los problemas generales de rutas de vehículos (VRP/VSP, rutas por nodos frente a rutas por arcos) identificando sus dimensiones operativas (flotas, depósitos, demandas, ventanas de tiempo y funciones objetivo).

10.1. Grafos eulerianos y el problema de los puentes de Königsberg

El nacimiento formal de la teoría de grafos y de la topología matemática se sitúa en 1736, cuando el célebre matemático suizo **Leonhard Euler** presentó en la Academia de San Petersburgo su memoria titulada *Solutio Problematis ad Geometriam Situs Pertinentis* (Euler 1741). En dicho trabajo, Euler abordó el célebre enigma planteado por los ciudadanos de la ciudad prusiana de **Königsberg** (actual Kaliningrado), atravesada por el río Pregel, el cual dividía la urbe en cuatro masas terrestres conectadas entre sí mediante siete puentes. El problema consistía en determinar si era posible diseñar un paseo urbano que recorriera la ciudad cruzando **cada uno de los siete puentes exactamente una vez y regresando al punto de partida**.

Euler demostró de forma analítica que tal recorrido cerrado era físicamente imposible. Su genialidad radicó en abstraer por completo los detalles geométricos (longitudes de calles, formas de las orillas o distancias reales) y modelar la topología del sistema mediante un **multigrafo**, donde las cuatro regiones terrestres se representaban como vértices (A, B, C, D) y los siete puentes como aristas que conectaban dichas regiones, tal como se ilustra en la Figura 10.1.

El análisis de Euler demostró que, para que un vértice cualquiera actúe como punto de paso intermedio de un recorrido continuo sin repetir puentes, cada vez que el caminante entra en dicho vértice por un puente debe existir necesariamente otro puente disponible sin cruzar para salir de él. En consecuencia, cada visita intermedia consume exactamente dos conexiones, lo

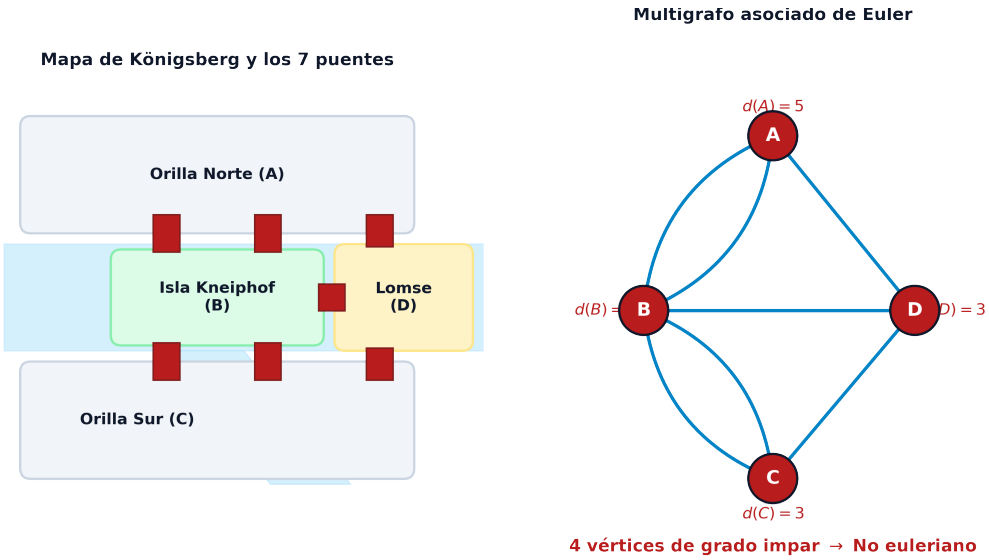

Figura 10.1: El problema de los siete puentes de Königsberg: mapa fluvial sobre el río Pregel (izquierda) y multigrafo abstracto de Euler con los grados nodales asociados (derecha)

que exige que el número de aristas incidentes en cada nodo intermedio (**grado del vértice**) sea obligatoriamente un **número par**.

Definición: Cadenas y ciclos eulerianos

Dado un multigrafo finito conexo no dirigido $G = (V, E)$:

- **Cadena euleriana**: Es una secuencia ordenada de vértices y aristas que recorre **todas las aristas** del conjunto E pasando por cada una de ellas **exactamente una vez** (sin repetir ninguna arista).
- **Ciclo euleriano**: Es una cadena euleriana **cerrada**, es decir, una cadena euleriana cuyo vértice inicial coincide con su vértice final.
- **Grafo euleriano**: Un multigrafo $G = (V, E)$ se denomina **euleriano** si admite al menos un ciclo euleriano.

La caracterización matemática completa de la existencia de tales trayectorias sobre redes conexas se formaliza en el teorema fundamental de Euler, extendido posteriormente por Carl Hierholzer en 1873.

! Teorema: Teorema de Euler de caracterización euleriana

Sea $G = (V, E)$ un multigrafo finito y conexo. Entonces:

1. G contiene un **ciclo euleriano** si y solo si **todos los vértices de V tienen grado par**:
$$d(i) \equiv 0 \pmod 2, \quad \forall i \in V$$

2. G contiene una **cadena euleriana abierta** (no cerrada) si y solo si el número de vértices de grado impar es **exactamente dos**. En tal caso, los dos vértices de grado impar constituyen necesariamente los extremos inicial y final de la cadena.

Demostración: Demostremos en primer lugar la condición necesaria para la existencia de un ciclo euleriano. Supongamos que G admite un ciclo euleriano C. Al recorrer el ciclo arista por arista desde el origen hasta el retorno final, cada paso a través de un vértice intermedio $i \in V$ utiliza una arista entrante y otra arista saliente no explorada previamente. Por tanto, cada tránsito a través de i incrementa su grado local en dos unidades. Como todas las aristas de E son visitadas exactamente una vez, el grado total $d(i)$ de cada vértice es el doble del número de veces que el ciclo pasa por él, resultando un número estrictamente par. Si la cadena es abierta y une dos vértices distintos u y v, el vértice inicial u tiene una arista saliente neta adicional (grado impar), el vértice final v tiene una arista entrante neta adicional (grado impar), y todos los demás vértices intermedios conservan balance par de entrada y salida.
Para demostrar la suficiencia en el caso de que todos los vértices tengan grado par, seleccionamos un vértice cualquiera v_0 y construimos un camino simple avanzando por aristas no utilizadas. Dado que cada vértice tiene grado par, al entrar en cualquier vértice siempre existirá al menos una arista libre para salir, a menos que regresemos al vértice de partida v_0. Así, se forma un ciclo inicial C_1. Si C_1 contiene todas las aristas de E, hemos terminado. Si no es así, al ser G conexo, existe algún vértice $v_k \in C_1$ que incide en aristas no pertenecientes a C_1. El subgrafo residual $G \setminus E(C_1)$ sigue teniendo todos sus vértices de grado par. Repitiendo el proceso desde v_k, obtenemos un nuevo ciclo C_2 que puede empalmarse en v_k dentro de C_1. Reiterando esta descomposición sobre el número finito de aristas, se obtiene un ciclo euleriano que integra la totalidad de E. ■

En el multigrafo de los puentes de Königsberg mostrado en la Figura 10.1, los grados de los cuatro vértices son $d(A) = 5$, $d(B) = 3$, $d(C) = 3$ y $d(D) = 3$. Al existir cuatro vértices de grado impar (ninguno con grado par), el teorema de Euler certifica formalmente la imposibilidad de trazar ni un ciclo ni una cadena euleriana abierta.

i Nota: Distinción entre cadenas y ciclos eulerianos según la paridad

Es conveniente clarificar con precisión la relación entre la noción general de **cadena euleriana** y la de **ciclo euleriano**:

- **Existencia de cadena euleriana en general**: Un grafo conexo admite una cadena euleriana (cerrada o abierta) si y solo si el número de vértices de grado impar pertenece al conjunto $\{0, 2\}$.
- **Caso $|V_{\textbf{impar}}| = 0$ (Ciclo euleriano)**: Si todos los vértices tienen grado par, la cadena es **cerrada** (un ciclo euleriano) y puede iniciarse y concluirse en cualquier vértice arbitrario de la red.
- **Caso $|V_{\textbf{impar}}| = 2$ (Cadena euleriana abierta)**: La cadena es **abierta** (no puede cerrarse sobre sí misma sin duplicar aristas) y sus extremos inicial y final son obligatoriamente los dos únicos vértices con grado impar.
- **Caso $|V_{\textbf{impar}}| \geq 4$**: No existe ninguna cadena euleriana, ni abierta ni cerrada (el caso de $|V_{\text{impar}}| = 1$ o cualquier número impar de vértices impares es topológicamente imposible en cualquier grafo por el Lema del apretón de manos).

10.1.1. Algoritmo constructivo para la determinación de cadenas eulerianas

Para determinar de forma computacional una cadena o ciclo euleriano en un multigrafo que cumple las condiciones de Euler, se requiere una estructura de datos algorítmica eficiente que permita extender un recorrido inicial e insertar recursivamente los ciclos secundarios que surjan en los vértices intermedios.

Presentamos a continuación el algoritmo formal de construcción de cadenas eulerianas mediante un vector de punteros de aristas sucesoras $= (\sigma(1), \dots, \sigma(m), \sigma(m+1))$, donde $m = |E|$ denota el número total de aristas del grafo. En esta estructura, cada componente $\sigma(e)$ almacena el identificador de la arista que sigue a la arista e en la secuencia del recorrido, y la posición auxiliar $\sigma(m+1)$ almacena el índice de la primera arista de la cadena.

i Esquema: Algoritmo de construcción de cadenas y ciclos eulerianos

Dado un grafo conexo $G = (V, E)$ con $m = |E|$ aristas numeradas $\{1, 2, \dots, m\}$, sean las siguientes estructuras de datos y parámetros auxiliares:

- $d(i)$: Grado del vértice $i \in V$.
- $w(i)$: Conjunto ordenado de aristas incidentes en el vértice i.
- $\delta_i(e) = j$: Función de incidencia que devuelve el vértice opuesto al que conecta la arista $e = \{i, j\}$ desde el nodo i.
- $\alpha(i)$: Contador dinámico del número de aristas incidentes en i que aún **no han sido exploradas** (inicialmente $\alpha(i) = d(i)$).

- v: Longitud acumulada del recorrido actual (número de aristas incorporadas).
- $\phi(i)$: Identificador de la arista utilizada para alcanzar por primera vez el vértice i dentro de la cadena (para el vértice inicial a, se define $\phi(a) = m + 1$).

El procedimiento algorítmico se articula en cuatro pasos:

1. **Paso 1 (Inicialización)**:
   - Si el grafo posee dos vértices de grado impar, se selecciona uno de ellos como vértice inicial a y el otro como vértice terminal b (fijando $i = a$ y $t = b$). Si todos los vértices son pares, se escoge un vértice arbitrario fijando $a = b$ $(i = a, t = a)$.
   - Inicializar $\sigma(e) = 0$ para todo $e \in \{1, \dots, m, m + 1\}$, $\alpha(i) = d(i)$ y $\phi(j) = 0$ para todo $j \in V \setminus \{a\}$, fijando $\phi(a) = m + 1$, $v = 0$, $e_1 = m + 1$ y $e_2 = -1$.
2. **Paso 2 (Extensión secuencial del recorrido)**:
   - Si $\alpha(i) = 0$, ir al **Paso 4**.
   - En caso contrario, sea e la arista que ocupa la posición actual $\alpha(i)$ en la lista de incidencias $w(i)$. Decrementar el contador: $\alpha(i) \leftarrow \alpha(i) - 1$.
   - Si $e = e_1$ o $\sigma(e) \neq 0$ (arista ya explorada en sentido inverso), repetir el **Paso 2**.
   - En otro caso (arista nueva disponible):

$$j = \delta_i(e), \quad \phi(j) = e, \quad \sigma(e_1) = e,$$
$$v \leftarrow v + 1, \quad \alpha(j) \leftarrow \alpha(j) - 1, \quad i \leftarrow j$$

   - Si el nuevo nodo alcanzado es el nodo objetivo $(i = t)$, ir al **Paso 3**. En caso contrario, actualizar la última arista incorporada $e_1 \leftarrow e$ y continuar en el **Paso 2**.
3. **Paso 3 (Cierre de subcadena y verificación de parada)**:
   - Enlazar la última arista con la continuación del ciclo: $\sigma(e) = e_2$.
   - Si la longitud total alcanza el número total de aristas $(v = m)$, el algoritmo **FINALIZA con éxito**: el vector describe la cadena euleriana completa.
   - Si $v < m$, quedan aristas no exploradas, por lo que se avanza al **Paso 4**.
4. **Paso 4 (Búsqueda y empalme de ciclos adyacentes)**:
   - Buscar un vértice $k \in V$ que satisfaga simultáneamente:
     1. $\alpha(k) \neq 0$ (le restan aristas incidentes sin explorar).
     2. $\phi(k) \neq 0$ (es un vértice perteneciente a la cadena ya construida).

- Configurar los punteros de inserción para abrir un ciclo secundario en dicho nodo:
$$i \leftarrow k, \quad t \leftarrow k, \quad e_1 \leftarrow \phi(k), \quad e_2 \leftarrow \sigma(e_1)$$
- Regresar al **Paso 2** para construir el ciclo euleriano adyacente que se intercalará en la posición de k.

En el siguiente ejemplo, analizamos la ejecución detallada de este algoritmo sobre un grafo de 4 nodos.

Ejemplo: Construcción paso a paso de una cadena euleriana

Consideremos el grafo conexo $G = (V, E)$ de 4 vértices $V = \{a, b, c, d\}$ y 4 aristas $E = \{1, 2, 3, 4\}$ ilustrado en la Figura 10.2 (panel izquierdo), cuyas aristas e incidencias son:

- Arista 1: $\{a, b\} \implies \delta_a(1) = b, \delta_b(1) = a$.
- Arista 2: $\{b, c\} \implies \delta_b(2) = c, \delta_c(2) = b$.
- Arista 3: $\{c, d\} \implies \delta_c(3) = d, \delta_d(3) = c$.
- Arista 4: $\{b, d\} \implies \delta_b(4) = d, \delta_d(4) = b$.

Evaluando los grados nodales:

$$d(a) = 1, \quad d(b) = 3, \quad d(c) = 2, \quad d(d) = 2$$

Al existir exactamente dos vértices de grado impar (a y b), el teorema de Euler garantiza la existencia de una cadena euleriana abierta que comenzará en a y finalizará en b.

1. **Inicialización (Paso 1)**:
   - Vértice inicial: $i = a$, vértice final: $t = b$.
   - Arista ficticia de cabecera: $m+1 = 5$. Punteros iniciales: $e_1 = 5, e_2 = -1, v = 0$.
   - Contadores: $\alpha(a) = 1, \alpha(b) = 3, \alpha(c) = 2, \alpha(d) = 2$.
   - Punteros de llegada: $\phi(a) = 5, \phi(b) = 0, \phi(c) = 0, \phi(d) = 0$.
2. **Primera extensión (Paso 2)**:
   - En $i = a$, $\alpha(a) = 1$. Arista disponible $e = 1$. Se actualiza $\alpha(a) = 0$.
   - Como $e = 1 \neq e_1 = 5$, se conecta la arista:
$$j = \delta_a(1) = b, \quad \phi(b) = 1, \quad \sigma(5) = 1,$$
$$v = 1, \quad \alpha(b) = 3 - 1 = 2, \quad i = b$$
   - Como el nodo actual b coincide con el destino $t = b$, se deriva al **Paso 3**.

3. **Cierre de tramo inicial (Paso 3)**:
   - Se fija $\sigma(1) = e_2 = -1$.
   - Como la longitud acumulada $v = 1 < 4$, la cadena no está completa. Se pasa al **Paso 4**.
4. **Búsqueda de vértice de bifurcación (Paso 4)**:
   - Se evalúa el nodo $k = b$: cumple $\alpha(b) = 2 \neq 0$ y $\phi(b) = 1 \neq 0$.
   - Se reconfiguran los punteros para intercalar un ciclo cerrado en b:
   $$i = b, \quad t = b, \quad e_1 = \phi(b) = 1, \quad e_2 = \sigma(1) = -1$$
   - Se regresa al **Paso 2**.
5. **Construcción del ciclo secundario (Pasos 2 y 3)**:
   - *Iteración desde b*: $\alpha(b) = 2$, arista $e = w_2(b) = 4$. Se actualiza $\alpha(b) = 1$.
   $$\begin{aligned} &j = \delta_b(4) = d, \quad \phi(d) = 4, \quad \sigma(1) = 4, \\ &v = 2, \quad \alpha(d) = 2 - 1 = 1, \quad i = d, \quad e_1 = 4 \end{aligned}$$
   - *Iteración desde d*: $\alpha(d) = 1$, arista $e = w_1(d) = 3$. Se actualiza $\alpha(d) = 0$.
   $$\begin{aligned} &j = \delta_d(3) = c, \quad \phi(c) = 3, \quad \sigma(4) = 3, \\ &v = 3, \quad \alpha(c) = 2 - 1 = 1, \quad i = c, \quad e_1 = 3 \end{aligned}$$
   - *Iteración desde c*: $\alpha(c) = 1$, arista $e = w_1(c) = 2$. Se actualiza $\alpha(c) = 0$.
   $$\begin{aligned} &j = \delta_c(2) = b, \quad \phi(b) = 2, \quad \sigma(3) = 2, \\ &v = 4, \quad \alpha(b) = 1 - 1 = 0, \quad i = b \end{aligned}$$
   - Al alcanzar de nuevo el destino intermedio $i = t = b$, se pasa al **Paso 3**:
   $$\sigma(2) = e_2 = -1$$
   - Como la longitud acumulada $v = 4 = m$, el algoritmo **termina con éxito**.

El vector resultante de punteros es:

$$= (\sigma(1), \sigma(2), \sigma(3), \sigma(4), \sigma(5)) = (4, -1, 2, 3, 1)$$

Siguiendo la cadena desde el puntero inicial $\sigma(5) = 1 \to \sigma(1) = 4 \to \sigma(4) = 3 \to \sigma(3) = 2 \to \sigma(2) = -1$, la secuencia ordenada de aristas es $(1, 4, 3, 2)$, correspondiente a la cadena euleriana de vértices:

$$a \xrightarrow{e=1} b \xrightarrow{e=4} d \xrightarrow{e=3} c \xrightarrow{e=2} b$$

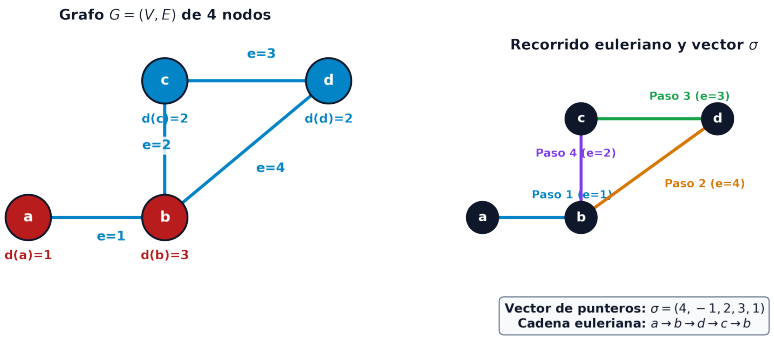

Figura 10.2: Grafo de 4 nodos y traza algorítmica de la cadena euleriana mediante el vector de punteros sigma

---

10.2. El Problema del Cartero Chino (CPP)

En la inmensa mayoría de las aplicaciones prácticas de transporte y servicios urbanos (tales como el reparto postal a domicilio, la recogida selectiva de residuos sólidos urbanos, la limpieza y barrido mecanizado de calles, el esparcimiento de sal en vías nevadas o la inspección de redes de tendido eléctrico y canalizaciones de agua), las redes viales reales no son eulerianas, ya que suelen contener múltiples intersecciones con un número impar de calles convergentes.

El **Problema del Cartero Chino** (conocido en la literatura internacional como *Chinese Postman Problem*, CPP, o problema del circuito de inspección de aristas) plantea determinar el recorrido cerrado de **longitud o coste total mínimo** que visite **cada arista de la red al menos una vez**, regresando al punto de partida (Kwan 1962). El problema fue formulado originalmente en 1960 por el matemático chino **Mei-Ko Kwan**, y su denominación en lengua inglesa fue propuesta en 1962 por el investigador operativo Alan J. Goldman.

i Definición: Problema del Cartero Chino (CPP)

Dada una red valorada no dirigida $G = (V, E, p)$, donde V es el conjunto de vértices, E es el conjunto de aristas y $p : E \to \mathbb{R}^+$ asigna un peso o longitud no negativa $p(e)$ a cada arista $e \in E$:
El **Problema del Cartero Chino** consiste en encontrar un circuito cerrado C que

recorra todas las aristas de E al menos una vez de tal manera que la longitud total del circuito sea mínima:

$$\min_{C} \sum_{e \in C} p(e) \quad \text{sujeto a} \quad E \subseteq C$$

Si la red original G es euleriana (todos sus vértices tienen grado par), cualquier ciclo euleriano constituye una solución óptima exacta del problema, y la longitud de la ruta óptima coincide exactamente con la suma de las longitudes de todas las aristas de la red: $\sum_{e \in E} p(e)$.

Sin embargo, si G contiene vértices de grado impar, resulta imposible recorrer la red pasando exactamente una sola vez por cada arista. Por tanto, el cartero se ve obligado a **repetir (duplicar) ciertas aristas** de la red. La resolución del CPP radica precisamente en determinar qué colección de aristas debe duplicarse para que el coste añadido sea el menor posible.

Para ilustrar este principio de forma intuitiva, consideremos la red valorada de 9 nodos mostrada en la Figura 10.4. Al evaluar los grados de sus vértices, se comprueba que cuatro de ellos (a, b, c, d) tienen grado impar $(d = 3)$, el nodo central e tiene grado par $(d = 4)$ y las cuatro esquinas (i, f, h, g) tienen grado 2. Al contener 4 nodos impares, la red no es euleriana.

Una solución directa para habilitar un ciclo cerrado consiste en añadir aristas duplicadas E' (copias exactas de aristas originales de E) hasta lograr que en el multigrafo resultante $G' = (V, E \cup E')$ todos los vértices tengan grado par. Por ejemplo, si duplicamos tentativamente las cuatro aristas que conectan los nodos impares con el nodo central e ($\{a, e\}, \{b, e\}, \{e, c\}, \{e, d\}$), como se ilustra en la Figura 10.3, los grados en G' pasan a ser:

$$d_{G'}(a) = 4, \quad d_{G'}(b) = 4, \quad d_{G'}(c) = 4, \quad d_{G'}(d) = 4, \quad d_{G'}(e) = 8,$$
$$d_{G'}(i) = d_{G'}(f) = d_{G'}(h) = d_{G'}(g) = 2$$

En este multigrafo G', **todos los vértices son pares**, por lo que ya admite un ciclo euleriano continuo. El coste añadido por esta eulerización tentativa es:

$$\text{Coste}(E') = p(a, e) + p(b, e) + p(e, c) + p(e, d) = 3 + 3 + 3 + 6 = 15$$

Ahora bien, surge la cuestión central: *¿Es este conjunto E' el de menor coste posible, o existe otra combinación de aristas que eulerice la red con un incremento de distancia inferior?* Para responder a esta pregunta de forma óptima, formalizaremos a continuación la estructura analítica del problema.

10.2.1. Caracterización analítica y eulerización óptima

Para duplicar aristas de manera óptima, debemos formalizar la estructura combinatoria de los vértices impares y de las aristas repetidas.

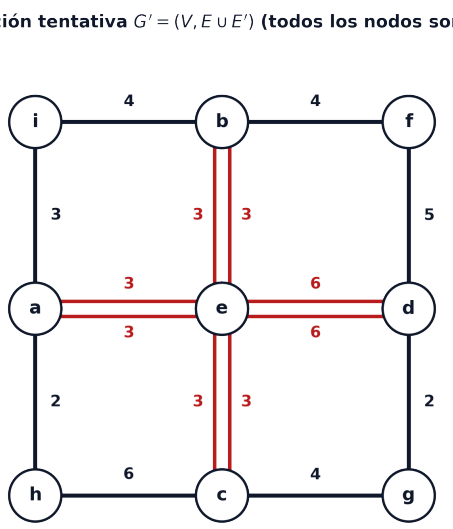

Figura 10.3: Eulerización conceptual tentativa de la red de 9 nodos mediante la duplicación de aristas hacia el nodo central e

Proposición: Paridad del número de vértices de grado impar

En cualquier multigrafo finito $G = (V, E)$, el número de vértices con grado impar es estrictamente un **número par**.
Demostración: Por el lema del apretón de manos (*Handshaking Lemma*), la suma de los grados de todos los vértices es igual al doble del número de aristas:

$$\sum_{i \in V} d(i) = 2|E|$$

Dado que $2|E|$ es un número par, podemos descomponer la suma entre el conjunto de vértices de grado par V_{par} y el conjunto de vértices de grado impar V_{impar}:

$$\sum_{i \in V_{\text{impar}}} d(i) + \sum_{i \in V_{\text{par}}} d(i) = 2|E|$$

Como la suma de términos pares $\sum_{i \in V_{\text{par}}} d(i)$ es par, la suma $\sum_{i \in V_{\text{impar}}} d(i)$ debe ser obligatoriamente un número par. Puesto que la suma de una colección de números impares es par si y solo si la cantidad de sumandos es par, se concluye que el cardinal $|V_{\text{impar}}|$ es necesariamente par. ■

Sea $V' = \{v \in V \mid d(v) \equiv 1 \pmod 2\}$ el subconjunto de vértices de grado impar en G, con $|V'| = 2k$. Para transformar G en un multigrafo euleriano $G' = (V, E \cup E')$, debemos añadir

un conjunto de aristas copia E' (donde cada arista de E' es un duplicado de una arista original de E) de forma que en G' todos los vértices tengan grado par.

Proposición: Estructura de caminos de las aristas duplicadas

Sea $G = (V, E)$ un grafo no euleriano y sea E' un conjunto minimal de aristas duplicadas que convierte a $G' = (V, E \cup E')$ en un grafo euleriano. Entonces, para todo vértice $i_1 \in V'$, el conjunto E' contiene una cadena que une i_1 con otro vértice $i_2 \in V'$.
Demostración: Por construcción, en el multigrafo eulerizado G' se cumple que $d_{G'}(i) \geq d_G(i)$ para todo $i \in V$, y todos los vértices en G' tienen grado par. Dado que $i_1 \in V'$ tenía grado impar en G, en el grafo de aristas añadidas $G_{E'} = (V, E')$ el grado de i_1 debe ser impar (para que la suma $d_G(i_1) + d_{E'}(i_1) = d_{G'}(i_1)$ sea par). Por tanto, existe al menos una arista añadida en E' que incide en i_1, denotada por $\{i_1, j\}$. Si el nodo $j \in V'$, hemos encontrado una cadena directa que une dos nodos de V' y el resultado queda demostrado. Si $j \notin V'$, el nodo j tenía grado par en G. Al añadir la arista $\{i_1, j\}$, su grado en G' se volvería impar a menos que exista otra arista $\{j, k\} \in E'$ incidente en j. Repitiendo este razonamiento de forma secuencial sobre los nodos intermedios, como el conjunto de vértices de la red es finito y no se pueden generar ramas infinitas, la cadena de aristas de E' debe terminar obligatoriamente en otro vértice $i_2 \in V'$. ■

Esta proposición demuestra algebraicamente que **la eulerización óptima de una red equivale a encontrar un conjunto de caminos de longitud mínima en G que emparejen los $2k$ vértices de grado impar de dos en dos**. Para formalizar esta optimización combinatoria sobre el grafo auxiliar de distancias, recordamos las definiciones canónicas de la teoría de emparejamientos:

Definición: Emparejamientos y emparejamiento perfecto de peso mínimo

Dado un grafo no dirigido $G = (V, E)$:

- **Emparejamiento (*matching*)**: Es un subconjunto de aristas $M \subseteq E$ tales que ningún par de aristas de M comparte vértices en común (es decir, no existen aristas adyacentes en M).
- **Vértice saturado**: Un vértice $v \in V$ se dice saturado por M si incide en alguna arista de M.
- **Emparejamiento perfecto**: Un emparejamiento M es perfecto si **satura a todos los vértices de** V (cada nodo de V es extremo de exactamente una arista de M). Para que un grafo admita un emparejamiento perfecto, es condición necesaria que $|V|$ sea par.
- **Problema del emparejamiento perfecto de peso mínimo**: En una red valorada $G = (V, E, p)$, consiste en determinar un emparejamiento perfecto M^* que minimice

la suma de los pesos de sus aristas:

$$\begin{aligned} \min_{M \subseteq E} \quad & \sum_{e \in M} p(e) \\ \text{sujeto a} \quad & M \text{ es emparejamiento perfecto} \end{aligned}$$

Dado que el grafo auxiliar $G'' = (V', E'')$ construido sobre el conjunto de vértices impares es completo y posee un número estrictamente par de nodos ($|V'| = 2k$), siempre admite al menos un emparejamiento perfecto. Por tanto, el procedimiento sistemático de resolución se articula en las siguientes etapas:

Esquema: Procedimiento general de resolución del Problema del Cartero Chino

Dado un grafo conexo valorado $G = (V, E, p)$:

1. **Identificación de vértices impares**: Determinar el grado $d(i)$ de cada vértice en G e identificar el subconjunto de nodos impares $V' = \{v \in V \mid d(v) \text{ es impar}\}$. Si $V' = \emptyset$, el grafo es euleriano y se pasa directamente al paso 5.
2. **Cálculo de distancias mínimas**: Calcular las distancias del camino mínimo $d_G(u, v)$ entre todo par de vértices $u, v \in V'$ utilizando el algoritmo de Dijkstra o Floyd-Warshall.
3. **Construcción del grafo auxiliar de emparejamiento**: Construir un **grafo auxiliar completo** $G'' = (V', E'')$, cuyos vértices son exclusivamente los elementos de V' y donde cada arista $\{u, v\} \in E''$ tiene un peso igual a la distancia mínima $d_G(u, v)$ calculada en el paso anterior.
4. **Resolución del emparejamiento perfecto de peso mínimo**: Determinar en G'' un **emparejamiento perfecto de peso mínimo** (utilizando el algoritmo de la Flor de Edmonds o enumeración de combinaciones si $|V'|$ es pequeño).
5. **Construcción del multigrafo euleriano y circuito final**: Para cada pareja de nodos $\{u, v\}$ seleccionada en el emparejamiento óptimo, duplicar en G las aristas que integran el camino mínimo entre u y v. El multigrafo resultante G' es euleriano. Aplicar el algoritmo de construcción euleriana para obtener la ruta final del cartero.

A continuación, aplicamos este procedimiento a un caso práctico de 9 nodos.

Ejemplo: Resolución completa del Problema del Cartero Chino en una red de 9 nodos

Consideremos la red valorada de 9 nodos $V = \{a, b, c, d, e, f, g, h, i\}$ y 12 aristas mostrada

en la Figura 10.4, con los siguientes pesos de arista:

$$p(i,b)=4,\quad p(b,f)=4,\quad p(i,a)=3,\quad p(b,e)=3,\quad p(f,d)=5,$$
$$p(a,e)=3,\quad p(e,d)=6,\quad p(a,h)=2,\quad p(e,c)=3,\quad p(d,g)=2,$$
$$p(h,c)=6,\quad p(c,g)=4$$

La suma del coste de todas las aristas originales del grafo es:

$$\sum_{e\in E} p(e) = 4+4+3+3+5+3+6+2+3+2+6+4 = 38$$

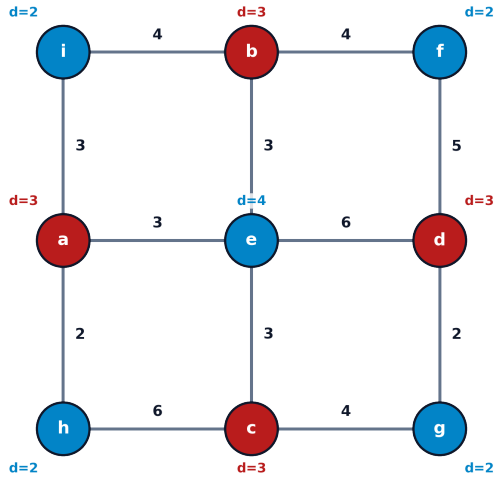

Figura 10.4: Red valorada original de 9 nodos para el Problema del Cartero Chino con los grados nodales y vértices impares destacados

1. **Identificación de nodos impares (V')**: Calculando los grados de los 9 vértices:

   $d(i)=2,\ d(b)=3,\ d(f)=2,\ d(a)=3,\ d(e)=4,\ d(d)=3,\ d(h)=2,\ d(c)=3,\ d(g)=2$

   El subconjunto de vértices con grado impar contiene 4 nodos: $V'=\{a,b,c,d\}$.

2. **Cálculo de caminos mínimos entre vértices de V'**:

   - Camino $a \leftrightarrow b$: Vía $a-e-b$, coste $d(a,b)=3+3=6$.
   - Camino $a \leftrightarrow c$: Vía $a-e-c$, coste $d(a,c)=3+3=6$.
   - Camino $a \leftrightarrow d$: Vía $a-e-d$, coste $d(a,d)=3+6=9$.
   - Camino $b \leftrightarrow c$: Vía $b-e-c$, coste $d(b,c)=3+3=6$.

- Camino $b \leftrightarrow d$: Vía $b - f - d$, coste $d(b,d) = 4 + 5 = 9$ (o vía $b - e - d$: $3 + 6 = 9$).
- Camino $c \leftrightarrow d$: Vía $c - g - d$, coste $d(c,d) = 4 + 2 = 6$.

3. **Construcción de G'' y evaluación de emparejamientos perfectos**: El grafo auxiliar completo $G'' = (V', E'')$ sobre los 4 nodos $\{a, b, c, d\}$ admite exactamente tres emparejamientos perfectos posibles, ilustrados en la Figura 10.5:

   - **Emparejamiento** $M_1 = \{\{a,b\},\{c,d\}\}$:

   $$\text{Coste}(M_1) = d(a,b) + d(c,d) = 6 + 6 = \mathbf{12} \quad \text{[ÓPTIMO]}$$

   - **Emparejamiento** $M_2 = \{\{a,c\},\{b,d\}\}$:

   $$\text{Coste}(M_2) = d(a,c) + d(b,d) = 6 + 9 = 15$$

   - **Emparejamiento** $M_3 = \{\{a,d\},\{b,c\}\}$:

   $$\text{Coste}(M_3) = d(a,d) + d(b,c) = 9 + 6 = 15$$

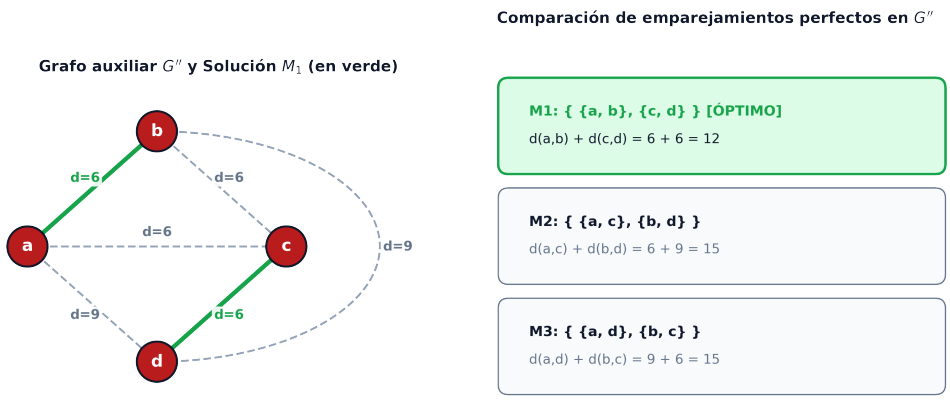

Figura 10.5: Grafo auxiliar completo G'' (izquierda) y comparación de costes de los tres emparejamientos perfectos (derecha)

4. **Eulerización y longitud óptima del circuito**: El emparejamiento óptimo M_1 prescribe duplicar las aristas que componen el camino entre a y b (aristas $\{a,e\}$ y $\{e,b\}$) y las que componen el camino entre c y d (aristas $\{c,g\}$ y $\{g,d\}$), como se ilustra en la Figura 10.6.

La longitud mínima de la ruta del cartero chino resulta:

$$\text{Longitud Óptima} = \sum_{e \in E} p(e) + \text{Coste}(M_1) = 38 + 12 = \mathbf{50}$$

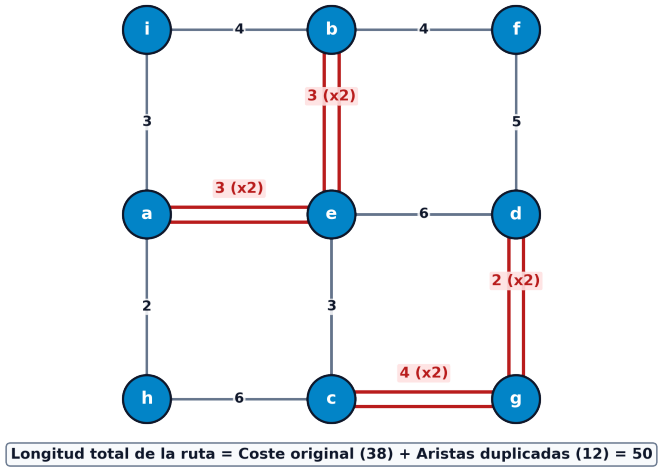

Figura 10.6: Multigrafo eulerizado con las aristas duplicadas destacadas en rojo y la solución óptima del cartero chino

Veamos ahora un segundo ejemplo clásico de aplicación en ingeniería civil y delimitación de parcelas.

Ejemplo: Problema de examen: Vallado perimetral continuo de parcelas

Se desea cercar un terreno dividiéndolo en cuatro parcelas A, B, C y D, según se indica en la Figura 10.7 (cada tramo de los bordes indica la longitud del mismo). Por motivos de seguridad, el cerramiento se hace mediante una cerca prefabricada que se extiende a lo largo de todos los bordes, que no se puede partir y debe terminar exactamente donde empieza.

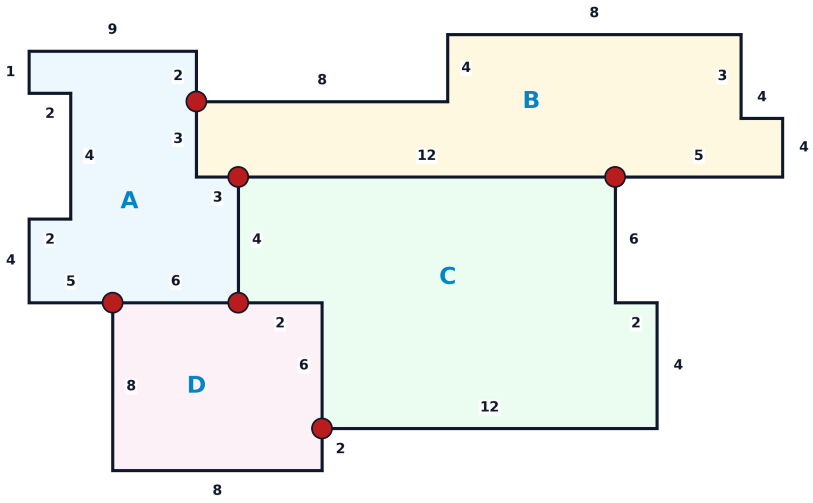

Figura 10.7: Plano geométrico del terreno con las cuatro parcelas A, B, C y D con sus cotas de longitud y los 6 vértices impares destacados

1. **(0.5 puntos) ¿Qué problema de grafos se está planteando?**: Se trata formalmente del **Problema del Cartero Chino (CPP)** (o problema de inspección de rutas). El objetivo es encontrar el circuito cerrado de longitud mínima que recorra todas las aristas de un grafo al menos una vez y regrese al punto de partida. Dado que se exige instalar una cerca continua que cubra todos los bordes, es necesario trazar un ciclo euleriano. Al contar el mapa con intersecciones donde confluyen tres bordes (**vértices de grado impar**), el grafo no es euleriano de origen. El problema consiste, por tanto, en determinar qué tramos deben duplicarse (para tender la cerca dos veces por el mismo borde) garantizando que la longitud extra sea la mínima posible.

2. **(1.0 punto) Describir el procedimiento de solución**: El procedimiento general de resolución se articula en las siguientes cinco etapas sistemáticas:

   - **Paso 1 (Identificación de vértices impares)**: Modelar la red topológica $G = (V, E, p)$, determinar el grado $d(v)$ de cada vértice e identificar el subconjunto de nodos con grado impar $V' = \{v \in V \mid d(v) \equiv 1 \pmod 2\}$.
   - **Paso 2 (Cálculo de distancias mínimas)**: Calcular las distancias del camino mínimo $d_G(u, v)$ entre todo par de vértices $u, v \in V'$ utilizando el algoritmo de Dijkstra.
   - **Paso 3 (Construcción del grafo auxiliar de emparejamiento)**: Construir

el grafo auxiliar completo $G'' = (V', E'')$ sobre el conjunto de nodos impares V', asignando a cada arista $\{u, v\} \in E''$ un peso igual a la distancia mínima $d_G(u, v)$ calculada en el paso anterior.

- **Paso 4 (Resolución del emparejamiento perfecto de peso mínimo)**: Determinar en G'' un **emparejamiento perfecto de peso mínimo** M^*.
- **Paso 5 (Construcción del multigrafo euleriano y cálculo de la longitud final)**: Duplicar en G las aristas que integran los caminos mínimos asociados a cada pareja de M^*. La longitud total de la valla continua será la suma de las longitudes de todos los tramos originales más el coste del emparejamiento óptimo:

$$L_{\text{total}} = \sum_{e \in E} p(e) + \text{Coste}(M^*)$$

3. **(1.0 punto) ¿Cuál es la solución para el caso planteado?**: Aplicamos de forma secuencial las 5 etapas del procedimiento descrito:

   - **Paso 1 (Identificación de vértices impares V')**: Se calculan las longitudes de los tramos que delimitan el terreno:
     - *Aristas internas (fronteras entre parcelas)*: Entre A y B (3), entre A y C (4), entre B y C (12), entre A y D (6), entre C y D ($2 + 6 = 8$). Suma interna = 33 m.
     - *Aristas externas (perímetro exterior)*: Borde exterior de A ($2 + 9 + 1 + 2 + 4 + 2 + 4 + 5 = 29$), borde de B ($8 + 4 + 8 + 3 + 4 + 4 + 5 = 36$), borde de C ($6 + 2 + 4 + 12 = 24$), borde de D ($8 + 8 + 2 = 18$). Suma externa = 107 m.
     - *Longitud base de la red*: $L_{\text{base}} = 33 + 107 = \mathbf{140}$ m.

     Analizando la topología, las esquinas exteriores tienen grado 2 (par), mientras que en los 6 puntos de intersección donde confluyen tres lindes (puntos rojos en la Figura 10.7), el grado es estrictamente 3 (impar). Por tanto, el conjunto de vértices impares contiene 6 nodos: $|V'| = 6$.
   - **Paso 2 (Cálculo de distancias mínimas entre vértices de V')**:
     - Camino entre el punto superior (A-B) y el central (A-B-C): Arista interior directa con distancia $d = \mathbf{3}$.
     - Camino entre el punto inferior (A-D) y el central inferior (A-C-D): Arista interior directa con distancia $d = \mathbf{6}$.
     - Camino entre los dos extremos de la derecha (extremo de B-C y extremo de C-D): Distancia mínima $d = \mathbf{24}$, alcanzable tanto por el contorno exterior de C ($6 + 2 + 4 + 12 = 24$) como por el interior (B-C) + (A-C) + (C-D) = $12 + 4 + 8 = 24$.
   - **Paso 3 (Construcción del grafo auxiliar G'')**: Se construye el grafo auxiliar completo $G'' = (V', E'')$ sobre los 6 vértices impares ponderado con la matriz de distancias mínimas.

- **Paso 4 (Resolución del emparejamiento perfecto de peso mínimo M^*)**: Evaluando las combinaciones de emparejamientos perfectos posibles sobre los 6 vértices, el emparejamiento óptimo es aquel que selecciona las tres parejas mínimas identificadas:

$$\text{Coste}(M^*) = 3 + 6 + 24 = \mathbf{33}\ \text{m}$$

- **Paso 5 (Construcción del multigrafo euleriano y longitud total óptima)**: Duplicando las aristas de los caminos mínimos asociados a M^*, todos los vértices pasan a tener grado par en el multigrafo resultante. La longitud mínima de la cerca prefabricada continua es:

$$\begin{aligned} L_{\text{total}} &= L_{\text{base}} + \text{Coste}(M^*) \\ &= 140\ \text{(base)} + 33\ \text{(duplicados)} = \mathbf{173}\ \text{m} \end{aligned}$$

10.2.2. Variantes del Problema del Cartero Chino

El modelo clásico no dirigido del cartero chino admite diversas extensiones operativas de gran relevancia:

- **Cartero chino dirigido / motorizado (Directed CPP)**: En cascos urbanos con calles de sentido único, la red se modela como un digrafo $G = (V, U)$. El digrafo es euleriano si y solo si para todo vértice $i \in V$ el grado de entrada coincide con el de salida ($d^-(i) = d^+(i)$). Si la red no es euleriana, la eulerización no se resuelve por emparejamiento, sino mediante un **modelo de transbordo y flujo a coste mínimo**, donde los nodos con exceso de salida ($d^+(i) > d^-(i)$) actúan como fuentes de oferta $b_i = d^+(i) - d^-(i)$ y los nodos con exceso de entrada ($d^-(i) > d^+(i)$) actúan como sumideros de demanda $b_j = -(d^-(j) - d^+(j))$.
- **Cartero chino con costes asimétricos / viento (Windy Postman Problem)**: El coste o tiempo de transitar por una calle depende de la dirección de avance debido a pendientes pronunciadas o corrientes de viento predominantes ($c(i,j) \neq c(j,i)$). Este problema es $\mathcal{NP}$-duro en el caso general.
- **Cartero rural y problemas con beneficios y pérdidas (Rural Postman Problem - RPP)**: En muchas aplicaciones (como la lectura de contadores rurales o el mantenimiento de autopistas), solo un subconjunto de aristas prioritarias $E_R \subseteq E$ debe ser recorrido de forma obligatoria, mientras que las restantes aristas $E \setminus E_R$ pueden utilizarse libremente como vías de tránsito si abaratan el recorrido global. El RPP es un problema $\mathcal{NP}$-completo.

10.3. Ciclos hamiltonianos y condiciones de hamiltonianidad

A diferencia de los ciclos eulerianos, cuyo objetivo es recorrer todas las aristas de una red sin repetición, existen numerosos problemas donde el objetivo consiste en visitar **todos los vértices** de la red exactamente una vez.

El concepto de **ciclo hamiltoniano** debe su nombre al matemático y astrónomo irlandés **Sir William Rowan Hamilton**, quien en 1857 patentó un juego didáctico denominado el *Juego Icosiano* (*Icosian Game*) (Hamilton 1857). El pasatiempo consistía en un tablero de madera que representaba la estructura de un dodecaedro regular de 20 vértices (identificados con nombres de ciudades del mundo), y el reto planteaba encontrar un recorrido a lo largo de las aristas del poliedro que visitara las 20 ciudades exactamente una vez sin repetir ninguna, regresando a la ciudad de origen.

i Definición: Ciclos y caminos hamiltonianos

Dado un grafo $G = (V, E)$ con $n = |V|$ vértices:

- **Ciclo hamiltoniano**: Es un ciclo simple en G que contiene **todos los vértices de** V exactamente una vez (excepto el vértice de partida, al que regresa para cerrar el ciclo).
- **Camino hamiltoniano**: Es una trayectoria o camino simple en G que visita todos los vértices de V exactamente una vez (sin regresar al origen).
- **Grafo hamiltoniano**: Un grafo que admite al menos un ciclo hamiltoniano.

A pesar de la aparente similitud conceptual entre el problema euleriano (visitar todas las aristas) y el problema hamiltoniano (visitar todos los vértices), existe un abismo infranqueable en su **complejidad computacional**:

- El problema de determinar si un grafo es euleriano se resuelve de forma instantánea en tiempo lineal $\mathcal{O}(|V| + |E|)$ comprobando la paridad de los grados. Pertenece a la clase $\mathcal{P}$.
- El problema de determinar si un grafo general contiene un ciclo hamiltoniano (**HAMILTONIAN-CYCLE**) es uno de los 21 problemas clásicos demostrados como $\mathcal{NP}$**-completos** por Richard Karp en 1972 (Karp 1972).

No se conocen condiciones necesarias y suficientes simultáneamente que puedan verificarse en tiempo polinomial. Por ello, el análisis formal se apoya en condiciones necesarias de corte y condiciones suficientes basadas en la densidad de grados.

10.3.1. Condiciones necesarias: 2-conexidad y cortes nodales

Para que un grafo admita un ciclo hamiltoniano, debe poseer una estructura de conectividad robusta que garantice la existencia de rutas alternativas.

Definición: Conjuntos de corte y k-conexidad

Dado un grafo conexo $G = (V, E)$:

- **Conjunto de corte de vértices**: Un subconjunto de vértices $A \subset V$ es un conjunto de corte si el subgrafo inducido por los restantes vértices $V \setminus A$ es disconexo.
- **Grafo k-conexo**: Un grafo G es k-conexo si $|V| \geq k + 1$ y no contiene ningún conjunto de corte de cardinal menor que k (es decir, se requiere eliminar al menos k vértices para desconectar el grafo). En particular, todo grafo k-conexo satisface $d_G(i) \geq k$ para todo $i \in V$.

Proposición: Condición necesaria de 2-conexidad

Si un grafo $G = (V, E)$ es hamiltoniano, entonces G es obligatoriamente **2-conexo** (no posee vértices de corte o puntos de articulación).
Demostración: Demostremos el resultado por reducción al absurdo. Supongamos que G es hamiltoniano pero no es 2-conexo. Entonces, existe un conjunto de corte $A = \{v\}$ formado por un único vértice (punto de articulación), cuya eliminación divide al grafo en al menos dos componentes conexas disyuntas G_1 y G_2. Cualquier ciclo hamiltoniano C debe visitar la totalidad de los vértices de G_1 y de G_2. Para transitar desde los vértices de G_1 hacia los de G_2, el ciclo debe pasar obligatoriamente por el único vértice conector v. Asimismo, para regresar de G_2 a G_1 y poder cerrar el ciclo, el recorrido debe transitar una segunda vez por v. Por tanto, el ciclo pasaría al menos dos veces por v, contradiciendo la definición de ciclo simple hamiltoniano. ■

La 2-conexidad es una condición estrictamente **necesaria pero no suficiente**. En la Figura 10.8 se muestra un contraejemplo clásico: un grafo de 5 nodos formado por tres caminos paralelos entre los nodos a y e. El grafo es 2-conexo (no se desconecta eliminando un solo nodo y todos sus vértices cumplen $d(v) \geq 2$), pero no es hamiltoniano porque cualquier ciclo que visite b, c y d (que tienen grado 2) requeriría pasar tres veces por a y por e.

10.3.2. Condiciones suficientes: Proposición de adyacencia y Teorema de Bondy y Chvátal

Para establecer condiciones suficientes de hamiltonianidad, se estudian los grafos completos y el efecto de añadir aristas entre vértices de grado elevado.

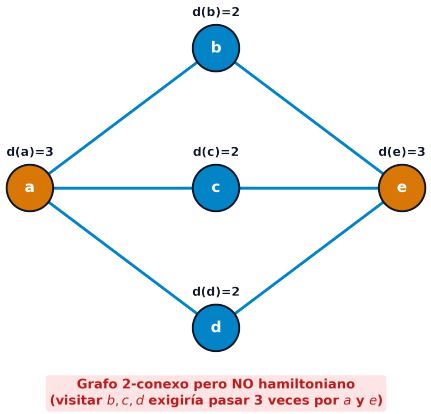

Figura 10.8: Contraejemplo: grafo 2-conexo que no es hamiltoniano debido al estrangulamiento en los nodos conectores

Proposición: Hamiltonianidad del grafo completo

Todo grafo simple completo K_n con $n \geq 3$ vértices es hamiltoniano y contiene exactamente:

$$\frac{(n-1)!}{2}$$

ciclos hamiltonianos distintos no orientados ($n!$ si se considera el orden y sentido de recorrido).

El resultado teórico fundamental que sustenta las condiciones modernas de suficiencia establece que añadir una arista entre dos nodos cuya suma de grados supera el número total de vértices no altera la condición de hamiltonianidad del grafo.

Teorema: Proposición fundamental de adyacencia de Bondy y Chvátal

Sea $G = (V, E)$ un grafo simple con $n = |V| \geq 3$ vértices y sean $s, t \in V$ dos vértices **no adyacentes** tales que la suma de sus grados cumple:

$$d_G(s) + d_G(t) \geq n$$

Se define el grafo ampliado $G + \{s, t\} = (V, E \cup \{\{s, t\}\})$. Entonces:

$$G \text{ es hamiltoniano} \iff G + \{s, t\} \text{ es hamiltoniano}$$

Demostración: La implicación directa ($\Longrightarrow$) es trivial: si G ya contiene un ciclo hamiltoniano, dicho ciclo existe igualmente en el supergrafo $G + \{s, t\}$.

Demostremos la implicación recíproca ($\Longleftarrow$). Supongamos que $G+\{s,t\}$ contiene un ciclo hamiltoniano C. Si la arista añadida $\{s,t\}$ no forma parte de C, entonces C está contenido íntegramente en G y el resultado queda demostrado. Supongamos ahora que $\{s,t\} \in C$. Numeramos los vértices a lo largo del ciclo C comenzando en $s = x_1$ y terminando en $t = x_n$, de modo que el ciclo en $G + \{s,t\}$ es:

$$s = x_1 \to x_2 \to x_3 \to ... \to x_{n-1} \to x_n = t \xrightarrow{\{s,t\}} s$$

Para reconstruir un ciclo hamiltoniano en el grafo original G sin utilizar la arista $\{s,t\}$, buscamos un índice intermedio $i \in \{2,3,...,n-2\}$ tal que en G existan simultáneamente la arista $\{s, x_{i+1}\}$ y la arista $\{t, x_i\}$, como se ilustra en la Figura 10.9.
Definimos los siguientes dos subconjuntos de vértices:

$$A = \{x_i \in V \mid \{s, x_{i+1}\} \in E,\ i \in \{2,...,n-2\}\}$$
$$B = \{x_i \in V \mid \{t, x_i\} \in E,\ i \in \{2,...,n-2\}\}$$

Evaluemos los cardinales de estos conjuntos:

- El vértice s puede ser adyacente a lo sumo a los nodos $\{x_2,...,x_{n-1}\}$. Dado que $\{s,t\} \notin E$ y descontando la arista $\{s,x_2\}$ (cuyo predecesor es x_1), el número de vecinos de s entre los nodos $\{x_3,...,x_{n-1}\}$ es $|A| = d_G(s) - 1$.
- De igual forma, el vértice t no está conectado a s, y descontando su conexión con x_{n-1}, se tiene $|B| = d_G(t) - 1$.

Sumando ambos cardinales:

$$|A| + |B| = (d_G(s) - 1) + (d_G(t) - 1) = d_G(s) + d_G(t) - 2 \geq n - 2$$

Por otra parte, ambos conjuntos están contenidos en el universo $U = \{x_2, x_3, ..., x_{n-2}\}$, cuyo cardinal es $|U| = n - 3$. Por tanto, la unión satisface $|A \cup B| \leq n - 3$. Aplicando el principio de inclusión-exclusión:

$$|A \cap B| = |A| + |B| - |A \cup B| \geq (n-2) - (n-3) = 1$$

Como $|A \cap B| \geq 1$, la intersección es **no vacía** ($A \cap B \neq \emptyset$). Existe al menos un vértice x_i tal que $\{s, x_{i+1}\} \in E$ y $\{t, x_i\} \in E$.
Eliminando del ciclo C las aristas $\{s,t\}$ y $\{x_i, x_{i+1}\}$ e insertando las aristas $\{s, x_{i+1}\}$ y $\{t, x_i\}$, se obtiene el ciclo:

$$s \to x_2 \to ... \to x_i \to t \to x_{n-1} \to x_{n-2} \to ... \to x_{i+1} \to s$$

Este ciclo recorre todos los vértices de V una sola vez y está compuesto exclusivamente por aristas de E. Por tanto, G es hamiltoniano. ■

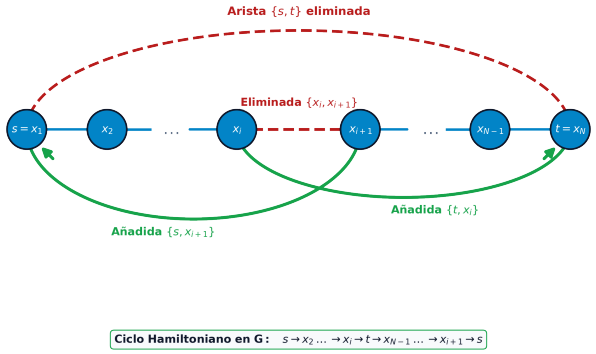

Figura 10.9: Esquema demostrativo de la proposición de adyacencia: sustitución de aristas para reconstruir el ciclo hamiltoniano

La aplicación iterativa de esta proposición conduce de forma natural al concepto de **clausura**.

Definición: Clausura de Bondy y Chvátal

Dado un grafo simple $G = (V, E)$ con n vértices, la **clausura de** G, denotada por $[G]$, es el grafo obtenido añadiendo recursivamente aristas entre parejas de vértices no adyacentes u, v que satisfacen $d(u) + d(v) \geq n$, hasta que no sea posible añadir ninguna arista adicional. La clausura $[G]$ es única e independiente del orden en que se añadan las aristas.

Teorema: Teorema de Bondy y Chvátal (1976)

Un grafo simple G es **hamiltoniano si y solo si su clausura** $[G]$ **es hamiltoniana**. En particular, si la clausura de G es el grafo completo ($[G] = K_n$), entonces G es **hamiltoniano** (Bondy y Chvátal 1976).

La caracterización de Bondy y Chvátal establece una equivalencia lógica exacta (G hamiltoniano $\iff$ $[G]$ hamiltoniano). No obstante, cuando se utiliza la condición simplificada de clausura completa $[G] = K_n$ como criterio práctico de verificación, debe tenerse en cuenta su naturaleza asimétrica:

Advertencia: El criterio $[G] = K_n$ es condición suficiente, pero no necesaria

Es crucial resaltar que la condición de que la clausura alcance el grafo completo ($[G] = K_n$) es una **condición suficiente pero no necesaria** para la existencia de ciclos hamiltonianos.

Como contraejemplo fundamental, consideremos el **grafo ciclo** $C_5 = (a, b, d, e, c, a)$ de $n = 5$ vértices ilustrado en la Figura 10.10. Este grafo es **evidentemente hamiltoniano** (el propio ciclo recorre todos sus vértices una sola vez). Sin embargo, al ser un ciclo simple regular de grado 2, todos sus vértices satisfacen $d(v) = 2$. Por tanto, para cualquier par de vértices no adyacentes u, v, la suma de grados resulta:

$$d(u) + d(v) = 2 + 2 = 4 < n = 5$$

Al no cumplirse la condición en ningún par, no es posible añadir ninguna arista, por lo que la clausura coincide con el grafo original: $[C_5] = C_5 \neq K_5$. Por consiguiente, si la clausura de un grafo no es completa ($[G] \neq K_n$), **no se puede deducir que el grafo no sea hamiltoniano** (el criterio de clausura completa resulta no concluyente).

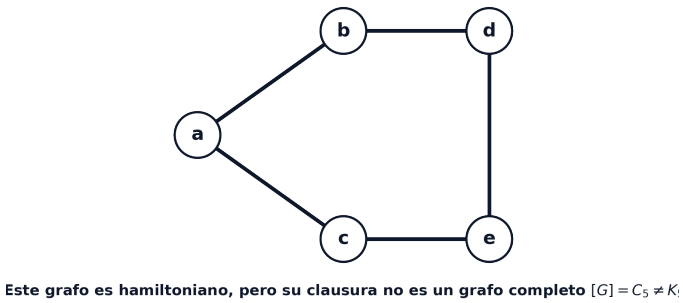

Figura 10.10: Contraejemplo de suficiencia: el grafo ciclo C_5 es hamiltoniano pero su clausura no es el grafo completo

Como corolarios directos del teorema de Bondy y Chvátal se deducen de forma inmediata los teoremas clásicos de suficiencia más célebres de la literatura:

Corolario: Teoremas clásicos de Dirac (1952) y Ore (1960)

Sea $G = (V, E)$ un grafo simple con $n \geq 3$ vértices:

- **Teorema de Ore (1960)**: Si para todo par de vértices no adyacentes $u, v \in V$ se cumple $d(u) + d(v) \geq n$, entonces G es hamiltoniano (su clausura es directamente el grafo completo K_n).

- **Teorema de Dirac (1952)**: Si el grado mínimo de todo vértice cumple $d(v) \geq \frac{n}{2}$ para todo $v \in V$, entonces para cualquier par no adyacente $d(u)+d(v) \geq \frac{n}{2}+\frac{n}{2} = n$, y por tanto G es hamiltoniano (Dirac 1952; Ore 1960).

En el siguiente ejemplo, ilustramos el cálculo de la clausura en dos grafos distintos.

Ejemplo: Cálculo y evaluación de la clausura de Bondy y Chvátal

Analicemos los dos grafos representados en la Figura 10.11:

1. **Ejemplo 1 (Grafo de 4 nodos, panel izquierdo)**:
   - Vértices: $V = \{a, b, c, d\}$, con $n = 4$.
   - Aristas originales: $\{a, b\}, \{a, c\}, \{a, d\}, \{b, c\}, \{b, d\}$.
   - Grados iniciales: $d(a) = 3, d(b) = 3, d(c) = 2, d(d) = 2$.
   - El único par de vértices no adyacentes es $\{c, d\}$.
   - Evaluando la condición: $d(c) + d(d) = 2 + 2 = 4 \geq n = 4$.
   - Se añade la arista $\{c, d\}$. El grafo resultante es el grafo completo K_4.
   - Por el Teorema de Bondy y Chvátal, $[G] = K_4 \implies G$ **es hamiltoniano**.
2. **Ejemplo 2 (Grafo de 5 nodos, panel derecho)**:
   - Vértices: $V = \{a, b, c, d, e\}$, con $n = 5$.
   - Aristas iniciales: $\{a, b\}, \{b, e\}, \{a, c\}, \{c, e\}, \{a, d\}, \{d, e\}$.
   - Grados iniciales: $d(a) = 3, d(e) = 3, d(b) = 2, d(c) = 2, d(d) = 2$.
   - Evaluando pares no adyacentes:
     - Para $\{a, e\}$: $d(a) + d(e) = 3 + 3 = 6 \geq 5$. Se añade la arista $\{a, e\}$.
     - Los grados se actualizan a $d(a) = 4, d(e) = 4$.
     - Evaluando los restantes pares no adyacentes $\{b, c\}, \{c, d\}, \{b, d\}$: $d(b) + d(c) = 2 + 2 = 4 < 5$, $d(c) + d(d) = 4 < 5$, $d(b) + d(d) = 4 < 5$.
   - No es posible añadir más aristas. La clausura $[G]$ no es completa ($[G] \neq K_5$). La condición de suficiencia no permite certificar la hamiltonianidad (el grafo no es hamiltoniano).

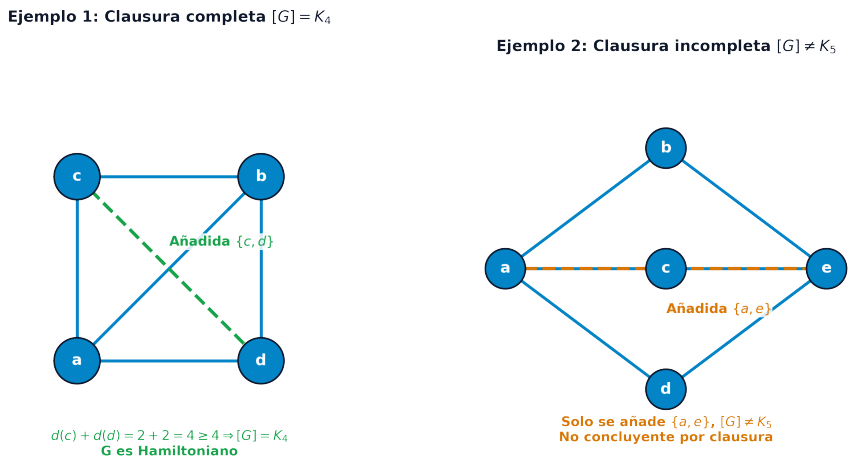

Figura 10.11: Cálculo de la clausura de Bondy y Chvátal: clausura completa $[G] = K_4$ (izquierda) y clausura incompleta (derecha)

10.4. El Problema del Viajante de Comercio (TSP)

El **Problema del Viajante de Comercio** (conocido mundialmente como *Traveling Salesperson Problem*, TSP) es, sin lugar a dudas, el problema más emblemático, estudiado y emblemático de la optimización combinatoria y la programación entera (G. Dantzig, Fulkerson, y Johnson 1954; Applegate et al. 2006).

El problema modela la situación de un agente comercial que debe partir de una ciudad base, visitar un conjunto de n ciudades exactamente una vez y regresar al punto de partida, de modo que la **distancia, tiempo o coste económico total acumulado sea mínimo**.

Las aplicaciones reales del TSP trascienden con creces el ruteo físico de personas y vehículos. Entre sus aplicaciones industriales más destacadas figuran:

- **Fabricación de circuitos impresos (PCB drilling)**: Optimización del orden de perforación de decenas de miles de orificios en placas electrónicas mediante brazos robóticos láser para minimizar el tiempo de desplazamiento del cabezal.
- **Secuenciación de tareas en máquinas (Sequence-dependent scheduling)**: Programación de lotes de producción en una máquina industrial donde el tiempo de limpieza y ajuste entre tareas depende de la tarea inmediatamente precedente (tiempos de cambio de matriz en prensas o purga de color en pintura).

- **Astronomía y observación espacial**: Secuenciación óptima de apuntado de telescopios orbitales (como el Hubble o James Webb) entre constelaciones celestes para minimizar el consumo de combustible en maniobras giroscópicas.
- **Biología computacional y genómica**: Reconstrucción y alineamiento de secuencias de fragmentos de ADN en el ensamblaje de genomas.

i Definición: Problema del Viajante de Comercio (TSP)

Dado un conjunto de n ciudades $V = \{1, 2, \dots, n\}$ y una matriz de costes o distancias $D = (d_{ij})_{n \times n}$, donde $d_{ij} \geq 0$ representa el coste de desplazarse directamente desde la ciudad i hasta la ciudad j:
El **TSP** consiste en encontrar una permutación $\pi = (\pi(1), \pi(2), \dots, \pi(n))$ de las n ciudades que minimice el coste total del ciclo hamiltoniano:

$$\min_{\pi} \left(\sum_{k=1}^{n-1} d_{\pi(k),\pi(k+1)} + d_{\pi(n),\pi(1)} \right)$$

Para abordar el TSP mediante optimizadores matemáticos (*solvers* de programación lineal entera), se han desarrollado diversas formulaciones con propiedades teóricas y computacionales muy dispares. Analizaremos las tres formulaciones fundamentales: el modelo por etapas o tramos (x_{ijk}), el modelo clásico de eliminación exponencial de subciclos de Dantzig, Fulkerson y Johnson (DFJ), y la formulación compacta polinomial de Miller, Tucker y Zemlin (MTZ).

10.4.1. Modelo 1 del TSP: Variables de posición de tramo (x_{ijk})

Una primera aproximación intuitiva para modelar el TSP mediante Programación Lineal Entera consiste en concebir el itinerario del agente como una secuencia ordenada de n etapas o tramos temporales sucesivos.

Variables de decisión: Para formular este modelo, se introducen las variables binarias con triple subíndice $x_{ijk} \in \{0, 1\}$, definidas como:

$$x_{ijk} = \begin{cases} 1 & \text{si el agente se desplaza directamente de } i \text{ a } j \text{ en la etapa } k \\ 0 & \text{en otro caso} \end{cases}$$

para todo $i, j, k \in \{1, \dots, n\}$.

Construcción pedagógica de las restricciones: A partir de estas variables, la exigencia de que la solución forme un ciclo hamiltoniano válido y continuo se traduce en cinco condiciones estructurales fundamentales:

1. **Minimización de la distancia total (Función objetivo)**: Cada desplazamiento entre i y j devenga un coste d_{ij} independientemente de la etapa k en la que se realice. La distancia total acumulada a lo largo de las n etapas del viaje es:

$$\min_x \sum_{i=1}^{n} \sum_{j=1}^{n} \sum_{k=1}^{n} d_{ij} x_{ijk}$$

2. **Salida única de cada ciudad**: El agente debe abandonar cada ciudad i exactamente una vez a lo largo del viaje completo, dirigiéndose hacia alguna ciudad j en alguna de las n etapas k:

$$\sum_{j=1}^{n} \sum_{k=1}^{n} x_{ijk} = 1, \quad \forall i = 1, \dots, n$$

3. **Llegada única a cada ciudad**: El agente debe acceder a cada ciudad j exactamente una vez a lo largo del viaje completo, proviniendo de alguna ciudad i en alguna etapa k:

$$\sum_{i=1}^{n} \sum_{k=1}^{n} x_{ijk} = 1, \quad \forall j = 1, \dots, n$$

4. **Ocupación exclusiva de cada etapa temporal**: En cada etapa $k \in \{1, \dots, n\}$ del itinerario solo puede llevarse a cabo exactamente un trayecto entre un par de ciudades:

$$\sum_{i=1}^{n} \sum_{j=1}^{n} x_{ijk} = 1, \quad \forall k = 1, \dots, n$$

5. **Continuidad espacial del recorrido entre etapas consecutivas**: Si en la etapa k el agente llega a la ciudad j (sumando sobre todos los posibles orígenes $i \neq j$), en la siguiente etapa $k+1$ debe partir obligatoriamente desde esa misma ciudad j (sumando sobre todos los posibles destinos $l \neq j$):

$$\sum_{i \neq j} x_{ijk} = \sum_{l \neq j} x_{j,l,k+1}, \quad \forall j = 1, \dots, n, \quad \forall k = 1, \dots, n$$

   Para la última etapa $k = n$, la etapa subsiguiente $k+1$ se identifica circularmente con la etapa inicial 1.

Formulación matemática consolidada del Modelo 1: Reuniendo todas las condiciones analizadas, el modelo completo de programación lineal entera queda formulado de la siguiente

manera:

$$
\begin{aligned}
\min_{x} \quad & \sum_{i=1}^{n}\sum_{j=1}^{n}\sum_{k=1}^{n} d_{ij}x_{ijk} \\
\text{sujeto a} \quad & \sum_{j=1}^{n}\sum_{k=1}^{n} x_{ijk} = 1, \quad \forall i = 1, \dots, n \\
& \sum_{i=1}^{n}\sum_{k=1}^{n} x_{ijk} = 1, \quad \forall j = 1, \dots, n \\
& \sum_{i=1}^{n}\sum_{j=1}^{n} x_{ijk} = 1, \quad \forall k = 1, \dots, n \\
& \sum_{i\neq j} x_{ijk} = \sum_{l\neq j} x_{j,l,k+1}, \quad \forall j = 1, \dots, n,\ k = 1, \dots, n \\
& x_{ijk} \in \{0, 1\}, \quad \forall i, j, k = 1, \dots, n
\end{aligned}
$$

Desde el punto de vista computacional, este modelo requiere n^3 variables binarias y $3n + n^2$ restricciones para una red de n ciudades. Aunque su planteamiento resulta transparente e intuitivo, el crecimiento cúbico de las variables limita su aplicación práctica a problemas de escala reducida.

10.4.2. Modelo 2 del TSP: Eliminación exponencial de subciclos (DFJ)

Para reducir drásticamente el número de variables de decisión, George Dantzig, Delbert Fulkerson y Selmer Johnson propusieron en 1954 prescindir del subíndice temporal k y trabajar exclusivamente con variables de arco (G. Dantzig, Fulkerson, y Johnson 1954).

Variables de decisión y grado de asignación: En este enfoque, la elección de las rutas se describe mediante variables binarias con doble subíndice:

$$
x_{ij} = \begin{cases} 1 & \text{si el arco dirigido } (i, j) \text{ forma parte de la ruta} \\ 0 & \text{en otro caso} \end{cases}
$$

para todo $i, j \in \{1, \dots, n\}$ con $i \neq j$.

Si imponemos únicamente las restricciones clásicas del problema de asignación:

- **Conservación de salida (Grado exterior 1)**: $\sum_{j=1, j\neq i}^{n} x_{ij} = 1, \quad \forall i = 1, \dots, n$
- **Conservación de entrada (Grado interior 1)**: $\sum_{i=1, i\neq j}^{n} x_{ij} = 1, \quad \forall j = 1, \dots, n$

cada ciudad tiene garantizado un único predecesor y un único sucesor. Sin embargo, estas dos condiciones no garantizan la conectividad global, permitiendo que la solución óptima se fracture en múltiples subciclos desconectados (*subtours*), como se ilustra en la Figura 10.12.

Restricciones de eliminación de subciclos (SEC): Para erradicar cualquier subciclo aislado, Dantzig, Fulkerson y Johnson establecieron que para todo subconjunto propio no

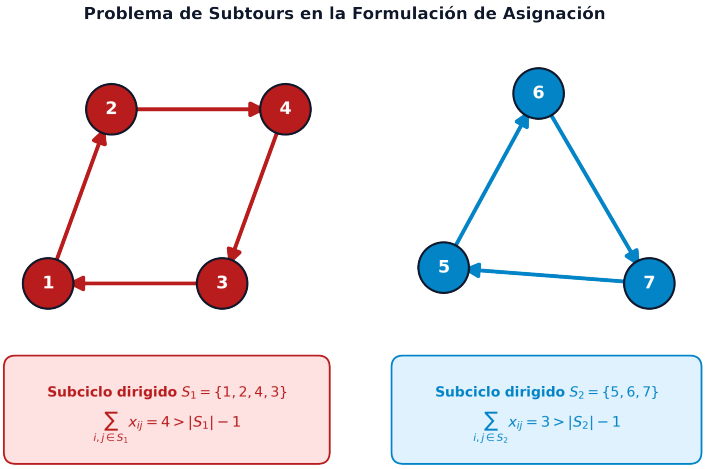

Figura 10.12: Fenómeno de subciclos desconectados generado por la relajación de asignación pura en una red de 7 nodos

vacío de ciudades $S \subset V$ con cardinal $2 \leq |S| \leq n-1$, el número de arcos dirigidos cuyos dos extremos pertenezcan a S no puede alcanzar el valor $|S|$, ya que ello formaría un ciclo cerrado aislado dentro de S. Esta condición da lugar a las **restricciones de eliminación de subciclos** (SEC):

$$\sum_{i \in S} \sum_{j \in S} x_{ij} \leq |S| - 1, \quad \forall S \subset V,\ 2 \leq |S| \leq n-1$$

Formulación matemática consolidada del Modelo DFJ: Integrando la función objetivo, las restricciones de grado y las restricciones SEC, la formulación clásica DFJ se consolida como:

$$\begin{aligned}
\min_{x} \quad & \sum_{i=1}^{n} \sum_{j=1}^{n} d_{ij} x_{ij} \\
\text{sujeto a} \quad & \sum_{j=1, j \neq i}^{n} x_{ij} = 1, \quad \forall i = 1, \ldots, n \\
& \sum_{i=1, i \neq j}^{n} x_{ij} = 1, \quad \forall j = 1, \ldots, n \\
& \sum_{i \in S} \sum_{j \in S} x_{ij} \leq |S| - 1, \quad \forall S \subset V,\ 2 \leq |S| \leq n-1 \\
& x_{ij} \in \{0, 1\}, \quad \forall i, j = 1, \ldots, n,\ i \neq j
\end{aligned}$$

Aunque el modelo DFJ requiere únicamente $n(n-1)$ variables binarias, el número de restricciones SEC es de orden exponencial $(2^n - 2)$. No obstante, este modelo posee la relajación lineal

continua más ajustada y fuerte conocida en optimización combinatoria. En la práctica, los algoritmos modernos de ramificación y corte (*Branch-and-Cut*) resuelven instancias de decenas de miles de ciudades incorporando las restricciones SEC de forma perezosa y dinámica (*lazy constraints*) únicamente cuando se detecta un subciclo violado.

10.4.3. Modelo 3 del TSP: Formulación compacta MTZ (Miller-Tucker-Zemlin)

En 1960, Clair Miller, Albert Tucker y Richard Zemlin desarrollaron una formulación alternativa que elimina los subciclos utilizando un número estrictamente polinomial de restricciones ($\mathcal{O}(n^2)$), permitiendo introducir el modelo completo directamente en cualquier optimizador lineal estándar sin necesidad de generadores de cortes dinámicos (Miller, Tucker, y Zemlin 1960).

Variables continuas de orden secuencial: El modelo MTZ toma una ciudad de referencia como depósito base (fijando habitualmente $u_1 = 1$) y define variables continuas auxiliares $u_i \geq 0$ para $i = 2, \dots, n$, las cuales representan la posición o número de orden en el que la ciudad i es visitada a lo largo del recorrido (satisfaciendo $2 \leq u_i \leq n$).

Mecánica algebraica de las restricciones MTZ: La eliminación de subciclos se consigue imponiendo la siguiente familia de inecuaciones cuadráticas en el número de nodos:

$$u_i - u_j + nx_{ij} \leq n - 1, \quad \forall i, j \in \{2, \dots, n\},\ i \neq j$$

Para comprender el fundamento algebraico de esta inecuación, analizamos los dos valores posibles de la variable binaria x_{ij}:

1. **Si el arco (i, j) forma parte de la ruta ($x_{ij} = 1$)**: Sustituyendo $x_{ij} = 1$ en la inecuación se obtiene $u_i - u_j + n(1) \leq n - 1 \iff u_j \geq u_i + 1$. La restricción fuerza de manera estricta a que el orden de visita de la ciudad j sea al menos una unidad mayor que el orden de la ciudad i. Como los índices deben crecer estrictamente a lo largo de cualquier subrecorrido, es imposible formar un subciclo cerrado que no contenga al depósito 1 (pues un subciclo $i_1 \to i_2 \to \dots \to i_m \to i_1$ exigiría $u_{i_1} < u_{i_2} < \dots < u_{i_m} < u_{i_1}$, lo cual constituye una imposibilidad matemática).
2. **Si el arco (i, j) no se utiliza ($x_{ij} = 0$)**: Sustituyendo $x_{ij} = 0$, la inecuación queda $u_i - u_j + 0 \leq n - 1 \iff u_i - u_j \leq n - 1$. Dado que las variables de orden satisfacen $2 \leq u_i \leq n$, la máxima diferencia posible entre dos índices cualesquiera es $(n) - (2) = n - 2 \leq n - 1$. Por consiguiente, la restricción queda completamente desactivada y resulta redundante, no imponiendo ninguna limitación artificial sobre nodos no conectados.

Formulación matemática consolidada del Modelo MTZ: El modelo compacto MTZ se consolida formalmente como:

$$
\begin{aligned}
\min_{x,u} \quad & \sum_{i=1}^{n}\sum_{j=1}^{n} d_{ij}x_{ij} \\
\text{sujeto a} \quad & \sum_{j=1,j\neq i}^{n} x_{ij} = 1, \quad \forall i = 1,\dots,n \\
& \sum_{i=1,i\neq j}^{n} x_{ij} = 1, \quad \forall j = 1,\dots,n \\
& u_i - u_j + n x_{ij} \leq n-1, \quad \forall i,j \in \{2,\dots,n\},\ i \neq j \\
& u_i \geq 0, \quad \forall i = 2,\dots,n \\
& x_{ij} \in \{0,1\}, \quad \forall i,j = 1,\dots,n,\ i \neq j
\end{aligned}
$$

En la comparativa entre MTZ y DFJ destacan dos factores determinantes:

- **Ventaja de MTZ**: Es un modelo compacto con $n^2 + n - 1$ variables y $n^2 - n + 2$ restricciones, resoluble directamente por cualquier *solver* estándar sin rutinas auxiliares de separación de cortes.
- **Desventaja de MTZ**: Su relajación lineal continua es significativamente más débil que la de DFJ, lo que provoca que los algoritmos de ramificación y acotación (*Branch-and-Bound*) requieran explorar un árbol de búsqueda mucho mayor para instancias medianas o grandes.

10.4.4. Heurísticas y el Algoritmo de Aproximación de Christofides

Dada la complejidad $\mathcal{NP}$-dura del TSP, en problemas de gran tamaño se recurre a heurísticas y algoritmos de aproximación con garantías teóricas:

- **Heurística constructiva del Vecino más Cercano (Nearest Neighbor)**: Parte de un nodo inicial y en cada paso salta al nodo no visitado más cercano en tiempo $\mathcal{O}(n^2)$. Aunque es muy rápida, suele dejar nodos aislados lejanos para el final, generando un retorno final de coste elevado.
- **Heurística de mejora local 2-Opt**: Parte de una ruta inicial válida y evalúa parejas de aristas $\{(u,v),(x,y)\}$. Si sustituirlas por $\{(u,x),(v,y)\}$ reduce la distancia total (lo que equivale a invertir el sentido de recorrido del subsegmento intermedio), se aplica el intercambio. Se itera hasta alcanzar un óptimo local 2-óptimo.

Para el **TSP métrico** (donde las distancias satisfacen la desigualdad triangular $d_{ij} \leq d_{ik} + d_{kj}$), el matemático greco-británico **Nicos Christofides** desarrolló en 1976 un célebre algoritmo de aproximación polinomial (Christofides 1976).

Esquema: Algoritmo de aproximación de Christofides (1976)

Dado un grafo completo con distancias no negativas que satisfacen la desigualdad triangular:

1. **Árbol Soporte de Mínimo Peso (MST)**: Calcular un árbol generador de mínimo peso T sobre el conjunto de nodos V mediante el algoritmo de Kruskal o Prim.
2. **Identificación de vértices impares**: Identificar el subconjunto $O \subset V$ de vértices que tienen grado impar en el árbol T (el número $|O|$ es necesariamente par).
3. **Emparejamiento perfecto de peso mínimo**: Calcular el emparejamiento perfecto de peso mínimo M sobre el subgrafo inducido por los vértices de O en el grafo original.
4. **Construcción del multigrafo euleriano**: Unir las aristas del árbol T y las del emparejamiento M para formar el multigrafo $H = T \cup M$. En H, todos los vértices tienen grado par.
5. **Ciclo euleriano y atajos hamiltonianos**: Hallar un ciclo euleriano en H y transformarlo en un ciclo hamiltoniano recorriendo sus vértices y aplicando **atajos** (*shortcuts*), es decir, saltando directamente a nodos no visitados omitiendo nodos repetidos.

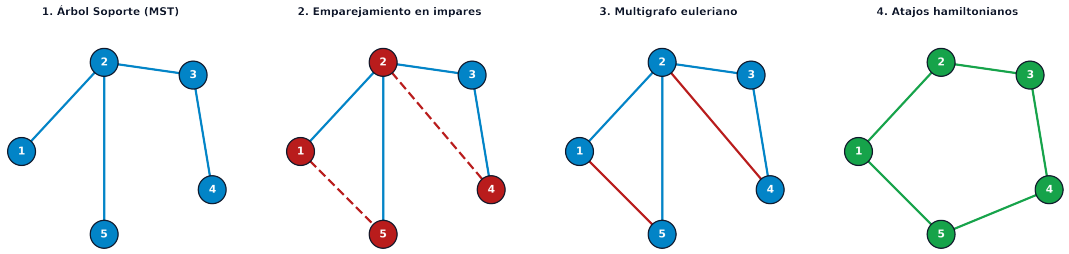

Figura 10.13: Las cuatro fases del Algoritmo de Christofides: (1) MST, (2) Emparejamiento en impares, (3) Multigrafo euleriano y (4) Atajos hamiltonianos

Teorema: Garantía de aproximación de factor 1.5 de Christofides

En cualquier grafo métrico, el algoritmo de Christofides garantiza una solución cuyo coste no supera **1.5 veces el coste de la solución óptima global**:

$$\text{Coste}(C_{\text{Christofides}}) \leq \frac{3}{2}\text{Coste}(C^*)$$

Demostración: Sea C^* el ciclo hamiltoniano óptimo global del TSP.

1. **Cota del MST**: Si eliminamos una arista arbitraria del ciclo óptimo C^*, obtene-

mos un camino simple que conecta todos los vértices. Dado que cualquier camino generador es un árbol soporte, y el MST T es por definición el árbol generador de menor peso:

$$\text{Coste}(T) \leq \text{Coste}(\text{camino}) < \text{Coste}(C^*)$$

2. **Cota del Emparejamiento**: Consideremos el ciclo óptimo C^* proyectado únicamente sobre el subconjunto de nodos impares O, omitiendo mediante atajos los nodos que no pertenecen a O. Por la desigualdad triangular, el coste de este ciclo inducido C_O^* cumple $\text{Coste}(C_O^*) \leq \text{Coste}(C^*)$. Al tener $|O|$ un número par de vértices, el ciclo C_O^* puede descomponerse en dos emparejamientos perfectos disjuntos y alternos M_1 y M_2. La suma de sus costes satisface:

$$\text{Coste}(M_1) + \text{Coste}(M_2) = \text{Coste}(C_O^*) \leq \text{Coste}(C^*)$$

Como M es el emparejamiento perfecto de peso mínimo sobre O:

$$\text{Coste}(M) \leq \text{mín}\{\text{Coste}(M_1), \text{Coste}(M_2)\} \leq \frac{1}{2}\text{Coste}(C^*)$$

3. **Combinación y atajos**: Sumando las aristas del multigrafo euleriano $H = T \cup M$:

$$\begin{aligned}\text{Coste}(H) &= \text{Coste}(T) + \text{Coste}(M) \\ &< \text{Coste}(C^*) + \frac{1}{2}\text{Coste}(C^*) = \frac{3}{2}\text{Coste}(C^*)\end{aligned}$$

Al aplicar atajos para convertir el recorrido euleriano en el ciclo hamiltoniano C, la desigualdad triangular garantiza que el coste no aumenta: $\text{Coste}(C) \leq \text{Coste}(H) \leq 1.5\text{Coste}(C^*)$. ■

10.5. Taxonomía y características de los Problemas de Rutas de Vehículos (VRP)

Tanto el Problema del Viajante de Comercio (TSP) como el Problema del Cartero Chino (CPP) constituyen los bloques fundacionales de una disciplina de extraordinaria amplitud en la ingeniería de sistemas, la investigación operativa y la logística de distribución: la familia de los **Problemas de Rutas de Vehículos** (*Vehicle Routing Problems*, VRP), introducidos formalmente por George Dantzig y John Ramser en 1959 (G. B. Dantzig y Ramser 1959).

Mientras que el TSP tradicional asume un único agente con capacidad infinita que visita un conjunto cerrado de ciudades, los problemas de distribución industrial involucran flotas

heterogéneas, restricciones de capacidad volumétrica o de tonelaje, ventanas temporales estrictas de entrega y múltiples centros logísticos de origen y destino.

Desde la perspectiva topológica, la primera distinción conceptual básica radica en la localización espacial de las demandas que deben ser atendidas dentro de la infraestructura de transporte, dando lugar a dos grandes familias complementarias esquematizadas en la Figura 10.14:

- **Problemas de rutas por nodos (Node Routing)**: Los puntos de demanda o clientes se sitúan exclusivamente en los **vértices** de la red, mientras que las aristas actúan únicamente como vías transitables de desplazamiento. Esta categoría engloba desde el TSP elemental hasta el **Problema de Rutas de Vehículos con Capacidad** (*Capacitated VRP*, CVRP) (donde una flota de vehículos con capacidad limitada Q abastece a múltiples clientes partiendo de un depósito), el **VRP con Ventanas de Tiempo** (VRPTW) y los problemas de **recogida y entrega simultánea** (*Pickup and Delivery Problem*, PDP).
- **Problemas de rutas por arcos (Arc Routing)**: Las demandas o servicios se encuentran distribuidos de manera continua a lo largo de las **aristas o arcos** de la red viaria. Mientras que el **Problema del Cartero Chino (CPP)** exige transitar por todas las aristas de la red (inspección de tuberías, líneas eléctricas o pavimentos), el **Problema del Cartero Rural (RPP)** atiende únicamente a un subconjunto prioritario de tramos. Cuando se consideran flotas con capacidad de carga finita, se formula el **Problema de Rutas por Arcos con Capacidad** (CARP), estándar en la recogida municipal de residuos sólidos urbanos y el esparcimiento de sal en vialidad invernal.
- **Problemas de rutas mixtos (General Routing Problems - GRP)**: Combinan servicios puntuales concentrados en ciertos vértices con demandas continuas distribuidas a lo largo de aristas específicas de la red.

Figura 10.14: Taxonomía topológica de problemas de rutas: bifurcación entre rutas por arcos (Arc Routing) y rutas por nodos (Node Routing)

Por otra parte, la traslación de estos problemas a modelos matemáticos computables y aplicables

a la logística real requiere caracterizar con precisión seis dimensiones operativas fundamentales, ilustradas en la Figura 10.15:

- **Composición y capacidad de la flota**: Se distingue entre *flotas homogéneas*, donde todos los vehículos son idénticos en capacidad de carga, autonomía y costes operativos, y *flotas heterogéneas*, donde coexisten vehículos de diversas tipologías con posibles restricciones de gálibo o acceso físico a cascos urbanos históricos.
- **Topología de las instalaciones y depósitos**: En los esquemas *monodepósito*, todos los vehículos inician y concluyen su recorrido en una base central única. En los esquemas *multidepósito* (*Multi-Depot VRP*), la distribución se coordina desde múltiples centros territoriales, pudiendo los vehículos pernoctar en su base de origen o admitir reubicación libre entre depósitos.
- **Certidumbre y dinamismo de la demanda**: Frente a los modelos *deterministas*, donde las cantidades requeridas por cada cliente se conocen con exactitud antes de iniciar las expediciones, los entornos *estocásticos o dinámicos* modelan la demanda como variables aleatorias o procesan solicitudes de última hora recibidas telemáticamente durante la ejecución en curso de la ruta.
- **Modalidad de las operaciones de transporte**: Comprende desde la *entrega pura* (el vehículo parte cargado y se vacía progresivamente) y la *recogida pura* (el vehículo parte vacío y va acumulando mercancía o residuos) hasta las *operaciones combinadas de recogida y entrega simultánea*, que exigen monitorizar la capacidad residual disponible en cada tramo intermedio de la ruta.
- **Restricciones temporales y ventanas de servicio**: Varían desde horizontes abiertos sin limitaciones horarias hasta *ventanas de tiempo rígidas* (*Hard Time Windows*), donde el servicio fuera del intervalo $[a_i, b_i]$ está estrictamente prohibido, o *ventanas flexibles* (*Soft Time Windows*), donde los adelantos o retrasos se penalizan económicamente en la función objetivo.
- **Estructura de costes y objetivos de optimización**: Aunque el objetivo clásico consiste en minimizar la distancia total recorrida, el tiempo de conducción o el consumo de combustible, los modelos avanzados integran la minimización del número total de vehículos activos, la reducción de emisiones de CO_2 y el *equilibrio de las cargas de trabajo* (*fair workload balancing*) entre los conductores.

Figura 10.15: Ejes y dimensiones fundamentales de clasificación operativa en la logística de rutas de vehículos

Conclusiones

A lo largo de diez capítulos estructurados en dos grandes bloques temáticos, hemos presentado el material de la asignatura de **Optimización y Análisis de Redes** del Grado en **Matemáticas**.

En este capítulo de cierre, te invitamos a reflexionar sobre las principales lecciones aprendidas durante el curso, destacando cómo el rigor matemático y el pensamiento analítico se convierten en herramientas indispensables para dominar la modelización matemática. Además, animamos a los estudiantes a continuar explorando y ampliando sus conocimientos en cursos posteriores, consolidando una base sólida para afrontar los desafíos de la optimización y la ciencia de datos moderna desde una perspectiva analítica, rigurosa y fundamentada.

Al finalizar este recorrido, queda patente que la optimización es mucho más que una colección de algoritmos aislados, constituyendo un marco de pensamiento estructurado para tomar decisiones óptimas bajo condiciones de recursos limitados. Hemos transitado desde los fundamentos continuos del análisis convexo y las condiciones de optimalidad hasta la estructura discreta y combinatorial de las redes y grafos, equipando a los futuros matemáticos con herramientas capaces de modelar, resolver e interpretar problemas complejos del mundo real.

Resumen del aprendizaje

A lo largo de este manual, hemos construido un conocimiento progresivo y bidireccional sobre la optimización matemática, cubriendo los siguientes pilares:

1. **Fundamentos y ciclo de la Investigación Operativa (Tema 1)**: Partimos de las raíces históricas y metodológicas de la disciplina, analizando las fases del ciclo de vida de un modelo matemático y formalizando la estructura canónica de los problemas de optimización con variables, función objetivo y restricciones.
2. **Optimización no lineal continua y métodos numéricos (Tema 2)**: Analizamos algoritmos univariantes sin derivadas (búsqueda dicotómica, sección áurea, Fibonacci) y con derivadas (bisección, Newton), así como métodos multivariantes directos (coordenadas cíclicas, Hooke-Jeeves), de primer orden (máximo descenso de Cauchy) y de segundo orden (Newton multivariante y Cuasi-Newton BFGS).

3. **Análisis convexo y subgradientes (Tema 3)**: Establecimos el marco teórico que garantiza la globalidad de los óptimos mediante conjuntos convexos, hiperplanos de separación y de soporte, y funciones convexas caracterizadas por gradientes y matrices hessianas, introduciendo el subgradiente y el subdiferencial para el tratamiento de funciones no diferenciables.
4. **Condiciones de optimalidad KKT, dualidad y Programación Cuadrática (Temas 4 y 5)**: Dedujimos las condiciones necesarias de Fritz-John y las condiciones necesarias y suficientes de Karush-Kuhn-Tucker (KKT) bajo cualificación de restricciones (LICQ y Slater). Aplicamos este formalismo a la Programación Lineal (demostrando la equivalencia con las variables duales del Símplex) y a la Programación Cuadrática mediante el método del Símplex de Wolfe con regla de entrada restringida.
5. **Estructuras de redes, Total Unimodularidad, árboles y caminos mínimos (Temas 6 y 7)**: Pasamos al dominio discreto de los grafos. Analizamos la propiedad de Total Unimodularidad (TUM) de la matriz de incidencia nodo-arco como puente que preserva la integridad en relajaciones continuas. Estudiamos árboles soporte de mínimo peso (Prim y Kruskal) y algoritmos de camino óptimo (Dijkstra, Bellman-Ford, Floyd-Warshall) junto con su formulación dual mediante potenciales nodales y tensiones.
6. **Flujos en redes, emparejamientos y problemas de rutas eulerianas, hamiltonianas y VRP (Temas 8, 9 y 10)**: Abordamos problemas combinatorios avanzados: el teorema de Flujo Máximo - Corte Mínimo de Ford-Fulkerson y Edmonds-Karp, el flujo de coste mínimo, emparejamientos y asignación óptima (Teoremas de Hall y Kőnig, Algoritmo Húngaro y Blossom de Edmonds), circuitos eulerianos (Cartero Chino), ciclos hamiltonianos, formulaciones de Programación Lineal Entera del TSP (modelos por etapas, DFJ con cortes de subciclo y MTZ compacto), aproximación de Christofides y la taxonomía del VRP.

Reflexiones finales

El estudio de la **Optimización y el Análisis de Redes** dota al matemático de un puente directo entre la abstracción algebraica y analítica y la resolución de problemas tangibles de toma de decisiones. Hemos visto cómo conceptos teóricos profundos (como la geometría convexa, la dualidad lineal y la estructura combinatorial de grafos) se traducen en algoritmos computacionales de alta eficiencia que gestionan la logística, las finanzas o las telecomunicaciones modernas.

Hemos aprendido que modelar no es un proceso mecánico ni una mera aplicación de recetas informáticas. Construir un modelo útil requiere un proceso iterativo de **abstracción, resolución, validación y análisis de sensibilidad**. Entender las hipótesis que garantizan la convergencia de un algoritmo o la integridad de una solución es lo que distingue a un matemático de un aplicador de software a ciegas.

Proyección futura: El valor del rigor matemático

Las competencias adquiridas en esta asignatura son esenciales en el perfil del matemático moderno. Vuestra formación os proporciona una ventaja competitiva fundamental: la capacidad de ir más allá del código, comprendiendo la geometría del espacio factible, la estabilidad de las restricciones y la justificación teórica de los óptimos obtenidos.

Este conocimiento es el lenguaje compartido con la **Investigación Operativa** avanzada, el **Aprendizaje Automático** y la **Ciencia de Datos Cuantitativa**. Mientras que otros perfiles aplican modelos como "cajas negras", vuestro rigor os capacita para diseñar nuevas formulaciones, diagnosticar fallos de convergencia y optimizar recursos con plenas garantías matemáticas.

Esta sólida base analítica os posiciona de manera idónea para trayectorias profesionales avanzadas en sectores estratégicos como **Ingeniería de Optimización y Logística**, **Científico de Datos Cuantitativo**, **Analista de Riesgos o Quants** en el sector financiero, o para continuar vuestra formación en **estudios de postgrado (Máster y Doctorado)** en optimización, estadística aplicada e investigación operativa.

¡Os deseamos el mayor de los éxitos en vuestra andadura profesional y académica!

Bibliografía

Ahuja, Ravindra K, Thomas L Magnanti, y James B Orlin. 1993. *Network Flows: Theory, Algorithms, and Applications*. Prentice Hall.

Applegate, David L, Robert E Bixby, Vasek Chvatal, y William J Cook. 2006. *The Traveling Salesman Problem: A Computational Study*. Princeton University Press.

Bazaraa, Mokhtar S, John J Jarvis, y Hanif D Sherali. 2011. *Linear Programming and Network Flows*. John Wiley & Sons.

Bazaraa, Mokhtar S, Hanif D Sherali, y Chitharanjan M Shetty. 2013. *Nonlinear Programming: Theory and Algorithms*. John Wiley & Sons.

Bellman, Richard E. 1957. *Dynamic Programming*. Princeton, NJ: Princeton University Press.

———. 1958. «On a routing problem». *Quarterly of Applied Mathematics* 16 (1): 87-90.

Berge, Claude. 1957. «Two theorems in graph theory». *Proceedings of the National Academy of Sciences* 43 (9): 842-44.

Bertsekas, Dimitri P. 1998. *Network Optimization: Continuous and Discrete Models*. Athena Scientific.

Bondy, John Adrian, y Václav Chvátal. 1976. «A method in graph theory». *Discrete Mathematics* 15 (2): 111-35.

Boyd, Stephen, y Lieven Vandenberghe. 2004. *Convex Optimization*. Cambridge University Press.

Cayley, Arthur. 1889. «A theorem on trees». *Quarterly Journal of Pure and Applied Mathematics* 23: 376-78.

Christofides, Nicos. 1976. «Worst-case analysis of a new heuristic for the travelling salesman problem». 388. Graduate School of Industrial Administration, Carnegie-Mellon University.

Cormen, Thomas H, Charles E Leiserson, Ronald L Rivest, y Clifford Stein. 2009. *Introduction to Algorithms*. 3rd ed. MIT Press.

Cournot, Augustin. 1838. *Recherches sur les principes mathématiques de la théorie des richesses*. Paris: L. Hachette.

Dantzig, George B, y John H Ramser. 1959. «The truck dispatching problem». *Management Science* 6 (1): 80-91.

Dantzig, George, Ray Fulkerson, y Selmer Johnson. 1954. «Solution of a large-scale traveling-salesman problem». *Journal of the Operations Research Society of America* 2 (4): 393-410.

Dijkstra, Edsger W. 1959. «A note on two problems in connexion with graphs». *Numerische Mathematik* 1 (1): 269-71.

Dirac, Gabriel Andrew. 1952. «Some theorems on abstract graphs». *Proceedings of the London Mathematical Society* 3 (1): 69-81.

Dudeney, Henry Ernest. 1958. *Amusements in Mathematics*. Dover Publications.

Edmonds, Jack. 1965. «Paths, trees, and flowers». *Canadian Journal of Mathematics* 17: 449-67.
Euler, Leonhard. 1736. «Solutio problematis ad geometriam situs pertinentis». *Commentarii Academiae Scientiarum Imperialis Petropolitanae* 8: 128-40.
———. 1741. «Solutio problematis ad geometriam situs pertinentis». *Commentarii Academiae Scientiarum Petropolitanae* 8: 128-40.
Floyd, Robert W. 1962. «Algorithm 97: Shortest path». *Communications of the ACM* 5 (6): 345.
Ford, Lester R. 1956. «Network flow theory». P-923. RAND Corporation.
Gallai, Tibor. 1959. «Über extreme Punkt-und Kantenmengen». *Ann. Univ. Sci. Budapest, Eötvös Sect. Math.* 2: 133-38.
Hamilton, William Rowan. 1857. «Memorandum respecting a new system of roots of unity (Icosian Game)». *Philosophical Magazine* 14 (96): 496.
Hillier, Frederick S, y Gerald J Lieberman. 2010. *Introducción a la Investigación de Operaciones*. 9na ed. McGraw-Hill.
Jarník, Vojtěch. 1930. «O jistém problému minimálním». *Práce Moravské Přírodovědecké Společnosti* 6: 57-63.
John, Fritz. 1948. «Extremum Problems with Inequalities as Side Conditions». En *Studies and Essays Presented to R. Courant on His 60th Birthday*, 187-204. New York: Interscience Publishers.
Karp, Richard M. 1972. «Reducibility among combinatorial problems». En *Complexity of Computer Computations*, 85-103. Springer.
Karush, William. 1939. «Minima of Functions of Several Variables with Inequalities as Side Conditions». Master's thesis, Department of Mathematics, University of Chicago.
Kruskal, Joseph B. 1956. «On the shortest spanning subtree of a graph and the traveling salesman problem». *Proceedings of the American Mathematical Society* 7 (1): 48-50.
Kuhn, Harold W, y Albert W Tucker. 1951. «Nonlinear Programming». En *Proceedings of the Second Berkeley Symposium on Mathematical Statistics and Probability*, 481-92. Berkeley, CA: University of California Press.
Kwan, Mei-Ko. 1962. «Graphic programming using odd or even points». *Chinese Mathematics* 1: 273-77.
Lovász, László, y Michael D Plummer. 2009. *Matching Theory*. Vol. 367. American Mathematical Society.
Luenberger, David G, y Yinyu Ye. 2015. *Linear and Nonlinear Programming*. 4th ed. Springer.
Markowitz, Harry. 1952. «Portfolio Selection». *The Journal of Finance* 7 (1): 77-91.
Miller, Clair E, Albert W Tucker, y Richard A Zemlin. 1960. «Integer programming formulation of traveling salesman problems». *Journal of the ACM (JACM)* 7 (4): 326-29.
Nocedal, Jorge, y Stephen Wright. 2006. *Numerical Optimization*. Springer Science & Business Media.
Ore, Øystein. 1960. «Note on Hamilton circuits». *The American Mathematical Monthly* 67 (1): 55-55.
Papadimitriou, Christos H, y Kenneth Steiglitz. 1998. *Combinatorial Optimization: Algorithms and Complexity*. Courier Corporation.
Prim, Robert Clay. 1957. «Shortest connection networks and some generalizations». *Bell System*

Technical Journal 36 (6): 1389-1401.
Rockafellar, R Tyrrell. 1970. *Convex Analysis*. Princeton University Press.
Roy, Bernard. 1959. «Transitivité et connexitié». *Comptes rendus de l'Académie des Sciences* 249: 216-18.
Shimbel, Alfonso. 1955. «Structure in communication nets». En *Proceedings of the Symposium on Information Networks*, 199-203.
Warshall, Stephen. 1962. «A theorem on Boolean matrices». *Journal of the ACM* 9 (1): 11-12.
Wolsey, Laurence A. 1998. *Integer Programming*. John Wiley & Sons.

PARTE III

Diapositivas y Presentaciones de Clase

Colección completa de transparencias docentes para exposición magistral y seminarios

> Conjunto de más de setecientas diapositivas estructuradas con diseño didáctico paralelo en dos columnas. Sintetizan los conceptos clave de cada tema, ofreciendo una guía visual continua para la docencia presencial, con formulaciones matemáticas alineadas, esquemas de algoritmos paso a paso y gráficos interactivos integrados.

Víctor Aceña Gil · Antonio Alonso Ayuso
CC BY-SA 4.0 Internacional · Curso 2026-2027

Índice de diapositivas

- Tema 1: Introducción a la investigación operativa
- Tema 2: Optimización no lineal
- Tema 3: Análisis convexo
- Tema 4: Condiciones de optimalidad y KKT
- Tema 5: Programación lineal y cuadrática
- Tema 6: Grafos y árboles soporte
- Tema 7: Problema del camino mínimo
- Tema 8: Flujos en redes
- Tema 9: Emparejamientos en redes

Tema 1: Introducción a la investigación operativa

Optimización y Análisis de Redes

Víctor Aceña Gil - Antonio Alonso Ayuso

2026-06-15

Introducción a la investigación operativa

Raíces históricas

La **investigación operativa (IO)** o *Operations Research* nace formalmente durante la Segunda Guerra Mundial:

- **Problemas complejos**: Logística, despliegue de radares, escolta de convoyes y asignación de recursos limitados.
- **Enfoque interdisciplinar**: Grupos de científicos (matemáticos, físicos, ingenieros) colaborando para aplicar el método científico a operaciones militares.
- **Postguerra**: Aplicación exitosa al crecimiento industrial, el comercio y la gestión pública.

Definición de investigación operativa

Operational research society

La Investigación Operativa es la **aplicación del método científico** a los **problemas complejos** producidos en la dirección y gestión de grandes sistemas de personas, máquinas, materiales y dinero, en la industria, comercio, administración y defensa.

- Consiste en construir un **modelo científico** del sistema (incluyendo azar y riesgo) para predecir y **comparar los resultados** de diferentes decisiones estratégicas.

Herramientas de la investigación operativa

La IO abarca múltiples metodologías cuantitativas:

- **Optimización matemática** (Lineal, Entera, No Lineal) ← *Foco del bloque I*
- **Teoría de grafos y redes** ← *Foco del bloque II*
- Sistemas dinámicos y teoría de control
- Modelos estocásticos y teoría de colas
- Simulación de eventos discretos
- Teoría de juegos y teoría de la decisión

El concepto de modelo

¿Qué es un modelo?

Un **modelo** es una representación simplificada de la realidad diseñada para estructurar, analizar y predecir el comportamiento de un sistema real.

Tipos de modelos

- **Modelos concretos (físicos)**: Representaciones físicas a escala (ej. túnel de viento, maqueta de un edificio).
- **Modelos abstractos (matemáticos)**: Relaciones y ecuaciones cuantitativas que definen la lógica interna del sistema. Son la herramienta central en ciencias de la decisión.

Ciclo de vida del modelado

El proceso de modelización matemática es iterativo:

1. **Formulación**: Traducir la realidad a variables y ecuaciones.
2. **Resolución**: Aplicar algoritmos para hallar el óptimo.
3. **Validación**: Contrastar con datos reales y analizar sensibilidad.
4. **Implementación**: Toma de decisiones informada.

Modelos de optimización

Formulación general

Un modelo de programación matemática consta de:

$$\begin{aligned} \min_{x \in \mathbb{R}^n} \quad & f(x) \\ \text{sujeto a} \quad & g_i(x) \leq 0, \quad i = 1, \ldots, m \\ & h_j(x) = 0, \quad j = 1, \ldots, p \end{aligned}$$

- **Variables de decisión (x)**: Las incógnitas que podemos controlar.
- **Función objetivo (f)**: La función real a maximizar o minimizar.
- **Restricciones (g_i, h_j)**: Límites físicos, económicos o lógicos que restringen las variables.

Clasificación de modelos de optimización

Atendiendo al tipo de ecuaciones y funciones:

- **Optimización lineal (LP)**: Función objetivo y restricciones estrictamente lineales.
- **Optimización no lineal (NLP)**: Objetivo o alguna restricción presentan curvatura no lineal.
- **Optimización estocástica**: Incluye parámetros probabilísticos y aleatorios.

Clasificación según el tipo de variables

- **Optimización continua**: Las variables de decisión pueden tomar cualquier valor real dentro de un intervalo:

$$x_i \geq 0, \quad x_i \in \mathbb{R}$$

- **Optimización entera**: Las variables deben ser valores enteros (ej. número de camiones a comprar):

$$x_i \in \mathbb{Z}$$

- **Optimización binaria**: Decisiones lógicas sí/no ($x_i \in \{0, 1\}$).
- **Entera mixta (MIP)**: Combina variables continuas y enteras.

Optimización no lineal y en redes

Bloque I: optimización no lineal (NLP)

Se estudian problemas continuos donde la curvatura juega un papel crítico:

- **Diferenciabilidad**: Uso del gradiente y la matriz Hessiana para el análisis de curvatura local.
- **Convexidad**: Si el problema es convexo, se garantiza la globalidad de los óptimos.
- **Algoritmos**:
  - *Búsqueda 1D*: Bisección, Newton, Sección Áurea.
  - *Multivariantes*: Máximo Descenso, Newton, BFGS.
  - *Con restricciones*: Condiciones de Karush-Kuhn-Tucker (KKT).

Bloque II: optimización en redes

Modelado y resolución eficiente de problemas estructurados sobre grafos:

- **Matriz de incidencia**: Totalmente unimodular (garantiza soluciones enteras en relajación lineal).
- **Algoritmos especializados**: Símplex de redes, Dijkstra, Kruskal, algoritmos de flujo máximo.

Problemas clave

- Caminos mínimos.
- Flujo máximo.
- Emparejamientos.
- Rutas de reparto (TSP).

Tema 2: optimización no lineal y métodos numéricos

Optimización y Análisis de Redes

Víctor Aceña Gil - Antonio Alonso Ayuso

2026-06-16

Introducción y formulación

¿De qué trata este tema?

La optimización no lineal (NLP) aborda problemas reales donde las relaciones matemáticas no se comportan de forma proporcional o lineal.

- **Economías de escala**: El coste unitario disminuye con el volumen de producción, rompiendo la proporcionalidad directa.
- **Elasticidad de la demanda**: La cantidad demandada es sensible al precio de venta, por lo que la función de ingresos ($I = P \cdot Q$) es inherentemente cuadrática.
- **Riesgo financiero**: La volatilidad de una cartera se modela mediante la covarianza conjunta (forma cuadrática acoplada).
- **Ajuste de modelos**: La estimación de parámetros en ciencia de datos suele penalizar errores cuadráticamente (mínimos cuadrados), generando funciones objetivo no lineales.

¿Qué aprenderás en este tema?

- **Formulación matemática**: Plantear modelos no lineales con restricciones generales.
- **Análisis local de curvatura**: Utilizar el gradiente y la matriz hessiana para caracterizar geométricamente las funciones.
- **Condiciones de optimalidad**: Aplicar las condiciones diferenciales necesarias y suficientes para identificar máximos, mínimos y puntos de silla.
- **Algoritmos de búsqueda 1D**: Programar y analizar la convergencia de solvers de una variable sin y con derivadas.
- **Algoritmos multivariantes**: Implementar y comparar los principales métodos de búsqueda local sin restricciones (coordenadas cíclicas, máximo descenso, Newton y Cuasi-Newton BFGS).

Formulación matemática general

Un **problema de optimización no lineal (PNL)** general se define matemáticamente sobre un espacio vectorial $\mathbb{R}^n$ como:

$$\begin{aligned} \min_{x \in \mathbb{R}^n} \quad & f(x) \\ \text{sujeto a} \quad & g_i(x) \leq 0, \quad i = 1, \ldots, m \\ & h_j(x) = 0, \quad j = 1, \ldots, p \end{aligned}$$

Donde:

- $f(x)$ es la **función objetivo**.
- $g_i(x)$ representa las restricciones de **desigualdad**.
- $h_j(x)$ representa las restricciones de **igualdad**.
- Al menos una de estas funciones es no lineal.

Geometría de la optimización: lineal vs no lineal

La no linealidad altera profundamente la geometría del espacio de búsqueda:

- **Programación lineal (LP)**:
  - Conjunto factible: Siempre un poliedro convexo.
  - Óptimo: Se localiza necesariamente en un **vértice** (punto extremo).
  - Algoritmos: El Símplex explora únicamente un número finito de vértices.
- **Programación no lineal (NLP)**:
  - Conjunto factible: Las restricciones no lineales curvan las fronteras.
  - Óptimo: Puede hallarse en el **interior** o en cualquier punto de la **frontera**.
  - Múltiples óptimos locales: Los solvers locales pueden quedar atrapados en soluciones subóptimas.

Casos particulares de la optimización no lineal

Clasificamos los problemas en familias según sus propiedades:

- **Programación cuadrática (QP)**: Objetivo cuadrático y restricciones afines (lineales):

$$\min_x \quad \frac{1}{2}x^T Q x - b^T x \quad \text{sujeto a} \quad Ax \leq d$$

- **Programación convexa**: Objetivo y restricciones de desigualdad convexas, e igualdades afines. ¡Todo mínimo local es global!
- **Programación separable**: Las funciones se pueden descomponer en sumas de una variable: $f(x) = \sum f_j(x_j)$.
- **Programación geométrica**: Modelada con posinomios, transformable en convexa mediante el cambio $y_j = \ln(x_j)$.
- **Programación fraccionaria**: Objetivo como cociente de dos funciones.

El monopolio de Cournot (1838)

- **Precio de venta**: $P(Q) = 10 - Q$ (elasticidad).
- **Coste total**: $C(Q) = 1 + 3Q$ (lineal).
- **Modelo de maximización**:

$$\max_{Q,P} \quad B(Q,P) = P \cdot Q - 3Q - 1$$

$$\text{sujeto a} \quad Q \leq 10 - P, \quad 0 \leq P \leq 8, \quad 0 \leq Q \leq 9$$

- **Reducción**: Sustituyendo la demanda activa ($P = 10 - Q$):

$$\max_{Q} \quad B(Q) = -Q^2 + 7Q - 1 \quad \text{sujeto a} \quad 2 \leq Q \leq 9$$

- **Óptimo analítico**:
  $B'(Q) = -2Q + 7 = 0 \implies Q^* = 3.5 \in [2, 9]$.

Monopolio de Cournot: análisis geométrico

El punto óptimo $(3.5, 6.5)$ se sitúa en la frontera y no coincide con ningún vértice de la región factible polimórfica:

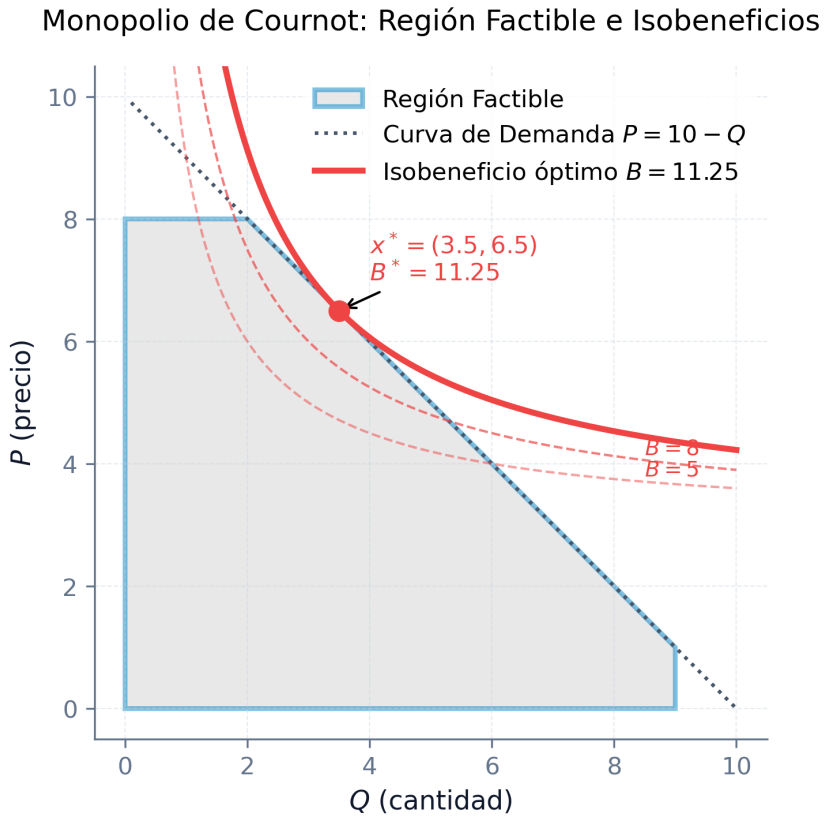

Selección de cartera de valores (Markowitz, 1952)

Inversión de capital C en n activos para maximizar rendimiento neto del riesgo:

$$\begin{aligned} \max_{x \in \mathbb{R}^n} \quad & \sum_{i=1}^{n} \mu_i x_i - \beta \sum_{i=1}^{n} \sum_{j=1}^{n} \sigma_{ij} x_i x_j \\ \text{sujeto a} \quad & \sum_{i=1}^{n} x_i \leq C \\ & x_i \geq 0, \quad i = 1, \ldots, n \end{aligned}$$

Donde:

- μ_i: Rendimiento esperado del activo i.
- σ_{ij}: Covarianza del rendimiento (riesgo cuadrático acoplado).
- $\beta > 0$: Coeficiente de aversión al riesgo.
- Es un problema **cuadrático convexo (QP)**.

Óptimos y análisis diferencial

Óptimos locales, globales y puntos de silla

Sea $f : \mathbb{R}^n \to \mathbb{R}$ definida sobre un conjunto factible $\mathcal{X} \subseteq \mathbb{R}^n$:

- **Mínimo global**: x^* es el óptimo absoluto si:

$$f(x) \geq f(x^*) \quad \forall x \in \mathcal{X}$$

- **Mínimo local**: x^* es el mejor en su entorno local si existe un radio $\epsilon > 0$ tal que:

$$f(x) \geq f(x^*) \quad \forall x \in \mathcal{X} \quad \text{con} \quad \|x - x^*\| \leq \epsilon$$

- **Estricto**: Si la desigualdad se cumple de forma estricta ($>$) para todo $x \neq x^*$.
- **Punto de silla**: Punto crítico que no es ni mínimo ni máximo local.

Tipos de óptimos de un vistazo

Diferencia fundamental con LP: múltiples óptimos locales mediocres frente al mínimo global único:

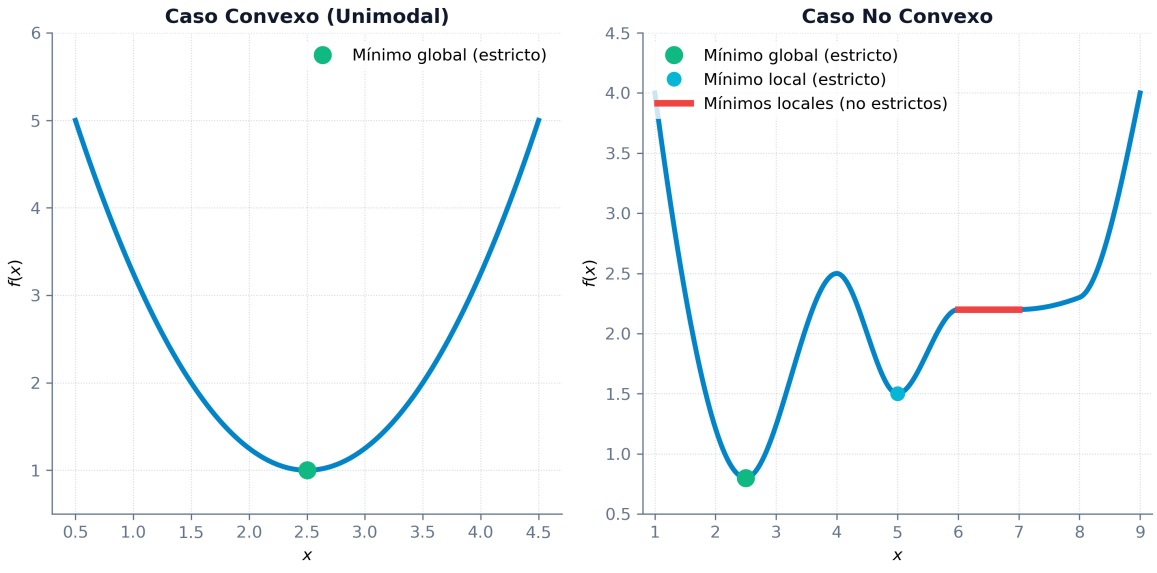

Herramientas de análisis diferencial

Asumiendo funciones con derivadas segundas continuas (de clase $\mathcal{C}^2$):

- **Vector gradiente**: Vector columna de derivadas de primer orden (pendiente):

$$\nabla f(x) = \left(\frac{\partial f(x)}{\partial x_1}, \frac{\partial f(x)}{\partial x_2}, \dots, \frac{\partial f(x)}{\partial x_n} \right)^T$$

- **Matriz hessiana**: Matriz simétrica de segundas derivadas parciales (curvatura):

$$[\nabla^2 f(x)]_{ij} = \frac{\partial^2 f(x)}{\partial x_i \partial x_j}$$

Desarrollo de Taylor multivariante

Aproximación cuadrática local de $f(x)$ alrededor de un punto de referencia $\bar{x}$:

$$f(x) = f(\bar{x}) + \nabla f(\bar{x})^T (x - \bar{x}) + \frac{1}{2}(x - \bar{x})^T \nabla^2 f(\bar{x})(x - \bar{x}) + o(\|x - \bar{x}\|^2)$$

Donde:

- El término lineal $\nabla f(\bar{x})^T (x - \bar{x})$ define el plano tangente.
- El término cuadrático $\frac{1}{2}(x - \bar{x})^T \nabla^2 f(\bar{x})(x - \bar{x})$ define la parábola de ajuste.
- Si la función $f(x)$ es cuadrática, la aproximación es exacta en todo el dominio.

Clasificación de la curvatura y matrices

Clasificación de $H = \nabla^2 f(x)$ según la forma cuadrática $z^T H z$:

- **Definida positiva ($H \succ 0$)**: $z^T H z > 0 \quad \forall z \neq 0$. Menores principales > 0. Autovalores > 0. (Curva en cuenco).
- **Semidefinida positiva ($H \succeq 0$)**: $z^T H z \geq 0 \quad \forall z$. Autovalores ≥ 0.
- **Definida negativa ($H \prec 0$)**: $z^T H z < 0 \quad \forall z \neq 0$. Menores alternan signo ($M_1 < 0, M_2 > 0$). Autovalores < 0. (Cúpula).
- **Semidefinida negativa ($H \preceq 0$)**: $z^T H z \leq 0 \quad \forall z$. Autovalores ≤ 0.
- **Indefinida**: Autovalores positivos y negativos. (Punto de silla).

Geometría de la curvatura: Definida positiva

Mínimo Circular ($H \succ 0$)

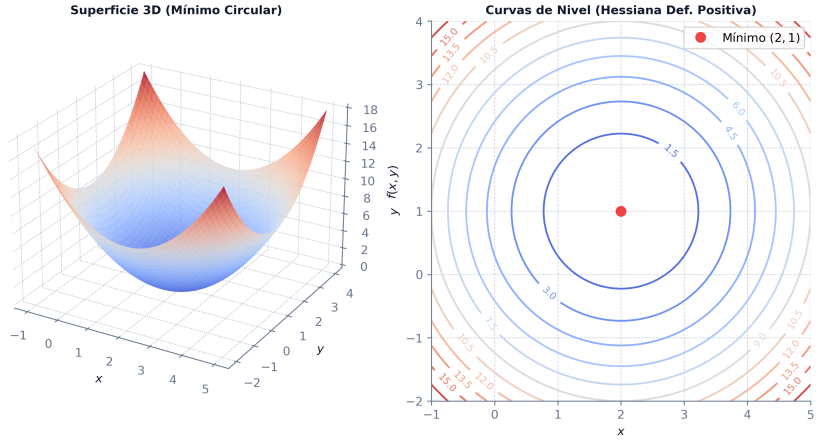

Mínimo Elíptico ($H \succ 0$)

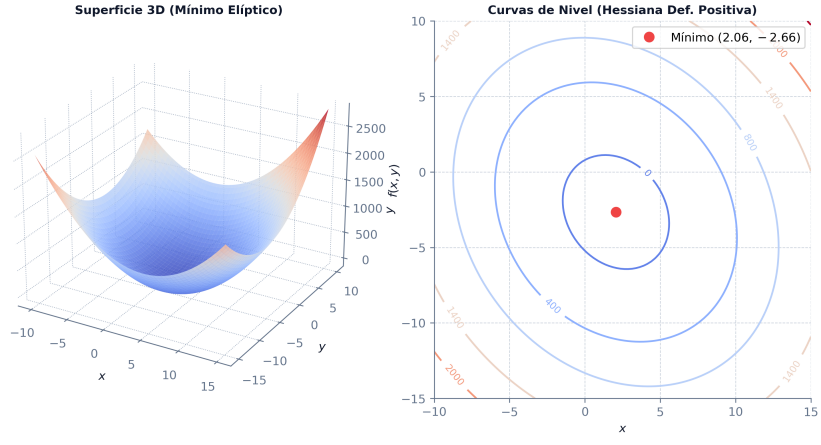

Geometría de la curvatura: Indefinida

Punto de Silla (Indefinida)

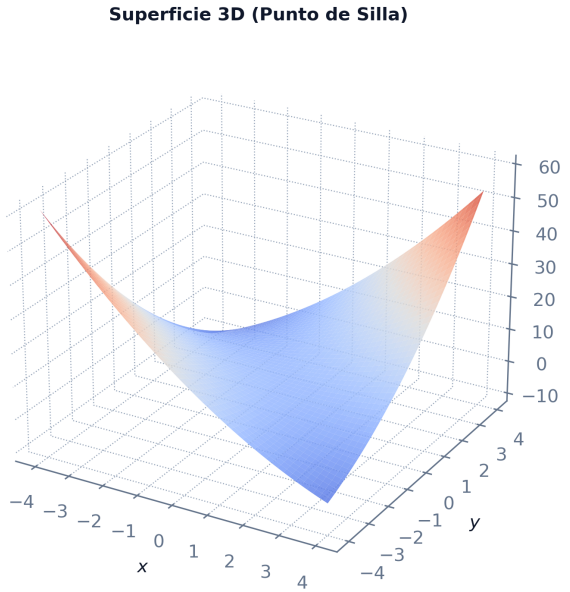

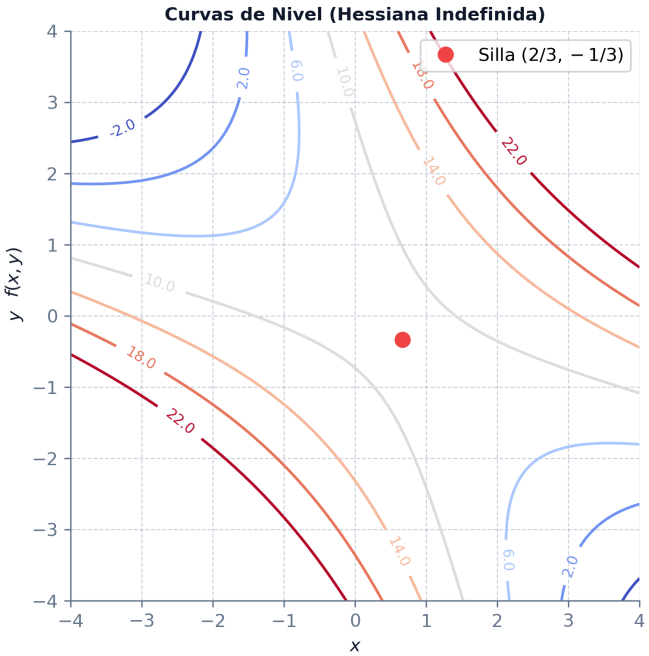

Condiciones de optimalidad en optimización libre

Caracterización diferencial de extremos locales sin restricciones:

- **Condición necesaria de primer orden (FONC)**: Si x^* es un mínimo local, entonces el gradiente se anula:

$$\nabla f(x^*) = 0$$

(El punto x^* es un **punto crítico** o estacionario).

- **Condición necesaria de segundo orden (SONC)**: Si x^* es un mínimo local:

$$\nabla^2 f(x^*) \succeq 0$$

- **Condición suficiente de segundo orden (SOSC)**: Si se cumple simultáneamente que:

$$\nabla f(x^*) = 0 \qquad \text{y} \qquad \nabla^2 f(x^*) \succ 0$$

Entonces x^* es un **mínimo local estricto**.

Métodos de búsqueda unidimensional

Métodos de búsqueda unidimensional

Consiste en minimizar una función real de una variable $f : \mathbb{R} \to \mathbb{R}$ en un intervalo acotado $[a, b]$.

- Caso de prueba para trazas numéricas:

$$f(x) = \frac{1}{4}x^4 - \frac{13}{3}x^3 + 27x^2 - 72x + 1$$

  definida en el intervalo $[1, 4]$.
- Mínimo global analítico situado exactamente en $x^* = 3.0$.

Función de prueba unidimensional

Representación gráfica de la función de prueba en el intervalo $[1, 4]$:

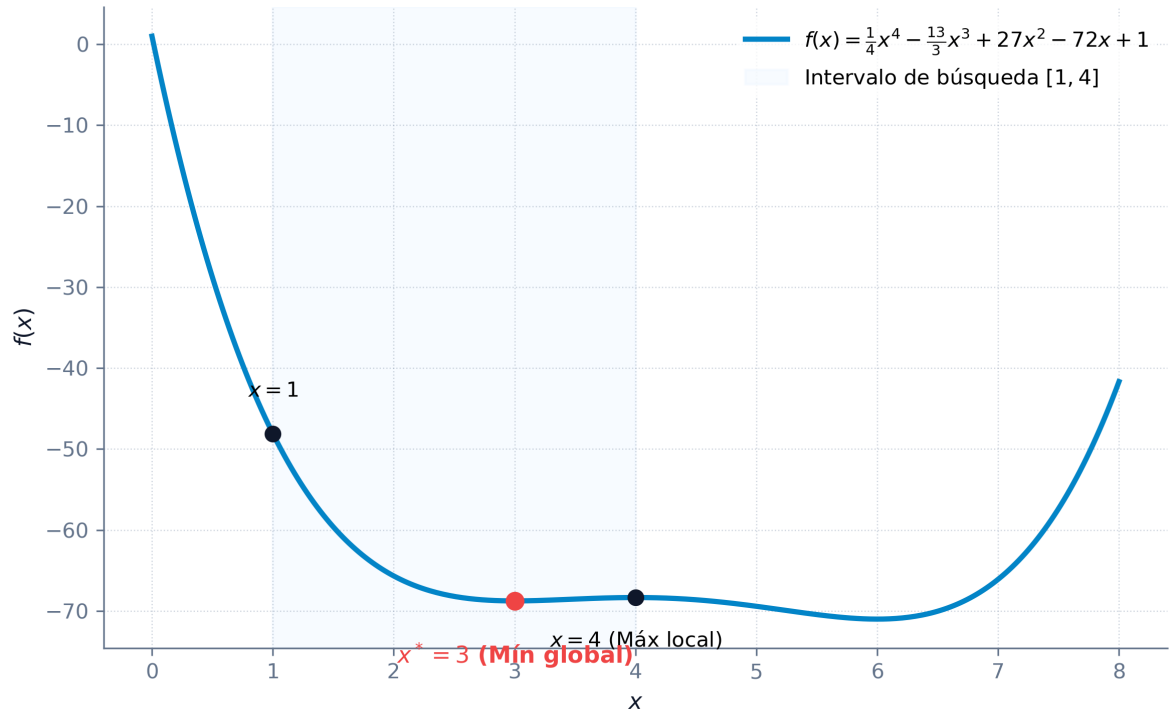

Métodos sin derivadas: búsqueda uniforme

- Subdivide el intervalo $[a, b]$ en n subintervalos iguales mediante una rejilla.
- Poco eficiente debido a que no aprovecha la información de las evaluaciones previas.

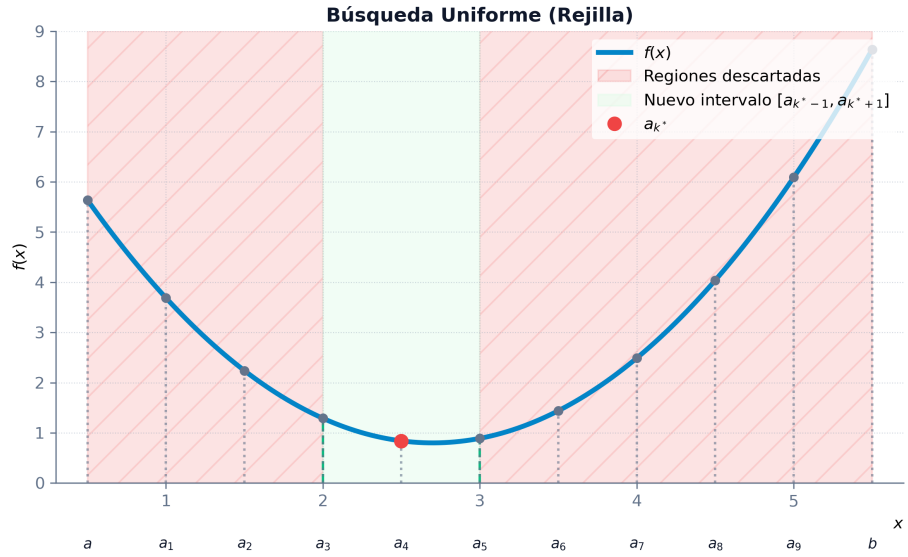

Búsqueda dicotómica: insuficiencia de un solo punto

Evaluar un único punto medio es insuficiente porque dos funciones unimodales diferentes pueden tener idéntico valor en el centro teniendo sus mínimos en lados opuestos:

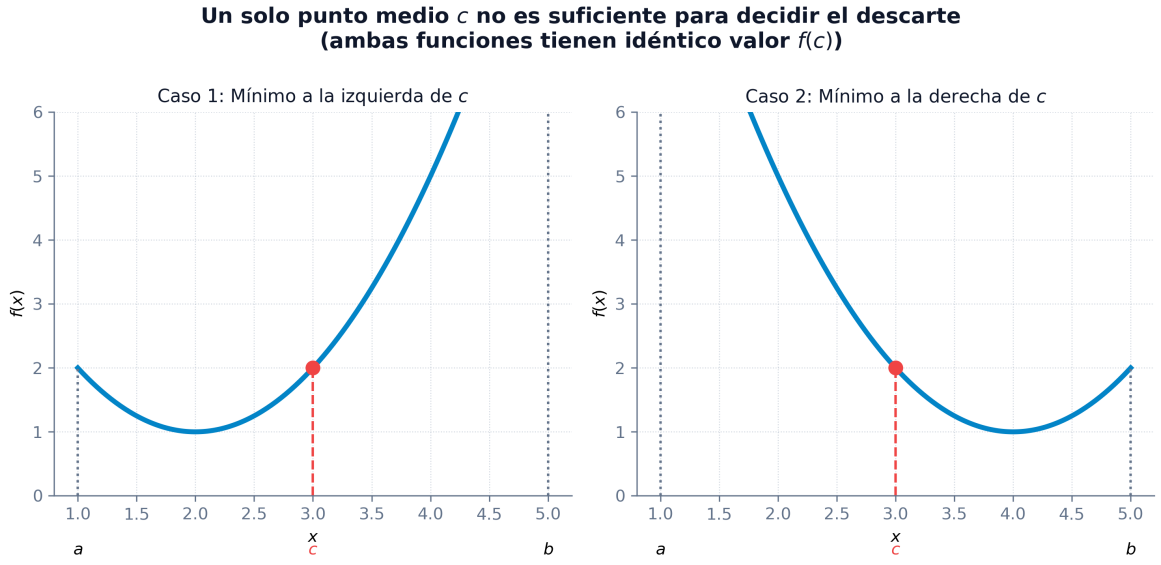

Métodos sin derivadas: búsqueda dicotómica

- Calcula dos puntos simétricos separados por una pequeña perturbación δ:

$$\lambda_k = \frac{a_k + b_k}{2} - \delta \qquad \mu_k = \frac{a_k + b_k}{2} + \delta$$

- Compara los valores de la función en ambos puntos para descartar una porción del intervalo en cada iteración:
  - Si $f(\lambda_k) < f(\mu_k) \implies$ el mínimo no está en $[\mu_k, b_k]$, nuevo intervalo $[a_k, \mu_k]$.
  - Si $f(\lambda_k) > f(\mu_k) \implies$ el mínimo no está en $[a_k, \lambda_k]$, nuevo intervalo $[\lambda_k, b_k]$.

Búsqueda dicotómica: paso a paso numérico (paso 1)

Minimizamos $f(x)$ en $[1, 4]$ con $\delta = 0.02$ y tolerancia $\epsilon = 0.15$:

- **Paso 1**: Intervalo inicial $[a_0, b_0] = [1, 4]$. Punto medio $c = 2.5$.
  - Planteamos y sustituimos:

$$\lambda_0 = \frac{a_0 + b_0}{2} - \delta = \frac{1+4}{2} - 0.02 = 2.48$$

$$\mu_0 = \frac{a_0 + b_0}{2} + \delta = \frac{1+4}{2} + 0.02 = 2.52$$

  - Calculamos evaluaciones:

$$f(2.48) \approx -68.1386 \qquad f(2.52) \approx -68.2437$$

  - Como $f(\lambda_0) > f(\mu_0) \implies$ descartamos $[a_0, \lambda_0]$. Nuevo intervalo: $[2.48, 4]$.

Búsqueda dicotómica: paso a paso numérico (paso 2)

- **Paso 2**: $[a_1, b_1] = [2.48, 4]$. Punto medio $c_1 = 3.24$.
  - Planteamos y sustituimos:

$$\lambda_1 = \frac{a_1 + b_1}{2} - \delta = 3.22$$

$$\mu_1 = \frac{a_1 + b_1}{2} + \delta = 3.26$$

  - Calculamos evaluaciones:

$$f(3.22) \approx -68.6910 \qquad f(3.26) \approx -68.6709$$

  - Como $f(\lambda_1) < f(\mu_1) \implies$ descartamos $[\mu_1, b_1]$. Nuevo intervalo: $[2.48, 3.26]$.

Búsqueda dicotómica: paso a paso numérico (paso 3 y siguientes)

- **Paso 3**: $[a_2, b_2] = [2.48, 3.26]$. Punto medio $c_2 = 2.87$.
  - Planteamos y sustituimos:

$$\lambda_2 = 2.85 \qquad \mu_2 = 2.89$$

  - Calculamos evaluaciones:

$$f(2.85) \approx -68.7116 \qquad f(2.89) \approx -68.7300$$

  - Como $f(\lambda_2) > f(\mu_2) \implies$ descartamos $[a_2, \lambda_2]$. Nuevo intervalo final: $[2.85, 3.26]$.
- **Fin de la búsqueda**: El intervalo final es $[2.85, 3.26]$ con amplitud 0.41. Para alcanzar la tolerancia $\epsilon = 0.15$ se requerirían iteraciones adicionales.

Búsqueda dicotómica: visualización del método

El proceso divide iterativamente el intervalo de búsqueda prácticamente a la mitad, convergiendo con rapidez hacia el óptimo mediante evaluaciones pareadas:

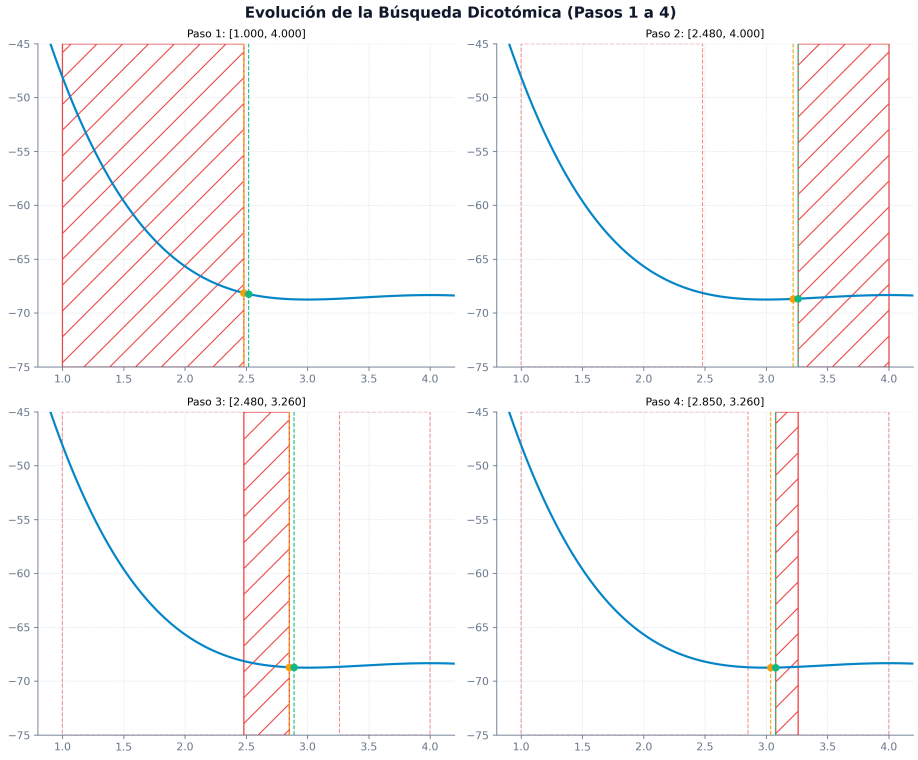

Métodos sin derivadas: sección áurea

- Optimiza la búsqueda dicotómica al reutilizar uno de los puntos evaluados en el paso anterior, reduciendo el coste computacional.
- La amplitud del intervalo se reduce de forma constante por la razón áurea:

$$I_k = \frac{b_k - a_k}{\alpha} \quad \text{con} \quad \alpha = \frac{1+\sqrt{5}}{2} \approx 1.61803$$

- Los puntos se localizan simétricamente en el intervalo:

$$\lambda_k = b_k - I_k \qquad \mu_k = a_k + I_k$$

Sección áurea: deducción del ratio α (1)

- Queremos que la razón entre las amplitudes de iteraciones sucesivas sea constante:

$$I_k = \alpha I_{k+1} \qquad I_{k+1} = \alpha I_{k+2} \implies I_k = \alpha^2 I_{k+2}$$

- Para poder reutilizar uno de los puntos internos del paso anterior, la suma de las amplitudes sucesivas debe satisfacer la relación de partición geométrica:

$$I_k = I_{k+1} + I_{k+2}$$

Sección áurea: deducción del ratio α (2)

- Sustituyendo las proporciones constantes de la escala en la partición geométrica:

$$\alpha^2 I_{k+2} = \alpha I_{k+2} + I_{k+2} \implies \alpha^2 - \alpha - 1 = 0$$

- Resolviendo esta ecuación cuadrática, la única raíz física posible ($\alpha > 1$) es la **razón áurea**:

$$\alpha = \frac{1+\sqrt{5}}{2} \approx 1.618033988$$

Sección áurea: paso a paso numérico (paso 1)

Minimizamos $f(x)$ en $[1, 4]$ con tolerancia $\epsilon = 0.15$:

- **Paso 1**: Intervalo inicial $[a_0, b_0] = [1, 4]$.
  - Amplitud teórica:

$$I_1 = \frac{b_0 - a_0}{\alpha} = \frac{4 - 1}{1.61803} \approx 1.8541$$

  - Sustituimos y calculamos puntos:

$$\lambda_0 = b_0 - I_1 = 4 - 1.8541 = 2.1459 \implies f(2.1459) \approx -66.692$$

$$\mu_0 = a_0 + I_1 = 1 + 1.8541 = 2.8541 \implies f(2.8541) \approx -68.714$$

  - Como $f(\lambda_0) > f(\mu_0) \implies$ descartamos $[a_0, \lambda_0]$. Nuevo intervalo: $[2.1459, 4]$.

Sección áurea: paso a paso numérico (paso 2)

- **Paso 2**: $[a_1, b_1] = [2.1459, 4]$. Amplitud $I_2 = 1.8541/1.61803 = 1.1459$.
  - Reutilizamos el punto interior evaluado:

$$\lambda_1 = \mu_0 = 2.8541 \implies f(2.8541) \approx -68.714$$

  - Sustituimos y calculamos el nuevo punto:

$$\mu_1 = a_1 + I_2 = 2.1459 + 1.1459 = 3.2918 \implies f(3.2918) \approx -68.654$$

  - Como $f(\lambda_1) < f(\mu_1) \implies$ descartamos $[\mu_1, b_1]$. Nuevo intervalo: $[2.1459, 3.2918]$.

Sección áurea: paso a paso numérico (pasos siguientes)

- **Paso 3**: $[a_2, b_2] = [2.1459, 3.2918]$. Amplitud $I_3 = 0.7082$.
  - Reutilizamos:

$$\mu_2 = \lambda_1 = 2.8541 \implies f(2.8541) \approx -68.714$$

  - Calculamos el nuevo punto:

$$\lambda_2 = b_2 - I_3 = 3.2918 - 0.7082 = 2.5836 \implies f(2.5836) \approx -68.386$$

  - Como $f(\lambda_2) > f(\mu_2) \implies$ descartamos $[a_2, \lambda_2]$. Nuevo intervalo: $[2.5836, 3.2918]$.
- **Convergencia**: El proceso continúa de forma análoga. En el **paso 7**, la amplitud de búsqueda se reduce a $0.1033 \leq 0.15$ (tolerancia alcanzada), con el óptimo localizado en el intervalo final $[2.91, 3.01]$.

Sección áurea: visualización del método

La amplitud del intervalo se contrae de forma secuencial manteniendo la proporción de la sección áurea, reutilizando las evaluaciones previas de forma simétrica:

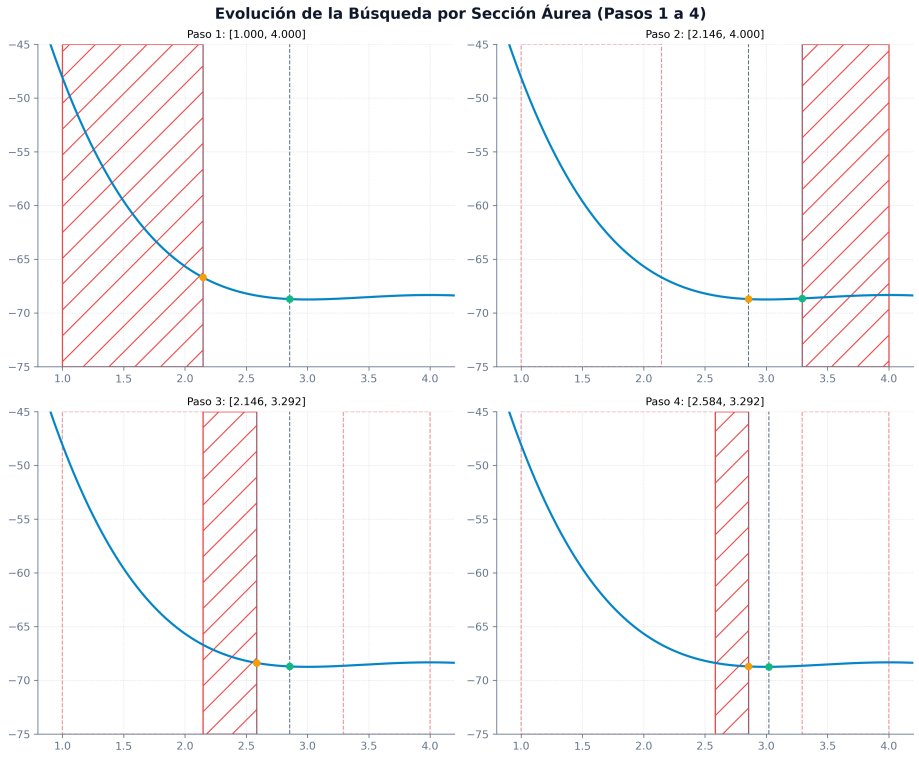

Métodos sin derivadas: Fibonacci

- Fija de antemano el número total de evaluaciones de función N para maximizar la reducción del intervalo final.
- Utiliza los términos de la serie de Fibonacci para definir los coeficientes de reducción:

$$F_0 = 1, F_1 = 1, F_2 = 2, F_3 = 3, F_4 = 5, F_5 = 8, F_6 = 13, F_7 = 21,$$

- La amplitud del paso en cada iteración k se calcula mediante:

$$I_k = \frac{F_{N-k}}{F_{N-k+2}}(b_{k-1} - a_{k-1})$$

Fibonacci: relación de amplitudes e intervalos (1)

- Se fija de antemano el número total de evaluaciones N.
- En la última iteración $(N-1)$, queremos que los puntos coincidan prácticamente en el centro para poder descartar la mitad del espacio restante:

$$I_{N-1} \approx 2I_N$$

- Siguiendo la regla de adición para la reutilización de puntos, las amplitudes de intervalos sucesivos se van acumulando:

$$I_{N-2} = I_{N-1} + I_N \approx 3I_N$$

$$I_{N-3} = I_{N-2} + I_{N-1} \approx 5I_N$$

Fibonacci: relación de amplitudes e intervalos (2)

- En general, las amplitudes sucesivas en la iteración k se relacionan mediante los términos de Fibonacci:

$$I_k = F_{N-k+1} I_N$$

- Esto nos permite deducir el paso en cada iteración en función del intervalo actual de incertidumbre:

$$I_{k+1} = \frac{F_{N-k}}{F_{N-k+1}} (b_k - a_k)$$

Fibonacci: paso a paso numérico (paso 1)

Minimizamos $f(x)$ en $[1, 4]$ mediante Fibonacci para un total de $N = 6$ evaluaciones ($F_7 = 21$):

- **Paso 1**: $[a_0, b_0] = [1, 4]$.
  - Amplitud teórica del paso:

$$I_1 = \frac{F_6}{F_7}(b_0 - a_0) = \frac{13}{21}(4 - 1) = \frac{39}{21} \approx 1.8571$$

  - Sustituimos y calculamos:

$$\lambda_0 = b_0 - I_1 = 4 - 1.8571 = 2.1429 \implies f(2.1429) \approx -66.673$$

$$\mu_0 = a_0 + I_1 = 1 + 1.8571 = 2.8571 \implies f(2.8571) \approx -68.715$$

  - Como $f(\lambda_0) > f(\mu_0) \implies$ nuevo intervalo: $[2.1429, 4]$.

Fibonacci: paso a paso numérico (paso 2 y siguientes)

- **Paso 2**: $[a_1, b_1] = [2.1429, 4]$. Paso $I_2 = \frac{F_5}{F_7}(b_0 - a_0) = \frac{8}{21} \cdot 3 = 1.1429$.
  - Reutilizamos el punto interior evaluado:

$$\lambda_1 = \mu_0 = 2.8571 \implies f(2.8571) \approx -68.715$$

  - Sustituimos y calculamos el nuevo punto:

$$\mu_1 = a_1 + I_2 = 2.1429 + 1.1429 = 3.2857 \implies f(3.2857) \approx -68.657$$

  - Como $f(\mu_1) > f(\lambda_1) \implies$ descartamos $[\mu_1, b_1]$. Nuevo intervalo final: $[2.1429, 3.2857]$.
- **Pasos siguientes**: El algoritmo continúa de forma análoga reduciendo los coeficientes de Fibonacci hasta agotar las $N = 6$ evaluaciones de la función planificadas, estrechando el intervalo en torno a $x^* = 3.0$.

Métodos con derivadas: bisección (Bolzano)

- Busca el cero de la primera derivada ($f'(x) = 0$) en un intervalo $[a, b]$ donde el signo de la derivada en los extremos sea opuesto ($f'(a) \cdot f'(b) < 0$).
- En cada paso, evalúa el punto medio del intervalo:

$$c_k = \frac{a_k + b_k}{2}$$

- Reduce el intervalo a la mitad analizando el signo de $f'(c_k)$:
  - Si $f'(c_k) < 0 \implies$ nuevo intervalo $[c_k, b_k]$.
  - Si $f'(c_k) > 0 \implies$ nuevo intervalo $[a_k, c_k]$.

Bisección: paso a paso numérico (paso 1)

Minimizamos $f(x)$ con $f'(x) = x^3 - 13x^2 + 54x - 72$ en $[1, 4]$, $\epsilon = 0.15$:

- **Paso 1**: $[a_0, b_0] = [1, 4]$.
  - Punto medio teórico:

$$c_0 = \frac{a_0 + b_0}{2} = \frac{1+4}{2} = 2.5$$

  - Sustituimos y calculamos la derivada:

$$f'(2.5) = (2.5)^3 - 13(2.5)^2 + 54(2.5) - 72 = -2.625 < 0$$

  - Descartamos la mitad izquierda $\implies$ nuevo intervalo $[2.5, 4]$.

Bisección: paso a paso numérico (paso 2)

- **Paso 2**: $[a_1, b_1] = [2.5, 4]$. Punto medio $c_1 = 3.25$.
  - Sustituimos y calculamos la derivada:

    $$f'(3.25) = (3.25)^3 - 13(3.25)^2 + 54(3.25) - 72 = 0.5156 > 0$$

  - Como $f'(c_1) > 0 \implies$ descartamos la mitad derecha. Nuevo intervalo: $[2.5, 3.25]$.

Bisección: paso a paso numérico (paso 3 y siguientes)

- **Paso 3**: $[a_2, b_2] = [2.5, 3.25]$. Punto medio $c_2 = 2.875$.
  - Sustituimos y calculamos la derivada:

    $$f'(2.875) = (2.875)^3 - 13(2.875)^2 + 54(2.875) - 72 = -0.4395 < 0$$

  - Como $f'(c_2) < 0 \implies$ descartamos la mitad izquierda. Nuevo intervalo: $[2.875, 3.25]$.
- **Convergencia**: En el **paso 5**, el intervalo es $[2.9531, 3.0469]$ con una amplitud de $0.0938 \leq 0.15$, alcanzando la tolerancia.

Bisección: visualización del método

El método se basa en el teorema de Bolzano, acotando sucesivamente el valor donde la derivada se anula dividiendo a la mitad la amplitud en cada iteración:

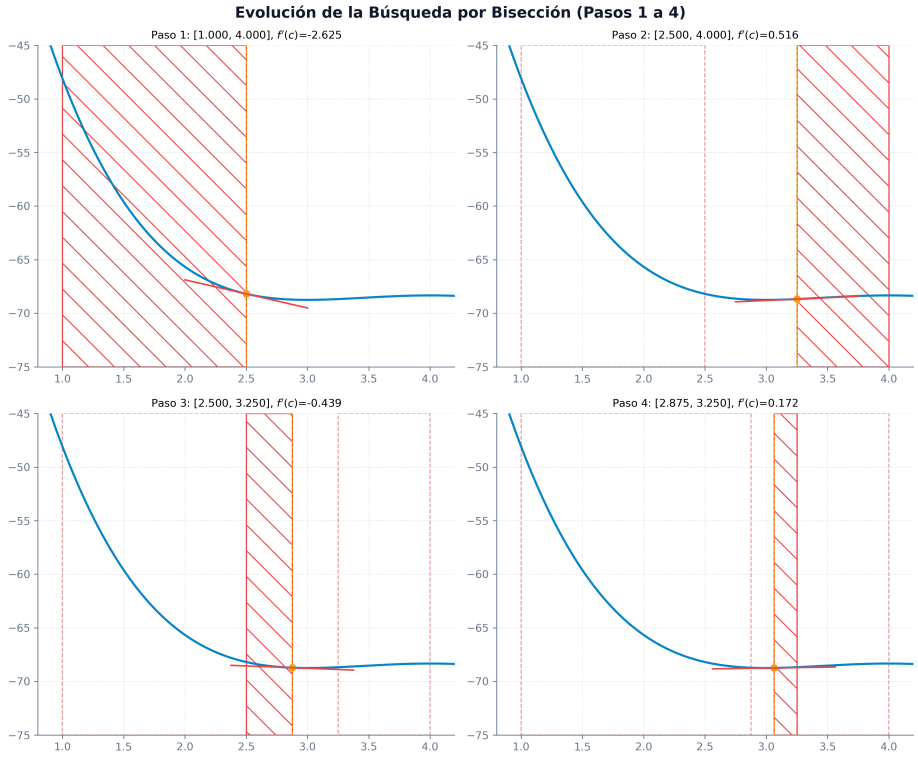

Métodos con derivadas: método de Newton 1D

- Aproxima la función objetivo mediante su polinomio de Taylor cuadrático alrededor del punto de búsqueda actual x_k.
- El siguiente punto iterado se obtiene saltando directamente al vértice de la parábola aproximada (donde la derivada aproximada se anula):

$$x_{k+1} = x_k - \frac{f'(x_k)}{f''(x_k)}$$

- Requiere que la función sea de clase $\mathcal{C}^2$ y que $f''(x_k) \neq 0$.

Newton 1D: deducción de la fórmula

- El desarrollo de Taylor de segundo orden en x_k es:

$$q(x) = f(x_k) + f'(x_k)(x - x_k) + \frac{1}{2} f''(x_k)(x - x_k)^2$$

- Para hallar el vértice de la aproximación parabólica, igualamos su derivada a cero:

$$q'(x) = f'(x_k) + f''(x_k)(x - x_k) = 0$$

- Despejando x, obtenemos el punto iterado x_{k+1}:

$$x - x_k = -\frac{f'(x_k)}{f''(x_k)} \implies x_{k+1} = x_k - \frac{f'(x_k)}{f''(x_k)}$$

Newton 1D: paso a paso numérico (paso 1)

Minimizamos la misma función partiendo de $x_0 = 1.0$:

- **Paso 1**: Partimos de $x_0 = 1.0$.
  - Ecuaciones teóricas y derivadas ($f''(x) = 3x^2 - 26x + 54$):

$$f'(x_0) = f'(1.0) = 1^3 - 13(1)^2 + 54(1) - 72 = -30.0$$

$$f''(x_0) = f''(1.0) = 3(1)^2 - 26(1) + 54 = 31.0$$

  - Sustituimos en la regla de Newton:

$$x_1 = x_0 - \frac{f'(x_0)}{f''(x_0)} = 1.0 - \frac{-30.0}{31.0} \approx 1.9677$$

Newton 1D: paso a paso numérico (paso 2)

- **Paso 2**: Partimos del punto anterior $x_1 = 1.9677$.
  - Calculamos primera y segunda derivada:

$$f'(1.9677) \approx -8.4589 \qquad f''(1.9677) \approx 14.4547$$

  - Sustituimos en la regla de Newton:

$$x_2 = x_1 - \frac{f'(x_1)}{f''(x_1)} = 1.9677 - \frac{-8.4589}{14.4547} \approx 2.5529$$

Newton 1D: paso a paso numérico (pasos 3-5)

- **Paso 3**: Partimos de $x_2 = 2.5529$.
  - Calculamos derivadas: $f'(2.5529) \approx -2.2300$, $f''(2.5529) \approx 7.1760$.
  - Actualización: $x_3 = 2.5529 - \frac{-2.2300}{7.1760} \approx 2.8637$.
- **Paso 4**: $x_3 = 2.8637 \implies x_4 = 2.8637 - \frac{-0.485}{4.146} \approx 2.9808$.
- **Paso 5**:
  $x_4 = 2.9808 \implies x_5 = 2.9808 - \frac{-0.059}{3.154} \approx 2.9995 \approx 3.0$.

Newton 1D: visualización del método

El algoritmo aproxima de manera local mediante parábolas sucesivas y converge muy rápido si el punto inicial x_0 está próximo al óptimo:

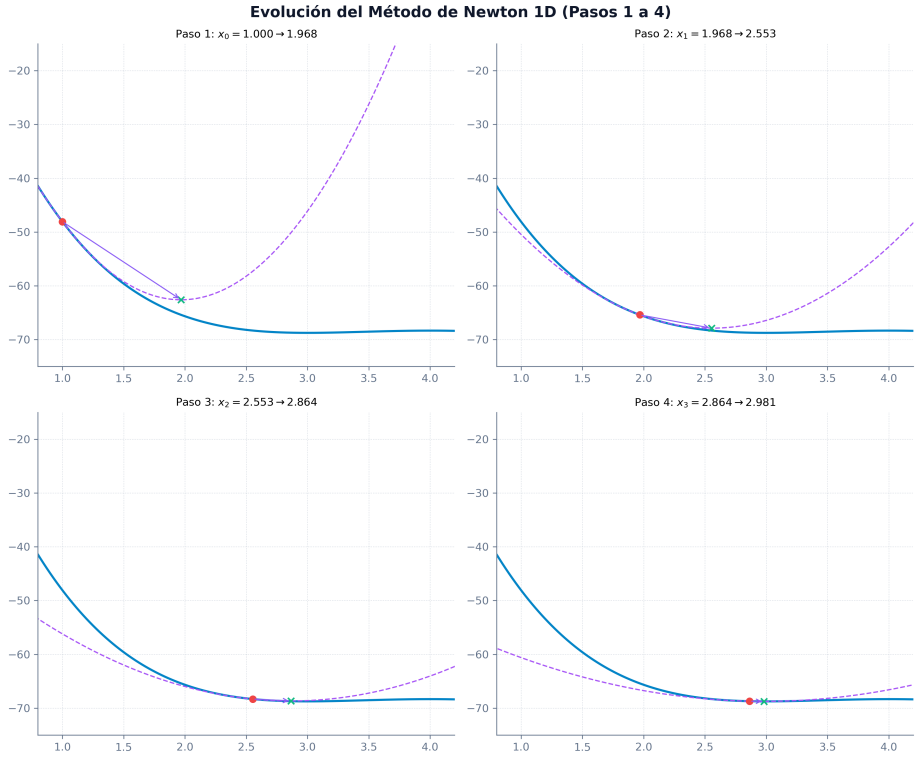

Método de la secante

- Evita el cálculo de la segunda derivada del método de Newton.
- Aproxima la curvatura mediante la diferencia de gradientes en los últimos dos pasos:

$$x_{k+1} = x_k - f'(x_k)\frac{x_k - x_{k-1}}{f'(x_k) - f'(x_{k-1})}$$

- Características:
  - Convergencia superlineal con orden ≈ 1.618.
  - Exige disponer de dos puntos iniciales x_0 y x_{-1}.

Secante: paso a paso numérico (pasos 1-2)

Minimizamos $f(x)$ en $[1, 4]$ partiendo de $x_{-1} = 1.0$ y $x_0 = 1.5$:

- **Paso 1**: $x_{-1} = 1.0$, $x_0 = 1.5$.
  - Evaluamos derivadas:
    $f'(1.0) = -30.0 \qquad f'(1.5) = -16.875.$
  - Sustituimos en la regla:

$$x_1 = 1.5 - (-16.875) \cdot \frac{1.5 - 1.0}{-16.875 - (-30.0)} \approx 2.1429$$

- **Paso 2**: $x_0 = 1.5$, $x_1 = 2.1429$.
  - Derivada nueva: $f'(2.1429) \approx -6.1399$.
  - Actualización:

$$x_2 = 2.1429 - (-6.1399) \cdot \frac{2.1429 - 1.5}{-6.1399 - (-16.875)} \approx 2.5106$$

Secante: paso a paso numérico (pasos siguientes)

- **Paso 3**: $x_1 = 2.1429$, $x_2 = 2.5106$.
  - Actualización: $x_3 \approx 2.7707$.
- **Paso 4**: $x_2 = 2.5106$, $x_3 = 2.7707$.
  - Actualización: $x_4 \approx 2.9157$.
- **Paso 5**: $x_3 = 2.7707$, $x_4 = 2.9157$.
  - Actualización: $x_5 \approx 2.9807$ (llegando a $x_7 \approx 2.9999 \approx 3.0$ en iteraciones posteriores sin calcular segundas derivadas).

Métodos multivariantes

Métodos multivariantes de optimización sin restricciones

Buscan minimizar $f : \mathbb{R}^n \to \mathbb{R}$ mediante la sucesión iterativa:

$$x_{k+1} = x_k + \alpha_k d_k$$

Donde:

- **Dirección de búsqueda (d_k)**: Debe ser de descenso (formar un ángulo obtuso con el gradiente):

$$\nabla f(x_k)^T d_k < 0$$

- **Tamaño de paso (α_k)**: Determina el avance óptimo a lo largo de la dirección. Se calcula resolviendo el problema unidimensional:

$$\alpha_k = \arg\min_{\alpha > 0} f(x_k + \alpha d_k)$$

Funciones multivariantes de prueba (1)

- **Función de distancia circular (desacoplada)**:

$$f(x, y) = (x - 2)^2 + (y - 1)^2$$

- Presenta un paraboloide circular de revolución simétrico con curvas de nivel circulares concéntricas y mínimo global en $x^* = (2, 1)^T$.

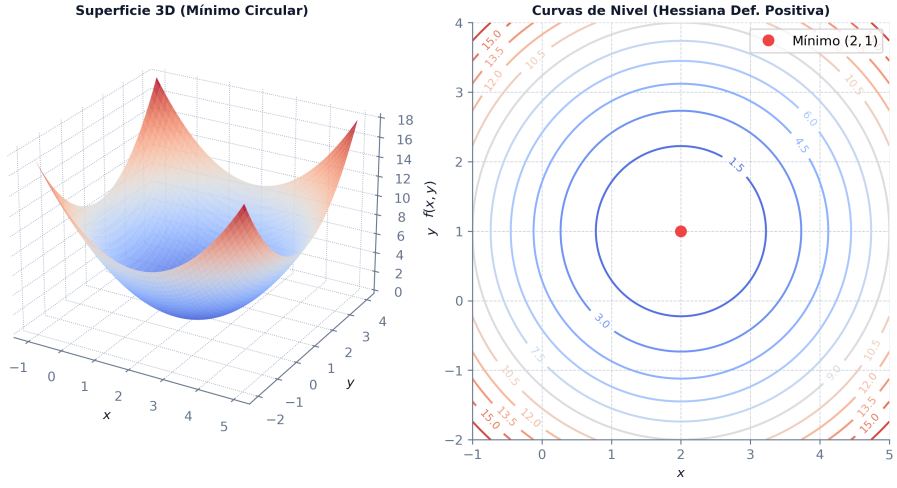

Funciones multivariantes de prueba (2)

- **Función cuadrática mal acondicionada (acoplada)**:

$$f(x, y) = 8x^2 + 3xy + 7y^2 - 25x + 31y - 29$$

- Presenta un paraboloide elíptico alargado con curvas de nivel elípticas y mínimo global en $x^* \approx (2.060, -2.656)^T$.

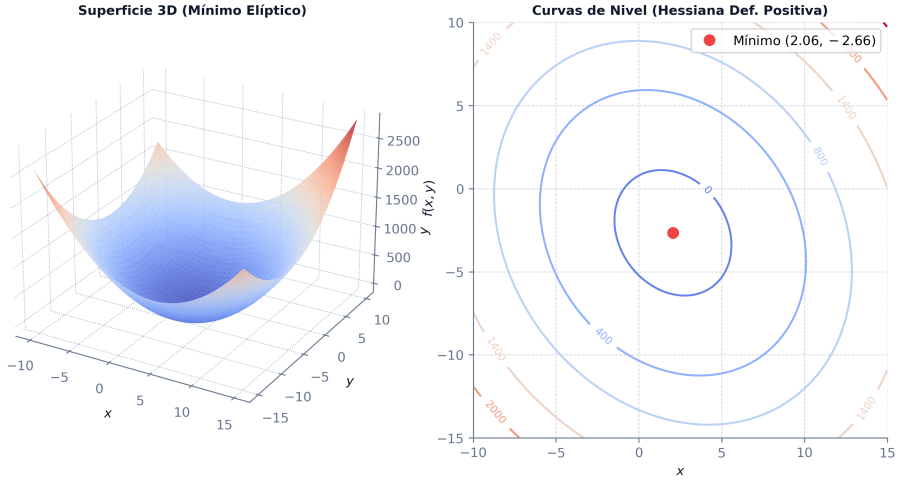

Método de coordenadas cíclicas

- Es un método de optimización multivariante de búsqueda directa (no requiere derivadas).
- Avanza de forma iterativa minimizando respecto a una sola variable de decisión a la vez de forma cíclica (direcciones de búsqueda ortogonales $d_k = e_i$):

$$x_{k+1} = x_k + \alpha_k e_i$$

- El tamaño de paso exacto α_k se calcula mediante una búsqueda lineal unidimensional exacta en la dirección e_i.

Coordenadas cíclicas: paso a paso numérico (paso 1)

Minimizamos $f(x,y) = 8x^2 + 3xy + 7y^2 - 25x + 31y - 29$ desde $x_0 = (0,0)^T$:

- **Paso 1**: Optimizamos respecto a x fijando $y = y_0 = 0$:
  - Sustituimos en la ecuación teórica:

    $$f(x,0) = 8x^2 + 3x(0) + 7(0)^2 - 25x + 31(0) - 29 = 8x^2 - 25x - 29$$

  - Derivamos respecto a x e igualamos a cero:

    $$\frac{df(x,0)}{dx} = 16x - 25 = 0 \implies x = \frac{25}{16} = 1.5625$$

  - El punto resultante es $x_1 = (1.5625, 0)^T$.

Coordenadas cíclicas: paso a paso numérico (paso 2)

- **Paso 2**: Optimizamos respecto a y fijando $x = 1.5625$:
  - Sustituimos en la ecuación:

$$f(1.5625, y) = 7y^2 + 35.6875y - 48.531$$

  - Derivamos respecto a y e igualamos a cero:

$$\frac{\partial f(1.5625, y)}{\partial y} = 14y + 35.6875 = 0 \implies y_2 \approx -2.5491$$

  - El punto resultante es $x_2 = (1.5625, -2.5491)^T$.

Coordenadas cíclicas: paso a paso numérico (paso 3)

- **Paso 3**: Optimizamos respecto a x fijando $y = -2.5491$:
  - Sustituimos en la ecuación:

$$f(x, -2.5491) = 8x^2 - 32.647x - 62.533$$

  - Derivamos respecto a x e igualamos a cero:

$$\frac{\partial f(x, -2.5491)}{\partial x} = 16x - 32.647 = 0 \implies x_3 \approx 2.0405$$

  - El punto resultante es $x_3 = (2.0405, -2.5491)^T$.

Coordenadas cíclicas: variables desacopladas

Avanza minimizando respecto a una sola variable a la vez. Si las variables están desacopladas (Hessiana diagonal), localiza el mínimo en exactamente $n = 2$ pasos ortogonales exactos:

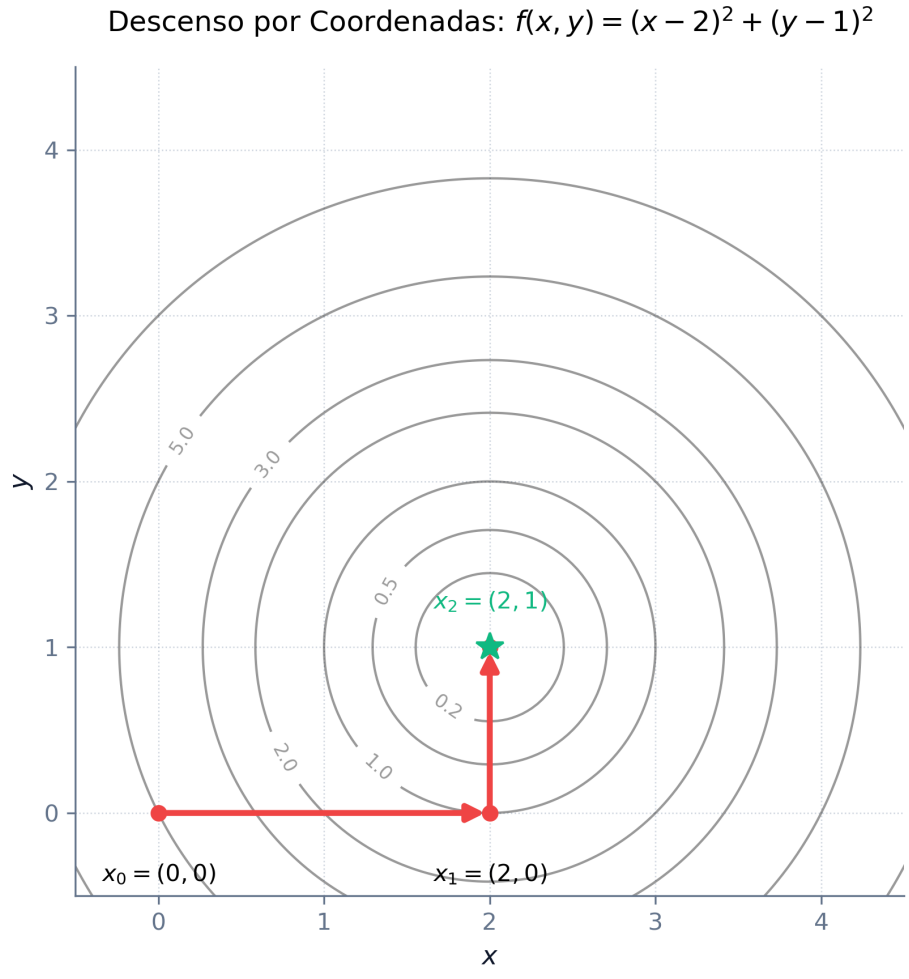

Coordenadas cíclicas: variables acopladas

Si las variables están acopladas (término bilineal $3xy$), la trayectoria dibuja un patrón de "escalera", haciendo lenta la convergencia:

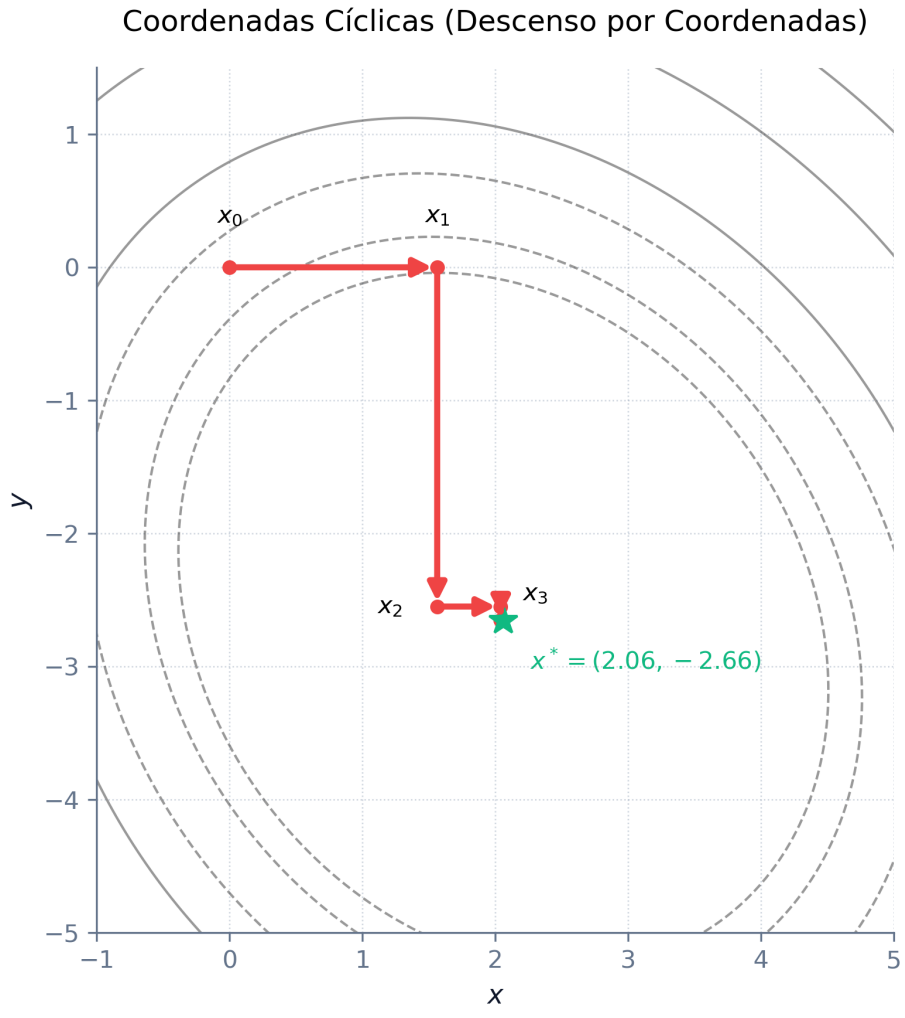

Método del máximo descenso

- Dirección de búsqueda: opuesta al gradiente local ($d_k = -\nabla f(x_k)$). ::: {.callout-important title="Ortogonalidad"} Si el tamaño de paso se calcula mediante búsqueda de línea exacta, las direcciones de búsqueda consecutivas son siempre ortogonales:

$$d_k^T d_{k+1} = 0$$

:::

- **Consecuencia geométrica**: El método avance generando un patrón en "zig-zag" característico con ángulos de 90° entre iteraciones sucesivas.

Máximo descenso: paso a paso numérico (paso 1)

Caso cuadrático acoplado $f(x, y)$ desde $x_0 = (0, 0)^T$:

- **Paso 1**: Calculamos el gradiente y la dirección de descenso:
  - Gradiente teórico:

$$\nabla f(x, y) = \begin{pmatrix} 16x + 3y - 25 \\ 3x + 14y + 31 \end{pmatrix}$$

  - Sustituimos $x_0 = (0, 0)^T$:

$$\nabla f(x_0) = \begin{pmatrix} 16(0) + 3(0) - 25 \\ 3(0) + 14(0) + 31 \end{pmatrix} = \begin{pmatrix} -25 \\ 31 \end{pmatrix}$$

  - Dirección de búsqueda ($d_0 = -\nabla f(x_0)$):

$$d_0 = \begin{pmatrix} 25 \\ -31 \end{pmatrix}$$

Máximo descenso: paso a paso numérico (paso 2)

- **Paso 2**: Búsqueda lineal exacta en la dirección $d_0 = (25, -31)^T$:
  - Sustituimos la trayectoria $x(\alpha) = x_0 + \alpha d_0 = (25\alpha, -31\alpha)^T$:

$$\phi(\alpha) = f(25\alpha, -31\alpha) = 9402\alpha^2 - 1586\alpha - 29$$

  - Derivamos e igualamos a cero:

$$\phi'(\alpha) = 18804\alpha - 1586 = 0 \implies \alpha_0 = \frac{1586}{18804} \approx 0.0843$$

Máximo descenso: paso a paso numérico (pasos 3-4)

- **Paso 3**: Actualizamos el punto con la longitud de paso óptima $\alpha_0 \approx 0.0843$:

$$x_1 = x_0 + \alpha_0 d_0 = \begin{pmatrix} 0 \\ 0 \end{pmatrix} + 0.0843 \begin{pmatrix} 25 \\ -31 \end{pmatrix} \approx \begin{pmatrix} 2.109 \\ -2.615 \end{pmatrix}$$

- **Paso 4**: Verificamos la ortogonalidad teórica en el nuevo punto:
  - Evaluamos el gradiente en x_1:

$$\nabla f(x_1) \approx \begin{pmatrix} 0.8925 \\ 0.7225 \end{pmatrix}$$

  - El producto escalar es nulo (ortogonales):

$$d_0^T \nabla f(x_1) = 25(0.8925) - 31(0.7225) \approx 0$$

Máximo descenso: visualización del método

La ortogonalidad obligada entre direcciones consecutivas debido a la búsqueda lineal exacta provoca un patrón de "zigzag" muy ineficiente en funciones con valles estrechos (elipses alargadas):

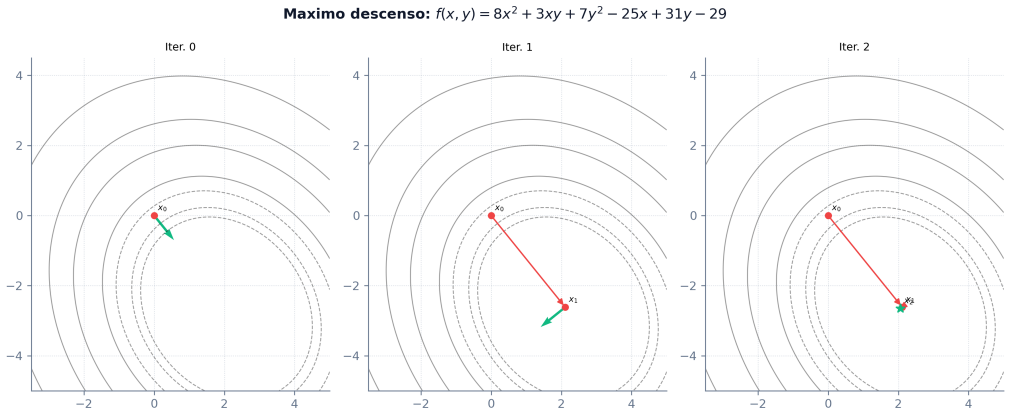

Método de Newton multivariante

Aproxima la función objetivo mediante una parábola multivariante en el punto actual x_k:

$$x_{k+1} = x_k - [\nabla^2 f(x_k)]^{-1} \nabla f(x_k)$$

- **Ventaja**: Convergencia cuadrática local de orden 2. Localiza el mínimo en 1 iteración para funciones cuadráticas.
- **Limitaciones**:
  - Coste computacional de resolver el sistema lineal es alto ($O(n^3)$).
  - Exige que la Hessiana sea definida positiva ($H \succ 0$).
  - Convergencia estrictamente local (puede divergir si se empieza lejos).

Newton multivariante: paso a paso numérico (pasos 1-2)

Minimizamos $f(x,y) = 8x^2 + 3xy + 7y^2 - 25x + 31y - 29$ desde $x_0 = (0,0)^T$:

- **Paso 1**: Calculamos el gradiente y la Hessiana en el punto actual:
  - Expresiones teóricas:

$$\nabla f(x,y) = \begin{pmatrix} 16x + 3y - 25 \\ 3x + 14y + 31 \end{pmatrix} \implies \nabla f(x_0) = \begin{pmatrix} -25 \\ 31 \end{pmatrix}$$

$$H = \nabla^2 f(x,y) = \begin{pmatrix} 16 & 3 \\ 3 & 14 \end{pmatrix} \quad \text{(constante)}$$

- **Paso 2**: Calculamos la inversa de la Hessiana H^{-1} (determinante $|H| = 16 \cdot 14 - 3^2 = 215$):

$$H^{-1} = \frac{1}{215} \begin{pmatrix} 14 & -3 \\ -3 & 16 \end{pmatrix}$$

Newton multivariante: paso a paso numérico (paso 3)

- **Paso 3**: Aplicamos la actualización iterativa del método de Newton:

$$x_1 = x_0 - H^{-1}\nabla f(x_0)$$

$$x_1 = \begin{pmatrix} 0 \\ 0 \end{pmatrix} - \frac{1}{215}\begin{pmatrix} 14 & -3 \\ -3 & 16 \end{pmatrix}\begin{pmatrix} -25 \\ 31 \end{pmatrix}$$

$$x_1 = -\frac{1}{215}\begin{pmatrix} 14(-25) - 3(31) \\ -3(-25) + 16(31) \end{pmatrix} = -\frac{1}{215}\begin{pmatrix} -443 \\ 571 \end{pmatrix} = \begin{pmatrix} 443/215 \\ -571/21 \end{pmatrix}$$

$$x_1 \approx \begin{pmatrix} 2.0605 \\ -2.6558 \end{pmatrix}$$

- **Conclusión**: Dado que la función $f(x, y)$ es cuadrática, la aproximación local es exacta y el método de Newton converge al mínimo global en **exactamente una iteración**.

Método cuasi-Newton: BFGS

Resuelven los inconvenientes del método de Newton estimando la inversa de la Hessiana $H_k \approx [\nabla^2 f(x_k)]^{-1}$ usando solo gradientes:

- Fuerzan la **ecuación de la secante**:

$$H_{k+1} y_k = s_k$$

  donde $s_k = x_{k+1} - x_k$ y $y_k = \nabla f(x_{k+1}) - \nabla f(x_k)$.
- Mantiene la matriz definida positiva en cada paso (si cumple condiciones de Wolfe).
- Costo de $O(n^2)$ por iteración y convergencia superlineal.

Tema 3: análisis convexo y condiciones de optimalidad

Optimización y Análisis de Redes

Víctor Aceña Gil - Antonio Alonso Ayuso

2026-07-09

Introducción y conjuntos convexos

¿De qué trata este tema?

El análisis convexo estudia las propiedades geométricas de conjuntos y funciones que garantizan la resolución eficiente y global de problemas de optimización.

- **Evitar óptimos locales**: Identificar estructuras donde no existen mínimos locales falsos, impidiendo que los algoritmos queden atrapados en soluciones subóptimas.
- **Optimización no diferenciable**: Extender la teoría de optimización clásica a funciones no suaves (con "codos" o esquinas) mediante el concepto de subgradiente y subdiferencial.
- **Garantías de unicidad y globalidad**: Caracterizar analíticamente cuándo una solución óptima es única y globalmente válida.
- **Generalizaciones matemáticas**: Relajar las condiciones de convexidad estricta mediante cuasi-convexidad y pseudo-convexidad para modelar problemas reales (como utilidad económica o eficiencias).

¿Qué aprenderás en este tema?

- **Álgebra de conjuntos convexos**: Demostrar la convexidad de dominios factibles y comprender la minimalidad de la envoltura convexa.
- **Geometría de funciones**: Caracterizar funciones a través de sus epígrafos y conjuntos de nivel.
- **Condiciones diferenciales de convexidad**: Emplear el gradiente (primer orden) y la Hessiana (segundo orden) para demostrar analíticamente la convexidad de una función.
- **Cálculo de subgradientes**: Determinar el subdiferencial de funciones no suaves y trazar planos de soporte inferior.
- **Optimalidad global**: Aplicar la caracterización variacional y de subgradientes para verificar y certificar mínimos restringidos.
- **Taxonomía de generalizaciones**: Clasificar y relacionar funciones cuasi-convexas, estrictamente cuasi-convexas, fuertemente cuasi-convexas y pseudo-convexas.

Conjuntos convexos: definición

Un conjunto $\mathcal{S} \subseteq \mathbb{R}^n$ es **convexo** si, para cualesquiera dos puntos $x_1, x_2 \in \mathcal{S}$, la combinación convexa de ambos pertenece también a $\mathcal{S}$ para todo $\lambda \in [0, 1]$:

$$\lambda x_1 + (1 - \lambda) x_2 \in \mathcal{S}, \quad \forall \lambda \in [0, 1]$$

- **Combinación lineal**:
  $\sum \lambda_i x_i$ con $\lambda_i \in \mathbb{R}$.
- **Combinación afín**:
  Combinación lineal con
  $\sum \lambda_i = 1$.
- **Combinación cónica**:
  Combinación lineal con
  $\lambda_i \geq 0$.
- **Combinación convexa**:
  Combinación lineal con
  $\lambda_i \geq 0$ y $\sum \lambda_i = 1$.

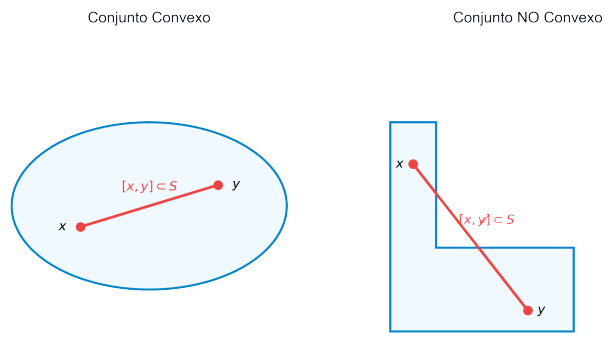

Ejemplos de conjuntos convexos básicos

- **Hiperplano**: Dado un vector normal no nulo $p \in \mathbb{R}^n$ y un escalar $\alpha \in \mathbb{R}$:

$$\mathcal{H} = \{x \in \mathbb{R}^n \mid p^T x = \alpha\}$$

- **Semiespacio Cerrado**: Región situada en uno de los lados de un hiperplano:

$$\mathcal{H}^- = \{x \in \mathbb{R}^n \mid p^T x \leq \alpha\} \qquad \mathcal{H}^+ = \{x \in \mathbb{R}^n \mid p^T x \geq \alpha\}$$

- **Poliedro o Politopo Convexo**: La intersección de un número finito de semiespacios cerrados:

$$\mathcal{P} = \{x \in \mathbb{R}^n \mid Ax \leq b\}$$

- **Bola Métrica**: Bola cerrada en $\mathbb{R}^n$ con centro en x_0 y radio $r \geq 0$ bajo cualquier norma $\|\cdot\|$:

$$\mathcal{B} = \{x \in \mathbb{R}^n \mid \|x - x_0\| \leq r\}$$

Propiedades algebraicas de conjuntos convexos

La convexidad se preserva bajo operaciones algebraicas fundamentales.

Propiedades de conservación: Sean $\mathcal{S}_1, \mathcal{S}_2 \subseteq \mathbb{R}^n$ dos conjuntos convexos:

1. **Intersección**: $\mathcal{S}_1 \cap \mathcal{S}_2$ es un conjunto convexo. (Generalizable a familias infinitas).
2. **Suma Directa**: $\mathcal{S}_1 \oplus \mathcal{S}_2 = \{x + y \mid x \in \mathcal{S}_1, y \in \mathcal{S}_2\}$ es convexo.
3. **Diferencia Directa**: $\mathcal{S}_1 \ominus \mathcal{S}_2 = \{x - y \mid x \in \mathcal{S}_1, y \in \mathcal{S}_2\}$ es convexo.

Envoltura convexa

La envoltura convexa $\mathcal{H}(\mathcal{S})$ de un conjunto $\mathcal{S}$ es el conjunto formado por todas las combinaciones lineales convexas posibles de puntos pertenecientes a $\mathcal{S}$:

$$\mathcal{H}(\mathcal{S}) = \left\{ x = \sum_{j=1}^{k} \lambda_j x_j \;\middle|\; x_j \in \mathcal{S},\ \lambda_j \geq 0,\ \sum_{j=1}^{k} \lambda_j = 1 \right\}$$

Minimalidad de la envoltura convexa

! Minimalidad de la envoltura convexa

La envoltura convexa $\mathcal{H}(\mathcal{S})$ es el menor conjunto convexo que contiene al conjunto $\mathcal{S}$.

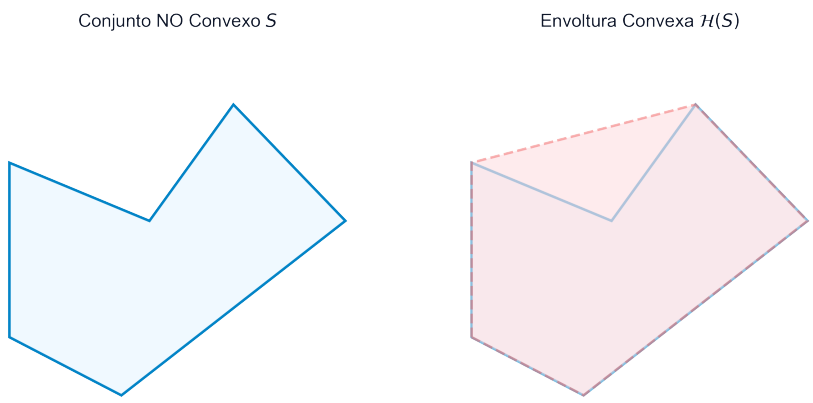

Politopos, símplices y puntos extremos

- **Politopo y Símplex**: Un *politopo* es la envoltura convexa de un número finito de puntos. Si son afínmente independientes, es un *símplex* (triángulo en 2D, tetraedro en 3D).
- **Puntos extremos**: Elemento $x \in \mathcal{S}$ que no puede expresarse como combinación convexa de otros dos puntos distintos. En poliedros coinciden con los **vértices**.

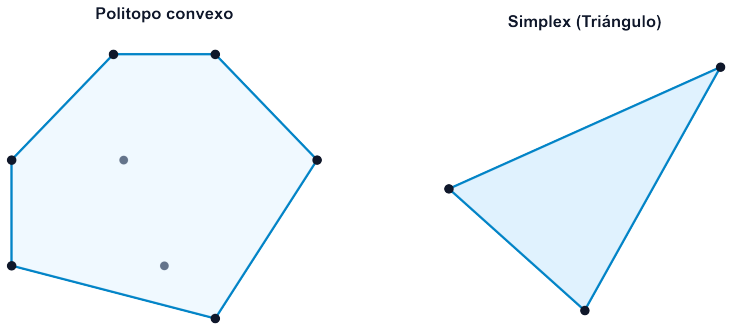

Optimización en poliedros

- **Teorema de Representación de Minkowski-Weyl**: Todo punto de un poliedro compacto $\mathcal{S}$ se puede expresar como una combinación lineal convexa de sus puntos extremos $\{x_1, \dots, x_k\}$.

! Maximización en poliedros

Sea $\mathcal{S}$ un conjunto poliedro convexo y compacto no vacío de $\mathbb{R}^n$, y sea $f : \mathcal{S} \to \mathbb{R}$ una función convexa. Si f alcanza su máximo en $\mathcal{S}$, entonces alcanza su máximo en al menos uno de los puntos extremos (vértices) de $\mathcal{S}$.

Funciones convexas

Funciones convexas: definición y secante

Una función $f : \mathcal{S} \to \mathbb{R}$ definida sobre un conjunto convexo $\mathcal{S}$ es **convexa** si la cuerda o secante que une cualesquiera dos puntos de su gráfica se sitúa sobre o por encima de la propia gráfica de la función:

$$f(\lambda x_1 + (1-\lambda)x_2) \leq \lambda f(x_1) + (1-\lambda) f(x_2), \quad \forall x_1, x_2 \in \mathcal{S},\ \forall \lambda \in [0,1]$$

- **Estrictamente convexa**: Si la desigualdad se cumple de forma estricta $(<)$ para todo $\lambda \in (0,1)$ y $x_1 \neq x_2$.
- **Cóncava**: Si $-f$ es convexa.

Ilustración de la convexidad

Visualización gráfica del concepto de secante. El valor de la función en el punto intermedio (curva azul) queda siempre por debajo de la combinación de sus extremos (recta roja):

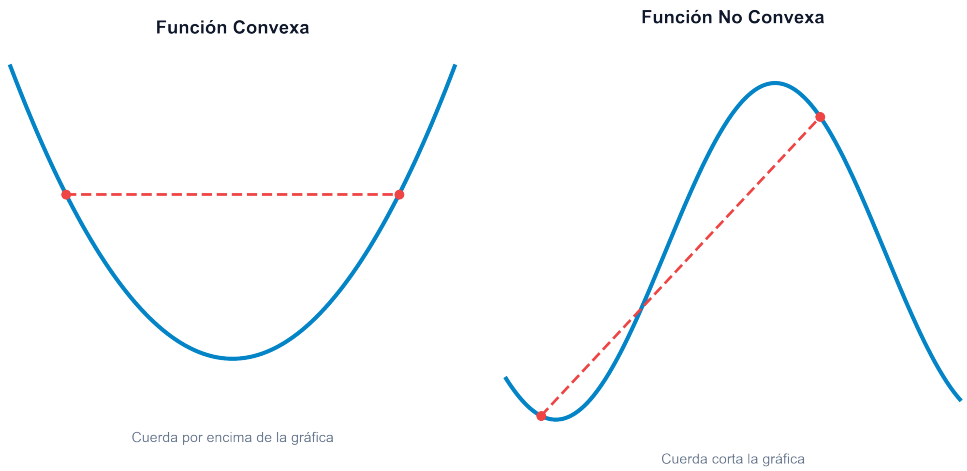

Continuidad de las funciones convexas

Continuidad de las funciones convexas

Sea $f : \mathcal{S} \to \mathbb{R}$ una función convexa, con $\mathcal{S}$ un conjunto convexo no vacío de $\mathbb{R}^n$. Entonces, f es continua en el interior de $\mathcal{S}$ (int $\mathcal{S}$).

- **Discontinuidad en la frontera**: La continuidad se restringe al interior de $\mathcal{S}$. En la frontera, una función convexa puede presentar discontinuidades.
  - *Ejemplo*: Sea $\mathcal{S} = [0, 1]$ y consideremos la función convexa:

$$f(x) = \begin{cases} x^2 & \text{si } x \in (0, 1) \\ 1 & \text{si } x = 0 \text{ o } x = 1 \end{cases}$$

Esta función es convexa en todo el intervalo $\mathcal{S}$, pero es discontinua en los límites frontera $x = 0$ y $x = 1$.

Operaciones que preservan la convexidad

Podemos construir funciones convexas complejas combinando funciones convexas sencillas:

- **Suma ponderada positiva**: Si $f_1, \dots, f_k$ son funciones convexas y $\alpha_1, \dots, \alpha_k \geq 0 \implies \sum_j \alpha_j f_j$ también es una función convexa.
- **Supremo puntual (Máximo)**: Si $f_1, \dots, f_k$ son funciones convexas, la función envoltura superior definida por el máximo puntual $f(x) = \max_j \{f_j(x)\}$ es convexa.
- **Composición afín**: Si $g : \mathbb{R}^m \to \mathbb{R}$ es una función activa y convexa y $h(x) = Ax + b$ es una transformación afín $\implies f(x) = g(Ax + b)$ es convexa.
- **Inversa de una cóncava**: Si $g : \mathbb{R}^n \to \mathbb{R}$ es una función cóncava $\implies f(x) = \frac{1}{g(x)}$ es una función convexa sobre el dominio restringido $\{x \mid g(x) > 0\}$.
- **Composición general (no decreciente)**: Si g es convexa y no decreciente, y h es convexa $\implies f(x) = g(h(x))$ es convexa.

Convexidad de los conjuntos de nivel

Convexidad de los conjuntos de nivel

Sea $f : \mathcal{S} \to \mathbb{R}$ una función convexa sobre un dominio convexo $\mathcal{S}$. Para cualquier constante $\alpha \in \mathbb{R}$, el conjunto de nivel inferior $\mathcal{S}_\alpha = \{x \in \mathcal{S} \mid f(x) \leq \alpha\}$ es un conjunto convexo.

Convexidad de los conjuntos de nivel: gráfica

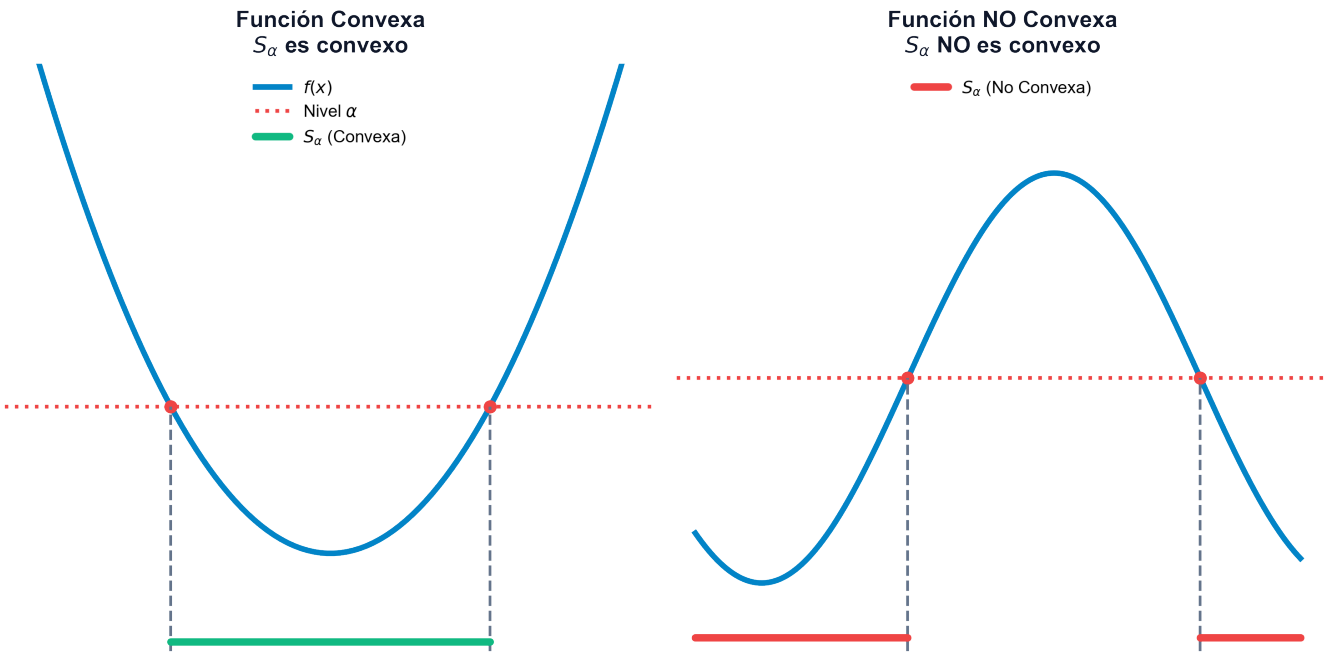

Epigrafo e hipografo

Asocian propiedades analíticas de las funciones con la geometría de conjuntos:

- **Epigrafo (epi f)**: El conjunto de puntos situados sobre o por encima de la gráfica de la función:

$$\text{epi } f = \{(x, y) \in \mathbb{R}^{n+1} \mid x \in \mathcal{S},\ y \geq f(x)\}$$

- **Hipografo (hyp f)**: El conjunto de puntos situados sobre o por debajo de la gráfica:

$$\text{hyp } f = \{(x, y) \in \mathbb{R}^{n+1} \mid x \in \mathcal{S},\ y \leq f(x)\}$$

Relación entre epigrafo y convexidad: gráfica

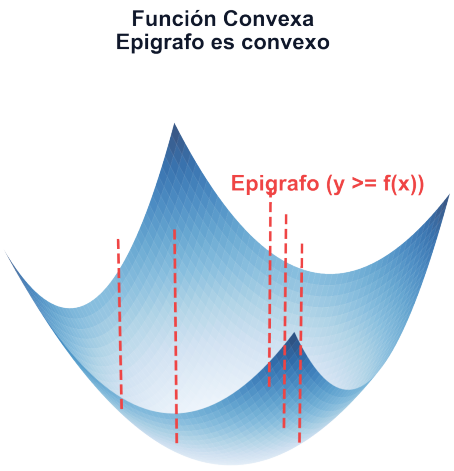

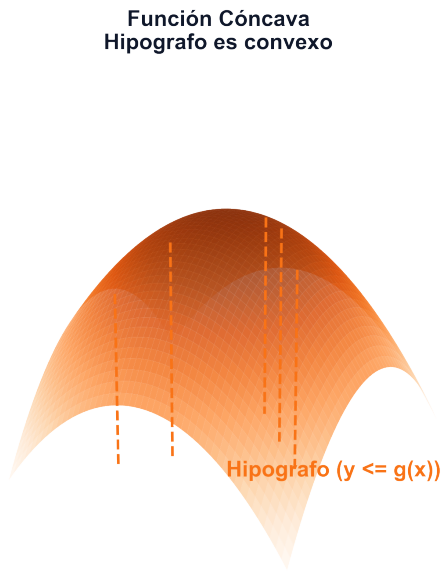

Relación entre epigrafo y convexidad

! Relación entre epigrafo y convexidad

Una función $f : \mathcal{S} \to \mathbb{R}$ es convexa si y solo si su epigrafo epi f es un conjunto convexo en $\mathbb{R}^{n+1}$.

Subgradientes y subdiferenciales

Para funciones no diferenciables (como $f(x) = |x|$), el concepto de gradiente se generaliza mediante subgradientes.

Un vector $\xi \in \mathbb{R}^n$ es un **subgradiente** de f en el punto $x_0 \in \mathcal{S}$ si define un plano de soporte inferior para la función:

$$f(x) \geq f(x_0) + \xi^T (x - x_0), \quad \forall x \in \mathcal{S}$$

- **Subdiferencial ($\partial f(x_0)$)**: El conjunto de todos los subgradientes de f en x_0.
- Si la función es diferenciable en x_0, el subdiferencial contiene un único elemento: el gradiente clásico $\partial f(x_0) = \{\nabla f(x_0)\}$.

Subgradientes: ilustración

Visualización geométrica del subdiferencial. En puntos singulares de no diferenciabilidad (codos), existen múltiples pendientes ξ que sirven de plano de soporte inferior:

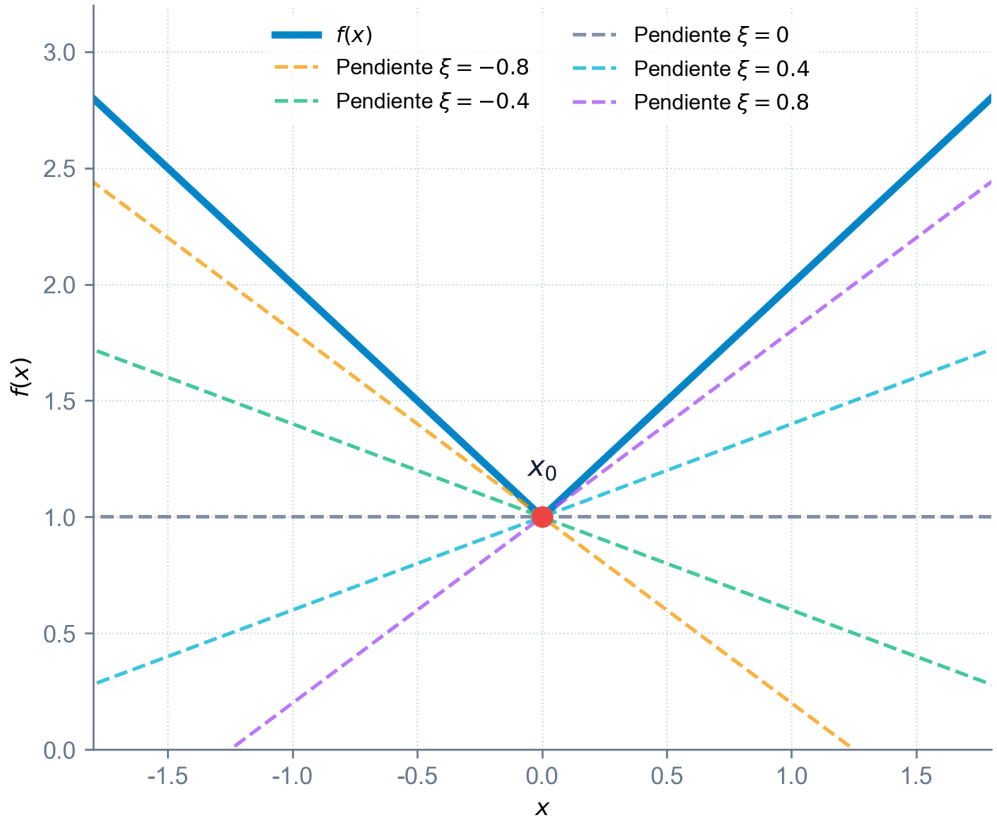

Existencia del subgradiente

El subdiferencial cuenta con soporte teórico de existencia en el interior y de unicidad local:

! Existencia del subgradiente (hiperplano soporte al epigrafo)

Sea $f : \mathcal{S} \to \mathbb{R}$ una función convexa, con $\mathcal{S}$ un conjunto convexo no vacío de $\mathbb{R}^n$. Para cualquier punto interior $x_0 \in \text{int } \mathcal{S}$, existe al menos un subgradiente $\xi \in \mathbb{R}^n$. Esto equivale a decir que el hiperplano $y = f(x_0) + \xi^T(x - x_0)$ es un hiperplano de soporte para el epigrafo de f, epi f, en el punto frontera $(x_0, f(x_0))$.

- **Caso de Convexidad Estricta**: Si $f : \mathcal{S} \to \mathbb{R}$ es estrictamente convexa, entonces para cualquier $x_0 \in \text{int } \mathcal{S}$ y cualquier subgradiente $\xi \in \partial f(x_0)$, se verifica la desigualdad estricta:

$$f(x) > f(x_0) + \xi^T(x - x_0), \quad \forall x \in \mathcal{S},\ x \neq x_0$$

Suficiencia de los subgradientes

La existencia de un vector de soporte inferior en cada punto del dominio es además suficiente para asegurar la convexidad:

! Suficiencia de la caracterización por subgradientes

Sea $\mathcal{S}$ un conjunto convexo abierto no vacío de $\mathbb{R}^n$ y sea $f : \mathcal{S} \to \mathbb{R}$ una función. Si para cada punto $x_0 \in \mathcal{S}$ existe un vector $\xi \in \mathbb{R}^n$ tal que:

$$f(x) \geq f(x_0) + \xi^T (x - x_0), \quad \forall x \in \mathcal{S}$$

entonces la función f es convexa en $\mathcal{S}$.

Reglas del cálculo de subgradientes

El cálculo con subgradientes sigue reglas analíticas análogas al cálculo diferencial estándar:

- **Regla de la Suma**:

$$\partial(f_1(x) + f_2(x)) = \partial f_1(x) \oplus \partial f_2(x)$$

- **Multiplicación Escalar**:

$$\partial(\alpha f(x)) = \alpha \partial f(x), \quad \forall \alpha \geq 0$$

- **Máximo de Funciones**: Si $f(x) = \max\{f_1(x), f_2(x)\}$ con f_1, f_2 convexas:

$$\partial f(x) = \mathcal{H}(\cup_{i \in \mathcal{J}(x)} \partial f_i(x))$$

donde $\mathcal{J}(x) = \{i \mid f_i(x) = f(x)\}$ es el conjunto de índices activos.

Subgradientes: Caso 1D (Función no suave)

- Sea la función convexa definida por tramos del libro:

$$f(x) = \max\{|x|-4,\ (x-2)^2-4\} = \begin{cases} x-4 & \text{si } 1 \le x \le 4 \\ (x-2)^2-4 & \text{en otro caso} \end{cases}$$

- **En puntos diferenciables**:
  - $x_0 = 2 \implies f'(2) = 1 \implies \partial f(2) = \{1\}$ (recta soporte: $y = x - 4$).
  - $x_0 = 5 \implies f'(5) = 6 \implies \partial f(5) = \{6\}$ (recta soporte: $y = 6x - 25$).
- **En puntos singulares o codos**:
  - $x_0 = 1 \implies f'_-(1) = -2,\ f'_+(1) = 1 \implies \partial f(1) = [-2, 1]$.
  - $x_0 = 4 \implies f'_-(4) = 1,\ f'_+(4) = 4 \implies \partial f(4) = [1, 4]$.

Subgradientes: Caso 1D Ilustración

Visualización del subdiferencial de la función anterior en un punto diferenciable (izquierda) frente a los puntos singulares de codo (derecha):

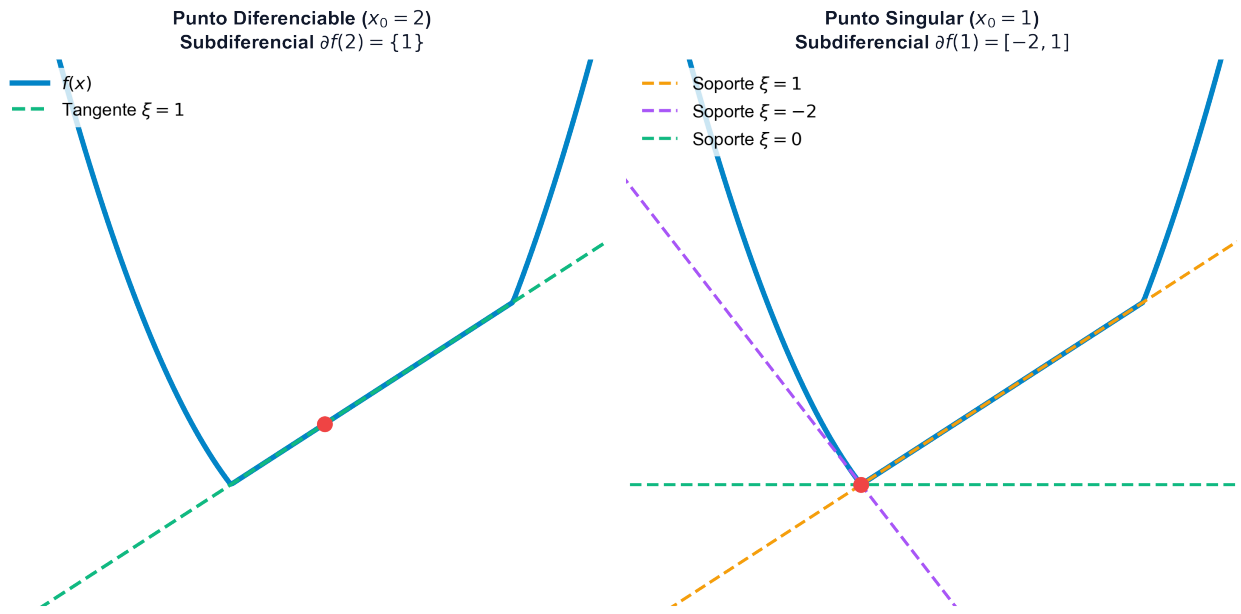

Subgradientes: Caso 2D (Plano soporte)

- Sea la función cuadrática diferenciable del libro:

$$f(x, y) = 8x^2 + 3xy + 7y^2 - 25x + 31y - 29$$

- En el punto de evaluación $\mathbf{x}_0 = (10, 10)^T$:
  - Valor de la función: $f(10, 10) = 1831$.
  - Derivadas parciales: $\frac{\partial f}{\partial x}(10, 10) = 165$ y $\frac{\partial f}{\partial y}(10, 10) = 201$.
- Al ser diferenciable, el subgradiente es único e igual al gradiente:

$$\xi = \nabla f(10, 10) = \begin{pmatrix} 165 \\ 201 \end{pmatrix} \implies \partial f(10, 10) = \left\{ \begin{pmatrix} 165 \\ 201 \end{pmatrix} \right\}$$

- El plano soporte tangente inferior en 3D es:

$$z = 1831 + 165(x - 10) + 201(y - 10)$$

Subgradientes: Caso 2D Ilustración

Plano soporte tangente de soporte inferior en 3D para la función del libro en el punto de tangencia $(10, 10, 1831)$:

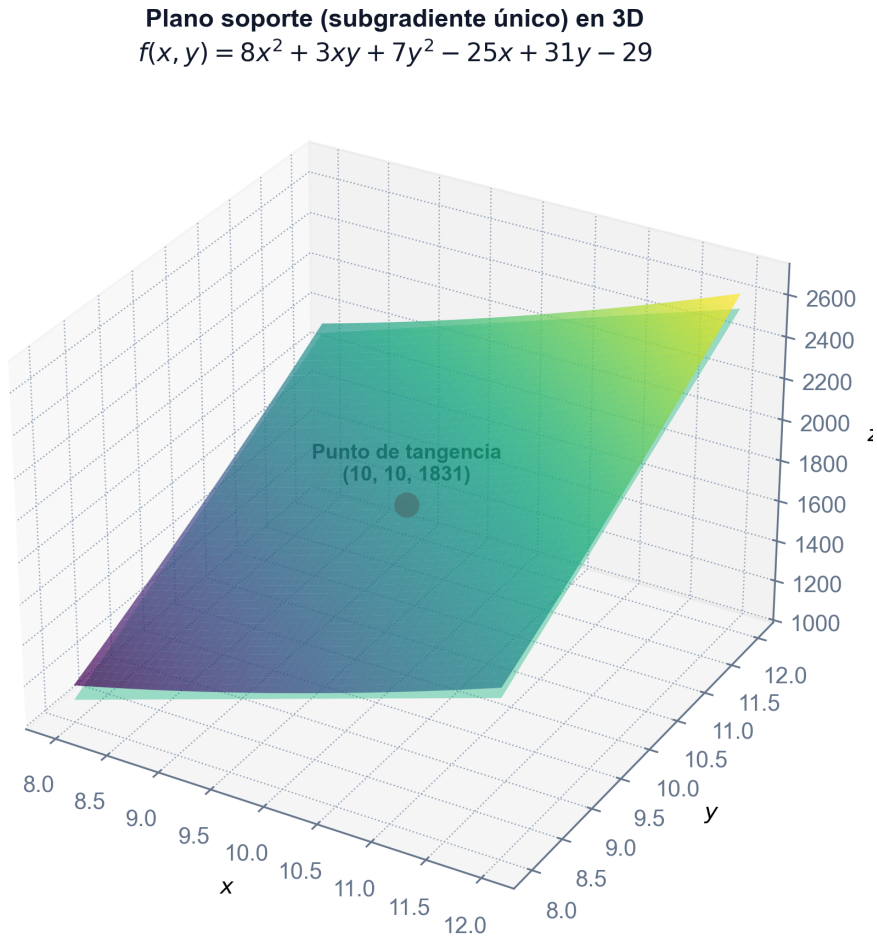

Caracterización diferencial

Caracterización de primer orden

Caracterización de primer orden

Si la función $f : \mathcal{S} \to \mathbb{R}$ es **diferenciable** en un conjunto abierto convexo $\mathcal{S}$:

1. f es **convexa** en $\mathcal{S}$ si y solo si:

$$f(x) \geq f(x_0) + \nabla f(x_0)^T (x - x_0), \quad \forall x, x_0 \in \mathcal{S}$$

2. f es **estrictamente convexa** en $\mathcal{S}$ si y solo si:

$$f(x) > f(x_0) + \nabla f(x_0)^T (x - x_0), \quad \forall x, x_0 \in \mathcal{S},\ x \neq x_0$$

Monotonía del gradiente

Monotonía del gradiente

Una función diferenciable f es convexa en un conjunto convexo abierto $\mathcal{S}$ si y solo si su gradiente es un operador monótono:

$$(\nabla f(x_2) - \nabla f(x_1))^T (x_2 - x_1) \geq 0, \quad \forall x_1, x_2 \in \mathcal{S}$$

Caracterización de segundo orden

Caracterización de segundo orden

Si la función $f : \mathcal{S} \to \mathbb{R}$ es **dos veces diferenciable** ($\mathcal{C}^2$) en un abierto convexo $\mathcal{S}$:

1. f es **convexa** en $\mathcal{S}$ si y solo si su matriz hessiana es semidefinida positiva en todo punto de $\mathcal{S}$:

$$\nabla^2 f(x) \succeq 0, \quad \forall x \in \mathcal{S}$$

2. Si la matriz hessiana es definida positiva en todo el dominio ($\nabla^2 f(x) \succ 0, \forall x \in \mathcal{S}$), entonces f es **estrictamente convexa** en $\mathcal{S}$.

- *Ejemplo de recíproco falso*: $f(x) = x^4$ es estrictamente convexa, pero $f''(0) = 0$ (solo semidefinida positiva).

Curvatura y Hessiana: Ejemplo 1

Estudiar la convexidad de la función cuadrática:

$$f(x_1, x_2, x_3) = x_1x_2 + 2x_1^2 + x_2^2 + 2x_3^2 - 6x_1x_3$$

- **Matriz Hessiana constante**:

$$\nabla^2 f = \begin{pmatrix} 4 & 1 & -6 \\ 1 & 2 & 0 \\ -6 & 0 & 4 \end{pmatrix}$$

- **Menores principales principales (Sylvester)**:
  - $M_1 = 4 > 0$.
  - $M_2 = 4(2) - 1^2 = 7 > 0$.
  - $M_3 = \det(\nabla^2 f) = 4(8) - 1(4) - 6(12) = -20 < 0$.
- Al ser el determinante negativo, la Hessiana es **indefinida**. La función no es ni cóncava ni convexa en $\mathbb{R}^3$.

Curvatura y Hessiana: Ejemplo 2

Estudiar la concavidad de la función:

$$f(x_1, x_2) = 10 - 2(x_2 - x_1^2)^2$$

- **Matriz Hessiana variable**:

$$\nabla^2 f(x) = \begin{pmatrix} 8x_2 - 24x_1^2 & 8x_1 \\ 8x_1 & -4 \end{pmatrix}$$

- Para que sea cóncava se requiere $\nabla^2 f(x) \preceq 0$ (semidefinida negativa):
  - $M_1 = 8x_2 - 24x_1^2 \leq 0$.
  - $M_2 = \det(\nabla^2 f) = 96x_1^2 - 32x_2 \geq 0 \implies x_2 \leq 3x_1^2$.
- Dado que $x_1^2 \leq 3x_1^2$, la condición limitante es $x_2 \leq x_1^2$ (región parabólica no convexa).

Curvatura y Hessiana: Ilustración Ejemplo 2

Visualización en 3D de la cresta parabólica no lineal de la función $f(x_1, x_2) = 10 - 2(x_2 - x_1^2)^2$. Fuera de la parábola $x_2 \leq x_1^2$, la curvatura deja de ser cóncava:

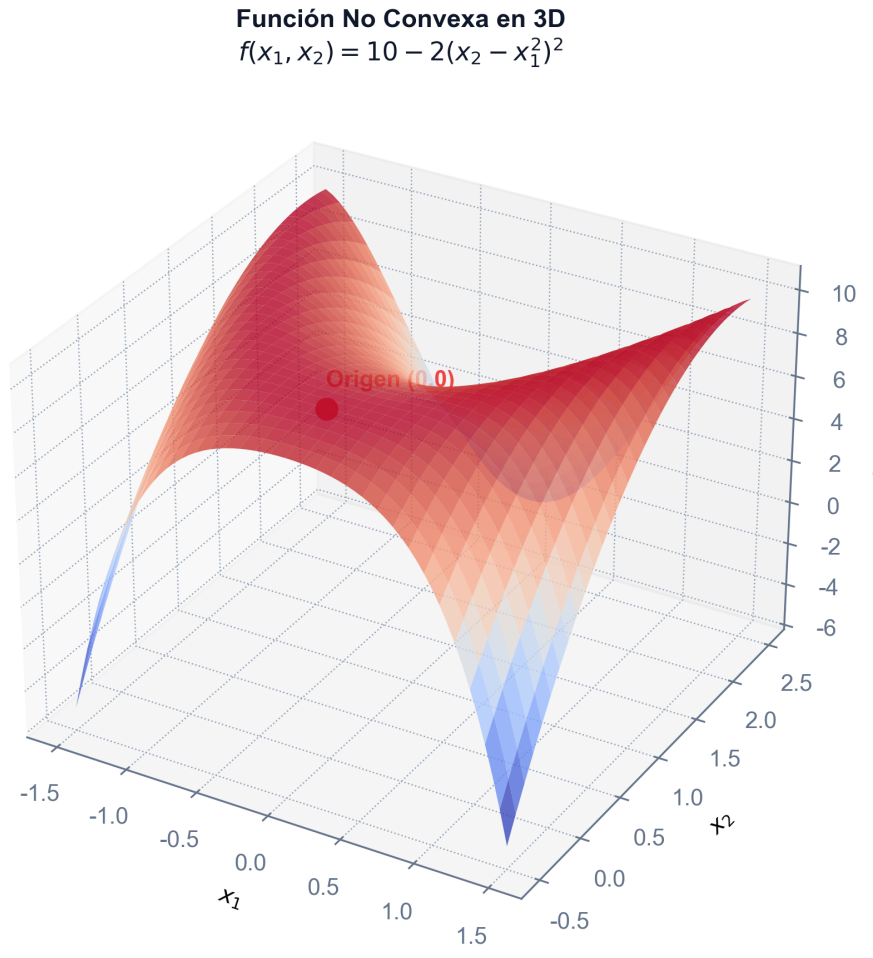

Curvatura y Hessiana: Ejemplo 3

Estudiar la convexidad de la función:

$$f(x, y, z) = x^2 + 3y^2 + z^2 + xy - 4z - 5x + 14$$

- **Matriz Hessiana constante**:

$$\nabla^2 f = \begin{pmatrix} 2 & 1 & 0 \\ 1 & 6 & 0 \\ 0 & 0 & 2 \end{pmatrix}$$

- **Menores principales**:
  - $M_1 = 2 > 0$.
  - $M_2 = 2(6) - 1^2 = 11 > 0$.
  - $M_3 = 2(M_2) = 22 > 0$.
- Al ser todos los menores principales estrictamente positivos, la Hessiana es **definida positiva** ($\nabla^2 f \succ 0$) en todo el dominio. La función es **estrictamente convexa** de forma global.

Óptimos y condiciones de optimalidad

Propiedades fundamentales del óptimo

La convexidad elimina la incertidumbre de la optimización no lineal clásica:

! Fundamental de la optimización convexa

Si $f : \mathcal{S} \to \mathbb{R}$ es una función convexa sobre un conjunto convexo $\mathcal{S}$, entonces cualquier mínimo local de f en $\mathcal{S}$ es también un mínimo global. Si la función f es estrictamente convexa, el mínimo global (si existe) es único.

Caracterización variacional de mínimos

¿Cómo verificar analíticamente si un punto x^* es un mínimo global?

- **Caracterización con subgradientes**: Un punto x^* es mínimo global de la función convexa f en $\mathcal{S}$ si y solo si el vector nulo 0 es un subgradiente de f en x^*:

$$0 \in \partial f(x^*)$$

- **Caracterización variacional diferenciable**: Si la función f es diferenciable en todo su dominio, entonces un punto x^* es un mínimo global en $\mathcal{S}$ si y solo si:

$$\nabla f(x^*)^T(x - x^*) \geq 0, \quad \forall x \in \mathcal{S}$$

Caracterización del conjunto de soluciones óptimas

! Caracterización del conjunto de soluciones óptimas

Sea $f : \mathcal{S} \to \mathbb{R}$ una función convexa y diferenciable sobre el conjunto convexo $\mathcal{S}$. Si existe al menos un mínimo global $x_0 \in \mathcal{S}$, entonces el conjunto de todas las soluciones óptimas $\mathcal{S}^*$ viene caracterizado por:

$$\mathcal{S}^* = \{x \in \mathcal{S} \mid \nabla f(x_0)^T(x - x_0) \geq 0 \quad \text{y} \quad \nabla f(x) = \nabla f(x_0)\}$$

Corolarios de la caracterización de óptimos

Bajo las mismas hipótesis de convexidad y diferenciabilidad y existiendo un mínimo global x_0:

- **Caracterización mediante igualdad**: El conjunto de soluciones óptimas $\mathcal{S}^*$ puede expresarse alternativamente mediante la condición de igualdad del gradiente:

$$\mathcal{S}^* = \{x \in \mathcal{S} \mid \nabla f(x_0)^T (x - x_0) = 0\}$$

- **Caso de funciones cuadráticas en poliedros**: Si $f(x) = c^T x + \frac{1}{2} x^T H x$ y el dominio $\mathcal{S}$ es un poliedro, entonces el conjunto de óptimos $\mathcal{S}^*$ es también un poliedro expresable como:

$$\mathcal{S}^* = \{x \in \mathcal{S} \mid c^T (x - x_0) = 0 \text{ y } H(x - x_0) = \mathbf{0}\}$$

Maximización de funciones convexas

! Condición necesaria para máximos locales de funciones convexas

Sea el problema de maximizar $f(x)$ sujeto a $x \in \mathcal{S}$, donde $f : \mathcal{S} \to \mathbb{R}$ es una función convexa y $\mathcal{S}$ es un conjunto convexo no vacío de $\mathbb{R}^n$. Si $x_0 \in \mathcal{S}$ es un óptimo local para este problema de maximización, entonces:

$$\xi^T(x - x_0) \leq 0, \quad \forall x \in \mathcal{S}$$

donde ξ es cualquier subgradiente de f en x_0 ($\xi \in \partial f(x_0)$).

Maximización: contraejemplo

- **Caso Diferenciable para Máximos Locales**: Si la función convexa f es además diferenciable en todo el dominio $\mathcal{S}$, la condición necesaria para que $x_0 \in \mathcal{S}$ sea un óptimo local del problema de maximización se simplifica a:

$$\nabla f(x_0)^T (x - x_0) \leq 0, \qquad \forall x \in \mathcal{S}$$

- La condición necesaria $\nabla f(x_0)^T (x - x_0) \leq 0$ para funciones convexas es muy débil y **no es suficiente** para garantizar un máximo local.

Maximización: contraejemplo gráfico

- **Contraejemplo**: Sea $f(x) = x^2$ en el dominio acotado $\mathcal{S} = [-1, 2]$.
  - Mínimo global en $x_0 = 0$, con gradiente nulo: $\nabla f(0) = 0$.
  - Se cumple la condición necesaria: $\nabla f(0)^T (x - 0) = 0 \leq 0, \quad \forall x \in \mathcal{S}$
  - Sin embargo, en $x_0 = 0$ la función alcanza su **mínimo global**, no un máximo.
  - El máximo global real está en la frontera derecha $x^* = 2$ con valor $f(2) = 4$.

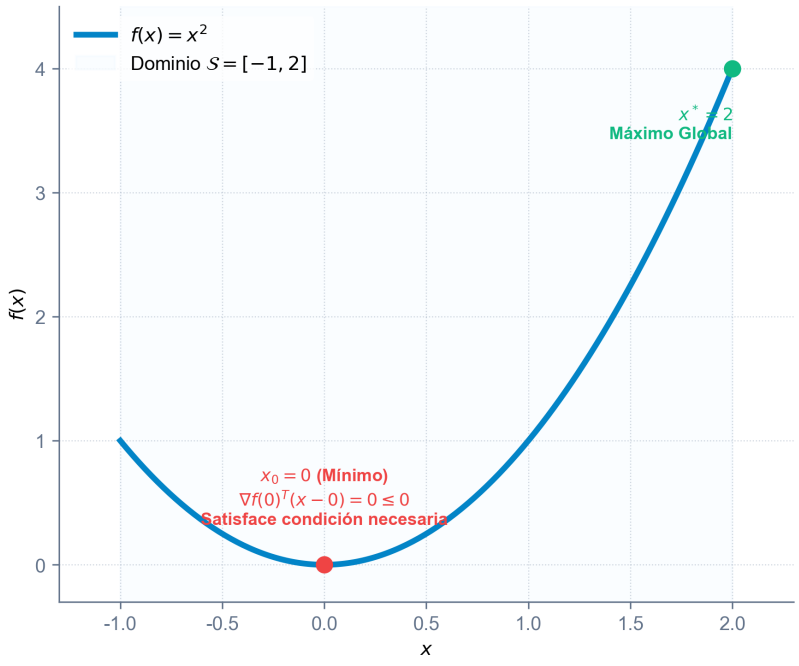

Óptimos: Ejemplo 1 (No diferenciable)

Minimizar la función definida por tramos del libro en $\mathbb{R}$:

$$f(x) = \begin{cases} x - 4 & \text{si } 1 \leq x \leq 4 \\ (x-2)^2 - 4 & \text{en otro caso} \end{cases}$$

- La función tiene un punto de no diferenciabilidad (codo) en $x^* = 1$.
- Calculamos el subdiferencial en dicho codo:
  - Derivada lateral izquierda (parábola): $f'_-(1) = 2(1-2) = -2$.
  - Derivada lateral derecha (recta): $f'_+(1) = 1$.
  - Subdiferencial en el codo: $\partial f(1) = [-2, 1]$.
- Como el cero pertenece al subdiferencial ($0 \in [-2, 1]$), el punto $x^* = 1$ es un **mínimo global** de la función con valor $f(1) = -3$.

Óptimos: Ilustración Ejemplo 1

Gráfica del Ejemplo 1. En el codo singular $x^* = 1$, la presencia del cero en el subdiferencial $[-2, 1]$ permite apoyar una recta de soporte horizontal (pendiente nula):

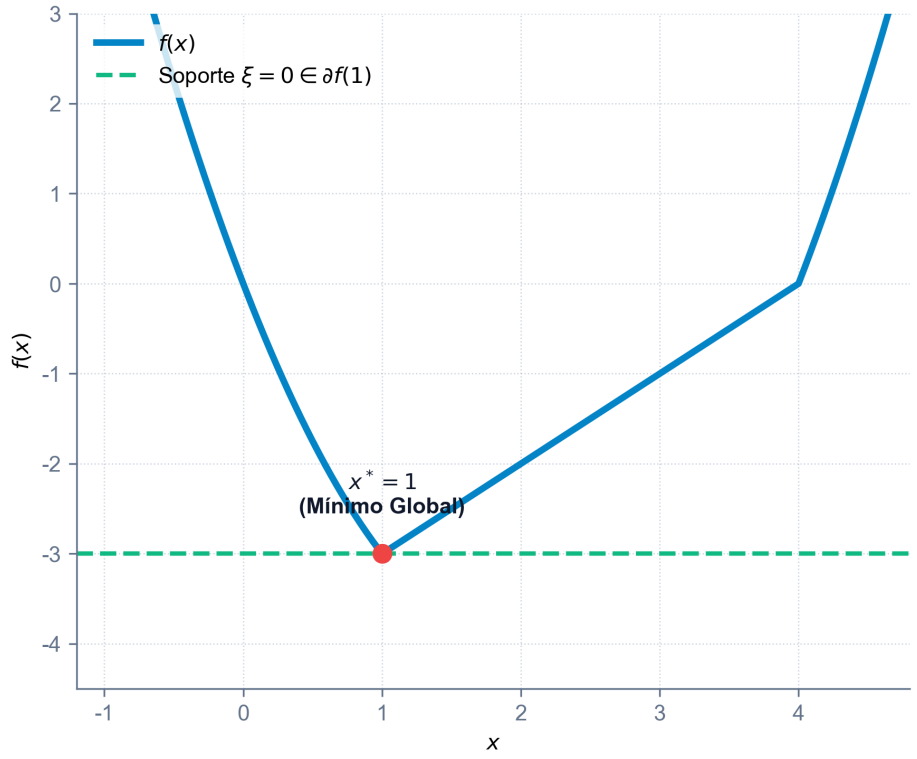

Óptimos: Ejemplo 2 (Dominio restringido 1D)

Minimizar la parábola convexa $f(x) = (x-2)^2 - 4$ sujeta a la restricción de caja $x \in [3, 5]$.

- El mínimo libre global está en $x = 2$, el cual es exterior al conjunto factible $\mathcal{S} = [3, 5]$.
- Evaluamos el punto frontera inferior factible $x^* = 3$:
  - Gradiente clásico en el óptimo de frontera: $\nabla f(3) = 2(3-2) = 2$.
  - El subdiferencial restringido a $\mathcal{S}$ en $x^* = 3$ es $\partial f_{\mathcal{S}}(3) = (-\infty, 2]$.
- Como el cero pertenece a este subdiferencial restringido $(0 \leq 2)$, el punto $x^* = 3$ es el **mínimo global restringido** con valor $f(3) = -3$.

Óptimos: Ilustración Ejemplo 2

La gráfica muestra la parábola en la región factible y cómo todas las pendientes del subdiferencial restringido $\xi \leq 2$ (incluyendo la pendiente nula) actúan como rectas soporte válidas:

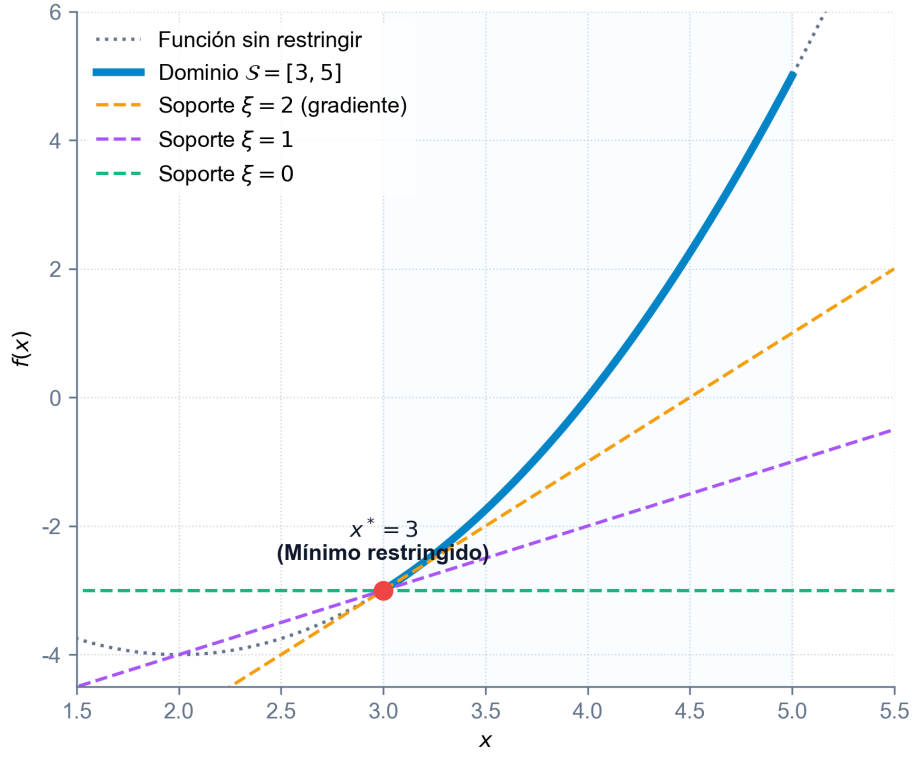

Óptimos: Ejemplo 3 (2D Frontera)

Minimizar la distancia cuadrática a un punto objetivo exterior $(3, 2)^T$:

$$\min_{x_1, x_2} \ (x_1 - 3)^2 + (x_2 - 2)^2$$

Sujeto al dominio convexo:

$$\mathcal{S} = \{\mathbf{x} \in \mathbb{R}^2 \mid x_1^2 + x_2^2 \leq 5, \ x_1 + 2x_2 \leq 4, \ x_1 \geq 0, \ x_2 \geq 0\}$$

- El óptimo analítico se localiza en la intersección de las fronteras activas: $\mathbf{x}^* = (2, 1)^T$.
- El gradiente apunta en dirección contraria al dominio: $\nabla f(x^*) = (-2, -2)^T$.
- La condición exige $\nabla f(x^*)^T(\mathbf{x} - \mathbf{x}^*) \geq 0 \implies -2(x_1 - 2) - 2(x_2 - 1) \geq 0 \iff x_1 + x_2 \leq 3$.

Óptimos: Ilustración Ejemplo 3

El gradiente $\nabla f(x^*)$ en el óptimo de frontera $(2, 1)$ forma un ángulo obtuso con todas las direcciones factibles que apuntan hacia el interior del polígono convexo:

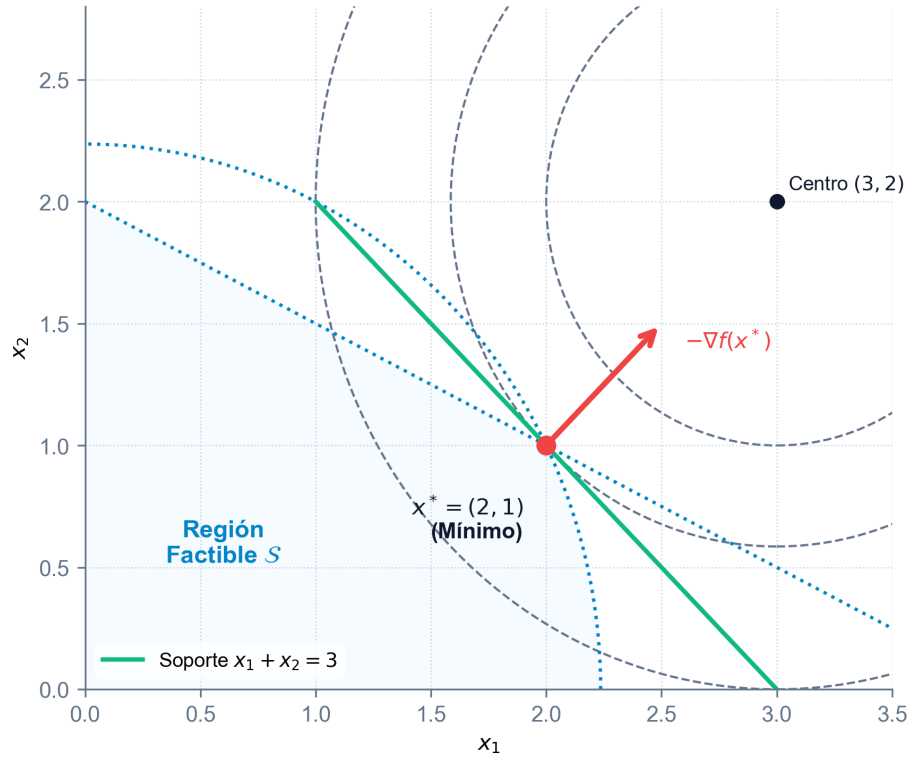

Óptimos: Ejemplo 4 (2D Interior)

Consideremos el mismo dominio convexo del Ejemplo 3, pero buscando el mínimo respecto al punto objetivo $(1,1)^T$, el cual es un punto interior de $\mathcal{S}$:

- Dado que $\mathbf{x}^* = (1,1)^T$ cumple estrictamente las restricciones:
  - $1^2 + 1^2 = 2 < 5$
  - $1 + 2(1) = 3 < 4$
  - $1 > 0,\ 1 > 0$
- El óptimo se sitúa en el interior del conjunto factible, comportándose como un problema libre.
- El gradiente se anula exactamente en el óptimo:

$$\nabla f(\mathbf{x}^*) = \mathbf{0}$$

Óptimos: Ilustración Ejemplo 4

Al situarse el punto de referencia $(1, 1)$ dentro de la región factible, la distancia cuadrática se minimiza de forma exacta con valor cero en dicho punto interior:

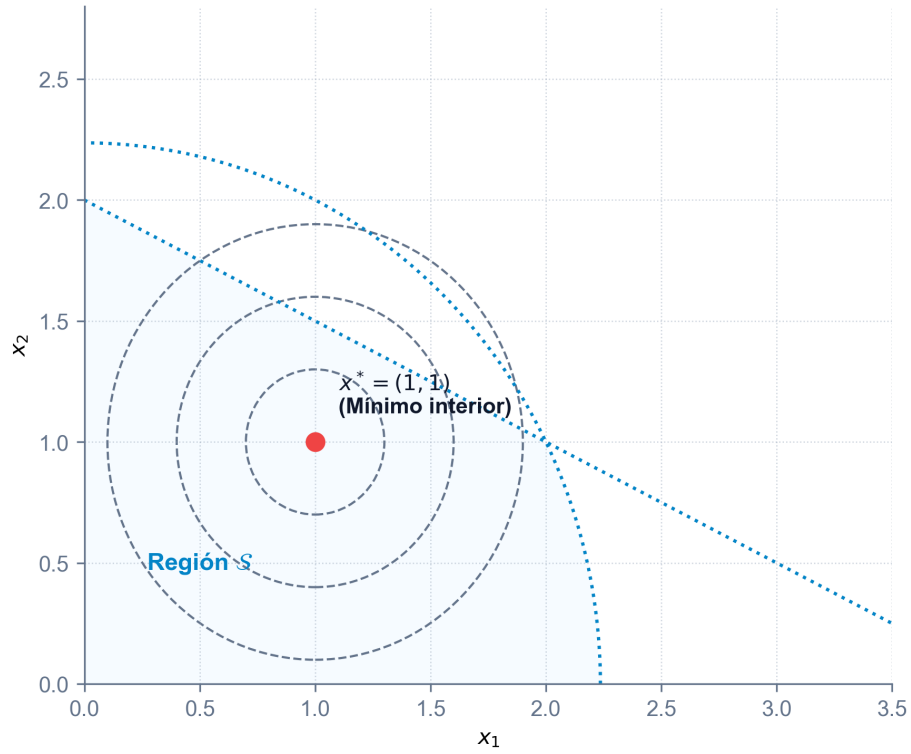

Generalizaciones de la convexidad

Funciones cuasi-convexas: concepto

! Equivalencia por conjuntos de nivel

Sea $f : \mathcal{S} \to \mathbb{R}$, con $\mathcal{S}$ un conjunto convexo no vacío de $\mathbb{R}^n$. La función f es cuasi-convexa si y solo si el conjunto de nivel inferior $\mathcal{S}_\alpha = \{x \in \mathcal{S} \mid f(x) \leq \alpha\}$ es convexo para cualquier número real α.

- **Definición equivalente**:

$$f(\lambda x + (1-\lambda)y) \leq \max(f(x), f(y)), \quad \forall x, y \in \mathcal{S},\ \lambda \in [0,1]$$

Ejemplos de cuasi-convexidad

Ejemplos de funciones cuasi-convexas no convexas. La función $f(x) = x^3$ (izquierda) y la función $f(x) = |x|^{0.5}$ (derecha) poseen conjuntos de nivel convexos (intervalos):

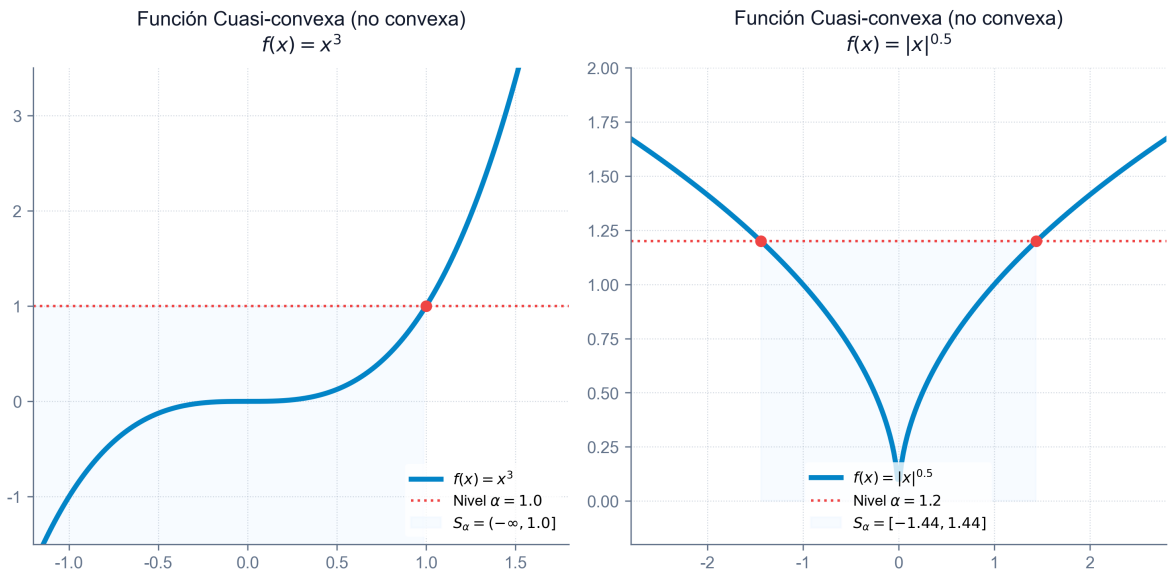

Óptimos locales y globales en cuasi-convexidad

- En funciones cuasi-convexas generales, **un mínimo local no es necesariamente global**.
- Pueden existir "mesetas" o regiones planas que atrapen a los algoritmos en óptimos locales mediocres:

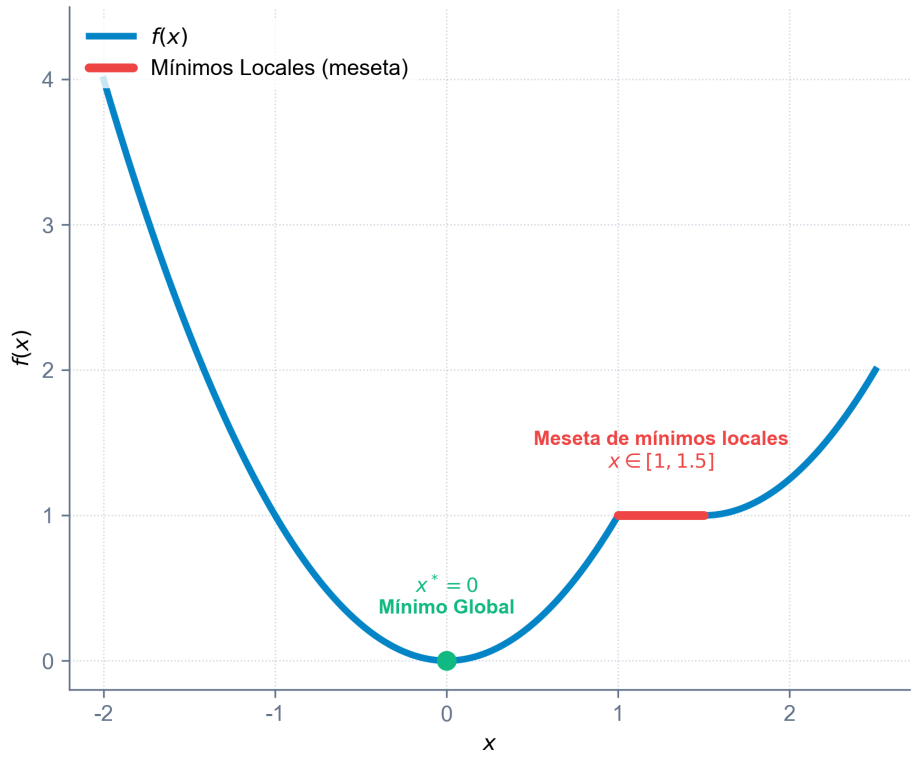

Funciones estrictamente cuasi-convexas

Para eliminar el problema de las mesetas de mínimos locales:

- **Definición**: Una función $f : \mathcal{S} \to \mathbb{R}$ es **estrictamente cuasi-convexa** si para todo $x \neq y$ con $f(x) \neq f(y)$:

$$f(\lambda x + (1-\lambda)y) < \max(f(x), f(y)), \quad \forall \lambda \in (0,1)$$

! Mínimos en funciones estrictamente cuasi-convexas

Si $f : \mathcal{S} \to \mathbb{R}$ es una función estrictamente cuasi-convexa definida en un conjunto convexo $\mathcal{S}$, entonces cualquier mínimo local es también un mínimo global.

- Si $f : \mathcal{S} \to \mathbb{R}$ es estrictamente cuasi-convexa y semicontinua inferiormente, con $\mathcal{S}$ un conjunto convexo no vacío, entonces f es cuasi-convexa.

Estricta cuasi-convexidad: Ilustración

Ejemplo de función estrictamente cuasi-convexa que posee un fondo plano de infinitos mínimos globales en el intervalo $[0, 1]$, demostrando la falta de unicidad:

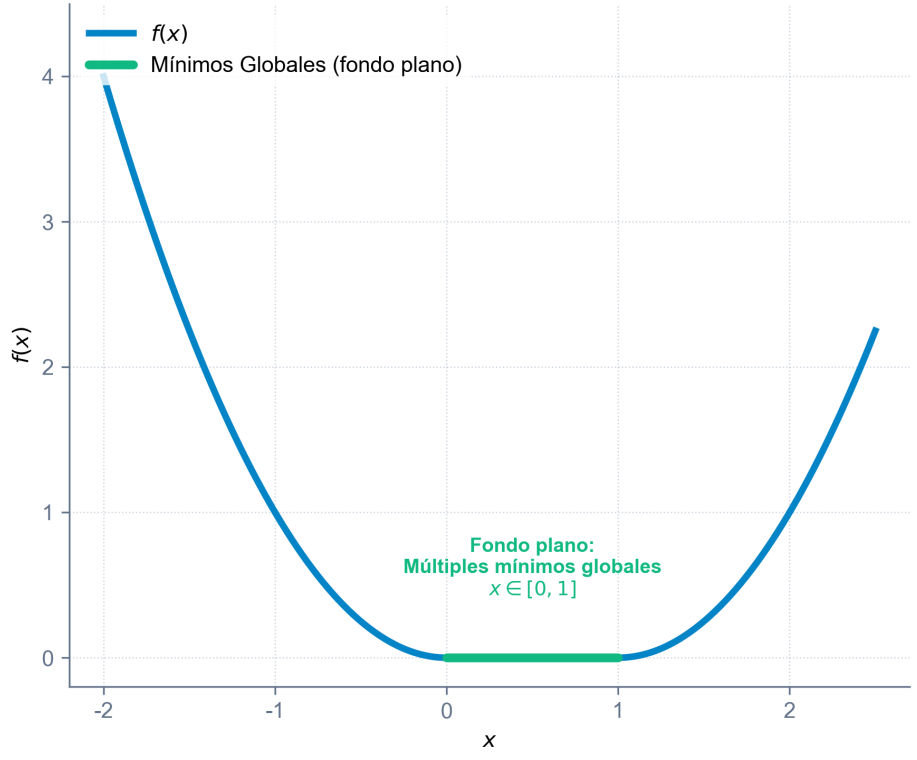

Funciones fuertemente cuasi-convexas

Para asegurar tanto la globalidad del óptimo como su **unicidad**:

- **Definición**: Una función $f : \mathcal{S} \to \mathbb{R}$ es **fuertemente cuasi-convexa** si para todo $x \neq y$:

$$f(\lambda x + (1-\lambda)y) < \max(f(x), f(y)), \quad \forall \lambda \in (0,1)$$

(Incluso si coinciden los valores de los extremos, $f(x) = f(y)$).

! Unicidad del mínimo en funciones fuertemente cuasi-convexas

Sea el problema de minimizar $f(x)$ sujeto a $x \in \mathcal{S}$, donde $f : \mathbb{R}^n \to \mathbb{R}$ es una función fuertemente cuasi-convexa y $\mathcal{S} \subseteq \mathbb{R}^n$ es un conjunto convexo no vacío. Si existe un mínimo local x_0, entonces x_0 es el único mínimo global.

Funciones pseudo-convexas

Se definen únicamente para funciones **diferenciables**. Representan la generalización más fuerte, garantizando que el óptimo se caracteriza por la anulación del gradiente.

- **Definición**: Una función diferenciable f es **pseudo-convexa** si:

$$\nabla f(y)^T(x-y) \geq 0 \implies f(x) \geq f(y)$$

- **Consecuencia**: Si el gradiente es nulo en un punto ($\nabla f(y) = \mathbf{0}$), entonces $\nabla f(y)^T(x-y) = 0 \geq 0$, lo que implica $f(x) \geq f(y)$ para todo x, demostrando que y es un **mínimo global**.

Relaciones entre las generalizaciones

Existen implicaciones lógicas estrictas entre estas clases de funciones:

! Relación entre pseudo-convexidad y cuasi-convexidad estricta

Sea $f : \mathcal{S} \to \mathbb{R}$ una función diferenciable en un conjunto convexo abierto no vacío $\mathcal{S}$. Si f es pseudo-convexa en $\mathcal{S}$, entonces es estrictamente cuasi-convexa.

! Relación entre pseudo-convexidad estricta y cuasi-convexidad fuerte

Sea $f : \mathcal{S} \to \mathbb{R}$ una función diferenciable en un conjunto convexo abierto no vacío $\mathcal{S}$. Si f es estrictamente pseudo-convexa en $\mathcal{S}$, entonces es fuertemente cuasi-convexa.

Jerarquía de generalizaciones de la convexidad

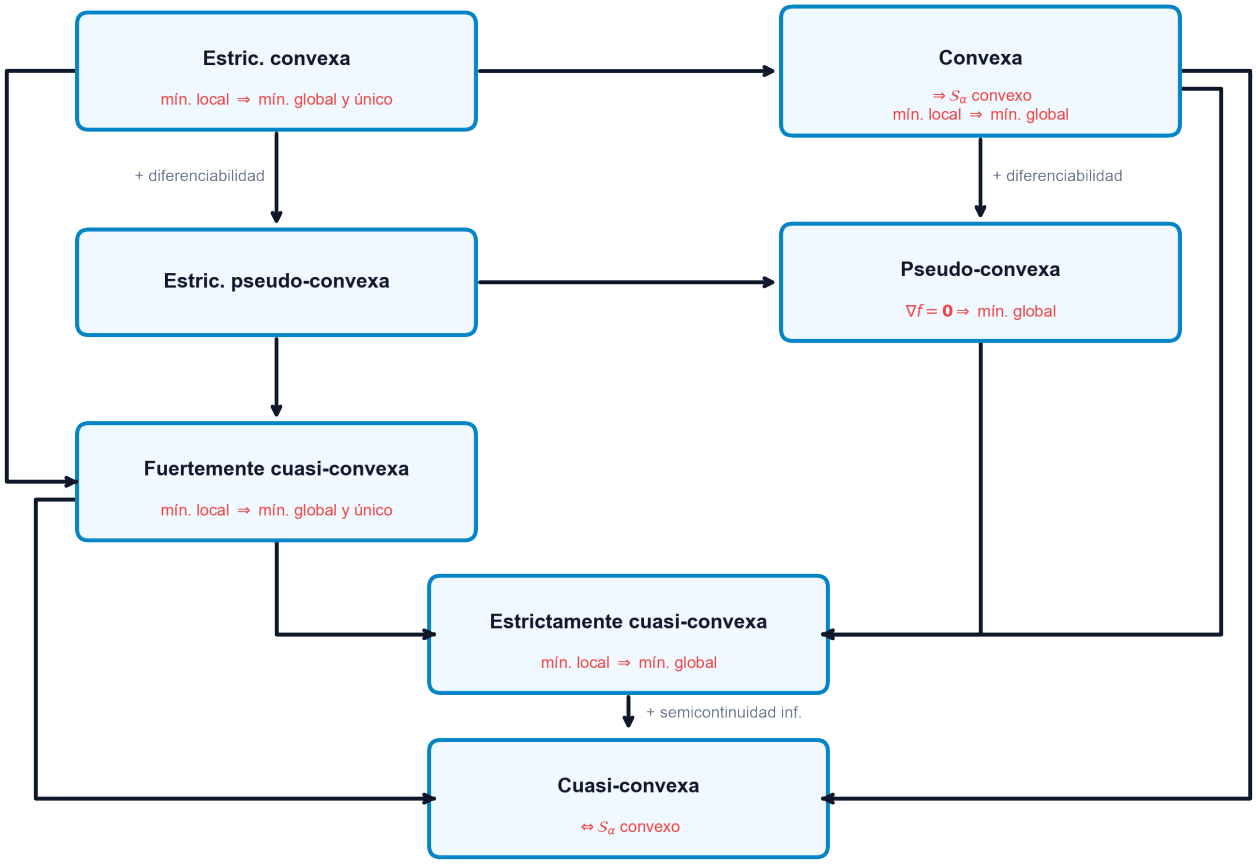

Teorema de equivalencia cuadrática

! Equivalencia cuadrática

Si la función $f : \mathcal{S} \to \mathbb{R}$ es una función cuadrática diferenciable en un conjunto convexo abierto $\mathcal{S}$, entonces las siguientes generalizaciones de la convexidad son lógicamente equivalentes:

1. f es pseudo-convexa si y solo si es estrictamente cuasi-convexa.
2. f es cuasi-convexa si y solo si es estrictamente cuasi-convexa.
3. f es estrictamente pseudo-convexa si y solo si es fuertemente cuasi-convexa.

Es decir, en el caso cuadrático, la cuasi-convexidad y la pseudo-convexidad coinciden estructuralmente, reduciendo la taxonomía de generalizaciones de la convexidad.

Ejemplos Visuales: Curvas de nivel 3D (1)

- **Función cuasi-convexa**:

$$f(x,y) = ((x-2)^2+(y-2)^2)^{0.25}$$

- Superficie tridimensional que no tiene curvatura convexa en sentido estricto.
- **Curvas de nivel**: Sus conjuntos de nivel inferior proyectados en el plano inferior son discos circulares **convexos**.

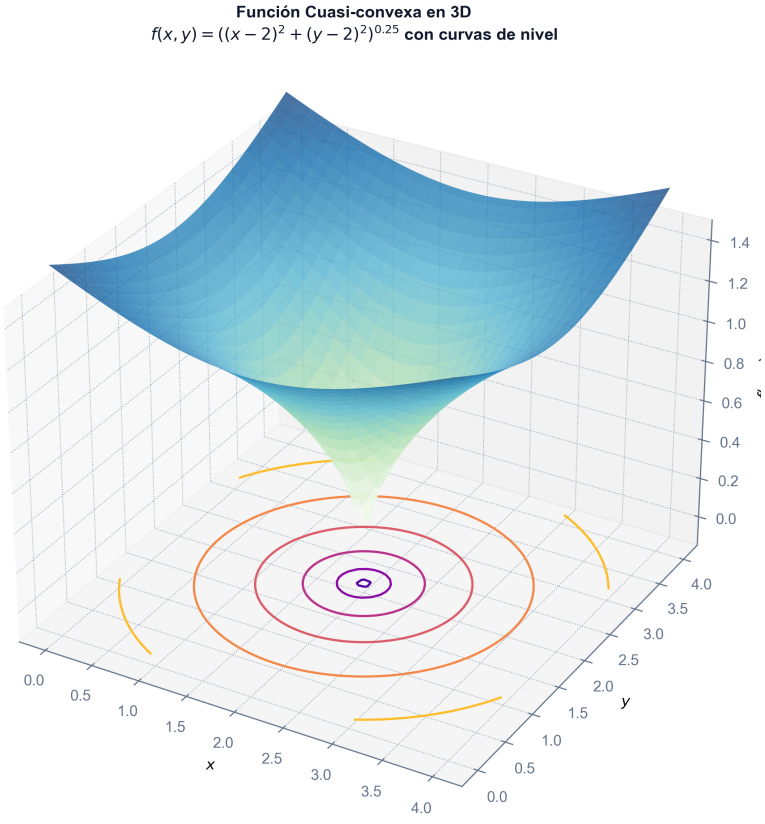

Ejemplos Visuales: Curvas de nivel 3D (2)

- **Función no cuasi-convexa**:

$$f(x, y) = 2x^3 + xy + y^3 - x + y$$

- La superficie muestra una curvatura irregular que no se asemeja a un cuenco.
- **Curvas de nivel**: Sus conjuntos de nivel inferior proyectados no son convexos (tienen forma de herraduras o pliegues).

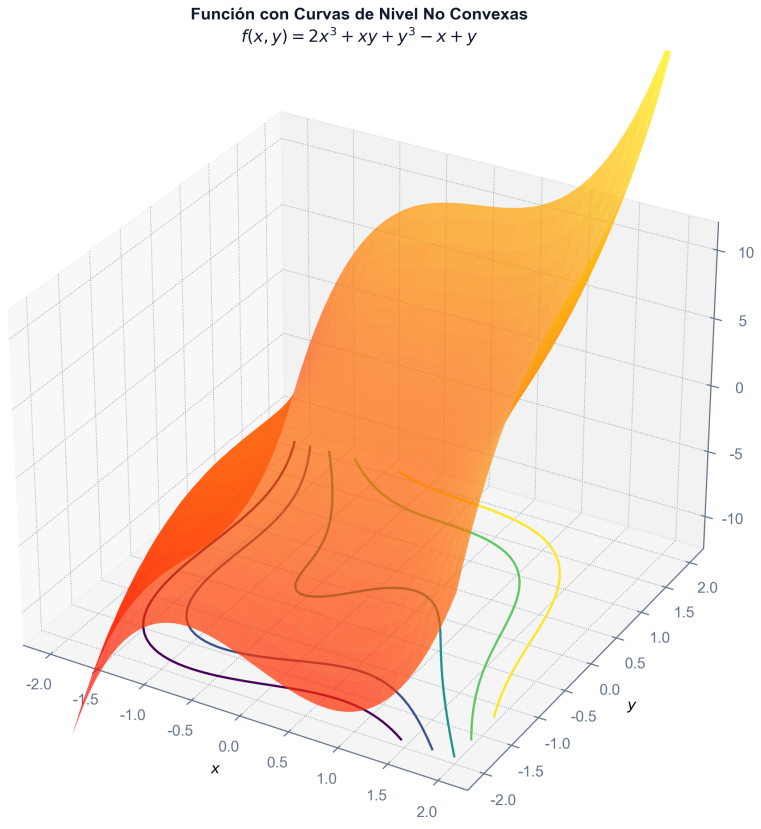

Convexidad puntual

Convexidad puntual (1)

La convexidad también puede estudiarse de forma localizada respecto a un determinado punto de interés $x_0 \in \mathcal{S}$ en un conjunto convexo no vacío $\mathcal{S}$:

1. **Convexa en** x_0:

   $$f(\lambda x_0+(1-\lambda)x) \leq \lambda f(x_0)+(1-\lambda)f(x), \quad \forall \lambda \in (0,1),\ \forall x \in \mathcal{S}$$

2. **Estrictamente convexa en** x_0:

   $$f(\lambda x_0+(1-\lambda)x) < \lambda f(x_0)+(1-\lambda)f(x), \quad \forall \lambda \in (0,1),\ \forall x \in \mathcal{S},\ x$$

3. **Cuasi-convexa en** x_0:

   $$f(\lambda x_0+(1-\lambda)x) \leq \max\{f(x_0), f(x)\}, \quad \forall \lambda \in (0,1),\ \forall x \in \mathcal{S}$$

Convexidad puntual (2)

4. **Estrictamente cuasi-convexa en** x_0:

   $f(\lambda x_0+(1-\lambda)x) < \max\{f(x_0), f(x)\}, \quad \forall \lambda \in (0,1),\ \forall x \in \mathcal{S}$ con

5. **Fuertemente cuasi-convexa en** x_0:

   $f(\lambda x_0+(1-\lambda)x) < \max\{f(x_0), f(x)\}, \quad \forall \lambda \in (0,1),\ \forall x \in \mathcal{S},\ x \neq$

6. **Pseudo-convexa en** x_0: (si f es diferenciable en x_0)

   $$\nabla f(x_0)^T(x - x_0) \geq 0 \implies f(x) \geq f(x_0), \quad \forall x \in \mathcal{S}$$

7. **Estrictamente pseudo-convexa en** x_0: (si f es diferenciable en x_0)

   $\nabla f(x_0)^T(x-x_0) \geq 0 \implies f(x) > f(x_0), \quad \forall x \in \mathcal{S},\ x \neq x_0$

Tema 4: condiciones de optimalidad y KKT

Optimización y Análisis de Redes

Víctor Aceña Gil - Antonio Alonso Ayuso

2026-07-14

Objetivos de aprendizaje

Al finalizar este capítulo, serás capaz de:

1. **Diferenciar** las condiciones necesarias y suficientes de primer y segundo orden (FONC, SONC y SOSC) para optimización sin restricciones.
2. **Caracterizar geométricamente** las direcciones de descenso y factibles a través de conos de direcciones algebraicos.
3. **Analizar las condiciones de Fritz-John**, interpretando su significado geométrico y su sensibilidad ante restricciones redundantes.
4. **Deducir y aplicar las condiciones de Karush-Kuhn-Tucker (KKT)** como fundamento analítico de la optimización restringida.
5. **Resolver analíticamente** problemas con restricciones de igualdad y desigualdad por medio de la cualificación de restricciones (LICQ) y el análisis sistemático por casos.

Optimización sin restricciones

¿Por qué estudiar problemas sin restricciones?

- **Base diferencial**: Los conceptos de aproximación local, gradiente, Hessiana y curvatura se extienden directamente al caso restringido.
- **Algoritmos indirectos**: Muchos métodos numéricos resuelven problemas con restricciones mediante una secuencia de subproblemas sin restricciones (ej. penalización, barrera).
- **Comportamiento local**: Permite comprender cómo se comporta una función localmente basándonos únicamente en la información de sus derivadas.

¿Qué es una dirección de descenso?

Una dirección $d \in \mathbb{R}^n$ es de **descenso** en $\bar{x}$ si existe un paso $\delta > 0$ tal que la función disminuye estrictamente:

$$f(\bar{x} + \lambda d) < f(\bar{x}), \quad \forall \lambda \in (0, \delta)$$

Propiedad diferencial:

- Si f es diferenciable en $\bar{x}$ y existe d tal que $\nabla f(\bar{x})^T d < 0$, entonces d es una dirección de descenso.
- El producto escalar negativo indica que el ángulo entre el gradiente $\nabla f(\bar{x})$ y la dirección d es obtuso.
- **Cono de direcciones de descenso**:

$$\mathcal{D}_0(\bar{x}) = \{d \in \mathbb{R}^n \mid \nabla f(\bar{x})^T d < 0\}$$

Condiciones de optimalidad sin restricciones (FONC y SONC)

Caracterización diferencial de extremos locales sin restricciones:

- **Condición necesaria de primer orden (FONC)**: Si $\bar{x}$ es un mínimo local de f (diferenciable en $\bar{x}$), entonces el gradiente se anula:

$$\nabla f(\bar{x}) = 0$$

*(El punto $\bar{x}$ es un **punto crítico** o estacionario, lo que vacía el cono de descenso: $\mathcal{D}_0(\bar{x}) = \emptyset$).*

- **Condición necesaria de segundo orden (SONC)**: Si $\bar{x}$ es un mínimo local de f (dos veces diferenciable en $\bar{x}$), entonces la matriz Hessiana es semidefinida positiva:

$$\nabla^2 f(\bar{x}) \succeq 0$$

Condiciones suficientes de segundo orden (SOSC)

! Condición Suficiente de Segundo Orden (SOSC)

Sea f dos veces diferenciable en un punto crítico $\bar{x}$ (donde $\nabla f(\bar{x}) = 0$).

- Si $\nabla^2 f(\bar{x}) \succ 0$ (definida positiva), entonces $\bar{x}$ es un **mínimo local estricto**.
- Si $\nabla^2 f(\bar{x}) \prec 0$ (definida negativa), entonces $\bar{x}$ es un **máximo local estricto**.
- Si $\nabla^2 f(\bar{x})$ es indefinida (autovalores positivos y negativos), entonces $\bar{x}$ es un **punto de silla**.

Si es únicamente semidefinida, la condición de segundo orden no es suficiente y existe ambigüedad.

Suficiencia de optimalidad global

Las condiciones SOSC son locales. Para certificar optimalidad global (garantizar que no existe ningún otro punto mejor en todo el dominio), necesitamos imponer convexidad:

! Suficiencia de Optimalidad bajo Pseudo-convexidad

Sea $f : \mathcal{S} \to \mathbb{R}$ una función pseudo-convexa definida sobre un conjunto convexo $\mathcal{S}$.
Un punto $\bar{x} \in \mathcal{S}$ es un **mínimo global** de f si y solo si es un punto estacionario:

$$\nabla f(\bar{x}) = 0$$

Derivadas de orden superior (una variable)

! Extremos univariantes de orden superior

Sea $f : \mathbb{R} \to \mathbb{R}$ una función infinitamente diferenciable en un punto crítico $\bar{x}$. Supongamos que la primera derivada no nula en $\bar{x}$ es de orden $n \geq 2$, es decir, $f^{(j)}(\bar{x}) = 0$ para todo $j = 1, \ldots, n-1$, y $f^{(n)}(\bar{x}) \neq 0$:

1. Si n es **impar**, entonces $\bar{x}$ es un **punto de inflexión** (no es un extremo local).
2. Si n es **par**:
   - Si $f^{(n)}(\bar{x}) > 0$, entonces $\bar{x}$ es un **mínimo local estricto**.
   - Si $f^{(n)}(\bar{x}) < 0$, entonces $\bar{x}$ es un **máximo local estricto**.

Derivadas de orden superior: ejemplo

Consideremos la función $f(x) = (x^2 - 1)^3$. Puntos críticos en $x^* \in \{0, 1, -1\}$:

- **En** $x^* = 0$:
  - $f''(0) = 6 > 0 \implies$ mínimo local por SOSC.
- **En** $x^* = \pm 1$:
  - $f''(\pm 1) = 0 \implies$ orden superior.
  - $f'''(\pm 1) = \pm 48 \neq 0 \implies$ primera derivada no nula es **impar** $(n = 3)$.
  - Son **puntos de inflexión**.

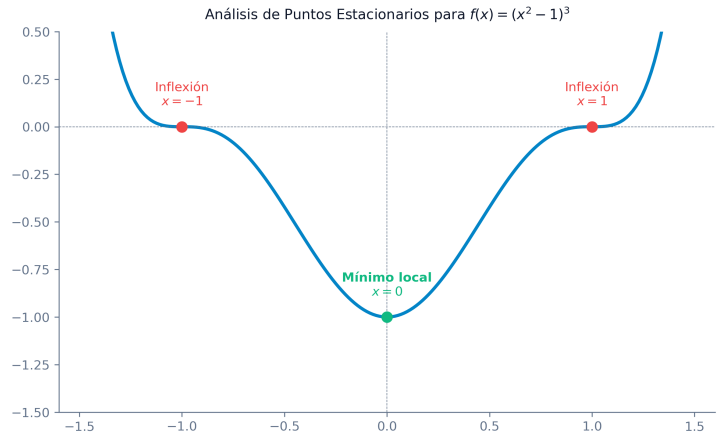

Optimización con restricciones

Introducción a la optimización con restricciones

En la práctica, la optimización matemática adquiere su verdadera complejidad al introducir restricciones sobre las variables de decisión.

Dos marcos de análisis:

1. **Marco general geométrico**: Conjunto factible $\mathcal{S} \subseteq \mathbb{R}^n$ genérico:
$$\min\{f(x) \mid x \in \mathcal{S}\}$$
2. **Problema con restricciones explícitas**: Definidas mediante desigualdades:
$$\min\{f(x) \mid x \in \mathcal{X},\ g_i(x) \leq 0,\ i = 1, \dots, m\}$$
donde el dominio de partida $\mathcal{X}$ es un abierto no vacío de $\mathbb{R}^n$, y tanto f como g_i son diferenciables.

Análisis local en la frontera

Para caracterizar si un punto frontera $\bar{x} \in \mathcal{S}$ es un mínimo local, analizamos movimientos infinitesimales a partir de él.

Requisitos del movimiento infinitesimal:

1. **Factibilidad**: Permanecer dentro de la región factible $\mathcal{S}$ para un paso suficientemente pequeño.
2. **Descenso**: Disminuir estrictamente el valor de la función objetivo $f(x)$.

- Ambas condiciones se formalizan geométricamente a través de los **conos de direcciones** (factibles y de descenso).

Conos de direcciones: factibilidad y descenso

Caracterización geométrica de los movimientos infinitesimales admisibles en $\bar{x} \in \mathcal{S}$:

- **Cono de Direcciones Factibles ($\mathcal{F}(\bar{x})$)**: Direcciones a lo largo de las cuales un paso infinitesimal no abandona la región factible:

$$\mathcal{F}(\bar{x}) = \{d \in \mathbb{R}^n \mid d \neq 0,\ \exists \delta_d > 0 \text{ t.q. } \bar{x}+\lambda d \in \mathcal{S},\ \forall \lambda \in (0, \delta_d)\}$$

- **Cono de Direcciones de Mejora/Descenso ($\mathcal{D}(\bar{x})$)**: Direcciones a lo largo de las cuales el valor de la función objetivo disminuye localmente:

$$\mathcal{D}(\bar{x}) = \{d \in \mathbb{R}^n \mid d \neq 0,\ \exists \delta_d > 0 \text{ t.q. } f(\bar{x}+\lambda d) < f(\bar{x}),\ \forall \lambda \in (0,$$

- **Condición necesaria geométrica de optimalidad**:

$$\bar{x} \text{ es mínimo local } \implies \mathcal{F}(\bar{x}) \cap \mathcal{D}(\bar{x}) = \emptyset$$

El cono de descenso analítico

Si f es diferenciable, aproximamos el cono de descenso real $\mathcal{D}(\bar{x})$ localmente:

- **Definición**: El cono analítico $\mathcal{D}_0(\bar{x})$ son las direcciones con ángulo obtuso respecto al gradiente:

$$\mathcal{D}_0(\bar{x}) = \{d \in \mathbb{R}^n \mid \nabla f(\bar{x})^T d < 0\}$$

- **Inclusión**: Se cumple que $\mathcal{D}_0(\bar{x}) \subseteq \mathcal{D}(\bar{x})$.
- **Significado geométrico**: Cualquier dirección $d \in \mathcal{D}_0(\bar{x})$ garantiza el descenso local de la función en $\bar{x}$.

Exclusión de Direcciones de Descenso y Factibilidad

! Exclusión de Direcciones de Descenso y Factibilidad

Si $\bar{x} \in \mathcal{S}$ es un mínimo local de una función diferenciable f, entonces el cono factible y el semiespacio de descenso analítico son disjuntos:

$$\mathcal{D}_0(\bar{x}) \cap \mathcal{F}(\bar{x}) = \emptyset$$

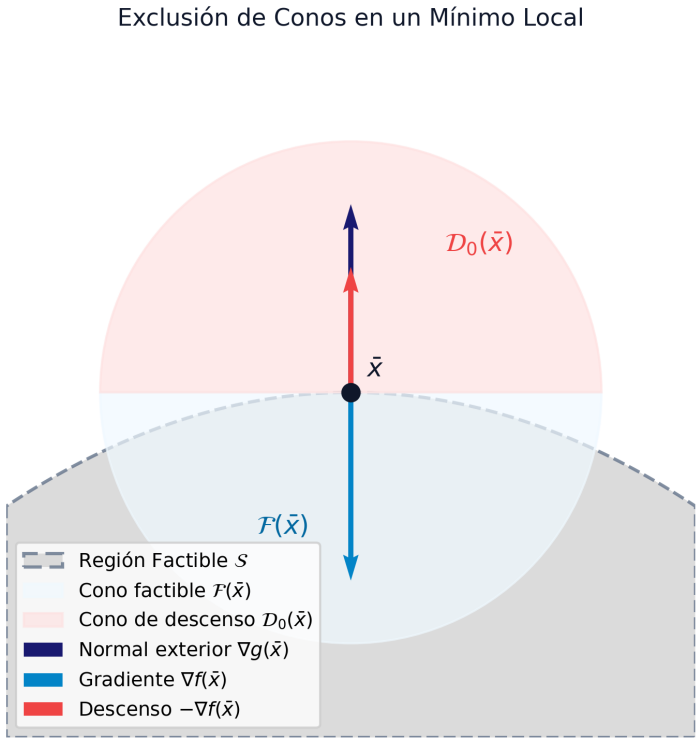

Suficiencia geométrica bajo Pseudo-convexidad

La condición de exclusión $\mathcal{D}_0(\bar{x}) \cap \mathcal{F}(\bar{x}) = \emptyset$ es necesaria. Bajo propiedades de convexidad, se convierte también en suficiente:

! Suficiencia geométrica bajo Pseudo-convexidad

Sea el problema de optimización $\min\{f(x) \mid x \in \mathcal{S}\}$, con f diferenciable y pseudo-convexa en $\bar{x} \in \mathcal{S}$. Si:

1. Se cumple la condición de exclusión geométrica: $\mathcal{D}_0(\bar{x}) \cap \mathcal{F}(\bar{x}) = \emptyset$.
2. Existe un entorno $N_\epsilon(\bar{x})$ de radio $\epsilon > 0$ tal que el vector $d = (x - \bar{x}) \in \mathcal{F}(\bar{x})$ para cualquier $x \in \mathcal{S} \cap N_\epsilon(\bar{x})$.

Entonces, $\bar{x}$ es un **mínimo local** de f.

Limitación del Cono de Direcciones Factibles

Limitación del Cono Factible Geométrico

El cono de direcciones factibles $\mathcal{F}(\bar{x})$ se define de forma puramente geométrica y depende del comportamiento infinitesimal de la frontera del conjunto $\mathcal{S}$.

- Determinar analíticamente si una dirección $d \in \mathcal{F}(\bar{x})$ requiere analizar la existencia de un paso $\delta > 0$ tal que $\bar{x} + \lambda d \in \mathcal{S}$ para todo $\lambda \in (0, \delta)$.
- Esta verificación es extremadamente compleja en la práctica para restricciones no lineales.

Solución: Si el conjunto factible está definido por restricciones analíticas de desigualdad diferenciables, aproximamos localmente el cono factible mediante el **cono de restricciones activas** $\mathcal{G}_0(\bar{x})$, el cual se calcula algebraicamente.

Restricciones de desigualdad y cono de restricciones activas

Restricciones de desigualdad y conjunto activo

La región factible $\mathcal{S}$ se define explícitamente mediante una serie de desigualdades analíticas:

$$\mathcal{S} = \{x \in \mathcal{X} \mid g_i(x) \leq 0,\ i = 1, \ldots, m\}$$

- **Región factible y dominio**: El dominio de partida $\mathcal{X} \subseteq \mathbb{R}^n$ es un abierto no vacío, y tanto f como las restricciones g_i son funciones diferenciables.
- **Restricciones inactivas**: Si $g_i(\bar{x}) < 0$, la restricción está **inactiva** y no limita localmente los movimientos admisibles en un entorno lo suficientemente pequeño de $\bar{x}$.
- **Conjunto activo**: El **conjunto activo** $\mathcal{I}$ está formado por los índices de las restricciones que se cumplen estrictamente como igualdad en $\bar{x}$:

$$\mathcal{I} = \{i \in \{1, \ldots, m\} \mid g_i(\bar{x}) = 0\}$$

Gradientes y movimiento admisible

Para analizar qué movimientos infinitesimales nos mantienen dentro de la región factible, estudiamos la geometría de las restricciones activas en $\bar{x}$:

- **Gradiente como dirección de crecimiento**: Si g_i $(i \in \mathcal{I})$ es diferenciable, el gradiente $\nabla g_i(\bar{x})$ señala la dirección de máximo crecimiento local de la restricción.
- **Orientación hacia el exterior**: Dado que las restricciones son de tipo "menor o igual que" $(g_i(x) \leq 0)$, el gradiente $\nabla g_i(\bar{x})$ apunta estrictamente hacia el exterior de la región factible $\mathcal{S}$.
- **Movimiento hacia el interior**: Si una dirección $d \in \mathbb{R}^n$ forma un ángulo obtuso con el gradiente de una restricción activa:

$$\nabla g_i(\bar{x})^T d < 0$$

entonces nos moveremos localmente hacia el interior factible de dicha restricción.

Ejemplo: Identificación – Planteamiento

Consideremos el siguiente problema bidimensional con restricciones lineales y circulares:

$$\begin{aligned} \min \quad & f(x_1, x_2) = (x_1 - 3)^2 + (x_2 - 2)^2 \\ \text{s.a.} \quad & g_1(x_1, x_2) = x_1^2 + x_2^2 - 5 \leq 0 \\ & g_2(x_1, x_2) = -x_1 \leq 0 \\ & g_3(x_1, x_2) = -x_2 \leq 0 \\ & g_4(x_1, x_2) = x_1 + x_2 - 3 \leq 0 \end{aligned}$$

- **Función objetivo**: Minimizar la distancia euclídea al cuadrado con respecto al centro $(3, 2)$.
- **Región factible** $\mathcal{S}$: Delimitada por la circunferencia g_1, los ejes de coordenadas g_2, g_3 y la recta oblicua g_4.

Ejemplo: Identificación – Conjuntos activos

Dependiendo de la ubicación del punto factible evaluado, el conjunto de restricciones activas $\mathcal{I}$ varía considerablemente:

- **Punto** $(1, 1)$: El punto es estrictamente interior, por lo que ninguna restricción se cumple con igualdad y $\mathcal{I} = \emptyset$.
- **Punto** $(0, 0)$: El punto está en el origen, lo que activa las fronteras de no negatividad, resultando $\mathcal{I} = \{2, 3\}$.
- **Punto** $(2, 1)$: Situado en la intersección de la circunferencia y la recta, activando ambas simultáneamente: $\mathcal{I} = \{1, 4\}$.
- **Punto** $(0, 1)$: Situado sobre el eje vertical, lo que activa únicamente la restricción de $x_1 \geq 0$, resultando $\mathcal{I} = \{2\}$.

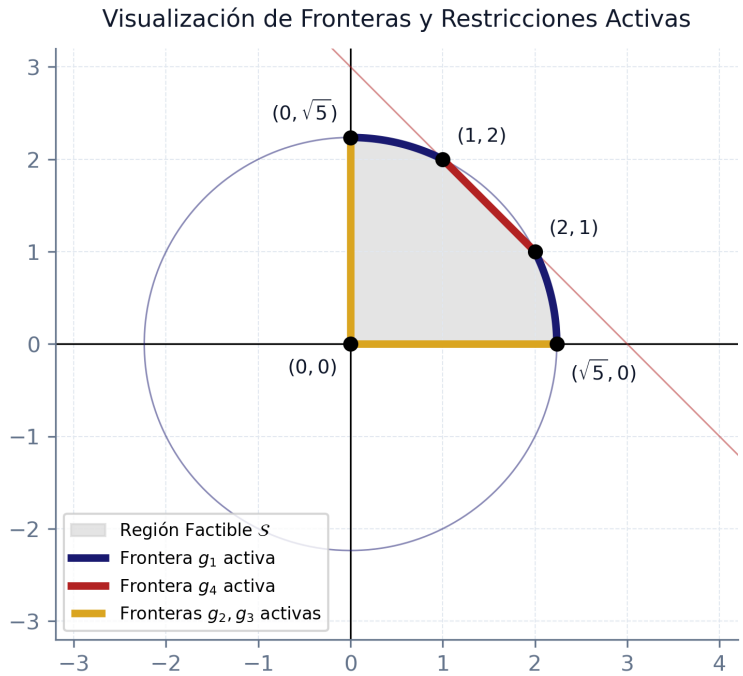

Ejemplo: Identificación – Gradientes en la frontera

Analicemos los gradientes de las restricciones activas en los puntos situados sobre la frontera de la región factible:

- **Punto** $(1, 2)$: Las restricciones activas son la circunferencia g_1 y la recta oblicua g_4 ($\mathcal{J} = \{1, 4\}$).
- **Cálculo de gradientes**:

$$\nabla g_1(1,2) = \begin{pmatrix} 2 \\ 4 \end{pmatrix}, \qquad \nabla g_4(1,2) =$$

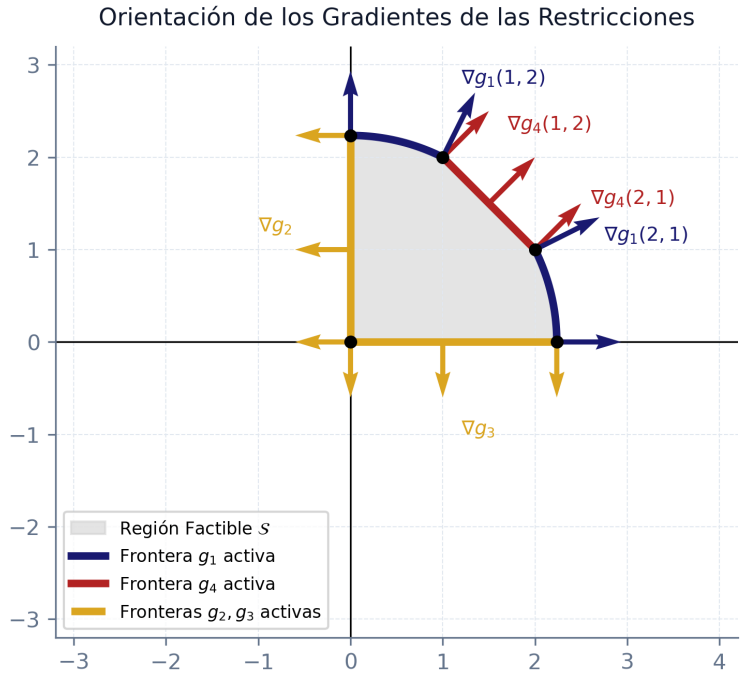

- **Orientación**: Ambos vectores señalan hacia fuera de la región factible, confirmando que el crecimiento de g_i nos aleja del conjunto factible $\mathcal{S}$.

Ejemplo: Identificación – Direcciones ortogonales

Analicemos qué ocurre con direcciones d ortogonales a los gradientes de restricciones activas ($\nabla g_i(\bar{x})^T d = 0$):

- **Punto** $(0, 1)$: La restricción $g_2(x) = -x_1 \leq 0$ está activa, con $\nabla g_2 = (-1, 0)^T$. La dirección vertical $d = (0, 1)^T$ es ortogonal al gradiente ($\nabla g_2^T d = 0$) y resulta factible, ya que mantiene al punto sobre la frontera.
- **Punto** $(1, 2)$: La restricción $g_4(x) = x_1 + x_2 - 3 \leq 0$ está activa, con $\nabla g_4 = (1, 1)^T$. La dirección tangencial $d = (1, -1)^T$ es ortogonal ($\nabla g_4^T d = 0$) y es factible por tratarse de una frontera lineal.

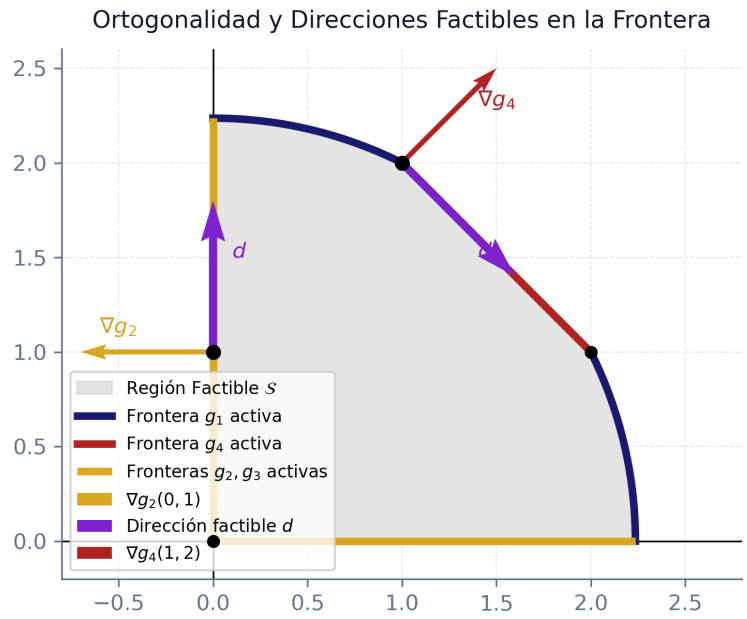

El cono analítico de restricciones activas

El cono de direcciones factibles geométricas $\mathcal{F}(\bar{x})$ requiere analizar la existencia de un paso admisible, lo que resulta muy complejo en la frontera. Lo aproximamos localmente de forma algebraica:

- **Definición**: El **cono analítico de restricciones activas** $\mathcal{G}_0(\bar{x})$ es el conjunto de direcciones que apuntan estrictamente hacia el interior de todas las restricciones activas en $\bar{x}$:

$$\mathcal{G}_0(\bar{x}) = \{d \in \mathbb{R}^n \mid \nabla g_i(\bar{x})^T d < 0, \ \forall i \in \mathcal{I}\}$$

- **Ventaja algebraica**: Se calcula directamente a partir de los gradientes de las restricciones activas en el punto de evaluación, sin necesidad de estimar la longitud de pasos infinitesimales.

Relación de inclusión de conos

La relación entre el cono algebraico $\mathcal{G}_0(\bar{x})$ y el cono factible geométrico $\mathcal{F}(\bar{x})$ es estrecha, pero presenta matices:

- **Inclusión fundamental**: Cualquier dirección que apunte estrictamente al interior de las restricciones activas es geométricamente factible:

$$\mathcal{G}_0(\bar{x}) \subseteq \mathcal{F}(\bar{x})$$

- **Inclusión estricta**: En general, no se cumple la igualdad ($\mathcal{G}_0(\bar{x}) \neq \mathcal{F}(\bar{x})$).
- **Causa de discrepancia**: Las direcciones d ortogonales a algún gradiente activo de frontera lineal ($\nabla g_i(\bar{x})^T d = 0$) pueden mantener al punto sobre la frontera y ser factibles geométricamente, pero no pertenecen al cono abierto algebraico $\mathcal{G}_0(\bar{x})$.

Intersección vacía con el cono activo

Intersección vacía con el cono activo

Sea el problema de optimización bajo restricciones de desigualdad, con f y g_i $(i \in \mathcal{I})$ diferenciables en el punto factible $\bar{x}$. Si $\bar{x}$ es un mínimo local, entonces el cono de descenso analítico y el cono analítico de restricciones activas son disjuntos:

$$\mathcal{D}_0(\bar{x}) \cap \mathcal{G}_0(\bar{x}) = \emptyset$$

- Dado que $\mathcal{G}_0(\bar{x}) \subseteq \mathcal{F}(\bar{x})$, de la exclusión geométrica necesaria $(\mathcal{D}_0(\bar{x}) \cap \mathcal{F}(\bar{x}) = \emptyset)$ se deduce de forma inmediata que la intersección con el cono analítico más restrictivo también debe ser vacía.

Suficiencia geométrica sin KKT

! Suficiencia geométrica sin KKT

Sea el problema de optimización con restricciones de desigualdad, con f y g_i $(i \in \mathcal{I})$ diferenciables en $\bar{x}$. Si se cumple:

1. La función objetivo f es **pseudo-convexa** en $\bar{x}$.
2. Las restricciones activas g_i son **estrictamente pseudo-convexas** en $\bar{x}$.
3. Se cumple que: $\mathcal{D}_0(\bar{x}) \cap \mathcal{G}_0(\bar{x}) = \emptyset$.

Entonces, $\bar{x}$ es un **mínimo local** del problema.

Ejemplo 1: Planteamiento y candidatos

Consideremos el problema de optimización restringido:

$$\begin{aligned} \min \quad & f(x_1, x_2) = (x_1 - 3)^2 + (x_2 - 2)^2 \\ \text{s.a.} \quad & g_1(x_1, x_2) = x_1^2 + x_2^2 - 5 \leq 0 \\ & g_2(x_1, x_2) = -x_1 \leq 0 \\ & g_3(x_1, x_2) = -x_2 \leq 0 \\ & g_4(x_1, x_2) = x_1 + x_2 - 3 \leq 0 \end{aligned}$$

- **Objetivo**: Minimizar la distancia al cuadrado con respecto al centro $(3, 2)$.
- **Candidatos de frontera**: Analizaremos el comportamiento de los conos de direcciones en dos puntos candidatos situados sobre la frontera de la región factible:
  1. El punto candidato $A(9/5, 6/5)$.
  2. El punto candidato $B(2, 1)$.

Ejemplo 1: Candidato $A(9/5, 6/5)$ – Conos

- **Restricciones activas**:

$$g_1(A) < 0, \quad g_4(A) = 0 \implies \mathcal{I} = \{$$

- **Gradientes relevantes**:

$$\nabla g_4(A) = \begin{pmatrix} 1 \\ 1 \end{pmatrix}, \quad \nabla f(A) = \begin{pmatrix} -12 \\ -8 \end{pmatrix}$$

- **Conos analíticos**:

$$\mathcal{G}_0(A) = \{d \in \mathbb{R}^2 \mid d_1 + d_2 < 0\}$$

$$\mathcal{D}_0(A) = \{d \in \mathbb{R}^2 \mid 3d_1 + 2d_2 > 0\}$$

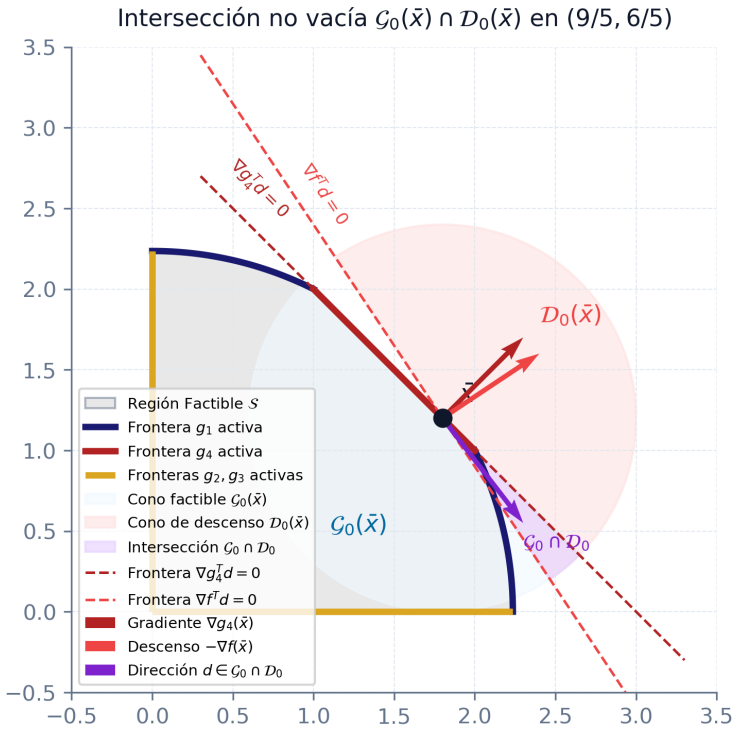

Ejemplo 1: Candidato $A(9/5, 6/5)$ – No optimalidad

- **Intersección de conos**:

$$\mathcal{G}_0(A) \cap \mathcal{D}_0(A) \neq \emptyset$$

- **Dirección de descenso factible**: La dirección $d = (1, -1.3)^T$ cumple:
  - $d_1 + d_2 = -0.3 < 0 \implies d \in \mathcal{G}_0(A)$
  - $3d_1 + 2d_2 = 0.4 > 0 \implies d \in \mathcal{D}_0(A)$
- **Conclusión**: Al existir direcciones factibles que a la vez son de descenso, el punto **no es un mínimo local**.

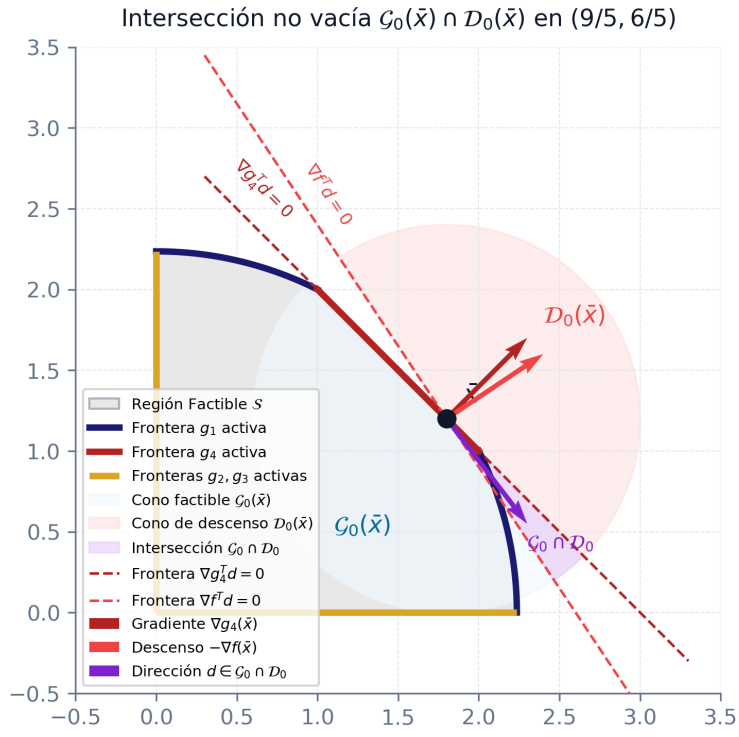

Ejemplo 1: Candidato $B(2,1)$ – Conos

- **Restricciones activas**:

$$g_1(B) = 0, \quad g_4(B) = 0 \implies \mathcal{J} = \cdot$$

- **Gradientes relevantes**:

$$\nabla g_1(B) = \begin{pmatrix} 4 \\ 2 \end{pmatrix}, \quad \nabla g_4(B) = \begin{pmatrix} 1 \\ 1 \end{pmatrix}$$

$$\nabla f(B) = \begin{pmatrix} -2 \\ -2 \end{pmatrix}$$

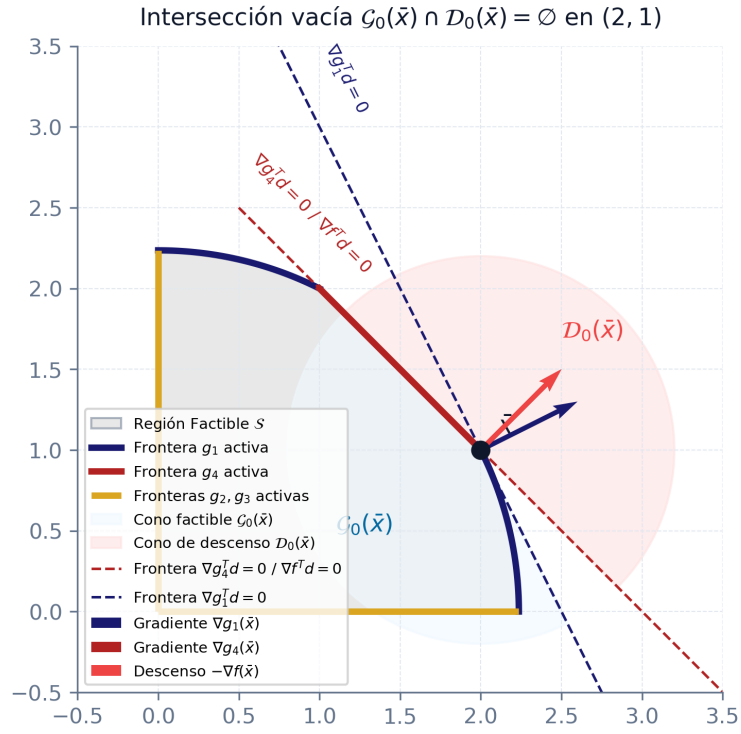

- **Conos analíticos**:

$$\mathcal{G}_0(B) = \{d \mid 2d_1 + d_2 < 0 \text{ y } d_1 + d_2 < 0\}$$

$$\mathcal{D}_0(B) = \{d \mid d_1 + d_2 > 0\}$$

Ejemplo 1: Candidato $B(2,1)$ – Optimalidad

- **Intersección vacía**:
  - Cualquier $d \in \mathcal{G}_0(B)$ exige $d_1 + d_2 < 0$.
  - Esto es incompatible con $d \in \mathcal{D}_0(B) \implies d_1 + d_2 > 0$.
  - Por lo tanto:

$$\mathcal{G}_0(B) \cap \mathcal{D}_0(B) = \emptyset$$

- **Conclusión**: Al ser un problema convexo (región factible y función objetivo convexas), $B(2,1)$ **es el mínimo global único**.

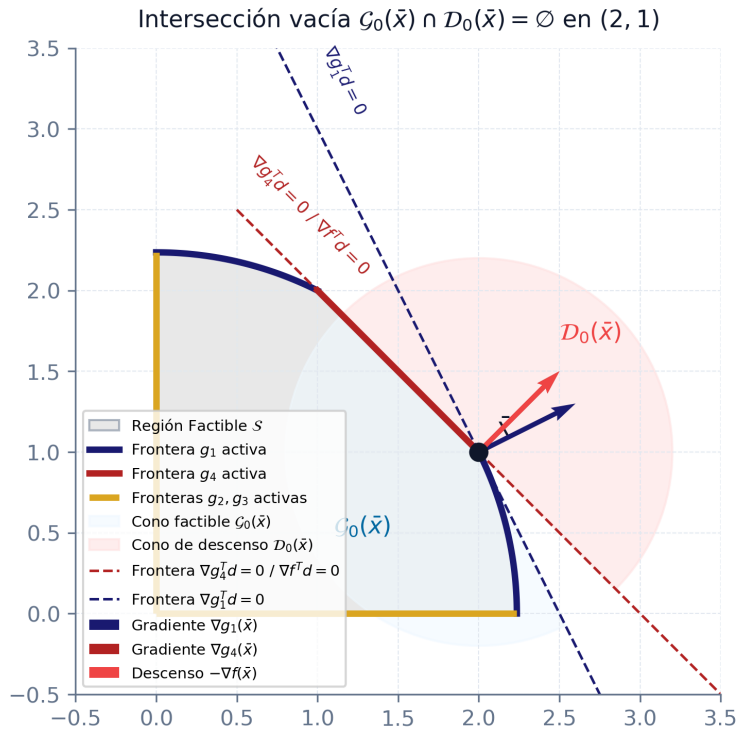

Ejemplo 2: Tangencia cúbica (Planteamiento)

Consideremos el siguiente problema singular de optimización:

$$
\begin{aligned}
\min \quad & f(x_1, x_2) = (x_1 - 1)^2 + (x_2 - 1)^2 \\
\text{s.a.} \quad & g_1(x_1, x_2) = (x_1 + x_2 - 1)^3 \leq 0 \\
& g_2(x_1, x_2) = -x_1 \leq 0 \\
& g_3(x_1, x_2) = -x_2 \leq 0
\end{aligned}
$$

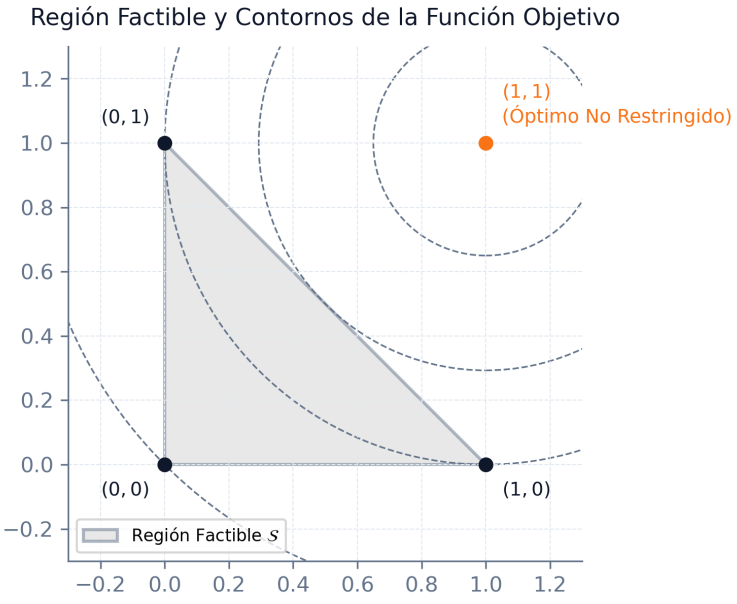

- **Geometría**:
  - Región factible $\mathcal{S}$: Triángulo.
  - Óptimo no restringido en el centro $(1, 1)$.
  - Mínimo global real en el punto medio de la hipotenusa: $\bar{x} = (1/2, 1/2)$.

Ejemplo 2: Análisis analítico en $\bar{x} = (1/2, 1/2)$

- **Restricciones activas**: En $\bar{x} = (1/2, 1/2)$, la restricción g_1 está activa ($g_1(\bar{x}) = 0$).
- **Cálculo de gradiente**:

$$\nabla g_1(x) = \begin{pmatrix} 3(x_1 + x_2 - 1)^2 \\ 3(x_1 + x_2 - 1)^2 \end{pmatrix} \implies \nabla g_1(\bar{x}) = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

- **Cono analítico activo**:

$$\mathcal{G}_0(\bar{x}) = \{d \in \mathbb{R}^2 \mid \nabla g_1(\bar{x})^T d < 0\} = \emptyset$$

- **Intersección vacía**: Al ser $\mathcal{G}_0(\bar{x}) = \emptyset$, se cumple trivialmente que:

$$\mathcal{D}_0(\bar{x}) \cap \mathcal{G}_0(\bar{x}) = \emptyset$$

La condición necesaria geométrica se satisface y el punto es, de hecho, el mínimo global.

Ejemplo 2: Limitación del caso singular

El hecho de que el gradiente de la restricción activa se anule en el óptimo genera una limitación teórica importante:

- **Falsos positivos**: Para cualquier punto sobre la hipotenusa $x_1 + x_2 = 1$ (por ejemplo, el punto $(1, 0)$), el gradiente $\nabla g_1(x)$ también es nulo.
- **Anulación del cono analítico**: Esto implica que $\mathcal{G}_0(x) = \emptyset$ y $\mathcal{D}_0(x) \cap \mathcal{G}_0(x) = \emptyset$ para **toda la recta**, incluso para puntos que no son mínimos locales.
- **Conclusión**: Cuando los gradientes de las restricciones activas se anulan o son linealmente dependientes, el cono analítico $\mathcal{G}_0(\bar{x})$ pierde su capacidad para representar el comportamiento geométrico real.
- **Necesidad**: Surge la necesidad de definir **condiciones de regularidad** de restricciones (cualificación de restricciones).

Ejemplo 2: Reformulación y regularización

Reescribimos la región factible con una restricción equivalente de primer orden:

$$g_1(x_1, x_2) = x_1 + x_2 - 1 \leq 0$$

- **Gradiente regularizado**:

$$\nabla g_1(x) = \begin{pmatrix} 1 \\ 1 \end{pmatrix} \neq \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

- **Conos resultantes**:

$$\mathcal{G}_0(\bar{x}) = \{d \in \mathbb{R}^2 \mid d_1 + d_2 < 0\}$$

- **Intersección vacía**: La condición $\mathcal{D}_0(\bar{x}) \cap \mathcal{G}_0(\bar{x}) = \emptyset$ ahora se verifica **únicamente** en el mínimo real $\bar{x} = (1/2, 1/2)$.

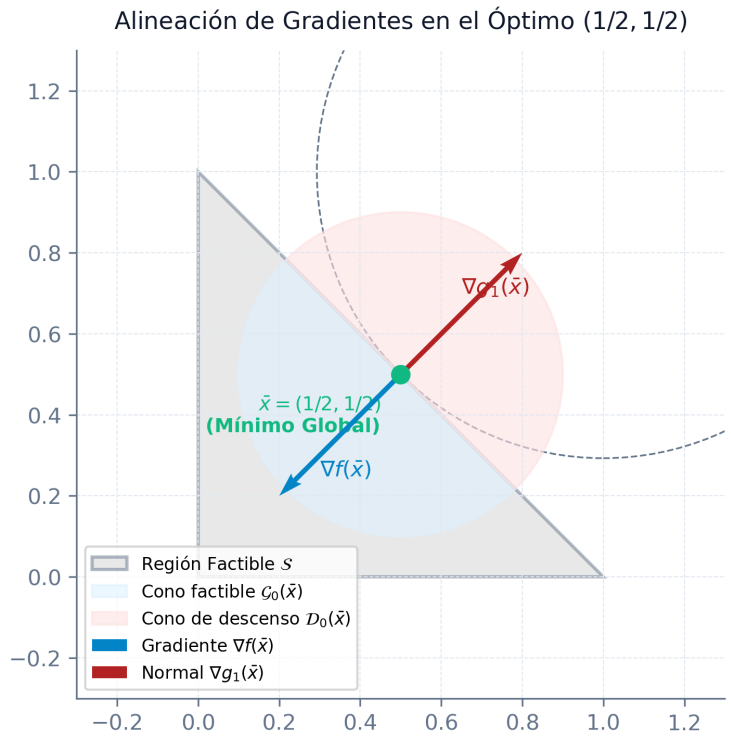

Condiciones de Fritz-John (FJ)

Introducción a las Condiciones de Fritz-John

- **De la geometría al álgebra**: Comprobar la optimalidad mediante la exclusión geométrica de conos ($\mathcal{D}_0 \cap \mathcal{G}_0 = \emptyset$) en el espacio de direcciones requiere evaluar infinitos vectores (inviable en la práctica).
- **Formulación dual**: Traducimos la exclusión geométrica en un sistema de ecuaciones algebraicas sobre los gradientes de las funciones en el punto de evaluación.
- **Lemas de alternativas**: Resultados del álgebra lineal y convexidad que asocian coeficientes (multiplicadores) a las restricciones a partir de la ausencia de direcciones comunes.

Lema: Alternativa de Farkas

Alternativa de Farkas

Sean A una matriz de dimensiones $m \times n$ y $c \in \mathbb{R}^n$. Uno y solo uno de los siguientes sistemas de restricciones tiene solución:

1. Existe $x \in \mathbb{R}^n$ tal que $Ax \leq 0$ y $c^T x > 0$.
2. Existe $y \in \mathbb{R}^m$ tal que $A^T y = c$ e $y \geq 0$.

- **Significado**: Nos permite caracterizar cuándo un vector c no puede formar un ángulo agudo con ninguna dirección factible, traduciéndolo en una combinación lineal cónica de las restricciones.

Lema: Alternativa de Gordan

Alternativa de Gordan

Sea A una matriz de dimensiones $m \times n$. Uno y solo uno de los siguientes sistemas de restricciones tiene solución:

1. Existe $x \in \mathbb{R}^n$ tal que $Ax < 0$.
2. Existe $y \in \mathbb{R}^m$ tal que $A^T y = 0$, $y \geq 0$ e $y \neq 0$.

- **Significado**: Garantiza que si no hay ninguna dirección que sea estrictamente interior a un conjunto de semiespacios, entonces existe una combinación lineal no trivial no negativa de sus vectores normales que se anula.

El equilibrio de fuerzas (Gordan)

La exclusión de direcciones de descenso factibles exige que no exista d tal que:

$$\nabla f(\bar{x})^T d < 0 \qquad \text{y} \qquad \nabla g_i(\bar{x})^T d < 0, \quad \forall i \in \mathcal{J}$$

- **Matriz de gradientes**: Definimos la matriz A cuyas filas son los gradientes $\nabla f(\bar{x})^T$ y $\nabla g_i(\bar{x})^T$ $(i \in \mathcal{J})$.
- **Ausencia de solución**: La optimalidad geométrica equivale a que el sistema lineal $Ad < 0$ no tenga solución.
- **Aplicación dual**: Por el Lema de Gordan, existe un vector de coeficientes no negativos $p = (u_0, u_{\mathcal{J}})^T \geq 0$ no nulo tal que:

$$u_0 \nabla f(\bar{x}) + \sum_{i \in \mathcal{J}} u_i \nabla g_i(\bar{x}) = 0$$

Condiciones necesarias de Fritz-John

! Condiciones necesarias de Fritz-John

Sea $\bar{x}$ un mínimo local del problema. Si f y g_i $(i \in \mathcal{I})$ son diferenciables en $\bar{x}$, existen multiplicadores $u_0, u_1, \ldots, u_m$ tales que:

1. **Factibilidad dual**: $u_0 \nabla f(\bar{x}) + \sum_{i=1}^{m} u_i \nabla g_i(\bar{x}) = 0$
2. **Holgura complementaria**:
   $u_i g_i(\bar{x}) = 0, \quad \forall i = 1, \ldots, m$
3. **No negatividad**: $u_0, u_i \geq 0, \quad \forall i = 1, \ldots, m$
4. **No trivialidad**: $(u_0, u_1, \ldots, u_m) \neq (0, 0, \ldots, 0)$

El papel del multiplicador u_0

El multiplicador u_0 corresponde a la función objetivo:

- **Caso regular ($u_0 > 0$)**: Podemos dividir toda la ecuación por u_0. Esto recupera de forma natural las **condiciones de KKT**, donde la función objetivo influye activamente en la optimalidad.
- **Caso singular ($u_0 = 0$)**: La función objetivo desaparece de la ecuación dual. Las condiciones se satisfacen de forma puramente geométrica por la disposición de las restricciones en la frontera, perdiendo su utilidad para discriminar mínimos.

Ejemplo: Interpretación en cuatro casos

Consideremos el punto de intersección $\bar{x} = (7/3, 4/3)$ bajo restricciones lineales activas:

$$g_1(x) = 2x + y - 6 \leq 0 \implies \nabla g_1 = (2, 1)^T$$

$$g_2(x) = x - y - 1 \leq 0 \implies \nabla g_2 = (1, -1)^T$$

- **Propósito**: Analizaremos la relación entre el gradiente opuesto del objetivo $-\nabla f(\bar{x})$ y los gradientes de las restricciones en cuatro escenarios distintos.
- **Equilibrio dual**: Estudiaremos cómo los signos y la dependencia lineal de los vectores determinan el tipo de punto y el valor de los multiplicadores.

Caso 1: Mínimo local regular

- **Problema**: Minimizar $f(x, y) = (x-5)^2 + (y-1)^2$ sujeto a g_1 y g_2.
- **Gradiente**: $-\nabla f(\bar{x}) = (16/3, -2/3)^T$, situado dentro del cono generado por los gradientes activos.
- **Ecuación dual**:

$$u_0 \begin{pmatrix} 16/3 \\ -2/3 \end{pmatrix} = u_1 \begin{pmatrix} 2 \\ 1 \end{pmatrix} + u_2 \begin{pmatrix} 1 \\ -1 \end{pmatrix}$$

- **Solución**: $u_1 = \frac{14}{9} u_0 > 0$, $u_2 = \frac{20}{9} u_0 > 0$. Punto regular con $u_0 = 1$.

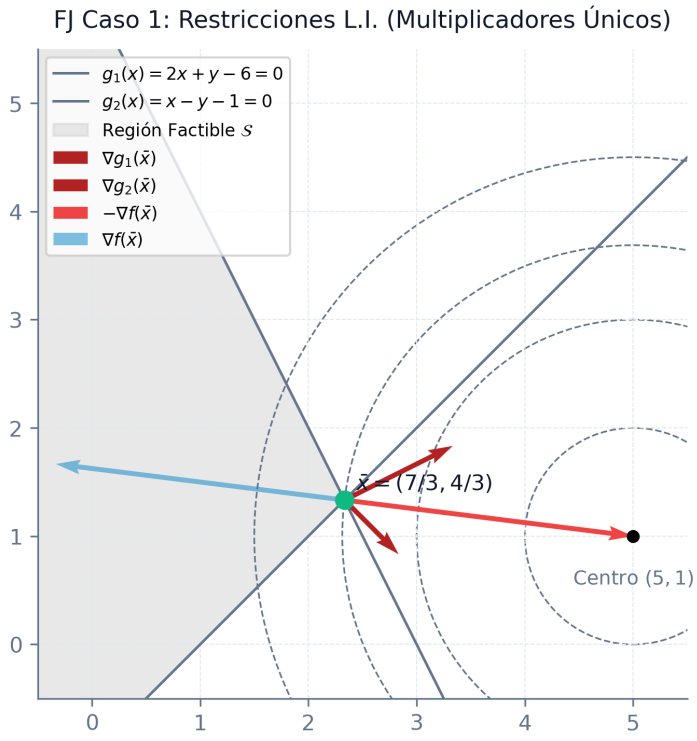

Caso 2: Restricción redundante

- **Problema**: Añadimos la restricción redundante $g_3(x, y) = x \leq 7/3$ con gradiente $\nabla g_3 = (1, 0)^T$.
- **Gradientes activos**: Son linealmente dependientes.
- **Ecuación dual**: Admite infinitas combinaciones para $-\nabla f(\bar{x})$. Con $u_0 = 1$:

$$u_1 \in [0, 14/9], \quad u_2 = u_1 + 2/3$$
$$u_3 = 14/3 - 3u_1$$

Se pierde la unicidad de multiplicadores.

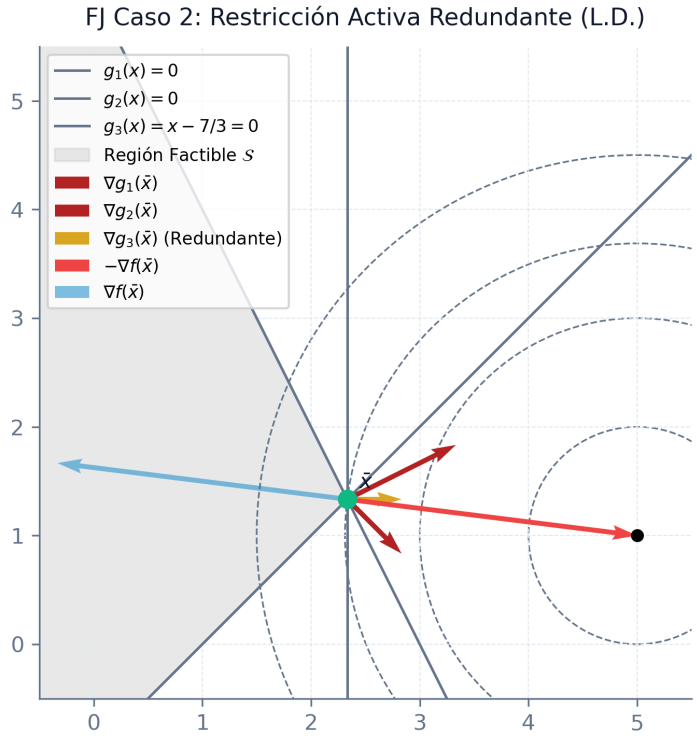

Caso 3: Singularidad ($u_0 = 0$)

- **Problema**: Añadimos la restricción opuesta $g_3(x, y) = -x \leq -7/3$ con $\nabla g_3 = (-1, 0)^T$.
- **Geometría**: Los tres gradientes activos impiden direcciones factibles ($\mathcal{G}_0 = \emptyset$).
- **Ecuación dual**: Se anula sin intervención de la función objetivo:

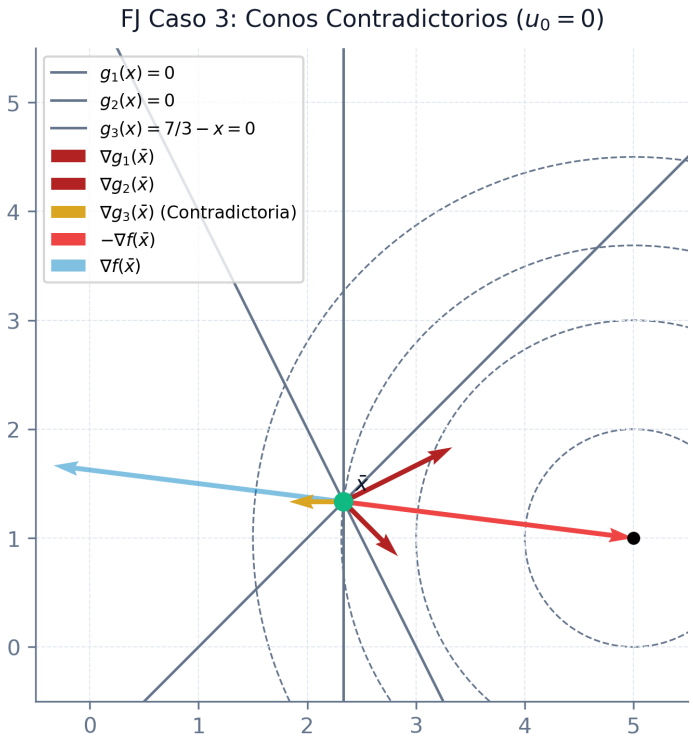

$$u_1 \begin{pmatrix} 2 \\ 1 \end{pmatrix} + u_2 \begin{pmatrix} 1 \\ -1 \end{pmatrix} + u_3 \begin{pmatrix} -1 \\ 0 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

- **Solución**: $u_0 = 0$, $u_1 = 1$, $u_2 = 1$, $u_3 = 3$. Las condiciones se cumplen de forma trivial.

Caso 4: Máximo local

- **Problema**: Minimizar $f(x, y) = -(x-5)^2 - (y-1)^2$ (maximizar la distancia).
- **Gradiente**: $-\nabla f(\bar{x}) = (-16/3, 2/3)^T$, apunta hacia fuera del cono factible.
- **Ecuación dual**: Al intentar resolver para $u_0 > 0$, los multiplicadores resultan negativos:

$$u_1 = -\frac{14}{9} u_0 < 0$$

- **Conclusión**: Las condiciones FJ descartan correctamente este candidato a mínimo local.

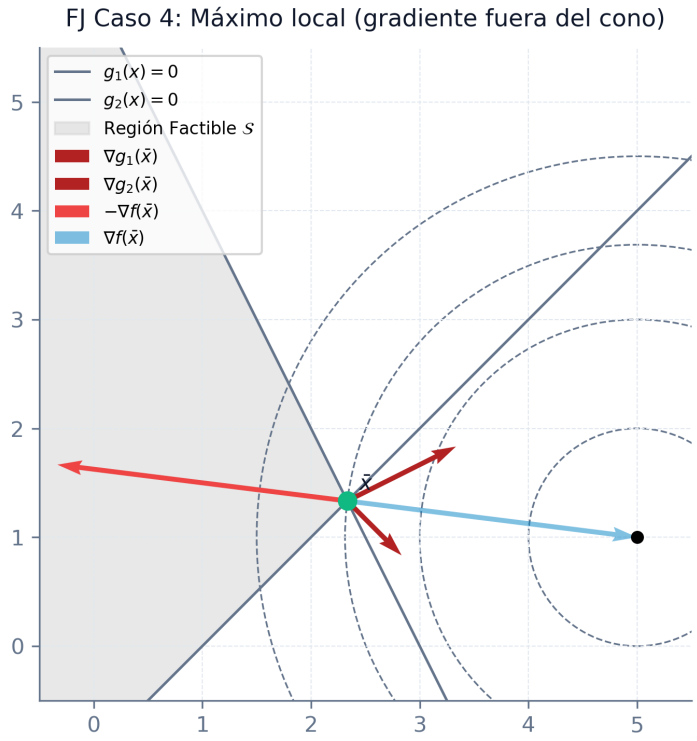

Clasificación de candidatos duales

El formalismo de Fritz-John permite clasificar los puntos candidatos en tres familias según su geometría:

- **Puntos de tangencia regular**: El gradiente de la función objetivo $\nabla f(\bar{x})$ y el de la restricción activa $\nabla g_i(\bar{x})$ son colineales y opuestos ($u_0 > 0$). El objetivo determina la optimalidad.
- **Vértices o puntos de esquina**: Varias restricciones activas linealmente independientes bloquean cualquier dirección factible.
- **Puntos singulares o de cúspide**: La frontera es tan restrictiva que la cualificación de restricciones falla (los gradientes activos son linealmente dependientes), permitiendo $u_0 = 0$.

Vulnerabilidad y redundancia en FJ

El hecho de que las singularidades permitan $u_0 = 0$ limita la utilidad del teorema en ciertos problemas. En puntos singulares, el gradiente de la función que deseamos minimizar no influye en las ecuaciones de optimalidad (insensibilidad).

⚠ Vulnerabilidad por redundancia trivial

Siempre se puede transformar artificialmente cualquier punto factible en un candidato Fritz-John con $u_0 = 0$ añadiendo una restricción redundante inútil como $\|x - \bar{x}\| \geq 0$, cuyo gradiente nulo anula el cono algebraico $\mathcal{G}_0$.

Ejemplo: Fallo de FJ (Planteamiento)

Consideremos el problema singular:

$$\begin{aligned} \min_{x} \quad & -x_1 \\ \text{sujeto a} \quad & g_1(x_1, x_2) = x_2 - (1 - x_1)^3 \leq \\ & g_2(x_1, x_2) = -x_2 \leq 0 \end{aligned}$$

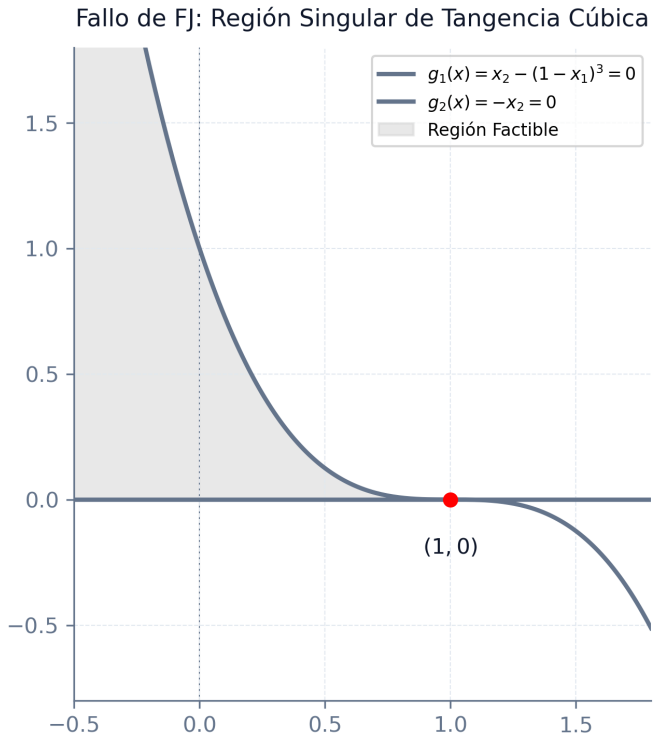

- **Óptimo**: $\bar{x} = (1, 0)$, ambas restricciones activas ($\mathcal{J} = \{1, 2\}$).
- **Gradientes**:

$$\nabla f(\bar{x}) = \begin{pmatrix} -1 \\ 0 \end{pmatrix}, \quad \nabla g_1(\bar{x}) = \begin{pmatrix} 0 \\ 1 \end{pmatrix}$$

$$\nabla g_2(\bar{x}) = \begin{pmatrix} 0 \\ -1 \end{pmatrix}$$

Ejemplo: Fallo de FJ (Análisis Dual)

- **Ecuación de Fritz-John**:

$$u_0 \begin{pmatrix} -1 \\ 0 \end{pmatrix} + u_1 \begin{pmatrix} 0 \\ 1 \end{pmatrix} + u_2 \begin{pmatrix} 0 \\ -1 \end{pmatrix} = \begin{pmatrix}$$

- **Sistema de ecuaciones**:

$$-u_0 = 0 \implies u_0 = 0$$

$$u_1 - u_2 = 0 \implies u_1 = u_2 = \alpha > 0$$

- **Resultado**: El multiplicador del objetivo se anula obligatoriamente ($u_0 = 0$). El objetivo no influye en las ecuaciones debido a la tangencia cúbica.

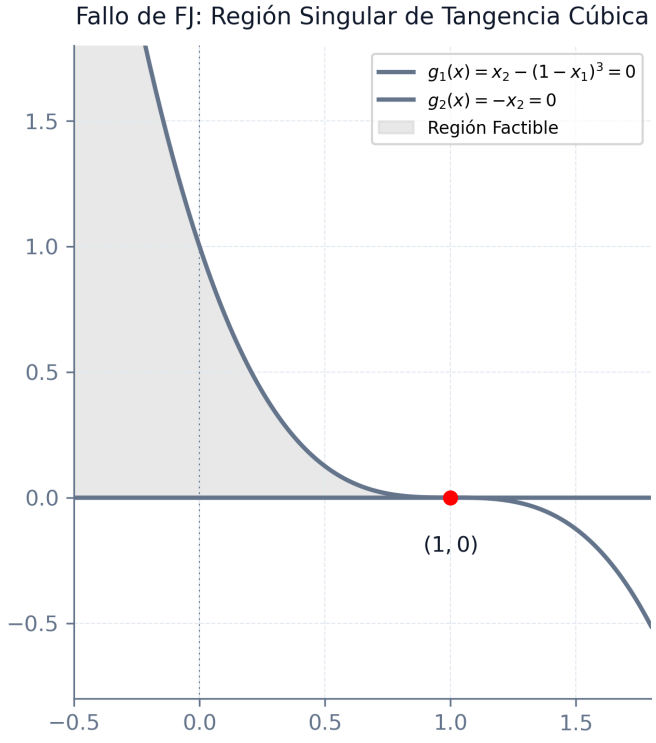

Ejemplo: FJ Regular (Planteamiento)

Sustituimos la restricción cúbica singular por una restricción lineal equivalente:

$$\begin{aligned} \min \quad & -x_1 \\ \text{s.a.} \quad & g_1(x_1, x_2) = x_1 + x_2 - 1 \leq 0 \\ & g_2(x_1, x_2) = -x_2 \leq 0 \end{aligned}$$

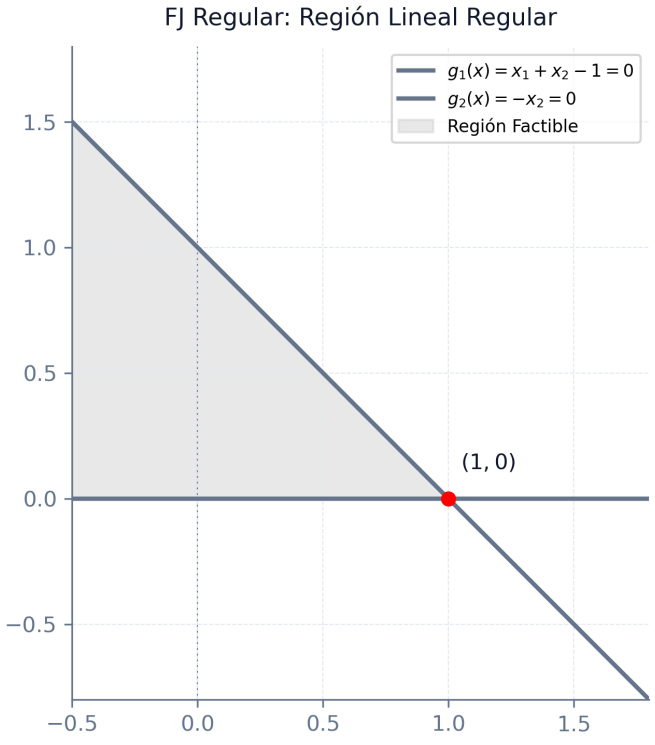

- **Óptimo**: $\bar{x} = (1, 0)$, ambas activas ($\mathcal{J} = \{1, 2\}$).
- **Gradientes**:

$$\nabla f(\bar{x}) = \begin{pmatrix} -1 \\ 0 \end{pmatrix}, \quad \nabla g_1(\bar{x}) = \begin{pmatrix} 1 \\ 1 \end{pmatrix}$$

$$\nabla g_2(\bar{x}) = \begin{pmatrix} 0 \\ -1 \end{pmatrix}$$

Ejemplo: FJ Regular (Análisis Dual)

- **Ecuación de Fritz-John**:

$$u_0 \begin{pmatrix} -1 \\ 0 \end{pmatrix} + u_1 \begin{pmatrix} 1 \\ 1 \end{pmatrix} + u_2 \begin{pmatrix} 0 \\ -1 \end{pmatrix} = \begin{pmatrix}$$

- **Sistema de ecuaciones**:

$$-u_0 + u_1 = 0 \implies u_1 = u_0$$

$$u_1 - u_2 = 0 \implies u_2 = u_1$$

- **Resultado**: Obtenemos $u_1 = u_2 = u_0$. Fijando $u_0 = 1$, la solución es $u_1 = u_2 = 1 > 0$. El objetivo influye activamente.

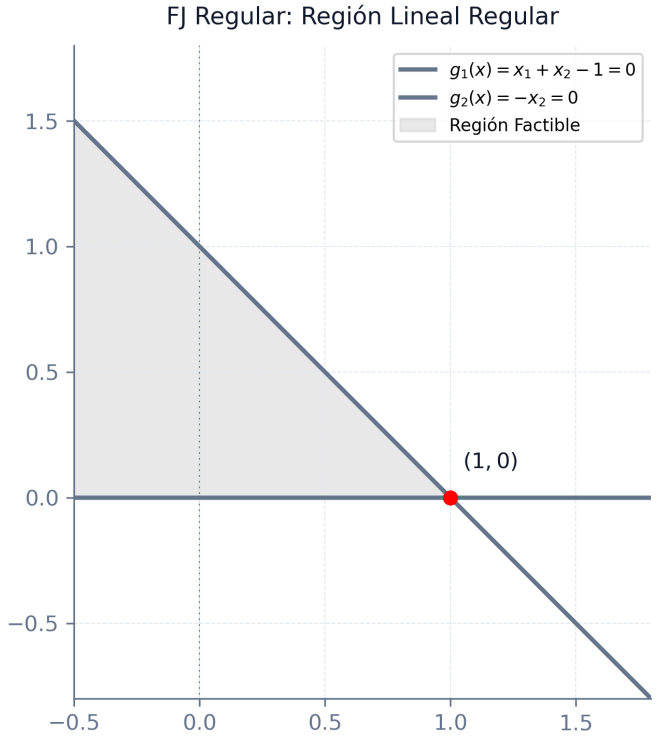

Condiciones de Karush-Kuhn-Tucker (KKT)

Introducción a las Condiciones KKT

- **Limitación de Fritz-John**: Cuando el multiplicador del objetivo es nulo ($u_0 = 0$), el gradiente de la función objetivo no influye en las ecuaciones duales de optimalidad.
- **Cualificación de restricciones**: Para garantizar que $u_0 > 0$ y poder omitir dicho coeficiente, Kuhn, Tucker (1951) y Karush (1939) introdujeron hipótesis de regularidad en el punto candidato.
- **Independencia Lineal (LICQ)**: La cualificación de restricciones más importante, que exige que los gradientes de las restricciones activas en el óptimo sean linealmente independientes.

Cualificación de restricciones: LICQ

! Independencia Lineal de Restricciones Activas (LICQ)

Un punto factible $\bar{x}$ satisface la condición de regularidad LICQ si el conjunto de vectores gradiente de las restricciones activas en dicho punto:

$$\{\nabla g_i(\bar{x}), \quad i \in \mathcal{I}(\bar{x})\}$$

es linealmente independiente.

- **Efecto dual**: Garantiza que no hay contradicciones ni redundancias críticas en la frontera factible, permitiendo la existencia y unicidad de los multiplicadores de Lagrange ordinarios.

Condiciones necesarias de KKT

! Condiciones necesarias de Karush-Kuhn-Tucker (KKT)

Sea $\bar{x}$ un mínimo local del problema. Si f y g_i son diferenciables, las inactivas continuas en $\bar{x}$, y se satisface la condición de regularidad **LICQ** en $\bar{x}$:
Entonces, existen multiplicadores únicos $u_1, u_2, \dots, u_m$ tales que:

1. **Factibilidad primal**: $g_i(\bar{x}) \leq 0, \quad \forall i = 1, \dots, m$
2. **Estacionariedad**: $\nabla f(\bar{x}) + \sum_{i=1}^{m} u_i \nabla g_i(\bar{x}) = 0$
3. **Holgura complementaria**:
   $u_i g_i(\bar{x}) = 0, \quad \forall i = 1, \dots, m$
4. **No negatividad**: $u_i \geq 0, \quad \forall i = 1, \dots, m$

Interpretación geométrica de KKT

- **Equilibrio de fuerzas**: El gradiente opuesto de la función objetivo $-\nabla f(\bar{x})$ debe ser una combinación lineal no negativa de los gradientes de las restricciones activas.
- **Exclusión de descenso**: Esto equivale a decir que el gradiente opuesto pertenece al cono dual de restricciones activas $\mathcal{G}_0^*(\bar{x})$.
- **Cierre del cono**: Garantiza que no existe ninguna dirección factible que sea a la vez de descenso.

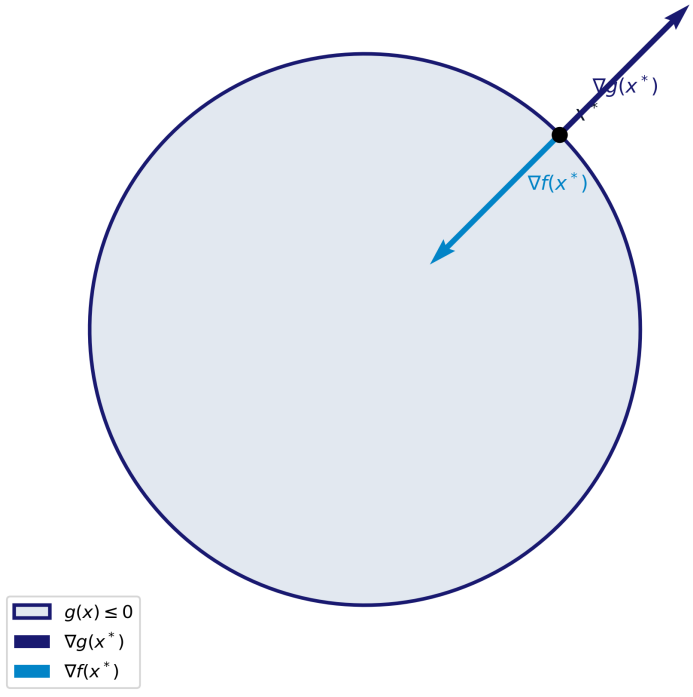

Advertencia: Condiciones únicamente necesarias

⚠ Las condiciones KKT son únicamente necesarias

Las condiciones KKT son únicamente **necesarias** en problemas generales. No se aplican a todos los puntos, sino que excluyen a aquellos que violan la cualificación de restricciones (LICQ). Existe la posibilidad de que el óptimo global del problema se encuentre precisamente entre los puntos excluidos (por ejemplo, en un punto singular de la frontera donde los gradientes de las restricciones activas sean linealmente dependientes). En cualquier resolución analítica, estos puntos singulares deben analizarse de manera independiente.

- Para **problemas lineales**, las condiciones KKT sí resultan ser necesarias y suficientes.

Observación: Extensión a máximos locales

Observación: Extensión a máximos locales

Si el punto $\bar{x}$ es un máximo local, entonces las condiciones necesarias de KKT siguen siendo válidas sin más que exigir que los multiplicadores de Lagrange sean no positivos:

$$u_i \leq 0, \quad \forall i = 1, \ldots, m$$

- El gradiente del objetivo $-\nabla f(\bar{x})$ apuntará en la dirección de la normal exterior de la frontera en lugar de hacia dentro de la región factible.

Condiciones suficientes KKT bajo Convexidad

! Condiciones suficientes de KKT bajo convexidad

Sea $\bar{x}$ un punto factible que satisface las condiciones necesarias de KKT con multiplicadores u_i. Si se verifica que:

1. La función objetivo $f(x)$ es **pseudo-convexa** en $\bar{x}$.
2. Las restricciones activas $g_i(x)$ $(i \in \mathcal{J})$ son **cuasi-convexas** y diferenciables en $\bar{x}$.

Entonces, $\bar{x}$ es un **mínimo global** del problema.

- **Unicidad**: Si f es estrictamente pseudo-convexa, el mínimo global $\bar{x}$ es único.

Observación sobre suficiencia local y unicidad

Observación sobre suficiencia local y unicidad

- **Suficiencia local**: Si las condiciones de pseudo-convexidad, cuasi-convexidad y diferenciabilidad se verifican sólo localmente en un entorno de $\bar{x}$, entonces el candidato será un mínimo local.
- **Máximos globales**: Si el punto es un máximo local, para garantizar que sea máximo global hay que exigir que la función objetivo f sea **pseudo-cóncava** (o $-f$ sea pseudo-convexa).
- **Unicidad**: Si la función objetivo es estrictamente pseudo-convexa, el punto mínimo global $\bar{x}$ es único.

Ejemplo 1: Caso de KKT con círculo y parábola (Planteamiento)

- **Problema de estudio**:

$$\min / \max \quad f(x_1, x_2) = x_1 + x_2$$

$$\text{s.a.} \quad g_1(x) = x_1^2 + x_2^2 - 4 \leq 0$$

$$g_2(x) = -x_1^2 + x_2 \leq 0$$

- **Gradientes**: $\nabla f = (1, 1)^T$
  $\nabla g_1 = (2x_1, 2x_2)^T$
  $\nabla g_2 = (-2x_1, 1)^T$
- **Dominio**: Región sombreada acotada por el círculo y la parábola.

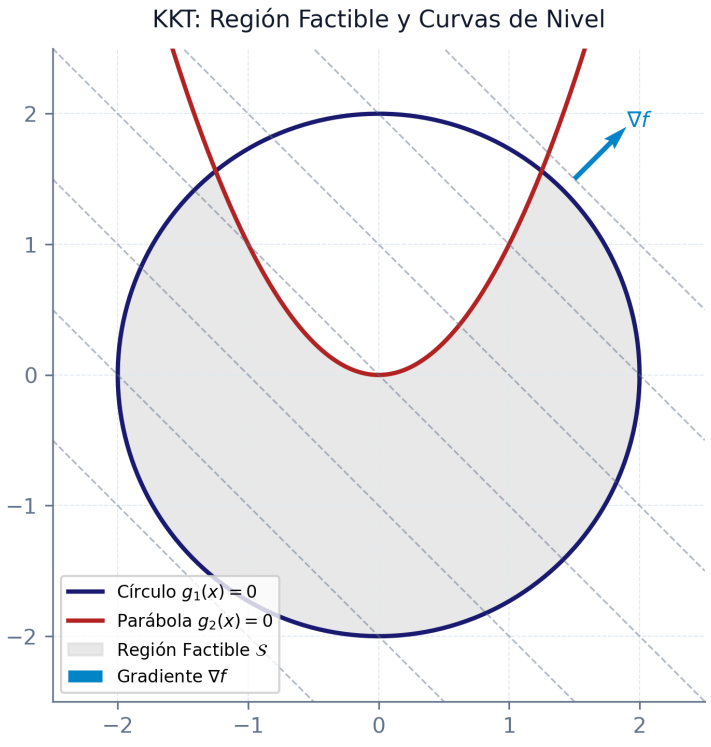

Ejemplo 1: Caso de KKT con círculo y parábola (Sistema KKT)

- **Función Lagrangiana**:

$$L(x,u) = x_1 + x_2 + u_1(x_1^2 + x_2^2 - 4) +$$

- **Condiciones algebraicas**:
  1. **Estacionariedad**:

$$1 + 2x_1(u_1 - u_2) = 0$$

$$1 + 2x_2 u_1 + u_2 = 0$$

  2. **Holgura**: $u_1 g_1(x) = 0$, $u_2 g_2(x) = 0$.
  3. **Signo**: $u_i \geq 0$ (mínimos), $u_i \leq 0$ (máximos).

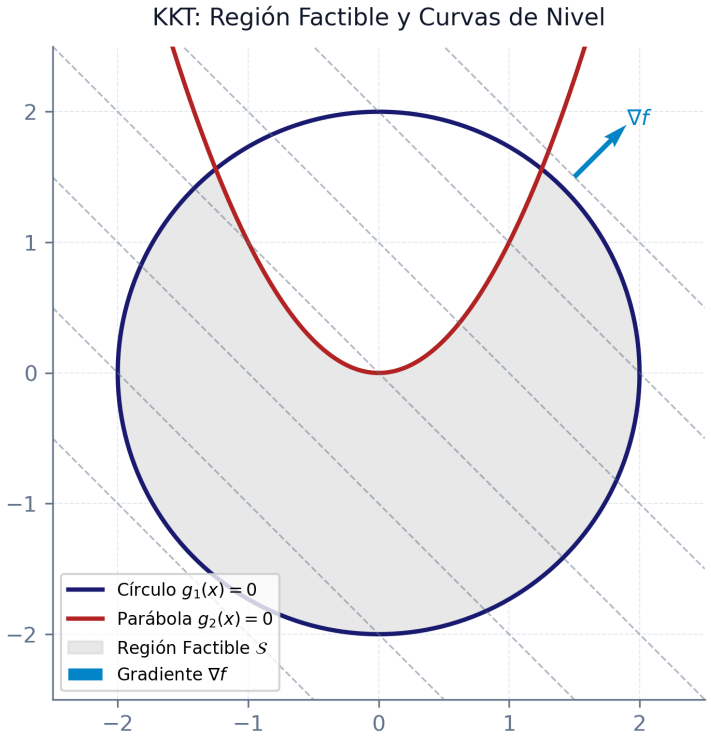

Ejemplo 1: Caso 1 – Círculo inactivo ($u_1 = 0$)

- **Condición**:
  $u_1 = 0 \implies u_2 \neq 0$ (g_2 es activa, $x_2 = x_1^2$).
- **Estacionariedad**:
  $1 - 2u_2x_1 = 0$ y
  $1 + u_2 = 0 \implies u_2 = -1$.
- **Coordenadas**: $1 - 2(-1)x_1 = 0 \implies x_1 = -1/2$.
  $x_2 = x_1^2 = 1/4$.
- **Candidato**: $A(-1/2, 1/4)^T$ con $u = (0, -1)^T$.

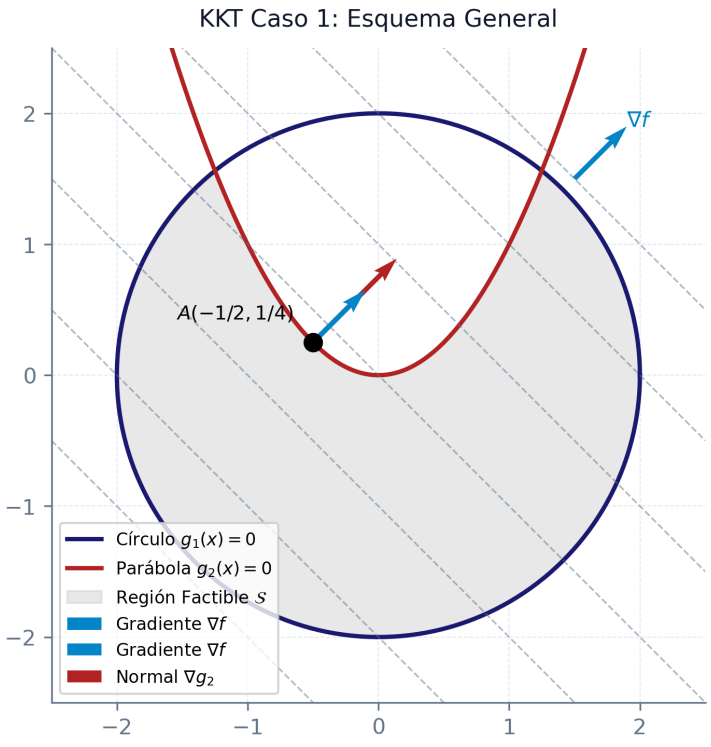

Ejemplo 1: Caso 1 – Análisis de $A(-1/2, 1/4)^T$

- **Multiplicador**: $u_2 = -1 < 0$.
  - Para mínimos ($u_i \geq 0$), se descarta.
  - Para máximos ($u_i \leq 0$), es candidato a máximo local.
- **Factibilidad primal**: $g_1(A) = 1/4 + 1/16 - 4 = -59/16 < 0$ (factible).
- **Segundo orden**: Sobre la parábola activa, la función es $f(t, t^2) = t + t^2$, que presenta un mínimo local en $t = -0.5$.
- **Conclusión**: El punto A **no es un máximo local** (punto de ensilladura restringida).

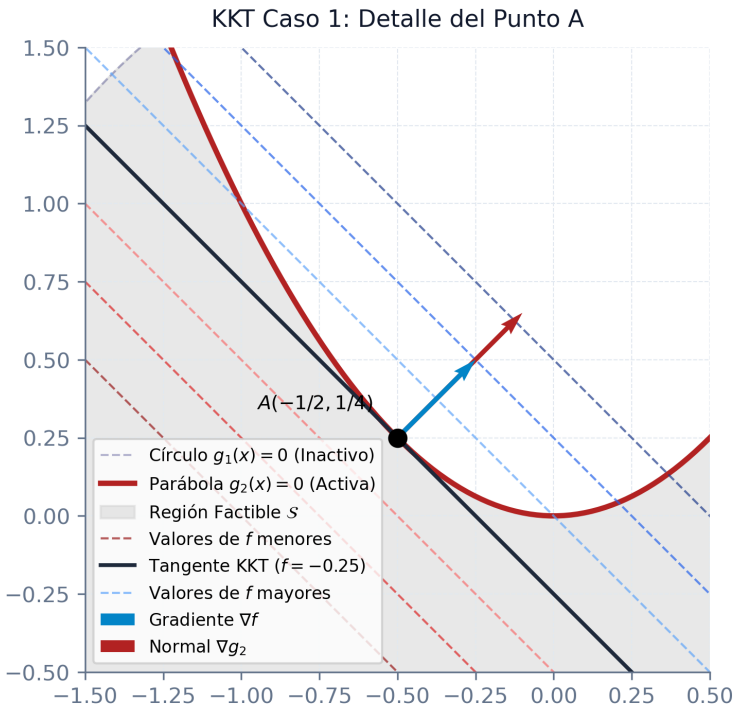

Ejemplo 1: Caso 2 – Parábola inactiva ($u_2 = 0$)

- **Condición**:
  $u_2 = 0 \implies u_1 \neq 0$ (g_1 es activa, $x_1^2 + x_2^2 = 4$).
- **Estacionariedad**:
  $1 + 2u_1 x_1 = 0$ y $1 + 2u_1 x_2 = 0 \implies x_1 = x_2 = -1/(2u_1)$.
- **Coordenadas**:
  $2x_1^2 = 4 \implies x_1 = \pm\sqrt{2}$.
- **Puntos de estudio**:
  $B(-\sqrt{2}, -\sqrt{2})^T$ y $C(\sqrt{2}, \sqrt{2})^T$.

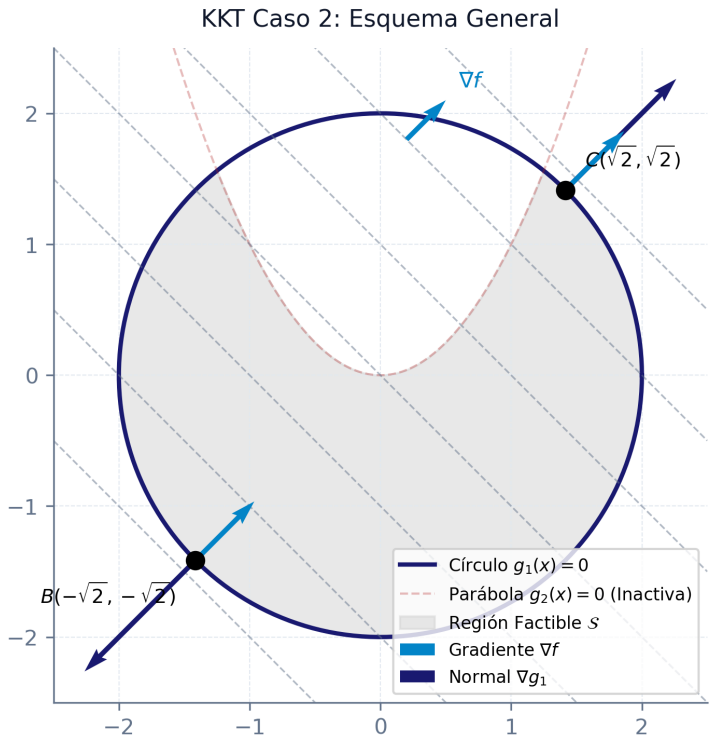

Ejemplo 1: Caso 2 – Análisis de $B(-\sqrt{2}, -\sqrt{2})^T$

- **Multiplicador**: $u_1 = \frac{1}{2\sqrt{2}} > 0 \implies$ candidato a **mínimo**.
- **Factibilidad primal**: $g_2(B) = -(-\sqrt{2})^2 - \sqrt{2} = -2 - \sqrt{2} < 0$ (factible).
- **Resultado**: El punto $B(-\sqrt{2}, -\sqrt{2})^T$ es un candidato KKT válido para mínimo global.
- **Interpretación**: Los gradientes se oponen perfectamente con multiplicador positivo.

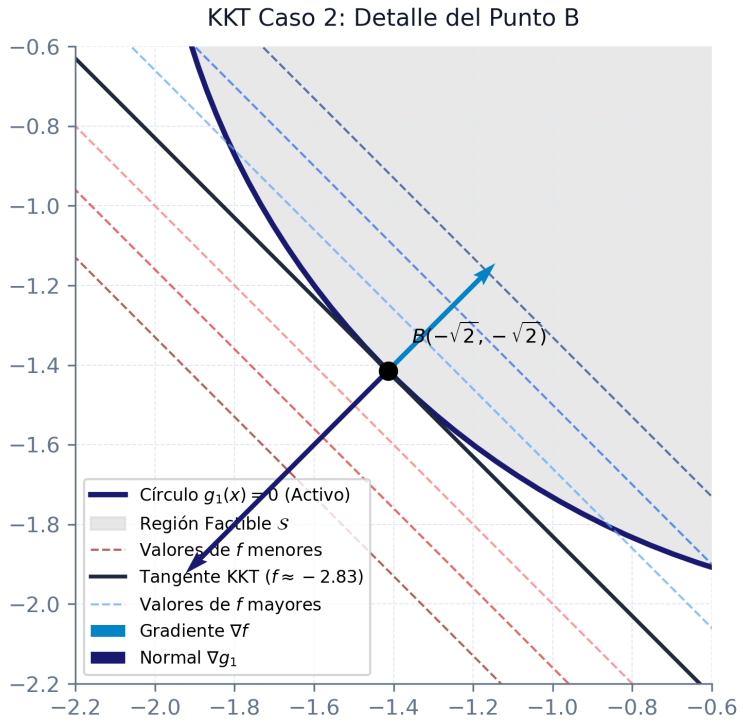

Ejemplo 1: Caso 2 – Análisis de $C(\sqrt{2}, \sqrt{2})^T$

- **Multiplicador**: $u_1 = -\frac{1}{2\sqrt{2}} < 0 \implies$ candidato a **máximo**.
- **Factibilidad primal**: $g_2(C) = -2+\sqrt{2} \approx -0.59 < 0$ (factible).
- **Resultado**: El punto $C(\sqrt{2}, \sqrt{2})^T$ es un candidato KKT válido para máximo global.
- **Interpretación**: Los gradientes apuntan en el mismo sentido con multiplicador negativo.

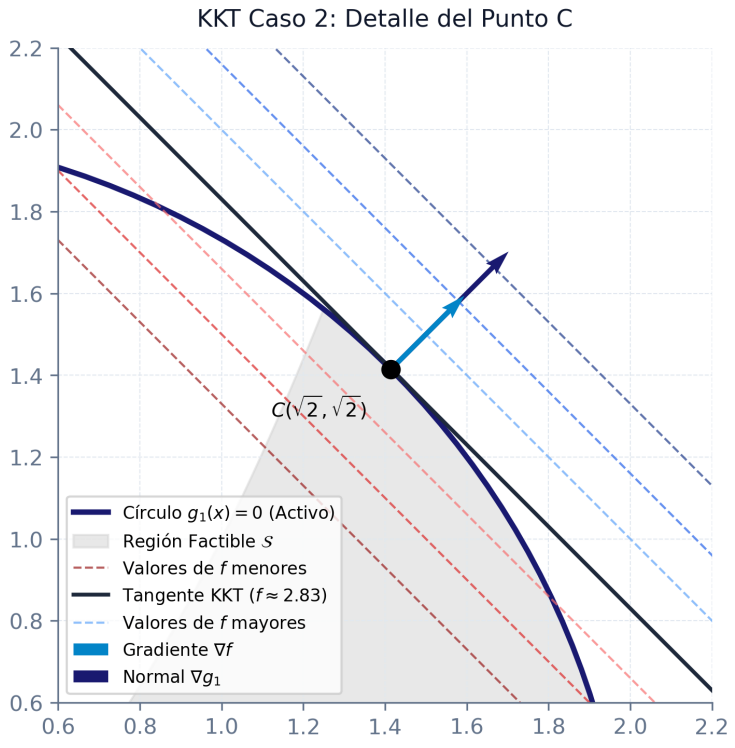

Ejemplo 1: Caso 3 – Ambas restricciones activas

- **Condición**: $g_1(x) = 0$ y $g_2(x) = 0$.
- **Intersección**: $x_1^2 + x_2^2 = 4$ y $x_2 = x_1^2 \implies x_1^4 + x_1^2 - 4 = 0$. $x_1^2 = \frac{-1+\sqrt{17}}{2} \approx 1.56 \implies x_1 \approx \pm 1.25$. $x_2 \approx 1.56$.
- **Puntos de cruce**: $E(1.25, 1.56)^T$ y $D(-1.25, 1.56)^T$.

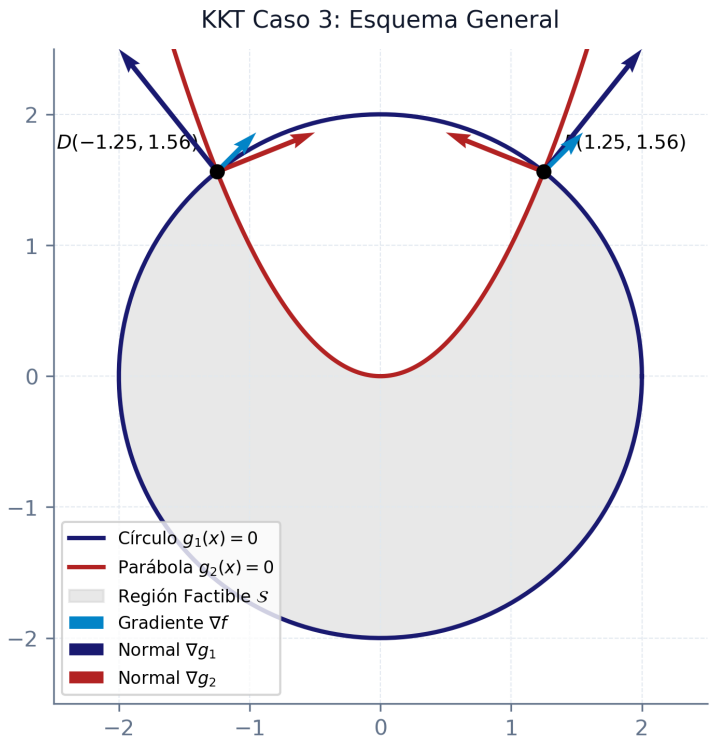

Ejemplo 1: Caso 3 – Análisis de E y D

- **Punto** $E(1.25, 1.56)^T$:
  $u_1 \approx -0.34 < 0$ y
  $u_2 \approx 0.06 > 0$.
  - Signos opuestos: se descarta.
- **Punto** $D(-1.25, 1.56)^T$:
  $u_1 \approx -0.15 < 0$ y
  $u_2 \approx -0.55 < 0$.
  - Ambos negativos: candidato a **máximo local**.
- **Comparación**: $f(D) \approx 0.31$, menor que $f(C) \approx 2.83$ (máximo global).

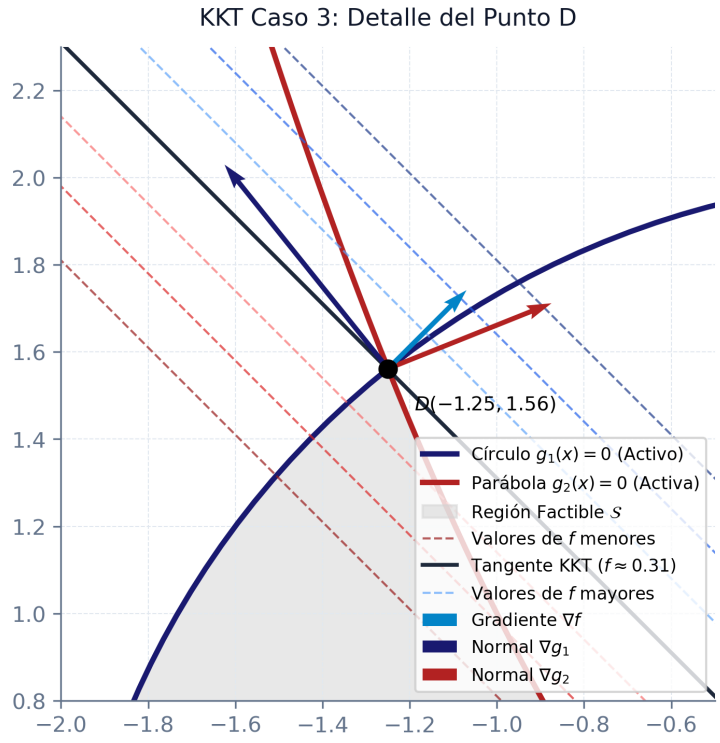

Ejemplo 1: Caracterización y Conclusión

- **Mínimo global**: $B(-\sqrt{2}, -\sqrt{2})^T$ con $f(B) \approx -2.83$.
- **Máximo global**: $C(\sqrt{2}, \sqrt{2})^T$ con $f(C) \approx 2.83$.
- **Máximo local**: $D(-1.25, 1.56)^T$ con $f(D) \approx 0.31$.
- **Verificación suficiente**:
  - f es lineal (convexa/cóncava).
  - g_1 es estrictamente convexa ($H_1 > 0$).
  - g_2 es cóncava ($H_2 \leq 0$). Falla suficiencia en D (pero es máximo gráfico).

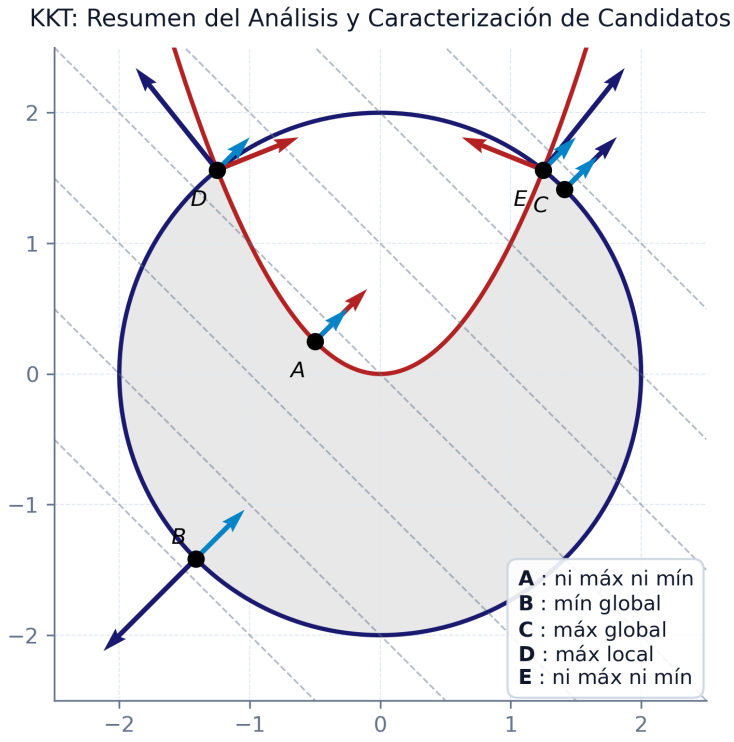

Esquema general de resolución KKT (Pasos 1-2)

Esquema general de resolución KKT

1. **Lagrangiana**: $L(x, u) = f(x) + \sum_{i=1}^{m} u_i g_i(x)$
2. **Sistema KKT** a resolver (estacionariedad y condiciones de optimalidad):
   - **Estacionariedad**: $\nabla_x L(x, u) = 0 \implies \frac{\partial L}{\partial x_j} = 0, \forall j = 1, \dots, n$
   - **Factibilidad primal**: $g_i(x) \leq 0, \forall i = 1, \dots, m$
   - **Holgura complementaria**: $u_i g_i(x) = 0, \forall i = 1, \dots, m$
   - **No negatividad**: $u_i \geq 0, \forall i = 1, \dots, m$ (para mínimos)

Esquema general de resolución KKT (Paso 3)

Esquema general de resolución KKT (Análisis de casos)

3. **Análisis por casos combinatorios**: Para resolver el sistema, para cada restricción i se evalúan las dos ramas posibles de la holgura complementaria:
   - **Caso A (Restricción inactiva)**: $g_i(x) < 0 \implies u_i = 0$.
   - **Caso B (Restricción activa)**: $g_i(x) = 0 \implies u_i \geq 0$.

- Esto da lugar a 2^m posibles combinaciones de restricciones activas e inactivas que deben analizarse algebraicamente de forma independiente.

Esquema general de resolución KKT (Pasos 4-5)

Esquema general de resolución KKT (Filtrado y suficiencia)

4. **Descartar candidatos** que violen la factibilidad primal o que resulten en multiplicadores con signo incorrecto.
5. **Comprobar la cualificación de restricciones (LICQ)** en los candidatos y aplicar las **condiciones suficientes por convexidad**.

- **Maximización**: Exigir que los multiplicadores sean no positivos ($u_i \leq 0$, $\forall i = 1, \ldots, m$).
- **Fritz-John**: Distinguir los casos en los que $u_0 > 0$ (KKT ordinarios) y aquellos en los que $u_0 = 0$ (puntos Fritz-John singulares).

Ejemplo 2: Múltiples restricciones (Planteamiento)

- **Problema de estudio**:

$$\begin{aligned} \min / \max \quad & f(x,y) = \left(x - \frac{9}{4}\right)^2 + (y-2)^2 \\ \text{s.a.} \quad & g_1(x,y) = -x + y^2 \leq 0 \\ & g_2(x,y) = x + y - 6 \leq 0 \\ & g_3(x,y) = -x \leq 0, \quad g_4(x,y) = -y \leq 0 \end{aligned}$$

- **Geometría**: Minimización o maximización de la distancia al punto $(2.25, 2)^T$ sobre un dominio delimitado por una parábola, una recta y los ejes de coordenadas.

Ejemplo 2: Caso 1 – Todas las restricciones inactivas

- **Condición**:
  $u_1 = u_2 = u_3 = u_4 = 0.$
- **Estacionariedad**:

$$2(x - 2.25) = 0 \implies x = 2.25$$

$$2(y - 2) = 0 \implies y = 2$$

- **Punto libre**: $(2.25, 2)^T$.
- **Factibilidad primal**:

$$g_1(2.25, 2) = -2.25+4 = 1.75 > 0$$

- **Resultado**: Se descarta el punto.

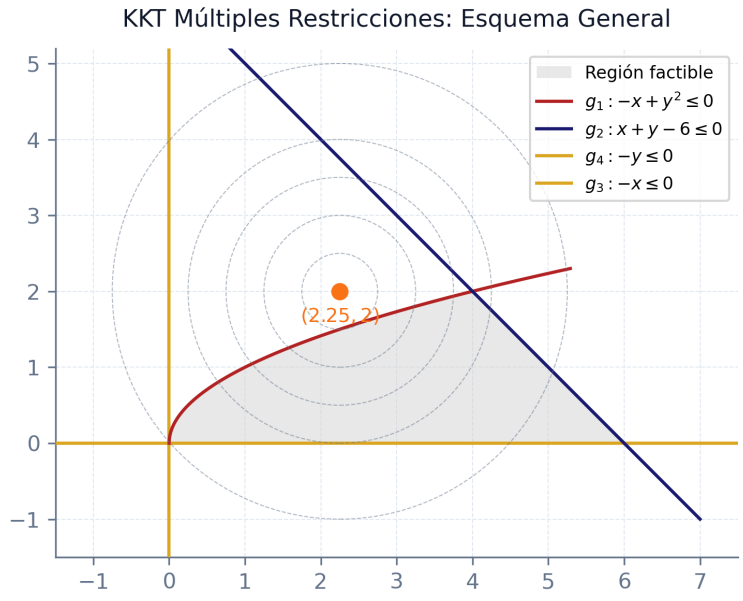

Ejemplo 2: Caso 2 – Una única restricción activa (g_1)

- **Condición**: $u_1 > 0$,
  $u_2 = u_3 = u_4 = 0$
  $(g_1 = 0 \implies x = y^2)$.
- **Estacionariedad**:
  $u_1 = 2x - 4.5$ y
  $2y - 4 + 2yu_1 = 0 \implies$
  $4y^3 - 7y - 4 = 0$.
- **Coordenadas**:
  $y \approx 1.55 \implies x \approx 2.40$.
- **Multiplicador**: $u_1 \approx 0.30 > 0$
  (candidato a mínimo).
- **Factibilidad primal**:
  $g_2(2.40, 1.55) =$
  $2.40 + 1.55 - 6 = -2.05 \leq 0$
  (factible).
- **Candidato**: $(2.40, 1.55)^T$.

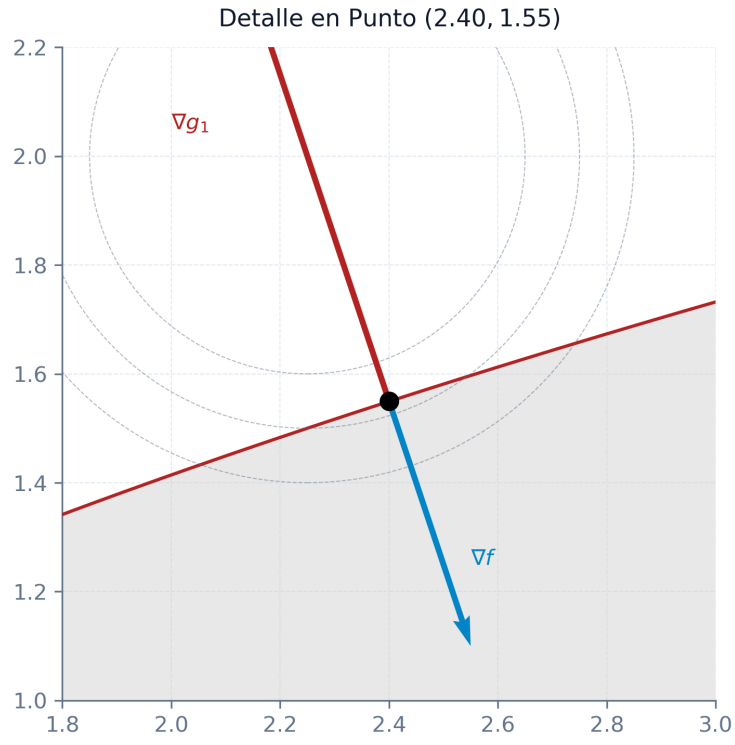

Ejemplo 2: Caso 2 – Una única restricción activa (g_2 y g_3)

- **Subcaso g_2 activa ($u_2 \neq 0,\ u_1 = u_3 = u_4 = 0$)**:
  - Estacionariedad: $x = y + 0.25$ con $x + y = 6 \implies y = 2.875,\ x = 3.125.$
  - Multiplicador: $u_2 = -1.75 < 0$ (candidato a máximo).
  - Factibilidad: $g_1(3.125, 2.875) \approx 5.14 > 0$ (**no factible**). Se descarta.
- **Subcaso g_3 activa ($u_3 \neq 0,\ u_1 = u_2 = u_4 = 0$)**:
  - Estacionariedad: $x = 0,\ y = 2.$
  - Multiplicador: $u_3 = -4.50 < 0$ (candidato a máximo).
  - Factibilidad: $g_1(0, 2) = 4 > 0$ (**no factible**). Se descarta.

Ejemplo 2: Caso 2 – Una única restricción activa (g_4)

- **Condición**: $u_4 > 0$, $u_1 = u_2 = u_3 = 0$ ($g_4 = -y = 0$).
- **Coordenadas**: $y = 0 \implies x = 2.25$.
- **Multiplicador**: $u_4 = -4 < 0$ (candidato a máximo).
- **Factibilidad primal**: $g_1(2.25, 0) = -2.25 \leq 0$ (factible). $g_2(2.25, 0) = 2.25 - 6 = -3.75 \leq 0$ (factible).
- **Candidato**: $(2.25, 0)^T$.

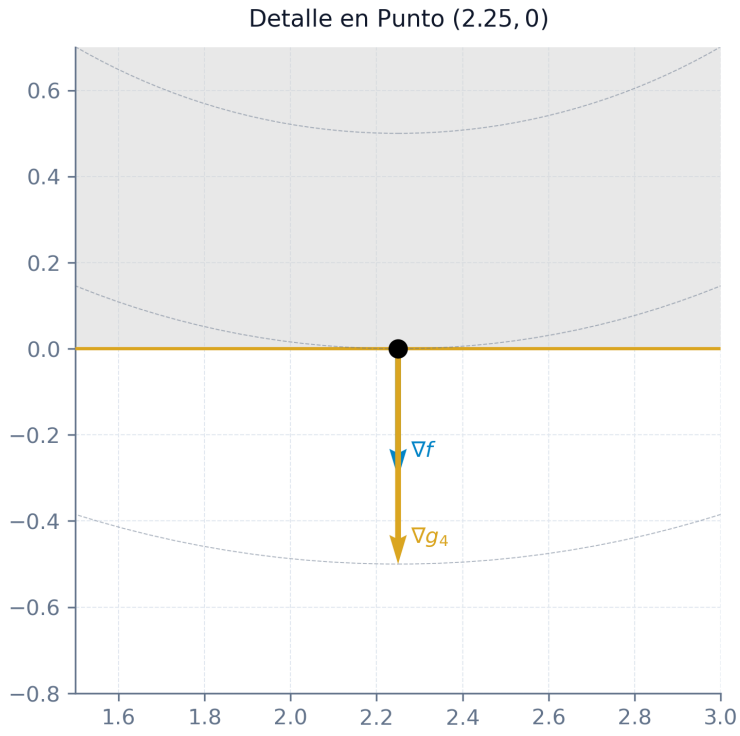

Ejemplo 2: Caso 3 – Dos restricciones activas (g_1, g_2)

- **Condición**:
  $u_1, u_2 \neq 0,\ u_3 = u_4 = 0.$
- **Intersección**: $x = y^2$ y
  $x + y = 6 \implies y^2 + y - 6 = 0 \implies y = 2,\ x = 4.$
- **Multiplicadores**:

$$3.5 - u_1 + u_2 = 0$$

$$4u_1 + u_2 = 0 \implies u_1 = 0.70 > 0,\ \iota$$

- **Resultado**: Signos opuestos $\implies$ **se descarta** (no es candidato a mínimo ni a máximo).

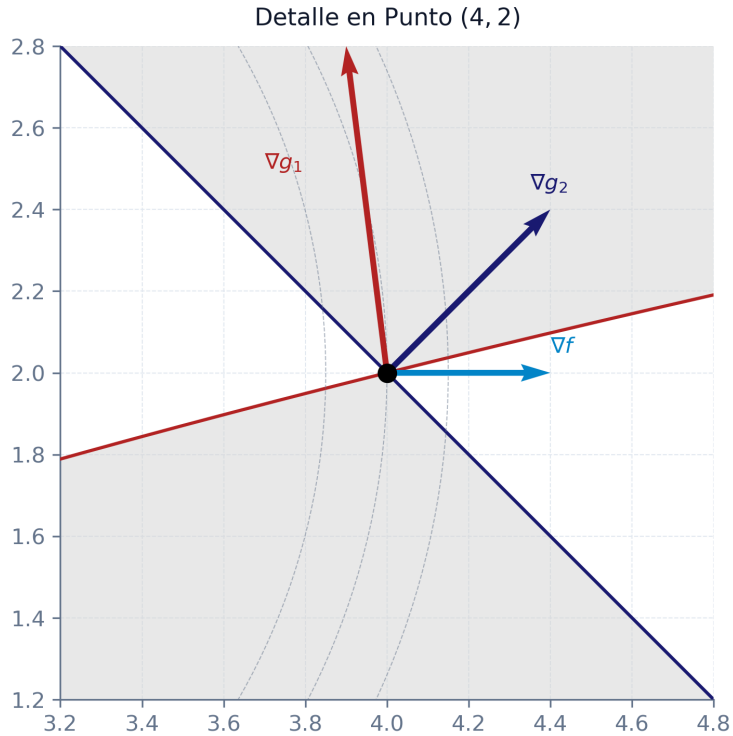

Ejemplo 2: Caso 3 – Dos restricciones activas (g_2, g_4)

- **Condición**: $u_2, u_4 > 0$,
  $u_1 = u_3 = 0$
  $(x + y = 6,\ y = 0 \implies x = 6)$.
- **Multiplicadores**:
  $u_2 = -7.50 < 0$ y
  $u_4 = -11.50 < 0$ (candidato a máximo).
- **Factibilidad primal**:
  $g_1(6, 0) = -6 \leq 0$ (factible).
- **Candidato**: $(6, 0)^T$.

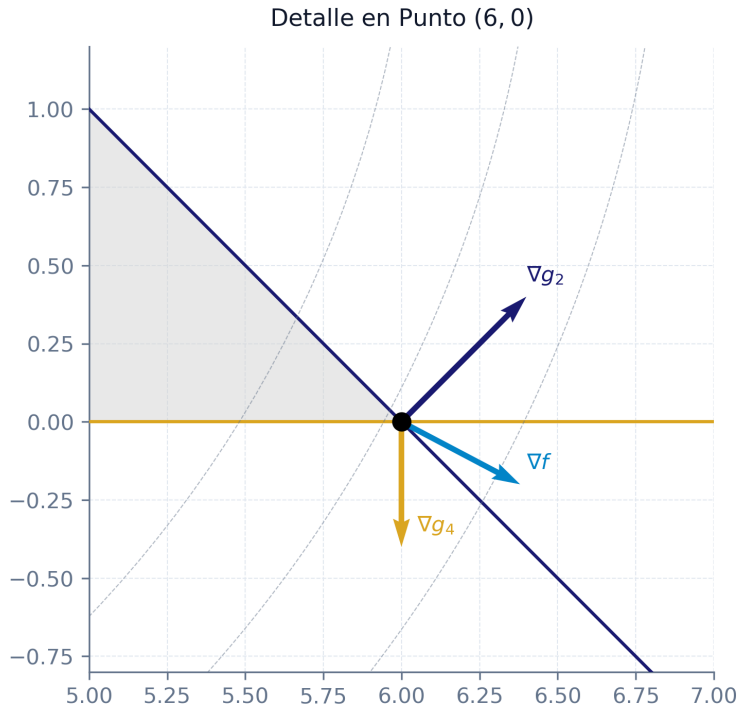

Ejemplo 2: Caso 3 – Dos restricciones activas (g_3, g_4)

- **Condición**: $u_3, u_4 \neq 0,\ u_1 = u_2 = 0 \implies x = 0,\ y = 0.$
- **Multiplicadores**: $u_3 = -4.50 < 0$ y $u_4 = -4.00 < 0$ (candidato a máximo).
- **Fallo de LICQ**: En $(0,0)^T$ la restricción $g_1(0,0) = 0$ también es activa. Los gradientes son dependientes.
- **Resultado**: Punto singular Fritz-John con $u_0 = 0$, candidato a máximo local.

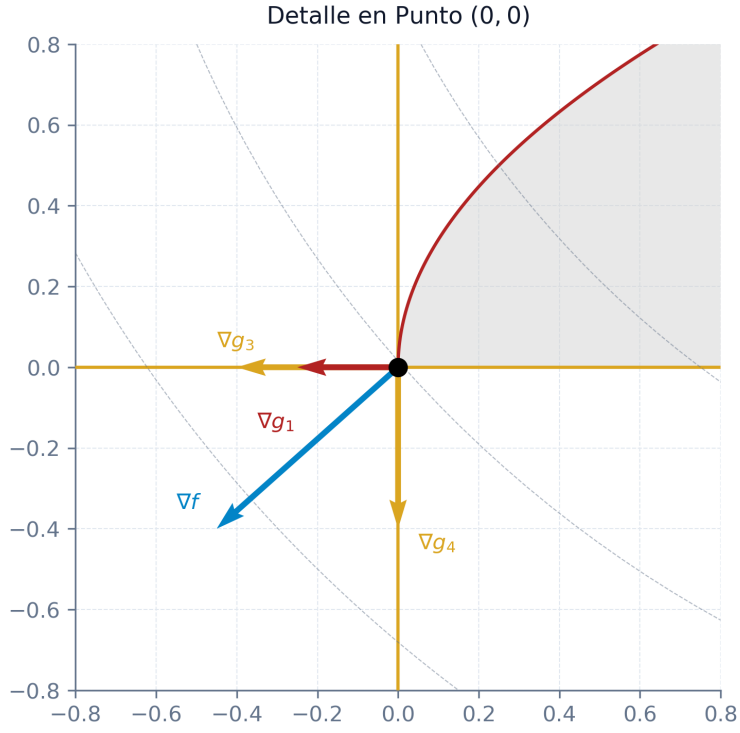

Ejemplo 2: Conclusión y Comparación

- **Mínimos**: El único candidato KKT es $(2.40, 1.55)^T$ con $f(2.40, 1.55) \approx 0.22$. Al ser el objetivo estrictamente convexo, es el **mínimo global**.
- **Máximos**: Evaluamos candidatos $(u_i \leq 0)$:
  - $(2.25, 0)^T \implies f(2.25, 0) = 4.00$
  - $(6, 0)^T \implies f(6, 0) = 18.06$ (**Máximo global**)
  - $(0, 0)^T \implies f(0, 0) = 9.06$ (Singular, máximo local)

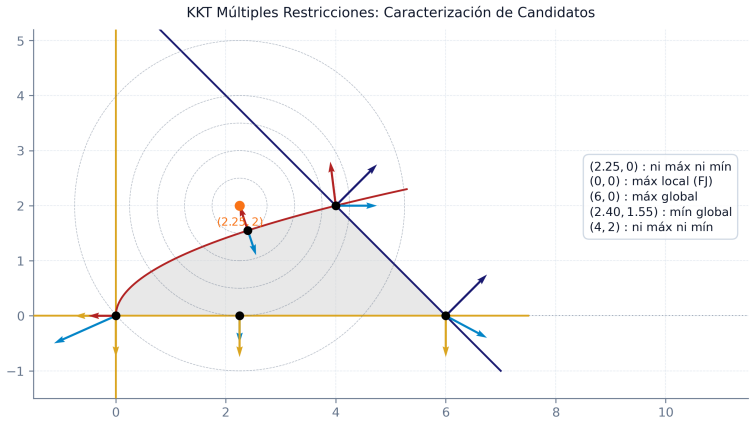

Ejemplo 3: Restricción circular y lineal (Planteamiento)

- **Problema de estudio**:

$$\min / \max \quad f(x,y) = 3x - y$$

$$\text{s.a.} \quad g_1(x,y) = x^2 + y^2 - 1 \leq 0$$

$$g_2(x,y) = -4x - y + 1 \leq 0$$

- **Gradientes**: $\nabla f = (3,-1)^T$
  $\nabla g_1 = (2x, 2y)^T$
  $\nabla g_2 = (-4,-1)^T$
- **Lagrangiana**:

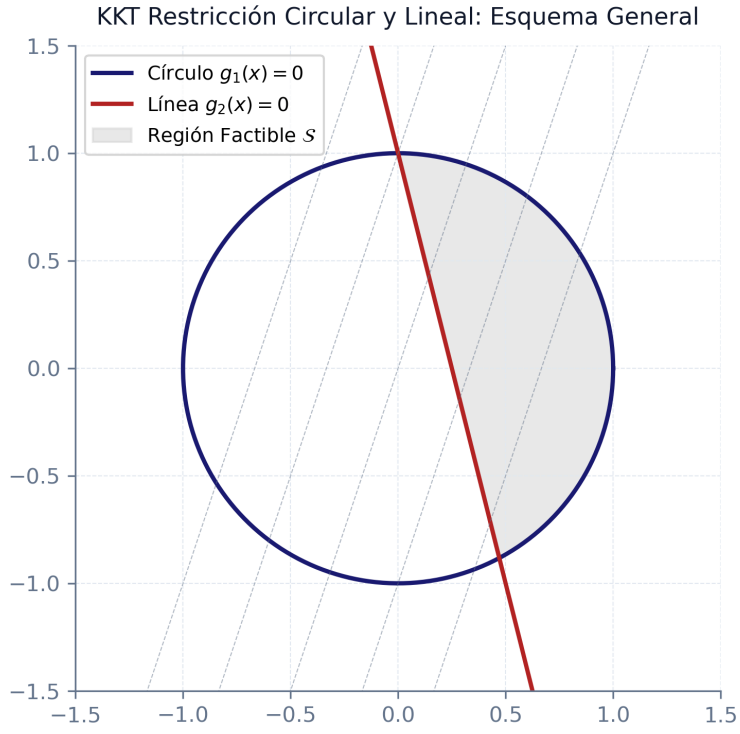

$$L = 3x - y + u_1(x^2 + y^2 - 1) + u_2(-4x - y + 1)$$

Ejemplo 3: Caso 1 – Inactivas y Caso 2 (g_1 activa con $u_1 > 0$)

- **Caso 1 (Inactivas)**:
  Contradicción $3 = 0$ y $-1 = 0$.
- **Caso 2 (g_1 activa, $u_2 = 0$)**:
  $x = -3/(2u_1)$, $y = 1/(2u_1)$
  con $x^2 + y^2 = 1$.

$$\implies u_1 = \pm\sqrt{10}/2 \approx \pm 1.58$$

- **Si $u_1 \approx 1.58 > 0$ (mínimo)**:
  $x \approx -0.95$, $y \approx 0.32$.
- **Factibilidad primal**:
  $g_2(x, y) \approx 4.48 > 0$ (no factible). Se descarta.

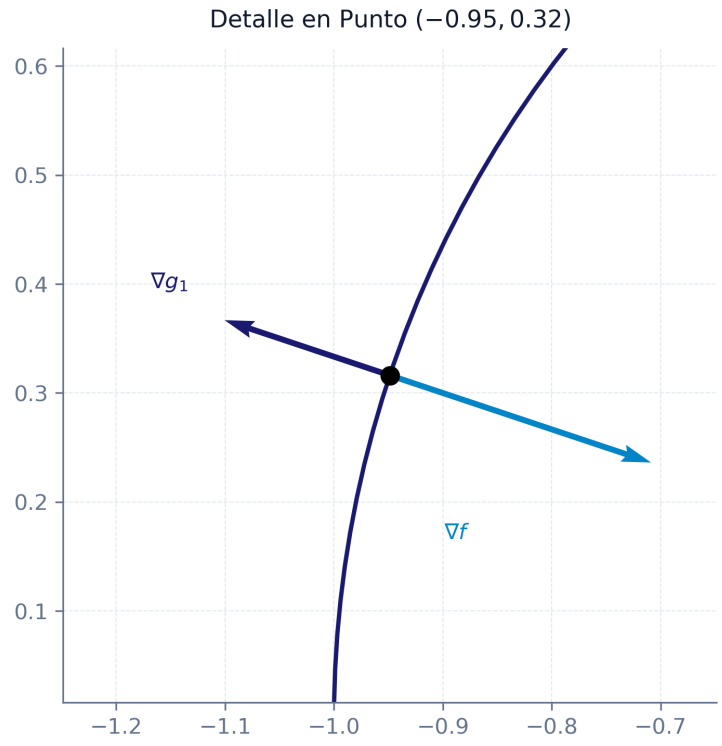

Ejemplo 3: Caso 2 – Solo g_1 activa con $u_1 < 0$

- **Si $u_1 \approx -1.58 < 0$ (máximo)**:

$$x = \frac{3}{\sqrt{10}} \approx 0.95, \quad y = -\frac{1}{\sqrt{10}} \approx -$$

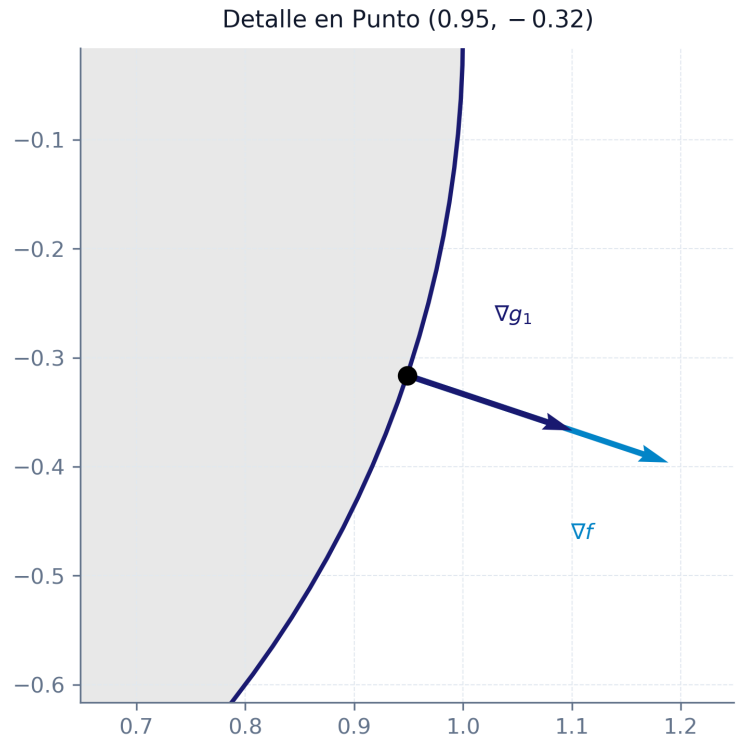

- **Factibilidad primal**:
  $g_2(x, y) \approx -2.48 \leq 0$ (factible).
- **Candidato a máximo**:
  $\left(\frac{3}{\sqrt{10}}, -\frac{1}{\sqrt{10}}\right)^T$ con $u = (-\sqrt{10}/2, 0)^T$.
- *Subcaso g_2 activa, $u_1 = 0$*:
  Contradicción $u_2 = 0.75$ y $u_2 = -1$.

Ejemplo 3: Caso 3 – Ambas restricciones activas (Intersección)

- **Intersección**: $x^2 + y^2 = 1$ y $-4x - y + 1 = 0 \implies y = 1 - 4x$.

  $\implies 17x^2 - 8x = 0 \implies x = 0$ ó x

- **Punto** $P_1(0,1)^T$:
  $3 - 4u_2 = 0 \implies u_2 = 3/4 \geq 0$.
  $-1 + 2u_1 - u_2 = 0 \implies u_1 = 7/8 \geq 0$.
- **Candidato a mínimo**:
  $P_1(0,1)^T$ con $u = (7/8, 3/4)^T$.

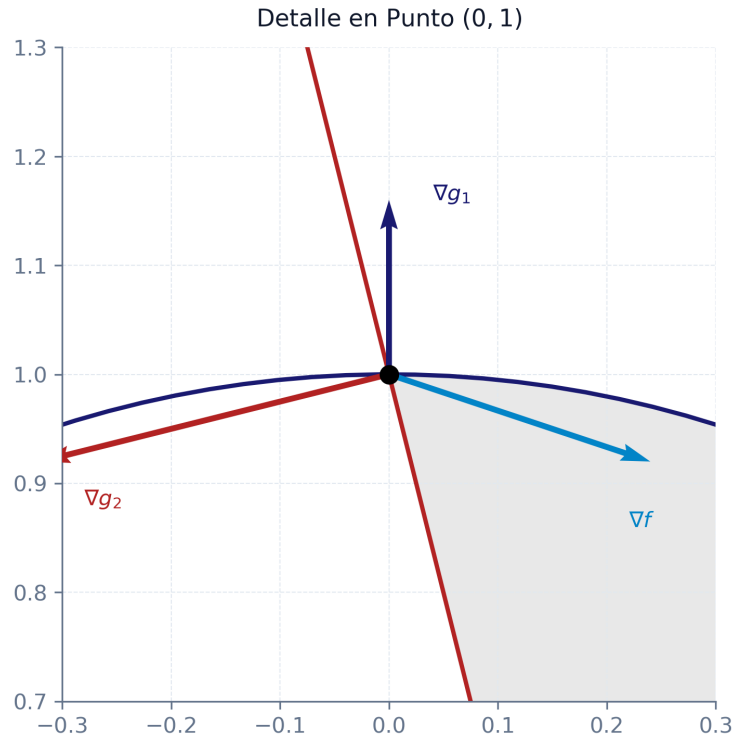

Ejemplo 3: Caso 3 – Intersección (Punto $(8/17, -15/17)^T$)

- **Punto** $P_2(8/17, -15/17)^T$:
  $3 + \frac{16}{17}u_1 - 4u_2 = 0.$
  $-1 - \frac{30}{17}u_1 - u_2 = 0.$
- **Solución**: $u_1 = -7/8 < 0$ y $u_2 = 37/68 > 0$.
- **Conclusión**: Signos opuestos $\Longrightarrow$ se descarta. No es punto KKT de primer orden.

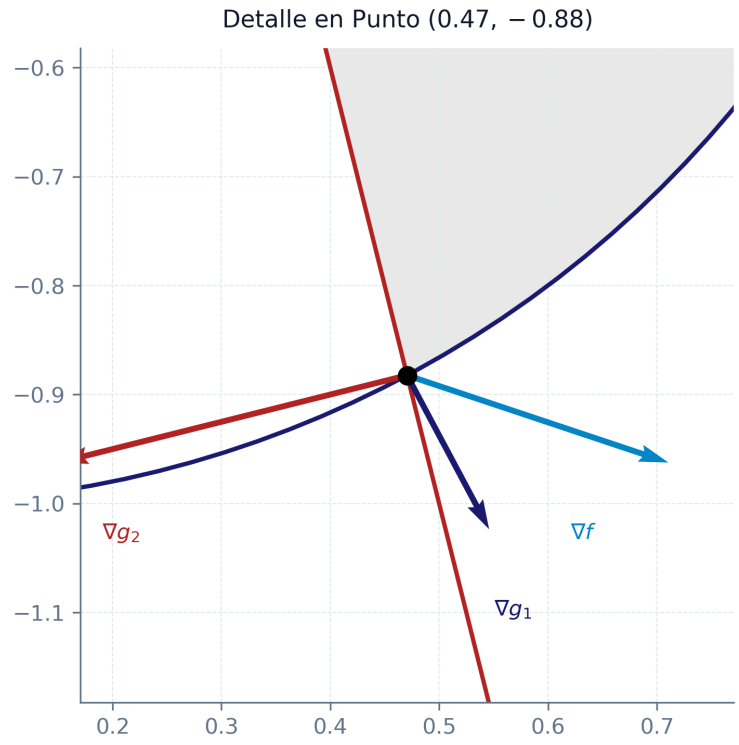

Ejemplo 3: Conclusión y Caracterización

- **Mínimo global**: $(0,1)^T$ con $f(0,1) = -1$.
  - f es lineal (pseudo-convexa).
  - g_1 es estrictamente convexa y g_2 es lineal (convexa).
  - Al tener $u_i \geq 0$, se satisfacen las condiciones suficientes.
- **Máximo global**: $\left(\frac{3}{\sqrt{10}}, -\frac{1}{\sqrt{10}}\right)^T$ con $f(x) \approx 3.16$.
  - f es lineal (pseudo-cóncava) y $u_1 < 0$.

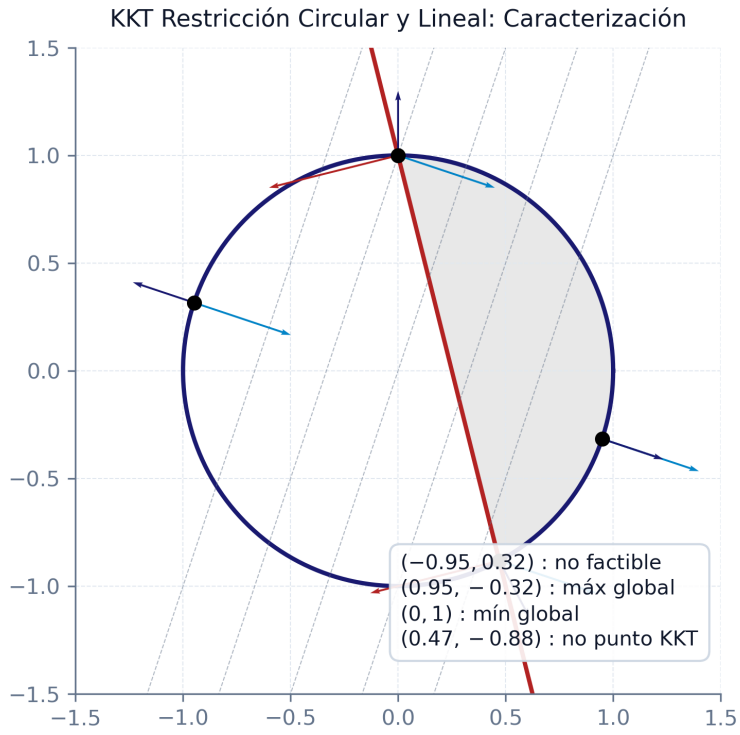

Restricciones de igualdad y desigualdad

Introducción a las restricciones de igualdad

- **Restricciones de igualdad**: Formulación del problema general de optimización con restricciones de igualdad $h_j(x) = 0$, para $j = 1, \ldots, \ell$:

  $$\min_x \{ f(x) \mid x \in \mathcal{X},\ g_i(x) \leq 0,\ i = 1, \ldots, m,\ h_j(x) = 0,\ j = 1, \ldots, \ell$$

- **Movimiento admisible**: A diferencia de las desigualdades que permiten movimientos hacia el interior de la región factible, las restricciones de igualdad obligan a que cualquier dirección admisible permanezca tangente a la hipersuperficie definida por $h_j(x) = 0$.
- **Aproximación lineal**: Localmente, el movimiento admisible debe ser ortogonal a los gradientes de las igualdades.

Cono de direcciones tangentes para igualdades

- **Definición**: Se define el cono de direcciones tangentes al espacio de igualdad en un punto factible $\bar{x}$ como:

$$\mathcal{H}_0(\bar{x}) = \{d \in \mathbb{R}^n \mid \nabla h_j(\bar{x})^T d = 0,\ j = 1, \dots, \ell\}$$

- **Interpretación geométrica**: El cono tangente representa el subespacio vectorial ortogonal a los gradientes de todas las restricciones de igualdad.
- **Intersección con desigualdades**: En problemas con restricciones mixtas, una dirección factible debe pertenecer tanto al cono de restricciones de desigualdad como al cono tangente de igualdades.

Exclusión geométrica generalizada

Exclusión geométrica generalizada

Sea $\bar{x}$ un mínimo local factible de $\min\{f(x) \mid g_i(x) \leq 0,\ i = 1, \ldots, m,\ h_j(x) = 0,\ j = 1, \ldots, \ell\}$ e $\mathcal{I}$ el conjunto activo en $\bar{x}$. Si f, g_i $(i \in \mathcal{I})$ son diferenciables en $\bar{x}$, g_i $(i \notin \mathcal{I})$ son continuas en $\bar{x}$, y h_j son continuamente diferenciables en $\bar{x}$ con gradientes $\nabla h_j(\bar{x})$ linealmente independientes, entonces la intersección de conos es vacía:

$$\mathcal{D}_0(\bar{x}) \cap \mathcal{G}_0(\bar{x}) \cap \mathcal{H}_0(\bar{x}) = \emptyset$$

con $\mathcal{G}_0(\bar{x}) = \{d \mid \nabla g_i(\bar{x})^T d < 0, i \in \mathcal{I}\}$ y $\mathcal{H}_0(\bar{x}) = \{d \mid \nabla h_j(\bar{x})^T d = 0, \forall j\}$.

Condiciones KKT Generales (LICQ)

! Condiciones necesarias de KKT generales

Sea $\bar{x}$ un mínimo local con conjunto activo $\mathcal{J}$ que satisface **LICQ** (los gradientes activos $\{\nabla g_i(\bar{x})\}_{i\in\mathcal{J}}$ y $\{\nabla h_j(\bar{x})\}$ son linealmente independientes). Si f, g_i $(i \in \mathcal{J})$ son diferenciables en $\bar{x}$, g_i $(i \notin \mathcal{J})$ son continuas en $\bar{x}$, y h_j son continuamente diferenciables en $\bar{x}$, existen multiplicadores únicos $u_i \geq 0$ $(i \in \mathcal{J})$ y $v_j \in \mathbb{R}$ (sin restricción de signo) tales que:

$$\nabla f(\bar{x}) + \sum_{i\in\mathcal{J}} u_i \nabla g_i(\bar{x}) + \sum_{j=1}^{\ell} v_j \nabla h_j(\bar{x}) = 0$$

Ejemplo 4: Restricciones mixtas (Planteamiento)

- **Problema de estudio**:

$$\min \quad f(x_1, x_2)$$

$$\text{s.a.} \quad g_1(x) = x_1^2 + x_2^2 - 5 \leq 0$$

$$g_2(x) = -x_1 \leq 0, \quad g_3(x) = -x_2 \leq 0$$

$$h_1(x) = x_1 + x_2 - 3 = 0$$

- **Geometría**: El dominio factible es el segmento de recta comprendido entre los extremos $(1, 2)^T$ y $(2, 1)^T$ en el primer cuadrante.
- **Lagrangiana**:

$$L(x, u, v) = f(x) + u_1(x_1^2 + x_2^2 - 5) - u_2 x_1 - u_3 x_2 + v_1(x_1 + x_2 - 3)$$

Ejemplo 4: Caso A – Distancia al origen ($f_1 = x_1^2 + x_2^2$)

- **Caso A.1 (Interior del segmento, $x_1 \in (1,2)$)**: Con $u_i = 0$, la estacionariedad requiere:

$$2x_1 + v_1 = 0,\ 2x_2 + v_1 = 0 \implies x_1 = x_2$$

  Sustituyendo en h_1:
  $x_1 + x_2 = 3 \implies \mathbf{x}^* = (1.5, 1.5)^T,\ v_1 = -3$ (mínimo KKT, $f_1 = 4.5$).
- **Caso A.2 (Extremos del segmento)**:
  - En $(1,2)^T$ (activas g_1, h_1):
    $2 + 2u_1 + v_1 = 0,\ 4 + 4u_1 + v_1 = 0 \implies u_1 = -1 < 0$ (descartado).
  - En $(2,1)^T$ (activas g_1, h_1): Por simetría, $u_1 = -1 < 0$ (descartado).

Ejemplo 4: Caso B – Distancia a $(3,2)$ $(f_2 = (x_1-3)^2 + (x_2-2)^2)$

- **Caso B.1 (Interior del segmento, $x_1 \in (1,2)$)**: $u_i = 0$.
  Estacionariedad: $2(x_1-3) + v_1 = 0$,
  $2(x_2-2) + v_1 = 0 \implies x_1 = x_2 + 1$.

  $(x_2+1)+x_2 = 3 \implies x = (2,1)^T$ (extremo, se descarta por interi

- **Caso B.2 (Extremos del segmento)**:
  - En $(1,2)^T$: $u_2 = u_3 = 0 \implies u_1 = -2 < 0$ (descartado).
  - En $(2,1)^T$: Activa g_1, h_1. Estacionariedad:

$$\left.\begin{aligned} -2 + 4u_1 + v_1 = 0 \\ -2 + 2u_1 + v_1 = 0 \end{aligned}\right\} \implies u_1 = 0 \geq 0,\ v_1 = 2$$

  - $(2,1)^T$ es el candidato a **mínimo local** ($f_2 = 2.0$).

Ejemplo 4: Resumen y Representación Gráfica

- **Función f_1 (Distancia al origen)**:
  - Mínimo KKT e interior en $(1.5, 1.5)^T$ con $f_1 = 4.5$.
  - Los extremos de la frontera circular están descartados $(u_1 = -1 < 0)$.
- **Función f_2 (Distancia a $(3, 2)$)**:
  - No hay estacionarios interiores.
  - Mínimo KKT y global en el extremo circular $(2, 1)^T$ con $f_2 = 2.0$ $(u_1 = 0 \geq 0)$.

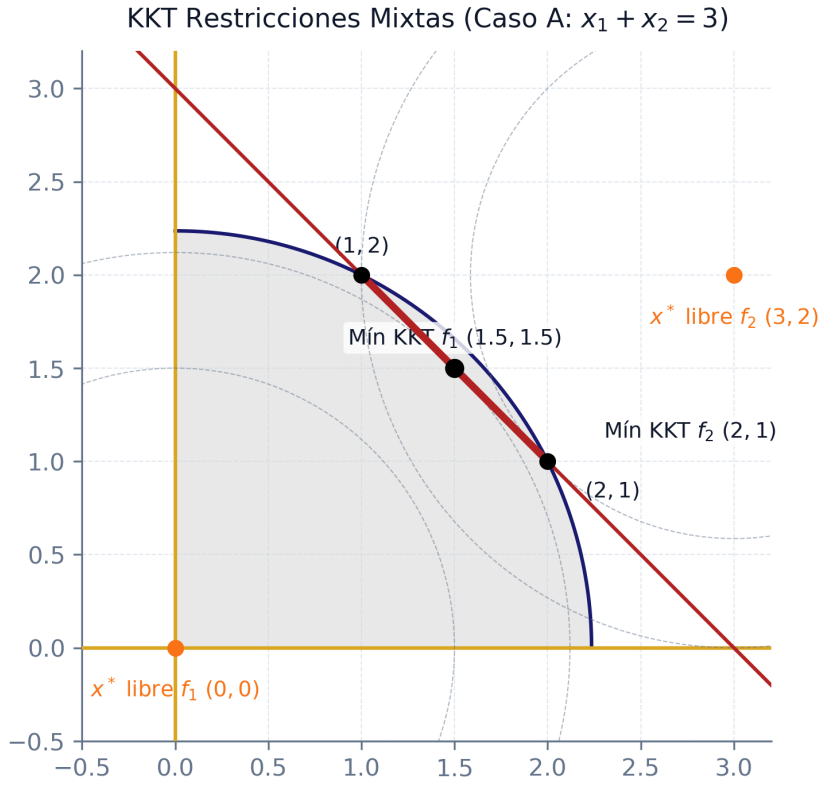

Ejemplo 5: Modificación de frontera (Planteamiento)

- **Recta frontera asimétrica**:

$$h_1(x) = x_1 + 2x_2 - 4 = 0$$

- **Dominio factible**: Sustituyendo $x_1 = 4 - 2x_2$ en la circunferencia:

$$(4-2x_2)^2+x_2^2 \leq 5 \implies 5x_2^2-16x_2+11 \leq 0 \implies x_2 \in [1, 2.2]$$

- **Primer cuadrante**: Exigiendo $x_1 \geq 0 \implies 4 - 2x_2 \geq 0 \implies x_2 \leq 2$.
- **Extremos**: El segmento factible real queda delimitado por los extremos $(2, 1)^T$ y $(0, 2)^T$.

Ejemplo 5: Caso A – Distancia al origen ($f_1 = x_1^2 + x_2^2$)

- **Caso A.1 (Interior del segmento, $x_2 \in (1,2)$)**: $u_i = 0$.
  Estacionariedad:

$$2x_1 + v_1 = 0, \quad 2x_2 + 2v_1 = 0 \implies x_2 = 2x_1$$

  Sustituyendo en h_1:

$$x_1 + 2(2x_1) = 4 \implies x^* = (0.8, 1.6)^T, \; v_1 = -1.6$$

  Satisface KKT y es el candidato a **mínimo local** ($f_1 = 3.2$).
- **Caso A.2 (Extremos del segmento)**:
  - En $(2,1)^T$: Activa $g_1, h_1 \implies u_1 = -1 < 0$ (descartado).
  - En $(0,2)^T$: Activa g_2, h_1 ($x_1 = 0$). Estacionariedad:

$$0 - u_2 + v_1 = 0 \text{ y } 4 + 2v_1 = 0 \implies v_1 = -2 \implies u_2 = -2 < 0 \quad \text{(desc}$$

Ejemplo 5: Caso B – Distancia a $(3,2)$ $(f_2 = (x_1-3)^2 + (x_2-2)^2)$

- **Caso B.1 (Interior del segmento, $x_2 \in (1,2)$)**: $u_i = 0$.
  Estacionariedad: $2(x_1-3) + v_1 = 0$,
  $2(x_2-2) + 2v_1 = 0 \implies x_2 = 2x_1 - 4$.

  $x_1 + 2(2x_1 - 4) = 4 \implies x_1 = 2.4,\ x_2 = 0.8 < 1$ (no factible, desc

- **Caso B.2 (Extremos del segmento)**:
  - En $(2,1)^T$: Activa g_1, h_1. Estacionariedad:

$$\left.\begin{aligned} -2 + 4u_1 + v_1 &= 0 \\ -2 + 2u_1 + 2v_1 &= 0 \end{aligned}\right\} \implies u_1 = 1/3 \geq 0,\ v_1 = 2/3$$

    Satisface KKT y es el candidato a **mínimo local** ($f_2 = 2.0$).
  - En $(0,2)^T$: Activa $g_2, h_1 \implies u_2 = -6 < 0$ (descartado).

Ejemplo 5: Resumen y Representación Gráfica

- **Función f_1 (Distancia al origen)**:
  - Mínimo KKT e interior en $(0.8, 1.6)^T$ con $f_1 = 3.2$.
  - Los extremos de la frontera están descartados ($u_1 < 0$ y $u_2 < 0$).
- **Función f_2 (Distancia a $(3, 2)$)**:
  - No hay estacionarios interiores factibles.
  - Mínimo KKT y global en el extremo circular $(2, 1)^T$ con $f_2 = 2.0$ ($u_1 = 1/3 \geq 0,\ v_1 = 2/3$).

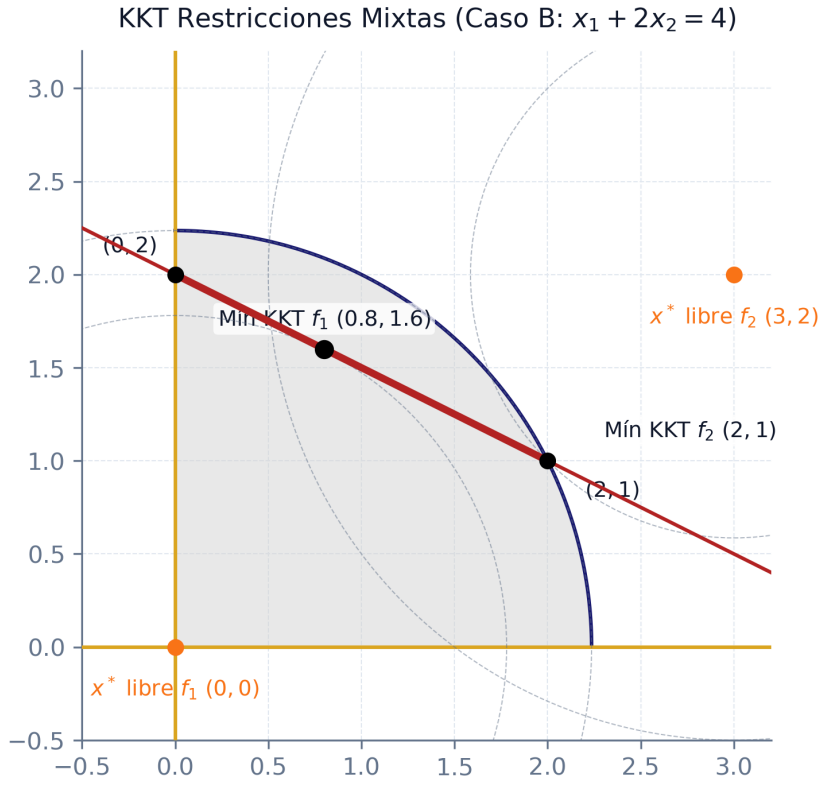

Tema 5: Programación lineal y cuadrática

Optimización y Análisis de Redes

Víctor Aceña Gil - Antonio Alonso Ayuso

2026-08-03

Objetivos de aprendizaje

1. **Deducir y justificar**: La equivalencia entre los multiplicadores KKT de un problema de programación lineal y las variables óptimas de su problema dual asociado.
2. **Demostrar formalmente**: El teorema de dualidad débil en programación lineal y deducir sus consecuencias sobre el salto dual y la no acotación.
3. **Interpretar económicamente**: Las variables duales como precios sombra (*shadow prices*) de los términos independientes.
4. **Clasificar los tipos de óptimos**: En programación lineal atendiendo a la unicidad, degeneración y acotación tanto del problema primal como del dual.
5. **Formular el sistema KKT**: Para problemas de programación cuadrática (QP) en forma matricial.
6. **Aplicar el algoritmo del Símplex de Wolfe**: (Regla de entrada restringida) para resolver de forma exacta problemas cuadráticos convexos.

Programación lineal (LP)

Introducción a la programación lineal

La **Programación Lineal (LP)** representa la piedra angular de la optimización matemática moderna y de la investigación operativa.

- **Definición**: Consiste en la optimización (minimización o maximización) de un criterio de rendimiento lineal expresado por un vector de costes $c \in \mathbb{R}^n$, sobre un conjunto de soluciones factibles delimitado por hiperplanos y semiespacios afines.
- **Poliedro convexo**: Desde una perspectiva geométrica, el conjunto factible de un problema de programación lineal constituye un poliedro convexo (un politopo si está acotado).

Propiedades geométricas fundamentales de la LP

Como consecuencia directa de la convexidad del conjunto y de la linealidad de la función objetivo, la programación lineal posee dos propiedades fundamentales:

1. **Ausencia de óptimos locales disjuntos**: Todo mínimo local es automáticamente un mínimo global.
2. **Teorema Fundamental de la LP**: Si el problema admite solución óptima finita y la región factible posee al menos un punto extremo (vértice), existe al menos un **vértice extremo** del poliedro donde se alcanza dicho óptimo global.

Geometría del conjunto factible poliédrico

- **Bordes poliédricos**: La región factible poliédrica tiene como bordes las restricciones afines activas.
- **Desplazamiento de curvas de nivel**: La función objetivo desplaza sus curvas de nivel hiperplánicas en la dirección de máximo descenso dictada por el vector gradiente del coste c.

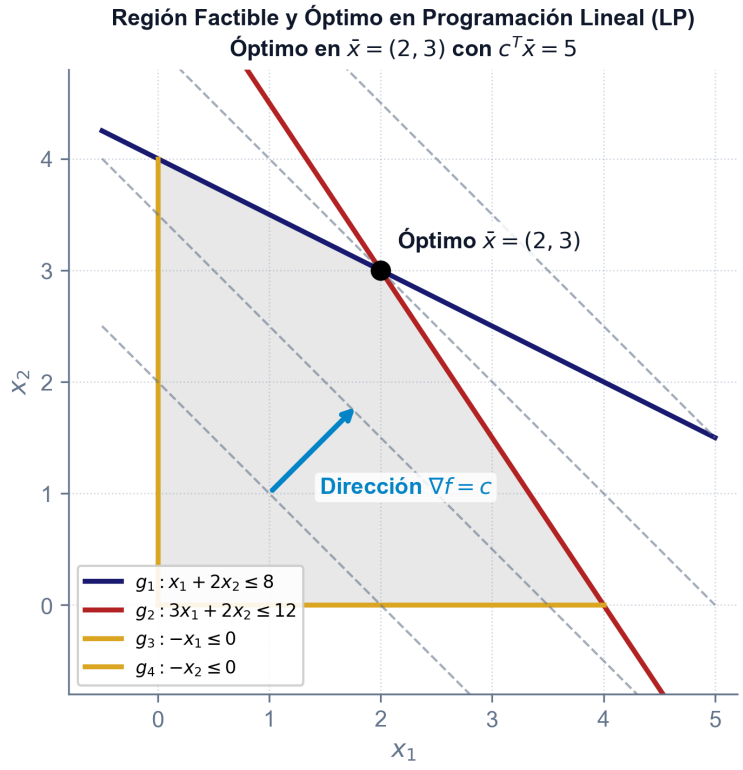

Dualidad en programación lineal

Concepto y perspectiva dual en programación lineal

A todo problema de programación lineal (**problema primal**), se le asocia de forma simétrica e involutiva otro problema lineal denominado **problema dual**.

Problema Primal (Asignación):

- **Objetivo**: Asignar niveles de actividad para minimizar un coste total (o maximizar un beneficio).
- **Restricciones**: Sujeto a restricciones de términos independientes.

Problema Dual (Valoración):

- **Objetivo**: Determinar la valoración económica óptima de dichos términos independientes.
- **Restricciones**: Garantizar que el valor atribuido no supere los costes o beneficios marginales.

Formulación canónica del par primal-dual

El problema primal original (P) se formula en su forma canónica de minimización como:

Problema Primal (P):

$$\begin{aligned} \min_{x \in \mathbb{R}^n} \quad & c^T x \\ \text{sujeto a} \quad & Ax \geq b \\ & x \geq 0 \end{aligned}$$

Problema Dual (D):

$$\begin{aligned} \max_{w \in \mathbb{R}^m} \quad & b^T w \\ \text{sujeto a} \quad & A^T w \leq c \\ & w \geq 0 \end{aligned}$$

- **Involución simétrica**: El problema dual del problema dual es exactamente el problema primal original.

Teorema de dualidad débil en LP

Dualidad débil en LP

Para cualquier solución factible x del problema primal (P) y cualquier solución factible w del problema dual (D), el valor de la función objetivo dual es una cota inferior del valor de la función objetivo primal:

$$b^T w \leq c^T x$$

Consecuencias fundamentales de la dualidad débil

Consecuencias de la desigualdad $b^T w \leq c^T x$

1. **Criterio de Certificación de Optimalidad (Salto Dual Nulo)**: Si para algún par de soluciones factibles x^* (primal) y w^* (dual) el valor de las respectivas funciones objetivo coincide:

$$b^T w^* = c^T x^*$$

   entonces x^* es una **solución óptima del primal (P)** y w^* es una **solución óptima del dual (D)**.
2. **No Acotación e Infactibilidad Recíproca**: Si uno de los dos problemas posee una solución **no acotada**, el otro problema **no tiene solución** (su región factible es vacía).

Condiciones KKT en programación lineal

Fundamento analítico de KKT en LP

Expresamos el problema primal (P) en su formato estándar de minimización con restricciones de desigualdad afines reordenadas en la forma $g_i(x) \leq 0$:

$$\begin{aligned} \min_{x \in \mathbb{R}^n} \quad & c^T x && (1) \\ \text{sujeto a} \quad & b - Ax \leq 0 && (2) \\ & -x \leq 0 && (3) \end{aligned}$$

- **Variables de decisión**: $x = (x_1, \ldots, x_n)^T \in \mathbb{R}^n$.
- **Vector de costes**: $c = (c_1, \ldots, c_n)^T \in \mathbb{R}^n$.
- **Matriz de coeficientes**: $A \in \mathbb{R}^{m \times n}$ (con filas a^i).
- **Vector de disponibilidades**: $b = (b_1, \ldots, b_m)^T \in \mathbb{R}^m$.

Propiedades analíticas y suficiencia de KKT en LP

Propiedades analíticas y suficiencia de KKT en LP

1. **Convexidad del dominio y la función**: La región factible S es un poliedro convexo intersección de semiespacios afines. La función objetivo $f(x) = c^T x$ es afín (convexa), garantizando que cualquier mínimo local sea un óptimo global.
2. **Suficiencia de las condiciones KKT**: Dado que las restricciones son afines, las cualificaciones de restricciones se satisfacen de forma trivial en todo el espacio. Por tanto, las condiciones KKT son **necesarias y suficientes** para la optimización global.

Gradientes de la función objetivo y restricciones

Calculamos los gradientes individuales de la función objetivo y restricciones:

- **Gradiente de la función objetivo**:

$$\nabla f(x) = c$$

- **Gradientes de las m restricciones generales de desigualdad**:

$$\nabla g_i(x) = -(a^i)^T, \quad i = 1, \dots, m$$

- **Gradientes de las n restricciones de no negatividad**:

$$\nabla g_{m+j}(x) = -e^j, \quad j = 1, \dots, n$$

Función Lagrangiana del problema lineal

Asociamos multiplicadores $u = (u_1, \dots, u_m)^T \geq 0$ a las restricciones afines generales y $v = (v_1, \dots, v_n)^T \geq 0$ a la no negatividad:

$$L(x, u, v) = c^T x + \sum_{i=1}^{m} u_i (b_i - a^i x) + \sum_{j=1}^{n} v_j (-x_j) = c^T x + u^T (b - Ax) - v^T$$

La condición de estacionariedad exige que el gradiente de la Lagrangiana se anule respecto a x:

$$\nabla_x L(x, u, v) = c - A^T u - v = 0$$

Conjunto completo de condiciones KKT para LP

Un triplete de vectores (x, u, v) satisface las condiciones KKT si y solo si verifica de forma simultánea:

1. **Factibilidad primal**: $Ax \geq b, \qquad x \geq 0$
2. **Factibilidad dual y estacionariedad**:
   $c - A^T u - v = 0 \quad$ con $u \geq 0$ y $v \geq 0$
3. **Holgura complementaria**:

$$u_i(b_i - a^i x) = 0, \quad \forall i = 1, \ldots, m$$
$$v_i x_i = 0, \quad \forall i = 1, \ldots, n$$

Estructura matricial y equivalencia dual de KKT

Componentes clave del sistema KKT

- **Factibilidad primal**: $Ax \geq b, x \geq 0 \implies$ Garantiza la pertenencia de x al poliedro factible del problema primal (P).
- **Factibilidad dual (estacionariedad)**: $c - A^T u - v = 0$ con $u \geq 0, v \geq 0 \implies v = c - A^T u \geq 0 \iff A^T u \leq c, u \geq 0$ (Factibilidad en D).
- **Holgura complementaria**: $u_i(b_i - a^i x) = 0, v_i x_i = 0 \implies$ Vincula la holgura de las restricciones generales con su valoración marginal dual.

Comparación de formulaciones primales y duales

Situando en paralelo la formulación canónica primal y dual:

$$\text{Primal (P):} \quad \begin{array}{ll} \min\limits_{x \in \mathbb{R}^n} & c^T x \\ \text{sujeto a} & Ax \geq b \\ & x \geq 0 \end{array} \qquad \text{Dual (D):} \quad \begin{array}{ll} \max\limits_{w \in \mathbb{R}^m} & b^T w \\ \text{sujeto a} & A^T w \leq c \\ & w \geq 0 \end{array}$$

- La factibilidad primal de KKT asegura que x es factible en (P).
- La estacionariedad y no negatividad de KKT aseguran que u es factible en (D).

Factibilidad dual de los multiplicadores KKT

Despejando v de la condición de estacionariedad:

$$\left.\begin{array}{r} c - A^T u - v = 0 \\ u, v \geq 0 \end{array}\right\} \implies \left.\begin{array}{r} v = c - A^T u \\ u, v \geq 0 \end{array}\right\} \implies \begin{array}{r} c - A^T u \geq 0 \\ u \geq 0 \end{array} \iff A$$

- Este desarrollo demuestra que el vector de multiplicadores KKT $u \in \mathbb{R}^m$ **es automáticamente una solución factible para el problema dual (D)**.

Salto dual nulo y relaciones KKT (Parte I)

Para comparar los valores de la función objetivo primal $c^T x$ y dual $b^T u$ en un punto KKT:

1. **Premultiplicación de estacionariedad**:
   Premultiplicamos la ecuación de estacionariedad $c - A^T u - v = 0$ por la izquierda por el vector fila $x^T \geq 0$:

$$x^T(c - A^T u - v) = 0$$

2. **Desarrollo algebraico**:

$$c^T x - x^T A^T u - x^T v = 0 \iff c^T x - u^T A x - v^T x = 0 \qquad (4)$$

Salto dual nulo y relaciones KKT (Parte II)

3. **Agregación de holguras complementarias**:
   Sumando las condiciones de holgura complementaria sobre todas las componentes:

$$\sum_{i=1}^{m} u_i(b_i - a^i x) = 0 \implies u^T b - u^T A x = 0 \implies b^T u = u^T A x$$

$$\sum_{i=1}^{n} v_i x_i = 0 \implies v^T x = 0$$

4. **Sustitución directa en la ecuación (4)**:
   Sustituyendo las identidades $u^T A x = b^T u$ y $v^T x = 0$ en la relación de estacionariedad (4):

$$c^T x - b^T u - 0 = 0 \iff c^T x = b^T u$$

   demostrando que el salto dual $(c^T x - b^T u)$ es exactamente cero.

Certificación de optimalidad mediante KKT

! Certificación de optimalidad mediante KKT

Dada una solución (x, u, v) que satisface las condiciones KKT de un problema lineal:

1. **Factibilidad primal**: x es factible para (P).
2. **Factibilidad dual**: u es factible para (D).
3. **Salto dual nulo**: $c^T x = b^T u$.

Conclusión: En virtud del Teorema de Dualidad Débil, x **es una solución óptima global del primal (P)** y u **es una solución óptima global del dual (D)**.

Precios sombra e interpretación económica

Significado económico de los multiplicadores KKT

En planificación de producción:

- **Precios sombra (*shadow prices*)**:
  Los multiplicadores duales u_i^* representan el valor marginal de los términos independientes:

$$u_i^* = \frac{\partial(c^T x^*)}{\partial b_i}$$

- **Variación de la función objetivo**: Mide la tasa instantánea de variación del valor óptimo ante un incremento marginal unitario en b_i.

Regla de asignación de términos independientes y holgura complementaria

La condición de holgura complementaria $u_i^*(b_i - a^i x^*) = 0$ formaliza una regla económica intuitiva:

- **Restricción inactiva o excedentaria**: Si en el óptimo $a^i x^* < b_i \implies b_i - a^i x^* > 0$, existe superávit del término independiente i. Aumentar la disponibilidad de un término independiente del cual ya se dispone de excedente no genera beneficio adicional ni reduce el coste óptimo. Por tanto, su valor marginal o precio sombra es nulo $(u_i^* = 0)$.
- **Restricción activa o limitante**: Si $u_i^* > 0$, la restricción limita el espacio factible, por lo que debe satisfacerse como igualdad estricta en el óptimo $(b_i - a^i x^* = 0)$.

Clasificación de óptimos y relaciones de dualidad

Caracterización teórica de los tipos de solución

La geometría del poliedro factible S y la independencia lineal de restricciones activas clasifican las soluciones según:

1. **Finitud y existencialidad**: Solución óptima finita, problema no acotado ($f \to -\infty$), o problema no factible ($S = \emptyset$).
2. **Unicidad frente a multiplicidad**: Solución única en un vértice o múltiples soluciones óptimas sobre una arista o cara de dimensión $d \geq 1$.

Degeneración primal y dual

3. **Degeneración primal y dual**:
   - **Degeneración primal**: Es no degenerada si se cortan exactamente n restricciones activas independientes (cumpliendo LICQ). Es **degenerada** si convergen más de n restricciones activas (sobredeterminación geométrica), admitiendo infinitos multiplicadores KKT válidos.
   - **Degeneración dual**: Es degenerada si presenta al menos un multiplicador dual nulo ($u_i^* = 0$) asociado a una restricción primal estrictamente activa ($b_i - a^i x^* = 0$).

Proposición: Equivalencia entre degeneración y múltiples óptimos

Proposición: Equivalencia entre degeneración y múltiples óptimos

Dado un problema de optimización lineal y su correspondiente problema dual asociado, uno de los dos problemas posee una solución óptima finita **degenerada** si y solo si el otro problema posee **múltiples puntos óptimos**.

Matriz de correspondencia primal-dual

Estado del Problema Primal	Estado del Problema Dual Asoci
Óptimo Único No Degenerado	Óptimo Único No Degenerado
Óptimo Único Degenerado	Múltiples Soluciones Óptimas
Múltiples Soluciones Óptimas	Óptimo Único Degenerado
No Acotado ($f \to -\infty$)	No Factible (Región Dual Vacía)
No Factible (Región Primal Vacía)	No Factible o No Acotado

Ejemplo: Análisis por casos de las condiciones KKT en LP

Caso 1: Solución óptima finita única no degenerada

Formulación:

$$
\begin{aligned}
\min \quad & -x-2y \\
\text{s.a.} \quad & x+y-4 \leq 0 \quad (g_1) \\
& -x+y-2 \leq 0 \quad (g_2) \\
& 2x+y-7 \leq 0 \quad (g_3) \\
& x, y \geq 0
\end{aligned}
$$

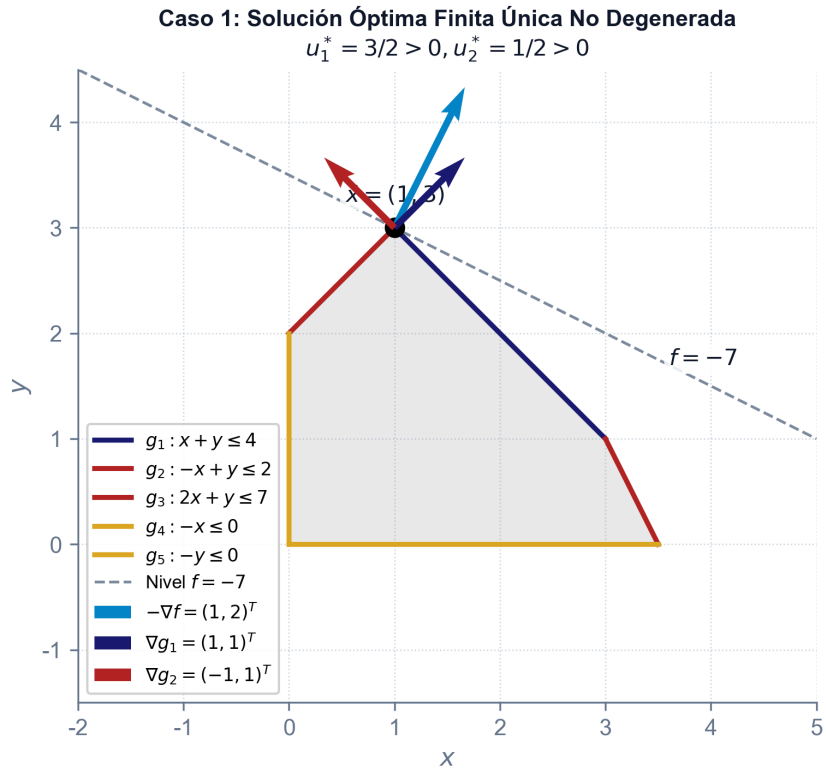

- **Óptimo primal**: $\bar{x} = (1, 3)$ con $f(1, 3) = -7$.
- **Restricciones activas**: g_1 y g_2 $(m_{activas} = 2 = n)$.
- **Estacionariedad KKT**:

$$
\begin{pmatrix} 1 \\ 2 \end{pmatrix} = u_1 \begin{pmatrix} 1 \\ 1 \end{pmatrix} + u_2 \begin{pmatrix} -1 \\ 1 \end{pmatrix} \implies u_1^* = \frac{3}{2},\ u_2^* = \frac{1}{2}
$$

- **Conclusión**: Solución dual única no degenerada

Caso 2: Solución óptima finita única degenerada

Inclusión de restricción redundante:

$$g_4(x, y) = y - 3 \leq 0$$

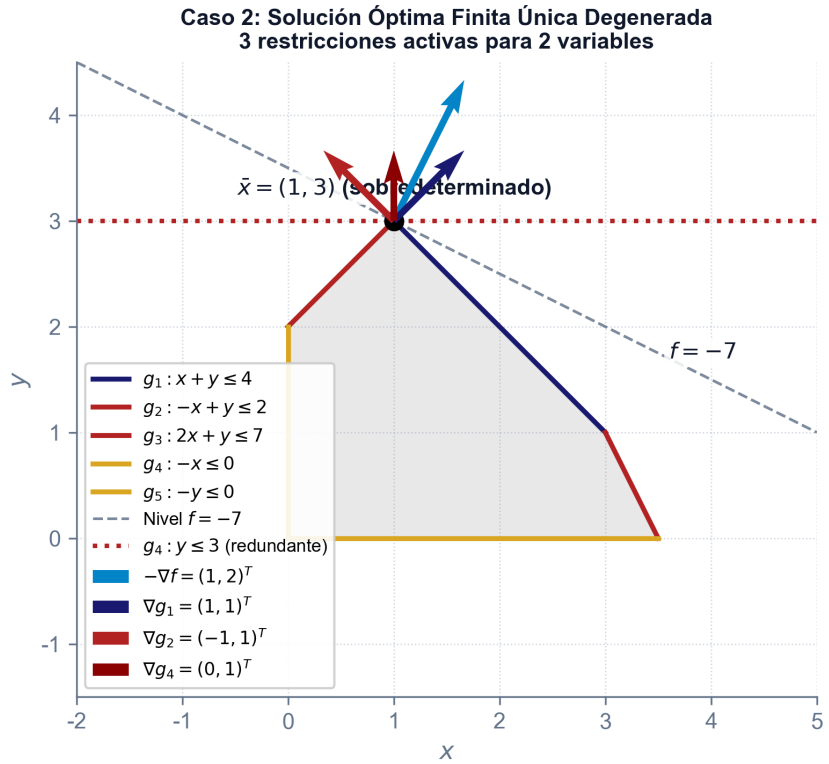

- **Óptimo primal**: $\bar{x} = (1, 3)$ con $f(1, 3) = -7$.
- **Sobredeterminación**: Convergen 3 restricciones activas (g_1, g_2, g_4) para $n = 2$ variables.
- **Ruptura de LICQ**: Gradientes linealmente dependientes.
- **Solución dual**: Múltiples vectores KKT válidos entre $u = (3/2, 1/2, 0)$ y $u' = (1, 0, 1)$.
- **Conclusión**: **El problema**

Caso 3: Múltiples soluciones no degeneradas

Función objetivo paralela:

$$\min \quad -x - y$$

- **Gradiente**: $-\nabla f = (1,1)^T$, paralelo a $\nabla g_1 = (1,1)^T$.
- **Conjunto óptimo**: Arista continua entre $(1,3)$ y $(3,1)$.
- **Estructura dual**:
  - En puntos interiores: $u_1^* = 1$, resto nulos.
  - En vértices: convergen 2 restricciones pero un multiplicador es nulo ($u_2^* = 0$ ó $u_3^* = 0$).
- **Conclusión**: **El problema dual tiene una solución degenerada**.

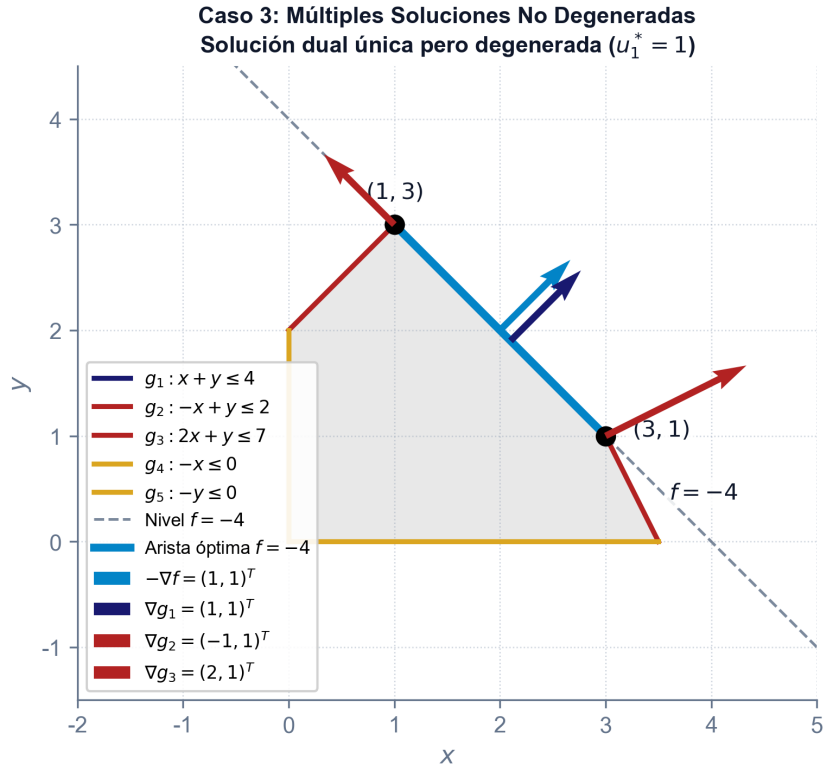

Caso 4A: Geometría de múltiples soluciones degeneradas

Arista óptima con sobredeterminación:

$$\min \quad -x-y \quad \text{con } g_4 : y-3 \leq 0$$

- **Geometría primal**: El segmento continuo entre $(1,3)$ y $(3,1)$ constituye el conjunto de soluciones óptimas primales.
- **Confiliencia en el vértice**: El vértice $(1,3)$ satisface simultáneamente g_1, g_2 y g_4.
- **Conclusión**: Múltiples óptimos primales con degeneración en la frontera.

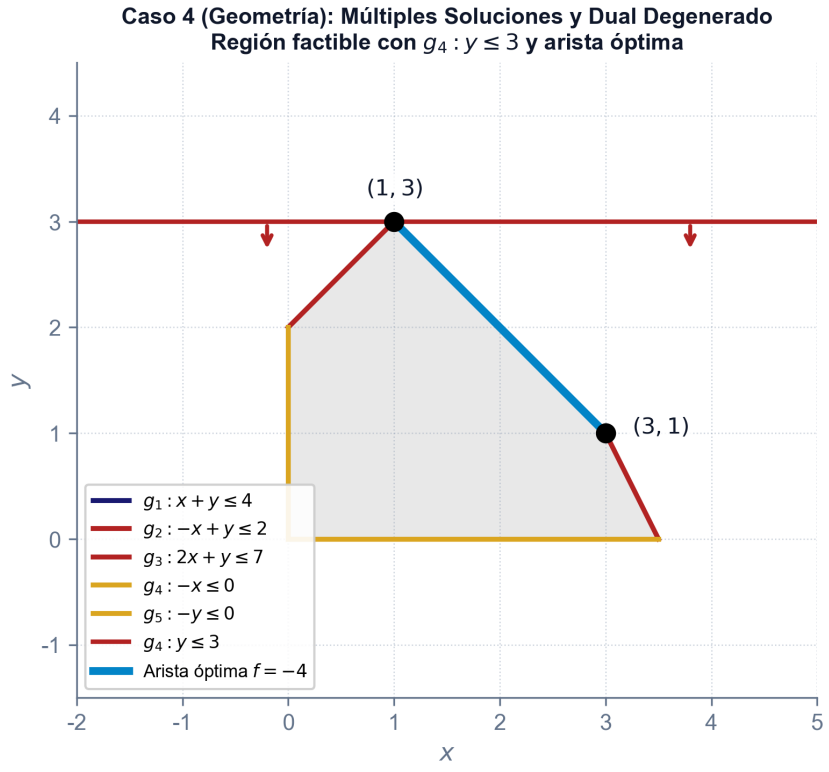

Caso 4B: Gradientes y dualidad degenerada en Caso 4

Análisis de estacionariedad KKT:

- **En el vértice sobredeterminado** $(1,3)$:

$$-\nabla f = u_1 \nabla g_1 + u_2 \nabla g_2 + u_4 \nabla g_4$$

Requiere dos multiplicadores nulos $(u_2 = 0, u_4 = 0)$.

- **En el vértice** $(3,1)$:

$$-\nabla f = u_1 \nabla g_1 + u_3 \nabla g_3 \implies u_3 = 0$$

- **Conclusión**: **El problema dual posee una solución degenerada**.

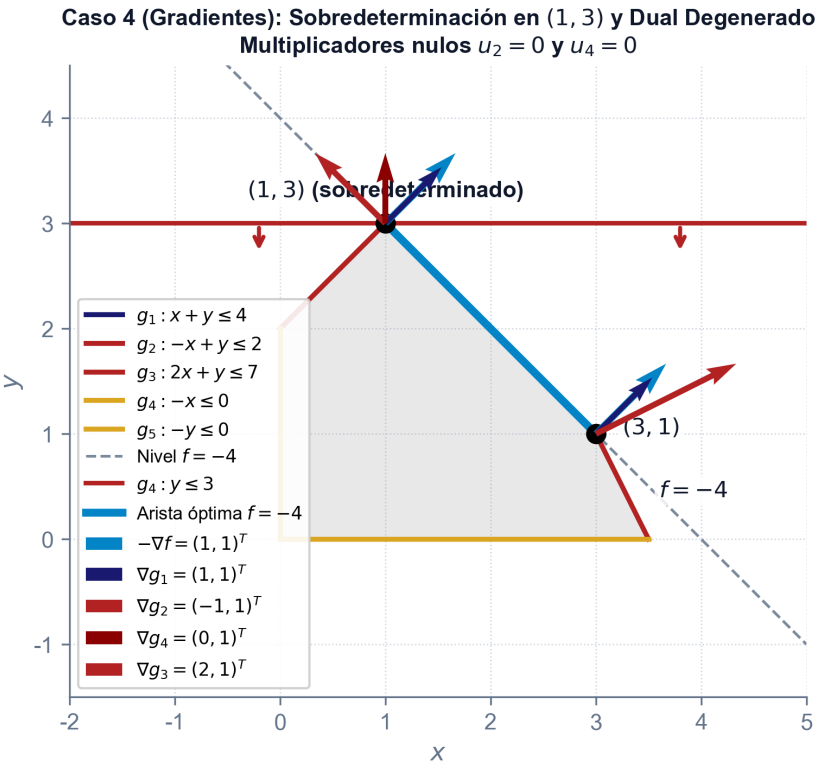

Caso 5: Solución no acotada

Eliminación de la restricción superior g_1:

$$\begin{aligned} \min \quad & -x - y \\ \text{s.a.} \quad & -x + y - 2 \leq 0 \quad (g_2) \\ & 2x + y - 7 \leq 0 \quad (g_3) \\ & x, y \geq 0 \end{aligned}$$

- **Comportamiento**: El coste decrece hacia $-\infty$ sobre un rayo de recesión.
- **Estructura dual**: Imposible satisfacer estacionariedad KKT.
- **Conclusión**: **El problema dual no tiene solución (es no factible)**.

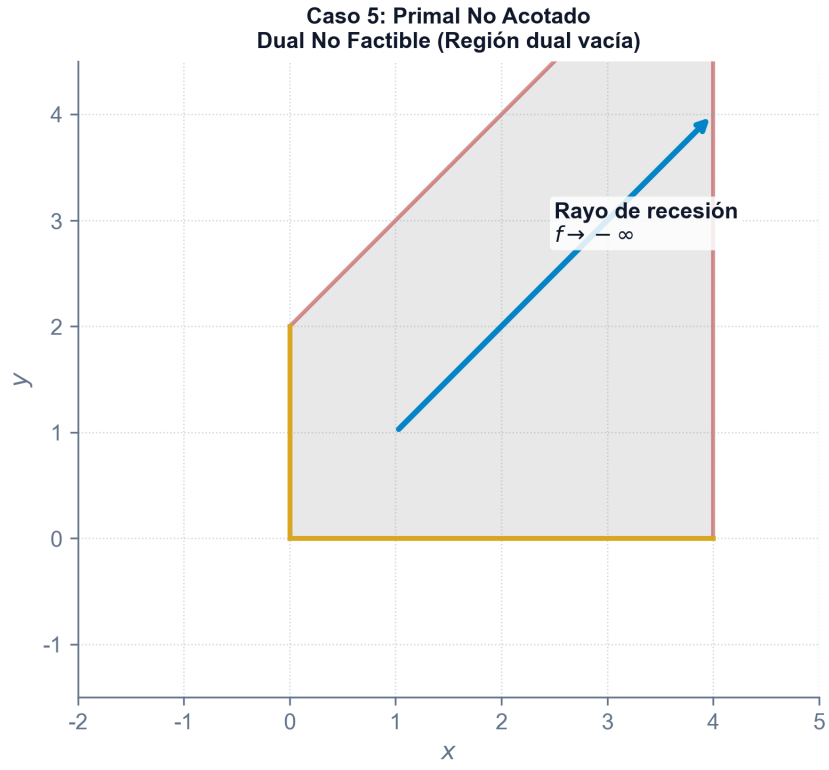

Caso 6: Problema no factible

Restricciones contradictorias:

$$\begin{aligned} \min \quad & -x-2y \\ \text{s.a.} \quad & x+y-1 \leq 0 \\ & -x-y+3.5 \leq 0 \\ & x, y \geq 0 \end{aligned}$$

- **Geometría**: La región factible primal es vacía.
- **Estructura dual**: El problema dual no puede tener solución óptima finita.
- **Conclusión**: **El problema dual es no factible o tiene solución no acotada**.

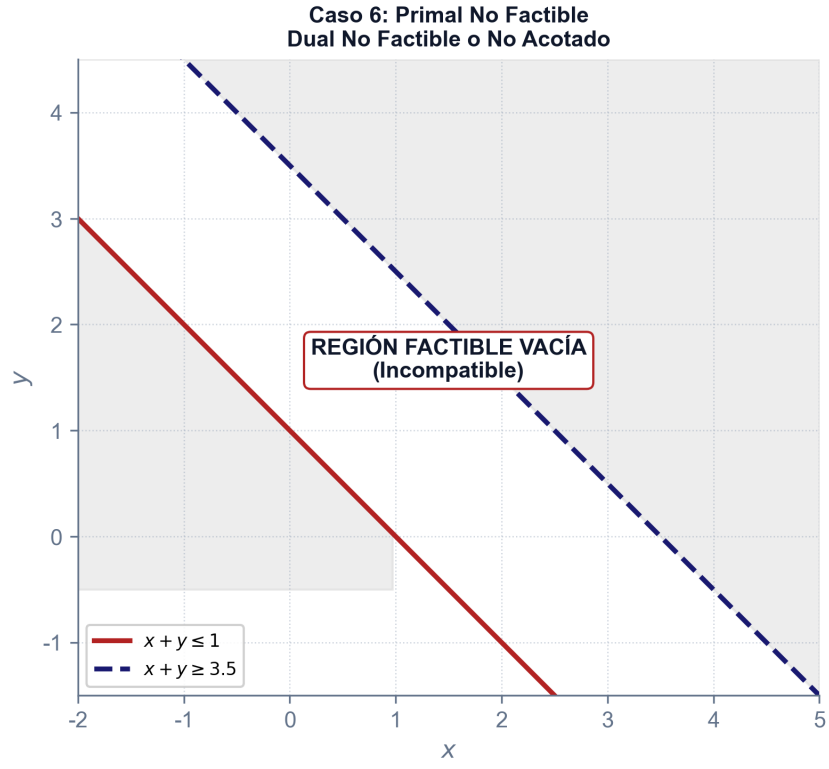

Programación cuadrática (QP)

Modelo general de programación cuadrática

Consideremos el modelo estándar general de optimización cuadrática:

$$\begin{aligned} \min_{x \in \mathbb{R}^n} \quad & f(x) = c^T x + \frac{1}{2} x^T Q x \\ \text{sujeto a} \quad & Ax \geq b \\ & x \geq 0 \end{aligned}$$

- **Vector de variables**: $x \in \mathbb{R}^n$, vector de costes $c \in \mathbb{R}^n$.
- **Matriz Hessiana** Q: Matriz cuadrada simétrica $n \times n$ $(Q = Q^T)$.
- **Región factible**: $S = \{x \in \mathbb{R}^n : Ax \geq b, x \geq 0\}$, intersección de semiespacios afines, constituyendo un conjunto **convexo y poliédrico**.

Interpretación geométrica de la función objetivo cuadrática

Observación: Interpretación geométrica en QP

Cuando la matriz Q es definida positiva ($Q \succ 0$), la función cuadrática $f(x)$ posee un único mínimo libre no restringido en $x^0 = -Q^{-1}c$. Sus curvas de nivel $f(x) = k$ forman elipsoides concéntricos centrados en x^0.

Desde una perspectiva geométrica, resolver el problema cuadrático equivale a encontrar el punto del poliedro factible S más cercano a x^0 según la métrica inducida por la matriz Q.

Derivación formal del sistema KKT

Lagrangiano de la programación cuadrática

Reescribiendo las restricciones en forma canónica $b - Ax \leq 0$ y $-x \leq 0$, construimos la función Lagrangiana extendida con multiplicadores $u \geq 0$ y $v \geq 0$:

$$L(x, u, v) = c^T x + \frac{1}{2} x^T Q x + u^T (b - Ax) - v^T x$$

Derivando parcialmente respecto al vector primal x e imponiendo las condiciones KKT:

1. **Factibilidad primal**: $Ax \geq b, \quad x \geq 0.$
2. **Factibilidad dual y estacionariedad**: $\nabla_x L(x, u, v) = c + Qx - A^T u - v = 0$ con $u \geq 0, v \geq 0.$
3. **Holgura complementaria**: $u_i(b_i - a^i x) = 0 \ (\forall i)$ y $v_i x_i = 0 \ (\forall i)$.

Factibilidad primal en QP

Las condiciones de factibilidad primal en programación cuadrática exigen:

- **Factibilidad de las restricciones generales de desigualdad**: $b - Ax \leq 0 \iff Ax \geq b$. Exige que la solución x satisfaga la totalidad de las m restricciones afines generales.
- **Factibilidad de no negatividad**: $-x \leq 0 \iff x \geq 0$. Garantiza que el vector de variables pertenezca al ortante no negativo.

Factibilidad dual y estacionariedad en QP

La condición de estacionariedad establece el equilibrio vectorial en el punto óptimo:

$$\nabla_x L(x, u, v) = c + Qx - A^T u - v = 0$$

- **Gradiente objetivo cuadrático**: $\nabla f(x) = c + Qx$. Debe poder expresarse como combinación lineal no negativa de los gradientes de las restricciones activas $A^T u + v$.
- **No negatividad dual**: $u \geq 0$ y $v \geq 0$ orientan los vectores normales en sentido opuesto a las direcciones de descenso.

Condiciones de holgura complementaria en QP

Las condiciones de holgura complementaria vinculan la actividad primal con los multiplicadores duales:

- **Complementariedad de recursos**:
  $u_i(b_i - a^i x) = 0, \quad \forall i = 1, \dots, m$. Si una restricción es inactiva $(b_i - a^i x < 0)$, su precio sombra es nulo $(u_i = 0)$. Si $u_i > 0$, se verifica como igualdad estricta $(a^i x = b_i)$.
- **Complementariedad de no negatividad**:
  $v_i x_i = 0, \quad \forall i = 1, \dots, n$. Si $x_i > 0 \implies v_i = 0$. Si $x_i = 0 \implies v_i \geq 0$.

Proposición: Suficiencia y convexidad ($Q \succeq 0$)

Proposición: Suficiencia de las condiciones KKT en QP convexa

Si la matriz de términos cuadráticos Q es semidefinida positiva ($Q \succeq 0$), el problema de programación cuadrática es convexo. En consecuencia, **cualquier solución que satisfaga el sistema de condiciones KKT es una solución óptima global**.

Advertencia: Importancia crítica de la convexidad ($Q \succeq 0$)

Si la matriz Q no es semidefinida positiva (posee autovalores estrictamente negativos), el problema cuadrático deja de ser convexo. En tal escenario, las condiciones KKT son únicamente necesarias pero no suficientes.

Transformación mediante variables de holgura y linealidad del sistema

Introducción de variables primales de holgura

Para transformar las desigualdades primales $b - Ax \leq 0$ en ecuaciones lineales, introducimos variables primales de holgura no negativas $y = (y_1, \dots, y_m)^T \geq 0$:

$$b - Ax \leq 0 \iff b - Ax + y = 0, \quad \text{con } y \geq 0$$

Se verifica la equivalencia analítica directa:

$$b_i - a^i x < 0 \iff y_i > 0, \quad \forall i = 1, \dots, m$$

Sustituyendo en la holgura complementaria:

$$u_i y_i = 0, \quad \forall i = 1, \dots, m$$

Equiparación global de holguras complementarias

Dado que todas las variables del sistema son no negativas $(u, v, x, y \geq 0)$, la anulación individual $u_i y_i = 0$ y $v_i x_i = 0$ equivale a la anulación de la suma escalar global:

$$\begin{cases} u_i y_i = 0, & \forall i = 1, \dots, m \\ v_i x_i = 0, & \forall i = 1, \dots, n \end{cases} \iff \sum_{i=1}^{m} u_i y_i + \sum_{i=1}^{n} v_i x_i = 0 \iff u^T y + v^T
$$

Sistema KKT matricial de la programación cuadrática

El sistema KKT para el problema cuadrático convexo se expresa en la siguiente forma estandarizada:

$$\begin{aligned} b - Ax + y &= 0 \\ c + Qx - A^T u - v &= 0 \\ x, y, u, v &\geq 0 \\ u^T y + v^T x &= 0 \end{aligned}$$

- **Linealidad del bloque de igualdad**: Excepto por la restricción no lineal de complementariedad ($u^T y + v^T x = 0$), todo el resto del sistema (factibilidad primal $b - Ax + y = 0$ y estacionariedad $c + Qx - A^T u - v = 0$) es **estrictamente lineal**.

Algoritmo del Símplex de Wolfe

Principio del Símplex de Wolfe y problema auxiliar

Se adapta el algoritmo del Símplex lineal sobre el sistema KKT ampliado mediante tres pasos:

1. **Relajar la holgura complementaria** $u^T y + v^T x = 0$.
2. **Añadir variables artificiales** $z = (z_1, \dots, z_n)^T \geq 0$ a la estacionariedad:

$$c + Qx - A^T u - v + z = 0 \quad \text{con } z \geq 0$$

3. **Minimizar la suma artificial** resolviendo el problema lineal auxiliar:

$$\min \sum_{i=1}^{n} z_i \quad \text{s.a. } b - Ax + y = 0,\ c + Qx - A^T u - v + z = 0,\ x, y, u, v, z$$

Regla de entrada restringida de Wolfe (Complementariedad)

Para garantizar la complementariedad en el problema auxiliar, se modifica el criterio de entrada a la base Símplex (*restricted entry rule*):

- **Regla de complementariedad primal-dual (u_i, y_i)**: La variable multiplicadora dual u_i **no es candidata** a entrar en la base Símplex si su correspondiente variable de holgura primal y_i es básica ($y_i \in$ Base), y viceversa.
- **Regla de complementariedad de no negatividad (v_j, x_j)**: La variable de holgura dual v_j **no es candidata** a entrar en la base Símplex si la correspondiente variable primal x_j es básica ($x_j \in$ Base), y viceversa.

Caracterización de la solución según la suma artificial

Al resolver el problema auxiliar bajo la regla de entrada restringida:

- **Si el valor óptimo es 0** $(\min \sum z_i = 0)$: Todas las variables artificiales salen de la base $(z^* = 0)$. Como la regla de pivote impide que variables complementarias formen parte de la base simultáneamente, la solución satisface $u^{*T} y^* + v^{*T} x^* = 0$ y x^* **es la solución óptima global**.
- **Si el valor óptimo es estrictamente positivo** $(\min \sum z_i > 0)$: Resulta imposible reducir las variables artificiales a cero respetando la regla restringida. Por tanto, **el problema cuadrático NO tiene solución (es no factible)**.

Garantía de convergencia finita del algoritmo

Nota: Garantía de convergencia finita del algoritmo de Wolfe

Puesto que el algoritmo del Símplex modificado por Wolfe opera sobre el conjunto de soluciones básicas factibles del sistema de ecuaciones lineales ampliado (el cual consta de un número finito de bases posibles) y la función objetivo auxiliar $\sum z_i$ decrece de manera monótona a cada paso de pivote, se garantiza que el algoritmo finaliza en un número finito de iteraciones.

Resolución completa mediante el Algoritmo del Símplex de Wolfe

Enunciado del problema cuadrático

Consideremos el problema de optimización cuadrática en el que se busca minimizar la distancia euclídea al cuadrado desde las variables (x_1, x_2) al punto objetivo $(4, 4)$, sobre una región factible poliédrica $S \subset \mathbb{R}^2$:

$$
\begin{array}{ll}
\min\limits_{x_1, x_2 \in \mathbb{R}} & (x_1 - 4)^2 + (x_2 - 4)^2 \\
\text{sujeto a} & x_1 + x_2 \leq 4 \\
& -x_1 + x_2 \leq 2 \\
& 2x_1 + x_2 \leq 7 \\
& x_1, x_2 \geq 0
\end{array}
\quad \equiv \quad
\begin{array}{ll}
\min\limits_{x_1, x_2 \in \mathbb{R}} & (x_1 - 4)^2 + (x_2 - \\
\text{sujeto a} & -4 + x_1 + x_2 \leq \\
& -2 - x_1 + x_2 \leq \\
& -7 + 2x_1 + x_2 \\
& x_1, x_2 \geq 0
\end{array}
$$

Formulación del problema auxiliar del Símplex de Wolfe

Identificamos $Q = \begin{pmatrix} 2 & 0 \\ 0 & 2 \end{pmatrix} \succ 0$, $c = (-8, -8)^T$,

$A = \begin{pmatrix} -1 & -1 \\ 1 & -1 \\ -2 & -1 \end{pmatrix}$ y $b = (-4, 2, -7)^T$.

Al introducir holguras primales $y_1, y_2, y_3 \geq 0$, multiplicadores duales $u_1, u_2, u_3 \geq 0$, holguras duales $v_1, v_2 \geq 0$ y artificiales $z_1, z_2 \geq 0$:

$$
\begin{aligned}
\min \quad & z_1 + z_2 \\
\text{sujeto a} \quad & -4 + x_1 + x_2 + y_1 = 0 \\
& -2 - x_1 + x_2 + y_2 = 0 \\
& -7 + 2x_1 + x_2 + y_3 = 0 \\
& 2(x_1 - 4) + u_1 - u_2 + 2u_3 - v_1 + z_1 = 0 \\
& 2(x_2 - 4) + u_1 + u_2 + u_3 - v_2 + z_2 = 0 \\
& x_1, x_2, y_1, y_2, y_3, u_1, u_2, u_3, v_1, v_2, z_1, z_2 \geq 0
\end{aligned}
$$

Representación gráfica de la solución

- **Centro no restringido**: Las curvas de nivel de la función objetivo representan círculos concéntricos centrados en el mínimo libre no restringido $(4, 4)$.
- **Tangencia óptima**: La solución óptima del problema corresponde al punto de la región factible S más próximo a $(4, 4)$, alcanzándose la tangencia en el punto $\bar{x} = (2, 2)$ con $f(2, 2) = 8$.

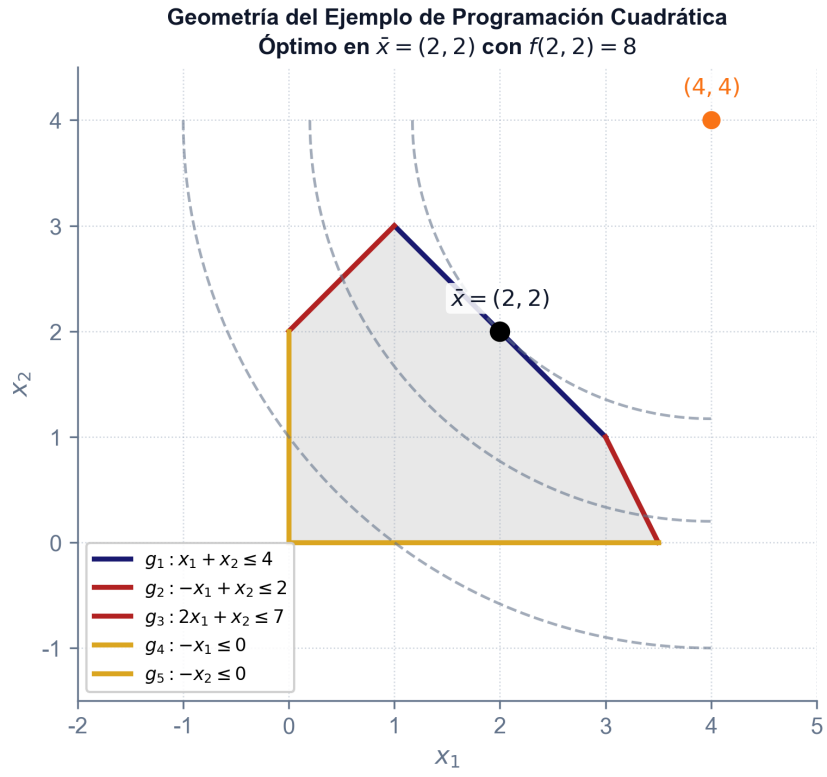

Solución matemática del sistema KKT

Al resolver el sistema KKT, la solución exacta resultante para todas las variables primales, duales, de holgura y artificiales es:

$$
\begin{aligned}
&x_1^* = 2, \quad x_2^* = 2 \\
&u_1^* = 4, \quad u_2^* = 0, \quad u_3^* = 0 \\
&y_1^* = 0, \quad y_2^* = 2, \quad y_3^* = 1 \\
&v_1^* = 0, \quad v_2^* = 0 \\
&z_1^* = 0, \quad z_2^* = 0
\end{aligned}
$$

Progresión iterativa de las tablas del Símplex

A continuación se detalla la progresión iterativa de las tablas del Símplex y su correspondiente traslación geométrica sobre la región factible a cada paso.

- **Fase I (Pivotes primales)**: Avanza sobre los vértices primales ajustando las variables de decisión x_1, x_2.
- **Fase II (Pivotes duales)**: Desbloquea multiplicadores duales conforme salen las holguras primales asociadas de la base.

Iteración 1: Inicio en el Origen (Explicación)

- **Solución básica inicial**: $x_1 = 0, x_2 = 0$, holguras $y_1 = 4, y_2 = 2, y_3 = 7$, artificiales $z_1 = 8, z_2 = 8$.
- **Base inicial**: $\{y_1, y_2, y_3, z_1, z_2\}$, **Objetivo artificial**: $z_1 + z_2 = 8 + 8 = 16$.
- **Criterio de entrada**: Los costes reducidos negativos son $x_1(-2)$, $x_2(-2)$, $u_1(-2)$ y $u_3(-3)$.
- **Regla de complementariedad dual**: Las variables u_1 y u_3 están bloqueadas porque sus variables primales asociadas y_1, y_3 forman parte de la base actual.
- **Pivote**: Seleccionamos la variable candidata $x_2 \downarrow$. Por el criterio del cociente mínimo, abandona la base $y_2 \uparrow$ con elemento pivote **1**.

Iteración 1: Tabla del Símplex de Wolfe

Base	Sol.	x_1	x_2	y_1	y_2	y_3	u_1	u_2	u_3	v_1	v_2	z_1	z_2
y_1	4	1	1	1	0	0	0	0	0	0	0	0	0
y_2	2	-1	**1**	0	1	0	0	0	0	0	0	0	0
y_3	7	2	1	0	0	1	0	0	0	0	0	0	0
z_1	8	2	0	0	0	0	1	-1	2	-1	0	1	0
z_2	8	0	2	0	0	0	1	1	1	0	-1	0	1
Coste	16	-2	-2	0	0	0	-2	0	-3	1	1	0	0

Iteración 1: Geometría en el Origen $(0, 0)$

- **Estado Primal**: El algoritmo se encuentra en el origen $\bar{x} = (0, 0)$.
- **Costes**: Coste artificial de $\sum z_i = 16$ y valor $f(0, 0) = 32$.

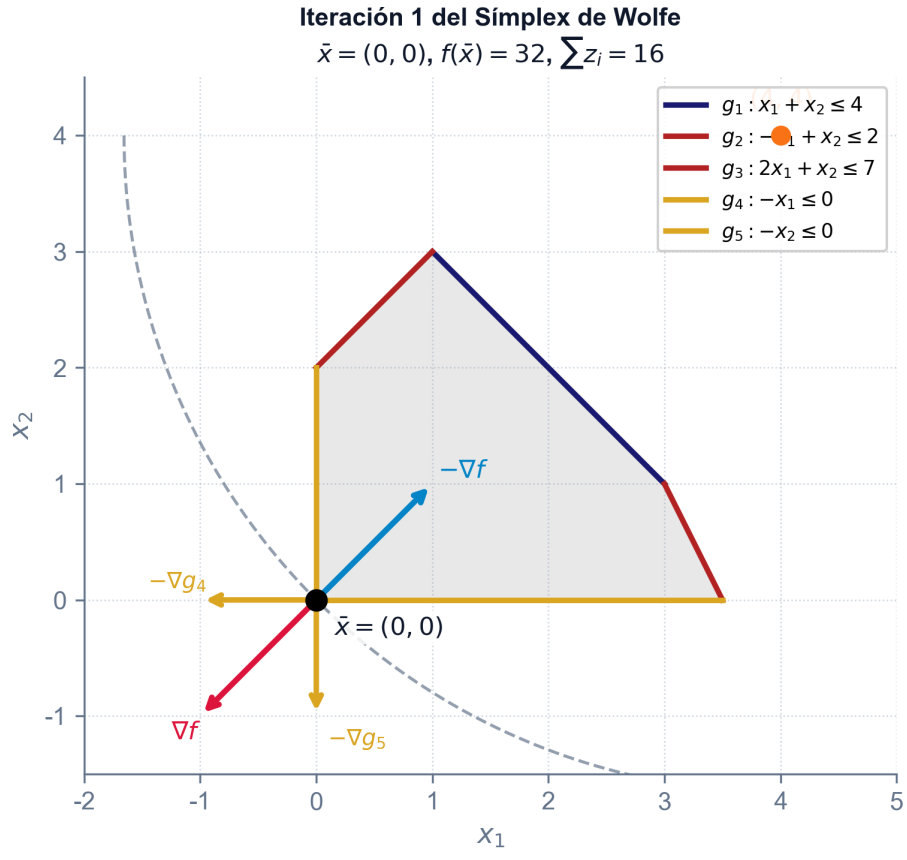

Iteración 2: Avance sobre el eje X_2 (Explicación)

- **Base**: $\{y_1, x_2, y_3, z_1, z_2\}$, con $x_2 = 2$. **Objetivo artificial**: 12.
- **Estado Primal**: Avance a lo largo del eje vertical hasta el vértice $\bar{x} = (0, 2)$, activando $-x_1 + x_2 \leq 2$ $(y_2 = 0)$, con $f(0, 2) = 20$.
- **Criterio de entrada**: Entra la variable primal $x_1 \downarrow$ (coste reducidos -4). Las variables duales u_1, u_3 continúan bloqueadas por $y_1, y_3 \in$ Base.
- **Pivote**: Abandona la base $y_1 \uparrow$ en la fila 1 con pivote **2**.

Iteración 2: Tabla del Símplex de Wolfe

Base	Sol.	x_1	x_2	y_1	y_2	y_3	u_1	u_2	u_3	v_1	v_2	z_1	z_2
y_1	2	**2**	0	1	-1	0	0	0	0	0	0	0	0
x_2	2	-1	1	0	1	0	0	0	0	0	0	0	0
y_3	5	3	0	-1	-1	1	0	0	0	0	0	0	0
z_1	8	2	0	0	0	0	1	-1	2	-1	0	1	0
z_2	4	2	0	0	-2	0	1	1	1	0	-1	0	1
Coste	12	-4	0	0	2	0	-2	0	-3	1	1	0	0

Iteración 2: Geometría en el Vértice $(0, 2)$

- **Estado Primal**: El punto se desplaza sobre el eje X_2 hasta el vértice $\bar{x} = (0, 2)$, donde se activa $-x_1 + x_2 \leq 2$ $(y_2 = 0)$.

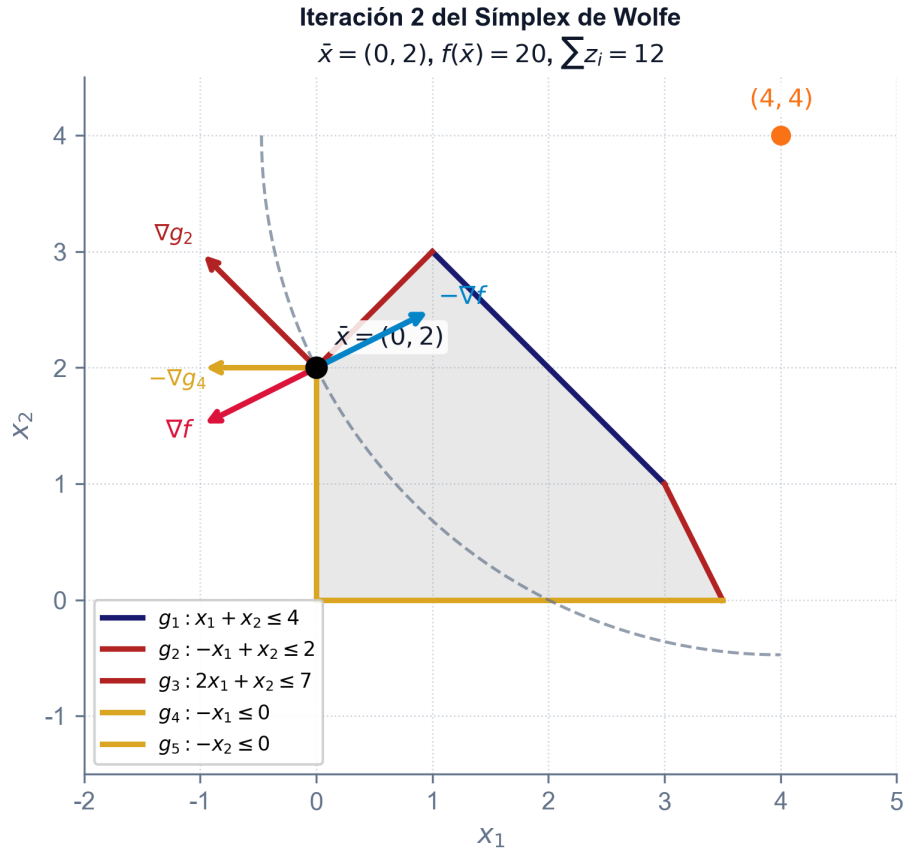

Iteración 3: Desplazamiento a $(1, 3)$ y Desbloqueo Dual

- **Base**: $\{x_1, x_2, y_3, z_1, z_2\}$, **Objetivo artificial**: 8.
- **Criterio de entrada**: Al salir y_1 de la base en la iteración anterior, la variable dual $u_1 \downarrow$ queda libre y entra en la base (coste reducido -2). La variable u_3 sigue bloqueada por $y_3 \in$ Base.
- **Pivote**: Abandona la base la variable artificial $z_2 \uparrow$ en la fila 5 con elemento pivote $\mathbf{1}$.

Iteración 3: Tabla del Símplex de Wolfe

Base	Sol.	x_1	x_2	y_1	y_2	y_3	u_1	u_2	u_3	v_1	v_2	z_1	z_2
x_1	1	1	0	$1/2$	$-1/2$	0	0	0	0	0	0	0	0
x_2	3	0	1	$1/2$	$1/2$	0	0	0	0	0	0	0	0
y_3	2	0	0	$-5/2$	$1/2$	1	0	0	0	0	0	0	0
z_1	6	0	0	-1	1	0	1	-1	2	-1	0	1	0
z_2	2	0	0	-1	-1	0	1	1	1	0	-1	0	1
Coste	8	0	0	2	0	0	-2	0	-3	1	1	0	0

Iteración 3: Geometría en el Vértice $(1, 3)$

- **Estado Primal**: El candidato avanza sobre $-x_1 + x_2 = 2$ hasta alcanzar el vértice $\bar{x} = (1, 3)$, donde se activa adicionalmente $x_1 + x_2 \leq 4$ $(y_1 = 0)$.

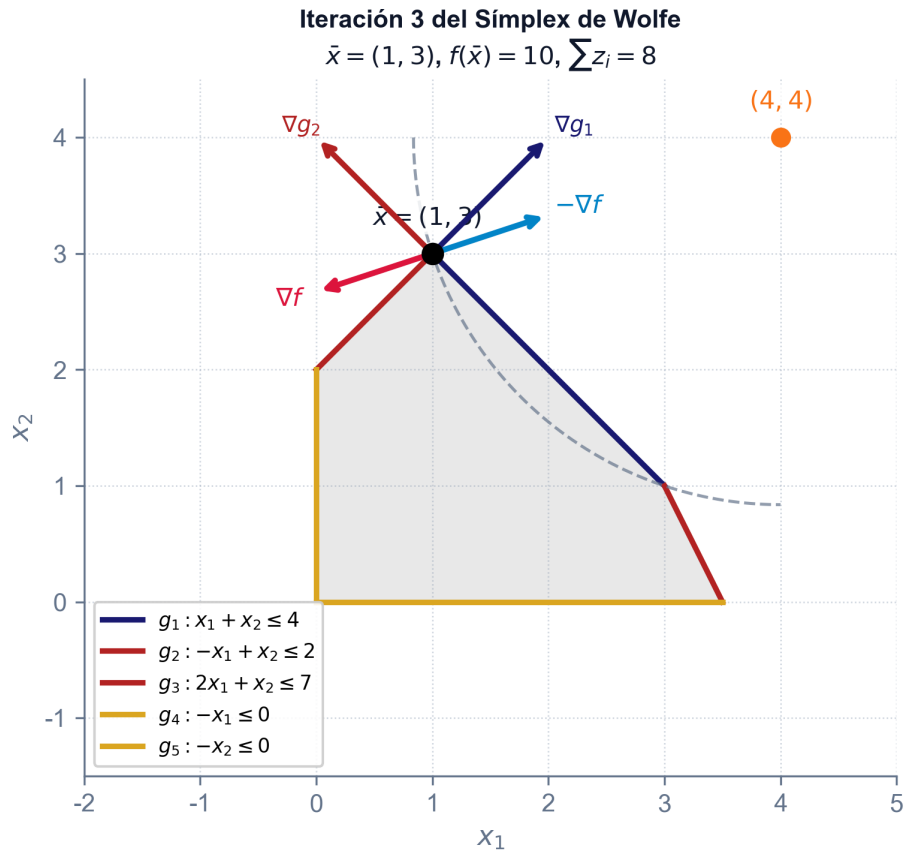

Iteración 4: Ajuste Dual en $(1, 3)$ (Explicación)

- **Base**: $\{x_1, x_2, y_3, z_1, u_1\}$, **Objetivo artificial**: 4.
- **Ajuste dual**: La solución primal se mantiene estática en $\bar{x} = (1, 3)$, pero u_1 entra en la base con valor $u_1 = 2$, eliminando z_2.
- **Criterio de entrada**: Entra la variable de holgura $y_2 \downarrow$ (coste reducido -2).
- **Pivote**: Sale de la base la última variable artificial $z_1 \uparrow$ en la fila 4 con pivote **2**.

Iteración 4: Tabla del Símplex de Wolfe

Base	Sol.	x_1	x_2	y_1	y_2	y_3	u_1	u_2	u_3	v_1	v_2	z_1	z_2
x_1	1	1	0	$1/2$	$-1/2$	0	0	0	0	0	0	0	0
x_2	3	0	1	$1/2$	$1/2$	0	0	0	0	0	0	0	0
y_3	2	0	0	$-5/2$	$1/2$	1	0	0	0	0	0	0	0
z_1	4	0	0	0	**2**	0	0	-2	1	-1	-1	1	-1
u_1	2	0	0	-1	-1	0	1	1	1	0	-1	0	1
Coste	4	0	0	0	-2	0	0	2	-1	1	-1	0	2

Iteración 4: Geometría de Ajuste Dual en $(1, 3)$

- **Estado Primal**: El punto en el espacio primal permanece en el vértice $\bar{x} = (1, 3)$ mientras se ajusta la tensión del multiplicador dual $(u_1 = 2)$.

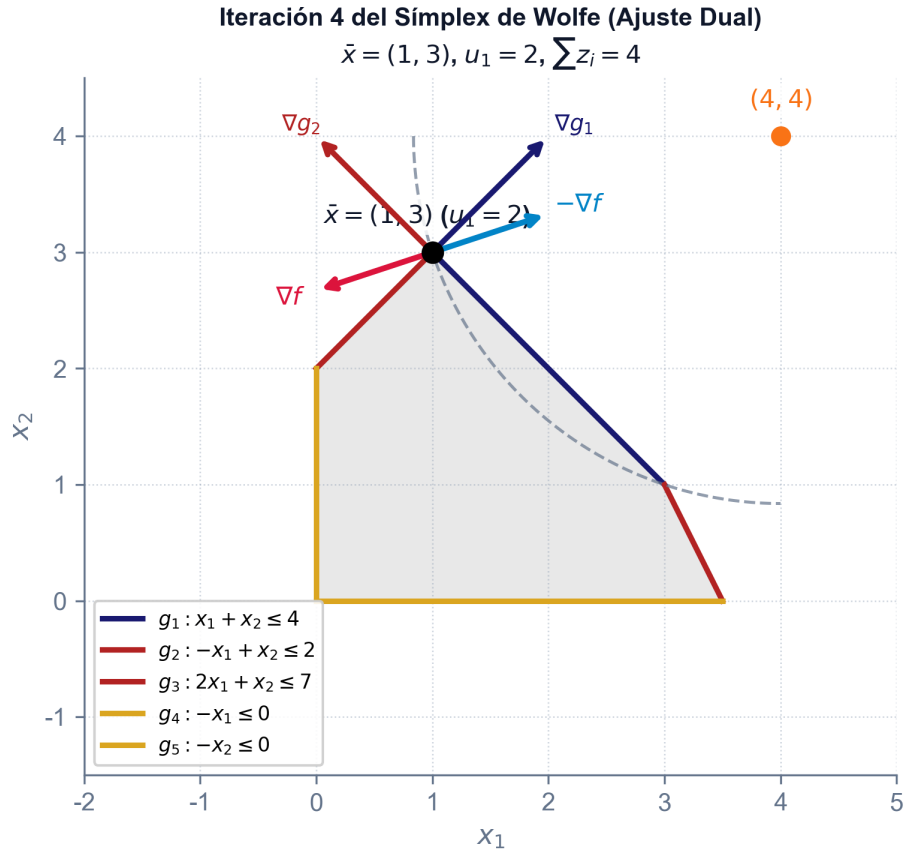

Iteración 5: Óptimo Global y Tangencia en $(2, 2)$

- **Base óptima**: $\{x_1, x_2, y_3, y_2, u_1\}$, **Objetivo artificial**: 0.
- **Consecución del óptimo**: La entrada de y_2 permite deslizar la solución sobre la cara activa $x_1 + x_2 = 4$ hasta $\bar{x} = (2, 2)$.
- **Tangencia cuadrática**: Se alcanza la tangencia con la superficie de nivel, anulando las variables artificiales ($\sum z_i = 0$), con $u_1^* = 4$ y $f(2, 2) = 8$.
- **Criterio de parada**: Todas las variables artificiales han salido de la base y no existen costes reducidos negativos viables bajo la regla restringida.

Iteración 5: Tabla Óptima Final del Símplex de Wolfe

Base	Sol.	x_1	x_2	y_1	y_2	y_3	u_1	u_2	u_3	v_1	v_2	z_1	z_2
x_1	2	1	0	1/2	0	0	0	−1/2	1/4	−1/4	1/4	1/4	−1/4
x_2	2	0	1	1/2	0	0	0	1/2	−1/4	1/4	−1/4	−1/4	1/4
y_3	1	0	0	−5/2	0	1	0	1/2	−1/4	1/4	−1/4	−1/4	1/4
y_2	2	0	0	0	1	0	0	−1	1/2	−1/2	1/2	1/2	−1/2
u_1	4	0	0	−1	0	0	1	0	3/2	−1/2	−1/2	1/2	1/2
Coste	0	0	0	0	0	0	0	0	0	0	0	1	1

Iteración 5: Geometría del Óptimo Global $(2, 2)$

- **Estado Primal**: Óptimo global en $\bar{x} = (2, 2)$.
- **Tangencia Cuadrática**: $\nabla f(2, 2) = -u_1^* \nabla g_1(2, 2)$ con $u_1^* = 4$.
- **Coste Mínimo**: $f(2, 2) = 8$.

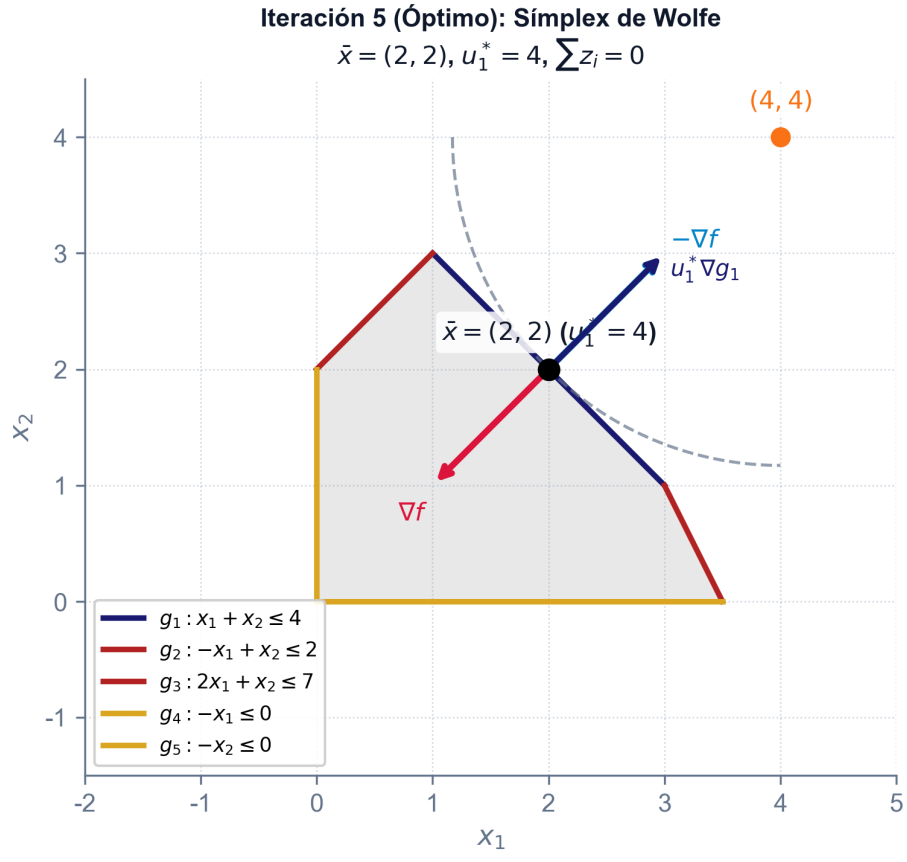

Trayectoria geométrica completa del Símplex de Wolfe

- **Paso 1**: Origen $(0, 0)$.
- **Paso 2**: Vértice $(0, 2)$ sobre el eje X_2.
- **Pasos 3-4**: Vértice $(1, 3)$ con ajuste dual $u_1 = 2$.
- **Paso 5**: Óptimo global $(2, 2)$ sobre la arista $x_1 + x_2 = 4$.

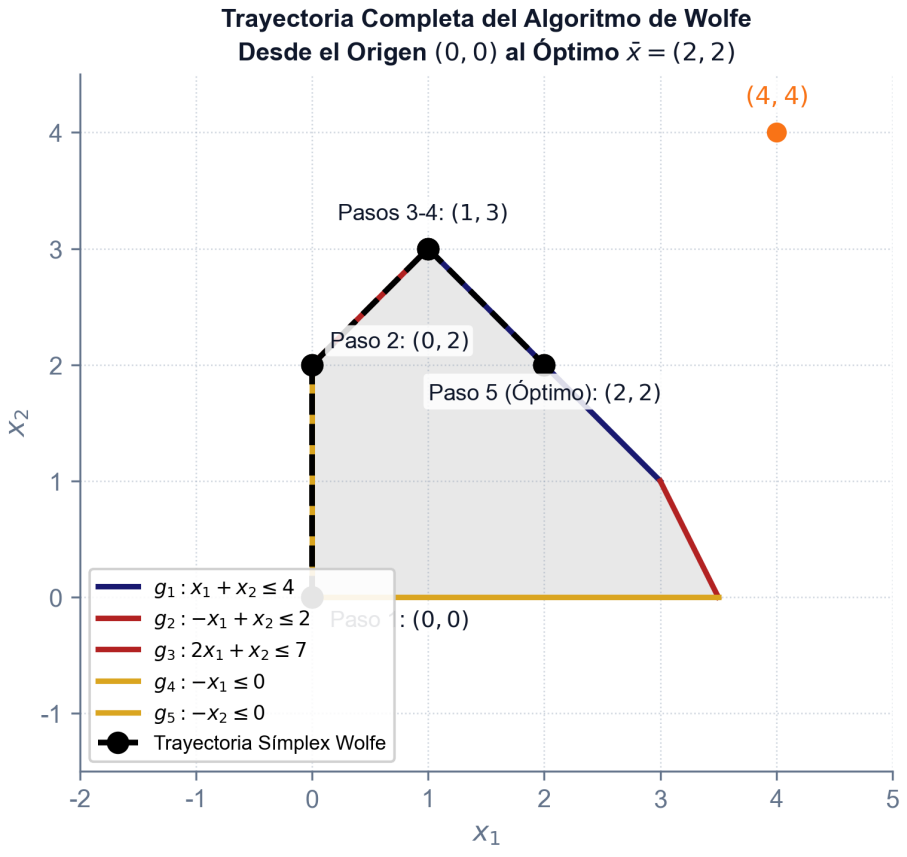

Consideraciones finales

Síntesis de la relación entre KKT, dualidad y Wolfe

En este tema se ha completado el estudio de la optimización restringida mediante las condiciones de Karush-Kuhn-Tucker (KKT) en problemas con estructura afín y cuadrática.

- **Fundamentación de la dualidad en LP**: Las condiciones KKT no solo caracterizan las soluciones óptimas primales, sino que establecen una equivalencia directa con el problema dual. Los multiplicadores de Lagrange actúan como **precios sombra**, cuantificando la sensibilidad del valor óptimo respecto a variaciones en los términos independientes.
- **Correspondencia geométrica primal-dual**: El análisis por casos en programación lineal demuestra que la degeneración en un espacio implica multiplicidad de soluciones en el espacio dual recíproco.

Conclusión algorítmica de la programación cuadrática

- **Estructura lineal del sistema KKT**: En problemas cuadráticos convexos ($Q \succeq 0$), el sistema KKT da lugar a un conjunto de ecuaciones lineales salvo por las restricciones bilineales de holgura complementaria ($u^T y = 0, v^T x = 0$).
- **Eficacia del Símplex de Wolfe**: El algoritmo del Símplex de Wolfe aprovecha esta linealidad introduciendo variables artificiales y resolviendo un problema de minimización auxiliar bajo la **regla de entrada restringida**.
- **Convergencia finita**: Esto garantiza la convergencia finita a la solución óptima global, navegando a través de los vértices y caras de la región factible poliédrica hasta alcanzar la tangencia cuadrática exacta.

Tema 6: Grafos y árboles soporte

Optimización y Análisis de Redes

Víctor Aceña Gil - Antonio Alonso Ayuso

2026-08-07

Objetivos de aprendizaje

1. **Definir** grafos dirigidos y no dirigidos, vecindades, grados e incidencias de corte.
2. **Diferenciar** cadenas, caminos, ciclos y circuitos, y clasificar la conexidad en digrafos.
3. **Caracterizar** grafos planares y bipartitos mediante Euler, Dudeney y Kuratowski.
4. **Formular** matrices de adyacencia e incidencia (TUM), vectores (α, β) y listas de adyacencia.
5. **Caracterizar** las propiedades equivalentes de árboles y el vector de padres.
6. **Aplicar** Kruskal y Prim para el MST y construir modelos de *Single-Linkage Clustering*.

El problema de los puentes de Königsberg (Euler, 1736)

Contexto histórico y los 7 puentes

- **Nacimiento de la Teoría de Grafos**: Formulado por Leonhard Euler en 1736.
- **Geografía urbana de Königsberg**: Cuatro regiones (A, B, C, D) separadas por el río Pregel y conectadas por 7 puentes de madera.
- **El Desafío**: Determinar si existe un paseo que cruce **cada uno de los 7 puentes exactamente una sola vez** y regrese al punto inicial.

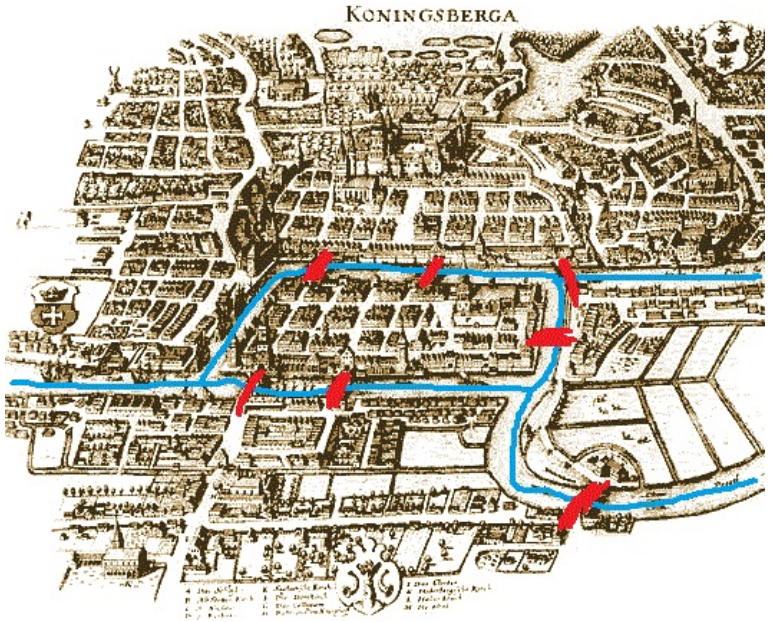

Abstracción topológica de Euler

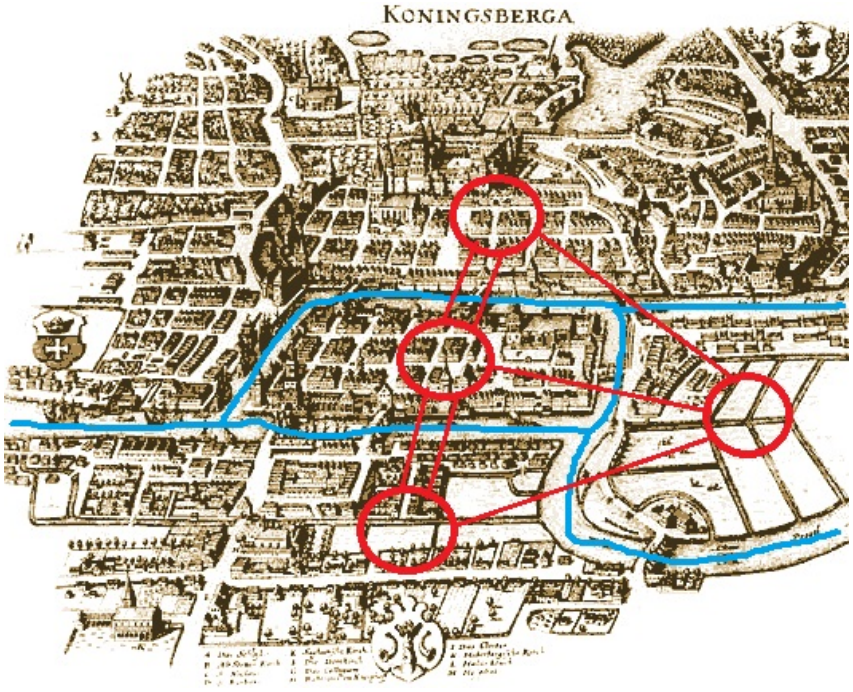

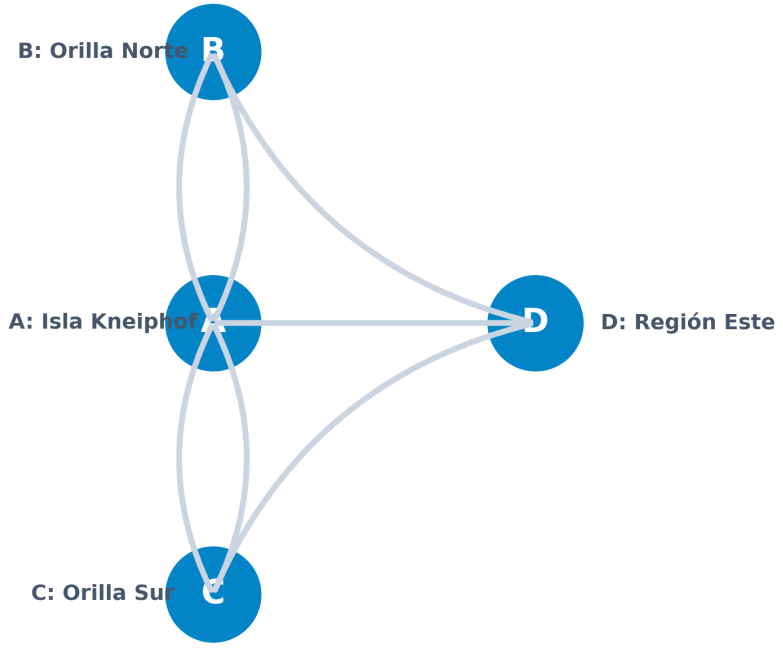

Imposibilidad del recorrido en Königsberg

- **Grado de un nodo**: Aristas incidentes en una masa de tierra.
- **Condición de tránsito**: Para no repetir puentes, todo nodo intermedio requiere grado **par**.
- **Grados en Königsberg**: $d(A) = 5$, $d(B) = 3$, $d(C) = 3$, $d(D) = 3$ (todos impares).
- **Conclusión**: Al tener 4 nodos impares, el circuito euleriano es **imposible**.

! Principio de Euler

Un grafo conexo admite un circuito euleriano s.i.s. **todos sus vértices tienen grado par**.

Conceptos fundamentales

Definición formal de grafos no dirigidos y digrafos

Definición: Grafo no dirigido

Un **grafo no dirigido** $G = (V, E)$ consiste en un conjunto finito no vacío de **vértices** V y un conjunto E de **aristas** formadas por pares no ordenados $\{u, v\}$ con $u, v \in V$.

Definición: Grafo dirigido (Digrafo)

Un **digrafo** $G = (V, U)$ consiste en un conjunto de vértices V y un conjunto U de **arcos** formados por tuplas ordenadas (u, v) donde u es el nodo origen y v el nodo destino.

Ejemplo: Red de transporte aéreo

- **Modelado de infraestructuras**: Los nodos representan aeropuertos y los arcos representan vuelos directos de ida sin escala.
- **Nodos de la red**: Aeropuertos $V = \{\text{MAD}, \text{BCN}, \text{PAR}, \text{LON}\}$.
- **Arcos antiparalelos**: (PAR, BCN) y (BCN, PAR) permiten tránsito bidireccional.

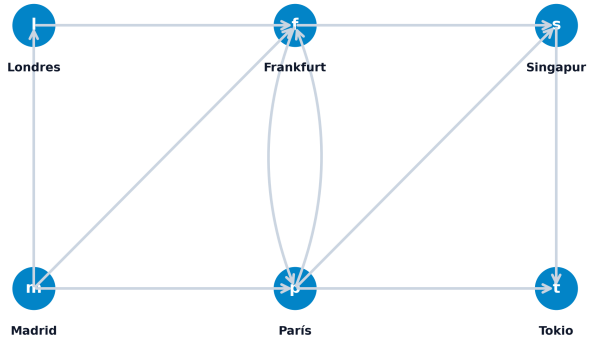

Estructura abstracta de digrafos

- **Tipología de arcos orientados**:
  - **Bucles (autodirecciones)**: $(2, 2)$ en el nodo 2.
  - **Arcos antiparalelos**: Par de arcos en sentidos opuestos, como $(1, 2)$ y $(2, 1)$ o $(2, 4)$ y $(4, 2)$.
  - **Arcos simples**: Arcos dirigidos en un único sentido, como $(1, 3)$, $(2, 3)$ y $(3, 4)$.

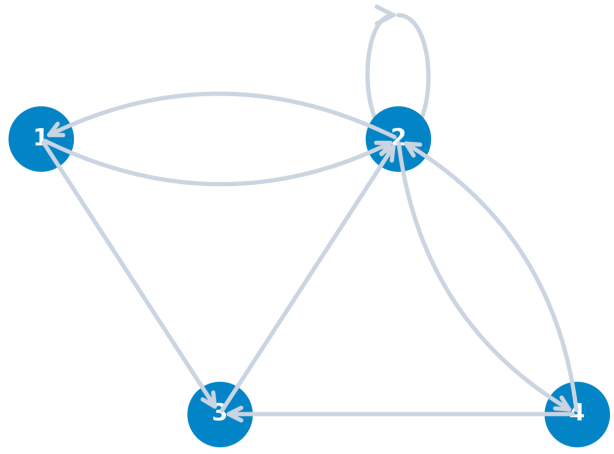

Adyacencia y vecindades de un nodo

Definición: Adyacencia y vecindades

Dado un digrafo $G = (V, U)$ o grafo no dirigido $G = (V, E)$ y un nodo $i \in V$:

- **Nodos adyacentes**: Dos nodos $i, j \in V$ son adyacentes si existe una conexión directa entre ellos ($(i, j) \in U$ ó $(j, i) \in U$).
- **Conjunto de Sucesores**: $\Gamma^+(i) = \{j \in V : (i, j) \in U\}$, nodos hacia los que parten arcos desde i.
- **Conjunto de Predecesores**: $\Gamma^-(i) = \{j \in V : (j, i) \in U\}$, nodos desde los que llegan arcos a i.
- **Vecindad Total**: $\Gamma(i) = \Gamma^+(i) \cup \Gamma^-(i)$, conjunto combinado de sucesores y predecesores de i.

Incidencia de arcos

Definición: Incidencia de arcos

Dado un digrafo $G = (V, U)$ o grafo no dirigido $G = (V, E)$:

- **Arcos adyacentes**: Dos arcos $u_1, u_2 \in U$ son adyacentes cuando comparten al menos un nodo extremo común (por ejemplo, los arcos $(1, 2)$ y $(2, 4)$ en el nodo 2).
- **Incidencia de salida**: Un arco $u = (i, j) \in U$ es **incidente de salida** en su nodo origen i.
- **Incidencia de entrada**: Un arco $u = (i, j) \in U$ es **incidente de entrada** en su nodo destino j.

Semigrados exterior e interior

Definición: Semigrados exterior e interior

Dado un digrafo $G = (V, U)$ y un nodo $i \in V$:

- **Semigrado exterior**:

$$d^+(i) = |\Gamma^+(i)|$$

  Número exacto de arcos salientes que parten del nodo i.

- **Semigrado interior**:

$$d^-(i) = |\Gamma^-(i)|$$

  Número exacto de arcos entrantes que ingresan en el nodo i.

Grado total y nodos notables

Definición: Grado total y nodos notables

Dado un grafo $G = (V, E)$ o digrafo $G = (V, U)$ y un nodo $i \in V$:

- **Grado total**:

$$d(i) = d^+(i) + d^-(i)$$

  Número total de arcos o aristas incidentes en el nodo i.
- **Nodo pendiente o hoja**: Nodo con grado total exactamente igual a 1 ($d(i) = 1$).
- **Nodo aislado**: Nodo desprovisto de conexiones incidentes ($d(i) = 0$).

Ilustración de vecindades y semigrados

- **Vecindad del nodo 3**:
  - Sucesores: $\Gamma^+(3) = \{2\}$
  - Predecesores: $\Gamma^-(3) = \{1, 4\}$
  - Vecindad total: $\Gamma(3) = \{1, 2, 4\}$

- **Semigrados y Nodos notables**:
  - Entrada y salida: $d^+(3) = 1, d^-(3) = 2$
  - Grado total: $d(3) = 1 + 2 = 3$
  - Nodo 5: $d^+(5) = 0, d^-(5) = 1 \implies d(5) = 1$

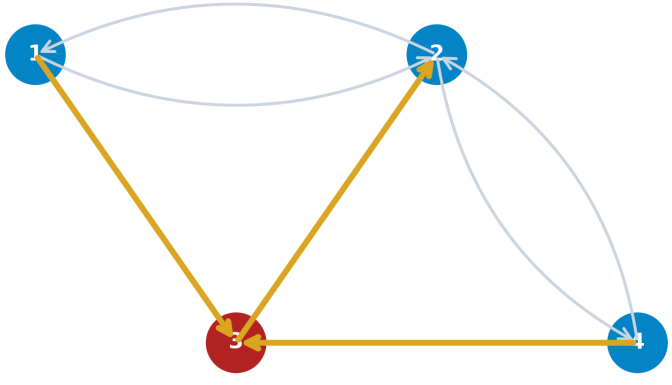

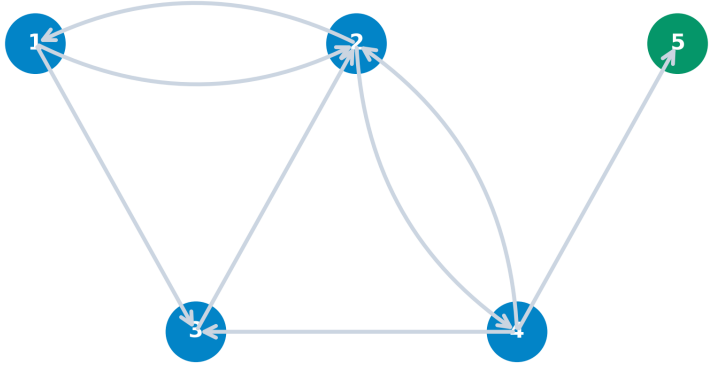

Lema del apretón de manos (Handshaking Lemma)

! Teorema de la suma de grados (Handshaking Lemma)

En todo grafo no dirigido $G = (V, E)$ con $|V| = n$ vértices y $|E| = m$ aristas, la suma de los grados de todos los vértices es igual al doble del número total de aristas:

$$\sum_{v \in V} d(v) = 2m$$

- **Significado combinatorio**:
  - Cada arista no dirigida conecta exactamente dos vértices extremos.
  - Al sumar los grados de todos los nodos, cada arista se contabiliza exactamente dos veces (apretón de manos de dos extremos).

Incidencia de conjuntos de nodos y cortes

Definición: Incidencia y corte de un conjunto A

Dado un digrafo $G = (V, U)$ y un subconjunto propio de nodos $A \subset V$:

- **Incidencia Exterior** $w^+(A)$: Conjunto de arcos que parten de A y finalizan fuera de A:
  $w^+(A) = \{(i, j) \in U : i \in A,\ j \in V \setminus A\}$
- **Incidencia Interior** $w^-(A)$: Conjunto de arcos que parten de fuera de A e ingresan en A:
  $w^-(A) = \{(i, j) \in U : i \in V \setminus A,\ j \in A\}$
- **Corte** $w(A)$: Unión de las incidencias exterior e interior de la frontera:
  $w(A) = w^+(A) \cup w^-(A)$

Ejemplo: Corte e incidencias para A = {2, 3}

Para el subconjunto de nodos $A = \{2, 3\}$:

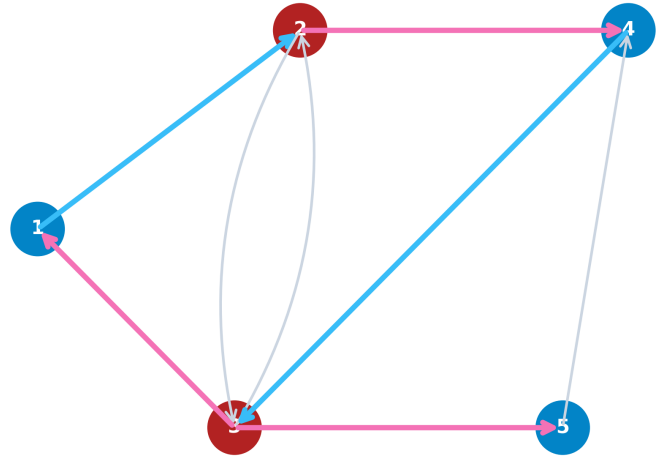

- **Incidencia exterior** (salientes de A):

$$w^+(A) = \{(2,4), (3,1), (3,5)\}$$

- **Incidencia interior** (entrantes a A):

$$w^-(A) = \{(1,2), (4,3)\}$$

- **Corte total** (frontera cruzada):

$$w(A) = \{(1,2), (2,4), (3,1), (3,5), (4,3)\}$$

Multigrafos y p-grafos

Definición: Multigrafo y p-grafo

- **Multigrafo / Multidigrafo**: Admite múltiples conexiones o aristas en paralelo entre un mismo par de vértices.
- **Multiplicidad**: Número exacto de conexiones paralelas entre dos nodos.
- p-**Grafo**: Multigrafo en el que la máxima multiplicidad de cualquier par de nodos es p.

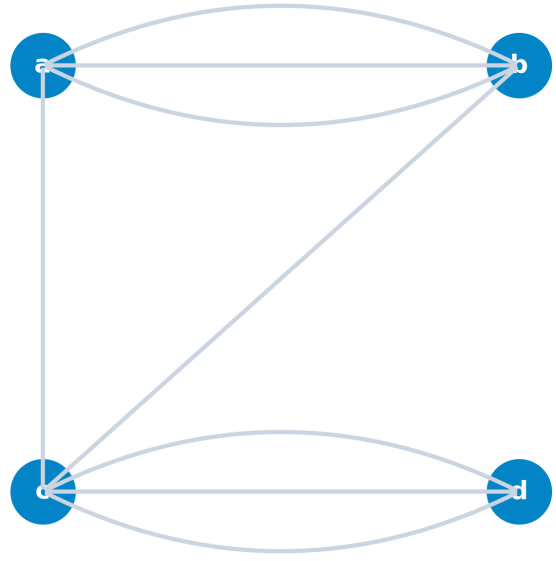

Grafos simples

Definición: Grafo simple

Un **grafo simple** (o **digrafo simple**) es un grafo de multiplicidad 1 desprovisto de autodirecciones o bucles (i, i).

- **Propiedad de exclusión**:
  - Para cualquier par de vértices $i, j \in V$, existe como máximo una única arista $\{i, j\} \in E$ (o un único arco $(i, j) \in U$).
  - Ningún nodo está conectado consigo mismo mediante un bucle $(i, i) \notin U$.

Grafos completos (no dirigidos) y Clanes (K_n)

Definición: Grafo completo y Clan Kn

Un **grafo completo** $G = (V, E)$ (o **clan / clique** K_n) es un grafo simple no dirigido en el que todo par de vértices distintos se encuentra directamente conectado por una arista:

$$\{i, j\} \in E, \quad \forall i \neq j \in V$$

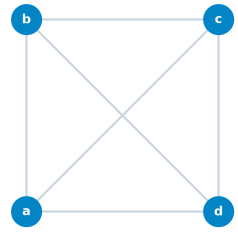

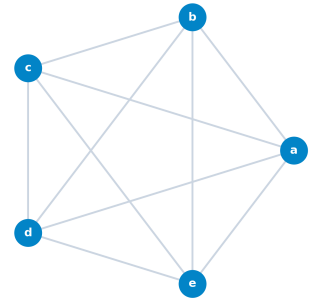

- **Número total de aristas**: $m = \binom{n}{2} = \frac{n(n-1)}{2}$.

Digrafos completos

Definición: Digrafo completo

Un digrafo $G = (V, U)$ se dice **completo** si para todo par de vértices distintos $i \neq j$, la ausencia de un arco en una dirección implica la existencia obligatoria del arco en sentido inverso:

$$(i, j) \notin U \implies (j, i) \in U \quad (\forall i \neq j)$$

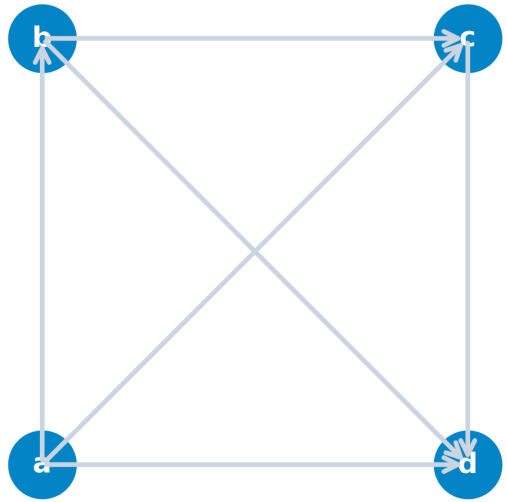

- **Interpretación orientada**: Se garantiza al menos un sentido de comunicación directa entre cualquier pareja de vértices.

Grafo base original de referencia $G = (V, U)$

- **Digrafo original de referencia**: Red orientada $G = (V, U)$ compuesta por $n = 5$ nodos $(V = \{1, 2, 3, 4, 5\})$ y 7 arcos.
- **Operaciones de subestructura**: A partir de esta red base se definen:
  - **Subgrafos inducidos**: Selección de un subconjunto de nodos $A \subset V$.
  - **Grafos parciales**: Selección de un subconjunto de arcos $W \subset U$.

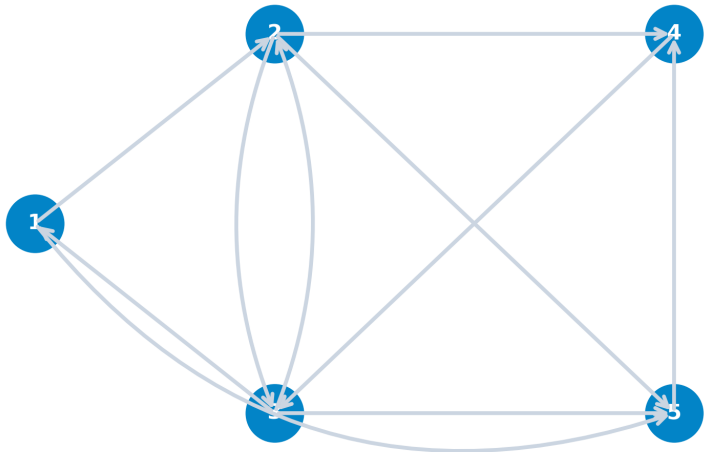

Subgrafos inducidos (por nodos)

Definición: Subgrafo inducido

Dado $G = (V, U)$ y un subconjunto de vértices $A \subset V$, el **subgrafo inducido** $G_A = (A, U_A)$ conserva únicamente los nodos de A y los arcos con ambos extremos en A:

$$U_A = \{(i, j) \in U : i, j \in A\}$$

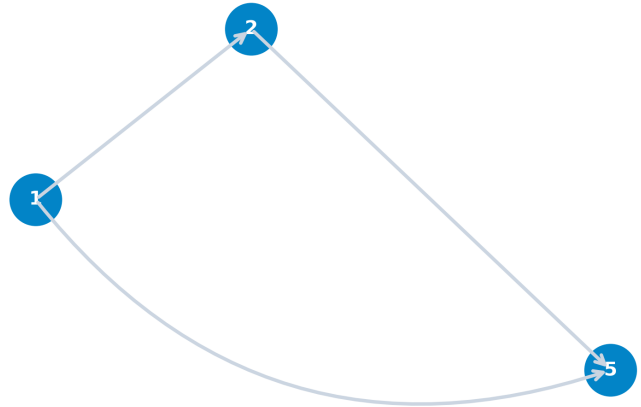

- **Ejemplo para** $A = \{1, 2, 5\}$: Los nodos $\{3, 4\}$ y sus arcos incidentes desaparecen por completo respecto a la red base G.

Grafos parciales (por arcos)

Definición: Grafo parcial

Dado $G = (V, U)$ y un subconjunto de arcos $W \subset U$, el **grafo parcial** $G(W) = (V, W)$ conserva los n vértices de V, restringiendo los arcos a W.

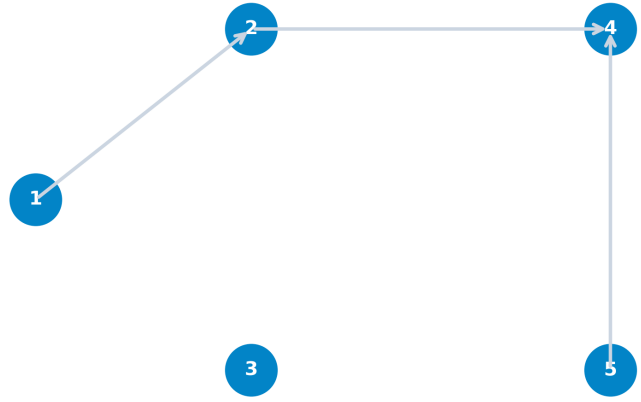

- **Ejemplo para** $W = \{(1,2),(2,4),(5,4)\}$: Los $n = 5$ nodos de G se preservan intactos. El nodo 3 permanece presente como **nodo aislado** $(d(3) = 0)$.

Grafo complementario ($\bar{G}$)

Definición: Grafo complementario

Dado un grafo simple $G = (V, E)$, su **grafo complementario** $\bar{G} = (V, \bar{E})$ mantiene los mismos vértices y contiene exactamente las aristas no presentes en E:

$$\{i, j\} \in \bar{E} \iff \{i, j\} \notin E \quad (\forall i \neq j)$$

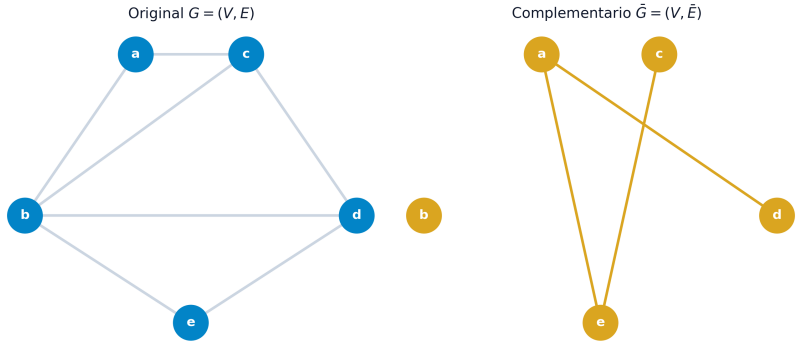

Recorridos y conectividad en redes

Recorridos en redes: Cadenas vs Caminos

Diferencia conceptual fundamental

- **Cadena** μ: Secuencia de arcos adyacentes $\mu = (u_1, u_2, \ldots, u_q)$ entre dos nodos que **no exige respetar la orientación de las flechas** (se pueden transitar en cualquier sentido). Caracteriza la **conectividad sintáctica/topológica**.
- **Camino** P: Secuencia de arcos orientados donde **todos los arcos se transitan strictly a favor de su sentido** (u_k finaliza donde u_{k+1} comienza). Caracteriza la **posibilidad real de transporte o flujo**.
- **En redes no dirigidas**, las nociones de cadena y camino resultan formalmente equivalentes.

Propiedades de recorridos: Elementalidad y Simplicidad

Definición: Elementalidad y Simplicidad

Dado un digrafo $G = (V, U)$ o grafo $G = (V, E)$:

- **Elemental**: Una cadena o camino es **elemental** si **no repite ningún vértice** en su secuencia.
- **Simple**: Una cadena o camino es **simple** si **no repite ningún arco o arista** en su secuencia.

- **Red de aeropuertos de referencia**: $V = \{m, l, p, f, s, t\}$ (Madrid, Londres, París, Frankfurt, Singapur, Tokio).

Ejemplo 1: Cadena elemental y simple (μ^1)

- **Cadena $\mu^1[m, p]$ de longitud $q = 3$:**

$$\mu^1 = \{(m, l), (l, f), (p, f)\}$$

- Recorre $\{m, l, f, p\}$ sin repetir ninguno $\Longrightarrow$ **Elemental**.
- Transita por 3 arcos distintos $\Longrightarrow$ **Simple**.
- El arco (p, f) en sentido inverso $\Longrightarrow$ Es una **cadena** (no un camino).

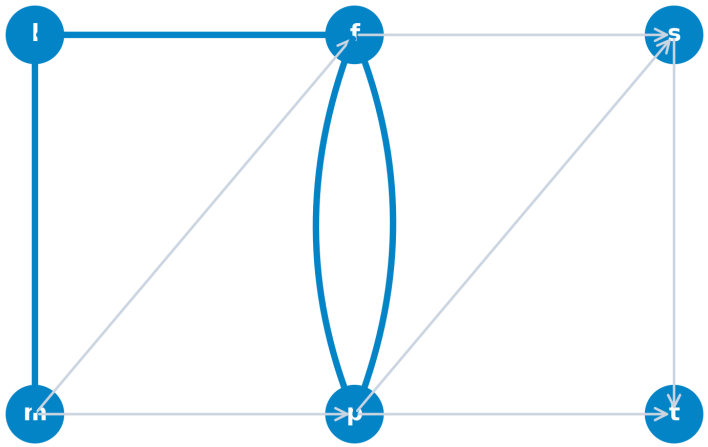

Ejemplo 2: Camino elemental y simple (μ^2)

- **Camino $\mu^2[p,t]$ de longitud $q = 3$:**

$$\mu^2 = \{(p,f),(f,s),(s,t)\}$$

- Todos los arcos en sentido directo $(p \to f \to s \to t)$ $\Longrightarrow$ Es un **camino**.
- No repite ningún vértice $\Longrightarrow$ **Elemental**.
- No repite ningún arco $\Longrightarrow$ **Simple**.

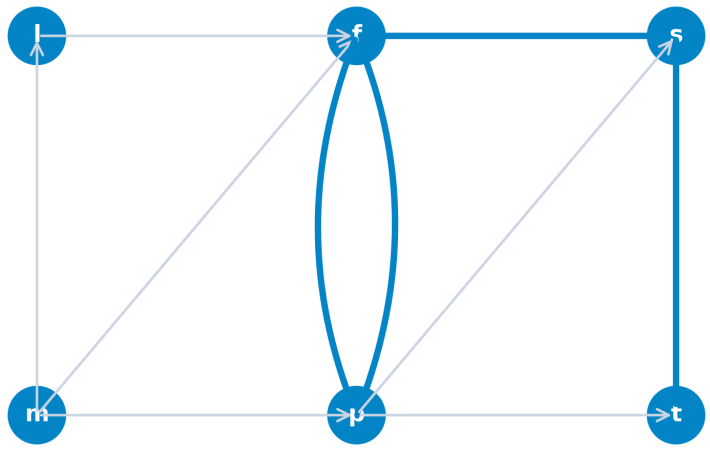

Ejemplo 3: Cadena simple no elemental (μ^3)

- **Cadena $\mu^3[m, p]$ de longitud $q = 5$:**

$$\mu^3 = \{(m, p), (p, f), (f, s), (p, s), (p, t)\}$$

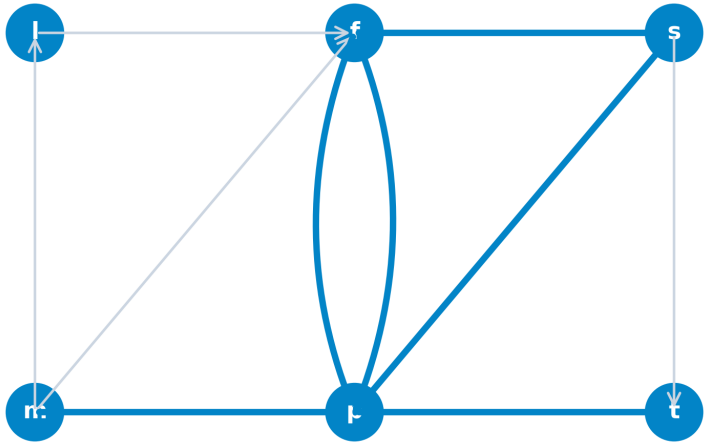

- Visita el nodo París (p) dos veces ($m \to p \to f \to s \to p \to t$) $\implies$ **No elemental**.
- No repite ninguno de sus 5 arcos $\implies$ **Simple**.

Ejemplo 4: Cadena ni elemental ni simple (μ^4)

- **Cadena μ^4 de longitud** $q = 6$:

$$\mu^4 = \{(l, f), (f, s), (p, s), (p, f), (f, s), (s, t)\}$$

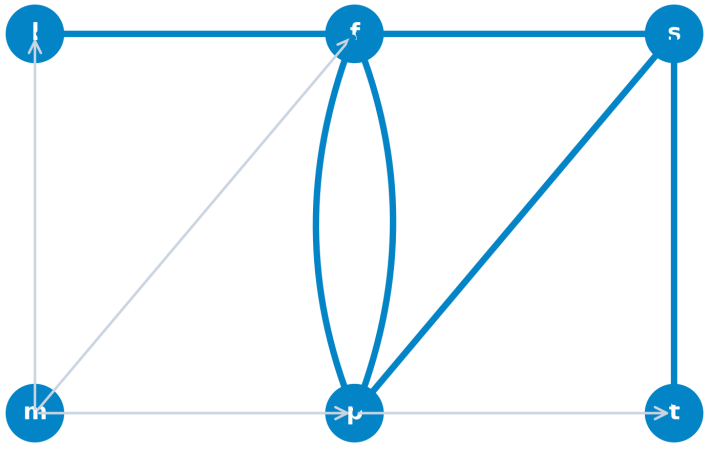

- Visita nodos repetidos $(f, s, p) \implies$ **No elemental**.
- Duplica el tránsito por el arco (f, s) dos veces $\implies$ **No simple**.

Ejemplo: Clasificación de cadenas (Análisis analítico)

Evaluación sobre un grafo no dirigido de 5 vértices $V = \{1, 2, 3, 4, 5\}$:

1. **Cadena** $\mu_1 = \{\{1, 2\}, \{2, 3\}, \{3, 4\}, \{4, 5\}\}$:
   - Visita 5 vértices distintos sin repetir ninguno $\implies$ **Elemental y simple**.
2. **Cadena** $\mu_2 = \{\{1, 2\}, \{2, 3\}, \{3, 4\}, \{4, 2\}, \{2, 5\}\}$:
   - Recorre 5 aristas distintas sin repetir ninguna, pero visita el nodo 2 dos veces $\implies$ **Simple pero no elemental**.
3. **Cadena** $\mu_3 = \{\{1, 2\}, \{2, 4\}, \{4, 3\}, \{3, 2\}, \{2, 1\}\}$:
   - Repite el nodo 2 y duplica la arista $\{1, 2\}$ $\implies$ **Ni elemental ni simple**.

Ejemplo: Clasificación de cadenas (Animación)

Ejemplo: Clasificación de caminos dirigidos (Análisis analítico)

Evaluación sobre una red dirigida de 7 vértices $V = \{a, b, c, d, e, f, g\}$:

1. **Camino** $P_1 = ((a, b), (b, c), (c, e), (e, f))$:
   - Transita en sentido directo por 5 vértices distintos y 4 arcos distintos $\implies$ **Elemental y simple**.
2. **Camino** $P_2 = ((c, g), (g, f), (f, b), (b, c), (c, e))$:
   - No repite arcos, pero el nodo c se visita dos veces $(c \to g \to f \to b \to c \to e) \implies$ **Simple pero no elemental**.
3. **Camino** $P_3 = ((c, e), (e, f), (f, b), (b, c), (c, e), (e, g))$:
   - Repite vértices (c, e) y duplica el arco $(c, e) \implies$ **Ni elemental ni simple**.

Ejemplo: Clasificación de caminos dirigidos (Animación)

Métricas de alcance y Diámetro $D(G)$

Definición: Distancia y Diámetro

- **Longitud**: Número de arcos q en la cadena.
- **Distancia geodésica** $d(i, j)$: Longitud de la cadena más corta entre i y j.
- **Diámetro** $D(G)$: Mayor distancia geodésica entre cualquier par de nodos:

$$D(G) = \max_{i,j \in V} d(i, j)$$

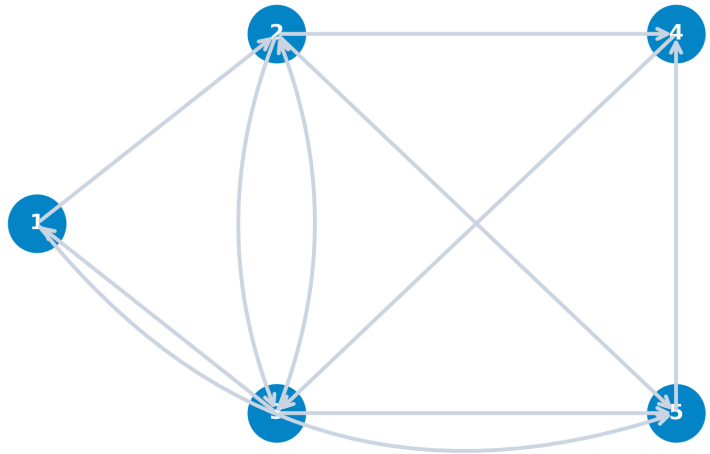

- En esta red de 5 nodos, la máxima distancia geodésica requerida para comunicar cualquier par es de 2 arcos $\implies D(G) = 2$.

Conectividad y conexidad fuerte

Definición: Grafo conexo y conexidad fuerte

Dado un grafo $G = (V, E)$ o digrafo $G = (V, U)$:

- **Grafo conexo (no dirigido)**: Existe al menos una **cadena** entre cualquier par de vértices.
- **Digrafo fuertemente conexo**: Existe al menos un **camino dirigido en ambos sentidos** (de i a j y de j a i) entre cualquier par de vértices.
- **Digrafo débilmente conexo**: Su grafo no dirigido subyacente es conexo (existen cadenas), pero carece de caminos dirigidos bidireccionales.

Ejemplo: Evaluación de conexidad en digrafos

- **Análisis de la red de 7 vértices**:
  - **Conexidad débil**: La red es **débilmente conexa** al existir cadenas no orientadas entre todo par de vértices.
  - **Fallo de conexidad fuerte**: La red **no es fuertemente conexa** porque el nodo d es un **sumidero** al que solo llegan arcos entrantes desde a, c, g, sin caminos salientes hacia los demás nodos.

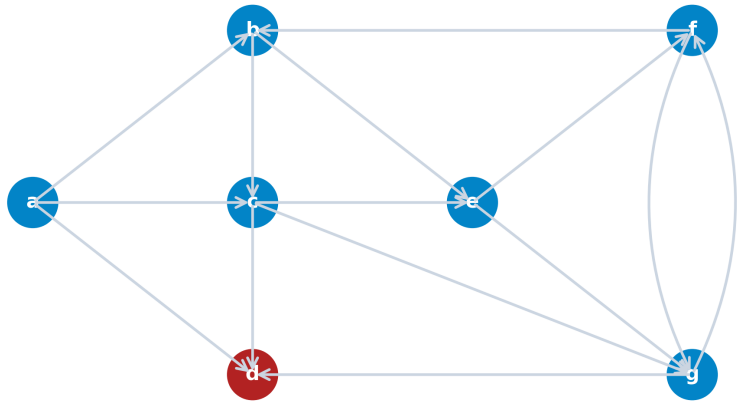

Componentes conexas como relación de equivalencia

Definición: Relación R de conexidad

$i \, R \, j \iff$
$\exists$ cadena entre i y j.
Es una **relación de equivalencia**:

1. **Reflexiva**: $i \, R \, i$ (cadena de longitud 0).
2. **Simétrica**: $i \, R \, j \implies j \, R \, i$.
3. **Transitiva**: $i \, R \, j \wedge j \, R \, k \implies i \, R \, k$.

Las clases de equivalencia definen las **componentes conexas**.

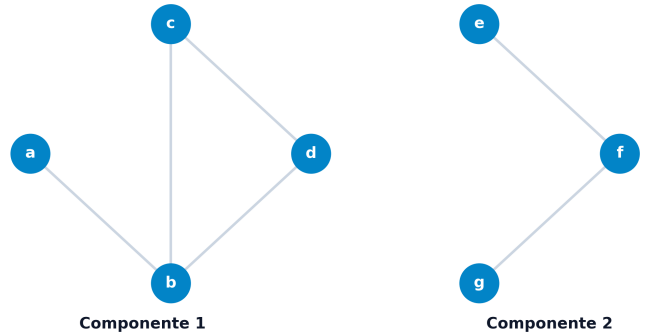

- Grafo descompuesto en 2 componentes conexas disjuntas.

Ciclos, circuitos y árboles

Definición: Recorridos cerrados

- **Ciclo**: Cadena simple cerrada $(v_0 = v_k)$.
- **Circuito**: Camino simple cerrado $(v_0 = v_k)$.
- **Bucle**: Ciclo de un solo arco/arista (i, i).
- **Árbol**: Grafo conexo acíclico.

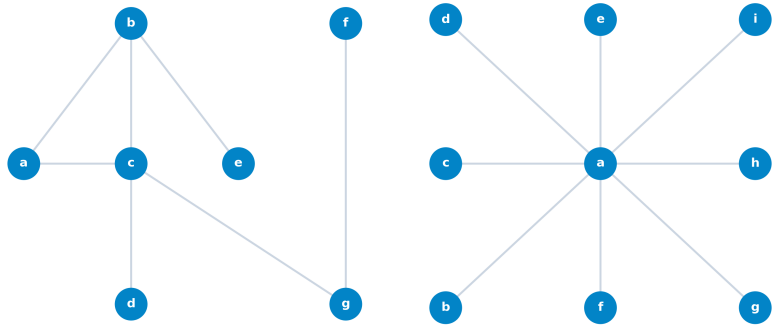

- Izquierda: Grafo con ciclo en triángulo.
- Derecha: Árbol en estrella acíclico.

Teorema de estructura de ciclos y hojas

! Propiedades estructurales

Para todo grafo conexo $G = (V, E)$ con $n > 1$:

1. **Ausencia de hojas**: Si todos los vértices tienen grado $d(v) \geq 2$, G contiene **al menos un ciclo**.
2. **Existencia de hojas**: Todo árbol conexo contiene **al menos un vértice pendiente** (hoja con $d(v) = 1$).
3. **Aristas en ciclos**: Una arista e pertenece a un ciclo si y solo si $G \setminus \{e\}$ sigue siendo conexo.

Grafos planares y bipartitos

Grafos planares y regiones

Definición: Grafo planar e incrustación

- **Grafo Planar**: Admite un dibujo en $\mathbb{R}^2$ sin intersecciones entre aristas.
- **Incrustación planar**: Dibujo sin cruces que divide el plano en r **caras/regiones** (incluyendo 1 región exterior no acotada).

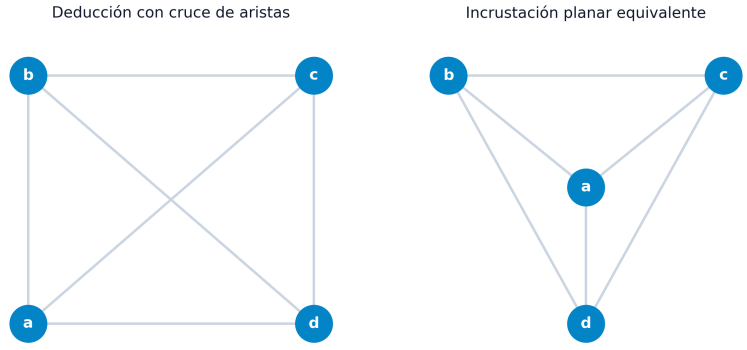

- El clan K_4 es **planar** al incrustar el nodo a dentro de la región $\{b, c, d\}$.

Acertijo de August Möbius (1840): El Rey y sus 5 Hijos

Testamento del Rey (Acertijo de August Möbius, 1840)

"Un rey ordenó en su testamento que, tras su muerte, su reino fuera dividido entre sus 5 hijos en 5 regiones contiguas de forma que cada región tuviera frontera común con todas las demás 4 regiones. ¿Es posible cumplir la voluntad del rey?"

- **Pregunta fundamental**: ¿Puede existir un mapa plano dividido en 5 regiones adyacentes donde todas compartan frontera común con las otras cuatro?

El Acertijo de Möbius y la no planaridad de K_5

- **Formulación mediante teoría de redes**:
  - Cumplir el testamento exige que el grafo dual de fronteras sea un **grafo completo de 5 vértices (K_5)**.
  - K_5 integra $n = 5$ vértices y $m = \frac{5 \times 4}{2} = 10$ aristas.
- **Resultado matemático**:
  - La respuesta es **negativa**.
  - K_5 es un **grafo no planar**: cualquier intento de incrustar sus 10 aristas en el plano produce al menos un cruce inevitable.

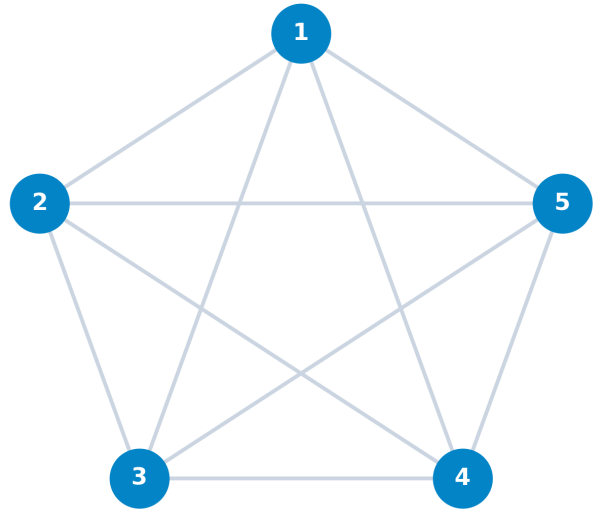

Grafos bipartitos y Bipartitos completos

Definición: Grafo bipartito y bipartito completo

Un grafo $G = (V, E)$ es **bipartito** si su conjunto de vértices admite una partición en dos subconjuntos disjuntos:

$$V = V_1 \cup V_2, \quad V_1 \cap V_2 = \emptyset$$

tal que toda arista conecta un vértice de V_1 con un vértice de V_2.

- **Bipartito Completo** K_{n_1,n_2}: Contiene todas las $n_1 \cdot n_2$ aristas entre V_1 y V_2.

Caracterización

Un grafo es bipartito $\iff$ **no contiene ningún ciclo de longitud impar**.

Problema de los tres servicios de Dudeney (1917)

Acertijo de Henry Ernest Dudeney (1917)

> *"¿Es posible canalizar las conducciones subterráneas de tres suministros esenciales (agua, gas y electricidad) hacia tres viviendas independientes de modo que ninguna tubería o cable se cruce con otro en el plano?"*

- **Pregunta fundamental**: ¿Es posible conectar 3 fuentes de suministro (A, G, E) a 3 casas (C_1, C_2, C_3) sin que los tendidos de tuberías o cables se intercepten en el plano?

El Problema de Dudeney y la no planaridad de $K_{3,3}$

- **Formulación mediante teoría de redes**:
  - Modela la incrustación del **grafo bipartito completo** $K_{3,3}$ ($n_1 = 3$ suministros, $n_2 = 3$ casas, $m = 3 \times 3 = 9$ aristas).
- **Resultado matemático**:
  - La respuesta al acertijo es **negativa**.
  - $K_{3,3}$ es un **grafo no planar**: tras trazar 8 conducciones, la novena queda atrapada en una cara acotada sin poder completarse sin cruzar una tubería previa.

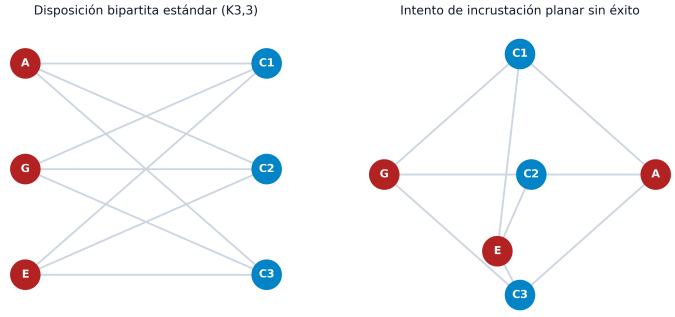

Homeomorfismo y Teorema de Kuratowski (1930)

Definición: Homeomorfismo

Dos grafos son **homeomórficos** si se obtienen uno del otro mediante subdivisión elemental de aristas (insertar/suprimir nodos de grado 2).

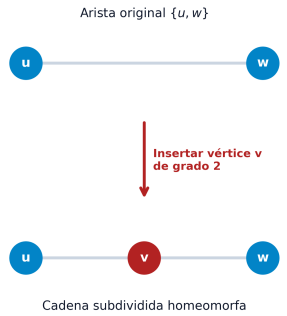

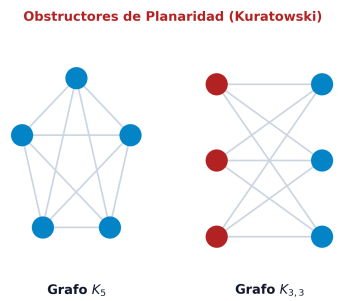

Teorema de Kuratowski (1930)

Un grafo G es **planar** $\iff$ **no contiene ningún subgrafo homeomórfico a K_5 ni a $K_{3,3}$.**

Demostración: Grafo de Petersen

- **Grafo de Petersen**: Grafo 3-regular con 10 vértices y 15 aristas.
- **No planaridad**: Contiene un subgrafo parcial homeomórfico a $K_{3,3}$.
- **Subdivisión**: Nodos rojos $V_1 = \{j, a, d\}$, nodos azules $V_2 = \{e, f, b\}$. Vértices g, h, i, c actúan de grado 2.

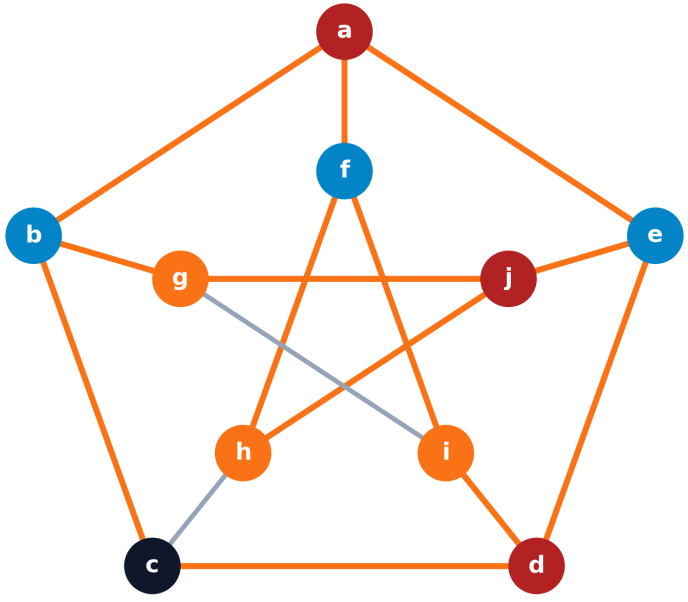

Fórmula planar de Euler

Fórmula planar de Euler

En todo grafo planar conexo con n vértices, m aristas y r regiones (incluyendo la cara exterior no acotada):

$$n + r = m + 2$$

- **Significado geométrico**:
  - Relación invariante entre vértices, aristas y caras sobre la superficie del plano.
  - Permite deducir las cotas superiores absolutas sobre la densidad de aristas en grafos planares.

Corolarios de la Fórmula de Euler

Corolario: Desigualdades de planaridad

1. En todo grafo planar conexo simple con $n \geq 3$:

$$m \leq 3n - 6$$

2. En todo grafo planar conexo simple **bipartito** (sin triángulos):

$$m \leq 2n - 4$$

Ejemplo: Prueba analítica de no planaridad

- **Prueba para K_5 ($n = 5, m = 10$):**
  - Condición de planaridad para $n \geq 3$:

    $$m \leq 3n - 6$$

  - Evaluación:

    $10 \leq 3(5) - 6 = 9$ (FALSO)

  - **Conclusión**: K_5 es **no planar**.

- **Prueba para $K_{3,3}$ ($n = 6, m = 9$):**
  - Grafo bipartito sin triángulos:

    $$m \leq 2n - 4$$

  - Evaluación:

    $9 \leq 2(6) - 4 = 8$ (FALSO)

  - **Conclusión**: $K_{3,3}$ es **no planar**.

Representación de grafos

Matriz de incidencia (Grafo no dirigido)

Definición: Matriz de incidencia nodo-arista

Dada una red no dirigida $G = (V, E)$, la **matriz de incidencia** $A \in \mathbb{R}^{n \times m}$ se define como:

$$a_{ik} = \begin{cases} 1 & \text{si } i \text{ es extremo de arista } e_k \\ 0 & \text{en otro caso} \end{cases}$$

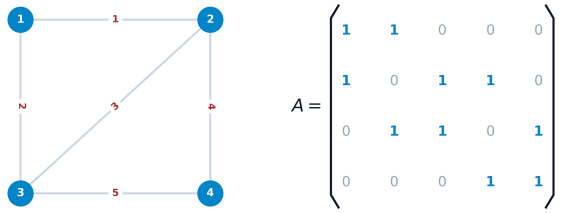

- **Suma por columnas**: Toda columna de A suma exactamente 2 (cada arista posee 2 extremos).

Matriz de incidencia (Digrafo y TUM)

Definición: Matriz de incidencia nodo-arco

Dado un digrafo $G = (V, U)$, la matriz $A \in \mathbb{R}^{n \times m}$ registra la orientación:

$$a_{ik} = \begin{cases} +1 & \text{si } i \text{ es el origen del arco } u_k \\ -1 & \text{si } i \text{ es el destino del arco } u_k \\ 0 & \text{en otro caso} \end{cases}$$

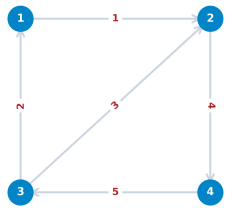

$$A = \begin{pmatrix} 1 & -1 & 0 & 0 & 0 \\ -1 & 0 & -1 & 1 & 0 \\ 0 & 1 & 1 & 0 & -1 \\ 0 & 0 & 0 & -1 & 1 \end{pmatrix}$$

- **Propiedad de Total Unimodularidad (TUM)**: Todo subdeterminante es $0, \pm 1$, garantizando soluciones enteras en flujos.

Matriz de adyacencia (Grafo no dirigido)

Definición: Matriz de adyacencia no dirigida

Dado un grafo simple no dirigido $G = (V, E)$, la **matriz de adyacencia** $B \in \mathbb{R}^{n \times n}$ se define como:

$$b_{ij} = \begin{cases} 1 & \text{si } \{i, j\} \in E \\ 0 & \text{en otro caso} \end{cases}$$

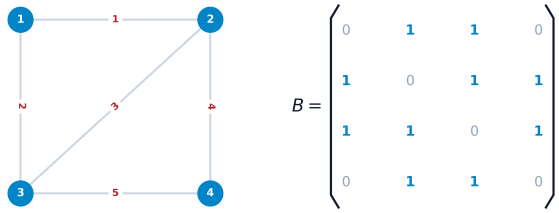

- **Matriz simétrica**: $B = B^T$ con ceros en la diagonal $(b_{ii} = 0)$.

Matriz de adyacencia (Digrafo)

Definición: Matriz de adyacencia orientada

Dado un digrafo $G = (V, U)$, la matriz $B \in \mathbb{R}^{n \times n}$ es asimétrica:

$$b_{ik} = \begin{cases} 1 & \text{si } (i,k) \in U \\ 0 & \text{en otro caso} \end{cases}$$

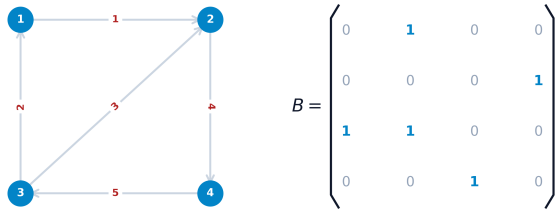

- **Conteo de caminos**: El elemento $(B^p)_{ik}$ de la potencia B^p indica el número exacto de caminos de longitud p entre los nodos i y k.

Motivación: Redes dispersas y almacenamiento

- **Inconveniente de matrices densas**: En redes dispersas (donde el número de arcos es mucho menor que el cuadrado de nodos, $m \ll n^2$), las matrices de adyacencia o incidencia almacenan más del 99% de entradas nulas (ceros).
- **Almacenamiento lineal eficiente**: Para optimizar el uso de memoria y la velocidad de cómputo, las matrices se sustituyen por dos vectores unidimensionales de dimensión reducida:
  - **Vector** β (dimensión m): Almacena los nodos de destino.
  - **Vector** α (dimensión $n+1$): Almacena los punteros de inicio.

Esquema de punteros (α, β) en digrafos

- **Vector** β (dimensión m): Contiene los nodos de destino j de todos los arcos $(i, j) \in U$, agrupados en orden lexicográfico según el nodo origen i.
- **Vector** α (dimensión $n + 1$): Punteros que indican la posición en β donde comienzan los arcos salientes de cada nodo i.
  - **Condición de cierre**: $\alpha(n + 1) = m + 1$.

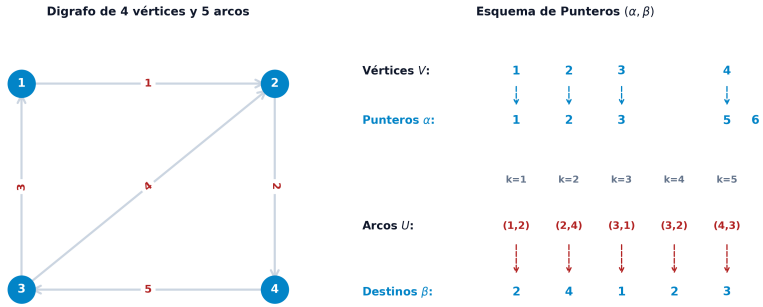

Ejemplo: Evaluación de vectores (α, β) en redes

- **Recurrencia regresiva para** α:

$$\alpha(k) = \alpha(k+1) - d^+(k)$$

con la condición inicial $\alpha(n+1) = m+1$.

- **Evaluación en la red** $(n = 6, m = 10)$:
  - Condición inicial: $\alpha(7) = 10 + 1 = 11$.
  - Vector de destinos $\beta \in \mathbb{R}^{10}$.
  - Vector de punteros resultante:

$$\alpha = (1, 4, 5, 7, 10, 11, 11)$$

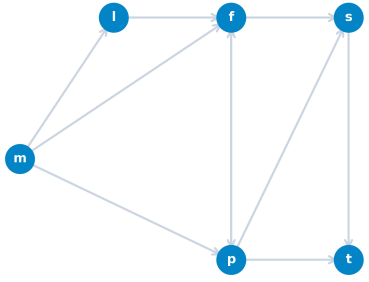

Arc j	u_j	beta(j)
1	(m, l)	l
2	(m, f)	f
3	(m, p)	p
4	(l, f)	f
5	(f, p)	p
6	(f, s)	s
7	(p, f)	f
8	(p, s)	s
9	(p, t)	t
10	(s, t)	t

Recurrencia de α:
$\alpha(t+1) = 11$
$\alpha(t) = 11 - 0 = 11$
$\alpha(s) = 11 - 1 = 10$
$\alpha(p) = 10 - 3 = 7$
$\alpha(f) = 7 - 2 = 5$
$\alpha(l) = 5 - 1 = 4$
$\alpha(m) = 4 - 3 = 1$

$\alpha = (1, 4, 5, 7, 10, 11, 11)$

Representación vectorial en grafos no dirigidos

- **Descomposición bidireccional**: En grafos no dirigidos $G = (V, E)$, cada arista $\{i, j\}$ se descompone en dos arcos orientados opuestos (i, j) y (j, i).
- **Dimensiones de los vectores**:
  - **Vector** β: Duplica su dimensión a $2m$ elementos para registrar ambas direcciones.
  - **Vector** α: Mantiene la dimensión $n + 1$ con $\alpha(n + 1) = 2m + 1$.

Grafo No Dirigido $V = \{a, b, c, d, e\}$ $(n = 5, m = 7)$

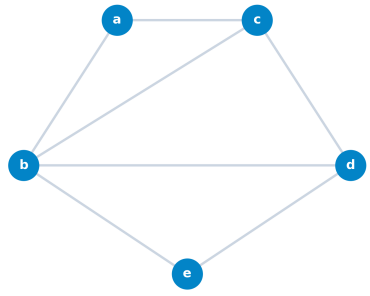

Arista j	beta(j)
{a, b}	b
{a, c}	c
{b, c}	c
{b, d}	d
{b, e}	e
{c, d}	d
{d, e}	e

Construcción del Vector α:
$\alpha(e + 1) = 8$
$\alpha(e) = 8 - 0 = 8$
$\alpha(d) = 8 - 1 = 7$
$\alpha(c) = 7 - 1 = 6$
$\alpha(b) = 6 - 3 = 3$
$\alpha(a) = 3 - 2 = 1$

$\alpha = (1, 3, 6, 7, 8, 8)$

Listas de adyacencia en digrafos

- **Estructura dinámica**:
  Arreglo de punteros Adj$[i]$ donde cada nodo i encadena la lista de sus nodos sucesores $\Gamma^+(i)$.
- **Propiedades computacionales**:
  - **Memoria óptima**:
    Complejidad espacial $O(n+m)$.
  - **Eficiencia dinámica**:
    Permite insertar y eliminar arcos de forma dinámica con tiempo $O(1)$.

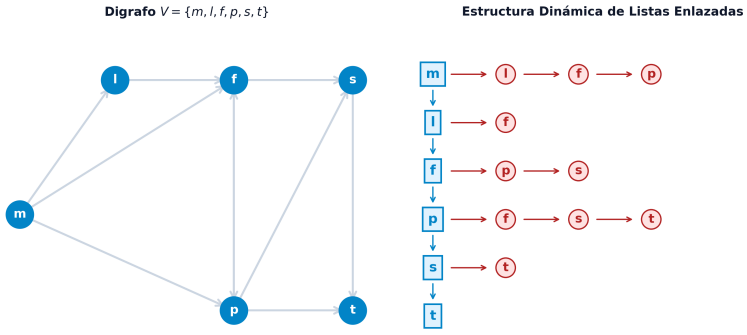

Listas de adyacencia en grafos no dirigidos

- **Listas enlazadas recíprocas**: En grafos no dirigidos $G = (V, E)$, cada arista no dirigida $\{u, v\}$ genera dos entradas recíprocas en las estructuras enlazadas:
  - El nodo v se añade a la lista Adj$[u]$.
  - Simétricamente, el nodo u se incorpora a la lista Adj$[v]$.
- **Ejemplo sobre** $V = \{a, b, c, d, e\}$: Representación en red de 5 vértices con conexiones simétricas bidireccionales.

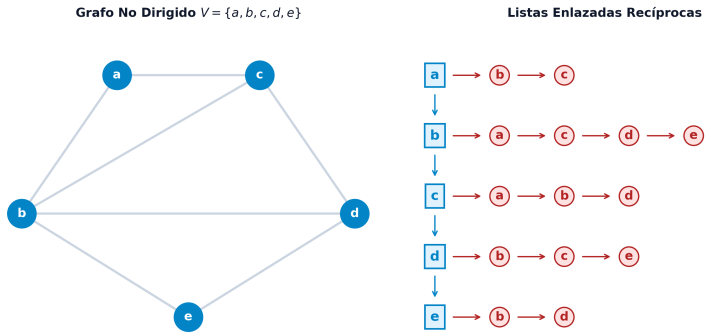

Estructura matemática de los árboles

Definición de Árbol y Bosque

Definición: Árbol y bosque

- **Árbol**: Grafo no dirigido **conexo y acíclico**.
- **Bosque**: Grafo acíclico cuyas componentes conexas son árboles.
- **Matriz de incidencia**: Sus columnas son linealmente independientes.

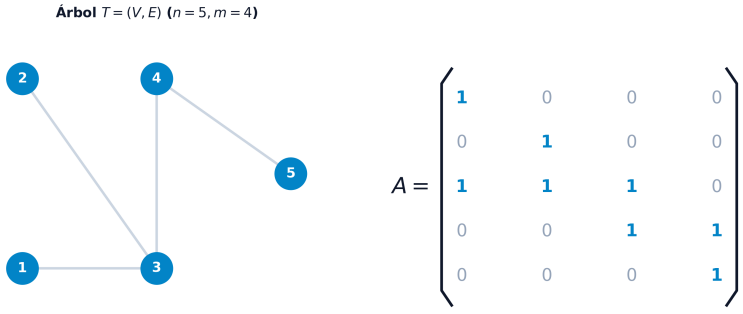

Teorema: Caracterizaciones de un árbol (Parte 1)

! Caracterizaciones equivalentes (1 a 3)

Dado un grafo no dirigido $G = (V, E)$ con n vértices y m aristas, las siguientes propiedades son **equivalentes**:

1. **Conexo y acíclico**: G es un grafo conexo sin ningún ciclo.
2. **Acíclico maximal**: G es acíclico y al añadir una nueva arista entre cualquier par de vértices no adyacentes se crea **exactamente un ciclo**.
3. **Unicidad de cadenas**: Existe una **única cadena simple** entre todo par de vértices de G.

Teorema: Caracterizaciones de un árbol (Parte 2)

! Caracterizaciones equivalentes (4 a 6)

4. **Mínimamente conexo**: G es conexo y la eliminación de cualquier arista **lo desconecta** ($G \setminus \{e\}$ no es conexo).
5. **Acíclico con $m = n - 1$ aristas**: G es acíclico y el número de aristas satisface exactamente $m = n - 1$.
6. **Conexo con $m = n - 1$ aristas**: G es conexo y el número de aristas satisface exactamente $m = n - 1$.

Fórmula de Cayley y Vector de padres

- **Fórmula de Cayley (1889)**: El número de árboles soporte sobre n vértices es:

$$T(n) = n^{n-2}$$

- **Representación por Vector de Padres** $p(v)$: Al elegir una raíz x_0, $p(v)$ almacena el antecesor directo en la cadena desde x_0. Ocupa solo n enteros.

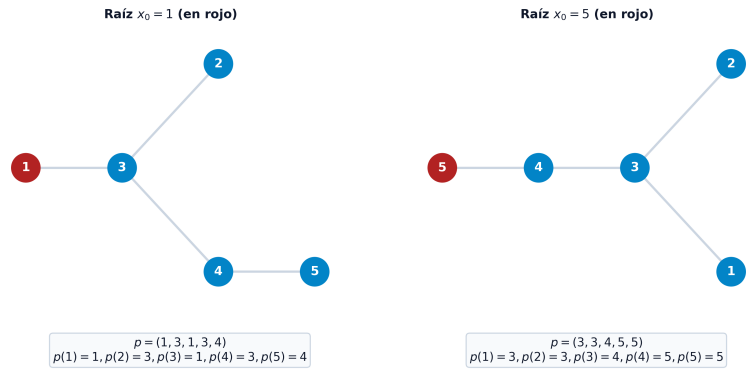

- Izquierda: Raíz $x_0 = 1 \implies p = (1, 3, 1, 3, 4)$.
- Derecha: Raíz $x_0 = 5 \implies p = (3, 3, 4, 5, 5)$.

Árbol soporte de mínimo peso (MST)

Redes valoradas: Definición y Notación

Definición: Red valorada y peso de aristas

Una **red valorada** es un par $(G, \mathbf{d})$, donde $G = (V, E)$ o $G = (V, U)$ es un grafo o digrafo y $\mathbf{d} \in \mathbb{R}^m$ es un vector cuyas componentes asignan un coste o peso $d(e) = d_e$ a cada arista $e \in E$ (o c_{ij} a cada arco $(i, j) \in U$).

Formulación Primal del Problema del MST

! Formulación Primal del Problema del MST

Dada una red valorada conexa no dirigida $(G, \mathbf{d})$ con $G = (V, E)$ y pesos $\{d_e : e \in E\}$, el **Problema del Árbol Soporte de Mínimo Peso** (*Minimum Spanning Tree*, MST) busca un subconjunto de aristas $T \subset E$ tal que $H = (V, T)$ sea un árbol soporte que minimice el peso acumulado:

$$\begin{aligned} \min_{T \subset E} \quad & d(T) = \sum_{e \in T} d_e \\ \text{sujeto a} \quad & H = (V, T) \text{ es un árbol soporte de } G \end{aligned}$$

Ejemplo: Espacio de soluciones del MST

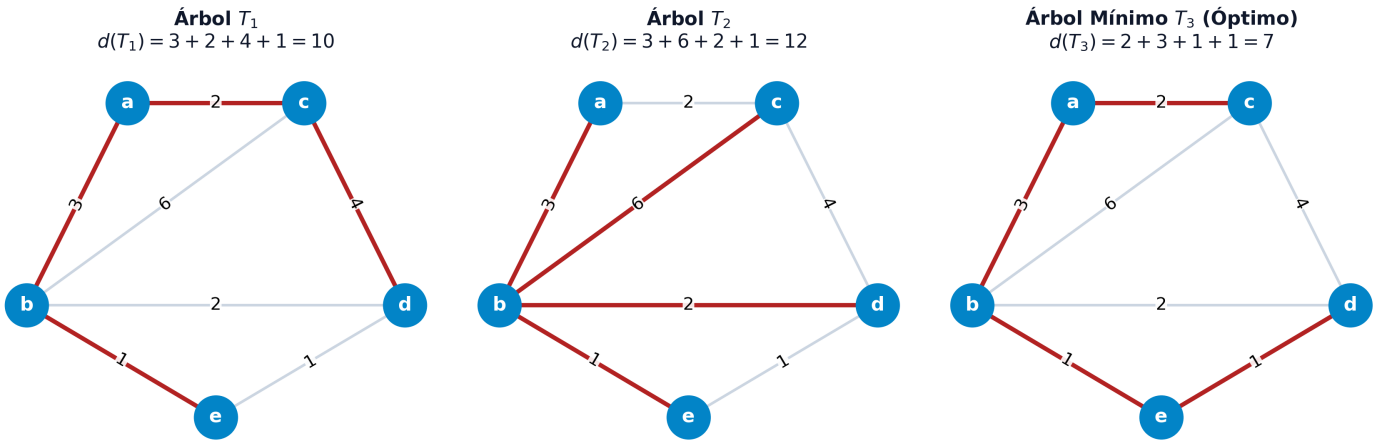

- Comparación de tres árboles soporte candidatos sobre una red no dirigida de 5 vértices $V = \{a, b, c, d, e\}$.

Ejemplo: Evaluación de coste en árboles candidatos

Evaluación de pesos acumulados sobre la red de 5 vértices:

- **Candidato** T_1 $(\{a,b\},\{a,c\},\{c,d\},\{b,e\})$:

$$d(T_1) = 3 + 2 + 4 + 1 = 10$$

- **Candidato** T_2 $(\{a,b\},\{b,c\},\{b,d\},\{b,e\})$:

$$d(T_2) = 3 + 6 + 2 + 1 = 12$$

- **Árbol Mínimo** T_3 **(Óptimo)** $(\{a,c\},\{a,b\},\{b,e\},\{e,d\})$:

$$d(T_3) = 2 + 3 + 1 + 1 = 7$$

Teorema: Propiedad del Corte (Cut Property)

! Teorema: Propiedad del Corte (Cut Property)

Sea $(G, \mathbf{d})$ una red valorada conexa no dirigida. Dado cualquier subconjunto propio de vértices $S \subset V$, si la arista $e^* = \{u, v\}$ con $u \in S, v \in V \setminus S$ es la arista de **peso estrictamente mínimo** que cruza el corte $w(S)$, entonces la arista e^* **pertenece obligatoriamente a todo Árbol Soporte de Mínimo Peso** de G.

- **Fundamento algorítmico**: La propiedad del corte permite tomar decisiones locales óptimas (*golosas*) sin necesidad de evaluar la cantidad exponencial de árboles soporte ($T(n) = n^{n-2}$).

Algoritmo de Kruskal: Estrategia Golosa

Filosofía del Algoritmo de Kruskal (1956)

- Propuesto por Joseph Kruskal (1956), adopta una **estrategia golosa (*greedy*) global** centrada en el ordenamiento de las aristas.
- Examina secuencialmente las aristas de la red en orden creciente de peso e incorpora a la solución parcial la arista disponible de menor coste, siempre que **no genere ningún ciclo** con las aristas previamente seleccionadas.

- **Bosque disjunto parcial**: En las fases intermedias, las aristas en T no forman una estructura conexa continua, sino un **bosque parcial de árboles disjuntos** que se fusionan progresivamente hasta alcanzar $|T| = n - 1$ aristas.

Esquema de Kruskal: Inicialización y Selección

Dada una red no dirigida valorada $G = (V, E, \mathbf{d})$ con $n = |V| > 1$ vértices:

- **Paso 0 (Inicialización)**:
  - Definir $T = \emptyset$ y conjunto de aristas disponibles $A \leftarrow E$.
- **Paso 1 (Bucle de Selección Golosa)**:
  - Mientras $|T| < n - 1$ y $A \neq \emptyset$:
    1. Identificar la arista $e \in A$ de menor peso global.
    2. Actualizar el conjunto de disponibles: $A \leftarrow A \setminus \{e\}$.
    3. Si el subconjunto $T \cup \{e\}$ **no contiene ningún ciclo**, aceptar: $T \leftarrow T \cup \{e\}$.

Esquema de Kruskal: Criterio de Parada

- **Paso 2 (Criterio de Parada y Verificación)**:
  - **Éxito**: Si $|T| = n - 1$, el par $H = (V, T)$ es un **Árbol Soporte de Mínimo Peso (MST)**.
  - **Desconexión**: Si $A = \emptyset$ y $|T| < n - 1$, la red G no era conexa, obteniéndose el bosque soporte de mínimo peso de sus componentes conexas.

Estructura Union-Find y Complejidad de Kruskal

Detección de ciclos con Union-Find

- Cada vértice inicia en su propio bloque disjunto: $S_k = \{k\}, \forall k \in V$.
- Para cada arista $e = \{i, j\}$, se consulta Find(i) y Find(j).
- Si Find$(i) \neq$ Find(j), **no hay ciclo**: se acepta la arista en T y se ejecuta Union$(S(i), S(j))$.
- Si Find$(i) =$ Find(j), la arista se descarta.

Complejidad computacional

- **Preordenación de aristas**: Ordenar las m aristas requiere $O(m \log m)$.
- Dado que $m \leq n^2 \implies \log m \leq 2 \log n$.
- **Complejidad total**: $O(m \log n)$ o $O(m \cdot \alpha(n))$ si las aristas están preordenadas.

Ejemplo Kruskal: Red de 6 vértices y Matriz de pesos

- **Planteamiento**: Obtener el MST mediante el Algoritmo de Kruskal para una red no dirigida de $n = 6$ vértices y 11 aristas valoradas con costes entre $d = 1$ y $d = 10$.
- **Topología y Matriz simétrica de pesos** $B \in \mathbb{R}^{6\times 6}$:

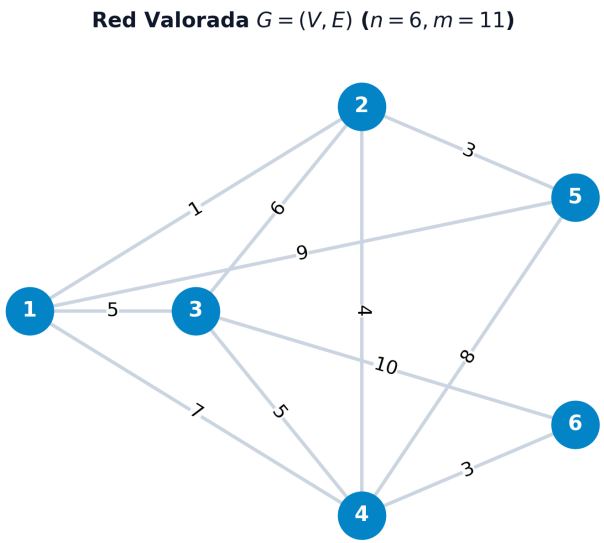

$$B = \begin{pmatrix} \cdot & \mathbf{1} & 5 & 7 & 9 & \infty \\ \mathbf{1} & \cdot & 6 & 4 & 3 & \infty \\ 5 & 6 & \cdot & 5 & \infty & 10 \\ 7 & 4 & 5 & \cdot & 8 & 3 \\ 9 & 3 & \infty & 8 & \cdot & \infty \\ \infty & \infty & 10 & 3 & \infty & \cdot \end{pmatrix}$$

Ejemplo Kruskal: Estado inicial ($k = 0$)

- **Vértices de la red**: $V = \{1, 2, 3, 4, 5, 6\}$ $(n = 6)$.
- **Árbol parcial vacíos**: $T = \emptyset$.
- **Estructura de subconjuntos disjuntos iniciales**:

$$\{1\}, \{2\}, \{3\}, \{4\}, \{5\}, \{6\}$$

- **Aristas candidatas ordenadas por peso creciente**:

1. $\{1, 2\}$ $(d = 1)$
2. $\{2, 5\}$ $(d = 3)$, $\{4, 6\}$ $(d = 3)$
3. $\{2, 4\}$ $(d = 4)$
4. $\{1, 3\}$ $(d = 5)$, $\{3, 4\}$ $(d = 5)$
5. $\{2, 3\}$ $(d = 6)$, $\{1, 4\}$ $(d = 7)$, $\{4, 5\}$ $(d = 8)$, $\{1, 5\}$ $(d = 9)$, $\{3, 5\}$ $(d = 9)$, $\{3, 6\}$ $(d = 10)$

Ejemplo Kruskal: Iteración 1 ($k = 1, d = 1$)

- **Selección de la arista de menor peso global**: $e_1 = \{1, 2\}$ con $d_{\{1,2\}} = 1$.
- **Consulta Union-Find**: $\text{Find}(1) \neq \text{Find}(2) \implies \{1\} \neq \{2\}$.
- **Actualización del árbol parcial**:
  - $T = \{\{1, 2\}\}$.
  - Subconjuntos disjuntos fusionados:

$$\{1, 2\},\ \{3\},\ \{4\},\ \{5\},\ \{6\}$$

Ejemplo Kruskal: Iteraciones 2 y 3 ($d = 3$, empates)

- **Iteración $k = 2$ ($d = 3$)**:
  - Candidatas de peso 3: $\{2, 5\}$ y $\{4, 6\}$. Seleccionar $\{2, 5\}$.
  - Find$(2) \neq$ Find$(5) \implies$ Aceptar $\{2, 5\}$.
  - $T = \{\{1, 2\}, \{2, 5\}\}$.
  - Subconjuntos: $\{1, 2, 5\}$, $\{3\}$, $\{4\}$, $\{6\}$.
- **Iteración $k = 3$ ($d = 3$)**:
  - Seleccionar la arista $\{4, 6\}$ de peso 3.
  - Find$(4) \neq$ Find$(6) \implies$ Aceptar $\{4, 6\}$.
  - $T = \{\{1, 2\}, \{2, 5\}, \{4, 6\}\}$.
  - Subconjuntos: $\{1, 2, 5\}$, $\{3\}$, $\{4, 6\}$.

Ejemplo Kruskal: Iteraciones 4 y 5 ($d = 4, d = 5$)

- **Iteración $k = 4$ ($d = 4$)**:
  - Arista $\{2, 4\}$ de peso 4.
  - Find$(2) \in \{1, 2, 5\}$ y Find$(4) \in \{4, 6\} \implies$ Componentes distintas, no forma ciclo.
  - $T = \{\{1, 2\}, \{2, 5\}, \{4, 6\}, \{2, 4\}\}$.
  - Subconjuntos: $\{1, 2, 4, 5, 6\}$, $\{3\}$.
- **Iteración $k = 5$ ($d = 5$, empate con $\{3, 4\}$)**:
  - Arista $\{1, 3\}$ de peso 5.
  - Find$(1) \in \{1, 2, 4, 5, 6\}$ y Find$(3) \in \{3\} \implies$ Aceptar $\{1, 3\}$.
  - $T = \{\{1, 2\}, \{2, 5\}, \{4, 6\}, \{2, 4\}, \{1, 3\}\}$.
  - Subconjuntos: $\{1, 2, 3, 4, 5, 6\}$ (1 sola componente conexa).

Ejemplo Kruskal: Conclusión y Peso Mínimo

- **Criterio de parada**: Se alcanzan exactamente $|T| = n - 1 = 5$ aristas en la solución parcial.
- **Cálculo del Peso Óptimo Acumulado**:

$$\begin{aligned} d(T) &= d_{\{1,2\}} + d_{\{2,5\}} + d_{\{4,6\}} + d_{\{2,4\}} + d_{\{1,3\}} \\ &= 1 + 3 + 3 + 4 + 5 = 16 \end{aligned}$$

- **Árbol Soporte Mínimo resultado**: $H = (V, T)$ con $T = \{\{1,2\}, \{2,5\}, \{4,6\}, \{2,4\}, \{1,3\}\}$.

Ejemplo Kruskal: Solución Óptima Alternativa T'

- **Resolución de empate en $k = 5$**: En la iteración 5 existía un empate entre $\{1, 3\}$ $(d = 5)$ y $\{3, 4\}$ $(d = 5)$.
- **Árbol Soporte Mínimo Alternativo T'**: Si se hubiese seleccionado $\{3, 4\}$ en lugar de $\{1, 3\}$:

$$T' = \{\{1, 2\}, \{2, 5\}, \{4, 6\}, \{2, 4\}, \{3, 4\}\}$$

- **Peso del árbol alternativo**:

$$d(T') = 1 + 3 + 3 + 4 + 5 = 16$$

- **Conclusión**: Cuando existen pesos duplicados, el árbol mínimo **puede no ser único**, aunque el peso óptimo $d(T)$ es siempre constante e invariable.

Ejemplo Kruskal: Traza animada interactiva

Complejidad del Algoritmo de Kruskal

Complejidad computacional de Kruskal

- **Sin ordenación previa de aristas**: $O(m \log m) = O(m \log n)$.
- **Con aristas preordenadas**: $O(m \cdot \alpha(n))$ (casi lineal mediante compresión de caminos en Union-Find).

Algoritmo de Prim (Jarník-Prim-Dijkstra)

Historia y Filosofía del Algoritmo de Prim (1957)

- Descubierto por Vojtěch Jarník (1930), redescubierto por Robert C. Prim (1957) y Edsger W. Dijkstra (1959).
- A diferencia de Kruskal (que gestiona un bosque inconexo), Prim hace crecer **una única arborescencia conexa continua** desde un nodo raíz inicial $v_1 \in V$.

- **Corte de la arborescencia**: Sea $P \subset V$ los nodos ya integrados ($P = \{v_1\}$ inicialmente) y $N = V \setminus P$ los nodos pendientes. En cada iteración se selecciona la arista de peso mínimo del corte $w(P)$.

Esquema de Prim: Inicialización y Selección

Dada una red no dirigida valorada $G = (V, E, \mathbf{d})$ conexa con $n = |V| > 1$:

- **Paso 0 (Inicialización)**:
  - Seleccionar nodo raíz arbitrario $v_1 \in V$.
  - $P = \{v_1\}, N = V \setminus \{v_1\}, T = \emptyset, i = 1$.
- **Paso 1 (Arista Mínima del Corte $w(P)$)**:
  - Identificar $e^* = \{x^*, y^*\}$ con $x^* \in P, y^* \in N$ tal que:

$$d(e^*) = \min\{d(e) : e = \{x, y\}, x \in P, y \in N\}$$

  - Actualizar: $P \leftarrow P \cup \{y^*\}, N \leftarrow N \setminus \{y^*\}, T \leftarrow T \cup \{e^*\}$.

Esquema de Prim: Criterio de Parada

- **Paso 2 (Criterio de Parada e Incremento)**:
  - **Éxito**: Si $i = n - 1$, detener el procedimiento: el par $H = (V, T)$ es un **Árbol Soporte de Mínimo Peso (MST)**.
  - **Iteración continua**: Si $i < n - 1$, actualizar $i \leftarrow i + 1$ y regresar al Paso 1.

Ejemplo Prim: Planteamiento y Raíz Inicial ($v_1 = 1$)

- **Misma red de referencia de 6 vértices**:
  $V = \{1, 2, 3, 4, 5, 6\}$ y 11 aristas.
- **Selección arbitraria del nodo raíz**: $v_1 = 1$.
- **Estado inicial ($i = 1$)**:
  - Nodos integrados en la arborescencia: $P = \{1\}$.
  - Nodos pendientes de visitar: $N = \{2, 3, 4, 5, 6\}$.
  - Aristas del árbol parcial: $T = \emptyset$.

Ejemplo Prim: Iteraciones 1 y 2 ($i = 1, i = 2$)

- **Iteración** $i = 1$:
  - Corte $w(P)$ desde $P = \{1\}$ hacia N: $\{1, 2\}$ $(d = 1)$, $\{1, 3\}$ $(d = 5)$, $\{1, 4\}$ $(d = 7)$, $\{1, 5\}$ $(d = 9)$.
  - Arista de peso mínimo: $e^* = \{1, 2\}$ con $d = 1$.
  - Actualización: $P = \{1, 2\}$, $N = \{3, 4, 5, 6\}$, $T = \{\{1, 2\}\}$.
- **Iteración** $i = 2$:
  - Corte $w(P)$ desde $P = \{1, 2\}$ hacia N: $\{1, 3\}$ $(d = 5)$, $\{1, 4\}$ $(d = 7)$, $\{1, 5\}$ $(d = 9)$, $\{2, 3\}$ $(d = 6)$, $\{2, 4\}$ $(d = 4)$, $\{2, 5\}$ $(d = 3)$.
  - Arista de peso mínimo: $e^* = \{2, 5\}$ con $d = 3$.
  - Actualización: $P = \{1, 2, 5\}$, $N = \{3, 4, 6\}$, $T = \{\{1, 2\}, \{2, 5\}\}$.

Ejemplo Prim: Iteraciones 3 y 4 ($i = 3, i = 4$)

- **Iteración** $i = 3$:
  - Corte $w(P)$ desde $P = \{1, 2, 5\}$ hacia $N = \{3, 4, 6\}$: $\{1, 3\}$ $(d = 5)$, $\{2, 4\}$ $(d = 4)$, $\{5, 4\}$ $(d = 8)$, etc.
  - Arista de peso mínimo: $e^* = \{2, 4\}$ con $d = 4$.
  - Actualización: $P = \{1, 2, 4, 5\}$, $N = \{3, 6\}$, $T = \{\{1, 2\}, \{2, 5\}, \{2, 4\}\}$.
- **Iteración** $i = 4$:
  - Corte $w(P)$ desde $P = \{1, 2, 4, 5\}$ hacia $N = \{3, 6\}$: $\{1, 3\}$ $(d = 5)$, $\{4, 3\}$ $(d = 5)$, $\{4, 6\}$ $(d = 3)$.
  - Arista de peso mínimo: $e^* = \{4, 6\}$ con $d = 3$.
  - Actualización: $P = \{1, 2, 4, 5, 6\}$, $N = \{3\}$, $T = \{\{1, 2\}, \{2, 5\}, \{2, 4\}, \{4, 6\}\}$.

Ejemplo Prim: Iteración 5 y Cierre ($i = 5$)

- **Iteración** $i = 5$:
  - Corte $w(P)$ desde $P = \{1, 2, 4, 5, 6\}$ hacia el único nodo restante $N = \{3\}$:
    - $\{1, 3\}$ $(d = 5)$, $\{4, 3\}$ $(d = 5)$, $\{2, 3\}$ $(d = 6)$, $\{5, 3\}$ $(d = 9)$, $\{6, 3\}$ $(d = 10)$.
  - **Resolución del empate**: Aristas de peso mínimo 5 ($\{1, 3\}$ y $\{3, 4\}$). Se elige libremente $\{1, 3\}$.
  - Actualización final: $P = V$, $N = \emptyset$, $T = \{\{1, 2\}, \{2, 5\}, \{2, 4\}, \{4, 6\}, \{1, 3\}\}$.
- **Parada**: Al alcanzarse $P = V$ $(|T| = n - 1 = 5)$, el proceso concluye.

Ejemplo Prim: Conclusión y Solución Alternativa $T^{'}$

- **Cálculo del Peso Mínimo Óptimo**:

$$\begin{aligned} d(T) &= d_{\{1,2\}} + d_{\{2,5\}} + d_{\{2,4\}} + d_{\{4,6\}} + d_{\{1,3\}} \\ &= 1 + 3 + 4 + 3 + 5 = 16 \end{aligned}$$

- **Solución Alternativa** T': Elegir la arista $\{3,4\}$ $(d = 5)$ en lugar de $\{1,3\}$ en la iteración 5 produce el árbol alternativo $T' = \{\{1,2\},\{2,5\},\{2,4\},\{4,6\},\{3,4\}\}$ con peso idéntico $d(T') = 16$.

Ejemplo Prim: Traza animada interactiva

Complejidad del Algoritmo de Prim

Complejidad computacional de Prim

- **Implementación estándar con matriz de adyacencia**: $O(n^2)$.
- **Implementación con Heap binario**: $O(m \log n)$.
- **Implementación con Montículo de Fibonacci (Fib-Heap)**: $O(m + n \log n)$ (óptimo para redes densas).

Aprendizaje no supervisado y Medidas de Desemejanza

Definición: Medida de desemejanza y distancia métrica

Dada una colección de observaciones x, y, una **función de desemejanza** $\delta(x, y)$ cuantifica la divergencia entre ambas observando:

1. **Coincidencia nula**: $\delta(x, y) = 0 \iff x = y$.
2. **No negatividad**: $\delta(x, y) \geq 0, \forall x, y$.
3. **Simetría**: $\delta(x, y) = \delta(y, x)$.

Si satisface la **desigualdad triangular** $\delta(x, y) \leq \delta(x, z) + \delta(y, z)$, es una **distancia métrica** (ej. $\|x - y\|_2$).

Algoritmo de las k-Medias (K-Means)

k-Medias (K-Means)

- **Objetivo de optimización**: Minimiza la variabilidad intra-grupo ($WCSS$, *within-cluster sum of squares*):

$$W(S, c) = \sum_{k=1}^{K} W(S_k) = \sum_{k=1}^{K} \sum_{x_i \in S_k} \|x_i - c_k\|^2$$

  donde c_k representa el centroide (media aritmética) del clúster S_k.
- **Restricción geométrica**: Al basarse en centroides y regiones de Voronoi delimitadas por hiperplanos, **exige clústeres esféricos y convexos**.

Clustering basado en Árbol Soporte de Mínimo Peso

Clustering basado en MST (Single-Linkage)

- **Modelado en red**: Modela la colección de n observaciones como una red completa $G = (V, E, \delta)$ valorada por desemejanzas $\delta(x, y)$ y calcula su MST $T = (V, E')$.
- **Partición por corte**: Elimina las $K - 1$ aristas de mayor peso (mayor desemejanza) del MST.
- **Propiedad clave**: Particiona la red de forma determinista en K componentes conexas de **geometría arbitraria y no lineal**.

Ejemplo: Partición determinista por corte del MST

- **Procedimiento sobre $n = 9$ observaciones**:
  1. Construir el MST completo sobre la red de desemejanzas.
  2. Identificar y cortar las $K - 1 = 2$ aristas de mayor peso: $\{2, 4\}$ (longitud 8.5) y $\{3, 7\}$ (longitud 7.0).
  3. **Resultado**: Partición determinista en $K = 3$ clústeres disjuntos.

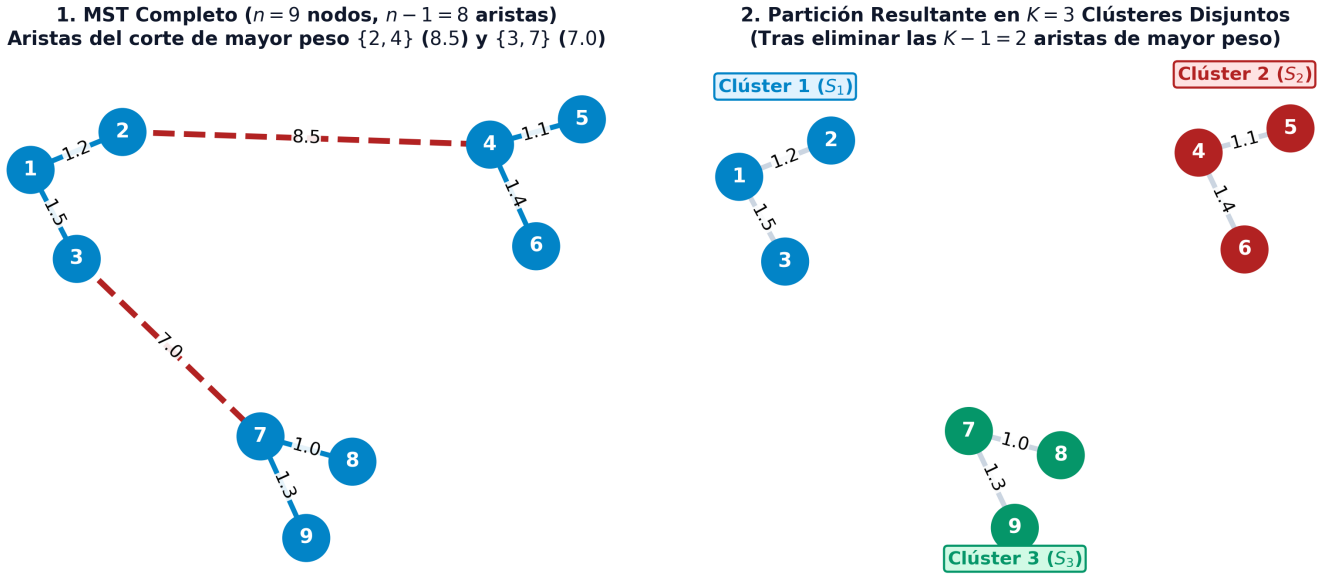

Detección de estructuras con geometría no lineal

- **Estructuras complejas**: Anillos concéntricos (panel izquierdo) y dos lunas entrelazadas (panel derecho).
- **Superioridad del MST**: Mientras k-medias fracasa al trazar hiperplanos lineales rígidos, el MST elimina el puente de mayor desemejanza entre estructuras, capturando la topología no convexa exacta.

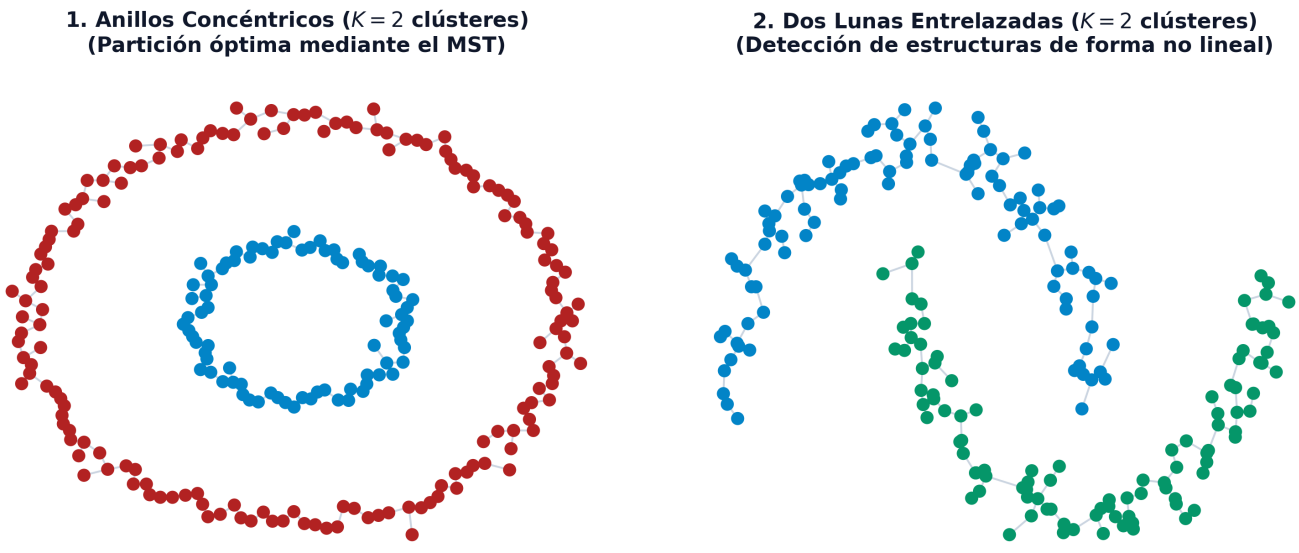

Generalización: Funciones de calidad de partición F

- **Enfoque de Optimización Objetivo**: En lugar de cortar únicamente las $K-1$ aristas de mayor peso, se define una **función de calidad o validez** $F : \mathcal{X}_\ell \to \mathbb{R}$ que evalúa la bondad de cada partición posible $C(V, E'')$.
- **Objetivo de Maximización**: Encontrar la partición de la red $C(V, E'') \in \mathcal{X}_\ell$ que maximiza el valor de la función de validez F.

Maximización de F sobre el MST (Procedimiento Divisivo)

Dada una red de datos $G = (V, E, \delta)$ y una función de calidad F:

1. **Obtener el MST**: $T = \text{MST}(G) = (V, E', \delta)$.
2. **Inicializar aristas activas**: $E'' = E'$.
3. **Bucle de Selección Divisiva**: Para $i = 1, \ldots, K-1$:
   - Identificar $\{u, v\} = \arg\max_{e \in E''} F(C(V, E'' \setminus \{e\}))$.
   - Eliminar la arista seleccionada: $E'' \leftarrow E'' \setminus \{\{u, v\}\}$.
4. **Resultado de la partición**: Devolver la partición óptima $C(V, E'')$.

Funciones de Calidad F: Separación y Variabilidad Intra-grupo

- **Criterio de mayor longitud (Separación)**: Suma de los costes/pesos de las aristas eliminadas del MST:

$$F(X_1, \ldots, X_\ell) = \sum_{i=1}^{\ell} \sum_{x_j \in X_i} x_j$$

- **Suma de cuadrados intra-grupo negativa ($-WCSS$)**: Minimización de la dispersión de las observaciones respecto a los centroides μ_i:

$$-WCSS(X_1, \ldots, X_\ell) = -\sum_{i=1}^{\ell} \sum_{x_j \in X_i} \|x_j - \mu_i\|^2$$

Funciones de Calidad F: Criterio de Información y Entropía

- **Criterio de Información / Entropía (IC)**: Balancea la homogeneidad de los subárboles con la proporción de observaciones:

$$IC(X_1, \ldots, X_\ell) = -d \sum_{i=1}^{\ell} \frac{n_i}{n} \log \frac{L_i}{n_i} - \sum_{i=1}^{\ell} \frac{n_i}{n} \log \frac{n_i}{n}$$

  donde L_i representa la suma de los pesos de las aristas en el i-ésimo subárbol y $n_i = |X_i|$ es la cardinalidad de dicho clúster.

- **Criterio de dispersión de aristas**: Minimización de la desviación típica de las distancias de las aristas intra-clúster.

Estrategias aglomerativas e inestabilidades prácticas

Estrategia aglomerativa y corrección de inestabilidad

- **Aproximación aglomerativa**: Comenzar con $E'' = \emptyset$ e ir añadiendo aristas del MST una a una que maximicen la función $F(C(V, E'' \cup \{\{u, v\}\}))$ hasta alcanzar K componentes conexas.
- **Inconveniente práctico**: Puede formar grupos aislados de muy pocas observaciones en las iteraciones iniciales.
- **Solución**: Incorporar penalizaciones o restricciones basadas en el **índice de Gini** que favorezcan el equilibrio cuando exista una disparidad excesiva en la dimensión de los clústeres.

Tema 7: Problema del camino mínimo

Optimización y Análisis de Redes

Víctor Aceña Gil - Antonio Alonso Ayuso

2026-08-11

Objetivos de aprendizaje

1. **Formular** el problema del camino mínimo y la matriz de distancias directas.
2. **Deducir** las ecuaciones de optimalidad de Bellman y su insuficiencia ante circuitos.
3. **Aplicar** la ordenación topológica en redes acíclicas (DAGs) en tiempo lineal $O(|V| + |U|)$.
4. **Ejecutar** el algoritmo de Dijkstra en redes con costes no negativos.
5. **Programar** el algoritmo de Bellman-Ford y detectar circuitos de coste negativo.
6. **Analizar** la formulación en programación lineal primal-dual y la propiedad TUM.
7. **Calcular** distancias entre todos los pares mediante Floyd-Warshall y min-suma.

Definición formal y condiciones de existencia

Contexto y trascendencia del problema del camino mínimo

- **Propósito fundamental**: Determinar la ruta de menor coste, distancia geodésica o tiempo acumulado desde un nodo origen s a un nodo destino t, o desde un origen único hacia todos los vértices.
- **Ámbitos de aplicación directa**:
  - Navegación GPS e infraestructuras de transporte multimodal.
  - Enrutamiento de paquetes de datos en redes de telecomunicaciones (IP/BGP).
  - Planificación logística de flotas de distribución y suministro.
- **Rol como subproblema crítico**:
  - Generación de columnas en Programación Entera y *Branch-and-Price*.
  - Algoritmos de Flujo de Coste Mínimo en redes.
  - Programación Dinámica multietapa.

Definición formal de red valorada

Red valorada y coste acumulado de un camino

Sea un digrafo conexo valorado $G = (V, U, \mathbf{d})$ con $V = \{1, \dots, n\}$ y $|U| = m$:

- **Vector de costes $\mathbf{d} \in \mathbb{R}^m$**: Asigna a cada arco dirigido $u = (i, j) \in U$ un peso, tiempo o coste $d(u) = d_{ij}$.
- **Coste acumulado de un camino** $\mu = (v_0, v_1, \dots, v_k)$:

$$d(\mu) = \sum_{u \in \mu} d_u = \sum_{j=1}^{k} d_{v_{j-1}, v_j}$$

Matriz de distancias directas

Matriz de distancias directas

La **matriz de distancias directas** $D \in \overline{\mathbb{R}}^{n \times n}$ contiene las conexiones directas entre todo par de vértices $i, j \in V$:

$$d_{ij} = \begin{cases} 0 & \text{si } i = j \\ d_u & \text{si } u = (i,j) \in U \\ +\infty & \text{si } (i,j) \notin U \text{ y } i \neq j \end{cases}$$

- Representa la información elemental de conectividad y coste de la red antes de aplicar los algoritmos de optimización.

Ejemplo: Red de itinerarios de vuelos internacionales

- **Objetivo**: Encontrar el itinerario de tarifa mínima desde Madrid (M) hasta Tokio (T).
- **Escalas disponibles**: Londres (L), París (P), Frankfurt (F) o Singapur (S).
- **Tarifas de arcos (en €)**:
  - Desde M: $(M, L) : 20$, $(M, F) : 40$, $(M, P) : 27$.
  - Conexiones intercontinentales: $(L, F) : 10$, $(F, P) : 11$, $(P, F) : 9$.
  - Vuelos a Asia: $(F, S) : 90$, $(P, S) : 100$, $(P, T) : 150$.
  - Tramo final: $(S, T) : 35$.

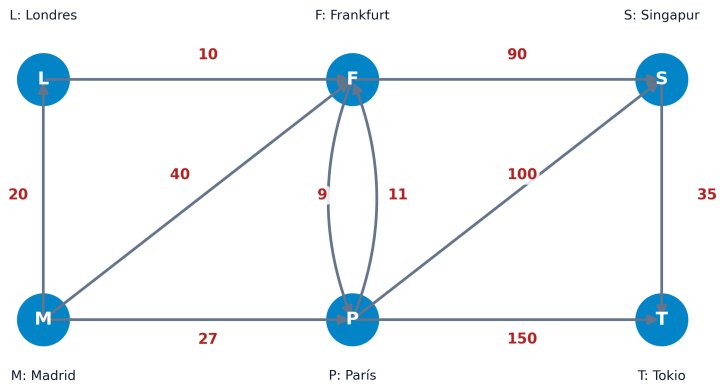

Ejemplo: Transporte marítimo con costes y beneficios

- **Planteamiento**: Itinerario óptimo de navegación entre un puerto origen O y un puerto destino D.
- **Modelado dual de pesos**:
  - **Costes de combustible**: Valores positivos ($d_{ij} > 0$).
  - **Beneficios de recarga**: Valores negativos ($d_{ij} < 0$).
- **Solución**: Minimizar costes en la red equivale a maximizar el beneficio neto total acumulado.

i Diferencia fundamental con el MST

A diferencia del MST (solución siempre finita), el camino mínimo con arcos negativos puede presentar **divergencia a** $-\infty$.

Paradoja del camino en grafos con circuitos negativos

- **Ruta simple inicial**:
  $\mu_1 = (a, b, e, f)$ con coste:

  $$d(\mu_1) = 3 + (-6) + 2 = -1$$

- **Circuito de coste negativo**:
  $\mu_C = (b, e, f, b)$ con coste:

  $$d(\mu_C) = -6+2+2 = -2 < 0$$

- **Divergencia a $-\infty$**: Dar k vueltas a μ_C reduce el coste a:

  $$d(\mu_k) = -1-2k \xrightarrow[k\to\infty]{} -\infty$$

Condición de existencia de solución óptima finita

! Condición de existencia de solución óptima finita

Dada una red dirigida $G = (V, U, \mathbf{d})$ y dos vértices $s, t \in V$, existe una solución óptima finita al problema del camino mínimo si y sólo si se cumplen:

- **Hipótesis H_1 (Accesibilidad)**: Existe al menos un camino dirigido que conecta el nodo origen s con el destino t.
- **Hipótesis H_2 (Ausencia de circuitos de coste negativo)**: Ningún camino dirigido de s a t contiene un circuito de coste total estrictamente negativo.

Ecuaciones de optimalidad de Bellman

Principio de Optimalidad de Bellman (1957)

Principio de Optimalidad de Bellman

Una secuencia óptima de decisiones que resuelve un problema de optimización multietapa debe cumplir la propiedad de que, cualquiera que sea el estado inicial y la decisión inicial adoptada, las decisiones restantes deben constituir una **política óptima** respecto al estado resultante.
(Toda subpolítica de una política óptima es a su vez una subpolítica óptima)

- **Interpretación en caminos mínimos**: Si el camino mínimo entre s y t es $\mu^*[s,t]$ y pasa por los vértices intermedios i y j, la subruta $\mu^*[i,j]$ es obligatoriamente el camino mínimo entre i y j.

Ecuaciones de optimalidad de Bellman

Ecuaciones de optimalidad de Bellman

En una red dirigida sin circuitos de coste negativo, las distancias mínimas u_j desde el origen $s = 1$ a los vértices $j = 2, \dots, n$ satisfacen:

$$u_1 = 0$$
$$u_j = \min_{k \neq j} \{u_k + d_{kj}\}, \quad \forall j = 2, \dots, n$$

- Físicamente expresan que la distancia a j es el mínimo entre las distancias acumuladas a sus predecesores k más el coste del arco directo (k, j).

Ejemplo: Planteamiento de las ecuaciones de Bellman

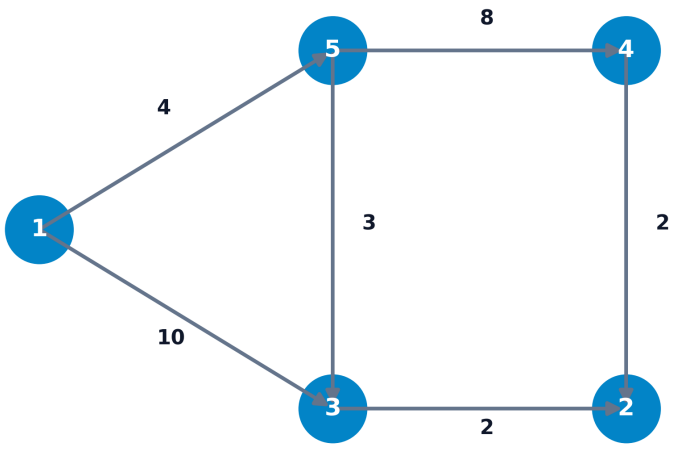

- **Formulación del sistema para** $s = 1$:

$$u_1 = 0$$
$$u_5 = \min\{u_1 + 4\} = 4$$
$$u_3 = \min\{u_1 + 10, u_5 + 3\} = \text{m}$$
$$u_4 = \min\{u_5 + 8\} = 12$$
$$u_2 = \min\{u_3 + 2, u_4 + 2\} = \text{mi}$$

- **Resultados**:
  - $\mathbf{u} = (0, 9, 7, 12, 4)$.
  - Pred $= (1, 3, 5, 5, 1)$.
  - Arborescencia: $\{(1, 5), (5, 3), (5, 4), (3, 2)\}$.

Insuficiencia y no unicidad ante circuitos de coste nulo

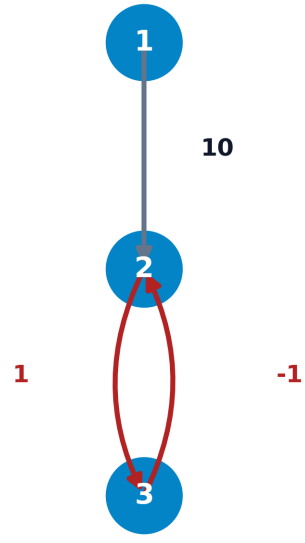

- **Circuito de coste nulo**: $2 \rightleftarrows 3$ con $d_{23} + d_{32} = 1 + (-1) = 0$.
- **Sistema de ecuaciones de Bellman**:

$$u_1 = 0$$
$$u_2 = \min\{10, u_3 - 1\}$$
$$u_3 = u_2 + 1$$

- **Múltiples soluciones algebraicas**:
  - $\mathbf{u} = (0, 10, 11) \implies$ **Solución física real**.
  - $\mathbf{u} = (0, 5, 6) \implies$ Satisface las ecuaciones pero **es falsa**.

Proposición: Arborescencia asociada a Bellman

Construcción de la arborescencia soporte

Las ecuaciones de optimalidad de Bellman:

$$u_1 = 0, \quad u_j = \min_{k \neq j} \{u_k + d_{kj}\}, \quad \forall j \neq 1$$

permiten construir de forma **única** la arborescencia de caminos mínimos con raíz en 1 si y sólo si en la red **no existen circuitos dirigidos de coste nulo ni negativo**.

Ejemplo: Ecuaciones de Bellman en la red de aeropuertos

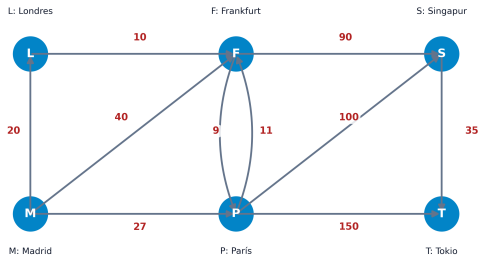

- **Ecuaciones desde Madrid (M) - Nodos iniciales**:
  - **Madrid (M)**: $u_M = 0$
  - **Londres (L)**:

$$u_L = \min\{u_M + 20\} = 20$$

  - **París (P)**:

$$u_P = \min\{u_M{+}27,\ u_F{+}9\} = \min\{27, 3$$

  - **Frankfurt (F)**:

$$u_F = \min\{u_M + 40,\ u_L + 10,\ u_P + 11\}$$
$$= \min\{40, 30, 38\} = 30$$

Ejemplo: Ecuaciones de Bellman en la red de aeropuertos (cont.)

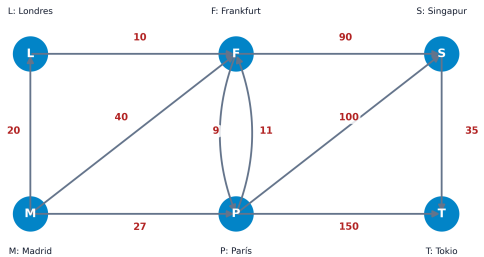

- **Ecuaciones hacia el destino final**:

$$u_S = \min\{u_F + 90,\ u_P + 100\} = \min\{120, 1$$
$$u_T = \min\{u_P + 150,\ u_S + 35\} = \min\{177, 1$$

- **Solución y Arborescencia Óptima** T^*:
  - **Ruta a Tokio**: $M \to L \to F \to S \to T$ (155 €).
  - **Predecesores**: $L \leftarrow M$, $P \leftarrow M$, $F \leftarrow L$, $S \leftarrow F$, $T \leftarrow S$.
  - **Arcos de** T^*: $\{(M, L), (M, P), (L, F), (F, S), (S, T)\}$.

Complejidad computacional de las ecuaciones de Bellman

- **Complejidad factorial $O(n!)$ en redes generales**: Sin conocer el orden secuencial de resolución de los vértices, explorar las combinaciones de predecesores requiere $O(n!)$ comparaciones.
- **Reducción de complejidad mediante ordenación topológica**: Si los nodos se ordenan secuencialmente de forma adecuada, la complejidad se reduce a $O(n^2)$ o tiempo estrictamente **lineal** $O(|V| + |U|)$.
- **Condición necesaria**: La ordenación topológica secuencial exige que el digrafo **no contenga circuitos dirigidos** (DAGs).

Redes sin circuitos (DAGs) y ordenación topológica

Caracterización de digrafos acíclicos (DAGs)

Caracterización mediante ordenación topológica

Un digrafo $G = (V, U)$ no tiene circuitos dirigidos si y sólo si existe una numeración de sus n vértices $v_1, v_2, \ldots, v_n$ tal que para todo arco dirigidos $(i, j) \in U$ se cumple:

$$i < j$$

- **Consecuencia matemática**: Todos los arcos de la red avanzan estrictamente de izquierda a derecha. No existen arcos de retroceso que puedan formar bucles.

Ejemplo: Verificación de ordenación topológica

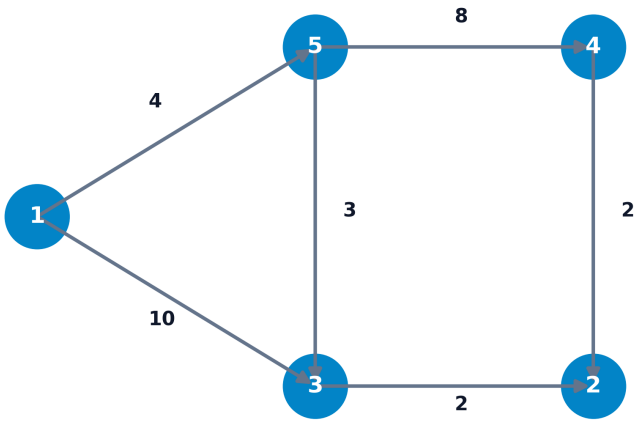

- **Secuencia propuesta**: $(1, 5, 3, 4, 2)$
- **Chequeo de arcos**:
  - $(1, 5) \implies 1^\circ \to 2^\circ$ (cumple $i < j$)
  - $(1, 3) \implies 1^\circ \to 3^\circ$ (cumple $i < j$)
  - $(5, 4) \implies 2^\circ \to 4^\circ$ (cumple $i < j$)
  - $(5, 3) \implies 2^\circ \to 3^\circ$ (cumple $i < j$)
  - $(4, 2) \implies 4^\circ \to 5^\circ$ (cumple $i < j$)
  - $(3, 2) \implies 3^\circ \to 5^\circ$ (cumple $i < j$)

Esquema del algoritmo de ordenación topológica

Algoritmo de numeración topológica

Dada la red dirigida $G = (V, U)$ con $n = |V|$ vértices:

1. **Paso 0**: Hacer $k \leftarrow 1$, $V' \leftarrow V$, $U' \leftarrow U$.
2. **Paso 1**: Seleccionar un nodo fuente $i \in V'$ con grado de entrada $d^-(i) = 0$ en U'.
3. **Paso 2**: Asignar al nodo i el orden k. Eliminar i y sus arcos incidentes:

$$V' \leftarrow V' \setminus \{i\}, \quad U' \leftarrow U' \setminus \{(i, j)\}$$

4. **Paso 3**: Si $k = n$, **parar**. En otro caso, hacer $k \leftarrow k + 1$ y regresar al Paso 1.

Resolución de Bellman en tiempo lineal en DAGs

- **Fórmula de recurrencia en orden topológico**:

$$u_1 = 0$$
$$u_j = \min_{i<j,\,(i,j)\in U} \{u_i + d_{ij}\}, \quad \forall j = 2, \ldots, n$$

- **Complejidad algorítmica**: Cada arco de la red se examina exactamente una vez durante el recorrido secuencial.

$$\text{Tiempo total} = O(|V| + |U|)$$

Ejemplo DAG: Grafo acíclico de 7 nodos

- **Grafo acíclico valorado**: Vértices $V = \{1, 2, 3, 4, 5, 6, 7\}$ con costes positivos y negativos.

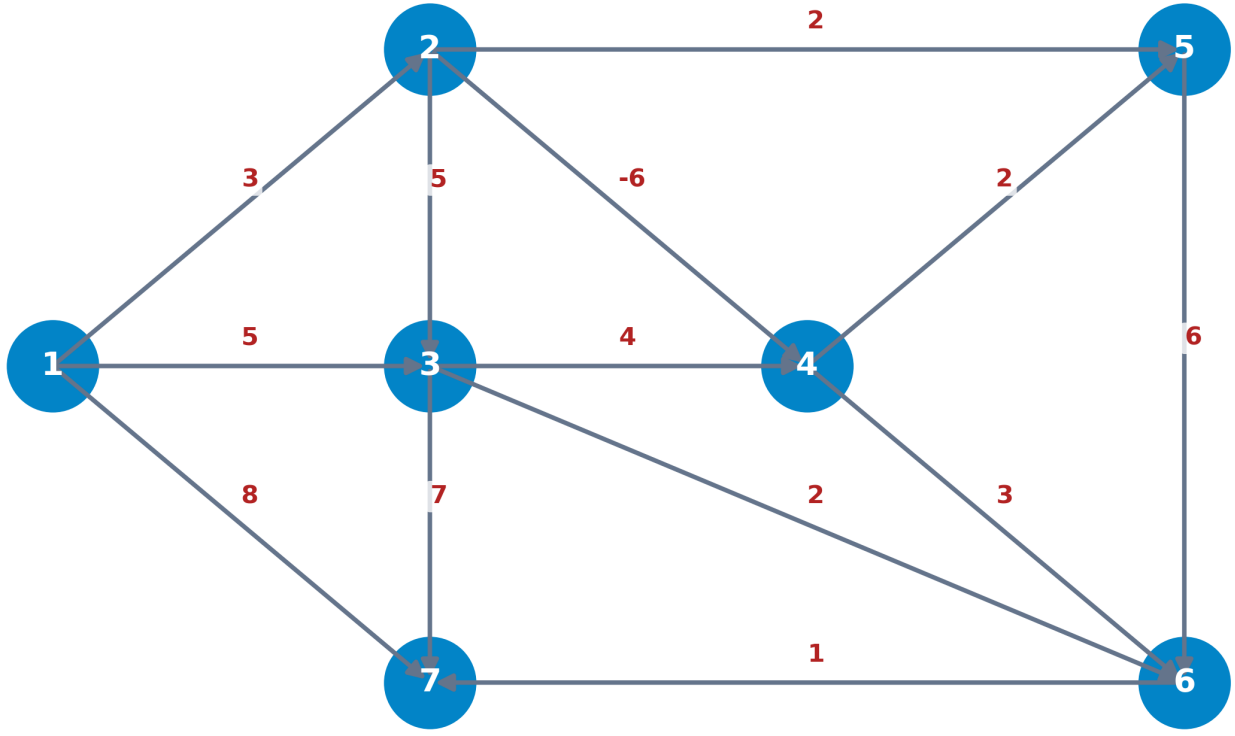

Ejemplo DAG: Iteraciones analíticas nodo por nodo

- $u_1 = 0$ (Origen).
- $u_2 = u_1 + d_{12} = 0 + 3 = 3$ ($\mathsf{Pred}(2) = 1$).
- $u_3 = \min\{u_1 + d_{13}, u_2 + d_{23}\} = \min\{0 + 5, 3 + 5\} = 5$ ($\mathsf{Pred}(3) = 1$).
- $u_4 = \min\{u_2 + d_{24}, u_3 + d_{34}\} = \min\{3 - 6, 5 + 4\} = -3$ ($\mathsf{Pred}(4) = 2$).
- $u_5 = \min\{u_2 + d_{25}, u_4 + d_{45}\} = \min\{3 + 2, -3 + 2\} = -1$ ($\mathsf{Pred}(5) = 4$).
- $u_6 = \min\{u_3 + d_{36}, u_4 + d_{46}, u_5 + d_{56}\} =$ $\min\{5 + 2, -3 + 3, -1 + 6\} = 0$ ($\mathsf{Pred}(6) = 4$).
- $u_7 = \min\{u_1 + d_{17}, u_3 + d_{37}, u_6 + d_{67}\} =$ $\min\{0 + 8, 5 + 7, 0 + 1\} = 1$ ($\mathsf{Pred}(7) = 6$).

Ejemplo DAG: Traza animada interactiva

Redes con pesos no negativos: Algoritmo de Dijkstra

Filosofía del Algoritmo de Dijkstra (1959)

Estrategia voraz de etiquetado permanente

Para redes con costes no negativos ($d_{ij} \geq 0$), se dividen los vértices en dos conjuntos:

- **Nodos Permanentes** $\mathcal{P}$: Vértices con distancia óptima definitiva conocida ($u_j = d(1, j)$).
- **Nodos Transitorios** $\mathcal{T} = V \setminus \mathcal{P}$: Vértices con cota de distancia provisional u_j.

- **Mecanismo voraz (*Greedy*)**: En cada etapa se transfiere a $\mathcal{P}$ el nodo $k \in \mathcal{T}$ con etiqueta mínima:

$$u_k = \min_{j \in \mathcal{T}} \{u_j\}$$

Definición de cota provisional u_j^P

Cota de distancia provisional

Dado el subconjunto permanente $\mathcal{P}$, la cota u_j^P asociada a un nodo $j \in \mathcal{T}$ representa la longitud del camino mínimo desde el origen 1 al nodo j utilizando como vértices intermedios **únicamente elementos de** $\mathcal{P}$:

$$u_j^P \equiv \text{distancia mínima de } 1 \text{ a } j \text{ pasando solo por } \mathcal{P}$$

- Al incorporar k a $\mathcal{P}$, las cotas de los vecinos transitorios se actualizan mediante:

$$u_j \leftarrow \min\{u_j,\, u_k + d_{kj}\}$$

Esquema del Algoritmo de Dijkstra

Algoritmo de Dijkstra

Dada la red con costes no negativos $d_{ij} \geq 0$:

1. **Paso 0 (Inicialización)**:
   - $u_1 = 0$, $u_j = d_{1j}$ $(\forall j \geq 2)$, $\mathcal{P} = \{1\}$, $\mathcal{T} = \{2, \ldots, n\}$, $\text{Pred}(j) = 1$.
2. **Paso 1 (Etiquetado permanente)**:
   - Seleccionar $k \in \mathcal{T}$ tal que $u_k = \min_{j \in \mathcal{T}} \{u_j\}$.
   - Hacer $\mathcal{P} \leftarrow \mathcal{P} \cup \{k\}$, $\mathcal{T} \leftarrow \mathcal{T} \setminus \{k\}$.
   - Si $\mathcal{T} = \emptyset$ o $u_k = \infty$, **parar**.
3. **Paso 2 (Relajación de etiquetas)**:
   - Para cada $j \in \mathcal{T}$ vecino de k: $u_j \leftarrow \min\{u_j, u_k + d_{kj}\}$. Si cambia, hacer $\text{Pred}(j) \leftarrow k$. Ir al Paso 1.

Correctitud del Algoritmo de Dijkstra

! Correctitud del algoritmo de Dijkstra

Si $d_{ij} \geq 0$ para todo $(i,j) \in U$, la etiqueta u_k asignada por el Algoritmo de Dijkstra en el momento en que un nodo k pasa a ser permanente ($\mathcal{P} \leftarrow \mathcal{P} \cup \{k\}$) es la **distancia mínima exacta** desde el origen 1 al nodo k.

- **Interpretación y fundamento de la no negatividad**:
  - Como $d_{ij} \geq 0$, la función de distancia a lo largo de cualquier camino es **monótona no decreciente**.
  - Ningún camino que atraviese un nodo transitorio $y \in \mathcal{T}$ puede ofrecer un coste menor que la etiqueta mínima $u_k = \min_{j \in \mathcal{T}}\{u_j\}$.
  - Al pasar k a permanente, su distancia u_k queda **definitivamente fijada y garantizada como óptima**.

Complejidad computacional de Dijkstra

Estructura de Datos	Complejidad Temporal	Contexto de Aplicación
Matriz de distancias	$O(n^2)$	Redes densas ($m \approx n^2$)
Heap binario (Min-Heap)	$O(m \log n)$	Redes dispersas ($m \ll n^2$)
Fibonacci Heap	$O(m + n \log n)$	Máxima eficiencia teórica

- **Justificación de la voracidad**: Si $d_{ij} \geq 0$, ningún nodo en $\mathcal{T}$ puede ofrecer un camino más corto hacia k que la propia cota actual $u_k = \min_{j \in \mathcal{T}} \{u_j\}$.

Ejemplo Dijkstra: Red de 5 nodos

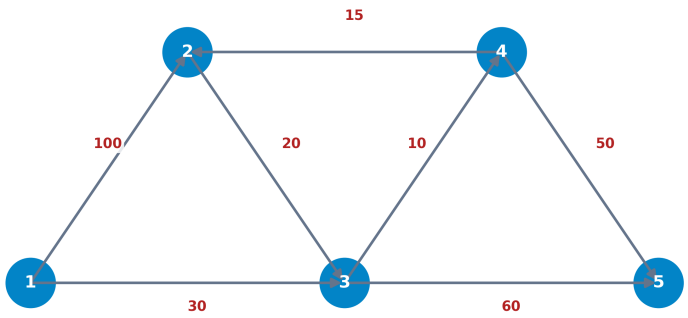

- **Digrafo de 5 nodos**: Costes estrictamente no negativos.
- **Objetivo**: Determinar el árbol de caminos mínimos desde el nodo origen 1.

Ejemplo Dijkstra: Iteración 0 e Iteración 1

- **Paso 0 (Inicialización)**:
  - $\mathcal{P} = \{1\}$, $\mathcal{T} = \{2, 3, 4, 5\}$.
  - $u = (0, 100, 30, \infty, \infty)$, Pred $= (1, 1, 1, 1, 1)$.
- **Iteración 1**:
  - Mínimo en $\mathcal{T}$: $k = 3$ con $u_3 = 30 \implies \mathcal{P} = \{1, 3\}$, $\mathcal{T} = \{2, 4, 5\}$.
  - Relajación de vecinos de 3:
    - $u_2 \leftarrow \min\{100, 30 + 20\} = 50$ (Pred$(2) = 3$).
    - $u_4 \leftarrow \min\{\infty, 30 + 10\} = 40$ (Pred$(4) = 3$).
    - $u_5 \leftarrow \min\{\infty, 30 + 60\} = 90$ (Pred$(5) = 3$).

Ejemplo Dijkstra: Iteraciones 2 a 4

- **Iteración 2**:
  - Mínimo en $\mathcal{T}$: $k = 4$ con $u_4 = 40 \implies \mathcal{P} = \{1, 3, 4\}$, $\mathcal{T} = \{2, 5\}$.
  - Vecinos de 4: (arco $(4, 2)$ peso 15: $40 + 15 = 55 > 50$, sin cambio; $(4, 5)$ peso 50: $40 + 50 = 90$, sin cambio).
- **Iteración 3**:
  - Mínimo en $\mathcal{T}$: $k = 2$ con $u_2 = 50 \implies \mathcal{P} = \{1, 3, 4, 2\}$, $\mathcal{T} = \{5\}$.
- **Iteración 4**:
  - Mínimo en $\mathcal{T}$: $k = 5$ con $u_5 = 90 \implies \mathcal{P} = \{1, 2, 3, 4, 5\}$, $\mathcal{T} = \emptyset$. **PARADA**.

Ejemplo Dijkstra: Tabla resumen de desarrollo

Etapa k	Nodo Permanetizado	u_k	Conjunto $\mathcal{P}$	Etiquetas $(u_1, u_2, u_3, u_4, u_5)$	Predecesores Pred(1..5)
Inicio	1	0	$\{1\}$	$(0, 100, 30, \infty, \infty)$	$(1, 1, 1, 1, 1)$
Iter 1	3	30	$\{1, 3\}$	$(0, 50, 30, 40, 90)$	$(1, 3, 3, 3, 3)$
Iter 2	4	40	$\{1, 3, 4\}$	$(0, 50, 30, 40, 90)$	$(1, 3, 3, 3, 3)$
Iter 3	2	50	$\{1, 3, 4, 2\}$	$(0, 50, 30, 40, 90)$	$(1, 3, 3, 3, 3)$
Iter 4	5	90	$\{1, 3, 4, 2, 5\}$	$(0, 50, 30, 40, 90)$	$(1, 3, 3, 3, 3)$

- **Arborescencia Óptima**: $\{(1, 3), (3, 4), (3, 2), (3, 5)\}$.

Ejemplo Dijkstra: Traza animada interactiva

Redes con pesos negativos: Algoritmo de Bellman-Ford

Concepto: Aproximación por número de arcos (1956-1959)

Aproximación iterativa por longitud de arcos

Para redes que contienen arcos con costes negativos (sin circuitos negativos), el **Algoritmo de Bellman-Ford** define:

- **Etiqueta** u_j^m: Longitud del camino mínimo desde el origen 1 al nodo j utilizando **a lo sumo** m **arcos**.
- **Relación de Recurrencia**:

$$u_j^m = \min\left\{u_j^{m-1},\ \min_{k\neq j}\{u_k^{m-1} + d_{kj}\}\right\}, \quad m = 1, \ldots, n-1$$

- **Complejidad**: $O(|V| \cdot |U|) = O(n^3)$ para redes densas.

Esquema del Algoritmo de Bellman-Ford (I: Inicialización)

Algoritmo de Bellman-Ford — Paso 1: Inicialización

Dada una red valorada dirigida $G = (V, U, \mathbf{d})$ con $n = |V|$ vértices:

- **Paso 1 (Inicialización para $m = 1$)**: Definir las etiquetas iniciales de distancia directa desde el origen 1:

$$u_j^1 = \begin{cases} 0 & \text{si } j = 1 \\ d_{1j} & \text{si } (1,j) \in U \\ \infty & \text{si } (1,j) \notin U \end{cases}$$

y establecer el vector de predecesores iniciales $\text{Pred}(j) = 1$. Inicializar el contador de arcos: $m \leftarrow 1$.

Esquema del Algoritmo de Bellman-Ford (II: Relajación)

Algoritmo de Bellman-Ford — Paso 2: Relajación de arcos

- **Paso 2 (Iteración de relajación)**:
  - Incrementar la longitud máxima permitida del camino: $m \leftarrow m + 1$.
  - Para cada nodo $j = 2, \ldots, n$, evaluar si es más ventajoso mantener la cota anterior o acceder a j pasando por un nodo intermedio k:

$$u_j^m = \min \left\{ u_j^{m-1},\ \min_{k \neq j} \{ u_k^{m-1} + d_{kj} \} \right\}$$

  - Si la etiqueta cambia ($u_j^m < u_j^{m-1}$), actualizar el predecesor: $\text{Pred}(j) \leftarrow k$.

Esquema del Algoritmo de Bellman-Ford (III: Parada)

Algoritmo de Bellman-Ford — Paso 3: Criterios de Parada

- **Paso 3 (Criterio de Parada y Convergencia)**:
  - **Parada Anticipada (Estabilidad)**: Si $u_j^m = u_j^{m-1}$ para todo $j = 2, \ldots, n$, la solución es **óptima y estable** $\Longrightarrow$ **PARAR**.
  - **Criterio Límite ($m = n - 1$)**: Si $m = n - 1$, se ha alcanzado el número máximo de arcos de un camino simple $\Longrightarrow$ **PARAR**.
  - **Continuación**: Si $m < n - 1$ y $u^m \neq u^{m-1}$, **regresar al Paso 2**.

- **Interpretación teórica**: Cualquier camino simple entre dos nodos contiene a lo sumo $n - 1$ arcos. Si la red no posee circuitos de coste negativo, la solución óptima se alcanza en $m \leq n - 1$ iteraciones.

Ejemplo Bellman-Ford: Red de 4 nodos con costes negativos

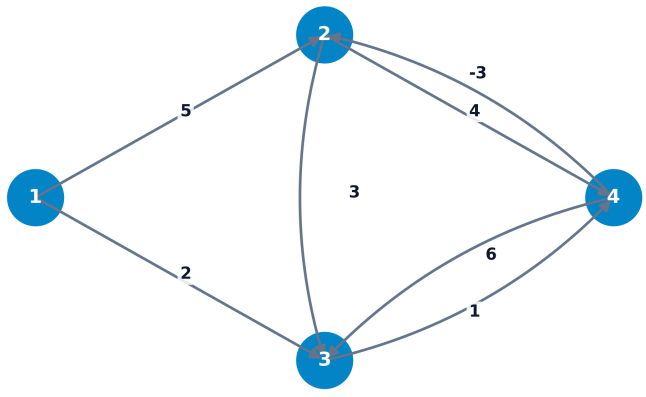

- **Arco negativo**: $(4, 2)$ con coste $d_{42} = -3$.
- **Objetivo**: Obtener las distancias mínimas desde el nodo 1.

Ejemplo Bellman-Ford: Desarrollo iterativo m=1 y m=2

- **Paso 1 ($m = 1$)**:
  - $u^1 = (0, 5, 2, \infty)$, Pred $= (1, 1, 1, 1)$.
- **Iteración** $m = 2$:
  - $u_2^2 = \min\{u_2^1, u_3^1 + d_{32}, u_4^1 + d_{42}\} = \min\{5, 2+\infty, \infty-3\} = 5$.
  - $u_3^2 = \min\{u_3^1, u_2^1 + d_{23}, u_4^1 + d_{43}\} = \min\{2, 5+3, \infty+6\} = 2$.
  - $u_4^2 = \min\{u_4^1, u_2^1 + d_{24}, u_3^1 + d_{34}\} = \min\{\infty, 5+4, 2+1\} = 3$.
  - Vector resultante: $u^2 = (0, 5, 2, 3)$, Pred $= (1, 1, 1, 3)$.

Ejemplo Bellman-Ford: Desarrollo iterativo m=3 y m=4

- **Iteración** $m = 3$:
  - $u_2^3 = \min\{5, u_3^2 + d_{32}, u_4^2 + d_{42}\} = \min\{5, 2 + \infty, 3 - 3\} = 0$ ($\text{Pred}(2) = 4$).
  - $u_3^3 = \min\{2, u_2^2 + d_{23}, u_4^2 + d_{43}\} = \min\{2, 5 + 3, 3 + 6\} = 2$.
  - $u_4^3 = \min\{3, u_2^2 + d_{24}, u_3^2 + d_{34}\} = \min\{3, 5 + 4, 2 + 1\} = 3$.
  - Vector resultante: $u^3 = (0, 0, 2, 3)$, $\text{Pred} = (1, 4, 1, 3)$.
- **Iteración** $m = 4$:
  - $u^4 = (0, 0, 2, 3) = u^3 \implies$ **CONVERGENCIA ALCANZADA**.

Ejemplo Bellman-Ford: Tabla resumen de iteraciones

Iteración m	u_1^m	u_2^m	u_3^m	u_4^m	Vector de Predecesores Pred	Estado de Convergencia
$m = 1$	0	5	2	∞	$(1, 1, 1, 1)$	Inicialización
$m = 2$	0	5	2	3	$(1, 1, 1, 3)$	Relajación de u_4
$m = 3$	0	0	2	3	$(1, 4, 1, 3)$	Relajación de u_2 vía $(4, 2)$
$m = 4$	0	0	2	3	$(1, 4, 1, 3)$	$u^4 = u^3 \implies$

Ejemplo Bellman-Ford: Traza animada interactiva

Detección de circuitos de coste negativo

Criterio de detección de circuitos de coste negativo

Existe un circuito de coste negativo accesible desde el origen si y sólo si en la iteración $m = n$:

$$u_j^n \neq u_j^{n-1} \quad \text{para algún } j \in V$$

- **Fundamento teórico**: Si no existen circuitos negativos, las distancias mínimas se alcanzan en a lo sumo $n-1$ arcos. Si la iteración n modifica alguna distancia ($u^n \neq u^{n-1}$), existe un circuito de peso estrictamente negativo.

Esquema: Algoritmo de Bellman-Ford adaptado

Algoritmo adaptado para detección de circuitos negativos

Dada una red valorada general $G = (V, U, \mathbf{d})$ con $n = |V|$ vértices:

1. **Inicialización ($m = 1$)**: $u_1^1 = 0$, $u_j^1 = d_{1j}$ $(\forall j \geq 2)$, $m \leftarrow 1$.
2. **Relajación iterativa**: Hacer $m \leftarrow m + 1$. Para cada nodo $j = 2, \ldots, n$:

$$u_j^m = \min \left\{ u_j^{m-1}, \min_{k \neq j} \{ u_k^{m-1} + d_{kj} \} \right\}$$

3. **Criterio de parada**:
   - Si $u^m = u^{m-1}$, **PARAR**: Solución óptima alcanzada.
   - Si $m = n$ y $u^n \neq u^{n-1}$, **PARAR**: Existen circuitos de coste negativo.
   - En otro caso ($m < n$), regresar al Paso 2.

Ejemplo: Detección de circuito negativo (7 nodos)

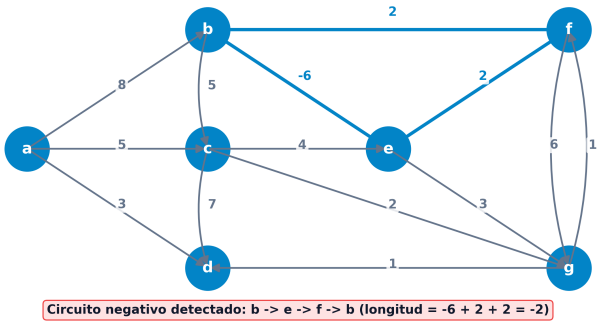

- **Circuito negativo**: $b \to e \to f \to b$ con coste acumulado $-6 + 2 + 2 = -2 < 0$.
- **Iteración $m = 6$ $(n - 1)$**: $u^6 = (0, 6, 5, 3, 0, 2, 3)$.
- **Iteración suplementaria** $m = n = 7$: $u_b^7 = \min\{u_b^6, u_f^6 + 2\} = \min\{6, 2 + 2\} = 4$.
- **Conclusión**: $u_b^7 = 4 \neq 6 = u_b^6 \implies \mathbf{u}^7 \neq \mathbf{u}^6$. Demostrada formalmente la presencia del circuito negativo.

Formulación en Programación Lineal Primal-Dual

Modelo Primal: Flujo de coste mínimo continuo

- **Planteamiento**: Enviar 1 unidad de flujo desde el origen s al destino t al menor coste.
- **Variables de decisión**: $x_{ij} \in \{0, 1\}$ (1 si el arco (i, j) forma parte del camino mínimo, 0 en otro caso).

$$\min_{\mathbf{x}} \quad \sum_{(i,j)\in U} d_{ij} x_{ij}$$

sujeto a

$$\sum_{k|(s,k)\in U} x_{sk} = 1 \quad \text{(Salida del nodo origen } s\text{)}$$

$$\sum_{k|(k,t)\in U} x_{kt} = 1 \quad \text{(Entrada al nodo destino } t\text{)}$$

$$\sum_{i|(i,k)\in U} x_{ik} = \sum_{j|(k,j)\in U} x_{kj}, \quad \forall k \neq s, t \quad \text{(Conservación de fluj}$$

$$x_{ij} \geq 0, \quad \forall (i, j) \in U$$

Teorema: Total Unimodularidad e Integridad (TUM)

! Total Unimodularidad de la matriz de incidencia

La matriz de incidencia nodo-arco $\mathbf{A} \in \{-1, 0, 1\}^{n \times m}$ de cualquier digrafo es **totalmente unimodular** (TUM).
Puesto que el vector de balances nodales $\mathbf{b} = (1, 0, \ldots, 0, -1)^T$ es entero, todas las soluciones básicas del poliedro continuo son **estrictamente enteras**:

$$x_{ij}^* \in \{0, 1\}$$

- **Garantía matemática**: La relajación continua de PL resuelve exactamente el problema combinatorio discreto sin necesitar restricciones de programación entera.

Modelo Dual: Potenciales nodales

- **Variables duales $u_i \in \mathbb{R}$ asociadas a la ecuación de balance de cada nodo $i \in V$:**

$$\begin{aligned} \max_{\mathbf{u}} \quad & u_t - u_s \\ \text{sujeto a} \quad & u_j - u_i \leq d_{ij}, \quad \forall (i,j) \in U \\ & u_i \in \mathbb{R}, \quad \forall i \in V \end{aligned}$$

- **Fijación de Referencia y Distancia Óptima**: Al fijar el origen en $u_s = 0$, la variable dual óptima u_j^* coincide exactamente con la **distancia mínima** $d(s,j)$ desde s hasta j.

Holgura complementaria e interpretación geométrica

- **Condiciones de Holgura Complementaria KKT**:

$$x_{ij}^* \left(d_{ij} - (u_j^* - u_i^*) \right) = 0, \quad \forall (i,j) \in U$$

- **Significado geométrico de la dualidad**:
  - **Arco en la ruta óptima ($x_{ij}^* = 1$)**: La restricción dual se satisface con **igualdad estricta**: $u_j^* - u_i^* = d_{ij}$.
  - **Arco no utilizado ($x_{ij}^* = 0$)**: La diferencia de potencial entre extremos no supera la distancia directa: $u_j^* - u_i^* < d_{ij}$.

Ejemplo: Formulación primal completa (7 nodos)

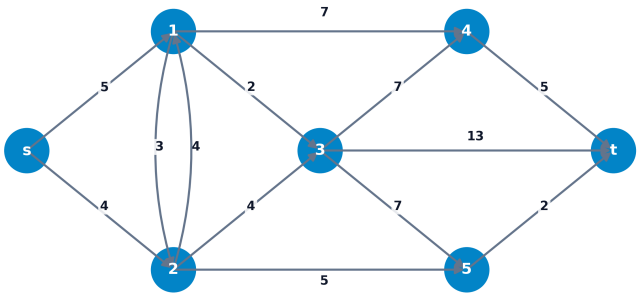

- **Función Objetivo**:

$$\begin{aligned}\min z = {} & 5x_{s1} + 4x_{s2} + 4x_{12} + 2x_{13} + \\ & + 4x_{23} + 5x_{25} + 7x_{34} + 7x_{35} \\ & + 5x_{4t} + 2x_{5t}\end{aligned}$$

- **Restricción Origen (s)**:

$$x_{s1} + x_{s2} = 1$$

- **Restricción Destino (t)**:

$$x_{3t} + x_{4t} + x_{5t} = 1$$

Ejemplo: Formulación primal completa (cont.)

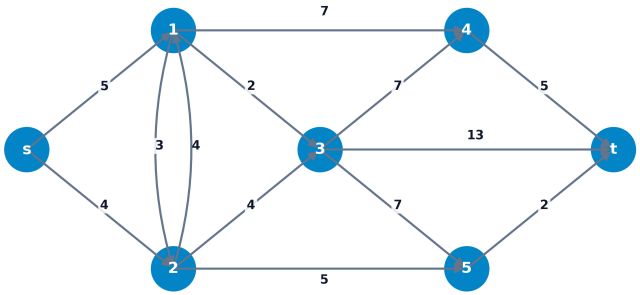

- **Conservación de flujo en nodos intermedios**:

Nodo 1: $x_{s1} + x_{21} = x_{12} + x_{13} + x_{14}$

Nodo 2: $x_{s2} + x_{12} = x_{21} + x_{23} + x_{25}$

Nodo 3: $x_{13} + x_{23} = x_{34} + x_{35} + x_{3t}$

Nodo 4: $x_{14} + x_{34} = x_{4t}$

Nodo 5: $x_{25} + x_{35} = x_{5t}$

- **Naturaleza de las variables**:

$$x_{ij} \in \{0, 1\}, \quad \forall (i, j) \in U$$

Caminos mínimos entre todos los pares de nodos

Motivación y estrategia global

- **Necesidad práctica**: Determinar las distancias mínimas entre **todos los pares de vértices** $(i, j) \in V \times V$.
- **Aproximaciones preliminares**:
  - Repetir n veces un algoritmo de origen único (Dijkstra o Bellman-Ford).
  - Con Dijkstra ($d_{ij} \geq 0$):
    $n \times O(m + n \log n) = O(nm + n^2 \log n)$.
  - Con Bellman-Ford: $n \times O(n^3) = O(n^4)$.
- **Desaprovechamiento de información**: La resolución independiente no reutiliza la información de subcaminos compartidos.

Álgebra Min-Suma o Tropical (Definición y Operador)

Producto matricial Min-Suma

Dadas dos matrices $A, B \in \overline{\mathbb{R}}^{n\times n}$, se define el **producto matricial Min-Suma** $C = A \otimes B$ en el semianillo $(\mathbb{R} \cup \{\infty\}, \min, +)$ mediante la sustitución operatoria $\sum \to \min$ y $\cdot \to +$:

$$\text{Producto Estándar: } c_{ij} = \sum_{k=1}^{n} a_{ik} \cdot b_{kj}$$

$$\Longrightarrow \quad \text{Producto Min-Suma: } c_{ij} = \min_{1\leq k\leq n} \{a_{ik} + b_{kj}\}$$

- **Matriz Inicial** $D^{(1)} = D$:

$$d_{ij}^{(1)} = d_{ij} \quad \text{(distancias directas de los arcos)}$$

Potencias Matriciales D^m y Paralelismo con Bellman-Ford

Relación de recurrencia en álgebra Min-Suma

La componente $(d_{ij})^m$ de $D^m = D^{m-1} \otimes D$ contiene la **distancia mínima entre** i **y** j **en a lo sumo** m **arcos**:

$$(d_{ij})^m = \min\left\{(d_{ij})^{m-1}, \min_{k \in V}\{(d_{ik})^{m-1} + d_{kj}\}\right\}$$

- **Equivalencia Didáctica con Bellman-Ford**:
  - La fila i-ésima de la matriz D^m equivale exactamente a resolver la iteración m de Bellman-Ford con el **vértice** i **como origen**.
  - El cálculo D^m resuelve en paralelo el problema para los n **posibles nodos origen** de la red.

Convergencia y Exponenciación Binaria (*Repeated Squaring*)

- **Convergencia y Complejidad Secuencial**:
  - **Cota de finitud en D^{n-1}**: Cualquier camino simple en una red de n vértices contiene a lo sumo $n-1$ arcos.
  - **Convergencia**: Sin circuitos de coste negativo, el algoritmo converge en D^{n-1}.
  - **Complejidad Secuencial**: $n-1$ productos matriciales $\implies \mathbf{O(n^4)}$.
- **Optimización por Exponenciación Binaria**:
  - Evaluamos potencias cuadráticas:

    $D^1 \to D^2 \to D^4 \to D^8 \ldots \to$
  - **Complejidad Optimizada**: Se realizan únicamente $\lceil \log_2(n-1) \rceil$ productos $\implies \mathbf{O(n^3 \log n)}$.

Ejemplo: Multiplicación de matrices min-suma — Matriz D^(1)

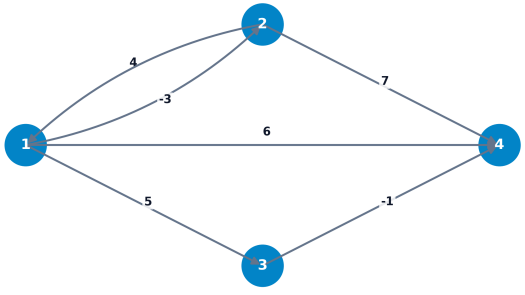

- **Matriz Inicial de Distancias Directas $D^{(1)}$:**

$$D^{(1)} = \begin{pmatrix} 0 & 4 & 5 & 6 \\ -3 & 0 & \infty & 7 \\ \infty & \infty & 0 & -1 \\ \infty & \infty & \infty & 0 \end{pmatrix}$$

- Contiene las distancias directas entre todo par de vértices $i, j \in V$ (caminos de a lo sumo 1 arco).

Ejemplo: Multiplicación de matrices min-suma — Matriz D^(2)

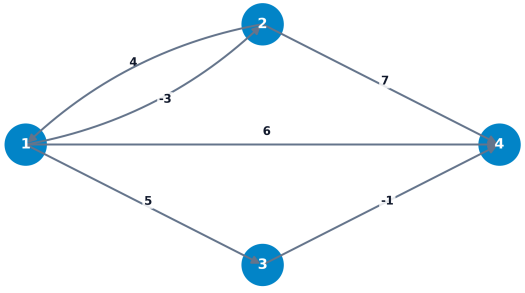

- **Iteración 2 ($D^{(2)} = D^{(1)} \otimes D^{(1)}$ - 2 arcos o menos)**:

$$D^{(2)} = \begin{pmatrix} 0 & 4 & 5 & 4 \\ -3 & 0 & \mathbf{2} & \mathbf{3} \\ \infty & \infty & 0 & -1 \\ \infty & \infty & \infty & 0 \end{pmatrix}$$

- **Relajaciones destacadas**:
  - $(d_{14})^2 = \min\{6,\ 5+(-1)\} = \mathbf{4}$ (vía $1 \to 3 \to 4$).
  - $(d_{23})^2 = \min\{\infty,\ -3+5\} = \mathbf{2}$ (vía $2 \to 1 \to 3$).

Ejemplo: Multiplicación de matrices min-suma — Matriz D^(3)

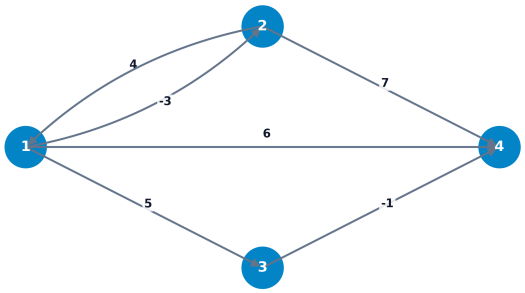

- **Iteración 3 ($D^{(3)} = D^{(2)} \otimes D^{(1)}$ - 3 arcos o menos)**:

$$D^{(3)} = \begin{pmatrix} 0 & 4 & 5 & 4 \\ -3 & 0 & 2 & \mathbf{1} \\ \infty & \infty & 0 & -1 \\ \infty & \infty & \infty & 0 \end{pmatrix}$$

- **Relajación de $(d_{24})^3$**: $\min\{3,\ -3+4\} = \mathbf{1}$ (vía $2 \to 1 \to 3 \to 4$).
- **Convergencia final**: Al ser $n = 4$, el algoritmo finaliza en $D^{(n-1)} = D^{(3)}$.

Algoritmo de Floyd-Warshall (1959-1962)

Relación de recurrencia de Programación Dinámica

Sea $d_{ij}^{(k)}$ la distancia mínima de i a j utilizando como vértices intermedios exclusivamente elementos del subconjunto $\{1, 2, \ldots, k\}$:

$$d_{ij}^{(k)} = \min\left\{d_{ij}^{(k-1)},\ d_{ik}^{(k-1)} + d_{kj}^{(k-1)}\right\}, \quad \forall i, j \in V$$

- **Complejidad algorítmica**: $O(n^3)$ con n iteraciones simples sobre matrices $n \times n$.

Esquema del Algoritmo de Floyd-Warshall

Algoritmo de Floyd-Warshall

Dada la matriz de distancias $D^{(0)} = D$ y la matriz de predecesores $P^{(0)}$ con $P_{ij} = j$:

1. **Bucle externo**: Para $k = 1, 2, \ldots, n$:
2. **Bucles internos**: Para $i = 1, 2, \ldots, n$:
3. Para $j = 1, 2, \ldots, n$:

$$\text{Si } d_{ik}^{(k-1)} + d_{kj}^{(k-1)} < d_{ij}^{(k-1)} \text{ entonces :}$$

$$d_{ij}^{(k)} \leftarrow d_{ik}^{(k-1)} + d_{kj}^{(k-1)}, \quad P_{ij}^{(k)} \leftarrow P_{ik}^{(k-1)}$$

Ejemplo Floyd-Warshall: Red de 5 nodos

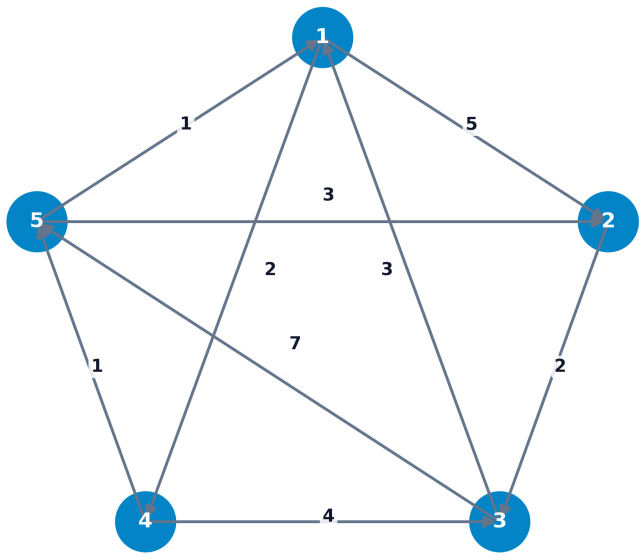

- **Digrafo de 5 nodos**: Pivotes secuenciales $k = 1, 2, 3, 4, 5$.
- **Objetivo**: Obtener la matriz de distancias absolutas $D^{(5)}$ y reconstruir rutas óptimas.

Ejemplo Floyd-Warshall: Matriz Inicial D^(0)

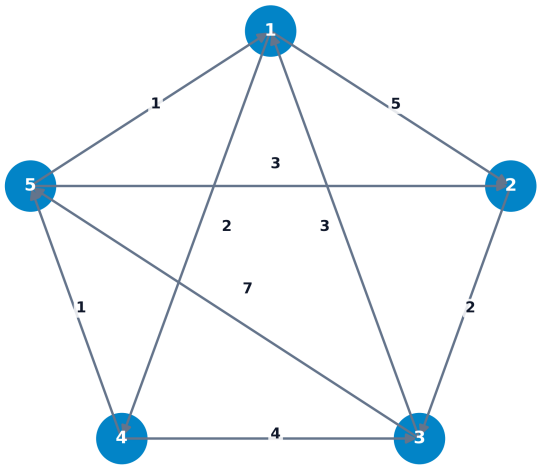

- **Matriz Inicial de Distancias Directas $D^{(0)}$:**

$$D^{(0)} = \begin{pmatrix} 0 & 5 & \infty & 2 & \infty \\ \infty & 0 & 2 & \infty & \infty \\ 3 & \infty & 0 & \infty & 7 \\ \infty & \infty & 4 & 0 & 1 \\ 1 & 3 & \infty & \infty & 0 \end{pmatrix}$$

- Contiene las distancias directas entre todo par de vértices $i, j \in V$ antes de aplicar ningún pivote intermedio.

Ejemplo Floyd-Warshall: Iteración k=1 (Pivote nodo 1)

- **Evaluación del pivote intermedio $k = 1$:**
  - **Fila 1**: $(0, 5, \infty, 2, \infty)$
  - **Columna 1**: $(0, \infty, 3, \infty, 1)^T$
- **Relajaciones de etiquetas**:
  - $d_{32}^{(1)} = \min\{\infty, 3 + 5\} = \mathbf{8}$
  - $d_{34}^{(1)} = \min\{\infty, 3 + 2\} = \mathbf{5}$
  - $d_{54}^{(1)} = \min\{\infty, 1 + 2\} = \mathbf{3}$

- **Matriz Resultante $D^{(1)}$:**

$$D^{(1)} = \begin{pmatrix} 0 & 5 & \infty & 2 & \infty \\ \infty & 0 & 2 & \infty & \infty \\ 3 & \mathbf{8} & 0 & \mathbf{5} & 7 \\ \infty & \infty & 4 & 0 & 1 \\ 1 & 3 & \infty & \mathbf{3} & 0 \end{pmatrix}$$

Ejemplo Floyd-Warshall: Iteración k=2 (Pivote nodo 2)

- **Evaluación del pivote intermedio** $k = 2$:
  - **Fila 2**: $(\infty, 0, 2, \infty, \infty)$
  - **Columna 2**: $(5, 0, 8, \infty, 3)^T$
- **Relajaciones de etiquetas**:
  - $d_{13}^{(2)} = \min\{\infty, 5 + 2\} = \mathbf{7}$
  - $d_{53}^{(2)} = \min\{\infty, 3 + 2\} = \mathbf{5}$

- **Matriz Resultante** $D^{(2)}$:

$$D^{(2)} = \begin{pmatrix} 0 & 5 & \mathbf{7} & 2 & \infty \\ \infty & 0 & 2 & \infty & \infty \\ 3 & 8 & 0 & 5 & 7 \\ \infty & \infty & 4 & 0 & 1 \\ 1 & 3 & \mathbf{5} & 3 & 0 \end{pmatrix}$$

Ejemplo Floyd-Warshall: Iteración k=3 (Pivote nodo 3)

- **Evaluación del pivote intermedio $k = 3$:**
  - **Fila 3**: $(3, 8, 0, 5, 7)$
  - **Columna 3**: $(7, 2, 0, 4, 5)^T$
- **Relajaciones de etiquetas**:
  - $d_{15}^{(3)} = \min\{\infty, 7 + 7\} = \mathbf{14}$
  - $d_{21}^{(3)} = \min\{\infty, 2 + 3\} = \mathbf{5}$
  - $d_{24}^{(3)} = \min\{\infty, 2 + 5\} = \mathbf{7}$
  - $d_{25}^{(3)} = \min\{\infty, 2 + 7\} = \mathbf{9}$
  - $d_{41}^{(3)} = \min\{\infty, 4 + 3\} = \mathbf{7}$
  - $d_{42}^{(3)} = \min\{\infty, 4 + 8\} = \mathbf{12}$
- **Matriz Resultante $D^{(3)}$:**

$$D^{(3)} = \begin{pmatrix} 0 & 5 & 7 & 2 & \mathbf{14} \\ \mathbf{5} & 0 & 2 & \mathbf{7} & \mathbf{9} \\ 3 & 8 & 0 & 5 & 7 \\ \mathbf{7} & \mathbf{12} & 4 & 0 & 1 \\ 1 & 3 & 5 & 3 & 0 \end{pmatrix}$$

Ejemplo Floyd-Warshall: Iteración k=4 (Pivote nodo 4)

- **Evaluación del pivote intermedio** $k = 4$:
  - **Fila 4**: $(7, 12, 4, 0, 1)$
  - **Columna 4**: $(2, 7, 5, 0, 3)^T$
- **Relajaciones de etiquetas**:
  - $d_{13}^{(4)} = \min\{7, 2+4\} = \mathbf{6}$
  - $d_{15}^{(4)} = \min\{14, 2+1\} = \mathbf{3}$
  - $d_{25}^{(4)} = \min\{9, 7+1\} = \mathbf{8}$
  - $d_{35}^{(4)} = \min\{7, 5+1\} = \mathbf{6}$

- **Matriz Resultante** $D^{(4)}$:

$$D^{(4)} = \begin{pmatrix} 0 & 5 & \mathbf{6} & 2 & \mathbf{3} \\ 5 & 0 & 2 & 7 & \mathbf{8} \\ 3 & 8 & 0 & 5 & \mathbf{6} \\ 7 & 12 & 4 & 0 & 1 \\ 1 & 3 & 5 & 3 & 0 \end{pmatrix}$$

Ejemplo Floyd-Warshall: Iteración k=5 (Matriz Final D^(5))

- **Evaluación del pivote intermedio** $k = 5$:
  - **Fila 5**: $(1, 3, 5, 3, 0)$
  - **Columna 5**: $(3, 8, 6, 1, 0)^T$
- **Relajaciones finales**:
  - $d_{41}^{(5)} = \min\{7, 1+1\} = \mathbf{2}$
  - $d_{42}^{(5)} = \min\{12, 1+3\} = \mathbf{4}$
- **Conclusión**: $D^{(5)}$ determina la distancia geodésica exacta entre todo par de vértices.

- **Matriz Final** $D^{(5)}$:

$$D^{(5)} = \begin{pmatrix} 0 & 5 & 6 & 2 & 3 \\ 5 & 0 & 2 & 7 & 8 \\ 3 & 8 & 0 & 5 & 6 \\ \mathbf{2} & \mathbf{4} & 4 & 0 & 1 \\ 1 & 3 & 5 & 3 & 0 \end{pmatrix}$$

Ejemplo Floyd-Warshall: Reconstrucción de la ruta óptima (4, 2)

- **Matriz de predecesores final** $P^{(5)}$:

$$\text{Para el par } (4,2): \quad P_{42} = 5$$

- **Traza de reconstrucción**:
  1. De 4 a 2: El primer paso intermedio pasa por el nodo 5 $\implies$ segmento $4 \to 5$.
  2. De 5 a 2: Inspeccionar $P_{52} = 2 \implies$ segmento directo $5 \to 2$.
- **Ruta elemental óptima**:

$$4 \to 5 \to 2$$

  - Coste acumulado: $d_{45} + d_{52} = 1 + 3 = \mathbf{4}$ (coincide con $d_{42}^{(5)} = 4$).

Ejemplo Floyd-Warshall: Traza animada interactiva

Tema 9: Emparejamientos en redes

Optimización y Análisis de Redes

Víctor Aceña Gil - Antonio Alonso Ayuso

2026-08-23

Objetivos de aprendizaje

1. **Definir** y **clasificar** emparejamientos maximales, de máximo cardinal y perfectos.
2. **Demostrar** y **aplicar** el Teorema de Berge mediante cadenas incrementales.
3. **Analizar** la descomposición del grafo diferencia simétrica $G' = (V, K_1 \triangle K_2)$.
4. **Construir** árboles y bosques alternantes con niveles Y^0 e Y^1.
5. **Ejecutar** el algoritmo de contracción y descompresión de flores de Edmonds.
6. **Demostrar** y **aplicar** el Teorema de Dualidad de Gallai ($|K_0| + |F_0| = |V|$).
7. **Formular** y **resolver** emparejamientos de máximo peso por costes reducidos.

Fundamentos y conceptos de emparejamiento

Asignación de tripulaciones de la RAF (1940)

- **Contexto de la Batalla de Inglaterra (1940)**:
  - Formar parejas de dos pilotos para cazas biplaza de combate.
- **Restricción de comunicación lingüística**:
  - Ambos aviadores deben dominar al menos un idioma común para coordinar maniobras en cabina.
- **Objetivo de optimización**:
  - Maximizar el número total de aviones biplaza que pueden despegar simultáneamente.
- **Competencias lingüísticas (7 aviadores)**:
  - P, P': Solo polaco.
  - PI: Polaco e inglés.
  - I: Solo inglés.
  - A: Solo alemán.
  - AI: Alemán e inglés.
  - FI: Francés e inglés.

Ejemplo RAF: Construcción del grafo de compatibilidad

- **Grafo simple no dirigido** $G = (V, E)$:
  - $V = \{P, PI, P', I, A, AI, FI\}$ (los 7 aviadores disponibles).
  - Aristas: Existe arista $\{u, v\} \in E$ si los pilotos u y v comparten al menos un idioma.

$$E = \{\{P, PI\}, \{P, P'\}, \{PI, P'\}, \{PI, I\}, \{PI, AI\}, \{PI, FI\}, \{I, FI\}, \{I, AI\}, \{FI, AI\}, \{A, AI\}\}$$

- **Cota superior teórica**: Con 7 pilotos, el número máximo de parejas disjuntas es $\lfloor 7/2 \rfloor = 3$.

Ejemplo RAF: Asignación codiciosa subóptima (Maximal)

- **Estrategia codiciosa (*greedy*)**:
  - Emparejar inmediatamente a los primeros aviadores compatibles disponibles:

$$K_1 = \{\{P, PI\}, \{A, AI\}\} \quad (|K_1| = 2)$$

- **Bloqueo del resto de aviadores**:
  - Al saturar a los bilingües PI y AI, los 3 aviadores restantes (P', FI, I) quedan aislados en tierra sin idioma común compartido.
- **Evaluación de maximalidad subóptima**:
  - Aviones biplaza operativos: **2**. Pilotos libres en tierra: **3** (P', FI, I).
  - K_1 es **maximal** por inclusión (no se puede añadir ninguna arista más directamente), pero no alcanza el máximo cardinal global.

Ejemplo RAF: Reasignación de máximo cardinal

- **Reasignación coordinada de parejas**:
  - Deshacer las asignaciones codiciosas para compartir los idiomas puente (polaco e inglés):

$$K_2 = \{\{P, P'\}, \{PI, I\}, \{AI, FI\}\} \quad (|K_2| = 3)$$

- **Alineación lingüística lograda**:
  - $\{P, P'\}$ se comunican en polaco; $\{PI, I\}$ y $\{AI, FI\}$ se comunican en inglés.
- **Resultado óptimo global**:
  - Aviones biplaza operativos: **3**. Piloto libre: solo **1** (A).
  - Se alcanza la cota teórica superior $\lfloor 7/2 \rfloor = 3$, demostrando que K_2 es de **máximo cardinal**.

Ejemplo RAF: Comparación gráfica de soluciones

- **Subóptimo K_1 (izq.)**: 2 aristas en azul; bloquea a P', FI, I.
- **Óptimo K_2 (der.)**: 3 aristas en rojo; emparejamiento de máximo cardinal con único libre A.

Definición: Emparejamiento en un grafo

Emparejamiento en un grafo

Dado un grafo no dirigido simple $G = (V, E)$, un **emparejamiento** (*matching*) es un subconjunto de aristas $K \subseteq E$ tal que ninguna pareja de aristas comparte vértices:

$$e_1 \cap e_2 = \emptyset, \quad \forall e_1, e_2 \in K,\ e_1 \neq e_2$$

- **Grado en** $G_K = (V, K)$: $\mathrm{gr}_{G_K}(v) \leq 1,\ \forall v \in V$.
- **Independencia**: Las aristas de K son mutuamente disjuntas en sus extremos.

Formulación algebraica y de programación lineal

- **Representación mediante vector binario**:
  - $\mathbf{x} \in \{0,1\}^{|E|}$, donde $x_e = 1$ si $e \in K$, y $x_e = 0$ en caso contrario.
- **Restricción de no adyacencia nodal**:

$$\sum_{e \in \delta(v)} x_e \leq 1, \quad \forall v \in V$$

- **Modelo en Programación Lineal Entera (PLE)**:

$$\max \left\{ \sum_{e \in E} x_e : \sum_{e \in \delta(v)} x_e \leq 1 \ \forall v \in V, \ x_e \in \{0,1\} \ \forall e \in E \right\}$$

Hereditariedad de los emparejamientos

Hereditariedad de los emparejamientos

Dado un grafo $G = (V, E)$ y un emparejamiento $K \subseteq E$, cualquier subconjunto $K' \subseteq K$ es también un emparejamiento de G.

- **Estructura de complejo simplicial**:
  - La familia $\mathcal{I}$ de todos los emparejamientos de G forma un sistema de independencia.
  - El conjunto vacío $\emptyset \in \mathcal{I}$ y cada arista individual $\{e\} \in \mathcal{I}$.
- **Espacio factible**: Las soluciones factibles son subconjuntos independientes de aristas.

Definición: Problema de emparejamiento de máximo cardinal

Problema de emparejamiento de máximo cardinal

Dado un grafo no dirigido $G = (V, E)$, el **problema de emparejamiento de máximo cardinal** consiste en determinar un emparejamiento $K \subseteq E$ que maximice $|K|$.

- **Objetivo de optimización global**: Hallar $K^* \in \mathcal{J}$ tal que $|K^*| = \max_{K \in \mathcal{J}} |K|$.
- **Cota superior general**: $|K| \leq \lfloor |V|/2 \rfloor$.

Definición: Vértices saturados y vértices expuestos

Vértices saturados y vértices expuestos

Dado un grafo $G = (V, E)$ y un emparejamiento $K \subseteq E$:

- Un vértice $x \in V$ está **saturado** por K si existe alguna arista $\{x, y\} \in K$ incidente en x.
- Un vértice $x \in V$ está **expuesto** (o libre) si ninguna arista de K incide en x.

- **Balance nodal**: Vértices saturados $= 2|K|$; Vértices expuestos $= |V| - 2|K|$.

Condición de parada por cardinalidad de expuestos

Condición de parada por cardinalidad de expuestos

Dado un grafo $G = (V, E)$ con $n = |V|$ vértices y un emparejamiento $K \subseteq E$, si el número de vértices no saturados (expuestos) es 0 o 1, entonces K es un **emparejamiento de máximo cardinal**.

- **Criterio determinista**:
  - Añadir una arista disjunta exige disponer de al menos 2 vértices libres disponibles.
  - Con ≤ 1 vértice libre, no es posible añadir ninguna arista más.

Emparejamiento maximal vs. Máximo cardinal

- **Emparejamiento maximal (por inclusión)**:
  - No se le puede añadir ninguna arista más de E de forma directa:

    $$\nexists e \in E \setminus K : K \cup \{e\} \in \mathcal{J}$$

  - Es un óptimo local alcanzado por algoritmos codiciosos (*greedy*).

- **Emparejamiento de máximo cardinal**:
  - Alcanza el máximo valor absoluto de $|K|$ entre todos los emparejamientos:

    $$|K^*| \geq |K|, \quad \forall K \in \mathcal{J}$$

  - Exige **reorganizar y reasignar parejas** a lo largo del grafo.

Definición: Emparejamiento perfecto

Emparejamiento perfecto (1-factor)

Dado un grafo $G = (V, E)$ con $n = |V|$ vértices, un emparejamiento $K \subseteq E$ se dice **perfecto** (o 1-factor) si satura a todos los vértices del grafo ($|V| - 2|K| = 0$):

$$|K| = \frac{n}{2}$$

- **Condición de paridad**: Requiere obligatoriamente que el orden $n = |V|$ sea un número **par**.

Resolución mediante cadenas alternantes e incrementales

Cadenas alternantes, cadenas incrementales y transferencias

- **Principio de mejora local iterativa**:
  - Modificar el emparejamiento actual intercambiando asignaciones para aumentar su tamaño.
- **Reasignación en cascada**:
  - Alternar aristas no emparejadas con emparejadas para reajustar aristas adyacentes.
- **Herramienta combinatoria**:
  - Las **cadenas alternantes** actúan como conductos de reasignación de parejas.

Definición: Cadena alternante e incremental

Cadena alternante e incremental

Dado un grafo $G = (V, E)$ y un emparejamiento $K \subseteq E$:

- Una **cadena alternante** es una cadena simple $\mu = (v_1, v_2, \ldots, v_k)$ cuyas aristas pertenecen y no pertenecen alternativamente a K (alternan entre K y $E \setminus K$).
- Una **cadena incremental** (o de aumento) $\mu[x, y]$ con $x \neq y$ es una cadena alternante cuyos dos vértices extremos x e y son **vértices expuestos** respecto de K.

Propiedades algebraicas de las cadenas incrementales

- **1. Longitud impar de aristas**:
  - Toda cadena incremental contiene un **número impar de aristas** $(2k+1)$.
  - Sus aristas primera y última pertenecen obligatoriamente a $E \setminus K$.
- **2. Balance asimétrico de aristas**:
  - Exactamente $k+1$ aristas pertenecen a $E \setminus K$.
  - Exactamente k aristas pertenecen a K.

$$|\mu \setminus K| = |\mu \cap K| + 1$$

Definición: Operación de transferencia

Operación de transferencia

Dado un emparejamiento K y una cadena incremental $\mu[x, y]$, la **transferencia** sustituye las aristas de $\mu \cap K$ por las de $\mu \setminus K$:

$$K' = K \triangle \mu[x, y] = (K \setminus \mu) \cup (\mu \setminus K)$$

El emparejamiento resultante satisface estrictamente:

$$|K'| = |K| + 1$$

Ejemplo Transferencia: Grafo de 6 nodos y estado inicial

- **Grafo simple** $G = (V, E)$:
  - Vértices: $V = \{1, 2, 3, 4, 5, 6\}$ (6 nodos).
  - Emparejamiento inicial: $K = \{\{2, 3\}, \{5, 6\}\}$ ($|K| = 2$).
- **Estado de saturación nodal**:
  - Vértices saturados ($sat = 1$): $\{2, 3, 5, 6\}$.
  - Vértices expuestos ($sat = 0$, libres): $\{1, 4\}$.
- **Objetivo algorítmico**:
  - Buscar un camino alternante que conecte los dos extremos libres 1 y 4 para aumentar el tamaño del emparejamiento.

Ejemplo Transferencia: Detección de la cadena incremental

- **Cadena alternante entre vértices libres 1 y 4**:

$$\mu = (1, 2, 3, 4)$$

- **Análisis de alternancia de aristas**:
  - $\{1, 2\} \in E \setminus K$ (no pertenece a K).
  - $\{2, 3\} \in K$ (pertenece a K).
  - $\{3, 4\} \in E \setminus K$ (no pertenece a K).
- **Propiedad fundamental de aumento**:
  - Longitud 3 (impar): contiene 2 aristas fuera de K frente a 1 dentro de K.
  - Al permutar la pertenencia de las aristas, el balance neto aportará $+1$ arista al emparejamiento.

Ejemplo Transferencia: Ejecución y emparejamiento perfecto

- **Diferencia simétrica** $K' = K \triangle \mu$:
  - Sale de K: $\{2, 3\}$. Entran a K: $\{1, 2\}$ y $\{3, 4\}$. Permanece: $\{5, 6\}$.

$$K' = \{\{1, 2\}, \{3, 4\}, \{5, 6\}\} \quad (|K'| = 3, \text{perfecto})$$

Estructura del grafo diferencia simétrica

Lema: Estructura del grafo diferencia simétrica

Dados dos emparejamientos cualesquiera K_1 y K_2 en un grafo simple $G = (V, E)$, el subgrafo generado por la diferencia simétrica $G' = (V, K_1 \triangle K_2)$ está compuesto exclusivamente por:

1. **Vértices aislados** (grado 0).
2. **Ciclos elementales alternantes** de longitud estrictamente par.
3. **Cadenas elementales alternantes** de longitud par o impar.

Análisis de grados en la diferencia simétrica

- **Grados nodales en** $G' = (V, K_1 \triangle K_2)$:
  - $d_{G'}(v) = 0$: Vértice no saturado por K_1 ni K_2, o saturado por la misma arista ($e \in K_1 \cap K_2$).
  - $d_{G'}(v) = 1$: Vértice saturado solo por uno de los dos emparejamientos (**extremos de cadenas**).
  - $d_{G'}(v) = 2$: Vértice saturado por aristas distintas en K_1 y K_2.
- **Consecuencia topológica**: $\Delta(G') \leq 2$, impidiendo ramificaciones de grado ≥ 3.

Componentes conexas en la diferencia simétrica

- Los ciclos deben tener longitud par obligatoria para alternar entre K_1 y K_2.

Ejemplo Diferencia Simétrica: Grafo bipartito de 10 vértices

- **Estructura bipartita**:
  - Conjunto superior: $\{1, 2, 3, 4, 5\}$; Conjunto inferior: $\{6, 7, 8, 9, 10\}$.
- **Emparejamientos a comparar**:
  - K_1 **(azul, 3 aristas)**: $K_1 = \{\{2, 7\}, \{3, 8\}, \{5, 10\}\}$.
  - K_2 **(rojo, 2 aristas)**: $K_2 = \{\{3, 10\}, \{5, 8\}\}$.
- **Objetivo de análisis**:
  - Superponer K_1 y K_2 en el subgrafo de discrepancias $G' = (V, K_1 \triangle K_2)$ y clasificar sus componentes conexas.

Ejemplo Diferencia Simétrica: Descomposición de componentes

- **Componentes en** $G' = (V, K_1 \triangle K_2)$:
  1. **Ciclo alternante par**: $(3, 8, 5, 10, 3)$ de longitud 4 (2 aristas azules de K_1 y 2 rojas de K_2).
  2. **Cadena alternante**: $(2, 7)$ de longitud 1 (arista de K_1).
  3. **Vértices aislados**: $1, 4, 6, 9$.

Teorema de caracterización de Berge

! Caracterización de Berge (1957)

Dado un grafo $G = (V, E)$, un emparejamiento $K \subseteq E$ es de **máximo cardinal** si y solo si el grafo G **no contiene ninguna cadena incremental** con respecto a K.

- **Condición necesaria y suficiente**:
  - Si existe cadena incremental μ, la transferencia $K \triangle \mu$ aumenta el cardinal.
  - Si no existen cadenas incrementales, la descomposición de $K \triangle K^*$ certifica $|K| = |K^*|$.

Interpretación y analogías del Teorema de Berge

- **Certificado de optimalidad global**:
  - Una condición local determinista (ausencia de cadenas incrementales) certifica la optimalidad global.
- **Analogías fundamentales en Investigación Operativa**:
  - **Ford-Fulkerson (Capítulo 8)**: La ausencia de caminos de aumento en la red residual certifica el flujo máximo.
  - **Método del Símplex (Capítulo 3)**: La no negatividad de los costes reducidos certifica el óptimo lineal.

Algoritmo del árbol alternante y contracción de flores (Edmonds)

Variable indicadora de saturación y estructura de K

- **Variable indicadora de saturación** $sat(x)$:

$$sat(x) = \begin{cases} 1, & \text{si } x \text{ está saturado por } K \\ 0, & \text{si } x \text{ es un vértice expuesto} \end{cases}$$

- **Bipartición de** $G_K = (V, K)$:
  - El subgrafo parcial formado exclusivamente por las aristas de K es siempre un **grafo bipartito**, pues cada arista forma una componente K_2 independiente.

Definición: Árbol alternante y bosque alternante

Árbol alternante y bosque alternante

Dados un grafo $G = (V, E)$ y un emparejamiento $K \subseteq E$, un **árbol alternante** es un subgrafo parcial $H = (W, T)$ que satisface:

1. H es un árbol (conexo y sin ciclos).
2. Existe un único vértice distinguido $r \in W$ (**raíz expuesta**, $sat(r) = 0$).
3. Cualquier cadena en H que une un vértice $w \in W$ con la raíz r es una **cadena alternante**.

Un conjunto de árboles alternantes disjuntos cuyas raíces son vértices expuestos forma un **bosque alternante** $\{H(r) : r \in R\}$.

Gestión computacional: Vector de antecesores p

- **Caracterización mediante el vector de padres $\mathbf{p} \in V^n$:**
  - Cada raíz $r \in R$ se identifica por la autorreferencia $p(r) = r$.
  - La única cadena alternante entre cualquier nodo w y su raíz r se recupera encadenando $\mathbf{p}$:

$$w \longleftrightarrow p(w) \longleftrightarrow p(p(w)) \longleftrightarrow \cdots \longleftrightarrow r$$

Ejemplo Bosque Alternante: Planteamiento y raíces en 6 nodos

- **Grafo de 6 vértices**:
  - $V = \{1, 2, 3, 4, 5, 6\}$ con aristas $\{\{1, 4\}, \{1, 5\}, \{1, 6\}, \{2, 5\}, \{3, 5\}\}$.
  - Emparejamiento actual: $K = \{\{1, 4\}, \{2, 5\}\}$ ($|K| = 2$).
- **Raíces expuestas ($sat = 0$)**:
  - $R = \{3, 6\}$. Iniciar dos árboles alternantes independientes: $H(3)$ y $H(6)$.
  - Desde raíz 3: explorar $\{3, 5\} \notin K$ y $\{5, 2\} \in K$.
  - Desde raíz 6: explorar $\{6, 1\} \notin K$ y $\{1, 4\} \in K$.

Ejemplo Bosque Alternante: Vector p y Optimalidad

- **Árboles alternantes**: $H(3) = (\{2,3,5\}, \{\{3,5\},\{2,5\}\})$; $H(6) = (\{1,4,6\}, \{\{6,1\},\{1,4\}\})$.
- **Vector de padres**: $\mathbf{p}^T = (6,5,3,1,3,6)$.
- **Optimalidad**: Al no alcanzarse más nodos libres, por Berge K es de **máximo cardinal** ($|K| = 2$).

Ejemplo Árbol 10 Nodos: Planteamiento y exploración desde raíz 1

- **Grafo bipartito con K_1 inicial**:

$$K_1 = \{\{2,7\}, \{3,8\}, \{5,10\}\} \quad (|K_1| = 3)$$

- **Exploración por niveles desde raíz expuesta $r = 1$ ($sat(1) = 0$)**:
  - $1 \to 7$ ($\notin K$) $\to 2$ ($\in K$).
  - $2 \to 8$ ($\notin K$) $\to 3$ ($\in K$).
  - $3 \to 10$ ($\notin K$) $\to 5$ ($\in K$).
- **Hojas libres alcanzadas desde nodo 3**:
  - $3 \to 6$ ($\notin K$, nodo libre 6) y $3 \to 9$ ($\notin K$, nodo libre 9).
  - Se detectan **dos cadenas incrementales disyuntivas** hacia la raíz 1.

Ejemplo Árbol 10 Nodos: Vector p y Transferencia

- **Vector de padres**: $\mathbf{p}^T = (1, 7, 8, 0, 10, 3, 1, 2, 3, 3)$.
- **Transferencia por nodo 6**: $\mu = (6, 3, 8, 2, 7, 1) \implies K_1' = \{\{6, 3\}, \{8, 2\}, \{7, 1\}, \{5, 10\}\}$ $(|K_1'| = 4)$.

El desafío de los ciclos impares en grafos generales

- **Grafos bipartitos**:
  - Todos los ciclos tienen longitud par.
  - La búsqueda con árboles alternantes progresa siempre de forma directa hacia nuevos vértices o detecta cadenas incrementales.
- **Grafos generales y ciclos impares**:
  - Los ciclos de longitud impar (**flores** o *blossoms*) introducen una dificultad estructural.
  - Un ciclo impar puede hacer que un nodo sea alcanzable por caminos alternantes pares e impares.

Propiedad de la flor en ciclos impares

- En un ciclo impar de $2k+1$ vértices (C_5), el emparejamiento maximal satura a $2k$ vértices con k aristas.
- **Propiedad clave**: **Cualquiera de los $2k+1$ vértices del ciclo puede elegirse libremente como el vértice expuesto**.

Definición: Grafo comprimido G/W

Contracción de un grafo (Grafo comprimido)

Dado un grafo no dirigido $G = (V, E)$ y un subconjunto de vértices $W \subset V$ correspondiente a un ciclo impar, se define el **grafo comprimido** G/W como:

$$G/W = \big((V \setminus W) \cup \{w\},\, E/W\big)$$

donde w es un nuevo pseudovértice y E/W reasigna las aristas incidentes en W hacia w.

Teorema: Contracción de ciclos impares de Edmonds

! Contracción de ciclos impares de Edmonds (1965)

Sea $G = (V, E)$ un grafo, $W \subset V$ un subconjunto de vértices asociado a un ciclo de longitud impar, y sea K_1 un emparejamiento en el grafo comprimido G/W.
Entonces, existe un emparejamiento K_W en el subgrafo generado por W tal que:

$$K = K_1 \cup K_W$$

es un emparejamiento válido de G.

Reglas operativas de descompresión de flores

- **1. Existencia de vértice expuesto**:
  - Al ser W un ciclo impar, siempre queda exactamente un vértice no saturado en W respecto de K_W.
- **2. Libertad de selección**:
  - Siempre es posible elegir de forma determinista qué vértice del ciclo queda no saturado.
- **3. Alineación con la arista exterior**:
  - Si el pseudonodo w está saturado en K_1, se deja no saturado en el ciclo el vértice $i \in W$ incidente en la arista exterior que satura a w.

Advertencia: Maximalidad en grafos comprimidos

- **Advertencia teórica**:
  - Que K_1 sea **maximal** en G/W no implica necesariamente que K sea de **máximo cardinal** en G.
- **Contraejemplo**:
  - Ciclo $\{1, 2, 3\}$ y aristas exteriores $\{\{1, 6\}, \{2, 4\}, \{3, 5\}\}$.
  - En G/W, $K_1 = \{\{w, 6\}\}$ es maximal pero produce $|K| = 2$ en G, cuando el óptimo en G es $|K^*| = 3$.

Niveles en el árbol alternante: Vértices pares e impares

- **Estructura jerárquica** (Y, T):
  - $Y \subseteq V$: Vértices explorados por el árbol.
  - $T \subseteq E$: Aristas del árbol alternante.
- **Conjunto de vértices pares ($Y^0 \subset Y$)**:
  - Vértices a distancia alternante par desde la raíz (incluye a la raíz a distancia 0).
- **Propiedad estructural de las hojas**:
  - Todas las hojas del árbol alternante deben ser obligatoriamente vértices pares (Y^0).

Jerarquía de niveles del árbol alternante

- Árbol alternante con raíz en $r = 0$. Vértices pares $Y^0 = \{0, 2, 4, 6, 8\}$ (en rojo).

Reglas de exploración desde vértices pares Y0

- **1. Detección de Ciclos Impares (Flores)**:
  - Si existen dos vértices de Y^0 conectados por una arista $\{i, j\} \in E$, se detecta un **ciclo impar** (flor). Se contrae en un supernodo w.
- **2. Expansión del Árbol hacia $j \notin Y$**:
  - **Hacia adyacente no saturado ($sat(j) = 0$)**: Se detecta una **cadena alternante incremental** entre la raíz y j.
  - **Hacia adyacente saturado ($sat(j) = 1$)**: Si $\{j, k\} \in K$, se incorporan $\{i, j\}$ y $\{j, k\}$, añadiendo k a Y^0.

Algoritmo de Flor de Edmonds: Paso A y Paso B

Esquema: Algoritmo de Flor de Edmonds (Parte 1)

- **Paso A (Inicialización)**:
  - Encontrar un emparejamiento inicial factible K en G (por ejemplo, $K = \emptyset$).
- **Paso B (Condición de parada elemental)**:
  - Si el número de vértices no saturados por K es 0 o 1, **PARAR**: K es de máximo cardinal. En caso contrario, ir al **Paso C**.

Algoritmo de Flor de Edmonds: Paso C (Casos 1 y 2)

i Esquema: Algoritmo de Flor de Edmonds (Paso C - Casos 1 y 2)

- **Paso C.1**: Seleccionar una raíz expuesta $i_0 \in V$ $(sat(i_0) = 0)$. Inicializar $Y = Y^0 = \{i_0\}$, $T = \emptyset$.
- **Paso C.2 (Exploración desde Y^0)**:
  - **Caso 1 (Detección de Flor)**: Si existen $i, j \in Y^0$ con $\{i, j\} \in E$, contraer el ciclo impar W en G/W, actualizar Y y Y^0 y volver al Paso C.2.
  - **Caso 2 (Extensión del Árbol)**: Si existe $i \in Y^0$ y $j \notin Y$ saturado por $\{j, k\} \in K$ con $\{i, j\} \in E$, incorporar $\{i, j\}$ y $\{j, k\}$ al árbol: $Y \leftarrow Y \cup \{j, k\}$, $Y^0 \leftarrow Y^0 \cup \{k\}$ y volver al Paso C.2.

Algoritmo de Flor de Edmonds: Paso C (Casos 3 y 4)

i Esquema: Algoritmo de Flor de Edmonds (Paso C - Casos 3 y 4)

- **Caso 3 (Detección de Cadena Incremental)**:
  - Si existe $i \in Y^0$ y $j \notin Y$ expuesto $(sat(j) = 0)$ con $\{i, j\} \in E$, se detecta una **cadena incremental** μ.
  - Realizar la transferencia $K \leftarrow K \triangle \mu$, descontraer todas las flores activas y volver al **Paso B**.
- **Caso 4 (Árbol Bloqueado / Húngaro)**:
  - Si no es posible aplicar ningún caso desde Y^0, fijar i_0 como no aumentable. Si quedan raíces sin explorar, ir a C.1; si no, **PARAR**: K es de **máximo cardinal**.

Ejemplo Edmonds: Traza completa en grafo de 8 nodos

- **Grafo $G = (V, E)$ de 8 vértices y 10 aristas**:
  - $V = \{1, 2, 3, 4, 5, 6, 7, 8\}$.
  - $E =$
    $\{\{6, 7\}, \{7, 8\}, \{1, 2\}, \{2, 3\}, \{3, 4\}, \{4, 5\}, \{4, 6\}, \{1, 5\}, \{1, 7\}, \{2, 8$
- **Fase Inicial**:
  - **Paso A**: $K = \emptyset$. Vértices expuestos: $\{1, 2, 3, 4, 5, 6, 7, 8\}$.
  - **Paso B**: 8 vértices expuestos $(> 1) \implies$ Proceder al Paso C.

Ejemplo Edmonds: Iteración 1 - Estado inicial K0

- **Paso C.1**: Raíz expuesta $i_0 = 1$. $Y = Y^0 = \{1\}$, $T = \emptyset$.
- **Paso C.2**:
  - Para $1 \in Y^0$, vecino expuesto $2 \notin Y$ con $\{1, 2\} \in E$ (Caso 3).
  - Cadena incremental: $\mu_1 = (1, 2)$.
- **Transferencia**:

$$K^1 = \{\{1, 2\}\}$$

Ejemplo Edmonds: Iteración 1 - Transferencia a K1

- **Nuevo estado**
  $K^1 = \{\{1, 2\}\}$:
  - Cardinal $|K^1| = 1$.
  - Vértices saturados: $\{1, 2\}$.
  - Vértices expuestos:
    $\{3, 4, 5, 6, 7, 8\}$.

Ejemplo Edmonds: Iteración 2 - Exploración desde raíz 3

- **Paso B**: 6 expuestos $\Longrightarrow$ Paso C.
- **Paso C.1**: Raíz expuesta $i_0 = 3$. $Y = Y^0 = \{3\}$.
- **Paso C.2 (Extensión del árbol)**:
  - Vecino saturado $2 \notin Y$ (por $\{1, 2\} \in K$).
  - Se incorporan $\{2, 3\}$ y $\{1, 2\}$:

$$Y = \{1, 2, 3\}, \quad Y^0 = \{1, 3\}$$

Ejemplo Edmonds: Iteración 2 - Transferencia a K2

- **Detección de cadena incremental**:
  - Desde $3 \in Y^0$, vecino expuesto $4 \notin Y$ con $\{3,4\} \in E$ (Caso 3).
  - Cadena incremental: $\mu_2 = (3,4)$.
- **Transferencia**:

$$K^2 = \{\{1,2\}, \{3,4\}\} \quad (|K^2| = 2)$$

  - Vértices libres restantes: $\{5,6,7,8\}$.

Ejemplo Edmonds: Iteración 3 - Exploración desde raíz 5

- **Paso B**: 4 expuestos $\{5, 6, 7, 8\}$.
- **Paso C.1**: Raíz expuesta $i_0 = 5$. $Y = Y^0 = \{5\}$.
- **Paso C.2 (Extensiones sucesivas)**:
  - Vecino saturado $1 \implies$ añadir $\{5, 1\}$ y $\{1, 2\}$.
  - Vecino saturado $4 \implies$ añadir $\{5, 4\}$ y $\{4, 3\}$.

  $$Y = \{1, 2, 3, 4, 5\}, \quad Y^0 = \{2, 3, 5\}$$

Ejemplo Edmonds: Iteración 3 - Detección de la Flor W

- **Caso 1 (Detección de Flor)**:
  - Entre los nodos pares $Y^0 = \{2, 3, 5\}$, existe la arista $\{2, 3\} \in E$.
  - Se identifica el ciclo impar de 5 vértices:

$$W = \{1, 2, 3, 4, 5\}$$

Ejemplo Edmonds: Iteración 3 - Contracción al pseudonodo w

- **Contracción de W:**
  - Comprimimos W en el pseudonodo w.
  - Grafo comprimido G/W con vértices $\{w, 6, 7, 8\}$.
  - Árbol actualizado: $Y = Y^0 = \{w\}$, $K = \emptyset$.
- **Transferencia en G/W:**
  - Arista $\{w, 6\}$ a nodo expuesto $6 \implies K = \{\{w, 6\}\}$.

Ejemplo Edmonds: Iteración 4 - Exploración en G/W

- **Paso B en G/W**:
  Expuestos $\{7, 8\}$.
- **Paso C.1**: Raíz $i_0 = 7$.
  $Y = Y^0 = \{7\}$.
- **Paso C.2 (Extensión)**:
  - Vecino saturado $w \implies$
    añadir $\{7, w\}$ y $\{w, 6\}$.

    $Y = \{w, 6, 7\}, \quad Y^0 = \{6, 7\}$

- **Detección de Segunda Flor**:
  - Arista $\{6, 7\} \in E$ entre pares
    $\implies W' = \{w, 6, 7\}$.

Ejemplo Edmonds: Fase de Descompresión de W'

- **Segunda contracción y parada**:
  - Comprimir W' en w'. Arista $\{w', 8\} \implies K = \{\{w', 8\}\}$.
  - 0 vértices libres en $G/W' \implies$ ¡Parada alcanzada!
- **Descompresión de W'**:
  - $\{w', 8\} \to \{7, 8\} \in E$.
  - En W', arista interna $\{w, 6\}$.

$K = \{\{w, 6\}, \{7, 8\}\}$ en G/W

Ejemplo Edmonds: Descompresión de W y Solución Perfecta

- **Descompresión de** $W = \{1, 2, 3, 4, 5\}$:
  - $\{w, 6\} \rightarrow \{4, 6\} \in E$.
  - Nodo 4 saturado exteriormente.
  - En W, emparejamiento interno $\{1, 5\}$ y $\{2, 3\}$.
- **Emparejamiento Óptimo Final**:

$$K^* = \{\{1, 5\}, \{2, 3\}, \{4, 6\}, \{7, 8\}\}$$

  - Cardinal $|K^*| = 4$ (**emparejamiento perfecto**).

Ejemplo Edmonds: Animación de la traza completa

Complejidad y síntesis del Algoritmo de Edmonds

- **Complejidad polinomial**:
  - Búsqueda por árbol y contracciones: $\mathcal{O}(|V|^2|E|)$ o $\mathcal{O}(|E|\sqrt{|V|})$ con estructuras avanzadas.
  - Pertenece estrictamente a la clase de complejidad **P**.
- **Síntesis metodológica**:
  1. Construir árboles alternantes desde raíces expuestas.
  2. Contraer ciclos impares (flores) entre nodos pares Y^0.
  3. Transferir al hallar vértices expuestos y descomprimir flores.

Problemas de recubrimiento en grafos y relaciones de dualidad

Ejemplo: Vigilancia de murallas en la fortaleza

- **Recinto de 12 torres**: Cada guardia asignado a una muralla $\{u, v\}$ vigila las dos torres extremas (u y v).
- **Objetivo**: Hallar el **número mínimo de guardias** necesarios para que **todas las torres queden vigiladas**.

Ejemplo: Solución de recubrimiento mínimo en la fortaleza

- **Modelo como recubrimiento de aristas $F \subseteq E$:**
  - Todo vértice $v \in V$ debe ser incidente en al menos una arista de F ($\sum x_e \geq 1$).
- **Selección óptima de 8 aristas (en rojo)**:

$$F_0 = \{\{1,2\}, \{2,12\}, \{2,3\}, \{4,5\}, \{6,7\}, \{8,9\}, \{8,10\}, \{8,11$$

- **Resultado**:
  - Se cubren las 12 torres con $|F_0| = 8$ guardias a coste mínimo.

Definición: Recubrimiento de aristas (Edge Cover)

Recubrimiento de aristas (Edge Cover)

Dado un grafo no dirigido $G = (V, E)$ sin vértices aislados, un **recubrimiento de aristas** (o *edge cover*) es un subconjunto de aristas $F \subseteq E$ tal que todo vértice $v \in V$ es incidente en al menos una arista de F:

$$\bigcup_{e \in F} e = V$$

- **Condición de existencia**: Requiere que G no contenga vértices aislados ($\text{gr}(v) \geq 1,\ \forall v \in V$).

Monotonía del recubrimiento

Monotonía del recubrimiento

Dado un grafo $G = (V, E)$ y un recubrimiento de aristas $F \subseteq E$, si $F' \subseteq E$ satisface $F \subseteq F'$, entonces F' es también un recubrimiento de aristas de G.

- **Contraste dual con emparejamientos**:
  - **Emparejamientos**: Hereditarios hacia abajo ($K' \subseteq K \implies K'$ emparejamiento).
  - **Recubrimientos**: Monótonos crecientes hacia arriba ($F \subseteq F' \implies F'$ recubrimiento).

Teorema: Dualidad de Gallai para emparejamientos y recubrimientos

! Dualidad de Gallai para emparejamientos y recubrimientos (1959)

Sea $G = (V, E)$ un grafo simple conexo con $n = |V|$ vértices y sin nodos aislados. Sean $K_0 \subseteq E$ un emparejamiento de **máximo cardinal** y $F_0 \subseteq E$ un recubrimiento de aristas de **mínimo cardinal**. Entonces se verifica la identidad exacta:

$$|K_0| + |F_0| = n$$

Construcción del recubrimiento mínimo F1 a partir de K0

- **Algoritmo constructivo directo**:
  1. Obtener el emparejamiento de máximo cardinal K_0.
  2. K_0 satura a $2|K_0|$ vértices, dejando $n - 2|K_0|$ vértices expuestos.
  3. Añadir una arista incidente $e_v \in E$ para cada vértice expuesto $v \notin V(K_0)$:

$$F_1 = K_0 \cup \{e_v \in E \mid v \in V \setminus V(K_0)\}$$

- **Cardinal mínimo**:
$|F_1| = |K_0| + (n - 2|K_0|) = n - |K_0| \implies |K_0| + |F_1| = n.$

Construcción del emparejamiento máximo K1 a partir de F0

- **Algoritmo constructivo recíproco**:
  1. Sea F_0 un recubrimiento de aristas de mínimo cardinal.
  2. El subgrafo (V, F_0) está formado exclusivamente por estrellas conexas (árboles de profundidad 1).
  3. Para cada estrella con $k \geq 2$ aristas, eliminar $k-1$ aristas redundantes, conservando una única arista por componente:

     $$K_1 = F_0 \setminus \{\text{aristas sobrantes en vértices de grado } > 1 \text{ en } F_0\}$$

  4. K_1 es un **emparejamiento de máximo cardinal** ($|K_1| = |K_0|$).

Significado combinatorio: Relación de conservación de Gallai

- **Dualidad entre Packing y Covering**:
  - Cada arista de un emparejamiento satura a 2 vértices distintos.
  - Cada arista adicional de un recubrimiento cubre a 1 vértice libre.
- **Conservación estructural**:
  - El déficit de aristas en el emparejamiento respecto del total de nodos se traduce exactamente en el superávit de aristas requeridas para el recubrimiento mínimo.

Ejemplo: Ilustración de la Dualidad de Gallai en 11 vértices

- **Grafo de 11 vértices**: $K_0 = \{\{1,2\},\{3,4\},\{5,6\},\{7,8\}\}$ ($|K_0| = 4$). Expuestos: $9, 10, 11$.
- **Recubrimiento mínimo**: Se añaden 3 aristas $\implies |F_0| = 4 + 3 = 7$ (en rojo). **Identidad**: $|K_0| + |F_0| = 4 + 7 = 11 = |V|$.

Emparejamiento de máximo peso y algoritmo primal-dual

Definición: Problema de emparejamiento de máximo peso

Problema de emparejamiento de máximo peso

Dado un grafo simple no dirigido $G = (V, E)$ y un vector de pesos $\mathbf{p} = \{p(e) \mid e \in E\}$, el **problema de emparejamiento de máximo peso** consiste en determinar un emparejamiento $K \subseteq E$ que maximice:

$$p(K) = \sum_{e \in K} p(e)$$

- **Ponderación vs Cardinalidad**:
  - Un emparejamiento óptimo en peso no tiene por qué saturar el mayor número de vértices si aristas individuales concentran pesos superiores.

Definición: Coste reducido de una cadena alternante

Coste reducido de una cadena alternante

Dado un grafo $G = (V, E)$ con pesos $p(e)$, un emparejamiento $K \subseteq E$ y una cadena alternante L, se define el **coste reducido** de L respecto de K, denotado por δ_L, como:

$$\delta_L = p(L \cap \overline{K}) - p(L \cap K) = \sum_{e \in L \setminus K} p(e) - \sum_{e \in L \cap K} p(e)$$

donde $\overline{K} = E \setminus K$.

Definición: Ciclo alternante y signo del coste reducido

Ciclo alternante

Dado un grafo $G = (V, E)$ y un emparejamiento $K \subseteq E$, un **ciclo alternante** es una cadena alternante cerrada y simple de longitud estrictamente par, cuyas aristas pertenecen y no pertenecen alternativamente a K.

- **Impacto económico**:
  - Si $\delta_L > 0$, la transferencia incrementa el peso: $p(K') = p(K) + \delta_L$.
  - Si $\delta_L = 0$, mantiene invariable el peso acumulado.

Teorema: Optimalidad por costes reducidos

! Optimalidad por costes reducidos

Dado un grafo $G = (V, E)$ con pesos $p(e)$ sobre las aristas, un emparejamiento $K \subseteq E$ es de **máximo peso** si y solo si **no existe ninguna cadena alternante** (abierta o cerrada) con coste reducido estrictamente positivo ($\delta_L \leq 0$ para toda cadena alternante L).

- **Generalización de Berge**:
  - Cardinal: Cadenas incrementales (ganancia $+1$ arista).
  - Ponderado: Cadenas con ganancia neta de peso positiva ($\delta_L > 0$).

Algoritmo de aumento por cardinalidad fija

- **Construcción inductiva por cardinalidades**
  $m = 1, 2, \ldots, \lfloor n/2 \rfloor$:
  - K^1: Arista individual de mayor peso en E.
  - K^2: Par de aristas disjuntas de mayor suma de pesos en E.
  - K^{m+1}: Se obtiene inductivamente a partir de K^m mediante transferencias de coste reducido máximo.

Teorema: Progresión de emparejamientos de peso máximo

! Progresión de emparejamientos de peso máximo

Sea $G = (V, E)$ un grafo, sea K^m el emparejamiento de máximo peso entre todos los de cardinal m, y sea L una **cadena alternante incremental** respecto de K^m que posea el **coste reducido máximo** $(\delta(L) = \max \delta)$.
Entonces, el emparejamiento $K^{m+1} = K^m \triangle L$ obtenido por la transferencia de L es el **emparejamiento de máximo peso entre todos los de cardinal** $m + 1$.

Ejemplo: Emparejamiento de peso máximo en grafo de 6 nodos

- **Grafo ponderado de 6 vértices y 9 aristas**:

$$p(4,5) = 5, \quad p(3,4) = 4, \quad p(2,3) = 3, \quad p(6,3) = 3, \quad p(6,5) =$$
$$p(1,2) = 2, \quad p(6,2) = 2, \quad p(1,6) = 1, \quad p(2,4) = 1$$

- **Objetivo algorítmico**: Determinar inductivamente la sucesión de emparejamientos óptimos K^1, K^2, K^3.

Ejemplo Peso Máximo: Paso 1 (Cardinal m = 1)

- **Arista de peso máximo**:

  $e^* = \{4, 5\}$ con $p(4, 5) = 5$

- **Emparejamiento** K^1:

  $K^1 = \{\{4, 5\}\}, \quad p(K^1) = 5$

- **Vértices expuestos**:
  $\{1, 2, 3, 6\}$.

Ejemplo Peso Máximo: Paso 2a - Búsqueda de aumento para m = 2

- **Evaluación de aristas disjuntas a $\{4, 5\}$:**
  - $\{2, 3\}$: $\delta = p(2, 3) = 3$.
  - $\{6, 3\}$: $\delta = p(6, 3) = 3$.
  - $\{1, 2\}$: $\delta = p(1, 2) = 2$.
- **Selección de la arista óptima**:
  - Se selecciona $L_1 = \{2, 3\}$ con incremento máximo $\delta(L_1) = 3$.

Ejemplo Peso Máximo: Paso 2b - Transferencia a K2

- **Nuevo estado K^2:**

  $$K^2 = K^1 \cup \{\{2,3\}\} = \{\{4,5\}, \{2,3\}\}$$

  $$p(K^2) = 5 + 3 = 8$$

- **Vértices expuestos restantes**:
  - Vértices libres: $\{1,6\}$.

Ejemplo Peso Máximo: Paso 3a - Evaluación de cadenas para m = 3

- **Cadenas entre expuestos 1 y 6**:
  1. $L_A = 1 - 6$:
     $\delta = p(1, 6) = 1$.
  2. $L_B = 1 - 2 - 3 - 6$:

     $\delta(L_B) = (2 + 3) - 3 = \mathbf{2}$

  3. $L_C = 1 - 2 - 3 - 4 - 5 - 6$:

     $\delta(L_C) = (2+4+2) - (3+5) = \mathbf{0}$

- **Selección de la cadena máxima**:
  - Cadena de ganancia máxima: L_B ($\delta = 2$).

Ejemplo Peso Máximo: Paso 3b - Transferencia a K3 y Solución Óptima

- **Transferencia**
  $K^3 = K^2 \triangle (1-2-3-6)$:
  - Entran $\{1,2\}$ y $\{3,6\}$;
    sale $\{2,3\}$.

    $K^3 = \{\{1,2\}, \{3,6\}, \{4,5\}\}$

    $p(K^3) = p(K^2) + \delta(L_B) = 8+2 = \mathbf{10}$
- **Optimalidad global absoluta**:
  - K^3 es **perfecto** y de **máximo peso global**.

Ejemplo Peso Máximo: Animación de la traza completa

Resumen de la traza y síntesis del Tema 9

- **Evolución por cardinalidades**:

Cardinal m	Empare-jamiento óptimo K^m	Cadena aplicada μ^*	Ganancia δ	Peso Total $p(K^m)$
$m = 1$	$\{\{4,5\}\}$	Arista máxima $\{4,5\}$	$+5$	**5**
$m = 2$	$\{\{4,5\},\{2,3\}\}$	$\{2,3\}$	$+3$	**8**
$m = 3$	$\{\{1,2\},\{3,6\},\{4,5\}\}$	$\{1,2,5,6\}$	$+2$	**10**

- **Conclusiones del capítulo**:
  - **Berge**: Ausencia de cadenas incrementales $\iff$ Máximo cardinal.
  - **Edmonds**: Contracción de flores para grafos generales en tiempo polinomial.
  - **Gallai**: Identidad exacta $|K_0| + |F_0| = n$.

Tema 10: Rutas eulerianas, hamiltonianas y problemas de rutas

Optimización y Análisis de Redes

Víctor Aceña Gil - Antonio Alonso Ayuso

2026-08-25

Objetivos de aprendizaje

1. **Diferenciar** grafos eulerianos (tiempo polinomial) y hamiltonianos ($\mathcal{NP}$-completos).
2. **Aplicar** el teorema de Euler y ejecutar el algoritmo constructivo de cadenas.
3. **Resolver** el Problema del Cartero Chino (CPP) mediante emparejamientos perfectos.
4. **Evaluar** ciclos hamiltonianos mediante 2-conexidad, clausura y teoremas de Dirac/Ore.
5. **Formular** el Problema del Viajante (TSP) comparando modelos DFJ y MTZ.
6. **Clasificar** los Problemas de Rutas de Vehículos (VRP) en *Node* y *Arc Routing*.

Grafos eulerianos y el problema de los puentes de Königsberg

El enigma histórico de Königsberg (1736)

- **Contexto geográfico (Königsberg, Prusia)**:
  - El río Pregel divide la ciudad en 4 masas terrestres (A, D islas, B, C riberas) conectadas por 7 puentes.
- **El desafío ciudadano**:
  - *¿Es posible cruzar cada uno de los 7 puentes exactamente una vez y regresar al punto de partida?*
- **La contribución de Leonhard Euler (1736)**:
  - Demostró su imposibilidad analítica mediante abstracción topológica, fundando la **teoría de grafos**.

Abstracción topológica de Euler

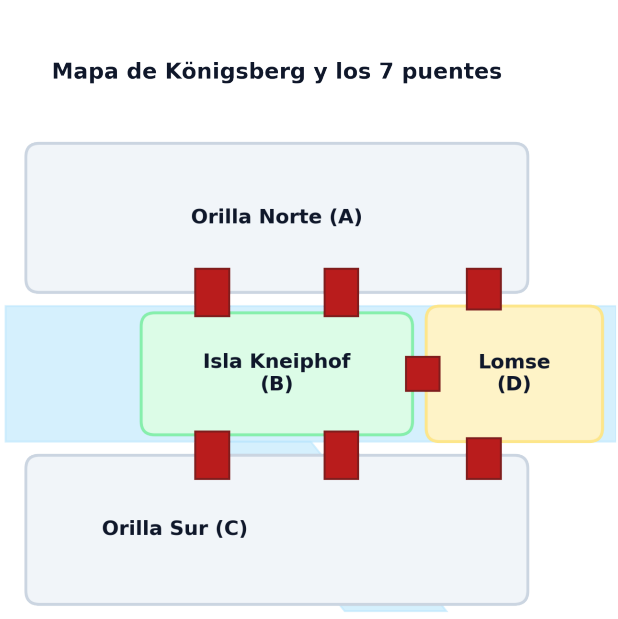

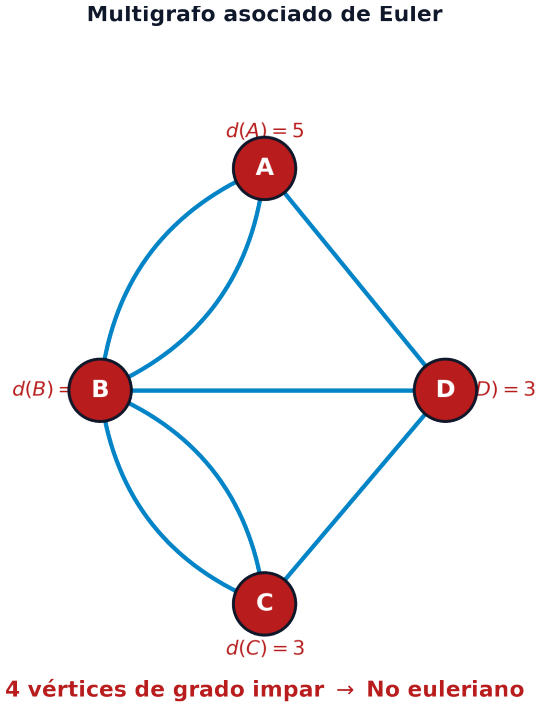

- **Del espacio geográfico al multigrafo abstracto**:
  - Masas de tierra $\rightarrow$ Vértices (A, B, C, D).
  - Puentes $\rightarrow$ Aristas ($m = 7$ conexiones).

Principio de conservación y grados nodales

- **Conservación de tránsito en nodos**:
  - Cada paso por un nodo intermedio consume 2 aristas (1 entrante y 1 saliente).
  - Por tanto, todo vértice intermedio en un circuito cerrado debe tener **grado par**.
- **Diagnóstico en Königsberg**:
  - $d(A) = 5$ (impar).
  - $d(B) = d(C) = d(D) = 3$ (impares).
  - Al tener 4 vértices impares, es **físicamente imposible** cerrar el recorrido.

Cadenas y ciclos eulerianos

Definición: Recorridos eulerianos

Dado un multigrafo finito conexo no dirigido $G = (V, E)$:

- **Cadena euleriana**: Recorre **todas las aristas** de E exactamente una vez.
- **Ciclo euleriano**: Cadena euleriana **cerrada** (inicio $=$ fin).
- **Grafo euleriano**: Admite al menos un ciclo euleriano.

- **Foco en aristas**:
  - Se pueden repetir vértices, pero **jamás se repite ninguna arista**.

Teorema de caracterización de Euler

! Condición necesaria y suficiente de Euler (1736, Hierholzer 1873)

Sea $G = (V, E)$ un multigrafo finito y conexo:

1. Admite **ciclo euleriano** $\iff$ **Todos los vértices tienen grado par**:

$$d(i) \equiv 0 \pmod 2, \quad \forall i \in V$$

2. Admite **cadena euleriana abierta** $\iff$ Hay **exactamente dos vértices impares** (extremos inicial y final de la cadena).

- **Complejidad lineal**: Test de paridad en tiempo $\mathcal{O}(|V| + |E|)$ (Clase $\mathcal{P}$).

Clasificación según la paridad de grados

- **Criterio de existencia en grafos conexos**:

Vértices impares ($\lvert V_{\text{impar}} \rvert$)	Tipo de recorrido euleriano	Propiedades
0	**Ciclo euleriano**	Inicio y fin en cualquier vértice.
2	**Cadena abierta**	Inicia en un impar y termina en el otro.
≥ 4	**No euleriano**	Requiere duplicar aristas (CPP).
Impar $(1, 3, ...)$	**Imposible**	Prohibido por el *Handshaking Lemma*.

Algoritmo constructivo: Punteros sucesores

- **Estructura de punteros** $= (\sigma(1), \ldots, \sigma(m), \sigma(m+1))$:
  - $\sigma(e)$: Identificador de la arista sucesora de e en la cadena.
  - $\sigma(m+1)$: Identificador de la **primera arista** del recorrido.
  - $\sigma(e) = -1$: Marca el final del recorrido.
- **Ventaja algorítmica**:
  - Permite intercalar ciclos secundarios en tiempo $\mathcal{O}(1)$ reasignando punteros.
  - Construcción de la cadena euleriana en tiempo lineal $\mathcal{O}(|E|)$.

Algoritmo constructivo: Variables de control

- **Estructuras auxiliares para un grafo con $m = |E|$ aristas**:
  - $w(i)$: Lista ordenada de aristas incidentes en el vértice i.
  - $\delta_i(e) = j$: Extremo opuesto al vértice i por la arista e.
  - $\alpha(i)$: Contador de aristas incidentes en i **sin explorar** ($\alpha(i) = d(i)$ al inicio).
  - v: Longitud acumulada del recorrido (aristas añadidas).
  - $\phi(i)$: Arista de primer acceso al vértice i ($\phi(\text{inicio}) = m + 1$).
  - e_1, e_2: Punteros auxiliares que delimitan el punto de inserción.

Algoritmo constructivo: Pasos 1 y 2

- **Paso 1 (Inicialización)**:
  - Si hay 2 impares: inicio $i = a$, fin $t = b$. Si todos son pares: $a = b$ $(i = a, t = a)$.
  - $\sigma(e) = 0$, $\alpha(i) = d(i)$, $\phi(j) = 0$, $\phi(a) = m + 1$, $v = 0$, $e_1 = m + 1, e_2 = -1$.
- **Paso 2 (Extensión secuencial)**:
  - Si $\alpha(i) = 0 \implies$ ir al **Paso 4**.
  - Si no, tomar $e = w_{\alpha(i)}(i)$ y decrementar $\alpha(i) \leftarrow \alpha(i) - 1$.
  - Si e no está explorada:

    $$j = \delta_i(e), \quad \phi(j) = e, \quad \sigma(e_1) = e, \quad v \leftarrow v+1, \quad \alpha(j) \leftarrow \alpha(j)-1,$$

  - Si $i = t \implies$ ir al **Paso 3**. Si no, $e_1 \leftarrow e$ y repetir Paso 2.

Algoritmo constructivo: Pasos 3 y 4

- **Paso 3 (Cierre de tramo y parada)**:
  - Enlazar: $\sigma(e) = e_2$.
  - Si $v = m \implies$ **FIN**: contiene la cadena euleriana completa.
  - Si $v < m \implies$ quedan aristas pendientes: avanzar al **Paso 4**.
- **Paso 4 (Búsqueda y empalme de ciclos)**:
  - Buscar nodo $k \in V$ en la cadena actual con $\alpha(k) \neq 0$ y $\phi(k) \neq 0$.
  - Configurar punteros para intercalar un ciclo cerrado en k:

$$i \leftarrow k, \quad t \leftarrow k, \quad e_1 \leftarrow \phi(k), \quad e_2 \leftarrow \sigma(e_1)$$

  - Volver al **Paso 2**.

Ejemplo: Grafo de 4 nodos y paridad

- **Aristas e incidencias**:
  - Arista 1: $\{a, b\} \implies \delta_a(1) = b, \delta_b(1) = a.$
  - Arista 2: $\{b, c\} \implies \delta_b(2) = c, \delta_c(2) = b.$
  - Arista 3: $\{c, d\} \implies \delta_c(3) = d, \delta_d(3) = c.$
  - Arista 4: $\{b, d\} \implies \delta_b(4) = d, \delta_d(4) = b.$
- **Grados nodales**:
  - $d(a) = 1$ (impar).
  - $d(b) = 3$ (impar).
  - $d(c) = 2,\ d(d) = 2$ (pares).
- **Diagnóstico de Euler**:
  - Exactamente dos vértices impares (a y b) $\implies$ Cadena abierta de a a b.

Ejemplo: Representación gráfica y vector

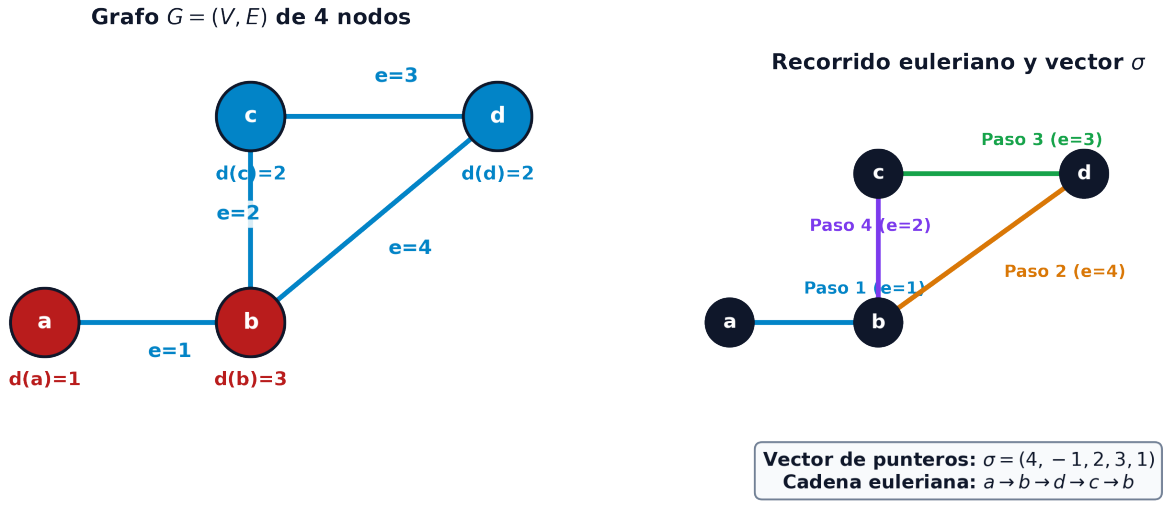

- **Panel izquierdo**: Topología del grafo de 4 nodos y 4 aristas.
- **Panel derecho**: Evolución detallada del vector de punteros sucesores tras cada paso.

Ejemplo: Inicialización y primera extensión (Pasos 1 y 2)

- **1. Inicialización (Paso 1)**:
  - Vértice inicial: $i = a$, vértice final: $t = b$.
  - Arista ficticia de cabecera: $m + 1 = 5$. Punteros iniciales: $e_1 = 5, e_2 = -1, v = 0$.
  - Contadores: $\alpha(a) = 1, \alpha(b) = 3, \alpha(c) = 2, \alpha(d) = 2$.
  - Punteros de llegada: $\phi(a) = 5, \phi(b) = 0, \phi(c) = 0, \phi(d) = 0$.
- **2. Primera extensión (Paso 2)**:
  - En $i = a$, $\alpha(a) = 1$. Arista disponible $e = 1$. Se actualiza $\alpha(a) = 0$.
  - Como $e = 1 \neq e_1 = 5$, se conecta la arista:

    $$j = \delta_a(1) = b, \quad \phi(b) = 1, \quad \sigma(5) = 1, \quad v = 1, \quad \alpha(b) = 2, \quad i = b$$

  - Como el nodo actual b coincide con el destino $t = b$, se deriva al **Paso 3**.

Ejemplo: Cierre inicial y bifurcación (Pasos 3 y 4)

- **3. Cierre de tramo inicial (Paso 3)**:
  - Se fija $\sigma(1) = e_2 = -1$.
  - Como la longitud acumulada $v = 1 < 4$, la cadena no está completa $\implies$ Se pasa al **Paso 4**.
- **4. Búsqueda de vértice de bifurcación (Paso 4)**:
  - Se evalúa el nodo $k = b$: cumple $\alpha(b) = 2 \neq 0$ y $\phi(b) = 1 \neq 0$.
  - Se reconfiguran los punteros para intercalar un ciclo cerrado en b:

$$i = b, \quad t = b, \quad e_1 = \phi(b) = 1, \quad e_2 = \sigma(1) = -1$$

  - Se regresa al **Paso 2**.

Ejemplo: Construcción del ciclo secundario (Pasos 2 y 3)

- **5. Construcción del ciclo secundario (Pasos 2 y 3)**:
  - *Iteración desde* b: $\alpha(b) = 2$, arista $e = w_2(b) = 4 \implies \alpha(b) = 1$:

    $$j = \delta_b(4) = d, \quad \phi(d) = 4, \quad \sigma(1) = 4, \quad v = 2, \quad \alpha(d) = 1, \quad i = d$$

  - *Iteración desde* d: $\alpha(d) = 1$, arista $e = w_1(d) = 3 \implies \alpha(d) = 0$:

    $$j = \delta_d(3) = c, \quad \phi(c) = 3, \quad \sigma(4) = 3, \quad v = 3, \quad \alpha(c) = 1, \quad i = c$$

  - *Iteración desde* c: $\alpha(c) = 1$, arista $e = w_1(c) = 2 \implies \alpha(c) = 0$:

    $$j = \delta_c(2) = b, \quad \phi(b) = 2, \quad \sigma(3) = 2, \quad v = 4, \quad \alpha(b) = 0, \quad i = b$$

  - Al alcanzar $i = t = b$, se pasa al **Paso 3**: $\sigma(2) = e_2 = -1$.
  - Como $v = 4 = m$, el algoritmo **termina con éxito**.

Ejemplo: Vector final y reconstrucción

- **Vector final de punteros** :

$$= (4, -1, 2, 3, 1)$$

- **Decodificación secuencial**:
  - Inicio:
    $\sigma(5) = 1 \implies$ Arista 1.
  - Sucesor de 1:
    $\sigma(1) = 4 \implies$ Arista 4.
  - Sucesor de 4:
    $\sigma(4) = 3 \implies$ Arista 3.
  - Sucesor de 3:
    $\sigma(3) = 2 \implies$ Arista 2.
  - Sucesor de 2:
    $\sigma(2) = -1 \implies$ FIN.

- **Secuencia de aristas**:

$$(1, 4, 3, 2)$$

- **Cadena de vértices**:

$$a \xrightarrow{e=1} b \xrightarrow{e=4} d \xrightarrow{e=3} c \xrightarrow{e=2} b$$

- **Verificación**:
  - Recorre las 4 aristas sin repetir.
  - Inicia en a y termina en b.

Resumen de grafos eulerianos

- **Caracterización exacta**:
  - La paridad de grados determina plenamente la existencia de circuitos eulerianos.
- **Complejidad polinomial**:
  - Verificación en $\mathcal{O}(|V| + |E|)$ y trazado en $\mathcal{O}(|E|)$ con punteros .
- **Limitación en redes reales**:
  - Las redes viales reales suelen tener nodos impares $\implies$ Requieren duplicar calles (**Problema del Cartero Chino**).

El Problema del Cartero Chino (CPP)

Motivación práctica e industrial del CPP

- **Aplicaciones urbanas e industriales**:
  - Reparto postal domiciliario.
  - Recogida de residuos urbanos.
  - Mantenimiento y quitanieves en vialidad invernal.
  - Inspección de redes eléctricas y canalizaciones.
- **El reto de optimización**:
  - En redes no eulerianas, es obligatorio transitar más de una vez por ciertas vías.
  - **Objetivo**: Minimizar la distancia o coste total acumulado de las aristas duplicadas.
- **Origen**: Formulado por **Mei-Ko Kwan** (1960).

Formulación del Problema del Cartero Chino

Definición: Problema del Cartero Chino (CPP)

Dada una red valorada no dirigida $G = (V, E, p)$ con pesos no negativos $p(e) \geq 0$:
El **CPP** consiste en hallar un circuito cerrado C que recorra todas las aristas de E al menos una vez al menor coste total:

$$\min_{C} \sum_{e \in C} p(e) \quad \text{sujeto a} \quad E \subseteq C$$

- **Red euleriana**: Longitud óptima $= \sum_{e \in E} p(e)$.
- **Red no euleriana**: Longitud óptima $=$ $\sum_{e \in E} p(e) + \text{Coste}(E' \text{ duplicados})$.

Eulerización conceptual tentativa (9 nodos)

- **Red valorada con 4 nodos impares**:
  - Vértices impares: $V' = \{a, b, c, d\}$ $(d = 3)$.
  - Nodo central e: $d(e) = 4$ (par).
  - Esquinas i, f, h, g: $d = 2$ (pares).
- **Duplicación tentativa hacia el centro** e:
  - Duplicar $\{a, e\}, \{b, e\}, \{e, c\}, \{e, d\}$.
  - Todos los grados en G' pasan a ser pares.
  - Coste añadido: $3 + 3 + 3 + 6 = \mathbf{15}$.

Eulerización tentativa $G' = (V, E \cup E')$ (todos los nodos son pares)

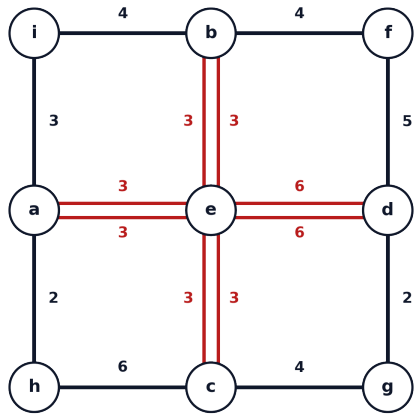

Proposición: Paridad del número de vértices de grado impar

Paridad del número de vértices de grado impar

En cualquier multigrafo finito $G = (V, E)$, el número de vértices con grado impar es estrictamente un **número par** ($|V'| = 2k$).

- **Consecuencia para la eulerización**:
  - Un grafo jamás puede tener una cantidad impar de vértices impares $(1, 3, 5, ...)$.
  - En redes no eulerianas, siempre existirá una cantidad par de nodos impares que conectar de dos en dos.

Proposición: Estructura de caminos de las aristas duplicadas

Estructura de caminos de las aristas duplicadas

Sea $G = (V, E)$ un grafo no euleriano y sea E' un conjunto minimal de aristas duplicadas que convierte a $G' = (V, E \cup E')$ en euleriano. Entonces, para todo $i_1 \in V'$, el conjunto E' contiene una cadena que une i_1 con otro vértice $i_2 \in V'$.

- **Interpretación combinatoria**:
  - Las aristas duplicadas en E' forman caminos disyuntos cuyos extremos son siempre vértices impares.
  - **La eulerización óptima equivale a un emparejamiento perfecto de peso mínimo entre los nodos impares**.

Definición: Emparejamientos y emparejamiento perfecto

- **Emparejamiento (*matching*)**:
  - Subconjunto de aristas $M \subseteq E$ sin vértices comunes:

    $$e_1 \cap e_2 = \emptyset, \quad \forall e_1, e_2 \in M$$

- **Vértice saturado**:
  - Nodo $v \in V$ que es extremo de alguna arista de M.

- **Emparejamiento perfecto**:
  - Satura a **todos los vértices de** V ($|V|$ debe ser par).
- **Matching de peso mínimo**:

  $$\min_{M \subseteq E} \sum_{e \in M} p(e) \quad \text{s.a. } M \text{ es perfec}$$

Esquema: Procedimiento general de resolución del CPP

- **1. Identificación de impares**:
  - Hallar $V' = \{v \in V \mid d(v) \text{ impar}\}$.
  - Si $V' = \emptyset \implies$ es euleriano.
- **2. Distancias mínimas**:
  - Calcular $d_G(u, v)$ en V' (Dijkstra).
- **3. Grafo auxiliar completo**:
  - $G'' = (V', E'')$ con $p''(u, v) = d_G(u, v)$.
- **4. Matching de peso mínimo**:
  - Determinar M^* en G'' (Edmonds o combinatoria).
- **5. Multigrafo y circuito final**:
  - Duplicar caminos mínimos de M^*.
  - Trazar la ruta euleriana con el algoritmo de punteros .

Ejemplo CPP (9 nodos): Grafo original e impares (Paso 1)

- **Red de 9 nodos y 12 aristas**:
  - Suma de aristas base:

$$\sum_{e \in E} p(e) = 38$$

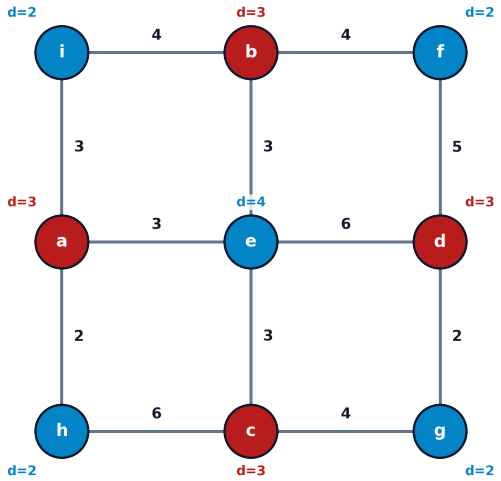

- **1. Identificación de impares (Paso 1)**:
  - $d(a) = d(b) = d(c) = d(d) = 3$
  - $\implies V' = \{a, b, c, d\}$.
  - $d(e) = 4,\ d(i) = d(f) = d(h) = d(g) = 2$.

Ejemplo CPP (9 nodos): Caminos mínimos en V' (Paso 2)

- **2. Distancias geodésicas en V' (Paso 2)**:
  - Desde a: $d(a,b) = \mathbf{6},\ d(a,c) = \mathbf{6},\ d(a,d) = \mathbf{9}$.
  - Desde b: $d(b,c) = \mathbf{6},\ d(b,d) = \mathbf{9}$.
  - Desde c: $d(c,d) = \mathbf{6}$.
- **Rutas mínimas obtenidas (Dijkstra)**:
  - Tránsitos por el centro e salvo:
    - Camino $b - f - d$ (coste $4 + 5 = 9$).
    - Camino $c - g - d$ (coste $4 + 2 = 6$).
- **Matriz simétrica $D_{V'}$**:

$$D_{V'} = \begin{pmatrix} - & 6 & 6 & 9 \\ 6 & - & 6 & 9 \\ 6 & 6 & - & 6 \\ 9 & 9 & 6 & - \end{pmatrix}$$

Ejemplo CPP (9 nodos): Grafo auxiliar y matching (Pasos 3 y 4)

Grafo auxiliar G'' y Solución M_1 (en verde)

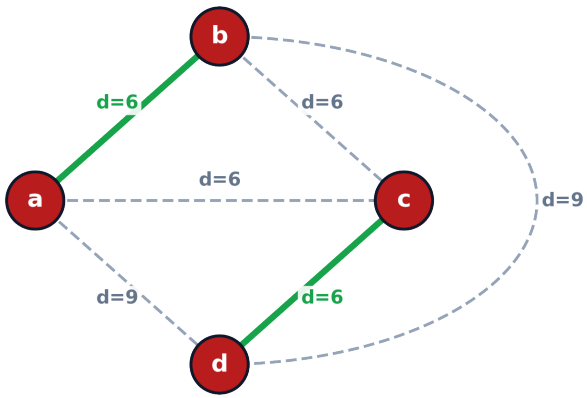

Comparación de emparejamientos perfectos en G''

M1: { {a, b}, {c, d} } [ÓPTIMO]
d(a,b) + d(c,d) = 6 + 6 = 12

M2: { {a, c}, {b, d} }
d(a,c) + d(b,d) = 6 + 9 = 15

M3: { {a, d}, {b, c} }
d(a,d) + d(b,c) = 9 + 6 = 15

- **3 y 4. Grafo auxiliar G'' y evaluación de matchings (Pasos 3 y 4)**:
  - $M_1 = \{\{a, b\}, \{c, d\}\}$: $d(a, b) + d(c, d) = 6 + 6 = \mathbf{12}$ **[ÓPTIMO]**.
  - $M_2 = \{\{a, c\}, \{b, d\}\}$: $d(a, c) + d(b, d) = 6 + 9 = 15$.
  - $M_3 = \{\{a, d\}, \{b, c\}\}$: $d(a, d) + d(b, c) = 9 + 6 = 15$.

Ejemplo CPP (9 nodos): Eulerización y solución óptima (Paso 5)

- **5. Eulerización y circuito óptimo (Paso 5)**:
  - Camino $a - e - b$ (duplica $\{a, e\}$ y $\{e, b\}$).
  - Camino $c - g - d$ (duplica $\{c, g\}$ y $\{g, d\}$).
- **Longitud total mínima del circuito**:

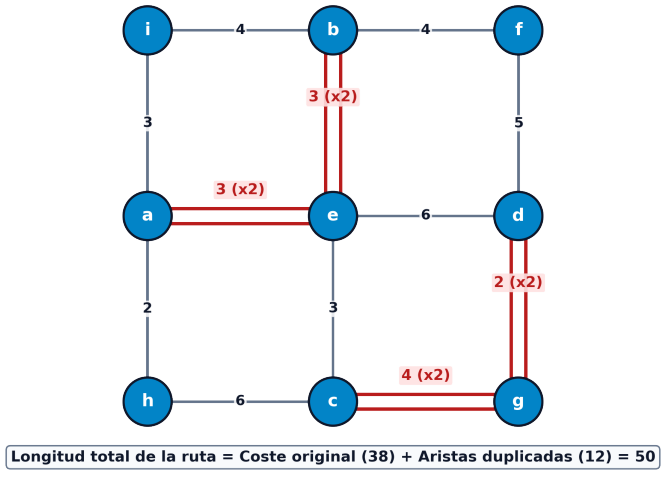

$$L_{\text{ópt}} = 38 \text{ (base)} + 12 \text{ (duplicados)} = \mathbf{50}$$

Ejemplo Examen: Enunciado y delimitación de parcelas

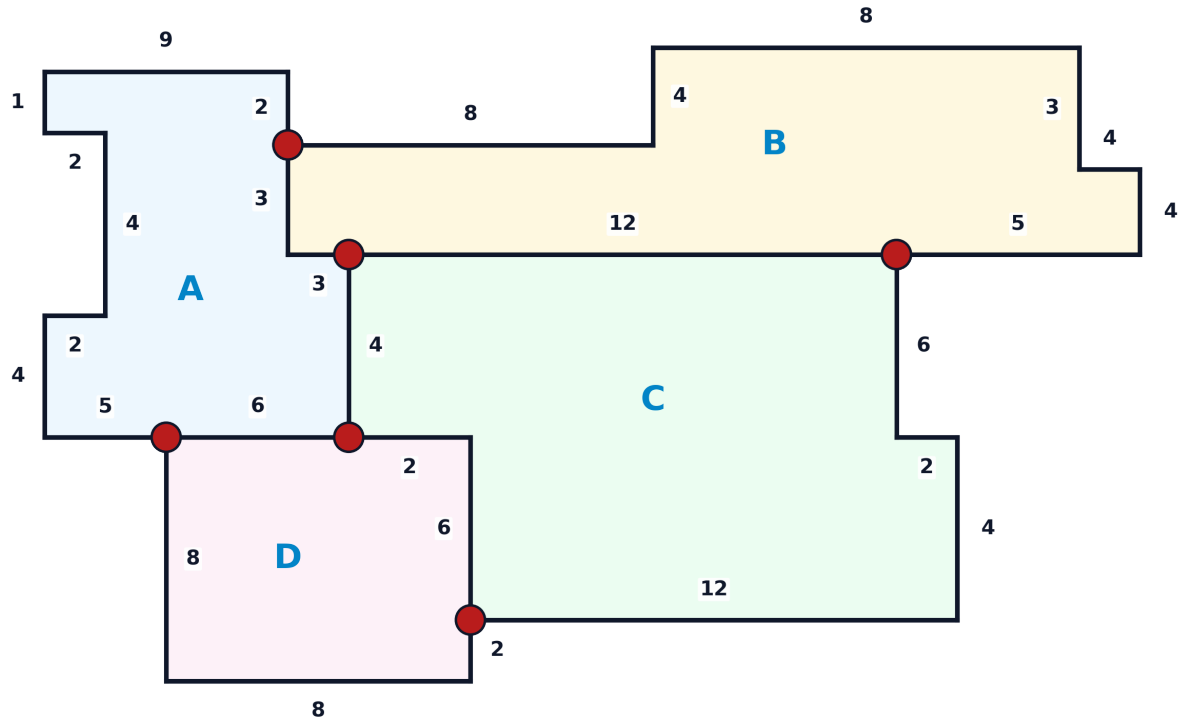

- **Planteamiento de la obra**:
  - Se desea cercar un terreno dividiéndolo en 4 parcelas (A, B, C y D).
  - El cerramiento se realiza mediante una cerca prefabricada continua que **no se puede partir** y debe terminar exactamente donde empieza.

Ejemplo Examen: Pregunta 1 - Modelado en teoría de grafos

- **1. ¿Qué problema de grafos se está planteando? (0.5 puntos)**:
  - Se trata formalmente del **Problema del Cartero Chino (CPP)** (o problema de inspección de rutas).
  - El objetivo es encontrar el circuito cerrado de longitud mínima que recorra todas las aristas de un grafo al menos una vez y regrese al punto de partida.
- **Justificación topológica**:
  - Al exigir una cerca continua y cerrada, es necesario trazar un **circuito euleriano**.
  - En el mapa existen intersecciones donde confluyen tres lindes (**vértices de grado impar** $d = 3$), por lo que el grafo original **no es euleriano**.
  - **Objetivo**: Determinar qué tramos deben duplicarse (tender la cerca dos veces por el mismo borde) garantizando que la longitud añadida sea mínima.

Ejemplo Examen: Pregunta 2 - Procedimiento de solución

- **Paso 1 (Identificación de impares)**:
  - Modelar $G = (V, E, p)$ y hallar: $V' = \{v \in V \mid d(v) \text{ impar}\}$.
- **Paso 2 (Distancias geodésicas)**:
  - Calcular $d_G(u, v)$ en V' con Dijkstra.
- **Paso 3 (Grafo auxiliar G'')**:
  - Construir $G'' = (V', E'')$ con pesos $p''(u, v) = d_G(u, v)$.
- **Paso 4 (Matching de peso mínimo)**:
  - Determinar el matching perfecto M^* en G''.
- **Paso 5 (Eulerización y longitud)**:
  - Duplicar caminos mínimos de M^*.
  - Longitud: $L_{\text{total}} = \sum_{e \in E} p(e) + \text{Coste}(M^*)$.

Ejemplo Examen: Pregunta 3 - Desglose de longitud base (L_{base})

- **Lindes internas (fronteras)**:
  - A-B: 3 m.
  - A-C: 4 m.
  - B-C: 12 m.
  - A-D: 6 m.
  - C-D: $2 + 6 = 8$ m.
  - **Suma interna** $= \mathbf{33}$ m.

- **Perímetro exterior (bordes)**:
  - Parcela A: $2+9+1+2+4+2+4+5 = 29$ m.
  - Parcela B: $8+4+8+3+4+4+5 = 36$ m.
  - Parcela C: $6 + 2 + 4 + 12 = 24$ m.
  - Parcela D: $8 + 8 + 2 = 18$ m.
  - **Suma externa** $= \mathbf{107}$ m.

- **Longitud base total de la red**:

$$L_{\text{base}} = 33 \text{ (internas)} + 107 \text{ (externas)} = \mathbf{140} \text{ m}$$

Ejemplo Examen: Pregunta 3 - Vértices impares V' (Paso 1)

- **Análisis topológico de los grados** $d(v)$:
  - **Esquinas exteriores del perímetro**:
    - En cada quiebro del borde exterior concurren exactamente 2 aristas $\implies$ Grado $d = 2$ (pares).
  - **Puntos de confluencia triple (puntos rojos en el plano)**:
    - En las 6 intersecciones donde confluyen tres lindes (fronteras entre parcelas y bordes exteriores), el grado es estrictamente $d = 3$ (impares).
- **Conjunto de vértices de grado impar**:

$$V' = \{v \in V \mid d(v) \equiv 1 \pmod 2\} \implies |V'| = \mathbf{6} \text{ vértices impares}$$

Ejemplo Examen: Pregunta 3 - Caminos mínimos en V' (Paso 2)

- **Paso 2 (Cálculo de distancias mínimas con Dijkstra)**:
- **Pareja 1 (Punto superior A-B a central A-B-C)**:
  - Camino interior directo con distancia $d = \mathbf{3}$ m.
- **Pareja 2 (Punto inferior A-D a central A-C-D)**:
  - Camino interior directo con distancia $d = \mathbf{6}$ m.
- **Pareja 3 (Extremos derechos: borde de B-C a borde de C-D)**:
  - Distancia mínima $d = \mathbf{24}$ m, alcanzable por dos rutas alternativas de igual coste:
    - *Por el contorno exterior de C*: $6 + 2 + 4 + 12 = \mathbf{24}$ m.
    - *Por el interior de la red*: $(B\text{-}C) + (A\text{-}C) + (C\text{-}D) = 12 + 4 + 8 = \mathbf{24}$ m.

Ejemplo Examen: Pregunta 3 - Matching y longitud total (Pasos 3 a 5)

- **Pasos 3 y 4 (Grafo auxiliar G'' y matching óptimo M^*)**:
  - Se construye el grafo auxiliar completo sobre los 6 nodos impares.
  - El emparejamiento perfecto de peso mínimo selecciona las tres parejas mínimas:

$$\text{Coste}(M^*) = 3 + 6 + 24 = \mathbf{33}\ \text{m}$$

- **Paso 5 (Multigrafo euleriano y longitud total de la valla)**:
  - Se duplican en el mapa los tres caminos mínimos identificados.
  - La longitud mínima de la cerca prefabricada continua necesaria es:

$$L_{\text{total}} = L_{\text{base}} + \text{Coste}(M^*) = 140\ \text{(base)} + 33\ \text{(duplicados)} = \mathbf{173}\ \text{m}$$

Variantes del Problema del Cartero Chino

- **Cartero Dirigido (Directed CPP)**:
  - Calles de sentido único ($d^-(i) = d^+(i)$).
  - La eulerización se resuelve mediante un **modelo de flujo a coste mínimo y transbordo** en tiempo polinomial.
- **Windy Postman Problem**:
  - Costes asimétricos por pendientes o viento ($c(i,j) \neq c(j,i)$). Es $\mathcal{NP}$-duro.
- **Cartero Rural (RPP)**:
  - Solo se recorre un subconjunto obligatorio $E_R \subseteq E$. Es $\mathcal{NP}$-completo.

Ciclos hamiltonianos y condiciones de hamiltonianidad

Origen histórico: El Juego Icosiano (1857)

- **Patente de Sir William Rowan Hamilton**:
  - Dodecaedro regular de 20 vértices (*Icosian Game*).
- **El reto planteado**:
  - Visitar las **20 ciudades exactamente una vez** regresando al origen.
- **Euler vs. Hamilton**:
  - Euler: Recorrer todas las **aristas**.
  - Hamilton: Visitar todos los **vértices**.

- **Complejidad computacional**:
  - Euleriano $\Longrightarrow$ Clase $\mathcal{P}$ ($\mathcal{O}(|V| + |E|)$).
  - Hamiltoniano $\Longrightarrow$ $\mathcal{NP}$-**completo** (Karp 1972).
- **Estrategia**:
  - No hay condiciones necesarias y suficientes simultáneas en $\mathcal{P}$.
  - Se estudian condiciones necesarias (conectividad) y suficientes (grados).

Ciclos y caminos hamiltonianos

Definición: Recorridos hamiltonianos

Dado un grafo $G = (V, E)$ con $n = |V|$ vértices:

- **Ciclo hamiltoniano**: Ciclo simple que visita **todos los vértices de** V exactamente una vez.
- **Camino hamiltoniano**: Camino simple que visita todos los vértices sin cerrar el ciclo.
- **Grafo hamiltoniano**: Grafo que admite al menos un ciclo hamiltoniano.

- **Propiedad básica**: Todo ciclo hamiltoniano en n vértices contiene exactamente n **aristas**.

Definición: Conjuntos de corte y k-conexidad

Definición: Conjuntos de corte y k-conexidad

Dado un grafo conexo $G = (V, E)$:

- **Conjunto de corte de vértices**: Subconjunto $A \subset V$ tal que el subgrafo inducido $V \setminus A$ es disconexo.
- **Grafo k-conexo**: $|V| \geq k + 1$ y no contiene ningún conjunto de corte de cardinal menor que k (se requiere eliminar al menos k vértices para desconectarlo).

- **Implicación en grados**: Todo grafo k-conexo satisface $d_G(i) \geq k, \ \forall i \in V$.

Proposición: Condición necesaria de 2-conexidad

Condición necesaria de 2-conexidad

Si un grafo $G = (V, E)$ es hamiltoniano, entonces G es obligatoriamente **2-conexo** (no posee vértices de corte o puntos de articulación).

- **Interpretación geométrica**:
  - Si existiera un vértice de corte v, el ciclo tendría que pasar al menos dos veces por v para transitar entre las componentes desconectadas (imposible en ciclo simple).
  - **Grado mínimo necesario**: $d(v) \geq 2, \ \forall v \in V$. Si existe algún $d(v) \leq 1 \implies$ No es hamiltoniano.

Contraejemplo: Grafo 2-conexo no hamiltoniano

- **La 2-conexidad NO es suficiente**:
  - Grafo de 5 nodos con 3 caminos paralelos entre a y e.
  - Cumple $d(i) \geq 2$ y es 2-conexo.
- **Por qué no es hamiltoniano**:
  - Para visitar b, c, d (de grado 2), el ciclo debería pasar 3 veces por a y por e.

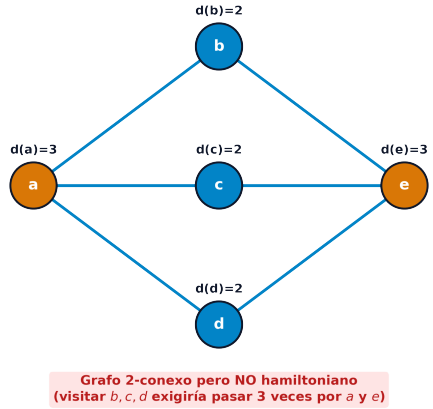

Hamiltonianidad del grafo completo K_n

Proposición: Ciclos en grafos completos

Todo grafo simple completo K_n con $n \geq 3$ es hamiltoniano y contiene exactamente:

$$\frac{(n-1)!}{2}$$

ciclos hamiltonianos distintos no orientados.

- **Crecimiento factorial**:
  - $n = 5 \implies 12$ ciclos.
  - $n = 10 \implies 181.440$ ciclos.
  - $n = 20 \implies 6 \times 10^{16}$ ciclos.

Proposición fundamental de adyacencia

! Proposición de adyacencia de Bondy y Chvátal (1976)

Sea $G = (V, E)$ un grafo con $n \geq 3$ vértices y sean $s, t \in V$ dos vértices **no adyacentes** con:

$$d_G(s) + d_G(t) \geq n$$

Se define $G + \{s, t\} = (V, E \cup \{\{s, t\}\})$. Entonces:

$$G \text{ es hamiltoniano} \iff G + \{s, t\} \text{ es hamiltoniano}$$

- **Conservación**: Añadir aristas con suma de grados $\geq n$ no altera la hamiltonianidad.

Interpretación geométrica de la adyacencia

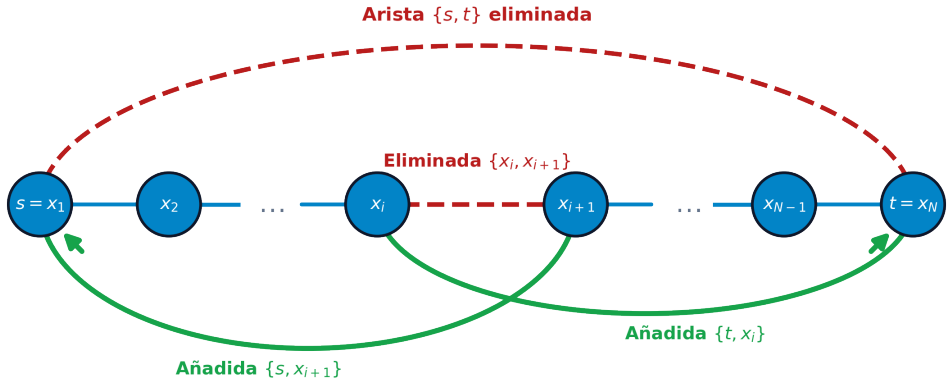

Ciclo Hamiltoniano en G: $s \to x_2 \ldots \to x_i \to t \to x_{N-1} \ldots \to x_{i+1} \to s$

- **Mecanismo de reconexión**:
  - Si en $G + \{s,t\}$ hay un ciclo que usa $\{s,t\}$, la condición $d(s) + d(t) \geq n$ asegura por palomar que existen $\{s, x_{i+1}\}$ y $\{t, x_i\}$.
  - Sustituyendo aristas se reconstruye el ciclo en G sin usar $\{s,t\}$.

Definición: Operador de Clausura

Definición: Clausura de un grafo (Bondy y Chvátal 1976)

Dado un grafo simple $G = (V, E)$ con n vértices, la **clausura** $[G]$ es el grafo obtenido al añadir recursivamente aristas entre parejas no adyacentes u, v que cumplen:

$$d(u) + d(v) \geq n$$

hasta que no sea posible añadir ninguna arista más. La clausura $[G]$ es **única e independiente del orden**.

Teorema de Bondy y Chvátal (1976)

! Teorema de Bondy y Chvátal (1976)

Un grafo simple G es **hamiltoniano si y solo si su clausura** $[G]$ **es hamiltoniana**. En particular, si $[G] = K_n$, entonces G es **hamiltoniano**.

- **Potencia algorítmica**:
  - Permite evaluar la hamiltonianidad añadiendo aristas en tiempo polinomial $\mathcal{O}(|V|^3)$.

Advertencia: El criterio $[G] = K_n$ es suficiente

- **Condición suficiente pero NO necesaria**:
  - Si $[G] = K_n \implies G$ es hamiltoniano.
  - Si $[G] \neq K_n \implies$ El test es **no concluyente** (puede o no ser hamiltoniano).
- **Contraejemplo del ciclo C_5 ($n = 5$)**:
  - C_5 es hamiltoniano y $d(v) = 2, \ \forall v$.
  - Pares no adyacentes: $2 + 2 = 4 < 5$.
  - Ninguna arista añadida: $[C_5] = C_5 \neq K_5$.

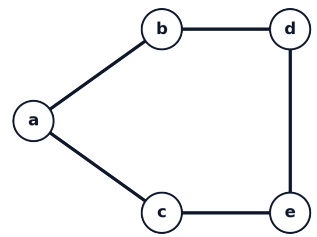

Este grafo es hamiltoniano, pero su clausura no es un grafo completo $[G] = C_5 \neq K_5$

Teoremas clásicos de Dirac y Ore

- **Teorema de Dirac (1952)**:
  - Grado mínimo uniforme:

$$d(v) \geq \frac{n}{2}, \quad \forall v \in V$$

  - Condición suficiente estricta.

- **Teorema de Ore (1960)**:
  - Pares no adyacentes:

$$d(u)+d(v) \geq n, \quad \forall \{u, v\} \notin I$$

  - Generaliza a Dirac.

- **Jerarquía de implicaciones**:

Dirac $\implies$ Ore $\implies$ Bondy-Chvátal $([G] = K_n) \implies G$ hamiltonia

Comparativa de criterios suficientes

- **Evaluación de condiciones suficientes de hamiltonianidad**:

Criterio	Condición evaluada	Exigencia topológica	Complejidad
Dirac (1952)	$\min_v d(v) \geq n/2$	Muy alta (grafo denso uniforme)	$\mathcal{O}(\lvert V\rvert)$
Ore (1960)	$d(u) + d(v) \geq n$	Alta (pares no adyacentes)	$\mathcal{O}(\lvert V\rvert^2)$
Bondy-Chvátal (1976)	$[G] = K_n$	**Máxima potencia deductiva**	$\mathcal{O}(\lvert V\rvert^3)$

- Bondy-Chvátal detecta ciclos en grafos donde Dirac y Ore fallan.

Ejemplo: Clausura de Bondy-Chvátal (Grafos de 4 y 5 nodos)

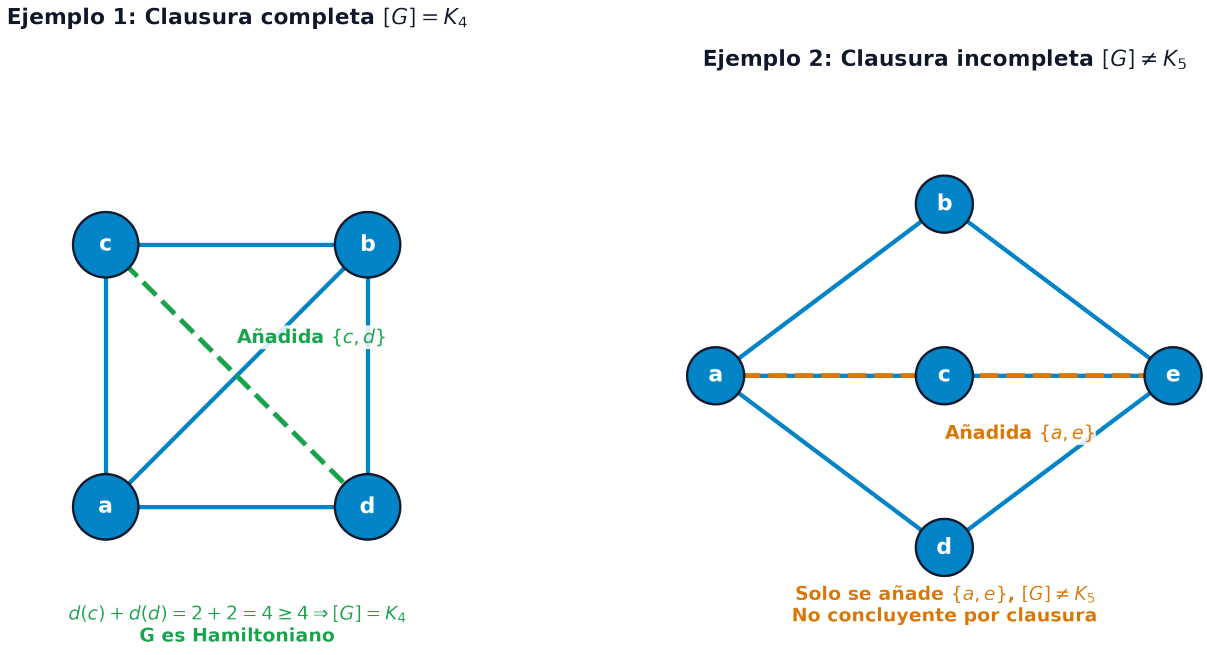

- **Panel izquierdo ($n = 4$)**: Grafo inicial con arista $\{c, d\}$ añadida por clausura (en naranja).
- **Panel derecho ($n = 5$)**: Grafo inicial con arista $\{a, e\}$ añadida; no permite añadir más aristas.

Ejemplo: Evaluación paso a paso de la clausura

- **1. Grafo de 4 nodos ($n = 4$, izquierda)**:
  - Grados iniciales: $d(a) = 3, d(b) = 3, d(c) = 2, d(d) = 2$.
  - Única pareja no adyacente $\{c, d\}$: $d(c) + d(d) = 2 + 2 = 4 \geq n = 4$.
  - Se añade $\{c, d\} \implies [G] = K_4$. **Conclusión: Hamiltoniano**.
- **2. Grafo de 5 nodos ($n = 5$, derecha)**:
  - Grados iniciales: $d(a) = 3, d(e) = 3, d(b) = d(c) = d(d) = 2$.
  - Pareja $\{a, e\}$: $d(a) + d(e) = 3 + 3 = 6 \geq n = 5 \implies$ Se añade $\{a, e\}$.
  - Grados actualizados: $d(a) = 4, d(e) = 4$; nodos b, c, d mantienen $d = 2$.
  - Resto de parejas no adyacentes: $d(u) + d(v) = 2 + 2 = 4 < 5$ (no se pueden añadir más).
  - $[G] \neq K_5 \implies$ **Test no concluyente**.

Resumen de condiciones de hamiltonianidad

- **Condiciones necesarias**:
  - Conexo y 2-conexo (sin vértices de corte o articulación).
  - Grado mínimo: $d(v) \geq 2,\ \forall v \in V$.
- **Condiciones suficientes**:
  - Dirac ($d \geq n/2$) $\implies$ Ore ($d_u + d_v \geq n$) $\implies$ Bondy-Chvátal ($[G] = K_n$).
- **Si** $[G] \neq K_n$:
  - Test no concluyente (el grafo puede o no ser hamiltoniano).
  - Resolución mediante modelos de Programación Lineal Entera (DFJ o MTZ).

El Problema del Viajante de Comercio (TSP)

El Problema del Viajante de Comercio (TSP)

- **Definición**:
  - Visitar n ciudades exactamente una vez y regresar al origen al **mínimo coste total**.
- **Complejidad y escala**:
  - Problema $\mathcal{NP}$-duro.
  - Espacio de búsqueda factorial: $(n-1)!/2$.

- **Formulación formal**:

$$\min_{\pi} \left(\sum_{k=1}^{n-1} d_{\pi(k),\pi(k+1)} + d_{\pi(n),\pi(1} \right.$$

donde π es una permutación de los vértices $\{1, \ldots, n\}$.

Aplicaciones industriales del TSP

- **Taladrado de circuitos impresos (PCB)**:
  - Optimización de trayectoria láser para miles de orificios.
- **Secuenciación de tareas en máquinas**:
  - Programación con tiempos de cambio de matriz dependientes del orden.
- **Orientación de telescopios espaciales**:
  - Maniobras de apuntado minimizando consumo de combustible.
- **Genómica computacional**:
  - Reconstrucción y alineamiento de fragmentos de ADN.

Modelos de Programación Lineal Entera para el TSP

- **Tres formulaciones matemáticas fundamentales**:

1. **Modelo 1 (Variables de posición de tramo x_{ijk})**:
   - Concibe el tour como una secuencia de n etapas temporales (n^3 variables).
2. **Modelo 2 (DFJ: Dantzig, Fulkerson y Johnson, 1954)**:
   - Variables de arco x_{ij} con restricciones exponenciales de subciclos (SEC).
   - Relajación lineal muy fuerte (*Branch-and-Cut*).
3. **Modelo 3 (MTZ: Miller, Tucker y Zemlin, 1960)**:
   - Formulación compacta con variables continuas de orden u_i ($\mathcal{O}(n^2)$ restricciones).

Modelo 1 del TSP: Variables de posición de tramo (x_{ijk})

- **Concepción del recorrido**:
  - El itinerario del agente se modela como una secuencia ordenada de n etapas o tramos sucesivos.
- **Variables de decisión tridimensionales**:

$$x_{ijk} = \begin{cases} 1 & \text{si el agente va directamente de } i \text{ a } j \text{ en la etapa } k \\ 0 & \text{en otro caso} \end{cases}$$

  para todo $i, j, k \in \{1, \dots, n\}$.
- **Dimensión**: Requiere n^3 variables binarias.

Modelo 1 del TSP: Función objetivo y salida única (1 y 2)

- **1. Minimización de la distancia total (Función objetivo)**:
  - Cada desplazamiento devenga un coste d_{ij} independientemente de la etapa k:

$$\min_x \sum_{i=1}^{n} \sum_{j=1}^{n} \sum_{k=1}^{n} d_{ij} x_{ijk}$$

- **2. Salida única de cada ciudad**:
  - El agente abandona cada ciudad i exactamente una vez a lo largo del viaje:

$$\sum_{j=1}^{n} \sum_{k=1}^{n} x_{ijk} = 1, \quad \forall i = 1, \ldots, n$$

Modelo 1 del TSP: Llegada y ocupación temporal (3 y 4)

- **3. Llegada única a cada ciudad**:
  - El agente accede a cada ciudad j exactamente una vez a lo largo del viaje:

$$\sum_{i=1}^{n}\sum_{k=1}^{n} x_{ijk} = 1, \quad \forall j = 1, \dots, n$$

- **4. Ocupación exclusiva de cada etapa temporal**:
  - En cada etapa $k \in \{1, \dots, n\}$ solo se realiza un único trayecto:

$$\sum_{i=1}^{n}\sum_{j=1}^{n} x_{ijk} = 1, \quad \forall k = 1, \dots, n$$

Modelo 1 del TSP: Continuidad espacial (5)

- **5. Continuidad espacial del recorrido entre etapas consecutivas**:
  - Si en la etapa k el agente llega a la ciudad j, en la etapa $k+1$ debe partir obligatoriamente desde esa misma ciudad j:

$$\sum_{i \neq j} x_{ijk} = \sum_{l \neq j} x_{j,l,k+1}, \quad \forall j = 1, \ldots, n, \quad \forall k = 1, \ldots, n$$

- **Cierre circular**: Para la última etapa $k = n$, la etapa subsiguiente $k+1$ se identifica circularmente con la etapa 1.

Modelo 1 del TSP: Formulación consolidada

$$
\begin{aligned}
\min_{x} \quad & \sum_{i=1}^{n}\sum_{j=1}^{n}\sum_{k=1}^{n} d_{ij}x_{ijk} \\
\text{s.a.} \quad & \sum_{j,k} x_{ijk} = 1, \ \forall i; \quad \sum_{i,k} x_{ijk} = 1, \ \forall j \\
& \sum_{i,j} x_{ijk} = 1, \ \forall k; \quad \sum_{i\neq j} x_{ijk} = \sum_{l\neq j} x_{j,l,k+1}, \ \forall j,k \\
& x_{ijk} \in \{0,1\}, \quad \forall i,j,k = 1,\dots,n
\end{aligned}
$$

- **Dimensión**: n^3 variables binarias y $3n + n^2$ restricciones.

Modelo 2 (DFJ): Variables de arco y asignación pura

- **Variables de decisión de arco**:

$$x_{ij} = \begin{cases} 1 & \text{si el arco dirigido } (i,j) \text{ forma parte de la ruta} \\ 0 & \text{en otro caso} \end{cases} \qquad \forall i \neq j$$

- **Restricciones de grado del problema de asignación**:
  - **Conservación de salida (Grado exterior 1)**:

$$\sum_{j=1, j\neq i}^{n} x_{ij} = 1, \quad \forall i = 1, \dots, n$$

  - **Conservación de entrada (Grado interior 1)**:

$$\sum_{i=1, i\neq j}^{n} x_{ij} = 1, \quad \forall j = 1, \dots, n$$

Modelo 2 (DFJ): El fenómeno de los subciclos (Subtours)

- **Riesgo de fractura de asignación**:
  - $d_{\text{in}} = 1$ y $d_{\text{out}} = 1$ no garantizan conexidad global.
- **Ejemplo en red de 7 nodos**:
  - Se rompe en 2 subciclos aislados:
    - Subciclo 1: $(1 \to 2 \to 3 \to 1)$.
    - Subciclo 2: $(4 \to 5 \to 6 \to 7 \to 4)$.
  - **No forma un ciclo hamiltoniano**.

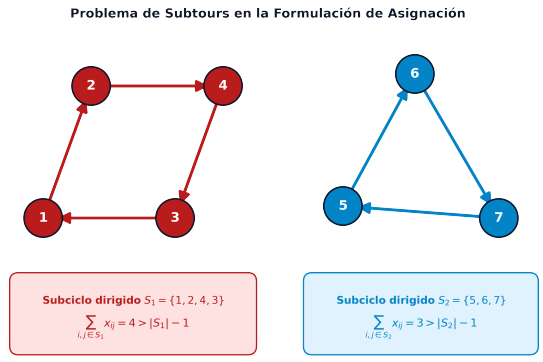

Modelo 2 (DFJ): Restricciones SEC

Restricciones de eliminación de subciclos (SEC DFJ 1954)

Para todo subconjunto propio no vacío $S \subset V$ con $2 \leq |S| \leq n-1$:

$$\sum_{i \in S} \sum_{j \in S} x_{ij} \leq |S| - 1$$

- **Fundamento combinatorio**:
  - Un subciclo cerrado aislado formado únicamente por ciudades de S tendría exactamente $|S|$ arcos.
  - La cota superior $|S| - 1$ fuerza obligatoriamente al tour a salir de S.

Modelo 2 (DFJ): Formulación consolidada y resolución

$$\min_{x} \quad \sum_{i=1}^{n}\sum_{j=1}^{n} d_{ij}x_{ij}$$

$$\text{s.a.} \quad \sum_{j=1,j\neq i}^{n} x_{ij} = 1, \quad \forall i = 1,\dots,n$$

$$\sum_{i=1,i\neq j}^{n} x_{ij} = 1, \quad \forall j = 1,\dots,n$$

$$\sum_{i\in S}\sum_{j\in S} x_{ij} \leq |S| - 1, \quad \forall S \subset V,\ 2 \leq |S| \leq n-1$$

$$x_{ij} \in \{0,1\}, \quad \forall i,j = 1,\dots,n,\ i \neq j$$

- **Propiedades**: $n(n-1)$ variables binarias y $2^n - 2$ restricciones SEC.
- **Branch-and-Cut**: Las SEC se incorporan como **cortes perezosos (*lazy constraints*)**.

Modelo 3 (MTZ): Variables de orden secuencial

- **Propuesta de Miller, Tucker y Zemlin (1960)**:
  - Elimina los subciclos con un número estrictamente polinomial de restricciones ($\mathcal{O}(n^2)$).
- **Variables de decisión**:
  - Variables binarias de arco: $x_{ij} \in \{0, 1\}$.
  - Depósito base fijado habitualmente en $u_1 = 1$.
  - Variables continuas auxiliares de posición:

$$u_i \geq 0, \quad \forall i = 2, \ldots, n \quad (2 \leq u_i \leq n)$$

donde u_i representa el número de orden en que se visita la ciudad i.

Modelo 3 (MTZ): Mecánica de eliminación de subciclos

Restricciones de orden MTZ (1960)

$$u_i - u_j + n x_{ij} \leq n - 1, \quad \forall i, j \in \{2, \dots, n\},\ i \neq j$$

- **1. Arco activo ($x_{ij} = 1$):**
  - $u_j \geq u_i + 1$.
  - El orden u_i crece estrictamente al avanzar.
  - **Imposibilita subciclos aislados** $i_1 \to \dots \to i_m \to i_1$ (exigiría $u_{i_1} < \dots < u_{i_1}$).
- **2. Arco inactivo ($x_{ij} = 0$):**
  - $u_i - u_j \leq n - 1$.
  - Como $2 \leq u_i, u_j \leq n$, la máxima diferencia es $n - 2 \leq n - 1$.
  - La restricción queda **desactivada**.

Modelo 3 (MTZ): Formulación matemática consolidada

$$\min_{x,u} \quad \sum_{i=1}^{n}\sum_{j=1}^{n} d_{ij}x_{ij}$$

$$\text{s.a.} \quad \sum_{j=1, j\neq i}^{n} x_{ij} = 1, \quad \forall i = 1, \dots, n$$

$$\sum_{i=1, i\neq j}^{n} x_{ij} = 1, \quad \forall j = 1, \dots, n$$

$$u_i - u_j + n x_{ij} \leq n-1, \quad \forall i, j \in \{2, \dots, n\},\ i \neq j$$

$$u_i \geq 0,\ \forall i \geq 2; \quad x_{ij} \in \{0,1\},\ \forall i \neq j$$

- **Dimensión**: $n(n-1)$ variables binarias, $n-1$ continuas y $n^2 - n + 2$ restricciones.

Comparativa formal: Modelo DFJ vs. Modelo MTZ

- **Compromiso entre dimensión y fortaleza poliédrica**:

Característica	Modelo DFJ (1954)	Modelo MTZ (1960)
Variables de decisión	$n(n-1)$ binarias	$n(n-1)$ binarias + $n-1$ continuas
Número de restricciones	$2^n - 2$ (exponencial)	$n^2 - n + 2$ (polinomial)
Relajación lineal continua	**Muy fuerte y ajustada**	**Significativamente débil**
Técnica de resolución	Branch-and-Cut (cortes dinámicos)	Solver MIP directo estándar
Escalabilidad práctica	Decenas de miles de ciudades	Cientos de ciudades

Heurísticas para el TSP: Vecino más Cercano y 2-Opt

- **Vecino más Cercano (Nearest Neighbor)**:
  - Heurística constructiva codiciosa en $\mathcal{O}(n^2)$.
  - En cada paso salta al nodo no visitado más próximo.
  - Muy rápida, pero suele dejar nodos lejanos con retorno costoso.

- **Búsqueda Local 2-Opt**:
  - Heurística de mejora local sobre un tour inicial.
  - Evalúa parejas de aristas $\{(u, v), (x, y)\}$ y las sustituye por $\{(u, x), (v, y)\}$.
  - Equivale a **invertir el sentido de recorrido** del subsegmento intermedio.
  - Itera hasta alcanzar un óptimo local 2-óptimo.

Algoritmo de aproximación de Christofides (1976)

- **Paso 1 (Árbol Soporte MST T)**:
  - Calcular un MST sobre V con Kruskal o Prim.
- **Paso 2 (Identificación de impares O)**:
  - Extraer nodos con grado impar en T ($|O|$ par).
- **Paso 3 (Matching perfecto M)**:
  - Matching perfecto de peso mínimo sobre O en el grafo original.
- **Paso 4 (Multigrafo euleriano H)**:
  - Unir $H = T \cup M \implies$ Grados pares en todo vértice.
- **Paso 5 (Ciclo euleriano y atajos)**:
  - Trazar el ciclo euleriano en H.
  - Aplicar **atajos** (*shortcuts*) omitiendo nodos repetidos para obtener el ciclo hamiltoniano.

Esquema visual de las fases de Christofides

- **Estrategia combinatoria**: (1) MST $\rightarrow$ (2) Emparejamiento en impares $\rightarrow$ (3) Multigrafo euleriano $\rightarrow$ (4) Atajos hamiltonianos.

Teorema de garantía de aproximación de Christofides

! Garantía de factor 1.5 de Christofides (1976)

En cualquier grafo métrico (con desigualdad triangular):

$$\text{Coste}(C_{\text{Christofides}}) \leq \frac{3}{2}\text{Coste}(C^*)$$

- **1. Cota del MST** T:
  - $\text{Coste}(T) < \text{Coste}(C^*)$.
- **2. Cota del Matching** M:
  - $\text{Coste}(M) \leq \frac{1}{2}\text{Coste}(C^*)$.
- **3. Multigrafo** $H = T \cup M$:
  - $\text{Coste}(H) < \frac{3}{2}\text{Coste}(C^*)$.
- **4. Atajos métricos**:
  - No aumentan el coste total.

Taxonomía y características de los Problemas de Rutas de Vehículos (VRP)

Del TSP al VRP: Origen y logística

- **Origen (Dantzig y Ramser 1959)**:
  - *The Truck Dispatching Problem*.
  - Generaliza el TSP a la gestión integral de flotas de vehículos.
- **Limitaciones del TSP elemental**:
  - Un único vehículo con capacidad ilimitada.
  - Sin ventanas de servicio ni múltiples bases logísticas.
- **La familia de problemas VRP**:
  - Coordina flotas para atender demandas territoriales minimizando costes de transporte.
  - Núcleo algorítmico del comercio electrónico y la distribución urbana.

Taxonomía topológica: Node vs. Arc Routing

- **Node Routing (Demandas en vértices)**: TSP, CVRP, VRPTW, Pickup & Delivery.
- **Arc Routing (Demandas continuas en aristas)**: Cartero Chino (CPP), Rural (RPP), CARP.

Clasificación según la localización de demanda

- **Rutas por Nodos (Node Routing)**:
  - **CVRP**: Flota con capacidad máxima Q que abastece a clientes con demandas q_i.
  - **VRPTW**: Clientes atendidos en ventanas de tiempo $[a_i, b_i]$.
  - **Multi-Depot VRP**: Múltiples bases logísticas territoriales.
  - **Pickup and Delivery (PDP)**: Recogida y entrega simultánea.
- **Rutas por Arcos (Arc Routing)**:
  - **Cartero Chino (CPP)**: Recorrer todas las aristas de la red (inspección vial/tuberías).
  - **Cartero Rural (RPP)**: Recorrer un subconjunto prioritario de aristas $E_R \subseteq E$.
  - **CARP**: Arcos con flota de camiones de capacidad limitada (recogida de residuos, quitanieves).

Las seis dimensiones operativas del VRP

Caracterización de las dimensiones operativas

- **1. Composición de flota**:
  - Homogénea vs. Heterogénea.
- **2. Depósitos e instalaciones**:
  - Monodepósito vs. Multidepósito.
- **3. Certeza de demanda**:
  - Determinista vs. Dinámica o Estocástica.
- **4. Operación de transporte**:
  - Entrega pura, recogida o simultánea.
- **5. Ventanas temporales**:
  - Sin ventanas, rígidas (*Hard*) o flexibles (*Soft*).
- **6. Objetivos de optimización**:
  - Distancia, tiempo, combustible, flota y CO_2.

PARTE IV

Colección de Ejercicios Prácticos

Enunciados clasificados por temas para el trabajo autónomo y la preparación de pruebas

> Boletines de problemas diseñados para afianzar tanto las técnicas de cálculo analítico como el modelado formal de problemas reales. Incluyen ejercicios de caracterización de convexidad, aplicación sistemática de condiciones KKT, análisis de dualidad y algoritmos fundamentales sobre grafos y redes.

Víctor Aceña Gil · Antonio Alonso Ayuso
CC BY-SA 4.0 Internacional · Curso 2026-2027

Índice de Ejercicios

Introducción **5**

Ejercicios del Tema 1: Introducción a la investigación operativa **6**
Ejercicio 1: modelado, ciclo de vida e historia 6
Ejercicio 2: formulación matemática y clasificación de modelos 6

Ejercicios del Tema 2: optimización no lineal y métodos numéricos **8**
Ejercicio 1: duopolio de Cournot con costes cuadráticos 8
Ejercicio 2: caracterización de curvatura y convexidad 8
Ejercicio 3: clasificación de puntos estacionarios 9
Ejercicio 4: trazado de búsqueda áurea y Newton 1D 9
Ejercicio 5: coordenadas cíclicas: optimización por direcciones ortogonales 10
Ejercicio 6: máximo descenso: invarianza ortogonal y trazado 10
Ejercicio 7: Newton multivariante: convergencia cuadrática 11

Ejercicios del Tema 3: análisis convexo **12**
Ejercicio 1: combinaciones convexas y conjuntos convexos 12
Ejercicio 2: operaciones algebraicas que preservan la convexidad 12
Ejercicio 3: puntos extremos y teorema de Minkowski-Weyl 13
Ejercicio 4: caracterización de primer orden de funciones convexas 13
Ejercicio 5: caracterización de segundo orden de la curvatura 14
Ejercicio 6: epígrafe, subgradientes y subdiferencial 14
Ejercicio 7: convexidad generalizada: funciones cuasiconvexas y pseudoconvexas . . . 14

Ejercicios del Tema 4: condiciones de optimalidad y KKT **16**
Ejercicio 1: clasificación de puntos estacionarios sin restricciones 16
Ejercicio 2: criterio de derivadas de orden superior (caso univariante) 16
Ejercicio 3: conos de direcciones factibles y de descenso 17
Ejercicio 4: condiciones de Fritz-John y fallo de LICQ 17
Ejercicio 5: resolución KKT completa con análisis por casos 18
Ejercicio 6: KKT y condiciones de suficiencia bajo convexidad 18
Ejercicio 7: KKT con restricciones mixtas (igualdad y desigualdad) 19
Ejercicio 8: análisis combinatorio de Fritz-John en región mixta 20

Ejercicios del Tema 5: dualidad KKT en programación lineal y cuadrática **21**
Ejercicio 1: formulación KKT, dualidad e interpretación de precios sombra en LP . . 21

Ejercicio 2: degeneración, sobredeterminación y relaciones de dualidad 22
Ejercicio 3: derivación analítica del sistema KKT en programación cuadrática (QP) 22
Ejercicio 4: aplicación iterativa del algoritmo del Símplex de Wolfe 23

Ejercicios del Tema 6: grafos y árboles soporte de mínimo peso **24**
Ejercicio 1: fundamentos de grafos, digrafos y lema de la suma de grados 24
Ejercicio 2: tipología de grafos, subgrafos y grafos complementarios 24
Ejercicio 3: recorridos, cadenas, caminos y métricas de red 25
Ejercicio 4: estructura de árboles, bosques y caracterizaciones equivalentes 25
Ejercicio 5: planaridad, fórmula de Euler y teorema de Kuratowski 26
Ejercicio 6: Algoritmo de Kruskal, matroides y propiedad del corte 26
Ejercicio 7: Algoritmo de Prim, invariancia y comparativa con el problema del camino mínimo (Dijkstra) 27
Ejercicio 8: aplicación en aprendizaje no supervisado: clustering basado en MST . . 27

Ejercicios del Tema 7: problema del camino mínimo **29**
Ejercicio 1: Ecuaciones de Bellman y ordenación topológica en DAGs 29
Ejercicio 2: Algoritmo de Dijkstra paso a paso 29
Ejercicio 3: Algoritmo de Bellman-Ford y detección de ciclos de coste negativo . . . 30
Ejercicio 4: Formulación en Programación Lineal Primal-Dual 30
Ejercicio 5: Algoritmo de Floyd-Warshall entre todos los pares 31

Ejercicios del Tema 8: flujos en redes **32**
Ejercicio 1: Formulación en Programación Lineal y Propiedades del Flujo Máximo . 32
Ejercicio 2: Algoritmo de Etiquetado Dinámico de Ford-Fulkerson paso a paso . . . 32
Ejercicio 3: Criterios de Optimalidad y Eliminación de Circuitos Negativos en Flujo de Coste Mínimo 33
Ejercicio 4: Crecimiento Iterativo por Caminos Mínimos (Teorema 2) 33
Ejercicio 5: El Problema del Transbordo y Reducción Unificada de Problemas de Redes 34

Ejercicios del Tema 9: emparejamientos en redes **35**
Ejercicio 1: Formulación en Programación Entera y Propiedades Algebraicas del Emparejamiento 35
Ejercicio 2: Cadenas Incrementales, Operación de Transferencia y Teorema de Berge 35
Ejercicio 3: Árboles Alternantes en Grafos Bipartitos y Detección de Cadenas Incrementales 36
Ejercicio 4: Algoritmo de Flor de Edmonds (Blossom Algorithm) y Ciclos Impares . 37
Ejercicio 5: Recubrimiento de Aristas, Dualidad de Gallai y Emparejamientos Ponderados 38

Ejercicios del Tema 10: rutas eulerianas, hamiltonianas y problemas de rutas **39**
Ejercicio 1: Grafos Eulerianos, Teorema de Euler y Algoritmo Constructivo de Cadenas 39
Ejercicio 2: Problema del Cartero Chino (CPP) y Matching de Nodos Impares . . . 40

Ejercicio 3: Grafos Hamiltonianos, Condiciones de Dirac, Ore y Clausura de Bondy-Chvátal 41
Ejercicio 4: Modelos de Programación Lineal Entera (PLE) para el Problema del Viajante de Comercio (TSP) 42
Ejercicio 5: Algoritmo de Aproximación de Christofides, Heurística 2-Opt y Taxonomía del VRP 43

Introducción

Este cuaderno recopila los enunciados de los ejercicios propuestos para la asignatura **Optimización y Análisis de Redes** para el Grado en Matemáticas.

El objetivo es que los alumnos trabajen en la formulación matemática y resolución manual o algorítmica de los distintos problemas antes de revisar el cuaderno de soluciones.

Ejercicios del Tema 1: Introducción a la investigación operativa

Ejercicio 1: modelado, ciclo de vida e historia

1. **El circo de Blackett**: Durante la Segunda Guerra Mundial, el grupo de investigación operativa liderado por Patrick Blackett analizó el tamaño óptimo de los convoyes de barcos mercantes escoltados que cruzaban el Atlántico. Explique el razonamiento matemático y operativo detrás de este problema: ¿por qué los convoyes más grandes resultaban ser más seguros frente a los ataques de submarinos enemigos (U-Boote)? Justifique la relación entre el perímetro del convoy (zona expuesta a ataques) y su área (capacidad de transporte).
2. **Propósitos de modelización**: En el contexto del diseño y gestión de una red de distribución eléctrica nacional:
   - Dé un ejemplo de **modelo físico/icónico**.
   - Dé un ejemplo de **modelo descriptivo**.
   - Dé un ejemplo de **modelo predictivo**.
   - Dé un ejemplo de **modelo prescriptivo**.
3. **Ciclo de vida en logística**: Una gran cadena de supermercados desea optimizar las rutas de reparto de su flota de camiones para minimizar el consumo de combustible. Describa brevemente qué acciones específicas se llevarían a cabo en cada una de las 4 fases del ciclo de vida del modelado matemático (Observación, Formulación, Validación e Implementación).

Ejercicio 2: formulación matemática y clasificación de modelos

Una microcervecería artesanal produce dos tipos de cerveza: una IPA (*India Pale Ale*) y una Stout. Para la elaboración de cada hectolitro (hl) se consumen recursos limitados según la siguiente tabla:

Cerveza	Malta (kg)	Lúpulo (kg)	Tiempo fermentación (días)
IPA	15	4	2
Stout	20	2	3
Disponibilidad	300 kg	50 kg	45 días-fermentador

El beneficio neto de la venta de un hectolitro de IPA es de 150 € y el de Stout es de 120 €.

Se pide:

1. **Formulación lineal**: Plantear el modelo de optimización matemática para maximizar el beneficio neto de la microcervecería. Defina con precisión las variables de decisión, la función objetivo y todas las restricciones operativas. Clasifique este modelo según los criterios tradicionales de optimización.
2. **Formulación no lineal con descuento por volumen**: Suponga ahora que el mercado es sensible a la cantidad producida, de modo que, para dar salida a un mayor volumen de producto, la microcervecería debe aplicar promociones. Esto provoca que el beneficio unitario de cada cerveza disminuya linealmente a medida que aumenta su producción total:

   - Para la cerveza IPA, el beneficio unitario base (150 €) se penaliza reduciéndose a razón de 2 € por cada hectolitro de IPA que se fabrique en total.
   - Para la cerveza Stout, el beneficio unitario base (120 €) se penaliza reduciéndose a razón de 3 € por cada hectolitro de Stout que se fabrique en total.

   Formule el nuevo problema de optimización para maximizar el beneficio total de la microcervecería y clasifíquelo nuevamente según su linealidad.

Ejercicios del Tema 2: optimización no lineal y métodos numéricos

Ejercicio 1: duopolio de Cournot con costes cuadráticos

Dos empresas competidoras, Empresa 1 y Empresa 2, producen un bien de consumo homogéneo. La función de demanda inversa de mercado viene dada por:

$$P(Q) = 20 - Q$$

donde $Q = Q_1 + Q_2$ es la producción total acumulada en el mercado. Las funciones de coste total de cada empresa son cuadráticas y se definen como:

$$C_1(Q_1) = 2Q_1 + \frac{1}{2}Q_1^2 \qquad \text{y} \qquad C_2(Q_2) = 3Q_2 + Q_2^2$$

Las producciones están limitadas físicamente por capacidades máximas: $Q_1 \leq 8$ y $Q_2 \leq 6$, y no pueden ser negativas.

Se pide:

1. Formular el problema de optimización individual de cada empresa para maximizar sus beneficios, determinando sus funciones de reacción o mejor respuesta $Q_1^*(Q_2)$ y $Q_2^*(Q_1)$.
2. Calcular analíticamente el equilibrio de Cournot-Nash del mercado (el punto donde ambas decisiones son óptimas simultáneamente).
3. Analizar la convexidad de las funciones de beneficio de cada empresa y discutir si el problema de optimización resultante es convexo.

Ejercicio 2: caracterización de curvatura y convexidad

Analizar la convexidad de las siguientes funciones en sus respectivos dominios utilizando el análisis de la matriz hessiana, calculando sus menores principales o sus autovalores:

1. $f(x, y) = e^{x^2+y^2}$ definida en $\mathbb{R}^2$.

2. $f(x, y) = 2x^2 - 4xy + y^4$ definida en $\mathbb{R}^2$.
3. $f(x, y) = -\ln(x) - \ln(y)$ definida en el dominio de valores estrictamente positivos $\mathbb{R}^2_{++} = \{(x, y) \in \mathbb{R}^2 \mid x > 0, y > 0\}$.

Ejercicio 3: clasificación de puntos estacionarios

Considerar la siguiente función real de dos variables:

$$f(x, y) = x^3 + y^3 - 3x - 12y + 20$$

Se pide:

1. Encontrar todos los puntos críticos o estacionarios de la función aplicando las condiciones de primer orden (FONC).
2. Clasificar cada uno de los puntos estacionarios hallados utilizando el criterio de la matriz hessiana y las condiciones de segundo orden (SOSC).
3. Determinar razonadamente si la función posee algún mínimo global o máximo global sobre todo el dominio $\mathbb{R}^2$.

Ejercicio 4: trazado de búsqueda áurea y Newton 1D

Se desea encontrar el mínimo global de la función real:

$$f(x) = x \ln(x) - 1.5x$$

en el intervalo acotado $[1, 3]$. Se sabe que el mínimo analítico exacto se encuentra en $x^* = e^{0.5} \approx 1.6487$.

Se pide:

1. Realizar de forma manual el **Paso 1** del método de la **Sección Áurea** para una tolerancia $\epsilon = 0.5$ (utilizar $\alpha \approx 1.61803$). Detallar la amplitud inicial, la posición de los puntos de evaluación λ_0, μ_0, sus correspondientes valores de función y el descarte de intervalo.
2. Realizar de forma manual el **Paso 1** del **Método de Newton 1D** partiendo de la aproximación inicial $x_0 = 1.0$. Mostrar detalladamente las ecuaciones de la primera y segunda derivada de la función, su evaluación en x_0 y el cálculo del siguiente punto x_1.

Ejercicio 5: coordenadas cíclicas: optimización por direcciones ortogonales

Dada la función cuadrática de dos variables con acoplamiento:

$$f(x, y) = 3x^2 + 2xy + y^2 - 4x - 2y$$

Se pide realizar la optimización local libre partiendo de la solución inicial $x_0 = (0, 0)^T$ aplicando el **Método de coordenadas cíclicas**:

1. Optimizar respecto a la variable x (fijando $y = 0$) mediante una búsqueda unidimensional exacta para hallar el punto intermedio x_1.
2. Optimizar respecto a la variable y (fijando $x = x_1$) mediante una búsqueda lineal exacta para determinar el siguiente iterado x_2.
3. Analizar si la convergencia en este método es directa (en un solo ciclo) o dibuja una trayectoria en escalera, justificándolo según el acoplamiento de la matriz hessiana.

Ejercicio 6: máximo descenso: invarianza ortogonal y trazado

Minimizar la misma función cuadrática:

$$f(x, y) = 3x^2 + 2xy + y^2 - 4x - 2y$$

partiendo desde $x_0 = (0, 0)^T$ utilizando el método del **Máximo descenso** con búsqueda de tamaño de paso exacta.

Se pide:

1. Calcular el gradiente analítico de la función y determinar la dirección inicial de búsqueda d_0.
2. Plantear la función unidimensional de paso $\phi(\alpha) = f(x_0 + \alpha d_0)$ y resolver analíticamente la optimización del tamaño de paso $\alpha_0 = \arg\min_{\alpha>0} \phi(\alpha)$. Calcular el siguiente punto iterado $x_1 = x_0 + \alpha_0 d_0$.
3. Calcular la dirección de búsqueda en el siguiente paso ($d_1 = -\nabla f(x_1)$) y demostrar analíticamente que d_0 y d_1 son ortogonales ($d_0^T d_1 = 0$), verificando el Teorema de Ortogonalidad Sucesiva.

Ejercicio 7: Newton multivariante: convergencia cuadrática

Dada la función cuadrática:

$$f(x, y) = 3x^2 + 2xy + y^2 - 4x - 2y$$

Se pide aplicar el método de **Newton multivariante** libre partiendo del punto de búsqueda inicial $x_0 = (0, 0)^T$:

1. Calcular el vector gradiente $\nabla f(x_0)$ y la matriz hessiana $H = \nabla^2 f(x_0)$.
2. Calcular analíticamente la matriz inversa de la hessiana H^{-1}.
3. Realizar la actualización de Newton $x_1 = x_0 - H^{-1}\nabla f(x_0)$. Comprobar que se alcanza el mínimo analítico exacto de la función en una única iteración y explicar razonadamente por qué se da este fenómeno.
4. Considere ahora una función no cuadrática dada por:

   $$g(x, y) = e^x - x + y^2$$

   Partiendo del punto inicial $x_0 = (1, 1)^T$, calcule la primera iteración de Newton multivariante x_1. Determine si x_1 es el óptimo analítico de la función y discuta cómo difiere la convergencia del método en funciones no cuadráticas.

Ejercicios del Tema 3: análisis convexo

Ejercicio 1: combinaciones convexas y conjuntos convexos

En la teoría de la optimización convexa, la intersección de conjuntos convexos juega un papel fundamental al definir regiones factibles que combinan múltiples restricciones.

Se pide:

1. Demostrar analíticamente que la intersección de una familia arbitraria (posiblemente infinita) de conjuntos convexos $\mathcal{S}_i \subseteq \mathbb{R}^n$, denotada por $\mathcal{S} = \bigcap_{i \in I} \mathcal{S}_i$, es a su vez un conjunto convexo.
2. Mostrar mediante un contraejemplo gráfico o analítico en $\mathbb{R}^2$ que la unión de dos conjuntos convexos $\mathcal{S}_1 \cup \mathcal{S}_2$ no es necesariamente un conjunto convexo.

Ejercicio 2: operaciones algebraicas que preservan la convexidad

Demostrar las siguientes propiedades relativas a la preservación de la convexidad de conjuntos bajo operaciones afines y algebraicas:

1. Sean $\mathcal{S}_1, \mathcal{S}_2 \subseteq \mathbb{R}^n$ dos conjuntos convexos. Demostrar que su **suma de Minkowski**, definida como:
$$\mathcal{S}_1 + \mathcal{S}_2 = \{x_1 + x_2 \mid x_1 \in \mathcal{S}_1,\ x_2 \in \mathcal{S}_2\}$$
es un conjunto convexo.
2. Sea $\mathcal{S} \subseteq \mathbb{R}^n$ un conjunto convexo, y sea $f : \mathbb{R}^n \to \mathbb{R}^m$ una transformación afín dada por $f(x) = Ax + b$, donde $A \in \mathbb{R}^{m \times n}$ y $b \in \mathbb{R}^m$. Demostrar que la imagen del conjunto, $f(\mathcal{S}) = \{Ax + b \mid x \in \mathcal{S}\}$, es un conjunto convexo en $\mathbb{R}^m$.

Ejercicio 3: puntos extremos y teorema de Minkowski-Weyl

Considerar el conjunto de puntos $\mathcal{S} \subseteq \mathbb{R}^2$ definido por la inecuación de la norma L_1:

$$\mathcal{S} = \{(x, y) \in \mathbb{R}^2 \mid |x| + |y| \leq 1\}$$

Se pide:

1. Dibujar o describir geométricamente el conjunto $\mathcal{S}$ en el plano real $\mathbb{R}^2$, determinando si es un conjunto convexo y acotado (un politopo).
2. Identificar todos los **puntos extremos** (o vértices) del conjunto $\mathcal{S}$ aplicando la definición formal de punto extremo (aquellos puntos que no pueden expresarse como combinación convexa propia de otros dos puntos distintos del conjunto).
3. Demostrar que cualquier punto interior o de la frontera de $\mathcal{S}$ (por ejemplo, el punto $(0.2, 0.5)^T$) se puede expresar como una combinación convexa de sus puntos extremos, de acuerdo con el Teorema de Representación de Minkowski.

Ejercicio 4: caracterización de primer orden de funciones convexas

Sea $f : \mathcal{S} \to \mathbb{R}$ una función continuamente diferenciable sobre un conjunto abierto y convexo $\mathcal{S} \subseteq \mathbb{R}^n$.

Se pide:

1. Demostrar analíticamente el teorema de caracterización de primer orden, el cual establece que f es convexa en $\mathcal{S}$ si y solo si:

   $$f(y) \geq f(x) + \nabla f(x)^T (y - x), \quad \forall x, y \in \mathcal{S}$$

   Ayuda: Para la implicación directa, utiliza el límite de la definición de convexidad cuando el parámetro de combinación $\lambda \to 0^+$.
2. Utilizando la desigualdad anterior, demostrar que si f es convexa en $\mathcal{S}$ y existe un punto $x^* \in \mathcal{S}$ tal que el gradiente se anula ($\nabla f(x^*) = 0$), entonces x^* es un **mínimo global** de la función en $\mathcal{S}$.

Ejercicio 5: caracterización de segundo orden de la curvatura

Estudiar analíticamente la convexidad o concavidad local y global de las siguientes funciones mediante el cálculo de sus matrices hessianas y el análisis de sus menores principales o autovalores:

1. $f(x, y) = x^2y^2 - x - y$ definida sobre el dominio global $\mathbb{R}^2$.
2. $f(x, y) = -\ln(4 - x^2 - y^2)$ definida sobre el disco abierto $\mathcal{S} = \{(x, y) \in \mathbb{R}^2 \mid x^2 + y^2 < 4\}$.
3. $f(x, y, z) = x^2 + 2y^2 + 5z^2 + 2xy - 4yz - 2x + 6$ definida sobre $\mathbb{R}^3$.

Ejercicio 6: epígrafe, subgradientes y subdiferencial

Sea la función real no diferenciable $f : \mathbb{R} \to \mathbb{R}$ definida por:

$$f(x) = |x| + |x - 1|$$

Se pide:

1. Trazar la gráfica de la función $f(x)$ en el intervalo $[-1, 2]$ y describir analíticamente su **epígrafe** epi(f).
2. Aplicar la definición de subgradiente para calcular el conjunto **subdiferencial** $\partial f(x)$ en los puntos $x_0 = 0$, $x_0 = 0.5$ y $x_0 = 1$.
3. Explicar la relación entre el conjunto subdiferencial y la optimización no diferenciable. Comprobar si se cumple la condición de optimalidad global ($0 \in \partial f(x^*)$) en el intervalo de puntos de mínimo de la función.

Ejercicio 7: convexidad generalizada: funciones cuasiconvexas y pseudoconvexas

El análisis de la convexidad generalizada nos permite estudiar la unicidad del óptimo en funciones que no cumplen con la definición estricta de convexidad pero que conservan propiedades equivalentes para algoritmos de optimización.

Se pide:

1. Considerar la función cúbica $f(x) = x^3 - 3x$ en $\mathbb{R}$. Identificar las regiones o intervalos donde la función es convexa, cóncava, cuasiconvexa y pseudoconvexa.
2. Considerar la función de campana inversa $g(x) = \frac{-1}{x^2+1}$ definida en $\mathbb{R}$.

    - Demostrar que $g(x)$ **no** es una función convexa sobre $\mathbb{R}$ analizando su segunda derivada.
    - Demostrar que $g(x)$ es **cuasiconvexa** y **pseudoconvexa** en todo $\mathbb{R}$.
    - Analizar qué consecuencias tiene este hecho para la convergencia de algoritmos de búsqueda local (como el método del descenso de gradiente) aplicados a esta función.

Ejercicios del Tema 4: condiciones de optimalidad y KKT

Ejercicio 1: clasificación de puntos estacionarios sin restricciones

Considerar la función real de dos variables:

$$f(x_1, x_2) = x_1^3 - 3x_1x_2^2 + x_2^4 - 2x_2^2$$

Se pide:

1. Encontrar todos los puntos estacionarios de la función aplicando las condiciones de primer orden (FONC), es decir, resolviendo el sistema $\nabla f(x_1, x_2) = 0$.
2. Calcular la matriz hessiana $\nabla^2 f(x_1, x_2)$ y evaluar las condiciones de segundo orden (SONC y SOSC) en cada punto estacionario hallado. Clasificar cada punto como mínimo local, máximo local, punto de silla o indeterminado.
3. Determinar razonadamente si la función posee algún mínimo global o máximo global sobre todo el dominio $\mathbb{R}^2$.

Ejercicio 2: criterio de derivadas de orden superior (caso univariante)

Considerar la función univariante:

$$f(x) = (x-1)^2(x+1)^2$$

Se pide:

1. Encontrar todos los puntos estacionarios de f en $\mathbb{R}$.
2. Aplicar el criterio de derivadas de orden superior para clasificar cada punto estacionario: si la primera derivada no nula $f^{(n)}(\bar{x})$ tiene orden n par, $\bar{x}$ es un extremo local; si n es impar, $\bar{x}$ es un punto de inflexión.

3. Identificar los mínimos locales, máximos locales y puntos de inflexión de la función. Indicar si alguno de los extremos locales es también un extremo global.

Ejercicio 3: conos de direcciones factibles y de descenso

Considerar el problema de optimización:

$$\min f(x_1, x_2) = -x_1 - 2x_2$$

sujeto a las restricciones:

$$g_1(x_1, x_2) = x_1^2 + x_2^2 - 4 \leq 0 \qquad g_2(x_1, x_2) = -x_1 \leq 0$$

Se pide evaluar las condiciones de optimalidad basadas en conos de direcciones en los puntos $\bar{x}_A = (2, 0)^T$ y $\bar{x}_B = (0, 2)^T$:

1. Identificar las restricciones activas en cada punto y calcular los gradientes de las restricciones activas $\nabla g_i(\bar{x})$.
2. Determinar el cono analítico de descenso $\mathcal{D}_0(\bar{x}) = \{d \mid \nabla f(\bar{x})^T d < 0\}$ y el cono de restricciones activas $\mathcal{G}_0(\bar{x}) = \{d \mid \nabla g_i(\bar{x})^T d < 0,\ \forall i \in \mathcal{I}\}$.
3. Comprobar si se cumple la condición necesaria $\mathcal{D}_0(\bar{x}) \cap \mathcal{G}_0(\bar{x}) = \emptyset$ en cada punto.
4. Interpretar geométricamente el resultado: ¿cuál de los dos puntos puede ser un óptimo local y por qué?

Ejercicio 4: condiciones de Fritz-John y fallo de LICQ

Considerar el problema de optimización:

$$\min f(x_1, x_2) = x_1 + x_2$$

sujeto a las restricciones:

$$g_1(x_1, x_2) = (x_1 - 1)^3 - x_2 \leq 0 \qquad g_2(x_1, x_2) = -x_2 \leq 0$$

Se pide analizar el punto $\bar{x} = (1, 0)^T$:

1. Verificar que $\bar{x}$ es un punto factible e identificar las restricciones activas.

2. Plantear las condiciones de Fritz-John en $\bar{x}$: escribir el sistema $u_0 \nabla f(\bar{x}) + u_1 \nabla g_1(\bar{x}) + u_2 \nabla g_2(\bar{x}) = 0$ con $u_0, u_1, u_2 \geq 0$, $(u_0, u_1, u_2) \neq (0, 0, 0)$.
3. Resolver el sistema y determinar los valores posibles de los multiplicadores u_0, u_1, u_2. ¿Es posible que $u_0 > 0$?
4. Comprobar si se satisface la condición LICQ (independencia lineal de los gradientes de las restricciones activas) en $\bar{x}$. Interpretar el resultado y explicar por qué las condiciones de Fritz-John son insuficientes en este caso para discriminar candidatos a óptimo.

Ejercicio 5: resolución KKT completa con análisis por casos

Considerar el problema de optimización:

$$\min f(x_1, x_2) = (x_1 - 3)^2 + (x_2 - 1)^2$$

sujeto a las restricciones de desigualdad:

$$g_1(x_1, x_2) = x_1^2 + x_2^2 - 4 \leq 0 \qquad g_2(x_1, x_2) = x_1 + x_2 - 1 \leq 0$$

Se pide:

1. Construir la función lagrangiana $L(x, u) = f(x) + u_1 g_1(x) + u_2 g_2(x)$ y plantear el sistema de condiciones KKT completo (estacionariedad, factibilidad primal, holgura complementaria y factibilidad dual).
2. Resolver el sistema KKT analizando exhaustivamente los cuatro casos combinatorios resultantes de la holgura complementaria: (a) ambas inactivas, (b) solo g_1 activa, (c) solo g_2 activa, (d) ambas activas.
3. Para cada caso, verificar la factibilidad primal y la condición de signo de los multiplicadores ($u_i \geq 0$). Descartar los casos que violen alguna condición.
4. Comparar los valores de la función objetivo en los candidatos válidos y determinar el mínimo global del problema.

Ejercicio 6: KKT y condiciones de suficiencia bajo convexidad

Considerar el problema de optimización:

$$\min f(x_1, x_2) = x_1^2 + x_2^2$$

sujeto a la restricción de desigualdad:

$$g_1(x_1, x_2) = -x_1 - x_2 + 1 \leq 0$$

Se pide:

1. Plantear y resolver las condiciones KKT del problema. Hallar el punto candidato $\bar{x}$ y el multiplicador u_1.
2. Verificar que la función objetivo f es estrictamente convexa en $\mathbb{R}^2$ analizando su hessiana.
3. Verificar que la restricción g_1 es una función afín (y por tanto convexa y cuasiconvexa).
4. Aplicar el teorema de suficiencia KKT: demostrar que, al ser f convexa y g_1 cuasiconvexa, el candidato KKT hallado es el mínimo global del problema.

Ejercicio 7: KKT con restricciones mixtas (igualdad y desigualdad)

Considerar el problema de optimización:

$$\min f(x_1, x_2) = x_1^2 + 2x_2^2$$

sujeto a las restricciones:

$$h_1(x_1, x_2) = x_1 + x_2 - 2 = 0 \qquad g_1(x_1, x_2) = -x_1 \leq 0$$

Se pide:

1. Plantear las condiciones KKT generalizadas para el problema con restricciones mixtas: sistema de estacionariedad $\nabla f + u_1 \nabla g_1 + v_1 \nabla h_1 = 0$, factibilidad primal, holgura complementaria y factibilidad dual ($u_1 \geq 0$, v_1 libre).
2. Resolver el sistema KKT analizando los dos casos: (a) g_1 inactiva ($x_1 > 0$, $u_1 = 0$) y (b) g_1 activa ($x_1 = 0$, $u_1 \geq 0$).
3. Para cada caso, verificar la factibilidad de todas las restricciones y las condiciones de signo.
4. Justificar por qué el multiplicador v_1 asociado a la restricción de igualdad puede tomar cualquier signo (positivo, negativo o nulo), a diferencia de los multiplicadores u_i de las restricciones de desigualdad.

Ejercicio 8: análisis combinatorio de Fritz-John en región mixta

Considerar el problema de encontrar el punto de la región factible más cercano a la coordenada $(3, 2)$, es decir:

$$\min_{x} \quad (x_1 - 3)^2 + (x_2 - 2)^2$$

bajo dos escenarios distintos para la frontera superior de la región.

Caso A: Frontera Simétrica Sujeto a las restricciones:

$$\begin{aligned} g_1(x) &= x_1^2 + x_2^2 - 5 \leq 0 \\ g_2(x) &= x_1 + x_2 - 3 \leq 0 \\ g_3(x) &= -x_1 \leq 0 \\ g_4(x) &= -x_2 \leq 0 \end{aligned}$$

Caso B: Frontera Asimétrica Sujeto a las mismas restricciones, excepto la segunda que cambia a:

$$g_2(x) = x_1 + 2x_2 - 4 \leq 0$$

Se pide: 1. Para el **Caso A**, identificar las esquinas factibles formadas por la intersección de la frontera lineal $g_2(x) = 0$ y la circular $g_1(x) = 0$ en el primer cuadrante. Plantear las condiciones de Fritz-John en cada una y verificar si satisfacen KKT (con $u_0 = 1$ o si se descartan). 2. Para el **Caso B**, calcular el punto de intersección de la frontera lineal $g_2(x) = 0$ y la circular $g_1(x) = 0$ en el primer cuadrante. Analizar dicho punto mediante las condiciones de Fritz-John y KKT. Analizar de igual forma la esquina del eje de ordenadas formada por $g_2(x) = 0$ y $g_3(x) = 0$.

Ejercicios del Tema 5: dualidad KKT en programación lineal y cuadrática

Ejercicio 1: formulación KKT, dualidad e interpretación de precios sombra en LP

Considerar el problema de programación lineal de maximización de beneficio:

$$\begin{aligned} \max_{x_1,x_2} \quad & z = 3x_1 + 5x_2 \\ \text{sujeto a} \quad & x_1 \leq 4 \quad (g_1) \\ & 2x_2 \leq 12 \quad (g_2) \\ & 3x_1 + 2x_2 \leq 18 \quad (g_3) \\ & x_1, x_2 \geq 0 \end{aligned}$$

Se pide:

1. Transformar el problema a la forma canónica de minimización $\min c^T x$ s.a. $Ax \leq b, x \geq 0$ y derivar analíticamente el sistema KKT completo (estacionariedad, factibilidad primal, factibilidad dual y holgura complementaria).
2. Formular formalmente el problema dual de Lagrange asociado (D).
3. Sabiendo que la solución primal óptima es $\bar{x} = (2, 6)^T$, aplicar el teorema de holgura complementaria para calcular exactamente los multiplicadores de Lagrange KKT u_1^*, u_2^*, u_3^* y verificar que constituyen una solución factible y óptima del problema dual.
4. Interpretar económicamente los precios sombra hallados: ¿cuál es el coste marginal de oportunidad asociado a cada una de las tres restricciones? Si el término independiente de la tercera restricción aumenta de $b_3 = 18$ a $b_3 = 19$, ¿cuál será el nuevo beneficio óptimo esperado?

Ejercicio 2: degeneración, sobredeterminación y relaciones de dualidad

Considerar el problema de programación lineal:

$$\begin{aligned} \min_{x_1,x_2} \quad & f(x_1,x_2) = -2x_1 - 4x_2 \\ \text{sujeto a} \quad & x_1 + x_2 \leq 4 \quad (g_1) \\ & -x_1 + x_2 \leq 2 \quad (g_2) \\ & x_2 \leq 3 \quad (g_3) \\ & x_1, x_2 \geq 0 \end{aligned}$$

Se pide:

1. Resolver gráficamente el problema primal y verificar que el óptimo se alcanza en el vértice $\bar{x} = (1,3)^T$.
2. Identificar las restricciones activas en $\bar{x}$ y justificar por qué existe sobredeterminación geométrica ($m_{activas} > n$) y fallo de la cualificación de restricciones de independencia lineal (LICQ).
3. Plantear el sistema KKT de estacionariedad en $\bar{x} = (1,3)^T$ y determinar la familia infinita de vectores de multiplicadores duales (u_1, u_2, u_3) que satisfacen las condiciones KKT.
4. Clasificar el par primal-dual dentro de las 6 relaciones fundamentales de dualidad estudiadas en la teoría.

Ejercicio 3: derivación analítica del sistema KKT en programación cuadrática (QP)

Considerar el problema de optimización cuadrática:

$$\begin{aligned} \min_{x_1,x_2} \quad & f(x_1,x_2) = \frac{1}{2}x_1^2 + x_2^2 - 4x_1 - 6x_2 \\ \text{sujeto a} \quad & x_1 + x_2 \leq 3 \quad (g_1) \\ & x_1 + 2x_2 \leq 4 \quad (g_2) \\ & x_1, x_2 \geq 0 \end{aligned}$$

Se pide:

1. Identificar la matriz cuadrática Q y el vector lineal c. Comprobar que Q es strictly definida positiva ($Q \succ 0$), garantizando la convexidad estricta del problema y la existencia de un único mínimo global.
2. Calcular el mínimo libre no restringido $x_0 = -Q^{-1}c$ y verificar si pertenece a la región factible.
3. Formular la función de Lagrange KKT y escribir la ecuación de estacionariedad $Qx + A^T u - v = -c$.
4. Introducir las variables de holgura primales $y_1, y_2 \geq 0$ y representar el sistema matricial KKT lineal completo de Wolfe.
5. Resolver analíticamente el sistema KKT por el método de casos sobre las restricciones activas para obtener la solución óptima exacta $(\bar{x}_1, \bar{x}_2)$ y sus multiplicadores duales (u_1^*, u_2^*).

Ejercicio 4: aplicación iterativa del algoritmo del Símplex de Wolfe

Considerar el problema cuadrático simple:

$$\begin{aligned} \min_{x_1, x_2} \quad & f(x_1, x_2) = x_1^2 + x_2^2 - 6x_1 - 4x_2 \\ \text{sujeto a} \quad & x_1 + x_2 \leq 2 \\ & x_1, x_2 \geq 0 \end{aligned}$$

Se pide:

1. Escribir las ecuaciones de factibilidad primal con la variable de holgura $y_1 \geq 0$ y las ecuaciones de estacionariedad KKT introduciendo las variables artificiales $z_1, z_2 \geq 0$.
2. Construir la tabla inicial del Símplex de Wolfe en el origen ($x_1 = 0, x_2 = 0$).
3. Aplicar rigurosamente la **regla de entrada restringida de Wolfe** en cada iteración: determinar qué variables duales están bloqueadas por la presencia de sus primales correspondientes en la base.
4. Ejecutar las iteraciones del algoritmo de pivotaje del Símplex hasta conseguir que la suma de variables artificiales sea $z_1 + z_2 = 0$.
5. Extraer la solución óptima primal $(\bar{x}_1, \bar{x}_2)$, el multiplicador dual u_1^* y verificar el cumplimiento estricto de la condición KKT de tangencia.

Ejercicios del Tema 6: grafos y árboles soporte de mínimo peso

Ejercicio 1: fundamentos de grafos, digrafos y lema de la suma de grados

Considerar la red dirigida $G_D = (V, A)$ sobre el conjunto de 6 vértices $V = \{1, 2, 3, 4, 5, 6\}$ con la siguiente colección de 10 arcos orientados:

$$A = \{(1,2), (1,3), (2,3), (2,4), (3,4), (3,5), (4,5), (4,6), (5,6), (6,1)\}$$

Se pide:

1. Dibujar el esquema conceptual de la red dirigida y calcular para cada nodo $v \in V$ su grado de entrada $\deg^-(v)$, su grado de salida $\deg^+(v)$ y su grado total $\deg(v)$.
2. Verificar numéricamente la versión para digrafos del *Handshaking Lemma*: $\sum_{v \in V} \deg^+(v) = \sum_{v \in V} \deg^-(v) = m$.
3. Si el sentido de los arcos se ignora para construir el grafo no dirigido subyacente $G = (V, E)$, calcular el grado $\deg(v)$ de cada vértice en G y comprobar que $\sum_{v \in V} \deg(v) = 2m$.
4. Para el subconjunto de nodos $A = \{2, 3, 4\}$, evaluar analíticamente la incidencia exterior $w^+(A)$, la incidencia interior $w^-(A)$ y el corte total $w(A)$.

Ejercicio 2: tipología de grafos, subgrafos y grafos complementarios

Considérese el grafo simple no dirigido $G = (V, E)$ de $n = 6$ vértices con conjunto de aristas $E = \{\{1,2\}, \{1,3\}, \{2,3\}, \{3,4\}, \{4,5\}, \{4,6\}, \{5,6\}\}$.

Se pide:

1. Clasificar el grafo G: determinar si es simple, completo, regular o bipartito. Justificar analíticamente la respuesta utilizando el Teorema de caracterización de grafos bipartitos (ausencia de ciclos impares).

2. Construir el subgrafo inducido por el subconjunto de vértices $S = \{1, 2, 3, 4\}$, denotado por $G[S]$. Indicar su número de aristas y si es un clan (*clique*).
3. Obtener el grafo complementario $\bar{G} = (V, \bar{E})$ y verificar numéricamente que el número de aristas satisface la relación $m(G) + m(\bar{G}) = \binom{n}{2}$.
4. Calcular el grado de cada vértice en $\bar{G}$ y comprobar que $\deg_{\bar{G}}(v) = n - 1 - \deg_G(v)$ para todo $v \in V$.

Ejercicio 3: recorridos, cadenas, caminos y métricas de red

En un grafo no dirigido $G = (V, E)$ sobre 7 vértices $V = \{1, 2, 3, 4, 5, 6, 7\}$, se analizan diversas secuencias de vértices y aristas:

1. Clasificar rigurosamente las siguientes secuencias como cadena o camino, indicando en cada caso si son **elementales** (sin repetición de vértices) o **simples** (sin repetición de aristas):

   - $\mu_1 = (1, 2, 3, 5, 6)$ pasando por las aristas $\{\{1, 2\}, \{2, 3\}, \{3, 5\}, \{5, 6\}\}$.
   - $\mu_2 = (1, 2, 4, 3, 2, 5)$ pasando por $\{\{1, 2\}, \{2, 4\}, \{4, 3\}, \{3, 2\}, \{2, 5\}\}$.
   - $\mu_3 = (1, 2, 3, 1, 2, 4)$ pasando por $\{\{1, 2\}, \{2, 3\}, \{3, 1\}, \{1, 2\}, \{2, 4\}\}$.

2. Supóngase que las distancias geodésicas mínimas (número de aristas del camino más corto) entre todos los pares de nodos del grafo vienen dadas por la matriz de distancias $D \in \mathbb{R}^{7\times 7}$. Para un nodo v, se define su **excentricidad** como $e(v) = \max_{u \in V} d(u, v)$.

   - Si las excentricidades de los nodos son $e(1) = 3, e(2) = 2, e(3) = 2, e(4) = 3, e(5) = 3, e(6) = 4, e(7) = 4$, determinar el **radio** $R(G)$, el **diámetro** $\mathrm{diam}(G)$ y el **centro** del grafo.

Ejercicio 4: estructura de árboles, bosques y caracterizaciones equivalentes

Considerar un grafo no dirigido $G = (V, E)$ con $n = 8$ vértices y $m = 12$ aristas.

Se pide:

1. Verificar si G puede ser un árbol. Si no es un árbol, determinar cuántas aristas deben eliminarse como mínimo para obtener un árbol soporte T.

2. Demostrar rigurosamente que en todo árbol con $n \geq 2$ vértices existen al menos dos vértices de grado 1 (nodos hoja).
3. Probar analíticamente la equivalencia entre dos caracterizaciones fundamentales de un árbol: (a) G es conexo y acíclico, y (b) entre todo par de vértices $u, v \in V$ existe un único camino simple.
4. Para un árbol T de 6 nodos $V = \{1, 2, 3, 4, 5, 6\}$ con aristas $E_T = \{\{1, 2\}, \{1, 3\}, \{2, 4\}, \{2, 5\}, \{3, 6\}\}$, escribir su representación por **vector de padres o predecesores** β tomando como nodo raíz el vértice $r = 1$.

Ejercicio 5: planaridad, fórmula de Euler y teorema de Kuratowski

Análisis topológico de la propiedad de planaridad en grafos.

Se pide:

1. Enunciar la **Fórmula Planar de Euler** ($n - m + r = 2$) para un grafo conexo planar y demostrar analíticamente que en todo grafo planar simple con $n \geq 3$ vértices se cumple la desigualdad $m \leq 3n - 6$.
2. Demostrar que si un grafo planar simple no contiene triángulos (su cintura es $g \geq 4$), la cota de aristas se estrecha a $m \leq 2n - 4$.
3. Aplicar las desigualdades anteriores para demostrar analíticamente que:
   - El grafo completo K_5 (5 vértices, 10 aristas) **no es planar**.
   - El grafo bipartito completo $K_{3,3}$ (6 vértices, 9 aristas) **no es planar**.
4. Enunciar el **Teorema de Kuratowski** y explicar cómo la presencia de un subgrafo homeomórfico a K_5 o $K_{3,3}$ demuestra la no planaridad del Grafo de Petersen.

Ejercicio 6: Algoritmo de Kruskal, matroides y propiedad del corte

Considérese una red no dirigida valorada de 6 vértices $V = \{A, B, C, D, E, F\}$ con las siguientes 10 aristas valoradas:

$$E = \{(A, B, 3), (A, C, 1), (A, D, 4), (B, C, 2), (B, E, 5),\\ (C, D, 6), (C, E, 3), (C, F, 7), (D, F, 2), (E, F, 4)\}$$

Se pide:

1. Formular matemáticamente el problema del Árbol Soporte de Mínimo Peso (MST) como un problema de optimización combinatoria.
2. Aplicar paso a paso el Algoritmo de Kruskal, indicando el orden de evaluación de las aristas, las componentes conexas disjuntas (*Union-Find*) tras cada incorporación y las aristas descartadas por formar ciclo.
3. Calcular el peso total del árbol soporte de mínimo peso $d(T)$.
4. Utilizar la **Propiedad del Corte (*Cut Property*)** para justificar analíticamente por qué la arista (A, C) pertenece obligatoriamente a todo MST de la red.
5. Determinar si el MST hallado es único o si existen árboles soporte de mínimo peso alternativos.

Ejercicio 7: Algoritmo de Prim, invariancia y comparativa con el problema del camino mínimo (Dijkstra)

Para la misma red no dirigida valorada de 6 vértices $V = \{A, B, C, D, E, F\}$ del Ejercicio 6:

Se pide:

1. Ejecutar paso a paso el Algoritmo de Prim eligiendo como nodo raíz inicial $v_1 = A$. Detallar para cada iteración $i = 1, \ldots, 5$ el conjunto de vértices visitados P, las aristas del corte $w(P)$ y la arista de peso mínimo seleccionada.
2. Verificar que el árbol resultante y su peso acumulado coinciden exactamente con la solución de Kruskal.
3. Ejecutar nuevamente Prim cambiando el nodo raíz inicial a $v_1 = F$. Justificar la invariancia del peso total del MST.
4. **Análisis Conceptual**: Explicar la diferencia fundamental entre un Árbol Soporte de Mínimo Peso (MST) y un Árbol de Caminos Mínimos (SPT, obtenido con Dijkstra desde un origen). Construir un contraejemplo numérico de 3 nodos donde el MST no coincida con el SPT.

Ejercicio 8: aplicación en aprendizaje no supervisado: clustering basado en MST

Análisis teórico y numérico del clustering jerárquico basado en la partición del MST.

Se pide:

1. Explicar el procedimiento algorítmico para segmentar un conjunto de N observaciones en $\mathbb{R}^d$ en k clústeres inconexos a partir del MST de la matriz de desemejanza.
2. Analizar teóricamente la función de calidad $F(T \setminus E_k) = \min_{e \in E_k} w(e)$ basada en la maximización de la distancia inter-clúster (*Single-Linkage*).
3. Comparar el comportamiento del clustering basado en MST frente al algoritmo k-medias ($WCSS$), argumentando por qué el MST es capaz de separar clústeres con geometrías no convexas (como anillos concéntricos o serpentinas).
4. **Ejercicio Numérico**: Considérense 6 puntos en $\mathbb{R}^2$: $p_1 = (0,0), p_2 = (1,0), p_3 = (0,1), p_4 = (5,5), p_5 = (6,5), p_6 = (5,6)$. Construir el MST utilizando la distancia euclídea y obtener la partición en $k = 2$ clústeres eliminando la arista de mayor peso.

Ejercicios del Tema 7: problema del camino mínimo

Ejercicio 1: Ecuaciones de Bellman y ordenación topológica en DAGs

Considérese el digrafo acíclico $G = (V, A, \mathbf{c})$ de $n = 6$ vértices $V = \{1, 2, 3, 4, 5, 6\}$ con costes de arcos dados por:

$$A = \{(1,2) : 3,\ (1,3) : 6,\ (2,3) : 2,\ (2,4) : 5,\\ (3,4) : 1,\ (3,5) : 4,\ (4,5) : 2,\ (4,6) : 7,\ (5,6) : 3\}$$

Se pide:

1. Verificar que la numeración de los vértices satisface la propiedad de ordenación topológica $i < j$ para todo $(i, j) \in A$.
2. Formular las ecuaciones de optimalidad de Bellman para el origen $s = 1$.
3. Resolver el sistema en tiempo lineal $O(|V| + |A|)$ obteniendo el vector de distancias mínimas $\mathbf{u} = (u_1, \ldots, u_6)$ y el vector de predecesores Pred.
4. Trazar la arborescencia de caminos mínimos resultante desde el origen 1.

Ejercicio 2: Algoritmo de Dijkstra paso a paso

Dado el digrafo valorado con costes no negativos $G = (V, A, \mathbf{c})$ con $V = \{1, 2, 3, 4, 5\}$ y arcos:

$$A = \{(1,2) : 10,\ (1,4) : 5,\ (2,3) : 1,\ (2,4) : 2,\\ (3,5) : 4,\ (4,2) : 3,\ (4,3) : 9,\ (4,5) : 2,\ (5,3) : 6\}$$

Se pide:

1. Ejecutar el Algoritmo de Dijkstra paso a paso para hallar los caminos mínimos desde el nodo origen 1 al resto de vértices.

2. Completar en cada iteración la tabla con los conjuntos de nodos permanentes $\mathcal{P}$, nodos transitorios $\mathcal{T}$, las etiquetas provisionales y definitivas u_j y el vector de predecesores $\text{Pred}(j)$.
3. Dibujar la arborescencia óptima final identificando las rutas y sus costes.

Ejercicio 3: Algoritmo de Bellman-Ford y detección de ciclos de coste negativo

Considérese el digrafo $G = (V, A, \mathbf{c})$ de 4 vértices con los siguientes arcos, alguno de los cuales posee peso negativo:

$$A = \{(1,2) : 4,\ (1,3) : 5,\ (2,3) : -3,\ (3,4) : 4,\ (4,2) : 1\}$$

Se pide:

1. Desarrollar las iteraciones $m = 1, 2, 3, 4$ del Algoritmo de Bellman-Ford evaluando las etiquetas $u_j^m = \min\{u_j^{m-1}, \min_k\{u_k^{m-1} + c_{kj}\}\}$.
2. Determinar si el algoritmo converge anticipadamente o si alcanza el límite $m = n - 1$.
3. Evaluar la iteración $m = 4$ para comprobar si existen circuitos de coste negativo. Justificar analíticamente la respuesta.

Ejercicio 4: Formulación en Programación Lineal Primal-Dual

Dada una red dirigida $G = (V, A, \mathbf{c})$ donde deseamos hallar el camino mínimo del nodo s al nodo t:

1. Escribir el modelo primal de flujo de coste mínimo de 1 unidad.
2. Demostrar formalmente por qué la matriz de incidencia nodo-arco $\mathbf{A}$ es totalmente unimodular (TUM) y qué implicación tiene esto sobre las soluciones del programa lineal continuo.
3. Formular el problema dual de programación lineal e interpretar físicamente las variables duales u_i como potenciales nodales.

Ejercicio 5: Algoritmo de Floyd-Warshall entre todos los pares

Dado el digrafo de 4 vértices $V = \{1, 2, 3, 4\}$ con matriz de distancias directas inicial $D^{(0)}$:

$$D^{(0)} = \begin{pmatrix} 0 & 3 & 8 & \infty \\ \infty & 0 & \infty & 1.7 \\ \infty & 4 & 0 & \infty \\ 2 & \infty & -5 & 0 \end{pmatrix}$$

Se pide:

1. Aplicar el Algoritmo de Floyd-Warshall calculando secuencialmente las matrices $D^{(1)}, D^{(2)}, D^{(3)}, D^{(4)}$.
2. Construir la matriz de reconstrucción de rutas $P^{(4)}$.
3. Determinar la distancia mínima y el camino elemental óptimo para conectar el par de nodos $(3, 1)$.

Ejercicios del Tema 8: flujos en redes

Ejercicio 1: Formulación en Programación Lineal y Propiedades del Flujo Máximo

Considérese la red de transporte dirigida $G = (V, U, \mathbf{c})$ de $n = 5$ vértices $V = \{s, 1, 2, 3, t\}$ con las siguientes capacidades acotadas en sus 7 arcos:

$$c_{s1} = 8, \quad c_{s2} = 6, \quad c_{12} = 3, \quad c_{13} = 4, \quad c_{23} = 2, \quad c_{1t} = 5, \quad c_{3t} = 7$$

Se pide:

1. Formular el programa lineal primal de flujo máximo $\max f_0$ definiendo la matriz de incidencia nodo-arco $\mathbf{A}$ y el sistema de conservación de flujo para vértices intermedios $\mathbf{Ax} = \mathbf{0}$.
2. Formular el problema dual continuo e interpretar físicamente las variables duales nodales $u_i \in \mathbb{R}$ y los multiplicadores de capacidad $w_{ij} \geq 0$.
3. Demostrar algebraicamente por el Teorema de Dualidad Fuerte la equivalencia exacta $f_0^* = C(w^+(S))$, justificando por qué el Teorema del Flujo Máximo - Corte Mínimo es la manifestación directa de la dualidad lineal.
4. Resolver analíticamente el modelo obteniendo la asignación óptima de flujos x_{ij}^*, el valor del flujo máximo f_0^* y la partición del corte de capacidad mínima (S, T).

Ejercicio 2: Algoritmo de Etiquetado Dinámico de Ford-Fulkerson paso a paso

Dada la red de transporte dirigida $G = (V, U, \mathbf{c})$ con 5 vértices $V = \{s, a, b, c, t\}$ y capacidades acotadas:

$$c_{sa} = 5, \quad c_{sb} = 4, \quad c_{ab} = 2, \quad c_{ac} = 4, \quad c_{bc} = 1, \quad c_{at} = 3, \quad c_{ct} = 6$$

Se pide:

1. Iniciar el procedimiento desde la solución de flujo nulo $\mathbf{f}^0 = \mathbf{0}$ para $f_0 = 0$.
2. Desarrollar paso a paso cada iteración del algoritmo de etiquetado dinámico de Ford-Fulkerson, indicando en cada paso el camino de aumento seleccionado en el grafo residual $G(\mathbf{f}^k)$, la capacidad residual Δ_k y la actualización de marcas $[\pm i, \Delta(j)]$.
3. Identificar la iteración de parada por imposibilidad de etiquetar el sumidero t.
4. Caracterizar el conjunto de nodos alcanzables $S = N$ y determinar los arcos que componen el corte de capacidad mínima $w^+(S)$ con su capacidad total.

Ejercicio 3: Criterios de Optimalidad y Eliminación de Circuitos Negativos en Flujo de Coste Mínimo

Considérese la red de 4 vértices $V = \{s, 1, 2, t\}$ con arcos, capacidades c_{ij} y costes unitarios de transporte $p_{ij} \in \mathbb{R}$:

$$(s,1) : c_{s1} = 3, p_{s1} = 2; \quad (s,2) : c_{s2} = 2, p_{s2} = 4; \quad (1,2) : c_{12} = 2, p_{12} = -3;$$
$$(2,1) : c_{21} = 1, p_{21} = 1; \quad (1,t) : c_{1t} = 3, p_{1t} = 1; \quad (2,t) : c_{2t} = 2, p_{2t} = 2$$

Se pide:

1. Probar la validez del Teorema 1 de optimalidad: un flujo de valor ν es de coste mínimo si y solo si $G(\mathbf{f})$ no contiene circuitos incrementales de coste negativo.
2. Dada la solución compatible inicial de prueba $\mathbf{f}^0$ con $f^0_{s2} = 2, f^0_{21} = 1, f^0_{1t} = 2$ (y cero en el resto), construir su grafo residual $G(\mathbf{f}^0)$ e identificar un circuito residual de coste negativo C_1.
3. Calcular la capacidad residual máxima δ_1 del circuito C_1, hacer circular dicho flujo y calcular la reducción exacta de coste total $C(\mathbf{f}^1) - C(\mathbf{f}^0)$.
4. Demostrar que el nuevo flujo $\mathbf{f}^1$ no contiene circuitos de coste negativo en $G(\mathbf{f}^1)$.

Ejercicio 4: Crecimiento Iterativo por Caminos Mínimos (Teorema 2)

Dada la red de transporte dirigida de 5 nodos $V = \{s, a, b, c, t\}$ con capacidades c_{ij} y costes unitarios p_{ij}:

$$(s,a) : c_{sa} = 3, p_{sa} = 3; \quad (s,b) : c_{sb} = 3, p_{sb} = 1; \quad (a,c) : c_{ac} = 2, p_{ac} = 2;$$

$$(b,c) : c_{bc} = 2, p_{bc} = 5; \quad (b,t) : c_{bt} = 4, p_{bt} = 2; \quad (c,t) : c_{ct} = 3, p_{ct} = 1$$

Se desea transmitir un caudal total de $\nu = 4$ unidades desde la fuente s al sumidero t al menor coste posible.

Se pide:

1. Partir del flujo óptimo inicial $\mathbf{f}^0 = \mathbf{0}$ para $\nu_0 = 0$.
2. Encontrar en cada iteración la cadena de incremento de coste residual mínimo desde s a t en el grafo de distancias residual $G(\mathbf{f}^k)$.
3. Calcular el incremento óptimo $\Delta_k = \min\{c(\mu_k), \nu - f_0\}$ y actualizar el flujo y los arcos inversos.
4. Construir la tabla completa de evoluciones de caudal f_0, coste acumulado $C(\mathbf{f}^k)$ y verificación de optimalidad para el volumen objetivo $\nu = 4$.

Ejercicio 5: El Problema del Transbordo y Reducción Unificada de Problemas de Redes

Considérese el problema de transbordo en una red dirigida $G = (V, U)$ con n nodos, m arcos, balances nodales $b_i \in \mathbb{R}$ y capacidades $\ell_{ij} \leq f_{ij} \leq c_{ij}$.

Se pide:

1. Demostrar analíticamente que si la red está en equilibrio ($\sum_{i=1}^{n} b_i = 0$), el sistema de ecuaciones de conservación de flujo $\mathbf{Af} = \mathbf{b}$ posee rango $n - 1$.
2. Formular la matriz de incidencia nodo-arco $\mathbf{A}$ y mostrar su estructura de unos y menos unos (+1 en arcos salientes, -1 en arcos entrantes).
3. Demostrar formalmente la reducción unificada de un problema de Transporte bipartito a un modelo de Transbordo equivalente introduciendo nodos intermedios de paso.
4. Explicar cómo la propiedad de unimodularidad total (TUM) de la matriz de incidencia $\mathbf{A}$ garantiza soluciones enteras óptimas $\mathbf{f}^* \in \mathbb{Z}^m$ siempre que los balances nodales b_i y las cotas de capacidad ℓ_{ij}, c_{ij} sean enteros.

Ejercicios del Tema 9: emparejamientos en redes

Ejercicio 1: Formulación en Programación Entera y Propiedades Algebraicas del Emparejamiento

Considérese un grafo simple no dirigido $G = (V, E)$ con $n = |V|$ vértices y $m = |E|$ aristas. Se define un emparejamiento como un subconjunto de aristas $K \subseteq E$ tal que ningún par de aristas en K comparte vértices en común.

Se pide:

1. Formular el problema de emparejamiento de máximo cardinal como un programa lineal entero (PLE) definiendo variables binarias $x_e \in \{0, 1\}$ para cada arista $e \in E$, la función objetivo y las restricciones de grado nodal en $\delta(v)$.
2. Demostrar formalmente que la familia de todos los emparejamientos de G, denotada por $\mathcal{J} = \{K \subseteq E \mid K \text{ es emparejamiento}\}$, satisface los axiomas de un complejo simplicial o complejo de independencia (propiedad de hereditariedad).
3. Diferenciar con rigor teórico entre un **emparejamiento maximal** (óptimo local respecto a la inclusión de aristas) y un **emparejamiento de máximo cardinal** (óptimo global). Proporcionar un contraejemplo mínimo sobre el camino de cuatro vértices P_4 donde un emparejamiento maximal no sea de máximo cardinal.
4. Demostrar analíticamente que el cardinal de cualquier emparejamiento K en un grafo de n vértices satisface la cota universal $|K| \leq \lfloor n/2 \rfloor$, y justificar por qué la condición de paridad (n par) es un requisito necesario (aunque no suficiente) para la existencia de un emparejamiento perfecto.

Ejercicio 2: Cadenas Incrementales, Operación de Transferencia y Teorema de Berge

Considérese el grafo no dirigido $G = (V, E)$ de $n = 8$ vértices $V = \{1, 2, 3, 4, 5, 6, 7, 8\}$ con aristas:

$$E = \{\{1,2\},\ \{1,3\},\ \{2,4\},\ \{3,4\},\ \{3,5\},\\ \{4,6\},\ \{5,6\},\ \{5,7\},\ \{6,8\},\ \{7,8\}\}$$

Partiendo del emparejamiento inicial no maximal de 2 aristas:

$$K_0 = \{\{1,3\},\ \{6,8\}\}$$

Se pide:

1. Clasificar el estado de todos los vértices del grafo respecto de K_0, identificando el conjunto de vértices saturados V_{sat} y el conjunto de vértices expuestos V_{exp}.
2. Identificar una cadena alternante elemental μ cuyos dos extremos pertenezcan a V_{exp} (cadena alternante incremental).
3. Aplicar formalmente la operación de transferencia algebraica mediante la diferencia simétrica $K_1 = K_0 \triangle \mu$, verificando que K_1 es un emparejamiento válido y que su cardinal satisface $|K_1| = |K_0| + 1 = 3$.
4. Enunciar y demostrar el Teorema fundamental de caracterización de Berge (1957), analizando la estructura topológica del grafo diferencia simétrica $H = (V, K \triangle K^*)$ entre un emparejamiento K y un emparejamiento óptimo K^*.

Ejercicio 3: Árboles Alternantes en Grafos Bipartitos y Detección de Cadenas Incrementales

Considérese el grafo bipartito $G = (V_1 \cup V_2, E)$ con partición de vértices $V_1 = \{1,2,3,4,5\}$ y $V_2 = \{6,7,8,9,10\}$, cuyas aristas son:

$$E = \{\{1,6\},\ \{1,7\},\ \{2,7\},\ \{2,8\},\ \{3,8\},\\ \{3,9\},\ \{4,8\},\ \{4,10\},\ \{5,9\},\ \{5,10\}\}$$

Se dispone del emparejamiento inicial $K_1 = \{\{2,7\},\ \{3,8\},\ \{5,10\}\}$ con $|K_1| = 3$.

Se pide:

1. Identificar el conjunto de raíces $R \subset V_1 \cup V_2$ formado por los vértices no saturados respecto de K_1.
2. Desarrollar la construcción del árbol alternante con raíz en el vértice expuesto $i_0 = 1$, especificando en cada nivel los vértices de paridad par (Y^0) e impar (Y^1) y las aristas incorporadas al árbol (T).

3. Construir el vector de antecesores/padres $\mathbf{p} \in \mathbb{N}^{10}$ tras la exploración completa del árbol desde la raíz 1.
4. Desenrollar mediante el vector $\mathbf{p}$ todas las cadenas incrementales que alcanzan vértices expuestos, seleccionar una cadena μ y ejecutar la transferencia para obtener un nuevo emparejamiento aumentado K_2 de cardinal 4.
5. Aplicar una segunda fase del algoritmo de árbol alternante sobre los vértices expuestos restantes hasta certificar la existencia de un emparejamiento perfecto de cardinal 5 o demostrar maximalidad.

Ejercicio 4: Algoritmo de Flor de Edmonds (Blossom Algorithm) y Ciclos Impares

Considérese el grafo no dirigido no bipartito $G = (V, E)$ de $n = 7$ vértices $V = \{1, 2, 3, 4, 5, 6, 7\}$ con aristas:

$$E = \big\{\{1,2\},\, \{2,3\},\, \{3,4\},\, \{4,5\},\, \{5,1\},\, \{3,6\},\, \{6,7\}\big\}$$

y el emparejamiento inicial $K = \big\{\{1,2\},\, \{3,4\}\big\}$ con $|K| = 2$.

Se pide:

1. Explicar por qué la presencia de ciclos impares en grafos generales no bipartitos impide la aplicación directa del algoritmo de árboles alternantes estándar de grafos bipartitos.
2. Iniciar el Algoritmo de Flor de Edmonds construyendo el árbol alternante desde el vértice expuesto $i_0 = 5$:
   - Identificar la extensión del árbol mediante aristas saturadas (Paso C.2, Caso 2).
   - Detectar la existencia de una arista $\{i, j\} \in E$ que une dos vértices pares $i, j \in Y^0$ y caracterizar la flor (ciclo impar) W resultante (Paso C.2, Caso 1).
3. Realizar la contracción del ciclo impar W en un supernodo w, especificando los conjuntos de vértices y aristas del grafo comprimido G/W.
4. Explorar el grafo comprimido G/W, detectar la cadena incremental que conecta con el vértice expuesto 7 y realizar la transferencia en G/W.
5. Ejecutar la descompresión determinista de la flor W aplicando el Teorema de Edmonds (1965) y reconstruir el emparejamiento óptimo final K^* sobre el grafo original G, indicando su cardinalidad y si es perfecto.

Ejercicio 5: Recubrimiento de Aristas, Dualidad de Gallai y Emparejamientos Ponderados

Considérese el grafo simple conexo $G = (V, E)$ de $n = 6$ vértices $V = \{1, 2, 3, 4, 5, 6\}$ con los siguientes pesos $p(e)$ asignados a sus 8 aristas:

$$p(1,2) = 6, \quad p(1,3) = 4, \quad p(2,4) = 5, \quad p(3,4) = 7,$$
$$p(3,5) = 3, \quad p(4,6) = 8, \quad p(5,6) = 4, \quad p(2,5) = 2$$

Se pide:

1. **Problema de Recubrimiento de Aristas y Teorema de Gallai**:
   - Definir formalmente el concepto de recubrimiento de aristas (*edge cover*) $F \subseteq E$ y formular su problema de mínimo cardinal en Programación Entera.
   - Enunciar el Teorema de Dualidad de Gallai (1959) demostrando la igualdad fundamental $|K_0| + |F_0| = n$, donde K_0 es un emparejamiento de máximo cardinal y F_0 es un recubrimiento de mínimo cardinal.
   - A partir de un emparejamiento de máximo cardinal del grafo dado, construir constructivamente un recubrimiento de aristas de mínimo cardinal aplicando la regla de Gallai.
2. **Algoritmo de Emparejamiento de Peso Máximo por Cardinalidad Creciente**:
   - Definir el coste reducido $\delta(L)$ de una cadena alternante respecto de un emparejamiento K.
   - Partir de $K^0 = \emptyset$ y obtener iterativamente el emparejamiento de máximo peso para cardinales $m = 1$, $m = 2$ y $m = 3$, detallando en cada paso todas las cadenas alternantes candidatas y sus costes reducidos $\delta(L)$.
   - Indicar el emparejamiento de peso máximo global K^* y su valor total óptimo.

Ejercicios del Tema 10: rutas eulerianas, hamiltonianas y problemas de rutas

Ejercicio 1: Grafos Eulerianos, Teorema de Euler y Algoritmo Constructivo de Cadenas

Considérese el grafo simple no dirigido y conexo $G = (V, E)$ de $n = 7$ vértices $V = \{1, 2, 3, 4, 5, 6, 7\}$ con el siguiente conjunto de 12 aristas:

$$E = \{\{1,2\}, \{1,3\}, \{2,3\}, \{2,4\}, \{2,5\}, \{3,4\}, \\ \{3,5\}, \{4,6\}, \{4,7\}, \{5,6\}, \{5,7\}, \{6,7\}\}$$

cuya secuencia de grados nodales es:

$$d(1) = 2, \quad d(2) = 4, \quad d(3) = 4, \quad d(4) = 4, \quad d(5) = 4, \quad d(6) = 4, \quad d(7) = 2$$

Se pide:

1. **Demostración de paridad**: Demostrar formalmente que en cualquier grafo euleriano no dirigido conexo, todos sus vértices deben tener obligatoriamente grado par, analizando el comportamiento de las aristas incidentes en cada paso de un circuito cerrado.
2. **Caracterización de Euler**: Aplicar el Teorema de Euler para certificar si el grafo G admite un circuito euleriano cerrado.
3. **Traza del algoritmo constructivo**: Desarrollar paso a paso el algoritmo constructivo de cadenas eulerianas:
   - Extraer un primer ciclo simple C_1 que comience y termine en el vértice 1.
   - Identificar las aristas residuales $E \setminus E(C_1)$ y localizar un vértice de contacto con aristas no visitadas.
   - Extraer un segundo ciclo C_2 en el grafo residual y realizar la fusión intercalada $C_1 \oplus C_2$.
   - Repetir el proceso hasta incorporar la totalidad de aristas de E, proporcionando la secuencia ordenada completa de vértices y aristas del recorrido euleriano final.
4. **Generalización a digrafos y caminos abiertos**:

- Enunciar la condición necesaria y suficiente para que un digrafo conexo admita un circuito euleriano dirigido en términos de sus grados de entrada $d^-(v)$ y de salida $d^+(v)$.
- Indicar qué condición de paridad debe cumplirse para que un grafo no dirigido admita una trayectoria euleriana abierta (recorrido que pasa por todas las aristas pero con extremos inicial y final distintos).

Ejercicio 2: Problema del Cartero Chino (CPP) y Matching de Nodos Impares

Considérese la red vial no dirigida y ponderada $G = (V, E, \mathbf{c})$ de $n = 8$ vértices $V = \{1, 2, 3, 4, 5, 6, 7, 8\}$ con las 12 aristas y costes asociados siguientes:

$$\begin{aligned} &c(1,2) = 4, \quad c(1,3) = 6, \quad c(2,3) = 3, \quad c(2,4) = 5, \\ &c(2,5) = 7, \quad c(3,5) = 8, \quad c(4,6) = 4, \quad c(4,7) = 6, \\ &c(5,6) = 5, \quad c(5,7) = 3, \quad c(6,8) = 7, \quad c(7,8) = 4 \end{aligned}$$

Un vehículo de inspección municipal debe partir del depósito situado en el nodo 1, recorrer cada calle de la red al menos una vez y regresar al depósito minimizando la distancia total recorrida.

Se pide:

1. **Identificación de paridades y vértices impares**: Calcular el grado de cada vértice $d(v)$ y determinar el conjunto de vértices con grado impar $V_{odd} \subset V$. Justificar analíticamente por qué $|V_{odd}|$ es siempre un número par.
2. **Matriz de distancias mínimas en V_{odd}**: Calcular la distancia más corta $d_G(u, v)$ para cada par de vértices en V_{odd} especificando el camino mínimo correspondiente.
3. **Emparejamiento perfecto de peso mínimo**: Construir el grafo completo auxiliar $K_{|V_{odd}|}$, enumerar todos los emparejamientos perfectos posibles, calcular el coste total de cada uno y seleccionar el emparejamiento óptimo M^*.
4. **Eulerización y coste óptimo del CPP**:
   - Construir el multigrafo euleriano G^* duplicando las aristas de los caminos mínimos asociados a M^*.
   - Calcular la longitud total de la ruta óptima del cartero chino $c(CPP) = \sum_{e \in E} c(e) + c(M^*)$.
   - Escribir una secuencia ordenada explícita de vértices que constituya un recorrido óptimo cerrado del cartero chino comenzando y terminando en el depósito 1.

Ejercicio 3: Grafos Hamiltonianos, Condiciones de Dirac, Ore y Clausura de Bondy-Chvátal

Considérese el grafo simple no dirigido $G = (V, E)$ de $n = 6$ vértices $V = \{1, 2, 3, 4, 5, 6\}$ con el siguiente conjunto de aristas:

$$E = \{\{1,2\},\ \{1,3\},\ \{1,4\},\ \{2,3\},\ \{2,5\},\ \{3,4\},\ \{3,6\},\ \{4,5\},\ \{5,6\}\}$$

Se pide:

1. **Condición de Dirac (1952)**:
   - Calcular los grados de todos los vértices de G y comprobar si se cumple la condición suficiente de Dirac: $d(v) \geq \frac{n}{2}, \quad \forall v \in V$.
   - ¿Permite el Teorema de Dirac asegurar que G es hamiltoniano? Justificar la respuesta.
2. **Condición de Ore (1960)**:
   - Identificar todos los pares de vértices no adyacentes $\{u, v\} \notin E$ y calcular la suma de sus grados $d(u) + d(v)$.
   - Comprobar si se satisface la condición suficiente de Ore: $d(u)+d(v) \geq n, \quad \forall \{u, v\} \notin E$.
3. **Clausura de Bondy-Chvátal (1976)**:
   - Describir el algoritmo determinista para obtener la clausura $[G]$.
   - Aplicar iterativamente el proceso sobre G, detallando las aristas que se añaden en cada paso en función de la suma de grados actualizados hasta alcanzar el punto fijo $[G]$.
   - Enunciar el Teorema de Bondy-Chvátal y concluir rigurosamente si G es un grafo hamiltoniano.
4. **Discusión sobre necesidad vs. suficiencia**:
   - Explicar por qué las condiciones de Dirac, Ore y Bondy-Chvátal son condiciones suficientes pero no necesarias.
   - Proporcionar un ejemplo de grafo que sea hamiltoniano pero cuya clausura $[G]$ no sea el grafo completo K_n (por ejemplo, el ciclo simple C_n con $n \geq 5$).

Ejercicio 4: Modelos de Programación Lineal Entera (PLE) para el Problema del Viajante de Comercio (TSP)

Considérese el Problema del Viajante de Comercio (TSP) definido sobre una red dirigida completa $G = (V, A)$ con conjunto de vértices $V = \{1, 2, \dots, n\}$ y matriz de costes de desplazamiento $C = (c_{ij})$.

Se pide:

1. **Modelo 1 por etapas**:
   - Formular el modelo de asignación por etapas definiendo variables binarias $x_{ijk} \in \{0, 1\}$ (indicando si el arco (i, j) se recorre en la etapa $k \in \{1, \dots, n\}$).
   - Escribir formalmente la función objetivo y los tres bloques de restricciones (asignación espacial, asignación temporal y continuidad secuencial).
   - Evaluar el número total de variables y restricciones del modelo en función de n.
2. **Modelo 2 de Dantzig-Fulkerson-Johnson (DFJ)**:
   - Formular el modelo clásico de 2 índices con variables $x_{ij} \in \{0, 1\}$.
   - Escribir las restricciones de grado nodal (conservación) y las restricciones de eliminación de subciclos (SEC, *Subtour Elimination Constraints*) en su formulación de corte conjuntista:

$$\sum_{i \in S} \sum_{j \in S, j \neq i} x_{ij} \leq |S| - 1, \quad \forall S \subset V,\ 2 \leq |S| \leq n - 1$$

   - Demostrar que el número total de restricciones SEC es $2^n - 2$ y explicar por qué este modelo se resuelve en la práctica mediante algoritmos de planos de corte y generación perezosa de restricciones (*lazy constraints*).
3. **Modelo 3 de Miller-Tucker-Zemlin (MTZ)**:
   - Formular el modelo compacto MTZ introduciendo variables continuas auxiliares de orden $u_i \in \mathbb{R}$ para $i \in \{2, \dots, n\}$.
   - Demostrar analíticamente que la desigualdad:

$$u_i - u_j + n x_{ij} \leq n - 1, \quad \forall i, j \in \{2, \dots, n\},\ i \neq j$$

     impide la existencia de cualquier subciclo cerrado que no pase por el depósito central 1.
   - Comparar la complejidad en número de restricciones del modelo MTZ frente al modelo DFJ.

Ejercicio 5: Algoritmo de Aproximación de Christofides, Heurística 2-Opt y Taxonomía del VRP

Considérese un problema del Viajante de Comercio métrico simétrico definido sobre $n = 5$ vértices $V = \{1, 2, 3, 4, 5\}$ con matriz de distancias euclídeas:

$$\mathbf{D} = \begin{pmatrix} 0 & 2 & 4 & 5 & 3 \\ 2 & 0 & 3 & 4 & 4 \\ 4 & 3 & 0 & 2 & 3 \\ 5 & 4 & 2 & 0 & 2 \\ 3 & 4 & 3 & 2 & 0 \end{pmatrix}$$

Se pide:

1. **Algoritmo de aproximación de Christofides**:
   - Calcular el Árbol Soporte de Mínimo Peso (T_{MST}) sobre el grafo completo mediante el algoritmo de Kruskal o Prim, indicando su coste total.
   - Identificar el subconjunto de vértices $V_{odd} \subset V$ que tienen grado impar en T_{MST}.
   - Calcular el emparejamiento perfecto de peso mínimo M^* inducido sobre V_{odd}.
   - Construir el multigrafo euleriano $H = T_{MST} \cup M^*$, determinar un circuito euleriano cerrado sobre H y aplicar atajos (*shortcuts*) para obtener un tour hamiltoniano $T_{Christofides}$.
   - Demostrar teóricamente por qué el algoritmo de Christofides garantiza un factor de aproximación $\frac{3}{2}$ respecto al coste del tour óptimo T^*, analizando las cotas $c(T_{MST}) < c(T^*)$ y $c(M^*) \leq \frac{1}{2}c(T^*)$.
2. **Heurística de mejora local 2-Opt**:
   - Partiendo del tour inicial no óptimo $T_0 = (1, 3, 2, 4, 5, 1)$, calcular su coste total.
   - Evaluar el movimiento 2-Opt que sustituye el par de aristas no adyacentes $(\{1, 3\}, \{2, 4\})$ por el par $(\{1, 2\}, \{3, 4\})$, calculando la variación neta de distancia Δc.
   - Describir cómo invierte este operador la orientación del subcamino intermedio para generar el nuevo tour admisible.
3. **Taxonomía del Problema de Rutas de Vehículos (VRP)**:
   - Explicar la diferencia fundamental entre problemas de rutas por arcos (*Arc Routing*) y rutas por nodos (*Node Routing*), citando ejemplos prácticos de aplicación en ingeniería logística.
   - Describir las 6 dimensiones operativas que caracterizan un problema de rutas de vehículos en la industria: composición de flota, configuración de depósitos, tipo de demanda, modalidad de transporte, ventanas de tiempo y criterios de optimización.

PARTE V

Problemas y Ejercicios Resueltos

Solucionario detallado con deducciones formales, tablas numéricas y comprobaciones analíticas

> Cuaderno completo de soluciones comentadas minuciosamente paso a paso. Proporciona las resoluciones exhaustivas de los boletines de ejercicios, detallando las iteraciones algebraicas, tablas pivote del método Símplex y comprobaciones analíticas que guían al estudiante en su proceso de aprendizaje autónomo.

Víctor Aceña Gil · Antonio Alonso Ayuso
CC BY-SA 4.0 Internacional · Curso 2026-2027

Índice de Soluciones

Introducción **5**

Ejercicios Tema 1: Introducción a la investigación operativa **6**
Ejercicio 1: modelado, ciclo de vida e historia 6
Ejercicio 2: formulación matemática y clasificación de modelos 8

Ejercicios del Tema 2: optimización no lineal y métodos numéricos **11**
Ejercicio 1: duopolio de Cournot con costes cuadráticos 11
Ejercicio 2: caracterización de curvatura y convexidad 14
Ejercicio 3: clasificación de puntos estacionarios 16
Ejercicio 4: trazado de búsqueda áurea y Newton 1D 18
Ejercicio 5: coordenadas cíclicas: optimización por direcciones ortogonales 20
Ejercicio 6: máximo descenso: invarianza ortogonal y trazado 22
Ejercicio 7: Newton multivariante: convergencia cuadrática 24

Ejercicios del Tema 3: análisis convexo **27**
Ejercicio 1: combinaciones convexas y conjuntos convexos 27
Ejercicio 2: operaciones algebraicas que preservan la convexidad 28
Ejercicio 3: puntos extremos y teorema de Minkowski-Weyl 30
Ejercicio 4: caracterización de primer orden de funciones convexas 33
Ejercicio 5: caracterización de segundo orden de la curvatura 35
Ejercicio 6: epígrafe, subgradientes y subdiferencial 38
Ejercicio 7: convexidad generalizada: funciones cuasiconvexas y pseudoconvexas . . . 40

Ejercicios del Tema 4: condiciones de optimalidad y KKT **43**
Ejercicio 1: clasificación de puntos estacionarios sin restricciones 43
Ejercicio 2: criterio de derivadas de orden superior (caso univariante) 47
Ejercicio 3: conos de direcciones factibles y de descenso 49
Ejercicio 4: condiciones de Fritz-John y fallo de LICQ 52
Ejercicio 5: resolución KKT completa con análisis por casos 54
Ejercicio 6: KKT y condiciones de suficiencia bajo convexidad 59
Ejercicio 7: KKT con restricciones mixtas (igualdad y desigualdad) 61
Ejercicio 8: análisis combinatorio de Fritz-John en región mixta 64

Ejercicios del Tema 5: dualidad KKT en programación lineal y cuadrática **67**
Ejercicio 1: formulación KKT, dualidad e interpretación de precios sombra en LP . . 67

Ejercicio 2: degeneración, sobredeterminación y relaciones de dualidad 70
Ejercicio 3: derivación analítica del sistema KKT en programación cuadrática (QP) 72
Ejercicio 4: aplicación iterativa del algoritmo del Símplex de Wolfe 76

Ejercicios del Tema 6: grafos y árboles soporte de mínimo peso 79
Ejercicio 1: fundamentos de grafos, digrafos y lema de la suma de grados 79
Ejercicio 2: tipología de grafos, subgrafos y grafos complementarios 82
Ejercicio 3: recorridos, cadenas, caminos y métricas de red 84
Ejercicio 4: estructura de árboles, bosques y caracterizaciones equivalentes 85
Ejercicio 5: planaridad, fórmula de Euler y teorema de Kuratowski 87
Ejercicio 6: Algoritmo de Kruskal, matroides y propiedad del corte 89
Ejercicio 7: Algoritmo de Prim, árboles de caminos mínimos y comparativa con el problema del camino mínimo (Dijkstra) 91
Ejercicio 8: aplicación en aprendizaje no supervisado: clustering basado en MST . . 94

Ejercicios del Tema 7: problema del camino mínimo 96
Ejercicio 1: Ecuaciones de Bellman y ordenación topológica en DAGs 96
Ejercicio 2: Algoritmo de Dijkstra paso a paso 98
Ejercicio 3: Algoritmo de Bellman-Ford y detección de ciclos de coste negativo . . . 100
Ejercicio 4: Formulación en Programación Lineal Primal-Dual 102
Ejercicio 5: Algoritmo de Floyd-Warshall entre todos los pares 103

Ejercicios del Tema 8: flujos en redes 106
Ejercicio 1: Formulación en Programación Lineal y Propiedades del Flujo Máximo . 106
Ejercicio 2: Algoritmo de Etiquetado Dinámico de Ford-Fulkerson paso a paso . . . 109
Ejercicio 3: Criterios de Optimalidad y Eliminación de Circuitos Negativos en Flujo de Coste Mínimo 111
Ejercicio 4: Crecimiento Iterativo por Caminos Mínimos (Teorema 2) 113
Ejercicio 5: El Problema del Transbordo y Reducción Unificada de Problemas de Redes 115

Ejercicios del Tema 9: emparejamientos en redes 117
Ejercicio 1: Formulación en Programación Entera y Propiedades Algebraicas del Emparejamiento 117
Ejercicio 2: Cadenas Incrementales, Operación de Transferencia y Teorema de Berge 119
Ejercicio 3: Árboles Alternantes en Grafos Bipartitos y Detección de Cadenas Incrementales 122
Ejercicio 4: Algoritmo de Flor de Edmonds (Blossom Algorithm) y Ciclos Impares . 125
Ejercicio 5: Recubrimiento de Aristas, Dualidad de Gallai y Emparejamientos Ponderados 128

Ejercicios del Tema 10: rutas eulerianas, hamiltonianas y problemas de rutas 132
Ejercicio 1: Grafos Eulerianos, Teorema de Euler y Algoritmo Constructivo de Cadenas 132
Ejercicio 2: Problema del Cartero Chino (CPP) y Matching de Nodos Impares . . . 135

Ejercicio 3: Grafos Hamiltonianos, Condiciones de Dirac, Ore y Clausura de Bondy-Chvátal 138
Ejercicio 4: Modelos de Programación Lineal Entera (PLE) para el Problema del Viajante de Comercio (TSP) 141
Ejercicio 5: Algoritmo de Aproximación de Christofides, Heurística 2-Opt y Taxonomía del VRP 144

Introducción

Este cuaderno recopila las **soluciones detalladas** a los ejercicios propuestos para la asignatura **Optimización y Análisis de Redes**.

Cada ejercicio contiene tanto la demostración matemática formal como la implementación de código en Python correspondiente para verificar las soluciones de manera numérica.

Ejercicios Tema 1: Introducción a la investigación operativa

Ejercicio 1: modelado, ciclo de vida e historia

1. **El circo de Blackett**: Durante la Segunda Guerra Mundial, el grupo de investigación operativa liderado por Patrick Blackett analizó el tamaño óptimo de los convoyes de barcos mercantes escoltados que cruzaban el Atlántico. Explique el razonamiento matemático y operativo detrás de este problema: ¿por qué los convoyes más grandes resultaban ser más seguros frente a los ataques de submarinos enemigos (U-Boote)? Justifique la relación entre el perímetro del convoy (zona expuesta a ataques) y su área (capacidad de transporte).

   Solución:

   El análisis de Patrick Blackett y su equipo sobre la seguridad de los convoyes navales durante la Segunda Guerra Mundial se basó en una relación geométrica fundamental:

   - **Geometría del convoy**:
     - Si agrupamos los barcos mercantes en una sola gran formación (aproximadamente circular), el **área** del convoy (proporcional al número de barcos que transportan mercancías) crece con el cuadrado del radio: $A \propto R^2$.
     - Sin embargo, el **perímetro** del convoy (la zona expuesta que debe ser protegida por barcos de escolta como destructores) crece linealmente con el radio: $P \propto R$.
   - **Consecuencia de seguridad**:
     - Al duplicar el área del convoy (doble de barcos mercantes), el perímetro expuesto sólo aumenta por un factor de aproximadamente $\sqrt{2} \approx 1.41$, no al doble.
     - Esto significa que un convoy grande requiere **menos escoltas por barco mercante** que varios convoyes pequeños separados.
     - Además, la probabilidad de que un submarino enemigo avistara un convoy grande era casi la misma que la de avistar un convoy pequeño, por lo que agrupar los barcos redujo drásticamente el número de encuentros y pérdidas.

2. **Propósitos de modelización**: En el contexto del diseño y gestión de una red de distribución eléctrica nacional:

   - Dé un ejemplo de **modelo físico/icónico**.

- Dé un ejemplo de **modelo descriptivo**.
- Dé un ejemplo de **modelo predictivo**.
- Dé un ejemplo de **modelo prescriptivo**.

Solución:

- **Modelo físico/icónico**: Una maqueta a escala de una subestación eléctrica para ensayar la distribución espacial física de los transformadores y cables de alta tensión.
- **Modelo descriptivo**: Un diagrama unifilar que representa el estado actual de las líneas de transporte y subestaciones, mostrando el flujo de potencia instantáneo en cada línea para responder a: *¿dónde hay sobrecarga hoy?*
- **Modelo predictivo**: Un modelo de regresión o red neuronal que estima la demanda eléctrica nacional para las próximas 24 horas basándose en la temperatura prevista y el día de la semana.
- **Modelo prescriptivo**: Un modelo de optimización (despacho económico de energía) que determina qué centrales generadoras deben encenderse y a qué potencia operar mañana para satisfacer la demanda prevista al menor coste operativo total.

3. **Ciclo de vida en logística**: Una gran cadena de supermercados desea optimizar las rutas de reparto de su flota de camiones para minimizar el consumo de combustible. Describa brevemente qué acciones específicas se llevarían a cabo en cada una de las 4 fases del ciclo de vida del modelado matemático (Observación, Formulación, Validación e Implementación).

   Solución:

   1. **Observación**: Reunirse con los gestores de tráfico, recopilar datos GPS de rutas históricas, consumos medios de combustible por vehículo y coordenadas de los puntos de entrega del supermercado.
   2. **Formulación**: Definir las variables de decisión (si el camión k visita el cliente j después de i), plantear la función objetivo (minimizar kilómetros o consumo equivalente de combustible) y escribir las restricciones (horarios de entrega, capacidad de carga máxima del camión, tiempos de descanso del conductor).
   3. **Validación**: Resolver el modelo para un subconjunto de rutas reales conocidas y contrastar el plan del algoritmo frente al plan histórico del supermercado para comprobar si la solución es realista y si el ahorro estimado es factible.
   4. **Implementación**: Integrar el software de optimización de rutas en la aplicación móvil de los repartidores y en el ERP del centro logístico, formando al personal de planificación.

Ejercicio 2: formulación matemática y clasificación de modelos

Una microcervecería artesanal produce dos tipos de cerveza: una IPA (*India Pale Ale*) y una Stout. Para la elaboración de cada hectolitro (hl) se consumen recursos limitados según la siguiente tabla:

Cerveza	Malta (kg)	Lúpulo (kg)	Tiempo fermentación (días)
IPA	15	4	2
Stout	20	2	3
Disponibilidad	300 kg	50 kg	45 días-fermentador

El beneficio neto de la venta de un hectolitro de IPA es de 150 € y el de Stout es de 120 €.

Se pide:

1. **Formulación lineal**: Plantear el modelo de optimización matemática para maximizar el beneficio neto de la microcervecería. Defina con precisión las variables de decisión, la función objetivo y todas las restricciones operativas. Clasifique este modelo según los criterios tradicionales de optimización.

   Solución:

   Definimos las variables de decisión:

   - x_1: Hectolitros (hl) de cerveza IPA a producir.
   - x_2: Hectolitros (hl) de cerveza Stout a producir.

   Formulación del modelo:

   $$\begin{aligned} \max_{x_1,x_2\in\mathbb{R}} \quad & Z = 150x_1 + 120x_2 \\ \text{sujeto a} \quad & 15x_1 + 20x_2 \leq 300 \\ & 4x_1 + 2x_2 \leq 50 \\ & 2x_1 + 3x_2 \leq 45 \\ & x_1, x_2 \geq 0 \end{aligned}$$

   Clasificación del modelo:

   - **Linealidad**: Modelo de Programación Lineal (LP), ya que tanto la función objetivo como todas las restricciones son funciones lineales.
   - **Dominio**: Programación continua (o real) en $\mathbb{R}^2$ (asumiendo que los hectolitros se pueden fraccionar).

- **Determinismo**: Modelo determinista (todos los parámetros son conocidos y no estocásticos).

2. **Formulación no lineal con descuento por volumen**: Suponga ahora que el mercado es sensible a la cantidad producida, de modo que, para dar salida a un mayor volumen de producto, la microcervecería debe aplicar promociones. Esto provoca que el beneficio unitario de cada cerveza disminuya linealmente a medida que aumenta su producción total:

   - Para la cerveza IPA, el beneficio unitario base (150 €) se penaliza reduciéndose a razón de 2 € por cada hectolitro de IPA que se fabrique en total.
   - Para la cerveza Stout, el beneficio unitario base (120 €) se penaliza reduciéndose a razón de 3 € por cada hectolitro de Stout que se fabrique en total.

   Formule el nuevo problema de optimización para maximizar el beneficio total de la microcervecería y clasifíquelo nuevamente según su linealidad.

   Solución:

   Deducimos las expresiones analíticas del beneficio unitario a partir de la descripción verbal:

   - Beneficio unitario de IPA: parte de la base de 150 € y disminuye a razón de 2 € por hectolitro x_1, resultando en $(150 - 2x_1)$ €/hl.
   - Beneficio unitario de Stout: parte de la base de 120 € y disminuye a razón de 3 € por hectolitro x_2, resultando en $(120 - 3x_2)$ €/hl.

   Formulación del modelo:

$$\begin{aligned} \max_{x_1, x_2 \in \mathbb{R}} \quad & Z(x_1, x_2) = -2x_1^2 + 150x_1 - 3x_2^2 + 120x_2 \\ \text{sujeto a} \quad & 15x_1 + 20x_2 \leq 300 \\ & 4x_1 + 2x_2 \leq 50 \\ & 2x_1 + 3x_2 \leq 45 \\ & x_1, x_2 \geq 0 \end{aligned}$$

   Clasificación del modelo:

   - **Linealidad**: Modelo de Programación No Lineal (NLP), debido a que la función objetivo contiene términos cuadráticos (es cóncava cuadrática).
   - **Dominio**: Continuo.
   - **Determinismo**: Determinista.

Verificación computacional mediante Python:

Podemos resolver el modelo cuadrático utilizando `scipy.optimize` en Python:

```python
import numpy as np
from scipy.optimize import minimize

# Definimos la función objetivo a minimizar (negativo del beneficio para maximizar)
def objective(x):
    return -(-2 * x[0]**2 + 150 * x[0] - 3 * x[1]**2 + 120 * x[1])

# Definimos las restricciones g_i(x) <= 0
constraints = [
    {'type': 'ineq', 'fun': lambda x: 300 - (15 * x[0] + 20 * x[1])},
    {'type': 'ineq', 'fun': lambda x: 50 - (4 * x[0] + 2 * x[1])},
    {'type': 'ineq', 'fun': lambda x: 45 - (2 * x[0] + 3 * x[1])}
]

# Límites de no negatividad
bounds = [(0, None), (0, None)]

# Punto de inicio
x0 = [0, 0]

# Resolver
res = minimize(objective, x0, method='SLSQP', bounds=bounds, constraints=constraints)

print("--- SOLUCIÓN DE VERIFICACIÓN ---")
print(f"Estado de la optimización: {res.message}")
print(f"Cantidad IPA (hl) óptima x1: {round(res.x[0], 4)} hl")
print(f"Cantidad Stout (hl) óptima x2: {round(res.x[1], 4)} hl")
print(f"Beneficio máximo total: {round(-res.fun, 2)} €")
```

```
--- SOLUCIÓN DE VERIFICACIÓN ---
Estado de la optimización: Optimization terminated successfully
Cantidad IPA (hl) óptima x1: 8.0 hl
Cantidad Stout (hl) óptima x2: 9.0 hl
Beneficio máximo total: 1909.0 €
```

Ejercicios del Tema 2: optimización no lineal y métodos numéricos

Ejercicio 1: duopolio de Cournot con costes cuadráticos

Dos empresas competidoras, Empresa 1 y Empresa 2, producen un bien de consumo homogéneo. La función de demanda inversa de mercado viene dada por:

$$P(Q) = 20 - Q$$

donde $Q = Q_1 + Q_2$ es la producción total acumulada en el mercado. Las funciones de coste total de cada empresa son cuadráticas y se definen como:

$$C_1(Q_1) = 2Q_1 + \frac{1}{2}Q_1^2 \qquad \text{y} \qquad C_2(Q_2) = 3Q_2 + Q_2^2$$

Las producciones están limitadas físicamente por capacidades máximas: $Q_1 \leq 8$ y $Q_2 \leq 6$, y no pueden ser negativas.

1. **Formulación del problema y funciones de reacción**: Formular el problema de optimización individual de cada empresa para maximizar sus beneficios, determinando sus funciones de reacción o mejor respuesta $Q_1^*(Q_2)$ y $Q_2^*(Q_1)$.

   Solución:

2. **Empresa 1**: El beneficio B_1 se define como la diferencia entre los ingresos y el coste total:

   $$B_1(Q_1, Q_2) = P(Q_1 + Q_2) \cdot Q_1 - C_1(Q_1)$$

   $$B_1(Q_1, Q_2) = (20 - Q_1 - Q_2)Q_1 - \left(2Q_1 + \frac{1}{2}Q_1^2\right) = 18Q_1 - \frac{3}{2}Q_1^2 - Q_1Q_2$$

   Para maximizar, derivamos respecto a Q_1 e igualamos a cero (FONC):

   $$\frac{\partial B_1}{\partial Q_1} = 18 - 3Q_1 - Q_2 = 0 \implies 3Q_1 = 18 - Q_2 \implies Q_1^*(Q_2) = 6 - \frac{Q_2}{3}$$

   Como $Q_2 \geq 0$, la función de mejor respuesta de la Empresa 1 satisface $Q_1^*(Q_2) \leq 6 \leq 8$, por lo que la restricción de capacidad máxima $Q_1 \leq 8$ no se satura y se cumple de forma inactiva.

3. **Empresa 2**: Su beneficio B_2 viene dado por:

$$B_2(Q_1, Q_2) = P(Q_1 + Q_2) \cdot Q_2 - C_2(Q_2)$$

$$B_2(Q_1, Q_2) = (20 - Q_1 - Q_2)Q_2 - (3Q_2 + Q_2^2) = 17Q_2 - 2Q_2^2 - Q_1Q_2$$

Derivando respecto a Q_2 e igualando a cero (FONC):

$$\frac{\partial B_2}{\partial Q_2} = 17 - 4Q_2 - Q_1 = 0 \implies 4Q_2 = 17 - Q_1 \implies Q_2^*(Q_1) = 4.25 - \frac{Q_1}{4}$$

De nuevo, dado que $Q_1 \geq 0$, se cumple que $Q_2^*(Q_1) \leq 4.25 \leq 6$, por lo que la restricción $Q_2 \leq 6$ tampoco se satura.

4. **Equilibrio de Cournot-Nash**: Calcular analíticamente el equilibrio de Cournot-Nash del mercado (el punto donde ambas decisiones son óptimas simultáneamente).

Solución:

El equilibrio de Cournot-Nash se encuentra resolviendo el sistema lineal de ecuaciones formado por las dos funciones de reacción:

$$\begin{cases} 3Q_1 + Q_2 = 18 \\ Q_1 + 4Q_2 = 17 \end{cases}$$

Despejando y resolviendo el sistema:

- De la segunda ecuación: $Q_1 = 17 - 4Q_2$.
- Sustituyendo en la primera:

$$3(17 - 4Q_2) + Q_2 = 18 \implies 51 - 12Q_2 + Q_2 = 18 \implies 11Q_2 = 33 \implies Q_2^* = 3$$

- Calculando Q_1:

$$Q_1^* = 17 - 4(3) = 5$$

El **equilibrio de Cournot-Nash** es:

$$(Q_1^*, Q_2^*) = (5, 3)$$

El precio de mercado resultante es:

$$P^* = 20 - (5 + 3) = 12 \text{ u.m.}$$

Los beneficios en el equilibrio de Nash de cada empresa son:

- Empresa 1: $B_1^* = 12 \cdot 5 - 2 \cdot 5 - 0.5 \cdot 5^2 = 60 - 10 - 12.5 = 37.5$ u.m.

- Empresa 2: $B_2^* = 12 \cdot 3 - 3 \cdot 3 - 3^2 = 36 - 9 - 9 = 18$ u.m.

3. **Análisis de la convexidad del beneficio**: Analizar la convexidad de las funciones de beneficio de cada empresa y discutir si el problema de optimización resultante es convexo.

   Solución:

4. **Convexidad del problema individual**: El problema de cada empresa es un problema de maximización de beneficios. En el contexto de optimización, un problema de maximización es convexo si la función objetivo es cóncava y el conjunto factible es convexo (lo cual se cumple ya que los intervalos de producción $[0, 8]$ y $[0, 6]$ son conjuntos convexos). Analicemos la segunda derivada de las funciones de beneficio individuales:

   - Empresa 1: $\frac{\partial^2 B_1}{\partial Q_1^2} = -3 < 0$. Al ser la segunda derivada estrictamente negativa para cualquier punto, B_1 es estrictamente cóncava respecto a Q_1.
   - Empresa 2: $\frac{\partial^2 B_2}{\partial Q_2^2} = -4 < 0$. Por tanto, B_2 es estrictamente cóncava respecto a Q_2.
   - **Conclusión**: Ambos problemas de optimización individuales son estrictamente convexos.

5. **Verificación del equilibrio en Python**: Podemos validar el cálculo y la concavidad de forma simbólica usando el siguiente script en Python:

```python
import sympy as sp

Q1, Q2 = sp.symbols('Q1 Q2')
B1 = (20 - Q1 - Q2)*Q1 - 2*Q1 - 0.5*Q1**2
B2 = (20 - Q1 - Q2)*Q2 - 3*Q2 - Q2**2

# Derivadas parciales de primer orden (FONC)
dB1 = sp.diff(B1, Q1)
dB2 = sp.diff(B2, Q2)

# Resolver sistema para el equilibrio de Nash
eq = sp.solve([dB1, dB2], (Q1, Q2))
print("Equilibrio de Nash (Q1, Q2):", eq)

# Verificar segundas derivadas (Concavidad)
d2B1 = sp.diff(B1, Q1, 2)
d2B2 = sp.diff(B2, Q2, 2)
print("Segunda derivada B1:", d2B1)
print("Segunda derivada B2:", d2B2)
```

```
Equilibrio de Nash (Q1, Q2): {Q1: 5.00000000000000, Q2: 3.00000000000000}
Segunda derivada B1: -3.00000000000000
Segunda derivada B2: -4
```

Ejercicio 2: caracterización de curvatura y convexidad

Analizar la convexidad de las siguientes funciones en sus respectivos dominios utilizando el análisis de la matriz hessiana, calculando sus menores principales o sus autovalores:

1. **Convexidad de $f(x, y) = e^{x^2+y^2}$ definida en $\mathbb{R}^2$**: Analizar la convexidad utilizando el análisis de la matriz hessiana, calculando sus menores principales o sus autovalores.

   Solución:

2. **Gradiente de primer orden**:

$$\frac{\partial f}{\partial x} = 2xe^{x^2+y^2} \qquad \text{y} \qquad \frac{\partial f}{\partial y} = 2ye^{x^2+y^2}$$

3. **Matriz hessiana (H)**: Calculando las segundas derivadas:

$$\frac{\partial^2 f}{\partial x^2} = (2 + 4x^2)e^{x^2+y^2} \qquad \frac{\partial^2 f}{\partial y^2} = (2 + 4y^2)e^{x^2+y^2}$$

$$\frac{\partial^2 f}{\partial x \partial y} = 4xye^{x^2+y^2}$$

   Por lo tanto:

$$H(x, y) = e^{x^2+y^2} \begin{pmatrix} 2 + 4x^2 & 4xy \\ 4xy & 2 + 4y^2 \end{pmatrix}$$

4. **Menores principales**:

   - $M_1 = e^{x^2+y^2}(2 + 4x^2) > 0$ (ya que la función exponencial es siempre estrictamente positiva y $2 + 4x^2 \geq 2$).
   - $M_2 = \det(H) = e^{2(x^2+y^2)} \left[(2 + 4x^2)(2 + 4y^2) - 16x^2y^2\right]$

     $$M_2 = e^{2(x^2+y^2)} \left[4 + 8x^2 + 8y^2 + 16x^2y^2 - 16x^2y^2\right] = e^{2(x^2+y^2)} \left[4 + 8x^2 + 8y^2\right] > 0$$

   - **Conclusión**: Dado que todos los menores principales son estrictamente positivos para cualquier $(x, y) \in \mathbb{R}^2$, la matriz hessiana es definida positiva ($H \succ 0$). Por tanto, la función es **estrictamente convexa** en todo su dominio $\mathbb{R}^2$.

5. **Convexidad de $f(x,y) = 2x^2 - 4xy + y^4$ definida en $\mathbb{R}^2$**: Analizar la convexidad utilizando el análisis de la matriz hessiana, calculando sus menores principales o sus autovalores.

   Solución:

6. **Gradiente**:
$$\frac{\partial f}{\partial x} = 4x - 4y \qquad \text{y} \qquad \frac{\partial f}{\partial y} = -4x + 4y^3$$

7. **Matriz hessiana (H)**:
$$H(x,y) = \begin{pmatrix} 4 & -4 \\ -4 & 12y^2 \end{pmatrix}$$

8. **Menores principales**:

   - $M_1 = 4 > 0$.
   - $M_2 = \det(H) = 48y^2 - 16 = 16(3y^2 - 1)$.
   - **Análisis**: Para que la función sea convexa en su dominio, la hessiana debe ser semidefinida positiva para todo $(x,y) \in \mathbb{R}^2$. Sin embargo, vemos que M_2 depende del valor de la variable y:
   - Si $3y^2 - 1 < 0 \implies |y| < \frac{1}{\sqrt{3}}$, entonces $M_2 < 0$. Al ser el determinante negativo, la matriz es indefinida.
   - **Conclusión**: La función **no es convexa en todo el dominio** $\mathbb{R}^2$ (únicamente exhibe convexidad local en el espacio donde se satisface $|y| \geq \frac{1}{\sqrt{3}}$).

9. **Convexidad de $f(x,y) = -\ln(x) - \ln(y)$ definida en el dominio de valores estrictamente positivos $\mathbb{R}^2_{++}$**: Analizar la convexidad utilizando el análisis de la matriz hessiana, calculando sus menores principales o sus autovalores.

   Solución:

10. **Gradiente**:
$$\frac{\partial f}{\partial x} = -\frac{1}{x} \qquad \text{y} \qquad \frac{\partial f}{\partial y} = -\frac{1}{y}$$

11. **Matriz hessiana (H)**:
$$H(x,y) = \begin{pmatrix} 1/x^2 & 0 \\ 0 & 1/y^2 \end{pmatrix}$$

12. **Menores principales**: En el dominio $\mathbb{R}^2_{++}$ se tiene que:

    - $M_1 = \frac{1}{x^2} > 0$ (ya que $x > 0$).
    - $M_2 = \det(H) = \frac{1}{x^2 y^2} > 0$ (ya que $x, y > 0$).

- **Conclusión**: Al ser los menores principales estrictamente positivos en todo el dominio de definición de la función, la hessiana es definida positiva ($H \succ 0$) y la función es **estrictamente convexa** en $\mathbb{R}^2_{++}$.

13. **Validación en Python (SymPy)**:

```
import sympy as sp

x, y = sp.symbols('x y', real=True)

# Caso 2: f(x, y) = 2x^2 - 4xy + y^4
f2 = 2*x**2 - 4*x*y + y**4
H2 = sp.hessian(f2, (x, y))
print("Hessiana de f2:\n", H2)
print("Determinante de H2:", H2.det())
```

```
Hessiana de f2:
 Matrix([[4, -4], [-4, 12*y**2]])
Determinante de H2: 48*y**2 - 16
```

Ejercicio 3: clasificación de puntos estacionarios

Considerar la siguiente función real de dos variables:

$$f(x, y) = x^3 + y^3 - 3x - 12y + 20$$

1. **Localización de puntos críticos**: Encontrar todos los puntos críticos o estacionarios de la función aplicando las condiciones de primer orden (FONC).

   Solución:

Las condiciones necesarias de primer orden (FONC) exigen que el vector gradiente sea nulo:

$$\nabla f(x, y) = \begin{pmatrix} 3x^2 - 3 \\ 3y^2 - 12 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

Esto genera un sistema de dos ecuaciones independientes:

1. $3x^2 - 3 = 0 \implies x^2 = 1 \implies x = \pm 1$.
2. $3y^2 - 12 = 0 \implies y^2 = 4 \implies y = \pm 2$.

Combinando todas las soluciones posibles, obtenemos **cuatro puntos críticos**:

- $P_1 = (1, 2)$
- $P_2 = (1, -2)$
- $P_3 = (-1, 2)$
- $P_4 = (-1, -2)$

2. **Clasificación de puntos críticos**: Clasificar cada uno de los puntos estacionarios hallados utilizando el criterio de la matriz hessiana y las condiciones de segundo orden (SOSC).

   Solución:

Calculamos la matriz hessiana general para la función:

$$H(x, y) = \begin{pmatrix} 6x & 0 \\ 0 & 6y \end{pmatrix}$$

Al ser una matriz diagonal, sus autovalores son directamente los elementos de la diagonal principal: $\lambda_1 = 6x$ y $\lambda_2 = 6y$. Evaluamos cada uno de los cuatro puntos:

1. **Punto** $P_1 = (1, 2)$:

$$H(1, 2) = \begin{pmatrix} 6 & 0 \\ 0 & 12 \end{pmatrix} \implies \lambda_1 = 6 > 0, \quad \lambda_2 = 12 > 0$$

   Hessiana definida positiva ($H \succ 0$). Por tanto, P_1 es un **mínimo local estricto**. Valor de la función: $f(1, 2) = 1^3 + 2^3 - 3(1) - 12(2) + 20 = 2$.

2. **Punto** $P_2 = (1, -2)$:

$$H(1, -2) = \begin{pmatrix} 6 & 0 \\ 0 & -12 \end{pmatrix} \implies \lambda_1 = 6 > 0, \quad \lambda_2 = -12 < 0$$

   Hessiana indefinida (autovalores de distinto signo). Por tanto, P_2 es un **punto de silla**. Valor de la función: $f(1, -2) = 1^3 + (-2)^3 - 3(1) - 12(-2) + 20 = 34$.

3. **Punto** $P_3 = (-1, 2)$:

$$H(-1, 2) = \begin{pmatrix} -6 & 0 \\ 0 & 12 \end{pmatrix} \implies \lambda_1 = -6 < 0, \quad \lambda_2 = 12 > 0$$

   Hessiana indefinida. Por tanto, P_3 es un **punto de silla**. Valor de la función: $f(-1, 2) = (-1)^3 + 2^3 - 3(-1) - 12(2) + 20 = 6$.

4. **Punto** $P_4 = (-1, -2)$:

$$H(-1,-2) = \begin{pmatrix} -6 & 0 \\ 0 & -12 \end{pmatrix} \implies \lambda_1 = -6 < 0, \quad \lambda_2 = -12 < 0$$

   Hessiana definida negativa ($H \prec 0$). Por tanto, P_4 es un **máximo local estricto**. Valor de la función: $f(-1,-2) = (-1)^3 + (-2)^3 - 3(-1) - 12(-2) + 20 = 38$.

5. **Análisis de óptimos globales**: Determinar razonadamente si la función posee algún mínimo global o máximo global sobre todo el dominio $\mathbb{R}^2$.

   Solución:

La función **no posee óptimos globales** sobre $\mathbb{R}^2$ por falta de acotación:

- Si fijamos $y = 0$ y hacemos tender $x \to +\infty$: $\lim_{x\to+\infty} f(x,0) = \lim_{x\to+\infty}(x^3 - 3x + 20) = +\infty$.
- Si fijamos $y = 0$ y hacemos tender $x \to -\infty$: $\lim_{x\to-\infty} f(x,0) = \lim_{x\to-\infty}(x^3 - 3x + 20) = -\infty$.

Dado que la función no está acotada superior ni inferiormente en $\mathbb{R}^2$, los mínimos y máximos locales hallados no pueden extender su validez de manera global.

Ejercicio 4: trazado de búsqueda áurea y Newton 1D

Se desea encontrar el mínimo global de la función real:

$$f(x) = x\ln(x) - 1.5x$$

en el intervalo acotado $[1, 3]$. Se sabe que el mínimo analítico exacto se encuentra en $x^* = e^{0.5} \approx 1.6487$.

1. **Paso 1 del método de la sección áurea**: Realizar de forma manual el **Paso 1** del método de la **Sección Áurea** para una tolerancia $\epsilon = 0.5$ (utilizar $\alpha \approx 1.61803$). Detallar la amplitud inicial, la posición de los puntos de evaluación λ_0, μ_0, sus correspondientes valores de función y el descarte de intervalo.

   Solución:

2. **Amplitud de búsqueda inicial**: El intervalo inicial es $[a_0, b_0] = [1, 3]$. Su amplitud es $b_0 - a_0 = 2.0$.

3. **Amplitud de reducción** I_1: Utilizando la razón áurea $\alpha \approx 1.61803$:

$$I_1 = \frac{b_0 - a_0}{\alpha} = \frac{2.0}{1.61803} \approx 1.2361$$

4. **Puntos de evaluación iniciales**:

$$\lambda_0 = b_0 - I_1 = 3 - 1.2361 = 1.7639$$

$$\mu_0 = a_0 + I_1 = 1 + 1.2361 = 2.2361$$

5. **Evaluación de la función**:

   - $f(\lambda_0) = f(1.7639) = 1.7639 \ln(1.7639) - 1.5(1.7639) \approx -1.6449$
   - $f(\mu_0) = f(2.2361) = 2.2361 \ln(2.2361) - 1.5(2.2361) \approx -1.5548$

6. **Descarte de intervalos**: Como $f(\lambda_0) < f(\mu_0)$ (es decir, $-1.6449 < -1.5548$), el mínimo no puede encontrarse en el subintervalo $[\mu_0, b_0]$. Por lo tanto, descartamos la porción derecha del dominio. El **nuevo intervalo** para la siguiente iteración es:

$$[a_1, b_1] = [a_0, \mu_0] = [1.0, 2.2361]$$

   Su amplitud es 1.2361, que resulta mayor que la tolerancia $\epsilon = 0.5$, por lo que el algoritmo continuaría.

7. **Paso 1 del método de Newton 1D**: Realizar de forma manual el **Paso 1** del **Método de Newton 1D** partiendo de la aproximación inicial $x_0 = 1.0$. Mostrar detalladamente las ecuaciones de la primera y segunda derivada de la función, su evaluación en x_0 y el cálculo del siguiente punto x_1.

   Solución:

8. **Ecuaciones de las derivadas**:

   - Función: $f(x) = x \ln(x) - 1.5x$
   - Primera derivada: $f'(x) = \ln(x) + x\left(\frac{1}{x}\right) - 1.5 = \ln(x) - 0.5$
   - Segunda derivada: $f''(x) = \frac{1}{x}$

9. **Evaluación en el punto inicial** $x_0 = 1.0$:

   - $f'(1.0) = \ln(1.0) - 0.5 = -0.5$
   - $f''(1.0) = \frac{1}{1.0} = 1.0$

10. **Actualización de Newton**:

$$x_1 = x_0 - \frac{f'(x_0)}{f''(x_0)} = 1.0 - \frac{-0.5}{1.0} = 1.5$$

La aproximación $x_1 = 1.5$ se sitúa notablemente cerca del óptimo analítico exacto $x^* \approx 1.6487$ en un único paso debido a que la función objetivo presenta una curvatura muy bien aproximada cuadráticamente en el entorno de x_0.

Ejercicio 5: coordenadas cíclicas: optimización por direcciones ortogonales

Dada la función cuadrática de dos variables con acoplamiento:

$$f(x, y) = 3x^2 + 2xy + y^2 - 4x - 2y$$

1. **Búsqueda lineal en la variable** x: Optimizar respecto a la variable x (fijando $y = 0$) mediante una búsqueda unidimensional exacta para hallar el punto intermedio x_1.

   Solución:

Partimos de $x_0 = (0, 0)^T$. Optimizamos respecto a la primera dirección coordenada $e_1 = (1, 0)^T$ fijando la variable $y = 0$:

$$f(x, 0) = 3x^2 + 2x(0) + (0)^2 - 4x - 2(0) = 3x^2 - 4x$$

Minimizamos esta función de una sola variable derivando e igualando a cero:

$$\frac{df(x, 0)}{dx} = 6x - 4 = 0 \implies x = \frac{4}{6} = \frac{2}{3} \approx 0.6667$$

El punto resultante al término de la primera búsqueda lineal es:

$$x_1 = \left(\frac{2}{3}, 0\right)^T$$

2. **Búsqueda lineal en la variable** y: Optimizar respecto a la variable y (fijando $x = x_1$) mediante una búsqueda lineal exacta para determinar el siguiente iterado x_2.

   Solución:

Fijando $x = x_1 = 2/3$, optimizamos ahora respecto a la segunda dirección coordenada $e_2 = (0, 1)^T$:

$$f(2/3, y) = 3\left(\frac{2}{3}\right)^2 + 2\left(\frac{2}{3}\right)y + y^2 - 4\left(\frac{2}{3}\right) - 2y$$

$$f(2/3, y) = \frac{4}{3} + \frac{4}{3}y + y^2 - \frac{8}{3} - 2y = y^2 - \frac{2}{3}y - \frac{4}{3}$$

Minimizamos derivando respecto a y e igualando a cero:

$$\frac{df(2/3, y)}{dy} = 2y - \frac{2}{3} = 0 \implies y = \frac{1}{3} \approx 0.3333$$

El punto resultante al final de la iteración (el primer ciclo de variables) es:

$$x_2 = \left(\frac{2}{3}, \frac{1}{3}\right)^T$$

3. **Análisis de convergencia y acoplamiento**: Analizar si la convergencia en este método es directa (en un solo ciclo) o dibuja una trayectoria en escalera, justificándolo según el acoplamiento de la matriz hessiana.

   Solución:

Calculemos el óptimo analítico global de la función cuadrática igualando su gradiente a cero:

$$\nabla f(x, y) = \begin{pmatrix} 6x + 2y - 4 \\ 2x + 2y - 2 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

Resolviendo el sistema:

- De la segunda ecuación: $2x + 2y = 2 \implies x + y = 1 \implies y = 1 - x$.
- Sustituyendo en la primera:

$$6x + 2(1 - x) - 4 = 0 \implies 4x - 2 = 0 \implies x^* = 0.5$$

- Sustituyendo: $y^* = 0.5$.

El mínimo analítico es $x^* = (0.5, 0.5)^T$. Dado que el punto tras un ciclo completo es $x_2 = (2/3, 1/3)^T \neq x^*$, el método de coordenadas cíclicas **no converge al óptimo de forma directa**.

Esto se debe a que la matriz hessiana:

$$H = \begin{pmatrix} 6 & 2 \\ 2 & 2 \end{pmatrix}$$

no es una matriz diagonal. El término de acoplamiento cruzado ($2xy$ con coeficiente diferente de cero) deforma las elipses de las curvas de nivel inclinándolas respecto a los ejes de coordenadas. Como el algoritmo solo avanza en direcciones estrictamente paralelas a los ejes coordenados de forma secuencial, se ve obligado a dibujar un camino de "escalones", ralentizando significativamente la convergencia hacia el óptimo.

Ejercicio 6: máximo descenso: invarianza ortogonal y trazado

Minimizar la misma función cuadrática:

$$f(x, y) = 3x^2 + 2xy + y^2 - 4x - 2y$$

partiendo desde $x_0 = (0, 0)^T$ utilizando el método del **Máximo descenso** con búsqueda de tamaño de paso exacta.

1. **Gradiente y dirección de búsqueda inicial**: Calcular el gradiente analítico de la función y determinar la dirección inicial de búsqueda d_0.

   Solución:

2. **Vector gradiente analítico**:

$$\nabla f(x, y) = \begin{pmatrix} 6x + 2y - 4 \\ 2x + 2y - 2 \end{pmatrix}$$

3. **Evaluación en la solución inicial** $x_0 = (0, 0)^T$:

$$\nabla f(x_0) = \begin{pmatrix} -4 \\ -2 \end{pmatrix}$$

4. **Dirección de máxima bajada** d_0: La dirección es el gradiente negativo:

$$d_0 = -\nabla f(x_0) = \begin{pmatrix} 4 \\ 2 \end{pmatrix}$$

5. **Búsqueda lineal exacta y actualización de puntos**: Plantear la función unidimensional de paso $\phi(\alpha) = f(x_0 + \alpha d_0)$ y resolver analíticamente la optimización del tamaño de paso $\alpha_0 = \arg\min_{\alpha>0} \phi(\alpha)$. Calcular el siguiente punto iterado $x_1 = x_0 + \alpha_0 d_0$.

   Solución:

6. **Trayectoria lineal parametrizada**:

$$x(\alpha) = x_0 + \alpha d_0 = \begin{pmatrix} 0 \\ 0 \end{pmatrix} + \alpha \begin{pmatrix} 4 \\ 2 \end{pmatrix} = \begin{pmatrix} 4\alpha \\ 2\alpha \end{pmatrix}$$

7. **Planteamiento de la función unidimensional** $\phi(\alpha)$: Sustituyendo las variables en la función objetivo:

$$\phi(\alpha) = f(4\alpha, 2\alpha) = 3(4\alpha)^2 + 2(4\alpha)(2\alpha) + (2\alpha)^2 - 4(4\alpha) - 2(2\alpha)$$

$$\phi(\alpha) = 48\alpha^2 + 16\alpha^2 + 4\alpha^2 - 16\alpha - 4\alpha = 68\alpha^2 - 20\alpha$$

8. **Optimización del tamaño de paso**: Minimizamos derivando respecto a α e igualando a cero:
$$\phi'(\alpha) = 136\alpha - 20 = 0 \implies \alpha_0 = \frac{20}{136} = \frac{5}{34} \approx 0.1471$$

9. **Actualización del punto**:
$$x_1 = x_0 + \alpha_0 d_0 = \begin{pmatrix}0\\0\end{pmatrix} + \frac{5}{34}\begin{pmatrix}4\\2\end{pmatrix} = \begin{pmatrix}10/17\\5/17\end{pmatrix} \approx \begin{pmatrix}0.5882\\0.2941\end{pmatrix}$$

10. **Verificación del Teorema de Ortogonalidad**: Calcular la dirección de búsqueda en el siguiente paso ($d_1 = -\nabla f(x_1)$) y demostrar analíticamente que d_0 y d_1 son ortogonales ($d_0^T d_1 = 0$), verificando el Teorema de Ortogonalidad Sucesiva.

    Solución:

11. **Evaluación del gradiente en** x_1:
$$\nabla f(x_1) = \begin{pmatrix}6(10/17) + 2(5/17) - 4\\2(10/17) + 2(5/17) - 2\end{pmatrix} = \begin{pmatrix}\frac{70}{17} - \frac{68}{17}\\\frac{30}{17} - \frac{34}{17}\end{pmatrix} = \begin{pmatrix}2/17\\-4/17\end{pmatrix}$$

12. **Siguiente dirección de búsqueda** d_1:
$$d_1 = -\nabla f(x_1) = \begin{pmatrix}-2/17\\4/17\end{pmatrix}$$

13. **Cálculo del producto escalar**:
$$d_0^T d_1 = \begin{pmatrix}4 & 2\end{pmatrix}\begin{pmatrix}-2/17\\4/17\end{pmatrix} = 4\left(-\frac{2}{17}\right) + 2\left(\frac{4}{17}\right) = -\frac{8}{17} + \frac{8}{17} = 0$$

El resultado demuestra de forma exacta que las direcciones de búsqueda consecutivas son ortogonales, validando experimentalmente el Teorema de la Ortogonalidad Sucesiva de los algoritmos de gradiente con búsqueda exacta.

Ejercicio 7: Newton multivariante: convergencia cuadrática

Dada la función cuadrática:

$$f(x, y) = 3x^2 + 2xy + y^2 - 4x - 2y$$

Se pide aplicar el método de **Newton multivariante** libre partiendo del punto de búsqueda inicial $x_0 = (0, 0)^T$:

1. **Gradiente y Hessiana iniciales**: Calcular el vector gradiente $\nabla f(x_0)$ y la matriz hessiana $H = \nabla^2 f(x_0)$.

   Solución:

2. **Gradiente evaluado en x_0**:
$$\nabla f(x_0) = \begin{pmatrix} -4 \\ -2 \end{pmatrix}$$

3. **Matriz hessiana (H)**: Al tratarse de una función cuadrática, las segundas derivadas parciales son constantes en todo el espacio:
$$H = \nabla^2 f(x) = \begin{pmatrix} 6 & 2 \\ 2 & 2 \end{pmatrix}$$

4. **Cálculo de la inversa de la Hessiana**: Calcular analíticamente la matriz inversa de la hessiana H^{-1}.

   Solución:

Para calcular la inversa de la matriz de segundo orden:

1. **Determinante**:
$$\det(H) = 6(2) - 2(2) = 12 - 4 = 8$$

2. **Matriz adjunta transpuesta**: La matriz es simétrica, por lo que:
$$H^{-1} = \frac{1}{\det(H)} \begin{pmatrix} H_{22} & -H_{12} \\ -H_{21} & H_{11} \end{pmatrix} = \frac{1}{8} \begin{pmatrix} 2 & -2 \\ -2 & 6 \end{pmatrix} = \begin{pmatrix} 0.25 & -0.25 \\ -0.25 & 0.75 \end{pmatrix}$$

3. **Actualización e interpretación física de la convergencia**: Realizar la actualización de Newton $x_1 = x_0 - H^{-1}\nabla f(x_0)$. Comprobar que se alcanza el mínimo analítico exacto de la función en una única iteración y explicar razonadamente por qué se da este fenómeno.

   Solución:

4. **Actualización de Newton**:

$$x_1 = x_0 - H^{-1}\nabla f(x_0)$$

$$x_1 = \begin{pmatrix}0\\0\end{pmatrix} - \begin{pmatrix}0.25 & -0.25\\-0.25 & 0.75\end{pmatrix}\begin{pmatrix}-4\\-2\end{pmatrix}$$

$$x_1 = \begin{pmatrix}0\\0\end{pmatrix} - \begin{pmatrix}0.25(-4) - 0.25(-2)\\-0.25(-4) + 0.75(-2)\end{pmatrix} = -\begin{pmatrix}-1 + 0.5\\1 - 1.5\end{pmatrix} = -\begin{pmatrix}-0.5\\-0.5\end{pmatrix} = \begin{pmatrix}0.5\\0.5\end{pmatrix}$$

5. **Explicación teórica**: El método de Newton multivariante calcula el siguiente iterado optimizando la aproximación cuadrática de segundo orden (Taylor) de la función en el punto actual. Para cualquier función estrictamente cuadrática, esta aproximación de segundo orden es **exacta** en todo el dominio de definición de la función. Como consecuencia directa de esto, la aproximación cuadrática no comete ningún error y el método de Newton localiza el mínimo global exacto en **exactamente una iteración** desde cualquier punto inicial arbitrario.

6. **Verificación de Newton Multivariante en Python (SciPy)**:

```python
import numpy as np
from scipy.optimize import minimize

def objective(x):
    return 3*x[0]**2 + 2*x[0]*x[1] + x[1]**2 - 4*x[0] - 2*x[1]

# Ejecutar el solver
res = minimize(objective, x0=[0.0, 0.0], method='Newton-CG', jac=lambda x: np.array([6*x[0]+2
print("Mínimo numérico alcanzado por Newton:", res.x)
```

```
Mínimo numérico alcanzado por Newton: [0.5 0.5]
```

---

4. **Newton multivariante en funciones no cuadráticas**: Considere ahora una función no cuadrática dada por:

$$g(x, y) = e^x - x + y^2$$

Partiendo del punto inicial $x_0 = (1, 1)^T$, calcule la primera iteración de Newton multivariante x_1. Determine si x_1 es el óptimo analítico de la función y discuta cómo difiere la convergencia del método en funciones no cuadráticas.

Solución:

5. **Cálculo del gradiente de $g(x, y)$**:

$$\nabla g(x, y) = \begin{pmatrix} e^x - 1 \\ 2y \end{pmatrix}$$

Evaluando en $x_0 = (1, 1)^T$:

$$\nabla g(1, 1) = \begin{pmatrix} e^1 - 1 \\ 2(1) \end{pmatrix} = \begin{pmatrix} e - 1 \\ 2 \end{pmatrix} \approx \begin{pmatrix} 1.7183 \\ 2 \end{pmatrix}$$

6. **Cálculo de la matriz hessiana de $g(x, y)$**:

$$H(x, y) = \nabla^2 g(x, y) = \begin{pmatrix} e^x & 0 \\ 0 & 2 \end{pmatrix}$$

Evaluando en $x_0 = (1, 1)^T$:

$$H(1, 1) = \begin{pmatrix} e & 0 \\ 0 & 2 \end{pmatrix} \approx \begin{pmatrix} 2.7183 & 0 \\ 0 & 2 \end{pmatrix}$$

7. **Cálculo de la matriz inversa de la hessiana**: Al ser una matriz diagonal, su inversa se obtiene directamente invirtiendo los elementos de la diagonal principal:

$$H^{-1}(1, 1) = \begin{pmatrix} e^{-1} & 0 \\ 0 & 0.5 \end{pmatrix} \approx \begin{pmatrix} 0.3679 & 0 \\ 0 & 0.5 \end{pmatrix}$$

8. **Actualización de Newton**:

$$x_1 = x_0 - H^{-1} \nabla g(x_0)$$

$$x_1 = \begin{pmatrix} 1 \\ 1 \end{pmatrix} - \begin{pmatrix} e^{-1} & 0 \\ 0 & 0.5 \end{pmatrix} \begin{pmatrix} e - 1 \\ 2 \end{pmatrix} = \begin{pmatrix} 1 \\ 1 \end{pmatrix} - \begin{pmatrix} e^{-1}(e - 1) \\ 0.5(2) \end{pmatrix} = \begin{pmatrix} 1 \\ 1 \end{pmatrix} - \begin{pmatrix} 1 - e^{-1} \\ 1 \end{pmatrix} = \begin{pmatrix} e^{-1} \\ 0 \end{pmatrix} \approx \begin{pmatrix} 0.3679 \\ 0 \end{pmatrix}$$

9. **Análisis del óptimo analítico**: El gradiente de $g(x, y)$ es nulo si:

$$\nabla g(x, y) = \begin{pmatrix} e^x - 1 \\ 2y \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix} \implies e^x = 1 \implies x^* = 0, \quad 2y = 0 \implies y^* = 0$$

El mínimo analítico global exacto se encuentra en $x^* = (0, 0)^T$. Dado que $x_1 = (e^{-1}, 0)^T \approx (0.3679, 0)^T \neq (0, 0)^T$, el método **no ha convergido al óptimo en una sola iteración**.

10. **Discusión de la convergencia**: En funciones no cuadráticas, la aproximación polinómica de segundo orden dada por el desarrollo de Taylor no es exacta en todo el espacio (debido a la presencia de derivadas de orden superior, como las de la exponencial e^x). Por tanto, la dirección y longitud de paso de Newton cometen un error de truncamiento. El método no alcanza el óptimo en una sola iteración, sino que requiere un proceso iterativo. Su principal ventaja es que goza de **convergencia cuadrática local** (es decir, el número de dígitos significativos correctos se duplica aproximadamente en cada iteración una vez que el algoritmo se encuentra lo suficientemente cerca del óptimo x^*).

Ejercicios del Tema 3: análisis convexo

Ejercicio 1: combinaciones convexas y conjuntos convexos

En la teoría de la optimización entera y lineal, la intersección de conjuntos convexos juega un papel fundamental al definir regiones factibles que combinan múltiples restricciones.

Se pide:

1. **Demostrar analíticamente que la intersección de una familia arbitraria (posiblemente infinita) de conjuntos convexos $\mathcal{S}_i \subseteq \mathbb{R}^n$, denotada por $\mathcal{S} = \bigcap_{i \in I} \mathcal{S}_i$, es a su vez un conjunto convexo.**:

   Solución:

Queremos demostrar que la intersección $\mathcal{S} = \bigcap_{i \in I} \mathcal{S}_i$ de una familia arbitraria de conjuntos convexos $\mathcal{S}_i \subseteq \mathbb{R}^n$ es un conjunto convexo.

Demostración:

1. Sean $x, y \in \mathcal{S}$ dos puntos cualesquiera de la intersección, y sea $\lambda \in [0, 1]$.
2. Por la definición de la intersección de conjuntos, si $x, y \in \mathcal{S}$, entonces $x \in \mathcal{S}_i$ e $y \in \mathcal{S}_i$ para todo índice $i \in I$.
3. Dado que cada conjunto $\mathcal{S}_i$ es convexo por hipótesis, cualquier combinación convexa de sus puntos también pertenece al conjunto. Por tanto, para todo $\lambda \in [0, 1]$ se cumple:

$$\lambda x + (1 - \lambda) y \in \mathcal{S}_i, \quad \forall i \in I$$

4. Al cumplirse esta pertenencia para todos los elementos de la familia ($i \in I$), se deduce por definición de intersección que:

$$\lambda x + (1 - \lambda) y \in \bigcap_{i \in I} \mathcal{S}_i = \mathcal{S}$$

5. Como esta relación es válida para cualesquiera $x, y \in \mathcal{S}$ y cualquier $\lambda \in [0, 1]$, el conjunto intersección $\mathcal{S}$ es **convexo**. ■

---

2. **Mostrar mediante un contraejemplo gráfico o analítico en $\mathbb{R}^2$ que la unión de dos conjuntos convexos $\mathcal{S}_1 \cup \mathcal{S}_2$ no es necesariamente un conjunto convexo.**:

   Solución:

Queremos mostrar mediante un contraejemplo en $\mathbb{R}^2$ que la unión de dos conjuntos convexos $\mathcal{S}_1 \cup \mathcal{S}_2$ no es necesariamente convexa.

Contraejemplo: Sean los conjuntos convexos $\mathcal{S}_1, \mathcal{S}_2 \subseteq \mathbb{R}^2$ definidos como dos intervalos cerrados (segmentos de recta unidimensionales en el eje x):

$$\mathcal{S}_1 = \{(x, 0)^T \in \mathbb{R}^2 \mid 0 \leq x \leq 1\}$$

$$\mathcal{S}_2 = \{(x, 0)^T \in \mathbb{R}^2 \mid 2 \leq x \leq 3\}$$

Ambos conjuntos son convexos por ser segmentos cerrados. Consideremos su unión $\mathcal{U} = \mathcal{S}_1 \cup \mathcal{S}_2$.

- Tomemos el punto $a = (0.5, 0)^T \in \mathcal{S}_1 \subseteq \mathcal{U}$.
- Tomemos el punto $b = (2.5, 0)^T \in \mathcal{S}_2 \subseteq \mathcal{U}$.
- Evaluemos su punto medio (combinación convexa con $\lambda = 0.5$):

$$c = 0.5a + 0.5b = 0.5(0.5, 0)^T + 0.5(2.5, 0)^T = (1.5, 0)^T$$

El punto $c = (1.5, 0)^T$ no pertenece a $\mathcal{S}_1$ (puesto que $1.5 > 1$) y tampoco pertenece a $\mathcal{S}_2$ (ya que $1.5 < 2$). Por tanto, $c \notin \mathcal{U}$.

Dado que existen dos puntos en $\mathcal{U}$ cuya combinación convexa no pertenece a $\mathcal{U}$, la unión **no es un conjunto convexo**. ■

Ejercicio 2: operaciones algebraicas que preservan la convexidad

Demostrar las siguientes propiedades relativas a la preservación de la convexidad de conjuntos bajo operaciones afines y algebraicas:

1. **Sean $\mathcal{S}_1, \mathcal{S}_2 \subseteq \mathbb{R}^n$ dos conjuntos convexos. Demostrar que su suma de Minkowski, definida como $\mathcal{S}_1 + \mathcal{S}_2 = \{x_1 + x_2 \mid x_1 \in \mathcal{S}_1,\ x_2 \in \mathcal{S}_2\}$, es un conjunto convexo.**:

   Solución:

Queremos demostrar que la suma de Minkowski $\mathcal{S}_1 + \mathcal{S}_2 = \{x_1 + x_2 \mid x_1 \in \mathcal{S}_1,\ x_2 \in \mathcal{S}_2\}$ de dos conjuntos convexos $\mathcal{S}_1, \mathcal{S}_2 \subseteq \mathbb{R}^n$ es convexa.

Demostración:

1. Sean $z_a, z_b \in \mathcal{S}_1 + \mathcal{S}_2$ dos puntos arbitrarios de la suma, y sea $\lambda \in [0, 1]$.
2. Por definición del conjunto suma, existen puntos $x_a, x_b \in \mathcal{S}_1$ e $y_a, y_b \in \mathcal{S}_2$ tales que:

$$z_a = x_a + y_a \qquad \text{y} \qquad z_b = x_b + y_b$$

3. Evaluamos la combinación convexa de z_a y z_b:

$$\lambda z_a + (1 - \lambda) z_b = \lambda(x_a + y_a) + (1 - \lambda)(x_b + y_b)$$

4. Agrupamos los términos correspondientes a cada uno de los conjuntos de procedencia:

$$\lambda z_a + (1 - \lambda) z_b = [\lambda x_a + (1 - \lambda) x_b] + [\lambda y_a + (1 - \lambda) y_b]$$

5. Puesto que $\mathcal{S}_1$ es convexo y $x_a, x_b \in \mathcal{S}_1$, definimos la combinación $x_c = \lambda x_a + (1 - \lambda) x_b \in \mathcal{S}_1$.
6. Puesto que $\mathcal{S}_2$ es convexo y $y_a, y_b \in \mathcal{S}_2$, definimos la combinación $y_c = \lambda y_a + (1 - \lambda) y_b \in \mathcal{S}_2$.
7. Por tanto, tenemos que:
$$\lambda z_a + (1 - \lambda) z_b = x_c + y_c$$
Como $x_c \in \mathcal{S}_1$ e $y_c \in \mathcal{S}_2$, se cumple que $x_c + y_c \in \mathcal{S}_1 + \mathcal{S}_2$.
8. Queda demostrado que la suma de Minkowski $\mathcal{S}_1 + \mathcal{S}_2$ es **convexa**. ■

---

2. **Sea $\mathcal{S} \subseteq \mathbb{R}^n$ un conjunto convexo, y sea $f : \mathbb{R}^n \to \mathbb{R}^m$ una transformación afín dada por $f(x) = Ax + b$, donde $A \in \mathbb{R}^{m \times n}$ y $b \in \mathbb{R}^m$. Demostrar que la imagen del conjunto, $f(\mathcal{S}) = \{Ax + b \mid x \in \mathcal{S}\}$, es un conjunto convexo en $\mathbb{R}^m$.**:

   Solución: Queremos demostrar que la imagen de un conjunto convexo $\mathcal{S} \subseteq \mathbb{R}^n$ bajo la transformación afín $f(x) = Ax + b$ es convexa en $\mathbb{R}^m$.

Demostración:

1. Sean $y_a, y_b \in f(\mathcal{S})$ dos puntos de la imagen, y sea $\lambda \in [0, 1]$.
2. Por definición del conjunto imagen, existen preimágenes $x_a, x_b \in \mathcal{S}$ tales que:

$$y_a = Ax_a + b \qquad \text{y} \qquad y_b = Ax_b + b$$

3. Evaluamos la combinación convexa de los puntos imagen:

$$\lambda y_a + (1-\lambda) y_b = \lambda(Ax_a + b) + (1-\lambda)(Ax_b + b)$$

4. Expandimos y factorizamos por la matriz A y por el vector constante b:

$$\lambda y_a + (1-\lambda) y_b = A\left[\lambda x_a + (1-\lambda) x_b\right] + \left[\lambda + (1-\lambda)\right] b = A\left[\lambda x_a + (1-\lambda) x_b\right] + b$$

5. Puesto que el dominio original $\mathcal{S}$ es un conjunto convexo y $x_a, x_b \in \mathcal{S}$, definimos el punto $x_c = \lambda x_a + (1-\lambda) x_b \in \mathcal{S}$.

6. Por consiguiente:

$$\lambda y_a + (1-\lambda) y_b = Ax_c + b = f(x_c)$$

   Como $x_c \in \mathcal{S}$, su transformación $f(x_c)$ pertenece por definición al conjunto imagen $f(\mathcal{S})$.

7. Se concluye que el conjunto imagen $f(\mathcal{S})$ es **convexo**. ■

Ejercicio 3: puntos extremos y teorema de Minkowski-Weyl

Considerar el conjunto de puntos $\mathcal{S} \subseteq \mathbb{R}^2$ definido por la inecuación de la norma L_1:

$$\mathcal{S} = \{(x, y) \in \mathbb{R}^2 \mid |x| + |y| \leq 1\}$$

Se pide:

1. **Dibujar o describir geométricamente el conjunto $\mathcal{S}$ en el plano real $\mathbb{R}^2$, determinando si es un conjunto convexo y acotado (un politopo).**:

   Solución:

El conjunto $\mathcal{S} = \{(x, y) \in \mathbb{R}^2 \mid |x| + |y| \leq 1\}$ representa el **círculo unidad bajo la norma L_1** en $\mathbb{R}^2$.

- En el primer cuadrante ($x, y \geq 0$), la frontera es la recta lineal $x + y = 1$.
- Replicando por simetría en los otros tres cuadrantes, el conjunto dibuja un **cuadrado rotado de** 45° (un rombo) centrado en el origen $(0, 0)^T$, cuyos vértices se encuentran en los puntos coordenados $(1, 0)^T$, $(0, 1)^T$, $(-1, 0)^T$ y $(0, -1)^T$.
- Al ser el círculo de una norma matemática, es de forma garantizada **convexo y acotado** (un politopo compacto).

---

2. **Identificar todos los puntos extremos (o vértices) del conjunto $\mathcal{S}$ aplicando la definición formal de punto extremo (aquellos puntos que no pueden expresarse como combinación convexa propia de otros dos puntos distintos del conjunto).**:

   Solución: Los **puntos extremos** de $\mathcal{S}$ son sus cuatro vértices:

$$\mathcal{E} = \left\{ v_1 = \begin{pmatrix} 1 \\ 0 \end{pmatrix}, v_2 = \begin{pmatrix} 0 \\ 1 \end{pmatrix}, v_3 = \begin{pmatrix} -1 \\ 0 \end{pmatrix}, v_4 = \begin{pmatrix} 0 \\ -1 \end{pmatrix} \right\}$$

Demostración formal para $v_1 = (1,0)^T$: Supongamos por reducción al absurdo que v_1 no es un punto extremo. Entonces existirían dos puntos distintos $a, b \in \mathcal{S}$ $(a \neq b)$ y un parámetro $\lambda \in (0,1)$ tales que:

$$\begin{pmatrix} 1 \\ 0 \end{pmatrix} = \lambda \begin{pmatrix} a_1 \\ a_2 \end{pmatrix} + (1-\lambda) \begin{pmatrix} b_1 \\ b_2 \end{pmatrix}$$

1. Para la primera coordenada se tiene:

$$1 = \lambda a_1 + (1-\lambda) b_1$$

   Como $a, b \in \mathcal{S}$, se cumple que $|a_1| \leq |a_1| + |a_2| \leq 1 \implies a_1 \leq 1$. Análogamente, $b_1 \leq 1$.

2. Para que una combinación convexa estricta $(\lambda \in (0,1))$ de dos números menores o iguales a 1 resulte exactamente en 1, es matemáticamente obligatorio que ambos números sean iguales a 1:

$$a_1 = 1 \qquad \text{y} \qquad b_1 = 1$$

3. Sustituyendo en la restricción del conjunto $|x| + |y| \leq 1$:

   - Para a: $|1| + |a_2| \leq 1 \implies 1 + |a_2| \leq 1 \implies a_2 = 0$.
   - Para b: $|1| + |b_2| \leq 1 \implies 1 + |b_2| \leq 1 \implies b_2 = 0$.

4. Esto implica que $a = (1,0)^T$ y $b = (1,0)^T$, lo cual contradice la hipótesis de partida de que a y b eran puntos distintos $(a \neq b)$.

5. Por lo tanto, $v_1 = (1,0)^T$ es un **punto extremo**. Por simetría en los cuadrantes, se demuestra idénticamente la propiedad para v_2, v_3 y v_4. ■

---

3. **Demostrar que cualquier punto interior o de la frontera de $\mathcal{S}$ (por ejemplo, el punto $(0.2, 0.5)^T$) se puede expresar como una combinación convexa de sus puntos extremos, de acuerdo con el Teorema de Representación de Minkowski.**:

   Solución:

Queremos escribir el punto $p = (0.2, 0.5)^T \in \mathcal{S}$ como una combinación convexa de sus puntos extremos:

$$p = \lambda_1 v_1 + \lambda_2 v_2 + \lambda_3 v_3 + \lambda_4 v_4$$

con $\lambda_i \geq 0$ y $\sum_{i=1}^{4} \lambda_i = 1$.

1. Escribimos el sistema de ecuaciones coordenadas correspondientes:

$$0.2 = \lambda_1(1) + \lambda_2(0) + \lambda_3(-1) + \lambda_4(0) \implies \lambda_1 - \lambda_3 = 0.2$$

$$0.5 = \lambda_1(0) + \lambda_2(1) + \lambda_3(0) + \lambda_4(-1) \implies \lambda_2 - \lambda_4 = 0.5$$

$$\lambda_1 + \lambda_2 + \lambda_3 + \lambda_4 = 1$$

2. Despejamos los pesos principales en función de los opuestos:

$$\lambda_1 = 0.2 + \lambda_3 \qquad \text{y} \qquad \lambda_2 = 0.5 + \lambda_4$$

3. Sustituimos en la ecuación de suma de pesos unitaria:

$$(0.2 + \lambda_3) + (0.5 + \lambda_4) + \lambda_3 + \lambda_4 = 1 \implies 0.7 + 2(\lambda_3 + \lambda_4) = 1 \implies \lambda_3 + \lambda_4 = 0.15$$

4. Asignamos un valor factible arbitrario para resolver el grado de libertad. Por ejemplo, elegimos $\lambda_4 = 0$. Esto nos da:

$$\lambda_3 = 0.15$$

$$\lambda_1 = 0.2 + 0.15 = 0.35$$

$$\lambda_2 = 0.5 + 0 = 0.50$$

$$\lambda_4 = 0.00$$

5. Verificamos que todos los coeficientes son no negativos ($\lambda_i \geq 0$) y suman 1 ($0.35 + 0.50 + 0.15 + 0 = 1.0$).

6. Comprobamos la combinación:

$$0.35 \begin{pmatrix} 1 \\ 0 \end{pmatrix} + 0.50 \begin{pmatrix} 0 \\ 1 \end{pmatrix} + 0.15 \begin{pmatrix} -1 \\ 0 \end{pmatrix} + 0 \begin{pmatrix} 0 \\ -1 \end{pmatrix} = \begin{pmatrix} 0.35 - 0.15 \\ 0.50 \end{pmatrix} = \begin{pmatrix} 0.2 \\ 0.5 \end{pmatrix} = p$$

La representación es correcta y válida. ■

Ejercicio 4: caracterización de primer orden de funciones convexas

Sea $f : \mathcal{S} \to \mathbb{R}$ una función continuamente diferenciable sobre un conjunto abierto y convexo $\mathcal{S} \subseteq \mathbb{R}^n$.

Se pide:

1. **Demostrar analíticamente el teorema de caracterización de primer orden, el cual establece que f es convexa en $\mathcal{S}$ si y solo si $f(y) \geq f(x)+\nabla f(x)^T(y-x),\ \forall x, y \in \mathcal{S}$.**:

   Solución:

Queremos demostrar que la diferenciabilidad de primer orden caracteriza la convexidad mediante la desigualdad $f(y) \geq f(x) + \nabla f(x)^T(y - x)$.

Demostración:

- **Implicación Directa ($\implies$)**:

  1. Asumimos que f es convexa en el conjunto convexo $\mathcal{S}$. Por tanto, para cualesquiera $x, y \in \mathcal{S}$ y cualquier $\lambda \in (0, 1]$, se cumple:

     $$f(\lambda y + (1 - \lambda)x) \leq \lambda f(y) + (1 - \lambda)f(x)$$

  2. Reescribimos el argumento de la izquierda como una perturbación en la dirección del vector $(y - x)$:

     $$f(x + \lambda(y - x)) \leq f(x) + \lambda(f(y) - f(x))$$

  3. Restamos $f(x)$ y dividimos entre el escalar estrictamente positivo $\lambda > 0$:

     $$\frac{f(x + \lambda(y - x)) - f(x)}{\lambda} \leq f(y) - f(x)$$

  4. Aplicamos el límite cuando $\lambda \to 0^+$ en ambos lados. El lado izquierdo coincide con la definición de la derivada direccional en la dirección $(y - x)$, que para funciones diferenciables se escribe como el producto escalar con el gradiente:

     $$\lim_{\lambda \to 0^+} \frac{f(x + \lambda(y - x)) - f(x)}{\lambda} = \nabla f(x)^T(y - x)$$

  5. Por tanto, se obtiene:

     $$\nabla f(x)^T(y - x) \leq f(y) - f(x) \implies f(y) \geq f(x) + \nabla f(x)^T(y - x) \quad \blacksquare$$

- **Implicación Inversa ($\impliedby$)**:

1. Asumimos que la desigualdad de primer orden es válida para todos los puntos del dominio.
2. Sean $x_1, x_2 \in \mathcal{S}$ dos puntos cualesquiera, $\lambda \in [0,1]$, y sea el punto intermedio $z = \lambda x_1 + (1-\lambda)x_2 \in \mathcal{S}$.
3. Evaluamos la desigualdad de primer orden tomando a z como punto de pivote:
   - Para $y = x_1$: $\quad f(x_1) \geq f(z) + \nabla f(z)^T(x_1 - z)$
   - Para $y = x_2$: $\quad f(x_2) \geq f(z) + \nabla f(z)^T(x_2 - z)$
4. Multiplicamos la primera ecuación por $\lambda \geq 0$, la segunda por $(1-\lambda) \geq 0$, y las sumamos:

   $$\lambda f(x_1) + (1-\lambda) f(x_2) \geq \lambda f(z) + (1-\lambda) f(z) + \nabla f(z)^T \left[\lambda(x_1 - z) + (1-\lambda)(x_2 - z)\right]$$

5. Simplificamos el término del corchete del producto escalar:

   $$\lambda x_1 - \lambda z + (1-\lambda)x_2 - (1-\lambda)z = [\lambda x_1 + (1-\lambda)x_2] - [\lambda + 1 - \lambda]\, z = z - z = 0$$

6. Por consiguiente, el término del gradiente se anula y obtenemos:

   $$\lambda f(x_1) + (1-\lambda) f(x_2) \geq f(z) = f(\lambda x_1 + (1-\lambda)x_2)$$

   Lo cual demuestra que f es una función **convexa**. ■

---

2. **Utilizando la desigualdad anterior, demostrar que si f es convexa en $\mathcal{S}$ y existe un punto $x^* \in \mathcal{S}$ tal que el gradiente se anula ($\nabla f(x^*) = 0$), entonces x^* es un mínimo global de la función en $\mathcal{S}$.**:

   Solución:

Queremos demostrar que si f es convexa y $\nabla f(x^*) = 0$, entonces x^* es un mínimo global.

Demostración:

1. Al ser f una función convexa y diferenciable, se cumple la caracterización de primer orden demostrada en la sección anterior para cualquier punto $y \in \mathcal{S}$:

   $$f(y) \geq f(x^*) + \nabla f(x^*)^T(y - x^*)$$

2. Sustituimos la condición de punto crítico $\nabla f(x^*) = 0$:

   $$f(y) \geq f(x^*) + 0^T(y - x^*) \implies f(y) \geq f(x^*), \quad \forall y \in \mathcal{S}$$

3. Al ser el valor de la función en x^* menor o igual al de cualquier otro punto y del dominio $\mathcal{S}$, x^* es obligatoriamente un **mínimo global** de la función. ■

Ejercicio 5: caracterización de segundo orden de la curvatura

Estudiar analíticamente la convexidad o concavidad local y global de las siguientes funciones mediante el cálculo de sus matrices hessianas y el análisis de sus menores principales o autovalores:

1. $f(x, y) = x^2y^2 - x - y$ **definida sobre el dominio global** $\mathbb{R}^2$**.**:

   Solución:

Dada la función $f(x, y) = x^2y^2 - x - y$ en $\mathbb{R}^2$:

1. Calculamos las primeras derivadas parciales:

$$\frac{\partial f}{\partial x} = 2xy^2 - 1 \qquad \text{y} \qquad \frac{\partial f}{\partial y} = 2x^2y - 1$$

2. Calculamos las segundas derivadas para construir la matriz hessiana:

$$\frac{\partial^2 f}{\partial x^2} = 2y^2, \qquad \frac{\partial^2 f}{\partial y^2} = 2x^2, \qquad \frac{\partial^2 f}{\partial x \partial y} = 4xy$$

$$\nabla^2 f(x, y) = \begin{pmatrix} 2y^2 & 4xy \\ 4xy & 2x^2 \end{pmatrix}$$

3. Analizamos los menores principales de la matriz:

   - Primer menor principal: $\Delta_1 = 2y^2 \geq 0$ (siempre no negativo).
   - Segundo menor principal (determinante):

$$\Delta_2 = \det(\nabla^2 f(x, y)) = (2y^2)(2x^2) - (4xy)^2 = 4x^2y^2 - 16x^2y^2 = -12x^2y^2$$

4. Observamos que para cualquier punto del plano donde las coordenadas sean no nulas ($x \neq 0$ e $y \neq 0$), el determinante es estrictamente negativo ($\Delta_2 < 0$).

5. Al tener un determinante negativo en casi todo el plano, la matriz hessiana es **indefinida**. Por tanto, la función **no es convexa ni cóncava** de manera global en $\mathbb{R}^2$.

---

2. $f(x, y) = -\ln(4 - x^2 - y^2)$ **definida sobre el disco abierto** $\mathcal{S} = \{(x, y) \in \mathbb{R}^2 \mid x^2 + y^2 < 4\}$**.**:

   Solución:

Dada la función $f(x, y) = -\ln(4 - x^2 - y^2)$ en el disco abierto $\mathcal{S} = \{(x, y) \in \mathbb{R}^2 \mid x^2 + y^2 < 4\}$:

1. Sea $u(x,y) = 4 - x^2 - y^2$. En el dominio dado se cumple que $u > 0$.

2. Calculamos el gradiente de la función aplicando la regla de la cadena:

$$\frac{\partial f}{\partial x} = -\frac{1}{u}(-2x) = \frac{2x}{u} \qquad \text{y} \qquad \frac{\partial f}{\partial y} = \frac{2y}{u}$$

3. Calculamos las segundas derivadas utilizando la regla del cociente:

$$\frac{\partial^2 f}{\partial x^2} = \frac{2u - 2x(-2x)}{u^2} = \frac{2(4 - x^2 - y^2) + 4x^2}{u^2} = \frac{8 + 2x^2 - 2y^2}{u^2}$$

$$\frac{\partial^2 f}{\partial y^2} = \frac{2u - 2y(-2y)}{u^2} = \frac{8 - 2x^2 + 2y^2}{u^2}$$

$$\frac{\partial^2 f}{\partial x \partial y} = \frac{0 - 2x(-2y)}{u^2} = \frac{4xy}{u^2}$$

4. Construimos la matriz Hessiana:

$$\nabla^2 f(x,y) = \frac{2}{u^2}\begin{pmatrix} 4 + x^2 - y^2 & 2xy \\ 2xy & 4 - x^2 + y^2 \end{pmatrix}$$

5. Evaluamos la positividad de los menores principales en el dominio $\mathcal{S}$:

   - **Primer menor principal (Δ_1)**:

   $$\Delta_1 = \frac{2}{u^2}(4 + x^2 - y^2)$$

   Dado que estamos en el disco $x^2 + y^2 < 4$, se cumple que $y^2 < 4 - x^2$. Sustituyendo esta cota superior:

   $$4 + x^2 - y^2 > 4 + x^2 - (4 - x^2) = 2x^2 \geq 0 \implies \Delta_1 > 0$$

   - **Segundo menor principal (Determinante Δ_2)**:

   $$\Delta_2 = \frac{4}{u^4}\left[(4 + x^2 - y^2)(4 - x^2 + y^2) - 4x^2y^2\right]$$

   Utilizando la identidad de diferencia de cuadrados para los términos diagonalizados $(4 + (x^2 - y^2))(4 - (x^2 - y^2)) = 16 - (x^2 - y^2)^2$:

   $$\Delta_2 = \frac{4}{u^4}\left[16 - (x^2 - y^2)^2 - 4x^2y^2\right] = \frac{4}{u^4}\left[16 - (x^4 - 2x^2y^2 + y^4) - 4x^2y^2\right]$$

   $$\Delta_2 = \frac{4}{u^4}\left[16 - (x^4 + 2x^2y^2 + y^4)\right] = \frac{4}{u^4}\left[16 - (x^2 + y^2)^2\right]$$

   Puesto que en el dominio se exige que $x^2 + y^2 < 4$, se deduce que su cuadrado es estrictamente menor a 16 (es decir, $(x^2 + y^2)^2 < 16$). Por tanto:

   $$16 - (x^2 + y^2)^2 > 0 \implies \Delta_2 > 0$$

6. Dado que ambos menores principales son estrictamente positivos en todos los puntos del disco abierto, la matriz hessiana es definida positiva ($\nabla^2 f(x,y) \succ 0$). Concluimos que la función es **estrictamente convexa** en $\mathcal{S}$.

---

3. $f(x,y,z) = x^2 + 2y^2 + 5z^2 + 2xy - 4yz - 2x + 6$ **definida sobre** $\mathbb{R}^3$**.**:

   Solución:

Dada la función $f(x,y,z) = x^2 + 2y^2 + 5z^2 + 2xy - 4yz - 2x + 6$ en $\mathbb{R}^3$:

1. Calculamos el gradiente analítico:

$$\nabla f(x,y,z) = \begin{pmatrix} 2x + 2y - 2 \\ 4y + 2x - 4z \\ 10z - 4y \end{pmatrix}$$

2. Derivamos de nuevo para obtener la matriz hessiana:

$$\nabla^2 f(x,y,z) = \begin{pmatrix} 2 & 2 & 0 \\ 2 & 4 & -4 \\ 0 & -4 & 10 \end{pmatrix}$$

3. Analizamos los menores principales de esta matriz constante:

   - **Menor principal 1**: $\Delta_1 = |2| = 2 > 0$.
   - **Menor principal 2**:

$$\Delta_2 = \det \begin{pmatrix} 2 & 2 \\ 2 & 4 \end{pmatrix} = (2)(4) - (2)(2) = 8 - 4 = 4 > 0$$

   - **Menor principal 3 (Determinante total)**:

$$\Delta_3 = 2 \cdot \det \begin{pmatrix} 4 & -4 \\ -4 & 10 \end{pmatrix} - 2 \cdot \det \begin{pmatrix} 2 & -4 \\ 0 & 10 \end{pmatrix} + 0$$

$$\Delta_3 = 2(40 - 16) - 2(20 - 0) = 2(24) - 40 = 48 - 40 = 8 > 0$$

4. Dado que todos los menores principales de la hessiana son estrictamente positivos ($\Delta_1 > 0, \Delta_2 > 0, \Delta_3 > 0$), la matriz es definida positiva de forma global ($\nabla^2 f \succ 0$).
5. Por lo tanto, la función cuadrática es **estrictamente convexa** (y fuertemente convexa) en todo $\mathbb{R}^3$.

Ejercicio 6: epígrafe, subgradientes y subdiferencial

Sea la función real no diferenciable $f : \mathbb{R} \to \mathbb{R}$ definida por:

$$f(x) = |x| + |x - 1|$$

Se pide:

1. **Trazar la gráfica de la función $f(x)$ en el intervalo $[-1, 2]$ y describir analíticamente su epígrafe epi(f).**:

   Solución:

Dada la función $f(x) = |x| + |x - 1|$:

1. Expresamos la función de forma analítica por intervalos eliminando los valores absolutos:
   - **Caso** $x \leq 0$: $\quad f(x) = -x - (x - 1) = 1 - 2x$.
   - **Caso** $0 < x < 1$: $\quad f(x) = x - (x - 1) = 1$.
   - **Caso** $x \geq 1$: $\quad f(x) = x + (x - 1) = 2x - 1$.
2. La gráfica dibuja una cubeta con pendientes laterales de -2 y $+2$ y un fondo plano horizontal a altura $y = 1$ en el intervalo $[0, 1]$.
3. El epígrafe de la función se define formalmente como el conjunto de puntos en el plano situados por encima de su gráfica:

$$\text{epi}(f) = \{(x, y) \in \mathbb{R}^2 \mid y \geq f(x)\}$$

$$\text{epi}(f) = \left\{ (x, y) \in \mathbb{R}^2 \;\middle|\; y \geq \begin{cases} 1 - 2x & \text{si } x \leq 0 \\ 1 & \text{si } 0 < x < 1 \\ 2x - 1 & \text{si } x \geq 1 \end{cases} \right\}$$

---

2. **Aplicar la definición de subgradiente para calcular el conjunto subdiferencial $\partial f(x)$ en los puntos $x_0 = 0$, $x_0 = 0.5$ y $x_0 = 1$.**:

   Solución:

El subdifferential $\partial f(x_0)$ de una función convexa en un punto x_0 está acotado por las derivadas laterales izquierda (f'_-) y derecha (f'_+):

$$\partial f(x_0) = [f'_-(x_0),\ f'_+(x_0)]$$

1. **En** $x_0 = 0.5$: La función es diferenciable en este punto (está en el tramo plano constante).

   - Derivada izquierda y derecha: $f'(0.5) = 0$.
   - Por tanto, el subdiferencial contiene un único elemento (el gradiente ordinario):

$$\partial f(0.5) = \{0\}$$

2. **En** $x_0 = 0$: El punto es un vértice de no diferenciabilidad.

   - Derivada lateral izquierda: $f'_-(0) = \lim_{h\to 0^-} \frac{(1-2h)-1}{h} = -2$.
   - Derivada lateral derecha: $f'_+(0) = \lim_{h\to 0^+} \frac{1-1}{h} = 0$.
   - Por lo tanto, el subdiferencial es el intervalo cerrado de pendientes intermedias:

$$\partial f(0) = [-2, 0]$$

3. **En** $x_0 = 1$: Es el otro vértice de no diferenciabilidad de la cubeta.

   - Derivada lateral izquierda: $f'_-(1) = \lim_{h\to 0^-} \frac{1-1}{h} = 0$.
   - Derivada lateral derecha: $f'_+(1) = \lim_{h\to 0^+} \frac{(2(1+h)-1)-1}{h} = 2$.
   - Por lo tanto, el subdiferencial es el intervalo:

$$\partial f(1) = [0, 2]$$

---

3. **Explicar la relación entre el conjunto subdiferencial y la optimización no diferenciable. Comprobar si se cumple la condición de optimalidad global ($0 \in \partial f(x^*)$) en el intervalo de puntos de mínimo de la función.**:

   Solución:

- En la optimización no diferenciable de funciones convexas, un punto x^* es un **mínimo global** si y solo si el subgradiente nulo pertenece a su subdiferencial:

$$0 \in \partial f(x^*)$$

- Evaluamos la condición en los tres tramos de mínimos de la función cubeta (los cuales ocurren para todo el intervalo $[0, 1]$):

  – Para cualquier punto estrictamente interior $x_0 \in (0, 1)$, se tiene $\partial f(x_0) = \{0\}$. Obviamente, $0 \in \{0\}$.
  – En el extremo izquierdo $x_0 = 0$, se tiene $\partial f(0) = [-2, 0]$, donde el 0 pertenece al intervalo.
  – En el extremo derecho $x_0 = 1$, se tiene $\partial f(1) = [0, 2]$, donde el 0 también pertenece al intervalo.

- De este modo, la condición de optimalidad de subgradiente identifica correctamente que todo el conjunto factible de mínimos globales de la función es el intervalo cerrado $[0, 1]$, donde el valor de la función es mínimo e igual a 1.

Ejercicio 7: convexidad generalizada: funciones cuasiconvexas y pseudoconvexas

El análisis de la convexidad generalizada nos permite estudiar la unicidad del óptimo en funciones que no cumplen con la definición estricta de convexidad pero que conservan propiedades equivalentes para algoritmos de optimización.

Se pide:

1. **Considerar la función cúbica $f(x) = x^3 - 3x$ en $\mathbb{R}$. Identificar las regiones o intervalos donde la función es convexa, cóncava, cuasiconvexa y pseudoconvexa.**:

   Solución:

Dada la función cúbica $f(x) = x^3 - 3x$ en $\mathbb{R}$:

1. Calculamos las derivadas:

$$f'(x) = 3x^2 - 3 = 3(x-1)(x+1) \qquad \text{y} \qquad f''(x) = 6x$$

2. **Convexidad y Concavidad**:

   - Para $x \geq 0$, la segunda derivada es no negativa ($f''(x) \geq 0$). Por tanto, la función es **convexa** en el intervalo $[0, +\infty)$.
   - Para $x \leq 0$, la segunda derivada es no positiva ($f''(x) \leq 0$). Por tanto, la función es **cóncava** en el intervalo $(-\infty, 0]$.

3. **Cuasiconvexidad**:

   - Una función real es cuasiconvex en un intervalo si sus conjuntos de nivel inferior son convexos, lo que equivale a exigir que la función sea **unimodal** (que decrezca hasta un punto y luego crezca, sin máximos locales intermedios).
   - La función cúbica tiene un máximo local en $x = -1$ (con valor $f(-1) = 2$) y un mínimo local en $x = 1$ (con valor $f(1) = -2$).
   - En el intervalo $[-1, +\infty)$, la función decrece desde 2 hasta el mínimo -2 en $x = 1$ y luego crece monótonamente hasta $+\infty$. Al ser unimodal en esta región, la función es **cuasiconvexa** en el intervalo $[-1, +\infty)$.

4. **Pseudoconvexidad**:

   - En el intervalo $[1, +\infty)$, la función es estrictamente creciente y su derivada es no negativa. Cumple la condición de pseudoconvexidad, siendo de hecho **estrictamente pseudoconvexa** en $[1, +\infty)$.

---

2. **Considerar la función de campana inversa $g(x) = \frac{-1}{x^2+1}$ definida en $\mathbb{R}$. Demostrar que $g(x)$ no es una función convexa sobre $\mathbb{R}$, demostrar que $g(x)$ es cuasiconvexa y pseudoconvexa en todo $\mathbb{R}$, y analizar qué consecuencias tiene para la convergencia de algoritmos de búsqueda local.**:

   Solución:

Dada la función $g(x) = \frac{-1}{x^2+1}$:

- **Verificación de la Convexidad**:

  1. Calculamos la primera derivada de la función:

$$g'(x) = \frac{2x}{(x^2+1)^2}$$

  2. Calculamos la segunda derivada aplicando la regla de la derivada del cociente:

$$g''(x) = \frac{2(x^2+1)^2 - 2x \cdot 2(x^2+1) \cdot 2x}{(x^2+1)^4} = \frac{2(x^2+1) - 8x^2}{(x^2+1)^3} = \frac{2-6x^2}{(x^2+1)^3}$$

  3. Evaluamos el signo de $g''(x)$:
     - La derivada segunda es estrictamente positiva ($g''(x) > 0$) para $|x| < \frac{1}{\sqrt{3}}$.
     - La derivada segunda es estrictamente negativa ($g''(x) < 0$) para $|x| > \frac{1}{\sqrt{3}}$ (zonas laterales de la campana).
  4. Dado que la segunda derivada cambia de signo en el dominio, la función **no es convexa** de manera global en $\mathbb{R}$.

- **Verificación de la Cuasiconvexidad**:

  1. Analizamos el comportamiento de la primera derivada $g'(x) = \frac{2x}{(x^2+1)^2}$:
     - Si $x < 0$, entonces $g'(x) < 0$ (la función es estrictamente decreciente).
     - Si $x = 0$, entonces $g'(x) = 0$ (punto estacionario).
     - Si $x > 0$, entonces $g'(x) > 0$ (la función es estrictamente creciente).
  2. La función decrece monótonamente en $(-\infty, 0]$ y crece monótonamente en $[0, +\infty)$. Al ser unimodal, sus conjuntos de nivel inferior son siempre intervalos convexos.
  3. Por lo tanto, $g(x)$ es **cuasiconvexa** en todo $\mathbb{R}$.

- **Verificación de la Pseudoconvexidad**:

  1. Comprobamos la definición de pseudoconvexidad, la cual exige que para cualquier par de puntos $x, y \in \mathbb{R}$:

  $$g'(x)(y-x) \geq 0 \implies g(y) \geq g(x)$$

  2. Analizamos los casos de evaluación según el signo de la coordenada x:
     - **Caso** $x = 0$: La derivada es nula $g'(0) = 0$. La condición del antecedente $g'(0)(y-0) = 0 \geq 0$ se cumple siempre. La implicación requiere que $g(y) \geq g(0) = -1$ para todo y, lo cual es cierto ya que -1 es el valor mínimo global de la función.
     - **Caso** $x > 0$: En esta región la derivada es positiva $g'(x) > 0$. Por tanto, el antecedente $g'(x)(y-x) \geq 0$ exige que $y - x \geq 0 \implies y \geq x$. Como la función es estrictamente creciente para valores positivos, si $y \geq x$ se cumple necesariamente que $g(y) \geq g(x)$.
     - **Caso** $x < 0$: Aquí la derivada es negativa $g'(x) < 0$. El antecedente $g'(x)(y - x) \geq 0$ exige entonces que $y - x \leq 0 \implies y \leq x$. Como la función es estrictamente decreciente para valores negativos, si $y \leq x$ (es decir, y es más negativo que x) el valor de la función es mayor, cumpliéndose $g(y) \geq g(x)$.
  3. Al verificarse la implicación en todos los casos, la función $g(x)$ es **pseudoconvexa** en todo $\mathbb{R}$.

- **Consecuencias Algorítmicas**: La pseudoconvexidad garantiza que **cualquier mínimo local o punto crítico estacionario es un mínimo global**. Aunque la función no sea convexa (presentando zonas con curvatura cóncava en los laterales del dominio), si aplicamos un algoritmo de búsqueda local de primer orden (como el método del descenso de gradiente) partiendo de cualquier punto inicial $x_0 \in \mathbb{R}$, el algoritmo se moverá en dirección opuesta al gradiente y tendrá la **garantía de converger globalmente al mínimo único** $x^* = 0$, sin quedar atrapado en ningún otro punto estacionario.

Ejercicios del Tema 4: condiciones de optimalidad y KKT

Ejercicio 1: clasificación de puntos estacionarios sin restricciones

Considerar la función real de dos variables:

$$f(x_1, x_2) = x_1^3 - 3x_1x_2^2 + x_2^4 - 2x_2^2$$

1. **Puntos estacionarios (FONC)**: Encontrar todos los puntos estacionarios de la función resolviendo el sistema $\nabla f(x_1, x_2) = 0$.

   Solución:

Calculamos las derivadas parciales de primer orden:

$$\frac{\partial f}{\partial x_1} = 3x_1^2 - 3x_2^2 = 3(x_1^2 - x_2^2) = 0$$

$$\frac{\partial f}{\partial x_2} = -6x_1x_2 + 4x_2^3 - 4x_2 = 2x_2(-3x_1 + 2x_2^2 - 2) = 0$$

De la primera ecuación: $x_1^2 = x_2^2$, es decir, $x_1 = \pm x_2$.

Caso $x_1 = x_2$: Sustituimos en la segunda ecuación:

$$2x_2(-3x_2 + 2x_2^2 - 2) = 0$$

- $x_2 = 0 \implies x_1 = 0$. Punto: $P_1 = (0, 0)$.
- $2x_2^2 - 3x_2 - 2 = 0 \implies x_2 = \frac{3 \pm \sqrt{9+16}}{4} = \frac{3 \pm 5}{4}$.
  - $x_2 = 2 \implies x_1 = 2$. Punto: $P_2 = (2, 2)$.
  - $x_2 = -1/2 \implies x_1 = -1/2$. Punto: $P_3 = (-1/2, -1/2)$.

Caso $x_1 = -x_2$: Sustituimos en la segunda ecuación:

$$2x_2(3x_2 + 2x_2^2 - 2) = 0$$

- $x_2 = 0 \implies x_1 = 0$. Punto: $P_1 = (0, 0)$ (ya encontrado).

- $2x_2^2 + 3x_2 - 2 = 0 \implies x_2 = \frac{-3 \pm \sqrt{9+16}}{4} = \frac{-3 \pm 5}{4}$.
  - $x_2 = 1/2 \implies x_1 = -1/2$. Punto: $P_4 = (-1/2, 1/2)$.
  - $x_2 = -2 \implies x_1 = 2$. Punto: $P_5 = (2, -2)$.

Los **cinco puntos estacionarios** son:

$$P_1 = (0,0), \quad P_2 = (2,2), \quad P_3 = (-1/2, -1/2), \quad P_4 = (-1/2, 1/2), \quad P_5 = (2, -2)$$

---

2. **Clasificación mediante condiciones de segundo orden (SONC/SOSC)**: Calcular la matriz hessiana y clasificar cada punto estacionario.

   Solución:

La matriz hessiana es:

$$\nabla^2 f(x_1, x_2) = \begin{pmatrix} 6x_1 & -6x_2 \\ -6x_2 & -6x_1 + 12x_2^2 - 4 \end{pmatrix}$$

Evaluamos en cada punto estacionario. Para la clasificación, analizamos la traza (tr), el determinante (det) y los autovalores:

- $P_1 = (0,0)$:
$$H(P_1) = \begin{pmatrix} 0 & 0 \\ 0 & -4 \end{pmatrix}$$
$\det(H) = 0$. El Hessiano es semidefinido negativo. La SOSC no se cumple (el determinante es nulo) y la SONC para mínimo exige $H \succeq 0$, que no se verifica. **Punto indeterminado** por condiciones de segundo orden (se requiere análisis de orden superior). Al evaluar la función en un entorno, $f(0, \epsilon) = \epsilon^4 - 2\epsilon^2 < 0 = f(0,0)$ para ϵ pequeño, mientras que $f(\epsilon, 0) = \epsilon^3$ cambia de signo. **Punto de silla**.

- $P_2 = (2,2)$:
$$H(P_2) = \begin{pmatrix} 12 & -12 \\ -12 & 32 \end{pmatrix}$$
$\det(H) = 12 \cdot 32 - 144 = 240 > 0$ y $H_{11} = 12 > 0$. Por la SOSC, $H \succ 0$. **Mínimo local estricto**.

- $P_3 = (-1/2, -1/2)$:
$$H(P_3) = \begin{pmatrix} -3 & 3 \\ 3 & -1 \end{pmatrix}$$
$\det(H) = 3 - 9 = -6 < 0$. Los autovalores tienen signos opuestos. **Punto de silla**.

- $P_4 = (-1/2, 1/2)$:

$$H(P_4) = \begin{pmatrix} -3 & -3 \\ -3 & -1 \end{pmatrix}$$

$\det(H) = 3 - 9 = -6 < 0$. Los autovalores tienen signos opuestos. **Punto de silla**.

- $P_5 = (2, -2)$:

$$H(P_5) = \begin{pmatrix} 12 & 12 \\ 12 & 32 \end{pmatrix}$$

$\det(H) = 384 - 144 = 240 > 0$ y $H_{11} = 12 > 0$. Por la SOSC, $H \succ 0$. **Mínimo local estricto**.

Resumen de clasificación:

Punto	$f(\bar{x})$	$\det(H)$	Clasificación
$P_1 = (0, 0)$	0	0	Punto de silla
$P_2 = (2, 2)$	-8	$240 > 0$	Mínimo local estricto
$P_3 = (-1/2, -1/2)$	$-3/16$	$-6 < 0$	Punto de silla
$P_4 = (-1/2, 1/2)$	$-3/16$	$-6 < 0$	Punto de silla
$P_5 = (2, -2)$	-8	$240 > 0$	Mínimo local estricto

---

3. **Existencia de extremos globales**: Determinar si la función posee mínimo o máximo global.

   Solución:

La función $f(x_1, x_2) = x_1^3 - 3x_1x_2^2 + x_2^4 - 2x_2^2$ no posee mínimo global ni máximo global en $\mathbb{R}^2$:

- Cuando $x_1 \to +\infty$ con $x_2 = 0$: $f(x_1, 0) = x_1^3 \to +\infty$.
- Cuando $x_1 \to -\infty$ con $x_2 = 0$: $f(x_1, 0) = x_1^3 \to -\infty$.

La función es **no acotada** tanto superior como inferiormente, por lo que no posee extremos globales en $\mathbb{R}^2$. Los mínimos locales $P_2 = (2, 2)$ y $P_5 = (2, -2)$ con $f = -8$ son los menores valores locales, pero no globales.

```
import sympy as sp

x1, x2 = sp.symbols('x1 x2')
f = x1**3 - 3*x1*x2**2 + x2**4 - 2*x2**2

# Gradiente
```

```python
grad = [sp.diff(f, v) for v in [x1, x2]]
print("Gradiente:", grad)

# Puntos estacionarios
pts = sp.solve(grad, [x1, x2])
print("\nPuntos estacionarios:")
for p in pts:
    print(f"  {p} -> f = {f.subs([(x1, p[0]), (x2, p[1])])}")

# Hessiana en cada punto
H = sp.Matrix([[sp.diff(f, x1, x1), sp.diff(f, x1, x2)],
               [sp.diff(f, x2, x1), sp.diff(f, x2, x2)]])
print("\nHessiana general:")
sp.pprint(H)

for p in pts:
    Hp = H.subs([(x1, p[0]), (x2, p[1])])
    print(f"\nH{p}: det = {Hp.det()}, eigenvals = {Hp.eigenvals()}")
```

```
Gradiente: [3*x1**2 - 3*x2**2, -6*x1*x2 + 4*x2**3 - 4*x2]

Puntos estacionarios:
  (-1/2, -1/2) -> f = -3/16
  (-1/2, 1/2) -> f = -3/16
  (0, 0) -> f = 0
  (2, -2) -> f = -8
  (2, 2) -> f = -8

Hessiana general:
⎡6⋅x          -6⋅x     ⎤
⎢                      2⎥
⎣-6⋅x   2   -3⋅x  + 6⋅x  - 2⎦

H(-1/2, -1/2): det = -15, eigenvals = {-sqrt(61)/2 - 1/2: 1, -1/2 + sqrt(61)/2: 1}

H(-1/2, 1/2): det = -15, eigenvals = {-sqrt(61)/2 - 1/2: 1, -1/2 + sqrt(61)/2: 1}

H(0, 0): det = 0, eigenvals = {0: 1, -4: 1}

H(2, -2): det = 240, eigenvals = {22 - 2*sqrt(61): 1, 2*sqrt(61) + 22: 1}
```

```
H(2, 2): det = 240, eigenvals = {22 - 2*sqrt(61): 1, 2*sqrt(61) + 22: 1}
```

Ejercicio 2: criterio de derivadas de orden superior (caso univariante)

Considerar la función univariante:

$$f(x) = (x-1)^2(x+1)^2$$

1. **Puntos estacionarios**: Encontrar todos los puntos estacionarios de f en $\mathbb{R}$.

   Solución:

Expandimos la función para facilitar la derivación. Observamos que $f(x) = [(x-1)(x+1)]^2 = (x^2-1)^2 = x^4 - 2x^2 + 1$.

Derivando:

$$f'(x) = 4x^3 - 4x = 4x(x^2-1) = 4x(x-1)(x+1)$$

Igualando a cero: $f'(x) = 0 \implies x = 0, \quad x = 1, \quad x = -1$.

Los **tres puntos estacionarios** son $\bar{x}_1 = -1$, $\bar{x}_2 = 0$ y $\bar{x}_3 = 1$.

---

2. **Criterio de derivadas de orden superior**: Aplicar el criterio para clasificar cada punto estacionario.

   Solución:

Calculamos las derivadas sucesivas:

$$f'(x) = 4x^3 - 4x, \qquad f''(x) = 12x^2 - 4, \qquad f'''(x) = 24x, \qquad f^{(4)}(x) = 24$$

- $\bar{x}_1 = -1$:
  - $f'(-1) = 0$ (estacionario).
  - $f''(-1) = 12 - 4 = 8 > 0$.
  - La primera derivada no nula es $f''(-1) = 8 > 0$, de orden $n = 2$ (par).
  - Por el criterio: **mínimo local**. Valor: $f(-1) = 0$.
- $\bar{x}_2 = 0$:
  - $f'(0) = 0$ (estacionario).
  - $f''(0) = -4 < 0$.

  - La primera derivada no nula es $f''(0) = -4 < 0$, de orden $n = 2$ (par).
  - Por el criterio: **máximo local**. Valor: $f(0) = 1$.

- $\bar{x}_3 = 1$:
  - $f'(1) = 0$ (estacionario).
  - $f''(1) = 12 - 4 = 8 > 0$.
  - La primera derivada no nula es $f''(1) = 8 > 0$, de orden $n = 2$ (par).
  - Por el criterio: **mínimo local**. Valor: $f(1) = 0$.

---

3. **Clasificación final y extremos globales**: Identificar los extremos locales y globales.

   Solución:

- $\bar{x}_1 = -1$ y $\bar{x}_3 = 1$ son **mínimos locales** con $f = 0$.
- $\bar{x}_2 = 0$ es un **máximo local** con $f = 1$.

Dado que $f(x) = (x^2 - 1)^2 \geq 0$ para todo $x \in \mathbb{R}$, y el valor $f = 0$ se alcanza en $x = \pm 1$, estos dos puntos son también **mínimos globales**.

El máximo local $\bar{x}_2 = 0$ con $f(0) = 1$ **no** es un máximo global, ya que $f(x) \to +\infty$ cuando $|x| \to \infty$.

```python
import sympy as sp

x = sp.Symbol('x')
f = (x - 1)**2 * (x + 1)**2

# Derivadas sucesivas
for k in range(1, 5):
    dk = sp.diff(f, x, k)
    print(f"f^({k})(x) = {sp.expand(dk)}")
    for pt in [-1, 0, 1]:
        print(f"  f^({k})({pt}) = {dk.subs(x, pt)}")
```

```
f^(1)(x) = 4*x**3 - 4*x
  f^(1)(-1) = 0
  f^(1)(0) = 0
  f^(1)(1) = 0
f^(2)(x) = 12*x**2 - 4
  f^(2)(-1) = 8
  f^(2)(0) = -4
```

```
  f^(2)(1) = 8
f^(3)(x) = 24*x
  f^(3)(-1) = -24
  f^(3)(0) = 0
  f^(3)(1) = 24
f^(4)(x) = 24
  f^(4)(-1) = 24
  f^(4)(0) = 24
  f^(4)(1) = 24
```

Ejercicio 3: conos de direcciones factibles y de descenso

Considerar el problema de optimización:

$$\begin{aligned} \min_{x_1,x_2\in\mathbb{R}} \quad & f(x_1,x_2) = -x_1 - 2x_2 \\ \text{sujeto a} \quad & g_1(x_1,x_2) = x_1^2 + x_2^2 - 4 \leq 0 \\ & g_2(x_1,x_2) = -x_1 \leq 0 \end{aligned}$$

Se pide evaluar las condiciones de optimalidad basadas en conos de direcciones en los puntos $\bar{x}_A = (2,0)^T$ y $\bar{x}_B = (0,2)^T$.

1. **Restricciones activas y gradientes**: Identificar las restricciones activas en cada punto.

   Solución:

Punto $\bar{x}_A = (2,0)^T$:

- $g_1(2,0) = 4 + 0 - 4 = 0 \rightarrow$ **activa**. $\nabla g_1(2,0) = (2\cdot 2, 2\cdot 0)^T = (4,0)^T$.
- $g_2(2,0) = -2 < 0 \rightarrow$ inactiva.
- Conjunto activo: $\mathcal{I}_A = \{1\}$.

Punto $\bar{x}_B = (0,2)^T$:

- $g_1(0,2) = 0 + 4 - 4 = 0 \rightarrow$ **activa**. $\nabla g_1(0,2) = (0,4)^T$.
- $g_2(0,2) = 0 \rightarrow$ **activa**. $\nabla g_2(0,2) = (-1,0)^T$.
- Conjunto activo: $\mathcal{I}_B = \{1,2\}$.

Además, el gradiente de la función objetivo es constante: $\nabla f = (-1,-2)^T$.

---

2. **Conos de descenso y de restricciones activas**: Determinar $\mathcal{D}_0(\bar{x})$ y $\mathcal{G}_0(\bar{x})$.

   Solución:

El cono analítico de descenso es:

$$\mathcal{D}_0(\bar{x}) = \{d \mid \nabla f^T d < 0\} = \{d \mid -d_1 - 2d_2 < 0\} = \{d \mid d_1 + 2d_2 > 0\}$$

Este cono es el mismo en ambos puntos, ya que ∇f es constante.

En $\bar{x}_A = (2, 0)$ (solo g_1 activa):

$$\mathcal{G}_0(\bar{x}_A) = \{d \mid \nabla g_1(\bar{x}_A)^T d < 0\} = \{d \mid 4d_1 < 0\} = \{d \mid d_1 < 0\}$$

En $\bar{x}_B = (0, 2)$ (g_1 y g_2 activas):

$$\mathcal{G}_0(\bar{x}_B) = \{d \mid \nabla g_1(\bar{x}_B)^T d < 0 \text{ y } \nabla g_2(\bar{x}_B)^T d < 0\} = \{d \mid 4d_2 < 0 \text{ y } -d_1 < 0\} = \{d \mid d_1 > 0,\ d_2 < 0\}$$

---

3. **Comprobación de la condición necesaria de optimalidad**: Verificar si $\mathcal{D}_0 \cap \mathcal{G}_0 = \emptyset$.

   Solución:

En $\bar{x}_A = (2, 0)$**:**

$\mathcal{D}_0 \cap \mathcal{G}_0 = \{d \mid d_1 + 2d_2 > 0 \text{ y } d_1 < 0\}$.

Tomemos $d = (-1, 2)^T$: $d_1 + 2d_2 = -1 + 4 = 3 > 0$ y $d_1 = -1 < 0$. Este vector pertenece a ambos conos. Por tanto, $\mathcal{D}_0 \cap \mathcal{G}_0 \neq \emptyset$ y la condición necesaria de optimalidad **no se satisface**. $\bar{x}_A$ **no** puede ser un óptimo local.

En $\bar{x}_B = (0, 2)$**:**

$\mathcal{D}_0 \cap \mathcal{G}_0 = \{d \mid d_1 + 2d_2 > 0,\ d_1 > 0,\ d_2 < 0\}$.

Para que se cumpla simultáneamente $d_1 > 0$, $d_2 < 0$ y $d_1 + 2d_2 > 0$, necesitaríamos $d_1 > -2d_2 = 2|d_2|$. Pero al exigir $d_1 > 2|d_2|$ con $d_2 < 0$, necesitamos un desplazamiento en x_1 mayor que el doble del desplazamiento en x_2. Comprobemos: si $d = (\alpha, -\beta)$ con $\alpha, \beta > 0$, entonces $d_1 + 2d_2 = \alpha - 2\beta > 0 \implies \alpha > 2\beta$.

Tomando, por ejemplo, $d = (3, -1)^T$: $d_1 + 2d_2 = 3 - 2 = 1 > 0$, $d_1 = 3 > 0$, $d_2 = -1 < 0$. Este vector satisface todas las condiciones, por lo que $\mathcal{D}_0 \cap \mathcal{G}_0 \neq \emptyset$ y la condición necesaria **tampoco** se satisface en $\bar{x}_B$.

En realidad, el mínimo de $f = -x_1 - 2x_2$ sujeto a estas restricciones no se encuentra en ninguno de estos dos puntos. El óptimo se sitúa en el interior del arco circular con $x_1 > 0$, concretamente en $\bar{x}^* = (2/\sqrt{5}, 4/\sqrt{5})^T$.

4. **Interpretación geométrica**: ¿Cuál de los dos puntos puede ser un óptimo local y por qué?

   Solución:

Ninguno de los dos puntos es un óptimo local, ya que en ambos la intersección de conos es no vacía:

- En $\bar{x}_A = (2, 0)$: la dirección de descenso $d = (-1, 2)^T$ (que apunta hacia el interior del disco y "sube" en x_2) es simultáneamente factible y de descenso. Geométricamente, al estar $\bar{x}_A$ en el ecuador del disco, moverse hacia arriba a lo largo de la frontera circular produce un fuerte descenso en f (que depende más de x_2).
- En $\bar{x}_B = (0, 2)$: la dirección $d = (3, -1)^T$ (entrar hacia el interior del disco con aumento de x_1) también es factible y produce descenso. Geométricamente, la función mejora moviéndose a lo largo de la frontera del disco hacia la zona de mayor x_1.

El óptimo global se halla donde el gradiente $\nabla f = (-1, -2)^T$ es proporcional al gradiente de la restricción activa $\nabla g_1 = (2x_1, 2x_2)^T$, lo que nos lleva a $x_2 = 2x_1$ sobre el círculo, dando $\bar{x}^* = (2/\sqrt{5}, 4/\sqrt{5})^T \approx (0.894, 1.789)^T$ con $f(\bar{x}^*) = -2\sqrt{5} \approx -4.47$.

```python
import sympy as sp

x1, x2 = sp.symbols('x1 x2')
f = -x1 - 2*x2
g1 = x1**2 + x2**2 - 4

# El óptimo satisface nabla f + u1 * nabla g1 = 0
u1 = sp.Symbol('u1', positive=True)
eq1 = -1 + u1*2*x1  # df/dx1 + u1*dg1/dx1 = 0
eq2 = -2 + u1*2*x2  # df/dx2 + u1*dg1/dx2 = 0
eq3 = x1**2 + x2**2 - 4  # g1 = 0

sol = sp.solve([eq1, eq2, eq3], [x1, x2, u1])
print("Óptimo KKT:")
for s in sol:
    print(f"  x1={s[0]}, x2={s[1]}, u1={s[2]}, f={f.subs([(x1,s[0]),(x2,s[1])])}")
```

```
Óptimo KKT:
  x1=2*sqrt(5)/5, x2=4*sqrt(5)/5, u1=sqrt(5)/4, f=-2*sqrt(5)
```

Ejercicio 4: condiciones de Fritz-John y fallo de LICQ

Considerar el problema de optimización:

$$\begin{aligned} \min_{x_1,x_2\in\mathbb{R}} \quad & f(x_1,x_2) = x_1 + x_2 \\ \text{sujeto a} \quad & g_1(x_1,x_2) = (x_1-1)^3 - x_2 \leq 0 \\ & g_2(x_1,x_2) = -x_2 \leq 0 \end{aligned}$$

Se pide analizar el punto $\bar{x} = (1,0)^T$.

1. **Factibilidad y restricciones activas**: Verificar que $\bar{x}$ es factible.

   Solución:

Evaluamos las restricciones en $\bar{x} = (1,0)^T$:

- $g_1(1,0) = (1-1)^3 - 0 = 0 \rightarrow$ **activa**.
- $g_2(1,0) = -0 = 0 \rightarrow$ **activa**.

El punto $\bar{x} = (1,0)^T$ es factible ($g_1 \leq 0$ y $g_2 \leq 0$), y **ambas restricciones son activas**, con $\mathcal{J} = \{1,2\}$.

---

2. **Condiciones de Fritz-John**: Plantear el sistema.

   Solución:

Los gradientes en $\bar{x}$ son:

$$\nabla f(1,0) = (1,1)^T$$

$$\nabla g_1(1,0) = (3(x_1-1)^2, -1)^T \Big|_{(1,0)} = (0,-1)^T$$

$$\nabla g_2(1,0) = (0,-1)^T$$

Las condiciones de Fritz-John exigen la existencia de multiplicadores $u_0, u_1, u_2 \geq 0$, no todos nulos, tales que:

$$u_0 \nabla f + u_1 \nabla g_1 + u_2 \nabla g_2 = 0$$

Componente a componente:

$$\begin{cases} u_0 \cdot 1 + u_1 \cdot 0 + u_2 \cdot 0 = 0 \\ u_0 \cdot 1 + u_1 \cdot (-1) + u_2 \cdot (-1) = 0 \end{cases}$$

---

3. **Resolución de los multiplicadores**: Resolver el sistema y analizar u_0.

   Solución:

De la primera ecuación: $u_0 = 0$.

Sustituyendo en la segunda ecuación: $0 - u_1 - u_2 = 0 \implies u_1 + u_2 = 0$.

Dado que $u_1 \geq 0$ y $u_2 \geq 0$, la única solución de $u_1 + u_2 = 0$ es $u_1 = u_2 = 0$. Pero esto contradice la condición de no trivialidad $(u_0, u_1, u_2) \neq (0, 0, 0)$.

Sin embargo, revisando el sistema, la primera ecuación fuerza $u_0 = 0$, y la segunda da $u_1 + u_2 = 0$ con $u_1, u_2 \geq 0$, lo cual obliga a $u_1 = u_2 = 0$, resultando en la solución trivial. Esto indica que las condiciones de Fritz-John **no tienen solución no trivial con multiplicadores no negativos** en el sentido convencional.

En realidad, la condición de Fritz-John sí se satisface formalmente para cualquier $(u_0, u_1, u_2) = (0, \alpha, -\alpha)$ si permitiéramos signos negativos, pero la formulación estándar FJ para mínimos exige $u_i \geq 0$, lo que hace que el sistema no tenga solución no trivial.

Esto significa que $\bar{x} = (1, 0)$ **no satisface las condiciones de Fritz-John** con multiplicadores no negativos, lo cual ocurre porque el punto no es un mínimo local (existen direcciones factibles de descenso). En efecto, $\bar{x}$ no es óptimo: tomando $x = (1 - \epsilon, 0)$ para $\epsilon > 0$ pequeño, se cumple $g_1 = -\epsilon^3 \leq 0$, $g_2 = 0 \leq 0$ y $f = 1 - \epsilon < 1 = f(\bar{x})$.

No es posible que $u_0 > 0$, ya que la primera ecuación lo prohíbe directamente.

---

4. **Comprobación de LICQ e interpretación**: Analizar la independencia lineal de los gradientes.

   Solución:

Los gradientes de las restricciones activas en $\bar{x}$ son:

$$\nabla g_1(1, 0) = (0, -1)^T \qquad \text{y} \qquad \nabla g_2(1, 0) = (0, -1)^T$$

Estos dos vectores son **linealmente dependientes** (de hecho, son idénticos). La condición LICQ **no se satisface** en $\bar{x} = (1, 0)$.

Interpretación: El fallo de LICQ tiene una causa geométrica clara. La restricción $g_1 = (x_1 - 1)^3 - x_2 \leq 0$ tiene un gradiente que se anula en su componente x_1 exactamente en $x_1 = 1$ (el exponente cúbico hace que la frontera tenga tangencia de tercer orden con la horizontal). Esto provoca que $\nabla g_1(1, 0) = (0, -1)^T$, que es colineal con $\nabla g_2 = (0, -1)^T$.

Cuando LICQ falla, las condiciones KKT no son aplicables como condiciones necesarias. Las condiciones de Fritz-John, siendo más generales, deberían capturar los candidatos, pero en este caso el punto no es un óptimo (existen direcciones factibles de descenso tangentes a la frontera cúbica).

```
import sympy as sp

x1, x2 = sp.symbols('x1 x2')
g1 = (x1 - 1)**3 - x2
g2 = -x2
f = x1 + x2

# Gradientes en (1, 0)
print("nabla f(1,0) =", [sp.diff(f, v).subs([(x1,1),(x2,0)]) for v in [x1,x2]])
print("nabla g1(1,0) =", [sp.diff(g1, v).subs([(x1,1),(x2,0)]) for v in [x1,x2]])
print("nabla g2(1,0) =", [sp.diff(g2, v).subs([(x1,1),(x2,0)]) for v in [x1,x2]])

# Verificar que (1,0) no es óptimo: evaluar f en (1-eps, 0)
eps = sp.Symbol('epsilon', positive=True)
x_test = (1 - eps, 0)
print(f"\nf(1-eps, 0) = {f.subs([(x1, x_test[0]), (x2, x_test[1])])}")
print(f"g1(1-eps, 0) = {g1.subs([(x1, x_test[0]), (x2, x_test[1])])}")
```

```
nabla f(1,0) = [1, 1]
nabla g1(1,0) = [0, -1]
nabla g2(1,0) = [0, -1]

f(1-eps, 0) = 1 - epsilon
g1(1-eps, 0) = -epsilon**3
```

Ejercicio 5: resolución KKT completa con análisis por casos

Considerar el problema de optimización:

$$\begin{aligned} \min_{x_1,x_2\in\mathbb{R}} \quad & f(x_1,x_2) = (x_1-3)^2 + (x_2-1)^2 \\ \text{sujeto a} \quad & g_1(x_1,x_2) = x_1^2 + x_2^2 - 4 \leq 0 \\ & g_2(x_1,x_2) = x_1 + x_2 - 1 \leq 0 \end{aligned}$$

1. **Función lagrangiana y sistema KKT**: Construir el lagrangiano y plantear las condiciones KKT.

   Solución:

La función lagrangiana es:

$$L(x,u) = (x_1-3)^2 + (x_2-1)^2 + u_1(x_1^2+x_2^2-4) + u_2(x_1+x_2-1)$$

Las condiciones KKT son:

Estacionariedad ($\nabla_x L = 0$):

$$\begin{cases} \frac{\partial L}{\partial x_1} = 2(x_1-3) + 2u_1x_1 + u_2 = 0 \\ \frac{\partial L}{\partial x_2} = 2(x_2-1) + 2u_1x_2 + u_2 = 0 \end{cases}$$

Factibilidad primal:

$$g_1(x) = x_1^2 + x_2^2 - 4 \leq 0, \qquad g_2(x) = x_1 + x_2 - 1 \leq 0$$

Holgura complementaria:

$$u_1 g_1(x) = 0, \qquad u_2 g_2(x) = 0$$

Factibilidad dual:

$$u_1 \geq 0, \qquad u_2 \geq 0$$

---

2. **Resolución por casos**: Analizar los cuatro casos combinatorios.

   Solución:

(a) Caso: $u_1 = 0$, $u_2 = 0$ (ambas inactivas):

El sistema de estacionariedad se reduce a:

$$\begin{cases} 2(x_1-3) = 0 \implies x_1 = 3 \\ 2(x_2-1) = 0 \implies x_2 = 1 \end{cases}$$

El candidato es $(3,1)$. Verificamos factibilidad primal:

$$g_1(3,1) = 9 + 1 - 4 = 6 > 0 \quad \text{(no factible)}$$

Descartado: viola la factibilidad primal.

(b) Caso: $u_1 \neq 0$**,** $u_2 = 0$ **(solo** g_1 **activa):**

Holgura complementaria exige $g_1 = 0$: $x_1^2 + x_2^2 = 4$.

El sistema de estacionariedad queda:

$$\begin{cases} 2(x_1 - 3) + 2u_1 x_1 = 0 \implies x_1(1 + u_1) = 3 \\ 2(x_2 - 1) + 2u_1 x_2 = 0 \implies x_2(1 + u_1) = 1 \end{cases}$$

Dividiendo: $\frac{x_1}{x_2} = 3$, es decir, $x_1 = 3x_2$. Sustituyendo en $x_1^2 + x_2^2 = 4$:

$$9x_2^2 + x_2^2 = 4 \implies 10x_2^2 = 4 \implies x_2 = \pm\frac{2}{\sqrt{10}}$$

- $x_2 = \frac{2}{\sqrt{10}} \approx 0.632$, $x_1 = \frac{6}{\sqrt{10}} \approx 1.897$. De $x_1(1 + u_1) = 3$: $u_1 = \frac{3}{x_1} - 1 = \frac{3\sqrt{10}}{6} - 1 = \frac{\sqrt{10}}{2} - 1 \approx 0.581 > 0$. Factibilidad: $g_2 = x_1 + x_2 - 1 = \frac{8}{\sqrt{10}} - 1 \approx 1.53 > 0$. **No factible**.

- $x_2 = -\frac{2}{\sqrt{10}}$, $x_1 = -\frac{6}{\sqrt{10}}$. De $x_1(1 + u_1) = 3$: $1 + u_1 = \frac{3}{-6/\sqrt{10}} = -\frac{\sqrt{10}}{2} < 0$, por lo que $u_1 < 0$.

Descartado en ambos subcasos.

(c) Caso: $u_1 = 0$**,** $u_2 \neq 0$ **(solo** g_2 **activa):**

Holgura complementaria exige $g_2 = 0$: $x_1 + x_2 = 1$.

El sistema de estacionariedad queda:

$$\begin{cases} 2(x_1 - 3) + u_2 = 0 \implies u_2 = -2(x_1 - 3) = 6 - 2x_1 \\ 2(x_2 - 1) + u_2 = 0 \implies u_2 = -2(x_2 - 1) = 2 - 2x_2 \end{cases}$$

Igualando: $6 - 2x_1 = 2 - 2x_2 \implies x_2 - x_1 = -2 \implies x_1 = x_2 + 2$.

Sustituyendo en $x_1 + x_2 = 1$: $x_2 + 2 + x_2 = 1 \implies x_2 = -1/2$, $x_1 = 3/2$.

- $u_2 = 6 - 2(3/2) = 3 > 0$.
- Factibilidad: $g_1(3/2, -1/2) = 9/4 + 1/4 - 4 = 10/4 - 4 = -3/2 < 0$.

Candidato válido: $\bar{x}_C = (3/2, -1/2)$ con $u_2 = 3$.

Valor de la función objetivo: $f(3/2, -1/2) = (3/2-3)^2 + (-1/2-1)^2 = 9/4 + 9/4 = 9/2 = 4.5$.

(d) Caso: $u_1 \neq 0$**,** $u_2 \neq 0$ **(ambas activas):**

Ambas restricciones activas: $x_1^2 + x_2^2 = 4$ y $x_1 + x_2 = 1$.

De $x_1 = 1 - x_2$: $(1-x_2)^2 + x_2^2 = 4 \implies 2x_2^2 - 2x_2 - 3 = 0$.

$$x_2 = \frac{2 \pm \sqrt{4+24}}{4} = \frac{2 \pm \sqrt{28}}{4} = \frac{1 \pm \sqrt{7}}{2}$$

- $x_2 = \frac{1+\sqrt{7}}{2} \approx 1.823$, $x_1 = \frac{1-\sqrt{7}}{2} \approx -0.823$.

  De la estacionariedad:

  $$u_2 = -2(x_1 - 3) - 2u_1 x_1 \qquad \text{y} \qquad u_2 = -2(x_2 - 1) - 2u_1 x_2$$

  Igualando: $-2(x_1 - 3) - 2u_1 x_1 = -2(x_2 - 1) - 2u_1 x_2$

  $$-2x_1 + 6 - 2u_1 x_1 = -2x_2 + 2 - 2u_1 x_2$$

  $$2(x_2 - x_1) + 4 = 2u_1(x_1 - x_2)$$

  $$2(x_2 - x_1)(1 + u_1) = -4 \implies u_1 = \frac{-4}{2(x_2 - x_1)} - 1$$

  Con $x_2 - x_1 = \sqrt{7}$: $u_1 = \frac{-2}{\sqrt{7}} - 1 \approx -1.756 < 0$.

- $x_2 = \frac{1-\sqrt{7}}{2} \approx -0.823$, $x_1 = \frac{1+\sqrt{7}}{2} \approx 1.823$.

  Con $x_2 - x_1 = -\sqrt{7}$: $u_1 = \frac{-2}{-\sqrt{7}} - 1 = \frac{2}{\sqrt{7}} - 1 \approx -0.244 < 0$.

Descartado en ambos subcasos: $u_1 < 0$.

---

3. **Verificación de factibilidad y signo de multiplicadores**: Resumen de candidatos válidos.

   Solución:

Caso	$\bar{x}$	u_1	u_2	Factible	$u_i \geq 0$	Válido
(a) $u_1 = u_2 = 0$	$(3, 1)$	0	0			
(b) g_1 activa	$(6/\sqrt{10}, 2/\sqrt{10})$	0.58	0			
(c) g_2 activa	$(3/2, -1/2)$	0	3			

Caso	$\bar{x}$	u_1	u_2	Factible	$u_i \geq 0$	Válido
(d) Ambas activas	$(\frac{1\pm\sqrt{7}}{2}, \frac{1\mp\sqrt{7}}{2})$	< 0	-			

El **único candidato KKT válido** es $\bar{x}_C = (3/2, -1/2)$.

---

4. **Mínimo global**: Clasificar el candidato.

   Solución:

El único candidato KKT válido es $\bar{x}_C = (3/2, -1/2)$ con $f(\bar{x}_C) = 9/2$.

Para confirmar que es el mínimo global, observamos que:

- La función objetivo $f(x_1, x_2) = (x_1 - 3)^2 + (x_2 - 1)^2$ es estrictamente convexa (su hessiana es $2I \succ 0$).
- La restricción $g_1 = x_1^2 + x_2^2 - 4$ es convexa (cuadrática con hessiana $2I \succ 0$).
- La restricción $g_2 = x_1 + x_2 - 1$ es afín (convexa y cuasiconvexa).
- La región factible es la intersección de un disco y un semiplano, que es un conjunto convexo, cerrado y acotado (compacto).

Al ser un problema de minimización convexa sobre un conjunto compacto, el teorema de suficiencia KKT garantiza que el candidato KKT es el **mínimo global**:

$$\bar{x}^* = (3/2, -1/2), \qquad f^* = 9/2$$

```python
import sympy as sp

x1, x2, u1, u2 = sp.symbols('x1 x2 u1 u2')
f = (x1 - 3)**2 + (x2 - 1)**2
g1 = x1**2 + x2**2 - 4
g2 = x1 + x2 - 1

L = f + u1*g1 + u2*g2
dL1 = sp.diff(L, x1)
dL2 = sp.diff(L, x2)

# Caso c: u1=0, g2=0
sol_c = sp.solve([dL1.subs(u1,0), dL2.subs(u1,0), g2], [x1, x2, u2])
print("Caso (c):", sol_c)
```

```python
xc = sol_c[x1], sol_c[x2]
print(f"f(3/2, -1/2) = {f.subs([(x1, xc[0]), (x2, xc[1])])}")
print(f"g1(3/2, -1/2) = {g1.subs([(x1, xc[0]), (x2, xc[1])])}")
```

```
Caso (c): {u2: 3, x1: 3/2, x2: -1/2}
f(3/2, -1/2) = 9/2
g1(3/2, -1/2) = -3/2
```

Ejercicio 6: KKT y condiciones de suficiencia bajo convexidad

Considerar el problema de optimización:

$$\begin{aligned} \min_{x_1,x_2\in\mathbb{R}} \quad & f(x_1,x_2) = x_1^2 + x_2^2 \\ \text{sujeto a} \quad & g_1(x_1,x_2) = -x_1 - x_2 + 1 \leq 0 \end{aligned}$$

1. **Resolución KKT**: Plantear y resolver las condiciones KKT.

   Solución:

La función lagrangiana es $L = x_1^2 + x_2^2 + u_1(-x_1 - x_2 + 1)$.

Estacionariedad:

$$\begin{cases} 2x_1 - u_1 = 0 \implies x_1 = u_1/2 \\ 2x_2 - u_1 = 0 \implies x_2 = u_1/2 \end{cases}$$

De las ecuaciones de estacionariedad: $x_1 = x_2 = u_1/2$.

Caso $u_1 = 0$ (restricción inactiva): $x_1 = x_2 = 0$. Pero $g_1(0,0) = 1 > 0$: no factible. **Descartado**.

Caso $u_1 > 0$ (restricción activa, $g_1 = 0$): $-x_1 - x_2 + 1 = 0 \implies x_1 + x_2 = 1$. Sustituyendo $x_1 = x_2$: $2x_1 = 1 \implies x_1 = x_2 = 1/2$, y $u_1 = 2x_1 = 1 > 0$.

El **candidato KKT** es $\bar{x} = (1/2, 1/2)$ con $u_1 = 1$ y $f(\bar{x}) = 1/2$.

---

2. **Convexidad de la función objetivo**: Verificar que f es estrictamente convexa.

   Solución:

La hessiana de f es:

$$\nabla^2 f = \begin{pmatrix} 2 & 0 \\ 0 & 2 \end{pmatrix} = 2I$$

Los autovalores son $\lambda_1 = \lambda_2 = 2 > 0$. La hessiana es definida positiva ($\nabla^2 f \succ 0$) para todo punto del dominio. Por lo tanto, f es **estrictamente convexa** en $\mathbb{R}^2$.

Una función estrictamente convexa es, en particular, pseudoconvexa: si $\nabla f(\bar{x})^T(y - \bar{x}) \geq 0$ entonces $f(y) \geq f(\bar{x})$, con igualdad solo si $y = \bar{x}$.

---

3. **Cuasiconvexidad de la restricción**: Verificar que g_1 es convexa y cuasiconvexa.

   Solución:

La restricción $g_1(x_1, x_2) = -x_1 - x_2 + 1$ es una función **afín** (lineal más constante). Toda función afín es simultáneamente convexa y cóncava, y por tanto también cuasiconvexa y cuasicóncava.

Su hessiana es la matriz nula $\nabla^2 g_1 = 0$, que es trivialmente semidefinida positiva. Se cumple la condición requerida por el teorema de suficiencia.

---

4. **Aplicación del teorema de suficiencia KKT**: Demostrar que el candidato es mínimo global.

   Solución:

Aplicamos el teorema de suficiencia KKT:

Hipótesis:

1. $\bar{x} = (1/2, 1/2)$ satisface todas las condiciones KKT (verificado en el apartado 1).
2. f es pseudoconvexa (es estrictamente convexa, como se demostró en el apartado 2).
3. La restricción activa g_1 es cuasiconvexa (es afín, como se verificó en el apartado 3).

Demostración:

Sea x cualquier punto factible ($g_1(x) \leq 0$). Como $g_1(\bar{x}) = 0$ (activa) y $g_1(x) \leq 0$, se tiene:

$$g_1(x) \leq g_1(\bar{x})$$

Por la cuasiconvexidad de g_1, los conjuntos de subnivel son convexos y se cumple que:

$$\nabla g_1(\bar{x})^T(x - \bar{x}) \leq 0$$

Dado que $\nabla g_1 = (-1,-1)^T$ y $u_1 = 1 > 0$, por la condición de estacionariedad:

$$\nabla f(\bar{x}) = -u_1 \nabla g_1(\bar{x}) = (1,1)^T$$

Entonces:

$$\nabla f(\bar{x})^T (x - \bar{x}) = -u_1 \nabla g_1(\bar{x})^T (x - \bar{x}) \geq 0$$

(ya que $u_1 > 0$ y $\nabla g_1(\bar{x})^T (x - \bar{x}) \leq 0$).

Finalmente, como f es pseudoconvexa y $\nabla f(\bar{x})^T (x - \bar{x}) \geq 0$, se concluye:

$$f(x) \geq f(\bar{x}) \qquad \forall x \text{ factible}$$

Por tanto, $\bar{x} = (1/2, 1/2)$ es el **mínimo global** del problema, con $f^* = 1/2$. ■

Ejercicio 7: KKT con restricciones mixtas (igualdad y desigualdad)

Considerar el problema de optimización:

$$\begin{aligned} \min_{x_1, x_2 \in \mathbb{R}} \quad & f(x_1, x_2) = x_1^2 + 2x_2^2 \\ \text{sujeto a} \quad & h_1(x_1, x_2) = x_1 + x_2 - 2 = 0 \\ & g_1(x_1, x_2) = -x_1 \leq 0 \end{aligned}$$

1. **Condiciones KKT generalizadas**: Plantear el sistema KKT con restricciones mixtas.

   Solución:

La función lagrangiana generalizada es:

$$L(x, u, v) = x_1^2 + 2x_2^2 + u_1(-x_1) + v_1(x_1 + x_2 - 2)$$

Las condiciones KKT generalizadas son:

Estacionariedad ($\nabla_x L = 0$):

$$\begin{cases} 2x_1 - u_1 + v_1 = 0 \\ 4x_2 + v_1 = 0 \end{cases}$$

Factibilidad primal:

$$h_1 : x_1 + x_2 - 2 = 0, \qquad g_1 : -x_1 \leq 0 \text{ (i.e., } x_1 \geq 0)$$

Holgura complementaria:

$$u_1 \cdot (-x_1) = 0$$

Factibilidad dual:

$$u_1 \geq 0, \qquad v_1 \in \mathbb{R} \text{ (libre)}$$

---

2. **Resolución por casos**: Analizar los dos casos.

   Solución:

(a) Caso: g_1 inactiva ($x_1 > 0$, $u_1 = 0$):

El sistema se simplifica a:

$$\begin{cases} 2x_1 + v_1 = 0 \implies v_1 = -2x_1 \\ 4x_2 + v_1 = 0 \implies v_1 = -4x_2 \\ x_1 + x_2 = 2 \end{cases}$$

De las dos primeras: $-2x_1 = -4x_2 \implies x_1 = 2x_2$. Sustituyendo en la igualdad: $2x_2 + x_2 = 2 \implies x_2 = 2/3$, $x_1 = 4/3$.

- $v_1 = -2 \cdot 4/3 = -8/3$.
- Comprobación: $x_1 = 4/3 > 0$. (la restricción de desigualdad es inactiva, como asumimos).

Candidato válido: $\bar{x}_A = (4/3, 2/3)$ con $u_1 = 0$, $v_1 = -8/3$ y $f(\bar{x}_A) = 16/9 + 8/9 = 24/9 = 8/3 \approx 2.667$.

(b) Caso: g_1 activa ($x_1 = 0$, $u_1 \geq 0$):

El sistema queda:

$$\begin{cases} 0 - u_1 + v_1 = 0 \implies v_1 = u_1 \\ 4x_2 + v_1 = 0 \\ 0 + x_2 = 2 \implies x_2 = 2 \end{cases}$$

De la segunda: $v_1 = -4 \cdot 2 = -8$, y por tanto $u_1 = v_1 = -8 < 0$.

Descartado: $u_1 < 0$ viola la factibilidad dual.

---

3. **Verificación de factibilidad y condiciones de signo**: Resumen.

   Solución:

Caso	$\bar{x}$	u_1	v_1	Factible	$u_1 \geq 0$	Válido
(a) g_1 inactiva	$(4/3, 2/3)$	0	$-8/3$			
(b) g_1 activa	$(0, 2)$	-8	-8			

El único candidato KKT válido es $\bar{x}^* = (4/3, 2/3)$ con $f^* = 8/3$.

Dado que f es estrictamente convexa, h_1 es afín y g_1 es afín, el problema es convexo y el candidato KKT es el **mínimo global**:

$$\bar{x}^* = (4/3, 2/3), \qquad f^* = 8/3 \approx 2.667$$

---

4. **Signo libre del multiplicador de igualdad**: Justificar por qué v_1 puede ser de cualquier signo.

   Solución:

El multiplicador v_1 asociado a la restricción de igualdad $h_1(x) = 0$ tiene **signo libre** ($v_1 \in \mathbb{R}$), a diferencia del multiplicador $u_1 \geq 0$ de la restricción de desigualdad. La razón fundamental es la siguiente:

- Una restricción de **desigualdad** $g_i(x) \leq 0$ define una frontera que separa la región factible de la no factible. El multiplicador u_i mide la "presión" de la restricción sobre el óptimo. Si la restricción se relaja (se mueve la frontera), la función objetivo solo puede mejorar o mantenerse igual, lo que impone un signo definido al multiplicador ($u_i \geq 0$ para minimización).
- Una restricción de **igualdad** $h_j(x) = 0$ confina el movimiento a una variedad (hipersuperficie). No existe una dirección "privilegiada" de relajación: la restricción puede violarse tanto en la dirección $h_j > 0$ como $h_j < 0$. Por tanto, el multiplicador v_j puede ser positivo, negativo o nulo según la posición relativa del gradiente del objetivo respecto a la variedad de la restricción.

En nuestro caso, $v_1 = -8/3 < 0$, lo cual es perfectamente válido. Esto indica que si relajáramos la igualdad $x_1 + x_2 = 2$ a $x_1 + x_2 = 2 + \epsilon$, el valor óptimo de f disminuiría (mejoraría) en $|v_1| \cdot \epsilon$ unidades para $\epsilon > 0$ pequeño.

```
import sympy as sp

x1, x2, u1, v1 = sp.symbols('x1 x2 u1 v1')
f = x1**2 + 2*x2**2
L = f + u1*(-x1) + v1*(x1 + x2 - 2)
```

```python
dL1 = sp.diff(L, x1)
dL2 = sp.diff(L, x2)
h1 = x1 + x2 - 2

# Caso (a): u1=0
sol_a = sp.solve([dL1.subs(u1, 0), dL2, h1], [x1, x2, v1])
print("Caso (a):", sol_a)
print(f"f = {f.subs([(x1, sol_a[x1]), (x2, sol_a[x2])])}")

# Caso (b): x1=0
sol_b = sp.solve([dL1.subs(x1, 0), dL2, h1.subs(x1, 0)], [x2, u1, v1])
print("\nCaso (b):", sol_b)
```

```
Caso (a): {v1: -8/3, x1: 4/3, x2: 2/3}
f = 8/3

Caso (b): {u1: -8, v1: -8, x2: 2}
```

Ejercicio 8: análisis combinatorio de Fritz-John en región mixta

1. **Caso A: Frontera Simétrica**

   Solución:

La región factible está delimitada por el círculo de radio $\sqrt{5}$ y la recta $x_1 + x_2 = 3$. La intersección de ambas curvas ocurre en los puntos $(1, 2)$ y $(2, 1)$, que actúan como "esquinas" o vértices de la frontera. El gradiente del objetivo es $\nabla f = (2(x_1 - 3), 2(x_2 - 2))^T$.

- **Esquina** $\bar{x} = (2, 1)$: Las restricciones activas son g_1 y g_2. Los gradientes son $\nabla g_1 = (4, 2)^T$ y $\nabla g_2 = (1, 1)^T$, los cuales son linealmente independientes. El gradiente del objetivo es $\nabla f(2, 1) = (-2, -2)^T$. La ecuación de Fritz-John es:

$$u_0 \begin{pmatrix} -2 \\ -2 \end{pmatrix} + u_1 \begin{pmatrix} 4 \\ 2 \end{pmatrix} + u_2 \begin{pmatrix} 1 \\ 1 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

  Para $u_0 = 1$ (KKT):

$$\begin{cases} -2 + 4u_1 + u_2 = 0 \\ -2 + 2u_1 + u_2 = 0 \end{cases} \implies 2u_1 = 0 \implies u_1 = 0,\ u_2 = 2 \geq 0$$

Al obtener multiplicadores no negativos ($u_1 = 0 \geq 0$, $u_2 = 2 \geq 0$), se satisfacen las condiciones KKT con $u_0 = 1$, siendo este punto un candidato a mínimo local (el óptimo global).

- **Esquina** $\bar{x} = (1, 2)$: Las restricciones activas son también g_1 y g_2, con gradientes $\nabla g_1 = (2, 4)^T$ y $\nabla g_2 = (1, 1)^T$. El gradiente del objetivo es $\nabla f(1, 2) = (-4, 0)^T$. Planteando la ecuación dual:

$$u_0 \begin{pmatrix} -4 \\ 0 \end{pmatrix} + u_1 \begin{pmatrix} 2 \\ 4 \end{pmatrix} + u_2 \begin{pmatrix} 1 \\ 1 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

Si intentamos resolver para $u_0 = 1$ (KKT):

$$\begin{cases} -4 + 2u_1 + u_2 = 0 \\ 4u_1 + u_2 = 0 \end{cases} \implies -2u_1 = 4 \implies u_1 = -2 < 0$$

Al resultar $u_1 < 0$, el punto se descarta como mínimo bajo las condiciones KKT. Si intentamos resolver con $u_0 = 0$, dado que los gradientes activos son linealmente independientes, la única solución es $u_1 = u_2 = 0$, lo que infringe la condición de no trivialidad. Por tanto, el punto $(1, 2)$ no verifica Fritz-John.

---

2. **Caso B: Frontera Asimétrica**

   Solución:

Modificamos la restricción lineal a $g_2(x) = x_1 + 2x_2 - 4 \leq 0$. La intersección de la recta y el círculo en el primer cuadrante ocurre en el punto $\bar{x} = (2, 1)$.

- **Esquina** $\bar{x} = (2, 1)$: Las restricciones activas son g_1 y g_2, con gradientes linealmente independientes $\nabla g_1 = (4, 2)^T$ y $\nabla g_2 = (1, 2)^T$. El gradiente del objetivo es $\nabla f(2, 1) = (-2, -2)^T$. La ecuación de Fritz-John:

$$u_0 \begin{pmatrix} -2 \\ -2 \end{pmatrix} + u_1 \begin{pmatrix} 4 \\ 2 \end{pmatrix} + u_2 \begin{pmatrix} 1 \\ 2 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

Para $u_0 = 1$:

$$\begin{cases} -2 + 4u_1 + u_2 = 0 \\ -2 + 2u_1 + 2u_2 = 0 \end{cases} \implies 3u_1 - 1 = 0 \implies u_1 = 1/3 \geq 0,\ u_2 = 2/3 \geq 0$$

Al ser ambos multiplicadores strictly positivos, el punto satisface las condiciones KKT con $u_0 = 1$ y es candidato a mínimo local.

- **Esquina** $\bar{x} = (0, 2)$: Las restricciones activas son la frontera lineal g_2 y el eje de ordenadas $g_3 = -x_1 \leq 0$. Los gradientes activos son $\nabla g_2 = (1, 2)^T$ y $\nabla g_3 = (-1, 0)^T$. El gradiente del objetivo es $\nabla f(0, 2) = (-6, 0)^T$. Planteando la ecuación dual:

$$u_0 \begin{pmatrix} -6 \\ 0 \end{pmatrix} + u_2 \begin{pmatrix} 1 \\ 2 \end{pmatrix} + u_3 \begin{pmatrix} -1 \\ 0 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

  Para $u_0 = 1$, la segunda fila exige $2u_2 = 0 \implies u_2 = 0$. Sustituyendo en la primera fila: $-6 - u_3 = 0 \implies u_3 = -6 < 0$, descartando el punto. Si fijamos $u_0 = 0$, la independencia de los gradientes activos obliga a $u_2 = u_3 = 0$, por lo que tampoco verifica Fritz-John.

```python
import sympy as sp

x1, x2, u0, u1, u2, u3 = sp.symbols('x1 x2 u0 u1 u2 u3')
f = (x1 - 3)**2 + (x2 - 2)**2
g1 = x1**2 + x2**2 - 5
g2_a = x1 + x2 - 3
g2_b = x1 + 2*x2 - 4
g3 = -x1

# Verificación Caso A en (2,1)
grad_f = sp.Matrix([sp.diff(f, x1), sp.diff(f, x2)]).subs([(x1, 2), (x2, 1)])
grad_g1 = sp.Matrix([sp.diff(g1, x1), sp.diff(g1, x2)]).subs([(x1, 2), (x2, 1)])
grad_g2 = sp.Matrix([sp.diff(g2_a, x1), sp.diff(g2_a, x2)]).subs([(x1, 2), (x2, 1)])

eq_a = u0 * grad_f + u1 * grad_g1 + u2 * grad_g2
sol_a = sp.solve(eq_a.subs(u0, 1), [u1, u2])
print("Caso A en (2,1):", sol_a)

# Verificación Caso B en (2,1)
grad_g2_b = sp.Matrix([sp.diff(g2_b, x1), sp.diff(g2_b, x2)]).subs([(x1, 2), (x2, 1)])
eq_b = u0 * grad_f + u1 * grad_g1 + u2 * grad_g2_b
sol_b = sp.solve(eq_b.subs(u0, 1), [u1, u2])
print("Caso B en (2,1):", sol_b)
```

```
Caso A en (2,1): {u1: 0, u2: 2}
Caso B en (2,1): {u1: 1/3, u2: 2/3}
```

Ejercicios del Tema 5: dualidad KKT en programación lineal y cuadrática

Ejercicio 1: formulación KKT, dualidad e interpretación de precios sombra en LP

Considerar el problema de programación lineal de maximización de beneficio:

$$\begin{aligned} \max_{x_1,x_2} \quad & z = 3x_1 + 5x_2 \\ \text{sujeto a} \quad & x_1 \leq 4 \quad (g_1) \\ & 2x_2 \leq 12 \quad (g_2) \\ & 3x_1 + 2x_2 \leq 18 \quad (g_3) \\ & x_1, x_2 \geq 0 \end{aligned}$$

Se pide:

1. Transformar el problema a la forma canónica de minimización $\min c^T x$ s.a. $Ax \leq b, x \geq 0$ y derivar analíticamente el sistema KKT completo (estacionariedad, factibilidad primal, factibilidad dual y holgura complementaria).

   Solución:

   Convertimos el problema a la forma canónica de minimización multiplicando la función objetivo por -1:

   $$\begin{aligned} \min_{x_1,x_2} \quad & f(x_1, x_2) = -3x_1 - 5x_2 \\ \text{sujeto a} \quad & x_1 - 4 \leq 0 \quad (g_1) \\ & 2x_2 - 12 \leq 0 \quad (g_2) \\ & 3x_1 + 2x_2 - 18 \leq 0 \quad (g_3) \\ & -x_1 \leq 0, \quad -x_2 \leq 0 \end{aligned}$$

   Asociando multiplicadores KKT $u_1, u_2, u_3 \geq 0$ a las tres restricciones generales de desigualdad y $v_1, v_2 \geq 0$ a la no negatividad, la función Lagrangiana es:

   $$L(x, u, v) = -3x_1 - 5x_2 + u_1(x_1 - 4) + u_2(2x_2 - 12) + u_3(3x_1 + 2x_2 - 18) - v_1 x_1 - v_2 x_2$$

El **sistema KKT completo** resulta:

- **Estacionariedad**:

$$\frac{\partial L}{\partial x_1} = -3 + u_1 + 3u_3 - v_1 = 0 \implies u_1 + 3u_3 - v_1 = 3$$

$$\frac{\partial L}{\partial x_2} = -5 + 2u_2 + 2u_3 - v_2 = 0 \implies 2u_2 + 2u_3 - v_2 = 5$$

- **Factibilidad Primal**: $x_1 \leq 4$, $2x_2 \leq 12$, $3x_1 + 2x_2 \leq 18$, $x_1 \geq 0$, $x_2 \geq 0$.
- **Factibilidad Dual**: $u_1 \geq 0$, $u_2 \geq 0$, $u_3 \geq 0$, $v_1 \geq 0$, $v_2 \geq 0$.
- **Holgura Complementaria**:

$$u_1(x_1 - 4) = 0$$

$$u_2(2x_2 - 12) = 0$$

$$u_3(3x_1 + 2x_2 - 18) = 0$$

$$v_1 x_1 = 0, \quad v_2 x_2 = 0$$

---

2. Formular formalmente el problema dual de Lagrange asociado (D).

Solución:

Tomando las condiciones de estacionariedad duales $v_1 = u_1 + 3u_3 - 3 \geq 0$ y $v_2 = 2u_2 + 2u_3 - 5 \geq 0$, el problema dual (D) se maximiza sobre los multiplicadores de Lagrange $u_1, u_2, u_3 \geq 0$:

$$\begin{aligned} \max_{u_1,u_2,u_3} \quad & w(u) = -4u_1 - 12u_2 - 18u_3 \\ \text{sujeto a} \quad & u_1 + 3u_3 \geq 3 \\ & 2u_2 + 2u_3 \geq 5 \\ & u_1, u_2, u_3 \geq 0 \end{aligned}$$

(O equivalentemente en función del problema original de maximización primal: $\min 4u_1 + 12u_2 + 18u_3$ s.a. $u_1 + 3u_3 \geq 3, 2u_2 + 2u_3 \geq 5, u \geq 0$).

---

3. Sabiendo que la solución primal óptima es $\bar{x} = (2, 6)^T$, aplicar el teorema de holgura complementaria para calcular exactamente los multiplicadores de Lagrange KKT u_1^*, u_2^*, u_3^* y verificar que constituyen una solución factible y óptima del problema dual.

   Solución:

   Evaluamos el punto primal $\bar{x} = (2, 6)^T$ en las restricciones:

   - $g_1(2, 6) = 2 - 4 = -2 < 0 \implies$ Inactiva $\implies u_1^* = 0$.
   - $g_2(2, 6) = 2(6) - 12 = 0 \implies$ Activa.
   - $g_3(2, 6) = 3(2) + 2(6) - 18 = 0 \implies$ Activa.
   - Dado que $x_1^* = 2 > 0$ y $x_2^* = 6 > 0$, la holgura complementaria exige $v_1^* = 0$ y $v_2^* = 0$.

   Sustituimos $u_1^* = 0$, $v_1^* = 0$ y $v_2^* = 0$ en el sistema de estacionariedad:

$$3u_3^* = 3 \implies u_3^* = 1$$

$$2u_2^* + 2(1) = 5 \implies 2u_2^* = 3 \implies u_2^* = \frac{3}{2}$$

   Los multiplicadores óptimos son:

$$u_1^* = 0, \quad u_2^* = \frac{3}{2} = 1.5, \quad u_3^* = 1$$

   Verificamos que $u_1^*, u_2^*, u_3^* \geq 0$ (factibilidad dual) y calculamos el valor de la función objetivo dual:

$$w(u^*) = -4(0) - 12(1.5) - 18(1) = -18 - 18 = -36$$

   El coste primal de minimización es $f(2, 6) = -3(2) - 5(6) = -36$, satisfaciendo la **dualidad fuerte** $f(\bar{x}) = w(u^*)$. En el problema original de maximización, el beneficio es $z^* = 36$.

---

4. Interpretar económicamente los precios sombra hallados: ¿cuál es el coste marginal de oportunidad asociado a cada una de las tres restricciones? Si el término independiente de la tercera restricción aumenta de $b_3 = 18$ a $b_3 = 19$, ¿cuál será el nuevo beneficio óptimo esperado?

   Solución:

   - **Precios sombra**:
     - $u_1^* = 0$: La restricción 1 es inactiva (se usan 2 unidades de 4 disponibles). Modificar el límite b_1 aporta un valor marginal nulo.

  - $u_2^* = 1.5$: La restricción 2 está activa. Cada unidad adicional en el término independiente b_2 incrementará el beneficio en 1.5 unidades monetarias.
  - $u_3^* = 1.0$: La restricción 3 está activa. Cada unidad adicional en el término independiente b_3 incrementará el beneficio en 1.0 unidad monetaria.
- **Sensibilidad ante cambio en** b_3: Si b_3 pasa de 18 a 19 ($\Delta b_3 = +1$), el nuevo beneficio óptimo esperado será:

$$z^*_{nuevo} = z^*_{actual} + u^*_3 \cdot \Delta b_3 = 36 + 1.0 \cdot (1) = 37$$

Ejercicio 2: degeneración, sobredeterminación y relaciones de dualidad

Considerar el problema de programación lineal:

$$\begin{aligned} \min_{x_1,x_2} \quad & f(x_1,x_2) = -2x_1 - 4x_2 \\ \text{sujeto a} \quad & x_1 + x_2 \leq 4 \quad (g_1) \\ & -x_1 + x_2 \leq 2 \quad (g_2) \\ & x_2 \leq 3 \quad (g_3) \\ & x_1, x_2 \geq 0 \end{aligned}$$

Se pide:

1. Resolver gráficamente el problema primal y verificar que el óptimo se alcanza en el vértice $\bar{x} = (1,3)^T$.

   Solución:

   Evaluamos los vértices de la región factible:

   - $(0,0) \implies f = 0$
   - $(0,2) \implies f = -8$
   - $(1,3) \implies f = -2(1) - 4(3) = -14$
   - $(3,1) \implies f = -2(3) - 4(1) = -10$
   - $(3.5,0) \implies f = -7$

   El mínimo valor de la función objetivo es $f^* = -14$, alcanzándose de forma única en el vértice $\bar{x} = (1,3)^T$.

---

2. Identificar las restricciones activas en $\bar{x}$ y justificar por qué existe sobredeterminación geométrica ($m_{activas} > n$) y fallo de la cualificación de restricciones de independencia lineal (LICQ).

   Solución:

   Evaluamos las restricciones en $\bar{x} = (1, 3)^T$:

   - $g_1(1, 3) = 1 + 3 = 4 \implies$ Activa
   - $g_2(1, 3) = -1 + 3 = 2 \implies$ Activa
   - $g_3(1, 3) = 3 = 3 \implies$ Activa

   Hay $m_{activas} = 3$ restricciones activas en un espacio de dimensión $n = 2$. Dado que $m_{activas} = 3 > 2 = n$, el vértice $\bar{x}$ está **sobredeterminado (degenerado en el primal)**. Los tres gradientes de las restricciones activas son:

$$\nabla g_1 = \begin{pmatrix} 1 \\ 1 \end{pmatrix}, \quad \nabla g_2 = \begin{pmatrix} -1 \\ 1 \end{pmatrix}, \quad \nabla g_3 = \begin{pmatrix} 0 \\ 1 \end{pmatrix}$$

   Tres vectores en $\mathbb{R}^2$ son necesariamente linealmente dependientes. Por tanto, **falla la condición de cualificación de restricciones (LICQ)**.

---

3. Plantear el sistema KKT de estacionariedad en $\bar{x} = (1, 3)^T$ y determinar la familia infinita de vectores de multiplicadores duales (u_1, u_2, u_3) que satisfacen las condiciones KKT.

   Solución:

   Dado que $x_1^* = 1 > 0$ y $x_2^* = 3 > 0$, las holguras duales son $v_1^* = 0, v_2^* = 0$. La ecuación de estacionariedad KKT exige:

$$-\nabla f(\bar{x}) = u_1 \nabla g_1 + u_2 \nabla g_2 + u_3 \nabla g_3$$

$$\begin{pmatrix} 2 \\ 4 \end{pmatrix} = u_1 \begin{pmatrix} 1 \\ 1 \end{pmatrix} + u_2 \begin{pmatrix} -1 \\ 1 \end{pmatrix} + u_3 \begin{pmatrix} 0 \\ 1 \end{pmatrix}$$

   Obtenemos el sistema lineal en (u_1, u_2, u_3):

$$1) \quad u_1 - u_2 = 2 \implies u_1 = u_2 + 2$$

$$2) \quad u_1 + u_2 + u_3 = 4$$

   Sustituimos $u_1 = u_2 + 2$ en la segunda ecuación:

$$(u_2 + 2) + u_2 + u_3 = 4 \implies 2u_2 + u_3 = 2 \implies u_3 = 2 - 2u_2$$

   Exigiendo factibilidad dual $u_1 \geq 0, u_2 \geq 0, u_3 \geq 0$:

- $u_2 \geq 0$
- $u_3 \geq 0 \implies 2 - 2u_2 \geq 0 \implies u_2 \leq 1$

Por tanto, existe una **infinidad de vectores KKT válidos** parametrizados por $u_2 \in [0, 1]$:

$$u(u_2) = (u_2 + 2,\, u_2,\, 2 - 2u_2)^T, \quad \forall u_2 \in [0, 1]$$

Extremos notables:

- Para $u_2 = 0 \implies u = (2, 0, 2)^T$.
- Para $u_2 = 1 \implies u = (3, 1, 0)^T$.

---

4. Clasificar el par primal-dual dentro de las 6 relaciones fundamentales de dualidad estudiadas en la teoría.

   Solución:

   Dado que la solución primal es única pero sobredeterminada ($m_{activas} > n$), el problema primal presenta **degeneración**. Como consecuencia, el sistema de multiplicadores de Lagrange KKT no es único, existiendo un segmento continuo de soluciones duales óptimas. Corresponde al **Caso 2 de Dualidad**: **Solución Primal Única Degenerada $\iff$ Múltiples Soluciones Duales Óptimas**.

Ejercicio 3: derivación analítica del sistema KKT en programación cuadrática (QP)

Considerar el problema de optimización cuadrática:

$$\begin{aligned} \min_{x_1, x_2} \quad & f(x_1, x_2) = \frac{1}{2}x_1^2 + x_2^2 - 4x_1 - 6x_2 \\ \text{sujeto a} \quad & x_1 + x_2 \leq 3 \quad (g_1) \\ & x_1 + 2x_2 \leq 4 \quad (g_2) \\ & x_1, x_2 \geq 0 \end{aligned}$$

Se pide:

1. Identificar la matriz cuadrática Q y el vector lineal c. Comprobar que Q es estrictamente definida positiva ($Q \succ 0$), garantizando la convexidad estricta del problema y la existencia de un único mínimo global.

   Solución:

   Reescribiendo la función objetivo cuadrática en forma matricial:

   $$f(x) = \frac{1}{2}x^T Q x + c^T x$$

   obtenemos:

   $$Q = \begin{pmatrix} 1 & 0 \\ 0 & 2 \end{pmatrix}, \quad c = \begin{pmatrix} -4 \\ -6 \end{pmatrix}$$

   Los autovalores de la matriz diagonal Q son $\lambda_1 = 1 > 0$ y $\lambda_2 = 2 > 0$. Al ser sus autovalores estrictamente positivos, $Q \succ 0$ es **estrictamente definida positiva**. La función objetivo es estrictamente convexa y la región factible es un poliedro convexo, lo que garantiza que todo punto KKT es un **único óptimo global absoluto**.

---

2. Calcular el mínimo libre no restringido $x_0 = -Q^{-1}c$ y verificar si pertenece a la región factible.

   Solución:

   El mínimo global sin restricciones se obtiene resolviendo $\nabla f(x) = Qx + c = 0$:

   $$x_0 = -Q^{-1}c = -\begin{pmatrix} 1 & 0 \\ 0 & 1/2 \end{pmatrix}\begin{pmatrix} -4 \\ -6 \end{pmatrix} = \begin{pmatrix} 4 \\ 3 \end{pmatrix}$$

   Evaluamos $x_0 = (4, 3)^T$ en las restricciones:

   $$g_1(4, 3) = 4 + 3 = 7 > 3 \quad \text{(Violada)}$$

   El mínimo no restringido $(4, 3)^T$ está fuera de la región factible, por lo que el óptimo se alcanzará necesariamente en la frontera del conjunto factible.

---

3. Formular la función de Lagrange KKT y escribir la ecuación de estacionariedad $Qx + A^T u - v = -c$.

   Solución:

$$L(x,u,v) = \frac{1}{2}x_1^2 + x_2^2 - 4x_1 - 6x_2 + u_1(x_1 + x_2 - 3) + u_2(x_1 + 2x_2 - 4) - v_1x_1 - v_2x_2$$

Derivando con respecto a x_1 y x_2:

$$\frac{\partial L}{\partial x_1} = x_1 - 4 + u_1 + u_2 - v_1 = 0 \implies x_1 + u_1 + u_2 - v_1 = 4$$

$$\frac{\partial L}{\partial x_2} = 2x_2 - 6 + u_1 + 2u_2 - v_2 = 0 \implies 2x_2 + u_1 + 2u_2 - v_2 = 6$$

En forma matricial $Qx + A^T u - v = -c$:

$$\begin{pmatrix} 1 & 0 \\ 0 & 2 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} + \begin{pmatrix} 1 & 1 \\ 1 & 2 \end{pmatrix} \begin{pmatrix} u_1 \\ u_2 \end{pmatrix} - \begin{pmatrix} v_1 \\ v_2 \end{pmatrix} = \begin{pmatrix} 4 \\ 6 \end{pmatrix}$$

---

4. Introducir las variables de holgura primales $y_1, y_2 \geq 0$ y representar el sistema matricial KKT lineal completo de Wolfe.

   Solución:

   Introduciendo las variables de holgura primales $y_1, y_2 \geq 0$:

$$x_1 + x_2 + y_1 = 3$$

$$x_1 + 2x_2 + y_2 = 4$$

   El sistema completo en bloques lineales resulta:

$$\begin{pmatrix} 1 & 0 & 0 & 0 & 1 & 1 & -1 & 0 \\ 0 & 2 & 0 & 0 & 1 & 2 & 0 & -1 \\ 1 & 1 & 1 & 0 & 0 & 0 & 0 & 0 \\ 1 & 2 & 0 & 1 & 0 & 0 & 0 & 0 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ y_1 \\ y_2 \\ u_1 \\ u_2 \\ v_1 \\ v_2 \end{pmatrix} = \begin{pmatrix} 4 \\ 6 \\ 3 \\ 4 \end{pmatrix}$$

   sujeto a $x, y, u, v \geq 0$ y $u_1y_1 + u_2y_2 + v_1x_1 + v_2x_2 = 0$.

---

5. Resolver analíticamente el sistema KKT por el método de casos sobre las restricciones activas para obtener la solución óptima exacta $(\bar{x}_1, \bar{x}_2)$ y sus multiplicadores duales (u_1^*, u_2^*).

   Solución:

   Analizamos la activación de las restricciones:

   - **Caso A (g_1 inactiva, g_2 activa)**: $y_1 > 0 \implies u_1 = 0$. Con $u_2 > 0 \implies y_2 = 0$.

   $$x_1 + 2x_2 = 4 \implies x_1 = 4 - 2x_2$$

   $$x_1 + u_2 = 4 \implies (4 - 2x_2) + u_2 = 4 \implies u_2 = 2x_2$$

   $$2x_2 + 2u_2 = 6 \implies 2x_2 + 2(2x_2) = 6 \implies 6x_2 = 6 \implies x_2^* = 1$$

   $$x_1^* = 4 - 2(1) = 2, \quad u_2^* = 2(1) = 2$$

   Comprobamos factibilidad primal en g_1:

   $$g_1(2,1) = 2 + 1 = 3 \leq 3 \quad \text{(Satisfecha como igualdad, } y_1^* = 0)$$

   En el punto $\bar{x} = (2,1)^T$, convergen ambas restricciones activas (g_1 y g_2).

   - **Caso B (Ambas restricciones activas g_1, g_2)**:

   $$x_1 + x_2 = 3$$

   $$x_1 + 2x_2 = 4 \implies x_2^* = 1,\ x_1^* = 2$$

   Sustituimos $x_1^* = 2, x_2^* = 1$ en el sistema de estacionariedad ($v_1 = 0, v_2 = 0$ pues $x > 0$):

   $$2 + u_1 + u_2 = 4 \implies u_1 + u_2 = 2$$

   $$2(1) + u_1 + 2u_2 = 6 \implies u_1 + 2u_2 = 4$$

   Restando ambas ecuaciones: $u_2^* = 2 \implies u_1^* = 0$.

   La solución óptima global única es:

   $$\bar{x} = (2,1)^T, \quad u_1^* = 0, \quad u_2^* = 2, \quad f(2,1) = \frac{1}{2}(4) + 1 - 8 - 6 = -11$$

Ejercicio 4: aplicación iterativa del algoritmo del Símplex de Wolfe

Considerar el problema cuadrático simple:

$$\begin{aligned} \min_{x_1,x_2} \quad & f(x_1,x_2) = x_1^2 + x_2^2 - 6x_1 - 4x_2 \\ \text{sujeto a} \quad & x_1 + x_2 \leq 2 \\ & x_1, x_2 \geq 0 \end{aligned}$$

Se pide:

1. Escribir las ecuaciones de factibilidad primal con la variable de holgura $y_1 \geq 0$ y las ecuaciones de estacionariedad KKT introduciendo las variables artificiales $z_1, z_2 \geq 0$.

   Solución:

   - **Factibilidad primal**: $x_1 + x_2 + y_1 = 2$, con $y_1 \geq 0$.
   - **Estacionariedad KKT con artificiales**:

   $$\frac{\partial f}{\partial x_1} = 2x_1 - 6 + u_1 - v_1 + z_1 = 0 \implies 2x_1 + u_1 - v_1 + z_1 = 6$$

   $$\frac{\partial f}{\partial x_2} = 2x_2 - 4 + u_1 - v_2 + z_2 = 0 \implies 2x_2 + u_1 - v_2 + z_2 = 4$$

---

2. Construir la tabla inicial del Símplex de Wolfe en el origen $(x_1 = 0, x_2 = 0)$.

   Solución:

   En el origen $x_1 = 0, x_2 = 0$, la holgura es $y_1 = 2$, y las artificiales valen $z_1 = 6, z_2 = 4$. Función objetivo auxiliar artificial: $\min W = z_1 + z_2 = 6 + 4 = 10$.

Base	Sol.	x_1	x_2	y_1	u_1	v_1	v_2	z_1	z_2
y_1	2	1	1	1	0	0	0	0	0
z_1	6	2	0	0	1	-1	0	1	0
z_2	4	0	2	0	1	0	-1	0	1
Coste	10	-2	-2	0	-2	1	1	0	0

---

3. Aplicar rigurosamente la **regla de entrada restringida de Wolfe** en cada iteración: determinar qué variables duales están bloqueadas por la presencia de sus primales correspondientes en la base.

   Solución:

   En la base inicial $\{y_1, z_1, z_2\}$:

   - Como $y_1 \in$ Base, la variable dual u_1 **está bloqueada** y no puede entrar en la base.
   - Las únicas variables primales candidatas a entrar con coste reducido negativo son x_1 (coste -2) y x_2 (coste -2).

---

4. Ejecutar las iteraciones del algoritmo de pivotaje del Símplex hasta conseguir que la suma de variables artificiales sea $z_1 + z_2 = 0$.

   Solución:

   - **Iteración 1**:
     Seleccionamos $x_1 \downarrow$ como variable entrante (coste -2).
     Cocientes mínimos: fila 1 ($2/1 = 2$), fila 2 ($6/2 = 3$).
     Sale de la base $y_1 \uparrow$ en la fila 1 con pivote **1**.

     Nueva tabla tras pivotar en x_1 (fila 1):

Base	Sol.	x_1	x_2	y_1	u_1	v_1	v_2	z_1	z_2
x_1	2	1	1	1	0	0	0	0	0
z_1	2	0	-2	-2	1	-1	0	1	0
z_2	4	0	2	0	1	0	-1	0	1
Coste	6	0	0	2	-2	1	1	0	0

   - **Iteración 2**:
     Al haber salido y_1 de la base, la variable dual $u_1 \downarrow$ **queda desbloqueada y entra** en la base (coste reducido -2).
     Cocientes mínimos: fila 2 ($2/1 = 2$), fila 3 ($4/1 = 4$).
     Sale de la base la variable artificial $z_1 \uparrow$ en la fila 2 con pivote **1**.

     Nueva tabla tras pivotar en u_1 (fila 2):

Base	Sol.	x_1	x_2	y_1	u_1	v_1	v_2	z_1	z_2
x_1	2	1	1	1	0	0	0	0	0
u_1	2	0	-2	-2	1	-1	0	1	0

Base	Sol.	x_1	x_2	y_1	u_1	v_1	v_2	z_1	z_2
z_2	2	0	4	2	0	1	-1	-1	1
Coste	2	0	-4	-2	0	-1	1	2	0

- **Iteración 3**:
  Entra $x_2 \downarrow$ (coste reducido -4). Como $v_2 \notin$ Base, x_2 es libre de entrar.
  Cocientes mínimos: fila 1 ($2/1 = 2$), fila 3 ($2/4 = 0.5$).
  Sale de la base la última variable artificial $z_2 \uparrow$ en la fila 3 con pivote **4**.

  Tabla Óptima Final:

Base	Sol.	x_1	x_2	y_1	u_1	v_1	v_2	z_1	z_2
x_1	1.5	1	0	1/2	0	$-1/4$	1/4	1/4	$-1/4$
u_1	3.0	0	0	-1	1	$-1/2$	$-1/2$	1/2	1/2
x_2	0.5	0	1	1/2	0	1/4	$-1/4$	$-1/4$	1/4
Coste	0	0	0	0	0	0	0	1	1

  Suma artificial $W = z_1 + z_2 = 0$. Algoritmo finalizado.

---

5. Extraer la solución óptima primal $(\bar{x}_1, \bar{x}_2)$, el multiplicador dual u_1^* y verificar el cumplimiento estricto de la condición KKT de tangencia.

   Solución:

   - **Solución óptima primal**: $\bar{x}_1 = 1.5$, $\bar{x}_2 = 0.5$.
   - **Holgura primal**: $y_1^* = 0$ (restricción $x_1 + x_2 \leq 2$ activa $1.5 + 0.5 = 2$).
   - **Multiplicador dual KKT**: $u_1^* = 3.0 \geq 0$.
   - **Verificación KKT de tangencia**:

$$\nabla f(1.5, 0.5) = \begin{pmatrix} 2(1.5) - 6 \\ 2(0.5) - 4 \end{pmatrix} = \begin{pmatrix} -3 \\ -3 \end{pmatrix}$$

$$\nabla g_1(1.5, 0.5) = \begin{pmatrix} 1 \\ 1 \end{pmatrix}$$

$$-\nabla f(\bar{x}) = \begin{pmatrix} 3 \\ 3 \end{pmatrix} = u_1^* \nabla g_1 = 3.0 \begin{pmatrix} 1 \\ 1 \end{pmatrix}$$

   Se verifica la condición KKT de estacionariedad y tangencia con $u_1^* = 3.0$.

Ejercicios del Tema 6: grafos y árboles soporte de mínimo peso

Ejercicio 1: fundamentos de grafos, digrafos y lema de la suma de grados

Considerar la red dirigida $G_D = (V, A)$ sobre el conjunto de 6 vértices $V = \{1, 2, 3, 4, 5, 6\}$ con la siguiente colección de 10 arcos orientados:

$$A = \{(1,2), (1,3), (2,3), (2,4), (3,4), (3,5), (4,5), (4,6), (5,6), (6,1)\}$$

Se pide:

1. Dibujar el esquema conceptual de la red dirigida y calcular para cada nodo $v \in V$ su grado de entrada $\deg^-(v)$, su grado de salida $\deg^+(v)$ y su grado total $\deg(v)$.

   Solución:

   Analizamos sistemáticamente cada nodo $v \in V$ contabilizando de forma explícita sus arcos de entrada (cuyo destino es v) y de salida (cuyo origen es v):

   - **Nodo 1**:
     - Arcos de entrada: $\{(6,1)\} \implies \deg^-(1) = 1$.
     - Arcos de salida: $\{(1,2), (1,3)\} \implies \deg^+(1) = 2$.
     - Grado total: $\deg(1) = \deg^-(1) + \deg^+(1) = 1 + 2 = 3$.
   - **Nodo 2**:
     - Arcos de entrada: $\{(1,2)\} \implies \deg^-(2) = 1$.
     - Arcos de salida: $\{(2,3), (2,4)\} \implies \deg^+(2) = 2$.
     - Grado total: $\deg(2) = 1 + 2 = 3$.
   - **Nodo 3**:
     - Arcos de entrada: $\{(1,3), (2,3)\} \implies \deg^-(3) = 2$.
     - Arcos de salida: $\{(3,4), (3,5)\} \implies \deg^+(3) = 2$.
     - Grado total: $\deg(3) = 2 + 2 = 4$.
   - **Nodo 4**:
     - Arcos de entrada: $\{(2,4), (3,4)\} \implies \deg^-(4) = 2$.

- Arcos de salida: $\{(4,5),(4,6)\} \implies \deg^+(4) = 2$.
- Grado total: $\deg(4) = 2 + 2 = 4$.

- **Nodo 5**:
  - Arcos de entrada: $\{(3,5),(4,5)\} \implies \deg^-(5) = 2$.
  - Arcos de salida: $\{(5,6)\} \implies \deg^+(5) = 1$.
  - Grado total: $\deg(5) = 2 + 1 = 3$.
- **Nodo 6**:
  - Arcos de entrada: $\{(4,6),(5,6)\} \implies \deg^-(6) = 2$.
  - Arcos de salida: $\{(6,1)\} \implies \deg^+(6) = 1$.
  - Grado total: $\deg(6) = 2 + 1 = 3$.

---

2. Verificar numéricamente la versión para digrafos del *Handshaking Lemma*: $\sum_{v\in V} \deg^+(v) = \sum_{v\in V} \deg^-(v) = m$.

   Solución:

   Sumamos vectorialmente la totalidad de los grados de salida y de entrada de los 6 vértices:

   $$\sum_{v=1}^{6} \deg^+(v) = \deg^+(1)+\deg^+(2)+\deg^+(3)+\deg^+(4)+\deg^+(5)+\deg^+(6) = 2+2+2+2+1+1 = 10$$

   $$\sum_{v=1}^{6} \deg^-(v) = \deg^-(1)+\deg^-(2)+\deg^-(3)+\deg^-(4)+\deg^-(5)+\deg^-(6) = 1+1+2+2+2+2 = 10$$

   Puesto que la red posee exactamente $m = 10$ arcos orientados, se verifica rigurosamente la identidad teórica del *Handshaking Lemma*:

   $$\sum_{v\in V} \deg^+(v) = \sum_{v\in V} \deg^-(v) = m = 10$$

---

3. Si el sentido de los arcos se ignora para construir el grafo no dirigido subyacente $G = (V, E)$, calcular el grado $\deg(v)$ de cada vértice en G y comprobar que $\sum_{v\in V} \deg(v) = 2m$.

   Solución:

   En el grafo no dirigido subyacente $G = (V, E)$, la dirección de paso desaparece y el grado $\deg_G(v)$ coincide con el número total de aristas incidentes en cada vértice:

   - $\deg_G(1) = 3$
   - $\deg_G(2) = 3$
   - $\deg_G(3) = 4$

- $\deg_G(4) = 4$
- $\deg_G(5) = 3$
- $\deg_G(6) = 3$

Calculamos la suma total de los grados en G:

$$\sum_{v \in V} \deg_G(v) = 3 + 3 + 4 + 4 + 3 + 3 = 20$$

Puesto que $m = 10$, comprobamos la formulación clásica del *Handshaking Lemma* no dirigido:

$$2m = 2(10) = 20 \implies \sum_{v \in V} \deg_G(v) = 2m$$

---

4. Para el subconjunto de nodos $A = \{2, 3, 4\}$, evaluar analíticamente la incidencia exterior $w^+(A)$, la incidencia interior $w^-(A)$ y el corte total $w(A)$.

   Solución:

   Consideramos el subconjunto de nodos $A = \{2, 3, 4\}$ y su complemento exógeno $V \setminus A = \{1, 5, 6\}$.

   - **Incidencia exterior** $w^+(A)$: Formada por todos los arcos (u, v) cuyo origen reside en A ($u \in \{2, 3, 4\}$) y cuyo destino pertenece al exterior $V \setminus A$ ($v \in \{1, 5, 6\}$):
     - Evaluando los arcos de 2: $(2, 3) \in A \times A$, $(2, 4) \in A \times A \implies$ Ninguno sale a $V \setminus A$.
     - Evaluando los arcos de 3: $(3, 4) \in A \times A$, $(3, 5) \implies$ Arco $(3, 5)$ sale a $V \setminus A$.
     - Evaluando los arcos de 4: $(4, 5)$ y $(4, 6) \implies$ Salen a $V \setminus A$.
     - Por tanto:
     $$w^+(A) = \{(3, 5), (4, 5), (4, 6)\}$$
   - **Incidencia interior** $w^-(A)$: Formada por todos los arcos (u, v) cuyo origen está en $V \setminus A$ ($u \in \{1, 5, 6\}$) y su destino entra a A ($v \in \{2, 3, 4\}$):
     - Evaluando arcos desde 1: $(1, 2)$ y $(1, 3) \implies$ Entran a A.
     - Evaluando arcos desde 5: $(5, 6) \implies$ Permanece en $V \setminus A$.
     - Evaluando arcos desde 6: $(6, 1) \implies$ Permanece en $V \setminus A$.
     - Por tanto:
     $$w^-(A) = \{(1, 2), (1, 3)\}$$
   - **Corte total** $w(A)$: Unión disjunta de la incidencia exterior e interior:

   $$w(A) = w^+(A) \cup w^-(A) = \{(1, 2), (1, 3), (3, 5), (4, 5), (4, 6)\}$$

Ejercicio 2: tipología de grafos, subgrafos y grafos complementarios

Considérese el grafo simple no dirigido $G = (V, E)$ de $n = 6$ vértices con conjunto de aristas $E = \{\{1,2\},\{1,3\},\{2,3\},\{3,4\},\{4,5\},\{4,6\},\{5,6\}\}$.

Se pide:

1. Clasificar el grafo G: determinar si es simple, completo, regular o bipartito. Justificar analíticamente la respuesta utilizando el Teorema de caracterización de grafos bipartitos (ausencia de ciclos impares).

   Solución:

   - **Simple**: Sí. No contiene bucles autodirigidos ($\{v, v\} \notin E$) ni aristas múltiples entre un mismo par de vértices.
   - **Completo**: No. El grafo contiene $m = 7$ aristas, mientras que un grafo completo de 6 vértices K_6 requiere $\binom{6}{2} = \frac{6\times5}{2} = 15$ aristas.
   - **Regular**: No. La secuencia de grados de los vértices es $\deg(1) = 2, \deg(2) = 2, \deg(3) = 3, \deg(4) = 3, \deg(5) = 2, \deg(6) = 2$, los cuales no son idénticos.
   - **Bipartito**: No. Por el **Teorema de caracterización de grafos bipartitos**, un grafo es bipartito si y solo si no contiene ningún ciclo de longitud impar. En G, los vértices $\{1, 2, 3\}$ forman el triangulo simple $C_3 = \{\{1,2\},\{2,3\},\{3,1\}\}$, que es un ciclo impar de longitud 3. Por consiguiente, G **no es bipartito**.

---

2. Construir el subgrafo inducido por el subconjunto de vértices $S = \{1, 2, 3, 4\}$, denotado por $G[S]$. Indicar su número de aristas y si es un clan (*clique*).

   Solución:

   El subgrafo inducido $G[S]$ se construye seleccionando los nodos $S = \{1, 2, 3, 4\}$ y **todas** las aristas de E cuyas dos extremidades pertenezcan a S:

   $$E[S] = \{\{u, v\} \in E \mid u, v \in S\} = \{\{1,2\},\{1,3\},\{2,3\},\{3,4\}\}$$

   El subgrafo inducido $G[S]$ contiene $m(G[S]) = 4$ aristas. **No es un clan (*clique*)**, pues para constituir un clan completo de 4 vértices (K_4) debería contener la totalidad de sus $\binom{4}{2} = 6$ aristas posibles, faltándole las aristas $\{1, 4\}$ y $\{2, 4\}$.

---

3. Obtener el grafo complementario $\bar{G} = (V, \bar{E})$ y verificar numéricamente que el número de aristas satisface la relación $m(G) + m(\bar{G}) = \binom{n}{2}$.

   Solución:

   El grafo complementario $\bar{G} = (V, \bar{E})$ mantiene el mismo conjunto de vértices V, y su conjunto de aristas $\bar{E}$ incluye todas las aristas no presentes en G:

   $$\bar{E} = \{\{1,4\},\{1,5\},\{1,6\},\{2,4\},\{2,5\},\{2,6\},\{3,5\},\{3,6\}\}$$

   Contabilizamos las aristas complementarias: $m(\bar{G}) = 8$. Comprobamos la relación de cobertura completa del grafo completo K_6:

   $$m(G) + m(\bar{G}) = 7 + 8 = 15 = \binom{6}{2}$$

---

4. Calcular el grado de cada vértice en $\bar{G}$ y comprobar que $\deg_{\bar{G}}(v) = n - 1 - \deg_G(v)$ para todo $v \in V$.

   Solución:

   Calculamos numéricamente los grados de cada vértice en $\bar{G}$:

   - $\deg_{\bar{G}}(1) = 6 - 1 - \deg_G(1) = 5 - 2 = 3$ (vecinos en $\bar{G}$: $\{4,5,6\}$)
   - $\deg_{\bar{G}}(2) = 6 - 1 - \deg_G(2) = 5 - 2 = 3$ (vecinos en $\bar{G}$: $\{4,5,6\}$)
   - $\deg_{\bar{G}}(3) = 6 - 1 - \deg_G(3) = 5 - 3 = 2$ (vecinos en $\bar{G}$: $\{5,6\}$)
   - $\deg_{\bar{G}}(4) = 6 - 1 - \deg_G(4) = 5 - 3 = 2$ (vecinos en $\bar{G}$: $\{1,2\}$)
   - $\deg_{\bar{G}}(5) = 6 - 1 - \deg_G(5) = 5 - 2 = 3$ (vecinos en $\bar{G}$: $\{1,2,3\}$)
   - $\deg_{\bar{G}}(6) = 6 - 1 - \deg_G(6) = 5 - 2 = 3$ (vecinos en $\bar{G}$: $\{1,2,3\}$)

   La suma de grados en $\bar{G}$ es $3 + 3 + 2 + 2 + 3 + 3 = 16 = 2(8) = 2m(\bar{G})$, verificando la consistencia del modelo.

Ejercicio 3: recorridos, cadenas, caminos y métricas de red

En un grafo no dirigido $G = (V, E)$ sobre 7 vértices $V = \{1, 2, 3, 4, 5, 6, 7\}$, se analizan diversas secuencias de vértices y aristas:

1. Clasificar rigurosamente las siguientes secuencias como cadena o camino, indicando en cada caso si son **elementales** (sin repetición de vértices) o **simples** (sin repetición de aristas):

   Solución:

   - $\mu_1 = (1, 2, 3, 5, 6)$ pasando por $\{\{1, 2\}, \{2, 3\}, \{3, 5\}, \{5, 6\}\}$:
     - Vértices visitados: $\{1, 2, 3, 5, 6\}$ (todos distintos $\implies$ **elemental**).
     - Aristas recorridas: todas distintas $\implies$ **simple**.
     - **Conclusión**: Es una **cadena elemental y simple**.
   - $\mu_2 = (1, 2, 4, 3, 2, 5)$ pasando por $\{\{1, 2\}, \{2, 4\}, \{4, 3\}, \{3, 2\}, \{2, 5\}\}$:
     - Vértices visitados: el vértice 2 se repite dos veces ($1 \to 2$ y $3 \to 2 \to 5$) $\implies$ **no elemental**.
     - Aristas recorridas: los 5 pares son distintos $\implies$ **simple**.
     - **Conclusión**: Es una **cadena simple pero no elemental**.
   - $\mu_3 = (1, 2, 3, 1, 2, 4)$ pasando por $\{\{1, 2\}, \{2, 3\}, \{3, 1\}, \{1, 2\}, \{2, 4\}\}$:
     - Vértices visitados: los vértices 1 y 2 se repiten $\implies$ **no elemental**.
     - Aristas recorridas: la arista $\{1, 2\}$ se recorre dos veces $\implies$ **no simple**.
     - **Conclusión**: Es una **cadena ni elemental ni simple** (recorrido general).

---

2. Supóngase que las excentricidades de los nodos son $e(1) = 3, e(2) = 2, e(3) = 2, e(4) = 3, e(5) = 3, e(6) = 4, e(7) = 4$. Determinar el **radio** $R(G)$, el **diámetro** $\text{diam}(G)$ y el **centro** del grafo.

   Solución:

   - **Radio** $R(G)$: Es la excentricidad mínima de la red:

   $$R(G) = \min_{v \in V} e(v) = \min\{3, 2, 2, 3, 3, 4, 4\} = 2$$

   - **Diámetro diam**(G): Es la excentricidad máxima de la red:

   $$\text{diam}(G) = \max_{v \in V} e(v) = \max\{3, 2, 2, 3, 3, 4, 4\} = 4$$

- **Centro del grafo** $C(G)$: Formado por el conjunto de vértices cuyo valor de excentricidad alcanza la cota mínima del radio $R(G) = 2$:

$$C(G) = \{v \in V \mid e(v) = R(G) = 2\} = \{2, 3\}$$

Ejercicio 4: estructura de árboles, bosques y caracterizaciones equivalentes

Considerar un grafo no dirigido $G = (V, E)$ con $n = 8$ vértices y $m = 12$ aristas.

Se pide:

1. Verificar si G puede ser un árbol. Si no es un árbol, determinar cuántas aristas deben eliminarse como mínimo para obtener un árbol soporte T.

   Solución:

   Un árbol sobre n vértices se define como un grafo conexo y acíclico que satisface estrictamente la relación $m = n - 1$. Para un conjunto de $n = 8$ vértices, todo árbol debe contener exactamente:

$$m_{rbol} = 8 - 1 = 7 \text{ aristas}$$

   Dado que el grafo analizado posee $m = 12 > 7$ aristas, G **no puede ser un árbol** (contiene ciclos cerrados obligatoriamente). El número de aristas que deben eliminarse como mínimo para destruir todos los ciclos y extraer un árbol soporte T coincide con el número ciclomático (o rango del ciclo $\mu(G)$):

$$\mu(G) = m - n + 1 = 12 - 8 + 1 = 5 \text{ aristas}$$

---

2. Demostrar rigurosamente que en todo árbol con $n \geq 2$ vértices existen al menos dos vértices de grado 1 (nodos hoja).

   Solución:

   Demostración: Sea $T = (V, E)$ un árbol con $n \geq 2$ vértices y $m = n-1$ aristas. Aplicando el *Handshaking Lemma*:

$$\sum_{v \in V} \deg(v) = 2m = 2(n - 1) = 2n - 2$$

Al ser T conexo y $n \geq 2$, no existen vértices aislados, de modo que $\deg(v) \geq 1$ para todo $v \in V$.

Supóngase por contradicción que T tuviera a lo sumo un único nodo hoja (un único vértice con $\deg(v) = 1$). En tal caso, los restantes $n-1$ vértices tendrían un grado de al menos 2 ($\deg(v) \geq 2$). Evaluando la suma total de los grados:

$$\sum_{v \in V} \deg(v) \geq 1 + 2(n-1) = 1 + 2n - 2 = 2n - 1$$

Comparando ambas expresiones obtenemos la desigualdad absurda:

$$2n - 2 \geq 2n - 1 \implies -2 \geq -1 \quad \text{(CONTRADICCIÓN)}$$

Por consiguiente, todo árbol con $n \geq 2$ vértices debe poseer obligatoriamente al menos **dos vértices de grado 1 (hojas)**. ■

---

3. Probar analíticamente la equivalencia entre dos caracterizaciones fundamentales de un árbol: (a) G es conexo y acíclico, y (b) entre todo par de vértices $u, v \in V$ existe un único camino simple.

   Solución:

   Demostración de la equivalencia $(a) \iff (b)$:

   - **Implicación** $(a) \implies (b)$: Supóngase que G es conexo y acíclico.
     - Al ser G conexo, existe al menos un camino simple entre cualquier par de vértices $u, v \in V$.
     - Si existieran dos caminos simples distintos P_1 y P_2 entre u y v, tomando el primer punto de divergencia y el primer punto de reencuentro se construiría un ciclo simple cerrado en G, lo cual contradice que G es acíclico. Por tanto, el camino simple es único.
   - **Implicación** $(b) \implies (a)$: Supóngase que entre todo par u, v existe un único camino simple.
     - La existencia de camino garantiza inmediatamente la conexidad de G.
     - Si existiera un ciclo C en G, cualquier par de vértices en el ciclo estaría conectado por al menos dos caminos simples alternativos (en ambos sentidos del ciclo), contradiciendo la unicidad de caminos. Por tanto, G debe ser acíclico. ■

---

4. Para un árbol T de 6 nodos $V = \{1, 2, 3, 4, 5, 6\}$ con aristas $E_T = \{\{1, 2\}, \{1, 3\}, \{2, 4\}, \{2, 5\}, \{3, 6\}\}$, escribir su representación por **vector de padres o predecesores** β tomando como nodo raíz el vértice $r = 1$.

   Solución:

   Enraizando el árbol en el nodo $r = 1$, la jerarquía de ascendencia asigna a cada vértice su predecesor directo β_i:

   - Nodo 1 (Raíz principal): $\beta_1 = 0$.
   - Nodo 2 (Hijo directo de 1): $\beta_2 = 1$.
   - Nodo 3 (Hijo directo de 1): $\beta_3 = 1$.
   - Nodo 4 (Hijo directo de 2): $\beta_4 = 2$.
   - Nodo 5 (Hijo directo de 2): $\beta_5 = 2$.
   - Nodo 6 (Hijo directo de 3): $\beta_6 = 3$.

   El vector de padres resulta:

$$\beta = (0, 1, 1, 2, 2, 3)$$

Ejercicio 5: planaridad, fórmula de Euler y teorema de Kuratowski

Análisis topológico de la propiedad de planaridad en grafos.

Se pide:

1. Enunciar la **Fórmula Planar de Euler** ($n - m + r = 2$) para un grafo conexo planar y demostrar analíticamente que en todo grafo planar simple con $n \geq 3$ vértices se cumple la desigualdad $m \leq 3n - 6$.

   Solución:

   Demostración: En una representación planar de un grafo simple con $n \geq 3$, cada región plana R_j está delimitada por un contorno cerrado de al menos 3 aristas (al no existir bucles ni aristas dobles). Al sumar los bordes de las r regiones, cada arista pertenece como máximo al contorno de 2 regiones:

$$2m = \sum_{j=1}^{r} \text{bordes}(R_j) \geq 3r \implies r \leq \frac{2}{3}m$$

   Sustituyendo esta desigualdad en la Fórmula Planar de Euler ($n - m + r = 2$):

$$n - m + \frac{2}{3}m \geq 2 \implies n - \frac{1}{3}m \geq 2 \implies \frac{1}{3}m \leq n - 2 \implies m \leq 3n - 6$$

---

2. Demostrar que si un grafo planar simple no contiene triángulos (su cintura es $g \geq 4$), la cota de aristas se estrecha a $m \leq 2n - 4$.

   Solución:

   Al no contener ciclos de longitud 3, la frontera mínima de cualquier región abarca al menos 4 aristas ($g \geq 4$):

   $$2m = \sum_{j=1}^{r} \text{bordes}(R_j) \geq 4r \implies r \leq \frac{1}{2}m$$

   Sustituyendo en la Fórmula de Euler ($n - m + r = 2$):

   $$n - m + \frac{1}{2}m \geq 2 \implies n - \frac{1}{2}m \geq 2 \implies \frac{1}{2}m \leq n - 2 \implies m \leq 2n - 4$$

---

3. Aplicar las desigualdades anteriores para demostrar analíticamente que:

   - El grafo completo K_5 (5 vértices, 10 aristas) **no es planar**.
   - El grafo bipartito completo $K_{3,3}$ (6 vértices, 9 aristas) **no es planar**.

   Solución:

   - **Grafo** K_5: Posee $n = 5$ vértices y $m = \binom{5}{2} = 10$ aristas. Evaluando $m \leq 3n - 6$:

     $$3(5) - 6 = 9 \implies 10 \leq 9 \quad \text{(FALSO)}$$

     Por tanto, K_5 **no es planar**.

   - **Grafo** $K_{3,3}$: Al ser bipartito completo, no contiene ciclos impares (su cintura es $g = 4$). Posee $n = 6$ vértices y $m = 3 \times 3 = 9$ aristas. Evaluando la cota para grafos sin triángulos $m \leq 2n - 4$:

     $$2(6) - 4 = 8 \implies 9 \leq 8 \quad \text{(FALSO)}$$

     Por tanto, $K_{3,3}$ **no es planar**.

---

4. Enunciar el **Teorema de Kuratowski** y explicar cómo la presencia de un subgrafo homeomórfico a K_5 o $K_{3,3}$ demuestra la no planaridad del Grafo de Petersen.

   Solución:

- **Teorema de Kuratowski (1930)**: Un grafo G es planar si y solo si no contiene ningún subgrafo homeomórfico (obtenido por eliminación o subdivisión elemental de aristas) a K_5 o $K_{3,3}$.
- **Grafo de Petersen**: Contiene $n = 10$ vértices y $m = 15$ aristas. Aunque cumple numéricamente la cota $15 \leq 3(10)-6 = 24$, la eliminación de vértices y la contracción de caminos revela la presencia de un subgrafo homeomórfico a $K_{3,3}$, lo que demuestra por el Teorema de Kuratowski que **el Grafo de Petersen no es planar**.

Ejercicio 6: Algoritmo de Kruskal, matroides y propiedad del corte

Considérese una red no dirigida valorada de 6 vértices $V = \{A, B, C, D, E, F\}$ con las siguientes 10 aristas valoradas:

$$E = \{(A, B, 3), (A, C, 1), (A, D, 4), (B, C, 2), (B, E, 5), \\ (C, D, 6), (C, E, 3), (C, F, 7), (D, F, 2), (E, F, 4)\}$$

Se pide:

1. Formular matemáticamente el problema del Árbol Soporte de Mínimo Peso (MST) como un problema de optimización combinatoria.

   Solución:

   Sea $\mathcal{T}$ la familia de todos los subconjuntos de aristas $T \subseteq E$ que constituyen un árbol soporte del grafo conexo $G = (V, E)$. El problema de optimización combinatoria se formula como:

   $$\begin{aligned} \min_{T \subseteq E} \quad & d(T) = \sum_{e \in T} w(e) \\ \text{sujeto a} \quad & |T| = n - 1 = 5 \\ & T \text{ es acíclico} \end{aligned}$$

---

2. Aplicar paso a paso el Algoritmo de Kruskal, indicando el orden de evaluación de las aristas, las componentes conexas disjuntas (*Union-Find*) tras cada incorporación y las aristas descartadas por formar ciclo.

   Solución:

Ordenamos la totalidad de las 10 aristas por peso estrictamente creciente:

$(A, C : 1), (B, C : 2), (D, F : 2), (A, B : 3), (C, E : 3), (A, D : 4), (E, F : 4), (B, E : 5), (C, D : 6), (C, F : 7)$

Tabla de Traza Detallada del Algoritmo de Kruskal:

Paso	Arista Evaluada e	Peso $w(e)$	¿Forma Ciclo en T?	Decisión	Componentes Conexas Resultantes
1	(A, C)	1	No	**ACEPTADA**	$\{A, C\}, \{B\}, \{D\}, \{E\}, \{F\}$
2	(B, C)	2	No	**ACEPTADA**	$\{A, B, C\}, \{D\}, \{E\}, \{F\}$
3	(D, F)	2	No	**ACEPTADA**	$\{A, B, C\}, \{D, F\}, \{E\}$
4	(A, B)	3	**Sí** $(A - B - C)$	**DESCARTADA**	$\{A, B, C\}, \{D, F\}, \{E\}$
5	(C, E)	3	No	**ACEPTADA**	$\{A, B, C, E\}, \{D, F\}$
6	(A, D)	4	No	**ACEPTADA**	$\{A, B, C, D, E, F\}$ (Conexo)

El algoritmo finaliza al haber seleccionado $n - 1 = 5$ aristas.

---

3. Calcular el peso total del árbol soporte de mínimo peso $d(T)$.

   Solución:

   El conjunto de aristas del MST es $T = \{(A, C), (B, C), (D, F), (C, E), (A, D)\}$. Su peso total acumulado es:

   $$d(T) = 1 + 2 + 2 + 3 + 4 = 12$$

---

4. Utilizar la **Propiedad del Corte (*Cut Property*)** para justificar analíticamente por qué la arista (A, C) pertenece obligatoriamente a todo MST de la red.

   Solución:

Considerando la partición de corte $S = \{A\}$ y $V \setminus S = \{B, C, D, E, F\}$, las aristas que cruzan el corte son:

$$w(\{A\}) = \{(A, C) : 1, (A, B) : 3, (A, D) : 4\}$$

Puesto que (A, C) posee un peso de 1, estrictamente menor que las demás aristas del corte $(1 < 3 < 4)$, por la **Propiedad del Corte** la arista (A, C) pertenece obligatoriamente a **todo** árbol soporte de mínimo peso de la red.

---

5. Determinar si el MST hallado es único o si existen árboles soporte de mínimo peso alternativos.

   Solución:

   En el Paso 6 existía la arista alternativa (E, F) con peso 4. Si en lugar de incorporar (A, D) seleccionamos (E, F), se obtiene el árbol alternativo:

   $$T' = \{(A, C), (B, C), (D, F), (C, E), (E, F)\}$$

   Su peso total es $d(T') = 1 + 2 + 2 + 3 + 4 = 12$. Por tanto, **el MST no es único**.

Ejercicio 7: Algoritmo de Prim, árboles de caminos mínimos y comparativa con el problema del camino mínimo (Dijkstra)

Para la misma red no dirigida valorada de 6 vértices $V = \{A, B, C, D, E, F\}$ del Ejercicio 6:

Se pide:

1. Ejecutar paso a paso el Algoritmo de Prim eligiendo como nodo raíz inicial $v_1 = A$. Detallar para cada iteración $i = 1, \ldots, 5$ el conjunto de vértices visitados P, las aristas del corte $w(P)$ y la arista de peso mínimo seleccionada.

   Solución:

   Tabla de Traza Detallada del Algoritmo de Prim (Raíz $v_1 = A$):

Iteración	Nodos Visitados P	Aristas del Corte $w(P)$	Arista Seleccionada (Peso Mínimo)	Nuevo Nodo Añadido	Peso Acumulado
0	$\{A\}$	$\{(A,B):3,(A,C):1,(A,D):4\}$	—	A	0
1	$\{A,C\}$	$\{(A,B):3,(A,D):4,(C,B):2,(C,D):6,(C,E):3,(C,F):7\}$	(A,C) (Peso 1)	C	1
2	$\{A,B,C\}$	$\{(A,D):4,(B,E):5,(C,D):6,(C,E):3,(C,F):7\}$	(B,C) (Peso 2)	B	3
3	$\{A,B,C,E\}$	$\{(A,D):4,(B,E):5,(C,D):6,(C,F):7,(E,F):4\}$	(C,E) (Peso 3)	E	6
4	$\{A,B,C,D,E\}$	$\{(C,F):7,(D,F):2,(E,F):4\}$	(A,D) (Peso 4)	D	10
5	$\{A,B,C,D,E,F\}$		(D,F) (Peso 2)	F	**12**

2. Verificar que el árbol resultante y su peso acumulado coinciden exactamente con la solución de Kruskal.

   Solución:

   El conjunto de aristas seleccionadas por el algoritmo de Prim es $T = \{(A,C),(B,C),(C,E),(A,D),(D,F)\}$. Su peso total es $1+2+3+4+2 = 12$, coincidiendo con el valor obtenido mediante el

algoritmo de Kruskal.

---

3. Ejecutar nuevamente Prim cambiando el nodo raíz inicial a $v_1 = F$. Justificar la invariancia del peso total del MST.

   Solución:

   Iniciando en $v_1 = F$:

   - Iteración 1: $P = \{F\}$, selecciona (D, F) de peso 2 $\implies$ $P = \{D, F\}$.
   - Iteración 2: $P = \{D, F\}$, selecciona (A, D) de peso 4 $\implies$ $P = \{A, D, F\}$.
   - Iteración 3: $P = \{A, D, F\}$, selecciona (A, C) de peso 1 $\implies$ $P = \{A, C, D, F\}$.
   - Iteración 4: $P = \{A, C, D, F\}$, selecciona (B, C) de peso 2 $\implies$ $P = \{A, B, C, D, F\}$.
   - Iteración 5: Selecciona (C, E) de peso 3 $\implies$ $P = V$.

   El peso total alcanzado es $2 + 4 + 1 + 2 + 3 = 12$. Esto demuestra que el peso del MST es un **invariante estructural del grafo**, independiente de la raíz elegida.

---

4. **Análisis Conceptual**: Explicar la diferencia fundamental entre un Árbol Soporte de Mínimo Peso (MST) y un Árbol de Caminos Mínimos (SPT, obtenido con Dijkstra desde un origen). Construir un contraejemplo numérico de 3 nodos donde el MST no coincida con el SPT.

   Solución:

   - **Diferencia Fundamental**:
     - **MST (Árbol Soporte de Mínimo Peso)**: Minimiza el peso total global sumando todas las aristas de la estructura: $\min \sum_{e \in T} w(e)$.
     - **SPT (Árbol de Caminos Mínimos)**: Minimiza la distancia acumulada individual desde la raíz s a cada uno de los nodos: $\min d_T(s, v), \forall v \in V$.
   - **Contraejemplo Numérico**: Considérese el grafo triángulo $V = \{A, B, C\}$ con aristas $w(A, B) = 2, w(A, C) = 2, w(B, C) = 1$.
     - **MST**: Aristas $\{(B, C), (A, B)\}$ con peso total $1 + 2 = 3$. En este árbol, la distancia de A a C es $d(A, B) + d(B, C) = 2 + 1 = 3$.
     - **SPT desde raíz** A: Aristas $\{(A, B), (A, C)\}$ con peso total $2 + 2 = 4$. La distancia de A a C es 2.

– **Conclusión**: El MST y el SPT de raíz A son árboles distintos y no coinciden.

Ejercicio 8: aplicación en aprendizaje no supervisado: clustering basado en MST

Análisis teórico y numérico del clustering jerárquico basado en la partición del MST.

Se pide:

1. Explicar el procedimiento algorítmico para segmentar un conjunto de N observaciones en $\mathbb{R}^d$ en k clústeres inconexos a partir del MST de la matriz de desemejanza.

   Solución:

   1. Formar el grafo completo valorado $G = (V, E, \mathbf{d})$, donde cada nodo representa un punto $p_i \in \mathbb{R}^d$ y el peso $d(p_i, p_j)$ es su distancia de desemejanza.
   2. Calcular el árbol soporte de mínimo peso T sobre G (contiene $N-1$ aristas).
   3. Ordenar las $N-1$ aristas de T por peso decreciente.
   4. Eliminar las $k-1$ aristas de mayor longitud. Las k componentes conexas disjuntas resultantes constituyen los k clústeres finales.

---

2. Analizar teóricamente la función de calidad $F(T \setminus E_k) = \min_{e \in E_k} w(e)$ basada en la maximización de la distancia inter-clúster (*Single-Linkage*).

   Solución:

   La retirada de las $k-1$ aristas más largas del MST maximiza implícitamente la separación mínima entre clústeres distintos. Por la propiedad del corte del MST, la distancia mínima entre cualquier punto del clúster C_i y cualquier punto del clúster C_j coincide con el peso de la arista eliminada que los unía, garantizando la optimalidad de la partición bajo el criterio *Single-Linkage*.

---

3. Comparar el comportamiento del clustering basado en MST frente al algoritmo k-medias ($WCSS$), argumentando por qué el MST es capaz de separar clústeres con geometrías no convexas (como anillos concéntricos o serpentinas).

   Solución:

El algoritmo de k-medias presupone la existencia de clústeres esféricos convexos delimitados por centroides, dividiendo el espacio mediante hiperplanos de Voronoi. Ante estructuras geométricas entrelazadas no convexas (como anillos o espirales), k-medias fracasa al cortar los anillos. En cambio, el MST conecta cada punto con su vecino más cercano en el espacio geodésico; al eliminar las aristas más largas, se separan limpiamente los anillos concéntricos sin importar su no convexidad.

---

4. **Ejercicio Numérico**: Considérense 6 puntos en $\mathbb{R}^2$: $p_1 = (0,0), p_2 = (1,0), p_3 = (0,1), p_4 = (5,5), p_5 = (6,5), p_6 = (5,6)$. Construir el MST utilizando la distancia euclídea y obtener la partición en $k = 2$ clústeres eliminando la arista de mayor peso.

   Solución:

   Calculamos la matriz de distancias euclídeas $d(p_i, p_j) = \sqrt{(x_i - x_j)^2 + (y_i - y_j)^2}$:

   - Intra-Grupo 1 $\{p_1, p_2, p_3\}$:
     - $d(p_1, p_2) = 1$
     - $d(p_1, p_3) = 1$
     - $d(p_2, p_3) = \sqrt{1^2 + 1^2} = \sqrt{2} \approx 1.414$
   - Intra-Grupo 2 $\{p_4, p_5, p_6\}$:
     - $d(p_4, p_5) = 1$
     - $d(p_4, p_6) = 1$
     - $d(p_5, p_6) = \sqrt{1^2 + 1^2} = \sqrt{2} \approx 1.414$
   - Distancia inter-grupo mínima: entre $p_3(0,1)$ y $p_4(5,5)$:

   $$d(p_3, p_4) = \sqrt{(5-0)^2 + (5-1)^2} = \sqrt{25 + 16} = \sqrt{41} \approx 6.403$$

   Construcción del MST:

   - Aristas seleccionadas: $T = \{(p_1, p_2) : 1, (p_1, p_3) : 1, (p_4, p_5) : 1, (p_4, p_6) : 1, (p_3, p_4) : 6.403\}$.
   - Para $k = 2$ clústeres, se elimina la arista de mayor peso $e_{max} = (p_3, p_4)$ con peso 6.403.
   - **Partición resultante en $k = 2$ clústeres**:
     - **Clúster 1**: $\{p_1, p_2, p_3\} = \{(0,0), (1,0), (0,1)\}$
     - **Clúster 2**: $\{p_4, p_5, p_6\} = \{(5,5), (6,5), (5,6)\}$

Ejercicios del Tema 7: problema del camino mínimo

Ejercicio 1: Ecuaciones de Bellman y ordenación topológica en DAGs

Considérese el digrafo acíclico $G = (V, A, \mathbf{c})$ de $n = 6$ vértices $V = \{1, 2, 3, 4, 5, 6\}$ con costes de arcos dados por:

$$A = \{(1,2) : 3,\ (1,3) : 6,\ (2,3) : 2,\ (2,4) : 5,\\ (3,4) : 1,\ (3,5) : 4,\ (4,5) : 2,\ (4,6) : 7,\ (5,6) : 3\}$$

Se pide:

1. Verificar que la numeración de los vértices satisface la propiedad de ordenación topológica $i < j$ para todo $(i, j) \in A$.

   Solución:

   Comprobamos la desigualdad estrictamente creciente $i < j$ para los 9 arcos del digrafo:

   - Arcos salientes del nodo 1: $(1,2) \implies 1 < 2$, $(1,3) \implies 1 < 3$.
   - Arcos salientes del nodo 2: $(2,3) \implies 2 < 3$, $(2,4) \implies 2 < 4$.
   - Arcos salientes del nodo 3: $(3,4) \implies 3 < 4$, $(3,5) \implies 3 < 5$.
   - Arcos salientes del nodo 4: $(4,5) \implies 4 < 5$, $(4,6) \implies 4 < 6$.
   - Arcos salientes del nodo 5: $(5,6) \implies 5 < 6$.

   Puesto que todo arco $(i, j) \in A$ satisface $i < j$, la numeración de nodos coincide con una ordenación topológica válida, lo que garantiza la ausencia de ciclos dirigidos y permite resolver el problema en tiempo lineal $O(|V| + |A|)$.

---

2. Formular las ecuaciones de optimalidad de Bellman para el origen $s = 1$.

   Solución:

Fijando la etiqueta del nodo origen en $u_1 = 0$, las ecuaciones de optimalidad de Bellman para cada nodo $j \in \{2, 3, 4, 5, 6\}$ en orden topológico resultan:

$$
\begin{aligned}
u_1 &= 0 \\
u_2 &= u_1 + c_{12} = 0 + 3 \\
u_3 &= \min\{u_1 + c_{13},\, u_2 + c_{23}\} \\
u_4 &= \min\{u_2 + c_{24},\, u_3 + c_{34}\} \\
u_5 &= \min\{u_3 + c_{35},\, u_4 + c_{45}\} \\
u_6 &= \min\{u_4 + c_{46},\, u_5 + c_{56}\}
\end{aligned}
$$

---

3. Resolver el sistema en tiempo lineal $O(|V| + |A|)$ obteniendo el vector de distancias mínimas $\mathbf{u} = (u_1, \ldots, u_6)$ y el vector de predecesores Pred.

   Solución:

   Sustituyendo los valores de las etiquetas provisionales en orden topológico hacia adelante:

   - **Nodo 1**: $u_1 = 0$, Pred(1) = 1.
   - **Nodo 2**: $u_2 = u_1 + c_{12} = 0 + 3 = 3$, Pred(2) = 1.
   - **Nodo 3**:

     $$u_3 = \min\{u_1 + c_{13}, u_2 + c_{23}\} = \min\{0 + 6, 3 + 2\} = \min\{6, 5\} = 5$$

     Como el mínimo se alcanza a través del nodo 2, fijamos Pred(3) = 2.
   - **Nodo 4**:

     $$u_4 = \min\{u_2 + c_{24}, u_3 + c_{34}\} = \min\{3 + 5, 5 + 1\} = \min\{8, 6\} = 6$$

     Como el mínimo proviene de 3, fijamos Pred(4) = 3.
   - **Nodo 5**:

     $$u_5 = \min\{u_3 + c_{35}, u_4 + c_{45}\} = \min\{5 + 4, 6 + 2\} = \min\{9, 8\} = 8$$

     Como el mínimo proviene de 4, fijamos Pred(5) = 4.
   - **Nodo 6**:

     $$u_6 = \min\{u_4 + c_{46}, u_5 + c_{56}\} = \min\{6 + 7, 8 + 3\} = \min\{13, 11\} = 11$$

     Como el mínimo proviene de 5, fijamos Pred(6) = 5.

Los vectores de solución resultan:

$$\mathbf{u}^* = (0, 3, 5, 6, 8, 11)$$

$$\text{Pred}^* = (1, 1, 2, 3, 4, 5)$$

---

4. Trazar la arborescencia de caminos mínimos resultante desde el origen 1.

   Solución:

   Reconstruyendo la arborescencia desde el vector de predecesores $\text{Pred}^* = (1, 1, 2, 3, 4, 5)$:

   - Ruta a nodo 2: $1 \to 2$ (coste 3).
   - Ruta a nodo 3: $1 \to 2 \to 3$ (coste 5).
   - Ruta a nodo 4: $1 \to 2 \to 3 \to 4$ (coste 6).
   - Ruta a nodo 5: $1 \to 2 \to 3 \to 4 \to 5$ (coste 8).
   - Ruta a nodo 6: $1 \to 2 \to 3 \to 4 \to 5 \to 6$ (coste 11).

   La arborescencia óptima está formada por el conjunto de arcos $A_T = \{(1,2), (2,3), (3,4), (4,5), (5,6)\}$.

Ejercicio 2: Algoritmo de Dijkstra paso a paso

Dado el digrafo valorado con costes no negativos $G = (V, A, \mathbf{c})$ con $V = \{1, 2, 3, 4, 5\}$ y arcos:

$$A = \{(1,2) : 10,\ (1,4) : 5,\ (2,3) : 1,\ (2,4) : 2,\\ (3,5) : 4,\ (4,2) : 3,\ (4,3) : 9,\ (4,5) : 2,\ (5,3) : 6\}$$

Se pide:

1. Ejecutar el Algoritmo de Dijkstra paso a paso para hallar los caminos mínimos desde el nodo origen 1 al resto de vértices.

   Solución:

   Inicializamos el procedimiento asignando $u_1 = 0$ al origen y $u_j = \infty$ para los demás nodos. El conjunto permanente inicial es $\mathcal{P} = \{1\}$ y el transitorio $\mathcal{T} = \{2, 3, 4, 5\}$.

---

2. Completar en cada iteración la tabla con los conjuntos de nodos permanentes $\mathcal{P}$, nodos transitorios $\mathcal{T}$, las etiquetas provisionales y definitivas u_j y el vector de predecesores $\text{Pred}(j)$.

   Solución:

   Tabla de Traza Detallada del Algoritmo de Dijkstra:

Iteración	Nodo Fijado k	u_k	Conjunto Permanente $\mathcal{P}$	Conjunto Transitorio $\mathcal{T}$	Etiquetas $(u_1, u_2, u_3, u_4, u_5)$	Predecesores $\text{Pred}(1..5)$	Explicación de Relajaciones
Inicial	—	—	$\{1\}$	$\{2,3,4,5\}$	$(0, 10, \infty, 5, \infty)$	$(\times, 1, 1, 1, 1)$	Relaja arcos salientes de 1: $(1,2) = 10, (1,4) = 5$.
Iter 1	$k = 4$	5	$\{1,4\}$	$\{2,3,5\}$	$(0, 8, 14, 5, 7)$	$(1, 4, 4, 1, 4)$	Relaja desde 4: $u_2 = \min(10, 5+3) = 8$; $u_3 = \min(\infty, 5+9) = 14$; $u_5 = \min(\infty, 5+2) = 7$.
Iter 2	$k = 5$	7	$\{1,4,5\}$	$\{2,3\}$	$(0, 8, 13, 5, 7)$	$(1, 4, 5, 1, 4)$	Relaja desde 5: $u_3 = \min(14, 7+6) = 13$.
Iter 3	$k = 2$	8	$\{1,4,5,2\}$	$\{3\}$	$(0, 8, 9, 5, 7)$	$(1, 4, 2, 1, 4)$	Relaja desde 2: $u_3 = \min(13, 8+1) = 9$.

Iteración	Nodo Fijado k	u_k	Conjunto Permanente $\mathcal{P}$	Conjunto Transitorio $\mathcal{T}$	Etiquetas $(u_1, u_2, u_3, u_4, u_5)$	Predecesores $(1, \ldots, 5)$	Explicación de Relajaciones
Iter 4	$k = 3$	9	$\{1, 2, 3, 4, 5\}$	$\emptyset$	$(0, 8, 9, 5, 7)$	$(1, 4, 2, 1, 4)$	Todos los nodos procesados $\Longrightarrow$ **PARAR**.

---

3. Dibujar la arborescencia óptima final identificando las rutas y sus costes.

   Solución:

   - **Vector de distancias óptimas**: $\mathbf{u}^* = (0, 8, 9, 5, 7)$.
   - **Vector de predecesores**: $\text{Pred}^* = (1, 4, 2, 1, 4)$.
   - **Rutas óptimas en detalle**:
     - Ruta al nodo 4: $1 \to 4$ (distancia 5).
     - Ruta al nodo 5: $1 \to 4 \to 5$ (distancia 7).
     - Ruta al nodo 2: $1 \to 4 \to 2$ (distancia 8).
     - Ruta al nodo 3: $1 \to 4 \to 2 \to 3$ (distancia 9).

Ejercicio 3: Algoritmo de Bellman-Ford y detección de ciclos de coste negativo

Considérese el digrafo $G = (V, A, \mathbf{c})$ de 4 vértices con los siguientes arcos, alguno de los cuales posee peso negativo:

$$A = \{(1,2) : 4,\ (1,3) : 5,\ (2,3) : -3,\ (3,4) : 4,\ (4,2) : 1\}$$

Se pide:

1. Desarrollar las iteraciones $m = 1, 2, 3, 4$ del Algoritmo de Bellman-Ford evaluando las etiquetas $u_j^m = \min\{u_j^{m-1}, \min_k\{u_k^{m-1} + c_{kj}\}\}$.

   Solución:

   Fijamos $u_1^0 = 0$ y $u_j^0 = \infty$ para $j \in \{2, 3, 4\}$:

   - **Iteración $m = 1$ (Relajación de arcos desde el origen)**:
     - $u_1^1 = 0$.
     - $u_2^1 = \min\{\infty, u_1^0 + c_{12}\} = \min\{\infty, 0 + 4\} = 4$.
     - $u_3^1 = \min\{\infty, u_1^0 + c_{13}\} = \min\{\infty, 0 + 5\} = 5$.
     - $u_4^1 = \infty$.
     - Vector $u^1 = (0, 4, 5, \infty)$.
   - **Iteración $m = 2$ (Caminos de hasta 2 arcos)**:
     - $u_2^2 = \min\{4, u_4^1 + c_{42}\} = \min\{4, \infty\} = 4$.
     - $u_3^2 = \min\{5, u_2^1 + c_{23}\} = \min\{5, 4 + (-3)\} = \min\{5, 1\} = 1$.
     - $u_4^2 = \min\{\infty, u_3^1 + c_{34}\} = \min\{\infty, 5 + 4\} = 9$.
     - Vector $u^2 = (0, 4, 1, 9)$.
   - **Iteración $m = 3$ (Caminos de hasta 3 arcos)**:
     - $u_2^3 = \min\{4, u_4^2 + c_{42}\} = \min\{4, 9 + 1\} = 4$.
     - $u_3^3 = \min\{1, u_2^2 + c_{23}\} = \min\{1, 4 - 3\} = 1$.
     - $u_4^3 = \min\{9, u_3^2 + c_{34}\} = \min\{9, 1 + 4\} = 5$.
     - Vector $u^3 = (0, 4, 1, 5)$.

---

2. Determinar si el algoritmo converge anticipadamente o si alcanza el límite $m = n - 1$.

   Solución:

   Evaluamos la iteración $m = 4$:

   - $u_2^4 = \min\{4, u_4^3 + c_{42}\} = \min\{4, 5 + 1\} = 4$.
   - $u_3^4 = \min\{1, u_2^3 + c_{23}\} = \min\{1, 4 - 3\} = 1$.
   - $u_4^4 = \min\{5, u_3^3 + c_{34}\} = \min\{5, 1 + 4\} = 5$.
   - Vector $u^4 = (0, 4, 1, 5)$.

   Puesto que $u^4 = u^3 = (0, 4, 1, 5)$, el algoritmo converge exactamente en la iteración $m = 3 = n - 1$.

---

3. Evaluar la iteración $m = 4$ para comprobar si existen circuitos de coste negativo. Justificar analíticamente la respuesta.

   Solución:

   Al ser $u^4 = u^3$, ninguna etiqueta de nodo se reduce durante la iteración $m = n = 4$. Por el criterio de convergencia de Bellman-Ford, esto demuestra analíticamente que **la red no contiene ningún circuito de coste negativo** alcanzable desde el origen 1. La solución de distancias mínimas es $\mathbf{u}^* = (0, 4, 1, 5)$.

Ejercicio 4: Formulación en Programación Lineal Primal-Dual

Dada una red dirigida $G = (V, A, \mathbf{c})$ donde deseamos hallar el camino mínimo del nodo s al nodo t:

1. Escribir el modelo primal de flujo de coste mínimo de 1 unidad.

   Solución:

$$\begin{aligned}
\min \quad & \sum_{(i,j)\in A} c_{ij} x_{ij} \\
\text{s.a.} \quad & \sum_{j|(i,j)\in A} x_{ij} - \sum_{k|(k,i)\in A} x_{ki} = \begin{cases} 1 & \text{si } i = s \\ -1 & \text{si } i = t \\ 0 & \text{si } i \neq s, t \end{cases} \qquad \forall i \in V \\
& x_{ij} \geq 0, \quad \forall (i,j) \in A
\end{aligned}$$

---

2. Demostrar formalmente por qué la matriz de incidencia nodo-arco $\mathbf{A}$ es totalmente unimodular (TUM) y qué implicación tiene esto sobre las soluciones del programa lineal continuo.

   Solución:

   - **Estructura de A**: Toda columna de $\mathbf{A}$ corresponde a un arco dirigido (u, v) y posee exactamente dos entradas no nulas: $+1$ en la fila u y -1 en la fila v.
   - **Criterio de Heller-Tompkins**: Para cualquier subconjunto de filas $R \subseteq V$, la suma de las filas del subconjunto produce entradas en $\{-1, 0, 1\}$. Por inducción sobre el tamaño de las submatrices cuadradas B, $\det(B) \in \{-1, 0, 1\}$.

- **Implicación**: Dado que $\mathbf{A}$ es TUM y el vector de demandas $\mathbf{b} = (1, 0, \dots, 0, -1)^T$ es entero, todos los vértices del poliedro factible son enteros. En consecuencia, el programa lineal continuo relaja la condición de mecanicidad entera sin perder optimalidad: $x_{ij}^* \in \{0, 1\}$. ■

---

3. Formular el problema dual de programación lineal e interpretar físicamente las variables duales u_i como potenciales nodales.

   Solución:

   Asociando la variable dual u_i a la restricción de conservación de flujo del nodo $i \in V$, el problema dual de programación lineal se formula como:

$$\begin{aligned} \max \quad & u_t - u_s \\ \text{s.a.} \quad & u_j - u_i \leq c_{ij}, \quad \forall (i,j) \in A \\ & u_i \in \mathbb{R}, \quad \forall i \in V \end{aligned}$$

   Fijando el potencial arbitrario del origen en $u_s = 0$, las restricciones duales $u_j \leq u_i + c_{ij}$ representan exactamente la condición de consistencia de Bellman. En el óptimo, u_j^* coincide con la distancia geodésica mínima desde s hasta el nodo j.

Ejercicio 5: Algoritmo de Floyd-Warshall entre todos los pares

Dado el digrafo de 4 vértices $V = \{1, 2, 3, 4\}$ con matriz de distancias directas inicial $D^{(0)}$:

$$D^{(0)} = \begin{pmatrix} 0 & 3 & 8 & \infty \\ \infty & 0 & \infty & 1.7 \\ \infty & 4 & 0 & \infty \\ 2 & \infty & -5 & 0 \end{pmatrix}$$

Se pide:

1. Aplicar el Algoritmo de Floyd-Warshall calculando secuencialmente las matrices $D^{(1)}, D^{(2)}, D^{(3)}, D^{(4)}$.

   Solución:

- $D^{(0)}$ **(Matriz Inicial)**:

$$D^{(0)} = \begin{pmatrix} 0 & 3 & 8 & \infty \\ \infty & 0 & \infty & 1.7 \\ \infty & 4 & 0 & \infty \\ 2 & \infty & -5 & 0 \end{pmatrix}$$

- $D^{(1)}$ **(Pivote nodo 1)**: Evaluamos $d_{ij}^{(1)} = \min\{d_{ij}^{(0)}, d_{i1}^{(0)} + d_{1j}^{(0)}\}$.
  - $d_{42}^{(1)} = \min\{\infty, d_{41}^{(0)} + d_{12}^{(0)}\} = \min\{\infty, 2+3\} = 5$.
  - $d_{43}^{(1)} = \min\{-5, d_{41}^{(0)} + d_{13}^{(0)}\} = \min\{-5, 2+8\} = -5$.

$$D^{(1)} = \begin{pmatrix} 0 & 3 & 8 & \infty \\ \infty & 0 & \infty & 1.7 \\ \infty & 4 & 0 & \infty \\ 2 & \mathbf{5} & -5 & 0 \end{pmatrix}$$

- $D^{(2)}$ **(Pivote nodo 2)**: Evaluamos $d_{ij}^{(2)} = \min\{d_{ij}^{(1)}, d_{i2}^{(1)} + d_{2j}^{(1)}\}$.
  - $d_{14}^{(2)} = \min\{\infty, d_{12}^{(1)} + d_{24}^{(1)}\} = \min\{\infty, 3+1.7\} = 4.7$.
  - $d_{34}^{(2)} = \min\{\infty, d_{32}^{(1)} + d_{24}^{(1)}\} = \min\{\infty, 4+1.7\} = 5.7$.

$$D^{(2)} = \begin{pmatrix} 0 & 3 & 8 & \mathbf{4.7} \\ \infty & 0 & \infty & 1.7 \\ \infty & 4 & 0 & \mathbf{5.7} \\ 2 & 5 & -5 & 0 \end{pmatrix}$$

- $D^{(3)}$ **(Pivote nodo 3)**: Evaluamos $d_{ij}^{(3)} = \min\{d_{ij}^{(2)}, d_{i3}^{(2)} + d_{3j}^{(2)}\}$.
  - $d_{42}^{(3)} = \min\{5, d_{43}^{(2)} + d_{32}^{(2)}\} = \min\{5, -5+4\} = -1$.
  - $d_{44}^{(3)} = \min\{0, d_{43}^{(2)} + d_{34}^{(2)}\} = \min\{0, -5+5.7\} = 0$.

$$D^{(3)} = \begin{pmatrix} 0 & 3 & 8 & 4.7 \\ \infty & 0 & \infty & 1.7 \\ \infty & 4 & 0 & 5.7 \\ 2 & \mathbf{-1} & -5 & 0 \end{pmatrix}$$

- $D^{(4)}$ **(Pivote nodo 4 - Matriz Final)**: Evaluamos $d_{ij}^{(4)} = \min\{d_{ij}^{(3)}, d_{i4}^{(3)} + d_{4j}^{(3)}\}$.
  - $d_{13}^{(4)} = \min\{8, d_{14}^{(3)} + d_{43}^{(3)}\} = \min\{8, 4.7 + (-5)\} = -0.3$.
  - $d_{21}^{(4)} = \min\{\infty, d_{24}^{(3)} + d_{41}^{(3)}\} = \min\{\infty, 1.7+2\} = 3.7$.
  - $d_{23}^{(4)} = \min\{\infty, d_{24}^{(3)} + d_{43}^{(3)}\} = \min\{\infty, 1.7 + (-5)\} = -3.3$.

- $d_{31}^{(4)} = \min\{\infty, d_{34}^{(3)} + d_{41}^{(3)}\} = \min\{\infty, 5.7 + 2\} = 7.7$.

$$D^{(4)} = \begin{pmatrix} 0 & 3 & \mathbf{-0.3} & 4.7 \\ \mathbf{3.7} & 0 & \mathbf{-3.3} & 1.7 \\ \mathbf{7.7} & 4 & 0 & 5.7 \\ 2 & -1 & -5 & 0 \end{pmatrix}$$

---

2. Construir la matriz de reconstrucción de rutas $P^{(4)}$.

   Solución:

   La matriz de predecesores $P^{(4)}$ almacena el primer nodo intermedio a visitar al salir del origen:

$$P^{(4)} = \begin{pmatrix} 1 & 2 & 4 & 2 \\ 4 & 2 & 4 & 4 \\ 4 & 2 & 3 & 4 \\ 1 & 3 & 3 & 4 \end{pmatrix}$$

---

3. Determinar la distancia mínima y el camino elemental óptimo para conectar el par de nodos $(3, 1)$.

   Solución:

   - **Distancia mínima**: $d(3, 1) = D_{31}^{(4)} = 7.7$.
   - **Reconstrucción del camino**:
     - Desde 3 hacia 1: $P_{31} = 4 \implies$ El camino comienza con $3 \to 4$.
     - Desde 4 hacia 1: $P_{41} = 1 \implies$ La siguiente etapa es $4 \to 1$.
   - **Camino óptimo resultante**: Secuencia de nodos $3 \to 4 \to 1$ con coste total $5.7 + 2 = 7.7$.

Ejercicios del Tema 8: flujos en redes

Ejercicio 1: Formulación en Programación Lineal y Propiedades del Flujo Máximo

Considérese la red de transporte dirigida $G = (V, U, \mathbf{c})$ de $n = 5$ vértices $V = \{s, 1, 2, 3, t\}$ con las siguientes capacidades acotadas en sus 7 arcos:

$$c_{s1} = 8, \quad c_{s2} = 6, \quad c_{12} = 3, \quad c_{13} = 4, \quad c_{23} = 2, \quad c_{1t} = 5, \quad c_{3t} = 7$$

Se pide:

1. Formular el programa lineal primal de flujo máximo $\max f_0$ definiendo la matriz de incidencia nodo-arco $\mathbf{A}$ y el sistema de conservación de flujo para vértices intermedios $\mathbf{Ax} = \mathbf{0}$.

   Solución:

   Definimos como variables de decisión los caudales circulantes $x_{ij} \geq 0$ en cada arco $(i, j) \in U$ y el valor total de flujo transmitido $f_0 \geq 0$. El programa lineal primal se establece como:

$$\begin{aligned}
\max_{x, f_0} \quad & f_0 \\
\text{sujeto a} \quad & -x_{s1} - x_{s2} = -f_0 && (i = s) \\
& x_{s1} - x_{12} - x_{13} - x_{1t} = 0 && (i = 1) \\
& x_{s2} + x_{12} - x_{23} = 0 && (i = 2) \\
& x_{13} + x_{23} - x_{3t} = 0 && (i = 3) \\
& x_{1t} + x_{3t} = f_0 && (i = t) \\
& 0 \leq x_{s1} \leq 8, \quad 0 \leq x_{s2} \leq 6, \quad 0 \leq x_{12} \leq 3 \\
& 0 \leq x_{13} \leq 4, \quad 0 \leq x_{23} \leq 2, \quad 0 \leq x_{1t} \leq 5, \quad 0 \leq x_{3t} \leq 7
\end{aligned}$$

   La matriz de incidencia nodo-arco $\mathbf{A} \in \mathbb{R}^{5 \times 7}$ se estructura asignando $+1$ al nodo de origen de cada arco y -1 a su nodo de destino.

2. Formular el problema dual continuo e interpretar físicamente las variables duales nodales $u_i \in \mathbb{R}$ y los multiplicadores de capacidad $w_{ij} \geq 0$.

Solución:

Asociando la variable dual u_i a la restricción de conservación de flujo en el nodo $i \in V$ (fijando el potencial del sumidero en $u_t = 0 \implies u_s = 1$) y los multiplicadores $w_{ij} \geq 0$ a las restricciones de capacidad $x_{ij} \leq c_{ij}$, las restricciones duales asociadas a los arcos $u_j - u_i + w_{ij} \geq 0$ se expresan como:

$$
\begin{aligned}
\min_{u,w} \quad & 8w_{s1} + 6w_{s2} + 3w_{12} + 4w_{13} + 2w_{23} + 5w_{1t} + 7w_{3t} & \\
\text{sujeto a} \quad & u_1 - u_s + w_{s1} \geq 0 \implies u_1 + w_{s1} \geq 1 & \text{(arco } (s,1)) \\
& u_2 - u_s + w_{s2} \geq 0 \implies u_2 + w_{s2} \geq 1 & \text{(arco } (s,2)) \\
& u_2 - u_1 + w_{12} \geq 0 & \text{(arco } (1,2)) \\
& u_3 - u_1 + w_{13} \geq 0 & \text{(arco } (1,3)) \\
& u_3 - u_2 + w_{23} \geq 0 & \text{(arco } (2,3)) \\
& u_t - u_1 + w_{1t} \geq 0 \implies -u_1 + w_{1t} \geq 0 & \text{(arco } (1,t)) \\
& u_t - u_3 + w_{3t} \geq 0 \implies -u_3 + w_{3t} \geq 0 & \text{(arco } (3,t)) \\
& w_{ij} \geq 0, \quad u_i \in \{0,1\} &
\end{aligned}
$$

Interpretación física: Las variables duales nodales $u_i \in \{0,1\}$ definen la pertenencia a los conjuntos de la partición del corte (S,T) con $S = \{i \mid u_i = 1\}$ y $T = \{j \mid u_j = 0\}$. Las variables $w_{ij} = \max\{0, u_i - u_j\} = 1$ identifican a los arcos salientes $w^+(S)$ del corte de capacidad mínima.

---

3. Demostrar algebraicamente por el Teorema de Dualidad Fuerte la equivalencia exacta $f_0^* = C(w^+(S))$, justificando por qué el Teorema del Flujo Máximo - Corte Mínimo es la manifestación directa de la dualidad lineal.

Solución:

Por el **Teorema de Dualidad Fuerte de la Programación Lineal**, si el programa lineal primal admite una solución óptima acotada f_0^*, el programa dual posee una solución óptima w^* cuyo valor objetivo coincide exactamente con el primal:

$$f_0^* = \sum_{(i,j) \in U} c_{ij} w_{ij}^*$$

En la solución óptima dual, los multiplicadores satisfacen $w_{ij}^* = 1$ si y solo si el arco (i,j) cruza desde el conjunto alcanzable S hasta el conjunto no alcanzable T ($(i,j) \in w^+(S)$), y $w_{ij}^* = 0$ en caso contrario. La función objetivo dual coincide numéricamente con la capacidad total del corte $C(S,T) = \sum_{(i,j)\in w^+(S)} c_{ij}$. Esto demuestra que **el Teorema del Flujo Máximo - Corte Mínimo es la interpretación geométrica directa de la dualidad fuerte en redes**. ■

---

4. Resolver analíticamente el modelo obteniendo la asignación óptima de flujos x_{ij}^*, el valor del flujo máximo f_0^* y la partición del corte de capacidad mínima (S,T).

   Solución:

   Trazamos las iteraciones de aumento de flujo:

   - **Camino 1** ($\mu_1 = s \to 1 \to t$): Capacidad residual $\Delta_1 = \min(c_{s1}, c_{1t}) = \min(8,5) = 5$. Asignamos $x_{s1} = 5, x_{1t} = 5$ (saturado).
   - **Camino 2** ($\mu_2 = s \to 1 \to 3 \to t$): Capacidad disponible en $(s,1)$ es $8-5=3$. Capacidad residual $\Delta_2 = \min(3, c_{13}, c_{3t}) = \min(3,4,7) = 3$. Asignamos $x_{s1} = 8$ (saturado), $x_{13} = 3, x_{3t} = 3$.
   - **Camino 3** ($\mu_3 = s \to 2 \to 23 \to 3 \to t$): Capacidad residual $\Delta_3 = \min(c_{s2}, c_{23}, c_{3t} - 3) = \min(6,2,7-3) = 2$. Asignamos $x_{s2} = 2, x_{23} = 2$ (saturado), $x_{3t} = 3+2 = 5$.

   Solución Primal Óptima:

   $$f_0^* = 5 + 3 + 2 = 10$$

   $$x_{s1}^* = 8, \quad x_{s2}^* = 2, \quad x_{12}^* = 0, \quad x_{13}^* = 3, \quad x_{23}^* = 2, \quad x_{1t}^* = 5, \quad x_{3t}^* = 5$$

   Corte de Capacidad Mínima: En el grafo residual final, los nodos alcanzables desde s son $S = \{s, 2\}$ y los no alcanzables son $T = \{1, 3, t\}$. Los arcos salientes que cruzan de S a T componen el corte $w^+(S) = \{(s,1), (2,3)\}$. Su capacidad total es:

   $$C(S,T) = c_{s1} + c_{23} = 8 + 2 = 10 = f_0^*$$

Ejercicio 2: Algoritmo de Etiquetado Dinámico de Ford-Fulkerson paso a paso

Dada la red de transporte dirigida $G = (V, U, \mathbf{c})$ con 5 vértices $V = \{s, a, b, c, t\}$ y capacidades acotadas:

$$c_{sa} = 5, \quad c_{sb} = 4, \quad c_{ab} = 2, \quad c_{ac} = 4, \quad c_{bc} = 1, \quad c_{at} = 3, \quad c_{ct} = 6$$

Se pide:

1. Iniciar el procedimiento desde la solución de flujo nulo $\mathbf{f}^0 = \mathbf{0}$ para $f_0 = 0$.

   Solución:

   Fijamos la asignación inicial de flujo nulo $\mathbf{f}^0 = \mathbf{0}$ en los 7 arcos. El caudal circulante inicial es $f_0 = 0$.

---

2. Desarrollar paso a paso cada iteración del algoritmo de etiquetado dinámico de Ford-Fulkerson, indicando en cada paso el camino de aumento seleccionado en el grafo residual $G(\mathbf{f}^k)$, la capacidad residual Δ_k y la actualización de marcas $[\pm i, \Delta(j)]$.

   Solución:

   Tabla de Traza Detallada del Algoritmo de Ford-Fulkerson:

Iteración	Camino de Aumento μ_k	Marcas de Etiquetado Generadas $[\pm i, \Delta_j]$	Incremento Δ_k	Flujos Actualizados f_{ij}^k	Caudal f_0
0	—	Marca $s : [-, \infty]$	—	Todos $f_{ij}^0 = 0$	0
1	$s \to a \to t$	$a : [+s, 5]$, $t : [+a, 3]$	$\min(5, 3) = 3$	$f_{sa}^1 = 3$, $f_{at}^1 = 3$ (Saturado)	3
2	$s \to a \to c \to t$	$a : [+s, 2]$, $c : [+a, 2]$, $t : [+c, 2]$	$\min(2, 4, 6) = 2$	$f_{sa}^2 = 5$ (Sat), $f_{ac}^2 = 2$, $f_{ct}^2 = 2$	5

Iteración	Camino de Aumento μ_k	Marcas de Etiquetado Generadas $[\pm i, \Delta_j]$	Incremento Δ_k	Flujos Actualizados f_{ij}^k	Caudal f_0
3	$s \to b \to c \to t$	$b : [+s, 4]$, $c : [+b, 1]$, $t : [+c, 1]$	$\min(4, 1, 4) = 1$	$f_{sb}^3 = 1$, $f_{bc}^3 = 1$ (Sat), $f_{ct}^3 = 3$	**6**

---

3. Identificar la iteración de parada por imposibilidad de etiquetar el sumidero t.

   Solución:

   - **Iteración 4 (Proceso de Parada)**:
     - Asignamos la marca inicial $[-, \infty]$ al nodo fuente s.
     - El arco (s, a) está totalmente saturado ($f_{sa} = 5 = c_{sa}$) $\implies$ el nodo a no puede ser etiquetado.
     - El arco (s, b) dispone de capacidad residual $4 - 1 = 3 \implies$ etiquetamos b con $[+s, 3]$.
     - Desde el nodo b, el único arco saliente (b, c) está completamente saturado ($f_{bc} = 1 = c_{bc}$). No existen arcos inversos cargados desde b.
     - Ningún otro vértice puede recibir marca. El sumidero t **no resulta alcanzable**.
     - **Criterio de Parada**: Se concluye el algoritmo garantizando que el flujo $f_0^* = 6$ es máximo.

---

4. Caracterizar el conjunto de nodos alcanzables $S = N$ y determinar los arcos que componen el corte de capacidad mínima $w^+(S)$ con su capacidad total.

   Solución:

   El conjunto de nodos etiquetados en la iteración final es $S = N = \{s, b\}$. El conjunto complementario no alcanzable es $T = V \setminus N = \{a, c, t\}$.

   Los arcos que cruzan desde el subconjunto S al subconjunto T constituyen el corte de capacidad mínima:

   $$w^+(S) = \{(s, a), (b, c)\}$$

Evaluamos la capacidad total del corte $C(S,T)$:

$$C(S,T) = c_{sa} + c_{bc} = 5 + 1 = 6 = f_0^*$$

Se confirma numéricamente la identidad exacta del Teorema de Flujo Máximo - Corte Mínimo ($f_0^* = C(S,T) = 6$).

Ejercicio 3: Criterios de Optimalidad y Eliminación de Circuitos Negativos en Flujo de Coste Mínimo

Considérese la red de 4 vértices $V = \{s, 1, 2, t\}$ con arcos, capacidades c_{ij} y costes unitarios de transporte $p_{ij} \in \mathbb{R}$:

$$(s,1) : c_{s1} = 3, p_{s1} = 2; \quad (s,2) : c_{s2} = 2, p_{s2} = 4; \quad (1,2) : c_{12} = 2, p_{12} = -3;$$
$$(2,1) : c_{21} = 1, p_{21} = 1; \quad (1,t) : c_{1t} = 3, p_{1t} = 1; \quad (2,t) : c_{2t} = 2, p_{2t} = 2$$

Se pide:

1. Probar la validez del Teorema 1 de optimalidad: un flujo de valor ν es de coste mínimo si y solo si $G(\mathbf{f})$ no contiene circuitos incrementales de coste negativo.

   Solución:

   Por el **Teorema 1**, cualquier modificación factible de un flujo $\mathbf{f}$ manteniendo constante el caudal ν se expresa como una combinación lineal de circulaciones cíclicas $\mathbf{f}' - \mathbf{f} = \sum {\alpha_k}^k$. Si la red residual $G(\mathbf{f})$ contiene un circuito orientado C con coste residual estricto $p(C) = \sum_{u \in C^+} p_u - \sum_{u \in C^-} p_u < 0$, hacer circular $\delta > 0$ unidades a lo largo de C reduce el coste total en $\delta \cdot p(C) < 0$ manteniendo constante el volumen circulante ν, lo que contradice la optimalidad de $\mathbf{f}$. Recíprocamente, si no existen circuitos negativos en $G(\mathbf{f})$, ninguna modificación cíclica puede reducir el coste, demostrando la optimalidad global. ■

---

2. Dada la solución compatible inicial de prueba $\mathbf{f}^0$ con $f^0_{s2} = 2, f^0_{21} = 1, f^0_{1t} = 2$ (y cero en el resto), construir su grafo residual $G(\mathbf{f}^0)$ e identificar un circuito residual de coste negativo C_1.

Solución:

Calculamos el coste total acumulado de la solución inicial $\mathbf{f}^0$ para un caudal de $\nu = 2$ unidades:

$$C(\mathbf{f}^0) = 2(p_{s2}) + 1(p_{21}) + 2(p_{1t}) = 2(4) + 1(1) + 2(1) = 8 + 1 + 2 = 11$$

Construimos el grafo residual $G(\mathbf{f}^0)$:

- Arco $(s, 2)$ saturado $(f = 2 = c) \implies$ genera el arco inverso $(2, s)$ con peso $-p_{s2} = -4$.
- Arco $(2, 1)$ totalmente cargado $(f = 1 = c) \implies$ genera el arco inverso $(1, 2)$ con peso $-p_{21} = -1$.
- Arco $(1, 2)$ sin flujo $(f = 0) \implies$ mantiene el arco directo $(1, 2)$ con peso $p_{12} = -3$.
- Arco $(s, 1)$ libre $(f = 0) \implies$ directo $(s, 1)$ peso 2.
- Arco $(1, t)$ parcialmente cargado $(f = 2 < 3) \implies$ directo $(1, t)$ peso 1, e inverso $(t, 1)$ peso -1.

Evaluando los circuitos cerrados en $G(\mathbf{f}^0)$, identificamos el circuito $C_1 = 1 \to 2 \to 1$ formado por el arco directo $(1, 2)$ y el arco inverso $(1, 2)$ de deshacer f_{21}:

$$p(C_1) = p_{12} + (-p_{21}) = (-3) + (-1) = -4 < 0$$

---

3. Calcular la capacidad residual máxima δ_1 del circuito C_1, hacer circular dicho flujo y calcular la reducción exacta de coste total $C(\mathbf{f}^1) - C(\mathbf{f}^0)$.

Solución:

La capacidad residual del circuito C_1 viene dada por la menor capacidad sobrante en sus arcos de avance y retorno:

$$\delta_1 = \min\{c_{12} - f^0_{12},\, f^0_{21}\} = \min\{2 - 0,\, 1\} = 1 \text{ unidad}$$

Actualizamos los flujos incrementando en 1 unidad el arco $(1, 2)$ y cancelando completamente el flujo inverso en $(2, 1)$:

$$f^1_{12} = 0 + 1 = 1, \quad f^1_{21} = 1 - 1 = 0$$

El coste total de la nueva distribución de flujo $\mathbf{f}^1$ resulta:

$$C(\mathbf{f}^1) = 2(p_{s2}) + 1(p_{12}) + 2(p_{1t}) = 2(4) + 1(-3) + 2(1) = 8 - 3 + 2 = 7$$

La variación de coste total coincide exactamente con el producto del flujo circulado por el peso del ciclo:

$$C(\mathbf{f}^1) - C(\mathbf{f}^0) = 7 - 11 = -4 = \delta_1 \cdot p(C_1) = 1 \cdot (-4)$$

---

4. Demostrar que el nuevo flujo $\mathbf{f}^1$ no contiene circuitos de coste negativo en $G(\mathbf{f}^1)$.

   Solución:

   En la red residual $G(\mathbf{f}^1)$, al haberse cancelado totalmente $f^1_{21} = 0$, el arco inverso $(1, 2)$ con peso -1 desaparece. Se comprueba que ningún otro circuito en $G(\mathbf{f}^1)$ posee peso negativo. Por el **Teorema 1**, el flujo $\mathbf{f}^1$ es globalmente óptimo para el caudal $\nu = 2$ con un coste mínimo de $C^* = 7$.

Ejercicio 4: Crecimiento Iterativo por Caminos Mínimos (Teorema 2)

Dada la red de transporte dirigida de 5 nodos $V = \{s, a, b, c, t\}$ con capacidades c_{ij} y costes unitarios p_{ij}:

$$(s,a) : c_{sa} = 3, p_{sa} = 3; \quad (s,b) : c_{sb} = 3, p_{sb} = 1; \quad (a,c) : c_{ac} = 2, p_{ac} = 2;$$
$$(b,c) : c_{bc} = 2, p_{bc} = 5; \quad (b,t) : c_{bt} = 4, p_{bt} = 2; \quad (c,t) : c_{ct} = 3, p_{ct} = 1$$

Se desea transmitir un caudal total de $\nu = 4$ unidades desde la fuente s al sumidero t al menor coste posible.

Se pide:

1. Partir del flujo óptimo inicial $\mathbf{f}^0 = \mathbf{0}$ para $\nu_0 = 0$.

   Solución:

   Iniciamos la búsqueda fijando la solución de flujo nulo $\mathbf{f}^0 = \mathbf{0}$ con caudal circulante $f_0 = 0$ y coste $C(\mathbf{f}^0) = 0$. Al ser todos los costes unitarios no negativos ($p_{ij} \geq 0$), por el Teorema 1 no existen ciclos iniciales de coste negativo, garantizando que $\mathbf{f}^0$ es óptimo para $\nu_0 = 0$.

---

2. Encontrar en cada iteración la cadena de incremento de coste residual mínimo desde s a t en el grafo de distancias residual $G(\mathbf{f}^k)$.

   Solución:

   - **Iteración 1 (Caudal $0 \to 3$)**:
     - Evaluamos la longitud de las cadenas orientadas en $G(\mathbf{f}^0)$:
       * $\mu_1 = s \to b \to t$: Coste residual $p(\mu_1) = p_{sb} + p_{bt} = 1 + 2 = 3$.
       * $\mu_2 = s \to a \to c \to t$: Coste residual $p(\mu_2) = 3 + 2 + 1 = 6$.
       * $\mu_3 = s \to b \to c \to t$: Coste residual $p(\mu_3) = 1 + 5 + 1 = 7$.
     - El camino de longitud mínima en el grafo de distancias residual es $\mu_1 = s \to b \to t$ con coste unitario 3.

---

3. Calcular el incremento óptimo $\Delta_k = \min\{c(\mu_k), \nu - f_0\}$ y actualizar el flujo y los arcos inversos.

   Solución:

   - Capacidad residual de la cadena μ_1: $c(\mu_1) = \min\{c_{sb} - f^0_{sb}, c_{bt} - f^0_{bt}\} = \min(3 - 0, 4 - 0) = 3$.
   - Incremento óptimo: $\Delta_1 = \min\{3, 4 - 0\} = 3$ unidades.
   - Flujo actualizado $\mathbf{f}^1$: $f^1_{sb} = 3$ (saturado), $f^1_{bt} = 3$. Caudal circulante $f_0 = 3$.
   - Coste acumulado: $C(\mathbf{f}^1) = 0 + 3 \times 3 = 9$.

---

4. Construir la tabla completa de evoluciones de caudal f_0, coste acumulado $C(\mathbf{f}^k)$ y verificación de optimalidad para el volumen objetivo $\nu = 4$.

   Solución:

   - **Iteración 2 (Caudal $3 \to 4$)**:
     - Al estar (s, b) saturado en $G(\mathbf{f}^1)$, la arista directa no está disponible. El siguiente camino de coste residual mínimo en $G(\mathbf{f}^1)$ es $\mu_2 = s \to a \to c \to t$ con coste $p(\mu_2) = 3 + 2 + 1 = 6$.
     - Capacidad residual de μ_2: $c(\mu_2) = \min(3, 2, 3) = 2$.
     - Incremento compatible: $\Delta_2 = \min\{2, 4 - 3\} = 1$ unidad.
     - Flujo actualizado $\mathbf{f}^2$: $f^2_{sa} = 1, f^2_{ac} = 1, f^2_{ct} = 1$. Caudal $f_0 = 3 + 1 = 4 = \nu$.
     - Coste acumulado final: $C(\mathbf{f}^2) = 9 + 1(6) = 15$.

   Tabla de Resumen Algorítmico:

Iteración k	Camino Mínimo μ_k	Coste Residual $p(\mu_k)$	Incremento Δ_k	Caudal Acumulado f_0	Coste Total $C(\mathbf{f}^k)$
0	Inicial ($\mathbf{f}^0 = \mathbf{0}$)	—	—	0	0
1	$s \to b \to t$	3	3	3	9
2	$s \to a \to c \to t$	6	1	4	**15**

Solución Óptima Final para $\nu = 4$:

$$f^*_{sb} = 3, \quad f^*_{bt} = 3, \quad f^*_{sa} = 1, \quad f^*_{ac} = 1, \quad f^*_{ct} = 1$$

$$C^* = 15$$

Ejercicio 5: El Problema del Transbordo y Reducción Unificada de Problemas de Redes

Considérese el problema de transbordo en una red dirigida $G = (V, U)$ con n nodos, m arcos, balances nodales $b_i \in \mathbb{R}$ y capacidades $\ell_{ij} \leq f_{ij} \leq c_{ij}$.

Se pide:

1. Demostrar analíticamente que si la red está en equilibrio ($\sum_{i=1}^{n} b_i = 0$), el sistema de ecuaciones de conservación de flujo $\mathbf{Af} = \mathbf{b}$ posee rango $n - 1$.

   Solución:

   Sumando la totalidad de las n filas de la matriz de incidencia nodo-arco $\mathbf{A}$, observamos que cada columna $u = (i, j)$ contiene exactamente dos entradas no nulas: $+1$ en la fila i y -1 en la fila j. La suma por columnas es idénticamente cero, lo que implica que las filas de $\mathbf{A}$ son linealmente dependientes. Al estar la red en equilibrio ($\sum_{i=1}^{n} b_i = 0$), cualquier restricción de conservación puede expresarse como combinación lineal de las restantes $n - 1$, demostrando que $\text{rango}(\mathbf{A}) = n - 1$. ■

---

2. Formular la matriz de incidencia nodo-arco $\mathbf{A}$ y mostrar su estructura de unos y menos unos (+1 en arcos salientes, -1 en arcos entrantes).

   Solución:

   La matriz de incidencia nodo-arco $\mathbf{A} \in \mathbb{R}^{n \times m}$ se define formalmente como:

$$a_{i,u} = \begin{cases} +1 & \text{si el arco } u = (i,j) \text{ sale del nodo } i \\ -1 & \text{si el arco } u = (k,i) \text{ entra al nodo } i \\ 0 & \text{en otro caso} \end{cases}$$

---

3. Demostrar formalmente la reducción unificada de un problema de Transporte bipartito a un modelo de Transbordo equivalente introduciendo nodos intermedios de paso.

   Solución:

   En un problema de transporte bipartito estándar se definen m orígenes con ofertas $a_i > 0$ y n destinos con demandas $d_j > 0$. Para reducirlo a un modelo de transbordo unificado sobre $G = (V, U)$, basta fijar $V = I \cup J$, definiendo los balances $b_i = a_i > 0$ para $i \in I$ y $b_j = -d_j < 0$ para $j \in J$. El sistema de conservación $\sum_j f_{ij} - \sum_k f_{ki} = b_i$ se reduce exactamente a las ecuaciones de oferta $\sum_j f_{ij} = a_i$ y demanda $\sum_i f_{ij} = d_j$, demostrando que el problema de transporte es un caso particular del transbordo. ■

---

4. Explicar cómo la propiedad de unimodularidad total (TUM) de la matriz de incidencia $\mathbf{A}$ garantiza soluciones enteras óptimas $\mathbf{f}^* \in \mathbb{Z}^m$ siempre que los balances nodales b_i y las cotas de capacidad ℓ_{ij}, c_{ij} sean enteros.

   Solución:

   Una matriz $\mathbf{A}$ es **Totalmente Unimodular (TUM)** si el determinante de cualquier submatriz cuadrada resulta $0, +1$ o -1. Dado que cada columna de $\mathbf{A}$ posee a lo sumo dos elementos no nulos ($+1$ y -1), $\mathbf{A}$ cumple el criterio de Heller-Tompkins y es TUM. Por la regla de Cramer, las soluciones en los vértices del poliedro factible vienen dadas por $\mathbf{f} = \mathbf{B}^{-1}\mathbf{b}$. Al tener las submatrices determinantes $\det(\mathbf{B}) = \pm 1$, la matriz inversa contiene únicamente elementos enteros, lo que garantiza que las soluciones óptimas continuas de Programación Lineal son **estrictamente enteras** ($\mathbf{f}^* \in \mathbb{Z}^m$), prescindiendo del uso de algoritmos de optimización entera Branch & Bound. ■

Ejercicios del Tema 9: emparejamientos en redes

Ejercicio 1: Formulación en Programación Entera y Propiedades Algebraicas del Emparejamiento

Considérese un grafo simple no dirigido $G = (V, E)$ con $n = |V|$ vértices y $m = |E|$ aristas. Se define un emparejamiento como un subconjunto de aristas $K \subseteq E$ tal que ningún par de aristas en K comparte vértices en común.

Se pide:

1. Formular el problema de emparejamiento de máximo cardinal como un programa lineal entero (PLE) definiendo variables binarias $x_e \in \{0, 1\}$ para cada arista $e \in E$, la función objetivo y las restricciones de grado nodal en $\delta(v)$.

   Solución:

   Para cada arista $e = \{u, v\} \in E$, definimos la variable de decisión binaria:

   $$x_e = \begin{cases} 1 & \text{si la arista } e \in E \text{ se incluye en el emparejamiento } K \\ 0 & \text{en caso contrario} \end{cases}$$

   Sea $\delta(v) = \{e \in E \mid v \in e\}$ el conjunto de aristas incidentes en el vértice $v \in V$. La condición de que ningún par de aristas seleccionadas comparta extremos exige que para todo vértice $v \in V$ incida a lo sumo una arista del emparejamiento. Por consiguiente, el programa lineal entero (PLE) de emparejamiento de máximo cardinal se formula como:

   $$\begin{aligned} \max_{x} \quad & \sum_{e \in E} x_e \\ \text{sujeto a} \quad & \sum_{e \in \delta(v)} x_e \leq 1, \quad \forall v \in V \\ & x_e \in \{0, 1\}, \quad \forall e \in E \end{aligned}$$

   El vector de grado saturado se define mediante $sat(v) = \sum_{e \in \delta(v)} x_e \in \{0, 1\}$, donde $sat(v) = 1$ indica que el vértice v está saturado y $sat(v) = 0$ que está expuesto.

---

2. Demostrar formalmente que la familia de todos los emparejamientos de G, denotada por $\mathcal{J} = \{K \subseteq E \mid K \text{ es emparejamiento}\}$, satisface los axiomas de un complejo simplicial o complejo de independencia (propiedad de hereditariedad).

   Solución:

   Un complejo simplicial abstracto o complejo de independencia sobre el conjunto base E es una familia $\mathcal{J} \subseteq \mathcal{P}(E)$ que satisface dos propiedades:

   1. **No vacuidad**: $\emptyset \in \mathcal{J}$. El conjunto vacío de aristas no contiene aristas incidentes entre sí, por lo que $K = \emptyset$ es un emparejamiento válido trivial.
   2. **Hereditariedad (cierre bajo inclusión)**: Si $K \in \mathcal{J}$ y $K' \subseteq K$, entonces $K' \in \mathcal{J}$.

   Demostración: Sea $K \in \mathcal{J}$ un emparejamiento en G. Por definición, para todo par de aristas distintas $e_1, e_2 \in K$, se verifica $e_1 \cap e_2 = \emptyset$. Sea $K' \subseteq K$ un subconjunto arbitrario de K. Si se toma cualquier par de aristas $e_1, e_2 \in K'$, dado que $K' \subseteq K$, necesariamente $e_1, e_2 \in K$, y por tanto $e_1 \cap e_2 = \emptyset$. En consecuencia, K' satisface la condición de no adyacencia nodal y es un emparejamiento válido en G. Por tanto, $K' \in \mathcal{J}$, lo que demuestra que $\mathcal{J}$ es un complejo de independencia. ■

---

3. Diferenciar con rigor teórico entre un **emparejamiento maximal** (óptimo local respecto a la inclusión de aristas) y un **emparejamiento de máximo cardinal** (óptimo global). Proporcionar un contraejemplo mínimo sobre el camino de cuatro vértices P_4 donde un emparejamiento maximal no sea de máximo cardinal.

   Solución:

   - **Emparejamiento maximal (óptimo local)**: Es un emparejamiento $K \subseteq E$ tal que no es posible añadir ninguna arista adicional de $E \setminus K$ sin violar la condición de independencia; es decir, no existe $e \in E \setminus K$ tal que $K \cup \{e\}$ sea un emparejamiento.
   - **Emparejamiento de máximo cardinal (óptimo global)**: Es un emparejamiento $K^* \subseteq E$ tal que $|K^*| \geq |K|$ para todo emparejamiento factible K de G.

   Todo emparejamiento de máximo cardinal es obligatoriamente maximal, pero el recíproco es falso en general.

   Contraejemplo mínimo en P_4: Considérese el camino P_4 con vértices $V = \{1, 2, 3, 4\}$ y aristas $E = \{\{1, 2\}, \{2, 3\}, \{3, 4\}\}$.

   - Si seleccionamos la arista central $K_1 = \{\{2, 3\}\}$, ningún arco restante de E puede añadirse porque $\{1, 2\}$ incide en 2 y $\{3, 4\}$ incide en 3. Por tanto, K_1 es **maximal** con $|K_1| = 1$.

- Sin embargo, el emparejamiento $K^* = \{\{1,2\}, \{3,4\}\}$ es válido y posee cardinal $|K^*| = 2$. Por consiguiente, K_1 es un óptimo local voraz subóptimo de cardinal 1, mientras que el máximo cardinal global es 2.

---

4. Demostrar analíticamente que el cardinal de cualquier emparejamiento K en un grafo de n vértices satisface la cota universal $|K| \leq \lfloor n/2 \rfloor$, y justificar por qué la condición de paridad (n par) es un requisito necesario (aunque no suficiente) para la existencia de un emparejamiento perfecto.

   Solución:

   Demostración de la cota: Cada arista $e = \{u, v\} \in K$ cubre exactamente 2 vértices distintos. Al ser las aristas de K disjuntas en vértices, el número total de vértices saturados por K es:

   $$|V_{sat}(K)| = 2|K|$$

   Dado que el conjunto de vértices saturados es un subconjunto de V, se cumple $|V_{sat}(K)| \leq |V| = n$, de donde:

   $$2|K| \leq n \implies |K| \leq \frac{n}{2}$$

   Como el cardinal $|K|$ es un número entero no negativo, se deduce que $|K| \leq \lfloor n/2 \rfloor$. ■

   Condición de paridad para emparejamientos perfectos: Un emparejamiento K es perfecto si satura a la totalidad de los vértices del grafo ($|V_{sat}(K)| = n$). Por tanto, debe cumplirse $2|K| = n \implies n = 2k$ con $k \in \mathbb{Z}^+$, lo que exige obligatoriamente que n sea par. Si n es impar, al menos un vértice debe quedar siempre expuesto ($|V_{exp}| \geq 1$), imposibilitando la existencia de un emparejamiento perfecto.

   Dicha condición no es suficiente: por ejemplo, el grafo estrella $K_{1,3}$ posee $n = 4$ vértices (par), pero su emparejamiento máximo tiene cardinal 1, ya que las 3 aristas inciden en el centro y no admite emparejamiento perfecto de cardinal 2.

Ejercicio 2: Cadenas Incrementales, Operación de Transferencia y Teorema de Berge

Considérese el grafo no dirigido $G = (V, E)$ de $n = 8$ vértices $V = \{1, 2, 3, 4, 5, 6, 7, 8\}$ con aristas:

$$E = \{\{1,2\},\ \{1,3\},\ \{2,4\},\ \{3,4\},\ \{3,5\},\ \{4,6\},\ \{5,6\},\ \{5,7\},\ \{6,8\},\ \{7,8\}\}$$

Partiendo del emparejamiento inicial no maximal de 2 aristas:

$$K_0 = \{\{1,3\},\ \{6,8\}\}$$

Se pide:

1. Clasificar el estado de todos los vértices del grafo respecto de K_0, identificando el conjunto de vértices saturados V_{sat} y el conjunto de vértices expuestos V_{exp}.

   Solución:

   Las aristas de $K_0 = \{\{1,3\},\ \{6,8\}\}$ saturan los vértices $\{1,3,6,8\}$. Por tanto:

   - **Vértices saturados ($sat(v) = 1$):** $V_{sat} = \{1,3,6,8\}$.
   - **Vértices expuestos ($sat(v) = 0$):** $V_{exp} = V \setminus V_{sat} = \{2,4,5,7\}$.

---

2. Identificar una cadena alternante elemental μ cuyos dos extremos pertenezcan a V_{exp} (cadena alternante incremental).

   Solución:

   Una cadena incremental respecto de K_0 debe comenzar en un vértice expuesto con arista fuera de K_0, alternar aristas de K_0 y fuera de K_0, y finalizar en otro vértice expuesto con arista fuera de K_0.

   Analizamos la secuencia de vértices $\mu = (2,1,3,5,7)$:

   - Extremo inicial $2 \in V_{exp}$ (expuesto).
   - Arista $\{2,1\} \notin K_0$ (fuera del emparejamiento).
   - Arista $\{1,3\} \in K_0$ (en el emparejamiento).
   - Arista $\{3,5\} \notin K_0$ (fuera del emparejamiento).
   - Extremo final $5 \in V_{exp}$ (expuesto).

   Por tanto, $\mu = (2,1,3,5)$ es una **cadena alternante incremental** de 3 aristas con extremos expuestos 2 y 5. (Otra cadena válida es $\mu' = (4,3,1,2)$ o $\mu'' = (7,5,3,1,2)$).

---

3. Aplicar formalmente la operación de transferencia algebraica mediante la diferencia simétrica $K_1 = K_0 \triangle \mu$, verificando que K_1 es un emparejamiento válido y que su cardinal satisface $|K_1| = |K_0| + 1 = 3$.

   Solución:

   Para la cadena incremental $\mu = (2, 1, 3, 5)$, el conjunto de aristas de la cadena es:

   $$E(\mu) = \{\{2,1\},\, \{1,3\},\, \{3,5\}\}$$

   Calculamos la diferencia simétrica $K_1 = K_0 \triangle E(\mu) = (K_0 \setminus E(\mu)) \cup (E(\mu) \setminus K_0)$:

   - Aristas eliminadas: $K_0 \cap E(\mu) = \{\{1,3\}\}$.
   - Aristas añadidas: $E(\mu) \setminus K_0 = \{\{2,1\},\, \{3,5\}\}$.
   - Aristas que permanecen invariables: $\{6,8\}$.

   Por consiguiente:

   $$K_1 = \{\{1,2\},\, \{3,5\},\, \{6,8\}\}$$

   Verificación de validez:

   - $\{1,2\}$ cubre $\{1,2\}$.
   - $\{3,5\}$ cubre $\{3,5\}$.
   - $\{6,8\}$ cubre $\{6,8\}$. Los 6 vértices saturados $\{1,2,3,5,6,8\}$ son mutuamente disjuntos. Ningún vértice tiene grado superior a 1 en K_1. *Cardinalidad*: $|K_1| = 3 = |K_0| + 1$.

---

4. Enunciar y demostrar el Teorema fundamental de caracterización de Berge (1957), analizando la estructura topológica del grafo diferencia simétrica $H = (V, K \triangle K^*)$ entre un emparejamiento K y un emparejamiento óptimo K^*.

   Solución:

   Teorema de Berge (1957): Un emparejamiento K en un grafo $G = (V, E)$ es de máximo cardinal si y solo si G no contiene ninguna cadena alternante incremental respecto de K.

   Demostración:

   - **Necesidad ($\Longrightarrow$)**: Si G contuviese una cadena incremental μ respecto de K, la transferencia $K' = K \triangle \mu$ generaría un emparejamiento válido con cardinal $|K'| = |K| + 1 > |K|$, lo que contradice la hipótesis de que K es de máximo cardinal.

- **Suficiencia ($\Longleftarrow$)**: Supongamos que K no es de máximo cardinal. Sea K^* un emparejamiento de máximo cardinal en G, de modo que $|K^*| > |K|$. Consideramos el subgrafo diferencia simétrica $H = (V, K \triangle K^*)$, con aristas $E_H = (K \setminus K^*) \cup (K^* \setminus K)$. En el grafo H, cada vértice $v \in V$ puede ser incidente a lo sumo en una arista de K y una arista de K^*, por lo que el grado de cualquier nodo en H satisface $d_H(v) \leq 2$. Por el Lema de Descomposición de Grafos de Grado ≤ 2, las componentes conexas de H son exclusivamente:

  1. Vértices aislados ($d_H(v) = 0$).
  2. Ciclos alternantes de longitud par (con igual número de aristas de K que de K^*).
  3. Cadenas alternantes simples.

  Puesto que $|K^*| > |K|$, en el conjunto de aristas E_H hay estrictamente más aristas de K^* que de K. Como los ciclos y cadenas pares contienen idéntico número de aristas de ambos emparejamientos, debe existir al menos una cadena alternante conexa P en H que contenga más aristas de K^* que de K. Dicha cadena P comienza y termina obligatoriamente con aristas de K^*. En consecuencia, sus dos extremos no pueden estar saturados por aristas de K (pues en H no incide ninguna arista de K en sus extremos), lo que certifica que P es una cadena alternante incremental respecto de K. Por reducción al absurdo, si no existen cadenas incrementales en G, K es necesariamente de máximo cardinal. ■

Ejercicio 3: Árboles Alternantes en Grafos Bipartitos y Detección de Cadenas Incrementales

Considérese el grafo bipartito $G = (V_1 \cup V_2, E)$ con partición de vértices $V_1 = \{1, 2, 3, 4, 5\}$ y $V_2 = \{6, 7, 8, 9, 10\}$, cuyas aristas son:

$$E = \{\{1,6\},\ \{1,7\},\ \{2,7\},\ \{2,8\},\ \{3,8\},\\ \{3,9\},\ \{4,8\},\ \{4,10\},\ \{5,9\},\ \{5,10\}\}$$

Se dispone del emparejamiento inicial $K_1 = \{\{2,7\},\ \{3,8\},\ \{5,10\}\}$ con $|K_1| = 3$.

Se pide:

1. Identificar el conjunto de raíces $R \subset V_1 \cup V_2$ formado por los vértices no saturados respecto de K_1.

   Solución:

Vértices saturados por K_1: $\{2,3,5\} \subset V_1$ y $\{7,8,10\} \subset V_2$. Vértices expuestos (raíces):

- En V_1: $\{1,4\}$.
- En V_2: $\{6,9\}$. El conjunto de raíces para explorar bosques alternantes es $R = \{1,4,6,9\}$.

---

2. Desarrollar la construcción del árbol alternante con raíz en el vértice expuesto $i_0 = 1$, especificando en cada nivel los vértices de paridad par (Y^0) e impar (Y^1) y las aristas incorporadas al árbol (T).

   Solución:

   - **Nivel 0 (Raíz par)**: $Y^0 = \{1\}$, $Y^1 = \emptyset$, $T = \emptyset$.
   - **Nivel 1 (Exploración de vecinos impares fuera de K_1)**: Desde $1 \in Y^0$, existen las aristas $\{1,6\}$ y $\{1,7\}$ fuera de K_1:
     - Vecino $6 \in V_2$ está expuesto ($sat(6) = 0$). ¡Se detecta extremo incremental!
     - Vecino $7 \in V_2$ está saturado por $\{7,2\} \in K_1$. Se incorpora 7 a Y^1 y 2 a Y^0. $Y^1 = \{6,7\}$, $T = \{\{1,6\}, \{1,7\}, \{7,2\}\}$, $Y^0 = \{1,2\}$.
   - **Nivel 2 y 3 (Exploración desde $2 \in Y^0$)**: Desde $2 \in Y^0$, evaluamos aristas fuera de K_1:
     - Vecino $8 \in V_2$ está saturado por $\{8,3\} \in K_1$. Se incorpora 8 a Y^1 y 3 a Y^0. $Y^1 = \{6,7,8\}$, $Y^0 = \{1,2,3\}$, $T = T \cup \{\{2,8\}, \{8,3\}\}$.
   - **Nivel 4 y 5 (Exploración desde $3 \in Y^0$)**: Desde $3 \in Y^0$, evaluamos aristas fuera de K_1:
     - Vecino $9 \in V_2$ está expuesto ($sat(9) = 0$). ¡Se detecta extremo incremental! $Y^1 = \{6,7,8,9\}$, $Y^0 = \{1,2,3\}$.

---

3. Construir el vector de antecesores/padres $\mathbf{p} \in \mathbb{N}^{10}$ tras la exploración completa del árbol desde la raíz 1.

   Solución:

   Registrando para cada nodo alcanzado el vértice predecesor en el árbol alternante:

   - $p(1) = 1$ (raíz)
   - $p(7) = 1$ (alcanzado desde 1)
   - $p(2) = 7$ (alcanzado por arista saturada $\{7,2\}$)

- $p(8) = 2$ (alcanzado desde 2)
- $p(3) = 8$ (alcanzado por arista saturada $\{8, 3\}$)
- $p(6) = 1$ (alcanzado desde 1)
- $p(9) = 3$ (alcanzado desde 3)
- Nodos no alcanzados desde la raíz 1: $p(4) = 0, p(5) = 0, p(10) = 0$.

Vector de antecesores:

$$\mathbf{p}^T = (1, 7, 8, 0, 0, 1, 1, 2, 3, 0)$$

---

4. Desenrollar mediante el vector $\mathbf{p}$ todas las cadenas incrementales que alcanzan vértices expuestos, seleccionar una cadena μ y ejecutar la transferencia para obtener un nuevo emparejamiento aumentado K_2 de cardinal 4.

   Solución:

   Vértices expuestos alcanzados por el árbol: 6 y 9.

   - **Cadena 1 (desde 6)**:

   $$6 \longleftarrow p(6) = 1 \implies \mu_1 = (6, 1)$$

   - **Cadena 2 (desde 9)**:

   $$9 \longleftarrow p(9) = 3 \longleftarrow p(3) = 8 \longleftarrow p(8) = 2 \longleftarrow p(2) = 7 \longleftarrow p(7) = 1 \implies \mu_2 = (9, 3, 8, 2, 7, 1)$$

   Seleccionamos la cadena elemental $\mu_1 = (1, 6)$ (arista directa $\{1, 6\}$). Aplicamos la transferencia:

   $$K_2 = K_1 \cup \big\{\{1, 6\}\big\} = \big\{\{1, 6\},\, \{2, 7\},\, \{3, 8\},\, \{5, 10\}\big\}, \quad |K_2| = 4$$

---

5. Aplicar una segunda fase del algoritmo de árbol alternante sobre los vértices expuestos restantes hasta certificar la existencia de un emparejamiento perfecto de cardinal 5 o demostrar maximalidad.

   Solución:

   Respecto de K_2, los únicos vértices expuestos restantes son $4 \in V_1$ y $9 \in V_2$. Inicializamos un nuevo árbol alternante con raíz en $i_0 = 4$:

   - $Y^0 = \{4\}, T = \emptyset$.
   - Desde $4 \in Y^0$, aristas fuera de K_2:

  - Vecino $8 \in V_2$ está saturado por $\{8,3\} \in K_2 \implies Y^1 = \{8\}, Y^0 = \{4,3\}, T = \{\{4,8\},\{8,3\}\}$.
  - Vecino $10 \in V_2$ está saturado por $\{10,5\} \in K_2 \implies Y^1 = \{8,10\}, Y^0 = \{4,3,5\}, T = T \cup \{\{4,10\},\{10,5\}\}$.
- Desde $3 \in Y^0$:
  - Vecino $9 \in V_2$ está expuesto ($sat(9) = 0$). ¡Se detecta cadena incremental! Desenrollando el camino: $9 \leftarrow 3 \leftarrow 8 \leftarrow 4$, obtenemos:

$$\mu = (4, 8, 3, 9)$$

Ejecutamos la transferencia $K^* = K_2 \triangle \mu$:

- Aristas eliminadas: $\{3,8\}$.
- Aristas incorporadas: $\{4,8\}$ y $\{3,9\}$.
- Aristas conservadas: $\{1,6\},\{2,7\},\{5,10\}$.

$$K^* = \{\{1,6\},\ \{2,7\},\ \{3,9\},\ \{4,8\},\ \{5,10\}\}$$

El cardinal es $|K^*| = 5 = 10/2$, alcanzando un **emparejamiento perfecto** en el grafo bipartito.

Ejercicio 4: Algoritmo de Flor de Edmonds (Blossom Algorithm) y Ciclos Impares

Considérese el grafo no dirigido no bipartito $G = (V, E)$ de $n = 7$ vértices $V = \{1, 2, 3, 4, 5, 6, 7\}$ con aristas:

$$E = \{\{1,2\},\ \{2,3\},\ \{3,4\},\ \{4,5\},\ \{5,1\},\ \{3,6\},\ \{6,7\}\}$$

y el emparejamiento inicial $K = \{\{1,2\},\ \{3,4\}\}$ con $|K| = 2$.

Se pide:

1. Explicar por qué la presencia de ciclos impares en grafos generales no bipartitos impide la aplicación directa del algoritmo de árboles alternantes estándar de grafos bipartitos.

   Solución:

   En grafos bipartitos, todos los ciclos son de longitud par. Esta propiedad garantiza que la paridad de la distancia desde la raíz es un invariante determinista: los vértices

en niveles pares siempre se alcanzan mediante aristas saturadas, y las aristas fuera del emparejamiento solo pueden conectar niveles pares con niveles impares.

En cambio, en un grafo general no bipartito con ciclos impares (por ejemplo, el ciclo de 5 vértices $C_5 = \{1, 2, 3, 4, 5\}$), dos vértices de la misma paridad en el árbol alternante ($i, j \in Y^0$) pueden ser adyacentes entre sí mediante una arista $\{i, j\} \in E$. Esto crea un ciclo alternante impar (denominado *flor* o *blossom*). En una flor de longitud $2k + 1$, existen simultáneamente dos caminos alternantes de distinta paridad hacia un mismo vértice. Esto provoca que el algoritmo estándar de árbol pueda clasificar erróneamente vértices pares como impares y viceversa, bloqueando la detección de cadenas incrementales auténticas. La técnica de contracción de Edmonds soluciona este obstáculo colapsando toda la flor en un único pseudonodo.

---

2. Iniciar el Algoritmo de Flor de Edmonds construyendo el árbol alternante desde el vértice expuesto $i_0 = 5$:

   - Identificar la extensión del árbol mediante aristas saturadas (Paso C.2, Caso 2).
   - Detectar la existencia de una arista $\{i, j\} \in E$ que une dos vértices pares $i, j \in Y^0$ y caracterizar la flor (ciclo impar) W resultante (Paso C.2, Caso 1).

   Solución:

   - **Paso A**: $K = \{\{1, 2\}, \{3, 4\}\}$. Vértices expuestos: $\{5, 6, 7\}$.
   - **Paso B**: Hay 3 vértices expuestos (> 1) $\implies$ Ir al **Paso C**.
   - **Paso C.1**: Seleccionamos la raíz expuesta $i_0 = 5$. Inicializamos el árbol: $Y = Y^0 = \{5\}$, $T = \emptyset$.
   - **Paso C.2 (Extensión 1)**: Para $5 \in Y^0$, existe el vecino saturado $1 \notin Y$ (saturado por $\{1, 2\} \in K$). Por Caso 2, añadimos $\{5, 1\}$ y $\{1, 2\}$ al árbol:

   $$Y = \{1, 2, 5\}, \quad Y^0 = \{2, 5\}, \quad T = \{\{5, 1\}, \{1, 2\}\}$$

   - **Paso C.2 (Extensión 2)**: Para $5 \in Y^0$, existe el vecino saturado $4 \notin Y$ (saturado por $\{3, 4\} \in K$). Por Caso 2, añadimos $\{5, 4\}$ y $\{4, 3\}$ al árbol:

   $$Y = \{1, 2, 3, 4, 5\}, \quad Y^0 = \{2, 3, 5\}, \quad T = \{\{5, 1\}, \{1, 2\}, \{5, 4\}, \{4, 3\}\}$$

   - **Paso C.2 (Detección de Flor por Caso 1)**: Evaluamos aristas entre vértices pares en $Y^0 = \{2, 3, 5\}$. Observamos que existe la arista $\{2, 3\} \in E$. Al conectar los vértices pares $2, 3 \in Y^0$, se detecta la **flor de 5 vértices**:

   $$W = \{1, 2, 3, 4, 5\}$$

---

3. Realizar la contracción del ciclo impar W en un supernodo w, especificando los conjuntos de vértices y aristas del grafo comprimido G/W.

   Solución:

   Comprimimos el subconjunto $W = \{1, 2, 3, 4, 5\}$ en el supernodo w:

   - **Vértices de** G/W: $V' = (V \setminus W) \cup \{w\} = \{w, 6, 7\}$.
   - **Aristas de** G/W:
     - Aristas que no tocan W: $\{6, 7\}$.
     - Aristas incidentes en W: la arista $\{3, 6\} \in E$ con $3 \in W, 6 \notin W$ se convierte en $\{w, 6\}$.

   $$E/W = \{\{w, 6\},\ \{6, 7\}\}$$

   En el grafo comprimido G/W, el árbol alternante se actualiza a $Y = Y^0 = \{w\}$, $T = \emptyset$ y el emparejamiento comprimido es $K = \emptyset$.

---

4. Explorar el grafo comprimido G/W, detectar la cadena incremental que conecta con el vértice expuesto 7 y realizar la transferencia en G/W.

   Solución:

   - Desde $w \in Y^0$ en G/W, evaluamos vecinos fuera del árbol:
     - Existe la arista $\{w, 6\}$ con 6 saturado / expuesto: 6 y 7 están expuestos.
     - Desde w, exploramos $\{w, 6\}$; como 6 está expuesto, la cadena $w - 6 - 7$ se puede extender o podemos explorar:
     - Paso C.2 (Caso 2/3): Desde $w \in Y^0$, la arista $\{w, 6\}$ conecta con el nodo expuesto $6 \implies$ Transferencia en G/W: $K = \{\{w, 6\}\}$.
     - Siguiente iteración desde $7 \in Y^0$: 7 conecta con $6 \in Y$ (saturado por $\{w, 6\}$) y alcanza $w \implies$ Cadena incremental en G/W: $\mu = (w, 6, 7)$ o transferencia directa con aristas $\{w, 6\}, \{6, 7\}$.
     - De forma más directa, la cadena incremental en G/W es $\mu' = (w, 6, 7)$ que conecta los vértices expuestos w y 7 a través de $\{w, 6\}$ y $\{6, 7\}$ (o transferencias sucesivas). El emparejamiento resultante en G/W contiene la arista $\{w, 6\}$ y satura al nodo 7 mediante $\{6, 7\}$ (o la arista $\{3, 6\}$).

---

5. Ejecutar la descompresión determinista de la flor W aplicando el Teorema de Edmonds (1965) y reconstruir el emparejamiento óptimo final K^* sobre el grafo original G, indicando su cardinalidad y si es perfecto.

   Solución:

   En G/W, tenemos el emparejamiento saturado con la arista $\{w, 6\}$ y $\{6, 7\}$ según la asignación:

   - La arista $\{w, 6\}$ proviene originalmente de la arista $\{3, 6\} \in E$.
   - En la flor $W = \{1, 2, 3, 4, 5\}$, el vértice 3 queda saturado hacia el exterior mediante la arista $\{3, 6\}$.
   - Aplicando la regla de descompresión de Edmonds, dejamos libre el vértice 3 dentro de W y saturamos los 4 vértices restantes $\{1, 2, 4, 5\}$ mediante un emparejamiento maximal de 2 aristas:

     $$K_W = \{\{1, 2\}, \{4, 5\}\} \quad \text{o} \quad \{\{5, 1\}, \{3, 4\} \dots\}$$

     Como $\{1, 2\}$ y $\{4, 5\}$ saturan exactamente a $\{1, 2, 4, 5\}$, ningún vértice de W queda doblemente saturado.

   Reconstruyendo la solución en el grafo original G:

   $$K^* = \{\{1, 2\}, \{4, 5\}, \{3, 6\}\}$$

   Cardinalidad: $|K^*| = 3$. *Evaluación*: En un grafo de $n = 7$ vértices (impar), el cardinal máximo posible es $\lfloor 7/2 \rfloor = 3$. Queda exactamente un vértice expuesto (7), por lo que K^* es de **máximo cardinal global**.

Ejercicio 5: Recubrimiento de Aristas, Dualidad de Gallai y Emparejamientos Ponderados

Considérese el grafo simple conexo $G = (V, E)$ de $n = 6$ vértices $V = \{1, 2, 3, 4, 5, 6\}$ con los siguientes pesos $p(e)$ asignados a sus 8 aristas:

$$p(1, 2) = 6, \quad p(1, 3) = 4, \quad p(2, 4) = 5, \quad p(3, 4) = 7,$$
$$p(3, 5) = 3, \quad p(4, 6) = 8, \quad p(5, 6) = 4, \quad p(2, 5) = 2$$

Se pide:

1. **Problema de Recubrimiento de Aristas y Teorema de Gallai**:

- Definir formalmente el concepto de recubrimiento de aristas (*edge cover*) $F \subseteq E$ y formular su problema de mínimo cardinal en Programación Entera.
- Enunciar el Teorema de Dualidad de Gallai (1959) demostrando la igualdad fundamental $|K_0| + |F_0| = n$, donde K_0 es un emparejamiento de máximo cardinal y F_0 es un recubrimiento de mínimo cardinal.
- A partir de un emparejamiento de máximo cardinal del grafo dado, construir constructivamente un recubrimiento de aristas de mínimo cardinal aplicando la regla de Gallai.

Solución:

- **Definición y Formulación de Recubrimiento de Aristas**: Un recubrimiento de aristas de un grafo $G = (V, E)$ sin vértices aislados es un subconjunto $F \subseteq E$ tal que todo vértice $v \in V$ es incidente en al menos una arista de F. Su modelo en Programación Lineal Entera es:

$$\begin{aligned} \min_{y} \quad & \sum_{e \in E} y_e \\ \text{sujeto a} \quad & \sum_{e \in \delta(v)} y_e \geq 1, \quad \forall v \in V \\ & y_e \in \{0,1\}, \quad \forall e \in E \end{aligned}$$

- **Demostración del Teorema de Gallai (1959)**: Sea K_0 un emparejamiento de máximo cardinal en G ($|K_0| = \alpha'(G)$). El número de vértices saturados por K_0 es $2|K_0|$, y el número de vértices expuestos es $n - 2|K_0|$. Para cada vértice expuesto $v \in V_{exp}$, seleccionamos una arista arbitraria incidente en v, formando un conjunto de aristas adicionales E_{add} con $|E_{add}| \leq n - 2|K_0|$. El conjunto $F = K_0 \cup E_{add}$ cubre a todos los vértices del grafo, por lo que es un recubrimiento válido de aristas cuyo cardinal satisface:

$$|F| = |K_0| + (n - 2|K_0|) = n - |K_0|$$

Por tanto, el recubrimiento mínimo F_0 satisface $|F_0| \leq n - |K_0| \implies |K_0| + |F_0| \leq n$.

Recíprocamente, sea F_0 un recubrimiento de mínimo cardinal ($|F_0| = \beta'(G)$). Al ser minimal, el subgrafo (V, F_0) es un bosque sin ciclos de longitud ≥ 3 formado por estrellas disjuntas de aristas. Seleccionando una arista de cada estrella, se obtiene un emparejamiento válido K con cardinal $|K| = n - |F_0|$. Dado que K_0 es de máximo cardinal, $|K_0| \geq |K| = n - |F_0| \implies |K_0| + |F_0| \geq n$. Combinando ambas desigualdades se obtiene la identidad exacta de Gallai:

$$|K_0| + |F_0| = n \quad \blacksquare$$

- **Construcción Constructiva**: En el grafo dado de 6 vértices, un emparejamiento perfecto de cardinal 3 es $K_0 = \{\{1,2\},\{3,4\},\{5,6\}\}$ con $|K_0| = 3$. Como no quedan vértices expuestos ($V_{exp} = \emptyset$), el propio conjunto de aristas del emparejamiento es un recubrimiento de aristas válido:

$$F_0 = K_0 = \{\{1,2\},\ \{3,4\},\ \{5,6\}\}$$

  Su cardinal es $|F_0| = 3$, verificando $|K_0| + |F_0| = 3 + 3 = 6 = n$.

---

2. **Algoritmo de Emparejamiento de Peso Máximo por Cardinalidad Creciente**:

- Definir el coste reducido $\delta(L)$ de una cadena alternante respecto de un emparejamiento K.
- Partir de $K^0 = \emptyset$ y obtener iterativamente el emparejamiento de máximo peso para cardinales $m = 1$, $m = 2$ y $m = 3$, detallando en cada paso todas las cadenas alternantes candidatas y sus costes reducidos $\delta(L)$.
- Indicar el emparejamiento de peso máximo global K^* y su valor total óptimo.

Solución:

- **Definición de Coste Reducido**: Dada una cadena alternante L respecto de K, su coste reducido es:

$$\delta(L) = \sum_{e \in L \setminus K} p(e) - \sum_{e \in L \cap K} p(e)$$

- **Ejecución del Algoritmo paso a paso**:

  1. **Cardinal** $m = 1$: Buscamos la arista con peso máximo en E:

$$e^* = \{4,6\} \quad \text{con } p(4,6) = 8$$

$$K^1 = \{\{4,6\}\}, \quad p(K^1) = 8$$

  2. **Cardinal** $m = 2$: Vértices expuestos respecto de K^1: $\{1,2,3,5\}$. Evaluamos aristas disjuntas con extremos en $\{1,2,3,5\}$:

     - $\{1,2\}$: $\delta = p(1,2) = 6$.
     - $\{1,3\}$: $\delta = p(1,3) = 4$.
     - $\{3,5\}$: $\delta = p(3,5) = 3$.
     - $\{2,5\}$: $\delta = p(2,5) = 2$.
     - Cadena alternante de 3 aristas pasando por $\{4,6\}$: $3-4-6-5$: $\delta = p(3,4)+p(5,6)-p(4,6) = 7+4-8 = 3$. $2-4-6-5$: $\delta = p(2,4)+p(5,6)-p(4,6) = 5+4-8 = 1$.

El coste reducido máximo es $\delta = 6$ correspondiente a la arista $\{1, 2\}$.

$$K^2 = K^1 \cup \{\{1, 2\}\} = \{\{1, 2\}, \{4, 6\}\}, \quad p(K^2) = 8 + 6 = 14$$

3. **Cardinal** $m = 3$: Vértices expuestos respecto de $K^2 = \{\{1, 2\}, \{4, 6\}\}$: $\{3, 5\}$. Evaluamos todas las cadenas alternantes que conectan los vértices expuestos 3 y 5:
   - **Cadena directa de 1 arista** ($L_A = 3 - 5$):

     $$\delta(L_A) = p(3, 5) = 3 \implies p = 14 + 3 = 17$$

   - **Cadena alternante de 3 aristas** ($L_B = 3 - 4 - 6 - 5$): Entran $\{3, 4\}$ y $\{5, 6\}$; sale $\{4, 6\} \in K^2$:

     $$\delta(L_B) = [p(3, 4) + p(5, 6)] - p(4, 6) = [7 + 4] - 8 = 3 \implies p = 14 + 3 = 17$$

   - **Cadena alternante pasando por** $\{1, 2\}$ ($L_C = 3 - 1 - 2 - 5$): Entran $\{1, 3\}$ y $\{2, 5\}$; sale $\{1, 2\} \in K^2$:

     $$\delta(L_C) = [p(1, 3) + p(2, 5)] - p(1, 2) = [4 + 2] - 6 = 0 \implies p = 14 + 0 = 14$$

   El coste reducido máximo es $\delta = 3$, obtenido tanto por L_A como por L_B. Seleccionando la transferencia con $L_A = \{3, 5\}$:

   $$K^3 = \{\{1, 2\}, \{3, 5\}, \{4, 6\}\}, \quad p(K^3) = 6 + 3 + 8 = 17$$

   (O bien mediante L_B: $K'^3 = \{\{1, 2\}, \{3, 4\}, \{5, 6\}\}$ con peso $6 + 7 + 4 = 17$).

- **Conclusión de Optimalidad Global**: Al ser K^3 un emparejamiento perfecto (6 vértices saturados), el **emparejamiento de peso máximo global** es:

  $$K^* = \{\{1, 2\}, \{3, 5\}, \{4, 6\}\} \quad \text{con peso óptimo total } p(K^*) = 17$$

Ejercicios del Tema 10: rutas eulerianas, hamiltonianas y problemas de rutas

Ejercicio 1: Grafos Eulerianos, Teorema de Euler y Algoritmo Constructivo de Cadenas

Considérese el grafo simple no dirigido y conexo $G = (V, E)$ de $n = 7$ vértices $V = \{1, 2, 3, 4, 5, 6, 7\}$ con el siguiente conjunto de 11 aristas:

$$E = \{\{1,2\}, \{1,3\}, \{2,3\}, \{2,4\}, \{2,5\}, \{3,4\}, \\ \{3,5\}, \{4,6\}, \{5,6\}, \{4,7\}, \{5,7\}\}$$

cuya secuencia de grados nodales es:

$$d(1) = 2, \quad d(2) = 4, \quad d(3) = 4, \quad d(4) = 4, \quad d(5) = 4, \quad d(6) = 2, \quad d(7) = 2$$

Se pide:

1. **Demostración de paridad**: Demostrar formalmente que en cualquier grafo euleriano no dirigido conexo, todos sus vértices deben tener obligatoriamente grado par, analizando el comportamiento de las aristas incidentes en cada paso de un circuito cerrado.

   Solución:

   Sea $G = (V, E)$ un grafo conexo que admite un circuito euleriano cerrado $C = (v_0, e_1, v_1, e_2, \dots, e_m, v_0)$ que recorre cada arista $e \in E$ exactamente una vez.

   Analicemos la contribución del recorrido C al grado de cada vértice $v \in V$:

   - **Vértices intermedios ($v \neq v_0$)**: Cada vez que el circuito cerrado pasa por el vértice v, entra a través de una arista incidente $e_{in} \in \delta(v)$ y sale obligatoriamente mediante una arista incidente distinta $e_{out} \in \delta(v)$. Cada tránsito aporta exactamente $+2$ al número de aristas incidentes utilizadas en v. Si el recorrido visita el vértice v un número $k_v \in \mathbb{N}$ de veces, el número total de aristas incidentes en v utilizadas por el circuito es $2k_v$.

- **Vértice inicial y final (v_0)**: El circuito se inicia saliendo de v_0 mediante la primera arista e_1, y concluye entrando a v_0 mediante la última arista e_m. Este par inicial-final aporta $+2$ al grado. Si adicionalmente el circuito visita v_0 como nodo intermedio k_{v_0} veces, el número total de aristas incidentes utilizadas es $2 + 2k_{v_0} = 2(k_{v_0} + 1)$.

Dado que por hipótesis el circuito euleriano recorre **todas** las aristas de E sin omitir ni repetir ninguna, el grado de cada vértice $v \in V$ coincide exactamente con el número de aristas incidentes utilizadas en la secuencia:

$$d(v) = 2k_v \in 2\mathbb{N}, \quad \forall v \in V$$

Por tanto, la paridad par en todos los vértices es una condición matemáticamente necesaria. ■

---

2. **Caracterización de Euler**: Aplicar el Teorema de Euler para certificar si el grafo G admite un circuito euleriano cerrado.

   Solución:

   El **Teorema de Euler (1736)** establece que un grafo no dirigido $G = (V, E)$ admite un circuito euleriano cerrado si y solo si se verifican simultáneamente dos condiciones:

   1. El grafo es conexo (salvo posibles vértices aislados de grado 0).
   2. Todos los vértices tienen grado estrictamente par: $d(v) \equiv 0 \pmod 2$, $\forall v \in V$.

   Evaluando el grafo G:

   - **Conectividad**: Existe camino entre cualquier par de vértices (el grafo consta de una única componente conexa con $|V| = 7$).
   - **Paridad de grados**:

     $$d(1) = 2, \quad d(2) = 4, \quad d(3) = 4, \quad d(4) = 4, \quad d(5) = 4, \quad d(6) = 2, \quad d(7) = 2$$

     Dado que todos los grados pertenecen a $\{2, 4\}$, todos los vértices son pares.

   Conclusión: Por el Teorema de Euler, el grafo G es estrictamente euleriano y admite al menos un circuito euleriano cerrado.

---

3. **Traza del algoritmo constructivo**: Desarrollar paso a paso el algoritmo constructivo de cadenas eulerianas.

   Solución:

   El algoritmo constructivo (basado en el método de descomposición de Hierholzer) descompone el grafo euleriano en una unión de ciclos simples disjuntos en aristas y los fusiona iterativamente:

   - **Paso 1 (Ciclo inicial C_1)**: Partiendo del vértice 1, trazamos un ciclo simple en G:

     $$C_1 = (1, 2, 3, 1)$$

     Aristas utilizadas: $E(C_1) = \{\{1,2\}, \{2,3\}, \{3,1\}\}$ (3 aristas). Grafo residual de aristas no visitadas: $E_1 = E \setminus E(C_1)$ $(11 - 3 = 8$ aristas).

   - **Paso 2 (Detección de contacto y ciclo secundario C_2)**: En el ciclo C_1, el vértice 2 tiene aristas incidentes no utilizadas en E_1: $\{2,4\}$ y $\{2,5\}$. Iniciamos una búsqueda desde el vértice 2 en el grafo residual E_1:

     $$C_2 = (2, 4, 6, 5, 2)$$

     Aristas utilizadas: $E(C_2) = \{\{2,4\}, \{4,6\}, \{6,5\}, \{5,2\}\}$ (4 aristas).

   - **Paso 3 (Fusión intercalada $C_1 \oplus C_2$)**: Insertamos el ciclo C_2 en la posición del vértice 2 dentro de C_1:

     $$C_{12} = (1, \mathbf{2}, \mathbf{4}, \mathbf{6}, \mathbf{5}, \mathbf{2}, 3, 1)$$

     Aristas residuales restantes: $E_2 = E_1 \setminus E(C_2)$ $(8 - 4 = 4$ aristas):

     $$E_2 = \{\{3,4\}, \{4,7\}, \{7,5\}, \{5,3\}\}$$

   - **Paso 4 (Tercer ciclo C_3 y fusión final)**: En el circuito acumulado C_{12}, el vértice 3 dispone de aristas pendientes en E_2. Trazamos el ciclo simple desde 3:

     $$C_3 = (3, 4, 7, 5, 3)$$

     Aristas utilizadas: $E(C_3) = \{\{3,4\}, \{4,7\}, \{7,5\}, \{5,3\}\}$ (4 aristas). El grafo residual queda vacío: $E \setminus (E(C_1) \cup E(C_2) \cup E(C_3)) = \emptyset$.

   - **Paso 5 (Fusión definitiva)**: Insertamos C_3 en el vértice 3 del circuito C_{12}:

     $$C^* = (1, 2, 4, 6, 5, 2, \mathbf{3}, \mathbf{4}, \mathbf{7}, \mathbf{5}, \mathbf{3}, 1)$$

   Resultado: La secuencia cerrada $(1, 2, 4, 6, 5, 2, 3, 4, 7, 5, 3, 1)$ recorre las 11 aristas de G exactamente una vez, constituyendo un circuito euleriano válido.

---

4. **Generalización a digrafos y caminos abiertos**:

   Solución:

   - **Digrafos eulerianos**: Un grafo dirigido conexo (en el sentido débil) admite un circuito euleriano dirigido cerrado si y solo si es balanceado en todos sus vértices, es decir, el grado de entrada coincide con el grado de salida en cada nodo:

   $$d^-(v) = d^+(v), \quad \forall v \in V$$

   - **Trayectorias eulerianas abiertas (semieulerianas)**: Un grafo no dirigido conexo admite un camino euleriano abierto (que recorre todas las aristas comenzando en un vértice u y finalizando en otro vértice $v \neq u$) si y solo si exactamente **dos vértices tienen grado impar** ($d(u)$ y $d(v)$ impares) y todos los demás vértices $w \in V \setminus \{u, v\}$ tienen grado estrictamente par. En tal caso, el recorrido se inicia obligatoriamente en uno de los vértices impares y concluye en el otro.

Ejercicio 2: Problema del Cartero Chino (CPP) y Matching de Nodos Impares

Considérese la red vial no dirigida y ponderada $G = (V, E, \mathbf{c})$ de $n = 8$ vértices $V = \{1, 2, 3, 4, 5, 6, 7, 8\}$ con las 12 aristas y costes asociados siguientes:

$$\begin{array}{llll} c(1,2) = 4, & c(1,3) = 6, & c(2,3) = 3, & c(2,4) = 5, \\ c(2,5) = 7, & c(3,5) = 8, & c(4,6) = 4, & c(4,7) = 6, \\ c(5,6) = 5, & c(5,7) = 3, & c(6,8) = 7, & c(7,8) = 4 \end{array}$$

Se pide:

1. **Identificación de paridades y vértices impares**: Calcular el grado de cada vértice $d(v)$ y determinar el conjunto de vértices con grado impar $V_{odd} \subset V$. Justificar analíticamente por qué $|V_{odd}|$ es siempre un número par.

   Solución:

   Calculamos el grado de cada vértice contando sus aristas incidentes:

   - $d(1) = 2$ (aristas $\{1,2\}, \{1,3\}$) $\rightarrow$ Par
   - $d(2) = 4$ (aristas $\{1,2\}, \{2,3\}, \{2,4\}, \{2,5\}$) $\rightarrow$ Par
   - $d(3) = 3$ (aristas $\{1,3\}, \{2,3\}, \{3,5\}$) $\rightarrow$ **Impar**

- $d(4) = 3$ (aristas $\{2,4\}, \{4,6\}, \{4,7\}$) $\rightarrow$ **Impar**
- $d(5) = 4$ (aristas $\{2,5\}, \{3,5\}, \{5,6\}, \{5,7\}$) $\rightarrow$ Par
- $d(6) = 3$ (aristas $\{4,6\}, \{5,6\}, \{6,8\}$) $\rightarrow$ **Impar**
- $d(7) = 3$ (aristas $\{4,7\}, \{5,7\}, \{7,8\}$) $\rightarrow$ **Impar**
- $d(8) = 2$ (aristas $\{6,8\}, \{7,8\}$) $\rightarrow$ Par

El conjunto de vértices impares es:

$$V_{odd} = \{3,4,6,7\}, \quad |V_{odd}| = 4$$

Demostración de paridad de $|V_{odd}|$: Por el **Lema del Apretón de Manos** de Euler, la suma de los grados de todos los vértices es igual al doble del número de aristas:

$$\sum_{v \in V} d(v) = 2|E|$$

Descomponiendo la suma entre vértices de grado par (V_{even}) e impar (V_{odd}):

$$\sum_{v \in V_{even}} d(v) + \sum_{v \in V_{odd}} d(v) = 2|E| \implies \sum_{v \in V_{odd}} d(v) = 2|E| - \sum_{v \in V_{even}} d(v)$$

Como $2|E|$ es par y la suma de números pares es par, la suma $\sum_{v \in V_{odd}} d(v)$ debe ser un número par. Dado que cada término $d(v)$ en esta suma es impar, una suma de enteros impares solo puede resultar par si el número de sumandos es par. Por tanto, $|V_{odd}|$ es necesariamente par. ■

---

2. **Matriz de distancias mínimas en** V_{odd}: Calcular la distancia más corta $d_G(u,v)$ para cada par de vértices en V_{odd}.

   Solución:

   Aplicando el algoritmo de Dijkstra para los 4 vértices impares $\{3,4,6,7\}$:

   - **Par** $\{3,4\}$:
     - Camino $(3,2,4)$: coste $c(3,2) + c(2,4) = 3 + 5 = 8$.
     - $d_G(3,4) = 8$.
   - **Par** $\{3,6\}$:
     - Camino $(3,2,4,6)$: coste $3 + 5 + 4 = 12$.
     - Camino $(3,5,6)$: coste $8 + 5 = 13$.
     - $d_G(3,6) = 12$.
   - **Par** $\{3,7\}$:
     - Camino $(3,5,7)$: coste $c(3,5) + c(5,7) = 8 + 3 = 11$.
     - Camino $(3,2,5,7)$: coste $3 + 7 + 3 = 13$.

  - $d_G(3,7) = 11$.
- **Par** $\{4,6\}$:
  - Arista directa $\{4,6\}$: coste 4.
  - $d_G(4,6) = 4$.
- **Par** $\{4,7\}$:
  - Arista directa $\{4,7\}$: coste 6.
  - $d_G(4,7) = 6$.
- **Par** $\{6,7\}$:
  - Camino $(6,5,7)$: coste $c(6,5) + c(5,7) = 5 + 3 = 8$.
  - Camino $(6,8,7)$: coste $c(6,8) + c(7,8) = 7 + 4 = 11$.
  - $d_G(6,7) = 8$.

La matriz simétrica de distancias mínimas sobre V_{odd} es:

$$\mathbf{D}_{odd} = \begin{pmatrix} - & 8 & 12 & 11 \\ 8 & - & 4 & 6 \\ 12 & 4 & - & 8 \\ 11 & 6 & 8 & - \end{pmatrix}$$

---

3. **Emparejamiento perfecto de peso mínimo**: Construir el grafo completo auxiliar K_4, evaluar todos los emparejamientos perfectos posibles y seleccionar el óptimo M^*.

   Solución:

   En un grafo completo K_4 existen exactamente $(4-1)!! = 3 \times 1 = 3$ emparejamientos perfectos posibles:

   1. **Emparejamiento** $M_1 = \{\{3,4\}, \{6,7\}\}$:

      $$\text{Coste}(M_1) = d_G(3,4) + d_G(6,7) = 8 + 8 = 16$$

   2. **Emparejamiento** $M_2 = \{\{3,6\}, \{4,7\}\}$:

      $$\text{Coste}(M_2) = d_G(3,6) + d_G(4,7) = 12 + 6 = 18$$

   3. **Emparejamiento** $M_3 = \{\{3,7\}, \{4,6\}\}$:

      $$\text{Coste}(M_3) = d_G(3,7) + d_G(4,6) = 11 + 4 = 15$$

   Resultado: El emparejamiento perfecto de peso mínimo es $M^* = M_3 = \{\{3,7\}, \{4,6\}\}$ con coste mínimo $\text{Coste}(M^*) = 15$.

---

4. **Eulerización y coste óptimo del CPP**:

   Solución:

   - **Aristas duplicadas para eulerizar el grafo**:
     - Para el par $\{3,7\}$: se duplican las aristas del camino mínimo $(3,5,7)$, es decir, $\{3,5\}$ (coste 8) y $\{5,7\}$ (coste 3).
     - Para el par $\{4,6\}$: se duplica la arista $\{4,6\}$ (coste 4).
   - **Coste total de la red original**:

$$\sum_{e\in E} c(e) = 4+6+3+5+7+8+4+6+5+3+7+4 = 62$$

   - **Coste de la ruta óptima del Cartero Chino**:

$$c(CPP) = \sum_{e\in E} c(e) + \text{Coste}(M^*) = 62 + 15 = 77$$

   - **Trazado de la ruta euleriana óptima cerrada desde el depósito 1**: En el multigrafo eulerizado G^* (donde $\{3,5\}$, $\{5,7\}$ y $\{4,6\}$ aparecen por duplicado), un recorrido euleriano cerrado óptimo es:

$$(1,2,4,6,8,7,5,6,\mathbf{4},\mathbf{6},4,7,\mathbf{5},\mathbf{7},5,\mathbf{3},\mathbf{5},3,2,5,2,3,1)$$

     donde las aristas duplicadas aparecen marcadas en negrita, logrando recorrer todas las calles de la red al menos una vez con distancia mínima 77.

Ejercicio 3: Grafos Hamiltonianos, Condiciones de Dirac, Ore y Clausura de Bondy-Chvátal

Considérese el grafo simple no dirigido $G = (V, E)$ de $n = 6$ vértices $V = \{1,2,3,4,5,6\}$ con el siguiente conjunto de 9 aristas:

$$E = \{\{1,2\},\{1,3\},\{1,4\},\{2,3\},\{2,5\},\{3,4\},\{3,6\},\{4,5\},\{5,6\}\}$$

Se pide:

1. **Condición de Dirac (1952)**:

   Solución:

   Calculamos los grados nodales:

   - $d(1) = 3$ ($\{1,2\}, \{1,3\}, \{1,4\}$)
   - $d(2) = 3$ ($\{1,2\}, \{2,3\}, \{2,5\}$)
   - $d(3) = 4$ ($\{1,3\}, \{2,3\}, \{3,4\}, \{3,6\}$)
   - $d(4) = 3$ ($\{1,4\}, \{3,4\}, \{4,5\}$)
   - $d(5) = 3$ ($\{2,5\}, \{4,5\}, \{5,6\}$)
   - $d(6) = 2$ ($\{3,6\}, \{5,6\}$)

   El **Teorema de Dirac** exige que $d(v) \geq \frac{n}{2} = \frac{6}{2} = 3$ para todo $v \in V$. Como $d(6) = 2 < 3$, el vértice 6 incumple la hipótesis. Por consiguiente, el Teorema de Dirac **no es aplicable** y no permite garantizar la existencia de un ciclo hamiltoniano.

---

2. **Condición de Ore (1960)**:

   Solución:

   El **Teorema de Ore** establece que si para todo par de vértices no adyacentes $\{u, v\} \notin E$ se verifica $d(u) + d(v) \geq n = 6$, entonces G es hamiltoniano.

   Evaluamos los pares de vértices no adyacentes en G:

   - $\{1,5\} \notin E \implies d(1) + d(5) = 3 + 3 = 6 \geq 6$ (Cumple)
   - $\{1,6\} \notin E \implies d(1) + d(6) = 3 + 2 = 5 < 6$ (**Falla**)
   - $\{2,4\} \notin E \implies d(2) + d(4) = 3 + 3 = 6 \geq 6$ (Cumple)
   - $\{2,6\} \notin E \implies d(2) + d(6) = 3 + 2 = 5 < 6$ (**Falla**)
   - $\{4,6\} \notin E \implies d(4) + d(6) = 3 + 2 = 5 < 6$ (**Falla**)

   Como existen pares no adyacentes cuya suma de grados es estrictamente menor que 6, la condición de Ore **no se satisface** globalmente en G.

---

3. **Clausura de Bondy-Chvátal (1976)**:

   Solución:

   La clausura $[G]$ de un grafo G de orden n se construye añadiendo recursivamente una arista $\{u, v\}$ entre pares no adyacentes tales que $d(u) + d(v) \geq n$, actualizando los grados tras cada adición hasta que no sea posible añadir más aristas.

- **Iteración 1**: Pares con $d(u) + d(v) \geq 6$:
  - Añadimos $\{1, 5\}$ $(d(1) + d(5) = 6)$.
  - Añadimos $\{2, 4\}$ $(d(2) + d(4) = 6)$. Grados actualizados:

$$d(1) = 4, \quad d(2) = 4, \quad d(3) = 4, \quad d(4) = 4, \quad d(5) = 4, \quad d(6) = 2$$

- **Iteración 2**: Reevaluamos los pares no adyacentes restantes con el vértice 6:
  - $\{1, 6\} \notin E \implies d(1) + d(6) = 4 + 2 = 6 \geq 6 \implies$ añadimos $\{1, 6\}$.
  - $\{2, 6\} \notin E \implies d(2) + d(6) = 4 + 2 = 6 \geq 6 \implies$ añadimos $\{2, 6\}$.
  - $\{4, 6\} \notin E \implies d(4) + d(6) = 4 + 2 = 6 \geq 6 \implies$ añadimos $\{4, 6\}$. Grados actualizados tras incorporar estas 3 aristas:

$$d(1) = 5, \quad d(2) = 5, \quad d(3) = 4, \quad d(4) = 5, \quad d(5) = 4, \quad d(6) = 5$$

- **Iteración 3**: Todos los vértices están conectados entre sí, por lo que la clausura obtenida es el grafo completo:

$$[G] = K_6$$

Teorema de Bondy-Chvátal: Un grafo G es hamiltoniano si y solo si su clausura $[G]$ es hamiltoniana. Dado que $[G] = K_6$ es completo (y por tanto trivialmente hamiltoniano), se concluye rigurosamente que el grafo original G **es hamiltoniano**.

Un ciclo hamiltoniano explícito en G es:

$$(1, 4, 5, 6, 3, 2, 1)$$

---

4. **Discusión sobre necesidad vs. suficiencia**:

   Solución:

   Las condiciones de Dirac, Ore y Bondy-Chvátal son **condiciones suficientes, pero no necesarias** para la existencia de ciclos hamiltonianos.

   Contraejemplo: Considérese el ciclo simple C_n con $n \geq 5$ (por ejemplo, C_5).

   - C_5 es trivialmente hamiltoniano (él mismo es un ciclo que visita todos los vértices).
   - Sin embargo, todos sus vértices tienen grado regular $d(v) = 2$.
   - Condición de Dirac: $d(v) = 2 < 2.5 = 5/2$ (falla).
   - Condición de Ore: para cualquier par no adyacente, $d(u) + d(v) = 2 + 2 = 4 < 5$ (falla).
   - Clausura de Bondy-Chvátal: no se puede añadir ninguna arista, por lo que $[C_5] = C_5 \neq K_5$.

Este contraejemplo demuestra que un grafo puede ser perfectamente hamiltoniano a pesar de no cumplir ninguna de las condiciones basadas en cotas de grado o clausuras densas.

Ejercicio 4: Modelos de Programación Lineal Entera (PLE) para el Problema del Viajante de Comercio (TSP)

Considérese el Problema del Viajante de Comercio (TSP) definido sobre una red dirigida completa $G = (V, A)$ con conjunto de vértices $V = \{1, 2, \dots, n\}$ y matriz de costes de desplazamiento $C = (c_{ij})$.

Se pide:

1. **Modelo 1 por etapas**:

   Solución:

   Definimos la variable de decisión binaria tridimensional:

   $$x_{ijk} = \begin{cases} 1 & \text{si el arco } (i,j) \in A \text{ se recorre en la etapa } k \in \{1, \dots, n\} \\ 0 & \text{en caso contrario} \end{cases}$$

   La formulación matemática del Modelo 1 es:

   $$\min_{x} \quad \sum_{i=1}^{n} \sum_{j=1, j\neq i}^{n} \sum_{k=1}^{n} c_{ij} x_{ijk}$$

   $$\text{sujeto a} \quad \sum_{j=1, j\neq i}^{n} \sum_{k=1}^{n} x_{ijk} = 1, \quad \forall i \in V \quad \text{(cada ciudad se visita exactamente una vez)}$$

   $$\sum_{i=1}^{n} \sum_{j=1, j\neq i}^{n} x_{ijk} = 1, \quad \forall k \in \{1, \dots, n\} \quad \text{(en cada etapa se realiza un único desplazamiento)}$$

   $$\sum_{i=1, i\neq j}^{n} x_{ijk} = \sum_{l=1, l\neq j}^{n} x_{jl,k+1}, \quad \forall j \in V, \forall k \in \{1, \dots, n-1\} \quad \text{(continuidad espacial de etapas)}$$

   $$\sum_{i=1, i\neq j}^{n} x_{ijn} = \sum_{l=1, l\neq j}^{n} x_{jl1}, \quad \forall j \in V \quad \text{(cierre cíclico de la última a la primera etapa)}$$

   $$x_{ijk} \in \{0, 1\}, \quad \forall (i,j) \in A, \forall k \in \{1, \dots, n\}$$

   Dimensión del modelo: Dispone de $n^2(n-1) = O(n^3)$ variables binarias y $O(n^2)$ restricciones, lo que provoca una explosión dimensional que limita su uso a instancias pequeñas.

2. **Modelo 2 de Dantzig-Fulkerson-Johnson (DFJ)**:

Solución:

Con variables binarias estándar $x_{ij} \in \{0,1\}$ (indicando si el arco (i,j) forma parte del tour):

$$\begin{aligned}
\min_{x} \quad & \sum_{i=1}^{n} \sum_{j=1, j\neq i}^{n} c_{ij} x_{ij} \\
\text{sujeto a} \quad & \sum_{j=1, j\neq i}^{n} x_{ij} = 1, \quad \forall i \in V \quad \text{(grado de salida unitario)} \\
& \sum_{i=1, i\neq j}^{n} x_{ij} = 1, \quad \forall j \in V \quad \text{(grado de entrada unitario)} \\
& \sum_{i\in S} \sum_{j\in S, j\neq i} x_{ij} \leq |S| - 1, \quad \forall S \subset V,\, 2 \leq |S| \leq n-1 \quad \text{(SECs)} \\
& x_{ij} \in \{0,1\}, \quad \forall i \neq j
\end{aligned}$$

Número de restricciones SEC: El número de subconjuntos no triviales $S \subset V$ con $2 \leq |S| \leq n-1$ es:

$$\sum_{k=2}^{n-1} \binom{n}{k} = 2^n - \binom{n}{0} - \binom{n}{1} - \binom{n}{n} = 2^n - n - 2$$

Al considerar la simetría complementaria (S vs $V \setminus S$), la familia de cortes tiene un orden exponencial $O(2^n)$.

Resolución práctica: Es imposible inyectar 2^n restricciones a priori para $n \geq 30$. Por ello, se resuelve inicialmente la relajación de asignación ($x_{ij} \in [0,1]$ con restricciones nodales). Al encontrar una solución entera con subciclos, se detecta el subconjunto S desconectado y se añade dinámicamente su restricción SEC mediante **generación perezosa de planos de corte** (*branch-and-cut*).

---

3. **Modelo 3 de Miller-Tucker-Zemlin (MTZ)**:

Solución:

El modelo MTZ sustituye las $O(2^n)$ restricciones SEC por variables continuas de orden de visita $u_i \in [1, n-1]$ para $i \in \{2, \dots, n\}$ (fijando el depósito en el nodo 1 con $u_1 = 0$):

$$
\begin{aligned}
\min_{x,u} \quad & \sum_{i=1}^{n} \sum_{j=1, j\neq i}^{n} c_{ij} x_{ij} \\
\text{sujeto a} \quad & \sum_{j=1, j\neq i}^{n} x_{ij} = 1, \quad \forall i \in V \\
& \sum_{i=1, i\neq j}^{n} x_{ij} = 1, \quad \forall j \in V \\
& u_i - u_j + n x_{ij} \leq n - 1, \quad \forall i, j \in \{2, \dots, n\},\ i \neq j \\
& 1 \leq u_i \leq n - 1, \quad \forall i \in \{2, \dots, n\} \\
& x_{ij} \in \{0, 1\}, \quad \forall i \neq j
\end{aligned}
$$

Demostración analítica de eliminación de subciclos: Supongamos que existe una solución factible que contiene un subciclo disjunto $C = (v_1, v_2, \dots, v_k, v_1)$ de longitud $k \geq 2$ que **no pasa por el depósito** 1 (es decir, $v_r \in \{2, \dots, n\}$ para todo $r = 1, \dots, k$).

Para cada arco (v_r, v_{r+1}) del subciclo, se tiene $x_{v_r, v_{r+1}} = 1$. Sustituyendo en la restricción MTZ:

$$u_{v_r} - u_{v_{r+1}} + n(1) \leq n - 1 \implies u_{v_r} - u_{v_{r+1}} \leq -1$$

Sumando estas k desigualdades a lo largo de todos los arcos del ciclo C:

$$\sum_{r=1}^{k} (u_{v_r} - u_{v_{r+1}}) \leq \sum_{r=1}^{k} (-1)$$

El término de la izquierda es una suma telescópica que se anula idénticamente:

$$(u_{v_1} - u_{v_2}) + (u_{v_2} - u_{v_3}) + \cdots + (u_{v_k} - u_{v_1}) = 0$$

Por tanto, obtenemos la contradicción:

$$0 \leq -k$$

Como $k \geq 2$, $-k \leq -2$, lo cual es absurdo ($0 \leq -2$). En consecuencia, no puede existir ningún subciclo cerrado que no contenga al nodo 1. ■

Comparativa: El modelo MTZ añade únicamente $(n-1)(n-2) = O(n^2)$ restricciones lineales compactas, permitiendo resolver el problema directamente en cualquier solver estándar sin necesidad de generadores de cortes dinámicos.

Ejercicio 5: Algoritmo de Aproximación de Christofides, Heurística 2-Opt y Taxonomía del VRP

Considérese un problema del Viajante de Comercio métrico simétrico definido sobre $n = 5$ vértices $V = \{1, 2, 3, 4, 5\}$ con matriz de distancias euclídeas:

$$\mathbf{D} = \begin{pmatrix} 0 & 2 & 4 & 5 & 3 \\ 2 & 0 & 3 & 4 & 4 \\ 4 & 3 & 0 & 2 & 3 \\ 5 & 4 & 2 & 0 & 2 \\ 3 & 4 & 3 & 2 & 0 \end{pmatrix}$$

Se pide:

1. **Algoritmo de aproximación de Christofides**:

   Solución:

   - **Paso 1: Árbol Soporte de Mínimo Peso (T_{MST})**: Ordenamos las aristas por coste no decreciente:
     - $\{1, 2\} = 2$ (se añade)
     - $\{3, 4\} = 2$ (se añade)
     - $\{4, 5\} = 2$ (se añade)
     - $\{1, 5\} = 3$ (se añade, conectando $\{1, 2\}$ con $\{3, 4, 5\}$) El árbol soporte mínimo es $T_{MST} = \{\{1, 2\}, \{1, 5\}, \{4, 5\}, \{3, 4\}\}$ con coste:

     $$c(T_{MST}) = 2 + 3 + 2 + 2 = 9$$

   - **Paso 2: Vértices de grado impar en T_{MST}**:
     - $d_T(1) = 2$ (aristas $\{1, 2\}, \{1, 5\}$) $\rightarrow$ Par
     - $d_T(2) = 1$ (arista $\{1, 2\}$) $\rightarrow$ **Impar**
     - $d_T(3) = 1$ (arista $\{3, 4\}$) $\rightarrow$ **Impar**
     - $d_T(4) = 2$ (aristas $\{3, 4\}, \{4, 5\}$) $\rightarrow$ Par
     - $d_T(5) = 2$ (aristas $\{1, 5\}, \{4, 5\}$) $\rightarrow$ Par El conjunto de vértices impares es $V_{odd} = \{2, 3\}$.
   - **Paso 3: Emparejamiento perfecto de peso mínimo en V_{odd}**: Al haber únicamente dos vértices impares, el único emparejamiento perfecto es la arista directa:

     $$M^* = \{\{2, 3\}\}, \quad c(M^*) = D(2, 3) = 3$$

- **Paso 4: Multigrafo euleriano y tour hamiltoniano**: Unimos el árbol y el matching:

$$H = T_{MST} \cup M^* = \{\{1,2\}, \{2,3\}, \{3,4\}, \{4,5\}, \{5,1\}\}$$

Como todos los vértices en H tienen grado 2, H forma directamente un ciclo hamiltoniano cerrado simple:

$$T_{Christofides} = (1,2,3,4,5,1)$$

Coste del tour obtenido:

$$c(T_{Christofides}) = 2+3+2+2+3 = 12$$

- **Demostración de la cota de aproximación** 3/2:

1. Sea T^* el tour óptimo del TSP. Al eliminar cualquier arista de T^*, obtenemos un camino soporte que por definición de MST satisface:

$$c(T_{MST}) < c(T^*)$$

2. Consideremos el ciclo óptimo T^* restringido a los vértices V_{odd} mediante atajos (*shortcuts*). Por la desigualdad triangular, $c(T^*_{odd}) \leq c(T^*)$. El ciclo par T^*_{odd} se puede descomponer en dos emparejamientos perfectos disjuntos M_1 y M_2 tales que $c(M_1) + c(M_2) = c(T^*_{odd}) \leq c(T^*)$. Por tanto:

$$c(M^*) \leq \min(c(M_1), c(M_2)) \leq \frac{1}{2}c(T^*)$$

3. Sumando ambas cotas:

$$c(T_{Christofides}) \leq c(T_{MST}) + c(M^*) < c(T^*) + \frac{1}{2}c(T^*) = \frac{3}{2}c(T^*)$$

El algoritmo de Christofides garantiza que la solución dista a lo sumo un 50% del óptimo global en cualquier métrica. ■

---

2. **Heurística de mejora local 2-Opt**:

Solución:

- **Tour inicial**: $T_0 = (1,3,2,4,5,1)$.

$$c(T_0) = D(1,3) + D(3,2) + D(2,4) + D(4,5) + D(5,1) = 4+3+4+2+3 = 16$$

- **Movimiento 2-Opt**: Sustituimos el par de aristas $(\{1,3\},\{2,4\})$ por el par $(\{1,2\},\{3,4\})$. Variación neta de coste:

  $$\Delta c = \big[D(1,2)+D(3,4)\big] - \big[D(1,3)+D(2,4)\big] = (2+2)-(4+4) = 4-8 = -4 < 0$$

- **Inversión de subcamino**: El subcamino intermedio $(3,2)$ se invierte a $(2,3)$, resultando el nuevo tour admisible:

  $$T_1 = (1,2,3,4,5,1)$$

  Coste actualizado: $c(T_1) = 16-4 = 12$.

---

3. **Taxonomía del Problema de Rutas de Vehículos (VRP)**:

   Solución:

   - **Clasificación topológica de servicio**:
     - **Rutas por Arcos (*Arc Routing*)**: La demanda de servicio se distribuye de forma continua a lo largo de las aristas de la red. Ejemplos industriales: recogida de basuras calle a calle, quitanieves, pintura de señalización vial e inspección de tendidos eléctricos o canalizaciones (CPP, RPP, CARP).
     - **Rutas por Nodos (*Node Routing*)**: La demanda está concentrada en clientes discretos localizados en los vértices del grafo. Ejemplos industriales: distribución de paquetería de comercio electrónico, abastecimiento de supermercados y transporte escolar (TSP, CVRP, VRPTW).
   - **Las 6 dimensiones operativas clave**:
     1. *Composición de flota*: Homogénea (vehículos idénticos) vs. heterogénea (distintas capacidades y costes operativos).
     2. *Configuración de depósitos*: Monodepósito (un único centro logístico) vs. multi-depósito (red territorial coordinada).
     3. *Naturaleza de la demanda*: Determinista (conocida antes de la ruta) vs. estocástica o dinámica (solicitudes en tiempo real).
     4. *Modalidad de transporte*: Entrega pura, recogida pura, o recogida y entrega simultánea (*Pick-up and Delivery Problem*, PDP).
     5. *Ventanas temporales*: Sin restricción horaria vs. ventanas de tiempo rígidas o flexibles para cada cliente.
     6. *Criterios de optimización*: Minimización de distancia/coste, reducción del número de vehículos necesarios o balanceo de carga de trabajo.

PARTE VI

Entorno de Software y Laboratorios

Herramientas computacionales en Python, modelado matemático y librerías científicas

Guía del entorno de experimentación computacional basado en el ecosistema científico de Python (SymPy, NumPy, SciPy, CVXPY y NetworkX). Presenta la estructura de los laboratorios prácticos, los cuadernos Jupyter interactivos y las librerías implementadas para la resolución computacional de los modelos de optimización y redes.

Víctor Aceña Gil · Antonio Alonso Ayuso
CC BY-SA 4.0 Internacional · Curso 2026-2027

Software utilizado en la asignatura

Los materiales prácticos de esta asignatura consisten en una serie de diez laboratorios desarrollados en Python y presentados en formato de cuaderno interactivo (`.qmd` de Quarto). Estos laboratorios son fundamentales para aplicar los conceptos teóricos vistos en clase, permitiendo al estudiante no solo ejecutar el código, sino también entender el razonamiento detrás de cada paso del análisis.

El código fuente completo de los laboratorios se encuentra publicado en acceso abierto y preservado digitalmente a largo plazo en **Software Heritage** para garantizar la reproducibilidad científica y la permanencia del software docente:

- **Repositorio de software:** https://github.com/URJCDSLab/OptimizacionAnalisisRedes_software
- **Identificador persistente (SWHID):** `swh:1:dir:85b3015deeb96b2949cfbeea61e1558c1c8b9504`
- **Archivo Software Heritage:** Consultar instantánea archivada

A continuación, se detalla el contenido de cada uno de los laboratorios incluidos en este repositorio.

Laboratorio 1: Introducción al Modelado y Cálculo Simbólico con SymPy

- **Descripción:** Este laboratorio introduce al estudiante en el uso del cálculo simbólico en Python mediante la biblioteca `SymPy` para obtener gradientes y matrices hessianas analíticas de forma exacta. Asimismo, se enseña el uso de `Autograd` para diferenciación automática numérica de funciones definidas por código. Por último, se aborda el estudio de la curvatura y la convexidad local y global en diversas dimensiones mediante el cálculo numérico de autovalores con `NumPy`.
- **Fichero Fuente:** `lab1_introduccion_sympy.qmd`

Laboratorio 2: Optimización No Lineal con Python

- **Descripción:** Esta sesión práctica se centra en la implementación y resolución de algoritmos de optimización continua sin y con restricciones. El alumno implementa manualmente el bucle del algoritmo de descenso de gradiente (búsqueda local de primer orden) para analizar su tasa de convergencia lineal. Posteriormente, se enseña a utilizar la biblioteca científica estándar `scipy.optimize` (en concreto, el método Quasi-Newton BFGS y el método de programación cuadrática sucesiva SLSQP). Finalmente, se introduce el modelado con `CVXPY` para optimización convexa disciplinada (DCP), destacando la facilidad de planteamiento y la obtención directa de las variables duales (multiplicadores de Lagrange) para verificar las condiciones de optimalidad de Karush-Kuhn-Tucker (KKT).
- **Fichero Fuente:** `lab2_opt_no_lineal.qmd`

Laboratorio 3: Análisis de Convexidad y Modelado con CVXPY

- **Descripción:** Este laboratorio profundiza en el análisis práctico de la convexidad y en la optimización utilizando Python. Se estudian dos vertientes principales: la verificación de la convexidad a través del análisis simbólico y numérico de los autovalores de la Hessiana mediante SymPy y NumPy, y el modelado y resolución de problemas bajo las reglas de la Programación Convexa Disciplinada (DCP) con CVXPY. A lo largo del laboratorio, se analizan las causas del error `DCPError` ante formulaciones no válidas, se estudia cómo reformular restricciones complejas (como raíces y productos cruzados) utilizando funciones atómicas como la media geométrica, y se obtienen e interpretan los multiplicadores de Lagrange (valores duales) para el análisis de sensibilidad de las restricciones.
- **Fichero Fuente:** `lab3_analisis_convexo.qmd`

Laboratorio 4: Condiciones de Optimalidad y KKT en Python

- **Descripción:** Esta sesión aborda el análisis computacional de las condiciones de optimalidad de Karush-Kuhn-Tucker (KKT) en problemas con y sin restricciones. El alumno implementa soluciones analíticas simbólicas en `SymPy` para evaluar la regularidad de las restricciones (cualificación LICQ mediante el rango de la matriz jacobiana activa), formula la ecuación de Fritz-John en casos singulares y programa la resolución combinatoria del sistema KKT derivado de las condiciones de holgura complementaria. Finalmente, contrasta los resultados analíticos con el modelado numérico en `CVXPY` y la extracción explícita de multiplicadores duales de Lagrange.
- **Fichero Fuente:** `lab4_condiciones_optimalidad.qmd`

Laboratorio 5: Dualidad KKT y Programación Cuadrática en Python

- **Descripción:** En este laboratorio se estudia la formulación y resolución práctica de la dualidad en Programación Lineal (LP) y Cuadrática (QP). El estudiante aprende a recuperar e interpretar los multiplicadores duales (precios sombra) mediante el atributo `.dual_value` en `CVXPY` para realizar análisis de sensibilidad sobre los términos independientes de las restricciones. Asimismo, implementa en Python el algoritmo del Símplex de Wolfe programando la regla de entrada restringida para garantizar la holgura complementaria y visualiza la trayectoria de convergencia sobre la región factible poliédrica.
- **Fichero Fuente:** `lab5_duales_lp_qp.qmd`

Laboratorio 6: Grafos y Árboles Soporte de Mínimo Peso en Python

- **Descripción:** Este laboratorio introduce la construcción, manipulación y análisis computacional de redes valoradas utilizando la biblioteca `NetworkX` en combinación con `NumPy` y `Matplotlib`. Se implementa la verificación numérica del *Handshaking Lemma* y el cálculo de métricas topológicas (grados, densidad, distancias geodésicas). El alumno programa desde cero la estructura de datos *Union-Find* (con compresión de caminos y unión por rango) para

implementar los algoritmos de Kruskal y Prim, finalizando con la aplicación del clustering basado en MST (*Single-linkage*) para la detección de patrones no convexos en ciencia de datos.
- **Fichero Fuente:** `lab6_grafos_arboles.qmd`

Laboratorio 7: Problemas de Camino Mínimo en Python

- **Descripción:** En este laboratorio se aborda la formulación, implementación y análisis algorítmico de problemas de camino mínimo sobre redes valoradas en Python. Se emplean las librerías `NetworkX`, `NumPy` y `CVXPY`. El estudiante programa desde cero los algoritmos de Dijkstra y Bellman-Ford con criterio de detección de circuitos de coste negativo en tiempo $O(|V| \cdot |U|)$. Asimismo, se formula el problema de flujo de coste mínimo primal-dual en `CVXPY` extrayendo los potenciales nodales duales y se programa el algoritmo de Floyd-Warshall en `NumPy` para obtener la matriz de distancias absolutas entre todos los pares de nodos.
- **Fichero Fuente:** `lab7_caminos_minimos.qmd`

Laboratorio 8: Flujos en Redes en Python

- **Descripción:** Este laboratorio se centra en la formulación, resolución y análisis computacional de problemas de flujo en redes. Utilizando `NetworkX`, el alumno modela redes de flujo dirigidas y resuelve el problema de Flujo Máximo mediante `nx.maximum_flow`, verificando el Teorema del Flujo Máximo - Corte Mínimo con `nx.minimum_cut`. Asimismo, programa problemas de Flujo a Coste Mínimo mediante `nx.min_cost_flow` y `nx.network_simplex`. Finalmente, formula el problema general de transbordo en `CVXPY` con balances nodales y cotas de capacidad, extrayendo las variables duales nodales para validar la interpretación económica de los potenciales de red.
- **Fichero Fuente:** `lab8_flujos_redes.qmd`

Laboratorio 9: Emparejamientos en Redes en Python

- **Descripción:** Esta sesión práctica aborda los problemas de emparejamiento (*matching*) y asignación en redes mediante `NetworkX` y `SciPy`. El estudiante resuelve problemas de emparejamiento bipartito de máximo cardinal (`nx.bipartite.maximum_matching`) y el problema de asignación lineal óptima con `scipy.optimize.linear_sum_assignment`. Para grafos generales no bipartitos con ciclos impares, aplica el algoritmo de la Flor de Edmonds (*Blossom*) con `nx.max_weight_matching`. Adicionalmente, calcula recubrimientos de aristas mínimos (`nx.min_edge_cover`) comprobando el Teorema de Dualidad de Gallai ($|K_0| + |F_0| = |V|$), y formula el modelo de Programación Lineal Entera (PLE) en `scipy.optimize.milp` analizando la brecha de integrabilidad.
- **Fichero Fuente:** `lab9_emparejamientos.qmd`

Laboratorio 10: Rutas Eulerianas, Hamiltonianas, TSP y VRP en Python

- **Descripción:** Este laboratorio final está dedicado a la implementación computacional de problemas clásicos de rutas en redes empleando `NetworkX`, `SciPy`, `PuLP` y `Matplotlib`. El alumno programa el algoritmo constructivo de circuitos eulerianos y resuelve el Problema del Cartero Chino (CPP) mediante emparejamiento de peso mínimo de nodos impares. Asimismo, formula y resuelve el Problema del Viajante de Comercio (TSP) como un programa lineal entero mediante el modelo compacto de Miller-Tucker-Zemlin (MTZ) en `PuLP`. Desarrolla desde cero heurísticas constructivas (Vecino más Cercano) y de búsqueda local (operador 2-Opt), evalúa el algoritmo de aproximación de Christofides (garantía de cota 1.5) y modela un problema básico de Rutas de Vehículos con Capacidad (CVRP) con flota homogénea.
- **Fichero Fuente:** `lab10_rutas.qmd`